Machine Translated by Google

Check for updates

Hindawi,
Problemas Matemáticos en Ingeniería,
Volumen 2020, Artículo ID 5965089, 11 páginas
https://doi.org/10.1155/2020/5965089

Artículo de investigación

Un método de máquina de aprendizaje de límite de ciclo profundo para entornos urbanos. Detección de incidentes de tráfico en autopistas

YunFeng Fang y [1,2] Qingfang Yang [1,2] Lili Zheng, [1,2] Xiangyu Zhou [1,2]
Bo Peng [1,2]

[1]Departamento de Ingeniería de Información y Control de Tráfico, Universidad de Jinlin, Changchun, China
[2]Centro de Investigación de Ingeniería de Jilin para Sistemas Inteligentes de Transporte (ITS), Changchun 130022, China

La correspondencia debe dirigirse a Lili Zheng; lilizheng@jlu.edu.cn

Recibido el 16 de diciembre de 2019; Aceptado el 26 de mayo de 2020; Publicado el 15 de julio de 2020

Editor académico: Mariko Nakano-Miyatake

Copyright © 2020 YunFeng Fang et al. - es un artículo de acceso abierto distribuido bajo la Licencia Creative Commons Atribución, que permite el uso, la distribución y la reproducción sin restricciones en cualquier medio, siempre que se cite correctamente la obra original.

En Beijing, Shanghai, Hangzhou y otras ciudades de China, la congestión del tráfico causada por incidentes de tráfico también representa entre el 50% y el 75% de la congestión total del tráfico en las autopistas. Por lo tanto, es de gran importancia estudiar un algoritmo de detección automática de incidentes de tráfico preciso y oportuno para garantizar la eficiencia operativa de las autopistas y mejorar el nivel de seguridad vial. Actualmente, se han propuesto muchos algoritmos eficaces de detección automática de eventos, pero los algoritmos existentes generalmente toman los parámetros originales del flujo de tráfico como variables de entrada, ignorando la construcción de conjuntos de variables de características y la selección de variables de características importantes. Este artículo presenta un algoritmo de detección automática de eventos basado en una máquina de aprendizaje de límite de ciclo profundo. El flujo de tráfico, la velocidad y la ocupación de la autopista urbana aguas abajo se extraen como valores de entrada de la red neuronal de bucle profundo. Los pesos de conexión iniciales y los umbrales de salida de la red neuronal de bucle profundo se optimizan utilizando el algoritmo de optimización de enjambre de partículas (PSO) mejorado para la búsqueda global. Se entrena una mayor precisión de clasificación de la máquina de aprendizaje extremo y se mejora el rendimiento de generalización de la máquina de aprendizaje extremo. Además, la máquina de aprendizaje extremo se utiliza como unidad de aprendizaje para el aprendizaje no supervisado capa por capa. Finalmente, los datos del detector de microondas del viaducto de Tangqiao en Hangzhou se utilizan para verificar el experimento y se comparan con LSTM, CNN, árbol de regresión con gradiente mejorado, SVM, BPNN y otros métodos. Los resultados muestran que el algoritmo puede transferir características de bajo nivel capa por capa para formar una representación de características más completa, conservando más información de entrada original. Puede ahorrar costosos recursos computacionales y reducir la complejidad del modelo. Además, la precisión de detección del algoritmo es alta, la tasa de detección es superior al 98% y la tasa de falsas alarmas es inferior al 3%. Es mejor que LSTM, CNN, árbol de regresión con gradiente mejorado y otros algoritmos. Es adecuado para la detección de incidentes de tráfico en autopistas urbanas.

1. Introducción

La situación del tráfico rodado en China es extremadamente grave. Con el rápido desarrollo del tráfico rodado urbano, el número de propietarios de automóviles y conductores de vehículos motorizados muestra una tendencia de rápido crecimiento, lo que ha provocado que los incidentes de tráfico rodado mantengan una base alta y una alta tasa de accidentes durante muchos años. Más del 50% de la congestión del tráfico rodado urbano en Shanghái, China, es causada por incidentes de tráfico en autopistas. La congestión causada por accidentes de tráfico en las autopistas reducirá la capacidad de las mismas, afectará a su eficiencia operativa y provocará graves accidentes de tráfico, poniendo en peligro la vida y la propiedad de las personas. Por lo tanto, es necesario estudiar el algoritmo de detección de la congestión en autopistas.

Los incidentes de tráfico mejoran la gestión de los incidentes de tráfico en las autopistas, permiten detectar y abordar los incidentes de tráfico a tiempo y reducen el impacto de los incidentes de tráfico en el tráfico de las autopistas urbanas.

En el aspecto de la detección de incidentes de tráfico, muchos expertos y académicos han realizado estudios de investigación y se han aplicado algunos logros. En [1], el Instituto de Transporte de Texas (TTI) desarrolló un algoritmo de desviación normal estándar. Este algoritmo establece un valor de desviación estándar. Si se detecta que el volumen de tráfico supera este valor, el sistema concluye que se producen incidentes de tráfico. El algoritmo de desviación normal estándar se aplica a la autopista de la Bahía de Houston. En [2], basándose en la teoría de catástrofes de -om, el Departamento de Ingeniería Civil de Michigan

Machine Translated by Google

La Universidad de Canadá desarrolló el algoritmo McMaster. La base de este algoritmo es que cuando la condición del tráfico cambia de un estado de congestión a un estado de no congestión, el cambio de ocupación y tasa de flujo no es obvio, pero el cambio de velocidad sí lo es. En [3], Hsiao et al. propusieron el esquema de usar lógica difusa para resolver la detección de incidentes de tráfico. El método de lógica difusa no puede determinar con precisión si hay incidentes de tráfico o no, sino que solo puede dar la probabilidad de incidentes de tráfico. En [4], Abdulhai y Ritchie introdujeron la red neuronal probabilística en la detección de incidentes de tráfico y llevaron a cabo un análisis de simulación con datos reales (bases de datos I-880 e I-35W). Los resultados muestran que el modelo puede mejorar significativamente la tasa de detección y cumplir con los requisitos de rendimiento de la detección de incidentes de tráfico. En [5], Yuan y Cheu intentaron usar máquinas de vectores de soporte (SVM) para detectar incidentes de tráfico. Se desarrollaron y probaron tres modelos SVM con la base de datos de tráfico I-880. Los resultados muestran que el rendimiento de detección es tan bueno como MLF. En el contexto de los macrodatos y el transporte inteligente, los algoritmos mencionados anteriormente suelen ser engorrosos en cuanto a cálculos, poco generales, con baja eficiencia de detección, baja precisión del modelo y no adecuados para grandes conjuntos de datos.

La máquina de aprendizaje extremo (ELM, por sus siglas en inglés) es un nuevo algoritmo de aprendizaje para redes neuronales de alimentación directa de una sola capa. ELM selecciona aleatoriamente pesos de entrada sin ajustarlos y calcula pesos de salida a través de la matriz inversa generalizada de Moore-Penrose. ELM tiene una velocidad de entrenamiento más rápida y una mayor capacidad de generalización y evita caer en mínimos locales. Para reducir el tiempo consumido en determinar el número de neuronas ocultas y asignar aleatoriamente pesos entre las máquinas de aprendizaje extremo propuestas por Huang et al. [6], el rendimiento y la velocidad de aprendizaje se pueden aumentar mediante cientos de redes neuronales de alimentación directa de una sola capa oculta. -e parámetros de los nodos de la capa oculta de la máquina de aprendizaje extremo se generan aleatoriamente de acuerdo con la distribución de probabilidad continua, y los parámetros de los nodos de la capa oculta son independientes de las muestras de entrenamiento. -ey no necesitan ser ajustados iterativamente en el proceso de entrenamiento. -ey tienen las características de una velocidad de entrenamiento rápida y una fuerte capacidad de generalización del modelo. -por lo tanto, en comparación con el método de red neuronal tradicional, ELM muestra ventajas obvias en problemas de clasificación y puede mantener un buen rendimiento de aprendizaje [7]; La velocidad de aprendizaje puede incrementarse cientos o incluso miles de veces, lo que resulta beneficioso para resolver problemas de detección de incidentes de tráfico en el contexto de grandes volúmenes de datos.

El aprendizaje profundo, o redes neuronales profundas, es la última línea de investigación en el campo del aprendizaje automático. Permite extraer en profundidad las características de distribución de grandes conjuntos de datos de tráfico y aplicarlas a la detección de incidentes de tráfico, lo que mejora considerablemente la precisión de dicha detección. Sin embargo, con el aumento de las capas de la red, su eficiencia de entrenamiento se reduce en gran medida y aumenta la probabilidad de que el modelo caiga en un óptimo local. En cuanto a la dificultad del entrenamiento, en [8], Springenberg adopta el modelo de red neuronal heterogénea para reemplazar la capa de convolución y la capa de agrupación en la red neuronal convolucional tradicional. Modelo de red con la capa de convolución cíclica del paso 2. Se utiliza el algoritmo de descenso de gradiente aleatorio por lotes -e para entrenar el modelo de red neuronal convolucional compleja actual para lograr el rendimiento de clasificación y detección, pero la dificultad del entrenamiento aumenta. En [9], Zhang et al. propusieron un marco de extracción de relaciones basado en RNN. El modelo -e de relación de larga distancia se construye mediante RNN bidireccional. Los experimentos en dos conjuntos de datos muestran que el modelo basado en RNN bidireccional es mejor que el basado en CNN, pero la eficiencia del entrenamiento es menor.

Para resolver los problemas anteriores, Huang Guangbin, fundador de la máquina de aprendizaje extremo, propuso un algoritmo de máquina de aprendizaje extremo multicapa profundo. La estructura de red neuronal multicapa permite extraer información abstracta de alto nivel de los datos. Al mismo tiempo, puede resolver eficazmente los problemas de alta dimensión de datos, etiquetado de muestras difícil, construcción de características compleja y entrenamiento complejo en la era del big data. La literatura [10] introduce por primera vez la combinación de la máquina de aprendizaje extremo y el autoencoder. Se cree que la capacidad de expresión de características de ELM-AE puede proporcionar una buena solución para la red neuronal multicapa de alimentación directa.
Además, en comparación con la red profunda más avanzada, la red multicapa basada en ELM puede proporcionar un mejor rendimiento. El documento

[11] considera que la arquitectura profunda puede obtener una representación de características de nivel superior y, por lo tanto, obtener información abstracta de nivel superior. Por consiguiente, se propone un modelo de máquina de aprendizaje extremo multicapa, que aprende la representación profunda de los datos a través de la máquina de aprendizaje extremo según la teoría de generalización de pila. En primer lugar, este artículo utilizará parámetros de flujo de tráfico y su combinación para construir un conjunto de variables inicial para la detección de incidentes de tráfico. Se utiliza la medida de importancia de variables de bosque aleatorio para seleccionar las variables características para la detección de incidentes de tráfico, y el modelo de máquina de aprendizaje de límite de ciclo profundo se utiliza para entrenar las variables características. Finalmente, el rendimiento del modelo se analiza con datos reales de autopista.

2. Descripción de los datos y selección de variables

La adquisición de datos de flujo de tráfico y datos de incidentes de tráfico es de gran importancia para el estudio de la detección de incidentes de tráfico. Los datos de flujo de tráfico obtenidos en este documento provienen principalmente de los datos del detector de microondas recopilados por el centro de monitoreo de la autopista urbana de Hangzhou en la sección del viaducto de Hangzhou durante 5 meses (del 11 de junio de 2015 al 11 de noviembre de 2015). Entre ellos, el intervalo de muestreo [12] de los datos de detección de tráfico por microondas es de 1 minuto, y el contenido de los datos recopilados es número de serie, número de detector fijo, fecha, hora, flujo, velocidad y tiempo de ocupación. La fuente de información de incidentes de tráfico es la información de incidentes de autopista publicada por la red de información de tráfico de Hangzhou. El estudio registró 223 piezas de información principal de incidentes de tráfico de la autopista de Hangzhou del 11 de junio al 11 de noviembre de 2015, incluidas 107 piezas de información de incidentes de tráfico efectivos. La información de incidentes de tráfico incluye número de serie, fecha, hora, longitud y latitud. Al anali

2629, 2020, 1, Descargado de https://onlinelibrary.wiley.com/doi/10.1155/2020/5965089 por Cochrane Perú, Wiley Online Library el [02/05/2026]. Consulte los Términos y condiciones (https://onlinelibrary.wiley.com/terms-and-conditions) en Wiley Online Library para conocer las reglas de uso; los artículos de acceso abierto se rigen por la Licencia Creative Commons aplicable.

Machine Translated by Google

En el algoritmo de detección de eventos, necesitamos hacer coincidir la información del evento con los datos del detector fijo en el espacio. Primero, debemos localizar la ubicación del evento en el mapa de Hangzhou y luego encontrar el número del detector fijo aguas arriba y aguas abajo correspondiente, y seleccionar los datos del detector fijo correspondientes según la ubicación y el período de tiempo del evento. Entre ellos, la ocurrencia del evento se marca con 1 y la ausencia de ocurrencia con 0. Algunos formatos de datos después del preprocesamiento se muestran en la Tabla 1.

La base de la detección de incidentes de tráfico radica en la alteración del flujo normal causada por dichos incidentes. Por lo tanto, antes de construir el algoritmo de detección de incidentes, es necesario analizar las características del flujo de tráfico durante el evento para determinar los parámetros característicos del modelo. Basándonos en la teoría de la fluctuación del flujo vehicular, este artículo analiza el impacto de los eventos de tráfico en las características del flujo de tráfico [13], a partir de las cuales se construye el conjunto de variables de características para la detección de eventos y se seleccionan los parámetros característicos importantes.

Para analizar las características del flujo de tráfico en el estado del evento, se seleccionan aleatoriamente 50 grupos de 107 grupos de datos de eventos de tráfico para validación cruzada para analizar el impacto de los eventos de tráfico en las características del flujo de tráfico, para así eliminar la interferencia de la hora del día, la ubicación del detector, el tipo y la ubicación del evento, la señal aguas abajo de la rampa de salida y otros factores. -a

través de una gran cantidad de datos de validación cruzada del detector y datos de eventos, se puede encontrar que el impacto de los eventos de tráfico en el flujo de tráfico conducirá directamente al cambio de los parámetros del flujo de tráfico (como flujo, velocidad, densidad y ocupación) en los puntos del evento y secciones aguas arriba y aguas abajo. -por lo tanto, el cambio significativo de los parámetros del flujo de tráfico durante el período de ocurrencia del evento es la base básica para el diseño del algoritmo de detección automática de eventos de tráfico. Entre ellos, la tendencia de cambio de los parámetros del flujo de tráfico aguas arriba y aguas abajo de la ubicación del evento se muestra en las Figuras 1 y 2, respectivamente. En las Figuras 1 y 2, Q es el flujo de tráfico, O es la tasa de ocupación y v es la velocidad.

En la Figura 1, cuando ocurre un accidente de tráfico en un tramo, el caudal y la velocidad registrados por el detector situado aguas arriba en el lugar del accidente disminuyen drásticamente, y la tasa de ocupación aumenta bruscamente.

En la Figura 2, cuando ocurre un accidente de tráfico en un tramo, el flujo registrado por el detector aguas abajo disminuye, la velocidad aumenta y la tasa de ocupación disminuye. Por lo tanto, la combinación de diferentes parámetros de tráfico y la combinación de detectores superiores e inferiores también muestran una alta sensibilidad a la ocurrencia de incidentes de tráfico.

En este documento, se construye un conjunto completo de variables iniciales basado en los valores medidos, predichos y combinados de los parámetros de flujo de tráfico en las áreas aguas arriba y aguas abajo. El conjunto de variables iniciales consta de siete partes: (1) los parámetros básicos de tráfico obtenidos realmente por el detector aguas arriba; (2) los parámetros básicos de tráfico obtenidos realmente por el detector aguas abajo; (3) la relación de combinación de los parámetros de tráfico reales del detector aguas arriba; (4) el grupo de los parámetros de tráfico reales del detector aguas abajo; (5) la relación de los parámetros de flujo de tráfico medidos y los predichos. parámetros del detector aguas arriba; (6) la relación de los parámetros de flujo de tráfico medidos y los parámetros predichos del detector aguas abajo; (7) la relación de los parámetros de flujo de tráfico medidos y los parámetros predichos del detector aguas abajo. -e relación de los parámetros de flujo de tráfico medidos del detector adyacente se muestra en la Tabla 2. -e valores predichos de los parámetros de flujo de tráfico se obtienen mediante el método de promedio móvil, y el quinto dato se predice utilizando los primeros cuatro datos adyacentes. -Hay 18 conjuntos de variables iniciales en la Tabla 2, que cubren exhaustivamente las

características del evento. Pero, en la aplicación práctica, hay demasiadas variables y la información que se necesita procesar es redundante. Aumenta la dificultad del modelado. -Por lo tanto, es necesario filtrar las variables características para reducir la complejidad de la construcción del modelo. El bosque aleatorio es una forma eficaz de reducir la dimensión de los datos [14] y mejorar la precisión de la clasificación de datos. Se utiliza ampliamente para medir la importancia de las variables. También es adecuado para resolver el problema de filtrar las variables importantes. La técnica de muestreo aleatorio Bootstrap y la técnica de división aleatoria de nodos se utilizan para extraer el nuevo conjunto de muestras

del conjunto de entrenamiento y establecer el modelo de número de decisión. Cuando los bosques aleatorios se muestrean mediante Bootstrap, se genera aproximadamente el 36,8 % de los datos "fuera de la bolsa" a la vez (Out of Bag, OOB). El uso de OOB como conjunto de prueba para evaluar el rendimiento predictivo de RF se denomina estimación OOB. La estimación OOB es insesgada cuando el número de árboles en RF es suficientemente grande.

Para los bosques aleatorios generados, asumimos que el número total de muestras OOB es NOOB. Cuando se utiliza OOB como conjunto de prueba para evaluar el rendimiento de la clasificación FE para bosques estocásticos, el número correcto de muestras probadas es kOOB. La fórmula de precisión de clasificación AccOOB es la siguiente:

$$\text{AccOOB} \quad \frac{\text{transmisión exterior}}{\text{NOVATO}}. \tag{1}$$

La medición de la importancia de las características es una característica importante de los bosques aleatorios (RF) y puede utilizarse como herramienta de selección de características para datos de alta dimensión. La disminución media de la precisión (MDA) es un índice importante para medir la importancia de las características. Supongamos que la muestra Bootstrap es B1, B2, . . . , Bn (n es el número de muestras de entrenamiento) y la característica es X1, X2, . . . , Xm (m es la dimensión de la característica). Los pasos para calcular la medida de importancia de la característica son los siguientes: Paso 1.

Establecer i = 1, crear un árbol de decisión Ti en la muestra de entrenamiento y marcar los datos de salida del bolsillo como OOBi .

Paso 2. Elija OOBi como conjunto de prueba, aplique Ti para clasificarlo y marque el número correcto de predicciones como AccOOBi .

Paso 3. Para cada característica X en OOBi , agregue ruido artificial al conjunto de datos y regístrelo como $\text{OOB}(1)_i$. Aplique Ti para clasificarlo y marque el número correcto de predicciones como $\text{AccOOB}(1)_i$.

Paso 4. Para i = 2 , 3, ... , n, repita los pasos 1 a 3.

2629, 2020, 1, Descargado de https://onlinelibrary.wiley.com/doi/10.1155/2020/5965089 por Cochrane Peru, Wiley Online Library el [02/05/2026]. Consulte los Términos y condiciones (https://onlinelibrary.wiley.com/terms-and-conditions) en Wiley Online Library para conocer las reglas de uso; los artículos de acceso abierto se rigen por la Licencia Creative Commons aplicable.

Machine Translated by Google

2629, 2020, 1, Descargado de https://onlinelibrary.wiley.com/doi/10.1155/2020/5986089 por Cochrane Peru, Wiley Online Library el [02/05/2028]. Consulte los Términos y condiciones (https://onlinelibrary.wiley.com/terms-and-conditions) en Wiley Online Library para conocer las reglas de uso; los artículos de acceso abierto se rigen por la Licencia Creative Commons aplicable.

Tabla 1: Algunos datos utilizados para la detección de incidentes de tráfico.

Datos del detector de microondas							
Tiempo	Sección aguas arriba			Sección aguas abajo			Etiqueta
	Caudal (pcu/min)	Velocidad (km/h)	Ocupación (%)	Caudal (pcu/min)	Velocidad (km/h)	Ocupación (%)	
10:03	40	68,43	24.51	42	67,65	23.7	0
10:04	44	69,54	19.8	48	72.03	20.6	0
10:05	38	76,75	23.6	41	74,12	21.2	0
10:06	25	24.12	75	56	68,24	12.6	1
10:07	22	16.45	72.4	45	73.45	11.3	1
. . .	. . .	. . .	. . .	. . .	. . .	. . .	. . .

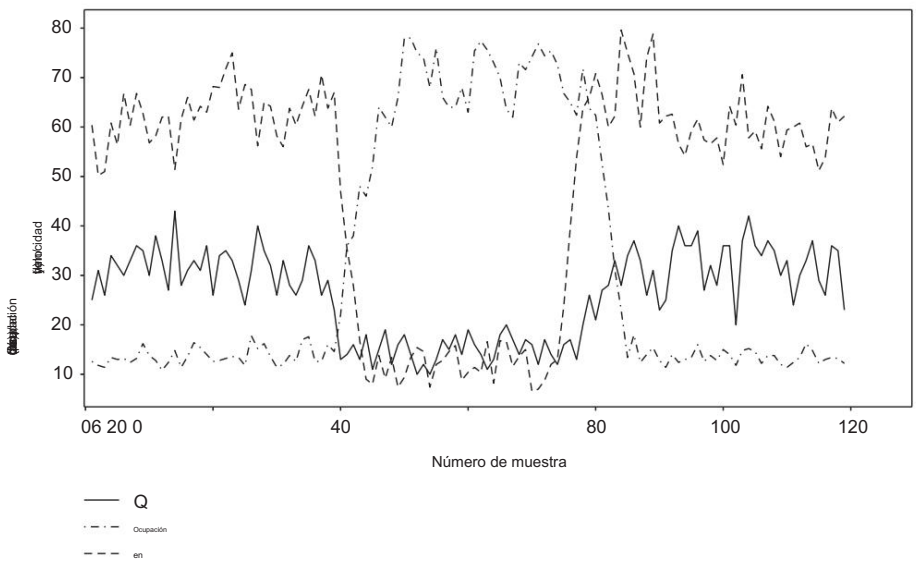


Figura 1: Cambio en los parámetros del flujo de tráfico para los detectores aguas arriba.

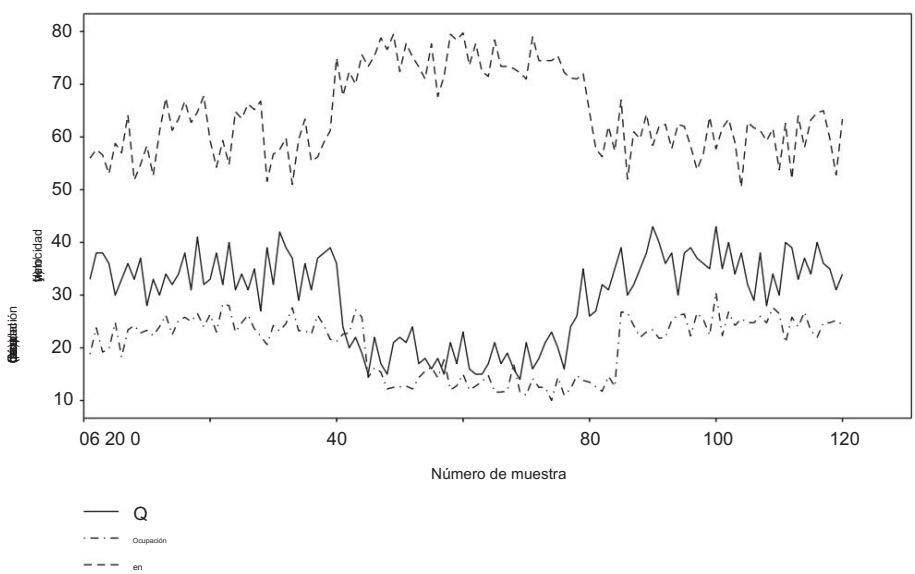


Figura 2: Cambio de los parámetros de flujo de tráfico para el detector aguas abajo.

Machine Translated by Google

2629, 2020, 1, Descargado de https://onlinelibrary.wiley.com/doi/10.1155/2020/5965089 por Cochrane Perú, Wiley Online Library el [02/05/2026]. Consulte los Términos y condiciones (https://onlinelibrary.wiley.com/terms-and-conditions) en Wiley Online Library para conocer las reglas de uso; los artículos de acceso abierto se rigen por la Licencia Creative Commons aplicable.

Tabla 2: Conjunto de variables iniciales para la detección de incidentes de tráfico.

Número de serie variable	Variable inicial
1	Caudal medido del detector aguas arriba
2	Velocidad medida del detector aguas arriba
3	Ocupación medida del detector aguas arriba
4	Caudal medido del detector aguas abajo
5	Velocidad medida del detector aguas abajo
6	Ocupación medida de los detectores posteriores
7	Relación entre ocupación y flujo medida simultáneamente por el mismo detector.
8	Relación entre ocupación y velocidad medidas simultáneamente por el mismo detector.
9	Relación entre el caudal y la velocidad medida simultáneamente por el mismo detector.
10	Relación entre el caudal medido y el caudal previsto del detector aguas arriba
11	Relación entre la velocidad medida y la velocidad prevista del detector aguas arriba.
12	Relación entre la tasa de ocupación medida y la tasa de ocupación prevista del detector aguas arriba.
13	Relación entre el caudal medido y el caudal previsto del detector aguas abajo
14	Relación entre la velocidad medida y la velocidad prevista del detector aguas abajo.
15	Relación entre la tasa de ocupación medida y la tasa de ocupación prevista del detector posterior.
16	Relación de flujo de detectores adyacentes aguas arriba y aguas abajo al mismo tiempo.
17	Relación de velocidad de los detectores adyacentes aguas arriba y aguas abajo al mismo tiempo.
18	Relación de ocupación de adquisición de detectores adyacentes aguas arriba y aguas abajo al mismo tiempo.

Paso 5. Para medir la importancia de la característica Xj, se debe
Se puede calcular mediante la siguiente fórmula:

$$\frac{1}{\text{MDAs}} \frac{1}{n} \sum_{i=1}^{n} \text{AccOOBi} - \text{AccOOB}(1)_i . \quad (2)$$

3. Método del límite de ciclo profundo Máquina de aprendizaje

La red neuronal convolucional cíclica consta de una capa de entrada, capa de convolución cíclica y capa de salida. Puede extraer La clasificación se realiza capa por capa mediante una capa de convolución cíclica y una capa de muestreo. La última capa es softmax. clasificador no lineal. -e Los pesos y sesgos de la red neuronal convolucional cíclica se entrenan mediante el algoritmo de Newton, cruzar la función de costo de entropía como la función objetivo de entrenamiento de red neuronal convolucional cíclica e iterativamente buscando la solución óptima mínima del objeto Función de la red neuronal convolucional cíclica. - Característica e La extracción es una parte del diseño completo del clasificador. -por lo tanto, Es ventajoso extraer características de la convolución cíclica. red neuronal como entrada de la máquina de aprendizaje límite. -e La máquina de aprendizaje extremo es una red neuronal de una sola capa oculta. red. Sus pesos de capa de entrada y valores de desplazamiento se generan aleatoriamente durante el proceso de inicialización. -en, el sesgos de peso desde la capa oculta a la capa de salida [15] se calculan utilizando el método inverso generalizado basado sobre la relación entre el resultado deseado y la entrada. Porque el desplazamiento de peso de la máquina de aprendizaje extremo es Calculado sin entrenamiento, la velocidad de entrenamiento de la máquina de aprendizaje extremo es más rápida. En el proceso de extracción Características del objetivo de la imagen, la red neuronal convolucional circular extrae mejor las características del objetivo de la imagen, por lo que el efecto de clasificación de la máquina de aprendizaje extremo de la circular La red neuronal convolucional es buena.

En la Figura 3, este artículo combina la convolución cíclica red neuronal con máquina de aprendizaje extremo y construye la máquina de aprendizaje extremo basada en el ciclo red neuronal convolucional para clasificar el objetivo de la imagen, que aprovecha al máximo las características del cíclico red neuronal convolucional para extraer las características abstractas y destacadas del objetivo de la imagen y el cálculo rápido de la máquina de aprendizaje extremo. En la Figura 4, el aprendizaje límite Modelo de máquina basado en red neuronal convolucional cíclica Consta de tres partes:

(1) La red neuronal convolucional cíclica está compuesta por capa de entrada, capa de convolución cíclica y salida capa de agrupación. Se utiliza el método cuasi-Newton. entrenar una red neuronal convolucional cíclica para realizar Extracción de características del objetivo de la imagen.

(2) Se utiliza una red neuronal convolucional cíclica para extraer las características de los objetos de la imagen como capa de entrada de la máquina de aprendizaje extremo para calcular los parámetros de la máquina de aprendizaje extremo.

(3) Utilizar una máquina de aprendizaje extremo para clasificar imágenes objetos.

-e algoritmo combinado de red neuronal convolucional y la máquina de aprendizaje extremo es la siguiente: entrenamiento de entrada datos de muestra, información de etiqueta de clase del objetivo y salida Modelo de entrenamiento de una red neuronal convolucional cíclica.

Porque el objetivo inicial de la máquina de aprendizaje extremo es resolver una red neuronal de alimentación directa de una sola capa oculta, asumiendo que una red neuronal de una sola capa oculta tiene N muestras, una red neuronal de una sola capa oculta con L capas ocultas Los nodos pueden expresarse como

$$\sum_{i=1}^{L} \beta_i g(w_i \cdot x_j + b_i) = o_j, \quad j = 1, \ldots, N. \quad (3)$$

En la fórmula (3), g(x) es la función de activación; wi $[w_{i1}, w_{i2}, \ldots, w_{in}]^T$ es la variable de peso de entrada; βi es la peso de salida; bi es el sesgo de la neurona de la capa oculta.

-en la función objetivo del aprendizaje mínimo El error de salida de la red neuronal de una sola capa oculta puede ser expresado como

Machine Translated by Google

2629, 2020, 1, Descargado de https://onlinelibrary.wiley.com/doi/10.1155/2020/5965089 por Cochrane Perú, Wiley Online Library el [02/05/2026]. Consulte los Términos y condiciones (https://onlinelibrary.wiley.com/terms-and-conditions) en Wiley Online Library para conocer las reglas de uso; los artículos de acceso abierto se rigen por la Licencia Creative Commons aplicable.

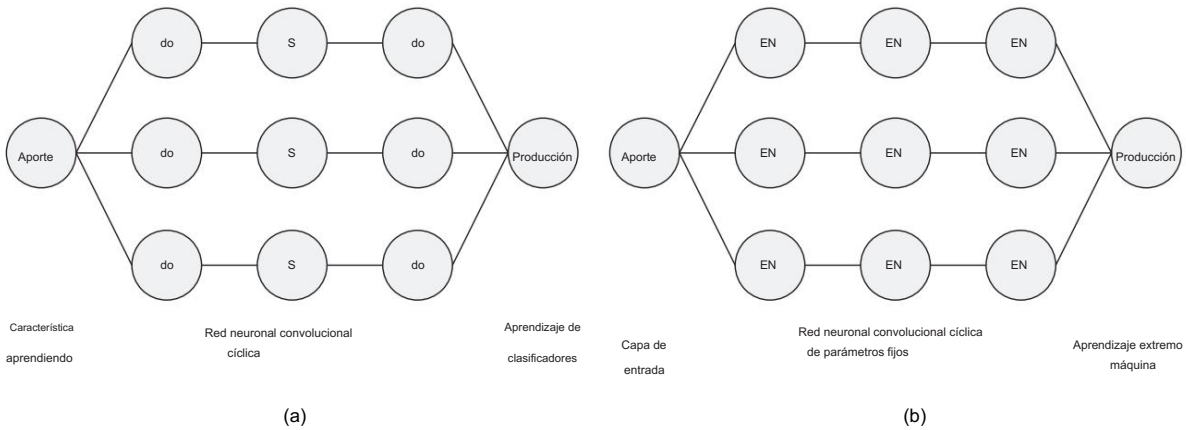


Figura 3: Entrenamiento de una máquina de aprendizaje extremo de ciclo profundo.

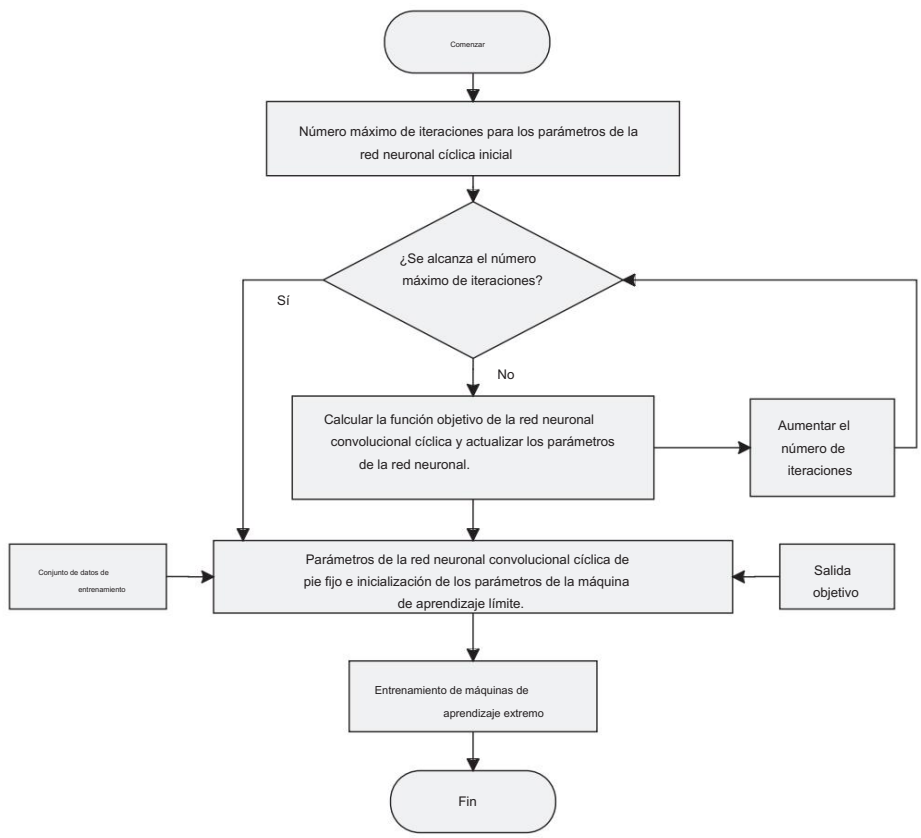


Figura 4: Entrenamiento de una máquina de aprendizaje extremo de ciclo profundo.

$$\sum_{j=1}^{n} o_{h,t_j} \tag{4}$$

-por lo tanto, la función objetivo del aprendizaje extremo La máquina puede expresarse como

$$H\beta = T, \tag{5}$$

donde H es la salida de los nodos ocultos, β es el peso de salida y T es la salida esperada.

Durante el proceso de entrenamiento, el gradiente del método de Newton cerca del punto de silla disminuye lentamente y cae fácilmente en un óptimo local, lo que dificulta el entrenamiento del modelo. El método de Newton necesita calcular la matriz negra de la función objetivo (hessiana) en el proceso de cálculo, y no puede garantizar que la matriz negra de la función objetivo sea siempre definida positiva. -e La derivada parcial de segundo orden de

la función objetivo necesita ser calculada, lo cual es demasiado grande y difícil de almacenar, por lo que la dirección del algoritmo no

Machine Translated by Google

2629, 2020, 1, Descargado de https://onlinelibrary.wiley.com/doi/10.1155/2020/6565089 por Cochrane Perú, Wiley Online Library el [02/05/2026]. Consulte los Términos y condiciones (https://onlinelibrary.wiley.com/terms-and-conditions) en Wiley Online Library para conocer las reglas de uso; los artículos de acceso abierto se rigen por la Licencia Creative Commons aplicable.

no siempre desciende. -us, el método de Newton falla. Para resolver este problema, se adopta un algoritmo BFGS mejorado basado en el método cuasi-Newton.

El algoritmo de Newton actualiza los parámetros del modelo de red neuronal de bucle profundo en el proceso de optimización de la siguiente manera:

$$wi+1 \quad w\,wi - \frac{jw}{2jw\,.} \tag{6}$$

Para superar las deficiencias del método de Newton, se adopta la ecuación cuasi-Newton y el valor inicial de la segunda derivada se reemplaza por la aproximación b: bk+1sk yk . (7)

Para optimizar mejor la función objetivo no convexa, se adopta el algoritmo de Newton mejorado de la siguiente manera:

$$bk+1 \quad bk - \frac{bksksTkbk}{sT\,bksk} + \frac{ykyTk}{yT_{\text{esquiar}}}. \tag{8}$$

En términos generales, los pesos w y el desplazamiento b de las neuronas ocultas en la máquina de aprendizaje extremo se establecen mediante una red neuronal de una sola capa oculta utilizando un método aleatorio. En este artículo, el conjunto de entrenamiento de la red neuronal convolucional cíclica se utiliza para aprender las características del objetivo como entrada de la máquina de aprendizaje límite de una sola capa oculta, y los pesos de las neuronas de la red neuronal de una sola capa oculta se establecen calculando la salida esperada del objetivo.

4. Estudio de caso

4.1. Entorno experimental. Para verificar el experimento de prueba de rendimiento del algoritmo de detección de eventos de tráfico en autopistas propuesto, el entorno experimental se muestra en la Tabla 3. La base de datos -e incluye 107 eventos

de tráfico (10294 muestras en total). Se seleccionan aleatoriamente 55 datos de eventos de tráfico para el entrenamiento y los 52 datos de eventos de tráfico restantes se utilizan para la prueba. Debido a que la cantidad de datos sin eventos es demasiado grande, las muestras sin eventos generalmente se seleccionan aleatoriamente para construir el conjunto de entrenamiento y el conjunto de prueba. Para conservar la información de las muestras sin eventos en gran medida, se utilizan el conjunto de entrenamiento y el conjunto de prueba. La proporción de muestras de eventos en el conjunto de prueba se establece en 20%. La composición del conjunto de entrenamiento y del conjunto de prueba se muestra en la Tabla 4.

En la práctica, el número de muestras de eventos de tráfico es mucho menor que el número de muestras sin eventos, y el número de muestras de ambos tipos está desequilibrado. Por lo tanto, la detección de incidentes de tráfico puede considerarse un problema de clasificación binaria de datos desequilibrados. La técnica de muestreo sintético de la clase minoritaria (SMOTE) es una técnica de sobremuestreo de uso común. SMOTE puede generar nuevas muestras que no existen en la muestra original. Por lo tanto, hasta cierto punto, evita el hiperajuste del algoritmo de clasificación. Se utiliza SMOTE estándar para equilibrar la muestra de detección de incidentes de tráfico. Los pasos específicos son los siguientes:

Tabla 3: Configuración del entorno experimental.

Proyecto	valores ambientales
Servidor	Dell PowerEdge T640
Procesador	Procesador Intel® Xeon® Bronze 3106 a 1,70 GHz 128
Memoria	GB 4
Tarjeta de video	GeForce RTX 2080 Ti Ubuntu
Sistema operativo	16.04 Python 3.6,
Entorno de desarrollo	TensorFlow, Keras

(1) Para cada muestra en el conjunto de muestras de eventos xi , utilice la distancia europea como medida para buscar K muestras en el conjunto de muestras de eventos más cercanas a la muestra. (2) La tasa de muestreo N se determina en función de la proporción entre el número de muestras sin eventos y el número de muestras con eventos, y se seleccionan aleatoriamente N muestras de las K muestras vecinas más cercanas de cada muestra de evento, denotadas como xij.

(3) Según la fórmula (1), se utiliza una interpolación lineal aleatoria entre muestras de vecinos más cercanos seleccionadas aleatoriamente xij y muestras de eventos xi para construir una nueva muestra de evento:

$$xnew \quad xi + rand(0, 1) \times xij - xi\,. \tag{9}$$

En la ecuación, rand(0, 1) representa un número aleatorio que pertenece a un intervalo amplio de 0,1.

(4) Fusionar la muestra de evento recién generada con el conjunto de muestras original para obtener un conjunto de muestras de entrenamiento relativamente equilibrado.

Para lograr un equilibrio relativo entre los dos tipos de muestras, se utiliza SMOTE para aumentar la muestra de eventos de tráfico en el conjunto de entrenamiento. Los parámetros específicos de SMOTE se configuran de la siguiente manera: el número de puntos de muestra adyacentes es 5 y la tasa de sobremuestreo es 30 000. El número de muestras en el conjunto de entrenamiento equilibrado es 20 360. Para eliminar los efectos de las diferentes dimensiones, mejorar la velocidad de entrenamiento y el efecto de clasificación, y normalizar los datos al intervalo [0, 1], la fórmula de normalización es:

$$yi \quad \frac{xi - xmin}{xmax - xmin}, \tag{10}$$

En la fórmula, xi son los datos originales, yi son los datos normalizados, xmax es el valor máximo de los datos originales y xmin es el valor mínimo de los datos originales.

4.2. Partición del conjunto de datos y filtrado de variables. - Los parámetros básicos del flujo de tráfico, a saber, el flujo de tráfico, la velocidad y la ocupación, se pueden obtener mediante un detector de microondas remoto. - El intervalo de muestreo de los datos es de 5 minutos. Al analizar la tendencia de cambio de los parámetros del flujo de tráfico, se filtraron artificialmente 123 incidentes de tráfico en la carretera principal, de los cuales 71 ocurrieron en el lado este y 52 en el lado oeste.

Los datos de incidentes de tráfico se clasifican según la línea principal este, la línea principal oeste y el tramo completo de la carretera. -ree

Machine Translated by Google

2629, 2020, 1, Descargado de https://onlinelibrary.wiley.com/doi/10.1155/2020/5965089 por Cochrane Perú, Wiley Online Library el [02/05/2026]. Consulte los Términos y condiciones (https://onlinelibrary.wiley.com/terms-and-conditions) en Wiley Online Library para conocer las reglas de uso; los artículos de acceso abierto se rigen por la Licencia Creative Commons aplicable.

Tabla 4: Composición de la muestra del conjunto de entrenamiento y del conjunto de prueba.

Categorías de conjuntos de datos	Tamaño total de la muestra	Número de muestra del evento	Número de evento
Conjunto de entrenamiento	26190	5240	55
Conjunto de prueba	22978	4595	52

Los conjuntos de datos de muestra se forman con el estado normal correspondiente. datos. Dos tercios de cada conjunto de datos se utilizan como entrenamiento muestras, y el resto se utilizan como muestras de prueba.

El algoritmo de bosque aleatorio se utiliza para medir la importancia de las variables iniciales y luego las variables clave que son Se seleccionan los más sensibles a los incidentes de tráfico. Entre ellos, mtry toma la raíz cuadrada del número de características variables recomendadas por Breiman y lo establece en 3. -e El número de CART en el bosque aleatorio se establece en 1000. -e La importancia de las variables del bosque aleatorio se calcula utilizando el programa de Python. Dieciocho variables iniciales se normalizan y se introducen en el programa de bosque aleatorio.
La figura 5 muestra la importancia de cada variable inicial.

Para reflejar el papel de las variables clave de detección, nosotros No solo se deben seleccionar la menor cantidad de variables posible, sino también garantizar la tasa correcta de detección de incidentes de tráfico. -aproximado análisis comparativo, las cuatro [16] variables con el mayor La importancia se seleccionó como las variables clave. La Figura 1 muestra que las cuatro variables más importantes son la relación de ocupación a velocidad del mismo detector, la relación de ocupación de detectores adyacentes aguas arriba y aguas abajo en el al mismo tiempo, la relación de ocupación a flujo del mismo detector y la relación de velocidad de aguas arriba adyacente y detectores posteriores al mismo tiempo.

4.3. Optimización por enjambre de partículas. La optimización por enjambre de partículas (PSO) se utiliza para obtener los parámetros óptimos del función kernel combinada. Para problemas generales, el rango establecido de partículas es 20–50. Para problemas específicos, el número de Las partículas pueden ser llevadas a 100–200. -e mayor es el rango espacial Cuanto más fácil sea la búsqueda, más fácil será encontrar la solución óptima global. y por supuesto, cuanto más tiempo se ejecute el algoritmo. Teniendo en cuenta que El número de partículas en el problema de detección de eventos es 20, puede resolver el problema de la detección de incidentes de tráfico y mejorar la eficiencia de entrenamiento del algoritmo. -e Los parámetros específicos de PSO son los siguientes: el número de partículas es 20, el La dimensión de las partículas es 3, y el factor de aceleración $c2 \quad c2 \quad 2$. -e El coeficiente de peso de inercia disminuye linealmente de 0,9 a 0,4 con el número de iteraciones, y el número máximo de iteraciones es 100. -e tasa de detección promedio de eventos de tráfico verificados por validación cruzada de 5 pliegues se utiliza como el valor de la función de aptitud. Tome el conjunto de datos de muestra del este principal línea como ejemplo para optimizar los parámetros. La Figura 6 muestra La curva de aplicabilidad de la optimización PSO.

Como se puede observar en la Figura 6, los parámetros óptimos de la función de núcleo combinada de la muestra de la línea principal este Los datos del conjunto son los siguientes: $\lambda = 0{,}53$, $\sigma = 0{,}25$ y $d = 3$.

4.4. Análisis de resultados. Para evaluar mejor la detección rendimiento de la máquina de aprendizaje extremo de ciclo profundo algoritmo (DELM) establecido en este documento, largo y corto plazo Algoritmo de memoria a corto y largo plazo (LSTM), red neuronal profunda (DBN) algoritmo, algoritmo de red neuronal convolucional (CNN), y el algoritmo de árbol de decisión de potenciación de gradiente (GBDT) son Seleccionado para comparación.

-e índices de evaluación del desempeño de incidentes de tráfico El algoritmo de detección incluye la tasa de detección (DR) y la falsa alarma. tasa de detección (FAR) y tiempo medio de detección (MTTD). DR representa el porcentaje del número de eventos detectados en un período de tiempo determinado con respecto al número real de eventos. FAR Representa el porcentaje de eventos de falsa alarma en todos los momentos de toma de decisiones durante un período de tiempo determinado. MTTD denota la media aritmética de la diferencia entre la Tiempo de ocurrencia del evento detectado y tiempo de ocurrencia real del evento. Las fórmulas de cálculo de los tres índices de evaluación son las siguientes:

$$\begin{aligned} \text{DR} &= \frac{\text{DN}}{\text{UN}} \times 100\%, \\ \text{FAR} &= \frac{\text{FN}}{\text{Informes totales}} \times 100\%, \\ \text{MTTD} &= \frac{1}{n} \sum_{i=1}^{n} [\text{TI}(i) - \text{AT}(i)]. \end{aligned} \tag{11}$$

En la fórmula anterior, DR es detección de incidentes de tráfico. tasa; DN es el número de eventos de tráfico detectados; AN es el número total de eventos de tráfico en el tiempo correspondiente; FAR es la tasa de falsas alarmas; FN es el número de tráfico informado erróneamente. eventos en tiempo correspondiente; RN son todos los tiempos de decisión en tiempo correspondiente; MTTD es el tiempo medio de detección; TI(i) es el tiempo del i incidente de tráfico detectado por el algoritmo; AT(i) es el tiempo real del i^{el} incidente de tráfico.

DR y FAR se utilizan para medir el rendimiento de detección de los algoritmos de detección automática de incidentes de tráfico. MTTD se utiliza para describir la eficiencia de detección de los algoritmos de detección automática de incidentes de tráfico. Los tres indicadores DR, FAR y MTTD están relacionados entre sí. y dependen el uno del otro. Si se obtiene un DR más alto, entonces debe conducir a un FAR más alto; mientras tanto, reducir el FAR lo hará Inevitablemente, DR reduce. De manera similar, si se obtiene un MTTD más corto, el FAR es relativamente más alto. Al evaluar un nuevo algoritmo de detección automática de incidentes de tráfico, hay Por lo general, existe una compensación entre estos 3 indicadores.

En términos generales, los tres indicadores de DR, FAR y Los MTTD se ven afectados por la determinación de la hora de inicio de el evento de tráfico. -e hora de ocurrencia del evento de tráfico detectado por el algoritmo se refiere al tiempo correspondiente a la anormalidad de los datos de flujo de tráfico causada por el impacto de el evento de tráfico y el impacto de la hora de finalización del evento de tráfico detectado por el algoritmo se refiere al momento en que el tráfico El flujo no se ve afectado por el evento de tráfico y el flujo de tráfico. Los datos vuelven a la normalidad. Porque este documento es una prueba fuera de línea. y la hora de inicio de los incidentes de tráfico no es como usar software de simulación para establecer el tiempo de ocurrencia directamente

Machine Translated by Google

2628, 2020, 1, Descargado de https://onlinelibrary.wiley.com/doi/10.1155/2020/6865089 por Cochrane Perú, Wiley Online Library el [02/05/2028]. Consulte los Términos y condiciones (https://onlinelibrary.wiley.com/terms-and-conditions) en Wiley Online Library para conocer las reglas de uso; los artículos de acceso abierto se rigen por la Licencia Creative Commons aplicable.

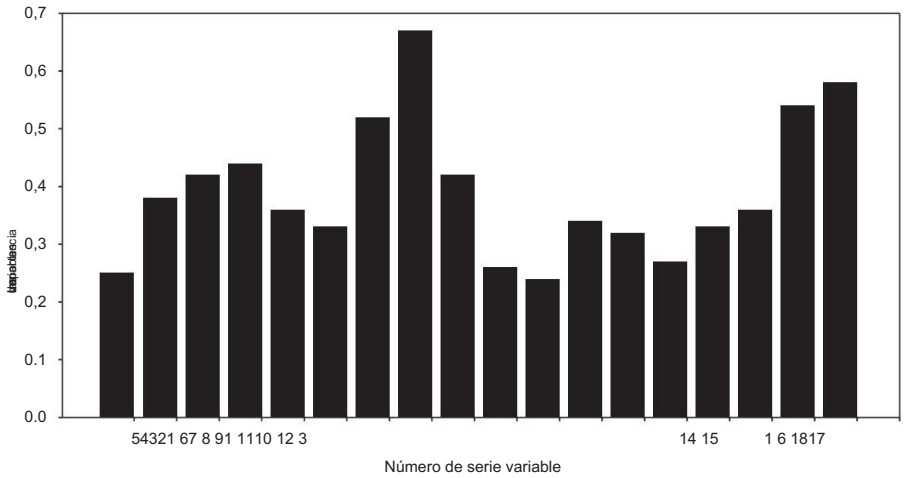


Figura 5: Importancia de la variable.

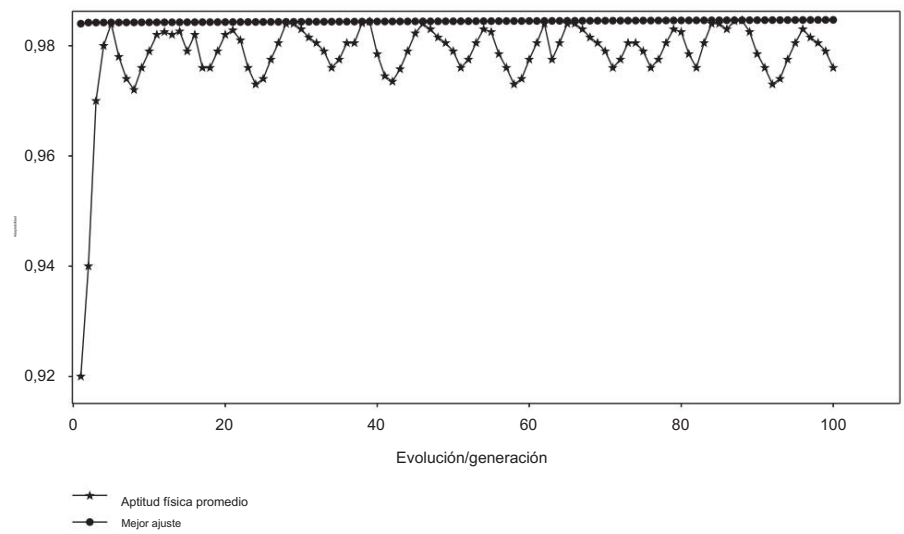


Figura 6: Curvas de aptitud de la optimización PSO.

Extraer datos de la base de datos, su método de determinación se basa en el juicio del umbral de datos. En un período determinado, el momento anormal de los datos de flujo de tráfico es la primera vez que ocurre el evento de tráfico. Después de un período de tiempo, cuando los datos de flujo de tráfico vuelven a la normalidad, el momento en que no hay anomalías es el momento en que termina el impacto del evento de tráfico. Sin embargo, en este artículo, el tiempo de inicio del incidente de tráfico tiene un impacto limitado en DR, FAR y MTTD. En la prueba fuera de línea, el tiempo de detección está relacionado con la velocidad de ejecución de la computadora y la velocidad de conexión al servidor, y esta prueba se realiza en la misma plataforma de hardware, y el tiempo de cálculo no es muy diferente; mientras que el algoritmo se ejecuta en línea, el tiempo de detección se ve afectado principalmente por la velocidad de transmisión de datos de la red [17] -e; su tasa de detección y tasa de falsa alarma se ven afectadas principalmente por el rendimiento de clasificación del algoritmo; cuanto mayor sea la precisión de clasificación del algoritmo, más eventos detectados correctamente y menos eventos de tráfico de falsa alarma. -e el tiempo de inicio del incidente de tráfico afecta principalmente la duración del incidente de tráfico. -por lo tanto, la hora de inicio del incidente de tráfico en este artículo es un indicador secundario. -e variables

iniciales y variables importantes se utilizaron para construir el conjunto de entrenamiento para probar el rendimiento de estos cinco algoritmos. -e los resultados se muestran en la Tabla 5. Se puede ver que, en comparación con el algoritmo de detección automática de eventos de tráfico que utiliza variables iniciales, el algoritmo de detección automática de eventos de tráfico que utiliza variables importantes ha mejorado en DR, FAR y MTTD, con mayor DR, menor FAR y menor MTTD. Entre ellos, el DR del algoritmo de detección de eventos DELM que utiliza variables importantes mejora en 3,99%, 2,08%, 2,27% y 2,72% en comparación con el DR de LSTM, DBN, CNN y GBDT; la diferencia de FAR es pequeña; el MTTD se ha reducido en 24,44%, 22,72%, 27,66% y 26,09%, respectivamente. Por lo tanto, el algoritmo DELM, que utiliza variables importantes, tiene un mejor rendimiento que los algoritmos LSTM, DBN, CNN y GBDT, y puede resolver eficazmente el problema de la detección de incidentes de tráfico en autopistas.

Machine Translated by Google

2629, 2020, 1, Descargado de https://onlinelibrary.wiley.com/doi/10.1155/2020/5965089 por Cochrane Perú, Wiley Online Library el [02/05/2026]. Consulte los Términos y condiciones (https://onlinelibrary.wiley.com/terms-and-conditions) en Wiley Online Library para conocer las reglas de uso; los artículos de acceso abierto se rigen por la Licencia Creative Commons aplicable.

Tabla 5: Comparación de los efectos de detección de diferentes algoritmos de detección.

Algoritmo de detección	Selección de variables			Variable inicial		
	DR (%)	LEJOS (%)	MTTD (min)	DR (%)	LEJOS (%)	MTTD (min)
DELM	98,42	0,56	0,68	92,20	0,63	1.09
LSTM	94,64	0,48	0,90	86,52	0,65	1.24
DBN	96,41	0,50	0,88	88,86	0,70	1.12
CNN	96,24	0,54	0,94	86,42	0,66	1.14
GBDT	95,81	0,50	0,92	87,86	0,76	1.21

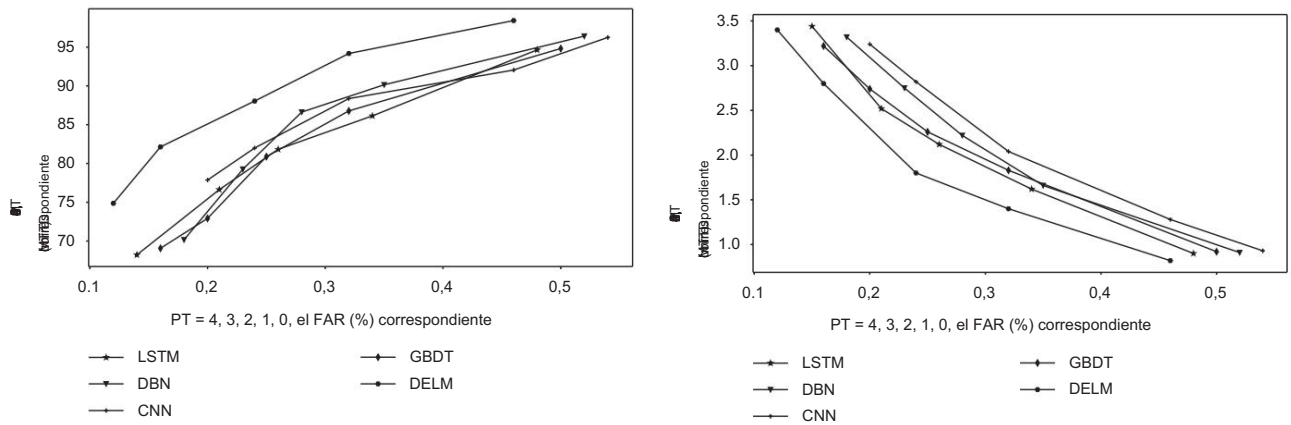


Figura 7: (a) Curva DR-FAR. (b) Curva MTTD-FAR.

La prueba de persistencia (PT) es una forma eficaz de reducir el FAR. La prueba de continuidad se refiere a la detección continua y por intervalos de incidentes de tráfico y en última instancia determina la ocurrencia de incidentes de tráfico.

Cuando no hay prueba continua, PT = 0. El MTTD se alarga a medida que aumenta el número de pruebas continuas. y DR disminuye a medida que aumenta el número de pruebas continuas. PT afecta el efecto de detección y la eficiencia de detección en cierta medida. Cuando PT 0–4, el rendimiento Las curvas de los tres algoritmos se muestran en la Figura 7. Como Como se muestra en la Figura 7(a), es la curva DR-FAR y, como se muestra en Figura 7(b), es la curva MTTD-FAR. Como se muestra en la Tabla 5, Cuando PT = 0, los tres indicadores corresponden al máximo. valores.

Como se puede observar en la Figura 7(a), cuando PT = 4, el La curva DR-FAR de DELM está más cerca de la esquina superior izquierda, indicando que el rendimiento del algoritmo DELM es mejor. -es, bajo las mismas condiciones DR, el FAR del El algoritmo DELM es mejor que LSTM, DBN, CNN y GBDT. -e La tasa de falsos positivos del algoritmo es menor; bajo la misma En condiciones FAR, el DR del algoritmo DELM es mayor que que de los algoritmos LSTM, DBN, CNN y GBDT. Para el Curva DR-FAR de cada algoritmo, cuando PT 1, el FAR La caída es mayor y la caída de DR es menor. Cuando el número de PT continúa aumentando, la disminución en FAR gradualmente La tasa de mortalidad disminuye y el descenso de la tasa de mortalidad se acelera gradualmente.

Como se puede observar en la Figura 7(b), cuando PT = 4, el La curva MTTD-FAR del algoritmo DELM está más cerca de la esquina inferior izquierda, lo que indica que el rendimiento de la El algoritmo DELM es mejor, -en es, bajo el mismo FAR, el El MTTD del algoritmo DELM es más corto que el MTTD de algoritmos LSTM, DBN, CNN y GBDT; bajo el mismo Condiciones MTTD, el MTTD del algoritmo DELM es más corto que el MTTD de LSTM, DBN, CNN y GBDT algoritmos. Para la curva MTTD-FAR de cada algoritmo, cuando PT 1, aunque el MTTD se incremente a un cierto En cierta medida, la disminución de FAR es mayor. A medida que aumenta el número de PT aumenta, la tasa de disminución de FAR se vuelve lenta y el La tasa de aumento del MTTD se acelera.

En resumen, los resultados de detección de eventos del DELM El algoritmo de inspección continua [18] es mejor que aquellos de LSTM, DBN, CNN y GBDT. Cuando PT 1, cada algoritmo puede equilibrar mejor los tres indicadores de DR, FAR, y MTTD.

5. Conclusión

(1) -e El algoritmo de bosque aleatorio utilizado en el artículo puede seleccionar eficazmente variables importantes para la detección de incidentes de tráfico, reduciendo la dimensión de entrada de incidentes de tráfico. algoritmo de detección y mejora del rendimiento del tráfico algoritmo de detección de incidentes. (2) -e rendimiento de DELM El algoritmo es mejor que el de LSTM, DBN, CNN y Algoritmos GBDT. (3) Cuando PT = 1, cada algoritmo puede equilibrar mejor los tres indicadores de DR, FAR y MTTD.

Para llegar a una conclusión más general, en el futuro investigación, el algoritmo DELM debe usarse en otros conjuntos de datos de incidentes de tráfico y análisis teóricos y demostrar la superioridad de DELM para incidentes de tráfico detección. Además, para construir una más completa

Machine Translated by Google

El tráfico, el conjunto de variables inicial para la detección de eventos, requiere un análisis más profundo.

Disponibilidad de datos

Los datos que respaldan las conclusiones de este estudio se presentan en las figuras y tablas del artículo. El código y los detalles relacionados con este trabajo están disponibles previa solicitud al autor correspondiente.

Conflictos de intereses

Los autores declaran que no existen conflictos de intereses en relación con la publicación de este artículo.

Referencias

[1] CL Dudek, CJ Messer y NB Buckles, Detección de incidentes en autopistas urbanas, Transportation Research Board, Washington, DC, EE. UU., 1974.

[2] Al Gall y FL Hall, Distinción entre congestión incidental y congestión recurrente: una lógica propuesta, Transportation Research Board, Washington, DC, EE. UU., 1989.

[3] C.-H Hsiao, C.-T. Lin y M. Cassidy, "Aplicación de lógica difusa y red neuronal para detectar automáticamente incidentes de tráfico en autopistas", Journal of Transportation Engineering, vol. 120, n.º 5, págs. 753–772, 1994.

[4] B. Abdulhai y SG Ritchie, "Mejora de la universalidad y transferibilidad de la detección de incidentes en autopistas mediante una red neuronal basada en el análisis bayesiano", Transportation Research Part C: Emerging Technologies, vol. 7, n.º 5, págs. 261–280, 1999.

[5] F. Yuan y RL Cheu, "Detección de incidentes mediante máquinas de vectores de soporte", Transportation Research Part C: Emerging Technologies, vol. 11, n.º 3-4, págs. 309–328, 2003.

[6] G. B Huang, H. Zhou, X. Ding et al., "Máquina de aprendizaje extremo para regresión y clasificación multiclase", IEEE Transactions on Systems, Man, and Cybernetics, vol. 42, no. 2, pp. 513–529, 2012.

[7] LL Chamara, H. Zhou y GB Huang, "Máquinas de aprendizaje extremo: aprendizaje representacional con ELMS para big data", Sistemas Inteligentes, IEEE, vol. 28, n.º 6, págs. 31–34, 2013.

[8] JT Springenberg, A. Dosovitskiy, T. Brox et al., "En busca de la simplicidad: la red totalmente convolucional", 2014, https://arxiv.org/ abs/1412.6806.

[9] D. Zhang y D. Wang, "Clasificación de relaciones mediante recursividad red neuronal", Ciencias de la Computación, 2015.

[10] CE Hatri y J. Boumhidi, "Detección de incidentes de tráfico urbano basada en aprendizaje profundo difuso", Cognitive Systems Research, vol. 50, pp. 206–213, 2018.

[11] L. Zhu, F. Guo, R. Krishnan y JW Polak, "Un enfoque de aprendizaje profundo para la detección de incidentes de tráfico en redes urbanas", en Actas de la 21.ª Conferencia Internacional sobre Sistemas de Transporte Inteligentes (ITSC) de 2018, págs. 1011–1016, IEEE, Maui, HI, EE. UU., noviembre de 2018.

[12] M. -aika, S. Tasneeyapant y S. Cheamanunkul, "Un enfoque rápido, escalable y no supervisado para la detección de incidentes de tráfico en tiempo real", en Actas de la 15.ª Conferencia Internacional Conjunta sobre Ciencias de la Computación e Ingeniería de Software (JCSSE) de 2018, págs. 205–210, IEEE, Nakhonpathom, -ailand, julio de 2018.

[13] T. Kongkhaensarn y M. Piantanakulchai, "Comparación de la red neuronal probabilística con el perceptrón multicapa y la máquina de vectores de soporte para la detección de incidentes de tráfico en "Autopista basada en datos de simulación", en Actas de la 15.ª Conferencia Internacional Conjunta sobre Ciencias de la Computación e Ingeniería de Software (JCSSE) de 2018, págs. 221–226, Nakhonpathom, -ailand, julio de 2018.

[14] L. Li, YJ Zhang, Y. Zheng y B. Ran, "Detección de incidentes de tráfico en tiempo real con métodos de clasificación", en Green Intelligent Transportation Systems, vol. 419, pp. 777–788, Springer, Berlín, Alemania, 2018.

[15] Y. Sun y ZX Hou, "Un nuevo método de detección de incidentes de tráfico anormales basado en una máquina de vectores de soporte mejorada", Journal of Applied Science and Engineering, vol. 21, no. 1, pp. 45–50, 2018.

[16] LC Li, X. Qu, J. Zhang y B. Ran, "Detección de incidentes de tráfico basada en aprendizaje automático extremo", Journal of Applied Science and Engineering, vol. 20, no. 4, pp. 409–416, 2017.

[17] F. Alesiani, L. Moreira-Matias y M. Faizrahnemoon, "Sobre el aprendizaje a partir de datos de flujo de tráfico inexactos e incompletos", IEEE Transactions on Intelligent Transportation Systems, vol. 19, no. 11, pp. 3698–3708, 2019.

[18] H. Benaddi, K. Ibrahimi y A. Benslimane, "Mejora del sistema de detección de intrusiones para el conjunto de datos NSL-KDD basado en PCA-agrupamiento difuso-KNN", en Actas de la 6.ª Conferencia Internacional de 2018 sobre Redes Inalámbricas y Comunicaciones Móviles (WINCOM), págs. 234–239, IEEE, Marrakech, Marruecos, octubre de 2018.

2829, 2020, 1, Descargado de https://onlinelibrary.wiley.com/doi/10.1155/2020/5965089 por Cochrane Perú, Wiley Online Library el [02/05/2028]. Consulte los Términos y condiciones (https://onlinelibrary.wiley.com/terms-and-conditions) en Wiley Online Library para conocer las reglas de uso; los artículos de acceso abierto se rigen por la Licencia Creative Commons aplicable.