Machine Translated by Google

scientific reports

Check for updates

ABIERTO

Un marco de fusión profunda multimodal para la detección de anomalías en el tráfico de autopistas

Mengmeng Duan1,2, Shaowei Sun3,4 y Mingzhou Liu3

1Laboratorio Provincial Clave de Anhui sobre Información y Seguridad del Transporte para Universidades, Hefei 230601, China. 2Facultad de Transporte Inteligente e Industria Moderna, Universidad de Anhui Sanlian, Hefei 230601, China. 3Escuela de Ingeniería Mecánica, Universidad Tecnológica de Hefei, Hefei 230009, Anhui, China. 4Instituto de Ingeniería de Transporte Inteligente, Anhui Transport Consulting & Design Institute Co., Ltd, Hefei 230088, Anhui, China. Correo electrónico: liumingzhou0551@163.com

Este artículo presenta un marco novedoso para la detección y predicción de eventos de tráfico anómalos en autopistas. Los sistemas tradicionales de monitoreo de tráfico suelen depender de una única fuente de datos, lo que limita la precisión y la robustez de la detección en entornos complejos. Para abordar estos desafíos, proponemos un marco de fusión profunda multimodal basado en redes neuronales gráficas heterogéneas (HGNN), mejorado mediante un algoritmo de estimación de probabilidad pesimista contrastiva de conjunto (CPLE). El marco integra datos de tráfico estáticos y dinámicos, incluyendo imágenes de vídeo, flujo de tráfico, velocidad de los vehículos y condiciones meteorológicas del túnel. Mediante una fusión de características eficaz, mejora significativamente la precisión y el rendimiento en tiempo real de la detección de anomalías. Los resultados experimentales demuestran que el modelo funciona de forma robusta en diversos escenarios, identificando con precisión eventos de tráfico anómalos con alta precisión y estabilidad. En comparación con modelos existentes como AGC-LSTM y AttentionDeepST, el modelo MHGNN-CPLE propuesto demuestra un rendimiento superior, particularmente en tareas de detección estática, alcanzando una precisión de 0,980 y una puntuación F1 de 0,967. En cambio, AGC-LSTM y AttentionDeepST alcanzan 0,965/0,945 y 0,960/0,935 en precisión y puntuación F1, respectivamente.

En escenarios dinámicos, el modelo mantiene una alta precisión incluso con niveles de ruido variables, lo que demuestra su gran robustez. Esta investigación surge de los crecientes desafíos de la urbanización, donde la detección y predicción en tiempo real de anomalías de tráfico son cada vez más cruciales. Nuestro marco integra eficazmente datos multimodales y aprovecha las redes neuronales de alto orden (HGNN) para capturar dependencias espaciotemporales complejas, mientras que el algoritmo CPLE mejora la robustez ante la incertidumbre. Los resultados confirman que el método propuesto ofrece una solución fiable y precisa para la detección de anomalías de tráfico en tiempo real, lo que representa un avance significativo en los sistemas de transporte inteligentes.

Palabras clave: Fusión profunda multimodal, Red neuronal gráfica heterogénea, Evento anómalo de tráfico, Detección dinámica, Detección estática

A medida que la urbanización continúa acelerándose, la gestión del tráfico en las carreteras enfrenta desafíos cada vez más formidables, particularmente en la detección y predicción en tiempo real de eventos de tráfico anormales. Incidentes como accidentes, congestión e interrupciones inducidas por el clima afectan significativamente la eficiencia y la seguridad de los sistemas viales. Por lo tanto, mejorar la precisión y la puntualidad de la detección de anomalías es esencial para reducir accidentes, mejorar el flujo de tráfico y garantizar la seguridad pública[1] . La mayoría de los sistemas de monitoreo de tráfico existentes se basan en una sola fuente de datos, como cámaras de vigilancia, radares o sensores, pasando por alto la naturaleza inherentemente multimodal de los eventos de tráfico. En consecuencia, los métodos tradicionales a menudo carecen de la precisión y robustez suficientes en entornos complejos[2,3] . Para abordar estas limitaciones, este artículo propone un marco novedoso basado en la fusión profunda multimodal y redes neuronales gráficas heterogéneas (HGNN). Al integrar diversas fuentes de datos, incluidas imágenes, nubes de puntos, sonido y temperatura, el marco captura las complejas dependencias espaciotemporales presentes en los sistemas de tráfico[4] . Las HGNN son particularmente adecuadas para manejar datos heterogéneos y permiten una fusión efectiva de información multimodal, mejorando así la precisión y confiabilidad de la predicción de eventos anormales[5] .

Además, para mejorar el rendimiento predictivo del modelo, se incorpora al marco el algoritmo de Estimación de Probabilidad Pesimista Contrastiva (CPLE). Este algoritmo mejora la robustez del modelo optimizando la confianza de la predicción mediante el ajuste de la probabilidad ponderada . En los últimos años, numerosos estudios

Machine Translated by Google

Han explorado la aplicación del aprendizaje profundo y otros algoritmos inteligentes a la detección de anomalías en el tráfico. Por ejemplo, Liang et al.7 desarrollaron un método para detectar sonidos anómalos utilizando una red neuronal convolucional (CNN) unidimensional con un mecanismo de autoatención multi-cabeza, lo que permite la identificación oportuna de eventos basada en datos de sonido. Zou et al.8 aplicaron el algoritmo TL-XGBoost para detectar anomalías en datos de transacciones ETC de autopistas, mientras que Zhang et al.9 propusieron un método de detección de anomalías para imágenes del fondo de ojo de la retina basado en conexiones de alta velocidad controladas, que también tiene potencial para la monitorización del tráfico. Estos trabajos reflejan un creciente interés en la monitorización inteligente del tráfico; sin embargo, se centran principalmente en la detección unimodal y no abordan el papel de la fusión multimodal para mejorar la robustez.

La detección de anomalías en el flujo de tráfico sigue siendo muy compleja, a menudo influenciada por factores como el clima, las condiciones de la superficie de la carretera y el rendimiento del equipo[1] . Por ejemplo, Khan y Ahmed[11] presentaron un enfoque de aprendizaje profundo para predecir la gravedad de los accidentes en condiciones climáticas adversas, y Wang et al.[12] predijeron la formación de hielo en la carretera utilizando sensores de temperatura de la superficie. Estos estudios resaltan el potencial de combinar datos multimodales con técnicas de aprendizaje profundo para una detección de anomalías más eficaz. En este contexto, presentamos un marco de detección de anomalías multimodal basado en HGNN, con el objetivo de mejorar la precisión, la fiabilidad y la aplicabilidad de los sistemas de tráfico inteligentes en entornos reales.

Trabajos relacionados

Los avances recientes en la detección de anomalías en el tráfico abarcan un amplio espectro de metodologías, desde sistemas basados en reglas hasta enfoques de aprendizaje profundo. Las técnicas tradicionales suelen basarse en métricas de flujo de tráfico, velocidad de los vehículos o datos visuales de cámaras de vigilancia, y emplean modelos estadísticos o reglas diseñadas manualmente para detectar anomalías. Sin embargo, estos sistemas tienen dificultades en condiciones complejas y dinámicas, y son altamente sensibles al ruido y a la variabilidad ambiental13.

Los métodos de aprendizaje automático han mejorado la detección de anomalías, pero a menudo presentan dificultades para integrar tipos de datos heterogéneos[1] . Por ejemplo, Han et al.[1] propusieron un marco basado en redes neuronales para la limpieza de datos en pavimentos de carreteras, mejorando la precisión del modelo mediante la reducción del ruido, pero sin adaptabilidad a fuentes heterogéneas. Las técnicas de aprendizaje profundo, como los autoencoders[1] o los modelos de reconocimiento de patrones[1] , han demostrado un mejor rendimiento en la detección de anomalías basada en imágenes, pero requieren una gran cantidad de datos de entrenamiento y son computacionalmente intensivas[1] .

Las redes neuronales gráficas (GNN) han ganado popularidad recientemente en aplicaciones de tráfico debido a su capacidad para modelar dependencias espaciotemporales19. Las GNN heterogéneas (HGNN), en particular, pueden manejar eficazmente diversos tipos de nodos y aristas, lo que las hace adecuadas para la fusión de datos multimodales20. Niu et al.21 y Zhang et al.22 exploraron las GNN para la predicción de flujo y la seguridad de la red, mientras que Zhou et al.23 se centraron en la detección de trayectorias de anomalías visuales. Sin embargo, muchos de estos modelos siguen limitados a entradas de una sola modalidad o escenarios específicos como grietas en el pavimento24 o datos transaccionales de ETC25,26.

Este estudio amplía los enfoques existentes basados en GNN al incorporar diversas entradas de sensores —incluidas imágenes, nubes de puntos, sonido y temperatura— en un marco de detección multimodal unificado. A diferencia de los métodos anteriores, que a menudo ignoran las interdependencias de los sensores o las correlaciones contextuales, nuestro modelo basado en HGNN captura las interacciones multimodales para mejorar la robustez y la generalización en condiciones de tráfico reales.

Diseño del sistema y construcción del modelo

El modelo propuesto consta de tres componentes principales: un módulo de preprocesamiento de sensores multimodales, una red neuronal gráfica heterogénea (HGNN) para la representación de características espaciotemporales y una estrategia de estimación de probabilidad pesimista contrastiva (CPLE) para mejorar la robustez ante la incertidumbre. La arquitectura general del sistema propuesto se ilustra en la Figura 1.

Diseño de métodos de adquisición y preprocesamiento de datos multimodales

La esencia de los sucesos anómalos en las autopistas (como accidentes y congestión) radica en la interacción de múltiples factores. Los datos unimodales solo reflejan características locales, mientras que los datos multimodales proporcionan información complementaria mediante la alineación espacio-temporal. En este estudio, se recopilan cuatro tipos clave de datos multimodales: imágenes, nubes de puntos, sonido y datos de temperatura. Estas fuentes de datos aportan información complementaria que ayuda al modelo a detectar y predecir eficazmente eventos de tráfico anómalos. En particular, mientras que las imágenes y las nubes de puntos ofrecen información visual y espacial crucial sobre las condiciones del tráfico, los datos de sonido y temperatura proporcionan un valioso contexto ambiental que mejora la robustez y la precisión del sistema de detección de anomalías.

Los datos de imagen se obtienen en tiempo real mediante cámaras de autopista. Se utilizan algoritmos avanzados de visión artificial, en particular redes neuronales convolucionales (CNN) y redes neuronales convolucionales basadas en regiones (R-CNN), para identificar elementos clave en escenas de tráfico. En la etapa de preprocesamiento de los datos de imagen, se llevan a cabo pasos como la reducción de ruido (mediante técnicas como el filtrado gaussiano o el filtrado de mediana), la normalización de escala y la estandarización. Además, se emplean componentes como la atención multi-cabeza y las redes neuronales convolucionales ponderadas para mejorar el rendimiento del modelo en escenarios de tráfico complejos.

Los datos de nube de puntos, proporcionados por sensores LiDAR, capturan la información espacial tridimensional de carreteras y vehículos. La clave del preprocesamiento de datos reside en alinear y fusionar los datos de nube de puntos de diferentes perspectivas para formar un modelo 3D coherente. Este estudio adopta un método de registro de nube de puntos basado en el algoritmo de Punto Más Cercano Iterativo (ICP). El proceso de correspondencia y fusión de nubes de puntos se puede representar mediante el siguiente modelo matemático:

$$Pfused = \sum n_{i=1} \text{ Para} \cdot \text{Sí} \quad (1)$$

Machine Translated by Google
www.nature.com/scientificreports/

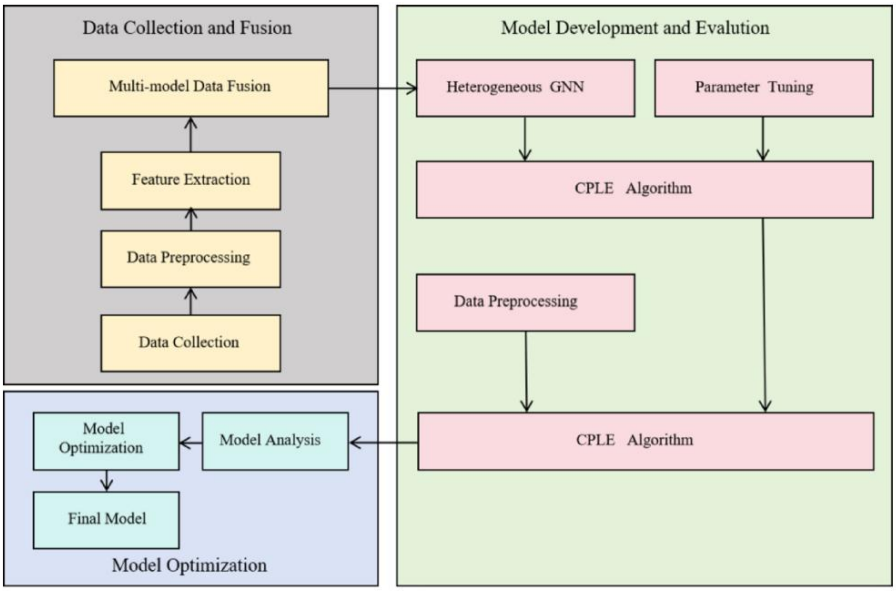


Figura 1. Proceso técnico de este artículo.

donde Pi es la nube de puntos cuyos datos fueron recopilados por el i-ésimo sensor, y wi es el peso correspondiente de cada sensor. Se aplica una estrategia de fusión basada en la ponderación por distancia y ángulo para mejorar la capacidad de expresión de la información espacial de los datos de la nube de puntos.

Los datos de sonido, recopilados mediante sensores de sonido instalados en las carreteras, desempeñan un papel crucial en la detección de anomalías en el tráfico. Los sonidos anormales, como el frenado, el ruido del motor o las colisiones, pueden indicar incidentes como accidentes o perturbaciones que no son visibles en las imágenes. Los pasos de preprocesamiento de los datos de sonido incluyen la eliminación del ruido de fondo, la extracción de características de frecuencia y la transformada de Fourier. Estos pasos ayudan a convertir las señales de sonido al dominio de la frecuencia para su posterior análisis. El modelo de preprocesamiento de datos de sonido se puede representar como:

$$\text{Frecuencia}_i = \text{Transformada de Fourier (Si)} \tag{2}$$

$$\text{Filtrado}_i = \text{Filtro (Sfreq}_i\text{, umbral)} \tag{3}$$

$$\text{Snorm}_i = \frac{\text{Filtrado}_i - \mu_s}{s_s} \tag{4}$$

donde Si es la señal de sonido original y Sfreq_i es la señal transformada en el dominio de la frecuencia, fthreshold es el umbral de frecuencia utilizado en la operación de filtrado para retener solo las frecuencias relevantes, μ son la $_s$ y s_s media y la desviación estándar de los datos de sonido filtrados, y Snorm_i es la señal de sonido normalizada. Esto garantiza que los datos de sonido estén listos para su posterior fusión con otras modalidades.

Los datos de temperatura, recopilados mediante sensores instalados en la superficie de la carretera, reflejan factores ambientales que pueden afectar significativamente el flujo y la seguridad del tráfico. Las fluctuaciones de temperatura, como la formación de hielo en la carretera durante el invierno o el calor extremo en verano, pueden provocar interrupciones del tráfico, accidentes o congestión. Por lo tanto, los datos de temperatura son una herramienta importante para predecir anomalías en el tráfico causadas por las condiciones meteorológicas. El preprocesamiento de los datos de temperatura implica la interpolación para gestionar los valores faltantes y la estandarización para garantizar la coherencia en diferentes periodos de tiempo y ubicaciones. El preprocesamiento de la temperatura se modela de la siguiente manera:

$$T_i^{\text{norma}} = \frac{Ti - \mu T}{\text{calle}} \tag{5}$$

donde μ T y σ T son la media y la desviación estándar de los datos de temperatura, y T el valor de la $_i^{\text{norma}}$ es el normalizado temperatura.

Tras el preprocesamiento, los datos de diferentes modalidades se fusionan para crear un vector de características integral para la detección de anomalías. El mecanismo de fusión combina estas fuentes de datos heterogéneas en un único vector que representa la condición del tráfico. El proceso de fusión incorpora una estrategia ponderada donde la contribución de cada modalidad se ajusta dinámicamente en función de su importancia para detectar anomalías de tráfico específicas. La fórmula de fusión es la siguiente:

$$\text{xfusionado} = \sum_{i=1}^{n} wi \cdot \text{xnorm}_i \tag{6}$$

donde xnorm_i representa el vector de características normalizado de cada modalidad, y wi es el peso de cada modalidad. Estos pesos se ajustan en función del rendimiento histórico de cada modalidad y su relevancia en

Machine Translated by Google

detección de diferentes eventos de tráfico. Por ejemplo, los datos de sonido pueden ser más importantes para detectar accidentes, mientras que los datos de temperatura podrían ser cruciales para identificar anomalías relacionadas con el clima. Para presentar la lógica de adquisición y preprocesamiento de datos multimodales con mayor claridad, escribimos el algoritmo como pseudocódigo, tal como se muestra en (Algoritmo 1).

Diseño de modelos de redes neuronales gráficas heterogéneas

Las redes neuronales gráficas heterogéneas (HGNN) desempeñan un papel fundamental en el marco propuesto para la detección y predicción de eventos de tráfico anómalos en autopistas, como se muestra en la figura 2. Este diseño de modelo aprovecha al máximo la naturaleza heterogénea de los distintos tipos de datos de tráfico y permite una fusión de información y un aprendizaje de representación eficaces mediante redes neuronales convolucionales gráficas (GCN) multinivel. Los datos de tráfico presentan fuertes dependencias espaciotemporales, y las relaciones entre las diferentes modalidades suelen ser complejas y diversas. Las HGNN facilitan la propagación y el aprendizaje eficientes de la información al utilizar las características estructurales únicas de los distintos tipos de nodos y aristas.

En este estudio, los nodos del grafo representan fuentes de datos multimodales, incluyendo flujo de tráfico, velocidad del vehículo, información de accidentes y temperatura ambiental, mientras que las aristas capturan las interrelaciones entre

Input: Highway camera data, LiDAR point cloud data, road sound sensor data, road temperature sensor data
Output: Fused and preprocessed feature vectors
// Image data processing
image_data = GetRealTimeImageDataFromHighwayCameras()
denoised_image = DenoiseImage(image_data)
normalized_image = NormalizeScale(denoised_image)
enhanced_image_features = EnhanceFeatures(normalized_image)
// Point cloud data processing
point_cloud_data = GetPointCloudDataFromLiDAR()
aligned_point_clouds = AlignPointClouds(point_cloud_data)
fused_point_cloud = FusePointClouds(aligned_point_clouds)
// Sound data processing
sound_data = GetSoundDataFromRoadSensors()
cleaned_sound = RemoveBackgroundNoise(sound_data)
frequency_domain_signal = FourierTransform(cleaned_sound)
filtered_signal = FrequencyDomainFiltering(frequency_domain_signal)
// Temperature data processing
temperature_data = GetTemperatureDataFromRoadSensors()
interpolated_temperature = InterpolateMissingValues(temperature_data)
smoothed_temperature = SmoothData(interpolated_temperature)
denoised_temperature = Denoise(smoothed_temperature)
// Standardization and normalization of all data
standardized_image = Standardize(enhanced_image_features)
standardized_point_cloud = Standardize(fused_point_cloud)
standardized_sound = Standardize(filtered_signal)
standardized_temperature = Standardize(denoised_temperature)
// Weighted fusion of multimodal data
weights = CalculateWeightsBasedOnHistoricalData()
fused_feature_vectors = WeightedFusion([standardized_image, standardized_point_cloud, standardized_sound, standardized_temperature], weights)
return fused_feature_vectors

Algoritmo 1. Adquisición y preprocesamiento de datos multimodales.

Machine Translated by Google
www.nature.com/scientificreports/

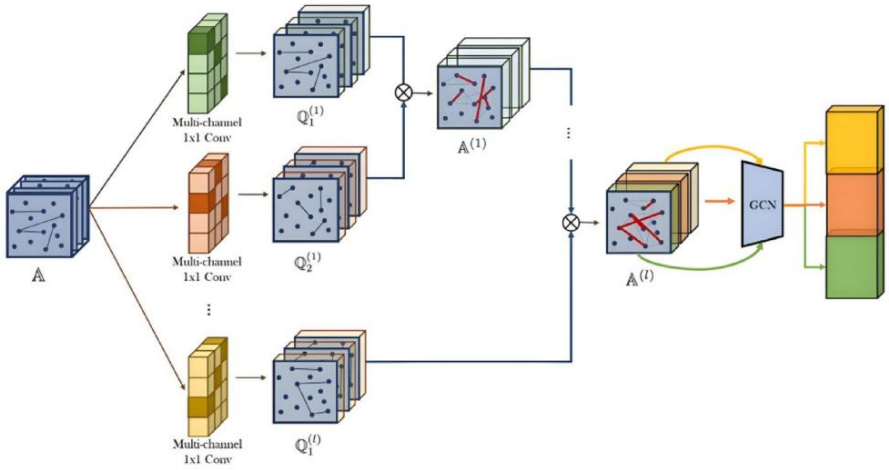


Figura 2. Estructura de red neuronal gráfica heterogénea.

Estos tipos de datos. Se diseña una arquitectura de red neuronal convolucional gráfica multinivel para actualizar adaptativamente las representaciones de los nodos en cada capa y fusionar eficazmente características de diferentes modalidades. Las actualizaciones de los nodos se realizan mediante agregación ponderada, incorporando información de los nodos vecinos y los pesos de las aristas correspondientes. El proceso de actualización se define formalmente mediante la siguiente ecuación:

$$h_i^{(l+1)} = \sigma\left(\sum_{j \in N(i)} \frac{1}{c_{ij}} W^{(l)} h_j^{(l)} + b^{(l)}\right) \tag{7}$$

donde $h_i^{(l+1)}$ representa el estado oculto del i-ésimo nodo en la (l+1)-ésima capa, N (i) denota el conjunto de nodos vecinos del i-ésimo nodo, $h_j^{(l)}$ es el estado oculto del j-ésimo nodo vecino en la l-ésima capa, $W^{(l)}$ es la matriz de pesos de la l-ésima capa, $b^{(l)}$ es el término de sesgo, σ es la función de activación y c_{ij} es el borde coeficiente de normalización.

Además, para mejorar aún más la capacidad del modelo para percibir y distinguir fuentes de datos heterogéneas, se emplean redes neuronales convolucionales gráficas ponderadas (Weighted GCN). Al introducir un mecanismo de ponderación entre diferentes modalidades, el modelo permite que ciertas fuentes de datos ejerzan una mayor influencia en los resultados de predicción durante el entrenamiento. La estrategia de ponderación adaptativa se representa formalmente mediante la siguiente ecuación:

$$S_i^{(l)} = \sum_{j \in N(i)} \alpha_{ij} W^{(l)} x_j^{(l)} + b^{(l)} \tag{8}$$

donde α_{ij} es el coeficiente de ponderación entre los nodos i y j, que puede ajustarse dinámicamente según la fuerza de la relación entre los nodos.

Para fusionar datos multimodales, se emplea una estrategia de fusión ponderada basada en un mecanismo de atención. Este enfoque ajusta de forma adaptativa la contribución de cada modalidad durante el proceso de propagación de la información. El peso asignado a cada modalidad se calcula según la siguiente ecuación:

$$\omega_i = \frac{\exp(a_i)}{\sum_{i=1}^{n} \exp(a_i)} \tag{9}$$

donde ai es la puntuación de atención que representa la i-ésima modalidad, y ω i denota su peso correspondiente. Para mejorar aún más la precisión de predicción del modelo, se incorpora el algoritmo de Estimación de Probabilidad Pesimista Contrastiva (CPLE) para optimizar los parámetros del modelo durante el entrenamiento. Este algoritmo mejora la capacidad del modelo para reconocer eventos anormales aprovechando las diferencias relativas entre las muestras. La función objetivo de CPLE se define de la siguiente manera:

$$L_{CPLE} = -\sum_{i=1}^{n} \log\left(\frac{\exp(y_i)}{\sum_{j=1}^{n} \exp(z_j)}\right) \tag{10}$$

donde zi denota la salida predicha de los datos de entrada en el modelo actual, y el objetivo de optimización LCP LE busca mejorar la precisión del modelo en la detección de eventos anormales minimizando la función de pérdida. La red neuronal gráfica heterogénea propuesta está diseñada para capturar de manera integral las relaciones complejas entre diferentes modalidades y ajustar adaptativamente las contribuciones a través de una combinación de mecanismos de ponderación y atención. Este diseño mejora significativamente el rendimiento del modelo en la predicción de eventos de tráfico anormales en autopistas. Cuando se integra con el algoritmo de estimación de probabilidad pesimista, el marco es capaz

Machine Translated by Google

para identificar de forma precisa y eficiente posibles anomalías de tráfico en entornos dinámicos, ofreciendo alertas oportunas y apoyo a la toma de decisiones para los sistemas de gestión de tráfico. Para ilustrar claramente la arquitectura y la lógica de la red neuronal gráfica heterogénea propuesta, el algoritmo correspondiente se presenta en pseudocódigo, como se muestra en (Algoritmo 2).

Diseño de algoritmos de estimación de probabilidad pesimista de comparación integrada (CPLE)

El algoritmo CPLE es particularmente adecuado para la detección de anomalías en el tráfico de autopistas debido a su capacidad de incorporar tanto la confianza de la predicción como la consistencia del vecindario. Al modelar las puntuaciones de anomalías utilizando una función de similitud de decaimiento exponencial y ajustando las distribuciones de predicción en consecuencia, CPLE mejora la robustez de la optimización en condiciones ruidosas o inciertas. Además, a diferencia de los optimizadores comunes

Input: Multimodal data features, number of layers L
Output: Model predictions
// Initialize graph nodes and edges
1: nodes = InitializeNodes(multimodal_data_features)
2: edges = InitializeEdges(nodes)
// Initialize model parameters
3: for $l = 1$ to L do
4: $W^{(l)}$ = InitializeWeightMatrix()
5: $b^{(l)}$ = InitializeBiasTerm()
6: end for
// Forward propagation
7: for $l = 1$ to L do
8: for each node i in nodes do
9: $h_i^{(l+1)}$ = ActivationFunction(
10: Sum over j in $N(i)$ of $(1 / c_{ij}) * W^{(l)} * h_i^{(l+1)} + b^{(l)}$
11:)
12: end for
13: end for
// Weighted graph convolution
14: for each node i in nodes do
15: $x_i^{(l)}$ = Sum over j in $N(i)$ of $(\alpha_{ij} * W^{(l)} * x_j^{(l)} + b^{(l)})$
16: end for
// Multimodal data fusion with attention mechanism
17: attention_scores = CalculateAttentionScores(multimodal_data_features)
18: weights = CalculateWeightsBasedOnAttention(attention_scores)
19: fused_features = WeightedFusion(multimodal_data_features, weights)
// Combine with Contrastive Pessimistic Likelihood Estimation (CLL)
20: loss = CalculateCLLLoss(fused_features, true_labels)
21: UpdateModelParameters(loss)
22: predictions = MakePredictions(fused_features)
23: return predictions

Algoritmo 2. Modelo de red neuronal gráfica heterogénea.

Machine Translated by Google
www.nature.com/scientificreports/

Al igual que Adam o SGD, CPLE ajusta dinámicamente la tasa de aprendizaje y la magnitud del gradiente en función de la dificultad de la muestra y la influencia espacial, lo que permite que el modelo se centre más en regiones anómalas o ambiguas. Este mecanismo de ajuste, con fundamentos teóricos, se adapta bien a la naturaleza multimodal y heterogénea de los datos de tráfico en autopistas.

Para optimizar aún más el proceso de inferencia del algoritmo CPLE, se introducen múltiples modelos matemáticos que permiten refinar conjuntamente el mecanismo de ponderación de muestras, la función de pérdida y la estrategia de optimización general, con el objetivo de mejorar la precisión y la robustez de la detección de eventos anómalos. En particular, los mismos coeficientes de ponderación se ajustan dinámicamente en función de la similitud entre las muestras.

El coeficiente de ponderación de la i-ésima muestra se actualiza en función de la diferencia entre los resultados predichos zi y las de las muestras vecinas zj . La fórmula de actualización específica es:

$$\omega_{mi}^{(norma)} = \frac{\omega_{mi}}{\sum_{i=1}^{norte} \omega_i} \tag{11}$$

donde n es el número total de muestras, ω i denota el coeficiente de ponderación original de cada muestra, y representa el coeficiente $\omega_i^{(norma)}$ de ponderación normalizado, asegurando que el peso total de todas las muestras sume 1. Sobre la base de la actualización de los coeficientes de ponderación, la función de pérdida en el algoritmo CPLE se modifica para tener en cuenta la importancia relativa de cada muestra. Suponiendo que la función de pérdida original es L, la función de pérdida ponderada se define de la siguiente manera:

$$\text{Peso L} = \sum_{i=1}^{norte} \omega_i^{(norma)} \cdot L(yi, yi) \tag{12}$$

donde L(yi, yi) es la función de pérdida estándar (como la pérdida de entropía cruzada), yi es la etiqueta verdadera de la i-ésima muestra, $y_i^{(norm)}$ es la salida predicha del modelo, y ω es el coeficiente de ponderación normalizado correspondiente a i para la i-ésima muestra. Para evitar que el modelo se sobreajuste a muestras anómalas y garantizar un aprendizaje adecuado a partir de muestras normales, se incorpora un término de regularización a la función de pérdida. Este término penaliza la atención excesiva a los valores atípicos y equilibra el proceso de entrenamiento. Se puede emplear la regularización de norma L2 u otras técnicas de regularización adecuadas. La expresión para el término de regularización se presenta a continuación:

$$Lreg = \lambda \sum_{i=1}^{n} |\omega_i|^2 \tag{13}$$

donde λ es el coeficiente de regularización, que controla la intensidad del término de regularización, ωi es un parámetro del modelo y |· |2 representa la norma L2. Durante el proceso de optimización, el algoritmo CPLE mide la importancia de las muestras anómalas definiendo una métrica de puntuación de anomalía. Suponiendo que el error de predicción de la muestra es denota $\varepsilon_i = |zi - yi|$, la medida de anomalía correspondiente se calcula como:

$$Di = \exp(-\alpha \varepsilon_i) \tag{14}$$

donde α es el parámetro de ajuste para la medición de anomalías y i denota el error de predicción de la i-ésima muestra. Durante el proceso de ponderación de muestras, los resultados de predicción finales del modelo se pueden refinar mediante un promedio ponderado, lo que mejora la sensibilidad del modelo a las muestras anómalas. La fórmula de ajuste ponderado para el resultado de predicción final se presenta a continuación:

$$y_{(ajustado)} = \frac{\sum_{j=1}^{norte} \omega_j^{(norma)} \cdot yj}{\sum_{j=1}^{norte} \omega_j^{(norma)}} \tag{15}$$

donde $\omega_j^{(norma)}$ es el coeficiente de ponderación normalizado de la j-ésima muestra, e yj denota el valor predicho de dicha muestra. Para enfatizar aún más la influencia de muestras similares, se introduce una métrica de influencia vecinal. Esta métrica ajusta las ponderaciones calculando la similitud entre cada muestra y las muestras circundantes. La fórmula de cálculo para la influencia vecinal se define como:

$$En = \sum_{j=1}^{n} \exp(-\beta \cdot |zi - zj|) \tag{16}$$

donde zj representa los resultados predichos de las muestras y β es un hiperparámetro que controla la sensibilidad de la medición de la influencia del vecindario. Para acelerar la convergencia del modelo, el algoritmo CPLE ajusta dinámicamente la tasa de aprendizaje en función de los pesos de las muestras. Suponiendo que la tasa de aprendizaje actual es η , la fórmula de actualización para la tasa de aprendizaje dinámica se define de la siguiente manera:

$$\eta^{(t+1)} = \eta^{(t)} \cdot \left(1 + \gamma \cdot \sum_{i=1}^{n} \omega_i^{(norma)} \cdot \varepsilon_i\right) \tag{17}$$

donde ω (t) es la tasa de aprendizaje actual, γ es la tasa de ajuste de la tasa de aprendizaje, $\omega_i^{(norma)}$ denota el i normalizado η es el coeficiente de ponderación de la i-ésima muestra, y i representa el error de predicción de la muestra. Para optimizar la función de pérdida ponderada, la actualización del gradiente durante la retropropagación se ajusta en función de los coeficientes de ponderación de la muestra. Suponiendo que el gradiente de la función de pérdida es L, la actualización del gradiente ponderado se calcula como:

Machine Translated by Google
www.nature.com/scientificreports/

$$L_{ponderado} = \sum_{i=1}^{n} \omega_i^{(norma)} \cdot L(yi, yi) \quad (18)$$

donde L(yi, yi) denota el gradiente estándar de la i-ésima muestra, y ω es su coeficiente de ponderación correspondiente. (norma)
Al incorporar estos mecanismos, el algoritmo CPLE permite que el modelo sea más sensible a la detección de eventos anómalos y se adapte de manera más flexible a las características y la dificultad de predicción de las muestras individuales durante el entrenamiento. Para facilitar una comprensión más clara del algoritmo de Estimación de Verosimilitud Pesimista de Comparación Integrada (CPLE), su estructura se presenta en formato de pseudocódigo en (Algoritmo 3).

Input: Training samples with predicted results z, true labels y, number of samples n, regularization coefficient λ, adjustment parameters α, β, learning rate η
Output: Optimized model
// Update sample weights
1: for i = 1 to n do
2: $\omega_i \leftarrow$ OriginalWeight(i)
3: $\omega_i^{(norm)} \leftarrow \omega_i$ / sum(ω_j for j = 1 to n)
4: end for
// Adjust loss function
5: Weighted_loss ← 0
6: for i = 1 to n do
7: $Loss_i \leftarrow$ StandardLossFunction(y_i, PredictedOutput_i)
8: Weighted_loss ← Weighted_loss + $\omega_i^{(norm)} * Loss_i$
9: end for
10: Regularization_term ← λ * sum(ω_i^2 for i = 1 to n)
11: Total_loss ← Weighted_loss + Regularization_term
// Calculate anomaly measure
12: for i = 1 to n do
13: $\epsilon_i \leftarrow |z_i - y_i|$
14: $D_i \leftarrow \exp(-\alpha * \epsilon_i)$
15: end for
// Adjust predictions
16: for i = 1 to n do
17: Adjusted_prediction_i ← sum($\omega_j^{(norm)}$ * PredictedOutput_j for j = 1 to n) / sum($\omega_j^{(norm)}$ for j = 1 to n)
18: end for
// Calculate neighborhood influence
19: for i = 1 to n do
20: $N_i \leftarrow$ sum(exp(-β * $|z_i - z_j|$) for j = 1 to n)
21: end for
// Update learning rate
22: for t = 1 to number_of_training_epochs do
23: $\eta^{(t+1)} \leftarrow \eta^t * (1 + \gamma *$ sum($\omega_i^{(norm)} * \epsilon_i$ for i = 1 to n))
24: end for

Algoritmo 3. Algoritmo de estimación de probabilidad pesimista de comparación integrada (CPLE).

Machine Translated by Google
www.nature.com/scientificreports/

Análisis del experimento y de los resultados

Selección del conjunto de datos y configuración de parámetros experimentales y proceso

Este estudio utiliza múltiples conjuntos de datos reales de tráfico en autopistas que abarcan una amplia gama de anomalías, como accidentes automovilísticos, congestión y cambios inducidos por el clima. Estos conjuntos de datos, recopilados en diversas regiones geográficas y condiciones ambientales, proporcionan representaciones detalladas de las características y patrones de anomalías variados, lo que los hace idóneos para analizar las variaciones del flujo de tráfico y predecir eventos anómalos en las autopistas.

Los principales conjuntos de datos de tráfico de carreteras utilizados en esta investigación incluyen:

(1) Conjunto de datos METR-LA [datos de flujo de tráfico de Los Ángeles, https://github.com/liyaguang/DCRNN]: Origen
Este conjunto de datos, procedente de la red de autopistas del área de Los Ángeles, contiene información sobre el flujo de tráfico recopilada mediante múltiples detectores de bucle. Incluye indicadores clave como la velocidad de los vehículos, la densidad del tráfico y el caudal, registrados a intervalos de cinco minutos en diversos periodos. El conjunto de datos es idóneo para la predicción del flujo de tráfico y la detección de eventos anómalos. Captura diversas anomalías de tráfico, como congestión, accidentes y actividades de mantenimiento vial.

(2) Conjunto de datos PEMS-BAY [Datos de flujo de tráfico del Área de la Bahía, https://github.com/liyaguang/DCRNN]: Este conjunto de datos, recopilado del sistema de monitoreo de tráfico del Área de la Bahía de San Francisco, contiene información detallada de sensores que abarca el flujo vehicular y la velocidad de los vehículos en múltiples intersecciones. Los datos se registran a intervalos de cinco minutos e incluyen indicadores clave como la velocidad y el volumen de tráfico. Este conjunto de datos es ideal para la predicción del flujo vehicular, el análisis de patrones y la detección de anomalías. Captura diversas anomalías de tráfico, como fluctuaciones del flujo vehicular inducidas por el clima, accidentes repentinos e intervenciones de control vehicular.

Dada la diversidad de orígenes y características de estos conjuntos de datos, se implementaron varios pasos de preprocesamiento para garantizar la calidad y la coherencia de los datos de entrada del modelo:

(1) Limpieza de datos y eliminación de ruido: Los conjuntos de datos se limpiaron inicialmente para eliminar las entradas corruptas o faltantes, que son comunes en los datos de sensores de tráfico del mundo real. Las lecturas anómalas causadas por fallas en los sensores se manejaron mediante la detección de valores atípicos, seguida de interpolación o exclusión según correspondiera.
(2) Normalización y estandarización: Dado que los conjuntos de datos provienen de distintas regiones (Los Ángeles y el Área de la Bahía) y pueden presentar rangos de valores variables (por ejemplo, unidades de velocidad o densidad), todas las características numéricas se normalizaron a una escala común. Se aplicó la normalización mínimo-máximo a características como la velocidad del vehículo y la densidad del tráfico para transformar los valores en un rango estandarizado (normalmente [0, 1]). Este paso ayuda a prevenir el sesgo hacia las características dominantes y mejora la estabilidad y la convergencia del entrenamiento.

(3) Alineación temporal: Dada la resolución temporal compartida de intervalos de cinco minutos, todos los datos se sincronizaron para garantizar la coherencia temporal en todo el conjunto de datos. Se ajustaron las ventanas de tiempo cuando fue necesario para alinear las observaciones, asegurando una representación coherente de los patrones de tráfico y los eventos anómalos a lo largo del tiempo.
(4) Manejo de datos faltantes: Los datos faltantes, un desafío inherente a los conjuntos de datos de tráfico, se abordaron mediante técnicas de interpolación. Se aplicó interpolación lineal a los intervalos cortos, mientras que se emplearon métodos más avanzados, como el relleno hacia adelante o hacia atrás, para períodos más largos de datos faltantes. Estos pasos aseguraron la continuidad y confiabilidad de los datos para un entrenamiento efectivo del modelo.

(5) Ingeniería e integración de características: Para mejorar el rendimiento del modelo, se derivaron características adicionales mediante el cálculo de promedios móviles y variaciones temporales en la densidad del tráfico en múltiples ventanas de tiempo, capturando así las fluctuaciones a corto plazo. Posteriormente, los datos de diferentes fuentes se integraron en un formato unificado, donde cada punto de datos incluía un atributo de tráfico (p. ej., flujo, velocidad, densidad), junto con las marcas de tiempo y la ubicación del sensor correspondientes. Este proceso de integración alineó los conjuntos de datos METR-LA y PEMS-BAY dentro de un espacio de características común, lo que permitió la comparación y fusión directas.

(6) Etiquetado de anomalías: Las anomalías de tráfico, como la congestión, los accidentes y las interrupciones relacionadas con el clima, se etiquetaron a partir de registros de eventos conocidos y patrones de detección basados en datos (por ejemplo, aumentos o disminuciones repentinas en el flujo de tráfico). Este etiquetado permitió el aprendizaje supervisado, lo que posibilitó que el modelo reconociera y predijera eventos anormales similares con mayor precisión.

Mediante los pasos de preprocesamiento mencionados, los datos de entrada se estandarizaron y limpiaron eficazmente, cumpliendo con los requisitos de calidad y consistencia necesarios para una predicción precisa y la detección de anomalías en diferentes regiones de carreteras. El conjunto de datos integrado resultante contenía características de tráfico uniformes y relevantes de múltiples regiones, lo que permitió un análisis más sólido y una predicción más fiable de los patrones y anomalías del tráfico.

Los conjuntos de entrenamiento y validación se construyeron para asegurar que el modelo pudiera aprender y generalizar eficazmente en diversos escenarios de tráfico. El conjunto de entrenamiento consistió en datos de flujo de tráfico de los conjuntos de datos METR-LA y PEMS-BAY, que se normalizaron y alinearon temporalmente para incluir características como la velocidad del vehículo, el caudal y la densidad del tráfico en múltiples segmentos de carretera y periodos de tiempo. Para abordar el desequilibrio de clases, se aplicaron métodos de sobremuestreo y submuestreo para equilibrar las muestras de eventos normales y anormales. El conjunto de validación se seleccionó aleatoriamente de los datos brutos para asegurar que no hubiera solapamiento con el conjunto de entrenamiento, y se diseñó para evaluar el rendimiento de generalización del modelo en diversas condiciones de tráfico. La proporción de división entre entrenamiento y validación se estableció en 80:20, lo que garantiza un aprendizaje suficiente a la vez que se preserva un conjunto de evaluación fiable.

Durante el experimento, todos los conjuntos de datos se sometieron a un proceso de preprocesamiento consistente para garantizar una alta calidad de los datos. Esto incluyó rellenar los valores faltantes mediante interpolación y el método del vecino más cercano, detectar y corregir valores atípicos mediante métodos estadísticos y estandarizar todas las características para garantizar la compatibilidad con los modelos de aprendizaje profundo. Los datos se segmentaron en series temporales de acuerdo con los requisitos experimentales para generar conjuntos de entrenamiento y prueba. Se utilizó una proporción de división estándar de 80:20 entre los datos de entrenamiento y prueba para preservar ambos

Machine Translated by Google
www.nature.com/scientificreports/

Representatividad de los datos y capacidad de generalización del modelo. Las configuraciones específicas de los parámetros del modelo se resumen en la Tabla 1.

Selección del modelo de comparación y del indicador de evaluación

En la simulación experimental, además de implementar el modelo MHGNN-CPLE propuesto, se seleccionaron dos modelos de referencia avanzados para el análisis comparativo: la Red de Memoria a Largo Plazo Convolucional de Grafos Adaptativa (AGC-LSTM) con un mecanismo de autoatención y el Modelo de Agregación Profunda con Atención (AttentionDeepST). AGC-LSTM combina redes de convolución de grafos con arquitecturas LSTM e integra un mecanismo de autoatención para capturar eficazmente las características espaciotemporales relevantes durante el proceso de fusión, mejorando así la precisión de la predicción. El modelo AttentionDeepST emplea una estructura de agregación profunda multinivel junto con un mecanismo de autoatención multimodal, lo que lo hace idóneo para escenarios de fusión complejos al mejorar tanto la precisión como la estabilidad. Estos modelos se seleccionaron para validar la eficacia y el avance del marco algorítmico propuesto.

Para evaluar exhaustivamente el rendimiento del modelo, se adoptaron cuatro métricas ampliamente utilizadas: precisión27, exhaustividad28, puntuación F129 y área bajo la curva (AUC)30. Al comparar estos indicadores, obtenemos una comprensión multidimensional de las capacidades del modelo en relación con los métodos de referencia para detectar eventos de tráfico anómalos.
Esto proporciona una base cuantitativa para evaluar la eficacia del enfoque propuesto y orientar la optimización posterior del modelo.

Resultados experimentales y análisis de rendimiento

El algoritmo propuesto en este estudio se aplica a la detección y predicción de eventos de tráfico anómalos tanto en escenarios estáticos como dinámicos.
Como parte del análisis, este artículo examina primero un caso de congestión vehicular anormal causada por un accidente en un túnel. La información sobre el flujo vehicular dentro del túnel se recopila mediante sensores de adquisición de imágenes, como se ilustra en la Figura 3. Inicialmente, se identifican los posibles riesgos de congestión en el área monitoreada mediante técnicas básicas de detección de vehículos y estimación de distancias, lo que permite la detección temprana de condiciones de tráfico anormales.

A partir de los resultados de detección mostrados en la figura anterior, se observa que el flujo de tráfico dentro del túnel presenta patrones basados en una sola imagen de vídeo. Sin embargo, esta información por sí sola es insuficiente para determinar el tipo específico de evento anómalo. Para abordar esta limitación, este estudio integra modalidades adicionales, como la velocidad media vehicular en tiempo real, el flujo de tráfico y la tasa de incidentes, correspondientes al período de tiempo analizado. Estas características se combinan para formar una representación integral que integra información visual, datos del entorno de tráfico y otras señales contextuales, como se ilustra en la figura 4.

A partir del procesamiento de los datos de características mencionados, se utilizó la información multimodal para detectar y predecir eventos anómalos en el tráfico de la autopista. El análisis se realizó en múltiples escenarios, incluyendo condiciones normales, clima extremo, congestión vehicular y accidentes, como se ilustra en la Figura 5.

Mediante la predicción y el análisis de eventos anómalos de tráfico en los tres escenarios mencionados, e integrando información como las condiciones meteorológicas, el flujo de tráfico y la velocidad media de los vehículos en diferentes tramos de carretera, se examinaron las tasas de ocurrencia de diversos tipos de accidentes. Los resultados estadísticos se presentan en la Tabla 2.

Con base en los resultados experimentales presentados anteriormente, el modelo propuesto demuestra su capacidad para detectar y predecir diversos tipos de anomalías de tráfico en autopistas mediante datos multimodales fusionados. Los resultados muestran que el modelo puede identificar eficazmente múltiples categorías de eventos de tráfico anómalos con alta precisión. En las comparaciones entre los tipos de eventos reales y los resultados predichos, el modelo logra una sólida consistencia predictiva.
Por ejemplo, en la congestión del tráfico, los tipos de eventos predichos coinciden estrechamente con las observaciones reales, y las probabilidades de anomalía predichas son casi idénticas a los valores reales. Por ejemplo, cuando la velocidad del vehículo es de 40,5 km/h y el flujo de tráfico es de 150,2 vehículos, las probabilidades reales y predichas de congestión son 0,85 y 0,83, respectivamente. Del mismo modo, para los accidentes de tráfico y las anomalías relacionadas con el clima, el modelo proporciona predicciones precisas, y las diferencias entre las probabilidades predichas y reales se mantienen dentro de límites aceptables.

Parámetro	Establecer valor	Explicar
Figura de las capas de la red neuronal	3 capas	Establezca el número de capas en la red neuronal gráfica para extraer dependencias espaciales en la estructura del grafo.
Tasa de aprendizaje	0,001	Tasa de aprendizaje inicial, utilizando el optimizador Adam.
Tamaño del lote	64	El número de muestras introducidas durante cada sesión de entrenamiento.
Estrategia de ponderación de muestras del algoritmo CPLE	Ponderación lineal	La estrategia de ponderación de muestras utiliza un esquema de ponderación lineal para potenciar la influencia de los diferentes tipos de muestras.
duración de la ventana de tiempo	10 unidades de tiempo (5 min/unidad)	Longitud de la ventana deslizante utilizada para datos de series temporales.
Épocas de entrenamiento	100 rondas	El número total de rondas de entrenamiento de la red hasta que el modelo converge.
Parámetros de regularización del modelo	0,0001	Se utiliza el parámetro de regularización L2 para evitar el sobreajuste.
Función de activación	reanudar	Función de activación utilizada para las capas ocultas con el fin de mejorar la capacidad de ajuste no lineal.
Tamaño de la capa oculta	128 neuronas	El número de neuronas en la capa oculta de una red neuronal gráfica.
tasa de abandono	0,5	Se utiliza la tasa de abandono (dropout) para evitar el sobreajuste.
Método de modelado de efectos no lineales	GCN combinado con LSTM (modo dual)	Combinación de redes neuronales convolucionales gráficas (GCN) y redes de memoria a corto y largo plazo (LSTM) para modelar efectos de interacción no lineales.
función objetivo	MSE (error cuadrático medio)	Medida de error utilizada en tareas de regresión para optimizar la precisión de las predicciones del modelo.

Tabla 1. Configuración de los parámetros del modelo experimental.

Machine Translated by Google
www.nature.com/scientificreports/

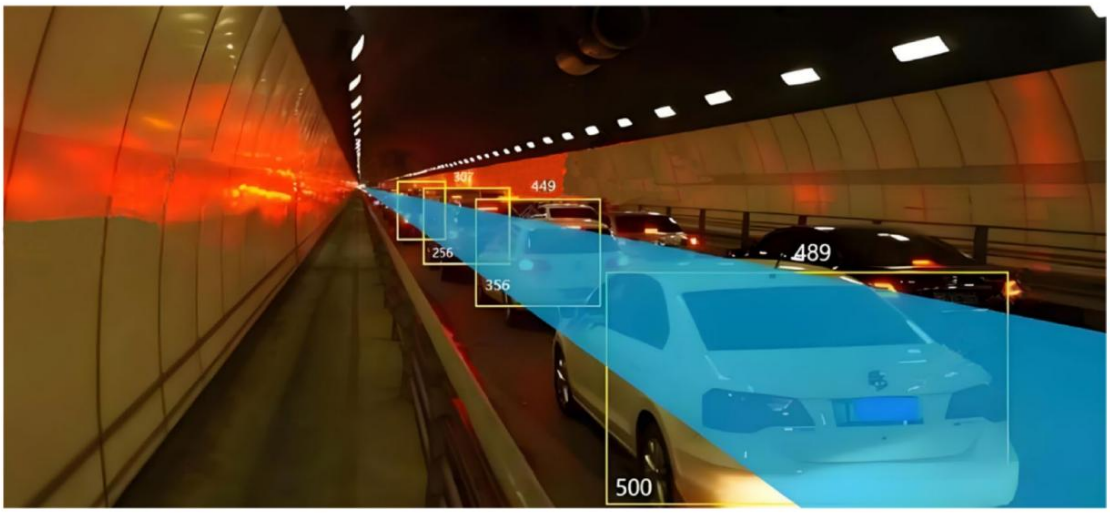


Figura 3. Monitorización de la información de imágenes y vídeos en condiciones de congestión de tráfico en un túnel.

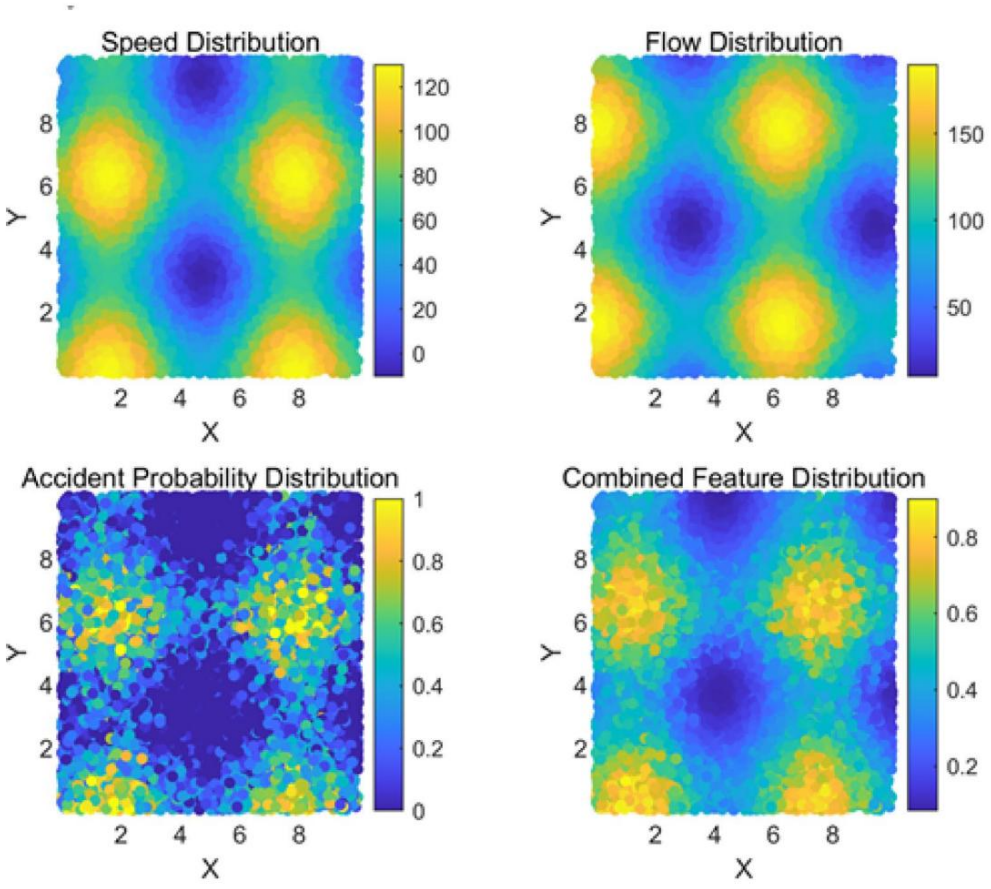


Figura 4. Datos de características fusionadas.

márgenes —demostrando sólidas capacidades de reconocimiento. En condiciones normales de tráfico, el modelo mantiene bajas probabilidades de predicción de anomalías, en consonancia con la situación real. Por ejemplo, a una velocidad de 60,4 km/h y un flujo vehicular de 130,3 vehículos, las probabilidades de anomalía predicha y real son 0,27 y 0,25, respectivamente. En resumen, la integración de datos de características multimodales mejora significativamente la precisión y la estabilidad del modelo para detectar y predecir anomalías de tráfico en diversos escenarios.

Además, los resultados de detección indican que el algoritmo propuesto funciona bien en el análisis de anomalías estáticas en autopistas. Para validar aún más la capacidad de detección dinámica del marco, se utilizó video en tiempo real.

Machine Translated by Google
www.nature.com/scientificreports/



Figura 5. Escenario típico de análisis predictivo.

Velocidad (km/h)	Flujo (vehículos)	Clima (índice)	Hora del día (índice)	Tipo de evento real	Probabilidad real de anomalía	Tipo de evento previsto	Probabilidad de anomalía prevista
40.5	150.2	0,80	0,9	Congestión de tráfico	0,85	Congestión del tráfico	0,83
20.3	90.7	0,90	0,2	Accidente	0,92	Accidente	0,91
60.4	130.3	0,75	0,6	Tráfico normal	0,25	Tráfico normal	0,27
35.8	175.0	0,70	0,8	Congestión de tráfico	0,78	Congestión del tráfico	0,79
50.2	100.1	0,85	0,4	Tráfico normal	0,18	Tráfico normal	0,20
5.0	50.0	1.00	0,3	Relacionado con el clima	0,90	Relacionado con el clima	0,88
15.2	95.3	0,95	0.1	Accidente	0,91	Accidente	0,89
55.0	120.0	0,70	0,7	Tráfico normal	0,30	Tráfico normal	0,32
80.3	160.2	0,60	0,5	Tráfico normal	0,22	Tráfico normal	0,23
10.5	180.1	0,85	0,9	Congestión de tráfico	0,80	Congestión del tráfico	0,82

Tabla 2. Resultados de la predicción de eventos anormales de tráfico bajo diferentes entradas de información fusionada.

Se incorporaron flujos de datos e información de series temporales de sensores para permitir el monitoreo continuo de eventos de tráfico anómalos en tramos de autopista. Los resultados de la percepción de las características de entrada en diferentes dimensiones del escenario, junto con las salidas fusionadas dinámicamente, se ilustran en la figura 6.

Como se ilustra en la Fig. 3, los resultados de la detección de anomalías basada en pulsos en cuatro escenarios de eventos de tráfico son: resumido de la siguiente manera:

En el escenario de “tráfico normal”, la señal permanece estable, sin fluctuaciones significativas, y anormal
La actividad de pulsos es mínima. La fluctuación máxima es de aproximadamente 0,3, lo que indica condiciones estables.

En el escenario de "accidente", aparece un pulso distintivo en la señal a los 40 segundos, con una amplitud de 0,5. El algoritmo de detección identifica y marca correctamente esta anomalía, demostrando una gran sensibilidad a las interrupciones repentinas.

En el caso de "congestión de tráfico", la señal presenta fluctuaciones periódicas con una amplitud de 0,3. Si bien el algoritmo detecta pulsos anormales frecuentes, el escenario muestra una tasa de falsas alarmas relativamente alta, lo que indica dificultades para distinguir entre anomalías reales relacionadas con la congestión y fluctuaciones normales.

En condiciones de "impacto meteorológico", la señal muestra una forma de onda de baja frecuencia similar a un coseno con variaciones de amplitud de aproximadamente 0,2. Si bien el algoritmo captura con precisión la tendencia de la anomalía, los errores de detección son ligeramente mayores en comparación con otros escenarios.

Además, se realizaron experimentos de simulación bajo diferentes niveles de ruido (que oscilan entre 0,05 y 0,3). Los resultados muestran que, a medida que aumenta el ruido, la precisión de detección de anomalías disminuye gradualmente, especialmente en entornos con mucho ruido. Sin embargo, el aumento del error de detección sigue siendo relativamente pequeño, lo que pone de relieve la

Machine Translated by Google
www.nature.com/scientificreports/

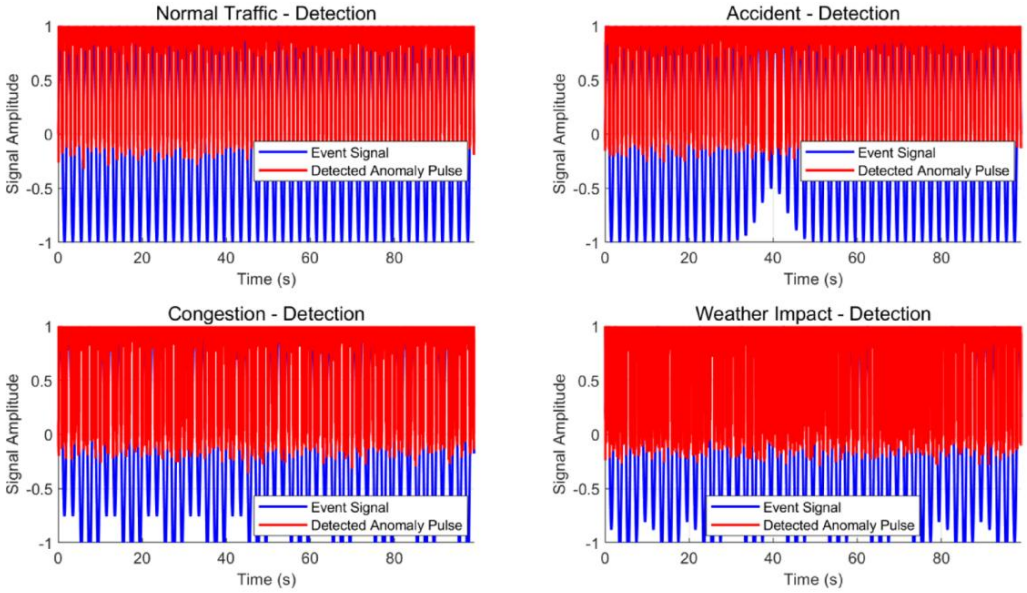


Figura 6. Diagrama de señal de pulso de los resultados de detección de eventos anormales dinámicos en cuatro escenarios diferentes.

Escenario del evento	Precisión	Exactitud	Tasa de recuperación	Puntuación F1	AUC (área bajo la curva)
Tráfico normal	0,965	0,980	0,950	0,965	0,985
accidente	0,960	0,980	0,940	0,960	0,975
Congestión	0,950	0,965	0,930	0,960	0,970
de tráfico Impacto del clima	0,955	0,975	0,930	0,952	0,980

Tabla 3. Indicadores generales de rendimiento del modelo de algoritmo presentado en este artículo para la detección dinámica de anomalías de tráfico en autopistas.

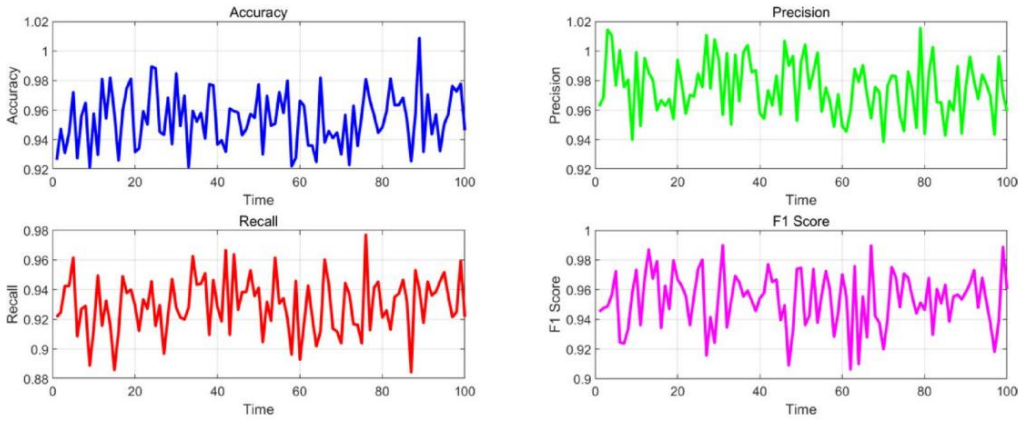


Figura 7. Cambios en varios indicadores de rendimiento en la dimensión temporal en escenarios normales.

Robustez del modelo propuesto frente a la interferencia de ruido en tareas de detección en tiempo real. La Tabla 3 muestra los resultados de detección dinámica según diversas métricas de evaluación, promediados en 1000 ensayos de simulación.

Para evaluar con mayor precisión la estabilidad de diversas métricas de rendimiento en diferentes escenarios de tráfico a lo largo del tiempo, este estudio monitoreó y analizó la evolución temporal de los indicadores clave de rendimiento durante el experimento. Se observaron y registraron los cambios en los parámetros de rendimiento en cada escenario, como se ilustra en las figuras 7, 8, 9 y 10. La variación temporal de las métricas de rendimiento en el escenario de tráfico normal se presenta en la figura 7.

En la figura 8 se muestran los cambios en la dimensión temporal de varios indicadores en el escenario del accidente.

En la figura 9 se muestran los cambios en varios indicadores en la dimensión temporal bajo escenarios de congestión.

Machine Translated by Google
www.nature.com/scientificreports/

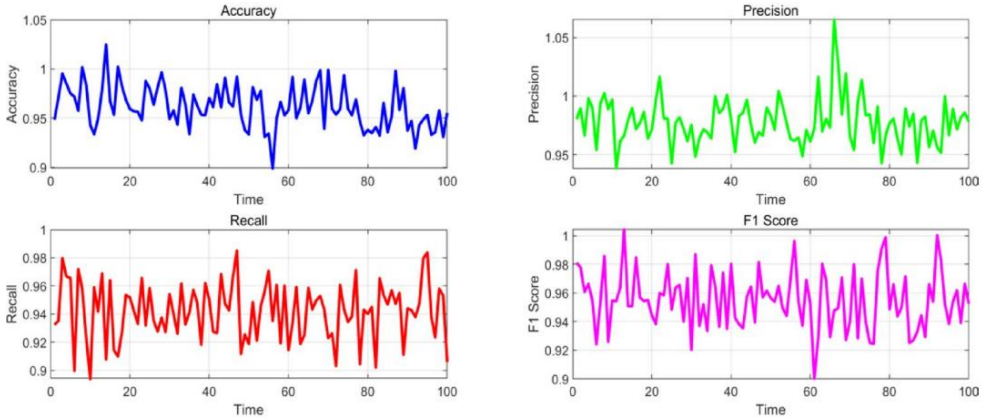


Figura 8. Cambios en varios indicadores de rendimiento en la dimensión temporal bajo escenarios de accidentes.

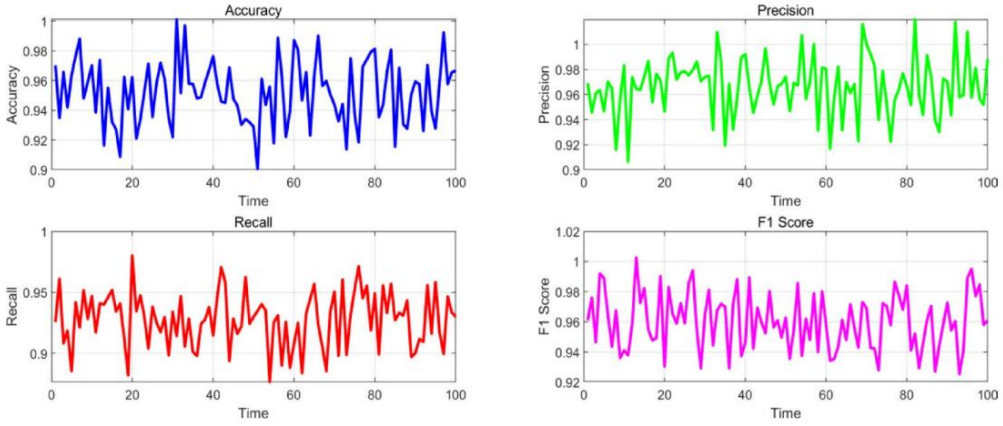


Figura 9. Cambios en varios indicadores de rendimiento en la dimensión temporal en escenarios de congestión.

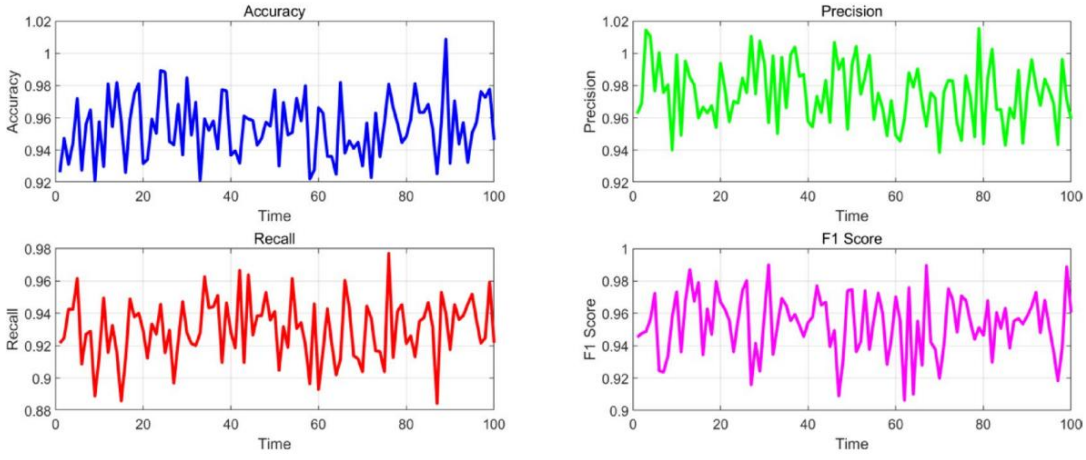


Figura 10. Cambios en varios indicadores de rendimiento en la dimensión temporal bajo la influencia de condiciones climáticas adversas.

Las tendencias cambiantes de varios indicadores en la dimensión temporal bajo la influencia de condiciones meteorológicas adversas. Las condiciones se muestran en la (Fig. 10).

Según los resultados experimentales, el algoritmo propuesto demuestra un sólido rendimiento general en la detección dinámica de anomalías de tráfico en autopistas. En diversos escenarios de eventos, incluyendo tráfico normal, accidentes, congestión y perturbaciones relacionadas con el clima, el modelo logra puntuaciones altas en los indicadores clave de rendimiento.

Machine Translated by Google
www.nature.com/scientificreports/

Algoritmo del modelo	Precisión	Exactitud	Tasa de recuperación	Puntuación F1	AUC (área bajo la curva)
MHGNN-CPLE	0,980		0,975	0,960	0,967	0,985
AGC-LSTM	0,965	0,950	0,940	0,945	0,960
AtenciónProfundaST	0,960	0,940	0,930	0,935	0,950

Tabla 4. Comparación del rendimiento de la detección estática (escenario de flujo de tráfico).

Algoritmo del modelo	Precisión	Exactitud	Tasa de recuperación	Puntuación F1	AUC (área bajo la curva)
MHGNN-CPLE	0,975		0,960	0,950	0,955	0,980
AGC-LSTM	0,950	0,945	0,920	0,932	0,965
AtenciónProfundaST	0,940	0,930	0,910	0,920	0,960

Tabla 5. Comparación del rendimiento de la predicción estática (escenario de predicción del flujo de tráfico).

Métricas como exactitud, precisión, exhaustividad, puntuación F1 y área bajo la curva (AUC). En escenarios de tráfico normales, el modelo alcanza una exactitud de 0,965, una precisión de 0,980, una exhaustividad de 0,950, un valor F1 de 0,965 y un AUC de 0,985, lo que indica excelentes capacidades de detección. En escenarios de accidentes y congestión, el rendimiento es ligeramente inferior, pero se mantiene en un nivel alto, con una exactitud y puntuaciones F1 cercanas a 0,96. En condiciones climáticas adversas, el modelo mantiene un rendimiento relativamente estable, con todas las métricas de evaluación cercanas o superiores a 0,95. Estos resultados demuestran la robustez y fiabilidad del algoritmo propuesto en diversos escenarios de tráfico, confirmando su eficacia en tareas de detección dinámica de anomalías en el tráfico.

Análisis experimental comparativo con modelos de algoritmos existentes
Para validar el avance del algoritmo propuesto en relación con los modelos existentes, este estudio realiza un análisis comparativo mediante simulaciones experimentales. En concreto, el modelo MHGNN-CPLE diseñado se evalúa frente a dos modelos de referencia que incorporan mecanismos de autoatención: la red neuronal convolucional adaptativa de memoria a largo y corto plazo (AGC-LSTM) y el modelo de agregación espaciotemporal profunda basado en atención (AttentionDeepST).

Como enfoque inicial, se considera la tarea de detección estática en un escenario de flujo de tráfico. Esta tarea está diseñada para evaluar la capacidad de los modelos para identificar y clasificar con precisión los estados del tráfico (como normal, congestionado, etc.) dentro de periodos de tiempo específicos. La detección estática generalmente requiere una alta precisión y fiabilidad de clasificación en segmentos de datos invariables en el tiempo. En este experimento, se evalúa y compara el rendimiento de los modelos MHGNN-CPLE, AGC-LSTM y AttentionDeepST utilizando métricas de evaluación estándar. Los resultados de la tarea de detección estática se resumen en la Tabla 4.

Los resultados experimentales demuestran que MHGNN-CPLE logra un rendimiento superior en tareas de detección estática, con una precisión de 0,980, superando significativamente a los otros dos modelos. AGC-LSTM alcanza una precisión de 0,950, pero su menor exhaustividad sugiere la posibilidad de detecciones omitidas durante el proceso de clasificación. Por el contrario, aunque AttentionDeepST logra una precisión ligeramente superior (0,960) a la de AGC-LSTM, su menor precisión y exhaustividad resultan en una puntuación F1 reducida de 0,935, lo que indica un rendimiento de clasificación general más débil. En resumen, MHGNN-CPLE no solo lidera en precisión, sino que también alcanza un AUC de 0,985, lo que subraya su robustez y fiabilidad en el procesamiento de datos de flujo de tráfico en condiciones estáticas.

En escenarios estáticos, la predicción del flujo de tráfico depende de la capacidad del modelo para capturar con precisión patrones temporales a partir de datos históricos. Para evaluar el rendimiento predictivo, este estudio compara MHGNN-CPLE, AGC-LSTM y AttentionDeepST en tareas de predicción de flujo de tráfico estático. Los resultados comparativos se presentan en la Tabla 5.

Como se muestra en los resultados experimentales, MHGNN-CPLE logra el mejor rendimiento predictivo entre los modelos evaluados, con una precisión de 0,975 y valores consistentemente altos tanto en precisión como en exhaustividad. Estos resultados resaltan la gran capacidad del modelo en la predicción del flujo de tráfico. Además, el valor AUC de 0,980 valida aún más su estabilidad y fiabilidad predictiva en escenarios del mundo real. En comparación, AGC-LSTM exhibe un rendimiento relativamente equilibrado, con una precisión de 0,950, pero valores ligeramente inferiores en precisión y exhaustividad. Su puntuación F1 de 0,932 sugiere que puede adoptar una estrategia más conservadora en la predicción del flujo de tráfico, lo que podría llevar a una subdetección en algunos casos. AttentionDeepST, sin embargo, se desempeña menos eficazmente en tareas de predicción estática. Una brecha notable entre su precisión y exhaustividad resulta en una puntuación F1 más baja de 0,920, lo que indica un rendimiento predictivo general más débil en comparación con los otros dos modelos. Los resultados comparativos se visualizan en (Fig. 11).

En segundo lugar, en escenarios dinámicos, el objetivo principal es identificar y detectar accidentes de tráfico en tiempo real. El principal desafío de la detección dinámica radica en capturar con precisión el momento exacto en que ocurre un accidente y clasificarlo eficazmente. Esta tarea requiere que los modelos respondan de forma rápida y fiable de manera continua. Para evaluar la capacidad de detección dinámica del modelo propuesto, se realizó un experimento comparativo utilizando los modelos MHGNN-CPLE, AGC-LSTM y AttentionDeepST. Su rendimiento se evaluó en términos de precisión, tasa de recuperación y puntuación F1 en escenarios de detección de accidentes. Los resultados de esta evaluación se presentan en la Tabla 6.

Machine Translated by Google
www.nature.com/scientificreports/

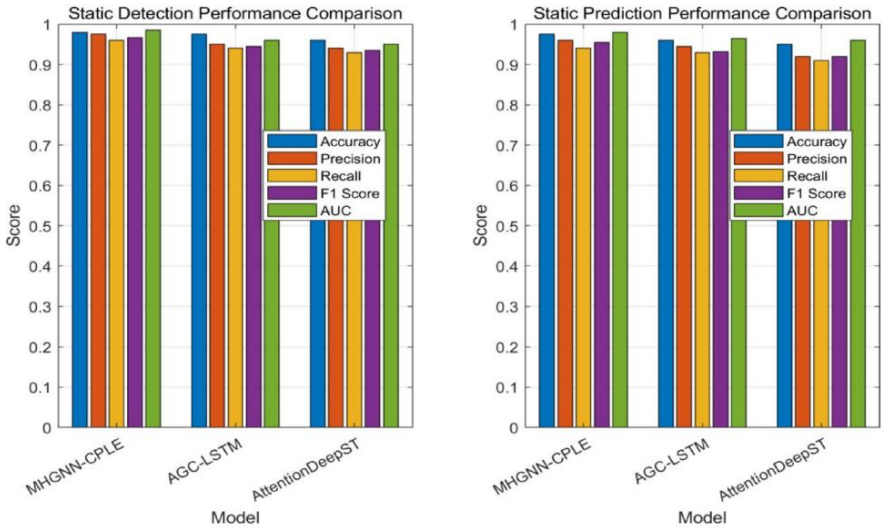


Figura 11. Comparación del rendimiento de detección y predicción de diferentes modelos de algoritmos en escenas estáticas.

Algoritmo del modelo Precisión Exactitud Tasa de recuperación Puntuación F1 AUC (área bajo la curva)					
MHGNN-CPLE 0.950		0,960	0,930	0,945	0,970
AGC-LSTM	0,940	0,950	0,910	0,930	0,960
AtenciónProfundaST 0,920		0,920	0,890	0,905	0,950

Tabla 6. Comparación del rendimiento de detección dinámica (Escenario de detección de accidentes).

Algoritmo del modelo Precisión Exactitud Tasa de recuperación Puntuación F1 AUC Robustez Significancia							Estabilidad
MHGNN-CPLE 0.940		0,950	0,920	0,935	0,965 Alto	Muy significativo Muy alto	
AGC-LSTM	0,925	0,930	0,900	0,915	0,950 Medio	Significativo	Alto
AtenciónProfundaST 0,910		0,900	0,880	0,890	0,930 Medio	Moderado	Medio

Tabla 7. Comparación del rendimiento de la predicción dinámica (escenarios de predicción de accidentes).

Los resultados experimentales indican que MHGNN-CPLE continúa demostrando sus ventajas en tareas de detección dinámica de accidentes. Alcanza una precisión de 0,950, una exactitud de 0,960, una exhaustividad de 0,930, una puntuación F1 de 0,945 y un AUC de 0,970, lo que refleja un rendimiento sólido y equilibrado en todos los indicadores clave. En comparación, si bien AGC-LSTM también tiene un buen desempeño, su tasa de exhaustividad es ligeramente inferior (0,910), lo que puede provocar detecciones fallidas en escenarios de accidentes críticos en el tiempo. AttentionDeepST, por el contrario, muestra un rendimiento relativamente modesto en esta tarea, con una precisión de 0,920 y una exhaustividad de 0,890. Sus resultados generales son más conservadores, lo que podría resultar en una mayor tasa de informes de accidentes no detectados. Estos hallazgos resaltan las fortalezas integrales de MHGNN-CPLE, que supera consistentemente a los modelos de referencia en la detección dinámica de accidentes, particularmente en el equilibrio entre la precisión de detección y la capacidad de respuesta en tiempo real.

La predicción dinámica de accidentes desempeña un papel fundamental en la gestión inteligente del tráfico, requiriendo modelos que analicen datos de tráfico en tiempo real y pronostiquen la posible ocurrencia de accidentes. El principal desafío reside en la capacidad del modelo para capturar eficazmente las fluctuaciones de la dependencia temporal en los patrones de flujo de tráfico. En este experimento, se evaluó el rendimiento de tres modelos —MHGNN-CPLE, AGC-LSTM y AttentionDeepST— en el contexto de la predicción dinámica de accidentes. Los resultados comparativos se presentan en la Tabla 7.

En escenarios de predicción de accidentes, el modelo MHGNN-CPLE ofrece el mejor rendimiento con los indicadores de rendimiento más altos, especialmente en términos de precisión (0,940), exactitud (0,950), exhaustividad (0,920) y AUC (0,965), demostrando una excelente capacidad predictiva. Además, su robustez fue calificada como "alta", su significancia como "muy significativa" y su robustez como "muy alta", lo que indica que el modelo puede mantener una excelente estabilidad y confiabilidad en diferentes entornos de datos. Por el contrario, aunque el modelo AGC-LSTM tiene un rendimiento ligeramente inferior con una exactitud de 0,925, una exactitud de 0,930, una exhaustividad de 0,900, una puntuación F1 de 0,915 y un AUC de 0,950, aún demuestra un rendimiento sólido. Su robustez es "moderada", su significancia es "significativa" y su robustez es "alta", lo que indica que el modelo funciona bien en la mayoría de los casos, pero puede ser ligeramente inadecuado en ciertos contextos específicos. El modelo AttentionDeepST ocupa el último lugar entre todos los indicadores, con una precisión de 0,910, una exactitud de 0,900, una exhaustividad de 0,880, una puntuación F1 de 0,890 y un AUC de 0,930, lo que indica un rendimiento predictivo relativamente bajo. Su robustez es "moderada", su significancia es "moderada" y su robustez es "moderada", lo que indica que el modelo puede

Machine Translated by Google
www.nature.com/scientificreports/

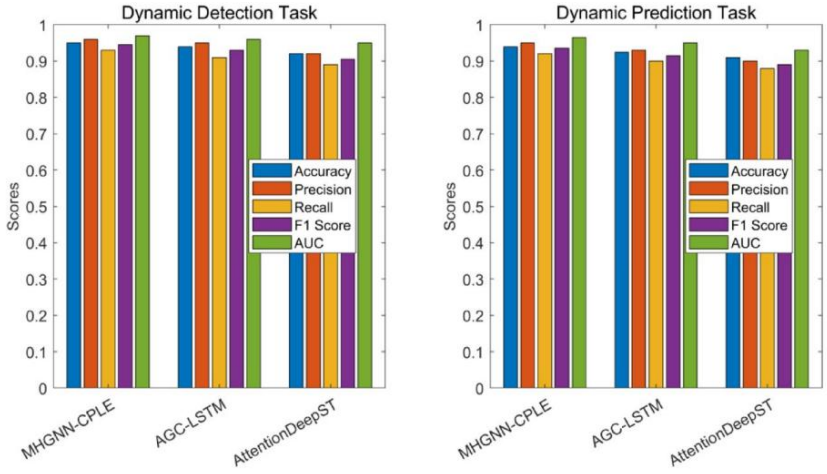


Figura 12. Comparación del rendimiento de la detección y predicción dinámicas en diferentes escenarios.

Modelo Algoritmo Precisión Exactitud Recuperación Puntuación F1 AUC				
MHGNN-CPLE 0,945		0,950	0,930 0,940	0,970
AGC-LSTM	0,920	0,930	0,900 0,915	0,955
AtenciónProfundaST 0.905		0,910	0,880 0,895	0,945

Tabla 8. Rendimiento de generalización entre conjuntos de datos.

No se desempeña tan bien como los dos primeros al trabajar con datos complejos y variables. En general, MHGNN-CPLE es el modelo más competitivo de los tres, adecuado para escenarios de aplicación que requieren alta precisión y estabilidad. AGC-LSTM es adecuado para la mayoría de las aplicaciones, pero puede que no se desempeñe tan bien como MHGNN-CPLE en condiciones extremas o complejas. AttentionDeepST es adecuado para escenarios de aplicación más simples, donde los requisitos de precisión son menos estrictos. La comparación exhaustiva se muestra en la Fig. 12.

Los resultados experimentales demuestran que el marco propuesto, que integra la fusión profunda multimodal y las redes neuronales gráficas heterogéneas (HGNN), logra una precisión y robustez superiores en la detección y predicción de eventos de tráfico anómalos en comparación con los enfoques tradicionales. En particular, la fusión de datos multimodales mejora sustancialmente la capacidad del modelo para capturar características detalladas en escenarios de tráfico complejos. Las HGNN modelan eficazmente las dependencias espaciotemporales, mientras que la introducción del algoritmo CPLE mejora aún más la sensibilidad del modelo a anomalías sutiles y emergentes. En comparación con los métodos existentes, el marco propuesto mantiene un alto rendimiento de forma consistente incluso en entornos desafiantes caracterizados por la complejidad y situaciones ruidosas, lo que confirma su fiabilidad y generalización en aplicaciones de tráfico reales.

Experimento de generalización entre conjuntos de datos

Para evaluar exhaustivamente la capacidad de generalización del marco propuesto, se realizaron experimentos con diferentes conjuntos de datos. En estos experimentos, el modelo se entrenó con un conjunto de datos y se probó con otro no visto para evaluar su adaptabilidad a diversas condiciones y entornos de tráfico. Específicamente, se utilizó el conjunto de datos METR-LA (datos de tráfico de Los Ángeles) para el entrenamiento, mientras que el conjunto de datos PEMS-BAY (datos de tráfico del Área de la Bahía de San Francisco) sirvió como conjunto de prueba. Esta configuración permitió una evaluación realista de la transferibilidad del modelo a través de redes de tráfico geográficamente y estructuralmente distintas. La evaluación se realizó utilizando cinco métricas de rendimiento estándar: precisión, exactitud, exhaustividad, puntuación F1 y AUC. Los resultados del experimento de generalización con diferentes conjuntos de datos se resumen en la Tabla 8.

Los resultados experimentales indican que el modelo MHGNN-CPLE propuesto exhibe un rendimiento de generalización superior en diferentes conjuntos de datos. Al evaluarlo en el conjunto de datos PEMS-BAY, el modelo alcanza una precisión de 0,945 y una puntuación F1 de 0,940, superando significativamente a los modelos de referencia AGC-LSTM y AttentionDeepST. Estos resultados resaltan la gran adaptabilidad del marco a nuevos entornos de tráfico sin necesidad de un reentrenamiento extenso. El modelo AGC-LSTM también demuestra una capacidad de generalización razonable, pero su rendimiento es consistentemente inferior al de MHGNN-CPLE, con una precisión de 0,920 y una puntuación F1 de 0,915, respectivamente. Por el contrario, AttentionDeepST presenta el rendimiento más bajo entre los tres modelos, alcanzando una precisión de 0,905 y una puntuación F1 de 0,895. Esto sugiere que AttentionDeepST podría tener dificultades para capturar los patrones subyacentes y las variaciones estructurales en conjuntos de datos de tráfico previamente desconocidos.

En general, el experimento de generalización entre conjuntos de datos subraya la robustez, la escalabilidad y la aplicabilidad práctica del marco MHGNN-CPLE. Su fuerte transferibilidad entre conjuntos de datos geográficamente distintos lo convierte en una solución prometedora para tareas de detección y predicción de anomalías en el tráfico de carreteras del mundo real, donde

Las condiciones de tráfico heterogéneas y dinámicas son la norma. Esta capacidad de generalización es esencial para el despliegue de sistemas de gestión de tráfico inteligentes, fiables, adaptables e independientes de la región.

experimento de prueba de robustez del modelo

Para evaluar con mayor precisión la robustez del modelo propuesto en diversas condiciones de ruido, se realizó un experimento específico de prueba de robustez. En escenarios reales de detección de anomalías en el tráfico, los datos de entrada suelen verse afectados por diversas formas de ruido, como fallos en los sensores, perturbaciones ambientales o errores de transmisión. Por lo tanto, garantizar la estabilidad del modelo en entornos ruidosos es fundamental para su implementación práctica.

En este experimento, se añadió ruido gaussiano de intensidad variable al conjunto de datos original para simular escenarios de corrupción de datos que pueden surgir en aplicaciones reales. Los niveles de ruido se establecieron en 5 %, 10 %, 15 % y 20 %. Al evaluar el rendimiento del modelo bajo estas diferentes condiciones de ruido, analizamos la capacidad de cada modelo para mantener la precisión y la fiabilidad de la detección.

El experimento se realizó utilizando el conjunto de datos PEMS-BAY y se emplearon las métricas de evaluación estándar, incluyendo exactitud, precisión, exhaustividad, puntuación F1 y AUC. Los resultados de la evaluación de robustez para cada modelo se resumen en la Tabla 9.

Los resultados experimentales muestran que, a medida que aumenta la intensidad del ruido, el rendimiento de todos los modelos disminuye en cierta medida. Sin embargo, el modelo MHGNN-CPLE demuestra una mayor resistencia al ruido. Con una intensidad de ruido del 5 %, el modelo MHGNN-CPLE alcanza una precisión de 0,960, una puntuación F1 de 0,960 y un AUC de 0,980.

Incluso con una alta intensidad de ruido del 20%, el modelo MHGNN-CPLE mantiene una precisión de 0,945, una puntuación F1 de 0,945 y un AUC de 0,965. En contraste, el rendimiento de los modelos AGC-LSTM y AttentionDeepST disminuye de forma estadísticamente más significativa. Por ejemplo, con una intensidad de ruido del 20%, el modelo AGC-LSTM tiene una precisión de 0,930 y una puntuación F1 de 0,927, mientras que el modelo AttentionDeepST tiene una precisión de 0,920 y una puntuación F1 de 0,917. Esto indica que el modelo MHGNN-CPLE puede funcionar de forma estable en diferentes niveles de ruido, mostrando una mayor robustez frente al ruido de los datos. Por lo tanto, es más adecuado para los entornos de datos complejos que se encuentran en la detección práctica de eventos anómalos de tráfico.

Análisis de casos de fallo

A pesar de la alta precisión general del marco propuesto, se identificaron algunos casos de fallo durante la validación. Estas clasificaciones erróneas proporcionan información valiosa sobre las limitaciones del modelo.

Un fallo común se produjo en escenarios con condiciones meteorológicas adversas. Por ejemplo, la niebla densa y la nieve ligera a menudo reducían la velocidad de los vehículos y el flujo de tráfico, lo que provocaba una clasificación errónea como congestión de tráfico en lugar de anomalías meteorológicas. En un caso, donde la anomalía real se debía a la niebla (probabilidad real de 0,87), el modelo predijo congestión con una probabilidad de 0,83. Esto pone de manifiesto la dificultad de distinguir anomalías visual y conductualmente similares cuando se depende únicamente de datos de sensores multimodales.

Otro modo de fallo se relacionaba con las actividades de mantenimiento vial, que generaban señales de audio y visuales similares a las producidas durante accidentes menores. En estos casos, el modelo detectaba erróneamente accidentes cuando en realidad se trataba de mantenimiento programado. Por ejemplo, un tramo de carretera en reparación con una ralentización moderada del tráfico y ruido de maquinaria se clasificó incorrectamente como accidente (probabilidad prevista: 0,79; valor real: 0,18).

Estos casos subrayan la necesidad de futuras mejoras en la diferenciación de anomalías, posiblemente a través de integración de metadatos (por ejemplo, programas de mantenimiento) o comunicación entre vehículos e infraestructura.

Estudios de ablación

Para evaluar la contribución de los componentes individuales y las modalidades de entrada en el modelo propuesto, se realizó un estudio exhaustivo de ablación. Los experimentos de ablación se dividieron en dos categorías: ablación a nivel de módulo y ablación a nivel de entrada.

Ablación a nivel de módulo

Evaluamos el impacto de tres componentes críticos en nuestro modelo: la red neuronal gráfica jerárquica (HGNN), el mecanismo de atención y el algoritmo de optimización CPLE. Cada componente fue evaluado de forma independiente.

Intensidad del ruido	Algoritmo del modelo	Precisión	Exactitud	Recuperación	Puntuación F1	AUC
5%	MHGNN-CPLE 0.960		0,970	0,950	0,960	0,980
	AGC-LSTM	0,945	0,955	0,935	0,945	0,975
	AtenciónProfundaST	0,935	0,945	0,925	0,935	0,965
10%	MHGNN-CPLE 0,955		0,965	0,945	0,955	0,975
	AGC-LSTM	0,940	0,950	0,925	0,937	0,970
	AtenciónProfundaST	0,930	0,940	0,915	0,927	0,960
15%	MHGNN-CPLE 0.950		0,960	0,940	0,950	0,970
	AGC-LSTM	0,935	0,945	0,920	0,932	0,965
	AtenciónProfundaST	0,925	0,935	0,910	0,922	0,955
20%	MHGNN-CPLE 0,945		0,955	0,935	0,945	0,965
	AGC-LSTM	0,930	0,940	0,915	0,927	0,960
	AtenciónProfundaST	0,920	0,930	0,905	0,917	0,950

Tabla 9. Resultados de las pruebas de robustez del modelo.

Machine Translated by Google
www.nature.com/scientificreports/

Variante del modelo	Exactitud	Puntuación F1	Precisión	Recuperación
Modelo completo (HGNN+Attn+CPLE)	0,975	0,962	0,960	0,965
sin HGNN (usar GCN)	0,942	0,930	0,925	0,934
sin mecanismo de atención	0,948	0,936	0,933	0,939
sin CPLE (usar Adam)	0,940	0,926	0,930	0,920

Tabla 10. Impacto de los componentes del modelo en el rendimiento de la detección de anomalías.

Modalidades de entrada utilizadas	Precisión	Puntuación F1
Todas las modalidades	0,975	0,962
Imagen + nube de puntos solamente	0,951	0,937
sin sonido	0,965	0,940
sin temperatura	0,958	0,942
Solo imagen	0,930	0,914
Solo nube de puntos	0,922	0,906

Tabla 11. Contribución de cada modalidad de sensor.

Se eliminaron o reemplazaron por una línea base más simple (por ejemplo, GCN estándar para HGNN, agrupamiento promedio para la atención y optimizador Adam en lugar de CPLE). Los resultados de las pruebas de robustez del modelo se presentan en la Tabla 10.

Los resultados indican claramente que cada uno de estos módulos contribuye significativamente al rendimiento general del modelo. La eliminación de HGNN conlleva una marcada disminución en la comprensión de la estructura espacial. El mecanismo de atención mejora la robustez frente a características redundantes o irrelevantes, mientras que CPLE optimiza la convergencia y el rendimiento, especialmente en condiciones de ruido.

Ablación a nivel de entrada

También realizamos experimentos de ablación de modalidades de entrada eliminando una o más entradas de sensores (imagen, nube de puntos, sonido, temperatura) y volviendo a entrenar el modelo.

Como se muestra en la Tabla 11, los resultados demuestran que las imágenes y los datos de nube de puntos son las modalidades predominantes para el análisis visual y espacial. Sin embargo, la exclusión de los datos de sonido y temperatura conlleva una notable disminución del rendimiento, especialmente en la detección de anomalías ocultas o relacionadas con el clima. Esto subraya la necesidad de estas modalidades para mejorar la generalización, sobre todo en entornos reales con condiciones ambientales y de tráfico complejas.

Interpretación diagnóstica del estudio de ablación

Cada componente del modelo propuesto contribuye de manera única a su rendimiento. El análisis diagnóstico de los resultados de la ablación revela las siguientes conclusiones:

- Eliminación de HGNN: Reemplazar HGNN con GCN estándar resultó en una disminución del 3,2 % en la precisión y del 3,6 % en la puntuación F1. Esto se debe principalmente a la capacidad de HGNN para capturar relaciones heterogéneas entre modalidades.
  Sin esta capacidad, el modelo tenía dificultades para fusionar datos espacial y semánticamente diversos, especialmente en escenarios de accidentes y congestión.
- Eliminación del mecanismo de atención: La exclusión del mecanismo de atención provocó que el modelo perdiera su capacidad de ponderación dinámica. En escenarios relacionados con el clima, donde la relevancia de cada modalidad fluctúa (por ejemplo, cuando la temperatura cobra mayor importancia), la ausencia de atención resultó en una discriminación deficiente de anomalías sutiles.
- Eliminación de CPLE: Reemplazar CPLE por el optimizador Adam provocó una disminución del rendimiento en condiciones de ruido. El algoritmo CPLE mejora la robustez ajustando dinámicamente los pesos de las muestras en función de la incertidumbre de la predicción. Sin él, el modelo mostró una menor precisión en clases de anomalías poco frecuentes, como la formación de hielo en la carretera o la congestión en sus primeras etapas.

Estos hallazgos resaltan las funciones complementarias de cada componente para mejorar tanto la generalización como la fiabilidad.

Debate y trabajo futuro

La integración de la fusión profunda multimodal y las redes neuronales de alto rendimiento (HGNN) representa un avance significativo en la detección y predicción de anomalías en el tráfico de autopistas. Al aprovechar diversos datos de sensores (imágenes, LiDAR, sonido y temperatura), el sistema logra capturar dependencias espaciotemporales complejas, lo que se traduce en mayor precisión y robustez en comparación con los modelos de referencia. La optimización CPLE de conjunto mejora aún más la fiabilidad mediante la ponderación adaptativa de las muestras inciertas.

Sin embargo, es necesario reconocer varias limitaciones prácticas. En primer lugar, el modelo depende de la entrada de sensores multimodales sincronizados y de alta resolución. En implementaciones del mundo real, los sensores pueden fallar o producir salidas degradadas debido al ruido ambiental o a fallas de hardware. Los datos faltantes o asíncronos podrían reducir el rendimiento del sistema. En segundo lugar, la complejidad computacional de los módulos HGNN y de fusión plantea desafíos para las aplicaciones reales.

Machine Translated by Google
www.nature.com/scientificreports/

inferencia temporal, particularmente en dispositivos periféricos con capacidad de procesamiento limitada. En tercer lugar, si bien nuestro modelo demuestra una gran capacidad de generalización en conjuntos de datos de validación cruzada, todos los datos provienen de escenarios de autopistas de California. Su transferibilidad a diferentes regiones geográficas o infraestructuras de sensores aún no se ha probado.

Para abordar estos problemas, en futuros trabajos se explorarán arquitecturas ligeras mediante la poda, la cuantización o la destilación del conocimiento, lo que permitirá su implementación en tiempo real. También planeamos desarrollar mecanismos robustos de desconexión de sensores para tolerar fallos parciales en la entrada. Además, se investigarán técnicas de adaptación de dominio y aprendizaje con pocos ejemplos para mejorar la generalización en diversos entornos. Finalmente, se prevén implementaciones piloto en túneles urbanos e intersecciones de autopistas para evaluar la latencia del sistema, la tolerancia a fallos y la viabilidad de la integración práctica.

Conclusión

El marco para la detección y predicción de eventos de tráfico anómalos en autopistas, que integra la fusión profunda multimodal y las redes neuronales gráficas heterogéneas (HGNN), consolida eficazmente múltiples fuentes de datos.
Al aprovechar las capacidades de modelado espaciotemporal de las redes neuronales gráficas junto con las técnicas de optimización del algoritmo CPLE, se mejora sustancialmente la precisión y la robustez en la detección de anomalías de tráfico. Este enfoque ha demostrado un gran potencial para potenciar el rendimiento de la detección. Si bien los resultados actuales son prometedores, su generalización aún debe validarse por completo. El modelo propuesto demuestra un rendimiento consistente en los conjuntos de datos METR-LA y PEMS-BAY, pero ambos conjuntos de datos provienen de regiones geográficas limitadas y comparten infraestructuras de sensores de tráfico similares. Esto plantea la posibilidad de que el rendimiento del modelo varíe al implementarse en diferentes condiciones ambientales o de infraestructura. Si bien la incorporación de conjuntos de datos más amplios está fuera del alcance de este estudio, el trabajo futuro ampliará los esfuerzos de validación para incluir diversas redes urbanas y de carreteras. Además de la generalización, la implementación práctica aún enfrenta varios desafíos, como la calidad de los datos, las inconsistencias y la demanda de procesamiento en tiempo real. Dada la naturaleza altamente dinámica y sensible al tiempo de las condiciones del tráfico, es crucial superar estas limitaciones para lograr un rendimiento óptimo.

Las futuras investigaciones deberían centrarse en varias líneas clave: perfeccionar las técnicas de fusión de datos para gestionar mejor la diversidad y la incompletitud de la información, aumentar la eficiencia computacional de los modelos para satisfacer las necesidades de procesamiento en tiempo real y explorar fuentes de datos adicionales, como redes de sensores, datos de redes sociales y comunicaciones entre vehículos, para obtener una visión más completa de los eventos de tráfico. Se espera que estos avances den lugar a sistemas de gestión del tráfico más precisos, escalables e inteligentes, lo que a su vez mejorará considerablemente la seguridad vial y la fluidez del tráfico.

Además, varias limitaciones prácticas del marco actual merecen mayor atención. En primer lugar, la complejidad computacional que introducen componentes como las HGNN y la optimización CPLE puede dificultar su implementación en sistemas con recursos limitados o en tiempo real. En segundo lugar, la dependencia de múltiples modalidades de sensores plantea dudas sobre su robustez en caso de fallos de sensores o flujos de datos incompletos. Por último, si bien el modelo funciona bien en experimentos controlados, su aplicabilidad en tiempo real sigue siendo limitada debido a los retrasos en el procesamiento, especialmente en la construcción de grafos y la fusión de características. Abordar estos problemas en trabajos futuros —mediante la simplificación del modelo, estrategias robustas de eliminación de modalidades y la optimización de la inferencia en tiempo real— será fundamental para garantizar la escalabilidad práctica y la implementación en sistemas inteligentes de monitorización del tráfico.

Disponibilidad de datos

Los datos están disponibles a solicitud razonable del autor correspondiente.

Recibido: 28 de abril de 2025; Aceptado: 3 de septiembre de 2025
Published online: 29 September 2025

Referencias

1. Nouri, M., Konyar, E., Gahrooeri, MR y Ilbeigi, M. Detección de anomalías de tráfico durante eventos extremos mediante un modelo autoexpresivo temporal (IEEE Transactions on Intelligent Transportation Systems, 2024).
2. Hong, Y. et al. STORM: Un modelo espacio-temporal sensible al contexto para predecir el tráfico anormal de multitudes provocado por eventos (IEEE Transactions on Intelligent Transportation Systems, 2024).
3. Han, L., Yu, R., Wang, C. y Abdel-Aty, M. Modelado basado en transformadores de eventos de conducción anormales para el riesgo de accidentes en autopistas evaluación. Transp. Res. Part. C: Emerg. Technol. 165, 104727 (2024).
4. Yang, X., Yan, M., Pan, S., Ye, X. y Fan, D. Red neuronal gráfica heterogénea simple y eficiente. En Actas de la Conferencia AAAI sobre Inteligencia Artificial 37 (9), 10816–10824 (2023).
5. Liu, T. y Meidani, H. Redes neuronales gráficas heterogéneas de extremo a extremo para la asignación de tráfico. Transp. Res. Part. C: Emerg. Technol. 165, 104695 (2024).
6. Loog, M. Estimación de probabilidad pesimista contrastiva para clasificación semisupervisada. IEEE Trans. Pattern Anal. Mach. Intell. 38 (3), 462–475 (2015).
7. Liang, C. et al. HADNet: Un nuevo enfoque ligero para la detección de sonidos anormales en autopistas basado en redes neuronales convolucionales 1D Red neuronal y mecanismo de autoatención multi-cabeza. Electronics 13 (21), 4229 (2024).
8. Zou, F. et al. Detección de anomalías en datos de transacciones ETC en autopistas basada en TL-XGBoost. Electronics 13 (1), 202 (2024).
9. Zhang, W. et al. Detección de anomalías mediante conexión de autopista de compuertas para imágenes del fondo de ojo retiniano. Pattern Recogn. 148, 110167 (2024).
10. Ren, Z. et al. Autoencoder gráfico con redes neuronales convolucionales temporales espejo para la detección de anomalías en el tráfico. Sci. Rep. 14 (1), 1247 (2024).
11. Khan, MN y Ahmed, MM Un nuevo enfoque de aprendizaje profundo para predecir la gravedad de los accidentes en condiciones climáticas adversas en zonas montañosas rurales autopista. J. Transp. Saf. Secur. 15 (8), 795–825 (2023).
12. Hu, S. et al. Fusión de datos de múltiples fuentes colectivas para modelar la resiliencia del tráfico a nivel de enlace ante eventos climáticos adversos. Int. J. Disaster Risk Reduct. 112, 104754 (2024).
13. Zhao, L. et al. Detección de datos anormales generativos para mejorar la seguridad vial basada en la comunicación celular vehículo a todo (IEEE Transacciones sobre comunicaciones y redes verdes, 2024).
14. Almukhalfi, H., Noor, A. y Noor, TH Enfoques de gestión del tráfico utilizando técnicas de aprendizaje automático y aprendizaje profundo: Un Encuesta. Eng. Appl. Artif. Intell. 133, 108147 (2024).

Machine Translated by Google
www.nature.com/scientificreports/

15. Han, C., Zhang, W. y Ma, T. Marco de limpieza de datos para datos de inspección de pavimentos asfálticos de carreteras basado en redes neuronales artificiales. Int. J. Pavement Eng. 23 (14), 5198–5210 (2022).
16. Mosin, V., Staron, M., Tarakanov, Y. y Durisic, D. Comparación de enfoques basados en autoencoders para la detección de anomalías en imágenes de escenarios de conducción en autopista. SN Appl. Sci. 4 (12), 334 (2022).
17. Jin, M., Sun, C. y Hu, Y. Un enfoque inteligente de detección de tráfico para vehículos en autopistas utilizando reconocimiento de patrones y aprendizaje profundo aprendizaje. Soft. Comput. 27 (8), 5041–5052 (2023).
18. Yao, J. y Ye, Y. El efecto del método de predicción de tráfico por reconocimiento de imágenes bajo aprendizaje profundo y algoritmo Naive Bayes en la seguridad del tráfico en autopistas. Image Vis. Comput. 103, 103971 (2020).
19. Zhou, J., Feng, J., Wang, X. y Zhang, M. Redes neuronales gráficas de Weisfeiler-Leman de folclore con restricción de distancia y poder de conteo de ciclos demostrable. Sistemas avanzados de procesamiento de información neuronal, 36. (2024).
20. Ma, Y., Yan, N., Li, J., Mortazavi, M. y Chawla, NV Hetgpt: Aprovechamiento del poder del ajuste rápido en redes neuronales gráficas heterogéneas preentrenadas. En Actas de la Conferencia ACM sobre Web 2024 1015–1023 (2024).
21. Niu, J., He, J., Li, Y. y Zhang, S. Estimación del rendimiento del flujo de tráfico espacio-temporal en autopistas mediante el cobro de peajes con pórtico. muestras: Un método de aprendizaje profundo. Math. Probl. Eng. 2022(1), 8711567 (2022).
22. Zhang, J. et al. Sistemas de transporte inteligentes basados en datos: una revisión. IEEE Trans. Intell. Transp. Syst. 12 (4), 1624–1639 (2011).
23. Zhou, D., Pei, B., Li, X., Jiang, D. y Wen, L. Aplicación innovadora de la tecnología BIM en la gestión de la construcción de carreteras. Sci. Rep. 14 (1), 15298 (2024).
24. Elghaish, F., Talebi, S., Abdellatef, E., Matarneh, ST, Hosseini, MR, Wu, S. y Nguyen, TQ Desarrollo de un nuevo aprendizaje profundo Modelo CNN para detectar y clasificar grietas en carreteras. J. Eng. Design Technol. 20 (4), 993–1014 (2022).
25. Liu, Y., Guo, H., Zhang, L., Liang, D., Zhu, Q., Liu, X. y Gou, Y. Investigación sobre el método de análisis de correlación de características de series temporales basado en el algoritmo de alineación temporal dinámica. IEEE Geosci. Remote Sens. Lett. 20, 1–5 (2023).
26. Zhong, G. et al. El sistema de monitoreo de riesgos de flujo de datos del sistema de red de autopistas basado en aprendizaje profundo. Int. J. Intell. Syst. 37 (11), 8878–8896 (2022).
27. Swets, JA Medición de la precisión de los sistemas de diagnóstico. Science 240 (4857), 1285–1293 (1988).
28. Buckland, M. y Gey, F. La relación entre la exhaustividad y la precisión. J. Am. Soc. Inform. Sci. 45 (1), 12–19 (1994).
29. Yacouby, R. y Axman, D. Extensión probabilística de la precisión, la exhaustividad y la puntuación F1 para una evaluación más completa de la clasificación. modelos. En Actas del primer taller sobre evaluación y comparación de sistemas de PLN (págs. 79–91). (2020).
30. Huang, J. y Ling, CX. Uso del AUC y la precisión en la evaluación de algoritmos de aprendizaje. IEEE Trans. Knowl. Data Eng. 17 (3), 299–310 (2005).

Contribuciones de los autores

Mengmeng Duan: Revisión, supervisión, metodología, validación; Shaowei Sun: Redacción del borrador original, revisión y edición, conceptualización, análisis formal, metodología, validación, obtención de financiación; Mingzhou Liu: Revisión, supervisión, visualización, gestión del proyecto. Todos los autores revisaron el manuscrito.

Fondos

Este trabajo fue financiado por el proyecto abierto del Laboratorio Clave de Información y Seguridad del Tráfico en las universidades ordinarias de la provincia de Anhui (JTX202302); el Proyecto de Jóvenes Sobresalientes de la Provincia de Anhui para Universidades (2022AH030161); 3. Programa de Investigación Científica Postdoctoral de Anhui (No. 2025B1094).

Declaraciones

Intereses contrapuestos

Los autores declaran no tener ningún conflicto de intereses.

Información adicional

La correspondencia y las solicitudes de materiales deben dirigirse a ML.

La información sobre reimpresiones y permisos está disponible en www.nature.com/reprints.

Nota del editor: Springer Nature mantiene una postura neutral con respecto a las reivindicaciones jurisdiccionales en los mapas publicados y las afiliaciones institucionales.

Acceso abierto. Este artículo está bajo la licencia Creative Commons Atribución-NoComercial-SinDerivadas 4.0 Internacional, que permite cualquier uso no comercial, compartir, distribuir y reproducir en cualquier medio o formato, siempre que se dé el crédito correspondiente al autor o autores originales y a la fuente, se proporcione un enlace a la licencia Creative Commons y se indique si se ha modificado el material licenciado. Bajo esta licencia, no se tiene permiso para compartir material adaptado derivado de este artículo o partes del mismo. Las imágenes u otro material de terceros incluidos en este artículo están sujetos a la licencia Creative Commons del artículo, a menos que se indique lo contrario en la línea de crédito del material. Si el material no está incluido en la licencia Creative Commons del artículo y su uso previsto no está permitido por la normativa vigente o excede el uso permitido, deberá obtener el permiso directamente del titular de los derechos de autor. Para ver una copia de esta licencia, visite http://creativecommo
ns.org/licenses/by-nc-nd/4.0/.

© El/los autor/es 2025