Machine Translated by Google

applied sciences

MDPI

Artículo

Método de detección de anomalías basado en predicciones para el flujo de tráfico. Datos con extracción de características multidominio

Xianguang Jia [1] Jie Qu [1], Yingying Lyu 2,*, Mengyi Guo [1] Jinke Zhang [1] y Fengxiang Guo [1]

[1] Facultad de Ingeniería de Transporte, Universidad de Ciencia y Tecnología de Kunming, Kunming 650500, China; jxg@kust.edu.cn (XJ); 20232206122@stu.kust.edu.cn (JQ); 20232206064@stu.kust.edu.cn (MG); zhangjinke1213@stu.kust.edu.cn (JZ); guofengxiang@kust.edu.cn (FG)

[2] Facultad de Ingeniería de la Información y Automatización, Universidad de Ciencia y Tecnología de Kunming, Kunming 650500, China *

Correspondencia: 20070102@kust.edu.cn

Resumen: La idea central de la detección de anomalías basada en predicción es identificar anomalías mediante la construcción de un modelo de predicción y la comparación de valores predichos y observados. Sin embargo, la mayoría de los modelos de predicción de flujo de tráfico existentes se centran principalmente en características espaciotemporales, descuidando el aprendizaje integral de características en el dominio de la frecuencia. Además, la precisión de la detección de anomalías suele verse limitada por un análisis insuficiente del error de predicción. Para abordar esta limitación, este artículo propone un método de detección de anomalías basado en predicción para datos de flujo de tráfico con extracción de características multidominio. El modelo de predicción se construye de la siguiente manera: primero, una red de memoria a largo y corto plazo bidireccional (Bi-LSTM) y una red de atención gráfica (GAT) extraen características temporales y espaciales, respectivamente. Luego, la transformada rápida de Fourier (FFT) convierte las señales del dominio del tiempo al dominio de la frecuencia, donde Transformer aprende las características de magnitud y fase. Finalmente, se construye un modelo de predicción utilizando las características extraídas del dominio del tiempo y del dominio de la frecuencia. Para el análisis de errores, este artículo aplica de forma innovadora la desigualdad de Chebyshev para determinar el umbral de error, identificando anomalías en función de si los errores superan dicho umbral. Los resultados experimentales demuestran que la integración de características multidominio permite capturar de forma más completa las características de los datos y mejorar la precisión de la predicción del modelo. En el experimento de detección de anomalías, se verificó que la construcción de un modelo de predicción de alta precisión y un análisis de errores adecuado permiten detectar anomalías en los datos de manera eficaz.

Palabras clave: extracción de características multidominio; series temporales multivariadas; transformada rápida de Fourier ; detección de anomalías; predicción del flujo de tráfico; desigualdad de Chebyshev

check for updates

Editor académico:
David Fernández-Llorca

Recibido: 23 de diciembre de 2024
Revisado: 6 de marzo de 2025
Aceptado: 14 de marzo de 2025
Publicado: 16 de marzo de 2025

Cita: Jia, X.; Qu, J.; Lyu, Y.; Guo, M.; Zhang, J.; Guo, F. Un método de detección de anomalías basado en predicción para datos de flujo de tráfico con múltiples dominios. Extracción de características. Appl. Sci. 2025, 15, 3234. https://doi.org/10.3390/ app15063234

Derechos de autor: © 2025 por los autores. Titular de la licencia: MDPI, Basilea, Suiza. Este artículo es de acceso abierto. distribuido bajo los términos y condiciones de Creative Commons Licencia de atribución (CC BY) (https://creativecommons.org/ licenses/by/4.0/).

1. Introducción

Los datos de series temporales se refieren a una colección de puntos de datos asociados con componentes temporales específicos, generalmente registrados a intervalos de tiempo uniformes [1]. Este tipo de datos refleja el estado o la magnitud de un fenómeno u objeto particular a lo largo del tiempo [2].

Una serie temporal multivariada (MTS, por sus siglas en inglés) es un conjunto de series temporales que comparten las mismas marcas de tiempo. En cada punto temporal, los datos se representan como una matriz de variables o valores numéricos, formando esencialmente una colección de múltiples series temporales univariadas capturadas a lo largo del tiempo [1]. Esta estructura de datos permite analizar las relaciones y los cambios dinámicos entre variables, lo que la convierte en una herramienta fundamental para estudiar sistemas complejos y explorar interacciones en diversos ámbitos. En el campo en constante evolución del análisis de series temporales, la identificación de patrones y cambios dinámicos es esencial para realizar pronósticos precisos y obtener información valiosa [3].

Machine Translated by Google

Los datos de flujo de tráfico son un ejemplo típico de MTS, que exhibe características temporales complejas como tendencias a largo plazo, estacionalidad, periodicidad y aleatoriedad. Por ejemplo, el tráfico de desplazamientos diarios aumenta durante las horas punta de la mañana y la tarde, pero disminuye significativamente por la noche; las zonas comerciales pueden estar más concurridas los fines de semana, mientras que las rutas de desplazamientos diarios experimentan un menor tráfico; el tráfico en autopistas aumenta durante los días festivos largos, mientras que el tráfico en las carreteras urbanas disminuye; los accidentes repentinos pueden provocar una caída brusca del tráfico, seguida de una fase de recuperación de la congestión.

Además, la propagación del flujo de tráfico dentro de una red vial está condicionada por su topología. El flujo de tráfico no se distribuye de forma independiente, sino que está influenciado por los segmentos viales anteriores y posteriores. A menudo existe una fuerte correlación entre segmentos viales o regiones adyacentes. Por lo tanto, más allá de las características típicas de los datos MTS, el flujo de tráfico también presenta características espaciales complejas.

Al analizar las características de los datos, es fundamental considerar no solo sus propiedades temporales y espaciales, sino también sus características en el dominio de la frecuencia. Por ejemplo, en los datos de flujo de tráfico, la magnitud de los diferentes componentes de frecuencia tras la transformación tiempo-frecuencia representa la energía de la señal en diversas frecuencias, mientras que la frecuencia correspondiente a la magnitud máxima indica el ciclo de tráfico principal. En el procesamiento de señales y el análisis de series temporales, los métodos en el dominio del tiempo y en el dominio de la frecuencia tienen sus ventajas y limitaciones. La combinación de ambos enfoques aprovecha sus ventajas complementarias, mejorando el análisis de señales y la extracción de características. Esta integración permite un examen más completo de las señales en las dimensiones temporal y frecuencial, superando las limitaciones de un único método de análisis.

Las anomalías en los datos de flujo de tráfico suelen indicar situaciones especiales, como fallos en los equipos o incidentes inesperados en periodos de tiempo específicos. No detectar estas anomalías de forma oportuna y precisa puede tener graves consecuencias. La detección rápida y eficaz de anomalías ayuda a identificar posibles problemas con antelación, minimizando así las pérdidas económicas innecesarias [4]. Por lo tanto, extraer de forma eficiente las posibles anomalías de los datos tiene un gran valor práctico.

Sin embargo, los métodos especializados de detección de anomalías en los datos de flujo de tráfico siguen siendo escasos. Los estudios existentes suelen adoptar un enfoque de detección uniforme sin considerar plenamente las necesidades específicas de cada ámbito. Además, muchos métodos se centran principalmente en las características espaciotemporales de los datos de flujo de tráfico, pasando por alto sus características en el dominio de la frecuencia, lo que limita la exploración de patrones periódicos. Este análisis unidimensional carece de especificidad para el manejo de anomalías de tráfico, lo que dificulta la captura precisa de patrones anómalos complejos.

Para lograr una detección de anomalías más precisa en los datos de flujo de tráfico, este artículo propone un método de detección de anomalías basado en predicción para datos de flujo de tráfico con extracción de características multidominio . Las innovaciones clave de este método son las

siguientes: 1. Optimización del modelo de predicción mediante la combinación de características de los datos.

Este método no solo se centra en las características temporales de los datos de flujo de tráfico, sino que también considera plenamente las correlaciones espaciales entre ellos. Mediante el uso de diferentes modelos para aprender conjuntamente las características temporales y espaciales, permite la extracción de características en el dominio del tiempo. Además, reconociendo que los datos de flujo de tráfico suelen presentar periodicidad y pueden estar sujetos a interferencias de ruido, este trabajo aprovecha las ventajas del análisis en el dominio de la frecuencia (como la identificación de periodicidad y la supresión de ruido) para explorar con mayor profundidad las características de los datos en dicho dominio. El modelo aprende entonces su representación en el dominio de la frecuencia , logrando una extracción de características más completa. Los resultados experimentales demuestran que los modelos de predicción que exploran completamente las características de los datos pueden mejorar significativamente la precisión de la predicción.

2. Análisis de errores y determinación del umbral

Machine Translated by Google

Los métodos predictivos se utilizan ampliamente en la detección de anomalías, basándose en la diferencia entre los valores predichos y observados para identificarlas. Sin embargo, la determinación de un umbral de error adecuado en los métodos existentes suele carecer de adaptabilidad y fiabilidad. Para abordar este problema, este artículo introduce la desigualdad de Chebyshev para establecer un umbral más científico y racional para el análisis de errores, mejorando así la precisión y la robustez de la detección de anomalías.

2. Trabajos relacionados

En escenarios de monitoreo reales, los datos de flujo de tráfico recopilados por sensores generalmente no están etiquetados [5] y suelen estar incompletos debido a diversos factores objetivos, lo que genera anomalías y datos faltantes. Esto requiere modelos de detección de anomalías con capacidades de aprendizaje no supervisado [6,7]. Además, la alta dimensionalidad, la naturaleza dinámica y la complejidad de los datos MTS [8] hacen que la identificación precisa de datos anómalos sea una tarea compleja.

Actualmente, los métodos de detección de anomalías en series temporales no supervisadas se pueden clasificar en enfoques tradicionales y basados en aprendizaje profundo. Los métodos tradicionales comunes incluyen enfoques estadísticos (tanto paramétricos como no paramétricos), así como técnicas de reconstrucción y agrupamiento basadas en aprendizaje automático clásico. En contraste, los métodos basados en aprendizaje profundo se centran principalmente en la predicción y la reconstrucción. Los métodos estadísticos suelen modelar cada variable en los datos de MTS de forma independiente, sin aprovechar completamente las relaciones espaciales entre múltiples variables. Para datos de MTS altamente correlacionados, los métodos de detección de anomalías basados en aprendizaje automático clásico y aprendizaje profundo se han convertido en la tendencia dominante en la investigación y la aplicación.

Los métodos de detección de anomalías basados en reconstrucción para series temporales multivariadas implican entrenar modelos para aprender representaciones latentes de subsecuencias temporales normales, reconstruir las subsecuencias multivariadas e identificar anomalías midiendo las diferencias entre las secuencias reconstruidas y originales. El análisis de componentes principales (PCA) es una técnica clásica de reducción de dimensionalidad y extracción de características [9]. Detecta anomalías evaluando si una muestra de datos puede reconstruirse de manera efectiva. Si una muestra es difícil de reconstruir, es probable que sus características sean inconsistentes con el conjunto de datos general, lo que indica que es una anomalía. Aosong et al. [10] aplicaron un método mejorado basado en PCA para detectar fallas en sensores de enfriadores. Qu et al. [11] propusieron un enfoque de optimización que minimiza los errores de reconstrucción intraclase mientras maximiza los errores de reconstrucción interclase para muestras de entrenamiento. Rashidi et al. [12] introdujeron una métrica de error de reconstrucción estandarizada, proporcionando un medio más efectivo para la evaluación de la precisión. Ana et al. [13] adoptaron una estructura de autoencoder parcialmente interpretable para mejorar las capacidades de compresión y reconstrucción de datos de PCA. Dan et al. [14] desarrollaron un novedoso marco de detección de anomalías semisupervisado basado en la similitud de reconstrucción. Ji et al. [15] propusieron un nuevo marco de detección de anomalías que integra el análisis estadístico con métodos de redes neuronales.

La detección de anomalías basada en agrupamiento es un método no supervisado típico que distingue anomalías basándose en tres supuestos comunes: los puntos de datos que no pertenecen a ningún grupo son anomalías, los puntos de datos lejos de los centros de los grupos son anomalías, y los puntos de datos dentro de grupos dispersos o pequeños son anomalías. Aziz et al. [16] aplicaron el agrupamiento K-means a los registros de detalles de llamadas (CDR) desde las perspectivas de detección y predicción de anomalías, proponiendo un método de detección de anomalías escalable y eficiente. Rajeshkumar et al. [17] optimizaron los modelos de detección de anomalías mejorando los clasificadores de aprendizaje automático. Wang et al. [18] introdujeron un algoritmo de detección de anomalías que combina técnicas de agrupamiento con modelos de autoencoder para identificar anomalías en el tráfico de red.

Machine Translated by Google

Debido al amplio potencial de aplicación del aprendizaje profundo en diversos campos, los métodos de detección de anomalías en series temporales basados en aprendizaje profundo han captado una atención significativa. Estos métodos pueden aprender relaciones temporales no lineales complejas y representaciones de alta dimensión de datos de series temporales. Nallappan et al. [19] propusieron un marco de recuperación de vídeo basado en contenido (CBVR) para la detección de anomalías en vídeos de vigilancia, aprovechando técnicas de aprendizaje profundo e indexación HNSW (Hierarchical Navigable Small W Iqbal et al. [20] aplicaron varios modelos de aprendizaje profundo para la detección de anomalías y la predicción de series temporales, e introdujeron un método estadístico para superar las limitaciones de los datos de series temporales de alta dimensión. Shafeiy et al. [21] introdujeron la técnica pionera MCN-LSTM para el monitoreo de la calidad del agua en tiempo real, abordando los desafíos de la detección de anomalías en datos de series temporales complejos.

Gracias a la continua optimización de los modelos y métodos de pronóstico, las técnicas de detección de anomalías basadas en predicciones han demostrado un importante potencial de desarrollo. Changzhi et al. [22] aplicaron métodos de pronóstico para detectar anomalías en datos de potencia. Takahashi et al. [23] propusieron el uso de umbrales estacionales para mejorar los métodos de detección basados en predicciones , abordando el desafío de determinar los umbrales de error. La Tabla 1 presenta una comparación de varios métodos de detección de anomalías.

Tabla 1. Comparación de varios métodos de detección de anomalías.

Método aplicado	Ventajas:	Desventajas:
PCA y mejora Métodos de PCA	Permite una detección de fallos sencilla mediante la replicación y mejora de las capacidades de compresión y reconstrucción de datos de PCA	Limitado por la naturaleza lineal del PCA, lo que dificulta el manejo de relaciones no lineales complejas; requiere mucha capacidad de cálculo.
Métodos basados en la refactorización y métodos de refactorización mejorados	Proporciona un método de evaluación de la precisión más eficaz, mejorando la exactitud en la detección de anomalías.	Este enfoque ofrece un medio más eficaz para evaluar la exactitud, mejorando la precisión en la detección de anomalías.
Algoritmos de agrupamiento y mejoras Algoritmos de agrupamiento	Métodos escalables y eficientes para la detección de anomalías.	Es sensible a la elección de hiperparámetros; requiere una gran cantidad de datos normales para el entrenamiento, lo que podría limitar la capacidad de detectar anomalías nuevas.
Basado en predicciones Detección de anomalías Métodos	Capaz de aprender relaciones temporales no lineales más complejas y representaciones de series temporales de alta dimensión.	Los errores de predicción pueden afectar el rendimiento de la detección; es posible que no se realice un análisis de errores adecuado.
Umbral estacional + Métodos de predicción	Mejora la determinación de los umbrales de error.	Es posible que las suposiciones sobre la estacionalidad no se apliquen a todos los datos de series temporales.

Con el avance del aprendizaje profundo, los modelos predictivos ahora consideran no solo las dependencias temporales de las muestras sino también las dependencias espaciales, incluida la topología de red de las muestras. Kidu et al. [24] extrajeron características espaciotemporales de las muestras para predecir e identificar actividades de los conductores. Ullah et al. [25] propusieron un método híbrido CNN-LSTM unidimensional para extraer características espaciotemporales para detectar fugas en tuberías. Tipper et al. [26] utilizaron CNN y LSTM para la detección de vídeos deepfake. Xiong et al. [27] introdujeron un marco SSA-CNN-LSTM con aumento de datos para la predicción de fallos.

Li et al. [28] introdujeron un modelo de red neuronal de extracción de múltiples características basado en LSTM convolucional para predecir los niveles de PM2.5 en el pronóstico de la calidad del aire, logrando una integración efectiva de correlaciones espaciales. Jiawei et al. [29] propusieron un nuevo método de detección basado en redes CNN y LSTM para explorar de manera integral la información espacio-temporal.

Machine Translated by Google

En el dominio del tiempo, el enfoque se centra típicamente en las características transitorias de una señal, que reflejan cómo cambia la señal a lo largo del tiempo y son adecuadas para monitorizar variaciones dinámicas. En cambio, en el dominio de la frecuencia, las señales complejas del dominio del tiempo se descomponen en componentes de diferentes frecuencias. El análisis de estas frecuencias permite identificar y suprimir eficazmente el ruido, haciendo hincapié en las características periódicas de la señal. El análisis en el dominio de la frecuencia es un método que examina las características de una señal en dicho dominio. Pascale et al. [30] revelaron las diferencias en la contribución de los componentes de frecuencia a la señal global a diferentes velocidades mediante el análisis de las emisiones de ruido de dos fuentes motorizadas distintas. Li et al. [31] propusieron un método de detección de suplantación de identidad en el Sistema Global de Navegación por Satélite (GNSS) basado en el procesamiento en el dominio de la frecuencia. La combinación de las características del dominio del tiempo y del dominio de la frecuencia proporciona una perspectiva más completa, mejorando la eficiencia y la precisión de la extracción de características y facilitando una mejor comprensión y análisis de las características de la señal.

Los métodos predictivos de detección de anomalías suelen requerir la construcción de un modelo de pronóstico preciso. Al comparar la diferencia entre los valores predichos y observados con un umbral predefinido, se pueden identificar anomalías. Según la revisión de la literatura, existen los siguientes desafíos clave en el campo de la detección de anomalías en el flujo de tráfico: 1. Falta de métodos especializados de detección de anomalías para datos de flujo de tráfico.

Si bien los datos de flujo de tráfico comparten características típicas de los datos MTS, también presentan fuertes dependencias espaciales. Sin embargo, los métodos existentes a menudo no tienen en cuenta estas propiedades espaciales.

2. Consideración limitada de las características del dominio de la frecuencia.

Los modelos predictivos actuales se centran principalmente en métodos del dominio del tiempo, aprovechando únicamente las características temporales y espaciales y pasando por alto las propiedades del dominio de la frecuencia. Como resultado, el proceso de aprendizaje de características para los datos MTS sigue siendo incompleto.

3. Incertidumbre en la determinación del umbral de error

En la detección predictiva de anomalías, establecer un umbral de error adecuado resulta un desafío. Dado que el análisis de errores es un paso crucial para garantizar la precisión de la detección, la falta de un método fiable de selección de umbrales puede afectar significativamente la eficacia de la detección de anomalías.

Basándose en los problemas y el análisis de la situación descritos anteriormente, este artículo propone un método de detección de anomalías basado en la predicción para datos de flujo de tráfico que incorpora la extracción de características multidominio . Este método aprovecha las características tanto del dominio temporal como del dominio frecuencial para capturar de forma integral las características temporales y espectrales de los datos, lo que permite la construcción de un modelo de predicción de series temporales eficaz. Mediante el análisis de los valores predichos y observados, se determina el umbral de error utilizando la desigualdad de Chebyshev, y se detectan anomalías comprobando si el error se encuentra dentro del rango del umbral. Este enfoque permite la detección eficaz de puntos de datos anómalos.

3. Metodología 3.1.

Descripción de los métodos de detección de anomalías

El método de detección de anomalías para datos de flujo de tráfico basado en predicción y extracción de características multidominio propuesto en este artículo consta de dos partes principales: la construcción del modelo de predicción y el análisis de errores para la detección de anomalías. El esquema general se muestra en la Figura 1.

Machine Translated by Google

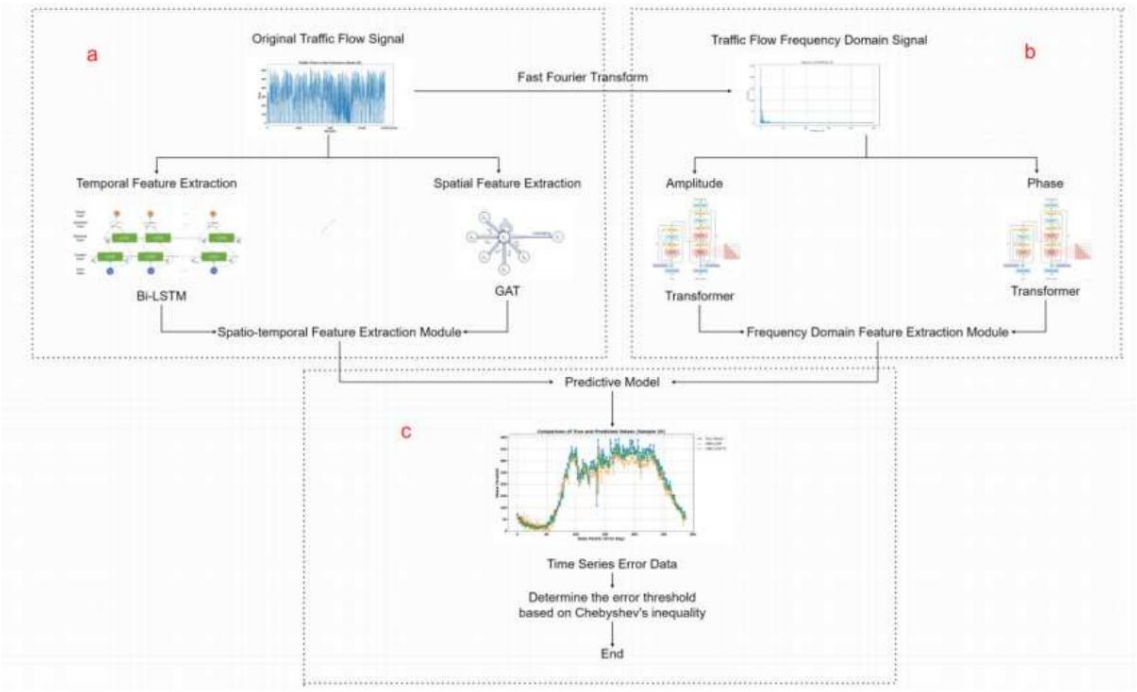


Figura 1. Marco general de los métodos de detección de anomalías. (a) Extracción de características en el dominio del tiempo módulo; (b) Módulo de extracción de características en el dominio de la frecuencia; (c) Análisis de errores y detección de anomalías.

La construcción del modelo de predicción consta principalmente de dos módulos: el módulo de extracción de características en el dominio del tiempo y el módulo de extracción de características en el dominio de la frecuencia.

El módulo de extracción de características en el dominio del tiempo utiliza una red bidireccional de largo y corto plazo (Bi-LSTM) para capturar las dependencias temporales en los datos y una red neuronal (GAT) para extraer las dependencias espaciales, lo que permite el aprendizaje de características tanto temporales como espaciales en el dominio del tiempo. El módulo de dominio de frecuencia aplica primero la Transformada Rápida de Fourier (FFT) para convertir la señal bruta del dominio del tiempo en una señal del dominio de la frecuencia. Luego, se utiliza un modelo Transformer para separar las características de amplitud y fase en el dominio de la frecuencia, facilitando el aprendizaje de características del dominio de la frecuencia. El modelo de predicción se construye integrando las características extraídas tanto del dominio del tiempo como del dominio de la frecuencia.

En este documento, el flujo de tráfico $X = x_t^1, x_t^2, x_t^3, \ldots x_t^N, \ldots \times R^{M\times N}$ se toma como un entrada, donde $x_t = \{x_t^1, x_t^2, x_t^3, \ldots, x_t^M\}$ se denota como la observación medida en el tiempo $t = \{1, 2, \cdots N\}$. El modelo de predicción predice el flujo de tráfico para el intervalo de tiempo $\{1,2, \ldots H\}$ en cada nodo basándose en las observaciones en una ventana de tiempo histórica K en ese nodo, por lo que el problema de predicción del flujo de tráfico en un nodo en particular se puede formular de la siguiente manera:

$$[x_{t0-K+1}, x_{t0-K+2}, \ldots x_{t0}] \xrightarrow{F} [x_{t0+1}, x_{t0+2}, \ldots x_{t0+H}]$$

donde F es el modelo de predicción.

La sección de análisis de errores y detección de anomalías utiliza la desigualdad de Chebyshev para determinar el valor umbral del error ei y analiza si el error et entre los valores observados x_t en un instante de tiempo t y el valor predicho $\hat{x}_t$ en ese punto está dentro del valor umbral para detectar si los datos en ese punto son anómalos o no.

3.2. Módulo de extracción de características en el dominio del tiempo

3.2.1. Extracción de características temporales basada en Bi-LSTM

Las redes de memoria a largo y corto plazo (LSTM) mejoran las redes neuronales recurrentes. Modelo de red neuronal recurrente (RNN) que aborda problemas como la explosión del gradiente y el desvanecimiento. gradientes, y se desempeñan excepcionalmente bien en tareas de predicción de secuencias. Bi-LSTM es un modelo LSTM bidireccional que añade una capa inversa para permitir la lectura bidireccional. Consta de dos modelos LSTM: un modelo hacia adelante y un modelo hacia atrás. El modelo hacia adelante

Machine Translated by Google

El modelo procesa la secuencia de entrada en sentido directo, de principio a fin, utilizando información pasada, mientras que el modelo inverso procesa la secuencia en sentido inverso, de fin a principio, aprovechando información futura.

Los datos de flujo de tráfico presentan características típicas de series temporales. La tecnología Bi-LSTM permite que, en cada paso de tiempo, cada unidad LSTM acceda a información contextual tanto pasada como futura, lo que la hace altamente eficaz para capturar dependencias a largo plazo en los datos de series temporales.

Las dos LSTM en Bi-LSTM tienen la misma estructura, y en el caso de LSTM hacia adelante, combina la Por ejemplo, en cada punto temporal, la LSTM utiliza la entrada $X = x^1, x^2, x^3 t x, \ldots x \ldots, x^N$ actual y el estado oculto h_{t-1} del punto temporal anterior $\overrightarrow{}$ para calcular la salida O_t. Al mismo tiempo, el estado oculto h_t del punto temporal actual se vuelve a utilizar como $\overrightarrow{}$ entrada del siguiente punto temporal, es decir:

$$O_t = \sigma\left(W_0 h_{t-1}, x^t\right) + b_0 \quad (1)$$

$$\overrightarrow{h_t} = O_t \tanh(C_t) \quad (2)$$

donde: W_0 y b_0 son los pesos y sesgos, respectivamente; σ es la función de activación; C_t denota los parámetros de estado en el momento actual; tanh es la función de activación tangente hiperbólica.

Después de que la entrada pasa por la LSTM, la salida $X^T \in R^{h \times T}$ se obtiene, donde h la dimensión de la capa oculta de la LSTM. X en cada paso ^{T} preserva la información del estado oculto de tiempo y es una representación de características que contiene la correlación temporal de los datos. Bi-LSTM, por otro lado, combina las LSTM hacia adelante y hacia atrás, y empalma el estado oculto $\overrightarrow{h_t}$ de la LSTM hacia adelante con el estado oculto $\overleftarrow{h_t}$ de la LSTM inversa para obtener la salida Bi-LSTM. Salida LSTM h_t, es decir:

$$h_t = \sigma\left(W \cdot \left[\overrightarrow{h_t}; \overleftarrow{h_t}\right] + c\right). \quad (3)$$

3.2.2. Extracción de características espaciales basada en

GAT Los datos de flujo de tráfico no solo exhiben características temporales, sino que también contienen relaciones espaciales entre los puntos de datos. Si bien los modelos tradicionales de series temporales se centran en extraer características temporales, modelar las dependencias espaciales utilizando estructuras de red e información de atributos también es crucial. Un grafo se compone de nodos y aristas, y G = {V, E, A} se utiliza para definir una red de transporte. En este contexto, V representa el conjunto de nodos, que corresponde a la colección de sensores en el sistema de carreteras; E representa el conjunto de aristas, que indica las relaciones entre los nodos, o las conexiones entre pares de sensores; y A denota la matriz de adyacencia de la red, típicamente una matriz de adyacencia ponderada por distancia que representa la conectividad entre cada nodo en la red de carreteras.

Mediante la construcción de esta matriz de adyacencia, los datos originales pueden transformarse en datos gráficos que capturan características espaciales.

En este documento, a los nodos con conexión se les asigna un valor de 1, mientras que a los nodos sin conexión se les asigna un valor de 0, construyendo una matriz de adyacencia que transforma los datos brutos en datos de grafo Aij con correlaciones espaciales. Durante el proceso de extracción de características espaciales, Aij se utiliza como entrada para aprender las correlaciones entre sensores, capturando las relaciones espaciales dentro de la serie temporal. Las condiciones del tráfico se pueden medir mediante H sensores, y

Machine Translated by Google

La matriz de adyacencia puede representar las relaciones entre diferentes estados de tráfico. Esto se puede expresar específicamente como la siguiente matriz:

$$X(z,t) = \begin{matrix} X(z,t0-T+1) \\ X(z,t0-T+2) \\ \vdots \\ X(z,t0-1) \\ X(z,t0) \end{matrix}^{T} = \begin{matrix} x(z1,t0-T+1) & x(z1,t0-T+2) & \cdots & x(z1,t-1) & x(z1,t0) \\ x(z2,t0-T+1) & x(z2,t0-T+2) & \cdots & x(z2,t-1) & x(z2,t0) \\ \vdots & \vdots & \cdots & \vdots & \vdots \\ x(zH,t0-T+1) & x(zH,t0-T+2) & \cdots & x(zH,t-1) & x(zH,t0) \end{matrix} \quad (4)$$

donde: x(zi ,t0) denota los datos medidos por el i-ésimo sensor zi en el momento t0; T denota la duración del tiempo histórico. Sea X(z,t) = x(z,t0−T+1) , x(z,t0−T+2) , . . . , x(z,t0−1) , x(z,t0) el flujo de tráfico medido por H sensores en el período de tiempo T, donde x(z,t0) = x(z1 ,t0) , x(z2,t0) , . . . , x(zH,t0) denota el flujo de tráfico de todos los sensores en el momento t0, x(zi ,t0) denota el flujo de tráfico del i-ésimo sensor en el momento t0.

GAT puede manejar datos irregulares y no estructurados. Al extraer características espaciales mediante la asignación adaptativa de pesos, la combinación de información local y global, y un mecanismo de atención multi-cabeza, GAT puede capturar y modelar eficazmente relaciones espaciales complejas, lo que le permite ser adecuado para una variedad de datos con estructura de grafo. Mediante el mecanismo de atención, los pesos se asignan dinámicamente en función de las relaciones entre nodos, priorizando así los nodos vecinos más importantes. Cada nodo calcula de forma adaptativa un promedio ponderado basado en las características y la fuerza de conexión de sus vecinos.
La capacidad de regular la atención de forma adaptativa, tanto a nivel local como global, al mismo tiempo, permite que el modelo capture mejor las relaciones entre los nodos y mejora la capacidad de modelar estructuras gráficas complejas.

La red GAT se implementa apilando múltiples capas de atención de grafos. Los coeficientes de atención se utilizan principalmente para medir la relación entre nodos, representando el peso de influencia del nodo vecino j sobre el nodo i. Un peso mayor indica una mayor importancia del vecino. Este mecanismo permite que GAT ajuste dinámicamente los pesos de propagación de la información. El coeficiente de atención para cada par de nodos (i, j) en una sola capa de atención se calcula de la siguiente manera:

$$\alpha ij = \frac{\exp \text{LeakyReLU}\left(a^{T} Whi \, Whj\right)}{\exp(\text{LeakyReLU}(a^{T}[Whi \,||Whk])) \sum k \quad Ni} \quad (5)$$

donde: Ni es el nodo vecino del nodo i; la característica de entrada del nodo es: h = {h1, h2, . . . , hN}, hi R M, donde N es el número de nodos y dimensión de la característica, y es el

La salida de la característica del nodo es: h = hhh 1 , 2 , . . . , N , i 2M′ matriz de peso de transformación aplicada en cada nodo; a R es un vector de peso que asigna las entradas a R; LeakyReLU es una función de activación no lineal; y || es una operación de unión.

La salida de cada nodo de cada capa GAT, es decir, la salida de características del nodo final, se representa como:

$$Hola' = \sigma \sum j \quad Ni \; \alpha ij Whi' \quad (6)$$

donde: αij es el coeficiente de atención del nodo i y del nodo j; y σ es una activación no lineal. función.

El mecanismo de atención de múltiples cabezas procesa las características de entrada en paralelo a través de múltiples mecanismos de atención gráfica y combina las salidas de múltiples cabezas de atención,

Machine Translated by Google

aplicar k mecanismos de atención independientes para calcular los estados ocultos y luego combinar sus características para obtener la siguiente representación de salida:

$$\text{Hola}' = \sigma \left(\frac{1}{k} \sum_{k=1}^{k} \sum j \quad Ni \quad a_{k\ ijWk\ hola} \right) \tag{7}$$

k donde: a es el coeficiente de atención normalizado del k-ésimo cabezal de atención. ij

3.3. Módulo de extracción de características en el dominio de la frecuencia 3.3.1. Procesamiento y análisis de datos basado en FFT

En el mundo real, los datos suelen presentar patrones complejos que combinan periodicidad y tendencias. Los datos de flujo de tráfico, recopilados por sensores durante un período específico, muestran características distintas según factores como días laborables o fines de semana, y horas de trabajo o no laborables. Esto los convierte en un ejemplo típico de señal discreta periódica. La amplitud de las fluctuaciones estacionales o los componentes del ciclo de tendencia presentan variaciones relativamente pequeñas a medida que cambia el nivel de la serie temporal. Por lo tanto, los datos de flujo de tráfico pueden analizarse mediante un modelo aditivo. En concreto, la serie temporal puede expresarse como la suma de varios componentes, como se muestra a continuación:

$$\text{área} = St + Tt + Rt \tag{8}$$

donde: yt denota los datos de la serie temporal, St denota el término del período, Tt denota el término de tendencia y Rt denota el término residual.

La transformada de Fourier (TF) es una herramienta matemática que se utiliza para convertir una señal del dominio del tiempo al dominio de la frecuencia, descomponiéndola en componentes sinusoidales de diferentes frecuencias. La idea fundamental es que cualquier señal, periódica o no periódica, puede representarse como una serie de ondas sinusoidales con frecuencias, amplitudes y fases variables. Sin embargo, dado que las computadoras suelen procesar señales discretas, se utiliza la transformada discreta de Fourier (TFD) para aproximar la TF.

La FFT es uno de los algoritmos más importantes en el procesamiento de señales y el análisis de datos, ya que proporciona un cálculo eficiente de la DFT. Al trabajar con datos de series temporales discretas, la aplicación de la FFT permite el análisis en el dominio de la frecuencia, lo que posibilita la identificación de componentes periódicos y ruido dentro de la serie temporal.

Si los datos se representan como X = x representa $^{1}, ^{2}x, \quad ^{3}tx, \ldots x \quad \ldots, x^{M}$, $X \quad R \quad ^{M\times T}$, donde T la longitud de la serie temporal, M representa la dimensión de los datos MTS y $\rightarrow j = xxxx\ 1\ ^{j}2, 3^{j}, \ldots ^{j}$ $^{i}T, \quad \rightarrow j \quad R^{T}$ son los datos de la serie temporal de los atributos j-ésimos = 1, 2, 3, ..., M de los datos de la serie temporal. Las muestras de la serie temporal sin procesar se dividen en vectores de igual longitud según diferentes atributos, que luego se utilizan como entradas para la FFT para realizar la transformación tiempo-frecuencia. Este proceso convierte las muestras del dominio del tiempo al dominio de la frecuencia. Finalmente, las muestras de la serie temporal se descomponen en una combinación de vectores seno y coseno, cada uno de los cuales representa un componente de una frecuencia diferente. El proceso de transformación tiempo-frecuencia se expresa mediante la siguiente fórmula:

$$j\,f_{l} = \sum_{t=1}^{T} x_{t}^{j} \quad \text{porque} \quad \frac{2\pi tn}{T} \quad - tú \quad \frac{2\pi tn}{T} \tag{9}$$

j donde: x_{es} un elemento en la muestra de secuencia, t = {1, 2, . . . , T} denota el índice de tiempo, i es la parte imaginaria que satisface la ^{2} j = −1, f l denota los datos del dominio de la frecuencia después de la FFT transformación i , y k = {1, 2, . . . , T} denota el índice del dominio de frecuencia. Después de la transformación de frecuencia del tiempo j, se pueden obtener los datos originales del flujo de tráfico, es decir, cada muestra de secuencia x

Machine Translated by Google

1 en X = x , 2 x , 3 t x , . . . x . . . , x M FFT, y el resultado f j = f 1 , f 2 , f 3 , . . . , f jjjj se somete a T se obtiene.

3.3.2. Extracción de características en el dominio de la frecuencia basada en transformador

En el módulo de extracción de características del dominio de la frecuencia, las muestras de entrada primero se someten a una transformación tiempo-frecuencia. Los datos se transfieren al espacio del dominio de la frecuencia, para obtener características de tiempo más profundas en el espacio del dominio de la frecuencia. De la j proceso de FFT, el resultado de salida f l conversión es un número complejo y f j es un conjunto de secuencias complejas, es decir, los datos convertidos no están en el rango de números reales y no se pueden ingresar directamente en el modelo para entrenamiento.

En el dominio de la frecuencia, la amplitud y la fase pueden reflejar completamente las características de los datos en dicho dominio. La amplitud en el dominio de la frecuencia se refiere a la información de amplitud de la señal en diferentes frecuencias, reflejando la magnitud de la energía de la señal en diferentes componentes de frecuencia; la fase se refiere a la información de fase de la señal en diferentes frecuencias, describiendo el desplazamiento de fase de la forma de onda de la señal en j frecuencias diferentes. Después de guardar los datos complejos f como valores de magnitud y fase, se puede resolver el problema de que los números complejos no se pueden ingresar en el entrenamiento del modelo. Específicamente , lo anterior se escribe de la siguiente forma: f = m + in, donde m y n son números reales , y el cálculo del valor de magnitud a y el valor de fase b es:

$$a = m2 + n \quad 2 \tag{10}$$

$$b = \arctan m \quad . \tag{11}$$

La secuencia compleja f j se puede guardar como dos conjuntos de secuencias de temporización: la amplitud j y la secuencia a secuencia de fase b j. , después de que se calculan la amplitud y la fase. Tomando lo para cada muestra de entrada 1 , 2 x , 3 t x , . . . x . . . , x M , cual se transforma como se describió anteriormente, X = x podemos decir que X → {A, P} , donde A es la secuencia de amplitud, P es la secuencia de fase, A, P R T M.

El Transformer se diferencia de los marcos CNN o RNN tradicionales en que consta de:

Consta de dos partes: un codificador y un decodificador. El decodificador Transformer tiene una estructura similar a la del codificador y consta de múltiples capas de codificación apiladas en tres partes: un mecanismo de autoatención multi-cabeza , enlace residual con normalización de capas y una red de alimentación directa.

Las secuencias de magnitud y fase se incorporan a la entrada y se codifican en la posición antes de que se introduce en el codificador Transformer. El proceso de incrustación de entrada X es:

$$Q, K, V = \text{Incrustación}(X) \tag{12}$$

donde: Q y K contienen la información posicional de los datos de entrada y V representa la información numérica de los datos de entrada. Se utilizarán para el cálculo de la atención en el Transformer, y el proceso de cálculo es:

$$\text{Atención}(Q, K, V) = \text{Entonces f tmax}\left(\frac{QKT}{\sqrt{dK}}\right)V \tag{13}$$

donde: dK es la dimensión del vector de entrada. El mecanismo de atención múltiple consiste en introducir Q, K, V en múltiples módulos de autoatención después de mapearlos a través de una red completamente conectada. Luego, las salidas de múltiples autoatención se empalman y finalmente las salidas

Machine Translated by Google

se integran a través de la capa totalmente conectada. El proceso aritmético del mecanismo de autoatención de múltiples cabezas es el siguiente:

$$\text{MultiHead}(Q, K, V) = \text{Concat}(\text{head1}, \text{head2}, \ldots \text{headn})W0 \quad (14)$$

$$\text{Headi} = \text{Atención}\ (Qi\ , Ki\ , Vi) \quad (15)$$

donde: W0 es la matriz de parámetros. Se conectan múltiples salidas después de calcular los resultados de cada cabezal de atención por separado para obtener la capa de ^{T} de la atención multicabeza salida X.

En la arquitectura Transformer, la red de alimentación directa (FFN), la conexión residual y la normalización de capas (LN) son componentes centrales. La FFN se utiliza para realizar transformaciones no lineales independientes en cada característica, con el siguiente proceso de cálculo:

$$\text{FFN}(X) = \text{ReLU}(XW1 + b1)W2 + b2 \quad (16)$$

donde: X es el vector de entrada, W1 y b1 son el peso y el sesgo de la primera capa, W2 y b2 son el peso y el sesgo de la segunda capa.

La conexión residual ayuda a mitigar el problema del gradiente evanescente y facilita la propagación de información en redes profundas. El propósito de la normalización de capas es normalizar todas las características de cada muestra, mejorando la estabilidad numérica y acelerando la convergencia del entrenamiento. El proceso de cálculo es el siguiente:

$$H1 = \text{LN}\ X^{T} + X \quad (17)$$

$$H2 = \text{FFN}(H1) \quad (18)$$

$$\tau = \text{LN}(H1 + H2) \quad (19)$$

donde: X y X^{T} representan la muestra de entrada y la salida de la capa de atención multi-cabeza, respectivamente, LN denota la conectividad residual y la normalización de la capa y FFN denota la red de alimentación directa, τ representa la representación de características obtenida después del procesamiento a través de la autoatención multi-cabeza, la red de alimentación directa, la conexión residual y la normalización de la capa.

3.4. Análisis de errores y detección de anomalías

3.4.1. Detección de anomalías basada en la desigualdad de Chebyshev

La desigualdad de Chebyshev es un teorema importante en la teoría de la probabilidad para estimar la probabilidad de un rango particular de un conjunto de datos, aplicable a todas las distribuciones de probabilidad. Proporciona un límite superior basado en la desviación estándar, lo que nos permite identificar puntos de datos que difieren de la media sin asumir una distribución de datos.

La desigualdad de Chebyshev establece que para cualquier variable aleatoria X, si la media de X ^{1} y la desviación estándar es σ, al menos $1 - k\ ^{2}$ — es μ de la proporción (o porcentaje) de datos Los puntos se encuentran dentro del rango μ ± kσ, donde k es un número positivo. El procedimiento aritmético para la detección de anomalías mediante la desigualdad de Chebyshev es el siguiente:

$$y = x\hat{}^{\ tt - x} \quad (20)$$

et es el error entre el valor predicho $x\hat{}$ t y el valor observado x donde: ^{t}.

$$\mu e = \frac{1}{n}\sum_{t=1}^{\infty} Y \quad (21)$$

Machine Translated by Google

$$\sigma e = \sqrt{\frac{1}{n}\sum_{t=1}^{n}(y - \mu e)^2} \quad (22)$$

donde: et representa el error de la t-ésima muestra, n es el número total de muestras, μe es la media del error y σe es la desviación estándar del error.

Según la desigualdad de Chebyshev, dada la media y la desviación estándar de la error, el valor umbral k se puede elegir para determinar el umbral de valores atípicos, es decir:

$$P(|et - \mu e| \geq k\sigma e) \leq \frac{1}{k^2} \quad (23)$$

Esta fórmula indica que la probabilidad del error et desviarse de la media μe por al menos k veces la desviación estándar no excederá $\frac{1}{k^2}$.

3.4.2. Proceso de detección de anomalías

El proceso principal de detección del método de detección de datos anómalos basado en predicción propuesto en este artículo es el siguiente:

1. Primero, el conjunto de datos se divide en un conjunto de entrenamiento y un conjunto de prueba en una proporción determinada; 2. Las características temporales de los datos originales de flujo de tráfico se extraen utilizando Bi-LSTM; los datos originales se construyen en datos gráficos con correlación espacial utilizando una matriz de adyacencia, y la correlación espacial de los datos gráficos se extrae mediante GAT; 3. Los datos brutos de flujo de tráfico se someten a FFT para transformar la señal al espacio del dominio de la frecuencia, y el modelo Transformer se utiliza para aprender las características de magnitud y fase en el dominio de la frecuencia; 4. Se aprenden completamente las características del dominio del tiempo y la frecuencia de los datos para construir modelos predictivos; 5. Con base en los datos observados en cada nodo en el tiempo histórico K, se predice el flujo de tráfico en ese nodo en el intervalo de tiempo H;
6. Analice el error et entre el valor observado y x, calcule el umbral del valor atípico t valor predicho $\hat{x}_t$, desalentar- según la desigualdad de Chebyshev y determine si el error et cae dentro del rango del umbral para detectar si los datos en el punto son datos anómalos o no.

4. Experimentos y resultados

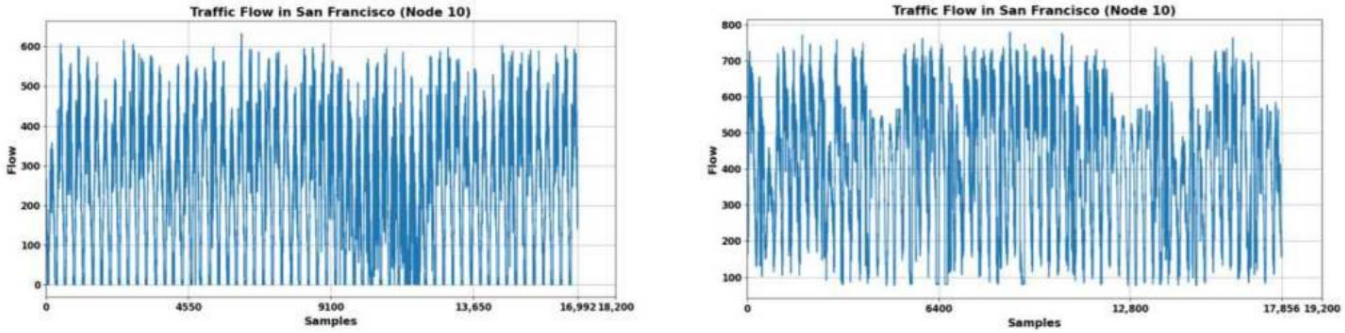
4.1. Conjuntos de datos

Los conjuntos de datos utilizados en este artículo son conjuntos de datos de acceso público proporcionados por el Sistema de Medición del Rendimiento (PEMS), un sistema de gestión del transporte de California. El conjunto PEMS04 utilizado en este artículo contiene datos generados por 307 detectores que recopilaron datos a intervalos de 5 minutos durante un total de 59 días. El conjunto PEMS08 contiene datos generados por 170 detectores que recopilaron datos a intervalos de 5 minutos durante un total de 62 días. Los datos recopilados por cada detector en cada adquisición contienen tres dimensiones de características: caudal, velocidad media y ocupación media. En este artículo, conservaremos el componente de caudal para los experimentos de predicción. El tráfico bruto del nodo 10 en ambos conjuntos de datos se muestra en la Figura 2a,b, donde (a) son los datos de tráfico del nodo 10 de PEMS04, 16.992 es la cantidad recopilada en 59 días en este nodo, y (b) son los datos de tráfico del nodo 10 de PEMS08, 17.856 es la cantidad recopilada en 62 días en este nodo. En el proceso de extracción de características del dominio de la frecuencia, sometimos la secuencia de flujo de tráfico original a FFT, y los espectrogramas del nodo 10 en ambos conjuntos de datos después de la transformación FFT se muestran en la Figura 3a,b.

Machine Translated by Google

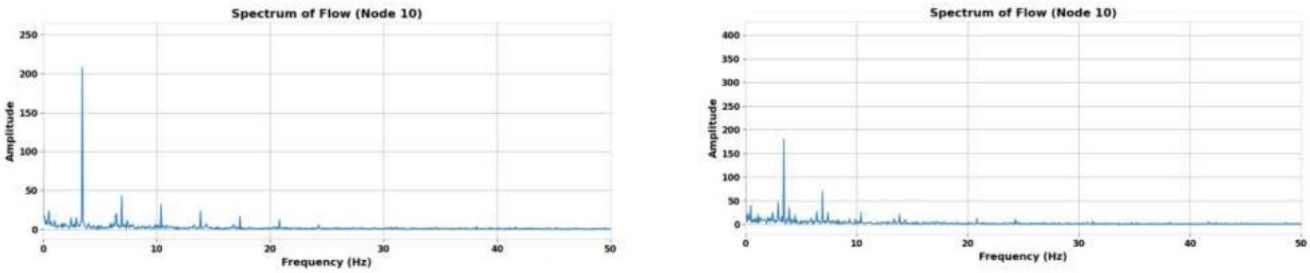
at this node. ¿Cuál es la trayectoria de alguien? , , s te quantty coecte n noe, an 62 days

En el proceso de extracción de características del dominio de la frecuencia, sometimos la secuencia de flujo de traza original a FFT, y los espectrogramas del nodo 10 en ambos conjuntos de datos después de la transformación FFT se muestran en la Figura 3a,b.



(a) PEMS04 Visualización del flujo de traza en el nodo 10 (b) PEMS08 Visualización del flujo de traza en el nodo 10

Figura 2. Figura 2. Visualización del flujo de tráfico en el nodo 10. Visualización del flujo de tráfico en el nodo 10.

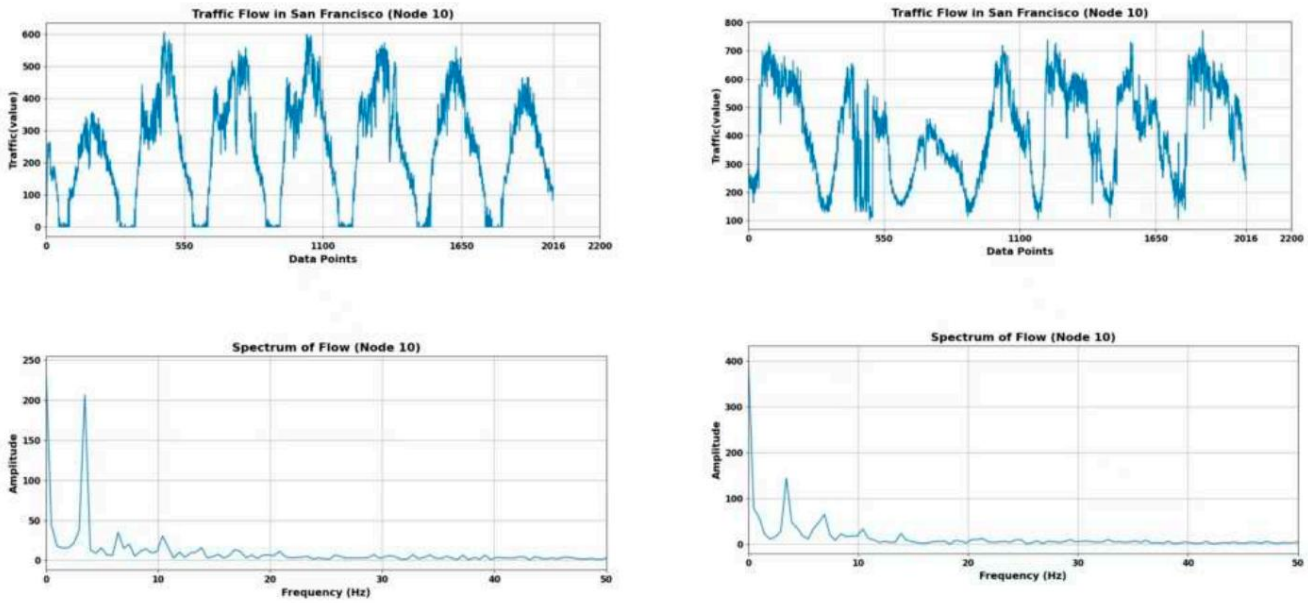


(a) Espectrograma PEMS04 del nodo 10 (b) Espectrograma PEMS08 del nodo 10

Figura 3. Espectrograma del nodo 10. Figura 3. Espectrograma del nodo 10.

ffi

Específicamente, el número de muestras recolectadas en un día es 288, y tomamos el tráfico Específicamente, el número de muestras recolectadas en un día es 288, y tomamos el tráfico tiempo de flujo de cuatro semanas para analizar, como se muestra en la Figura 4a. Además, desde el dominio del tiempo, principal, se puede ver que presenta una periodicidad clara. Sin embargo, otras características no son Los datos presentados no se pueden obtener del dominio del tiempo. Los datos no se pueden obtener del dominio del tiempo.



(a) PEMS04 Flujo de tráfico semanal y espectrograma en el nodo 10 (a) PEMS04 Flujo de tráfico semanal y espectrograma en el nodo 10 (b) PEMS08 Flujo de tráfico semanal y espectrograma en el nodo 10 (b) PEMS08 Flujo de tráfico semanal y espectrograma en el nodo 10

Figura 4. Flujo de tráfico semanal y espectrograma en el nodo 10.

ffi

Figura 4. Flujo de traza semanal y espectrograma en el nodo 10.

La amplitud representa la fuerza o energía de una señal a una frecuencia específica.

Machine Translated by Google

La amplitud representa la fuerza o energía de una señal a una frecuencia específica. Cuanto mayor sea la amplitud, mayor será la contribución de ese componente de frecuencia a la señal. La amplitud se utiliza habitualmente para identificar los componentes de frecuencia dominantes de la señal. La fase, por otro lado, indica la relación entre un componente de frecuencia específico y el tiempo. La información de fase es crucial para comprender la forma de onda, la periodicidad y los retardos de tiempo de la señal . Cuando se superponen varias señales, las diferencias de fase pueden causar interferencias, lo que, a su vez, puede afectar la forma final de la señal.

4.2. Métricas de evaluación

El método de detección de anomalías propuesto en este artículo se basa en la predicción de flujo, y la precisión de la detección está relacionada con la precisión de la predicción. Las métricas de evaluación seleccionadas son el Error Absoluto Medio (MAE), el Error Cuadrático Medio (RMSE) y el Error Porcentual Absoluto Medio (MAPE). Donde: x^t es el valor observado, $\hat{x}^t$ es la predicción es el valor y n es el número total de muestras.

El MAE mide el valor absoluto promedio de los errores de predicción, que representa la desviación promedio entre los valores predichos y los valores reales. Cuanto menor sea el valor, más precisa será la predicción. La fórmula de cálculo es la siguiente:

$$ES = \frac{1}{n}\sum_{t=1}^{n} |x^t - \hat{x}^t|. \quad (24)$$

El RMSE calcula el error cuadrático medio, que es la raíz cuadrada del promedio de los errores al cuadrado. Dado que elevar al cuadrado amplifica los errores grandes, el RMSE enfatiza el impacto de estos. Es adecuado para escenarios sensibles a errores grandes. Cuanto menor sea el valor, mejor será el ajuste del modelo. La fórmula de cálculo es la siguiente:

$$RMSE = \sqrt{\frac{1}{n}\sum_{t=1}^{n} (x^t - \hat{x}^t)^2}. \quad (25)$$

El MAPE mide el porcentaje de error con respecto a los valores reales, proporcionando una métrica de error adimensional. Cuanto menor sea el valor, menor será el error de predicción del modelo.
La fórmula de cálculo es la siguiente:

$$MAPA = \frac{100\%}{n}\sum_{t=1}^{n} \frac{|x^t - \hat{x}^t|}{x^t}. \quad (26)$$

El coeficiente de eficiencia de Nash-Sutcliffe (NSE) se utiliza comúnmente para cuantificar la precisión predictiva de los modelos de simulación y se aplica ampliamente en la evaluación de modelos hidrológicos, meteorológicos y ambientales. El NSE es un indicador del grado de ajuste entre las predicciones del modelo y los valores observados. Calcula el error cuadrático medio entre los resultados predichos y los valores observados, y lo compara con la varianza de estos últimos. El rango del NSE va de −∞ a 1, donde un valor más cercano a 1 indica un mejor rendimiento del modelo. La expresión matemática del NSE es la siguiente:

$$NSE = 1 - \frac{\sum_{t=1}^{n} (x^t - \hat{x}^t)^2}{\sum_{t=1}^{n} (x^t - \bar{x}^t)^2} \quad (27)$$

donde: x^t es el valor observado, $\hat{x}^t$ es el valor predicho, y $\bar{x}^t$ es la media de los observaciones.

Machine Translated by Google

4.3. Modelos contrastantes y experimentos de ablación

LSTM se ha aplicado ampliamente en escenarios de predicción, principalmente para capturar dependencias temporales. En tareas de pronóstico de series temporales, puede explorar eficazmente las características variables en el tiempo de los datos. Por ejemplo, Abbass et al. [32] utilizaron LSTM para desarrollar un modelo de predicción de estabilidad de voltaje para sistemas de energía, mientras que Wang et al. [33] propusieron un modelo de predicción de consumo de combustible de barcos basado en LSTM utilizando un mecanismo de autoatención. Para capturar dependencias temporales y espaciales simultáneamente, se utiliza CNN para capturar relaciones espaciales. La combinación de CNN y LSTM se ha convertido en un modelo temporal común para la predicción del flujo de tráfico [26–30]. Para evaluar el impacto de las características del dominio de la frecuencia propuestas en este artículo en los resultados de predicción, se compararon los siguientes modelos: 1. LSTM-CNN: LSTM es un tipo especial de RNN que aprende información dependiente a largo plazo y se utiliza ampliamente en el procesamiento de datos secuenciales. CNN es una clase de modelos de aprendizaje profundo especializados para procesar datos con estructura de cuadrícula. Enfoque de aprendizaje profundo temporal + red neuronal convolucional para capturar correlaciones tanto temporales como espaciales;

2. Bi-LSTM-GAT: Bi-LSTM es un modelo LSTM bidireccional que logra lecturas bidireccionales mediante la adición de una capa inversa. GAT [17] utiliza un mecanismo de atención para aprender adaptativamente la conectividad entre nodos para lograr la agregación ponderada de vecinos y lograr la capacidad de capturar correlaciones espaciales para correlaciones espaciales con conectividad compleja. Este experimento captura correlaciones tanto temporales como espaciales;

3. LSTM-CNN-TF: Transformer [18] captura las dependencias de largo alcance en el dominio de la frecuencia a través de un mecanismo de autoatención y lo combina con el enfoque clásico de aprendizaje profundo temporal en el dominio del tiempo + red neuronal convolucional para realizar la predicción combinada en el dominio del tiempo y el dominio de la frecuencia propuesta en este trabajo. papel.

4.4. Configuración

experimental En el experimento, los datos de 59 días de PEMS04 se dividen en un conjunto de entrenamiento y un conjunto de prueba, utilizando los primeros 45 días para el entrenamiento del modelo y los 14 días siguientes para las pruebas. En PEMS08, los datos de 62 días se dividen en un conjunto de entrenamiento y un conjunto de prueba, utilizando los primeros 48 días para el entrenamiento y los 14 días restantes para las pruebas. Para cada conjunto de datos, se utilizan datos históricos de 6 intervalos de tiempo (media hora) para predecir el cambio en el flujo de tráfico en el siguiente intervalo de tiempo (5 minutos).

Todas las redes de aprendizaje profundo de este estudio se implementaron con PyTorch 2.3.1. El modelo utiliza el optimizador Adam con una tasa de aprendizaje de 0,0001, un tamaño de lote de 64 y 50 épocas. Además, se emplean estrategias de disminución de la tasa de aprendizaje y parada temprana para evitar el sobreajuste.

Los parámetros de red del modelo propuesto en este artículo se establecen de la siguiente manera: el número de cabezas de atención múltiple en la red GAT num_heads es 4; el número de capas ocultas num_hid es 6; y la dimensión de la característica de salida out_c es 6. El número de capas num_layers de Bi-LSTM es 2, la dimensión de la capa oculta hid_c es 16, y la dimensión de la característica de salida out_c es 6; el codificador Transformmer tiene una dimensión de salida coder_c de 8; el número de codificadores y decodificadores num_coder es 2, y el número de cabezas de atención num_heads es 4. El tamaño del núcleo convolucional kernel_size de la CNN es 5 en los experimentos de comparación y ablación.

4.5. Resultados previstos

Para verificar las ventajas del modelo BI-GAT-TF propuesto en este artículo, se realizó un experimento comparativo con el modelo de predicción CNN-LSTM-TF. Además, para

Machine Translated by Google

evaluar la efectividad de la extracción de características espaciales en el dominio de la frecuencia propuesta en
Para mejorar la precisión predictiva del modelo, se realizó un estudio de ablación mediante la eliminación
el módulo de extracción de características en el dominio de la frecuencia del modelo BI-GAT-TF y la observación
los resultados. Para una comprensión más intuitiva del impacto de la característica del dominio de la frecuencia
Extracción de los resultados experimentales, también se hizo una comparación entre el método tradicional
Modelo CNN-LSTM y modelo CNN-LSTM-TF.

Los resultados experimentales comparan el modelo de predicción propuesto con el modelo de referencia.
Los modelos se muestran en las Figuras 5 y 6. A partir de los resultados, el modelo propuesto logra el
MAE más bajo, MAPE (%) y RMSE en los conjuntos de datos PEMS04 y PEMS08. Específicamente,
en el conjunto de datos PEMS04, los valores son 26,05, 12,36 y 37,08, mientras que en el conjunto de datos PEMS08,
Los valores son 19,12, 7,25 y 19,12, respectivamente. El NSE también es el más alto en ambos casos.
conjuntos de datos, con valores de 0,93 y 0,97, respectivamente. Estos resultados indican que la propuesta
El modelo logra un rendimiento óptimo en términos de error de predicción y precisión. En particular, el
Los resultados experimentales en el conjunto de datos PEMS08 superan a los del conjunto de datos PEMS04.
Esto se puede atribuir al hecho de que el conjunto de datos PEMS08 contiene un mayor número de flujos de tráfico.
secuencias, lo que proporciona una longitud total de secuencia mayor. Este aumento en la longitud de la secuencia
ofrece una clara ventaja en términos de entrenamiento del modelo y extracción de características. En conclusión, el
La longitud de la secuencia ofrece una clara ventaja en términos de entrenamiento del modelo y extracción de características.
En conclusión, el método de predicción propuesto demuestra un excelente
Se basa en conjuntos de datos de prueba del mundo real, logrando predicciones más precisas.

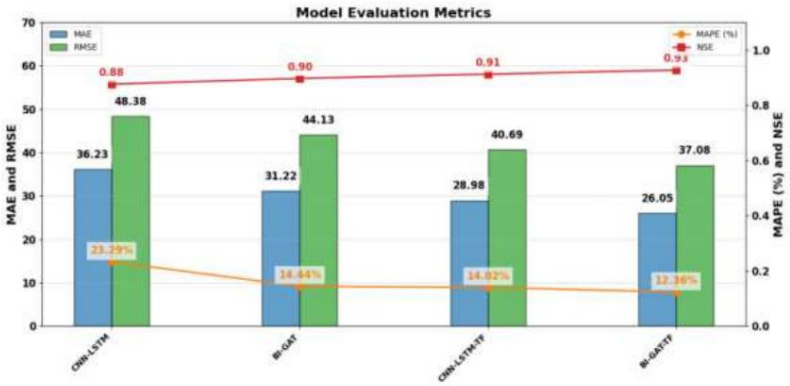


Figura 5. Métricas de rendimiento de cada modelo en el conjunto de datos PEMS04.
Figura 5. Métricas de rendimiento de cada modelo en el conjunto de datos PEMS04.

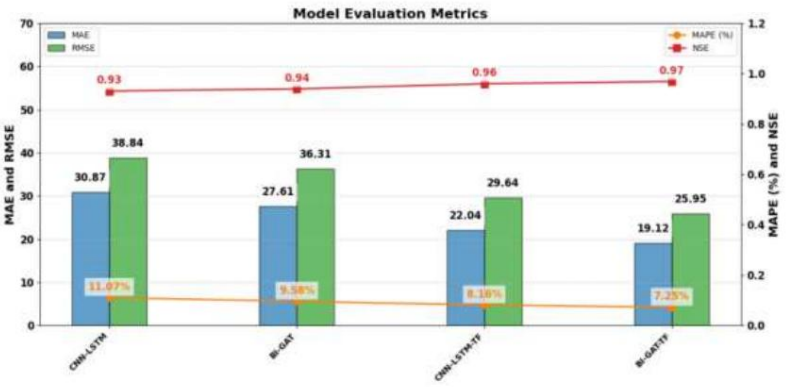
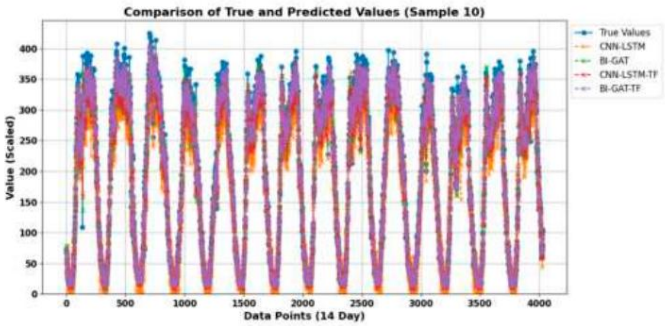


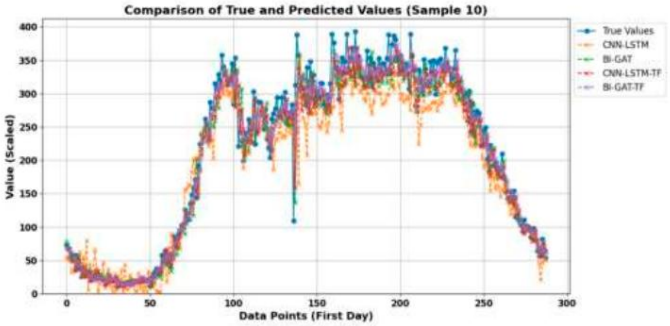
Figura 6. Métricas de rendimiento de cada modelo en el conjunto de datos PEMS08.
Figura 6. Métricas de rendimiento de cada modelo en el conjunto de datos PEMS08.

Las figuras 7 y 8 muestran los resultados experimentales para el nodo 10 en los sistemas PEMS04 y PEMS08.
Las figuras 7 y 8 muestran los resultados experimentales para el nodo 10 de los conjuntos de datos PEMS04 y PEMS08, respectivamente. (a) muestra los resultados de predicción del flujo de tráfico de 14 días para
de predicción del flujo de tráfico de 14 días para cada modelo:
cada modelo; (b) muestra los resultados de predicción del flujo de tráfico para cada modelo en el primer día; (c) muestra los
(b) muestra los resultados de predicción del flujo de tráfico para cada modelo en el primer día; (c) muestra los resultados
predicción del flujo de tráfico para CNN-LSTM y CNN-LSTM-TF en el primer día; (d)
Resultados de predicción del flujo de tráfico para CNN-LSTM y CNN-LSTM-TF en el primer día; (d) muestra los resultados
de predicción de flujo de tráfico para BI-GAT y BI-GAT-TF en el primer día; (e)
muestra los resultados de predicción del flujo de tráfico para BI-GAT y BI-GAT-TF en el primer día; (e)
muestra los resultados de predicción del flujo de tráfico para CNN-LSTM-TF y BI-GAT-TF en el primer día.
muestra los resultados de predicción de flujo de traza para CNN-LSTM-TF y BI-GAT-TF en el primer día.
día.

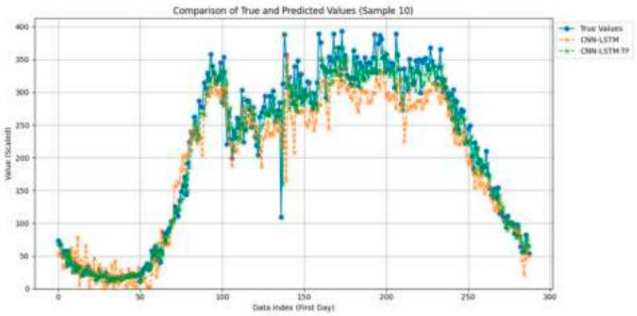
Machine Translated by Google



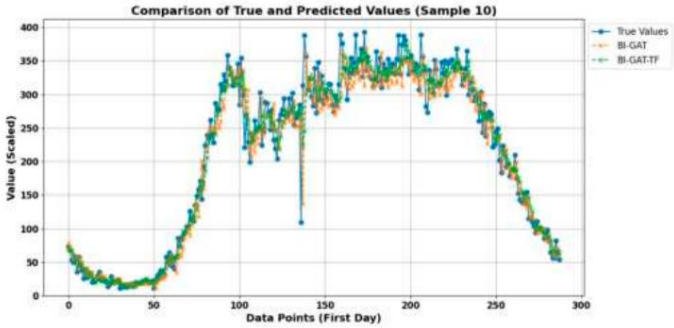
(a) Los resultados de la predicción del flujo de tráfico a 14 días para cada modelo.



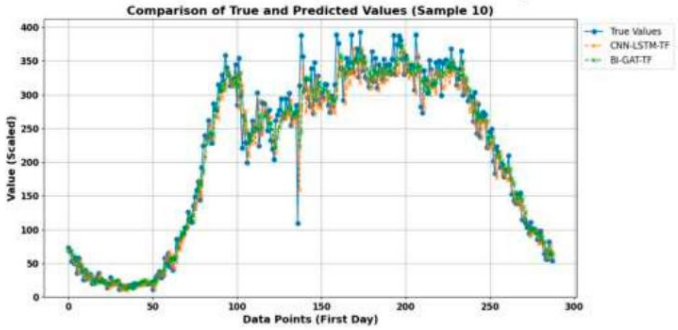
(b) Los resultados de la predicción del flujo de tráfico para cada modelo en el primer día.



(c) Resultados de predicción del flujo de tráfico para CNN-LSTM y CNN-LSTM-TF en el primer día.



(d) Los resultados de la predicción del flujo de tráfico para BI-GAT y BI-GAT-TF en el primer día.



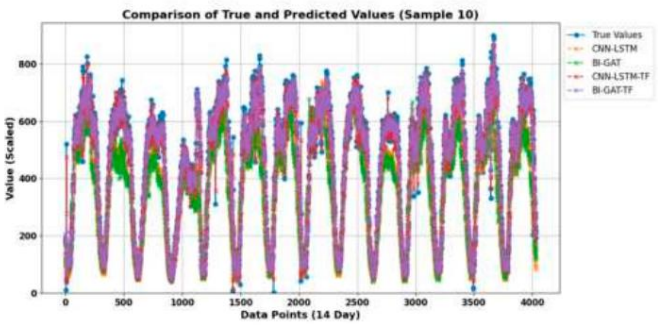
(e) Resultados de predicción del flujo de tráfico para CNN-LSTM-TF y BI-GAT-TF en el primer día.

Figura 7. Resultados experimentales en el conjunto de datos PEMS04.

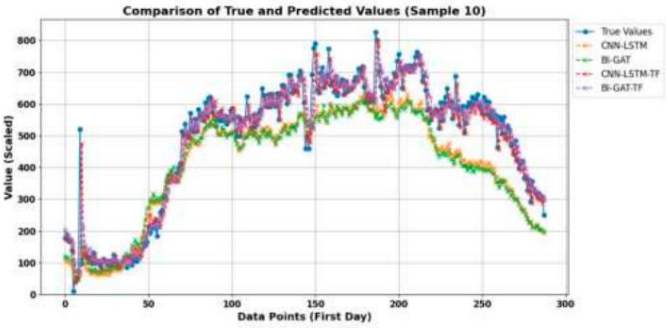
Como se muestra en las figuras 7c,d y 8c,d, los resultados indican que los modelos de predicción con El módulo de extracción de características del dominio de frecuencia se acerca más a los datos reales. Los resultados en Las figuras 7e y 8e demuestran más claramente que el modelo BI-GAT-TF funciona mejor en términos de ajuste en comparación con CNN-LSTM-TF. Esto sugiere que el modelo propuesto, ambos en términos del modelo de extracción de características del dominio del tiempo seleccionado y la idea de frecuencia La extracción de características del dominio mejora significativamente la precisión predictiva del modelo.

Cabe destacar que, tanto en los conjuntos de datos PEMS04 como PEMS08, hay puntos de datos. con grandes fluctuaciones, como alrededor del mediodía en PEMS04 (alrededor de las 12:00) y alrededor de la 1 AM en PEMS08. En estos momentos, el rendimiento de ajuste de CNN-LSTM-TF es mejor que el de otros tres modelos. Sin embargo, al analizar estos puntos, es importante considerar no no solo el ajuste del modelo en estos puntos, sino también si los datos recopilados en estos momentos Los puntos pueden ser anómalos.

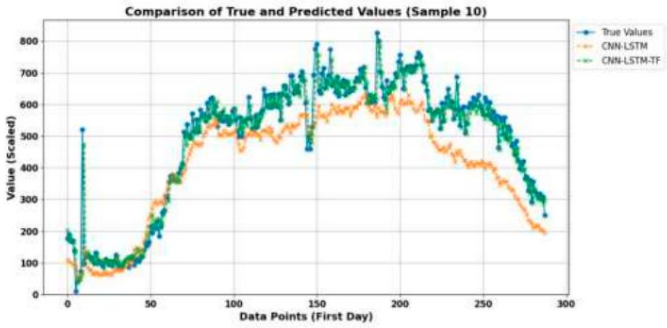
Machine Translated by Google



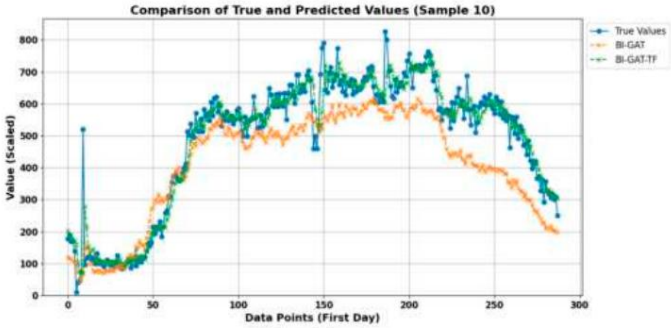
(a) Los resultados de la predicción del flujo de tráfico a 14 días para cada modelo.



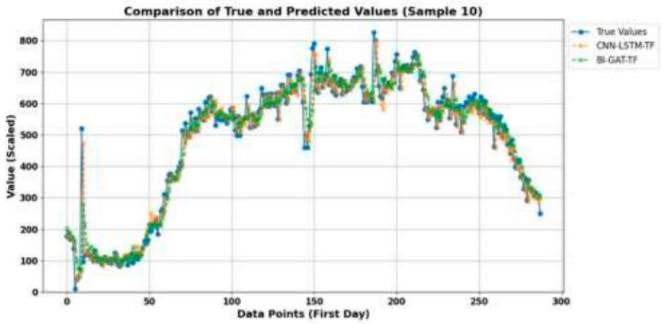
(b) Los resultados de la predicción del flujo de tráfico para cada modelo en el primer día.



(c) Resultados de predicción del flujo de tráfico para CNN-LSTM y CNN-LSTM-TF en el primer día.



(d) Los resultados de la predicción del flujo de tráfico para BI-GAT y BI-GAT-TF en el primer día.



(e) Resultados de predicción del flujo de tráfico para CNN-LSTM-TF y BI-GAT-TF en el primer día.

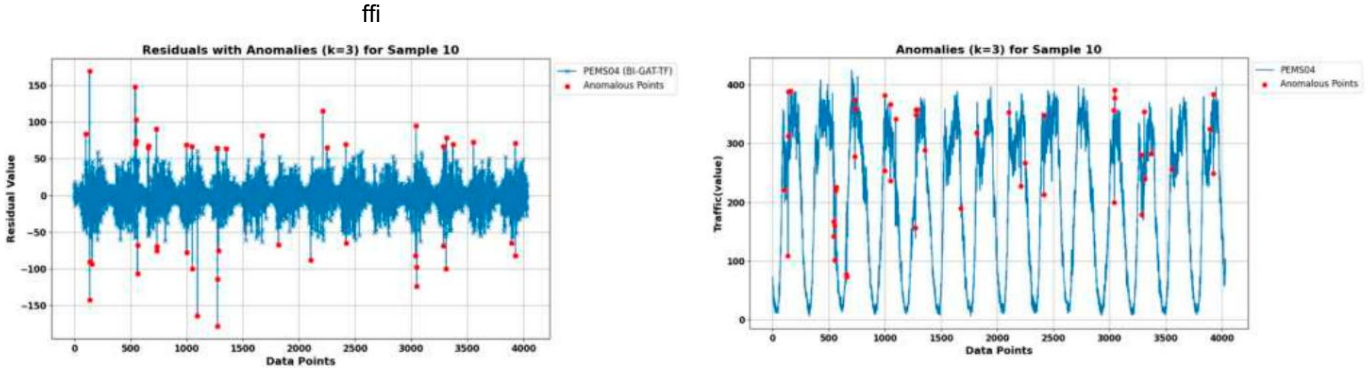
Figura 8. Resultados experimentales en el conjunto de datos PEMS08.

4.6. Resultados de detección anormales

La parte de detección de anomalías requiere primero determinar el umbral de error. Establezca k en 3. Según la desigualdad de Chebyshev, un error et que excede μe + 3σe o μe − 3σe es considerado como un valor atípico para ese punto de datos, es decir, al menos $1 \frac{1}{9} \approx 88{,}9\%$ de los errores debería estar dentro del rango de μe ± 3σe . Combinado con la predicción propuesta anteriormente modelo, se lleva a cabo la detección de anomalías y el número de anomalías detectadas en el Los conjuntos de datos PEMS04 y PEMS08 son 46 y 51, respectivamente. Los resultados de la detección se muestran a continuación. en las Figuras 9 y 10. Entre ellas, las Figuras 9a y 10a muestran los gráficos de residuos para los dos conjuntos de datos, que muestran el rango residual cuando k = 3 y las anomalías detectadas en el residuo gráficos. Las figuras 9b y 10b muestran los puntos anómalos detectados en el flujo de tráfico original. para los dos conjuntos de datos.

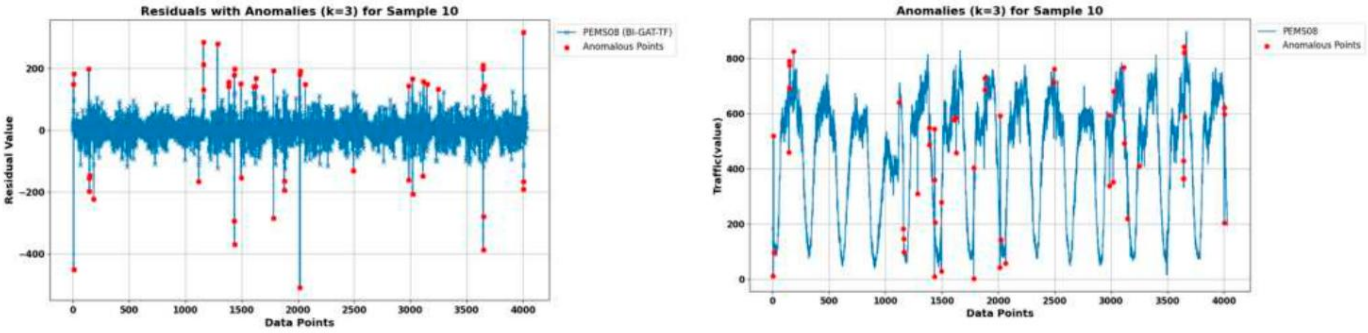
3 +
3 −
1− 88,9%
3 ±

Machine Translated by Google



(a) Gráfico de residuos. b) Resultados de la detección de anomalías.

Figura 9. Resultados de la detección de anomalías en el conjunto de datos PEMS04.



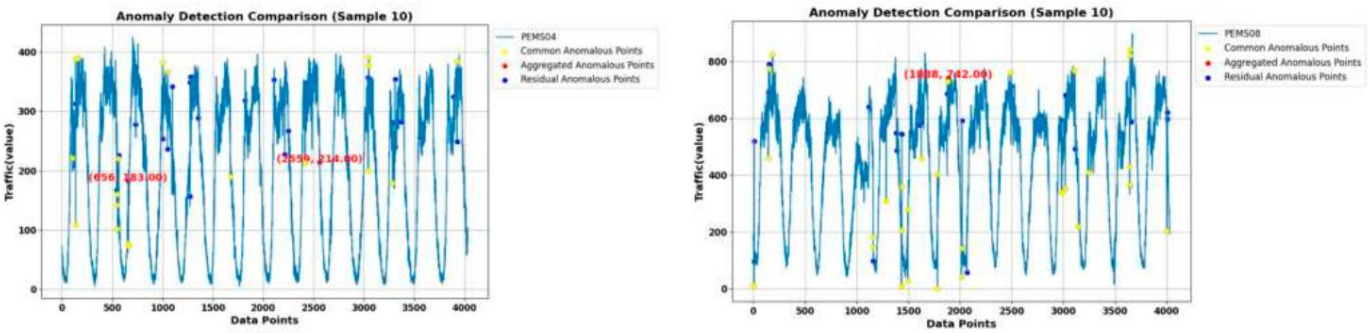
(a) Gráfico de residuos. b) Resultados de la detección de anomalías.

Figura 10. Resultados de la detección de anomalías en el conjunto de datos PEMS08.

El conjunto de datos utilizado en este artículo son datos reales de flujo de tráfico y no hay etiquetado de datos de anomalías. Para verificar de manera más razonable la efectividad y precisión de los Método de detección en este artículo, este artículo compara los métodos clásicos de detección de anomalías no supervisados: el método de bosque aislado basado en conjuntos [34], el método basado en reconstrucción El método LSTM-VAE [35] y los métodos LSTM-NDT [36] basados en predicción , para profundizar aún más validar la precisión de la detección de anomalías. Isolation Forest (IF) distingue lo normal y datos anormales por aislamiento y es adecuado para datos de alta dimensión y a gran escala conjuntos de datos; LSTM-VAE captura dependencias temporales invocando un modelo combinatorio que introduce variables potenciales aprendidas por VAE en LSTM y, finalmente, identifica anomalías. mediante el uso de las probabilidades de reconstrucción; y LSTM-NDT predice las anomalías utilizando datos LSTM, detecta anomalías calculando errores e introduce un método no supervisado. Estrategia de umbralización de anomalías no paramétrica.

Los resultados de los tres métodos, Isolation Forest, LSTM-VAE y LSTM-NDT, son: agregados por el método de votación, y al menos dos métodos están configurados para considerar un punto como anómalo antes de que se considere como una anomalía. Las anomalías obtenidas de la La agregación se compara con las anomalías detectadas en este documento, y los resultados son: mostrado en la Figura 11. Los puntos azules en la figura son las anomalías detectadas utilizando el métodos en este artículo y no detectados por los métodos de agregación, los puntos amarillos son las anomalías comunes detectadas por los métodos de agregación y también detectadas por el métodos en este artículo, y los puntos rojos son las anomalías detectadas por la agregación métodos y no detectados por los métodos de este artículo.

Machine Translated by Google



(a) Resultados de agregación de datos anómalos en el conjunto de datos PEMS04.

(b) Resultados de agregación de datos anómalos en el conjunto de datos PEMS08.

Figura 11. Resultados de agregación de datos anómalos en conjuntos de datos.

El análisis de los resultados de la agregación muestra que en el conjunto de datos PEMS04, el número de agregación es 21, y el número de anomalías

El método de detección de este artículo es 46. En comparación con las anomalías obtenidas por el método de agregación, el método de detección de este artículo detectó 19 de ellas y 2 datos

No se detectaron puntos. En el conjunto de datos PEMS08, el número de anomalías obtenidas por el método de

El método de agregación es 30, y el número de anomalías obtenidas por el método de detección no se

El método de agregación es 30,51. En comparación con las anomalías obtenidas por el método de detección de agregación , el

método, el método de detección con este artículo detecta 29 de ellos, y 1 punto de datos no está en este

detectado.

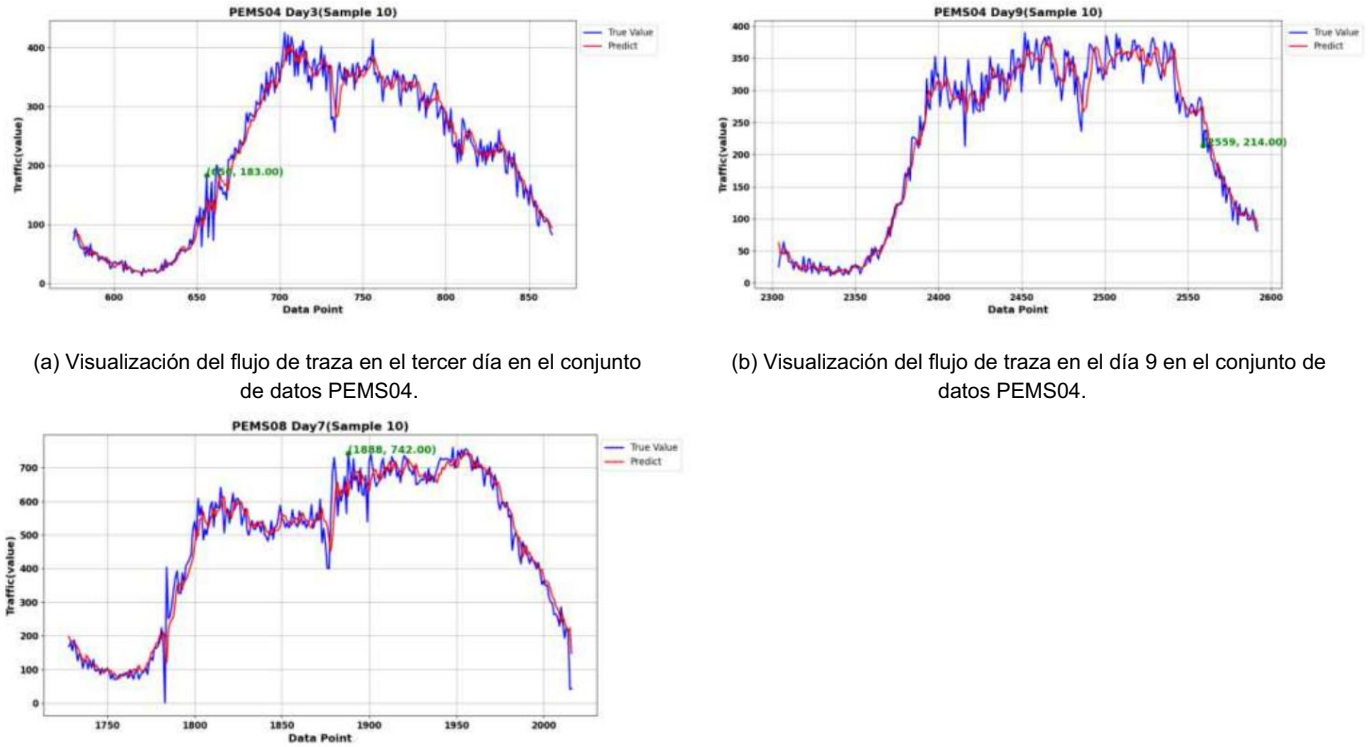
El método de detección utilizado en este artículo detecta 29 de ellos, y 1 punto de datos no se detecta.

Después del análisis, los dos puntos de datos que no fueron detectados en este documento en el PEMS04

El conjunto de datos se encontraba en los períodos de tiempo del tercer y noveno día. De manera similar, el punto de datos en

El séptimo conjunto de datos PEMS08 que parecía no haber sido detectado, se encontraba en el período de tiempo

día, como se muestra en la Figura 12.



(a) Visualización del flujo de traza en el tercer día en el conjunto de datos PEMS04.

(b) Visualización del flujo de traza en el día 9 en el conjunto de datos PEMS04.

(c) Visualización del flujo de traza en el séptimo día en el conjunto de datos PEMS08.

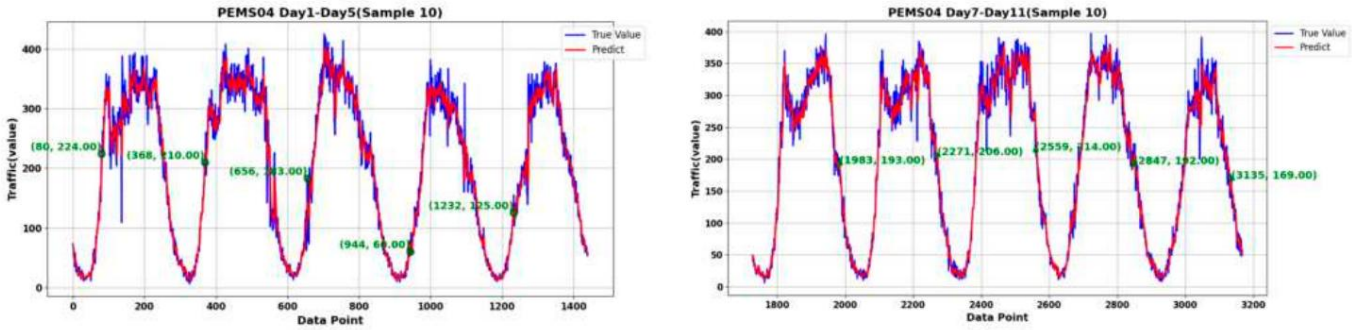
Figura 12. Visualización de los puntos de datos no detectados en el conjunto de datos.

Figura 12. Visualización de los puntos de datos no detectados en el conjunto de datos.

Ampliamos el rango de tiempo y visualizamos los resultados, como se muestra en las Figuras 13 y 14. Específicamente, la Figura 13a muestra el flujo de trazas del primer al quinto día en el conjunto de datos PEMS04, mientras que la Figura 13b muestra el flujo de trazas del séptimo al undécimo día en el conjunto de datos PEMS04. La Figura 14 muestra el flujo de trazas del quinto al noveno día.

Machine Translated by Google

Ampliamos el intervalo de tiempo y visualizamos los resultados, como se muestra en las figuras 13 y 14. Específicamente, la Figura 13a muestra el flujo de tráfico desde el primer hasta el quinto día en el PEMS04. conjunto de datos, mientras que la Figura 13b muestra el flujo de tráfico del séptimo al undécimo día en el conjunto de datos PEMS04. La figura 14 muestra el flujo de tráfico del quinto al noveno día en el Conjunto de datos PEMS08. Los puntos de datos en las figuras representan las coordenadas de los puntos de datos. que no fueron detectados por nuestro método, así como las coordenadas de los dos días anteriores y después de cada uno de estos puntos.



(a) Visualización del flujo de tráfico del 1 al 5 (b) Visualización del flujo de tráfico del 7 al 11 (a) Visualización del flujo de tráfico del 1 al 5 (b) Visualización del flujo de tráfico del 7 al 11 día en el conjunto de datos PEMS04.
día en el conjunto de datos PEMS04. día en el conjunto de datos PEMS04.

Figura 13. Visualización parcial del flujo de traza del conjunto de datos PEMS04.
Figura 13. Visualización parcial del flujo de tráfico del conjunto de datos PEMS04.

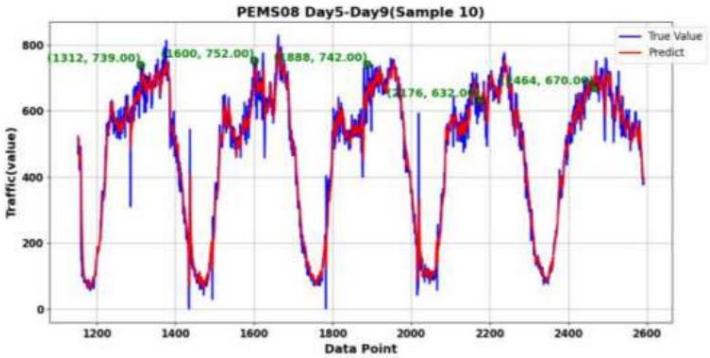


Figura 14. Visualización del flujo de tráfico desde el día 5 hasta el día 9 en el conjunto de datos PEMS08.
Figura 14. Visualización del flujo de traza desde el día 5 hasta el día 9 en el conjunto de datos PEMS08.

Los datos de flujo de tráfico muestran ciertos patrones periódicos, como diferencias en el flujo durante el
Los datos de flujo de seguimiento muestran ciertos patrones periódicos, como diferencias en el flujo durante el período típico (horas punta de la mañana y de la tarde) y períodos valle. También puede mostrar
períodos pico (horas pico de la mañana y de la tarde) y períodos fuera de pico. También puede mostrar variaciones estacionales a diario, semanalmente o mensualmente. Además, el flujo de tráfico entre
variaciones estacionales a diario, semanal o mensualmente. Además, el flujo de la vía entre tramos de carretera o intersecciones adyacentes suele estar correlacionado con las condiciones del tráfico aguas arriba.
El flujo entre tramos de carretera o intersecciones adyacentes suele estar correlacionado, de modo que el flujo aguas arriba influye en el flujo aguas abajo. El flujo normalmente cambia dentro de un rango razonable.
condiciones que influyen en las aguas abajo. El flujo cambia típicamente dentro de una característica razonable que se puede aprovechar para evaluar mejor si los puntos de datos no detectados son
rango. Esta característica se puede aprovechar para evaluar mejor si los datos no detectados son realmente anomalías. Sin embargo, los puntos de datos no detectados en las figuras no muestran ninguna
Los puntos son verdaderas anomalías. Sin embargo, los puntos de datos no detectados en las figuras no presentan anomalías significativas y se mantienen dentro de un rango de variación razonable.
no muestran anomalías significativas y se mantienen dentro de un rango de variación razonable.

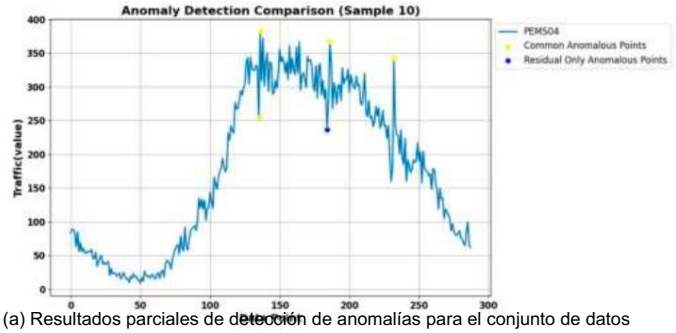
Un análisis de las anomalías detectadas por el método propuesto pero no detectadas por el método propuesto.
Un análisis de las anomalías detectadas por el método propuesto pero no detectadas por el método propuesto.
El método de agregación revela que el método de detección propuesto identifica más anomalías.
El método de agregación revela que el método de detección propuesto identifica más anomalías con características anormales claras que no se alinean con los cambios de flujo de tráfico a corto plazo,
radica en características claramente anormales que no se alinean con el flujo de traza a corto plazo como se muestra en la Figura 15. La razón de este resultado, aparte del método de agregación
cambios, como se muestra en la Figura 15. La razón de este resultado, además de la agregación que provoca la pérdida de algunas anomalías, radica principalmente en las limitaciones de lo mencionado anteriormente.
El método que causa la pérdida de algunas anomalías radica principalmente en las limitaciones de los métodos de detección de anomalías anteriores al manejar datos de alta dimensión y series temporales.
Los métodos de detección de anomalías mencionados al manejar instancias de series temporales y de alta dimensión , el método Isolation Forest asume que las características son independientes, pero en los datos de series temporales, las
dependencias temporales (como tendencias o estacionalidad) son cruciales y no logra detectarlas.

En los datos de series temporales, las dependencias temporales (como las tendencias o la estacionalidad) son cruciales, y modelar estas relaciones temporales. LSTM-VAE, si bien es eficaz, requiere un entrenamiento complejo.
No logra modelar estas relaciones temporales. LSTM-VAE, aunque eficaz, requiere com-

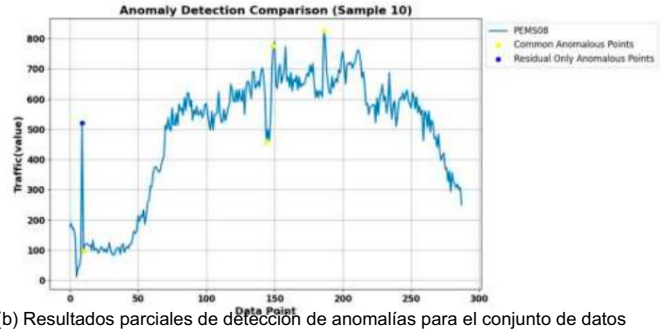
El entrenamiento es complejo y requiere mucho tiempo y recursos computacionales, especialmente para series temporales largas o datos de alta dimensión. Su eficiencia de entrenamiento es relativamente baja, y cuando la diferencia entre anomalías y datos normales es pequeña, el modelo puede tener dificultades para diferenciar entre ambos. LSTM-NDT asume que los errores de predicción de los datos normales son

Machine Translated by Google

y requiere mucho tiempo y recursos computacionales, especialmente para series temporales largas o datos de alta dimensión. Su eficiencia de entrenamiento es relativamente baja, y cuando la diferencia entre Si las anomalías y los datos normales son pequeños, el modelo puede tener dificultades para diferenciar entre ellos. Dos. LSTM-NDT supone que los errores de predicción de los datos normales son pequeños, mientras que aquellos el modelo de predicción y la capacidad reducida de diferenciación de errores, lo que hace que los impactos negativos de las anomalías sean mayores. Sin embargo, al modelar solo características temporales, no logra adecuadamente detección de anomalías. aprender todas las características de los datos, lo que lleva a un rendimiento deficiente del modelo de predicción. y una capacidad reducida de diferenciación de errores, lo que repercute negativamente en la detección de anomalías.



(a) Resultados parciales de detección de anomalías para el conjunto de datos PEMS04



(b) Resultados parciales de detección de anomalías para el conjunto de datos PEMS08

(a) Resultados parciales de detección de anomalías para el conjunto de datos PEMS04
(b) Resultados parciales de detección de anomalías para el conjunto de datos PEMS08

Figura 15. Resultados parciales de detección de anomalías para el conjunto de datos.
Figura 15. Resultados parciales de detección de anomalías para el conjunto de datos.

Además, el método de detección propuesto en este artículo también identifica casos donde La diferencia entre dos puntos de datos anómalos en un corto intervalo de tiempo es demasiado grande. y clasifica los datos entre estas anomalías como anormales, como se muestra en la Figura 16.

El conjunto de datos de este estudio se recopila cada 5 minutos y se basa en el análisis del flujo de tráfico características de variación, cambios significativos en el flujo de tráfico dentro de un corto período pueden ser causado no solo por anomalías en la recopilación de datos sino también por la ocurrencia de inesperados eventos.

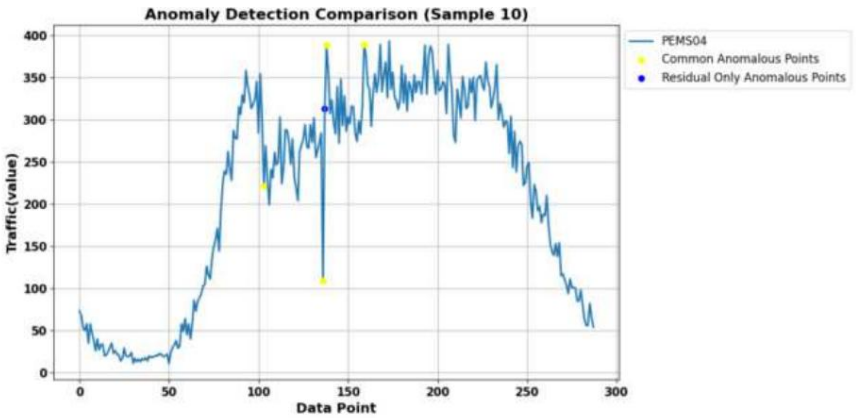


Figura 16. Resultados parciales de detección de anomalías para el conjunto de datos PEMS04.
Figura 16. Resultados parciales de detección de anomalías para el conjunto de datos PEMS04.

Para verificar si las fluctuaciones drásticas en el flujo de tráfico durante este período de tiempo fueron causadas por un evento repentino, analizamos la relación básica entre aguas arriba y aguas abajo. A raíz de un suceso repentino, analizamos la relación básica entre el flujo de tráfico ascendente y descendente. La relación entre el tráfico ascendente y descendente flujo aguas abajo. La relación entre el flujo aguas arriba y aguas abajo. El flujo es altamente dinámico y acoplado. El flujo aguas arriba afecta al flujo aguas abajo a través de un efecto de transmisión, mientras que el flujo aguas abajo también puede influir en el flujo aguas arriba a través de un efecto de retroalimentación. Observamos los cambios de flujo de los nodos conectados a este nodo en particular durante este período de tiempo, como se muestra en la Figura 17. De la Figura 17, no hubo cambios significativos. en el flujo de tráfico aguas arriba y aguas abajo durante este período, lo que hace que el cambios en el flujo aguas arriba y aguas abajo durante este período, haciendo que el similar- Probabilidad de un evento repentino mínima. Basándonos en consideraciones prácticas, si es anormal La probabilidad de un evento repentino es mínima. Basándose en consideraciones prácticas, si se detectan datos anormales tanto al principio como al final de un corto período de recopilación de datos, es muy probable que los datos medidos durante este corto período también sean anormales. Por lo tanto, la situación en la que dos puntos de datos anómalos dentro de un corto período de tiempo tienen una gran discrepancia, y los datos

Machine Translated by Google

Los datos se detectan tanto al principio como al final de un breve período de recopilación de datos.
medido durante este corto período es muy probable que también sea anormal. Por lo tanto, la situación en la que
dos puntos de datos anómalos dentro de un corto período de tiempo tienen una gran discrepancia y los datos
estos puntos también se clasifica como anormal, lo que se alinea mejor con escenarios del mundo real. Entre
Este análisis valida aún más que el método de detección de anomalías propuesto en este artículo
aún más que el método de detección de anomalías propuesto en este artículo Este análisis valida
tiene mayor precisión.
tiene mayor precisión.

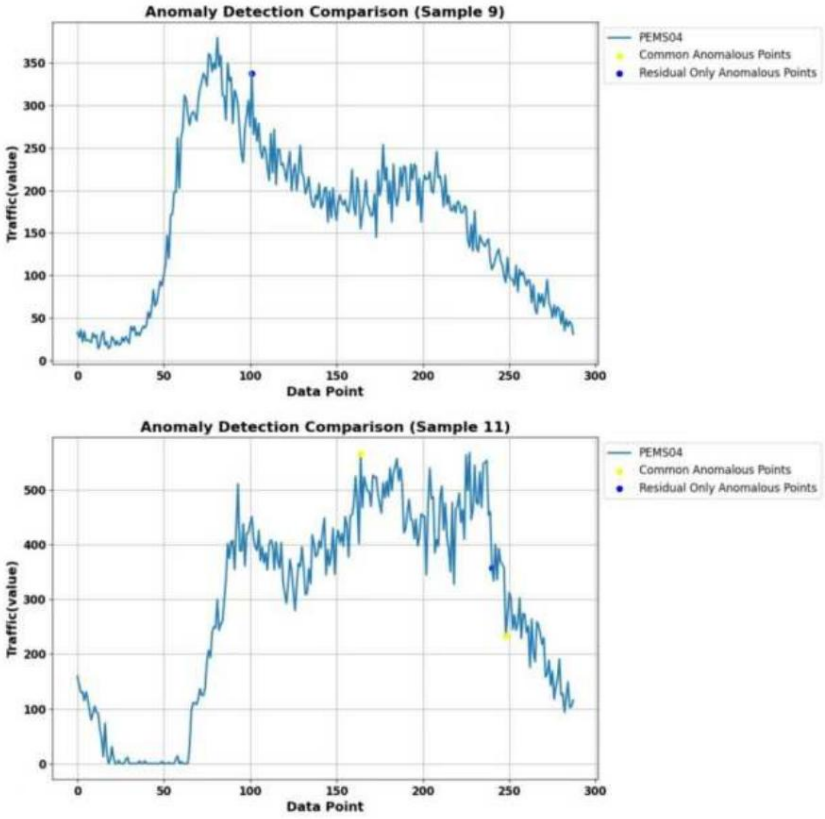


Figura 17. Visualización del flujo de tráfico de nodos advacentes para el nodo.
Figura 17. Visualización del flujo de traza de nodos adyacentes para el nodo.

5. Conclusiones
5. Conclusiones

Este artículo propone un método de detección de anomalías en el flujo de tráfico basado en predicción
Este artículo propone un método de detección de anomalías de flujo de trazas basado en la extracción predictiva
de características multidominio. El método reduce los errores de predicción mediante la construcción de
Extracción de características multidominio. El método reduce los errores de predicción mediante la construcción de un
modelo de predicción más preciso y determina el umbral de error utilizando la ecuación de Chebyshev.
modelo de predicción más preciso y determina el umbral de error utilizando la desigualdad de Chebyshev. Los puntos
de datos anómalos se identifican comprobando si el error de predicción
desigualdad. Los puntos de datos anómalos se identifican comprobando si el error de predicción cae dentro del rango
umbral. Los resultados experimentales demuestran que la optimización de la
cae dentro del rango umbral. Los resultados experimentales demuestran que optimizar el modelo de predicción y mejorar
el método de análisis de errores puede mejorar eficazmente el
Un modelo de predicción y la mejora del método de análisis de errores pueden aumentar eficazmente la precisión de la
detección de anomalías.
precisión en la detección de anomalías.

En términos de mejora del modelo de predicción, el enfoque propuesto aprovecha al máximo
En términos de mejora del modelo de predicción, el enfoque propuesto aprovecha al máximo las características
de los datos de flujo de tráfico e incorpora características tanto del dominio del tiempo como del dominio de la frecuencia
para el modelado de series temporales. En el dominio del tiempo, el modelo captura la información temporal.

características del dominio para el modelado de series temporales. En el dominio del tiempo, el modelo captura
correlaciones temporales y espaciales de la serie temporal, mientras que en el dominio de la frecuencia, extrae
correlaciones porales y espaciales de la serie temporal, mientras que en el dominio de la frecuencia, extrae información
de amplitud y fase para aprender características relacionadas con la frecuencia. Experimental
información de amplitud y fase para aprender características relacionadas con la frecuencia. Los resultados
experimentales en los conjuntos de datos PEMS04 y PEMS08 muestran que la precisión de predicción de la
Los resultados en los conjuntos de datos PEMS04 y PEMS08 muestran que la precisión de predicción de la
El modelo de extracción de características multidominio es significativamente superior al de los métodos que dependen de
El modelo de extracción de características multidominio es significativamente superior al de los métodos que se basan
unicamente en características del dominio del tiempo. Esta conclusión sigue siendo válida incluso cuando se compara con
Basándonos únicamente en características del dominio del tiempo, esta conclusión sigue siendo válida incluso al
compararía con el modelo clásico CNN-LSTM.
el modelo clásico CNN-LSTM.

En términos de análisis de errores y determinación del umbral de error, este artículo propone de manera innovadora
En términos de análisis de errores y determinación del umbral de error, este artículo introduce de
manera innovadora la desigualdad de Chebyshev para establecer el umbral de error. Al determinar si
Se introduce la desigualdad de Chebyshev para establecer el umbral de error. Al determinar si el error excede este
umbral, se realiza un análisis de error más científico y racional.
logrado, mejorando la precisión y robustez de la detección de anomalías. Como resultado, las anomalías potenciales
dentro del conjunto de datos se identifican eficazmente. Finalmente, una comparación con

Machine Translated by Google

Cuando el error supera este umbral, se realiza un análisis de errores más científico y racional, lo que mejora la precisión y la robustez de la detección de anomalías. Como resultado, se identifican eficazmente las posibles anomalías en el conjunto de datos. Finalmente, se lleva a cabo una comparación con métodos clásicos de detección de anomalías no supervisados para validar de forma más razonable la precisión del método propuesto en la detección de anomalías en conjuntos de datos sin etiquetar.

También cabe destacar que el conjunto de datos utilizado en este trabajo presenta algunas limitaciones, como una menor cantidad de datos faltantes y una menor proporción de ruido, entre otras. En el futuro, podremos realizar experimentos con etiquetas de valores atípicos más claras, añadiendo diferentes proporciones de ruido, comparando diversos modelos de referencia, etc., para mejorar continuamente la precisión de la detección.

Contribuciones de los autores: Conceptualización, XJ; Análisis formal, MG; Recursos, YL; Curación de datos, JZ; Redacción del borrador original, JQ; Revisión y edición, JQ; Supervisión, XJ y FG; Obtención de financiación, FG. Todos los autores han leído y aprobado la versión publicada del manuscrito.

Financiación: Esta investigación fue financiada por la Fundación Nacional de Ciencias Naturales de China (número de subvención 52462050) para el proyecto titulado “Análisis, evaluación cuantitativa y alerta temprana a corto plazo del mecanismo de evolución del riesgo del tráfico rodado en condiciones meteorológicas complejas en zonas de meseta y montañosas”.

Declaración del Comité de Ética Institucional: No aplica.

Declaración de consentimiento informado: No aplicable.

Declaración de disponibilidad de datos: Los datos que respaldan este estudio se incluyen en el artículo.

Conflictos de intereses: Los autores declaran no tener conflictos de intereses.

Referencias

1. Alqahtani, A.; Ali, M.; Xie, X.; Jones, MW. Agrupamiento profundo de series temporales: una revisión. Electronics 2021, 10, 3001. [CrossRef]
2. Zang, L.; Wang, T.; Zhang, B.; Li, C. Predicción de flujo de tráfico no estacionario basada en aprendizaje por transferencia utilizando AdaRNN y DCORAL. Expert Syst. Appl. 2024, 258, 125143. [CrossRef]
3. Gupta, M.; Wadhvani, R.; Rasool, A. Análisis exhaustivo de la detección de dinámicas de puntos de cambio en datos de series temporales: una revisión. Expert Syst. Appl. 2024, 248, 123342. [CrossRef]
4. Feng, J.; Zhang, Y.; Piao, X.; Hu, Y.; Yin, B. Detección de anomalías de tráfico basada en redes neuronales convolucionales de hipergrafos espaciotemporales Redes. Física. Mecánica Estadística. Sus Aplicaciones. 2024, 646, 129891. [CrossRef]
5. Wang, X.; Fan, J.; Yan, F.; Hu, H.; Zeng, Z.; Wu, P.; Huang, H.; Zhang, H. Detección de anomalías no supervisada mediante destilación inversa profesor-alumno mejorada con características normales. Electronics 2024, 13, 4125. [CrossRef]
6. Iliopoulos, A.; Violos, J.; Diou, C.; Varlamis, I. Feature Bagging with Nested Rotations (FBNR) para la detección de anomalías en series temporales multivariadas. Future Gener. Comput. Syst. 2025, 163, 107545. [CrossRef]
7. Yu, LR; Lu, QR; Xue, Y. DTAAD: Redes de atención Tcn duales para la detección de anomalías en datos de series temporales multivariadas. Knowl. -Based Syst. 2024, 295, 111849. [CrossRef]
8. Xie, S.; Li, L.; Zhu, Y. Detección de anomalías en series temporales multivariadas en IoT mediante descomposición wavelet discreta y redes de atención gráfica dual. Comput. Secur. 2024, 146, 104075. [CrossRef]
9. Dai, Z.; Hu, L.; Sun, H. PCA generalizado robusto para mejorar la discriminabilidad y la recuperabilidad. Neural Netw. 2025, 181, 106814. [CrossRef]
10. Aosong, L.; Yunpeng, H.; Guannan, L. El impacto del método PCA mejorado basado en la detección de anomalías en fallas de sensores de enfriadores detección. Int. J. Refrig. 2023, 155, 184–194.
11. Qu, X.; Huang, J.; Cheng, Z. Aprendizaje de diccionario discriminativo para clasificación basada en representación no negativa. Expert Syst. Solicitud 2024, 251, 123998. [CrossRef]
12. Rashidi, M.; Tashakori, S.; Kalhori, H.; Bahmanpour, M.; Li, B. Identificación iterativa de la fuerza de impacto en el hormigón de un puente. Cubierta. Sensores 2023, 23, 9257. [CrossRef]
13. Fernández-Navamuel, A.; Magalhaes, F.; Zamora-Sánchez, D.; Omella, ÁJ; García-Sánchez, D.; Pardo, D. El aprendizaje profundo mejoró el análisis de componentes principales para el monitoreo de la salud estructural. Estructura. Monitor de salud. 2022, 21, 1710–1722. [Referencia cruzada]
14. Dan, L.; Shisheng, Z.; Lin, L.; Minghang, Z.; Xuyun, F.; Xueyun, L. CSiamese: una novedosa detección de anomalías semisupervisada Marco de trabajo para turbinas de gas mediante similitud de reconstrucción. Neural Comput. Appl. 2023, 35, 16403–16427.

Machine Translated by Google

15. Ji, Y.; Wenhua, W.; Song, L. Modelo de detección de anomalías del sistema de amarre basado en el método LSTM PCA. Ocean. Eng. 2022, 254, 111350.

16. Aziz, Z.; Bestak, R. Perspectiva sobre la detección y predicción de anomalías y la mejora de la seguridad de las redes móviles mediante el aprovechamiento de Agrupamiento K-Means en registros de detalles de llamadas. Sensors 2024, 24, 1716. [CrossRef]

17. Rajeshkumar, C.; Soundar, KR; Muthuselvi, R.; Kumar, RR. Modelo UTO-LAB: modelo de detección de anomalías pulmonares sin contacto basado en USRP con clasificador de aprendizaje automático optimizado. Biomed. Signal Process. Control. 2025, 99, 106823. [CrossRef]

18. Wang, D.; Nie, M.; Chen, D. BAE: Algoritmo de detección de anomalías basado en agrupamiento y autoencoder. Matemáticas 2023, 11, 3398. [CrossRef]

19. Nallappan, M.; Velswamy, R. Exploración de la recuperación de vídeo basada en contenido mediante aprendizaje profundo con índice jerárquico de mundo pequeño navegable y características ResNet-50 para la detección de anomalías. Expert Syst. Appl. 2024, 247, 123197. [CrossRef]

20. Iqbal, A.; Amin, R. Pronóstico de series temporales y detección de anomalías mediante aprendizaje profundo. Comput. Chem. Eng. 2024, 182, 108560. [CrossRef]

21. Shafeiy, EE; Alsabaan, M.; Ibrahem, MI; Elwahsh, H. Detección de anomalías en tiempo real para el monitoreo de sensores de calidad del agua basada en Sobre la técnica de aprendizaje profundo multivariado. Sensors 2023, 23, 8613. [CrossRef] [PubMed]

22. Changzhi, L.; Dandan, L.; Mao, W.; Hanlin, W.; Shuai, X. Detección de valores atípicos en datos de potencia de series temporales basada en predicción. Errores. Energies 2023, 16, 582. [CrossRef]

23. Takahashi, K.; Ooka, R.; Kurosaki, A. Umbral estacional para reducir los falsos positivos en la detección de valores atípicos basada en predicciones. Datos de energía de edificios. J. Build. Eng. 2024, 84, 108539. [CrossRef]

24. Kidu, T.; Song, Y.; Seo, KW; Lee, S.; Park, T. Un sistema inteligente de reconocimiento de la actividad del conductor en tiempo real mediante información espaciotemporal Características. Appl. Sci. 2024, 14, 7985. [CrossRef]

25. Ullah, S.; Ullah, N.; Siddique, MF; Ahmad, Z.; Kim, JM Extracción de características espaciotemporales para la detección de fugas en tuberías en ciudades inteligentes mediante señales de emisión acústica: un enfoque híbrido unidimensional de red neuronal convolucional y memoria a corto y largo plazo . Appl. Sci. 2024, 14, 10339. [CrossRef]

26. Tipper, S.; Atlam, HF; Lallie, HS Una investigación sobre la utilización de CNN con LSTM para la detección de deepfakes de vídeo. Appl. Sci. 2024, 14, 9754. [CrossRef]

27. Xiong, J.; Sun, Y.; Sun, J.; Wan, Y.; Yu, G. Predicción de fallas basada en SSA-CNN-LSTM impulsada por datos temporales dispersos de sistemas electromecánicos. Equipamiento ical en estaciones de transporte ferroviario. Appl. Sci. 2024, 14, 8156. [CrossRef]

28. Li, S.; Sun, Y.; Wang, P. Predicción de la concentración de PM2.5 sobre la base de la fusión de escalas espaciales multitemporales. Appl. Sci. 2024, 14, 7152. [CrossRef]

29. Yuan, J.; Jiao, Z. Detección de alimentadores defectuosos para fallas monofásicas a tierra en redes de distribución basada en CNN de parche a parche y LSTM de alimentador a alimentador. Int. J. Electr. Power Energy Syst. 2023, 147, 108909. [CrossRef]

30. Pascale, A.; Guarnaccia, C.; Coelho, MC Análisis de las emisiones de ruido de un solo vehículo en el dominio de la frecuencia para dos motorizaciones diferentes. J. Environ. Manag. 2024, 370, 122905. [CrossRef]

31. Li, S.; Tang, X.; Lin, H.; Wang, F. Detección de suplantación de identidad GNSS basada en procesamiento en el dominio de la frecuencia. Measurement 2025, 242, 115872. [CrossRef]

32. Abbass, MJ; Lis, R.; Rebizant, W. Un modelo predictivo que utiliza la técnica de memoria a largo y corto plazo (LSTM) para la estabilidad de voltaje del sistema eléctrico. Appl. Sci. 2024, 14, 7279. [CrossRef]

33. Wang, Z.; Lu, T.; Han, Y.; Zhang, C.; Zeng, X.; Li, W. Mejora de la precisión en la predicción del consumo de combustible y la intensidad de carbono de los buques mediante un modelo de memoria a corto y largo plazo con mecanismo de autoatención. Appl. Sci. 2024, 14, 8526. [CrossRef]

34. Zhangming, X.; Daofei, Z.; Dafang, L.; Shujing, H.; Luo, Z. Detección de anomalías en datos de energía metalúrgica basada en iForest-AE. Ciencias Aplicadas 2022, 12, 9977. [CrossRef]

35. Park, D.; Hoshi, Y.; Kemp, CC Un detector de anomalías multimodal para la alimentación asistida por robot utilizando un modelo variacional basado en LSTM Codificador automático. Robot IEEE. Automático. Letón. 2018, 3, 1544-1551. [Referencia cruzada]

36. Hundman, K.; Constantinou, V.; Laporte, C.; Colwell, I.; Soderstrom, T. Detección de anomalías en naves espaciales mediante LSTM y umbralización dinámica no paramétrica. En Actas de Knowledge Discovery & Data Mining, 19-23 de agosto de 2018; págs. 387-395.

Aviso legal/Nota del editor: Las declaraciones, opiniones y datos contenidos en todas las publicaciones son responsabilidad exclusiva de sus autores y colaboradores, y no de MDPI ni de sus editores. MDPI y sus editores no se responsabilizan de los daños a personas o bienes que pudieran derivarse de las ideas, métodos, instrucciones o productos mencionados en el contenido.