Machine Translated by Google

IEEE Access
Multidisciplinary | Rapid Review | Open Access Journal

Recibido el 21 de julio de 2025, aceptado el 11 de septiembre de 2025, fecha de publicación el 22 de septiembre de 2025,
fecha de la versión actual el 26 de septiembre de 2025.

Identificador de objeto digital 10.1109/ACCESS.2025.3612407

RESEARCH ARTICLE

Un modelo de secuencia multitarea profunda auto-imputable para la detección de interrupciones de tráfico en condiciones extremas Condiciones

MINA NOURI Y MOHAMMAD ILBEIGI
Instituto Tecnológico Stevens, Hoboken, NJ 07030, EE. UU.

Autor de correspondencia: Mohammad Ilbeigi (milbeigi@stevens.edu)

Este trabajo fue financiado por la Fundación Nacional de Ciencias (National Science Foundation) bajo la subvención CMMI-2026795.

RESUMEN Los patrones de tráfico anómalos causados por eventos extremos pueden perturbar significativamente el flujo vehicular en amplias regiones de las redes viales urbanas. La detección oportuna y confiable de dichas perturbaciones es crucial para una gestión eficaz del tráfico. Sin embargo, los métodos de detección de anomalías existentes no pueden detectar simultáneamente perturbaciones a nivel de red y local, y suelen tener dificultades con datos de tráfico incompletos, un problema común durante eventos extremos. Para abordar estas limitaciones, proponemos un novedoso modelo de Secuencia Multitarea Profunda de Autoimputación (SI-DMSeq) para la monitorización del tráfico y la detección de perturbaciones a dos niveles. El modelo realiza simultáneamente dos tareas distintas: 1) reconstruir secuencias de datos de tráfico, lo que permite la detección de anomalías mediante un enfoque basado en autoencoders, y 2) realizar predicciones con un paso de anticipación, lo que sirve para imputar los datos faltantes para el siguiente paso temporal. Para respaldar un entrenamiento robusto a pesar de las lagunas de datos, incorporamos una estrategia de imputación iterativa durante la fase de entrenamiento. Durante la inferencia, la tarea de reconstrucción se utiliza para detectar perturbaciones del tráfico a nivel de red y local, mientras que la tarea de predicción proporciona una imputación confiable de los valores faltantes en condiciones de tráfico típicas. Evaluamos el modelo SI-DMSeq utilizando datos históricos de tráfico de la red vial de Manhattan en la ciudad de Nueva York, centrándonos en las interrupciones causadas por el huracán Sandy en 2012 y la tormenta de nieve navideña de 2010. Los resultados demuestran que el método propuesto identifica con precisión las interrupciones tanto a nivel de red como local e imputa de manera eficiente los datos de tráfico faltantes.

TÉRMINOS DE ÍNDICE: Detección de anomalías, imputación de datos, aprendizaje multitarea, redes de tráfico urbano.

I. INTRODUCCIÓN

Ante eventos extremos, la importancia del monitoreo del tráfico y la detección de interrupciones en las redes viales urbanas es fundamental. Estos eventos, ya sean naturales o provocados por el hombre, suelen causar interrupciones significativas en el flujo normal del tráfico, lo que puede generar una congestión generalizada en toda la red. La detección oportuna y confiable de dichas interrupciones permite una gestión informada del tráfico para mitigar los impactos adversos del evento en las condiciones del tráfico urbano. Por lo tanto, es esencial desarrollar una metodología que no solo evalúe las condiciones generales del tráfico a nivel de la red, sino que también identifique las regiones específicas que experimentan los efectos más severos. Este enfoque de doble nivel permite a las autoridades de transporte implementar intervenciones específicas.

El editor asociado que coordina la revisión de este manuscrito y Yanli Xu fue quien aprobó su publicación.

donde más se necesitan, garantizando al mismo tiempo que la red en su conjunto siga siendo funcional y resiliente.

A pesar de los avances en la monitorización del tráfico, los métodos actuales presentan varias limitaciones. Muchos enfoques se centran en detectar interrupciones en tramos específicos de carretera o intentan la detección en toda la red sin identificar las zonas más afectadas. Además, la falta de datos de tráfico incompletos sigue siendo un problema importante, ya que puede degradar el rendimiento de los modelos de detección.

Motivados por estas limitaciones, proponemos un enfoque novedoso e integral para detectar interrupciones del tráfico durante eventos extremos, tanto a nivel de red como local, manejando datos de tráfico incompletos. Nuestro método está diseñado para lograr tres objetivos clave:

1. Identificar interrupciones significativas del tráfico resultantes de eventos extremos a nivel de red.

© 2025 Los autores. Esta obra está bajo una licencia Creative Commons Atribución 4.0.
Para obtener más información, consulte https://creativecommons.org/licenses/by/4.0/

Machine Translated by Google

2. Identificar las regiones más afectadas por estos eventos a nivel de zona pequeña.
3. Imputación de datos de tráfico faltantes durante la monitorización proceso.

Más concretamente, presentamos un modelo de secuencia multitarea profunda con autoimputación (SI-DMSeq) diseñado para realizar dos tareas principales: reconstrucción y predicción. Este modelo analiza datos de tráfico secuenciales, reconstruye simultáneamente la secuencia de entrada y pronostica los datos de tráfico para el siguiente paso temporal. En nuestro marco, estos componentes se denominan «Autoencoder» y «Predictor futuro», respectivamente. El modelo se entrena utilizando datos de tráfico normales e incorpora una estrategia de imputación iterativa para gestionar los valores faltantes en el conjunto de datos de entrenamiento.

El autoencoder entrenado captura los patrones de tráfico normales, pero presenta altos errores de reconstrucción en condiciones de tráfico anómalas. Durante la inferencia, aprovechamos esta propiedad para detectar interrupciones a gran escala mediante un gráfico de control estadístico que identifica valores anómalos de pérdida de reconstrucción.

Además, proponemos un método de puntuación innovador para identificar las regiones más afectadas dentro de la red. El componente Future Predictor garantiza la continuidad del monitoreo mediante la imputación de los valores faltantes para los pasos de tiempo subsiguientes.

La principal innovación de nuestro enfoque reside en su capacidad de detección de interrupciones de doble nivel y en la perfecta integración de la imputación y la detección de anomalías dentro de un único marco multitarea. A diferencia de los métodos existentes, que se limitan a una sola tarea o nivel de detección, nuestro modelo realiza ambas tareas simultáneamente y permite la detección de doble nivel. La integración de un gráfico de control estadístico para la detección de anomalías basada en la reconstrucción, un mecanismo de puntuación para localizar interrupciones graves y la imputación basada en la predicción para el manejo de valores faltantes permite que el sistema de monitoreo opere eficazmente incluso en presencia de datos incompletos. Este diseño integral aborda las principales limitaciones de trabajos anteriores y facilita un monitoreo robusto de doble nivel de las condiciones del tráfico urbano durante eventos extremos.

El resto de este artículo se estructura de la siguiente manera: la Sección II ofrece una revisión exhaustiva de trabajos relacionados con la detección de interrupciones del tráfico urbano. La Sección III presenta nuestra metodología en detalle. En la Sección IV, validamos nuestro método propuesto mediante estudios de caso reales y demostramos su eficacia. Finalmente, la Sección V resume nuestros hallazgos y analiza posibles líneas de investigación futuras.

II. TRABAJOS RELACIONADOS

La detección de interrupciones del tráfico ha sido objeto de numerosos estudios. Estos estudios se pueden clasificar en tres grupos principales: El primer grupo se centra en la detección de interrupciones en un segmento vial específico o en un número reducido de carreteras. Un subconjunto de estudios de este grupo (p. ej., [1], [2], [3], [4]) emplea técnicas de predicción del tráfico, donde se utilizan datos históricos para pronosticar las condiciones del tráfico a corto plazo. Las desviaciones significativas de los valores previstos se identifican entonces como interrupciones. Por ejemplo, Harrou et al. [3] introdujeron una metodología de estimación del tráfico. que combina las fortalezas de un modelo de tráfico lineal conmutado por partes (PWSL) y un modelo de filtro de Kalman (KF). Además, propusieron una técnica basada en K vecinos más cercanos (KNN) para identificar y señalar desviaciones significativas entre la salida del estimador PWSL-KF y las observaciones reales como condiciones de tráfico anormales. En otro estudio, Evans et al. [4] propusieron un modelo de bosque aleatorio basado en contexto para predecir el flujo de tráfico y generar alertas cuando los valores observados caen persistentemente fuera de los intervalos de predicción. Si bien son efectivos para interrupciones locales, estos métodos presentan desafíos cuando se aplican a redes a gran escala. En tales redes, la gran cantidad de segmentos de carretera conduce a una cantidad significativa de falsas alarmas.

Otro subconjunto de estudios del primer grupo emplea modelos de clasificación para distinguir entre estados de tráfico normales y anormales. Los algoritmos de aprendizaje automático, como Random Forest (p. ej., [5], [6]), Support Vector Machines (p. ej., [7], [8], [9]) y Neural Networks (p. ej., [10], [11], [12], [13]), se utilizan comúnmente para este propósito. Sin embargo, el rendimiento de estos modelos disminuye significativamente con datos de entrenamiento desequilibrados [14]. Este desafío se vuelve particularmente crucial en el contexto de eventos extremos, donde la disponibilidad limitada de muestras de eventos impide el entrenamiento de un modelo efectivo.

El segundo grupo de estudios tiene como objetivo ampliar los métodos de detección de interrupciones del tráfico a regiones más grandes al incluir un mayor número de segmentos de carretera (por ejemplo, [15], [16], [17], [18]). Estos estudios suelen emplear enfoques basados en la descomposición para capturar las correlaciones espaciotemporales inherentes en el tráfico regular y utilizarlas para detectar interrupciones. Por ejemplo, Tisljaric et al. [16] utilizaron técnicas de descomposición tensorial para analizar patrones de tráfico transformando datos de tráfico basados en GPS en una Matriz de Transición de Velocidad (STM). Luego identificaron interrupciones evaluando la significancia de la divergencia de Kullback-Leibler entre los patrones de tráfico observados y promedio. Li et al. [17] propusieron un modelo acoplado de factorización tensorial robusta bayesiana escalable (SBRTF acoplada) para identificar patrones de tráfico anormales no recurrentes. Su modelo separa el tráfico regular de los eventos no recurrentes descomponiendo los datos de tráfico en un componente de bajo rango (que representa el tráfico regular) y un componente atípico disperso (que representa los eventos no recurrentes). Si bien los métodos presentados en estos estudios no sufren el problema de las falsas alarmas que enfrentaron los estudios del primer grupo, se limitan al análisis fuera de línea, ya que detectan anomalías retrospectivamente analizando todos los datos recopilados durante un período específico.

Por lo tanto, no son aplicables para la detección de interrupciones en tiempo casi real.

El tercer grupo de estudios aborda la detección de interrupciones a escala de red (p. ej., [19], [20], [21]). Estos estudios buscan identificar interrupciones a gran escala resultantes de eventos extremos. Por ejemplo, Donovan y Work [19] analizaron datos GPS de taxis para crear distribuciones de probabilidad de ritmos de viaje típicos entre varias regiones de la ciudad de Nueva York. Posteriormente, utilizaron estas distribuciones para detectar interrupciones importantes causadas por eventos extremos. Un estudio más reciente de Hu et al. [21] propuso un método basado en autoencoder para detectar eventos extremos en origen-destino.

Machine Translated by Google

Datos de movilidad representados como gráficos dependientes del tiempo. Su método emplea técnicas de incrustación para capturar patrones de tráfico típicos y utiliza un marco de autoencoder para identificar gráficos anómalos asociados con eventos extremos.
Si bien estos enfoques que abarcan toda la red son excelentes para identificar eventos a gran escala, no pueden determinar las regiones específicas que se ven más afectadas por dichos eventos.

Además de las limitaciones ya mencionadas en los métodos existentes para detectar simultáneamente interrupciones del tráfico a nivel de red y local, la falta de datos de tráfico completos supone un desafío crucial para el diseño de métodos de monitorización del tráfico. A pesar de los avances en los métodos de recopilación de datos de tráfico, los datos obtenidos de grandes redes viales suelen ser incompletos. Esta falta de información completa dificulta la monitorización eficaz del tráfico y la detección de interrupciones.
La imputación de datos faltantes sin considerar los patrones espaciotemporales subyacentes puede resultar en la inserción de puntos de datos erróneos e inexactos. Estas imprecisiones pueden degradar el rendimiento de un modelo de detección de interrupciones. Para abordar este problema, Hu y Work [22] introdujeron un método basado en el enfoque de descomposición tensorial robusta para identificar interrupciones de tráfico en datos parcialmente observados, imputando los datos faltantes en condiciones de tráfico típicas. Sin embargo, su método detecta las interrupciones de forma retroactiva y no es adecuado para el monitoreo en línea de redes viales. Esta limitación impide la aplicación del monitoreo de tráfico en tiempo real o casi real.

Además, en la literatura se han explorado modelos de asignación de tráfico como un medio para estimar las condiciones del tráfico de red y predecir puntos de datos faltantes. Estos modelos se basan en principios de asignación dinámica o de equilibrio para inferir el flujo de tráfico entre enlaces a partir de la demanda y las restricciones de la red (p. ej., [23], [24], [25], [26]). Si bien estos modelos pueden proporcionar estimaciones razonables de los patrones de tráfico típicos, a menudo se ven limitados por su dependencia de supuestos estáticos o semiestáticos y pueden no capturar interrupciones abruptas de manera efectiva. Además, su complejidad computacional los hace menos prácticos para aplicaciones en tiempo real o casi en tiempo real.

Este artículo pretende superar estos desafíos mediante la introducción de un marco de detección de interrupciones casi en tiempo real que detecta simultáneamente anomalías de tráfico tanto a nivel de red como localizadas, al tiempo que gestiona eficazmente los datos faltantes.

III. METODOLOGÍA

En esta sección, comenzamos con una explicación detallada del modelo SI-DMSeq. A continuación, presentamos nuestro método de imputación de datos. Posteriormente, introducimos la función de pérdida dinámica utilizada para entrenar el modelo SI-DMSeq.
Por último, profundizamos en la detección de interrupciones del tráfico tanto a nivel de red como de zona.

A. LA ARQUITECTURA DEL MODELO SI-DMSEQ

Nuestro modelo propuesto sigue una arquitectura codificador-decodificador. Está diseñado para el aprendizaje secuencia a secuencia multitarea [27] y emplea memoria a largo y corto plazo (LSTM).

redes [28] para el manejo de datos de tráfico secuenciales. Este modelo consta de una LSTM codificadora profunda y dos LSTM decodificadoras profundas independientes, ambas utilizando un codificador compartido. La LSTM codificadora se encarga de analizar los datos de tráfico secuenciales para capturar su información contextual y extraer una representación significativa de la secuencia de entrada. Posteriormente, el primer decodificador reconstruye la secuencia de entrada basándose en esta representación aprendida. Simultáneamente, el segundo decodificador pronostica los datos de tráfico para el siguiente paso temporal utilizando la información codificada obtenida del codificador compartido.

La combinación de tareas de reconstrucción y predicción ayuda a superar las limitaciones inherentes a los modelos individuales. Un autoencoder independiente puede aprender representaciones triviales que simplemente memorizan la secuencia de entrada. Además, un predictor futuro independiente podría mostrar un sesgo hacia los datos recientes y pasar por alto patrones más generales.
Sin embargo, el aprendizaje simultáneo de las tareas de reconstrucción y predicción sirve como mecanismo de regularización.
La tarea de reconstrucción requiere capturar características detalladas de la secuencia de entrada, mientras que la tarea de predicción exige la capacidad de generalizar y extrapolar a partir de estas características aprendidas. Al optimizar conjuntamente ambas tareas, se fomenta que el modelo combinado aprenda una representación más informativa y generalizada de la secuencia de entrada. Esta representación conserva información sobre toda la secuencia y captura características significativas que benefician tanto a la reconstrucción como a la predicción.

La figura 1 ilustra la arquitectura del modelo SI-DMSeq propuesto. En el resto de esta sección se ofrece una explicación detallada de cada componente.

1) CODIFICADOR COMPARTIDO

El codificador compartido consta de L capas LSTM apiladas. Cada capa opera sobre los datos de entrada secuencialmente para capturar su información contextual y generar una representación codificada de la secuencia de entrada. Específicamente, dada una secuencia de entrada $X = \{x1, x2, \cdots, xT\}$, donde T representa el es un longitud de secuencia y valores de ^{CON} vector de dimensión Z de tráfico $xt \in R$ en el paso de tiempo t, el codificador compartido procesa los vectores de entrada secuencialmente y los asigna a una serie de ocultos Vectores de estado L , denotados por hh donde $h_1, h_2, \cdots, h_T, \ldots, h_t \in R$ representa el estado oculto de la capa superior generado en el instante t, donde h denota el tamaño oculto. Estos vectores contienen la información codificada de los datos secuenciales y capturan las dependencias y los patrones dentro de la secuencia de entrada.

Los estados ocultos y de celda finales de las capas del codificador (es decir, $ll \in \{1, \cdots, L\}$) se utilizan como estados iniciales para los dos decodificadoresposteriores c T , T .

2) DECODIFICADOR DE RECONSTRUCCIÓN

El decodificador de reconstrucción tiene la tarea de recrear la secuencia de entrada utilizando la información codificada obtenida del codificador compartido. Este decodificador consta de L capas LSTM apiladas seguidas de una capa densa, que trabajan colectivamente para reconstruir la entrada original. También aprovecha un mecanismo de atención [29] para enfocar dinámicamente en

Machine Translated by Google

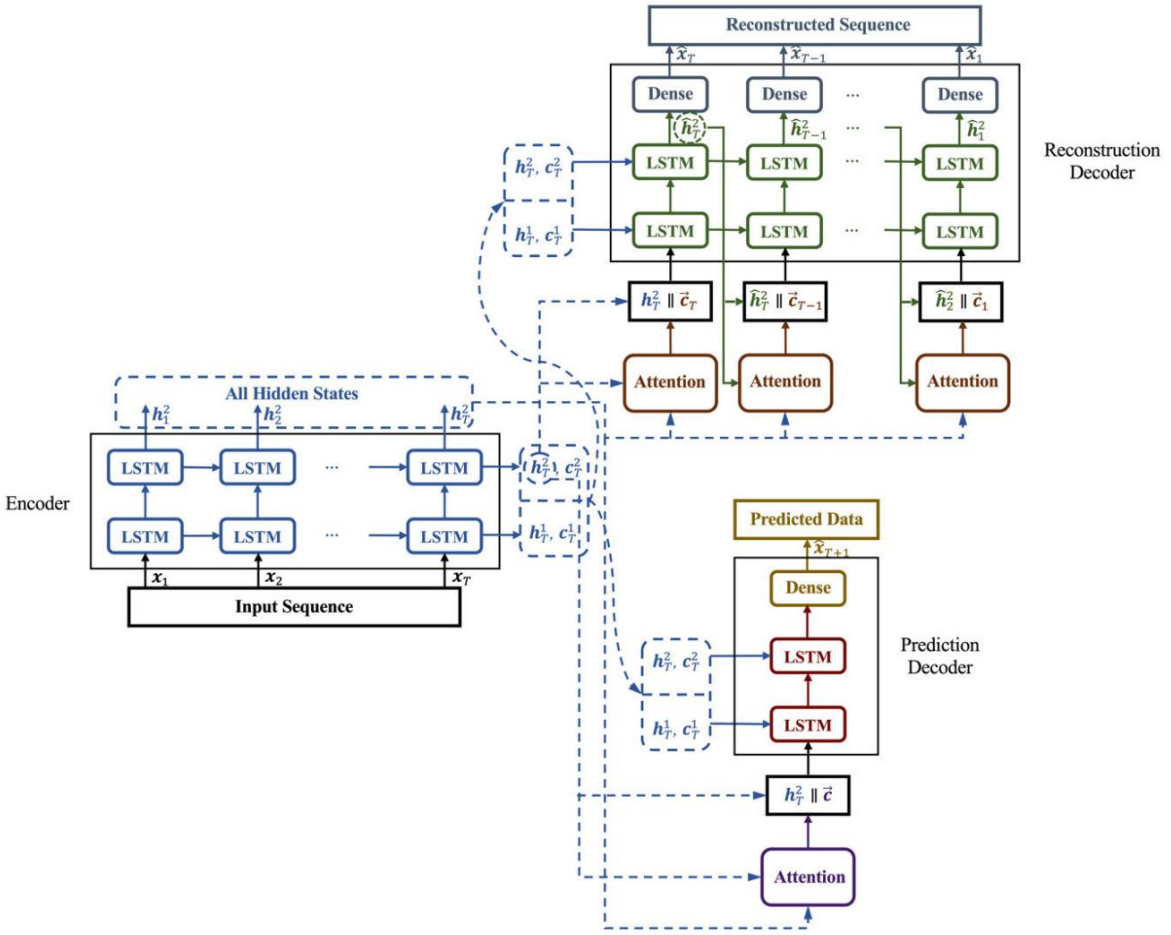


FIGURA 1. Arquitectura del modelo SI-DMSeq.

partes relevantes de la secuencia codificada durante el proceso de reconstrucción. Específicamente, en cada paso de decodificación d, el mecanismo de atención calcula un vector de contexto cd que representa las partes importantes de la secuencia de entrada para generar la salida actual. La Sección III-B describe los pasos involucrados en el cálculo del vector de contexto. Este vector de contexto se concatena con el estado oculto del decodificador anterior y se pasa a través de las capas del decodificador para producir la salida. El objetivo del decodificador de reconstrucción es generar una secuencia de salida de longitud T que idealmente coincida con la secuencia de entrada en orden inverso.

3) DECODIFICADOR DE PREDICCIÓN

El decodificador de predicción está diseñado para pronosticar datos de tráfico para el paso de tiempo subsiguiente utilizando la información codificada obtenida del codificador compartido. Similar al decodificador de reconstrucción, consta de L capas LSTM seguidas de una capa densa y emplea un mecanismo de atención para una predicción futura efectiva. Al codificar la secuencia de entrada, el mecanismo de atención calcula un vector de contexto c que resalta la información más relevante dentro de la secuencia de entrada para predecir datos de tráfico subsiguientes. Este vector de contexto se concatena luego con el último estado oculto de la codificador (es decir, h_T^L) antes de ser utilizado como entrada para la predicción decodificador. La salida de este decodificador es un vector que contiene valores de tráfico previstos para el siguiente paso de tiempo en la secuencia (es decir, xT+1).

B. MECANISMO DE ATENCIÓN

El mecanismo de atención permite que el modelo se centre dinámicamente en diferentes partes de la secuencia de entrada durante el proceso de decodificación. Este mecanismo emplea una función de puntuación para calcular la alineación en cada paso de tiempo de la secuencia de entrada con respecto al paso de decodificación en curso. Estas puntuaciones resaltan las partes de la secuencia de entrada más relevantes para generar la salida actual.

En el modelo SI-DMSeq propuesto, adoptamos una función de puntuación ampliamente utilizada que emplea una red neuronal de alimentación directa con una sola capa oculta y una función de activación tanh.

En cada paso de decodificación d, las puntuaciones de alineación se calculan considerando los estados ocultos de la capa superior del codificador en todos los pasos de tiempo (es decir, $\{h_t^L\}_{t=1}^{T}$) junto con el estado oculto de la capa superior del decodificador del paso de decodificación anterior (es decir, $\hat{h}_{d-1}^L$):

$$\text{Lah}_{t,\ \hat{h}_{d-1}^L} = v_a^T \tanh W_a h_t ; \hat{h}_{d-1}^L \quad (1)$$

Machine Translated by Google

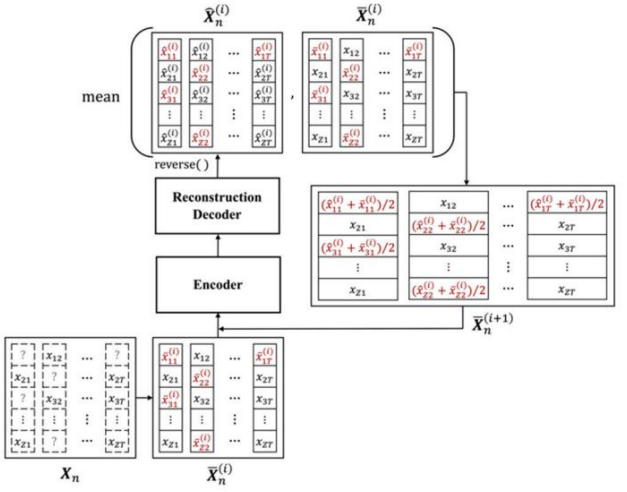


FIGURA 2. Proceso de imputación de datos durante el entrenamiento del modelo.

aquí, Wa R h×2h y va R h son parámetros aprendibles y h L t h^L d−1 representa la concatenación del codificador y estados ocultos del decodificador.

Tras calcular las puntuaciones, se utiliza una función Softmax para obtener los pesos de atención correspondientes. Esto garantiza que la suma de los pesos sea igual a uno y represente una distribución de probabilidad.

$$\alpha_{d,t} = \text{softmax}\left(a_h \, {}^{L}_{t,} \, \hat{h}^{L}_{d-1}\right) \tag{2}$$

Luego, el vector de contexto cd se calcula como la suma ponderada de los estados ocultos del codificador utilizando los pesos de atención.

$$cd = \sum_{t=1}^{T} \alpha_{d,t} h^{L}_{t,} \tag{3}$$

donde T es la longitud de la secuencia de entrada. Este vector de contexto captura la información relevante de los estados ocultos del codificador para el paso de decodificación actual.

Finalmente, el vector de contexto cd se concatena con el estado oculto del decodificador anterior h^L antes de ser utilizado como entrada. d−1 para la celda LSTM del decodificador actual.

C. IMPUTACIÓN DE DATOS FALTANTES

Nuestro modelo SI-DMSeq propuesto integra una estrategia iterativa de imputación de datos directamente dentro del proceso de entrenamiento. En lugar de tratar la imputación como un paso separado, nuestro modelo maneja simultáneamente los valores faltantes mientras aprende los patrones de tráfico subyacentes. Específicamente, adoptamos el método introducido por Pan et al. [30], que aprovecha el componente Autoencoder del modelo para imputar iterativamente los datos faltantes. Inicialmente, los valores faltantes se imputan con el promedio de los valores observados de los pasos de tiempo correspondientes. A medida que avanza el entrenamiento, estos valores imputados se refinan progresivamente con la media de los datos de entrada y los datos reconstruidos de cada paso de propagación hacia adelante. Este proceso de imputación iterativa permite que el modelo infiera la información faltante basándose en la distribución subyacente de los datos observados. Al completar la fase de entrenamiento, se obtienen tanto los valores imputados como los parámetros del modelo aprendidos.

Las ecuaciones matemáticas para este enfoque son las siguientes:

$$\bar{X}_{_}(1) = M_{x,n} \circ X_n + M_{x,n} \circ \text{media1}(X_n)$$

$$\hat{X}(i)\, n\,, \hat{y}^{(i)} = \text{modelo}\, \bar{X}(i)_{h,} \qquad i = 1, 2, \cdots$$

$$\bar{X}_{_}(i+1) = M_{x,n} \circ \bar{X}(i)_{_} + M_{x,n} \circ \hat{X}(i)_{_} + \bar{X}_{_}(i) \tag{4}$$

donde la matriz Xn R denota la n-ésima muestra de secuencia en el conjunto de datos de entrenamiento, con Z y T representando el número de valores de tráfico y el número de pasos de tiempo, indica el respectivamente. La matriz binaria Mx,n R posiciones de valores faltantes dentro de Xn. El símbolo ◦ denota la multiplicación elemento a elemento, y el operador realiza una negación bit a bit, cambiando cada 0 a 1 y cada 1 a 0. La función mean1 (·) calcula el promedio de todos los valores no faltantes a lo largo de la primera dimensión de la muestra incompleta Xn, y model(·) denota el paso de propagación hacia adelante dentro del proceso iterativo. En la época i, X^ (i) (i) envía la secuencia de entrada reconstruida, y y^ el vector de tráfico predicho para el paso de tiempo subsiguiente. X¯ (i+1) es la muestra de secuencia imputada, donde n repre- los valores faltantes se sustituyen con la media de la secuencia de denota el entrada y su reconstrucción obtenida de la propagación hacia adelante. Esta secuencia imputada sirve como entrada para el modelo en la época (i + 1). La Fig. 2 muestra el proceso de imputación de datos durante el entrenamiento.

Para garantizar la continuidad del análisis durante la fase de inferencia, el modelo emplea su componente de predicción (es decir, el Predictor Futuro) para completar los valores faltantes para el siguiente paso de tiempo.

D. FUNCIÓN DE PÉRDIDA DINÁMICA Y ENTRENAMIENTO DEL MODELO

Nuestro modelo propuesto utiliza una función de pérdida dinámica para imputar eficazmente los datos faltantes, priorizando la reconstrucción y la precisión de la predicción. Esta función adapta dinámicamente su enfoque a lo largo del proceso de entrenamiento. En las primeras épocas, se centra en reconstruir y predecir los valores no faltantes. Esto garantiza que el modelo capture los patrones subyacentes en los datos observados. A medida que avanza el entrenamiento, la función de pérdida cambia gradualmente su enfoque hacia la imputación de valores faltantes y, finalmente, logra un equilibrio entre la reconstrucción y predicción de valores no faltantes y la imputación de los faltantes. Este enfoque adaptativo permite al modelo inferir eficazmente la información faltante basándose en el contexto observado dentro de los datos de entrenamiento, mejorando así su rendimiento en las tareas de reconstrucción y predicción de secuencias. La función de pérdida dinámica se define de la siguiente manera:

$$L = \sum_{n=1}^{\text{norte}} {}_{un}{}^{(i)} \left\| M_{x,n} + \beta(i) M_{x,n} \circ \hat{X}(i)_{_} - \bar{X}_{_}(i) \right\|_F^2 + a^{(i)} \left\| m_{i,n} \circ \hat{y} - y_n \right\|_{_}^{(i)2},$$

$$_{un}{}^{(i)} = 2 - \frac{i}{\text{épocas}2}\,; \quad \beta^{(i)}_{_} = \frac{i}{\text{épocas}2} \tag{5}$$

Machine Translated by Google

Algoritmo 1

Entrada: datos de secuencia faltantes X R N×T×Z y su correspondiente tensor de máscara binaria Mx N×T×Z , datos objetivo faltantes Y R N×Z R y su correspondiente matriz de máscara binaria My R N×Z , máximo número de épocas, tamaño del lote B

X¯ (1) = Mx ◦ X+Mx ◦ media1 (X);

N = len (X); para

i = 1 hasta épocas hacer (i)

a = 2 − i épocas2 ; = i

épocas2 β (i)

obtener una lista aleatoriamente mezclada de enteros

P = pj j=1 norte k = 0 únicos que van de 1 a N;

repetir

min((k+1) B,N) extraer B enteros de P, denotados como inds = pj j=1+k B obtener un lote de muestras del conjunto de datos usando los enteros extraídos inds, denotados como X¯ (i)

b ,Mxb, Yb,Myb ;

Xˆ (i) Yˆ (i) = modelo X¯ (i) b ;

b ;

pérdida = α (i) Mx,b + β (i)Mx,b ◦ Xˆ (i) b − X¯ (i) b 2 F + a (i) My,b ◦ Yˆ (i) b −Yb 2 F ;

retropropaga la pérdida y actualiza los parámetros del modelo;

X¯ b (i+1) = Mx,b ◦ X¯ (i) b + Mx,b ◦ Xˆ (i) b + X¯ (i) b 2 hasta que se haya iterado todo el conjunto de datos hasta el final

donde X¯ (i) denota la n-ésima secuencia de entrada en la i-ésima y Xˆ (i) época, es su reconstrucción generada por el modelo. La matriz binaria Mx,n representa las ubicaciones de los valores faltantes dentro de la secuencia original Xn, y el vector binario my,n indica las posiciones de los valores faltantes en el n-ésimo objetivo, denotado como yn. Los valores objetivo predichos están representados por yˆn, y N es el número de muestras de entrenamiento. Además, (i) y β (i) a denotan los coeficientes adaptativos asociados con el error de reconstrucción/predicción de valores no faltantes y el error de imputación de valores faltantes, respectivamente. Estos coeficientes se ajustan dinámicamente con el número de época i, donde épocas se refieren al número máximo de épocas permitidas. (i) transita gradualmente de 2 a cambia de 0 a 1. 1, mientras que A medida que i aumenta, α β (i) · denota la norma de Frobenius al cuadrado que es la suma de los cuadrados de todos los elementos en la F matriz y · 2 representa la norma euclidiana al cuadrado que es la suma de los cuadrados de todos los elementos individuales del vector.

Durante todo el proceso de entrenamiento, la actualización de los parámetros del modelo y la imputación de los valores faltantes ocurren simultáneamente. El procedimiento de entrenamiento del modelo propuesto es el siguiente:

Inicialmente, los valores faltantes se reemplazan con la media de los valores no faltantes de sus respectivos pasos de tiempo. En cada época de entrenamiento, el conjunto de datos de entrenamiento se divide en lotes aleatorios de un tamaño B elegido. Luego, se realiza la propagación hacia adelante para cada lote, donde el lote de datos se introduce en el modelo para generar tanto secuencias reconstruidas como predicciones futuras. Después de cada paso de propagación hacia adelante, la media del lote de entrada y su reconstrucción se calcula utilizando (4). Además, la ecuación (5) se utiliza para calcular la pérdida para el lote actual. Posteriormente, los parámetros del modelo

Los datos se actualizan mediante retropropagación utilizando un algoritmo de optimización seleccionado. Posteriormente, los valores faltantes en el lote de entrada se imputan con la media de los datos de entrada y su reconstrucción obtenida mediante la propagación hacia adelante. Estos pasos se repiten para cada lote del conjunto de datos de entrenamiento durante cada época. El proceso completo se repite durante un número determinado de épocas o hasta que se cumpla un criterio de parada predefinido. El algoritmo 1 proporciona la representación en pseudocódigo del proceso de entrenamiento.

E. ANÁLISIS DE LA COMPLEJIDAD DEL TIEMPO DE INFERENCIA

La complejidad computacional del modelo SI-DMSeq propuesto en cada paso de inferencia se puede analizar considerando sus tres componentes principales:

1) CODIFICADOR

El codificador consta de L capas LSTM apiladas que procesan una secuencia de entrada de longitud T, donde cada elemento es un vector de tráfico de tamaño Z (el número de zonas). Para cada capa y paso de tiempo, las operaciones LSTM implican multiplicaciones de matrices con el tamaño oculto h, lo que resulta en una complejidad temporal de O LTh2 + ThZ para todo el codificador.

2) DECODIFICADOR DE RECONSTRUCCIÓN

El decodificador de reconstrucción también se compone de L capas LSTM apiladas y reconstruye la secuencia de entrada de longitud T, donde cada paso de decodificación, involucra un mecanismo de atención que agrega un término cuadrático con respecto a la longitud de la secuencia y el tamaño oculto. La complejidad temporal total para este componente es O LTh2 + ThZ + T 2h 2 ·

3) DECODIFICADOR DE PREDICCIÓN

El decodificador de predicción, de manera similar, consta de L capas LSTM y predice el estado del tráfico para el siguiente paso de tiempo. También utiliza un mecanismo de atención, pero como genera solo un vector, su costo computacional es menor. La complejidad de este componente es O Lh2 + hZ + Th2 .

Considerando todos los componentes y simplificando a términos dominantes, la complejidad temporal total de inferencia del modelo SI-DMSeq es O LTh2 + ThZ + T 2h 2 Esta complejidad aumenta linealmente con el número de capas y zonas, y cuadráticamente con la longitud de la secuencia y el tamaño oculto. Cabe destacar que el costo computacional del modelo depende únicamente de parámetros fijos durante la implementación y es independiente del tamaño total del conjunto de datos Dado que la complejidad crece linealmente con el número de zonas (un indicador clave del tamaño de la red), el modelo es inherentemente escalable a grandes redes urbanas. Esta escalabilidad permite que SI-DMSeq mantenga una baja latencia y un rendimiento robusto en entornos urbanos a gran escala, y admite aplicaciones casi en tiempo real en sistemas de tráfico urbanos.

F. DETECCIÓN DE INTERRUPCIONES DE TRÁFICO

1) DETECCIÓN DE INTERRUPCIONES A NIVEL DE RED

Cuando el modelo SI-DMSeq se entrena con datos de tráfico normales, puede capturar eficazmente patrones de tráfico regulares, pero no puede

Machine Translated by Google

para dar cuenta de patrones inusuales causados por un evento anómalo. Durante la fase de inferencia, el modelo entrenado puede reconstruir de forma fiable los estados de tráfico en condiciones normales. Sin embargo, cuando un evento extremo interrumpe la red, los patrones de tráfico cambian significativamente. En consecuencia, el modelo presenta altos errores de reconstrucción al enfrentarse a estos estados de tráfico anómalos. Aprovechando esta limitación, podemos detectar interrupciones en toda la red monitorizando la pérdida de reconstrucción del modelo propuesto durante todo el periodo de inferencia.

Nuestro sistema de monitorización se basa en gráficos de Control Estadístico de Procesos (CEP) [31], herramientas potentes para detectar desviaciones estadísticamente significativas en un proceso. Estos gráficos representan una estadística específica a lo largo del tiempo y utilizan límites de control superior e inferior (LCS e ICI) para identificar variaciones anormales. Estos límites se determinan a partir de datos históricos y representan el rango de variación esperado en las estadísticas de monitorización. Cuando la estadística supera estos límites, indica la ocurrencia de un evento disruptivo.

Para detectar interrupciones en toda la red, definimos nuestra estadística de monitorización como el error cuadrático medio (ECM) de reconstrucción en todos los valores observados en la secuencia de entrada. Específicamente, en cada paso de tiempo t, la estadística de monitoreo μt se calcula de la siguiente manera:

$$\mu t = \frac{\text{Monte} \circ \hat{X}_t - Xt \overset{2}{}_F}{\text{suma}(\quad Mt)}, \tag{6}$$

donde la matriz $Xt \in R^{Z \times T}$ denota la secuencia de entrada en el tiempo t, que abarca desde el paso de tiempo (t − T + 1) hasta el paso de tiempo t, con T representando la longitud de la secuencia y Z denotando el número de zonas de tráfico en la red. Cada elemento de esta matriz corresponde al valor de tráfico de una zona específica en un punto determinado del tiempo. $\hat{X}$ denota la secuencia reconstruida obtenida del modelo, y la matriz binaria Mt indica las ubicaciones de los valores faltantes dentro de la secuencia de entrada. El operador invierte los valores de la matriz binaria, convirtiendo cada 0 en 1 y viceversa. La función suma (·) calcula la suma de todos los elementos en su matriz de entrada, y $\|\cdot\|_F^2$ denota la norma de Frobenius al cuadrado.

En nuestro estudio, el gráfico de control estadístico se crea en función de la distribución subyacente de nuestra estadística de monitorización. Específicamente, utilizamos datos históricos de un período de condiciones de tráfico normales para identificar empíricamente la distribución de Basándonos μt . en esta distribución empírica, establecemos los límites de control del gráfico utilizando un nivel de significancia preseleccionado.
Cualquier desviación significativa de los patrones de tráfico habituales se manifestará como una caída del estadístico μt fuera de los límites de control, lo que indica la ocurrencia de un evento a gran escala dentro de la red.

2) DETECCIÓN DE INTERRUPCIONES A NIVEL DE ZONA

Durante un evento extremo, ciertas zonas de la red pueden experimentar patrones de tráfico más anómalos. Diversos factores, como la ubicación geográfica, la densidad de población, la infraestructura local y la naturaleza del evento, contribuyen a distintos grados de interrupción en las diferentes zonas.

Para identificar las zonas más afectadas de la red, calculamos puntuaciones de anomalías para cada zona durante el período de inferencia.
Estas puntuaciones se obtienen imponiendo una penalización que induce escasez en la pérdida de reconstrucción del modelo para cada zona individual. Suponiendo que el error cuadrático medio (ECM) de reconstrucción para la zona z en el tiempo t se denota por ezt , calculamos su puntuación de anomalía, denotada como szt , aplicando un operador de umbralización suave [32] al valor de ezt :

$$szt = \text{sgn}(ezt) \cdot \max(|ezt| - \lambda, 0), \tag{7}$$

donde sgn (·) representa la función signo y λ denota el parámetro umbral. λ se ajusta para asegurar que durante los períodos sin eventos, las puntuaciones de anomalía para la mayoría de las zonas sean cero.
Una puntuación más alta indica patrones de tráfico más anómalos en una zona específica en un momento dado. Este sistema de puntuación nos permite identificar qué zonas se ven más afectadas por el evento extremo y priorizar nuestras medidas de mitigación en consecuencia.

IV. APLICACIÓN EN EL MUNDO REAL Y EVALUACIÓN DEL RENDIMIENTO

En esta sección, presentamos estudios de caso reales donde aplicamos nuestro método propuesto de detección de interrupciones a la red vial de Manhattan, Nueva York, utilizando un conjunto de datos de tráfico disponible públicamente [33]. Específicamente, evaluamos su rendimiento en la identificación de interrupciones causadas por el huracán Sandy en 2012 y una tormenta de nieve navideña en 2010.

Estos eventos, junto con otros eventos disruptivos, tanto relacionados con el clima como no relacionados con él, como celebraciones públicas, han sido identificados previamente en el conjunto de datos de la ciudad de Nueva York por [19] y validados utilizando registros oficiales de eventos.
Para este estudio, se seleccionaron el huracán Sandy y la tormenta de nieve navideña como ejemplos representativos de emergencias a gran escala provocadas por fenómenos meteorológicos, que son particularmente relevantes para evaluar la capacidad de nuestro método para detectar interrupciones significativas en el flujo del tráfico urbano.

En este estudio, nos centramos en el área de Manhattan debido a su alta densidad de tráfico, su extensa red y la disponibilidad de datos de tráfico de alta calidad que incluyen eventos extremos bien documentados. Estas características la convierten en un entorno atractivo y exigente para evaluar métodos de detección de interrupciones. Si bien nuestra evaluación se limita geográficamente a Manhattan, el marco SI-DMSeq propuesto está diseñado para ser generalizable y aplicable a diversas áreas urbanas.

Para la implementación y evaluación, nos basamos exclusivamente en bibliotecas de análisis de datos y aprendizaje profundo de propósito general, como pandas y PyTorch, sin utilizar bibliotecas especializadas en análisis espacial. Sin embargo, cuando sea apropiado, los investigadores pueden aprovechar bibliotecas de análisis espacial de código abierto, como PySAL [34], para complementar el procesamiento de datos y mejorar el flujo de trabajo analítico. El código fuente desarrollado para este estudio está disponible públicamente en GitHub: https://github.com/minanouri/SI-DMSeq

A. DESCRIPCIÓN Y PREPARACIÓN DEL CONJUNTO DE DATOS

Para evaluar nuestro método propuesto, utilizamos un conjunto de datos de acceso abierto y disponible públicamente derivado de datos históricos.

Machine Translated by Google

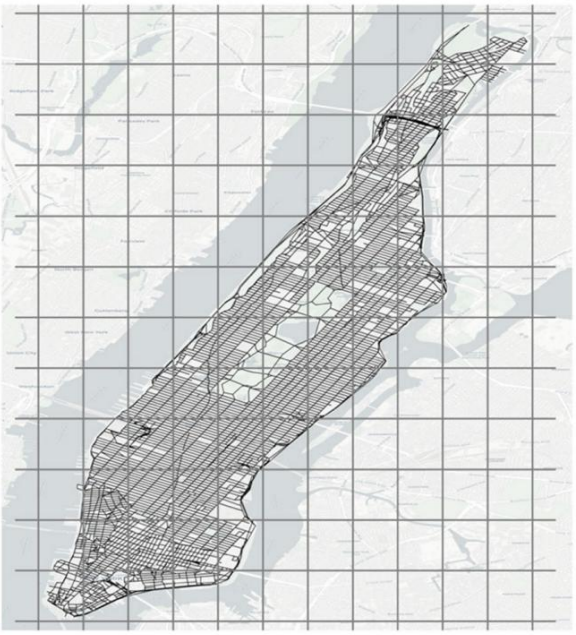


FIGURA 3. División de la red vial de Manhattan en zonas.

Trayectorias de casi 700 millones de viajes en taxi dentro de la ciudad de Nueva York [33]. Este conjunto de datos proporciona tiempos de viaje promedio por hora para segmentos viales individuales en toda la ciudad, desde enero de 2010 hasta diciembre de 2013. También incluye información detallada sobre las coordenadas y la longitud de cada segmento vial.

Para preparar el conjunto de datos para nuestro modelo, llevamos a cabo una serie de... de los pasos de preprocesamiento que se describen a continuación:

El huracán Sandy se originó el 22 de octubre de 2012 y tocó tierra cerca de Atlantic City, Nueva Jersey, a última hora de la noche del 29 de octubre de 2012. Por consiguiente, seleccionamos datos de tráfico registrados antes del lunes 15 de octubre de 2012, del distrito de Manhattan para construir y entrenar el modelo SI-DMSeq. Además, como el modelo propuesto requiere entrenamiento con datos de tráfico normales, filtramos los datos registrados durante períodos de grandes interrupciones en la red vial de Manhattan. Estas interrupciones, resultantes de eventos como ventiscas, tormentas y celebraciones de Año Nuevo, han sido identificadas previamente por [19]. Los datos de tráfico que abarcan desde el lunes 15 de octubre de 2012 (dos semanas antes del huracán) hasta el lunes 5 de noviembre de 2012 (una semana después del huracán) se utilizan para evaluar el rendimiento del modelo en la detección de interrupciones causadas por el huracán Sandy.

A continuación, agrupamos los segmentos de carretera adyacentes en zonas pequeñas. Estas zonas se definen mediante un sistema de cuadrícula con celdas de igual tamaño. Cada zona consta de segmentos de carretera cuyos puntos medios se encuentran dentro de los límites definidos por el sistema de cuadrícula. Como se muestra en la figura 3, la red vial de Manhattan está dividida en cuarenta y seis zonas.

Luego, obtenemos el ritmo promedio horario del tráfico dentro de cada zona. El ritmo promedio en un solo segmento de carretera se define como el tiempo promedio de viaje dividido por la longitud del segmento de carretera [35]. Calculamos el ritmo promedio de una zona como el promedio ponderado por longitud de los pasos de todos sus segmentos de carretera constituyentes. Específicamente, el paso promedio de la zona z en el tiempo t, denotado por xzt , se determina de la siguiente manera:

$$xzt = \frac{\sum_{r \in Sz} lr\, prt}{\sum_{r \in Sz} lr}, \tag{8}$$

donde Sz representa el conjunto de todos los segmentos de carretera dentro de la zona z, prt denota el ritmo promedio en el segmento de carretera r en el paso de tiempo t, y lr es la longitud del segmento de carretera r.

En cada intervalo de tiempo t, los valores de ritmo promedio se organizan en un formato vectorial, donde cada elemento corresponde al ritmo de tráfico promedio dentro de una zona específica de la red.
Esta secuencia temporal de vectores forma una serie temporal multivariada.

Para simular un entorno de implementación realista y garantizar que el rendimiento del modelo se valide con datos futuros no vistos, dividimos la serie temporal cronológicamente y reservamos el 20 % más reciente de los datos de tráfico seleccionados (es decir, datos anteriores al 15 de octubre de 2012) como conjunto de validación. Esta estrategia evita la fuga de información al preservar el orden temporal, lo cual es fundamental para el modelado de series temporales, y refleja un escenario del mundo real donde el modelo se entrena con datos pasados y se aplica a observaciones futuras. La elección del 20 % sigue la práctica estándar en aprendizaje automático, donde normalmente se reserva entre el 20 % y el 25 % de los datos disponibles para la validación. Esta proporción proporciona un tamaño de muestra suficiente para un ajuste robusto de hiperparámetros, a la vez que conserva suficientes datos para un entrenamiento efectivo del modelo. Además, eliminamos aleatoriamente el 25 % de las observaciones de los datos de entrenamiento para evaluar la efectividad de la estrategia de imputación propuesta.

Utilizamos un enfoque de ventana deslizante para generar pares de entrada-destino para el entrenamiento de nuestro modelo SI-DMSeq. Teniendo en cuenta los patrones diarios inherentes a los datos de tráfico, seleccionamos una ventana de tamaño fijo con una longitud T = 24. Esta ventana se desplaza a lo largo de los datos un paso de tiempo a la vez y crea una serie de secuencias superpuestas, cada una de las cuales abarca T pasos de tiempo. Estas secuencias sirven como entrada para el modelo. El objetivo para el decodificador de reconstrucción es la secuencia de entrada original en orden inverso, mientras que para el decodificador de predicción, el objetivo es el vector de tráfico para el paso de tiempo siguiente. A lo largo del proceso de entrenamiento, el modelo aprende a reconstruir la secuencia de entrada y a realizar predicciones con un paso de antelación aprovechando los patrones codificados en los datos de entrada.

B. CONFIGURACIÓN DEL MODELO

El modelo SI-DMSeq propuesto se configura con los siguientes ajustes específicos: El codificador compartido emplea dos capas LSTM para extraer características importantes de los datos de entrada. Tanto el decodificador de reconstrucción como el de predicción utilizan dos capas LSTM seguidas de una capa densa para sus respectivas tareas.
Cada celda LSTM del modelo y las capas densas constan de 64 neuronas. Para mejorar aún más la generalización, se aplica un mecanismo Dropout [36] con una probabilidad de 0,2 a las salidas de las capas LSTM inferiores dentro de cada componente.
El optimizador Adam [37], con una tasa de aprendizaje de 0,01, se emplea para minimizar la función de pérdida dinámica presentada.

Machine Translated by Google

TABLA 1. Análisis comparativo del rendimiento de la imputación.

Percentage of missing data (ρ)	RMSE			
	Temporal Mean	RTRC	PARATUCK2	SI-DMSeq
10%	0.0744 (2e-3)	0.0344 (1e-3)	0.0360 (1e-3)	**0.0318** (9e-4)
20%	0.0747 (1e-3)	0.0357 (1e-3)	0.0361 (1e-3)	**0.0324** (1e-3)
30%	0.0748 (7e-4)	0.0365 (6e-4)	0.0366 (7e-4)	**0.0325** (5e-4)
40%	0.0750 (7e-4)	0.0374 (8e-4)	0.0366 (7e-4)	**0.0332** (5e-4)
50%	0.0754 (7e-4)	0.0388 (8e-4)	0.0377 (9e-4)	**0.0337** (6e-4)

en (5) a través de los datos de entrenamiento. El entrenamiento se lleva a cabo en minilotes de tamaño 64, y el modelo se entrena durante 20 épocas.

C. EVALUACIÓN DEL DESEMPEÑO DE LA IMPUTACIÓN

Para evaluar el rendimiento de imputación en la fase de inferencia de nuestro modelo propuesto, realizamos un análisis comparativo con tres métodos de referencia. El primer método es el enfoque ingenuo de Media Temporal, donde los valores faltantes se imputan utilizando el promedio de los valores no faltantes del paso de tiempo correspondiente. El segundo método, el método de Recuperación y Completación Robusta de Tensores (RTRC) [22], [38], utiliza la técnica de Análisis de Componentes Principales Robusto de Orden Superior (PCA) para descubrir la estructura subyacente de bajo rango inherente a los patrones de tráfico típicos. Esta estructura se utiliza luego para regenerar los datos tensoriales originales y completar los valores faltantes. El tercer método es el método de imputación PARATUCK2 [39], que emplea un enfoque de descomposición para capturar información espacio-temporal de los datos de tráfico. Este método crea una representación agrupada de baja dimensión de los patrones de tráfico y completa los valores faltantes reconstruyendo los perfiles de tráfico de la red a partir de esta representación.

Nuestra evaluación se lleva a cabo en condiciones de tráfico típicas. Específicamente, utilizamos datos recopilados entre el 15 y el 29 de octubre de 2012, y enmascaramos aleatoriamente ρ = {10, 20, 30, 40, 50} por ciento de los datos disponibles como valores faltantes. Las observaciones parciales restantes se utilizan como entradas para los modelos. Para cuantificar el rendimiento de la imputación en la fase de inferencia, utilizamos la métrica del error cuadrático medio (RMSE), que se define de la siguiente manera:

$$\text{RMSE} = \sqrt{\frac{\sum_{} (\hat{x}_{zt} - x_{zt})^2}{||}}, \tag{9}$$

donde se refiere al conjunto de todos los valores enmascarados y || representa el número total de valores enmascarados. x_{zt} denota el valor de tráfico observado para la zona z en el tiempo t, y $\hat{x}_{zt}$ representa su valor estimado correspondiente proporcionado por el modelo.

La Tabla 1 presenta la media y la desviación estándar del RMSE en 10 ensayos de imputación en la fase de inferencia para diferentes porcentajes de datos faltantes (ρ), utilizando el modelo propuesto y tres enfoques de referencia. Los resultados demuestran Nuestro enfoque propuesto supera a los métodos de referencia en todos los niveles especificados de datos faltantes. Esto subraya la eficacia del componente de predicción de nuestro modelo (es decir, el Predictor Futuro) para imputar datos de tráfico faltantes en condiciones típicas.

D. DETECCIÓN DE INTERRUPCIONES A NIVEL DE RED

A lo largo del proceso de entrenamiento, el modelo SI-DMSeq aprende con destreza a capturar y recrear patrones de tráfico típicos. Sin embargo, no puede adaptarse a patrones inusuales derivados de eventos anómalos. Por consiguiente, si bien el autoencoder entrenado reconstruye eficazmente los datos de tráfico en condiciones normales, tiende a presentar altos errores de reconstrucción ante estados de tráfico anómalos durante eventos extremos. Aprovechando esta limitación, identificamos interrupciones de tráfico a nivel de red mediante el monitoreo continuo de la estadística μ (presentada en (6)) durante el período de inferencia.

Para lograr esto, desarrollamos un gráfico de control empírico basado en la distribución subyacente del estadístico μ. Específicamente, utilizamos datos que abarcan desde el 15 de octubre hasta el 22 de octubre de 2012 (denominado Fase 1 en la Fig. 4) para identificar empíricamente la distribución de μ. Este período se caracteriza por condiciones de tráfico normales, sin interrupciones a gran escala experimentadas por la red [19]. Usando la biblioteca de Python distfit [40], determinamos que la distribución de Weibull, con parámetros shape=0.809, location=0.0006 y scale=0.0001, se ajusta mejor a los valores observados de μ en la Fase 1 (como se ilustra en la Fig. 5). Con base en esta distribución, establecemos el límite de control superior (UCL) para μ en 0.0011 para lograr un nivel de significancia de 0.02. Los datos correspondientes al período comprendido entre el 22 de octubre y el 5 de noviembre de 2012 (denominados Fase 2 en la Figura 4) se utilizan posteriormente para supervisar las condiciones del tráfico de la red y detectar anomalías causadas por el huracán.

Es importante destacar que ajustar el nivel de significancia ofrece un enfoque flexible para detectar interrupciones. Los niveles de significancia más bajos priorizan la detección de interrupciones más graves, minimizando las falsas alarmas. Por el contrario, los niveles de significancia más altos aumentan la sensibilidad a desviaciones menores, pero incrementan la probabilidad de falsas alarmas.

La figura 4 muestra el proceso de monitoreo. Esta figura revela que la red encontró patrones de tráfico anómalos durante el período del 30 de octubre al 2 de noviembre de 2012, que corresponde al momento en que el huracán Sandy afectó la ciudad de Nueva York. Las interrupciones comenzaron alrededor de la medianoche del 30 de octubre, unas horas después.

Machine Translated by Google

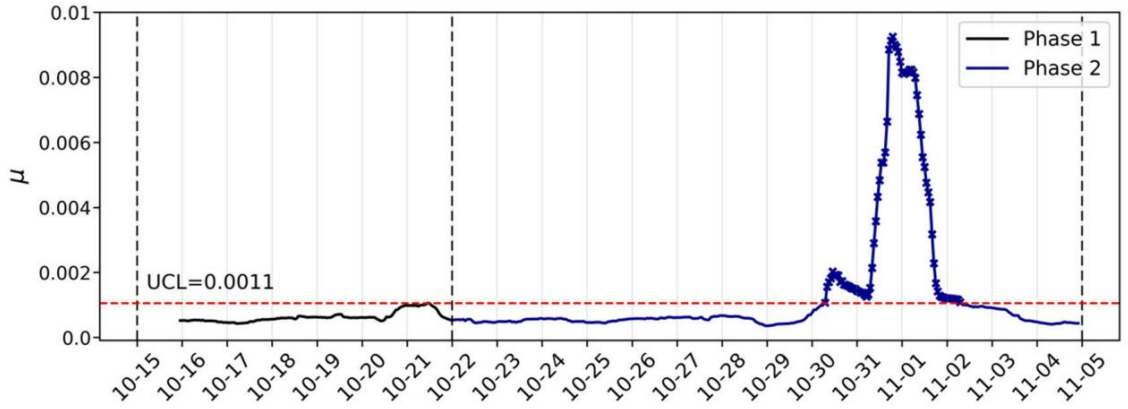


FIGURA 4. Estudio de caso del huracán Sandy: proceso de monitoreo del μstatístico. Se detectaron interrupciones del tráfico alrededor de la medianoche del 30 de octubre de 2012, que persistieron hasta la mañana del 2 de noviembre de 2012.

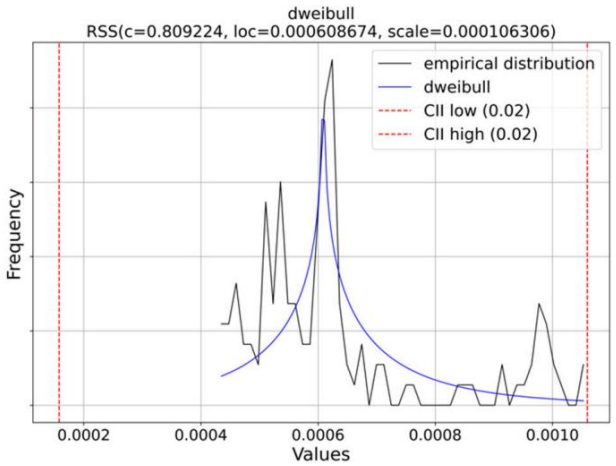


FIGURA 5. Estudio de caso del huracán Sandy: distribución que mejor se ajusta a los valores observados de μ durante la Fase 1.

El huracán tocó tierra cerca de Atlantic City, Nueva Jersey, y persistió hasta la mañana del 2 de noviembre de 2012. Estas observaciones coinciden con estudios anteriores que han examinado interrupciones en toda la red, como los realizados por [19] y [20].

E. IDENTIFICACIÓN DE LAS ZONAS MÁS AFECTADAS

Para evaluar el impacto del huracán Sandy en diferentes zonas, calculamos puntuaciones de anomalía para cada zona en cada paso de tiempo durante el período de inferencia. Como se detalla en la Sección III-F, estas puntuaciones se calculan aplicando un operador de umbralización suave a la pérdida de reconstrucción del modelo SI-DMSeq para cada zona específica. En este estudio, establecimos el parámetro de umbral λ en 0,0009. Este umbral resulta en que el 85 % de las puntuaciones de anomalía sean cero durante los períodos sin eventos.

La figura 6 muestra las puntuaciones de anomalías para las cuarenta y seis zonas desde el 22 de octubre hasta el 5 de noviembre de 2012. Estas puntuaciones cuantifican la magnitud de la desviación respecto a los patrones de tráfico previstos, donde los valores más altos indican mayores anomalías en zonas específicas en determinados momentos. El impacto del huracán en la red es evidente en esta figura.

Para demostrar la eficacia de nuestro método propuesto en la identificación de zonas con anomalías, empleamos un enfoque de validación visual. En este enfoque, examinamos visualmente las series temporales de ritmo de diversas zonas con diferentes puntuaciones de anomalía. Los resultados confirman que las zonas con puntuaciones de anomalía más altas presentan desviaciones más significativas en sus series temporales de ritmo, mientras que aquellas con puntuaciones más bajas muestran cambios mínimos en los valores de ritmo. Por ejemplo, en la figura 6, las zonas n.° 8 y n.° 25 obtienen puntuaciones de anomalía altas el 31 de octubre de 2012. Esto coincide con sus series temporales de ritmo en las figuras 7(a) y 7(b), respectivamente, que indican una congestión severa en estas zonas durante ese período. Por el contrario, las puntuaciones más bajas para las zonas n.° 13 y n.° 45 sugieren que estas zonas se vieron menos afectadas por el huracán. Sus series temporales de ritmo en las figuras 7(c) y 7(d) confirman que no experimentaron una interrupción significativa durante el evento.

F. ANÁLISIS ADICIONAL CON ESCENARIO DE TORMENTA DE NIEVE EN NUEVA YORK

Para evaluar aún más la robustez del método propuesto, analizamos su rendimiento durante un evento diferente, pero menos extremo: una fuerte tormenta de nieve que azotó la ciudad de Nueva York el 26 de diciembre de 2010 [40]. Utilizando el conjunto de datos de tráfico de la ciudad de Nueva York, el modelo entrenado se aplica a datos que abarcan desde el 12 de diciembre de 2010 (dos semanas antes del evento) hasta el 2 de enero de 2011 (una semana después del evento) en Manhattan.
área.

La figura 8 ilustra el seguimiento del estadístico μ durante el período de tiempo seleccionado. El límite de control superior en este gráfico se deriva de la distribución subyacente de los valores de μ durante la Fase 1 (del 12 al 19 de diciembre de 2010), que se calibra para mantener un nivel de significancia de 0,02.
El gráfico revela que la red experimentó patrones de tráfico anómalos durante la tormenta de nieve del 26 al 27 de diciembre de 2010. Además, destaca la continuación de estas anomalías durante el período de fin de año. Estas anomalías se atribuyen tanto al retraso en el proceso de remoción de nieve [41] como al impacto del evento de Año Nuevo, que en conjunto contribuyeron a cambios significativos en el tráfico.

Machine Translated by Google

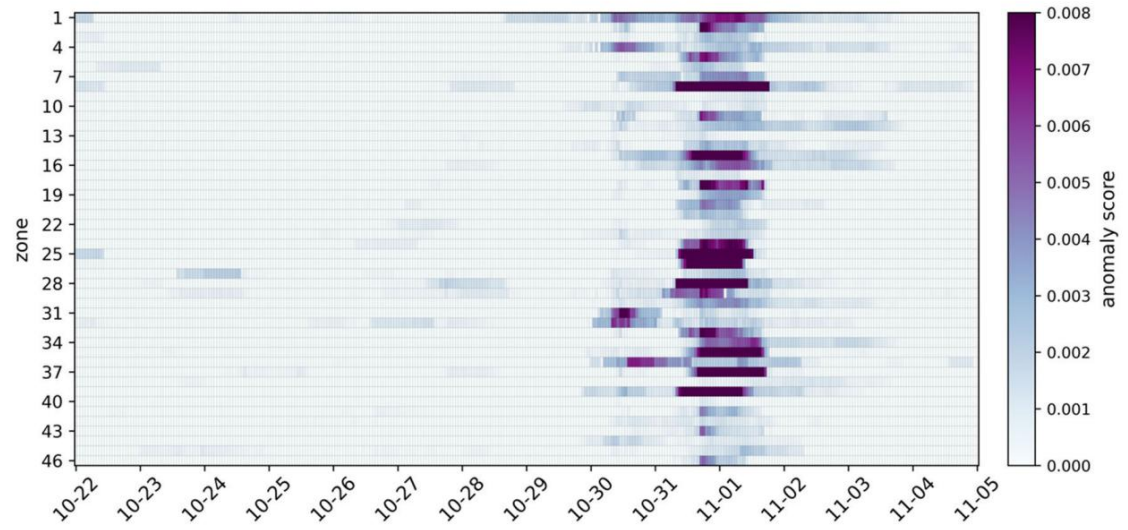


FIGURA 6. Estudio de caso del huracán Sandy: puntuaciones de anomalías para cada zona durante el período de inferencia (del 22 de octubre al 5 de noviembre de 2012).

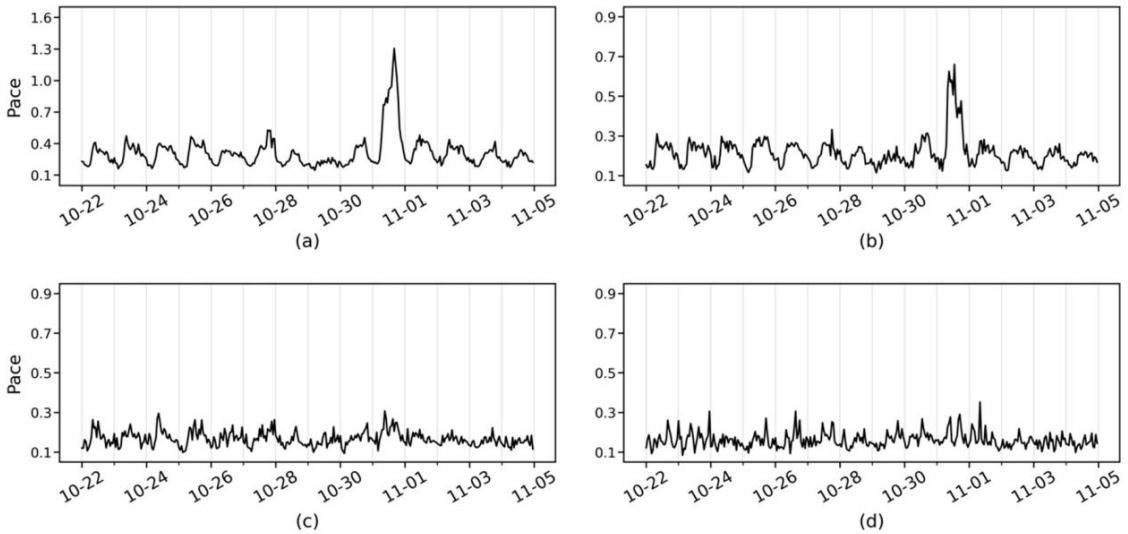


FIGURA 7. Estudio de caso del huracán Sandy: series temporales de zonas con puntuaciones de anomalía altas ((a) y (b)) y bajas ((c) y (d)). (a) Zona n.° 8. (b) Zona n.° 25. (c) Zona n.° 13. (d) Zona n.° 45.

comportamiento. También se han identificado patrones similares de interrupciones en toda la red durante este período en investigaciones anteriores ([19], [20]).

La Figura 9 ilustra cómo variaron las anomalías de tráfico en las cuarenta y seis zonas de la red desde el 19 de diciembre de 2010 hasta el 2 de enero de 2011, según las puntuaciones de anomalía. Estas puntuaciones representan el grado de desviación de las condiciones de tráfico esperadas, donde los valores más altos indican interrupciones más sustanciales. Por ejemplo, la figura revela que las zonas n.° 8 y n.° 16 experimentaron anomalías más intensas durante el período de fin de año en comparación con la tormenta de nieve navideña. Esta observación coincide con las interrupciones mostradas en sus gráficos de ritmo en las Figuras 10(a) y 10(b), particularmente entre el 28 y el 31 de diciembre. Por el contrario, la zona n.° 10 registró sus puntuaciones de anomalía más altas durante la tormenta de nieve del 27 de diciembre, lo que sugiere que se vio más afectada por ese evento, como se muestra en la Figura 10(c). Mientras tanto, la zona n.° 21 mostró puntuaciones de anomalía consistentemente bajas durante todo el período observado, lo que indica un impacto mínimo de los eventos, como lo respalda su gráfico de ritmo en la Figura 10(d).

G. EFICIENCIA DE LA INFERENCIA Y CONSIDERACIONES DE IMPLEMENTACIÓN

Aunque el conjunto de datos original de la ciudad de Nueva York es de gran tamaño, nuestro modelo propuesto está diseñado para procesar los datos de manera eficiente, centrándose en secuencias cortas y manejables en cada paso de tiempo. En concreto, el modelo solo procesa secuencias de longitud T, donde , cada elemento es un vector de tráfico que contiene Z valores, siendo Z el número de zonas de la red.

Este diseño garantiza que, en cualquier momento dado, el modelo esté manejando una cantidad fija y relativamente pequeña de datos, independientemente del tamaño total del conjunto de datos. El cálculo

Machine Translated by Google

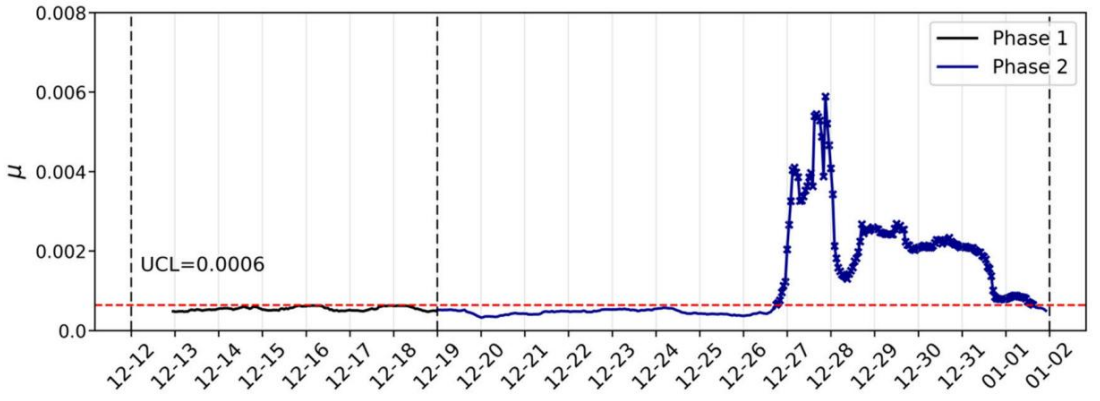


FIGURA 8. Estudio de caso de la tormenta de nieve navideña: seguimiento de la microestadística desde el 12 de diciembre de 2010 hasta el 2 de enero de 2011. Tráfico Se detectan anomalías durante el evento de ventisca y el período de fin de año.

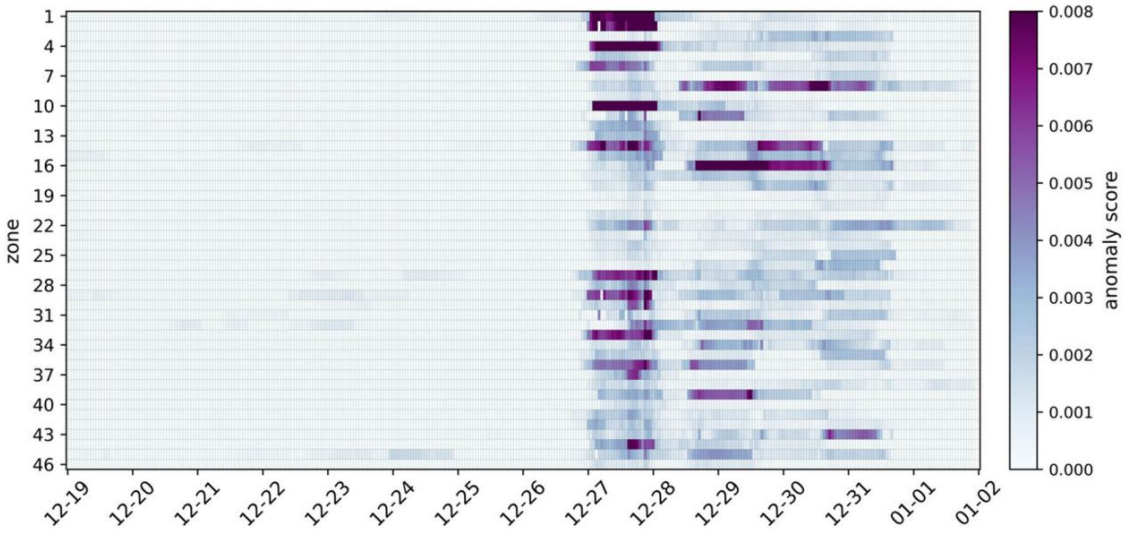


FIGURA 9. Estudio de caso de la tormenta de nieve navideña: puntuaciones de anomalías para cada zona de tráfico desde el 19 de diciembre de 2010 hasta el 2 de enero de 2011.

La complejidad de cada paso de inferencia aumenta linealmente con la número de zonas Z y cuadráticamente con la longitud de la secuencia Esto permite un análisis rápido y una detección oportuna del tráfico. interrupciones, lo que hace que el modelo sea adecuado para aplicaciones casi en tiempo real.

Además, nuestro proceso de preprocesamiento de datos es sencillo y computacionalmente eficiente. Los pasos principales incluyen: La agregación a nivel de zona y la generación de secuencias se implementan utilizando operaciones vectorizadas en el análisis de datos estándar. bibliotecas como Pandas. Estas operaciones están altamente optimizadas y admiten la ejecución en paralelo, lo que permite la rápida preparación de secuencias de entrada. Como resultado, tanto las fases de preprocesamiento como las de inferencia se simplifican para brindar soporte detección oportuna y confiable de interrupciones en entornos urbanos a gran escala entornos.

Para complementar el análisis de complejidad teórica, Evaluamos el tiempo de inferencia empírica del SI-DMSeq. modelo utilizando el conjunto de datos de NYC en una MacBook Pro con un Procesador Intel Core i7 de cuatro núcleos a 2,3 GHz y 32 GB de RAM. Para una longitud de secuencia de T = 24 y Z = 46 zonas, El tiempo promedio de inferencia por secuencia fue aproximadamente 55 milisegundos. Este resultado confirma la idoneidad del modelo. para una implementación casi en tiempo real en la monitorización del tráfico en el mundo real. aplicaciones.

Si bien el conjunto de datos utilizado en este estudio proporciona tiempos de viaje promedio por hora, nuestro método propuesto no está inherentemente limitado por esta resolución temporal. Puede integrarse sin problemas. con fuentes de datos de mayor frecuencia, como las que proporcionan tiempos de viaje en intervalos de 30 segundos, si están disponibles. Esta flexibilidad permite una posible implementación en tráfico casi en tiempo real. sistemas de monitoreo. Mediante el procesamiento continuo de flujos datos de tráfico, el modelo puede detectar dinámicamente interrupciones y Brindar apoyo oportuno para la toma de decisiones informadas.

H. LIMITACIONES Y TRABAJOS FUTUROS

La implementación actual de nuestro método propuesto emplea un enfoque basado en cuadrículas para definir zonas de tráfico, que tiene probado eficaz en Manhattan debido a la uniformidad de su red vial. Para ciudades con redes irregulares o no reticulares, el mismo marco podría generalizarse reemplazando la cuadrícula fija con zonas derivadas de la topología de la red o agrupamiento espacial. Futuros estudios podrían explorar el análisis basado en datos. metodologías para optimizar las formas y tamaños de las zonas basadas en sobre las características de la red local. Desarrollo de zonificación adaptativa

Machine Translated by Google

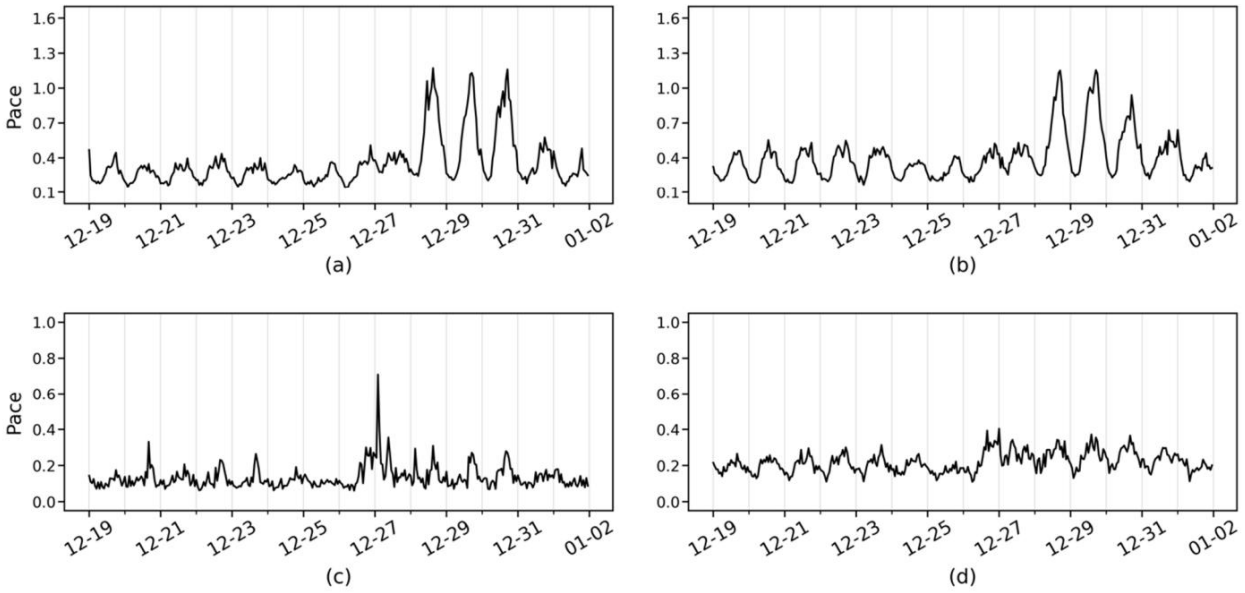


FIGURA 10. Estudio de caso de la tormenta de nieve navideña: series temporales de ritmo de zonas de ejemplo con puntuaciones de anomalía altas ((a), (b) y (c)) y bajas ((d)). (a) Zona n.° 8. (b) Zona n.° 16. (c) Zona n.° 10. (d) Zona n.° 21.

Las estrategias adaptadas a diversos entornos urbanos podrían mejorar aún más la aplicabilidad y el rendimiento del modelo.

Si bien nuestro modelo está diseñado para manejar diversos patrones de tráfico y escenarios de eventos, su evaluación actual se limita a Manhattan y eventos extremos relacionados con el clima. Para mejorar la generalización y la robustez del enfoque, la investigación futura debería explorar su aplicabilidad a ciudades con diferentes diseños espaciales, infraestructuras de tráfico y comportamientos de congestión. Dado el amplio rango de eventos de tráfico disruptivos que afectan a las ciudades a nivel mundial, también es importante ampliar los tipos de escenarios evaluados. La investigación futura debería incluir no-

Se analizarán eventos meteorológicos, como grandes concentraciones públicas y fallas en la infraestructura, para evaluar completamente la adaptabilidad del modelo en diversos contextos. Además, en el futuro se podría explorar la clasificación de eventos disruptivos según la gravedad y la extensión espacial de su impacto en el tráfico. Esto mejoraría la interpretabilidad de los resultados de detección y permitiría desarrollar estrategias de gestión y respuesta del tráfico más específicas.

Además, en trabajos futuros se podría investigar la integración de arquitecturas más avanzadas, como las redes neuronales gráficas (GNN) y los modelos basados en transformadores, en los componentes de autoencoder y predictor futuro del marco de trabajo. Estas arquitecturas tienen el potencial de mejorar la extracción de características espaciotemporales y el rendimiento de la imputación, especialmente en redes con topologías complejas.

V. CONCLUSIÓN

Reconociendo la importancia de reducir la congestión del tráfico durante eventos extremos, este estudio propone un innovador modelo de secuencia multitarea profunda de autoimputación (SI-DMSeq) para el monitoreo de tráfico de doble nivel y la detección de interrupciones, que está diseñado específicamente para trabajar con conjuntos de datos incompletos. El modelo se entrena para realizar dos tareas distintas: (1) reconstruir secuencias de datos de tráfico y (2) generar predicciones de un paso adelante. Adopta un enfoque iterativo

Estrategia de imputación durante el entrenamiento para gestionar los datos de tráfico faltantes. Durante la inferencia, la tarea de reconstrucción permite la detección de interrupciones tanto a nivel de red como local mediante un enfoque basado en autoencoders, mientras que la tarea de predicción proporciona una imputación fiable de los valores faltantes en condiciones de tráfico típicas.

Aplicamos el método propuesto a la red vial de Manhattan, Nueva York, para evaluar su desempeño en la detección de patrones de tráfico anormales durante el huracán Sandy en 2012 y la tormenta de nieve navideña de 2010. Los resultados

Demostrar la capacidad del método para detectar de forma precisa y simultánea las interrupciones del tráfico provocadas por eventos tanto a nivel de red como de zona, al tiempo que se imputan de forma eficiente los datos faltantes durante todo el proceso de monitorización.

Si bien el huracán Sandy fue bien pronosticado desde una perspectiva meteorológica, su impacto en la red de transporte, particularmente a nivel de tramos viales, fue un fenómeno espaciotemporal complejo y dinámico que no se pudo anticipar fácilmente. Además, la tormenta de nieve que azotó la ciudad de Nueva York el 26 de diciembre de 2010 provocó interrupciones de tráfico imprevistas influenciadas por diversos factores, como retrasos en la remoción de nieve y actividades relacionadas con las festividades.

Nuestro método propuesto ofrece un enfoque basado en datos para el monitoreo del tráfico y la detección de interrupciones en tiempo casi real. Mediante el análisis continuo de las condiciones del tráfico, nuestro método proporciona información valiosa que puede respaldar las labores de respuesta ante emergencias y mejorar la gestión del tráfico antes, durante y después de eventos de gran magnitud.

RECONOCIMIENTO

Las opiniones, hallazgos, conclusiones o recomendaciones expresadas en este material pertenecen a los autores y no reflejan necesariamente las opiniones de la Fundación Nacional de Ciencias.

Machine Translated by Google

REFERENCIAS

[1] JE Abanto, CC Reyes, JA Malinao y HN Adorna, "Detección y modelado de incidentes de tráfico utilizando algoritmos de frecuencia cuántica y modelos de media móvil integrada autorregresiva", en Proc. IISA, julio de 2013, págs. 1–6.

[2] H. Li, S.-L. Li, H. Zhu, X. Zhao y X. Zhang, "Algoritmo de detección automatizada de incidentes de tráfico en autopistas urbanas basado en series temporales de longitud", en Actas de la 8.ª Conferencia Internacional sobre Sistemas de Transporte Inteligentes Verdes y Seguridad, 2018, págs. 625–633.

[3] F. Harrou, A. Zeroual y Y. Sun, "Monitoreo de la congestión del tráfico utilizando una estrategia kNN mejorada", Measurement, vol. 156, mayo de 2020, art. no. 107534.

[4] J. Evans, B. Waterson y A. Hamilton, "Un algoritmo de detección de incidentes de bosque aleatorio que incorpora contextos", Int. J. Intell. Transp. Syst. Res., vol. 18, n.º 2, págs. 230–242, mayo de 2020.

[5] N. Dogru y A. Subasi, "Detección de accidentes de tráfico mediante un clasificador de bosque aleatorio", en Actas de la 15.ª Conferencia de Tecnología de Aprendizaje (L&T), febrero de 2018, págs. 40–45.

[6] Y. Sun, T. Mallick, P. Balaprakash y J. Macfarlane, "Un aprendizaje débil supervisado centrado en datos para la detección de incidentes de tráfico en autopistas", Accident Anal. Prevention, vol. 176, oct. 2022, art. n.º 106779.

[7] B. Yao, P. Hu, M. Zhang y M. Jin, "Una máquina de vectores de soporte con el algoritmo de búsqueda tabú para la detección de incidentes en autopistas", Int. J. Appl. Math. Ciencias de la Computación, vol. 24, n.º 2, págs. 397–404, junio de 2014.

[8] J. Xiao, "Aprendizaje de conjuntos SVM y KNN para la detección de incidentes de tráfico"," Phys. A, Stat. Mech. Appl., vol. 517, pp. 29–35, marzo de 2019.

[9] AB Parsa, H. Taghipour, S. Derrible y AK Mohammadian, "Detección de accidentes en tiempo real: Cómo lidiar con datos desequilibrados", Accident Anal. Prevention, vol. 129, págs. 202–210, agosto de 2019.

[10] D. Srinivasan, X. Jin y RL Cheu, "Modelos de redes neuronales adaptativas para la detección automática de incidentes en autopistas", Neurocomputing, vol. 64, pp. 473–496, marzo de 2005.

[11] L. Zhu, F. Guo, R. Krishnan y JW Polak, "Un enfoque de aprendizaje profundo para la detección de incidentes de tráfico en redes urbanas", en Actas de la 21.ª Conferencia Internacional. Intel. Transp. Sistema. (ITSC), noviembre de 2018, págs. 1011-1016.

[12] Q. Shang, L. Feng y S. Gao, "Un método híbrido para la detección de incidentes de tráfico utilizando bosque aleatorio-eliminación recursiva de características y red de memoria a corto y largo plazo con algoritmo de optimización bayesiana", IEEE Access, vol. 9, pp. 1219–1232, 2021.

[13] L. Li, Y. Lin, B. Du, F. Yang y B. Ran, "Detección de incidentes de tráfico en tiempo real basada en un modelo híbrido de aprendizaje profundo", Transportmetrica A, Transp. Sci., vol. 18, n.º 1, págs. 78–98, marzo de 2022.

[14] Y. Lin, L. Li, H. Jing, B. Ran y D. Sun, "Detección automatizada de incidentes de tráfico con un conjunto de datos más pequeño basado en redes generativas adversarias", Accident Anal. Prevention, vol. 144, septiembre de 2020, art. n.º 105628.

[15] S. Yang, K. Kalpakis y A. Biem, "Detección de eventos de tráfico rodado mediante el acoplamiento de múltiples series temporales con un método bayesiano no paramétrico", IEEE Trans. Intell. Transp. Syst., vol. 15, n.º 5, págs. 1936–1946, octubre de 2014.

[16] L. Tišljarić, S. Fernandes, T. Carić y J. Gama, "Detección de anomalías de tráfico espaciotemporales en redes viales urbanas mediante el método de descomposición tensorial", en Proc. Int. Conf. Discovery Sci., octubre de 2020, págs. 674–688.

[17] Q. Li, H. Tan, Z. Jiang, Y. Wu y L. Ye, "Detección de congestión de tráfico no recurrente con un modelo de factorización tensorial robusto bayesiano escalable acoplado", Neurocomputing, vol. 430, pp. 138–149, marzo de 2021.

[18] SE Sofuoglu y S. Aviyente, "GLOSS: Detección de anomalías basada en tensores en datos de tráfico urbano espaciotemporales", Signal Process., vol. 192, marzo de 2022, art. n.º 108370.

[19] B. Donovan y DB Work, "Cuantificación empírica de la resiliencia del sistema de transporte a escala urbana ante eventos extremos", Transp. Res. C, Emerg. Tecnología, vol. 79, págs. 333–346, junio de 2017.

[20] M. Ilbeigi, "Control estadístico de procesos para analizar la resiliencia de las redes de transporte", Int. J. Disaster Risk Reduction, vol. 33, pp. 155–161, febrero de 2019.

[21] Y. Hu, A. Qu y D. Work, "Detección de eventos de tráfico extremos mediante un autoencoder gráfico con contexto aumentado", ACM Trans. Intell. Syst. Technol., vol. 13, n.º 6, págs. 1–23, septiembre de 2022.

[22] Y. Hu y DB Work, "Recuperación robusta de tensores con valores atípicos de fibra para eventos de tráfico", ACM Trans. Knowl. Discovery Data, vol. 15, n.º 1, págs. 1–27, dic. 2020.

[23] E. Siri, S. Siri y S. Sacone, "Evaluación del rendimiento de la red bajo eventos disruptivos a través de un modelo de asignación de tráfico progresivo", IFAC-PapersOnLine, vol. 53, n.° 2, págs. 15017–15022, enero de 2020.

[24] T. Liu y H. Meidani, "Redes neuronales gráficas heterogéneas de extremo a extremo para la asignación de tráfico", Transp. Res. C, Emerg. Technol., vol. 165, agosto de 2024, art. n.º 104695.

[25] T. Liu y H. Meidani, "Redes neuronales de secuencia de grafos heterogéneas para la asignación dinámica de tráfico", 2024, arXiv:2408.04131.

[26] G. Fusco, C. Colombaroni, L. Comelli y N. Isaenko, "Predicciones de tráfico a corto plazo en grandes redes de tráfico urbano: Aplicaciones de modelos de aprendizaje automático basados en redes y modelos de asignación dinámica de tráfico", en Proc. Int. Conf. Models Technol. Intell. Transp. Syst. (MT-ITS), junio de 2015, pp. 93–101.

[27] M.-T. Luong, QV Le, I. Sutskever, O. Vinyals y L. Kaiser, "Aprendizaje secuencia a secuencia multitarea", 2015, arXiv:1511.06114.

[28] S. Hochreiter y J. Schmidhuber, "Memoria a corto y largo plazo", Neural Comput., vol. 9, n.º 8, págs. 1735–1780, noviembre de 1997.

[29] D. Bahdanau, K. Cho y Y. Bengio, "Traducción automática neuronal mediante el aprendizaje conjunto de alineación y traducción", 2014, arXiv:1409.0473.

[30] Z. Pan, Y. Wang, K. Wang, H. Chen, C. Yang y W. Gui, "Imputación de valores faltantes en series temporales utilizando un autoencoder profundo con relleno de mediana de aprendizaje adaptativo", IEEE Trans. Cybern., vol. 53, n.° 2, págs. 695–706, febrero de 2023.

[31] DC Montgomery, Introducción al control estadístico de calidad. Hoboken, Nueva Jersey, EE. UU.: Wiley, 2009.

[32] T. Hastie, R. Tibshirani y M. Wainwright, Aprendizaje estadístico con escasez: el Lasso y generalizaciones. Boca Raton, FL, EE. UU.: CRC Press, 2015.

[33] B. Donovan y DB Work. (Junio de 2015). Datos abiertos: Estimaciones de tráfico de la ciudad de Nueva York 2010-2013. Universidad de Illinois. [En línea]. Disponible en: https://uofi.app.box.com/v/NYC-traffic-estimates

[34] SJ Rey y L. Anselin, "PySAL: Una biblioteca de Python de métodos de análisis espacial", en Handbook of Applied Spatial Analysis: Software Tools, Methods and Applications. Berlín, Alemania: Springer, 2009, pp. 175–193.

[35] CF Daganzo, Fundamentos de operaciones de transporte y tráfico. Pérgamo, Oxford, 1997.

[36] N. Srivastava, GE Hinton, A. Krizhevsky, I. Sutskever y R. Salakhutdi-nov, "Dropout: Una forma sencilla de evitar el sobreajuste en las redes neuronales", J. Mach. Learn. Res., vol. 15, n.º 1, págs. 1929–1958, 2014.

[37] DP Kingma y J. Ba, "Adam: Un método para la optimización estocástica" 2014, arXiv:1412.6980.

[38] D. Goldfarb y Z. Qin, "Recuperación robusta de tensores de bajo rango: modelos y algoritmos", SIAM J. Matrix Anal. Appl., vol. 35, n.º 1, págs. 225–253, enero de 2014.

[39] M. Nouri, M. Reisi-Gahrooei y M. Ilbeigi, "Un método para la imputación de datos de tráfico granular basado en PARATUCK2", Transp. Res. Rec., J. Transp. Res. Board, vol. 2676, n.º 10, págs. 220–230, octubre de 2022.

[40] E. Taskesen. (Oct. 2020). Distfit es una biblioteca de Python para el ajuste de densidad de probabilidad. Biblioteca de Python. [En línea]. Disponible en: https://erdogant.github.io/distfit

[41] Wikipedia. (2010). Tormenta de nieve norteamericana de diciembre de 2010. Consultado: 15 de marzo de 2025. [En línea]. Disponible en: https://en.wikipedia.org/wiki/December_2010_North_American_blizzard



Mina Nouri obtuvo la licenciatura y la maestría en ingeniería civil por la Universidad de Teherán, Irán, y el doctorado en ingeniería civil por el Instituto Tecnológico Stevens, en Hoboken, Nueva Jersey, EE. UU. Sus áreas de investigación incluyen el aprendizaje automático, el análisis de macrodatos y la detección de anomalías, con aplicaciones a sistemas del mundo real.



Mohammad Ilbeigi obtuvo la licenciatura en ingeniería civil por la Universidad Tecnológica Sharif, la maestría en ingeniería civil por la Universidad de Teherán (Irán), y la maestría en ciencias e ingeniería computacional, así como el doctorado en gestión de la construcción, por el Instituto Tecnológico de Georgia (Georgia Institute of Technology), en Atlanta (EE. UU.). Actualmente es profesor asistente en el Departamento de Ingeniería Civil, Ambiental y Oceánica del Instituto Tecnológico Stevens (Stevens Institute of Technology), en Hoboken (Nueva Jersey, EE. UU.). Su investigación se centra en el desarrollo de infraestructuras resilientes y adaptables.