Machine Translated by Google

Un enfoque de detección e identificación de anomalías de tráfico basado en el aprendizaje multiinstancia.

Dong Feng,
Instituto de Ciencias de la Información,
Universidad Jiaotong de Pekín, Pekín,
China, dongfeng@bjtu.edu.cn, Autor
de correspondencia

Mangui Liang,
Instituto de Ciencias de la Información,
Universidad Jiaotong de Beijing, Beijing,
China;
mgliang@bjtu.edu.cn

Guangchao Wang ,
Instituto de Investigación de Tecnología de
Inteligencia Artificial de Nueva Generación
de Qingdao, Qingdao, China.
wangguangchao@boyunvision.com

ABSTRACTO

La detección de anomalías en el tráfico desempeña un papel importante en la prevención eficaz y la gestión oportuna de los accidentes de tráfico. Sin embargo, actualmente la detección de anomalías en el tráfico aún se encuentra en sus inicios, dependiendo principalmente de la intervención manual, lo que no solo consume mucha mano de obra, sino que también resulta ineficiente en términos de tiempo. De acuerdo con las características de las escenas de tráfico urbano, este artículo propone una estructura de red MFnet basada en múltiples módulos de fibra, con el objetivo de lograr una extracción rápida y un cálculo en tiempo real de las características de la transmisión de vídeo mediante convolución de grupo y conectividad dispersa. Además, se introduce el método de aprendizaje multiinstancia débilmente supervisado para el entrenamiento en la aplicación del modelo de detección de anomalías en el tráfico , lo que reduce la dificultad de etiquetar vídeos de muestra y mejora la capacidad de detección de anomalías en escenarios complejos . Los resultados experimentales basados en datos de vídeo de tráfico reales muestran que este método propuesto, en comparación con los métodos de detección de anomalías en el tráfico existentes , es bueno en términos de precisión de detección y tasa de recuperación, y es eficiente en la detección de anomalías en escenarios de tráfico reales.

CONCEPTOS DE CCS

• CCS –> Metodologías de computación –> Modelado y simulación –> Desarrollo y análisis de modelos –> Metodologías de modelado;

PALABRAS CLAVE

Detección de anomalías en vídeo, aprendizaje automático, IA, extracción de características, aprendizaje multiinstancia

Formato de referencia ACM:
Dong Feng, Mangui Liang y Guangchao Wang. 2021. Un enfoque de detección e identificación de anomalías de tráfico basado en aprendizaje multiinstancia. En la 2.ª Conferencia Internacional sobre Computación y Ciencia de Datos (CONFCDS 2021), del 28 al 30 de enero de 2021, Stanford, CA, EE. UU. ACM, Nueva York, NY, EE. UU., 7 páginas. https://doi.org/10.1145/3448734.3450926

Se concede permiso para realizar copias digitales o impresas de la totalidad o parte de esta obra para uso personal o en el aula, sin coste alguno, siempre que dichas copias no se realicen ni distribuyan con fines de lucro o ventaja comercial y que incluyan este aviso y la cita completa en la primera página. Los derechos de autor de los componentes de esta obra que pertenezcan a terceros ajenos a ACM deben respetarse. Se permite la elaboración de resúmenes con la debida atribución. Para cualquier otro tipo de copia, republicación, publicación en servidores o redistribución a listas de correo, se requiere autorización previa específica y/o el pago de una tarifa. Solicite los permisos a permissions@acm.org.
CONFCDS 2021, del 28 al 30 de enero de 2021, Stanford, CA,
EE. UU. © 2021 Association for Computing Machinery.
ACM ISBN 978-1-4503-8957-0/21/01. . . $15.00
https://doi.org/10.1145/3448734.3450926

1. INTRODUCCIÓN

El procesamiento de imágenes, la visión artificial, el aprendizaje profundo y otras tecnologías informáticas permiten superar las limitaciones de la videovigilancia tradicional y realizar un análisis inteligente de los datos, así como la detección activa y la alerta en tiempo real de anomalías en el tráfico. Estas tecnologías son de gran importancia para la monitorización y el análisis inteligentes de los vídeos de tráfico urbano.

En el tráfico urbano, comportamientos como el estacionamiento ilegal, la conducción lenta y la conducción en sentido contrario son muy propensos a causar accidentes y congestión. Los accidentes de tráfico graves provocan lesiones personales y enormes pérdidas económicas. La detección oportuna y la respuesta rápida y eficaz ante cualquier accidente de tráfico son vitales para garantizar la seguridad vial en las ciudades. La detección de anomalías de tráfico basada en vídeo es una línea de investigación clave en el transporte inteligente. La detección de anomalías de tráfico mediante videovigilancia se compone principalmente de cuatro pasos básicos: preprocesamiento de imágenes, representación de eventos básicos , construcción de un modelo de detección de anomalías y análisis de anomalías [13–15]. La representación básica de eventos y la construcción de un modelo de detección de anomalías desempeñan un papel fundamental para garantizar la eficiencia y el rendimiento de la detección de anomalías en el tráfico. Este trabajo, basado en una estructura de red multifibra con segmentación semántica de imágenes y el algoritmo de identificación de vídeo MFNet, logra la extracción y clasificación de características de imágenes de vídeo , reduciendo la carga computacional de las redes neuronales profundas espaciotemporales . Asimismo, se introduce un método de aprendizaje multiinstancia para la red de puntuación de la detección de anomalías en el tráfico, con el fin de optimizar iterativamente los resultados de la clasificación.

Este artículo se centra principalmente en: 1) exponer los algoritmos de detección de anomalías existentes , así como sus ventajas y desventajas; 2) aclarar las reglas de fragmentación de vídeo y diseñar la estructura de la red MFNet para lograr una extracción rápida de las características de las imágenes de vídeo; y 3) introducir el método de aprendizaje de instancias múltiples para la red de puntuación, con el fin de maximizar las puntuaciones positivas y negativas y mejorar la precisión de la detección de anomalías en el tráfico.

Este documento consta principalmente de cinco secciones y un resumen. En concreto, la Sección 1 presenta los antecedentes y la importancia de la detección de anomalías en el tráfico. La Sección 2 analiza los resultados de las investigaciones existentes, así como las ventajas y desventajas de la detección de anomalías en el tráfico. La sección 3 describe el diseño y la aplicación del modelo de red MFNet. La sección 4 detalla la aplicación del método de aprendizaje multiinstancia débilmente supervisado a la red de puntuación. La sección 5 presenta los detalles y resultados experimentales. Finalmente, se ofrece un resumen y una perspectiva a futuro.

Machine Translated by Google

2 TRABAJOS RELACIONADOS

En comparación con la detección de objetivos clásica, la detección de anomalías en vídeo suele imposibilitar la recopilación de conjuntos de datos de anomalías suficientes y completos. La técnica de clasificación supervisada convencional y eficaz no suele ser adecuada para la detección de anomalías en vídeo (en lo que respecta a la técnica de clasificación supervisada, se requieren datos que contengan información tanto de eventos normales como anómalos etiquetados para el entrenamiento) [10-12]. Según los escenarios y condiciones de uso, las técnicas existentes de detección de anomalías en vídeo se dividen en las siguientes tres categorías:

• Detección de anomalías en vídeo semisupervisada

En cuanto a la detección de anomalías en vídeo semisupervisada, los vídeos de eventos normales solo se pueden utilizar para construir un modelo de eventos normales, y todos los eventos que se desvíen de este modelo durante la fase de prueba se identificarán como eventos anómalos. La técnica de detección de anomalías en vídeo semisupervisada presupone que no existe información previa sobre la anomalía, lo que concuerda con el supuesto de mundo abierto para la detección de anomalías. La mayoría de las soluciones existentes se basan en este supuesto. Consulte la bibliografía relacionada [1-5] para obtener más detalles sobre soluciones representativas.

• Mantenimiento de la integridad de las especificaciones. Detección de anomalías de vídeo no supervisada.

No se utilizan datos etiquetados artificialmente (eventos normales o anómalos) para la detección no supervisada de anomalías en vídeo, y la anomalía más diferenciada se identifica en función de las propiedades y características de distribución de los datos de eventos de vídeo. En comparación con la detección semisupervisada de anomalías en vídeo, la detección no supervisada se acerca más a la realidad en cuanto al escenario, pero requiere muchos menos datos de entrenamiento. Además, la detección no supervisada de anomalías en vídeo, como línea de investigación emergente en los últimos años, es más difícil de implementar. Consulte la bibliografía relacionada [6-8] para obtener más detalles sobre trabajos representativos.

• Detección de anomalías en vídeo con supervisión débil.

En cuanto a la detección de anomalías en vídeo con supervisión débil, se pueden utilizar pocos vídeos, o vídeos con etiquetas débiles, que contengan información sobre eventos anómalos para el entrenamiento. Con respecto al etiquetado débil, la posición del píxel o fotograma anómalo se marca de forma imprecisa , y la presencia de información anómala en un vídeo se indica solo a un nivel general (marcando si un vídeo contiene información anómala, sin necesidad de marcar la posición específica del fotograma anómalo). La detección de anomalías en vídeo con supervisión débil se acerca más a los escenarios de la vida real, lo que supera principalmente la debilidad de ignorar por completo la información previa de eventos anómalos conocidos en el modo de detección de anomalías en vídeo semisupervisada. Actualmente, existen pocos métodos de detección de anomalías en vídeo con supervisión débil como nueva línea de investigación. Consulte la bibliografía relacionada [9] para obtener detalles sobre trabajos representativos.

Este artículo logra una extracción rápida de características de imagen de la secuencia de fotogramas de vídeo a través del modelo de red MFNet, e introduce el método de aprendizaje débilmente supervisado de instancias múltiples para la puntuación de anomalías de tráfico, realizando una investigación en profundidad sobre la detección de anomalías de tráfico.

3. EL DISEÑO DE MFNET PARA FUNCIONALIDADES EXTRACCIÓN

La red neuronal convolucional 3D (CNN 3D) es la preferida para la extracción y clasificación de características de imágenes de vídeo. A diferencia de la CNN 2D, la CNN 3D utiliza un núcleo de convolución 3D en el tiempo y el espacio para la convolución de la red. Si bien la CNN 3D puede extraer características de imagen con gran precisión, conlleva una enorme sobrecarga de la operación de convolución y un aumento exponencial en la dimensión del tensor de entrada/salida en comparación con la CNN 2D. Para reducir la carga computacional de las redes neuronales profundas espaciotemporales y garantizar una velocidad de inferencia similar a la de la CNN 2D, manteniendo la precisión de la clasificación, este artículo propone el concepto de red multifibra, que divide la red compleja en múltiples redes ligeras mediante una estructura de conexión dispersa y logra la fusión de información entre diferentes fibras a través del módulo multiplexor.

Esta sección presenta primero la unidad multifibra, la unidad básica del modelo CNN 3D. La unidad multifibra minimiza la interna

conecta capas de red y mejora la eficiencia del modelo, teniendo buena compatibilidad y adaptabilidad a CNN 2D y CNN 3D.
La unidad multifibra está integrada en la CNN 2D para ilustrar su
Se analiza la eficacia y la precisión en la identificación de imágenes. Esta sección aplica la unidad multifibra a la CNN 3D, describiendo la solución específica.

La unidad multifibra está diseñada a partir de la optimización de la unidad residual altamente modular, lo que facilita el entrenamiento y la implementación del modelo. La unidad residual tradicional aprende características mediante dos capas convolucionales, lo cual es claro y fácil de entender, pero conlleva una enorme carga computacional, como se muestra en la Figura 1(a).
El número de conexiones convolucionales de la unidad multifibra se expresa mediante la siguiente fórmula. Donde Min denota el número de canales de entrada, Mmid representa el número de canales en la capa intermedia de la unidad residual y Mout es el número de canales de salida:

$$\text{Conexiones} = \text{Mín} \quad \text{Mmid} + \text{Mmid} \quad \text{Mout} \tag{1}$$

Solo se tienen en cuenta las constantes derivadas de los cambios en la relación de conexión , mientras que otras constantes, como la dimensión de la característica de entrada y la dimensión del núcleo de convolución, se ignoran. De este modo, la fórmula anterior se simplifica. La fórmula (1) muestra que el número de conexiones es proporcional al cuadrado del ancho de la red. En otras palabras, la sobrecarga computacional aumentará si el ancho de la red de la unidad estructural aumenta k k^2veces. Para reducir las conexiones de la red y la sobrecarga computacional total , la unidad residual compleja se divide y se convierte en N canales paralelos separables, lo que se conoce como fibrosis modular.

Después de la fibrosis, cada canal en la unidad residual se vuelve independiente, como se muestra en la Figura 1. El ancho de la red de la unidad estructural permanece sin cambios, pero el número de conexiones se reduce a 1/N del original, como se muestra en la fórmula (2):

$$\text{Conec} = N \quad (\text{Min}/N \quad \text{Mmid}/N + \text{Mmid}/N \quad \text{Mout}/N)$$

$$= (\text{Min} \quad \text{Mmid} + \text{Mmid} \quad \text{Mout})/N \tag{2}$$

Para lograr la fusión y el intercambio de información de características entre diferentes canales, se accede al módulo multiplexor antes de la operación de convolución, que amplifica y redirige la

Machine Translated by Google

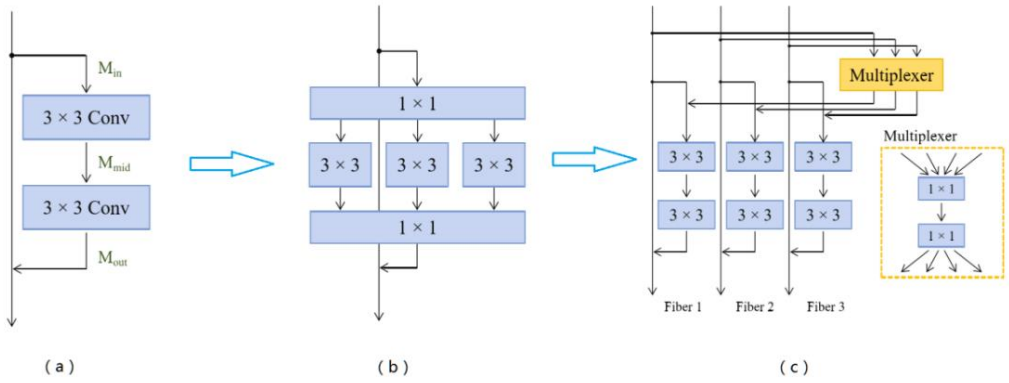


Figura 1: Proceso de cambio de la red ResNet a la red multifibra

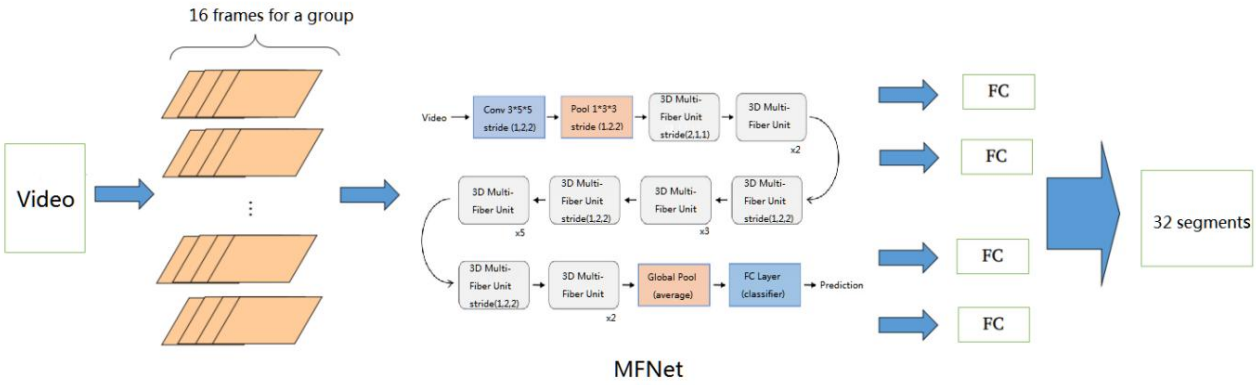


Figura 2: Estructura de red multifibra basada en convolución 3D

Información de características multicanal, desempeñando el papel de distribución de enrutamiento . El módulo multiplexor primero realiza una reducción de la dimensión del canal mediante el núcleo de convolución 1*1, para lograr la interacción de información entre diferentes canales y compensar la pérdida de información generada por el seccionamiento. A continuación, se restaura el número de canales de entrada mediante la ampliación de la dimensión del núcleo de convolución 1*1 .

La CNN 3D basada en MFNet está diseñada para extraer características de vídeo y detectar anomalías. MFNet tiene una estructura de red ResNet-50, y la unidad residual se reemplaza por la unidad multifibra propuesta en este trabajo. Después de extraer las características de cada vídeo a partir de 16 fotogramas, todos los vectores de características de un vídeo completo se integran en un vector de características de 32×768 y se envían a la red MFNet para la extracción de características. Si el vídeo tiene menos de 32 vectores de características, se utilizarán vectores adyacentes para completar el conjunto; de lo contrario, se seleccionarán 32 vectores de características mediante muestreo uniforme. Luego, los vectores de características se introducen en la capa FC para la puntuación de anomalías, como se muestra en la Figura 2. La estructura de red multifibra propuesta aquí puede reducir las conexiones de canal y la sobrecarga computacional de la CNN 3D, y también mejorar la eficiencia del modelo CNN 2D . Para demostrar la aplicabilidad general de la estructura de red multifibra , la parte experimental de este artículo expone la mejora del rendimiento de la clasificación de imágenes 2D y exactitud.

4 INSTANCIAS MÚLTIPLES DÉBILMENTE SUPERVISADAS APRENDIENDO

Después de extraer las características de la imagen de video mediante MFNet, 32 segmentos de características totalmente conectadas se envían a la red de puntuación para la clasificación y puntuación de los segmentos anómalos. El método de aprendizaje no supervisado se suele adoptar para la detección tradicional de anomalías de tráfico , lo que puede reducir la dificultad del etiquetado de datos. Sin embargo, es casi imposible recopilar todos los eventos normales y anómalos en la realidad, y los juicios sobre el mismo evento pueden variar en diferentes escenarios. Por lo tanto, no se pueden obtener resultados de clasificación precisos después del entrenamiento y la puntuación mediante el método de aprendizaje no supervisado. Este artículo adopta el método de aprendizaje multiinstancia débilmente supervisado para la clasificación y puntuación de anomalías. Las bolsas positivas y negativas se definen en la Figura 3. Cada video de entrenamiento se divide en 32 segmentos iguales. Si los 32 segmentos de video son eventos normales, el video constituye una bolsa negativa. Si existe uno o más eventos anómalos en los 32 segmentos de video, el video se define como una bolsa positiva. En comparación con la bolsa negativa, la bolsa positiva no necesita información adicional de etiquetado de tiempo/espacio para identificar la ubicación específica de la anomalía.

Machine Translated by Google

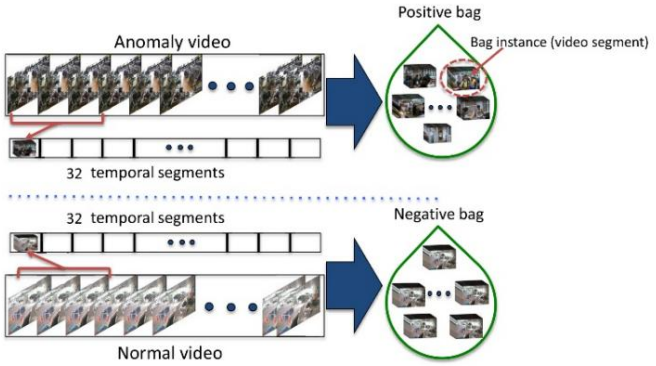


Figura 3: División de bolsas positivas y negativas con supervisión débil.

La red de puntuación se basa en una red neuronal totalmente conectada de 3 capas, como se muestra en la Figura 4, mediante la cual se puntúa cada segmento de vídeo. Para evitar el sobreajuste y mejorar la capacidad de generalización de la red de puntuación, se añade una capa de abandono (dropout) y se detiene aleatoriamente algún detector de características. Los segmentos de vídeo de los conjuntos positivos y negativos se introducen en el modelo de red, y cada segmento se puntúa mediante la red de puntuación. El segmento con la puntuación más alta del conjunto positivo se selecciona como la instancia de anomalía potencial, y el segmento con la puntuación más alta del conjunto negativo se selecciona como la instancia sin anomalía. Los parámetros del modelo se entrenan en función de las puntuaciones de ambas instancias . Se utiliza la función de pérdida de bisagra para maximizar la diferencia de puntuación entre la instancia positiva y la negativa.

La fórmula es la siguiente:

$$l(\beta a, \beta n) = \max(0, 1 - \max_{\beta a} f(v_i^{\beta a}) + \max_{\beta n} f(v_i^{\beta n})) \quad (3)$$

Donde f() representa la salida de puntuación. Cuando las puntuaciones de un evento anómalo y un evento normal son 1 y 0, el valor de pérdida alcanza el mínimo 0; de lo contrario, es mayor que 0. Por lo tanto, la función de pérdida puede maximizar el espacio de distancia entre instancias positivas y negativas. Para mejorar la precisión de la detección de anomalías, se añaden dos restricciones a la función de pérdida: la restricción de suavidad y la restricción de escasez. Primero, todos los segmentos de características de cada bolsa positiva o negativa provienen del mismo vídeo, por lo que las puntuaciones de los segmentos de características deben cambiar suavemente. Se minimiza el cuadrado de la diferencia entre dos segmentos de características adyacentes para garantizar la transición suave de los valores de las características. Segundo, normalmente solo existen unas pocas instancias de anomalía en una bolsa positiva, por lo que la restricción de suavidad puede hacer que todas las instancias en una bolsa positiva tiendan a obtener puntuaciones más altas. Por lo tanto, se añade la pérdida para restringir por separado la puntuación general. La expresión general se muestra en la fórmula 4:

$$l(\beta a, \beta n) = \max(0, 1 - \max_{\beta a} f(v_i^{\beta a}) + \max_{\beta n} f(v_i^{\beta n}))$$

$$+ \lambda 1 \sum_{i}^{(n-1)} (f(v_a^i) - f(v_a^{i+1}))^2 + \lambda 2 \sum_{i} f(n_a^i) \quad (4)$$

Finalmente, se añaden términos de regularización para obtener la expresión de la función objetivo de la siguiente manera:

$$L(W) = l(\beta a, \beta n) + \lambda 3 \quad W \quad F \quad (5)$$

5 RESULTADOS EXPERIMENTALES

5.1 Detalles de implementación

Primero, se evaluaron los indicadores de rendimiento del modelo de red MFNet y el modelo de algoritmo avanzado reciente, con Kinetics, UCF-101 y HMDB51 como conjuntos de datos públicos. Luego, se utilizó la red de puntuación basada en aprendizaje de instancias múltiples para detectar y evaluar eventos anómalos. Todos los experimentos se basan en el marco de trabajo PyTorch. Antes de que el flujo de video ingresara al modelo de red, el tamaño de píxel de entrada se ajustó uniformemente a 224*224, y la velocidad de fotogramas se estableció en 30 fps. Luego, se generaron segmentos de video cada 16 fotogramas y se ingresaron a la red MFNet. En el terminal de salida de la red, las características de imagen de 16 fotogramas se integraron en un vector de características de 768 dimensiones. Luego, 32 segmentos de características obtenidos después del muestreo de video se ingresaron a la red neuronal compuesta por tres capas FC. Las tres capas FC constan de 512, 32 y 1 unidades de detección de características, respectivamente. Se añadió una capa de abandono entre las capas FC y se descartó aleatoriamente cierta información de características para garantizar la capacidad de generalización del modelo. En cuanto a los parámetros de la función de pérdida, el coeficiente de correspondencia entre la restricción de suavidad y la restricción de escasez se estableció como λ1 = λ2 = 6 10−5 y el coeficiente de regularización se estableció como λ3 = 0,02 para obtener el mejor índice de rendimiento.

5.2 Resultados y evaluación

Primero, se verificó la efectividad del modelo MFNet en el aprendizaje de características de video , y se utilizó el conjunto de datos a gran escala Kinetics para evaluar el modelo (el conjunto de datos Kinetics consta de 300,000 segmentos de video y contiene 400 categorías de acción). La tasa de aprendizaje inicial del modelo se estableció en 0.1, que disminuyó gradualmente en 0.0001 durante el proceso de entrenamiento. Se adoptó el descenso de gradiente estocástico (SGD) para optimizar cada lote de entrenamiento. Se utilizó un clúster compuesto por 64 GPU para el entrenamiento del modelo. La Figura 5 muestra la curva de precisión de entrenamiento y verificación. Como se observa en esta figura, el modelo de red pudo converger rápidamente, y solo se necesitaron alrededor de 36,000 iteraciones para completar todo el entrenamiento.

La Tabla 1 muestra los resultados de identificación de video del modelo generados a partir de diferentes entrenamientos de algoritmos bajo las condiciones del conjunto de datos a gran escala Kinetics. Según los datos experimentales mostrados en la siguiente tabla, el algoritmo MFNet, en contraste con otros algoritmos, mejora significativamente en el número de parámetros de peso , el número de cálculos de punto flotante y la precisión de Top-1. Se necesitan pocos haces de fibra múltiple para el algoritmo MFNet , lo que puede reducir considerablemente la sobrecarga computacional al tiempo que garantiza la precisión de identificación. El uso de la estructura de red de fibra múltiple reduce la sobrecarga computacional total a solo 11,1 G, igual a la sobrecarga computacional de una CNN 2D ordinaria.

MFNet permite la máxima precisión de identificación de Top-1/Top-5. En términos de tamaño, el algoritmo MFNetR es solo 1/8 del algoritmo R(2+1)D-RGB, pero es 13 veces más rápido que el algoritmo R(2+1)D-RGB.

Machine Translated by Google

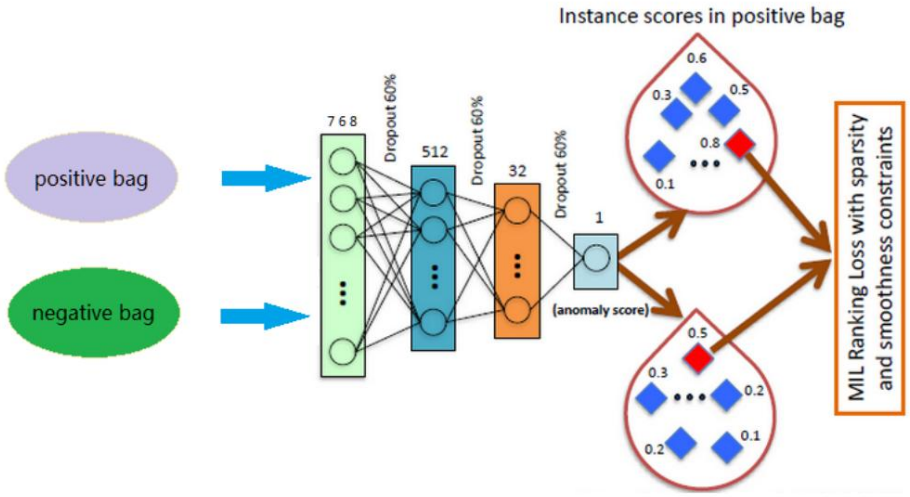


Figura 4: Diagrama de flujo de la detección de anomalías con supervisión débil

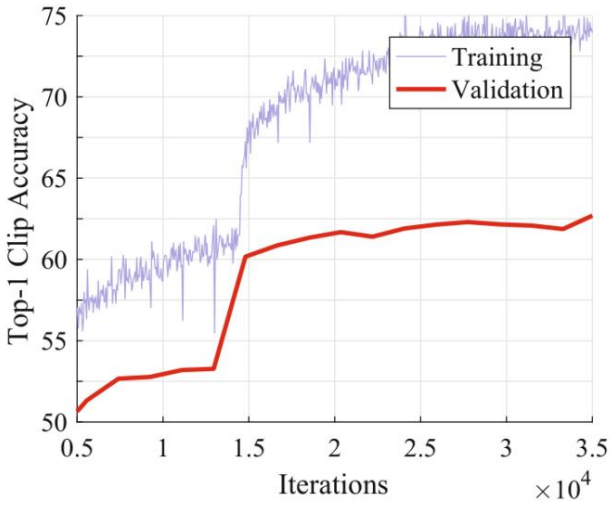


Figura 5: Precisión de identificación de MFNet bajo las condiciones del conjunto de datos Kinetics.

en velocidad de cálculo e inferencia, con una mejora de la precisión Top-1 en un 0,8%. Además, el modelo MFNet de multifibra
La estructura de red minimiza el uso de los recursos de memoria de la GPU en el proceso de entrenamiento o inferencia.

Mediante el método de aprendizaje multiinstancia débilmente supervisado, En el con- se pueden identificar eventos normales y eventos anómalos.
proceso de iteración constante. Mediante este método, la red puede aprender automáticamente una gran cantidad de videos etiquetados con resultados positivos y casos negativos, y luego predice las ubicaciones de los segmentos anómalos en el video. La red puede generar puntuaciones altas.
para segmentos de vídeo anómalos en el proceso de entrenamiento iterativo. La figura 6 ilustra los cambios de las puntuaciones de anomalías con un aumento en iteración durante el entrenamiento de videos que contienen anomalías Información del evento. Cuando el número de iteraciones alcance 1.000, La red asigna puntuaciones altas a los segmentos anómalos y normales.

Tabla 1: Comparación del rendimiento entre los algoritmos MFNet y varios algoritmos clásicos bajo las condiciones de Ki-
conjunto de datos de nética

Método	Parámetros	FLOPs	Top-1	Los 5 mejores
Doble flujo	12,5 millones	-	62,2%	-
ConvNet+LSTM 9M		-	63,3%	-
S3D	8,8 millones	66,4G	69,4%	89,1%
I3D-RGB	12,1 millones	107,9 g	71,1%	89,3%
R(2+1)D-RGB	63,6 millones	152,4G	72,0%	90,0%
MF-Net (Nuestra)	7,8 millones	10,6 g	73,8%	91,4%

Después de 3.000 iteraciones, la red separa gradualmente la Segmentos anómalos y normales, los segmentos anómalos aún se mantienen Las puntuaciones altas y las puntuaciones de los segmentos normales comienzan a disminuir. Sin embargo, aún se necesita mejorar la duración y la separación.
de segmentos anómalos, y algunos segmentos normales aún existen en el intervalo de puntuación del segmento de anomalía. Cuando el número de iteraciones Al alcanzar los 5.000 y 8.000, la red puede localizar segmentos anómalos. en el vídeo con mayor precisión después de aprender más ejemplos de vídeo. Aunque la información de cualquier segmento de vídeo no se utiliza, Aún se puede predecir la ubicación de un segmento anómalo en el video.
a través del algoritmo MFNet según la puntuación de anomalía.

Finalmente, el algoritmo MFNet fue analizado en tráfico real. escenas. Primero, un segmento de video de un accidente de tráfico típico fue seleccionado, como se muestra en la Figura 7. La anomalía de tráfico se muestra entre El noveno y el duodécimo fotograma del vídeo. Basado en MFNet. El algoritmo detectó la anomalía de tráfico de manera oportuna. Como se muestra en la curva de detección, se da una puntuación de anomalía muy alta. en caso de cualquier anomalía de tráfico. La curva es relativamente plana desde el primer fotograma hasta el noveno fotograma, donde las puntuaciones de anomalía son pequeñas y dentro de los umbrales dados. Sin embargo, la curva de detección Cae desde el fotograma 13 hasta el fotograma 15. El algoritmo MFNet es eficaz para detectar cualquier anomalía de tráfico de manera oportuna, pero El problema del seguimiento continuo de anomalías aún necesita ser resuelto.

Machine Translated by Google

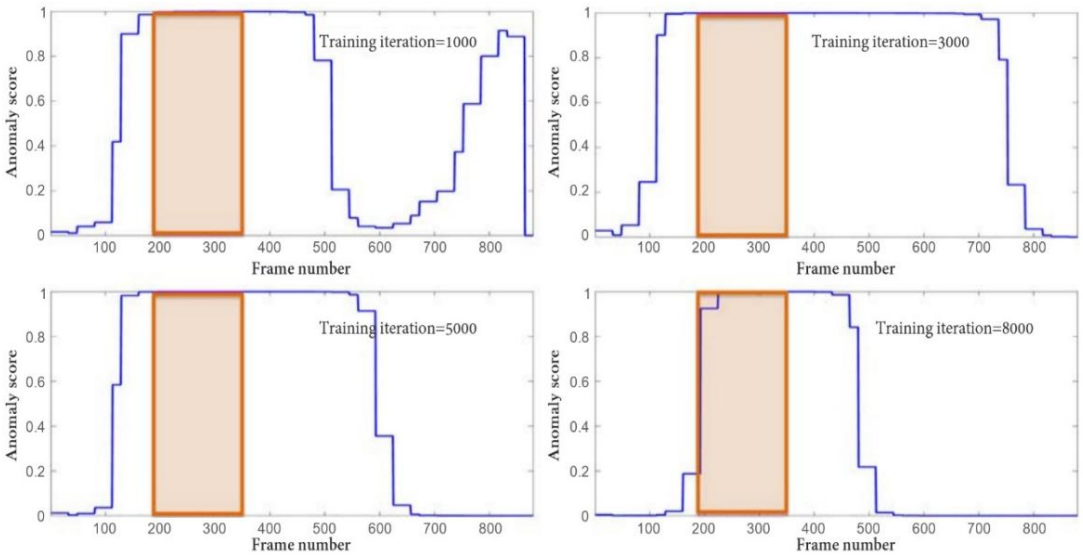


Figura 6: Cambios en las puntuaciones de anomalías de los vídeos de entrenamiento con el aumento de las iteraciones.

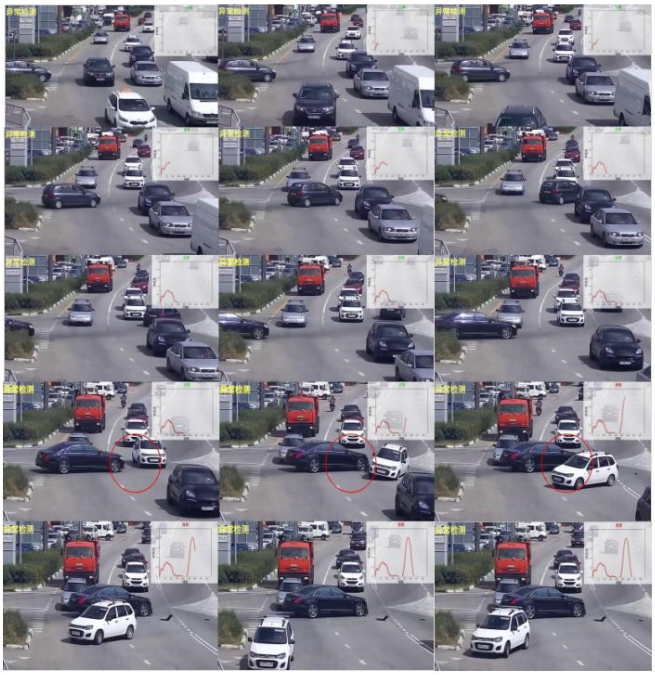


Figura 7: Identificación de anomalías en el vídeo mediante el método de supervisión débil.

Resuelto. Las redes de memoria a corto y largo plazo, como LSTM y MFNet, deben integrarse y analizarse exhaustivamente para garantizar una monitorización completa de los eventos anómalos.

6 CONCLUSIONES

Se propone un método de aprendizaje profundo para lograr la detección de anomalías en el tráfico. La complejidad y diversidad de las anomalías hacen que Es difícil lograr la detección de anomalías basándose únicamente en datos de eventos normales. Por lo tanto, se utilizan dos tipos de datos para el entrenamiento del modelo . Para evitar el trabajo masivo de etiquetado relacionado con los datos de vídeo de entrenamiento, se adopta una estructura de red de aprendizaje de instancias múltiples para la puntuación de instancias. Se necesita poco trabajo de etiquetado, pero la precisión de la clasificación y puntuación de eventos no se ve afectada. Los resultados experimentales demuestran que el nuevo método de detección de anomalías de tráfico es significativamente mejor que los algoritmos de detección tradicionales. La investigación futura se centrará en la asociación de diversas condiciones de y parámetros con la ocurrencia de eventos anómalos, para lograr una mejor alerta temprana ante cualquier posible anomalía en el tráfico.

EXPRESIONES DE GRATITUD

Este trabajo fue financiado en parte por el Proyecto Conjunto de la Fundación Nacional de Ciencias Naturales de China bajo la subvención n.° U1636109. y el Programa Nacional 863 (n.º 2007AA01Z203).

REFERENCIAS

[1] SIMON JJ, JEFFREY K U. Nueva extensión del filtro de Kalman a sistemas no lineales [C] //Sociedad Internacional de Óptica y Fotónica (SPIE), 1997.

[2] LUO WH, JUN LX, XIAO QZ, et al. Seguimiento de múltiples objetos: una revisión [J]. arXiv:1409.7618,2014.

[3] CHANHO K, FUXIN L, ARRIDHANA C, et al. Seguimiento de hipótesis múltiples revisado [C] // Conferencia Internacional IEEE sobre Visión por Computadora (ICCV). 2015:4696-4704.

[4] XIANG Y, ALAHI A, SAVARESE S. Aprendizaje para rastrear: seguimiento de múltiples objetos en línea mediante toma de decisiones [C] //2015 IEEE International Conference on Computer Vision (ICCV). 2015:4705-4713.

[5] LEAL TL, FERRER CC, SCHINDLER K. Aprendizaje mediante seguimiento: siamesecnn para una asociación de objetivos robusta [J]. Talleres CVPR, 2016: 418-425.

[6] SI YT, BJOERN A, MYKHAYLOA, et al. Seguimiento de múltiples personas mediante multicorte y coincidencia profunda [M]. Talleres de Visión por Computadora ECCV 2016, 2016: 100-111.

[7] AMIR S, ALEXANDRE A, SILVIO S. Rastreo de lo inrastreable: aprendizaje para rastrear múltiples señales con dependencias a largo plazo [J]. ICCV, 2017: 300-311.

[8] WEIMING H, TIENIU T, LIANG W, et al. Un estudio sobre la vigilancia visual del movimiento y los comportamientos de los objetos [J]. IEEE Trans. Systems, Man, and Cybernetics, 2004, 34(3): 334-352.

[9] ROLLER D, DANILDIS K, NAGEL H H. Seguimiento de objetos basado en modelos en secuencias de imágenes monoculares de escenas de tráfico rodado [J]. International Journal of Computer Vision, 1993, 10(3): 257-281.

Machine Translated by Google

[10] J. Kooij, M. Liem, J. Krijnders, T. Andringa y D. Gavrila. Detección multimodal de agresión humana. Computer Vision and Image Understanding, 2016.

[11] L. Kratz y K. Nishino. Detección de anomalías en escenas extremadamente concurridas utilizando modelos de patrones de movimiento espacio-temporales. En CVPR, 2009.

[12] W. Li, V. Mahadevan y N. Vasconcelos. Detección y localización de anomalías en escenas concurridas. TPAMI, 2014.

[13] C. Lu, J. Shi y J. Jia. Detección de eventos anormales a 150 fps en matlab. En ICCV, 2013.

[14] R. Mehran, A. Oyama y M. Shah. Detección de comportamiento anormal de multitudes utilizando un modelo de fuerza social. En CVPR, 2009.

[15] S. Mohammadi, A. Perina, H. Kiani y M. Vittorio. Multitudes enojadas: detección Eventos violentos en videos. En ECCV, 2016.