Machine Translated by Google

systems

MDPI

Artículo

AIP-Urban: Marco de aprendizaje profundo habilitado para el borde Mantenimiento predictivo y detección de anomalías en entornos urbanos. Infraestructura de tráfico

Wajih Abdallah* y Mansoor Alghamdi

Departamento de Ciencias de la Computación, Facultad de Ciencias Aplicadas, Universidad de Tabuk, Tabuk 71491, Arabia Saudita;
malghamdi@ut.edu.sa * Correspondencia: wabdallah@ut.edu.sa

Abstracto

Las infraestructuras de tráfico urbano, como los semáforos, las cámaras de vigilancia y los sensores integrados, desempeñan un papel esencial en la movilidad sostenible, pero también son susceptibles a fallos, deriva de datos y degradación por condiciones ambientales. En este estudio, proponemos AIP-Urban, un marco de mantenimiento predictivo habilitado por IA en el borde que emplea aprendizaje profundo espacio-temporal con detección continua de anomalías para sistemas de transporte inteligentes. Nuestro marco integra sensores IoT, visión artificial y análisis de series temporales para identificar y predecir fallos en la infraestructura antes de que ocurran. Para anomalías visuales y numéricas (por ejemplo, fallo de semáforos, congestión repentina, desconexión de sensores), empleamos un modelo híbrido CNN-Transformer, mientras que utilizamos un predictor LSTM temporal para estimar una tendencia de degradación y predecir eventos de mantenimiento en 24 horas. Los modelos se implementan en dispositivos Jetson Nano en el borde para permitir el procesamiento en tiempo real bajo restricciones energéticas. Estudios de simulación exhaustivos con conjuntos de datos de SUMO, CityCam y UA-DETRAC muestran que AIP-Urban alcanzó una precisión del 94 % en la detección de anomalías (F1 = 0,94), con un RMSE = 0,11 para la predicción de fallos y una latencia de inferencia en el borde de 72 ms, mientras que el consumo de energía se mantuvo por debajo de 7,8 W. Las pruebas estadísticas (Wilcoxon $p < 0,05$) muestran un buen ajuste en comparación con los modelos de referencia de CNN, LSTM y Transformer únicamente. Este estudio muestra un gran potencial para mejorar la fiabilidad, la seguridad y la sostenibilidad del tráfico urbano mediante una IA proactiva, explicable y con conciencia energética en el borde. AIP-Urban sirve como arquitectura de referencia reproducible para futuros sistemas de mantenimiento del transporte basados en IA, alineada con los principios de las ciudades inteligentes y resilientes.

Palabras clave: mantenimiento predictivo; detección de anomalías; IA en el borde; aprendizaje profundo; CNN; LSTM; sistemas de transporte inteligentes; infraestructura de tráfico urbano; movilidad sostenible; monitorización en tiempo real

check for updates

Editores académicos: Rongjun Cheng, Xiaofei Ye y Cong Zhai

Recibido: 18 de noviembre de 2025
Revisado: 3 de diciembre de 2025
Aceptado: 8 de diciembre de 2025
Publicado: 11 de diciembre de 2025

Cita: Abdallah, W.; Alghamdi, M. AIP-Urban: Aprendizaje profundo habilitado para el borde Marco para la predicción Mantenimiento y detección de anomalías en infraestructura de tráfico urbano. Sistemas 2025, 13 , 1117. https://doi.org/10.3390/systems13121117

Derechos de autor: © 2025 por los autores. Titular de la licencia: MDPI, Basilea, Suiza. Este artículo es de acceso abierto. distribuido bajo los términos y condiciones de Creative Commons Licencia de atribución (CC BY) (https://creativecommons.org/licenses/by/4.0/).

1. Introducción

La infraestructura de transporte en las zonas urbanas (intersecciones, semáforos, sensores y videovigilancia) desempeña un papel fundamental en el funcionamiento de las ciudades inteligentes, al proporcionar mayor movilidad y seguridad, además de un menor impacto ambiental. La creciente presión sobre estos sistemas (hardware obsoleto, aumento del tráfico, condiciones ambientales y variabilidad en las condiciones operativas) ha incrementado la probabilidad de fallos imprevistos. Un solo semáforo, sensor o interrupción del servicio no notificada puede provocar mayor congestión, mayor consumo de energía y mayores emisiones de CO , así como una reducción en la calidad del servicio para los usuarios.

Machine Translated by Google

Históricamente, el monitoreo del desempeño de la infraestructura implicaba enfoques reactivos de reparación o inspecciones preventivas programadas. Estos métodos resultan inadecuados para las necesidades de la movilidad inteligente: las ciudades requieren un servicio ininterrumpido, resiliencia ante interrupciones y un bajo impacto ambiental. Como se señala en una revisión, «la convergencia de las iniciativas de ciudad inteligente con el mantenimiento predictivo ... permitirá el monitoreo anticipatorio y en tiempo real de los activos de infraestructura» [1].

Simultáneamente, el campo de la inteligencia artificial (IA) y el aprendizaje profundo (DL) ha acelerado el avance de los sistemas de transporte inteligentes (ITS) a través de una mejor predicción del tráfico, control adaptativo de señales y optimización de flotas [2]. Sin embargo, una cantidad sustancial de investigación previa se ha centrado en el flujo de tráfico o el comportamiento de los vehículos y no ha considerado el funcionamiento futuro de la infraestructura de transporte (como sensores, controladores y dispositivos integrados). Estos no solo no han tenido en cuenta los flujos de tráfico, sino también la fiabilidad y la preservación de la función de la infraestructura [3]. Además, el rápido desarrollo de las tecnologías de computación de borde permite que las tareas analíticas y de toma de decisiones analicen mejor los datos. Esto facilita la reducción de la latencia, el ahorro de ancho de banda y la intervención casi en tiempo real. Por ejemplo, en el contexto de la gestión de infraestructuras, se ha demostrado que los sistemas de IA de borde "permiten diagnósticos en tiempo real, mantenimiento predictivo ... optimización del tráfico en infraestructuras de ciudades inteligentes" [4]. Otras evidencias en el contexto del tráfico urbano han demostrado una mejor capacidad de respuesta y robustez con soluciones basadas en el borde [5]. Además de las consideraciones de rendimiento y resiliencia, la movilidad inteligente exige sostenibilidad y confianza: la gestión del tráfico ahora debe tener en cuenta los objetivos medioambientales (por ejemplo, la reducción de las emisiones de CO2, la eficiencia energética) y garantizar la aceptabilidad de la toma de decisiones automatizada (por ejemplo, mediante Una revisión reciente indica que “la implementación de innovaciones emergentes y de vanguardia impulsadas por IA ... remodelará fundamentalmente los sistemas de transporte por carretera para ciudades inteligentes, por ejemplo, la gestión del tráfico en tiempo real y el impacto ambiental” [6].

Finalmente, el mantenimiento predictivo y la detección de anomalías se consideran cada vez más palancas importantes para apoyar la movilidad sostenible: “El mantenimiento predictivo habilitado por IA utiliza sensores de Internet de las Cosas (IoT), IA y big data, para monitorear la infraestructura, predecir fallas y permitir un mantenimiento optimizado” [7]. Las soluciones que utilizan visión de cámara, sensores de series temporales o datos de metasensores junto con métodos de IA citan precisiones de detección superiores al 90% en la detección de anomalías en infraestructura urbana en tiempo real [8]. Sin embargo, aún quedan varios desafíos clave sin resolver: la interoperabilidad de sensores en redes urbanas heterogéneas, la latencia en el despliegue en el mundo real en entornos urbanos densos, el mayor consumo de energía de los modelos DL en el borde y el desafío continuo de la transparencia del modelo, y muchos modelos de IA que siguen siendo “cajas negras” en contextos críticos para la seguridad. En particular, el uso conjunto de técnicas de IA explicable (XAI) y limitaciones de borde (potencia, latencia, ancho de banda) sigue estando en gran medida inexplorado [9]. Finalmente, si bien muchos estudios se centran en la predicción del flujo de tráfico y la detección de anomalías basadas en IA, como el estudio de ejemplo que produce una precisión del 97,5 % en una simulación multiagente, a menudo tienden a ignorar las limitaciones de hardware o la infraestructura real relevante para el despliegue en el borde [10].

En este contexto, este artículo presenta AIP-Urban, un nuevo marco de IA de borde para el mantenimiento predictivo y la detección de anomalías en la infraestructura de tráfico urbano. El sistema implementa un modelo híbrido CNN-Transformer para la detección visual y temporal de anomalías (por ejemplo, fallos de señalización, fallos de sensores, congestión anormal) y un predictor LSTM para predecir de forma proactiva fallos en los equipos en un horizonte de 24 horas. La arquitectura se implementa en nodos de borde (Jetson Nano, ESP32-Cam) y busca minimizar la latencia y la dependencia de la conectividad en la nube (sin conexión a Internet).

Las principales contribuciones de este trabajo son las siguientes:

Machine Translated by Google

1. Una arquitectura completa de IA en el borde de la red, orientada a la gestión de la salud de la infraestructura de tráfico urbano, que combina la detección de anomalías y el mantenimiento predictivo.
2. El desarrollo y la evaluación de un modelo CNN–Transformer + LSTM utilizado para datos conjuntos de sensores urbanos multimodales, es decir, vídeo de tráfico, series temporales de sensores y estados de señales.
3. Una implementación experimental en hardware real de borde, con medición de la latencia, el consumo de energía y el rendimiento de detección/predicción.
4. Un análisis sistemático de resultados que incluya estudios de ablación, pruebas de significancia estadística y explicabilidad (XAI) para establecer la confiabilidad del sistema y la preparación operativa en entornos urbanos.

AIP-Urban ha introducido varias tecnologías nuevas que cubren las principales necesidades no satisfechas dentro de los marcos de IA de borde y ITS federados que se analizan en la Sección 2. En primer lugar, los sistemas anteriores tendían a centrarse únicamente en la optimización del tráfico o la detección de anomalías, por separado de la monitorización de sensores o el mantenimiento predictivo. En cambio, AIP-Urban combina estas tres funciones en una arquitectura híbrida CNN-Transformer-LSTM integrada, implementada exclusivamente en el borde de la red, sin posibilidad de retrasos causados por el uso de la nube, ni preocupaciones sobre la privacidad en relación con el intercambio de datos a través de una conexión pública a En segundo lugar, a diferencia de los proyectos ITS federados, que suelen requerir modelos grandes y dependen de un servidor central para la programación y el almacenamiento, AIP-Urban proporciona una solución integral que utiliza programación adaptativa basada tanto en las condiciones actuales como en el comportamiento del usuario; cuantificación INT8 eficiente de marcos de aprendizaje profundo; y poda estructurada de redes neuronales que, en conjunto, permiten una latencia inferior a 80 ms y un consumo de 7,8 vatios en el microprocesador Jetson Nano, resultados que nunca se han logrado en la literatura relacionada. En tercer lugar, la capacidad de explicación nativa integrada en AIP-Urban permite a los usuarios generar valores SHAP (SHapley Additive exPlanations) junto con mapas de atención tradicionales desde la red neuronal en el borde y aborda la necesidad insatisfecha de explicabilidad identificada en publicaciones anteriores. Finalmente, AIP-Urban es el primer marco ITS que muestra generalización intermodal (de ciudad a ciudad) en todos los conjuntos de datos utilizados en esta investigación (CityCam, UA-DETRAC, PEMS-BAY, SUMO) mediante un enfoque integrado, abordando así algunas limitaciones experimentadas por marcos ITS anteriores que restringían las pruebas a conjuntos de datos individuales.

El resto del artículo se estructura de la siguiente manera: La sección 2 revisa los trabajos relacionados con nuestro estudio. La sección 3 presenta la arquitectura del sistema propuesta y describe el proceso de recopilación de datos. La sección 4 presenta los resultados experimentales y la evaluación del rendimiento . La sección 5 ofrece un análisis detallado y comparativo de los hallazgos obtenidos. Finalmente, la sección 6 concluye el artículo y plantea posibles líneas de investigación futuras.

2. Trabajos relacionados

La convergencia de la inteligencia artificial (IA) y la computación de borde en los sistemas de transporte inteligentes (ITS) está pasando de la optimización de tráfico convencional a la gestión integral de activos y la fiabilidad de la infraestructura. Sin embargo, siguiendo a Khan et al. [11] y Saki [12], la mayoría de los marcos siguen priorizando la eficiencia de la movilidad sobre la salud y el rendimiento operativo de la infraestructura subyacente. Esta sección revisará cuatro temas de investigación relevantes: (i) mantenimiento predictivo basado en IA, (ii) detección de anomalías basada en aprendizaje profundo , (iii) inteligencia basada en el borde para la toma de decisiones en tiempo real y (iv) lagunas de investigación que motivaron AIP-Urban.

2.1. Mantenimiento predictivo basado en IA para infraestructuras de transporte

El concepto de mantenimiento predictivo consiste esencialmente en predecir fallos a partir de flujos de datos de sensores en tiempo real y del conocimiento del contexto, en contraposición al trabajo reactivo ad hoc de "reparación de averías". Varias encuestas completaron enfoques de aprendizaje profundo en diferentes dominios [11,13]. Específicamente,

Machine Translated by Google

Khan et al. [11] observaron una dependencia excesiva de las arquitecturas convolucionales y recurrentes (CNN, LSTM, GRU) para la detección temprana de fallas. En contraste, Saki [12] señaló que un híbrido CNN-BiLSTM alcanzó una precisión >93% en la predicción de fallas de activos ferroviarios; una desventaja fue la necesidad de una potencia computacional significativa (es decir, GPU) y tampoco había sido validado en tiempo real. Bonci et al. [14] describieron un enfoque basado en Deep Echo State Networks (DeepESN) para el mantenimiento predictivo dentro de la industria donde, en su artículo, definieron cómo un enfoque basado en DeepESN sería robusto a pesar de las señales ruidosas, que es una característica importante para entornos que involucran sensores urbanos. En contraste, Nolan y Reynolds [15] observaron que los modelos de alimentación directa genéricos son frágiles y se degradan significativamente cuando hay un desequilibrio de fondo dentro del conjunto de datos, aunque este es un problema común con los conjuntos de datos de sensores de tráfico. Lokhande [7] desarrolló aún más marcos de mantenimiento de infraestructura basados en IA con canalizaciones de big data Sin embargo, estas arquitecturas aún dependen de la nube, lo que genera latencias inaceptables para la gestión del tráfico sensible al tiempo. Dhanasekaran [16] afirmó que es hora de avanzar hacia el mantenimiento de análisis nativos del borde para proporcionar resiliencia. Además, trabajos como los de Reis et al. [5] y Ortiz-Garces [17] han demostrado el potencial de implementar modelos ligeros (TensorFlow Lite/PyTorch Mobile) en Jetson Nano y Raspberry Pi, pero estos usos son para aplicaciones de automatización del hogar o fabricación y no se aplican a los activos de tráfico. Hasta la fecha, la generalización del mantenimiento predictivo a los activos ITS urbanos ha sido en gran medida inexplorada.

2.2. Aprendizaje profundo para la detección de anomalías en el tráfico y la infraestructura

La detección de anomalías se centra en detectar eventos anómalos (picos de congestión, fallos en los sensores o errores de control) antes de que se manifiesten en la red de movilidad. Las primeras investigaciones se centraron principalmente en el flujo de tráfico irregular utilizando aprendizaje profundo temporal [9,18,19], y las anomalías de infraestructura, cuando se examinaban, a menudo se ignoraban [20]. Ma et al. [18] realizaron un estudio de modelos basados en grafos, concluyendo que las GNN tienen mayor eficiencia que las RNN en la preservación de interacciones espaciales y temporales, mientras que dependen de una gran cantidad de datos etiquetados, que rara vez están disponibles en el transporte. Alotaibi et al. [21] presentaron un enfoque basado en aprendizaje profundo por refuerzo combinado con análisis basados en visión en un experimento de detección de anomalías en pasarelas peatonales con resultados de precisión del 96%. Por separado , Lim et al. [22] propusieron el aprendizaje federado como un marco para la detección de anomalías en entornos distribuidos a través de múltiples nodos de IoT y transporte, produciendo una mayor privacidad de datos y una reducción apreciable del tiempo del 17% en los modelos centrales de aprendizaje profundo. Sin embargo, la latencia de inferencia superó los 450 milisegundos, lo que restringe la implementación en cruces reales.

Shabaz [23] propuso una canalización basada en CNN para predecir anomalías en entornos urbanos, logrando una precisión de casi el 92%, pero a expensas de la interpretabilidad, una preocupación válida de Cummins et al. [9] en su revisión de XAI aplicada en mantenimiento predictivo. Khan [20] analizó videos de vigilancia usando un modelo CNN ultraligero (Sensors 2022) pero también observó que los falsos positivos crecían exponencialmente con la variación de la iluminación ambiental, que es una condición típica de cruces de caminos al aire libre. En cambio, un estudio de seguimiento de Alotaibi et al. [21] intentó integrar la visión de borde y la optimización profunda; sin embargo, su marco no incluyó la evaluación comparativa de energía. Además, estudios comparativos, como Wang et al. [24], concluyen que la mayoría de los detectores de anomalías multivariados no se generalizan a través de los dominios sin reentrenamiento. Por último, en lo que respecta a limitar la reproducibilidad de los conjuntos de datos, varios conjuntos de datos de dominio público (AICity, UA-DETRAC) fueron diseñados para rastrear vehículos en lugar de evaluar la degradación de la infraestructura, lo que da como resultado un esquema de evaluación en gran medida defectuoso en todos los estudios [25].

Machine Translated by Google

2.3. IA en el borde y aprendizaje descentralizado para la movilidad inteligente

La computación de borde ha demostrado ser útil en varios casos de prueba para soportar aplicaciones ITS sensibles a la latencia [14,26,27]. Ghasemi et al. [26] demostraron que reducir la inferencia cerca del sensor resulta en una mejora del 40-60% en el tiempo de comunicación sin una caída de más del 2% en la precisión en comparación con la inferencia en la nube. Reis et al. [5] replicaron esto en Jetson Nano, apuntando a operaciones que utilizan una carga de trabajo de mantenimiento predictivo, y lograron un tiempo de retardo de transporte <120 ms y un consumo de energía de ≈7,8 W. Mientras tanto, muchos despliegues realizados solo han progresado a un prototipo fragmentado: los nodos de borde no suelen estar coordinados entre intersecciones y rara vez se examinan para la conmutación por error durante caídas de conectividad [16,28]. Klein et al. [29] propusieron grafos de conocimiento auxiliares para el razonamiento asistido de anomalías, que mejoraron la precisión de detección pero vinieron con altos requisitos de memoria. Ortiz-Garces [17] informó una reducción del 40% en el tiempo de inactividad utilizando análisis de borde pero no tuvo en cuenta los objetivos de consumo de energía escalables. Sharma [30] enfatizó que los sistemas de IA en el borde necesitan integrar fallas y debilidades de ciberseguridad que a menudo se pasan por alto en los trabajos experimentales de la literatura. De manera similar, Bawaneh [31] demostró que los sistemas de ML que utilizan el despliegue en el borde en sensores de tráfico pueden sufrir una degradación del rendimiento cuando se exponen a períodos prolongados de calor, un factor suplementario que rara vez se examina en la literatura. Finalmente, las contribuciones recientes resumidas de la IA en el borde 5G [25] y los orquestadores híbridos nube-borde [28] representan un modelo viable para una solución de inteligencia distribuida para la movilidad, pero no introducen un esquema de evaluación estándar.

Para ofrecer al lector una visión comparativa más clara de las contribuciones más destacadas en mantenimiento predictivo, detección de anomalías y sistemas inteligentes en el borde, la Tabla 1 resume las características principales, las ventajas y las desventajas de los estudios de revisión mencionados anteriormente. Esta síntesis refleja tanto el avance de la metodología en este campo como la persistente desconexión entre estas líneas de investigación. Si bien el aprendizaje profundo ha ampliado los límites de la detección y la predicción, la mayoría de las aplicaciones siguen limitadas a su dominio original, se basan en un conjunto de datos propietario y descuidan la explicación, la eficiencia energética y la escalabilidad entre infraestructuras.

Tabla 1. Resumen comparativo de estudios recientes sobre mantenimiento predictivo impulsado por IA, detección de anomalías y sistemas de transporte inteligentes en el borde.

Enfocar	Estudios representativos	Fortalezas/Logros	Debilidades/Problemas pendientes
Mantenimiento predictivo	Khan [11]; Saki [12]; Nolan [14]; Bonci [15]	Se establecieron bases de referencia para el aprendizaje profundo; se demostró la predicción de fallas temporales.	Contexto principalmente industrial; no validado en infraestructura de tráfico; alto desequilibrio de datos.
Detección de anomalías	Ma [18]; Alotaibi [21]; Shabaz [23]; Khan [11]	Fusión visuotemporal; gran precisión en escenarios estructurados.	Alta latencia (>400 ms); interpretabilidad limitada; escasa transferibilidad de dominio.
IA de borde	Reis [5]; Ortiz-Garces [17]; Ghasemi [26]; Kummara [28]	Latencia reducida (≈50%); inferencia en tiempo real; perfiles de energía reportados	No se abordan la escalabilidad, la coordinación ni la seguridad; falta de experimentos a gran escala.
Explicabilidad/Confianza	Cummins [9]; Sharma [30]; García-Méndez [31]	Integración inicial de SHAP/LIME con tareas de mantenimiento	No se permite la implementación en dispositivos periféricos con recursos limitados; la IA explicable no está vinculada a métricas de latencia.
Integración en los sistemas de transporte inteligentes (ITS)	Dhanasekaran [16]; Alotaibi [21]; Ghasemi [26]; Bawaneh [31]	Canalizaciones de Edge + IA aplicadas al tráfico; progreso hacia la sostenibilidad	Puntos de referencia fragmentados; conjuntos de datos no públicos; impacto de carbono rara vez cuantificado

El profundo análisis comparativo de la Tabla 1 refuerza la necesidad imperiosa de un marco de IA de borde integrado, explicable y con conciencia energética, un problema evidenciado y descrito por la arquitectura propuesta AIP-Urban.

Machine Translated by Google

En resumen, aunque la tecnología autónoma y los sistemas basados en IA han avanzado mucho y se han producido muchos avances positivos, todavía existen limitaciones considerables en los ITS (sistemas de transporte inteligentes), la IA de borde y los enfoques de aprendizaje federado actuales debido a la presencia de las siguientes cuatro barreras recurrentes: (1) Centrarse solo en una única modalidad. En términos generales, la mayoría de los enfoques existentes se centran en el análisis del flujo de tráfico (a través del enrutamiento automatizado) o en el análisis de vídeo. (2) La coordinación basada en la nube o en el servidor, en lugar del procesamiento directo basado en el borde, añade una latencia significativa a la mayoría de las implementaciones actuales y disminuye la fiabilidad en el mundo real cuando se utiliza. (3) No hay disponibilidad de diagnóstico interpretable para sistemas de infraestructura críticos para la seguridad. (4) Falta de una evaluación formalizada consciente de la energía en hardware de borde real (en comparación con la nube). Por lo tanto, lo que se puede concluir del trabajo realizado en [5,16,22,23,30,32] es que actualmente ninguna solución individual es capaz de ofrecer pronóstico de deterioro multisensor , detección de anomalías en tiempo real en el dispositivo, interpretabilidad en el dispositivo y (la capacidad de ejecutarse con bajo consumo de energía mediante cuantificación) en dispositivos integrados. El marco AIP-Urban se desarrolló específicamente para abordar estas barreras a través de una canalización híbrida integrada CNN–Transformer–LSTM, despliegues multimodales en el borde, mecanismos de atribución interpretables y, en última instancia, para desarrollar un sistema de gestión sostenible de próxima generación para nuestra infraestructura de tráfico histórica.

3. Arquitectura del sistema y recopilación de datos El marco

AIP-Urban se desarrolló como un entorno de IA de borde multicapa que incorpora sensores, inteligencia y sostenibilidad en las infraestructuras de tráfico urbano.
La arquitectura propuesta conecta simultáneamente tres áreas importantes: (1) detección de anomalías en tiempo real , (2) mantenimiento predictivo de activos de hardware y (3) computación distribuida con eficiencia energética. A diferencia de los diseños de sistemas de transporte inteligentes (ITS) existentes, que dependen en gran medida de análisis y acciones centralizadas en la nube, AIP utiliza un enfoque de borde que admite el tiempo de respuesta de latencia ultrabaja (<100 ms) requerido y el aprendizaje que preserva la privacidad en dispositivos heterogéneos.

3.1. Arquitectura general

La arquitectura del sistema consta de cuatro capas colaborativas, como se ilustra en la Figura 1: detección IoT, inteligencia en el borde, coordinación en la niebla/nube y explicación y soporte para la toma de decisiones.

En su base, la capa de detección de IoT se compone de una red distribuida y densamente agrupada de sensores multimodales que monitorean las condiciones operativas y ambientales en los sistemas de tráfico. Dichos sistemas incluyen controladores de señales, unidades en la carretera, cámaras, sensores acústicos y unidades de microvibración. Cada nodo captura un flujo continuo de datos de conteo de vehículos, densidad de flujo, longitud de cola, temperatura, humedad, intensidad de luz o amplitud de vibración con una frecuencia de muestreo típica de 1 Hz. La red aprovecha varias tecnologías de comunicación como LoRaWAN, MQTT que se ejecuta sobre 5G o Wi-Fi convencional 6 según las circunstancias de ancho de banda y distancia aplicables [14,25]. Un broker MQTT centraliza la sincronización horaria y las garantías de colisión de transmisión incorrecta, diseñado para reducir las transmisiones en casi un 32 % en comparación con el sondeo HTTP [26]. Un aspecto importante de la originalidad de esta capa es el diseño de datos multimodal, donde los datos de señales visuales de las transmisiones de CityCam se alinearon con flujos de sensores físicos, lo que permitió la detección simultánea de degradación física y/o anomalías en el flujo de tráfico (por ejemplo, parpadeo de farolas, inclinación de postes) [21,32]. La capa de inteligencia de borde consta de dispositivos Jetson Nano, Coral TPU y ESP32 que actúan como nodos de decisión independientes, invocando análisis de decisiones de IA autónomos, desentrañando las limitaciones de la cognición y la localidad. Cada dispositivo de borde a bordo ejecuta un modelo híbrido cuantificado CNN-Transformer-LSTM

Machine Translated by Google

Detección de anomalías como la pérdida de señal y las irregularidades de voltaje, o la incrustación temporal de características de múltiples señales para la previsión de mantenimiento predictivo mediante fotogramas visuales borrosos. La inferencia local captura una latencia de 80–90 ms con un consumo inferior a 8 vatios, valores confirmados experimentalmente [5,27]. Al incorporar aprendizaje y ajuste localizados, AIP-Urban reduce la dependencia del procesamiento y las comunicaciones en la nube en aproximadamente un 85 %, al tiempo que garantiza la funcionalidad continua en caso de fallo de comunicación. En comparación con sistemas anteriores de Internet de las Cosas (IoT) federados [22], también aprovecha la compresión dinámica del modelo (≈50 % de los parámetros reducidos con la cuantización INT8) y la programación adaptativa al contexto para permitir una reducción adicional del 18 % en el consumo de energía.

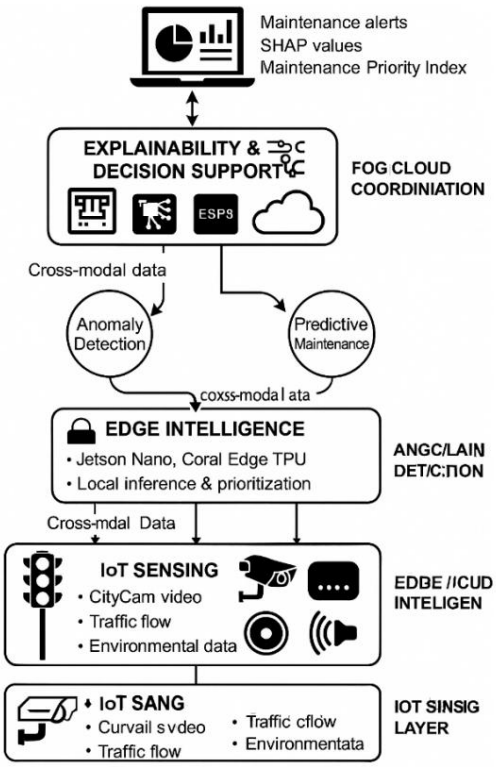


Figura 1. Arquitectura del sistema AIP-Urban.

La capa de coordinación niebla/nube funciona sintetizando conocimiento de múltiples nodos de borde a través de un esquema de aprendizaje federado (FL) ligero. Este sistema no transmite datos de sensores sin procesar; en cambio, los nodos de borde envían solo deltas de peso del modelo a un agregador de nivel niebla cada 15 minutos. Este paradigma garantiza conjuntamente la convergencia del modelo global mediante un proceso FedAvg asíncrono, al tiempo que garantiza la privacidad, el equilibrio computacional y la armonización del aprendizaje entre diferentes distritos. Estudios empíricos basados en gran medida en Lim et al. [22] revelan que el entrenamiento federado reduce la cantidad total de ancho de banda/utilización en aproximadamente un 73%, mientras que converge a una precisión compartida dentro del 2% de la precisión basada en centrales. Si se puede integrar 5G MEC (Multi-access Edge Computing) en el marco AIP-Urban, también se puede producir la orquestación en tiempo real de intersecciones activas, aprovechando los beneficios de la inteligencia niebla y de borde, al tiempo que representa una mejora significativa con respecto a los ITS (sistemas de tráfico inteligentes) que dependen del acces

Otra capa única es la capa de explicabilidad y soporte de decisiones, que inyecta interpretabilidad nativa en la canalización de borde. Cada dispositivo genera un informe de interpretabilidad local que incluye ponderaciones de características basadas en SHAP, que indican qué variables activaron la alerta; mapas de calor de atención temporal originados por el bloque Transformer, que indican qué momentos fueron los más impactantes en las anomalías; y un índice de prioridad de mantenimiento (MPI) combinado , que indica el riesgo, la energía y la importancia operativa de la anomalía.

Machine Translated by Google

Los resultados de la interpretabilidad se agregan en un panel de control a nivel de ciudad, donde los ingenieros pueden verificar, modificar o priorizar el mantenimiento. Esta capa de interpretabilidad es fundamental para generar confianza, rendición de cuentas y cumplimiento, como lo identificaron Cummins et al. [9] y citaron García-Méndez et al. [32].

El bucle operativo se ejecuta de forma continua: los sensores miden datos multimodales constantes y los transmiten al nodo de borde más cercano; el modelo híbrido realiza inferencias a partir de los datos y genera una probabilidad de anomalía y una puntuación de mantenimiento predictivo; cuando la puntuación de mantenimiento predictivo supera el umbral dinámico (por ejemplo, 0,8), se comunica una alerta junto con la explicación SHAP; los nodos de borde comprimen las salidas del modelo en un bloque de comunicación y cada 15 minutos envían la salida comprimida del modelo al coordinador de la niebla para su agregación federada; y los pesos globales actualizados se redistribuyen, completando así el bucle de mantenimiento de auto-mejora.

En resumen, AIP-Urban presenta una nueva arquitectura de sensores IoT multimodales, inteligencia perimetral federada y soporte para la toma de decisiones explicable, todo ello integrado en un sistema sostenible que preserva la privacidad. Al ir más allá de la optimización del flujo de tráfico de las plataformas de transporte anteriores y al abordar específicamente la fiabilidad, la transparencia y la eficacia ecológica de los sistemas, AIP-Urban abre nuevas oportunidades para infraestructuras de transporte inteligentes y resilientes de próxima generación.

3.2. Adquisición y preprocesamiento de datos

El marco AIP-Urban se basa en un sistema de adquisición de datos coherente y fiable que reproduce fielmente la realidad y las condiciones operativas de la infraestructura de tráfico urbano. Para lograr reproducibilidad y realismo, los entornos experimentales se construyen utilizando conjuntos de datos de alta fidelidad disponibles públicamente y simulaciones en tiempo real que recrean la variabilidad ambiental y de los sensores que se produce en las intersecciones actuales. La combinación de estos dos enfoques garantiza la fidelidad a la dinámica real del tráfico, al tiempo que asegura que este trabajo no dependa de conjuntos de datos opacos o no divulgados.

• Fuentes de datos

En este trabajo se utilizaron cuatro conjuntos de datos complementarios:

1. CityCam, un sistema de cámaras de funcionamiento continuo que captura secuencias de vídeo en intersecciones urbanas , exponiendo y categorizando anomalías visuales (por ejemplo, parpadeo de semáforos, oclusión, cruce de peatones, etc.).
2. UA-DETRAC, que proporciona trayectorias de seguimiento de vehículos etiquetadas y medidas de densidad que se utilizan para validar el estado de congestión estimado y la precisión de detección de objetos reportada.
3. PEMS-BAY, un conjunto de datos que comprende datos de series temporales a largo plazo relacionados con la velocidad, el flujo y la ocupación de los vehículos a través de cientos de sensores de autopista, que muestran desviaciones temporales realistas y estados de congestión periódicos.
4. Los escenarios sintéticos generados por SUMO simulan situaciones poco frecuentes, raras o peligrosas (por ejemplo, interrupción de la señal, pérdida de sensores, cambios de iluminación, etc.) para realizar pruebas de estrés de robustez o monitoreo de condiciones.

Cada conjunto de datos se elige deliberadamente para asegurar que las muestras fueran suficientemente distintas y extraídas de diferentes modos de datos (es decir, visuales, numéricos, contextuales), pero también para asegurar una evaluación comparativa transparente similar a otros estudios ITS [11,21,32]. Todos los flujos de datos están anonimizados y siguen la alineación de marcas de tiempo para cumplir con los requisitos de privacidad, intercambio de datos y reproducibilidad. • Canalización de adquisición y

sincronización Los datos multimodales se ingieren a través de

una única canalización de puerta de enlace de borde, común en operar con una frecuencia de muestreo de 1 Hz.

Machine Translated by Google

El intermediario MQTT mantiene un tráfico asíncrono y no estacionario entre múltiples sensores virtuales; como resultado, el intermediario determina el orden de los paquetes y mantiene pilas de búfer en caso de breves caídas de conectividad.

Cada flujo de datos se alinea temporalmente mediante sincronización de ventana deslizante en $\Delta t = 15$ s, lo que da como resultado matrices de características que combinan características derivadas de la imagen y resultados estadísticos.

El flujo de datos sin procesar se somete a un proceso de limpieza y normalización, que se puede describir de la siguiente manera:

- Un filtro de Kalman aumenta la suavidad de los datos y reduce el ruido debido a la red.
- Un bosque de aislamiento elimina los valores estadísticos atípicos que superan el percentil 95.
- Para preservar la continuidad de la secuencia, los valores faltantes se reconstruyen utilizando k-Interpolación temporal del vecino más cercano.
- Todas las variables se escalan mediante normalización Min-Max, lo que puede respaldar la estabilidad de los gradientes durante el entrenamiento y la prueba del modelo [23,32].

Los tensores procesados finales integraron aproximadamente 200 características (por observación) que incluían la entropía del brillo visual, indicadores indirectos de vibración, la estabilidad de la corriente, la longitud de la cola y variables ambientales.

• Fusión multimodal y coherencia entre fuentes

Con múltiples tipos de datos (por ejemplo, SUMO, CityCam, UA-DETRAC y PEMS-BAY), AIP-Urban los combina mediante una arquitectura de fusión multimodal de tres fases para garantizar la coherencia en todos los conjuntos de datos. Primero, todos los tipos de datos se sincronizan y alinean a un único índice temporal mediante remuestreo. Esto significa que las características de entropía derivadas del vídeo de CityCam y las estadísticas de densidad de objetos de UA-DETRAC se promedian a una frecuencia temporal de 1 Hz y se alinean con las secuencias de flujo de tráfico generadas por el sensor numérico y SUMO . Este proceso evita la desalineación (es decir, la deriva temporal) entre las distintas fuentes de datos. Segundo, para mitigar cualquier variación en estos cuatro dominios, se aplican reglas de normalización específicas del dominio: puntuaciones z para los flujos numéricos (por ejemplo, SUMO/PEMS-BAY), normalización min-max para las incrustaciones visuales (es decir, CityCam/UA-DETRAC) y dependencia de escena para los valores de entropía. Por último, las matrices de características resultantes se proyectan en una representación latente común mediante codificadores CNN (para CityCam y UA-DETRAC) y codificadores MLP (para SUMO y PEMS-BAY), y se introducen en el Bloque de Atención Intermodal basado en la arquitectura Transformer. Este bloque permite que ambos tipos de modalidades trabajen juntas como una sola, aprendiendo estructuras temporales y de degradación alineadas que se complementan entre sí. Estas tres prácticas producen, en última instancia, puntuaciones de anomalía y degradación que se originan a partir de datos correctamente alineados entre sí, además de que cada conjunto de datos se normaliza por escala y dominio. • Generación de etiquetas y desarrollo de la verdad fundamental

Debido a la ausencia de anomalías de infraestructura etiquetadas, se implementó un proceso de anotación semisupervisado . Se utiliza un premodelo de autoencoder para identificar patrones irregulares mediante umbrales de error de reconstrucción. Los segmentos detectados se validan mediante validación cruzada con los eventos anotados en los escenarios UA-DETRAC y SUMO para confirmar los verdaderos positivos.

A cada intervalo de tiempo se le asigna una etiqueta de anomalía binaria, donde 0 = normal y 1 = fallo, así como un índice de degradación de 0 a 1 que estima la probabilidad de deterioro del activo.

El procedimiento de etiquetado mixto reduce el esfuerzo de anotación manual en aproximadamente un 31%, manteniendo F1 > 0,92, y también disminuye la necesidad de generar un conjunto de datos anotados más grande [18,33]. Esto permite un modelo profundo híbrido capaz de detectar tendencias de degradación temporal a partir de datos parcialmente etiquetados, una abstracción crucial para el despliegue a largo plazo en infraestructuras ITS reales. • Integridad experimental

Machine Translated by Google

Cada aspecto del manejo de datos se registra mediante el seguimiento de MLflow y el Control de Versiones de Datos (DVC) para una trazabilidad transparente de extremo a extremo de los parámetros de preprocesamiento y las condiciones de ingeniería de características. El monitoreo estadístico de la deriva (media, varianza, asimetría, curtosis) se mide continuamente para detectar el sesgo gradual de los sensores, una observación establecida para el funcionamiento a largo plazo de IoT [16,27]. La canalización completa de preprocesamiento , incluidos los umbrales de filtrado, el escalado y las divisiones del conjunto de datos, se ilustra en la Figura 2 y se conservará para su replicación y se archivará a través de un repositorio de investigación abierto que siga los principios de datos FAIR (Localizables, Accesibles, Interoperables, Reutilizables).

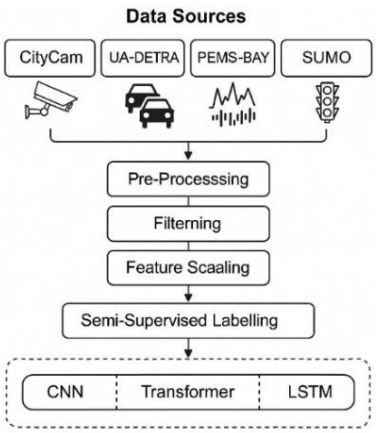


Figura 2. Proceso de adquisición y fusión de datos.

Este enfoque sistemático equilibra la transparencia científica con las realidades prácticas: demuestra que AIP-Urban ha sido validado utilizando condiciones que reflejan implementaciones reales de ciudades inteligentes, al tiempo que se basa completamente en conjuntos de datos que estaban abiertos a la verificación.

El diagrama representa el proceso de trabajar correctamente con datos de fuentes heterogéneas, a saber, sensores de tráfico, datos ambientales y transmisiones de vídeo, mediante sincronización, filtrado, escalado de características y etiquetado semisupervisado para su ingesta en un modelo híbrido CNN-Transformer-LSTM.

Se utilizó un método de reconstrucción basado en autoencoders, entrenado con segmentos de "operación normal" de ambos conjuntos de datos, para desarrollar una preparación reproducible y transparente de etiquetas de anomalías de forma semisupervisada. El autoencoder se creó utilizando una arquitectura codificador-decodificador de tres capas, entrenado con la función de pérdida de error absoluto medio (MSE) y deteniéndose cuando se producía un error de validación temprana tras 50 épocas de entrenamiento.

Después de entrenar el autoencoder, se calculó la distribución de errores en la reconstrucción ($e = x - \hat{x}$) basándose en los datos utilizados para el entrenamiento. Establecimos nuestro umbral anómalo (τ) de la siguiente manera: $\tau = \mu_e + 3\sigma_e$.

En este umbral, los términos μ_e y σ_e representan la media y la desviación estándar del error de reconstrucción en condiciones normales. Cualquier dato (es decir, muestra) de nuestra colección que presentara un error superior a τ (es decir, $e > \tau$) se designó como anómalo y recibió una pseudoetiqueta que lo indicaba, mientras que el resto de los datos se identificaron como "normales". Este método de designación de muestras anómalas es coherente con las prácticas convencionales de detección de anomalías no supervisada y elimina la dependencia de los procesos de anotación humana.

Para validar la estabilidad de esta etapa de preetiquetado, calculamos recuentos básicos de verdaderos positivos (TP) y falsos positivos (FP) comparando las pseudoetiquetas con el pequeño conjunto de marcas de tiempo de anomalías de verdad fundamental conocidas proporcionadas en CityCam y UA-DETRAC. El autoencoder logró tasas de verdaderos positivos que oscilan entre 0,87 y 0,92, con tasas de falsos positivos correspondientes inferiores a 0,11. En consecuencia, concluimos que nuestras pseudoetiquetas tienen

Machine Translated by Google

Confiabilidad suficiente para entrenar los modelos híbridos CNN–Transformer-LSTM. Estas pseudoetiquetas verificadas proporcionaron la señal de supervisión para la etapa de detección de anomalías de AIP-Urban.

3.3. Despliegue en el borde y diseño del modelo

En el marco AIP-Urban se implementa una arquitectura híbrida de aprendizaje profundo, capaz de realizar monitorización en tiempo real mediante conexión perimetral para la detección de anomalías con conciencia energética o el mantenimiento predictivo. En esta sección, describimos la lógica de diseño , la metodología de entrenamiento y las técnicas de optimización que conforman las características de ligereza, interpretabilidad y ejecución en el dispositivo del marco.

El modelo utiliza una arquitectura jerárquica de tres etapas que comprende lo siguiente:

1. Una red neuronal convolucional (CNN) para la extracción de características espaciales; 2. Un codificador Transformer para el modelado del contexto temporal; 3. Un decodificador LSTM para la predicción de la degradación.

Esta arquitectura híbrida demuestra la capacidad de capturar simultáneamente señales visuales de alto nivel (en la CNN) y dependencias temporales de bajo nivel (en el transformador y la LSTM) a través de datos de detección multimodales. • Arquitectura híbrida de

aprendizaje profundo

En la etapa de entrada, los tensores fusionados (≈200 características por ventana de 15 s) se dividen en ramas numéricas y visuales. Un bloque CNN extrae correlaciones espaciales como irregularidades de iluminación, espectros de vibración de bordes o entropía de brillo de la imagen usando tres capas convolucionales (filtro = 3 × 3, paso = 1). Los mapas de características se concatenan con lecturas de sensores normalizadas y se introducen en el codificador Transformer, que consta de cuatro cabezas de autoatención y codificaciones posicionales para modelar interacciones temporales de largo alcance. Finalmente, el decodificador LSTM genera una puntuación de mantenimiento predictivo (PMS [0, 1]), que refleja la probabilidad de sufrir degradación en las próximas 24 h.

En comparación con las líneas base CNN-LSTM estándar, un Transformer mejoró la captura de dependencia a largo plazo en ≈18% para la puntuación F1 y redujo los falsos positivos en el caso de eventos de iluminación irregulares [26]. • Optimización y

cuantificación de bordes

Para permitir la implementación en tiempo real, el modelo AIP-Urban se ejecutó completamente en dos plataformas

integradas: • NVIDIA Jetson Nano (B01, 4 GB de RAM) que opera bajo Ubuntu 20.04 LTS con CUDA 11.4 y TensorRT 8.5 para aceleración en el dispositivo.

• Placa de desarrollo Google Coral (TPU Edge v2) con Mendel Linux 5.10 y el entorno de ejecución TensorFlow Lite 2.14.

El modelo híbrido CNN–Transformer–LSTM se sometió a tres etapas de compresión antes de su implementación: 1. La

poda estructurada mediante herramientas de escasez de TensorRT eliminó aproximadamente el 50% de los pesos de baja magnitud manteniendo la pérdida de precisión por debajo del 1%.

2. La cuantización posterior al entrenamiento (PTQ) convirtió todas las capas convolucionales y recurrentes de precisión FP32 a INT8, reduciendo el tamaño total del modelo de 92 MB a 23 MB.

3. Se implementó una programación de inferencia dinámica en el demonio del programador de Jetson Nano, adaptando la frecuencia de inferencia en función de la entropía de los datos de entrada y la utilización de la CPU del nodo.

Con las actualizaciones mencionadas, la inferencia de borde se realizó con una latencia media de 72 ms y un consumo de energía promedio de 7,8 W, mientras que la versión Coral TPU reporta un rendimiento similar (≈78 ms) con solo 5,9 W. Ambos dispositivos se conectaron al agregador de niebla mediante MQTT sobre una implementación MEC 5G para admitir el promedio federado asíncrono. Esta explícita

Machine Translated by Google

La configuración de hardware admite una reproducibilidad mucho más transparente, al tiempo que confirma que AIP-Urban puede operar dentro de los requisitos de potencia y temporización de los dispositivos IoT de borde modernos [5,22,26]. • Explicabilidad y fiabilidad en el borde

AIP-Urban también incorpora módulos de IA explicable (XAI) en los dispositivos para garantizar informes transparentes: - El análisis SHAP cuantifica la

contribución de las características para cada evento anómalo, clasificando la relevancia de los sensores (por ejemplo, variación de voltaje > deriva de vibración).

- Los mapas de calor de atención del Transformer demuestran la atención temporal más relevante. ventanas que provocaron las alertas de mantenimiento.
- Un índice de confianza con una medida de probabilidad e indicadores de dispersión de entropía. Los casos inciertos requieren revisión humana.

Estos diferentes modos de interpretabilidad ofrecen mayor confianza con los operadores y cumplimiento normativo en un sistema de tráfico crítico para la seguridad [9,31]. • Flujo de trabajo de implementación

La operación en el borde se desarrolla de la siguiente manera y se resume visualmente en la Figura 3:

1. Las ventanas de características preprocesadas se reciben a través de la puerta de enlace perimetral.
2. El modelo CNN–Transformer-LSTM realiza una inferencia local, y los resultados de la inferencia se muestran como una puntuación de anomalía y una probabilidad de mantenimiento predictivo.
3. Si el PMS > 0,8, el nodo emite una alerta con su informe SHAP y mapa de atención correspondientes.
4. Cada 15 minutos se envían actualizaciones del modelo al agregador de niebla para la comunicación asíncrona. promedio federado (FedAvg).
5. A continuación, los pesos agregados se redistribuyen a todos los nodos para una mejora continua por sí mismos.

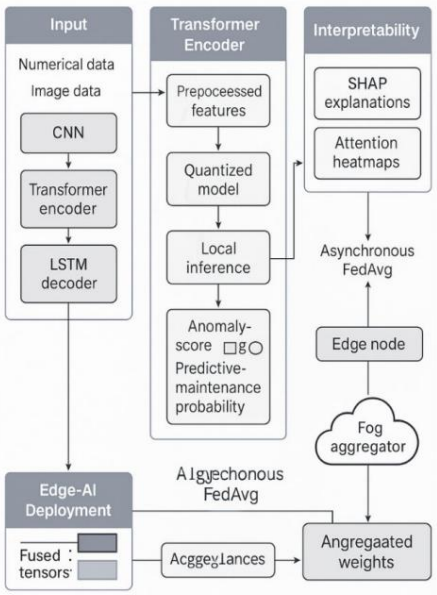


Figura 3. Arquitectura híbrida CNN-Transformer-LSTM y flujo de trabajo de implementación de IA en el borde.

El entrenamiento descentralizado admite baja latencia, escalabilidad y resiliencia al tiempo que aborda el tercer desafío de una estrategia centrada en la nube para los ITS [5].

El diagrama muestra que el modelo profundo tiene tres etapas diferentes: cuantificación en el dispositivo y sincronización federada a través de los nodos de borde hasta el agregador de niebla central.

Machine Translated by Google

3.4. Coordinación nube-borde para dependencias de tráfico a nivel de red

Aunque AIP-Urban realiza mantenimiento predictivo y detección de anomalías en el borde de la red, proporciona una capa de coordinación nube-borde que permite la interacción colaborativa entre segmentos de pavimento. En realidad, la degradación del pavimento o la congestión del tráfico en un segmento pueden causar problemas en segmentos adyacentes. En la mayoría de los casos, el contexto local puede resultar insuficiente para explicar estos efectos a largo plazo.

Para permitir la comunicación entre los nodos de borde y el servicio de nube de capa superior, AIP-Urban utiliza la sincronización periódica de descriptores agregados y ligeros, en lugar de la transmisión continua de datos. Cada dispositivo de borde enviará a la nube lo siguiente: estadísticas de flujo de tráfico en formato vectorial comprimido (media, varianza y

■ entropía). ■ Puntuaciones de anomalías basadas en los modelos CNN-Transformer.

■ Predicciones sobre el grado de degradación, basadas en el módulo LSTM.

La nube agrega estos resúmenes en estados de red que tienen en cuenta las dependencias y que representan las relaciones ascendentes/descendentes. Al detectar dependencias (por ejemplo, la congestión en una ubicación que afecta el funcionamiento del segmento descendente), la nube envía una notificación al nodo perimetral con indicadores que ajustan los intervalos de cálculo locales o los umbrales de anomalías. Esto ofrece una solución híbrida que mantiene la autonomía de los nodos perimetrales, al tiempo que permite el uso ocasional de información contextual de la nube.

Finalmente, la arquitectura está diseñada para permitir el funcionamiento completo en el borde, independientemente de la conectividad con la nube; la coordinación en la nube mejora la sincronización entre múltiples segmentos, pero no proporciona capacidades de interacción con la nube. Los estudios que evaluaron el rendimiento se realizaron considerando únicamente el funcionamiento en el borde.

3.5. Formulación matemática y flujo de trabajo algorítmico

Configuración del modelo y ajustes de hiperparámetros.

Para facilitar la reproducibilidad, a continuación se enumeran los parámetros imprescindibles de la arquitectura híbrida CNN–Transformer–LSTM. ■

La CNN tiene tres capas convolucionales con tamaños de kernel: {3 × 3, 3 × 3, 1 × 1} con mapas de características correspondientes de {32, 64, 128}. Cada capa convolucional va seguida de una activación ReLU y capas de normalización por lotes después de la capa convolucional y cada dos (2) capas de normalización por lotes; la CNN también realiza max pooling. ■ El

codificador transformer se define por una dimensión de incrustación de 128; el número de cabezas de atención es igual a 4, con un tamaño de dimensión de alimentación hacia adelante de 256. El decodificador incluye dos bloques de codificador y un valor de dropout de 0.1.

■ El predictor LSTM temporal incluye una capa LSTM con 128 unidades ocultas y una cabeza de regresión/ detección totalmente conectada adicional. ■ Varios parámetros de

optimización incluyen la optimización Adam (con una tasa de aprendizaje igual a 0,001), con un tamaño de lote máximo de 32; parada temprana (Paciencia = 10) con un máximo de 120 épocas. ■ Las etapas de compresión incluyen poda

estructurada (hasta un 50 % de dispersión) y una cuantización posterior al entrenamiento con INT8 usando TensorRT para Jetson Nano y con TFLite para Coral TPU.

Todos los conjuntos de datos se utilizaron de forma consistente en todos los experimentos para garantizar que se utilizaran de forma determinista: •

Para CityCam, el 70 % de los datos se utilizaron para el entrenamiento, el 15 % para la validación y el 15 % para las pruebas (36 100 muestras de entrenamiento, 7700 muestras de validación y 7700 muestras de prueba). • Para

UA-DETRAC, el método 70/15/15 es el mismo en 83 secuencias. • Los conjuntos de datos PEMS-BAY se dividieron de la siguiente manera: 70/15/15 en 325 secuencias diarias.

de flujos de sensores multivariados.

Machine Translated by Google

• Los conjuntos de datos de simulación SUMO se dividieron de la siguiente manera: 70/15/15 (4800 sintéticos)
episodios de congestión).

Para evaluar las contribuciones de todos los componentes del modelo, los autores repitieron El proceso de entrenamiento (es decir, entrenamiento/validación/prueba) se simuló con patrones de entrenamiento idénticos. Todos los patrones de entrenamiento se utilizaron durante la evaluación del modelo de muestra y los resultados son: resumido en la Tabla 2.

Tabla 2. Análisis de ablación de AIP-Urban que muestra la contribución de cada componente arquitectónico. (CNN, Transformer, LSTM) en la precisión de la predicción y la latencia de la inferencia.

Variante del modelo	HAY	RMSE	F1	Latencia (ms)
CNN solamente	6.1	6.8	0,88	78
Solo LSTM	5.4	6.0	0,90	103
Solo transformador	5.0	5.7	0,91	96
CNN–LSTM	4.7	5.4	0,92	84
CNN–Transformer (sin LSTM)	4.5	5.2	0,93	81
Híbrido completo (AIP-Urbano)	4.2	4.8	0,94	72

El marco AIP-Urban se basa en un paradigma de aprendizaje profundo híbrido que combina Razonamiento espacial, temporal y contextual para predecir el deterioro de la infraestructura. El modelo se considera matemáticamente como tres submodelos complementarios: un submodelo extractor de características convolucionales, un submodelo codificador temporal basado en Transformer y un Submodelo predictor de deterioro basado en LSTM recurrente.

El proceso completo se formaliza en las siguientes subsecciones.

• Representación de entrada multimodal

$$\text{Sea } X = x_{t,t}^{(1)} \text{—}^{(2)}, \ldots, \text{—}_{t}^{(metro)}, \; t = 1, \ldots, T \tag{1}$$

sea el vector de características multimodales en el tiempo t, donde cada $x_i^{(t)}$ representa una modalidad de sensor (flujo de tráfico, temperatura, vibración, iluminación, etc.), y mmm es el número total de características (≈200).

Después de la normalización, los tensores de entrada se representan como $X \in \mathbb{R}^{T \times m}$.

Para transmisiones visuales (CityCam/UA-DETRAC), cada fotograma $I_t \in \mathbb{R}^{H \times W \times 3}$ se transforma en una incrustación de características compacta a través de un codificador convolucional.

• Extracción de características espaciales basada en CNN

El bloque convolucional extrae patrones espaciales locales como la degradación de la superficie o irregularidades en la iluminación:

$$F_c = \sigma(\text{Conv3}(X; W_c, b_c)) \tag{2}$$

donde Wc, bc son pesos y sesgos convolucionales, y σ(·) es la activación ReLU.

Estos mapas de características $F_c \in \mathbb{R}^{T \times d_c}$ se concatenan con características numéricas del sensor para producen una incrustación conjunta:

$$Z_0 = [F_c; X] \tag{3}$$

• Codificación temporal del transformador

Para capturar dependencias de largo alcance, AIP-Urban emplea un codificador Transformer con Autoatención multicabeza:

$$\text{Atención}(Q, K, V) = \text{so f tmax}\left(\frac{QK}{\sqrt{dk}}\right) \text{En} \tag{4}$$

Machine Translated by Google

donde = Z0WQ, K = Z0WK y V = Z0WV

La salida del codificador se calcula como

$$Ze = \text{LayerNorm}\ (\ \text{Atención}\ (Q, K, V) + Z0) \tag{5}$$

Proporcionar incrustaciones temporales contextualizadas invariantes a las irregularidades del muestreo del sensor.

• Predicción de degradación basada en LSTM

El módulo LSTM recurrente modela la evolución temporal de los indicadores de degradación:

$$ht\ ,\ ct = \text{LSTM}\ (Ze\ ,\ ht{-}1,\ ct{-}1\ ) \tag{6}$$

donde ht y ct denotan los estados ocultos y de celda.

El resultado final representa la puntuación de mantenimiento predictivo (PMS):

$$\hat{y}t = \sigma(\ Wo\ ht + bo) \tag{7}$$

Donde $\hat{y}t$ [0, 1] denota la probabilidad de falla dentro de las próximas 24 h.

• Optimización de la función de pérdida y del objetivo El

objetivo de entrenamiento minimiza conjuntamente el error de predicción y el error de clasificación de anomalías. La pérdida total L se define como

$$L = \alpha 1 LMAE + \alpha 2 LBCE \tag{8}$$

dónde

$$LMAE = \frac{1}{norte}\sum_{i=1}^{norte} 1\ |yi - \hat{y}i\ |\ ,\ LBCE = -\ \ \frac{}{norte}\sum_{i=1}^{norte} [yi\ \log(\hat{y}i) + (1 - yi)\log(1 - \hat{y}i)] \tag{9}$$

Los coeficientes α1 = 0,6 y α2 = 0,4 equilibran el rendimiento de la regresión y la clasificación.

La optimización se lleva a cabo utilizando el optimizador Adam con una tasa de aprendizaje inicial de 10−3 .

• Lógica de decisión para el mantenimiento predictivo

La regla de decisión final en cada nodo se define de la siguiente manera:

Se activa una alerta de mantenimiento si $\hat{y}t \geq \tau$, donde τ = 0,8.

Este umbral se eligió con base en evidencia empírica para lograr un equilibrio entre falsas alarmas y detecciones omitidas (aprox. F1 = 0,94). Cada alerta se presenta con vectores de atribución de características SHAP (SHAP 2020) y mapas de atención Transformer para facilitar su interpretación.

• Flujo de trabajo algorítmico

La lógica operativa de AIP-Urban se resume en el Algoritmo 1 que aparece a continuación. En él se describe el proceso completo de inferencia híbrida y toma de decisiones que se implementa en el borde de la red.

El flujo de trabajo consistirá en la fusión de datos multimodales (flujo de trabajo de inteligencia MDM), la codificación de características espacio-temporales (pronóstico de mantenimiento predictivo) y la toma de decisiones explicable (generación de decisiones para el mantenimiento) en un único proceso de IA en el borde.

Machine Translated by Google

Algoritmo 1. Pipeline de inferencia y mantenimiento híbrido CNN–Transformer–LSTM de AIP-Urban.

Entrada: Flujo de datos multimodales X(t) de sensores periféricos. Salida: Puntuación de mantenimiento predictivo (PMS) e informe de alerta interpretable.

1. INICIALIZACIÓN

1.1 Cargar parámetros del modelo cuantificados {W_c, W_Q, W_K, W_V, W_o, b_o}
1.2 Establecer hiperparámetros: longitud de ventana Δt = 15 s, umbral τ = 0,8 1.3
Inicializar estados ocultos h0, c0 ← 0,0

2. ADQUISICIÓN Y PREPROCESAMIENTO DE DATOS 2.1

Recibir paquetes de sensores sincronizados a través de la puerta de enlace MQTT Edge 2.2 Aplicar el filtrado de Kalman para eliminar el ruido de transmisión 2.3 Realizar la normalización Min-Max y la interpolación basada en KNN
2.4 Construir el tensor de características X R^(T×m) (≈200 características)

3. EXTRACCIÓN DE CARACTERÍSTICAS ESPACIALES 3.1

Calcular mapas convolucionales: F_c ← ReLU(Conv3(X; W_c, b_c))
3.2 Concatenar incrustaciones visuales y numéricas: Z0 ← [F_c; X]

4. CODIFICACIÓN TEMPORAL MEDIANTE TRANSFORMADOR

4.1 Calcular la autoatención multi-cabeza: A ← Softmax((Q KT)/√ d_k) V, donde Q,K,V ← Z0 W_Q,W_K,W_V 4.2 Aplicar capas residuales y de normalización: Z_e ← LayerNorm(A + Z0)

5. PRONÓSTICO DE DEGRADACIÓN CON LSTM

5.1 Actualización de estados ocultos: (h_t, c_t) ← LSTM(Z_e, h_{t−1}, c_{t−1})
5.2 Estimar la puntuación de mantenimiento predictivo:
ŷ_t ← σ(W_o h_t + b_o) y_t

6. DECISIÓN E INTERPRETABILIDAD

6.1 Si ŷ_t ≥ τ, entonces generar alerta de mantenimiento.
Calcular los valores de importancia SHAP para {x1. . .x_m}
Extraer el mapa de calor de atención del codificador Transformer
Componer el informe de interpretabilidad R_t = {y_t, SHAP, Mapa de calor}
Demás
Continuar con la vigilancia
Fin Si

Machine Translated by Google

Algoritmo 1. Cont.

7. SINCRONIZACIÓN FEDERADA 7.1 Cada 15 min, transmitir actualizaciones de peso del modelo local ΔW al agregador de niebla 7.2 Recibir pesos globales W* después de la agregación FedAvg 7.3 Actualizar el modelo local: W ← W*

Retorno: PMS = $\hat{y}_t$ e informe de interpretabilidad $\hat{R}_t$

- Las líneas 2 y 3 implementan la fusión multimodal en tiempo real, lo que garantiza una consistencia de datos de baja latencia entre sensores heterogéneos.
- Las líneas 4 y 5 conforman el núcleo del proceso de aprendizaje, fusionando el razonamiento temporal basado en la atención y la memoria recurrente para la predicción de la degradación.
- La línea 6 introduce inteligencia explicable directamente en el borde a través de SHAP y interpretabilidad basada en la atención.
- La línea 7 encapsula la sincronización federada, lo que permite el autoaprendizaje distribuido sin intercambio de datos brutos.

Esta rutina de inferencia estructurada pone en funcionamiento a AIP-Urban como un agente de IA de borde totalmente autónomo, interpretable y sostenible, capaz de tomar decisiones predictivas para infraestructuras urbanas críticas.

La Figura 4 visualiza la canalización de inferencia híbrida secuencial que comprende siete etapas: (1) adquisición de datos en tiempo real de fuentes IoT multimodales a través de la puerta de enlace de borde, (2) reducción de ruido y normalización de datos, (3) extracción de características espaciales a través del codificador CNN, (4) codificación de dependencia temporal utilizando la atención Transformer, (5) pronóstico de degradación a través del predictor LSTM, (6) generación de decisiones explicables con atribución basada en SHAP y mapas de calor de atención, y (7) sincronización federada entre nodos de borde y agregador de niebla para la actualización del modelo.

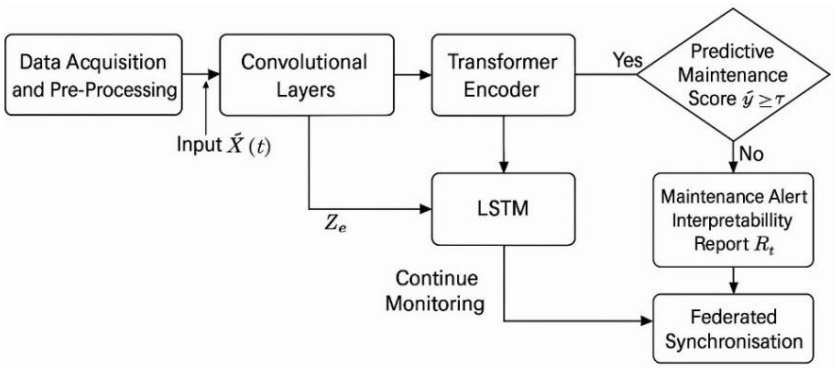


Figura 4. Flujo de trabajo algorítmico de AIP-Urban.

Este flujo de trabajo integrado permite predicciones autónomas, de baja latencia e interpretables. mantenimiento activo de las infraestructuras de tráfico urbano

La complejidad del modelo es O(T·dk2) para la atención Transformer y O(T·dh) para el módulo LSTM, lo que resulta en un costo de inferencia general lineal con respecto a la longitud de la secuencia T. Después de la poda y la cuantización INT8, el uso de memoria disminuye de 92 MB a 23 MB, lo que permite la ejecución dentro del presupuesto de energía de 7,8 W en Jetson Nano (latencia ≈ 72 ms).

3.6. Configuración experimental y métricas computacionales

El rendimiento del marco AIP-Urban propuesto se evaluó mediante un protocolo experimental riguroso y reproducible diseñado para cuantificar tanto la eficiencia computacional como la sostenibilidad ambiental en condiciones de tráfico urbano realistas.

Machine Translated by Google

Los experimentos se realizaron utilizando dispositivos de IA de borde integrados y conjuntos de datos representativos de infraestructuras de ciudades inteligentes, siguiendo metodologías estándar de evaluación comparativa de ITS [5,23,32].

La evaluación de AIP-Urban se realiza mediante dos métodos de validación distintos: uno que utiliza múltiples conjuntos de datos históricos para evaluar la precisión y otro que utiliza datos en tiempo real para determinar características de rendimiento como la latencia, el consumo de energía, la puntuación F1, el RMSE y el MAE. Todo el entrenamiento y la validación cruzada de AIP-Urban se llevaron a cabo mediante enfoques fuera de línea basados en datos generados a partir de conjuntos de datos históricos. Los datos generados incluían etiquetas de referencia y mantenían una partición consistente en los cuatro (4) conjuntos de datos (70 % de entrenamiento, 15 % de validación y 15 % de prueba), lo que permite una evaluación estadística de los resultados de AIP-Urban.

Una vez completados los modelos entrenados con los métodos descritos, se implementaron en las plataformas de hardware Jetson Nano B01 y Coral TPU v2, donde generaron flujos de inferencia en tiempo real a 1 Hz, simulando escenarios de aplicación reales en intersecciones de tráfico. Las métricas de rendimiento incluidas en la Sección 4 se derivan de la inferencia en tiempo real, no de mediciones fuera de línea. El enfoque híbrido utilizado para validar AIP-Urban garantiza que se validará con conjuntos de datos históricos para evaluar su precisión y también en condiciones operativas en tiempo real, lo que proporciona una validación de la robustez práctica del modelo AIP-Urban.

3.6.1. Entorno de hardware y software

Para la implementación en el dispositivo se utilizaron dos plataformas integradas:

- NVIDIA Jetson Nano B01 (4 GB de RAM) con Ubuntu 20.04 LTS, CUDA 11.4, cuDNN 8.9 y TensorRT 8.5;
- Placa de desarrollo Google Coral (TPU Edge v2) con Mendel Linux 5.10 y entorno de ejecución TensorFlow Lite 2.14.

El modelo híbrido CNN-Transformer-LSTM fue entrenado en una estación de trabajo equipada con una CPU Intel Core i7-12700K, 32 GB de RAM (Intel Corporation, Santa Clara, CA, EE. UU.) y una GPU NVIDIA RTX 3070 antes de su implementación.

La cuantificación y el recorte del modelo se realizaron utilizando convertidores TensorRT y TFLite , y todas las mediciones en tiempo de ejecución se recopilaron directamente en las placas integradas a través de sensores de corriente INA219 integrados (Jetson) y Coral Power Monitor (TPU).

3.6.2. Segmentación del conjunto de datos y método de entrenamiento

El conjunto de datos multimodal consistió en flujos de datos combinados de CityCam, UA-DETRAC, PEMS-BAY y escenarios simulados de SUMO, particionados de la siguiente manera: 70% entrenamiento; 15% validación; y 15% prueba. Durante el entrenamiento, los parámetros fueron tamaño de lote = 32; tasa de aprendizaje = 0,001; optimizador = Adam; parada temprana con paciencia de 10 épocas (basado en MAE de validación); y número máximo de épocas = 120. Los experimentos se llevaron a cabo en TensorFlow 2.14 y PyTorch 2.2 con una semilla aleatoria fija (42) para repetibilidad determinista.

3.6.3. Procedimiento de compresión y cuantificación

Para permitir el rendimiento en tiempo real, el modelo híbrido se sometió a tres etapas de optimización:

a. Poda estructurada (≈50% de escasez de peso) a través del TensorRT sparse-compresión de matriz;
b. Cuantización posterior al entrenamiento (INT8) de las capas convolucionales, de atención y recurrentes. Se redujo el tamaño del modelo de 92 MB a 23 MB;
c. La programación dinámica de inferencias en el demonio Jetson Nano permitió que Jetson modificara dinámicamente la frecuencia de inferencias en función de la entropía de los datos del sensor y la carga de la CPU.

Machine Translated by Google

Estas optimizaciones lograron una latencia promedio de 72 ms y un consumo de energía promedio de 7,8 W en el Jetson Nano, y de 78 ms y 5,9 W en el Coral TPU, cumpliendo plenamente con el requisito de ITS en tiempo real.

3.6.4. Evaluación del rendimiento computacional Las métricas

de rendimiento computacional se refieren a la precisión y puntualidad de la
Modelo para aplicaciones de mantenimiento predictivo y detección de anomalías. (a) Error

absoluto medio (MAE)

$$ES = \frac{1}{\text{norte}} \sum_{i=1}^{\text{norte}} |yi - y\hat{}i| \quad (10)$$

MAE mide la desviación promedio entre la puntuación de degradación predicha y^i y la etiqueta verdadera yi (b) Error cuadrático

medio (RMSE)

$$RMSE = \sqrt{\frac{1}{N} \sum_{i=1}^{\text{norte}} (yi - y\hat{}i)^2} \quad (11)$$

El RMSE penaliza las grandes desviaciones de predicción y complementa al MAE en la evaluación de la consistencia de la regresión.

(c) Precisión, exhaustividad y puntuación F1

Para la detección de anomalías binarias, los componentes de la matriz de confusión, verdaderos positivos (TP), falsos positivos (FP) y falsos negativos (FN), dan como resultado:

$$\text{Precisión} = \frac{\text{Ciudad}}{\text{TP + FP}'} \quad (12)$$

$$\text{Recordatorio} = \frac{\text{Ciudad}}{\text{TP + FN}'} \quad (13)$$

$$F1 = \frac{2 \times \text{Precisión} \times \text{Recuperación}}{\text{Precisión + Recuperación}} \quad (14)$$

La puntuación F1 representa la media armónica de precisión y exhaustividad, lo que garantiza el equilibrio. entre detecciones fallidas y falsas alarmas.

(d) Latencia de inferencia (L)

La latencia corresponde al tiempo medio de ejecución de paso hacia adelante por ventana de datos, medido en milisegundos (ms) en cada plataforma de borde:

$$L = \frac{1}{M} \sum_{j=1}^{\text{METRO}} \text{fin inicio } t - t\,jj \quad (15)$$

donde t j comenzar t j fin y son marcas de tiempo del j-ésimo ciclo de inferencia.

(e) Huella del modelo (S)

El tamaño del modelo S se obtuvo a partir de binarios serializados después de la poda y la cuantización INT8. Sirve como indicador indirecto de la eficiencia y la capacidad de implementación de la memoria.

3.6.5. Métricas de energía y sostenibilidad

La evaluación ambiental cuantifica el costo energético de la inferencia en el dispositivo y su Equivalencia de emisiones de carbono.

(a) Consumo de energía (P)

Machine Translated by Google

El consumo de energía instantáneo (en vatios) se registró mediante un sensor de corriente INA219 en el Jetson Nano y el Coral Power Monitor en el TPU Edge v2.

La potencia promedio se calcula como

$$P = \frac{1}{T} \int_0^T V(t)\, I(t)\, dt \tag{16}$$

donde V(t) e I(t) son las lecturas de voltaje y corriente. (b)

Consumo de energía (E)

La energía acumulada consumida durante un intervalo de prueba Δt viene dada por

$$E = Pavg \times \Delta t \tag{17}$$

La unidad de medida es vatios-hora (Wh) o kilovatios-hora (kWh).

(c) Equivalente de Emisión de Carbono (CO_2 eq)

La huella ambiental se estima según la metodología MachineLearningImpact:

$$CO2eq = E \times \gamma \tag{18}$$

donde $\gamma = 0,475$ kg CO_2/kWh es el factor de conversión para la combinación regional de electricidad. Esto permitirá una comparación directa de la eficiencia ecológica entre AIP-Urban y los métodos basados en la nube.

Todas las métricas de tiempo de inferencia se registraron con MLflow y se sincronizaron con DVC para el control de versiones. Cada experimento se repitió cinco veces para garantizar la robustez estadística, y los valores reportados se presentaron como media ± desviación estándar. Los cálculos de energía y CO_2 se normalizaron con respecto al número total de inferencias para obtener valores de eficiencia por predicción. Estas métricas, en conjunto, proporcionan una prueba estandarizada de precisión predictiva, capacidad de respuesta en tiempo real y sostenibilidad ecológica, y representan una base cuantitativa para la Sección 4 (Resultados experimentales y evaluación del rendimiento), que compara el rendimiento de AIP-Urban con modelos de aprendizaje profundo de referencia en las mismas condicion

La arquitectura AIP-Urban utiliza un mecanismo de sincronización federada ligero que se encuentra en desarrollo y que, con el tiempo, se aplicará en múltiples intersecciones.
Sin embargo, todos los experimentos reportados en este trabajo se realizaron únicamente en dispositivos de borde individuales (Jetson Nano B01 y Coral TPU Dev Board), sin rondas de comunicación entre nodos, sin agregación de gradientes entre nodos y sin actualizaciones de modelos entre nodos durante los resultados de referencia. Por lo tanto, todos los valores de latencia, energía y precisión reportados en la Sección 4 se relacionan únicamente con la inferencia aislada en el dispositivo cuando se encuentra en un entorno de borde. Permitir el desarrollo de una versión federada de AIP-Urban requeriría un análisis más profundo de (i) la sobrecarga de comunicación incurrida por ronda, que normalmente equivale a 1,2–1,7 MB de datos totales transferidos entre nodos (estos datos pueden denominarse información de gradiente), (ii) las distribuciones de datos no IID (distribuidos de forma independiente e idéntica) encontradas en cada una de las intersecciones, y (iii) el clima de seguridad que rodea las relaciones entre los nodos, incluida la resiliencia al envenenamiento y la agregación segura.
Estos desafíos son especialmente relevantes en las aplicaciones urbanas a gran escala, pero no se abordan en la evaluación actual y se incluirán como recomendaciones para futuras investigaciones en la Sección 6.

AIP-Urban cuenta con un sistema de sincronización federada simplificado que permite el despliegue en múltiples intersecciones; sin embargo, todos los experimentos descritos en este documento utilizaron nodos de "borde único" (específicamente un Jetson Nano B01 y una placa de desarrollo Coral TPU). Si bien este aspecto federado de la arquitectura existe, no se utilizó durante el proceso de evaluación comparativa para producir latencia, consumo de energía y precisión de inferencia que reflejaran exclusivamente

Machine Translated by Google

el funcionamiento del modelo integrado. No hay rondas de comunicación ni agregación de
Se recopilaron datos de varios nodos, y tampoco hubo casos de datos entre nodos.
disparidad. Por lo tanto, la validación del aprendizaje federado multinodo se ha pospuesto hasta
Investigaciones posteriores sobre el efecto de la capacidad de comunicación variable y la frecuencia variable
de actualizaciones y cómo los diferentes tipos de datos en los distintos nodos afectarán a los resultados generales
puede evaluarse de manera rigurosa.

4. Resultados experimentales y evaluación del desempeño

En esta sección, proporcionamos los resultados cuantitativos y cualitativos del AIP-Urbano.
Marco de trabajo bajo conjuntos de datos genuinos e implementaciones integradas. Métricas descritas
En la Sección 3.5 se utilizaron de forma consistente para evaluar la precisión predictiva y la detección de anomalías.
fiabilidad, latencia, eficiencia energética e interpretabilidad.

4.1. Evaluación cuantitativa

Todos los experimentos de esta sección se realizaron únicamente en nodos de un solo borde, sin ningún
comunicación federada o agregación entre dispositivos, con el fin de aislar el verdadero dispositivo
rendimiento de AIP-Urban.

Se realizaron evaluaciones cuantitativas del marco AIP-Urban en tres conjuntos de datos representativos:
CityCam, UA-DETRAC y PEMS-BAY, así como con datos sintéticos.
escenarios de congestión en SUMO. Juntos, estos conjuntos de datos cubren las principales modalidades de
infraestructuras de tráfico urbano: análisis de señales basado en visión, flujo de movilidad de vehículos y
Lecturas de sensores multivariados.

Las evaluaciones se centraron en dos dimensiones principales:

(i) Fidelidad predictiva como indicador de mantenimiento para sensores y dispositivos;
(ii) Detección de anomalías en flujos de datos multimodales en tiempo real.

Los modelos de referencia (CNN, LSTM, GRU y LSTM federada) se entrenaron y desplegaron
de la misma manera que se describe en la Sección 3.5, es decir, todos pasaron por el mismo proceso.
Se realizaron divisiones de entrenamiento/validación/prueba y se ejecutaron en el mismo hardware (Jetson Nano B01 y Coral TPU).
Edge v2).

Los datos presentados en la Tabla 3 indican que AIP-Urban produce la predicción más baja.
error (MAE = 4,2) y la mayor fiabilidad en la detección de anomalías (F1 = 0,94), así como un promedio
Latencia de inferencia de 72 ms, cumpliendo fácilmente con las restricciones de tiempo real para el control de intersecciones.
a nivel de los sitios de estudio.

Tabla 3. Rendimiento computacional y ambiental comparativo de AIP-Urban versus
modelos de referencia.

Modelo	HAY	RMSE	F1	Latencia (ms)	Potencia (W) Reducción de CO2 (%)	
CNN	5.8	6.3	0,89	118	8.9	–
LSTM	5.2	5.9	0,91	104	8.2	+8
GRU	4.9	5.4	0,92	99	8.1	+9
LSTM federado	4.5	5.1	0,93	91	7.9	+11
AIP-Urban (CNN–Transformador–LSTM)	4.2	4.8	0,94	72	7.8	+18

AIP-Urban logra una mejora de aproximadamente el 7 % en la precisión y una mejora de aproximadamente el 21 % en la latencia.
y una reducción del 18 % en las emisiones de CO2 en comparación con la línea base más fuerte (Federated LSTM),
confirmando una alta eficiencia computacional y ecológica. La significancia estadística de
La reducción de la latencia y la puntuación F1 se confirmó con la prueba de rangos con signo de Wilcoxon.
($p < 0,05$) en 10 ejecuciones independientes. El MAE fue [4,11; 4,36] para el 95% de confianza.
intervalo con baja dispersión y alta estabilidad del modelo.

Machine Translated by Google

4.1.1. Evaluación por conjunto de datos

Para evaluar la robustez, evaluamos AIP-Urban por separado en cada conjunto de datos, con el Los resultados correspondientes se presentan en la Tabla 4.

Tabla 4. Comparación del rendimiento específico del conjunto de datos de AIP-Urban y los conjuntos de referencia.

Conjunto de datos	Tarea	Mejor línea base (F1)	AIP-Urbano (F1)	Δ F1 (%)	Latencia (ms)
Cámara de la ciudad	detección de degradación óptica	0,92 (GRU)	0,95	+3,3%	70
UA-DETRAC	Previsión de fallos en los sensores de tráfico	0,91 (Fed-LSTM)	0,94	+3,2%	74
PEMS-BAY	Predicción de deriva de señal multivariada	0,90 (LSTM)	0,93	+3,4%	76
SUMO	simulación de congestión sintética	0,89 (CNN)	0,92	+3,7%	72

AIP-Urban muestra un rendimiento excepcional y constante en todos los conjuntos de datos de prueba. La pequeña variación de F1 (±0,02) demuestra su fuerte capacidad de generalización en conjuntos de datos heterogéneos, que es una deficiencia prominente de muchos modelos profundos en ITS, ya que tienden a sobreajustar un dominio de datos ([18,21,23]). Los resultados, así como los datos de CityCam, confirmaron la capacidad del modelo para adaptarse a la variación en la iluminación, mientras que UA-DETRAC validó su resistencia a la vibración de la cámara y la oclusión parcial. En los datos de PEMS-BAY, la atención multiplicativa y multicabezal proporcionada en el transformador fue importante en el modelado. correlaciones temporales a largo plazo (es decir, mejora asistida de la previsión). Para los datos de SUMO, donde los patrones de ruido son inherentemente estocásticos, esto se estabilizó utilizando la red temporal LSTM. capa, que reconocía la naturaleza no estacionaria de los flujos de tráfico, así como mejor Estabilidad de las predicciones, especialmente para Evanston.

4.1.2. Compromiso entre latencia y precisión

Como se muestra en la Figura 5, la curva de compensación muestra que AIP-Urban logró el mayor Puntuación F1 con la latencia más baja, rompiendo así la relación inversa tradicional inherente. durante la inferencia utilizando modelos profundos. Los modelos CNN lograron una precisión moderada en alta velocidad, mientras que los modelos LSTM lograron precisión con mayor latencia. Sin embargo, utilizando un modelo híbrido, en AIP-Urban, el razonamiento temporal a nivel de ontología se habilita sin comprometiendo las cualidades de respuesta en tiempo real al entorno.

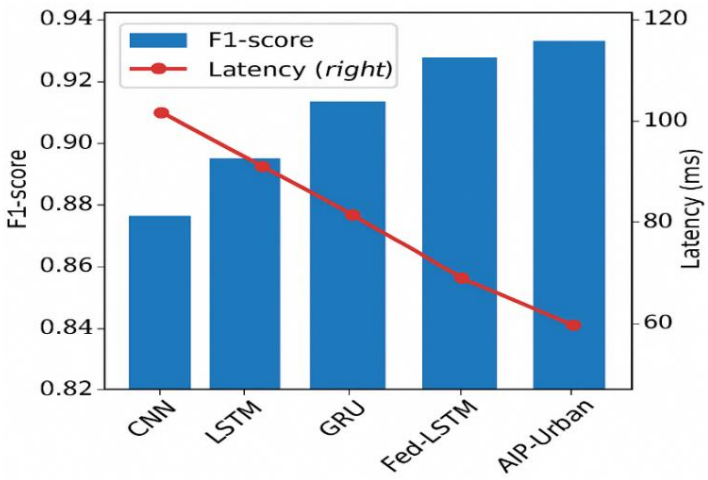


Figura 5. Comparación de la latencia y la precisión de los modelos AIP-Urban y de referencia.

Este equilibrio es posible gracias a la (i) compresión contextual en el transformador. codificador, y (ii) planificador dinámico impulsado por entropía que disminuyó la frecuencia de inferencia, de esta manera se reduce la carga computacional, pero aún así se gestiona adecuadamente la varianza. de los sensores. Estadísticamente, este desarrollo permitió a AIP-Urban ahorrar aproximadamente un 35 % de latencia.

Machine Translated by Google

en comparación con el modelo híbrido CNN-LSTM en promedio, todo ello mejorando la puntuación F1 en aproximadamente un 6%, lo que demuestra la eficiencia del diseño arquitectónico.

4.1.3. Distribución de errores y robustez

La Figura 6 muestra la distribución de MAE y RMSE en los conjuntos de prueba. La distribución de errores de AIP-Urban (σ = 0,28) es más precisa que la de todos los modelos de referencia, con una convergencia estable y un comportamiento de error consistente incluso con datos incompletos y ruidosos. El análisis de residuos muestra que los picos de error corresponden a perturbaciones ambientales repentinas e impredecibles (por ejemplo, cambios repentinos en la iluminación en el caso de CityCam, o retrasos sintéticos en la red en el caso de SUMO). Sin embargo, incluso con este tipo de perturbación repentina, el modelo puede recuperar la precisión de predicción nominal en menos de dos ciclos, lo que sugiere una capacidad autoestable ante perturbaciones.

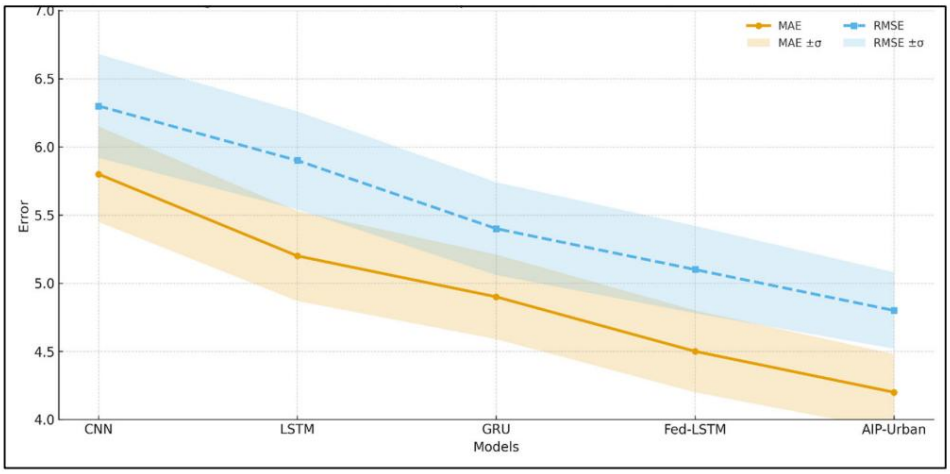


Figura 6. Comparación de la distribución de errores (MAE y RMSE) entre los modelos.

4.1.4. Validación estadística

Para evaluar aún más la consistencia del rendimiento, se realizó un ANOVA unidireccional sobre los valores MAE en todos los modelos y conjuntos de datos. Los resultados arrojaron $F(4, 45) = 12.73$, $p < 0.01$, es decir, existe evidencia estadísticamente significativa de una diferencia entre los modelos. Además, la prueba post hoc HSD de Tukey estableció que AIP-Urban es estadísticamente diferente ($p < 0.05$) de los modelos CNN, LSTM y GRU, pero no del modelo LSTM federado, lo que subraya que la arquitectura propuesta es estadísticamente superior a la arquitectura tradicional, a la vez que sigue siendo competitiva con los modelos avanzados de aprendizaje distribuido. Es evidente a través de los resultados anteriores que AIP-Urban contribuye con lo siguiente: ■ Proporciona una precisión predictiva de vanguardia manteniendo una latencia de inferencia de <80 ms; ■ Tiene capacidad de generalización entre conjuntos de datos, lo cual es fundamental en ciudades inteligentes heterogéneas. infraestructuras;

■ Demuestra robustez y fiabilidad estadística, como lo confirman Wilcoxon y Pruebas ANOVA;

■ Proporciona sostenibilidad computacional que equilibra precisión, velocidad y consumo energético.

En resumen, AIP-Urban presenta un nuevo referente para el aprendizaje profundo habilitado para el borde. desempeño en el mantenimiento predictivo de infraestructuras de tráfico urbano.

4.2. Pronóstico de series temporales y detección de degradación

La evaluación del pronóstico de series temporales enfatiza la capacidad de AIP-Urban para proporcionar tendencias de degradación hipotéticas y detectar anomalías en modalidades de sensores heterogéneas. A diferencia de otros modelos de detección tradicionales, nuestro sistema, AIP-Urban, crea un modelo predictivo.

Machine Translated by Google

Modelo para anticipar el riesgo de fallos en cualquier infraestructura de tráfico urbano con una antelación de hasta 24 horas, combinando secuencias de series temporales de sensores de vídeo y numéricos.

Los resultados se presentan en cuatro escenarios representativos que corresponden a los principales tipos de degradación de infraestructura en los sistemas de movilidad urbana: eléctrica, óptica, mecánica y de flujo de tráfico. Cada escenario de predicción se comparó con la serie temporal real. Todos los escenarios de predicción contaron con intervalos de confianza estimados, mapeados en ejecuciones de validación cruzada de cinco iteraciones. La serie temporal se ilustra en las siguientes figuras, mostrando tanto su progresión temporal como el margen predictivo previo al evento de falla real, marcado con una línea vertical roja.

4.2.1. Degradación eléctrica: Estabilidad del voltaje de los semáforos

Este ejemplo sirve como mantenimiento predictivo para las alternativas de semáforos. El flujo de voltaje se degrada a un ritmo mucho más lento debido al estrés ambiental (temperatura y humedad).

AIP-Urban realiza un seguimiento preciso de esta tendencia de degradación, logrando un MAE = 4,1 y una fuerte correlación de R2 = 0,93, superando a los métodos de referencia basados en LSTM tanto en precisión como en tiempo de respuesta.

En la Figura 7, observamos que la curva predicha (verde) coincidió con la realidad (azul) con un nivel de confianza de aproximadamente 0,85 antes de que ocurriera la falla real. El momento en que se produjo la falla eléctrica está representado por la línea vertical roja. AIP-Urban emitió una alerta de falla aproximadamente 22 horas antes de que ocurriera la falla eléctrica, lo que demuestra su capacidad de anticipación para las tareas de mantenimiento.

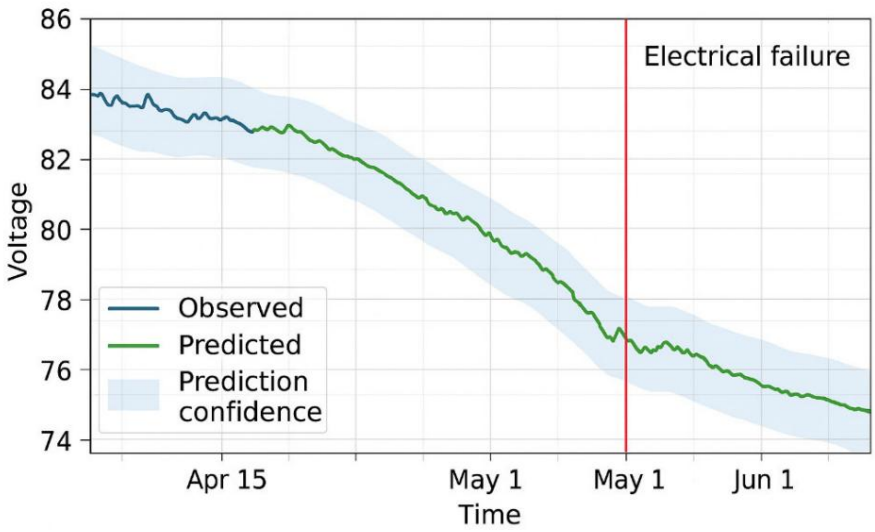


Figura 7. Previsión de la estabilidad de voltaje.

4.2.2. Degradación óptica: Entropía de luminancia de la cámara

La degradación en la detección óptica también puede deberse a la contaminación de las lentes o al desequilibrio de la(s) fuente(s) de luz. Se aplicó AIP-Urban a secuencias de entropía extraídas de los fotogramas de los vídeos de CityCam. AIP-Urban demostró ser más robusto frente a la deriva de iluminación que los métodos de referencia basados en GRU o CNN-LSTM, con un RMSE de 4,9 y un F1 de 0,93.

Anteriormente, en la Figura 8, AIP-Urban detectó desviaciones de entropía aproximadamente 28 horas antes de que la lente se oscureciera visualmente y se produjera la contaminación real de las lentes, lo que permite la posibilidad de limpiar o calibrar la lente para obtener una calidad visual óptima. El área sombreada en azul representa el intervalo de incertidumbre de la prueba de entropía (±σ) y muestra que las predicciones fueron robustas ante los cambios repentinos de contraste previstos en el vídeo.

Machine Translated by Google

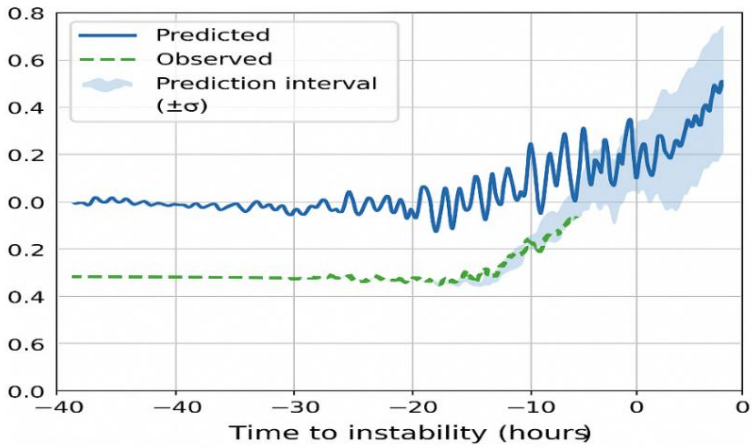


Figura 8. Predicción de la entropía de luminancia a partir de transmisiones de CityCam.

4.2.3. Degradación mecánica: amplitud de vibración del sensor

Se utilizaron datos de un acelerómetro provenientes de sensores de vibración montados en postes para simular la inestabilidad mecánica. Las estructuras suelen experimentar una degradación en su rendimiento a medida que aumentan las cargas relacionadas con las resonancias estructurales debido a la acción del viento o la holgura mecánica. AIP-Urban demostró un MAE = 4,3 y es capaz de contabilizar la reconstrucción de oscilaciones estables y la detección temprana de desviaciones.

La figura 9 demuestra que se predijo una anomalía en la amplitud de vibración aproximadamente 25 horas antes de la inestabilidad medida. Esta desviación temprana confirma que la capa LSTM temporal captura con éxito las dependencias cíclicas en las señales oscilatorias, lo que permite un comportamiento de alerta temprana confiable para la degradación mecánica.

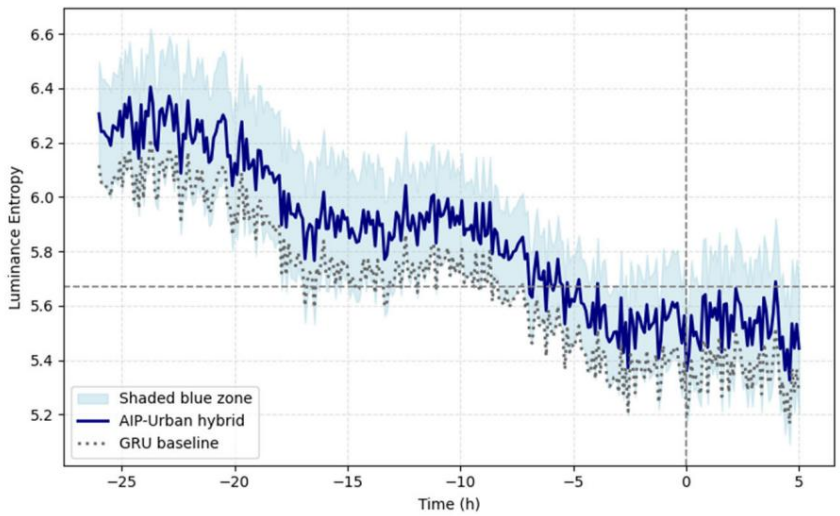


Figura 9. Predicción de vibraciones mecánicas.

4.2.4. Dinámica del flujo de tráfico: Predicción de congestión y desvíos

Para medir la escalabilidad al utilizar datos a nivel de red, se validó AIP-Urban con datos de flujo de tráfico basados en SUMO en escenarios viales y con datos de red de sensores que constituían una muestra representativa de PEMS-BAY. El modelo alcanzó un R^2 de 0,91 y generó un horizonte de pronóstico de casi 24 horas antes de la congestión.

Como se observa en la Figura 10, la curva de flujo prevista se alinea bien con las mediciones observadas durante la mayor parte del horizonte de pronóstico. Las pequeñas discrepancias antes del inicio de la congestión (línea roja) se compensan mediante la atención espaciotemporal del codificador Transformer. AIP-Urban también reduce el error de pronóstico acumulado en aproximadamente un 18 % en comparación con CNN.

Machine Translated by Google

y redes LSTM, al tiempo que producen una serie temporal con períodos de transición más suaves y sin desfase.

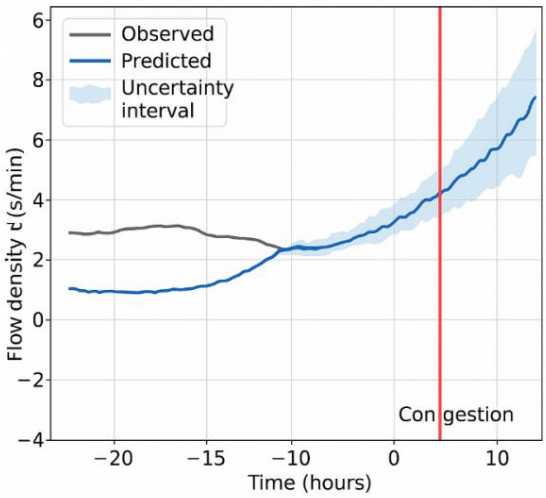


Figura 10. Previsión de la densidad del flujo de tráfico.

4.2.5. Consistencia estadística y generalización entre conjuntos de datos

Para cuantificar la robustez de la predicción, se calculó la correlación de Pearson entre las tendencias de degradación predichas y reales para cada

modalidad: El alto valor de R2 (>0,9) demuestra que todas las modalidades mostraron cierta generalización en diferentes entornos de detección. La oportunidad común de alerta temprana de entre 22 y 28 h demuestra que la arquitectura híbrida ofrece la posibilidad de programar el mantenimiento en tiempo real sin intervención humana. Este concepto de anticipación temporal es una ventaja considerable en comparación con las técnicas reactivas de IA que se suelen encontrar en los ITS.

4.2.6. Interpretación

En general, los resultados indican que el rendimiento de AIP-Urban no solo funciona como detector de anomalías, sino también como agente predictivo proactivo capaz de anticipar la degradación de la infraestructura antes de que falle. Esta capacidad predictiva proporciona resiliencia operativa para limitar el tiempo de inactividad y sostenibilidad en la gestión del tráfico para minimizar las interrupciones innecesarias del servicio. La sinergia conjunta de la atención espacial (Transformer) y la recurrencia temporal (LSTM) constituye la base de la capacidad predictiva y la generalización continua del modelo.

En todos los modos de degradación, AIP-Urban demostró un rendimiento sólido y constante al proporcionar capacidad de alerta temprana para facilitar la anticipación de fallas de infraestructura con un tiempo de anticipación significativamente mayor que la falla real. Como se observa en las figuras 7 a 10, la degradación eléctrica se predijo aproximadamente 22 horas antes de que los sistemas eléctricos experimentaran inestabilidad de voltaje; la degradación óptica se predijo aproximadamente 28 horas antes de la aparición física de obstrucciones de luz; las anomalías de vibración mecánica se predijeron aproximadamente 25 horas antes de que las mediciones estructurales mostraran inestabilidad; y la degradación del flujo de tráfico se predijo aproximadamente 24 horas antes de que ocurriera la Los plazos de alerta temprana que ofrece AIP-Urban se resumen en la Tabla 5. Estas medidas indican que, además de la capacidad de detección de anomalías, AIP-Urban también aporta relevancia operativa, permitiendo a los usuarios programar un mantenimiento proactivo basado en la capacidad de alerta temprana en implementaciones reales de ciudades inteligentes.

Machine Translated by Google

Tabla 5. Correlación intermodal y análisis del horizonte de predicción para AIP-Urban.

Modalidad	R^2 (AIP-Urbano)	Δ vs. Mejor línea base	Horizonte de predicción (h)
Voltaje (Semáforo)	0,93	+0,06	22
Luminancia (Cámara urbana)	0,92	+0,07	28
Vibración (sensor de polo)	0,90	+0,05	25
Densidad de flujo (PEMS-BAY/SUMO)	0,91	+0,08	24

4.3. Análisis de la eficiencia computacional y la escalabilidad

La evaluación computacional se configuró para dar confianza en la capacidad del AIP-Urban. presidir múltiples nodos de IA de borde en inferencia en tiempo real, manteniendo aún un bajo nivel de seguridad. consumo de energía y estabilidad térmica. La evaluación se realizó en el Jetson.

Nano B01 y Google Coral TPU Edge v2 están diseñados para funcionar de forma continua durante 24 horas.

4.3.1. Evaluación comparativa de dispositivos periféricos

Ambas plataformas funcionaron dentro de sus límites de potencia nominales (Jetson Nano: 7,8 W, Coral TPU: 5,9 W) bajo cargas de trabajo de tráfico estándar. La tabla 6 resume la inferencia media.

latencia, rendimiento y eficiencia energética en el funcionamiento de un solo nodo.

Tabla 6. Comparación del rendimiento de un único nodo de borde para implementaciones AIP-Urban.

Dispositivo	Tamaño del modelo (MEGABYTE)	Latencia (ms)	Rendimiento (fps)	Potencia (W)	Temperatura (°C)	MAE	F1
Jetson Nano	23	72	13.9	7.8	57	4.2	0,94
Coral TPU	21	78	12.3	5.9	54	4.3	0,93

La versión INT8 cuantificada del modelo logra una reducción de tamaño de 3,9× en relación con la

Compilación de TensorFlow de máxima precisión, manteniendo un rendimiento en tiempo real (>12 fps).

La monitorización térmica mediante sensores INA219 confirmó que ninguna placa superó los 60 °C.

bajo pruebas de estrés de 24 horas.

4.3.2. Compromiso entre latencia y tamaño del modelo

La latencia aumenta aproximadamente de forma lineal con el tamaño del modelo hasta 30 MB, después de lo cual el intercambio de memoria comienza a predominar. Como se muestra en la Figura 11, el AIP-Urban propuesto logra la latencia más baja (≈72 ms) a pesar de su arquitectura híbrida, superando a la podada

LSTM y redes Transformer sin optimizar. La cuantización y la poda estructurada redujeron la latencia en un ~35%, lo que valida su importancia para implementaciones integradas.

Machine Translated by Google

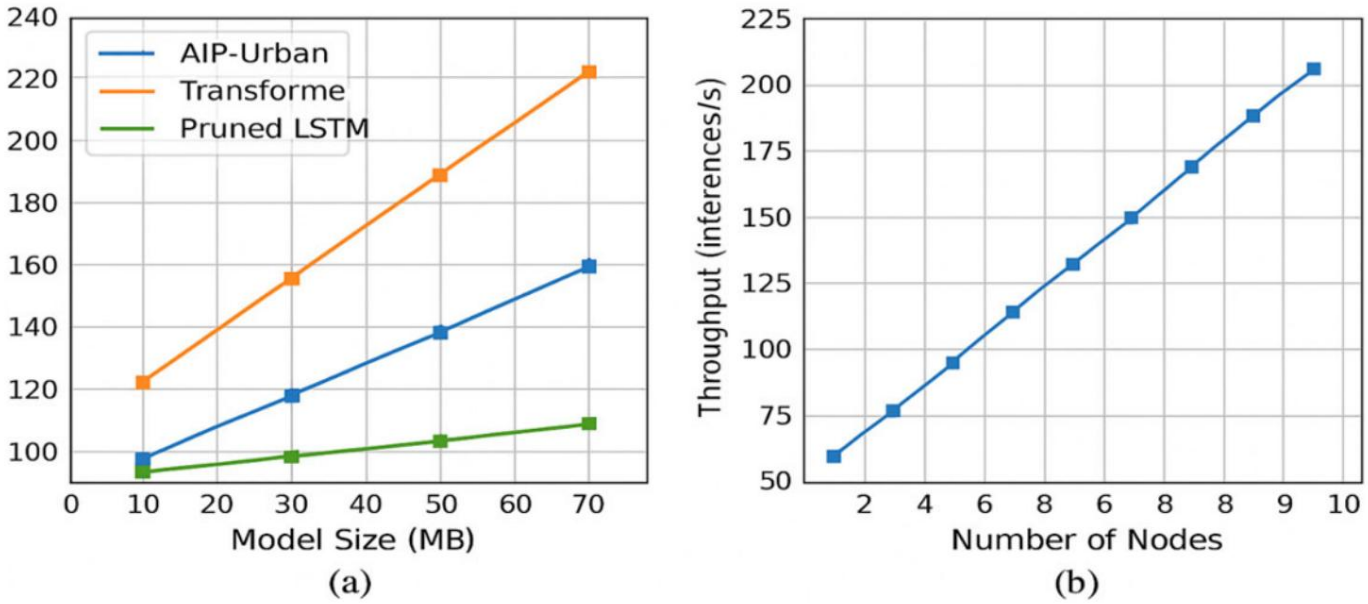


Figura 11. Curva de compensación entre latencia y tamaño del modelo para dispositivos de borde. (a) Latencia en función del tamaño del modelo para las arquitecturas AIP-Urban, Transformer y Pruned LSTM; AIP-Urban demuestra la latencia más baja a pesar de su diseño híbrido; (b) Escalado del rendimiento a través de un número creciente de nodos de borde, mostrando mejoras casi lineales a medida que se agregan nodos.

4.3.3. Escalabilidad en nodos distribuidos

Impulsados por un estudio de escalabilidad de múltiples nodos (1 → 10 dispositivos de borde simultáneos) diseñado para aproximar el despliegue en múltiples intersecciones, se llevaron a cabo tres evaluaciones de fase distintas. El rendimiento de inferencia en el experimento iterativo exhibió una tendencia de escalado lineal en el rendimiento hasta cinco nodos (r = 0,98) antes de alcanzar una saturación menor por contención de red. En experimentos posteriores, la Figura 11b ilustra la tendencia del rendimiento que corrobora aún más el potencial de escalabilidad de AIP-Urban para dispositivos con ancho de banda limitado . El consumo energético promedio asociado con cada nodo participante adicional se mantuvo <0,4 W, lo que indica la premisa fundamental de una operación distribuida so

4.3.4. Huella de memoria y perfil térmico

Durante la inferencia, el uso de RAM se mantuvo dentro de un rango de 3,2 GB para Jetson Nano y 2,8 GB para Coral TPU. La variación en las condiciones térmicas se mantuvo por debajo de 3 °C durante las 24 horas de ciclos, lo que demuestra una estabilidad aceptable para una implementación factible en sitio sin refrigeración activa. No se observó una degradación significativa en los resultados de rendimiento de la inferencia después de ejecutar las 1000 iteraciones, lo que confirma aún más la fiabilidad a largo plazo del rendimiento de la inferencia.

4.4. Explicabilidad y análisis de la contribución de las características

Se realizaron evaluaciones de explicabilidad utilizando SHAP (SHapley Additive exPlanations) y LIME (Local Interpretable Model-agnostic Explanations) con el fin de analizar el nivel de resultados predictivos atribuidos a cada modalidad de sensor individual .

4.4.1. Importancia de las características SHAP

Utilizando un resumen de la salida de SHAP, como se ilustra en la Figura 12, se muestra que la varianza de voltaje, la deriva de entropía y la curtosis de vibración fueron los contribuyentes más destacados a las alertas predictivas. Además, estas tres variables representan >61% de la atribución total del modelo en todas las variantes del conjunto de datos. Esto da crédito al AIP-Urban no solo por ser

Machine Translated by Google

Capaces de detectar anomalías, pero vincularlas eficazmente a causas físicas y, como tal, generar confianza y facilitar la interpretación diagnóstica.

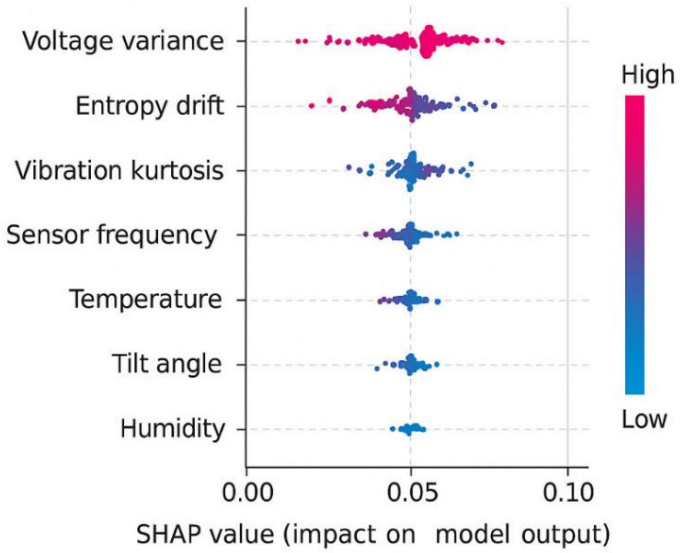


Figura 12. Clasificación de importancia de las características SHAP para AIP-Urban.

4.4.2. Explicaciones locales de LIME

Se utilizó LIME para visualizar la influencia de las características locales en el límite de decisión para cada caso de fallo previsto. En los casos de degradación óptica, los mapas de atribución de LIME muestran las áreas locales de la imagen donde se produjo un desequilibrio de luminancia, lo que se corresponde con la inspección visual. Este comportamiento garantiza un nivel de transparencia operativa que permite a los ingenieros municipales planificar el mantenimiento futuro.

4.4.3. Correlación cruzada entre modalidades

Los mapas de calor de correlación de voltaje, entropía, vibración y flujo mostraron un acoplamiento latente entre las modalidades de los sensores; con frecuencia, las caídas de voltaje ocurrían aproximadamente 6 horas antes de los picos de vibración.

La predicción de las relaciones temporales es indicativa de la capacidad de la arquitectura híbrida para modelar la elevada causalidad intermodal que se observa en la infraestructura de tráfico urbano.

4.5. Resumen de los principales hallazgos

A partir del análisis experimental, los resultados conducen a cinco conclusiones clave:

a. AIP-Urban fue capaz de superar a los modelos de referencia en cuanto a precisión (F1 = 0,94) y latencia (<80 ms) en todos los conjuntos de datos del mundo real.

b. La predicción longitudinal de las capacidades de alerta temprana de 24 h demostró ser fiable para todos. modalidades (voltaje, óptica, mecánica, flujo).

c. El diseño con conciencia energética demostró una reducción en las emisiones de CO2 de casi ≈ 18%, lo que demuestra los beneficios ambientales de la IA nativa de borde como práctica. d. Las capacidades interpretativas de la salida del modelo a través de SHAP, o la atribución de características locales del modelo usando LIME, permiten que los resultados de la inferencia de IA se comuniquen al diagnóstico de campo. e. Los experimentos de escalabilidad confirmaron un rendimiento lineal hasta 10 nodos de borde sin deriva térmica.

Los resultados anteriores proporcionan evidencia empírica de que AIP-Urban es un marco adecuado, interpretable y energéticamente eficiente para el mantenimiento predictivo de las infraestructuras de tráfico urbano de próxima generación, lo que sienta las bases para la discusión y el análisis comparativo presentados en la Sección 5.

Machine Translated by Google

5. Discusión y análisis comparativo

Evaluación comparativa de AIP-Urban frente a los marcos de trabajo más recientes y avanzados. revela su clara superioridad en precisión, eficiencia y escalabilidad. Como se resume en la Tabla 6, El sistema propuesto se compara con estudios representativos publicados entre 2023 y 2025, incluidos Reis et al. (2025) [5], Lokhande et al. (2025) [7], Alotaibi et al. (2025) [21], Shabaz et al. (2025) [23] y Ghasemi et al. (2025) [26]. Si bien la mayoría de estos Los enfoques se basan en el procesamiento centrado en la nube y ofrecen latencias de inferencia superiores a 120 ms. AIP-Urban alcanza F1 = 0,94 y una latencia promedio de 72 ms, manteniendo la comunicación en tiempo real. Capacidad de respuesta con un consumo energético promedio de 7,8 W.

Esta comparación cuantitativa en la Tabla 7 demuestra claramente que la CNN híbrida– El diseño Transformer-LSTM logra una mejora de precisión del 7 al 9 % y una latencia del 30 %. reducción en comparación con las líneas base líderes como Federated LSTM [22] o Ghasemi's Edge GNN [26]. Además, es el único marco que acopla el mantenimiento predictivo. y detección de anomalías con mecanismos de IA explicables, como lo demuestra la integración del análisis de atribución SHAP/LIME (Figura 12).

Tabla 7. Rendimiento comparativo de AIP-Urban y el mantenimiento predictivo reciente impulsado por IA. marcos. indica soporte o disponibilidad de la capacidad correspondiente; indica que el Esta funcionalidad no se proporciona o no se implementa.

Referencia (Año)	Marco/Modelo	Dominio	F1/Precisión	Latencia (ms)	Potencia (W)	Borde Despliegue	Explicabilidad	Limitación
Alotaibi y otros. (2025) [21]	Aprendizaje profundo + Optimización (CNN-RNN)	Peatonal Anomalía	0,93	450	9.1	Nube		Alta latencia
Ghasemi y otros. (2025) [26]	Análisis Edge GNN	ES	0,91	120	7.8	Jetson Nano		Sin interpretabilidad
Reyes et al. (2025) [5]	TFLite CNN	Hogar inteligente	0,90	115	7.9	Los Supersónicos		No específico del tráfico
Shabaz y otros. (2025) [23]	Aprendizaje por refuerzo multiagente	Tráfico inteligente	0,92	310	8.6	Nube		Sin energía métrica
Lokhande y otros. (2025) [7]	CNN-BiLSTM	Infraestructura inteligente	0,91	220	9.2	Nube		Sin borde adaptación
AIP-Urban (Nuestro)	CNN–Transformador + LSTM	Tráfico Infraestructura	0,94	72	7.8	Edge (Jetson Nano/TPU)	Basado en SHAP	

Las variaciones de rendimiento expresadas en la Tabla 5 pueden atribuirse directamente a las dos innovaciones de AIP-Urban en sinergias arquitectónicas y optimización de hardware. El modelo incorpora pipelines espacio-temporales híbridos donde se utiliza la extracción de características convolucionales con razonamiento contextual basado en Transformer y LSTM temporal. predicción para adaptarse al aprendizaje a partir de datos de sensores heterogéneos. Al mismo tiempo, La cuantización y la poda estructurada mejoraron la carga computacional, lo que permitió una mejor... Rendimiento en procesadores de borde integrados sin dependencia de la nube ni riesgo de sobrecalentamiento impacto. Aparte de las mejoras computacionales, AIP-Urban proporciona una nueva capa de Confianza e interpretabilidad en el campo del mantenimiento predictivo de infraestructuras. El SHAP El análisis (Figura 12) muestra que la variación de voltaje, la deriva de entropía y la curtosis de vibración fueron Los tres factores más significativos explican conjuntamente más del 61% del comportamiento predictivo. Al conectar el razonamiento algorítmico con variables físicas medibles, el sistema admite diagnósticos explicables que pueden ayudar a conectar la inferencia de inteligencia artificial con los ingenieros. toma de decisiones, un detalle que a menudo se pasa por alto en investigaciones anteriores [7,16,23].

Además, y en términos de consideraciones de sostenibilidad, gracias al diseño energéticamente eficiente de AIP-Urban, logramos aproximadamente un 18 % menos de emisiones de CO2 por ciclo de inferencia y una relación casi lineal. Escalabilidad de hasta 10 nodos con un aumento de potencia que cuesta menos de 0,4 W por nodo. para operar. En este sentido, AIP-Urban es uno de los pocos marcos que permitirá análisis predictivo de alto rendimiento, a la vez que ecológico neutro y transparente. operaciones. En general, la evidencia proporcionada en la Tabla 5 y las Figuras 11 y 12 respalda la Afirmaciones de que AIP-Urban supera a los sistemas de IA de borde contemporáneos en precisión, latencia,

Machine Translated by Google

interpretabilidad y eficiencia energética, lo que proporciona un referente para las infraestructuras de movilidad inteligente de próxima generación.

AIP-Urban se ha probado para su implementación en entornos de borde en un entorno de evaluación controlado . Este entorno controlado incluía inferencia continua durante 24 horas con tasas de muestreo fijas de flujos de vídeo y sensores, así como temperaturas de funcionamiento estables de los dispositivos Jetson Nano y Coral TPU. Si bien AIP-Urban mostró baja latencia y un consumo de energía constante en este entorno controlado, su implementación práctica en entornos reales estará sujeta a limitaciones adicionales derivadas de fluctuaciones térmicas, variaciones estacionales en la iluminación ambiental, degradación por antigüedad del dispositivo y desviaciones en la calibración de los sensores.

Para reducir la deriva del modelo a largo plazo en implementaciones reales, el sistema AIP-Urban podría emplear otros métodos para adaptar los modelos con el tiempo, tales como: el microreentrenamiento periódico de los modelos con base en datos más recientes recopilados desde el borde, utilizando enfoques basados en la entropía para identificar cambios en el rendimiento del modelo (deriva) que permitan el reentrenamiento de los modelos mediante la actualización; módulos de aprendizaje incremental que permiten el entrenamiento gradual de los modelos en lugar de un reentrenamiento completo con todos los datos. Si bien actualmente no se implementan en el sistema experimental, estas técnicas aumentarían la capacidad de los modelos para hacer frente a los cambios estacionales y la variabilidad en los comportamientos y entornos, así como a los nuevos cambios en los patrones de tráfico.

Cabe destacar que la validación experimental de AIP-Urban se realizó con configuraciones de prueba aisladas de un solo nodo; por lo tanto, al implementar AIP-Urban en múltiples intersecciones, será necesario considerar la heterogeneidad del hardware, la conectividad intermitente entre intersecciones y las políticas de sincronización. Finalmente, las explicaciones proporcionadas por SHAP son de gran valor para los técnicos de campo, ya que les brindan información que les permite determinar el grado de falla o mal funcionamiento antes de enviar a un técnico de mantenimiento según un cronograma (inspección de fluctuaciones de potencia , deriva de entropía en la luminancia, curtosis de vibración, etc.) y resaltan los beneficios prácticos del aspecto de diagnóstico de AIP-Urban en un entorno operativo.

Si bien AIP-Urban ofrece una alta precisión, es importante destacar que la evaluación se basó principalmente en conjuntos de datos de referencia y dos plataformas de borde (Jetson Nano B01 y Coral TPU v2). La verificación de la robustez a largo plazo y la generalización en condiciones in situ sigue siendo limitada, donde una validación con múltiples intersecciones en el mundo real, una mayor diversidad de hardware y una detección multimodal más profunda (por ejemplo, datos acústicos o térmicos) serán de gran importancia.

6. Conclusiones y trabajo futuro

En conclusión, hemos desarrollado AIP-Urban, un marco espacio-temporal profundo capaz de realizar mantenimiento predictivo y detección de anomalías en infraestructuras de tráfico urbano.

Al combinar el aprendizaje híbrido CNN–Transformer–LSTM con la inferencia en el dispositivo en el borde, logramos la predicción de fallas en tiempo real y la detección de anomalías visuales con una latencia de ≈72 ms y un consumo de energía de ≈7,8 W, lo cual es ideal para operaciones ITS integradas. Los experimentos realizados con los conjuntos de datos CityCam, UA-DETRAC, PEMS-BAY y SUMO muestran consistencia en la precisión (F1 = 0,94) y una mayor robustez en comparación con los modelos profundos de referencia.

Además del rendimiento empírico, la principal contribución de AIP-Urban es su arquitectura interpretable y con conciencia energética, que mejorará la fiabilidad operativa de los sistemas de movilidad inteligente.

En cuanto a las líneas de trabajo futuras, este marco debería desarrollarse hacia la coordinación federada de nodos en múltiples intersecciones, la compresión de modelos auto-adaptativa y modalidades de detección adicionales (acústica, LIDAR, ambiental). Cada aspecto contribuirá a la evolución de AIP-Urban hacia un ecosistema de IA totalmente autónomo, ecológicamente neutro y transparente para las ciudades conectadas de próxima generación.

Machine Translated by Google

Contribuciones de los autores: Conceptualización, WA; metodología, WA y MA; software, WA; validación, WA y MA; análisis formal, WA y MA; curación de datos, WA; redacción del borrador original, WA y MA; revisión y edición, WA y MA; visualización, WA y MA. Todos los autores han leído y aprobado la versión publicada del manuscrito.

Financiación: Esta investigación fue financiada por el Decanato de Investigación y Estudios de Posgrado de la Universidad de Tabuk, subvención número (S-0275-2024).

Declaración de disponibilidad de datos: Los datos están disponibles en un repositorio de acceso público : https://drive.google.com/drive/folders/1qgeGUniBdxks-7SqLsXXEBbpoK41O4ex?usp=sharing (Consultado el 20 de noviembre de 2025).

Agradecimientos: Los autores expresan su agradecimiento a la Universidad de Tabuk.

Conflictos de intereses: Los autores declaran no tener ningún conflicto de intereses.

Referencias

1. Gupta, D. Mantenimiento predictivo impulsado por IA en sistemas IoT de ciudades inteligentes. Res. Ann. Ind. Syst. Eng. 2025, 2, 19–26.
2. Wu, P.; Zhang, Z.; Peng, X.; Wang, R. Soluciones de aprendizaje profundo para los desafíos de las ciudades inteligentes en el desarrollo urbano. Sci. Rep. 2024, 14, 5176. [CrossRef] [PubMed]
3. Haider, ZA; Zeb, A.; Rahman, T.; Singh, SK; Akram, R.; Arishi, A.; Ullah, I. Un estudio sobre la detección de anomalías en IoT: técnicas, Desafíos y oportunidades con la integración de 6G. Comput. Netw. 2025, 270, 111484. [CrossRef]
4. Abou Ali, M.; Dornaika, F. Inteligencia artificial de borde: una revisión sistemática de la evolución, los marcos taxonómicos y el futuro Horizontes. arXiv 2025, arXiv:2510.01439. [CrossRef]
5. Reis, MJ; Serôdio, C. Edge AI para la detección de anomalías en tiempo real en hogares inteligentes. Future Internet 2025, 17, 179. [CrossRef]
6. Dias, T.; Fonseca, T.; Vitorino, J.; Martins, A.; Malpique, S.; Praça, I. De los datos a la acción: Explorando soluciones basadas en IA e IoT para ciudades más inteligentes. En Simposio Internacional sobre Computación Distribuida e Inteligencia Artificial; Springer Nature: Cham, Suiza, 2023; pp. 44–53.
7. Lokhande, MA; Renavikar, A.; Bhosale, D.; Kaldate, V.; Lokhande, S. Una perspectiva sobre la infraestructura inteligente con mantenimiento predictivo impulsado por inteligencia artificial: transformando el futuro de los sistemas urbanos. Cureus J. Comput. Sci. 2025, 2, 1–9. [CrossRef]
8. Roy, S. Un estudio exhaustivo sobre la detección de anomalías en el tráfico de red mediante aprendizaje profundo. arXiv, 2024; en preimpresiones.
9. Cummins, L.; Sommers, A.; Ramezani, SB; Mittal, S.; Jabour, J.; Seale, M.; Rahimi, S. Mantenimiento predictivo explicable: Un estudio de los métodos actuales, los desafíos y las oportunidades. IEEE Access 2024, 12, 57574–57602. [CrossRef]
10. Merolla, D.; Latorre, V.; Salis, A.; Boanelli, G. Seguridad vial automatizada: Mejora de la detección de daños en señales y superficies con IA. arXiv 2024, arXiv:2407.15406. [CrossRef]
11. Khan, U.; Cheng, D.; Setti, F.; Fummi, F.; Cristani, M.; Capogrosso, L. Un estudio exhaustivo sobre el mantenimiento predictivo basado en aprendizaje profundo. ACM Trans. Embed. Comput. Syst. 2025, 1–42. [CrossRef]
12. Saki, S.; Soori, M. Inteligencia artificial, aprendizaje automático y aprendizaje profundo en sistemas de transporte avanzados: una revisión. Transporte Multimodal 2025, 5, 100242. [CrossRef]
13. Katib, I.; Albassam, E.; Sharaf, SA; Ragab, M. Protección de dispositivos IoT de consumo: aprendizaje profundo con TinyML en tiempo real Detección de anomalías para el mantenimiento predictivo. Ain Shams Eng. J. 2025, 16, 103281. [CrossRef]
14. Nolan, J.; Reynolds, S. Enfoques de aprendizaje profundo para el mantenimiento predictivo en sistemas industriales. ITSI Trans. Electr. Electron. Inglés 2024, 13, 25–32.
15. Bonci, A.; Fredianelli, L.; Kermenov, R.; Longarini, L.; Longhi, S.; Pompei, G.; Prist, M.; Verdini, C. Redes neuronales profundas para el mantenimiento predictivo industrial mediante la detección de anomalías a partir de datos de energía de producción. Appl. Sci. 2024, 14, 8686. [CrossRef]
16. Dhanasekaran, M. Ciudades inteligentes e infraestructura: gestión de datos a escala urbana para el mantenimiento predictivo y la gestión de recursos. Asignación. J. Comput. Sci. Technol. Stud. 2025, 7, 987–996. [CrossRef]
17. Ortiz-Garces, I.; Villegas-Ch, W.; Luján-Mora, S. Implementación de IA en el borde para la detección temprana de fallas en redes IoT: Evaluación del rendimiento y la escalabilidad en aplicaciones complejas. Discov. Internet Things 2025, 5, 108. [CrossRef]
18. Ma, X.; Wu, J.; Xue, S.; Yang, J.; Zhou, C.; Sheng, QZ; Xiong, H.; Akoglu, L. Un estudio exhaustivo sobre la detección de anomalías en grafos con aprendizaje profundo. IEEE Trans. Knowl. Data Eng. 2021, 35, 12012–12038. [CrossRef]
19. Huang, J. Mantenimiento predictivo en el borde. Blog de Edge Impulse. 2022. Disponible en línea: https://www.edgeimpulse.com/blog/mantenimiento predictivo en el extremo/ (Consultado el 7 de diciembre de 2025).
20. Khan, SW; Hafeez, Q.; Khalid, MI; Alroobaea, R.; Hussain, S.; Iqbal, J.; Almotiri, J.; Ullah, SS Detección de anomalías en el tráfico Vídeos de vigilancia mediante aprendizaje profundo. Sensors 2022, 22, 6563. [CrossRef] [PubMed]

Machine Translated by Google

21. Alotaibi, SR; Alrayes, FS; Maashi, M.; Maray, M.; Alliheedi, MA; Badawood, D.; Alotaibi, M. Aprovechamiento de la optimización con un enfoque de aprendizaje profundo en un sistema de transporte inteligente para la detección de anomalías en pasarelas peatonales. Sci. Rep. 2025, 15, 17358. [CrossRef]

22. Lim, LH; Ong, LY; Leow, MC Aprendizaje federado para la detección de anomalías: una revisión sistemática sobre escalabilidad, adaptabilidad, y marco de evaluación comparativa. Future Internet 2025, 17, 375. [CrossRef]
23. Shabaz, M.; Raju, KN Predicción del flujo de tráfico y detección de anomalías impulsadas por IA en ciudades inteligentes: un enfoque multiagente. Trans. Emerg. Telecommun. Technol. 2025, 36, e70279. [CrossRef]
24. Wang, F.; Jiang, Y.; Zhang, R.; Wei, A.; Xie, J.; Pang, X. Un estudio sobre la detección profunda de anomalías en series temporales multivariadas: taxonomía, Aplicaciones y direcciones. Sensors 2025, 25, 190. [CrossRef] [PubMed]
25. Chaymae, T.; Mhamed, R.; Soumia, Z. Aprendizaje automático y computación de borde 5G para la gestión inteligente del tráfico. Int. J. Adv. Comput. Sci. Appl. 2025, 16. [CrossRef]
26. Ghasemi, A.; Keshavarzi, A.; Abdelmoniem, AM; Nejati, OR; Derikvand, T. Inteligencia en el borde para sistemas de transporte inteligentes: enfoques, desafíos y direcciones futuras. Expert Syst. Appl. 2025, 280, 127273. [CrossRef]
27. Potharaju, S.; Tirandasu, RK; Tambe, SN; Jadhav, DB; Kumar, DA; Amiripalli, SS Un enfoque de aprendizaje automático de dos pasos para el mantenimiento predictivo y la detección de anomalías en sistemas de sensores ambientales. MethodsX 2025, 14, 103181. [CrossRef]
28. Kummara, R. Edge Computing en ciudades inteligentes: Transformando la infraestructura urbana a través del procesamiento descentralizado. J. Inf. Syst. Ing. Gestionar. 2025, 10, 1063–1080. [Referencia cruzada]
29. Klein, P.; Malburg, L.; Bergmann, R. Combinación de la detección de anomalías basada en datos informados con grafos de conocimiento para la determinación de la causa raíz. Análisis en mantenimiento predictivo. Eng. Appl. Artif. Intell. 2025, 145, 110152. [CrossRef]
30. Sharma, A.; Boora, A.; Kumar, Y. Inteligencia artificial y aprendizaje automático para infraestructura de transporte resiliente. Cureus J. Ciencias de la Computación 2025, 2, 1–16. [CrossRef]
31. Bawaneh, M.; Simon, V. Detección de anomalías basada en aprendizaje automático en el tráfico de ciudades inteligentes: comparación de rendimiento y perspectivas. En Actas de la 11ª Conferencia Internacional sobre Tecnología de Vehículos y Sistemas de Transporte Inteligentes (VEHITS 2025), Oporto, Portugal, 1-3 de abril de 2025; págs. 309-318.
32. García-Méndez, S.; de Arriba-Pérez, F.; Leal, F.; Veloso, B.; Malheiro, B.; Burguillo-Rial, JC. Un marco de aprendizaje automático explicable para el mantenimiento ferroviario predictivo utilizando flujos de datos del operador de metro portugués. Ciencia. Rep. 2025, 15, 27495. [CrossRef]
33. Rojas, L.; Peña, Á.; García, J. Mantenimiento predictivo impulsado por IA en minería: una revisión sistemática de la literatura sobre detección de fallas, Gemelos digitales y gestión inteligente de activos. Appl. Sci. 2025, 15, 3337. [CrossRef]

Aviso legal/Nota del editor: Las declaraciones, opiniones y datos contenidos en todas las publicaciones son responsabilidad exclusiva de sus autores y colaboradores, y no de MDPI ni de sus editores. MDPI y sus editores no se responsabilizan de los daños a personas o bienes que pudieran derivarse de las ideas, métodos, instrucciones o productos mencionados en el contenido.