Machine Translated by Google

sensores

MDPI

Artículo

Detección de anomalías en vídeos de vigilancia de tráfico mediante Aprendizaje profundo

Sardar Waqar Khan [1] Qasim Hafeez [2], Muhammad Irfan Khalid [3], Roobaea Alroobaea [4], Saddam Hussein [5,*], Jawaid Iqbal [6] Jasem Almotiri [4] y Syed Sajid Ullah [7,8,*]

1 Departamento de Tecnologías de la Información, Universidad de Sialkot, Sialkot 51040, Pakistán
2 Facultad de Ingeniería Física e Informática, Universidad de Hertfordshire, Hatfield AL10 9AB, Reino Unido
3 Departamento de Ingeniería de la Información y Eléctrica y Matemáticas Aplicadas, Universidad de Salerno, 84084 Fisciano, SA, Italia
4 Departamento de Ciencias de la Computación, Facultad de Informática y Tecnologías de la Información, Universidad de Taif, PO Box 11099, Taif 21944, Arabia Saudita
5 Departamento de Ciencias de la Computación, Universidad Capital de Ciencia y Tecnología, Islamabad 44000, Pakistán
6 Escuela de Ciencias Digitales, Universiti Brunei Darussalam, Jalan Tungku Link, Gadong BE1410, Brunei
7 Departamento de Tecnologías de la Información y la Comunicación, Universidad de Agder (UiA), N-4898 Grimstad, Noruega
8 Departamento de Ingeniería Eléctrica e Informática, Universidad de Villanova, Villanova, PA 19085, EE. UU.
* Correspondencia: saddamicup1993@gmail.com (SH); syed.s.ullah@uia.no (SSU)

Resumen: En el pasado reciente, se ha colocado una gran cantidad de cámaras en una variedad de espacios públicos y privados. áreas privadas con fines de vigilancia, monitoreo de acciones humanas anormales y tráfico vigilancia. La detección y el reconocimiento de actividad anormal en un entorno del mundo real es un gran desafío. desafío, ya que puede haber muchos tipos de actividades alarmantes y anormales, como robos, violencia, y accidentes. Esta investigación trata sobre accidentes en videos de tráfico. En el mundo moderno, el tráfico en video Las cámaras de vigilancia (VTSS) se utilizan para la vigilancia y el monitoreo del tráfico. A medida que la población está aumentando drásticamente, la probabilidad de accidentes también está aumentando. El VTSS se utiliza para detectar eventos o incidentes anormales relacionados con el tráfico en diferentes carreteras y autopistas, como atascos de tráfico, congestión de tráfico y accidentes de vehículos. En la mayoría de los accidentes, las personas están indefensas y algunas mueren debido a la falta de disponibilidad de atención médica de emergencia en carreteras largas y en aquellos lugares que están lejos de las ciudades. Esta investigación propone una metodología para detectar accidentes automáticamente mediante vigilancia. videos. Una revisión de la literatura sugiere que las redes neuronales convolucionales (CNN), que son un enfoque especializado de aprendizaje profundo, pionero en trabajar con datos en forma de cuadrícula, es eficaz en imágenes y análisis de video. Esta investigación utiliza CNN para encontrar anomalías (accidentes) en videos capturados por el VTSS e implementar un algoritmo de predicción rodante para lograr una alta precisión. En el entrenamiento de El modelo CNN, un conjunto de datos de imágenes de accidentes vehiculares (VAID), compuesto por imágenes con anomalías, fue construido y utilizado. Para probar la metodología propuesta, se verificó el modelo CNN entrenado. en múltiples videos, y los resultados fueron recopilados y analizados. Los resultados de esta investigación muestran la detección exitosa de eventos de accidentes de tráfico con una precisión del 82% en la vigilancia del tráfico vídeos del sistema.

Palabras clave: aprendizaje profundo; clasificación de vídeo; detección de accidentes; sistema de vigilancia; anomalía detección

check for updates

Cita: Khan, SW; Hafeez, Q.; Khalid, MI; Alroobaea, R.; Hussain, S.; Iqbal, J.; Almotiri, J.; Ulá, SS Detección de anomalías en el tráfico Vídeos de vigilancia mediante Deep Aprendizaje. Sensores 2022, 22, 6563. https://doi.org/10.3390/s22176563

Editores académicos: Zhe-Ming Lu y Amin Ullah

Recibido: 25 de junio de 2022
Aceptado: 26 de agosto de 2022
Publicado: 31 de agosto de 2022

Nota del editor: MDPI mantiene una postura neutral. con respecto a las reclamaciones jurisdiccionales en mapas publicados y afiliación institucional citas.

Derechos de autor: © 2022 por los autores. Titular de la licencia: MDPI, Basilea, Suiza. Este artículo es de acceso abierto. distribuido bajo los términos y condiciones de Creative Commons Licencia de atribución (CC BY) (https://creativecommons.org/licenses/by/4.0/).

1. Introducción

El proceso mediante el cual se monitorean el comportamiento y las actividades para gestionar y proteger a las personas se llama vigilancia. El método más popular para observar comportamientos interesantes La visualización de objetos a distancia se realiza mediante dispositivos de Internet de las Cosas (IoT), como circuitos cerrados. cámaras de televisión (CCTV). Se logra una mejora en la calidad de vida mediante la implementación inteligencia artificial en dispositivos IoT [1,2]. En los últimos años, un gran número de CCTV

Machine Translated by Google

Se instalaron cámaras en varias áreas públicas y privadas para la seguridad y el monitoreo de actividades y tráfico anómalos. Estas cámaras pueden ayudar a encontrar anomalías y tomar medidas en consecuencia [3]. Actualmente, la detección de anomalías es un tema emergente para investigadores en diferentes dominios como la industria, los negocios, el fraude móvil, la salud y las actividades locales de las personas [4–6]. La detección de anomalías es muy beneficiosa para proteger y salvar las propiedades de los bienes públicos y privados. Las cámaras de vigilancia se utilizan con fines de seguridad o para encontrar eventos anómalos [7] o irregularidades [8] en lugares públicos o privados. En 2017, se instalaron 954,261 cámaras de CCTV en lugares públicos en Corea del Sur, lo que representó un aumento del 12.9% con respecto al año anterior [9]. Las cámaras de vigilancia brindan la capacidad de detectar actividades anómalas y comportamientos anormales en el mundo real.

La detección de anomalías basada en imágenes (AD) es el proceso de identificar una imagen que no es visible como perteneciente a las clases regulares (inliers) o a las clases anómalas (outliers) mediante el aprendizaje a partir de imágenes normales utilizadas para el entrenamiento. Esto es de gran importancia en situaciones del mundo real, como la monitorización de eventos anómalos mediante cámaras de vigilancia, ya que la mayoría de los datos son normales, pero la detección de datos anómalos es necesaria. Un desafío importante en la detección de anomalías en imágenes (AD) es aprender datos discriminativos únicamente a partir de imágenes de apariencia normal en el entrenamiento de clases [10].

El sector del transporte también se enfrenta a numerosos problemas con el aumento de la población, como la congestión del tráfico, los atascos y los accidentes de tráfico. En el mundo actual, se utilizan nuevas tecnologías para superar este tipo de problemas. En casi todos los países desarrollados, se han implementado sistemas de videovigilancia (VCSS) en carreteras locales, estaciones de ferrocarril, aeropuertos, calles, autopistas, aparcamientos, autovías y otros lugares de alta prioridad [11]. Los VCSS reducen la intervención humana en la monitorización y captura de la actividad del tráfico, presentan automáticamente al usuario una transmisión en tiempo real de ubicaciones remotas importantes y almacenan la transmisión en forma de vídeos. Los VCSS instalados se utilizan para la detección y el seguimiento de vehículos, la clasificación de vehículos, la estimación del flujo de tráfico, anomalías, accidentes de tráfico, etc., y son utilizados activamente por las fuerzas del orden y otros departamentos.

La instalación de un VCSS no elimina por completo la intervención humana, ya que se requiere la supervisión constante de una persona para detectar anomalías como accidentes de tráfico, bloqueos, etc. Los investigadores en este campo también están trabajando para automatizar esta parte mediante el desarrollo de algoritmos y soluciones sofisticadas para la detección de anomalías en vídeo. Investigaciones recientes en detección de anomalías han demostrado que la clasificación binaria (normal y anormal) proporciona resultados precisos y eficaces [12]. Sin embargo, este método presenta limitaciones debido a la escasez de vídeos de eventos a

Por lo tanto, los investigadores también han presentado una nueva categoría de técnicas que requieren poca o ninguna supervisión, incluyendo el aprendizaje de diccionarios [13], características espaciotemporales [14,15] y autoencoders [16], que entrenan los modelos computacionales con actividades normales y el comportamiento habitual del entorno monitorizado. Encontrar un conjunto de datos para el comportamiento habitual del entorno no es difícil, ya que la mayoría de los datos de vigilancia disponibles se componen de actividades normales. Durante la fase de prueba, estas técnicas fueron capaces de detectar eventos anómalos debido a desviaciones de las actividades normales.

Esta investigación se centra en la detección de un tipo de anomalía, concretamente accidentes de tráfico, a partir de vídeos mediante una red neuronal convolucional (CNN), un tipo especial de red neuronal artificial . Para la vigilancia del tráfico, se utiliza un sistema de vigilancia de tráfico basado en vídeo (VTSS) con capacidades adicionales . Para entrenar el modelo CNN y detectar anomalías en un vídeo, se requiere una gran cantidad de datos, ya que el modelo se entrena para reconocer diferentes tipos de accidentes de tráfico. El VTSS permite generar los datos necesarios para el entrenamiento del modelo CNN. Con el tiempo, los VTSS se han ido mejorando y optimizando en la recopilación, el almacenamiento y la limpieza de datos, por lo que existe una cantidad considerable de contenido disponible en línea. Sin embargo, el crecimiento continuo de los datos y la incorporación de diferentes tipos de anomalías exigen que la metodología propuesta sea generalizable, lo que convierte la detección de anomalías en una tarea comple

Machine Translated by Google

En esta investigación, se busca detectar accidentes de tráfico analizando imágenes de fotogramas en videos del Sistema de Vigilancia de Tráfico (VTSS) para brindar asistencia a las personas afectadas . Además, el sistema facilita el trabajo del personal que supervisa las múltiples pantallas del VTSS. Esta investigación utiliza un algoritmo supervisado, específicamente una red neuronal convolucional (CNN), para identificar las características distintivas del comportamiento anómalo. Para ello, se entrena el modelo CNN con imágenes del accidente. El autoencoder convolucional integrado en el modelo CNN se utiliza para aprender los patrones espaciales de las imágenes. El modelo CNN entrenado se emplea para clasificar los fotogramas de los videos de tráfico, cuyos resultados se recopilan y analizan como parte de la experimentación de la metodología propuesta.

El VTSS es un sistema de vigilancia de tráfico que se utiliza para monitorear la circulación vehicular. La señal de video que proporciona el VTSS se utiliza para detectar cualquier actividad anómala y tomar las medidas correspondientes. La intervención humana es indispensable para observar las anomalías detectadas por el VTSS. Esta investigación tiene como objetivo desarrollar una técnica para detectar automáticamente accidentes de tráfico, que constituyen un tipo de anomalía, en un vídeo.

Contribución

- En esta investigación proponemos una mejora en el VTSS mediante la integración con nuestra técnica propuesta para la detección automática de accidentes en una transmisión de video.
- Proponemos un método novedoso de clasificación de video mediante la integración de la salida de la CNN. Algoritmo de predicción de promedio móvil del modelo.
- Durante esta investigación, se creó un conjunto de datos de imágenes de accidentes de vehículos (VAID) para entrenar la CNN. El conjunto de datos consta de 1360 imágenes capturadas por cámaras normales y el VTSS.

La estructura general del artículo se resume a continuación: La sección 2 examina trabajos relacionados, mientras que la sección 3 define brevemente la metodología propuesta. La sección 4 trata sobre la implementación. La sección 5 se refiere a los experimentos y profundiza en los resultados y la discusión, y la sección 6 presenta las conclusiones.

2. Obras relacionadas

En trabajos relacionados, estudiamos los sistemas de vigilancia y su funcionamiento. También analizamos su utilidad para detectar actividades anómalas en lugares públicos o privados, así como en carreteras y autopistas. Esto nos permitió determinar qué algoritmo de aprendizaje profundo es el más adecuado para el análisis de imágenes o vídeos.

El proceso de monitorear el comportamiento y la actividad para gestionar y proteger a las personas se denomina vigilancia. El sistema de vigilancia es utilizado principalmente por organizaciones médicas y de seguridad. El mejor método de vigilancia consiste en observar objetos y personas a larga distancia mediante cámaras. Estas se denominan cámaras CCTV, y el sistema en cuestión se conoce como sistema de videovigilancia (VCSS). El sistema de videovigilancia ha sido muy popular en los últimos años debido a su bajo coste de hardware y a las altas preocupaciones de seguridad que ofrece. Estos sistemas se utilizan para detectar comportamientos anómalos e identificar actividades irregulares y patrones anormales en los datos de vídeo [17,18].

En la era moderna, estos sistemas de vigilancia también se utilizan para seguir o monitorear el tráfico. Estos sistemas son sistemas de vigilancia de tráfico (VTSS). Estos sistemas generan una gran cantidad de datos en forma de videos. Varun Chandola [7] explicó las anomalías y sus tipos. Una anomalía es una forma de patrones en los datos que no se comportan normalmente.

Estos patrones se mencionan como anomalías, sorpresas, discordancias, expectativas, valores atípicos, peculiaridades, observaciones o contaminantes en diversos dominios de aplicación. La detección de anomalías es un método que se utiliza para encontrar patrones irregulares en los datos que siguen el comportamiento esperado. Muchos autores e investigadores han realizado sus investigaciones sobre detección de anomalías basadas en la clasificación de imágenes y vídeos. Mehrsan Javan y Martin D. Levine [19] describieron el método para encontrar anomalías en vídeos densos basado en el volumen espaciotemporal.

El entrenamiento proporciona ejemplos de comportamientos normales. Este tipo de evento ocurre en tiempo real a partir de un video densamente muestreado cuando se captura en la región espaciotemporal de actividad anómala. Mediante el uso de un marco de probabilidad, se modela el volumen de video, que se basa en

Machine Translated by Google

en la composición espaciotemporal. El marco calcula la probabilidad de comportamiento normal en el video. Se utiliza el marco de probabilidad. Disminuye el tiempo para calcular la similitud. Esta técnica es mucho más rápida que los métodos IBC y MDT. M. Sabokrou, M. Fathy y M. Hoseini [20] presentaron un método preciso y rápido para la localización de anomalías y detección de anomalías en video. Utilizaron un clasificador en cascada para la detección de anomalías en el video, en el que se involucraron dos fases basadas en el análisis de SV (valor espacial) y RE. Este método fue propuesto para la detección rápida de anomalías.

Xinyi Cui et al. [21] presentaron una nueva técnica para describir el estado actual del comportamiento de un sujeto basándose en la posición/velocidad del sujeto y sus vecinos. Utilizaron la función de potencial de energía de interacción. Para esta técnica, el comportamiento social se capturó mediante la relación entre su acción y potencial de energía. Para esta técnica, utilizaron una máquina de vectores de soporte para considerar el patrón raro de energía-acción como una anomalía. Este método propuesto aprovecha la relación entre el estado actual de una persona y sus reacciones. Además, esta técnica no depende de algoritmos de seguimiento y detección humana, y su rendimiento es mucho mejor en los conjuntos de datos BEHAVE y UMN.

Cem Direkoglu y Melike Sah [22] presentaron un nuevo flujo óptico basado en características utilizado para la detección de comportamiento anormal de una multitud. Funciona a nivel de píxel. Este método toma diferencias de ángulo en cada nivel de píxel para encontrar comportamiento anómalo. Además, compara la diferencia de ángulo del fotograma actual con el anterior. Para detectar comportamiento normal, se utiliza una máquina de vectores de soporte simple de una clase. Además, realizaron experimentos en los conjuntos de datos UMN y PETS2009. Shifeng Li y Chunxiao Liu [23] introdujeron el marco MAP para la detección de anomalías utilizando conocimiento previo.
El marco bayesiano se integra con el conocimiento previo para la detección de anomalías. La función de verosimilitud se calcula mediante la plantilla de cuadrícula máxima. Este experimento proporciona resultados muy eficaces en situaciones complejas.

Habib Ullah [24] describió el flujo de peatones y detectó anomalías en una zona concurrida. Propuso el modelo GKIM para la detección y localización de objetos anómalos en el flujo peatonal. Calculó la tasa de error de detección (EER) y la tasa de detección (DR) tanto a nivel de píxel como a nivel de fotograma. En el análisis a nivel de fotograma, la detección de entidades anómalas se basa en su ubicación, y en el análisis a nivel de píxel, este método localiza la entidad anómala en función de su píxel.

En un método de V. Ravindran [25], se utilizaron el procesamiento de imágenes y el aprendizaje automático para detectar automáticamente accidentes de tráfico utilizando la imagen estática de la cámara, que se colocó en carreteras y calles. Un solo fotograma es la combinación de tres pasos que permiten analizar accidentes utilizando la imagen estática. Esto utiliza máquinas de vectores de soporte (SVM) entrenadas en grafos geográficos HOG y GLCM geográficos. Esta etapa propone un método para encontrar automáticamente accidentes de tráfico. El segundo paso es una técnica de aprendizaje supervisado que detecta coches rayados como una serie de imágenes estáticas. Esta es una nueva categoría de objetos que los métodos de visión artificial no han podido ver. La etapa final incluye dos conjuntos de datos de coches dañados, DCD-1 y DCD-2, que son gratuitos. Esta modificación se basa en la distancia para capturar la calidad de las imágenes. La precisión del sistema es del 82 % en el conjunto de datos de coches dañados-1, que se capturó a aproximadamente 2 m utilizando alta calidad. La precisión fue del 64 % en DCD2, que capturó los siguientes 20 m con la misma característica. La técnica de visión artificial tuvo éxito en la localización de coches dañados. Este proyecto tiene una desventaja importante: no puede encontrar coches que han sufrido daños graves.

Shivangi [26] propuso un modelo basado en IoT para identificar accidentes e informar a las autoridades lo antes posible. El vehículo estaría equipado con sensores inteligentes y microcontroladores que se activarían durante un accidente. Este sistema permite combinar otros módulos para llegar al lugar del accidente y enviar la información a un hospital cercano. Este modo de comunicación inalámbrica envía mensajes mediante GPS y GSM.

Ahmar Azam [27] propuso un sistema de prevención de accidentes basado en IoT que utiliza un detector para comprobar el alcohol y un acelerómetro. Arduino Nano es el sensor de alcohol. Un módem GSMC, o GSM, gestiona los SMS. El motor del vehículo se muestra mediante GPS (sistema de posicionamiento global), una pantalla LCD y un ventilador de CPU. El dispositivo utilizado para leer el alcohol

Machine Translated by Google

Detecta la salida de resistencia equivalente, que permite la absorción de alcohol. El módulo GSM permite la transmisión entre teléfonos móviles, el sistema de detección de accidentes y el sistema de notificación. El GPS localiza el lugar del accidente y envía estas señales de microondas a los satélites.

G. Liang [28] presentó la detección automática de accidentes con la ayuda de una SVM modificada por el algoritmo de colonia de hormigas (ACA). Esto permite predecir accidentes de tráfico. Aquí se utiliza el Internet de las Cosas (IoT), que es el mecanismo general del transporte inteligente. Se emplearon tecnologías como RFID y comunicación inalámbrica. Estas se utilizan para registros de movimiento en la vida real para la predicción y configuraciones estándar de tráfico vial para mejorar la evaluación de la situación. La SVM reformada y mejorada por ACA pudo lograr velocidades de fusión más rápidas. Además, los errores cuadráticos medios, que están relacionados con las SVM simples, fueron más severos. El algoritmo de colonia de hormigas demostró ser eficiente.

Tian wang [29] propuso un marco para el análisis y la representación. Sin seguimiento de objetos, extrae características visuales basadas en el flujo óptico. Utiliza SVM de una clase y PCA para encontrar comportamientos anómalos. Es una técnica de aprendizaje supervisado, ya que buscan que aprenda los comportamientos regulares. Este proceso tiene tres pasos principales. Primero, utilizando la técnica de flujo óptico HornCSchunk (HS) en escala de grises, calcula el flujo óptico de fotogramas individuales. Segundo, cada fotograma calcula el HOFO (histograma de orientación del flujo óptico). Para ahorrar tiempo, no considera el área de fondo. Por lo tanto, utiliza los dos clasificadores anteriores para la clasificación de características de video de vigilancia. Muestra buenos resultados en la escena PET y el conjunto de datos UMN. Las limitaciones de este algoritmo son que no hay entrenamiento en línea y hay altas tasas de falsas alarmas. Debido a la amplia disponibilidad de datos y procesadores a precios más económicos, en muchos dominios los enfoques de aprendizaje profundo demostraron su notable rendimiento en áreas como la detección de anomalías [30], la detección de objetos [31,32], el modelado de temas [33], la clasificación de imágenes [34], la segmentación semántica [35], el seguimiento visual [36,37], el aprendizaje de representaciones [38], etc.

Ren et al. [39] expresaron el efecto de correlación espaciotemporal en los datos relacionados con accidentes de tráfico y crearon un modelo de red neuronal recurrente para la predicción del riesgo de accidentes. Es un sistema proactivo para evaluar los accidentes de tráfico relacionados. Las características adicionales, como el tráfico y las características de la carretera, también se pueden usar para mejorar la precisión. Bortnikov et al. [40] crearon el modelo de detección de accidentes, una red neuronal convolucional 3D. Para entrenar el modelo, produjeron videos de tráfico en juegos. Se aplicaron dos funciones de pérdida para la prueba con y sin flujo óptico. Este modelo se aplicó a videos de tráfico del mundo real. Tian et al. [41] propusieron el modelo de aprendizaje profundo usando el algoritmo de detección de objetos You Only Look Once (YOLO) para accidentes de coche. También se usó para recopilar otra información, como la ubicación del accidente. Para obtener precisión y detección en tiempo real, este modelo tiene una función de pérdida multiescala y una técnica para la fusión de características con pesos vitales.

Ohgushi et al. [42] utilizaron un autoencoder con segmentación para detectar obstáculos en las carreteras. El codificador del autoencoder es un generador de imágenes semánticas y el decodificador es un generador de imágenes fotográficas. Esta técnica funciona de forma no supervisada, de modo que el modelo se entrena en una carretera normal. Además de otro enfoque de aprendizaje profundo para la vigilancia del tráfico presentado por Yao et al. [43], se utilizan técnicas de seguimiento de objetos y actividades inusuales . El enfoque de aprendizaje no supervisado se utiliza para vídeos capturados por cámaras de salpicadero. En esta técnica, el modelo se entrena con eventos normales. Durante las pruebas, los patrones que se desvían de la normalidad se consideran anomalías.

Zhang Minli [44] describió una red neuronal artificial. Una RNA está altamente inspirada en el sistema nervioso biológico (como el cerebro humano). La RNA consta de tres capas: la capa de entrada, la capa de salida y la capa oculta. La capa oculta puede constar de una o más capas. Cada capa tiene un número diferente de neuronas. Su transmisión es hacia adelante o reversible. La entrada x es proporcionada por la capa de entrada. Algunas capas ocultas realizan algunos procesos sobre esta entrada, e y es el valor predicho que es el resultado generado por la

Machine Translated by Google

capa de salida. Las redes neuronales artificiales tienen muchas ventajas, pero la principal es que pueden resolver fácilmente problemas de incertidumbre, multifactoriales y no lineales.

Keiron O'Shea [45] describió brevemente las redes neuronales convolucionales (CNN). Son una forma de ANN. Se utilizan básicamente para reconocer patrones en imágenes. Además, se utilizan para reducir los parámetros para construir un nuevo modelo. Las CNN tienen cinco capas múltiples: la capa de entrada, la capa convolucional, la capa de agrupación, la capa totalmente conectada y la capa de salida. La capa de entrada tiene los valores de los píxeles en la imagen. Las capas convolucionales aplican un peso a los valores y obtienen el producto escalar de ambos. La función ReLU se utiliza para aplicar funciones de activación, como la sigmoide, a la salida de la capa anterior. La capa de agrupación se utiliza para reducir la dimensionalidad espacial de cualquier entrada y disminuir el número de parámetros en esa activación. Las capas totalmente conectadas funcionan como ANN simples. Obtienen una puntuación de la función de activación y la utilizan para la clasificación. La función ReLU se puede utilizar en estas capas para aumentar el rendimiento.

Andrej Karpathy y George Toderici [46] analizaron brevemente el rendimiento de las CNN en una gran cantidad de clasificaciones de vídeo. Obtuvieron arquitecturas de CNN con la capacidad de aprender características a partir de datos parcialmente etiquetados. Utilizaron el conjunto de datos UCF-101 para el experimento. Se observó que el modelo de fotograma único siempre presenta un mejor rendimie También indicaron que una arquitectura mixta que combine flujos de alta resolución y contexto de bajo nivel será una forma eficaz de aumentar la velocidad de las CNN sin perder precisión. Además, al reentrenar tres capas de la CNN, obtuvieron la mayor tasa de aprendizaje por transferencia.

Guilhem Cheron e Ivan Laptev [47] propusieron un nuevo enfoque para la red neuronal convolucional, denominado red neuronal convolucional basada en la pose (P-CNN). Su objetivo era reconocer acciones humanas en vídeo. Mediante el seguimiento de las partes del cuerpo humano, recopilaron información sobre su movimiento. Implementaron este enfoque en los conjuntos de datos de cocina JHMDB y MPII. En ambos conjuntos de datos, el enfoque propuesto demostró una mejora con respecto a los métodos de vanguardia.

CNN también demostró su eficacia al predecir correctamente patrones anómalos de enfermedades a partir de imágenes médicas, como tumores cerebrales en imágenes de resonancia magnética [48], la enfermedad por coronavirus en radiografías de tórax [49] y la detección temprana del cáncer de mama [50]. Se utiliza una estrategia automatizada para la clasificación de anomalías, así como para la localización y recuperación de informes de las anomalías identificadas. MSDNet presenta un conjunto de modelos neuronales convolucionales para clasificar anomalías, que combina las capacidades de varios modelos CNN para mejorar la precisión de la clasificación. El modelo propuesto también se diseñó para localizar y mostrar la anomalía detectada en la radiografía, utilizando un algoritmo de detección de regiones anómalas que mejora aún más la calidad del diagnóstico.

A diferencia de los métodos tradicionales, la CNN puede detectar automáticamente las características de las señales de vibración en el dominio del tiempo sin necesidad de procesamiento. Para lograr un diagnóstico inteligente y mejorar la precisión del reconocimiento, el modelo WKCNN sigue la idea de ampliar los núcleos de convolución para obtener una mayor área receptiva y propone un patrón de diseño basado en este concepto [51].

Se está investigando el proceso de detección de anomalías de la red de monitoreo inteligente de autopistas, que se basa en computación de borde y aprendizaje profundo, para mejorar el monitoreo en tiempo real de las autopistas. El servidor de procesamiento de borde envía datos de video de las cámaras que forman parte de la estructura de monitoreo inteligente para su filtrado y posterior transferencia a las redes neuronales convolucionales. El modelo CNN emplea un histograma de flujo óptico, que es una técnica multiescala para procesar las imágenes de video después del cálculo de borde para producir conjuntos de muestras para el entrenamiento, y envía estos datos al modelo AlexNet para su uso en la extracción de características [52].

Otros algoritmos de aprendizaje automático, como RNN y LSTM, se utilizan principalmente para el procesamiento de datos y del lenguaje. La revisión bibliográfica anterior demuestra que las CNN son más útiles para el análisis visual (imágenes y vídeo). La comparación de los trabajos relacionados se muestra en la Tabla 1.

Machine Translated by Google

Tabla 1. Resumen de diferentes técnicas de aprendizaje automático y aprendizaje profundo para detectar accidentes en diferentes conjuntos de datos.

Autor	Dominio	Conjunto de datos	Algoritmos y herramientas
G. Liang [28]	Detección de accidentes de tráfico mediante SVM e IoT	Datos de tráfico del mundo real, como la señal del campo magnético y la señal de sonido.	Un algoritmo de colonia de hormigas en SVM
V. Ravindean [25]	Detección de accidentes de tráfico mediante técnicas de aprendizaje automático	Imágenes capturadas desde 2 m hasta 20 m.	SVM entrenado con histograma de características de matriz de gradiente y nivel de gris. coexistencia
Shivangi-Sharma [26]	Detección de accidentes automovilísticos mediante IoT	Datos del mundo real	Arduino IDE, GPS y GSM con sensores de frecuencia cardíaca
N. Kumar y otros [27]	Detección de accidentes de vehículos mediante fusión de sensores	1167 observaciones de variación en la velocidad mediante la realización del experimento de rotación.	Naive Bayes (NB), modelo de mezcla gaussiana (GMM) y árbol de decisión Técnicas (DT)
Ren [39]	Un enfoque de aprendizaje profundo para la predicción del riesgo de accidentes de tráfico en toda la ciudad.	Datos del mundo real	Modelo de aprendizaje profundo de LSTM con mejoras
Bortnikov y otros [40]	Detección de accidentes mediante redes neuronales convolucionales 3D para la monitorización automatizada del tráfico en ciudades inteligentes.	Vídeos de tráfico en tiempo real	Un modelo de aprendizaje profundo Red neuronal convolucional 3D
Tian et al. [41]	Un método automático de detección de accidentes automovilísticos basado en sistemas cooperativos de infraestructura vehicular.	Conjunto de datos CAD-CVIS	modelo de red neuronal profunda YOLO-CA
Ohgushi y otros [42]	Método de detección de obstáculos en la carretera basado en un autoencoder con segmentación semántica.	conjunto de datos de anomalías en carreteras	Autoencoder con segmentación semántica
Yao y otros [43]	Detección de accidentes de tráfico sin supervisión en vídeos en primera persona	Vídeos de cámaras montadas en el salpicadero	Método de localización de objetos futuros

3. Metodología El

enfoque propuesto comienza con la recopilación de imágenes de accidentes o choques automovilísticos utilizando videos de VTSS. Se utilizó un modelo de aprendizaje automático (ML) de la familia de redes neuronales artificiales conocidas como redes neuronales convolucionales (CNN) para crear un modelo de detección de anomalías. El modelo de detección de anomalías se entrenó con un subconjunto de los datos recopilados. Finalmente, el modelo entrenado se utilizó para clasificar los datos sin etiquetar. Los resultados fueron Luego se compararon con los resultados reales para evaluar el desempeño del modelo en la detección de anomalías. El diagrama de flujo general de la metodología se muestra en la Figura 1.

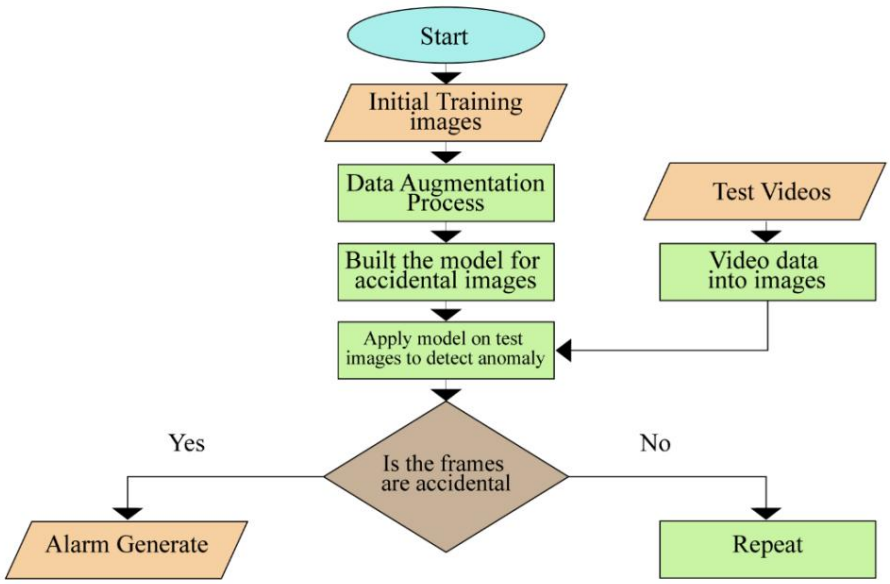


Figura 1. Diagrama de flujo de la metodología. El primer paso es inicializar las imágenes de entrenamiento. El segundo paso es un proceso de aumento de datos. El tercer paso es construir el modelo para imágenes de accidentes. El cuarto paso es aplicar el modelo a las imágenes. El quinto paso es la detección de una anomalía en los fotogramas. cuarto paso es aplicar el modelo a las imágenes. El quinto paso es la detección de una anomalía en los fotogra El último paso consiste en generar la alarma o repetir el algoritmo.
El último paso consiste en generar la alarma o repetir el algoritmo.

3.1. Red neuronal convolucional en aprendizaje profundo para la detección de anomalías

El aprendizaje profundo (DL) es una categoría de redes neuronales artificiales (ANN). Las ANN en DL constan de al menos tres capas, donde la primera capa es para la entrada, la última capa es para la salida y las capas intermedias son capas ocultas [53]. La arquitectura general de una

Machine Translated by Google

Figura 1. Diagrama de flujo de la metodología. El primer paso es inicializar las imágenes de entrenamiento. El segundo paso es un proceso de aumento de datos. El tercer paso es construir el modelo para imágenes de accidentes. El cuarto paso es aplicar el modelo a las imágenes. El quinto paso es la detección de una anomalía en ti. El paso final es generar la alarma o repetir el algoritmo.

3.1. Red neuronal convolucional en aprendizaje profundo para la detección de anomalías

3.1. Red neuronal convolucional en aprendizaje profundo para la detección de anomalías

El aprendizaje profundo (DL) es una categoría de redes neuronales artificiales (RNA). El aprendizaje profundo (DL) es una categoría de redes neuronales artificiales (RNA). Las RNA DL consta de al menos tres capas, donde la primera capa es para la entrada, la última capa i en DL consta de al menos tres capas, donde la primera capa es para la entrada, la última capa es para salida, y las capas intermedias son capas ocultas [53]. La salida arquitectónica general, y las capas intermedias son capas ocultas [53]. La arquitectura general de una

En la Figura 2 se muestra una red neuronal convolucional (CNN) para la detección de anomalías.

En la Figura 2 se muestra una red neuronal convolucional (CNN) para la detección de anomalías .

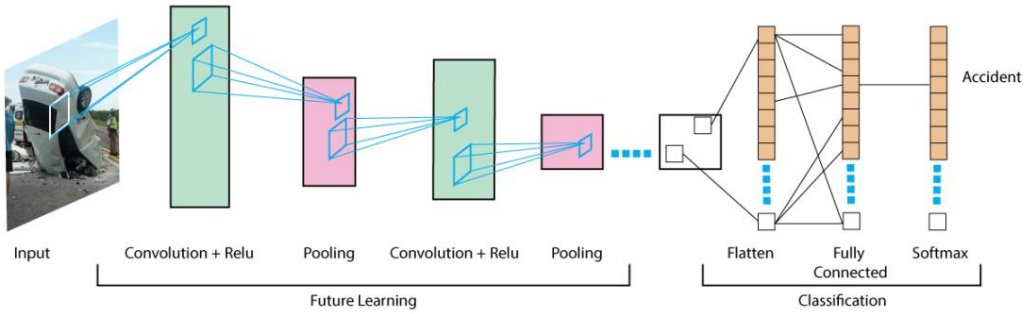


Figura 2. Arquitectura de CNN para detección de anomalías. En esta arquitectura, la capa de entrada i imágenes, se implementan dos procesos principales en ellas, aprendizaje futuro y clasificación. El futuro El proceso de aprendizaje consta de capas convolucionales con funciones de activación y capas de agrupación. El proceso de clasificación consta de una capa de aplanamiento, una capa totalmente conectada y una función de activación softmax.

Figura 2. Arquitectura de CNN para detección de anomalías. En esta arquitectura, la capa de entrada proporciona imágenes, se implementan dos procesos principales en ellas, aprendizaje futuro y clasificación. El futuro El proceso de aprendizaje consta de capas convolucionales con funciones de activación y capas de agrupación. El proceso de clasificación consta de una capa de aplanamiento, una capa totalmente conectada y una función de activación softmax.

CNN es una de las principales categorías de redes neuronales para la clasificación de imágenes y reconocimiento de imágenes, como se observa en una revisión de la literatura [54] . Un modelo CNN típico

Consta de cinco capas:

- Capa de entrada;
- Capa de convolución;
- Capa de agrupación;
- Capa totalmente conectada;
- Capa de salida.

CNN es una de las principales categorías de redes neuronales para la clasificación de imágenes y

Consta de cinco capas:

• Capa de entrada;

• Capa de convolución;

• Capa de agrupación;

• Capa totalmente conectada; •

• Capa de salida.

La arquitectura general de una CNN se basa en tres módulos. El diagrama de bloques de La arquitectura general de una CNN se basa en tres módulos. El diagrama de bloquesde Los módulos de la CNN se muestran en la Figura 3, incluyendo:

- Entrada;
- Capacitación;
- Clasificación.

Los módulos de la CNN se muestran en la Figura 3, incluyendo:

• Entrada; •

Entrada,

Capacitación; •

Capacitación;

• Clasificación.

• Clasificación.

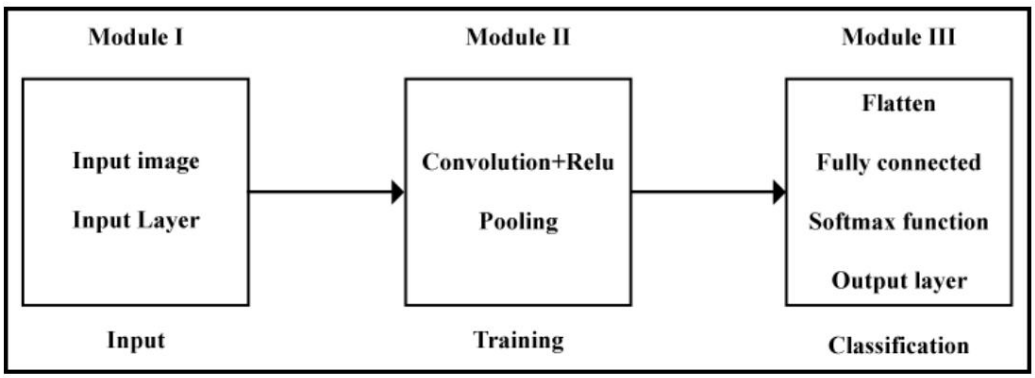


Figura 3. Diagrama de bloques de los módulos CNN. Consta de tres módulos principales. El primer módulo es entrada. Consiste en una capa de entrada o imagen de entrada. El segundo módulo es entrenamiento. Consiste en capas convolucionales y de agrupación. El tercer módulo es de clasificación. Consta de capas convolucionales y de agrupación totalmente conectadas. El tercer módulo es de clasificación. Consta de capas totalmente conectadas. capa, una función de activación y una capa de salida.

Figura 3. Diagrama de bloques de los módulos CNN. Consta de tres módulos principales. El primer módulo es entrada . Consiste en una capa de entrada o imagen de entrada. El segundo módulo es entrenamiento. Consiste en capas convolucionales y de agrupación. El tercer módulo es de clasificación. Consta de capas convolucionales y de agrupación totalmente conectadas. El tercer módulo es de clasificación. Consta de capas totalmente conectadas. capa, una función de activación y una capa de salida.

3.1.1. El número de parámetros en las CNN

En el caso de una CNN, cada capa se compone de dos tipos de parámetros: pesos y sesgos. En total, el número de parámetros utilizados es la suma de todos los sesgos y ponderaciones.

3.1.2. Imagen de entrada

Machine Translated by Google

Figura 3. Diagrama de bloques de los módulos de la CNN. Consta de tres módulos principales. El primer módulo es de entrada. Consta de una capa de entrada o imagen de entrada. El segundo módulo es de entrenamiento. Consta de capas convolucionales y de agrupación. El tercer módulo es de clasificación. Consta de una capa totalmente conectada, una función de activación y una capa de salida.

3.1.1. El número de parámetros en las CNN

3.1.1. En el caso de una CNN, cada capa se compone de dos tipos de parámetros: pesos y sesgos. En total, el número de parámetros utilizados es la suma de todos los sesgos y

En el caso de una CNN, cada capa se compone de dos tipos de parámetros: pesos y sesgos. En total, el número de parámetros utilizados es la suma de todos los sesgos y

pesos.

3.1.2. Imagen de entrada

3.1.2. Imagen de entrada

Una imagen consiste en matrices de píxeles en formato digital, tal como las utiliza y almacena un ordenador.

Una imagen consiste en matrices de píxeles en formato digital, tal como las utiliza y almacena un ordenador.

sistema computarizado. El número de estas matrices depende del tipo de imagen y

número de estas matrices depende del tipo de imagen y

las dimensiones de estas matrices dependen de la resolución de la imagen. La Figura 4 describe

Las dimensiones de estas matrices dependen de la resolución de la imagen. La Figura 4 describe

cómo se puede representar una dimensión de la imagen como h × w × d, donde h es la altura de la

como se puede representar una dimensión de la imagen como h × w × d, donde h es la altura de la

imagen, w es el ancho y d es el número de matrices que representan una imagen. El valor de

imagen, w es el ancho y d es el número de matrices que representan una imagen. El valor de

d es 3 en el caso de una imagen RGB y 1 para una imagen en escala de grises.

d es 3 en el caso de una imagen RGB y 1 para una imagen en escala de grises.

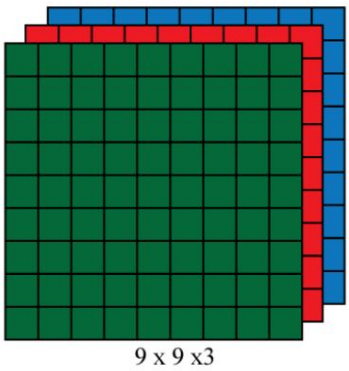


Figura 4. Matriz RGB. Aquí, está representada por nueve columnas , nueve filas y tres canales. canales.

3.1.3. Capa de entrada

3.1.3. Capa de entrada

La capa de entrada de un modelo CNN es responsable de transferir los datos de la imagen a la red. En un modelo CNN, la capa de entrada consta de una matriz que acepta la entrada.

La capa de entrada de un modelo CNN es responsable de transferir los datos de la imagen a la red. En un modelo CNN, la capa de entrada consta de una matriz que acepta la entrada.

imagen como parámetro y reenvía los datos de la imagen a las siguientes capas. Si la imagen consiste en múltiples matrices,

imagen como parámetro y reenvía los datos de la imagen a las siguientes capas. Si la imagen consiste en

luego la imagen se convierte en una sola matriz antes de proporcionarla a la red.

la capa de entrada utilizando otras técnicas disponibles.

3.1.4. Capa convolucional

La segunda capa del modelo CNN es la capa convolucional, que extrae la características de la imagen dada como entradas. Para extraer características de la entrada, esta capa utiliza un pequeño cuadrado de datos de entrada que es igual al tamaño de la matriz del núcleo o del filtro. La matriz del núcleo es una matriz definida por el usuario que se utiliza para mantener partes específicas de la matriz de la imagen. expresadas en las ecuaciones (1) y (2), donde h es la altura de la imagen, w es el ancho de la misma. imagen, d representa el número de canales en RGB y f es el filtro.

$$\begin{matrix} \text{Matriz de imagen } (h \times w \times d) \\ \text{Filtro } (fh \times fw \times d) \end{matrix} \quad (1)$$

$$\text{Salida } (h - fh - 1) \times (w - fw - 1) \times 1 \quad (2)$$

Después de pasar la matriz del kernel por toda la imagen, se obtiene una nueva matriz que se reduce en tamaño y ruido y solo captura el punto de interés de la imagen que se crea, que es llamado mapa de características. La capa convolucional también contiene la ReLU (unidad lineal rectificadora). como función de activación, que permite que la capa de convolución conserve solo los datos positivos. y para agregar no linealidad al modelo CNN. La función ReLU se da en la ecuación (3).

$$f(x) = \max(0, x) \quad (3)$$

Machine Translated by Google

3.1.5. Capa de agrupación

La función de la capa de agrupación es minimizar la masa espacial de la imagen después de un capa convolucional. La capa de agrupación se utiliza principalmente para reducir el tamaño de la imagen de entrada. manteniendo intactas las características importantes de la imagen. Otra razón para agregar el La capa de agrupación sirve para reducir el costo del cálculo, ya que después de esta capa los datos de la imagen son proporcionado a una red neuronal. En la capa de agrupación, se calcula un filtro sobre la salida de la capa convolucional. Hay dos parámetros para la capa de agrupación, uno es un filtro, que es una matriz pequeña, y la otra es un paso, que denota el número de pasos para moverse. filtro después del cálculo. Cada cálculo del filtro sobre los datos da como resultado un único valor que se utiliza para crear una pequeña matriz para la imagen de entrada mientras se conserva el significativo información. La dimensión de la matriz de salida de la capa de agrupación depende del tamaño del filtro, el paso y la imagen de entrada. En la práctica se utilizan varios tipos de agrupamiento:

- Agrupación de sumas;
- Agrupación promedio;
- Agrupación máxima.

3.1.6. Aplanamiento

La matriz de salida de la capa de agrupación se somete primero a una capa de aplanamiento antes de reenviar la información a la red neuronal. La función de la capa de aplanamiento es convertir la matriz en una matriz de valores con un ancho de 1. El propósito de esto La transformación consiste en hacer que la matriz de entrada sea compatible con la red neuronal, ya que

PARES La red neuronal no puede procesar los datos tipo matriz y solo puede procesar un vector de características. En la Figura 5 se muestra una representación visual de esta transformación .

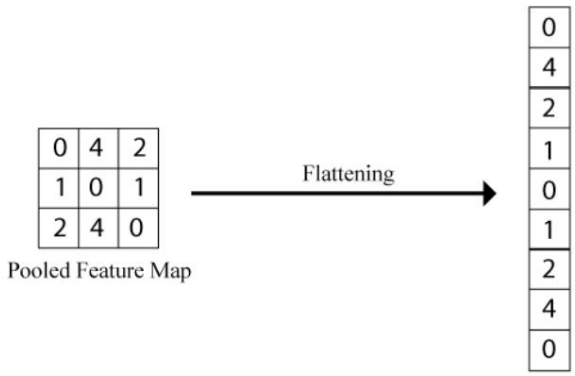


Figura 5. La técnica de aplanamiento presenta toda la matriz en una sola columna.

3.1.7. Capa totalmente conectada

3.1.7. Capa totalmente conectada

La siguiente capa en el modelo CNN es la capa totalmente conectada. Estas capas pueden ser una La siguiente capa en el modelo CNN es la capa totalmente conectada. Estas capas pueden ser una o varias y están compuestas por neuronas. Las neuronas en estas capas están conectadas a o múltiples y están compuestas por neuronas. Las neuronas en estas capas están conectadas a todas las cada neurona en la siguiente capa. Estas capas actúan de manera similar a las capas ocultas en la red neuronas en la siguiente capa. Estas capas actúan de manera similar a las capas ocultas en la red neuronal, donde se lleva a cabo el mismo proceso de aprendizaje para aprender las características extraídas de red, donde se lleva a cabo el mismo proceso de aprendizaje para aprender las características extraídas de la imagen por las capas anteriores. El propósito de esta capa es aprender las características de la la imagen mediante las capas anteriores. El propósito de esta capa es aprender las características de las imágenes y clasificar las imágenes precedentes en función de las características aprendidas. imágenes y clasificar las imágenes precedentes en función de las características aprendidas.

3.1.8. Función Softmax

3.1.8. Función Softmax

Softmax es una función de activación utilizada en la capa de salida de una CNN. La capa totalmente conectada puede utilizar cualquier tipo de función de activación, pero la razón para utilizar Softmax en la capa de salida de una CNN es que proporciona la distribución de probabilidad sobre las clases. La capa conectada puede usar cualquier tipo de función de activación, pero la razón para usar Softmax en La capa de salida de una CNN es que proporciona la distribución de probabilidad sobre las clases. que se utilizan para asignar una clase a las imágenes de entrada. La salida de la función Softmax es una un vector que proporciona la lista de resultados posibles que representan la distribución de probabilidad. que se utilizan para asignar una clase a las imágenes de entrada. La salida de la función Softmax es vector que proporciona la lista de posibles resultados que representan la distribución de probabilidad. La función Softmax se da de la siguiente manera en la ecuación (4). En esta ecuación, S es Softmax, y ción. La función Softmax se da de la siguiente manera en la ecuación (4). En esta ecuación, es Soft-max, representa el vector de entrada y una función exponencial estándar de la función de entrada está representada por .

$$( ) = \sum \quad (4)$$

Machine Translated by Google

representa el vector de entrada, y una función exponencial estándar de la función de entrada está representada por e yi·

$$S(yi) = \frac{yi}{\sum j \, e \, yi} \quad (4)$$

3.1.9. Capa de salida

La última capa de las capas totalmente conectadas es la capa de salida de una CNN, descrita anteriormente. Esta capa utiliza la función Softmax como función de activación, que produce un valor entre 0 y 1, indicando la probabilidad de que una imagen pertenezca a una clase específica. El número de neuronas en la capa de salida es igual al número de clases en las que se debe clasificar una imagen. Todas las neuronas de la capa de salida muestran la distribución de probabilidad de la imagen para las clases, y se asigna a la imagen la clase con la mayor probabilidad .

3.2. Difícil

Esta investigación utiliza la biblioteca Keras para la implementación del modelo CNN. Keras es una biblioteca de Python de código abierto, eficaz y fácil de usar para el desarrollo de redes neuronales artificiales [55]. Keras proporciona una interfaz para bibliotecas de computación numérica bien organizadas, como TensorFlow y Theano, y ofrece API completas que permiten a los usuarios entrenar y desarrollar modelos de redes neuronales con tan solo unas pocas líneas de código.

3.3. Conjuntos de datos anteriores

Para encontrar un conjunto de datos de accidentes de tráfico, se realizó un examen detallado de conjuntos de datos de detección de anomalías de vídeo de uso común , que incluyeron BOSS [56], UMN [20], av- enue [14], entrada del metro [57], salida del metro [57], UCSD Ped1 [58], UCSO Ped2 [58] y UCF [59]. El conjunto de datos UCF [59] consiste en vídeos de vigilancia largos en los que intenta cubrir casi 13 tipos de anomalías del mundo real, incluyendo arresto, agresión, abuso, incendio provocado, tiroteo, pelea, robo, accidente, explosión, hurto en tiendas, vandalismo y robo. Este conjunto de datos consta de 950 vídeos de vigilancia que capturan diferentes tipos de anomalías enumeradas y 950 vídeos normales. El conjunto de datos avenue fue proporcionado y utilizado por C. Lu [14] y consta de 37 vídeos en los que 16 se utilizaron para entrenamiento y 21 para pruebas. El conjunto de datos UMN [20] consta de cinco vídeos diferentes en los que se capturó el comportamiento anómalo de personas caminando y corriendo en sentido contrario. El conjunto de datos USD Ped1 [58] consta de un total de 70 vídeos de vigilancia, de los cuales 34 se utilizaron en la fase de entrenamiento y los otros 36 en la fase de pruebas. Este conjunto de datos también busca capturar el comportamiento anómalo de los peatones. El conjunto de datos USD Ped2 [58] contiene 28 videoclips de vigilancia que también se diseñaron para estudios sobre la detección de anomalías en calles Los eventos normales en este conjunto de datos son peatones caminando, y los eventos anormales son ciclistas, sillas de ruedas, patinadores y corredores. El conjunto de datos de la entrada del metro [57] consiste en un video largo, con una duración de 1 h 36 min, que captura el movimiento de los peatones que entran a la estación de metro. Este conjunto de datos ofrece cinco tipos de eventos anómalos, es decir, merodeo (IT), caminar en dirección incorrecta (WD), interacciones irregulares entre personas (II), falta de pago (NP) y otros. El conjunto de datos de la salida del metro [57] también consiste en un video de 43 min que captura a las personas que salen de la estación de metro. El conjunto de datos BOSS [46] es un conjunto de videos de vigilancia capturados por la cámara en un tren. Consta de 12 videoclips. Los eventos de interés para la detección de anomalías en este conjunto de datos son situaciones de pánico, acoso y personas enfermas. Todos estos conjuntos de datos se utilizan ampliamente en la investigación en detección de anomalías y se utilizan como referencia para comparar los resultados producidos por nuevas técnicas co

3.4. Conjunto de datos de imágenes de accidentes de vehículos (VAID)

Después de revisar los conjuntos de datos disponibles, se observó que el conjunto de datos de accidentes de tráfico no estaba disponible, por lo que se construyó un nuevo conjunto de datos de anomalías basado en accidentes de tráfico. El nuevo conjunto de datos consta de imágenes y videos de accidentes de tráfico. Los detalles para

Machine Translated by Google

Todos los conjuntos de datos anteriores se resumen en la Tabla 2, y las estadísticas para el nuevo conjunto de datos son: dado en la Tabla 3.

Tabla 2. Comparación entre conjuntos de datos en diferentes parámetros como el número de vídeos, entrenamiento vídeos, vídeos de prueba, fotogramas promedio, longitud del conjunto de datos y tipo de anomalía.

conjuntos de datos	Números de Vídeos	Vídeos de formación	Vídeos de prueba	Fotogramas promedio	Longitud del conjunto de datos	Tipo de anomalía
UCSD Ped1 [49]	70	34	36	201	5 minutos	Carritos, motociclistas, Caminando
UCSD Ped2 [49]	28	16	12	163	5 minutos	Carritos, motociclistas, Caminando
Metro Entrada [48]	1	20 minutos	-	121.749	1,5 h	NP, WD, IT, II
Salida del metro [48]	1	5 minutos	-	64.901	1,5 h	NP, WD, IT, II
Avenida [12]	37	16	21	839	30 minutos	Ejecutar, Nuevo objeto, Tirar
UMN [5]	5	3	2	1290	5 minutos	Correr
JEFE [47]	12	8	4	4052	27 minutos	Pánico, Enfermedad, Acoso
UCF [50]	1900	1610	290	7247	128 h	Abuso, arresto, Peleas, incendio provocado

Tabla 3. Conjunto de datos de imágenes de accidentes de vehículos (VAID). Esta base de datos se creó recopilando accidentes. Fotogramas de vídeos de accidentes. Estos fueron recopilados de diferentes plataformas.

Conjunto de datos	Imágenes de entrenamiento	Vídeos de prueba	Tipo de anomalía
SOLO	1360	30	accidentes de tráfico

3.4.1. Colección de imágenes/vídeos

Para construir el conjunto de datos utilizado en esta investigación, se recopilaron imágenes y videos de diferentes fuentes a través de Internet. Las 278 imágenes del conjunto de datos se adquirieron directamente de diferentes repositorios de imágenes tomadas con cámaras de alta resolución (HRC) y disponibles a través de Internet. El resto de las 1082 imágenes se recopilaron convirtiendo el accidente o Convierta videos de accidentes automovilísticos en imágenes aplicando una herramienta de procesamiento de video de terceros llamada DVD. Video Soft Free Studio. Los videos de los que se capturaron las imágenes del accidente fueron la salida de un VTSS disponible a través de Internet. Otra parte del conjunto de datos son las pruebas. videos, que también fueron recopilados de diferentes fuentes en Internet y suman un total de un total de 30 vídeos de prueba. El conjunto de datos resultante consiste en eventos de accidentes de tráfico en carreteras, carreteras y autopistas, y los vehículos capturados teniendo accidentes son automóviles, camiones, autobuses y motocicletas.

Las cámaras de vigilancia de tráfico capturan los accidentes en diferentes entornos, por lo que Para acomodar este efecto en nuestro conjunto de datos, se aseguró que una parte del contenido recopilado fuera en diferentes condiciones ambientales como día, noche, niebla y lluvia. El conjunto de datos El contenido también tiene diferentes resoluciones para hacer que los datos sean más diversos. La figura 6 muestra un subconjunto de imágenes de accidentes donde las primeras cuatro imágenes se tomaron directamente de las disponibles El contenido en línea y las siguientes cuatro imágenes se extrajeron de vídeos recopilados de un sistema VTSS.

La Tabla 2 describe las estadísticas generales del conjunto de datos recién creado, y la distribución es representado en la Figura 7.

3.4.2. Preprocesamiento de datos

Durante el preprocesamiento de las imágenes para entrenar el modelo CNN, las imágenes fueron transformado en una serie de pasos para resolver problemas de compatibilidad y para aumentar el modelo generalización. El primer paso en el preprocesamiento de una imagen de entrada es intercambiar el color. canales, es decir, reorganización de canales RGB para hacer que la imagen sea compatible con Keras. El siguiente paso es redimensionar la imagen de entrada a un tamaño fijo, es decir, 224 × 224, sin tomar la relación de aspecto de la imagen en consideración. En el último paso del preprocesamiento de una En la imagen, se aplica la sustracción de la media, donde se calcula la media para todos los píxeles. valores en la imagen y la media se resta de los valores de los píxeles. La razón detrás

Machine Translated by Google

a través de internet. El resto de las 1082 imágenes se obtuvieron convirtiendo los vídeos de accidentes de coche en imágenes mediante una herramienta de procesamiento de vídeo de terceros llamada Video Soft Free Studio. Los vídeos de los que se capturaron las imágenes de los accidentes son la salida de un VTSS disponible en internet. Otra parte del conjunto de datos son los vídeos de prueba, que también se recopilaron de diferentes fuentes en internet y suman un total de 30 vídeos de prueba. El conjunto de datos resultante consiste en eventos de accidentes de tráfico en carreteras, autopistas y autovías, y los vehículos capturados que sufrieron accidentes son camiones, autobuses y motocicletas.

Este paso consiste en realizar una estandarización a la que se ajusten los demás parámetros, como los pesos y sesgos. El preprocesamiento de una imagen hace que la imagen esté lista para ser proporcionada a

En la fase de prueba de esta investigación, se aplicó el mismo conjunto de técnicas.

por lo que durante las pruebas, los fotogramas de la

videos se reprodujeron en bucle y todos los fotogramas fueron sometidos al mismo preprocesamiento que el

entrenamiento disponibles.

Las cámaras de vigilancia de tráfico capturan los accidentes en diferentes entornos, se pueden hacer referencias a

Para tener en cuenta este efecto en nuestro conjunto de datos, se aplicó un modelo CNN a una parte del contenido recopilado

en diferentes condiciones ambientales como día, noche, niebla y lluvia. Las pruebas del modelo CNN se realizaron en videos,

El contenido también tiene diferentes resoluciones para hacer que los datos sean más diversos. La Figura 6 muestra que los

subconjunto de imágenes de accidentes donde las primeras cuatro imágenes se tomaron directamente de las imágenes de

El contenido en línea y las siguientes cuatro imágenes se extrajeron de videos recopilados de un V



Figura 6. Imágenes del conjunto de datos de accidentes. En este conjunto de datos, todas las imágenes consisten en accidentes.

Algunas Figura 6. Imágenes del conjunto de datos de accidentes. En este conjunto de datos, todas las imágenes consisten en accidentes. Algunas fueron captadas por cámaras cerradas y la mayoría fueron captadas por cámaras de vigilancia.

captadas por cámaras cerradas y la mayoría fueron captadas por cámaras de vigilancia.

La Tabla 2 describe las estadísticas generales del conjunto de datos recién creado, y la distribución se representa en la Figura 7.

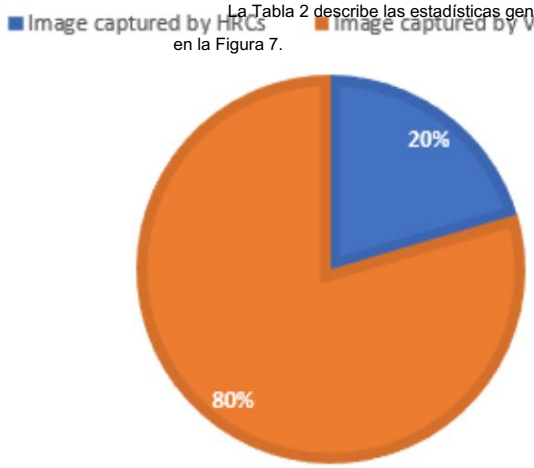


Figura 7. Distribuciones de datos de entrenamiento. El conjunto de datos VAD se dividió en dos categorías diferentes, Figura 7.

entrenamiento y prueba, donde el 80% de las imágenes se utilizaron para el conjunto de datos de entrenamiento.

Distribuciones de datos de entrenamiento. El conjunto de datos VAD se dividió en dos categorías diferentes,

entrenamiento y prueba, donde el 80% de las imágenes se utilizaron para el conjunto de datos de entrenamiento.

3.4.2. Preprocesamiento de datos

Otra técnica utilizada en la fase de preprocesamiento del entrenamiento es el aumento de datos.

Esta técnica es muy popular al trabajar con imágenes, ya que ayuda a crear más datos,

Durante el preprocesamiento de las imágenes para entrenar el modelo CNN, las imágenes ayudan a que los modelos computacionales puedan generalizar mejor. En esta investigación,

Se transformaron en una serie de pasos para resolver problemas de compatibilidad y para aumentar las múltiples técnicas de aumento de datos utilizadas, es decir, desplazamiento, rotación, cizallamiento, volteo, etc. Datos generalización del modelo. El primer paso en el preprocesamiento de una imagen de entrada es intercambiar aumento no fue aplicable en la fase de prueba, ya que no había necesidad de multiplicar los canales de color, es decir, el canal RGB, se reorganizan para hacer que la imagen sea compatible con los datos y generar más.

Keras. El siguiente paso es redimensionar la imagen de entrada a un tamaño fijo, es decir, 224 × 224, sin tener en cuenta la relación de aspecto de la imagen. En el último paso del preprocesamiento 3.5. Matrices de evaluación

Procesamiento de una imagen, se aplica la resta de la media a la imagen, donde se calcula la media. Para analizar la capacidad del método implementado, se utilizaron las siguientes matrices.

Se calcula para todos los valores de píxeles de la imagen y se resta la media de los valores de píxeles. Se implementó y se utilizó para evaluar nuestro modelo.

El objetivo de este paso es estandarizar los parámetros, como los pesos y los sesgos, para que sirvan de referencia. El preprocesamiento de una imagen la prepara para su uso con un modelo CNN. En la fase de prueba de esta investigación, se aplicó el mismo conjunto de técnicas. Las pruebas del modelo CNN se realizaron con vídeos, reproduciendo en bucle los fotogramas y sometiéndolos al mismo preprocesamiento que las imágenes de entrenamiento.

Otra técnica utilizada en la fase de preprocesamiento del entrenamiento es el aumento de datos.

Machine Translated by Google

3.5.1. Matriz de confusión

Esta matriz se utiliza para calcular el grado de error y la precisión en los objetos clasificados.

En la matriz de confusión, TP y TN representan el número total de muestras clasificadas correctamente, donde TP corresponde a verdaderos positivos y TN a verdaderos negativos. FP y FN representan el número total de muestras clasificadas incorrectamente, donde FP corresponde a falsos positivos y FN a falsos negativos.

3.5.2. Precisión

La precisión muestra el rendimiento de un modelo en términos de muestras clasificadas correctamente.

La precisión se puede determinar mediante la matriz de confusión, que es la relación entre la suma de las muestras clasificadas correctamente, tanto positivas como negativas, y el número total de muestras en el conjunto de datos.

$$\text{Precisión} = \frac{TP + TN}{\text{total}} \quad (5)$$

3.5.3. Precisión

La precisión se utiliza principalmente para determinar cuándo el número de muestras clasificadas erróneamente como positivas es muy elevado. La precisión es la proporción entre el número de muestras clasificadas correctamente como positivas y la suma del número de muestras clasificadas correctamente como positivas y las clasificadas erróneamente como positivas.

$$\text{Precisión} = \frac{\text{Ciudad}}{TP + FP} \quad (6)$$

3.5.4. Recuperación

La exhaustividad es la proporción entre el número de muestras clasificadas como positivas que realmente lo son y el número total de muestras clasificadas correctamente. Se utilizó una matriz de exhaustividad para calcular el número de positivos reales que el modelo detectó en el conjunto de datos de prueba.

$$\text{Recordatorio} = \frac{\text{Ciudad}}{TP + FN} \quad (7)$$

3.5.5. Puntuación F1

La puntuación F1 es el promedio ponderado de precisión y exhaustividad. Para lograr un equilibrio entre ambas, es necesaria la puntuación F1.

$$\text{Puntuación F1} = 2 \times \frac{\text{Precisión} \times \text{Recuperación}}{\text{Precisión} + \text{Recuperación}} \quad (8)$$

3.5.6. Tasa de error

La tasa de error mide el porcentaje de muestras clasificadas erróneamente , ya sea como positivas o negativas. Esta matriz se utilizó para calcular la tasa de error del modelo CNN en el conjunto de datos proporcionado.

$$\text{Tasa de error} = \frac{FP + FN}{\text{total}} \quad (9)$$

3.6. Flujo de datos del enfoque de aprendizaje automático propuesto

El flujo de datos (FD) explica los datos y su flujo general a través del sistema.
El objetivo principal de DF es presentar el flujo de información sobre el origen, el almacenamiento y el destino final de los datos. En esta investigación, dado que los datos pasan por numerosos filtros y modelos de cálculo, mostrar este flujo en un diagrama facilita la comprensión de la configuración de extremo a extremo. Primero, se etiquetaron las imágenes con accidentes y se insertaron en la capa de entrada para la extracción de características. Se creó un modelo y se entrenó con estas características de las imágenes de accidentes. Tras el entrenamiento, se proporcionó el vídeo como entrada de prueba. Finalmente, el modelo predijo el vídeo a partir de sus características.

Machine Translated by Google

4. Implementación 4.1.

Configuración del entorno El

entorno para la implementación de la metodología se muestra en la Tabla 4.

Tabla 4. Montaje experimental.

UPC	Procesador Intel Core i5-3570 de 3,40 GHz
Número de núcleos en la CPU	4
Tamaño de la memoria	8 GB
Sistema operativo	Windows 10

4.2. Herramienta para el

enfoque de aprendizaje automático Python es un lenguaje de alto nivel, versátil y fácil de usar. Se recomienda ampliamente para el campo científico actual de la IA, el aprendizaje automático, el aprendizaje profundo y el procesamiento del lenguaje natural. Python proporciona bibliotecas importantes para el aprendizaje profundo, como Keras, matplotlib, sklearn, imutils, NumPy, argparse, pickle, cv2 y os, que son útiles para la evaluación y el desarrollo de modelos de aprendizaje profundo, la computación científica en general, la visualización y la gestión de datos. Por las razones expuestas, se utilizó Python para la implementación de un clasificador que detecta anomalías (accidentes) en videos de entrada.

4.3. Etiquetado de

datos Se creó un archivo de Excel para etiquetar los datos, y se importaron los nombres de todas las imágenes que existían en la carpeta de datos. Tras renombrar todas las imágenes con el formato y la numeración adecuados, se les asignó la etiqueta "accidente".

4.4. Implementación del enfoque DL

Para la implementación del enfoque de aprendizaje profundo, se utilizó un algoritmo supervisado denominado redes neuronales convolucionales (CNN) para entrenar el clasificador, ya que, como se desprende de la revisión bibliográfica y la sección de metodología, el rendimiento de las CNN es elevado en la clasificación de imágenes y la detección de objetos. La implementación se realizó en lenguaje de programación Python.

4.5. Preprocesamiento

Tras cargar una imagen, es necesario realizar un preprocesamiento antes de utilizarla para el entrenamiento. Para garantizar la compatibilidad con Keras y OpenCV, el preprocesamiento intercambió los canales de color y redimensionó la imagen a 244 × 244 píxeles.

4.6. Aumento de datos (AD)

Para mejorar la generalización del modelo, se utilizaron técnicas de aumento de datos. Inicializamos dos objetos DA, uno para entrenamiento y otro para validación. El objeto de entrenamiento aplicó volteos, zooms, rotaciones, cortes, rotaciones aleatorias y desplazamientos a los datos. En los datos de validación, solo se aplicó la técnica de sustracción de la media, en lugar de las técnicas de aumento de datos.

4.7. CNN

Se utilizó la API de Keras para diseñar el modelo CNN en dos partes: el modelo base y el modelo de cabeza. Para inicializar el modelo base, utilizamos el modelo preentrenado ResNet50 con pesos de ImageNet, ya que, en nuestro caso, necesitábamos clasificar imágenes de entrada con etiquetas de clase dentro de ImageNet. Al final del modelo base, especificamos la forma de entrada de 244 × 244 × 3, que son las dimensiones de la imagen de entrada para las que ResNet50 fue entrenado

originalmente. baseModel = ResNet50(weights = “imagenet”,
include_top = False, input_tensor = Input (shape = (224, 224, 3)))

Machine Translated by Google

El modelo de cabeza se creó sobre el modelo base, por lo que la salida generada desde el modelo base se consideró la entrada del modelo principal. A continuación, añadimos un Capa de agrupación promedio 2D y tamaño de la agrupación especificado en las direcciones x e y. La salida generada por la capa anterior necesitaba ser aplanada para entrar en la capa completamente conectada (FC). La capa FC tenía 512 nodos en nuestro modelo, que utilizaba un rectificado Unidad ReLU como función de activación. La capa de salida tenía los tamaños de las clases con clasificación Softmax. Congelamos el modelo base en esta etapa, por lo que no fue entrenado.

El modelo de cabeza se creó sobre el modelo base, por lo que la salida generada desde el modelo base se consideró la entrada del modelo principal. A continuación, añadimos un Capa de agrupación promedio 2D y tamaño de la agrupación especificado en las direcciones x e y. La salida generada por la capa anterior necesitaba ser aplanada para entrar en la capa completamente conectada (FC). La capa FC tenía 512 nodos en nuestro modelo, que utilizaba un rectificado Unidad ReLU como función de activación. La capa de salida tenía los tamaños de las clases con clasificación Softmax. Congelamos el modelo base en esta etapa, por lo que no fue entrenado.

Clasificación Softmax. En esta etapa, congelamos el modelo base, por lo que no se entrenó mediante retropropagación.

retropropagación.

4.8. Compilación y entrenamiento del modelo

4.8. Compilación y entrenamiento del modelo

Después de desarrollar la arquitectura de la CNN en Keras, compilamos nuestro modelo con un optimizador, como el descenso de gradiente estocástico (SGD), y con tasas iniciales de aprendizaje y desaprendizaje de 1 × 10−4 . Utilizamos la “entropía cruzada binaria” para calcular la pérdida de entrenamiento con nuestras clases. Para entrenar el modelo construido en nuestros datos, pasamos todos nuestros datos de entrenamiento con los argumentos trainX y trainY junto con 32 tamaños de lote y 10 números de épocas. Después de la ejecución de la función "generador de ajuste" en nuestro modelo, los datos fueron aprendidos por nuestra red con subestación media y aumento de datos. Después de esto, nuestro modelo Keras, que se presenta en la Figura 8.

Tras desarrollar la arquitectura de la CNN en Keras, compilamos nuestro modelo con un optimizador, como el descenso de gradiente estocástico (SGD), y con tasas iniciales de aprendizaje y desaprendizaje de 1 × 10−4 . Utilizamos la “entropía cruzada binaria” para calcular la pérdida de entrenamiento con nuestras clases. Para entrenar el modelo construido en nuestros datos, pasamos todos nuestros datos de entrenamiento con los argumentos trainX y trainY junto con 32 tamaños de lote y 10 números de épocas. Después de la ejecución de la función "generador de ajuste" en nuestro modelo, los datos fueron aprendidos por nuestra red con subestación media y aumento de datos. Después de esto, guardamos nuestro modelo de Keras, que se presenta en la Figura 8.

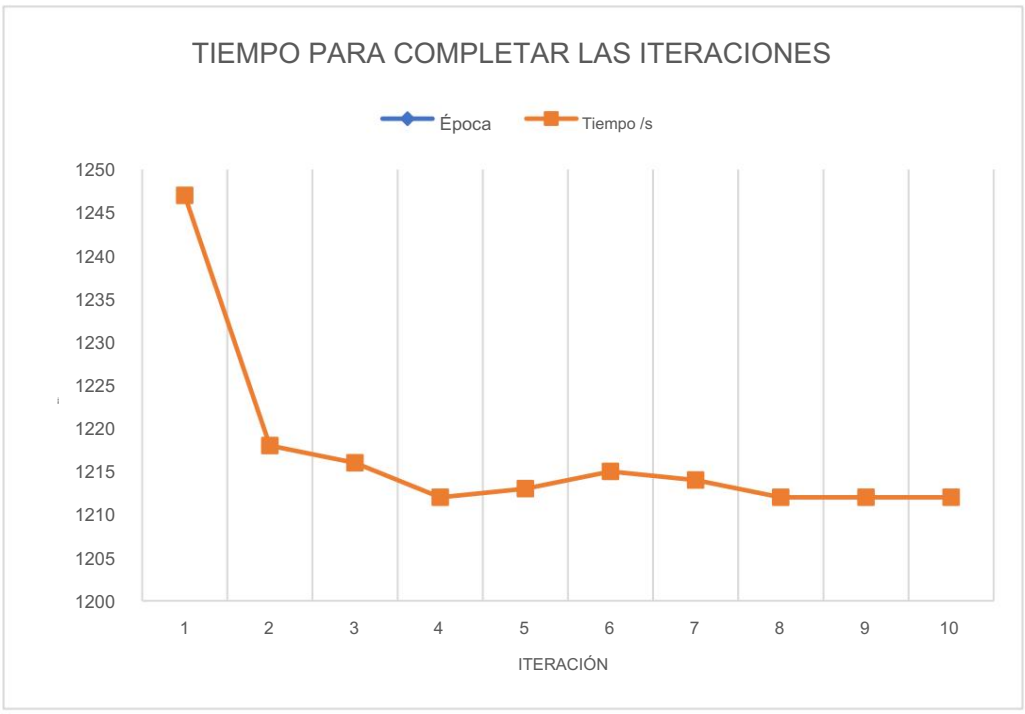


Figura 8. Tiempo, en segundos, para completar las épocas. Una época es un ciclo completo del modelo revisando los datos de entrenamiento.

Figura 8. Tiempo, en segundos, para completar las épocas. Una época es un ciclo completo del modelo revisando los datos de entrenamiento.

4.8.1. Resultado del entrenamiento

Aquí, entrenamos nuestro modelo en VAID con 10 épocas usando el comando que se muestra a continuación.

```
$ python train.py −−dataset Anomaly − Classifier/data
/ −−model output/activity.model −−label
−bin output/lb.pickle −−epochs 10
/ . − − h 10
```

4.8.2. Resultado de las iteraciones

Las 10 épocas tardaron una cantidad considerable de tiempo en completarse debido a la limitación de recursos. La primera iteración tardó 1247 s en completarse, y la décima iteración tardó 1218 s en completarse. Los tiempos de todas las iteraciones se muestran en la Figura 8.

Las 10 épocas tardaron un tiempo considerable en completarse debido a la limitación de ejecución. Los tiempos de todas las iteraciones se muestran en la Figura 8.
de recursos. La primera iteración tardó 1247 s en completarse y la décima iteración tardó 1218 s en ejecutarse.
Los tiempos de todas las iteraciones se muestran en la Figura 8.

Machine Translated by Google

La pérdida de entrenamiento de nuestro modelo fue de 0,1327. En la primera época, la pérdida de entrenamiento fue
de 0,6874 y disminuyó con el aumento de épocas, como se muestra en la Figura 9. Después de la
décima iteración, la pérdida de entrenamiento fue de 0,1327.

En la décima iteración, la pérdida de entrenamiento fue de 0,1327.

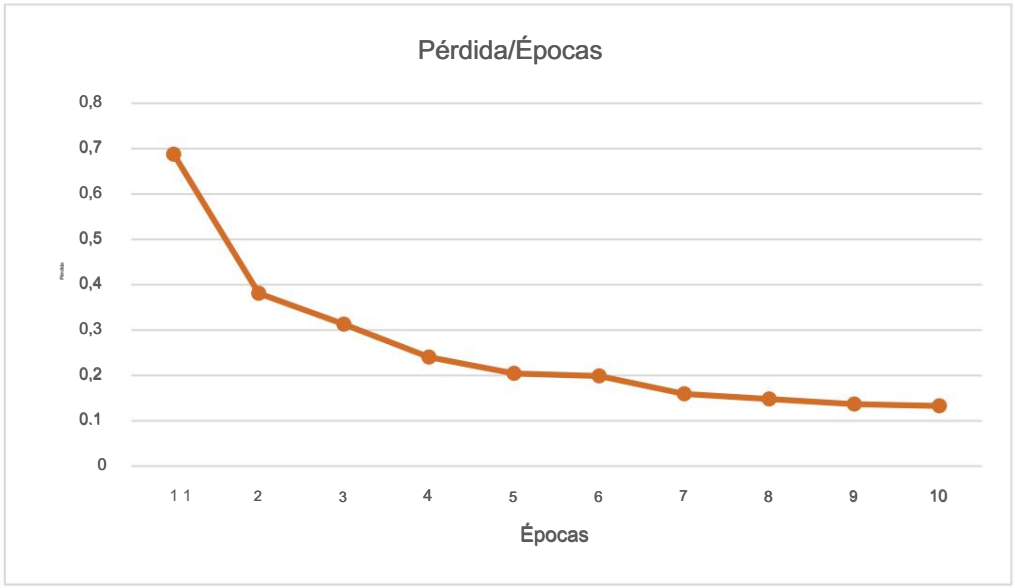


Figura 9. Pérdida del modelo de entrenamiento. La pérdida de entrenamiento es una matriz que se utiliza para evaluar cómo
Figura 9. Pérdida del modelo de entrenamiento. La pérdida de entrenamiento es una matriz que se utiliza para evaluar cómo se ajusta el modelo
El modelo se ajusta a los datos de entrenamiento. Esta imagen representa el error, que se redujo al aumentar las épocas.

aumentando las épocas.

La precisión de entrenamiento de nuestro modelo fue de 0,956, o aproximadamente del 95%. Además, el
en la Figura 10.

La precisión aumentó a medida que continuaban las iteraciones, como se muestra en la Figura 10.

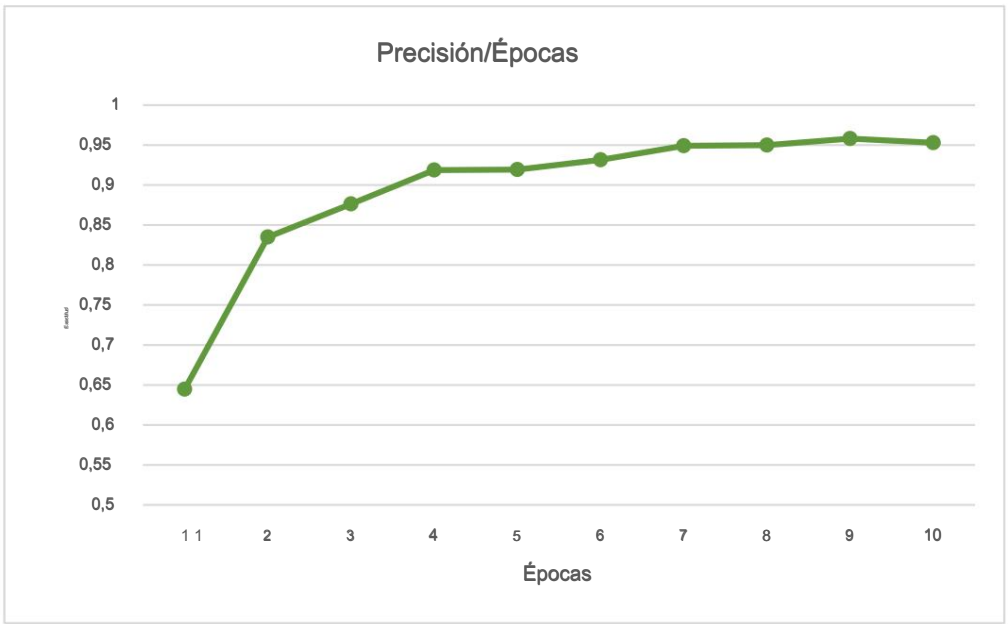


Figura 10. Precisión del modelo. Esta figura muestra que la precisión aumentó con el aumento de las épocas.
Esta figura muestra que la precisión aumentó con el aumento de las épocas.
épocas.

La pérdida total de entrenamiento, la precisión del entrenamiento, la pérdida de validación y la precisión de la validación
Los resultados del conjunto de datos YAID se muestran en la Figura 11.

Machine Translated by Google



Figura 11. La pérdida de entrenamiento y la precisión en el conjunto de datos VAID. En esta figura, la línea roja representa la pérdida de entrenamiento, la línea azul representa la pérdida de prueba, la línea púrpura representa la pérdida de entrenamiento y la precisión de entrenamiento, y la línea verde representa la precisión de prueba.

Figura 11. La pérdida de entrenamiento y la precisión en el conjunto de datos VAID. En esta figura, la línea roja representa la pérdida de entrenamiento, la línea azul representa la pérdida de prueba, la línea morada representa la precisión de entrenamiento y la línea verde representa la precisión de prueba.

4.9. Prueba del modelo

Una sección anterior de este capítulo analiza el proceso de construcción de un modelo CNN, entrenamiento del modelo en VAID. Esta parte explica ahora los pasos involucrados en las pruebas de un promedio móvil de predicción en el conjunto de datos de prueba. El conjunto de datos de prueba es una colección de videos de accidentes recopilados de diferentes fuentes.

4.9. Prueba del modelo

Una sección anterior de este capítulo analiza el proceso de construcción de una CNN y el posterior entrenamiento del modelo en VAID. Esta parte explica ahora los pasos involucrados en las pruebas de un promedio móvil de predicción en el conjunto de datos de prueba. El conjunto de datos de prueba es una colección de videos de accidentes recopilados de diferentes fuentes.

Para el algoritmo de promedio móvil, cargamos el módulo de Python necesario y “deque” y “collections”. Luego, inicializamos nuestro “cv2.VideoCapture”. Luego recorremos los fotogramas del video. Utilizamos la clase VideoCapture de OpenCV. El objeto comenzó a recorrer los fotogramas del vídeo. Utilizamos la clase VideoCapture de Open para leer los fotogramas de nuestro flujo de vídeo, mientras que se utilizó un bucle para adquirir fotogramas de un vídeo. leyendo los fotogramas uno por uno hasta el final del video. El vídeo se reproduce leyendo los fotogramas uno por uno hasta el final del mismo.

Para el algoritmo de promedio móvil, cargamos el módulo y los paquetes de Python necesarios, como edades como “deque” y “collections”. Luego, inicializamos nuestro objeto “cv2.VideoCapture” y comenzamos a para leer fotogramas de nuestra transmisión de vídeo mientras se usaba un bucle para adquirir fotogramas

4.9.1. Preprocesamiento del fotograma

En el preprocesamiento de un fotograma, se realizaron los mismos pasos que durante el entrenamiento, incluyendo: intercambio de canales de color, redimensionamiento a píxeles fijos y resta de la media.

4.9.1. Preprocesamiento del fotograma

En el preprocesamiento de un fotograma, se realizaron los mismos pasos que durante el entrenamiento mediante el intercambio de canales de color, el redimensionamiento a píxeles fijos y la resta de la media.

4.9.2. Interfaz de clasificación de fotogramas y promedio móvil de predicción

Inicialmente, se hizo una predicción en cada fotograma del vídeo, pero al observar el como resultado, se vio que la predicción se realizaba rápidamente, ya que todos los fotogramas del vídeo, pero al observar la aparición de la anomalía, la prueba resultó positiva. Cuando probamos, se observó que la etiqueta parpadeaba rápidamente, ya que no todos los fotogramas en los que

Para solucionar el problema del parpadeo, se realizó una predicción en cada fotograma del vídeo. y el resultado de la predicción se agregó a un array. Se utilizó la función deque para realizar un algoritmo promedio de predicción con un tamaño de cola de 128 sobre el array, calculando la media móvil en la clase de etiquetas para el promedio móvil. Después de eso, se utilizó la función de la biblioteca NumPy para encontrar la etiqueta con la mayor probabilidad correspondiente entre las predicciones promedio.

4.9.2. Interfaz de clasificación de fotogramas y promedio móvil de predicción

Inicialmente, se realizó una predicción en cada fotograma del vídeo, pero al observar la aparición de la anomalía, la prueba resultó positiva. Cuando probamos, se observó que la etiqueta parpadeaba rápidamente, ya que no todos los fotogramas en los que

Para solucionar el problema del parpadeo, se realizó una predicción en cada fotograma del vídeo. La predicción se agregó a un array. Se utilizó la función deque para realizar un algoritmo promedio de predicción con un tamaño de cola de 128 sobre el array, calculando la media móvil en la clase de etiquetas para el promedio móvil. Después de eso, se utilizó la función de la biblioteca NumPy para encontrar la etiqueta con la mayor probabilidad correspondiente entre las predicciones promedio.

Machine Translated by Google

4.9.3. Etiqueta de salida/resultado

Cuando el modelo Keras entrenado detectó una anomalía (accidente), se le aplicó una prueba.
etiqueta predicha en el fotograma con la ayuda de un texto descriptivo. Luego, dibujó una
una biblioteca de Python (OpenCV).

5. Experimentación y evaluación

5.1. Conjunto de datos de prueba

En el conjunto de datos de prueba, teníamos 30 videos de accidentes y flujo normal de tráfico, como mencionados en la Tabla 5. Todos estos videos fueron grabados por cámaras utilizadas en VTSS en diferentes condiciones ambientales.

Tabla 5. Conjunto de datos de prueba.

Conjunto de datos	Conjunto de datos	Número de vídeos	Número de vídeos	Comportamiento	Comportamiento
Pruebas	Pruebas	20	20	accidentes	accidentes
Pruebas	Pruebas	10	10	Incidentes sin accidentes	Incidentes sin accidentes

La duración de los videos en el conjunto de datos de prueba varía de 40 s a 10 s. Este conjunto de datos se divide en dos categorías, accidentes y sin accidentes. La categoría de accidentes tiene 20 videos, y la categoría sin accidentes tiene 10 videos. La distribución del conjunto de datos de prueba se muestra en la Figura 12.

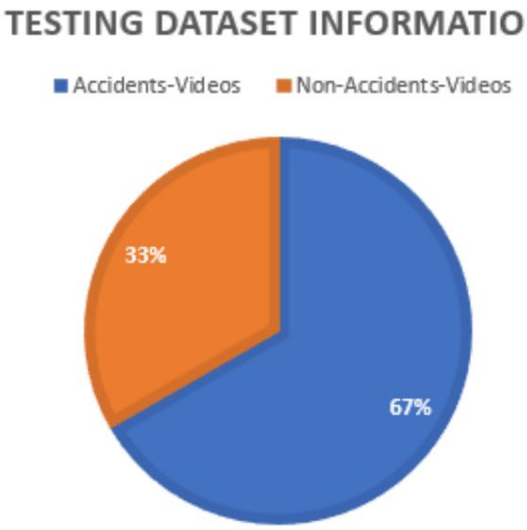


Figura 12. Distribución de los datos de prueba. Los datos de prueba consistieron en vídeos de accidentes y de situaciones sin accidentes. El porcentaje de vídeos sin accidentes fue del 33%, y el de vídeos de accidentes, del 37%.

En el conjunto de datos de prueba, se capturaron un total de 15 videos con cámaras de alta resolución (HRC) durante el día y 7 durante la noche mediante un sistema VTSS. Además, se capturaron cinco videos con cámaras de baja resolución (LRC) durante el día y tres durante la noche. Esta distribución se muestra en la Figura 13.

5.2. Resultados experimentales

Para evaluar el modelo entrenado sobre datos no vistos, es decir, para el conjunto de datos de prueba que alimentamos todo el conjunto de datos de prueba, que se basa en 30 videos, a nuestro modelo entrenado uno por uno y evaluó los resultados para medir el rendimiento del modelo. El modelo fue implementado de manera que reproduce el vídeo de entrada en una pantalla y etiqueta los fotogramas del mismo. Vídeo de entrada con la etiqueta detectada. A continuación se muestran algunas instantáneas del sistema de captura. escenarios con diferentes situaciones.

Machine Translated by Google

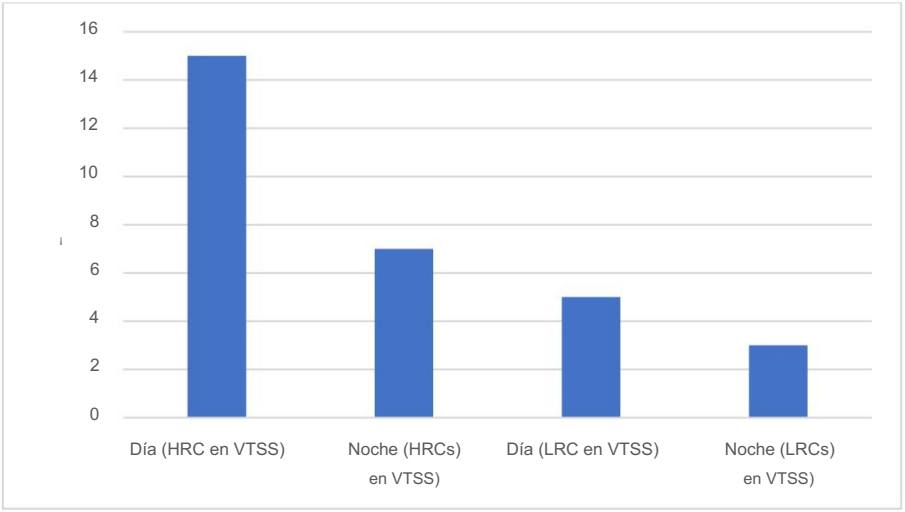


Figura 13. Vídeos de entrenamiento distribuidos según el día y la noche. En este gráfico, los dos diferentes Figura 13. Vídeos de entrenamiento distribuidos según el día y la noche. En este gráfico, los dos diferentes
Las categorías se utilizan en dos escenarios diferentes: cámaras de alta resolución y cámaras de baja resolución. Las categorías se utilizan en dos escenarios diferentes: cámaras de alta resolución y cámaras de baja resolución.
en situaciones diurnas y nocturnas. en situaciones diurnas y nocturnas.

5.2. Resultados experimentales

Para evaluar el modelo entrenado sobre datos no vistos, es decir, para el conjunto de datos de prueba que alimentamos. En el primer escenario, proporcionamos un vídeo con el nombre 001261.mp4, que capturó un autobús chocando con un coche durante el día. El modelo pudo detectar la imagen como una anomalía, y se evaluaron las actividades paralelas para evaluar el rendimiento del modelo. El modelo se implementó y etiquetó el diseñado de forma que reproduzca el vídeo de entrada en una pantalla y etiquete los fotogramas de la entrada $ Vídeo con la etiqueta detectada. A continuación se muestran algunas instantáneas del sistema capturando sce- Historias con diferentes ejemplos_clips/001261.mp4 –output output/001261_1frame.avi –size 1

python predict_video.py –model model/activity.model –label-bin model/lb.pickle \

Resultados

5.2.1. Escenario 1

Sensores 2022, 22, x PARA REVISIÓN POR PARES 22 de 29

En el primer escenario, proporcionamos un vídeo con el nombre 001261.mp4, que capturó Un autobús colisionó con un automóvil durante el día. El modelo pudo detectar la imagen como una anomalía y la etiquetó como un "accidente".

La cámara del VTSS no está instalada demasiado lejos, como se muestra en la Figura 14.



Figura 14. Resultado capturado por la prueba 1. En este escenario, la resolución de la cámara era demasiado baja, pero Figura 14. Resultado capturado por la prueba 1. En este escenario, la resolución de la cámara era demasiado baja, pero
El ángulo de visión era el correcto. El ángulo de visión era el correcto.

5.2.2. Escenario 2

En el segundo escenario, proporcionamos un vídeo llamado acci21.mp4, que mostraba una colisión entre dos coches por la noche. El modelo detectó la imagen como una anomalía y la etiquetó como un "accidente".

$ python predict_video.py --model model/activity.model --label-bin model/lb.pickle \

Machine Translated by Google

Figura 14. Resultado capturado por la prueba 1. En este caso, la resolución de la cámara era demasiado baja, pero el ángulo de visión estaba en la dirección correcta.

5.2.2. Escenario 2

5.2.2. Escenario 2 En

el segundo escenario, proporcionamos un video con el nombre acci21.mp4, que capturaba En el segundo escenario,

proporcionamos un video con el nombre acci21.mp4, que capturaba un automóvil chocando con un automóvil por la noche. El modelo pudo detectar el fotograma como una anomalía y lo etiquetó como una actividad 'accidente'. y etiquetó

el fotograma como una actividad 'accidente'. $ python predict_video.py –model model/activity.model –label-bin model/lb.pickle \ $ python predict_video.py --model model/

activity.model --label-bin model/lb.pickle \ –input example_clips/

acci21.mp4 –output output/acci21_1frame.avi –size 128

--input example_clips/acci21.mp4 --output output/acci21_1frame.avi --size 128

Resultado

Resultado

En este escenario, la cámara VTSS se instaló lejos del lugar donde En este escenario, la cámara VTSS se instaló

lejos del lugar donde ocurrió el accidente, pero el modelo lo etiquetó correctamente como "accidente". Debido a que se instaló una cámara VTSS de alta resolución aquí, capturó el accidente claramente, como se muestra en la Figura 15 .

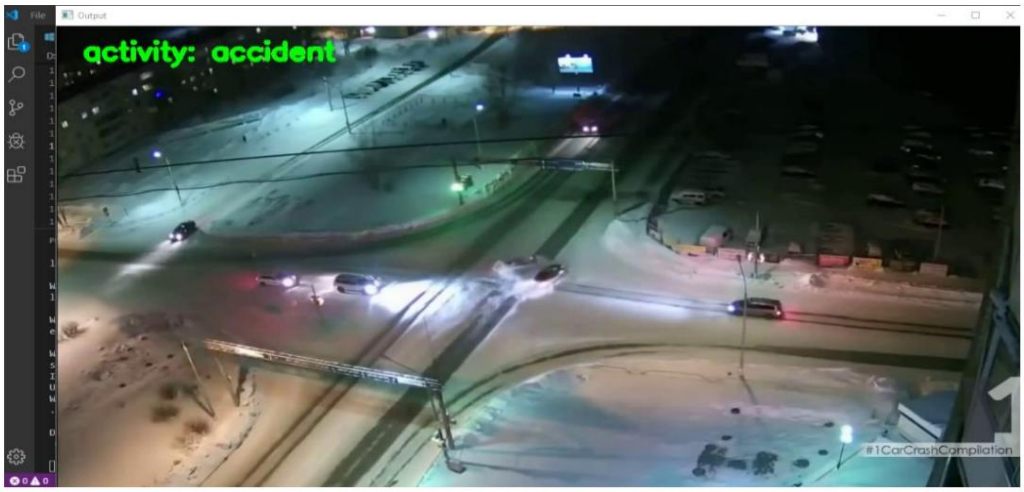


Figura 15. Resultado obtenido en la prueba 2. Fue correctamente etiquetado como un accidente.

Figura 15. Resultado obtenido en la prueba 2. Fue correctamente etiquetado como un accidente.

5.2.3. Escenario 3

5.2.3. Escenario 3

En el tercer escenario, proporcionamos un video con el nombre ambil.mp4, que capturé. En el tercer escenario,

proporcionamos un video con el nombre ambil.mp4, que capturó dos autos chocando entre sí después de la lluvia pudo detectar. El modelo pudo detectar la anomalía, y etiquetó el fotograma después de la colisión. El fotograma como una anomalía, y etiquetó el fotograma como una actividad 'accidente'.

$ python predict_video.py –model model/activity.model –label-bin model/lb.pickle \ –input example_clips/ambil.mp4 –output output/ambil_1frame.avi –size 128

Resultado

En este caso, la cámara VTSS se instaló lejos del lugar del accidente, pero el modelo lo identificó correctamente como tal. Gracias a que se instaló una cámara VTSS de alta resolución, esta captó el accidente con claridad, como se muestra en la Figura 16.

5.2.4. Escenario 4

En el cuarto escenario, proporcionamos un video llamado lrpvd.mp4, que mostraba la colisión de un jeep con un automóvil. El modelo detectó el fotograma como una anomalía y lo etiquetó como un "accidente".

Resultado

El modelo no pudo marcar este fotograma como un accidente, pero hay un accidente capturado en este fotograma. La razón de esto podría ser la mala calidad de la imagen o la abundancia de fuentes de luz que obstruyen la vista del accidente. También se puede observar

Machine Translated by Google


```
$ python predict_video.py --model model/activity.model --label-bin model/lb.pickle \
--input example_clips/ambil.mp4 --output output/ambil_1frame.avi --size 128
```

Resultado

En este escenario, la cámara VTSS se instaló lejos del lugar donde ocurrió el accidente, pero el modelo lo etiquetó correctamente como un "accidente". Debido a que una cámara VTSS de alta resolución en este fotograma también dificulta la detección de un accidente para una persona, como se muestra en Figura 17 .

Aquí se instaló una cámara de alta resolución que capturó el accidente con claridad, como se muestra en la 16.



Figura 16. El resultado obtenido en la prueba 3 fue etiquetado correctamente como “accidental”.

5.2.4. Escenario 4

En el cuarto escenario, proporcionamos un video llamado lrpvd.mp4, que mostraba un jeep chocando con un automóvil. El modelo pudo detectar el fotograma como una anomalía y lo etiquetó como una actividad de "accidente".

Resultado

El modelo no pudo marcar este fotograma como un accidente, pero hay un accidente registrado en este fotograma. La razón de esto podría ser la mala calidad de la imagen o la interferencia de las fuentes de luz que obstruyen la vista del accidente. También se puede observar en la Figura 16. El resultado capturado por la prueba 3 fue etiquetado correctamente como "accidental".

Figura 16. El resultado obtenido en la prueba 3 fue etiquetado correctamente como “accidental”. Este marco también detectó un accidente, también es difícil para una persona, como se muestra en la figura.

5.2.4. Escenario 4

En el cuarto escenario, proporcionamos un video llamado lrpvd.mp4, que mostraba la colisión de un jeep con un automóvil. El modelo detectó el fotograma como una anomalía y lo etiquetó como una "actividad: accidente".

Resultado

El modelo no pudo identificar este fotograma como un accidente, pero sí se registró uno. Esto podría deberse a la mala calidad de la imagen o a la abundancia de fuentes de luz que obstruyen la visión del accidente. También se observa que, en este fotograma, la detección del accidente resulta difícil para una persona, como se muestra en la Figura 17.

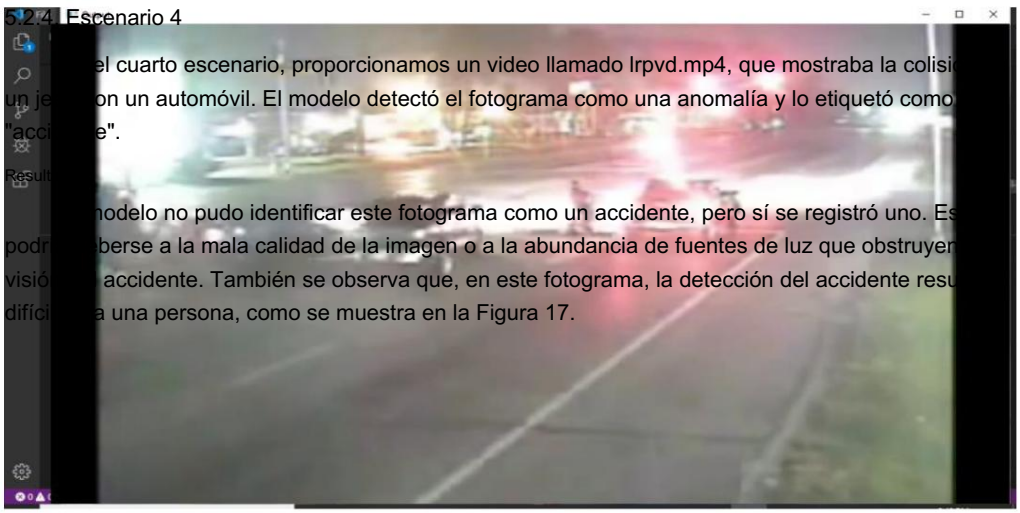


Figura 17. Resultado capturado por la prueba 4. Mostró el resultado sin etiquetar la imagen.

Figura 17. Resultado capturado por la prueba 4. Mostró el resultado sin etiquetar la imagen.

5.2.5. Escenario 5

En el quinto escenario, proporcionamos un video con el nombre norm6.mp4, que capturó el flujo normal de tráfico durante el día. El modelo pudo detectar que el marco era normal.

```
$ python predict_video.py –model model/activity.model –label-bin model/lb.pickle \
–entrada example_clips/norm6.mp4 –salida output/norm6_1frame.avi –tamaño 128
```

Resultado

Figura 17. Resultado capturado por la prueba 4. Mostró el resultado sin etiquetar la imagen.

En este escenario, se instaló una cámara de alta resolución de un sistema VTSS en esta ubicación. El modelo lo etiquetó correctamente como normal, y se muestra en la Figura 18.

5.3. Resultados y discusión

El conjunto de datos de entrenamiento constaba de 30 vídeos de accidentes y de situaciones sin accidentes (tráfico habitual). Se realizó una serie de 30 pruebas para la validación del modelo entrenado. Cada prueba tenía una video único para predecir su etiqueta. La matriz de confusión de estos experimentos se muestra en Tabla 6.

Machine Translated by Google

```
$ python predict_video.py --model model/activity.model --label-bin model/lb.pickle \
--input example_clips/norm6.mp4 --output output/norm6_1frame.avi --size 128
```

Resultado

En este caso, se instaló una cámara de alta resolución de un sistema VTSS en esta ubicación. El modelo la etiquetó correctamente como normal, y se muestra en la Figura 18.

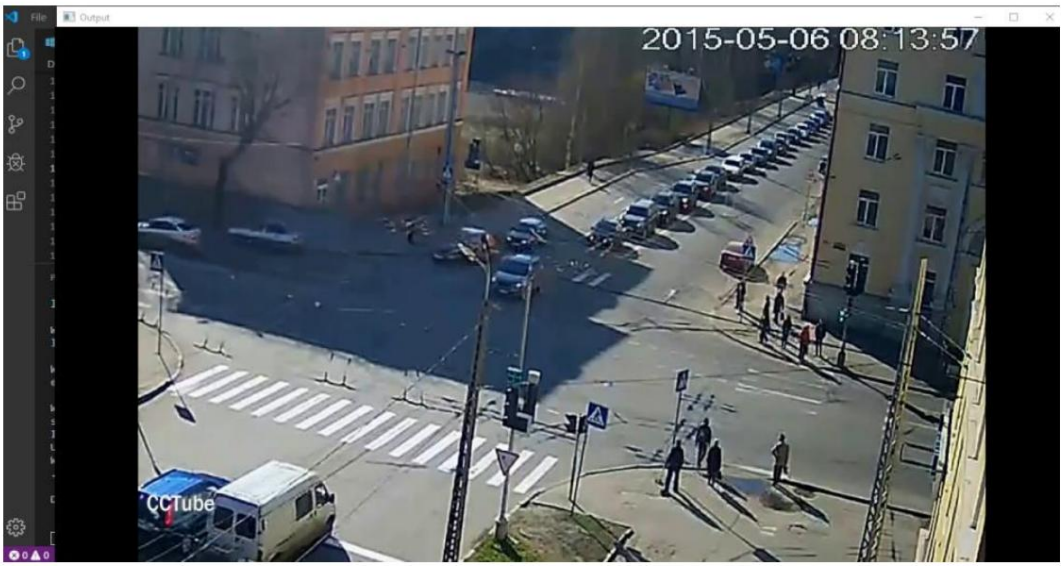


Figura 18. Resultado capturado por la prueba 4. En esta imagen, el modelo no detectó ningún accidente.

Figura 18. Resultado capturado por la prueba 4. En esta imagen, el modelo no detectó ningún accidente.

5.3. Resultados y discusión

El conjunto de datos de entrenamiento contiene 30 videos de accidentes y de no accidentes (total N = 30). Se realizó una serie de 30 pruebas para la validación del modelo entrenado. Cada prueba tiene 2 falsos habitualmente un video para predecir su etiqueta. La matriz de confusión de estos experimentos es como se muestra en la Tabla 6.

Tabla 6. Matriz de confusión del modelo CNN con un algoritmo de predicción continua. El número de verdaderos positivos es 16, el número de verdaderos negativos es 8, el número de falsos positivos es 4 y el número de falsos negativos es 2.

		Clase prevista		
	La clase real y	Sí	No	N = 30
	Sí	TP = 16	FN = 2	18
	No	FP = 4	TN = 8	12
		20	10	

Aquí, TP es el número de vídeos de accidentes reales que fueron etiquetados como accidentes, el TN es el número de videos reales sin accidentes que fueron marcados correctamente como normales. videos. FP es el número de videos de accidentes reales en los que el modelo entrenado no pudo detectar el accidente, y FN es el número de vídeos reales sin accidente que son erróneamente clasificados como accidentes. El resultado de la matriz de confusión se muestra en la Figura 19.

Aquí, TP es el número de vídeos de accidentes reales que fueron etiquetados como accidentes, y TN es el número de vídeos reales sin accidentes que fueron correctamente marcados como vídeos normales. FP es el número de vídeos de accidentes reales en los que el modelo entrenado no fue capaz de detectar el accidente, y FN es el número de vídeos reales sin accidentes que se clasifican erróneamente como accidentes. El resultado de la matriz de confusión se muestra en la Figura 19.

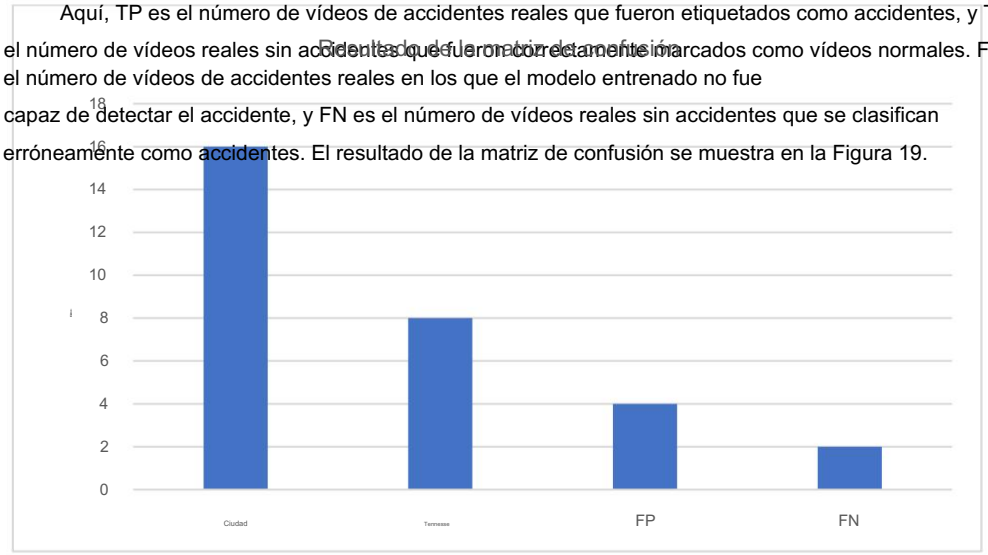


Figura 19. Resultado de la matriz de confusión en los datos de prueba del conjunto de datos de imágenes de accidentes de vehículos (VAID).

Figura 19. Resultado de la matriz de confusión en los datos de prueba del conjunto de datos de imágenes de accidentes de vehículos (VAID).

(SOLO).

El modelo CNN entrenado pudo clasificar correctamente 24 videos del conjunto de datos de prueba dado y no pudo clasificar correctamente 6 videos. Se observó visualmente que el modelo no pudo clasificar correctamente los videos con resoluciones bajas, con anomalías en las distancias de las cámaras de vigilancia de los entornos y las cámaras de vigilancia.

Machine Translated by Google

Figura 19. Resultado de la matriz de confusión en los datos de prueba del conjunto de datos de imágenes de accidentes vehiculares Sensors 2022, 22, 6563 (VAID).

El modelo entrenado con CNN pudo clasificar correctamente 24 videos de la prueba dada. El modelo entrenado con CNN pudo clasificar correctamente 24 videos de la prueba dada. Se observó visualmente que el conjunto de datos y no pudo clasificar correctamente 6 videos. Se observó visualmente que el modelo no pudo clasificar correctamente los videos con baja resolución, con anomalías. El modelo no pudo clasificar correctamente los videos con baja resolución, con anomalías, largas distancias de las cámaras de vigilancia, entornos con niebla y cámaras de vigilancia - distancias de las cámaras de vigilancia, entornos con niebla y cámaras de vigilancia, eras frente al reflejo de la luz. La precisión alcanzada después de evaluar el modelo resultó frente al reflejo de la luz. La precisión alcanzada después de evaluar el modelo resultó llega a ser casi el 80% para el conjunto de datos dado, como se muestra en la Figura 20. ser casi el 80% para el conjunto de datos dado, como se muestra en la Figura 20.

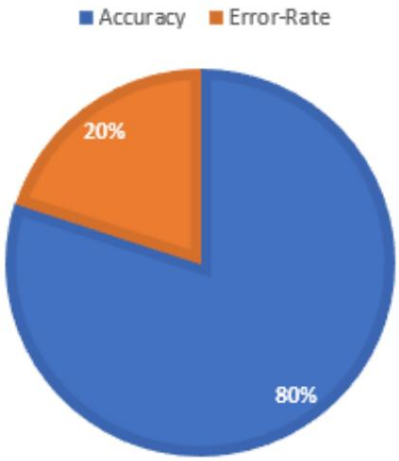


Figura 20. Medición de precisión del conjunto de datos de imágenes de accidentes vehiculares (VAID). Se logró una precisión del 80% en el conjunto de datos de prueba.

Figura 20. Medición de la precisión del conjunto de datos de imágenes de accidentes vehiculares (VAID). Se alcanzó una precisión del 80%.

Se comporta de forma irregular en el conjunto de datos de prueba.

La Figura 21 muestra una precisión de 0,8, una exhaustividad de 0,88 y una puntuación f1 de casi 0,845 en el La figura 21 muestra una precisión de 0,8, una exhaustividad de 0,88 y una puntuación F1 de casi 0,845 en los datos de prueba, lo que implica un buen rendimiento del modelo entrenado. datos de prueba, lo que implica un buen rendimiento del modelo entrenado.

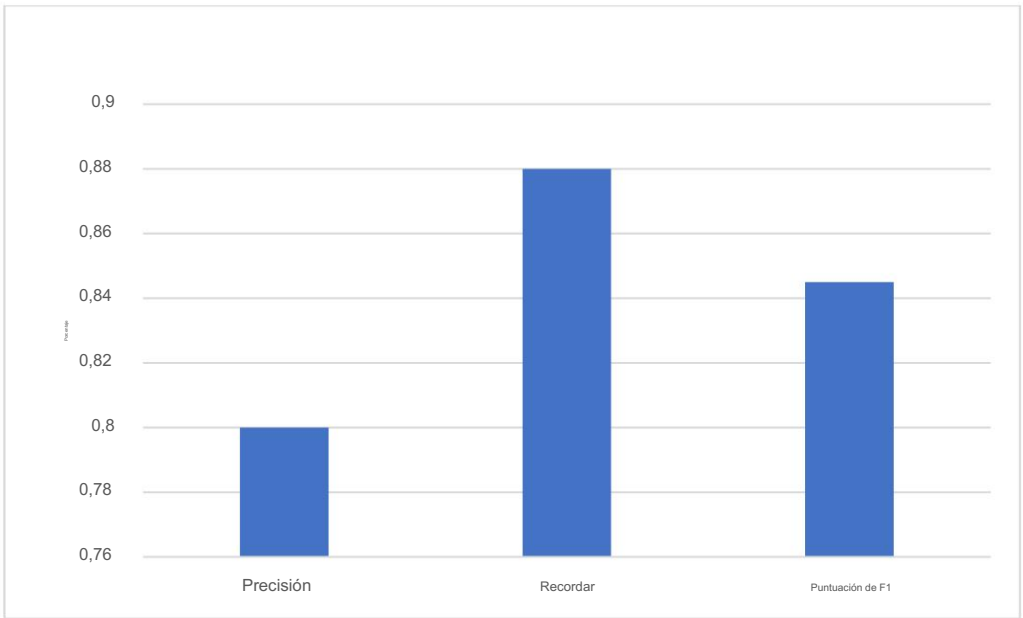


Figura 21. Esta imagen presenta los resultados de la precisión, la exhaustividad y la puntuación F1 del modelo CNN con algoritmos de predicción continua. La precisión fue de 0,8, la exhaustividad fue de 0,88 y la puntuación F1 fue de 0,85.

Figura 21. Esta imagen presenta los resultados de la precisión, la exhaustividad y la puntuación F1 del modelo CNN con 0,85.

5.4. Efecto del algoritmo de predicción de promedio móvil con CNN y CNN simple

5.4. Efecto del algoritmo de predicción de promedio móvil con CNN y CNN simple

El conjunto de datos VAID se utilizó para ambos modelos para obtener resultados mediante la evaluación. matriz, exactitud, puntuación F1, exhaustividad y precisión. Los resultados generales se muestran en la Tabla 7. El conjunto de datos VAID se utilizó para ambos modelos para obtener resultados mediante la matriz de evaluación, la precisión, la puntuación F1, la exhaustividad y la exactitud. Los resultados generales se muestran en la Tabla 7.

Tabla 7. Comparación de resultados de CNN normal y CNN con algoritmo de predicción de promedio móvil.

Conjunto de datos	CNN	CNN con promedio móvil Algoritmo de predicción
Precisión	73	80
Recordar	79	88

Machine Translated by Google

Tabla 7. Comparación de resultados de CNN normal y CNN con algoritmo de predicción de promedio móvil.

Conjunto de datos	CNN	CNN con promedio móvil Algoritmo de predicción
Precisión	73	80
Recordar	79	88
Exactitud	72	82
Puntuación de F1	75	85

5.5. La complejidad computacional de diferentes enfoques

Esta sección examina la complejidad computacional de nuestro modelo propuesto con
CNN simple. La Tabla 8 muestra los tiempos de ejecución de nuestro modelo propuesto, así como de otro.
Red neuronal convolucional (CNN) de referencia en el conjunto de datos VAID utilizado para el entrenamiento y la predicción.

Tabla 8. Complejidad computacional de diferentes enfoques. La complejidad computacional de los enfoques simples
La CNN fue del 75% durante el entrenamiento y del 70% durante las pruebas. La complejidad computacional de la CNN con
El algoritmo de predicción de promedio móvil tuvo un rendimiento del 69% durante el entrenamiento y del 67% durante las pruebas.

Modelo	SOLO CONJUNTO DE DATOS	
	Entrenamiento	Pruebas
CNN	75%	70%
CNN con algoritmo de predicción de promedio móvil	69%	67%

5.6. Comparación con investigaciones previas

Diferentes investigadores llevaron a cabo diferentes investigaciones para clasificar los videos utilizando
enfoques de aprendizaje automático. En investigaciones anteriores, el clasificador bayesiano ingenuo y la CNN simple
El algoritmo se utilizó para la clasificación de video. Este algoritmo trata cada fotograma individual de
el vídeo como independiente de los demás fotogramas del vídeo, por lo tanto la implementación de
El algoritmo se enfrentó al problema del "parpadeo de las etiquetas".

En el enfoque que proponemos, se utilizó una red neuronal convolucional (CNN) con promedio móvil de predicciones.
Este algoritmo permite al sistema registrar el último número n de observaciones, promedio
y selecciona la etiqueta con la mayor probabilidad de encontrar la etiqueta para el fotograma actual.
de video. Como se discutió en la implementación, el problema del parpadeo se abordó utilizando
este algoritmo. La suposición al aplicar esta técnica al video es que la actual
El marco tiene un contenido similar al de las últimas n observaciones y no puede cambiar mucho.
dentro del tiempo de un fotograma. Como los videos son de naturaleza temporal, es decir, el contenido del video,
En la mayoría de los casos, depende del paso del tiempo, y los videos en el conjunto de datos de prueba fueron
En cuanto a su comportamiento temporal, esta suposición puede mantenerse en esta investigación. Por lo tanto, el promedio móvil
El algoritmo es aplicable. El uso de este algoritmo suaviza las predicciones y hace que la
La solución propuesta consiste en un mejor clasificador de vídeo.

6. Conclusiones

El aprendizaje profundo (DL) es un nuevo campo del aprendizaje automático (ML) que generalmente proporciona
resultados significativamente precisos. El aprendizaje profundo se utiliza principalmente para resolver problemas complejos.
con el apoyo de redes neuronales profundas y complejas. Las técnicas de aprendizaje profundo tienen la
capacidad para resolver problemas que serían muy difíciles o incluso imposibles de resolver con métodos anteriores
métodos estadísticos y de aprendizaje automático. El aprendizaje profundo ha demostrado ser útil en muchos campos de
ciencia, y actualmente sus técnicas se utilizan para resolver muchos problemas prácticos que eran
difícil de resolver antes. El aprendizaje profundo también se puede utilizar para encontrar anomalías en diferentes tipos.
de datos. Sus técnicas, CNN, RNN y LSTM, se utilizan para detectar o encontrar datos anómalos.
de diferentes conjuntos de datos. Un enfoque de aprendizaje profundo CNN tiene buena reputación para la
reorganización de la clasificación de objetos e imágenes en investigaciones previas. En esta investigación, CNN
Se utilizó para detectar anomalías (accidentes) en videos capturados por sistemas de vigilancia de tráfico.
sistemas (VTSS). Para las redes neuronales, se requiere un gran conjunto de datos etiquetados para realizar
buen entrenamiento. Para ello, creamos un conjunto de datos llamado imagen de accidente vehicular.

Machine Translated by Google

Conjunto de datos (VAID) que consta de 1360 imágenes de accidentes vehiculares. Dado que este conjunto de datos se consideró insuficiente para entrenar el modelo, utilizamos técnicas de aumento de datos como rotación, cizallamiento, zoom y volteo en la fase de entrenamiento del algoritmo. El modelo CNN se construyó entrenando con VAID, y para validarlo y evaluarlo, se utilizó un conjunto de datos de 30 vídeos. Durante las pruebas, nos enfrentamos al problema del parpadeo de etiquetas entre imágenes, lo que tuvo un gran impacto en la precisión. Por lo tanto, se utilizó un algoritmo de promedio móvil de predicción junto con el modelo CNN entrenado para resolver el problema del parpadeo de etiquetas y hacerlo efectivo para la clasificación de vídeos. Esta investigación tiene como objetivo ayudar a las personas lesionadas en accidentes y al personal que supervisa simultáneamente múltiples pantallas de sistemas de vigilancia de tráfico. Este sistema puede detectar anomalías (accidentes) a través de vídeos y ayudar a notificar al personal para que tome medidas. La investigación propuesta muestra buenos resultados al probarla con vídeos capturados por cámaras de alta resolución utilizadas en sistemas de vigilancia de tráfico. Sin embargo, el modelo no pudo proporcionar resultados eficientes en vídeos grabados a grandes distancias y en entornos con niebla.

Una dirección plausible para el trabajo futuro puede orientarse hacia la búsqueda de modelos mejorados. que pueda adaptarse a vídeos grabados a larga distancia, con poca cobertura y en entornos con niebla.

Contribuciones de los autores: Conceptualización, RA y JA; Curación de datos, RA y JA; Obtención de financiación, RA y JA; Metodología, RA; Validación, RA y JA; Redacción del borrador original, SWK, QH, MIK, RA, SH, JI, JA y SSU; Revisión y edición, RA y JA. Todos los autores han leído y aprobado la versión publicada del manuscrito.

Financiación: Los autores agradecen al proyecto de apoyo a investigadores de la Universidad de Taif número (TURSP-2020/36), Universidad de Taif, Taif, Arabia Saudita.

Declaración del Comité de Ética Institucional: No aplica.

Declaración de consentimiento informado: No aplicable.

Declaración de disponibilidad de datos: No aplicable.

Conflictos de intereses: Los autores declaran no tener ningún conflicto de intereses.

Referencias

1. Zanella, A.; Bui, N.; Castellani, A.; Vangelista, L.; Zorzi, M. Internet de las cosas para ciudades inteligentes. IEEE IoT J. 2014, 1, 22–32. [Referencia cruzada]
2. Kumar, M.; Raju, KS; Kumar, D.; Goyal, N.; Verma, S.; Singh, A. Un marco eficiente que utiliza reconocimiento visual para IoT basado en Vigilancia de ciudades inteligentes. Multimed. Tools Appl. 2021, 80, 1–19. [CrossRef]
3. Jan, A.; Khan, GM Reconocimiento de eventos maliciosos del mundo real en grabaciones de CCTV utilizando una red cuasi-3D. J. Ambient Intell. Humaniz. Comput. 2022. [CrossRef]
4. Ullah, A.; Muhammad, K.; Haq, IU; Baik, SW. Reconocimiento de acciones mediante autoencoder profundo optimizado y CNN para flujos de datos de vigilancia en entornos no estacionarios. Future Gener. Comput. Syst. 2019, 96, 386–397. [CrossRef]
5. Batchuluun, G.; Kim, YG; Kim, JH; Hong, HG; Park, KR Reconocimiento robusto del comportamiento en entornos de vigilancia inteligentes. Sensores 2016, 16, 1010. [CrossRef] [PubMed]
6. Sajjad, M.; Khan, S.; Muhammad, K.; Wu, W.; Ullah, A.; Baik, SW. Clasificación de tumores cerebrales multigrado mediante CNN profunda con aumento de datos extenso. J. Comput. Sci. 2019, 30, 174–182. [CrossRef]
7. Chandola, V.; Banerjee, A.; Kumar, V. Detección de anomalías: una revisión. ACM Comput. Surv. 2009, 41, 1–58. [CrossRef]
8. Boiman, O.; Irani, M. Detección de irregularidades en imágenes y en vídeo. Int. J. Comput. Vis. 2007, 74, 17–31. [CrossRef] 9. Statista. Corea del Sur: Número de cámaras de CCTV en 2018. Disponible en línea : https://www.statista.com/statistics/651509/south-korea-cctv-cameras/ (Consultado el 7 de noviembre de 2019).
10. Lin, D.; Li, Y.; Xie, S.; Nwe, TL; Dong, S. DDR-ID: Descomposición de imágenes basada en redes de reconstrucción profunda dual para la detección de anomalías. arXiv 2021, arXiv:2007.09431v1. [CrossRef]
11. Motamed, M.; Machemehl, R. Detección de incidentes en autopistas en tiempo real; Instituto de Transporte de Texas A&M: Bryan, TX, EE. UU., 2014.
12. Zhou, S.; Shen, W.; Zeng, D.; Fang, M.; Wei, Y.; Zhang, Z. Redes neuronales convolucionales espacio-temporales para la detección y localización de anomalías en escenas concurridas. Signal Process. Image Commun. 2016, 47, 358–368. [CrossRef]
13. Yen, SH; Wang, CH Detección de eventos anormales mediante HOSF. En Actas de la Conferencia Internacional de TI de 2013 Convergencia y Seguridad, ICITCS, Macao, China, 16-18 de diciembre de 2013.
14. Lu, C.; Shi, J.; Jia, J. Detección de eventos anormales a 150 FPS en MATLAB. En Actas de la Conferencia Internacional IEEE sobre Visión por Computadora, Sídney, Australia, 2-8 de diciembre de 2013.

Machine Translated by Google

15. Zhao, B.; Fei-Fei, L.; Xing, EP Detección en línea de eventos inusuales en videos mediante codificación dispersa dinámica. En Actas de la Conferencia de la Sociedad de Computación del IEEE sobre Visión por Computadora y Reconocimiento de Patrones, Colorado Springs, CO, EE. UU., 20-25 de junio de 2011; págs. 3313-3320.
16. Sabokrou, M.; Fathy, M.; Hoseini, M.; Klette, R. Detección y localización de anomalías en tiempo real en escenas concurridas. En Actas de los Talleres de la Conferencia IEEE sobre Visión por Computadora y Reconocimiento de Patrones, Boston, MA, EE. UU., 7-12 de junio de 2015; págs. 56-62.
17. Kiran, BR; Thomas, DM; Parakkal, R. Una visión general de los métodos basados en aprendizaje profundo para la detección de anomalías no supervisada y semisupervisada en vídeos. J. Imaging 2018, 4, 36. [CrossRef]
18. Christiansen, P.; Nielsen, LN; Steen, KA; Jørgensen, RN; Karstoft, H. DeepAnomaly: Combinación de sustracción de fondo y aprendizaje profundo para la detección de obstáculos y anomalías en un campo agrícola. Sensors 2016, 16, 1904. [CrossRef]
19. Roshtkhari, MJ; Levine, MD Visión y comprensión de imágenes, y Undefined 2013, Un método de aprendizaje en línea y en tiempo real para detectar anomalías en videos utilizando composiciones espaciotemporales; Elsevier: Ámsterdam, Países Bajos, 2013.
20. Sabokrou, M.; Fathy, M.; Hoseini, M. Detección y localización de anomalías de vídeo basadas en la escasez y el error de reconstrucción de autoencoder. Electron. Lett. 2016, 52, 1122–1124. [CrossRef]
21. Cui, X.; Liu, Q.; Zhang, S.; Yang, F.; Metaxas, DN. Residuo espectral temporal para la detección rápida de movimiento saliente. Neurocomputing 2012, 86, 24–32. [CrossRef]
22. Direkoglu, C.; Sah, M.; OConnor, NE. Detección de comportamiento anormal en multitudes mediante nuevas características basadas en flujo óptico. En Actas de la 14.ª Conferencia Internacional IEEE de 2017 sobre Vigilancia Avanzada Basada en Vídeo y Señales (AVSS), Lecce, Italia, del 29 de agosto al 1 de septiembre de 2017.
23. Li, S.; Liu, C.; Yang, Y. Detección de anomalías basada en máxima probabilidad a posteriori. Pattern Recognit. Lett. 2018, 107, 91–97. [CrossRef]
24. Ullah, H.; Altamimi, AB; Uzair, M.; Ullah, M. Detección y localización de entidades anómalas en flujos peatonales. Neurocomputing 2018, 290, 74–86. [CrossRef]
25. Ravindran, V.; Viswanathan, L.; Rangaswamy, S. Un nuevo enfoque para la detección automática de accidentes de tráfico mediante visión artificial. técnicas. Int. J. Adv. Comput. Sci. 2016, 7, 235–242. [CrossRef]
26. Sharma, S.; Sebastian, S. Algoritmo de detección y notificación de accidentes automovilísticos basado en IoT para accidentes de carretera generales. Int. J. Electr. Ingeniería Informática 2019, 9, 2088–8708. [CrossRef]
27. Azam, A.; Singh, K. Prevención de accidentes de tráfico mediante detector de alcohol y módulo acelerómetro. EasyChair n.º 5047. 26 de febrero de 2021. Disponible en línea: https://easychair.org/publications/preprint/7TfD (Consultado el 24 de junio de 2022).
28. Liang, G. Detección automática de accidentes de tráfico basada en el internet de las cosas y la máquina de vectores de soporte. Int. J. Smart Home 2015, 9, 97–106. [CrossRef]
29. Wang, T.; Snoussi, H. Detección de eventos anómalos mediante análisis de características de flujo óptico. Sensors 2015, 15, 7156–7171. [CrossRef]
30. Pawar, K.; Attar, V. Enfoques de aprendizaje profundo para la detección de actividad anómala basada en vídeo. World Wide Web 2019, 22, 571–601. [CrossRef]
31. Pathak, AR; Pandey, M.; Rautaray, S. Aplicación del aprendizaje profundo para la detección de objetos. Procedia Comput. Sci. 2018, 132, 1706–1717. [CrossRef]
32. Pathak, AR; Pandey, M.; Rautaray, S.; Pawar, K. Evaluación de la detección de objetos mediante redes neuronales convolucionales profundas. En Computación inteligente e información y comunicación; Springer: Singapur, 2018; Volumen 673.
33. Pathak, AR; Pandey, M.; Rautaray, S. Análisis de sentimiento a nivel de tema de datos de redes sociales utilizando aprendizaje profundo. Appl. Soft Comput. 2021, 108, 107440. [CrossRef]
34. Algan, G.; Ulusoy, I. Clasificación de imágenes con aprendizaje profundo en presencia de etiquetas ruidosas: una revisión. Knowl.-Based Syst. 2021, 215, 106771. [CrossRef]
35. Ouahabi, A.; Taleb-Ahmed, A. Aprendizaje profundo para la segmentación semántica en tiempo real: Aplicación en imágenes de ultrasonido. Pattern Recognit. Lett. 2021, 144, 27–34. [CrossRef]
36. Marvasti-Zadeh, SM; Cheng, L.; Ghanei-Yakhdan, H.; Kasaei, S. Aprendizaje profundo para el seguimiento visual: una revisión exhaustiva. IEEE Trans. Intell. Transp. Syst. 2022, 23, 3943–3968. [CrossRef]
37. Yousaf, U.; Khan, A.; Ali, H.; Khan, FG; Rehman, ZU; Shah, S.; Ali, F.; Pack, S.; Ali, S. Un enfoque basado en aprendizaje profundo para Localización y reconocimiento de matrículas de vehículos pakistaníes. Sensors 2021, 21, 7696. [CrossRef]
38. Pawar, K.; Attar, VZ Evaluación de arquitecturas de autoencoders para la representación de datos. En Aprendizaje profundo: conceptos y arquitecturas; Pedrycz, W., Chen, S.-M., Eds.; Springer International Publishing: Nueva York, NY, EE. UU., 2020; pp. 101–132.
39. Ren, H.; Song, Y.; Wang, J.; Hu, Y.; Lei, J. Un enfoque de aprendizaje profundo para la predicción del riesgo de accidentes de tráfico en toda la ciudad. En Actas de la 21.ª Conferencia Internacional sobre Sistemas de Transporte Inteligentes de 2018, Maui, HI, EE. UU., 4-7 de noviembre de 2018; págs. 3346-3351.
40. Bortnikov, M.; Khan, A.; Khattak, AM; Ahmad, M. Reconocimiento de accidentes mediante CNN 3D para monitoreo automatizado de tráfico en sistemas inteligentes ciudades. En Science and Information Conference; Springer: Cham, Suiza, 2019; pp. 256–264.
41. Tian, D.; Zhang, C.; Duan, X.; Wang, X. Un método automático de detección de accidentes automovilísticos basado en sistemas cooperativos de infraestructura vehicular. IEEE Access 2019, 7, 127453–127463. [CrossRef]
42. Ohgushi, T.; Horiguchi, K.; Yamanaka, M. Método de detección de obstáculos en la carretera basado en un autoencoder con segmentación semántica. En las Actas de la Conferencia Asiática sobre Visión por Computadora, Kioto, Japón, 30 de noviembre de 2020.
43. Yao, Y.; Xu, M.; Wang, Y.; Crandall, DJ; Atkins, EM. Detección no supervisada de accidentes de tráfico en vídeos en primera persona. Preimpresión de arXiv. 2019, arXiv:1903.00618.

Machine Translated by Google

44. Minli, Z.; Shanshan, Q. Investigación sobre la aplicación de redes neuronales artificiales en ofertas de licitación para proyectos de construcción. Phys. Procedía 2012, 24, 1781-1788. [CrossRef]
45. OShea, K.; Nash, R. Una introducción a las redes neuronales convolucionales. Preimpresión de arXiv 2015, arXiv:1511.08458.
46. Karpathy, A.; Toderici, G.; Shetty, S.; Leung, T.; Sukthankar, R.; Fei-Fei, L. Clasificación de vídeo a gran escala con redes neuronales convolucionales. En Actas de la conferencia IEEE sobre visión por ordenador y reconocimiento de patrones, Columbus, OH, EE. UU., 23-28 de junio de 2014.
47. Chéron, G.; Laptev, I.; Schmid, C. P-CNN: Características de CNN basadas en pose para el reconocimiento de acciones. En Actas del IEEE Conferencia Internacional sobre Visión por Computadora, Santiago, Chile, 7–13 de diciembre de 2015; págs. 3218–3226.
48. Deepak, S.; Ameer, PM Categorización automatizada de tumores cerebrales a partir de resonancia magnética utilizando características de CNN y SVM. J. Ambient Intell. Human. Comput. 2021, 12, 8357–8369. [CrossRef]
49. Hafeez, U.; Umer, M.; Hameed, A.; Mustafa, H.; Sohaib, A.; Nappi, M.; Madni, HA Un sistema de predicción de enfermedades por coronavirus basado en CNN para radiografías de tórax. J Ambient Intell Humaniz Comput. 2022, 1–15. [Referencia cruzada]
50. Singh, L.; Alam, A. Una metodología híbrida eficiente para la detección temprana del cáncer de mama en mamografías digitales. J. Ambient Intel. Humaniz. Computadora. 2022. [Referencia cruzada]
51. Song, X.; Cong, Y.; Song, Y.; Chen, Y.; Liang, P. Un modelo de diagnóstico de fallas en rodamientos basado en CNN con núcleos de convolución amplios. J. Inteligencia ambiental. Humano. Computadora. 2021, 13, 4041–4056. [Referencia cruzada]
52. Wang, J.; Wang, M.; Liu, Q.; Yin, G.; Zhang, Y. Detección profunda de anomalías en autopistas basada en computación de borde y aprendizaje profundo aprendizaje. J. Ambient Intell. Human. Comput. 2022, 13, 1293–1305. [CrossRef]
53. Krizhevsky, A.; Sutskever, I.; Hinton, GE Clasificación de ImageNet con redes neuronales convolucionales profundas. Adv. Neural Inf. Process. Syst. 2012, 25, 1097–1105. [CrossRef]
54. Su, H.; Maji, S.; Kalogerakis, E.; Learned-Miller, E. Redes neuronales convolucionales multivista para el reconocimiento de formas 3D. arXiv 2015, arXiv:1505.00880.
55. Chollet, F. Keras. 2015. Disponible en línea: https://github.com/fchollet/keras (Consultado el 25 de marzo de 2021).
56. Multitel, Centro de Investigación e Innovación Tecnológica. Disponible en línea: https://www.multitel.be/ (consultado el 29 de septiembre de 2019).
57. Anti´c, B.; Ommer, B. Análisis de vídeo para la detección de anomalías. En Actas de la Conferencia Internacional IEEE sobre Computación Vision, Washington, DC, EE. UU., 6-13 de noviembre de 2011; págs. 2415-2422.
58. Li, W.; Mahadevan, V.; Vasconcelos, N. Detección y localización de anomalías en escenas concurridas. IEEE Trans. Pattern Anal. Mach. Intel. 2014, 36, 18–32.
59. Sultani, W.; Chen, C.; Shah, M. Detección de anomalías en el mundo real en vídeos de vigilancia. En Actas de la Conferencia IEEE sobre Visión por Computadora y Reconocimiento de Patrones, Salt Lake City, UT, EE. UU., 18–23 de junio de 2018; págs. 6479–6488.