Machine Translated by Google

Detección continua de correlación de valores atípicos basada en autoencoder para Predicción del flujo de tráfico en tiempo real

Himanshu Choudhary, Universidad Tecnológica de Eindhoven, Eindhoven, Países Bajos himanshu.dce12@gmail.com

Marwan Hassani, Universidad Tecnológica de Eindhoven, Eindhoven, Países Bajos m.hassani@tue.nl

ABSTRACTO

En los entornos urbanos, la congestión del tráfico, a menudo identificada por sucesos atípicos como accidentes u obras, supone un reto importante. Estos valores atípicos provocan fluctuaciones abruptas en el tráfico, lo que requiere modelado en tiempo real para predicciones precisas. El marco de trabajo propuesto, denominado OWAM (Outlier Weighted Autoencoder Modeling), aborda este problema mediante el uso de autoencoders para la detección local de valores atípicos en cada sensor de tráfico y la generación de puntuaciones de correlación para evaluar el impacto del tráfico vecino. Estas puntuaciones, que sirven como información ponderada de los sensores vecinos, mejoran el rendimiento del modelo y permiten actualizaciones efectivas en tiempo real. OWAM logra un equilibrio entre precisión y eficiencia, lo que lo hace altamente adecuado para aplicaciones del mundo real. Este avance en los modelos de predicción de tráfico contribuye significativamente al campo de la gestión del transporte . El marco de trabajo y sus conjuntos de datos están disponibles públicamente en https://github.com/himanshudce/OWAM.

Formato de referencia ACM: Himanshu Choudhary y Marwan Hassani. 2024. Detección continua de correlación de valores atípicos basada en autoencoders para la predicción del flujo de tráfico en tiempo real . En el 39.º Simposio ACM/SIGAPP sobre Computación Aplicada (SAC '24), del 8 al 12 de abril de 2024, Ávila, España. ACM, Nueva York, NY, EE. UU., Artículo 4, 3 páginas. https://doi.org/10.1145/3605098.3636162

1. INTRODUCCIÓN

La congestión del tráfico, un importante desafío urbano, impacta negativamente la salud pública, la estabilidad económica y la calidad ambiental debido al aumento de las emisiones y la contaminación del aire [18]. La optimización de los sistemas de tráfico existentes es crucial para mejorar el flujo vehicular, ya que la ampliación de la capacidad vial no siempre es factible. Si bien el modelado del tráfico ha experimentado avances significativos, persisten desafíos, particularmente al abordar escenarios atípicos como accidentes, eventos o trabajos viales, donde los patrones de tráfico se desvían marcadamente de la norma. Estas situaciones son repentinas y pueden alterar completamente el flujo vehicular; por lo tanto, requieren soluciones de modelado de tráfico en tiempo real que sean capaces de acomodar tales cambios dinámicos y atípicos en el tráfico de forma simultánea.

Nuestro estudio introduce el marco de modelado de autoencoder ponderado de valores atípicos (OWAM), diseñado para mejorar las predicciones de tráfico tanto en escenarios dinámicos como atípicos. Aprovechando los autoencoders (AE) para la detección local de valores atípicos en tiempo real, OWAM integra la Tierra Distancia de movimiento (EMD)[1] como función de pérdida en AE para mejorar el rendimiento . Basándonos en la puntuación de valores atípicos, calculamos correlaciones entre el sensor objetivo y sus vecinos y, posteriormente, fusionamos los datos vecinos con los datos objetivo, asignando pesos basados en sus puntuaciones de correlación para garantizar una influencia precisa. Además, incorporamos actualizaciones del modelo basadas en valores atípicos a través de OWAM para abordar eficazmente tanto los escenarios de valores atípicos como los cambios dinámicos simultáneamente. Evaluamos el marco utilizando tres conjuntos de datos del mundo real diferentes: Hague, METR-LA y PEMS-BAY. Las contribuciones clave de esta investigación son el innovador marco OWAM para Predicción mejorada del flujo de tráfico, la novedosa arquitectura de detección de valores atípicos que integra la pérdida EMD, la evaluación exhaustiva de conjuntos de datos reales y la provisión de una implementación de código abierto para futuras investigaciones. Una exploración exhaustiva de OWAM con una evaluación experimental más profunda está disponible en [6].

2. ANTECEDENTES Y TRABAJOS RELACIONADOS

En el campo de la detección de valores atípicos y el modelado de tráfico, se han utilizado métodos tradicionales como SVM de una clase, factores de valores atípicos locales (LOF) y bosques de aislamiento para identificar puntos de datos que se desvían de los patrones normales [4, 14, 20]. Sin embargo, estas técnicas suelen ser insuficientes en aplicaciones en tiempo real, como la predicción del flujo de tráfico, debido a problemas de escalabilidad y altos tiempos de respuesta. Los autoencoders (AE) han surgido como un enfoque más eficaz, particularmente en escenarios en línea (con algoritmos como KitNET [17] y MemStream [2]).
Los autoencoders ponderados por probabilidad (PW-AE) [5] mejoran aún más el enfoque AE al optimizar las funciones de pérdida basadas en la probabilidad de anomalía, manejando de manera eficiente la deriva de conceptos y las anomalías del flujo de datos.

Por otro lado, el modelado de tráfico ha evolucionado para incluir técnicas paramétricas, de aprendizaje automático y de aprendizaje profundo [15]. Los métodos híbridos y de aprendizaje profundo, como las CNN y las LSTM, que pueden extraer dependencias espacio-temporales, han mostrado un rendimiento mejorado [11, 13]. Además, el uso de distribuciones de probabilidad de flujo (FPD) y la distancia de Earth Mover ha mostrado resultados prometedores en la detección efectiva de valores atípicos en datos de tráfico [1, 7, 8, 16].

Sin embargo, estos enfoques suelen presentar deficiencias al gestionar simultáneamente las actualizaciones en tiempo real y los escenarios atípicos, lo cual es necesario para capturar la naturaleza dinámica del tráfico. Esto genera una brecha en la investigación, ya que se necesitan modelos capaces de gestionar de manera eficiente tanto los escenarios atípicos como los ajustes en tiempo real.

3. METODOLOGÍA

El marco de modelado de autoencoder ponderado de valores atípicos (OWAM, por sus siglas en inglés), ilustrado en la Figura 2, ofrece un enfoque novedoso para el modelado del tráfico. Comienza agregando datos de tráfico a intervalos de 5 minutos y creando distribuciones de probabilidad de flujo (FPD) para cada ventana de 1 hora.

Se concede permiso para realizar copias digitales o impresas de parte o la totalidad de esta obra para uso personal o en el aula, sin coste alguno, siempre que dichas copias no se realicen ni distribuyan con fines de lucro o ventaja comercial y que incluyan este aviso y la cita completa en la primera página. Los derechos de autor de los componentes de terceros de esta obra deben respetarse. Para cualquier otro uso, póngase en contacto con el propietario/autor(es).

SAC '24, 8-12 de abril de 2024, Ávila, España © 2024

Derechos de autor reservados por el/los propietario/s/autor/es.

ISBN de ACM 979-8-4007-0243-3/24/04.
https://doi.org/10.1145/3605098.3636162

Machine Translated by Google

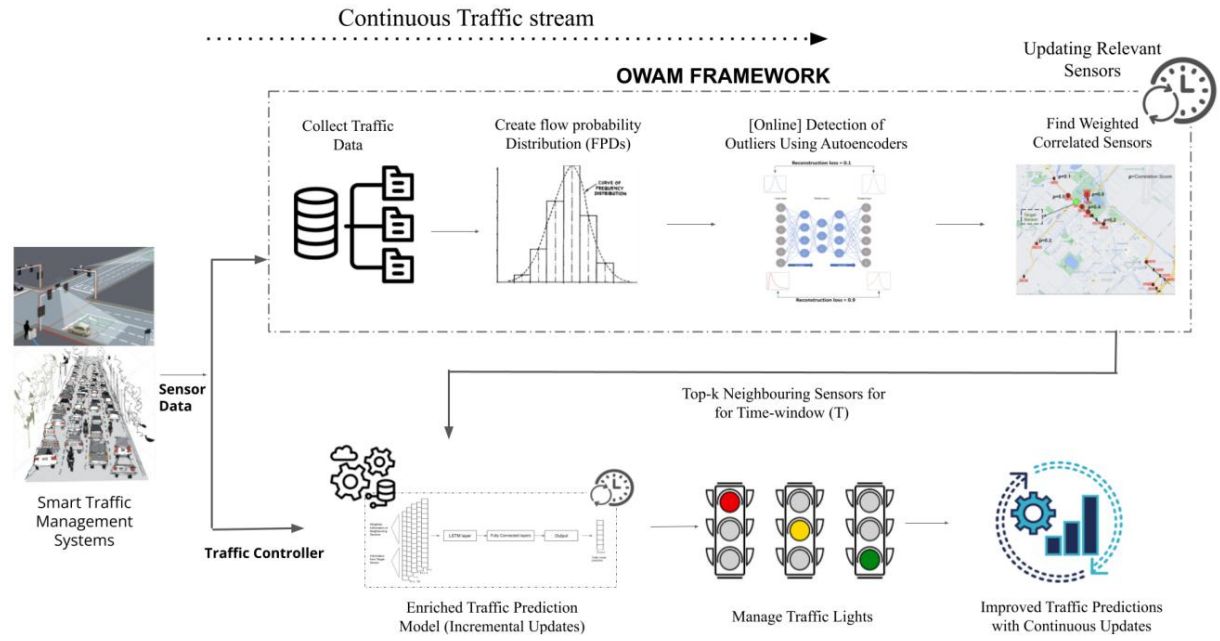


Figura 1: Descripción general del marco OWAM con actualizaciones en tiempo real.

para capturar tendencias de tráfico de alto nivel y reducir el ruido. Muy corto
Los intervalos para FPD pueden introducir ruido excesivo, mientras que los intervalos muy largos
Los intervalos pueden suavizar demasiado los datos, lo que podría hacer que se pierdan datos importantes.
patrones.

En la fase central de detección de valores atípicos, OWAM emplea métodos en línea.
autoencoders (AE) para el análisis en tiempo real de FPD, identificando anomalías
locales en cada sensor. Un aspecto novedoso de este proceso es el
integración de la pérdida de distancia de Earth Mover (EMD) con AE, mejorando la
precisión de la detección de valores atípicos. El marco conserva la
puntuaciones atípicas brutas para cada sensor, lo que garantiza una comprensión
integral de la dinámica del tráfico sin necesidad de información adicional.
filtrado por umbral.

OWAM calcula entonces las puntuaciones de correlación entre el objetivo.
sensor y sus vecinos utilizando las puntuaciones de valores atípicos. Estas puntuaciones
sirven como ponderaciones para ajustar la importancia de los sensores vecinos.
información antes de su integración con los datos del sensor objetivo.
Los datos ponderados se concatenan con los datos del sensor objetivo y se introducen en
Un modelo LSTM para la predicción eficiente del tráfico. La metodología.
destaca que OWAM puede mejorar no solo LSTM sino cualquier tráfico
modelo de predicción.

El marco está diseñado para adaptarse a la naturaleza dinámica de
El tráfico se gestiona mediante una estrategia de actualización incremental. Recalcula
periódicamente la información sobre valores atípicos y correlación para cada intervalo de tiempo.
y actualiza incrementalmente el modelo LSTM con esta nueva información . Comenzando con
datos históricos, el modelo integra datos de
ventanas de tiempo subsiguientes utilizando una metodología de prueba y luego entrenamiento [3],
Garantizar la adaptabilidad en tiempo real.

Para evaluar y analizar el modelo, nuestra investigación utiliza tres
conjuntos de datos del mundo real, cada uno de los cuales captura diferentes aspectos del flujo de tráfico.
tal como se describe en la Tabla 1.

Tabla 1: Información del conjunto de datos

Conjunto de datos	Hague	METR-LA	PEMS-BAY
#Muestras	236.736	52.116	34.272
#Sensores	23	325	207
Frecuencia de muestreo	5 minutos	5 minutos	5 minutos
Rango de tiempo	2 años	4 meses	6 meses
Indicador de tráfico	#Vehículos	Velocidad (mi/h)	Velocidad (mi/h)

4. RESULTADOS Y CONCLUSIÓN

Para evaluar, primero investigamos el impacto de OWAM en la dimensionalidad del modelo de
tráfico, encontrando que el número óptimo de sensores
La inclusión varía según el conjunto de datos. El conjunto de datos de La Haya, debido a la menor
número de sensores, favoreció la inclusión de todos los sensores vecinos,
mientras que los conjuntos de datos METR-LA y PEMS-BAY requirieron un enfoque más selectivo,
favoreciendo al 10% al 50% superior de los sensores vecinos.
para mejorar las predicciones. Vale la pena señalar que utilizar solo el
sensor objetivo o incorporar toda la información del sensor disponible
La red de tráfico da como resultado un rendimiento de predicción más bajo.
El aumento del tiempo de entrenamiento es notable para las dimensiones superiores.
Conjunto de datos PEMS-BAY con respecto a otros.

La integración de la pérdida de distancia de movimiento de tierra (EMD) en los
autocodificadores dentro de OWAM resultó en un rendimiento superior, demostrando una mejora
del 5% al 11% para METR-LA y PEMS-BAY.
conjuntos de datos en comparación con modelos que utilizan la función de pérdida RMSE. El uso de EMD
La pérdida provocó una mayor varianza en las puntuaciones de valores atípicos, lo que permitió que el modelo
para diferenciar mejor entre sensores más y menos relevantes.

En comparación, OWAM superó al LSTM Baseline y
modelos anteriores basados en valores atípicos en términos de puntuaciones RMSE, como se muestra en
Tabla 2. Al igualar el modelo DGCRN de última generación en el
En el conjunto de datos de La Haya, DGCRN lo superó en el METR-LA.

Machine Translated by Google

Tabla 2: Resultados combinados para La Haya, METR-LA y PEMS-
conjuntos de datos de BAY

Nombre del modelo del conjunto de datos	RMSE	Tiempo de entrenamiento	Tiempo de evaluación
la Haya	OWAM (Nuestro) 13.479	677,74	47.617
	HST[21] 13.631	244.31	101.32
	Kit-Net[17] 13.540	305.37	48.267
	DGCRN[12] 13.110	5043.31	280.00
	OBIS[16] 13.547	682.81	51.30
	Línea base LSTM 13.547	682.81	29.83
METRO-LA	OWAM (Nuestro) 5.880	46.18	8.09
	HST[21] 6.815	47.53	27.37
	Kit-Net[17] 5.883	55.44	11.58
	DGCRN[12] 4.161	11263.23	310.04
	OBIS[16] 7.421	91.37	10,78
	LSTM Baseline 8.831	106.06	11.11
PEMS-BAHÍA	OWAM (Ours) 4.036	303,94	97,56
	HST[21] 4.816	372,86	110,73
	Kit-Net[17] 4.312	356,96	104.393
	DGCRN[12] 1.591	25900.67	780,04
	OBIS[16] 4.375	377,49	99,27
	LSTM Baseline 5.434	405.05	111,74

y los conjuntos de datos PEMS-BAY debido a la superioridad espaciotemporal de DGCRN.
manejo de dependencias. Sin embargo, el procesamiento es mucho más rápido que el de OWAM.
Los tiempos lo convierten en una opción más práctica para aplicaciones del mundo real,
especialmente en el modelado de tráfico a gran escala y en tiempo real donde los datos rápidos
El procesamiento y la toma de decisiones son clave. La capacidad de OWAM para manejar
eficientemente conjuntos de datos más grandes y escenarios complejos con una menor carga
computacional que DGCRN lo convierte en una solución escalable y eficiente en tiempo.
Solución para la gestión del tráfico y aplicaciones similares.

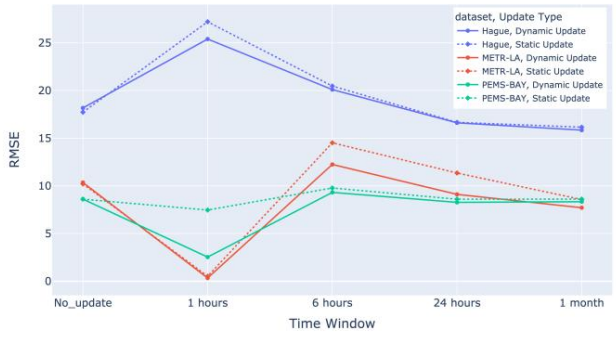


Figura 2: Descripción general del marco OWAM con tiempo real
Actualizaciones

En entornos en tiempo real, OWAM demostró su eficacia mediante
Mejora significativa del rendimiento mediante actualizaciones dinámicas
basado en correlaciones ponderadas por valores atípicos como se indica en la Figura 2.
Esta mejora fue particularmente notable tanto en corto (1-
horas) y períodos de tiempo más largos (diarios o mensuales), mostrando
su adaptabilidad a diversos escenarios de tráfico. Esto enfatiza la
necesidad de seleccionar ventanas de tiempo apropiadas para las actualizaciones del modelo
basado en el análisis de datos y el estudio de patrones.

En conclusión, el marco de modelado de autoencoder ponderado de valores atípicos
(OWAM) presenta un enfoque novedoso para el modelado de tráfico impulsado por
valores atípicos , fusionando eficazmente técnicas avanzadas de detección de valores
atípicos con análisis de tráfico en tiempo real. Al incorporar autoencoders con pérdida
de distancia de Earth Mover, OWAM mejora significativamente la detección de valores
atípicos e integra información de anomalías en
modelos de predicción de tráfico que ofrecen actualizaciones dinámicas en tiempo real
modelado. Los resultados experimentales demuestran la superioridad de OWAM.
rendimiento, superando a los modelos tradicionales y proporcionando un
Solución eficiente para aplicaciones de tráfico en tiempo real. En el futuro,
planeamos incorporar elementos de GNN en nuestra arquitectura para
lograr un equilibrio entre la precisión superior de las GNN y
las capacidades de procesamiento rápido de los modelos basados en valores atípicos.
Además , la asignación de pesos y el entrenamiento del modelo en una red unificada.
mediante el uso de un mecanismo de atención podría producir un resultado robusto y
modelo interpretable. La aplicabilidad de OWAM se extiende a campos
que requiere detección de anomalías y detección de deriva conceptual en tiempo real
[9, 10, 19], abriendo nuevas vías de investigación en diversos ámbitos.

REFERENCIAS

[1] Erik Andersen, Marco Chiarandini, Marwan Hassani, Stefan Jänicke, Panagio-tis Tampakis y Arthur Zimek. 2022. Evaluación de la distribución de probabilidad Métricas de distancia en la detección de anomalías en el flujo de tráfico. En MDM.

[2] Siddharth Bhatia, Arjit Jain, Shivin Srivastava, Kenji Kawaguchi y Bryan Hooi. 2022. MemStream: Detección de anomalías basada en memoria en flujos multiaspecto. con Concept Drift. (2022).

[3] Albert Bifet, Geoff Holmes, Bernhard Pfahringer y Andreas Pfisterer. 2018. Aprendizaje automático para flujos de datos: con ejemplos prácticos en MOA. MIT Press.

[4] Markus M. Breunig, Hans-Peter Kriegel, Raymond T. Ng y Jörg Sander. 2000. LOF: Identificación de valores atípicos locales basados en la densidad. (2000).

[5] Lucas Cazzonelli y Cedric Kulbach. 2023. Detección de anomalías con Autoen- Codificadores en flujos de datos. En ECML PKDD.

[6] Himanshu Choudhary y Marwan Hassani. 2023. Mejora del flujo de tráfico. Predicción mediante autoencoders ponderados por valores atípicos: Gestión de cambios en tiempo real. arXiv:2312.16596 [cs.LG]

[7] Youcef Djenouri y Arthur Zimek. 2018. Detección de valores atípicos en el tráfico urbano. Datos. En WIMS. ACM.

[8] Wesley Fitters, Alfredo Cuzzocrea y Marwan Hassani. 2021. Mejora de LSTM Predicción de datos de flujo de tráfico vehicular mediante correlaciones de valores atípicos. En COMPSAC. 210–217. https://doi.org/10.1109/COMPSAC51774.2021.00039

[9] Marwan Hassani. 2019. Detección de deriva conceptual de flujos de eventos mediante un Ventana adaptativa. En ECMS. 230–239.

[10] Jesús Huete, Abdulhakim Ali Qahtan y Marwan Hassani. 2023. PrefijoCDD: Detección eficaz de la deriva conceptual en línea sobre flujos de eventos mediante árboles de prefijos. En COMPSAC. 328–333.

[11] Georgios N Kouziokas. 2021. Red neuronal LSTM bidireccional y unidireccional profunda Redes en la previsión del flujo de tráfico a partir de factores ambientales. En CSUM.

[12] Fuxian Li, Jie Feng, Huan Yan, Guangyin Jin, Depeng Jin y Yong Li. 2022. Red recurrente convolucional de gráficos dinámicos para la predicción del tráfico: punto de referencia y Solución. (2022).

[13] Yaguang Li, Rose Yu, Cyrus Shahabi y Yan Liu. 2018. Difusión Convolucional Red neuronal recurrente: predicción de tráfico basada en datos. En ICLR.

[14] Fei Tony Liu, Kai Ting y Zhi-Hua Zhou. 2009. Bosque de aislamiento. En ICDM.

[15] Boris Medina-Salgado, Eddy Sánchez-DelaCruz, Pilar Pozos-Parra, and Javier E. Sierra. 2022. Técnicas de predicción del flujo de tráfico urbano: Una revisión. (2022).

[16] Tom Mertens y Marwan Hassani. 2022. ¿Podemos aprender de los valores atípicos? Optimización no supervisada de sistemas inteligentes de gestión del tráfico vehicular. En ECML PKDD.

[17] Yisroel Mirsky, Tomer Doitshman, Yuval Elovici y Asaf Shabtai. 2018. Kitsune: Un conjunto de autoencoders para la detección de intrusiones en redes en línea. (2018).

[18] C. Pasquale, I. Papamichail, C. Roncoli, S. Sacone, S. Siri y M. Papageorgiou. 2015. Regulación del tráfico en autopistas de dos clases para reducir la congestión y las emisiones. mediante control óptimo no lineal. (2015).

[19] Erik Scharwächter, Emmanuel Müller, Jonathan Donges, Marwan Hassani y Thomas Seidl. 2016. Detección de procesos de cambio en redes dinámicas mediante Minería de reglas de evolución de grafos frecuentes. En ICDM. 1191–1196.

[20] Bernhard Schölkopf, Robert C Williamson, Alex Smola, John Shawe-Taylor y John Platt. 1999. Método de vectores de soporte para la detección de novedades. En NIPS.

[21] Swee Chuan Tan, Kai Ming Ting y Fei Tony Liu. 2011. Detección rápida de anomalías. para transmisión de datos. En IJCAI.