Machine Translated by Google

Check for updates

Hindawi
Wireless Communications and Mobile Computing Volumen 2022, Artículo ID 4222827, 12 páginas https://doi.org/10.1155/2022/4222827

WILEY | Hindawi

Artículo de investigación

Detección automática de anomalías de tráfico en la red vial con Red neuronal gráfica espacio-temporal Aprendizaje de representaciones

Hengyuan Zhang y [1] Suyao Zhao [2,] Rui Heng Liu [1,] Wenlong Wang [2] Yixin Hong, [1] Runjiu Hu [3]

[1]Facultad de Ciencias e Ingeniería Cibernética, Universidad de Zhengzhou, provincia de Henan, China.
[2]Colegio Internacional de la Universidad de Zhengzhou, provincia de Henan, China
[3]Wuhan Eleho Co., Ltd., China

La correspondencia debe dirigirse a Ruiheng Liu; lrhis2019@stu.zzu.edu.cn y Runjiu Hu; hurunjiu@163.com

Recibido el 25 de abril de 2022; Revisado el 20 de mayo de 2022; Aceptado el 3 de junio de 2022; Publicado el 20 de junio de 2022

Editor académico: Kuruva Lakshmanna

Copyright © 2022 Hengyuan Zhang et al. Este es un artículo de acceso abierto distribuido bajo la Licencia Creative Commons Atribución, que permite el uso, la distribución y la reproducción sin restricciones en cualquier medio, siempre que se cite correctamente la obra original.

La detección de anomalías en el tráfico es fundamental para un sistema de transporte inteligente. La detección automática de anomalías en el tráfico proporciona información suficiente para la toma de decisiones a operadores de redes viales, viajeros y otras partes interesadas. Esta investigación propone un novedoso método automático de detección de anomalías en el tráfico basado en el aprendizaje de representaciones de redes neuronales gráficas espacio-temporales. La detección de anomalías se divide en dos pasos: primero, se aprende la representación implícita de características gráficas de series temporales multivariadas de flujos de tráfico mediante un modelo de atención gráfica para predecir los estados del tráfico. Segundo, se detectan anomalías en el tráfico mediante el cálculo de la puntuación de desviación gráfica para comparar la desviación de los estados de tráfico predichos con los observados. Los experimentos realizados con conjuntos de datos de redes reales demuestran que, con un flujo de trabajo integral y una representación espacio-temporal de los estados del tráfico, este método detecta las anomalías de forma precisa y automática, y logra un mejor rendimiento que los métodos de referencia.

1. Introducción

Con el aumento anual del uso de vehículos y la expansión gradual de la red de tráfico, existe una creciente demanda de detección de eventos anómalos en dicha red. Necesitamos monitorear cada vía y gestionar la que pueda verse afectada de inmediato tras una situación anómala. Mediante una gestión eficaz, se pueden abordar a tiempo las congestiones de tráfico y los accidentes, garantizando así el funcionamiento normal del tráfico. En la práctica, contamos con múltiples puntos de recolección de información en la ciudad para recopilar grandes cantidades de datos de series temporales sobre el estado, la velocidad y otra información relativa a la vía. Estos datos interactúan entre sí de forma compleja. Por ejemplo, un atasco en una vía aumentará el número de vehículos en otras vías. El aumento del tráfico en esa ruta, a su vez, impulsará a los conductores cuyo destino a lo largo de ella para elegir otras rutas, lo que tiene un impacto más amplio. La complejidad de los datos en cada sección de la red de tráfico correspondiente ha aumentado rápidamente con el desarrollo de las ciudades, lo que ha reducido la eficacia de los métodos de detección tradicionales. Si se aplica eficazmente el análisis de patrones de flujo de tráfico espacio-temporal y la detección de anomalías, podremos detectar secciones de carretera anómalas, predecir las estaciones donde podrían surgir problemas y, de esta forma, prevenirlos y solucionarlos con prontitud. Así, la eficiencia del transporte mejorará significativamente.

La detección de situaciones inesperadas en redes viales es un problema típico de detección de anomalías complejas. Este tipo de investigación detecta la presencia de anomalías analizando datos históricos y las resuelve a tiempo, evitando así efectos indeseables adicionales. Los algoritmos clásicos para problemas de detección de anomalías incluyen la construcción de modelos lineales, como el método de análisis de componentes principales (PCA); distancia-

Machine Translated by Google

6302, 2022, 1, Descargado de https://onlinelibrary.wiley.com/doi/10.1155/2022/4222827 por Cochrane Perú, Wiley Online Library el [02/05/2026]. Consulte los Términos y condiciones (https://onlinelibrary.wiley.com/terms-and-conditions) en Wiley Online Library para conocer las reglas de uso; los artículos de acceso abierto se rigen por la Licencia Creative Commons aplicable.

Medidas basadas en datos, como el método de k vecinos más cercanos (KNN); detección basada en clústeres, como el método de agrupamiento espacial basado en densidad de aplicaciones con ruido (DBSCAN); y medidas basadas en densidad, como el algoritmo de factor de valores atípicos locales (LOF). Estos esquemas determinan si se producirán anomalías analizando las características más relevantes.
Sus principios claros y concisos sientan una buena base para futuras investigaciones y análisis. Sin embargo, la situación del tráfico en el mundo real suele estar influenciada por muchos factores.
Por ejemplo, las condiciones de tráfico reales están fuertemente correlacionadas en el tiempo y el espacio, por lo que es esencial construir un modelo espacio-temporal dinámico no lineal para predecir anomalías en las redes viales. La simplicidad de los modelos anteriores limita su análisis a una profundidad mayor. No pueden satisfacer las necesidades prácticas de predicción. Gracias a los continuos esfuerzos de muchos investigadores, en los últimos años se han desarrollado algunos métodos basados en el aprendizaje profundo de grafos para mejorar la precisión de la detección de anomalías. La detección de anomalías basada en redes generativas antagónicas (GAN) es un método popular ampliamente utilizado en la detección de anomalías. Este método genera el espacio oculto de la red aprendiendo y capturando las características de los datos dentro de dicho espacio. Sin embargo, la mayoría de estos métodos son más adecuados y específicos para el análisis de anomalías en puntos concretos. Durante la detección de eventos anómalos en la red de tráfico, no solo necesitamos detectar la situación de los puntos individuales dispersos en cada carretera, sino también prestar atención a la situación general del tráfico y la interacción entre los puntos.

El concepto de red neuronal gráfica (GNN) fue introducido por primera vez por Gori et al. en [1]. En [2], Bruna et al. introdujeron la convolución en las redes neuronales gráficas, lo que mejoró considerablemente su efecto. En el estudio de problemas relacionados con grafos, los datos de grafos suelen contener dos partes de información: información de atributos e información de estructura. En la predicción de eventos anómalos en redes de tráfico, podemos obtener fácilmente la información de atributos de las redes viales, como el tiempo de paso de los vehículos y la velocidad de los vehículos, pero aún carecemos de su información estructural.

Para resolver este problema, propusimos un novedoso método de detección de anomalías de tráfico basado en modelos de redes de desviación de grafos (GDN). Nuestro método consta de cuatro partes principales: (1) Incrustaciones de información de tráfico. La red vial se modela como un grafo en este método, donde los nodos representan enlaces viales. La información de atributos espaciales y temporales reales de cada nodo se incrusta en el grafo, que es la base para el análisis posterior. (2) Aprendizaje de la estructura del grafo espacio-temporal del estado del tráfico. Los datos de entrada son algunos datos temporales discretos sin información estructural. Para comprender la situación general, necesitamos aprender la información implícita entre los nodos para determinar las propiedades estructurales generales. (3) Predicción del estado del tráfico. El modelo de atención del grafo se utiliza para predecir el estado del tráfico de cada nodo. Un nodo en una estructura de grafo no se ve afectado por otros nodos de la misma manera. El mecanismo de atención del grafo hace que los resultados de la predicción sean más realistas al ajustar dinámicamente la función de atención. (4) Detección de anomalías de tráfico. Esta sección se encarga de explicar las desviaciones para que los resultados sean más convincentes. Utilizando el grafo dirigido aprendido con diferentes pesos, podríamos explicar ¿Qué nodos contribuyen a las anomalías? La puntuación de desviación del grafo identifica e interpreta las desviaciones en las relaciones entre sitios aprendidas en el grafo. Los resultados muestran que podemos obtener un modelo con buenos resultados al incorporar la información de los sitios y aprender aún más la relación entre los nodos.

2. Revisión de la literatura

2.1. Predicción del estado del tráfico. La predicción del estado del tráfico es un problema crítico en el ámbito del transporte. Para predecir la situación de la red de tráfico, es necesario analizar las series temporales de la información de entrada. Los datos de las series temporales se organizan cronológicamente, varían con el tiempo y están interrelacionados. Debido a la variedad de variables de tráfico y a la variabilidad de los estados del tráfico en diferentes tramos de carretera, la tarea de predicción del estado del tráfico puede considerarse un problema de pronóstico de series temporales multivariadas.

Generalmente existen dos categorías para la predicción del estado del tráfico: métodos estadísticos tradicionales y métodos basados en aprendizaje automático. Los enfoques estadísticos tradicionales incluyen el modelo autorregresivo (AR) [3], el modelo de media móvil (MA) [4] y el modelo autorregresivo integrado de media móvil (ARIMA) [5] que se obtiene al fusionar AR y MA. Ya en [6], Williams y Hoel construyen un modelo y pronostican el flujo de tráfico vehicular como un proceso ARIMA estacional. En [7], Ghosh et al. utilizaron un modelo de paseo aleatorio, la técnica de suavizado exponencial de Holt-Winters y un modelo ARIMA estacional para predecir los flujos de tráfico en Dublín. Sin embargo, las situaciones realistas a menudo tienen características no lineales muy complejas. Con el rápido desarrollo del aprendizaje automático, especialmente el aprendizaje profundo, los problemas de pronóstico de series temporales se han desarrollado aún más. En [8], Cai et al. construyeron un modelo de k vecinos más cercanos para el pronóstico de tráfico a corto plazo en múltiples pasos Lim y Zohren [9], explicando algunos de los métodos en los que el aprendizaje profundo apoya la decisión de datos de series temporales. Esto también sirve de inspiración para el desarrollo de problemas posteriores de pronóstico de series temporales.
Zhao et al. construyeron un modelo de pronóstico de tráfico basado en memoria a corto y largo plazo en 2017. Ese mismo año, Yu et al. formularon el problema en grafos y construyeron el modelo con estructuras convolucionales completas, que logran una velocidad de entrenamiento mucho más rápida con menos parámetros. Además, la dificultad radica en que las redes de tráfico realistas suelen tener fuertes dependencias espaciales y temporales. En [10], Cui et al. combinan LSTM y GNN para descubrir las dependencias temporales y espaciales. Ese mismo año, Wang et al. combinan el algoritmo de factor de valores atípicos locales (LOF) basado en partición de cuadrícula y desarrollan un algoritmo LOF basado en cuadrícula para detectar el área anormal en Beijing. Park et al. propusieron un modelo LSTM-VAE que reemplaza la red de alimentación directa para medir la puntuación de anomalía y lograr mejores resultados. En 2019, Li et al. entrenan un modelo GAN con un discriminador LSTM-RNN para calcular las puntuaciones de anomalía para cada nodo. En [11], Geiger et al. Se utiliza el modelo TadGAN, entrenado con pérdida de consistencia cíclica para permitir una reconstrucción eficaz de datos de series temporales. En 2022 se propuso un enfoque de ciencia de datos computacional (CDS). Carrera et al. también proponen un

Machine Translated by Google

6302, 2022, 1, Descargado de https://onlinelibrary.wiley.com/doi/10.1155/2022/4222827 por Cochrane Perú, Wiley Online Library el [02/05/2026]. Consulte los Términos y condiciones (https://onlinelibrary.wiley.com/terms-and-conditions) en Wiley Online Library para conocer las reglas de uso; los artículos de acceso abierto se rigen por la Licencia Creative Commons aplicable.

Tabla 1: Resultados de la comparación con trabajos anteriores.

Metodología	Contenidos de investigación	Múltiples variables		Relación de datos		
		Sí	No	Temporal	Espacial	Temporal-espacial
Método basado en estadísticas	El modelo autorregresivo integrado de media móvil (ARIMA) [6]		√	√		
	El factor de valores atípicos locales (LOF) [19]	√		√		
en aprendizaje automático	k-vecinos más cercanos (KNN) [8]	√		√		
	Memoria a corto y largo plazo (LSTM) (Zhao et al., 2017)	√		√		
	Red neuronal convolucional gráfica (GCN) [20]	√		√		
	Este estudio	√		√		√

red antagónica convolucional de grafos espaciotemporales (STGAN) para modelar la dinámica del tráfico en [12].

2.2. Detección de anomalías. El objetivo de la detección de anomalías es identificar datos que se desvían de los patrones esperados y detectar aquellos que difieren de los datos normales. La detección de anomalías tiene una amplia gama de aplicaciones en el mundo real, como la detección de fallos en dispositivos, la detección de datos médicos, la detección de intrusiones en redes, la detección de fraudes y la detección de anomalías en series temporales. Generalmente, clasificamos las anomalías en anomalías puntuales, anomalías condicionales y anomalías de población. Los métodos de detección de anomalías también se clasifican comúnmente en los siguientes tres tipos: detección de anomalías supervisada, detección de anomalías no supervisada y detección de anomalías semisupervisada. Los métodos básicos para la detección de anomalías incluyen métodos basados en estadísticas [13], métodos basados en modelos lineales [14], detección basada en clústeres DBSCAN [15], métodos basados en distancia KNN [16], detección de proximidad basada en densidad LOF [17] y métodos integrados como bosques aislados [18]. Con los esfuerzos continuos de muchos investigadores, algunos métodos basados en aprendizaje profundo se han desarrollado en los últimos años, y la precisión de la predicción de anomalías ha mejorado enormemente. Una red generativa antagónica (GAN) es un ejemplo muy representativo. Un generador GAN se utiliza para aprender la distribución de datos para encontrar la imagen a la que debería corresponder y luego compararla para determinar si ocurren anomalías.

La detección de anomalías en redes viales puede considerarse una tarea de detección de anomalías supervisada en el caso de clases de muestra desequilibradas. Buscamos determinar si se producen condiciones anómalas detectando una serie temporal de estados operativos en una ubicación en un momento dado. Si bien la detección de anomalías suele referirse a un punto específico, en la detección de anomalías en redes viales es necesario prestar atención a múltiples puntos en toda la red. Nuestros datos de entrada no poseen una estructura gráfica en el problema de predicción de redes de tráfico, sino solo una secuencia de datos de series temporales discretas. El modelo necesita aprender implícitamente y descubrir por sí mismo la relación entre los nodos para luego utilizar la red de atención gráfica y detectar anomalías en la red vial.

En comparación con los métodos y escenarios de detección utilizados en la detección de anomalías de tráfico anteriores, las características de los nodos suelen ser homogéneas. Sin embargo, en la situación real, los nodos de la red vial pueden elegir diferentes indicadores según las condiciones específicas. Esto da como resultado que la estructura de las redes viales sea a menudo heterogénea. Al mismo tiempo, para formar la estructura de la red vial, los datos Es necesario contar con relaciones estructurales. Obtener dichos datos es una tarea difícil. Este artículo resuelve el problema de la heterogeneidad mapeando los nodos a un espacio uniforme de alta dimensión. Además, aprendemos la relación implícita de los nodos mediante el mecanismo de atención y el cálculo de la puntuación de desviación del grafo.

Para poder comparar con mayor claridad las diferencias entre los trabajos anteriores y nuestro modelo, hemos seleccionado algunos trabajos representativos para la comparación; los resultados se muestran en la Tabla 1.

3. Metodología

3.1. Descripción del problema. Este estudio formula el problema de detección de anomalías de tráfico como una tarea de detección de anomalías supervisada. Se propone un método de detección en dos etapas basado en el modelo GDL. Los nodos de detección, distribuidos en diferentes ubicaciones de la red vial, predecirán si se producirán anomalías o no. Sin embargo, detectar anomalías en las carreteras suele ser una tarea difícil. La situación del tráfico en un punto determinado estará correlacionada con otros nodos en las dimensiones espacial y temporal.

(1) Dimensión espacial. Debido a la naturaleza de las conexiones viales, algunos indicadores de tráfico, como la velocidad de paso, el tiempo de viaje y otros indicadores importantes para evaluar incidentes de tráfico en una estación, se ven afectados por los nodos conectados. Por ejemplo, cuando ocurre un accidente de tráfico en un lugar determinado, el flujo de tráfico se propagará hacia los nodos circundantes debido al cierre de la carretera o a otras variaciones, lo que provocará cambios en la situación de los nodos asociados circundantes.

(2) Dimensión temporal. Cuando se produce una anomalía en un nodo, el resultado se refleja en la dimensión temporal adyacente, tanto a corto como a largo plazo. Por ejemplo, si se detecta una anomalía a las 10:00 a. m., su impacto puede seguir sintiéndose hasta las 11:00 a. m. A veces, el efecto incluso puede manifestarse antes de que la anomalía se haya producido por completo. Por ejemplo, se puede detectar una anomalía a las 9:55 a. m.

La Tabla 2 muestra las notaciones utilizadas en este documento, y La tabla 3 muestra las abreviaturas que utilizamos en este artículo.

Machine Translated by Google

6302, 2022, 1, Descargado de https://onlinelibrary.wiley.com/doi/10.1155/2022/4223827 por Cochrane Perú, Wiley Online Library el [02/05/2026]. Consulte los Términos y condiciones (https://onlinelibrary.wiley.com/terms-and-conditions) en Wiley Online Library para conocer las reglas de uso; los artículos de acceso abierto se rigen por la Licencia Creative Commons aplicable.

Tabla 2: Notaciones utilizadas en este artículo.

Símbolo	Descripción
I Prueba TðÞ prueba	Datos de diferentes estaciones en el momento de la prueba Ttest
nodo	El vector de incrustación de la estación i
A mí	La matriz de adyacencia dona la relación entre el nodo i y el nodo j
Nodo base	El conjunto de nodos de relación candidatos de i
usado	La similitud entre la incrustación vector del nodo i y el vector de incrustación de su nodo candidato j
morir	La puntuación de los nodos a través del mecanismo de atención gráfica
ai,j	El coeficiente de atención
ErrðPt	Valor de error del sitio i en el momento t
Asma	Se utilizará una puntuación suavizada para decidir sobre si ha ocurrido o no una excepción

Tabla 3: Abreviaturas utilizadas en este documento.

Abreviatura	Nombre completo
PCA	Análisis de componentes principales
KNN	k vecinos más cercanos
DBSCAN	Agrupamiento espacial basado en densidad de aplicaciones con ruido
LOF	Algoritmo de factor de valores atípicos locales
GNN	Red neuronal gráfica
GDN	Red de desviación de grafos
CON	Modelo autorregresivo
Y	El modelo de media móvil
ARIMA	El modelo integrado autorregresivo modelo de media móvil
LSTM	Memoria a corto y largo plazo
GDL	aprendizaje profundo geométrico
GCNs	Red neuronal convolucional gráfica
PUERTA	Redes de atención gráfica
Rango intercuartílico (RIC)	Rango intercuartil
SMA	Media móvil simple
OCSVM	La máquina de vectores de soporte de una clase
HBOS	Detección de valores atípicos basada en histogramas
COPOD	Detector de valores atípicos basado en cópulas
IFOREST	Bosque del aislamiento

3.2. Descripción general. Propusimos un método novedoso para el tráfico. detección de anomalías basada en la red de desviación de grafos Método (GDN). Como muestra la Figura 1, nuestro método consiste en: cuatro partes principales:

(1) Incrustación de información de tráfico. El atributo real La información de cada nodo está integrada en el gráfico, lo cual sienta las bases para el análisis posterior

(2) Estructura del grafo espacio-temporal del estado del tráfico Aprendizaje. Los datos de entrada son algunos datos temporales discretos. datos que no tienen información estructural. Nosotros es necesario aprender la información implícita entre los nodos. para determinar las propiedades estructurales generales para comprender la situación general

(3) Predicción del estado del tráfico. Un punto en una estructura de grafo. se ve afectado de manera diferente por otros nodos. El gráfico El mecanismo de atención hace que los resultados de la predicción más realista ajustando dinámicamente la atención función

(4) Detección de anomalías de tráfico. Esta sección explica la desviaciones para hacer los resultados más precisos. Los resultados muestran que al incrustar la información del sitio y seguir aprendiendo la relación entre los nodos, podemos obtener un modelo con buenos resultados

En este artículo utilizamos un método de aprendizaje no supervisado. Según sus principios generales, nuestro conjunto de entrenamiento es Se supone que consiste enteramente en datos normales. Cada vez, el Los datos que introducimos en el modelo contienen datos para ciertas estaciones dentro de un cierto intervalo de tiempo. Para detectar el tráfico anomalías en una sola estación, elegimos usar el número de estaciones como una característica de los datos. Además, para ingresar y organizar la información de todos los nodos simultáneamente, Extraemos la información de la marca de tiempo original, las características de tiempo discreto y las agregamos al vector de entrada.

Nuestros datos fueron recopilados de diferentes estaciones en la ciudad. durante el período de la prueba T : se pueden expresar como = [I ðÞ1Þ prueba ,…,I "Prueba T" prueba]. Determinamos si se ha producido una excepción. a través del valor de salida: o(t) f0, 1g. Si en el momento de t observamos que o(t) =1, esto indica que hay una anomalía. ocurriendo en este momento. La figura 2 muestra la procesión. de nuestra red de detección.

3.3. Incrustaciones de información de tráfico. Porque nuestra red es heterogéneos, los diferentes nodos tienen propiedades diferentes y características. Por lo tanto, si queremos reflejar la información de diferentes nodos bajo la misma estructura de grafo, necesitamos para mapear las características al mismo espacio. Usamos una incrustación vector para representar las características de cada estación:

$$I^{\text{Prueba T}}_{\text{prueba}} \quad vi, \quad vi \quad Rd, \text{agujeros} \quad fg\ 1, 2, \overset{N:}{;} \qquad \text{ð1Þ}$$

N representa el número de estaciones, d la dimensión del vector de incrustación y vi la incrustación de la i-ésima estación. vector.

La importancia de las capas de incrustación se refleja en que convierte nuestra matriz dispersa en una matriz densa por alguna razón transformaciones lineales, y esta matriz densa caracteriza Todos los sitios con algunas características típicas. Esta matriz densa no solo representa la correspondencia uno a uno entre la matriz densa y las características individuales; de hecho, también contiene una gran cantidad de relaciones intrínsecas entre nodos. y nodos. Mientras tanto, el resultado de la variante 2 en la parte de Los experimentos de ablación muestran que el módulo de incrustación La capa es necesaria. Al eliminar este módulo, la precisión se reduce en un 36,99%. La tasa de detección se reduce en un 36,99%. 8,45% mientras que la tasa de falsas alarmas aumenta al 39,14%. Por

Machine Translated by Google

6302, 2022, 1, Descargado de https://onlinelibrary.wiley.com/doi/10.1155/2022/4222827 por Cochrane Perú, Wiley Online Library el [02/05/2028]. Consulte los Términos y condiciones (https://onlinelibrary.wiley.com/terms-and-conditions) en Wiley Online Library para conocer las reglas de uso; los artículos de acceso abierto se rigen por la Licencia Creative Commons aplicable.

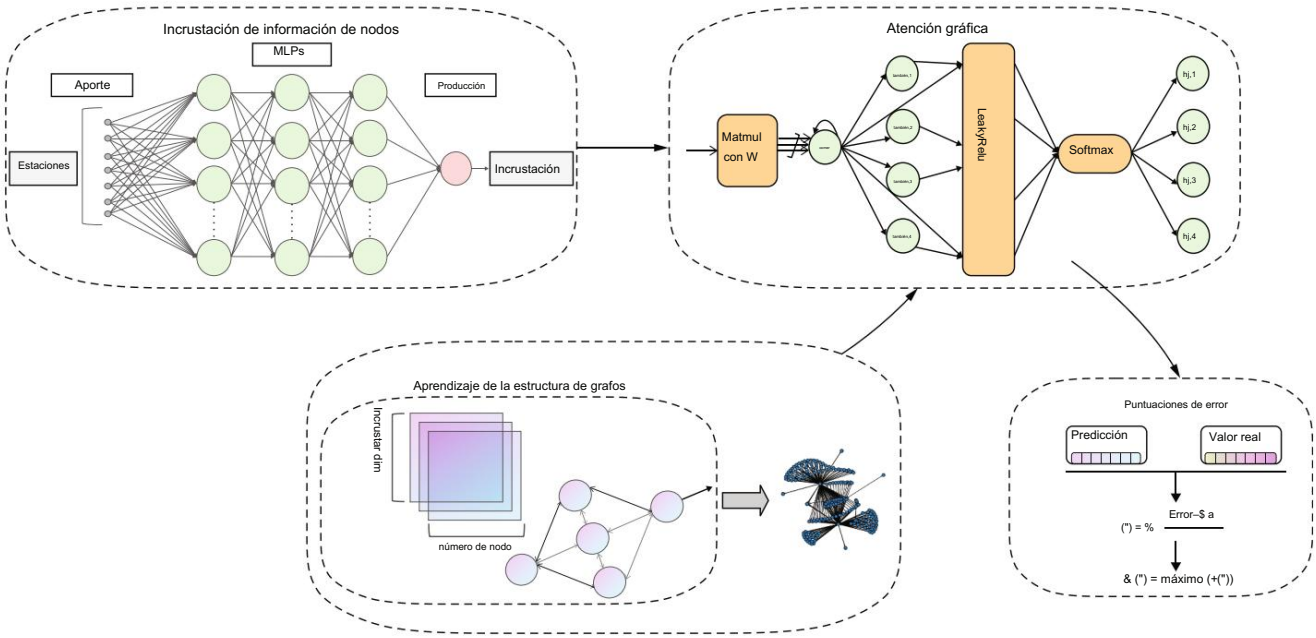


Figura 1: Metodología de detección de anomalías en la red de tráfico.

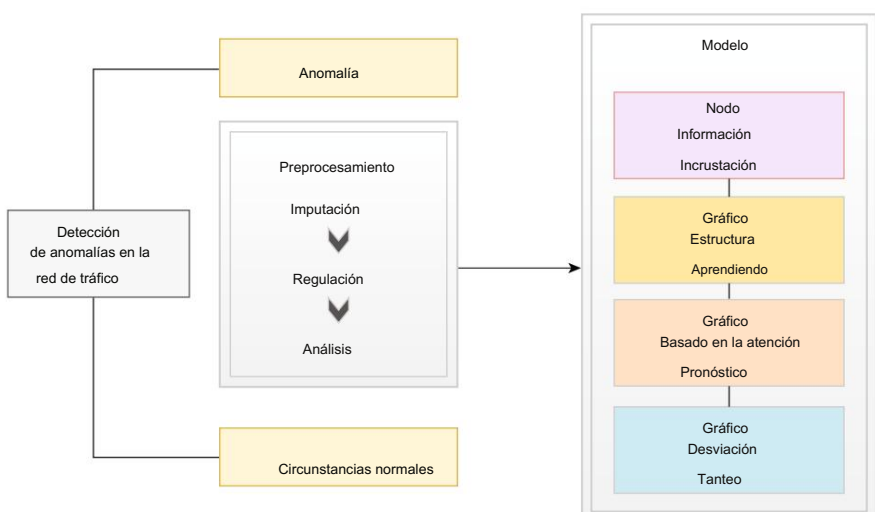


Figura 2: Proceso de detección de anomalías en la red de tráfico.

Al comparar el rendimiento de la variante 2 con el modelo propuesto, se destaca la importancia del módulo de incrustación de información de tráfico.

3.4. Aprendizaje de la estructura gráfica espacio-temporal del estado del tráfico. Una vez que obtengamos los vectores de incrustación de nodos, utilizaremos el VI para aprender la estructura del grafo.

Los datos que utilizamos son originalmente secuencias de series temporales y no tienen conexiones entre nodos. Sin embargo, queremos comprender si existe una relación entre los nodos, así como la magnitud de la influencia en el modelo de detección de anomalías en las redes viales. Por lo tanto, aprenderemos la relación implícita entre los sitios durante el proceso de entrenamiento mediante el diseño de un Marco estructural. Finalmente, obtendremos un grafo dirigido que representa las conexiones entre diferentes sitios a través del aprendizaje. En este grafo dirigido, los nodos representan los sitios donde recopilamos información, y las aristas representan las dependencias entre ellos. La conexión entre los dos sitios representa la información recopilada en un sitio que se utilizará para el entrenamiento en el segundo sitio. Representamos este grafo dirigido mediante la matriz de adyacencia M, donde Mij representa la existencia de aristas dirigidas del nodo i al nodo j, lo que significa que los dos sitios tienen una correlación espacial. Usamos Ri para representar el conjunto de nodos de relación candidatos de i.

$$Ri \quad fg\ 1, 2,: \quad , N \setminus fgi \qquad \text{ð2Þ}$$

Machine Translated by Google

6302, 2022, 1, Descargado de https://onlinelibrary.wiley.com/doi/10.1155/2022/4222827 por Cochrane Perú, Wiley Online Library el [02/05/2026]. Consulte los Términos y condiciones (https://onlinelibrary.wiley.com/terms-and-conditions) en Wiley Online Library para conocer las reglas de uso; los artículos de acceso abierto se rigen por la Licencia Creative Commons aplicable.

Para comprender las dependencias entre los sitios, calculamos la similitud entre el vector de incrustación del nodo i y el vector de incrustación de su nodo candidato j Ri :

$$\text{usado} \frac{\text{vi Tvj}}{\text{= vkki vj}} \text{ para j Ri ,} \quad \text{ð3Þ}$$

$$\text{Mji = j TopK eji : k Ri ÈÉ ÀÁ ÈÉ :} \quad \text{ð4Þ}$$

Primero calculamos el producto escalar normalizado con una capa normalizada entre el vector de incrustación del sensor i y la relación candidata j Ri . Luego, seleccionamos el índice de los k valores principales de la entrada (es decir, el producto escalar normalizado) y los elegimos como los K nodos más importantes relacionados con el nodo i. El usuario determina el valor de k según el grado de dispersión deseado. El proceso de cálculo del producto escalar y selección de los k nodos principales se repite en cada lote durante cada época. Finalmente, obtenemos la matriz de adyacencia M, que representa la relación implícita entre los nodos de la estación.

3.5. Predicción del estado del tráfico. Previamente, utilizamos el módulo Topk, y nuestro modelo puede aprender la estructura gráfica de la proximidad de los nodos de la carretera implícita en los datos calculando el producto escalar del vector de incrustación. Después de eso, obtenemos una topología de correlación general. Un nodo específico y las intersecciones de la carretera asociadas a él no tienen exactamente la misma situación en la red vial. La situación habitual es que cuando ocurre un accidente en una ubicación determinada, el impacto de ese punto se propagará a los nodos circundantes en diferentes grados.

Las GCN tradicionales suelen tener limitaciones significativas para este tipo de tareas. No pueden ajustar los pesos de los vecinos (no pueden especificar pesos diferentes para distintos nodos en un vecindario) en función de los atributos de las características de los nodos. Esto limita la capacidad del modelo para capturar la relevancia de la información espacial, lo que resulta en predicciones menos precisas en la práctica. Por lo tanto, utilizamos el mecanismo de atención de grafos calculando los nodos y utilizando los nodos críticos j Mji = fj Topkðfeji : k Ri gÞg que aprendimos con Topk para calcular la función de similitud πðj, iÞ.

$$\text{ðÞt gi ðÞt = vi Wxi ,} \quad \text{ð5Þ}$$

$$\text{πðÞ i, j = LeakyReLu aT gi} \frac{\text{ðÞt ðÞt gj}}{} \quad \text{ð6Þ}$$

Aquí, nuestra formulación difiere de la formulación estándar de GAT en el artículo. Para utilizar el vector de incrustación de una mejor manera, hemos elegido una ventana deslizante usando xi R que denota la característica de la entrada del nodo.

El control de ventana deslizante se utiliza para seleccionar un rango de tiempo de datos de tamaño fijo como entrada para predecir el resultado en el siguiente punto temporal. Aquí, el tiempo t se define como xi :

$$\text{xi}^{t} \text{ Yo t-ventana, yo t-ventana+1, ..., I}$$
$$\text{t−1 hi: ð7Þ}$$

RðiÞ = fjjMij >0g es la matriz de adyacencia Mij que representa la topología a través de lo que hemos aprendido, que es también el conjunto de nodos adyacentes al nodo i. W d×w denota la matriz de pesos de la capa de transformación lineal compartida por todos los nodos de nuestro modelo para la mejora de características de los nodos de entrada. vi dona el vector de incrustación del nodo i. representa una operación de unión en las características transformadas.

Por lo tanto, el gi puede combinar las características transformadas con el vector de incrustación que aprendimos, lo que puede mejorar la efectividad del mecanismo de atención. Para la función de activación final, elegimos la función LeakyReLU general como activación no lineal para calcular el coeficiente de atención.

Después de calcular el coeficiente de correlación, utilizamos softmax para normalizar el coeficiente de correlación y obtuvimos el coeficiente de atención ai,j .

$$\text{ai,j} = \frac{\text{exp ðÞ πðÞ i, j}}{\text{∑k Niðþ fgi expðÞ πðÞ i, j}} \quad \text{ð8Þ}$$

La función softmax convierte un vector de K valores reales en un vector de K valores reales cuya suma es igual a 1. Los K valores de entrada del vector pueden ser positivos, negativos, cero o mayores que 1, pero softmax los transforma en valores entre 0 y 1, de modo que los valores convertidos pueden interpretarse como probabilidades. Si uno de los valores de entrada es pequeño o negativo, softmax lo convierte en una probabilidad pequeña, y si es grande, lo convierte en una probabilidad grande, pero siempre dentro del rango de 0 a 1. Esta propiedad se cumple exactamente con las propiedades del cálculo de ponderación.

El algoritmo GAT obtiene una puntuación para cada nodo vecino calculando el grado de correlación entre ellos, pero esta puntuación puede variar considerablemente. La función softmax resulta útil en este caso, ya que convierte la puntuación de correlación calculada en una distribución de probabilidad normalizada. El resultado resultante se distribuye entre 0 y 1 según el valor de la puntuación, lo que puede considerarse como la importancia de cada nodo, es decir, sus valores de ponderación. Teniendo en cuenta lo anterior, optamos por utilizar la función softmax.

Finalmente, agregamos nuestros coeficientes de atención calculados para obtener nuevas características para la salida de cada nodo, que incorporan la información que hemos aprendido de los nodos vecinos. En este caso, la función de activación que elegimos usar es ReLU.

$$\text{salida = Re Lu} \quad \text{9Þ}$$
$$\text{j RiðÞ+1 ai,j Wxj !:}$$

3.6. Detección de anomalías de tráfico. Para que el modelo sea más preciso, buscamos comprender las anomalías de la relación y las razones de su existencia. Por lo tanto, calculamos las puntuaciones de anomalía para cada sitio y las combinamos para obtener una única puntuación de anomalía para cada intervalo de tiempo. Esto permite al usuario especificar qué sitios presentan anomalías. La puntuación de anomalía se calcula comparando el comportamiento esperado en el instante t con el comportamiento observado. El valor de error Err del sitio i en el instante t se puede expresar de la siguiente manera:

$$\text{ErrðÞt = si ðÞt − si ðÞt} \quad \text{ð10Þ}$$

Machine Translated by Google

6302, 2022, 1, Descargado de https://onlinelibrary.wiley.com/doi/10.1155/2022/4222827 por Cochrane Perú, Wiley Online Library el [02/05/2026]. Consulte los Términos y condiciones (https://onlinelibrary.wiley.com/terms-and-conditions) en Wiley Online Library para conocer las reglas de uso; los artículos de acceso abierto se rigen por la Licencia Creative Commons aplicable.

Dado que las distintas estaciones tienen características diferentes, sus valores de desviación pueden variar considerablemente en consecuencia. Normalizamos rigurosamente los valores de error para cada sitio con el fin de evitar que un sitio se vea excesivamente influenciado por otros sitios.

$$\text{error} = \frac{\text{Error} - \mu\tilde{}i}{\sigma\tilde{}i}, \quad \text{ð11Þ}$$

donde μ~i y σ~i son la mediana y el rango intercuartil (RIC) a través de los intervalos de tiempo de los valores de Erri ðtÞ , respectivamente. El rango intercuartílico (RIC) se define como la diferencia de dispersión entre los percentiles 75 y 25 de los datos. Optamos por la mediana y el RIC en lugar de la media y la desviación estándar. El RIC mejora la precisión de las estadísticas del conjunto de datos al eliminar los valores atípicos de baja contribución. De igual manera, la mediana reduce la influencia de los valores atípicos, lo que se traduce en una mayor robustez. El trabajo [21] demuestra que presentan una mayor robustez ante anomalías.

Utilizamos la función max para agregar los sitios y calcular la anomalía general en el momento t.

$$\text{Atð}\text{Þ} = \max_{i} \text{aiðÞt} : \quad \text{ð12Þ}$$

Para suprimir los cambios bruscos de valores, utilizamos una media móvil simple (SMA) [22] para generar una puntuación suavizada As(t). Si As(t) supera un umbral fijo, la marca de tiempo t se marcará como una excepción. En este caso, establecemos el umbral en el valor máximo de As(t) en los datos de validación.

4. Experimentos

4.1. Conjuntos de datos. Los registros de incidentes concluyen 13759 registros de congestión, 1139 registros de accidentes, 74 registros de construcción de carreteras y 3 registros de cierre de carriles. El conjunto de datos para este experimento proviene de Beijing y es una serie de datos recopilados en un entorno de tráfico natural. La Figura 3 muestra la distribución de las anomalías según el conjunto de datos. Antes de predecir anomalías en la red vial, tenemos dos requisitos para los datos de entrenamiento de entrada: (1) es necesario que esté claro qué estación describen los datos, y (2) los datos deben ser temporalmente coherentes. Necesitamos realizar una operación de preprocesamiento en los datos brutos para cumplir con estos requisitos. Las características con marca de tiempo de los datos originales se extraen y se agregan a las características de ID originales, de modo que incluso si los datos se interrumpen completamente, podemos asegurar que la secuencia de la serie temporal no se rompe.

4.2. Métricas de evaluación. Aquí utilizamos las tres métricas de tasa de detección, tasa de falsas alarmas y precisión para evaluar y comparar el modelo de referencia con nuestro modelo modificado.

$$\text{Tasa de detección} = \frac{\text{Ciudad}}{\text{TP} + \text{FN}}, \quad \text{ð13Þ}$$

$$\text{Tasa de falsas alarmas} = \frac{\text{FP}}{\text{FP} + \text{TN}}, \quad \text{14Þ}$$



Figura 3: Mapa de densidad de kernel de la distribución de anomalías de tráfico.

$$\text{Precisión} = \frac{\text{TP} + \text{TN}}{\text{Ciudad}} + \text{TN} + \text{FP} + \text{FN}: \quad \text{ð15Þ}$$

Las definiciones de FN, FP, TN y TP son las siguientes:

(1) FN (falso negativo): la muestra se considera negativa, pero en realidad es positiva.

(2) FP (falso positivo): la muestra se considera positiva, pero es negativa.

(3) TN (verdadero negativo): la muestra se considera negativa y, de hecho, también es una muestra negativa.

(4) TP (verdadero positivo): la muestra se considera positiva y, de hecho, lo es.

Con estas métricas, podemos estimar qué modelos ofrecen mejores resultados.

4.3. Métodos de comparación. Comparamos el modelo propuesto en este artículo con los métodos de vanguardia (SOTA) para la detección de anomalías, junto con algunos estudios previos sobre detección de anomalías que utilizan el modelo de referencia como comparación de los resultados. Los modelos y métodos incluyen los siguientes:

4.3.1. Modelo lineal

(1) OCSVM. La máquina de vectores de soporte de una clase [23] es diferente del modelo SVM tradicional. OCSVM es adecuada para problemas de clasificación donde solo hay un tipo de muestra o donde hay dos tipos de muestras, pero el número de muestras de un tipo es mucho menor que el número de muestras del otro tipo. El problema de detección de anomalías es típico de este último caso. Las muestras se pueden clasificar como normales o anormales. Además, el número de muestras normales es mucho mayor que el número de muestras anormales. Cuando intentamos hacer un juicio sobre una muestra, si las características

Machine Translated by Google

6302, 2022, 1, Descargado de https://onlinelibrary.wiley.com/doi/10.1155/2022/4222827 por Cochrane Perú, Wiley Online Library el [02/05/2026]. Consulte los Términos y condiciones (https://onlinelibrary.wiley.com/terms-and-conditions) en Wiley Online Library para conocer las reglas de uso; los artículos de acceso abierto se rigen por la Licencia Creative Commons aplicable.

Dado que los datos extraídos de esa muestra no coinciden con las características del caso normal incluido en el clasificador, podemos concluir que se trata de un caso anormal.

4.3.2. Basado en la proximidad

(1) LOF. La idea principal del método del factor de valores atípicos locales es asignar un grado de valor atípico a cada ejemplo de datos dentro de un cierto rango [24, 25]. El factor de valores atípicos es el promedio de la razón entre la densidad de alcanzabilidad local de un punto y la densidad de alcanzabilidad local de sus nodos vecinos. Si esta razón se acerca a 1, significa que las densidades entre los dos nodos son similares y pueden pertenecer conjuntamente a un clúster; si esta razón es mucho mayor que 1, significa que la densidad del nodo es mucho menor que la densidad de sus puntos vecinos. Es muy probable que el nodo sea una anomalía.

(2) HBOS. La detección de valores atípicos basada en histogramas asume la independencia de las características y puntúa los registros en tiempo lineal. Es menos precisa, pero tiene una velocidad de cálculo superior en comparación con los métodos multivariados [26]. Este método divide la muestra en múltiples intervalos según las características. La probabilidad de valores atípicos es mayor en intervalos con un tamaño de muestra pequeño.

4.3.3. Modelo probabilístico

(1) COPOD. El algoritmo de detección de valores atípicos basado en cópulas no solo no requiere calcular la distancia entre muestras, sino que tampoco requiere ajustar los parámetros. Presenta las ventajas de alta velocidad y bajo costo de ejecución [27]. El método COPOD calcula el grado de anomalía en cada dimensión y luego halla la anomalía promedio en todas las dimensiones. Este método evalúa las anomalías estimando la probabilidad de cola de cada punto.

(2) IFOREST. El algoritmo de bosque aislado es un algoritmo rápido de detección de anomalías basado en aprendizaje integrado, que utiliza un árbol binario para segmentar y procesar los datos. La profundidad de los puntos de datos en el árbol binario refleja la "escasez" de los datos [28]. Determinamos el grado de anomalía de los datos estimando la puntuación de anomalía. Cuanto menor sea la longitud promedio de la ruta de los datos en múltiples árboles, mayor será la probabilidad de que los datos sean anómalos.

(3) LSTM-VAE. LSTM-VAE [29, 30] reemplaza la red de alimentación directa en un VAE con LSTM para aprovechar las ventajas de LSTM y VAE. Puede medir el error de reconstrucción con la puntuación de anomalía.

(4) MAD-GAN. MAD-GAN [31] entrena un modelo GAN con un discriminador LSTM-RNN para calcular las puntuaciones de anomalía para cada nodo.

4.4. Configuración experimental. Nuestros modelos se construyen en un entorno Python con PyTorch versión 1.10.1 y PyTorch Geometric Library versión 2.0.3. También se implementan en una CPU Intel(R) Xeon(R) Gold 6278C a 2,60 GHz y tarjetas gráficas NVI-DIA Tesla T4.

4.5. Hiperparámetros. Usamos un optimizador Adam con una tasa de aprendizaje de 0.001 para lograr la optimización. El modelo se entrena hasta 100 épocas y usamos una técnica de parada temprana. Poblamos cada nodo como un vector de 32 dimensiones y usamos un valor k de tamaño 6 en el módulo Topk. El número de celdas ocultas se establece en 128, el tamaño del lote se establece en 32 y el tamaño de la ventana deslizante se establece en 48. Usamos el 80% de los datos como conjunto de datos de entrenamiento y el 20% restante se selecciona como conjunto de validación. Después de confirmar la selección de estos hiperparámetros cruciales, usamos el método de búsqueda en cuadrícula para realizar el proceso de búsqueda. El rango específico de variaciones de los hiperparámetros es el tamaño del lote, ventanas deslizantes, dimensión de incrustación y Topk.

La mejor combinación de parámetros se obtiene tras la búsqueda, como se muestra en la Tabla 4. El parámetro `embedding dim` representa que reflejamos las características de los nodos en un espacio de 32 dimensiones. Utilizamos la función de activación `LeakyReLU` para calcular los pesos. El número óptimo de vecinos seleccionados es 6.

4.6. Resultados. En la Tabla 5, mostramos el rendimiento de nuestro método GDN y los métodos de referencia en cuanto a tasa de detección, tasa de falsas alarmas y precisión en el conjunto de datos de Beijing. Los resultados muestran que el método GDN tiene un valor de 0,9749 y 0,9701 en tasa de detección y precisión, lo que es mejor que otros experimentos de referencia. El valor de la tasa de falsas alarmas es de 0,0251, que es significativamente menor que otros experimentos de referencia. Asimismo, comparamos los resultados con algunos métodos de vanguardia, incluidos LSTM-VAE y MAD-GAN. Podemos encontrar que nuestro modelo es equivalente en términos de precisión y tasa de detección y tiene un mejor rendimiento en FAR. Estos resultados muestran que nuestro método tiene un resultado de predicción superior.

4.7. Experimentos de ablación. Los experimentos de ablación se utilizan como análisis de sensibilidad para los módulos principales del modelo propuesto. Se implementan tres variantes eliminando gradualmente un módulo determinado del modelo propuesto:

(1) Variante 1. Esta variante se implementa eliminando el módulo Topk del modelo propuesto para investigar la importancia de las representaciones estructurales del grafo de tráfico aprendido. El módulo Topk ayuda al modelo propuesto a filtrar los nodos con puntuaciones altas de interconexiones y a determinar qué nodos pueden tener una relación. Después de eliminar el módulo Topk, todos los nodos del grafo están asociados, lo que significa un grafo estático completo. Los datos de la tabla muestran una disminución significativa en la precisión del modelo, lo que indica que las uniones selectivas en la estructura del grafo hacen que el modelo sea menos complejo y, por lo tanto, mejoran el rendimiento.

(2) Variante 2. Para examinar la efectividad del módulo de incrustación de información de tráfico, esta variante se implementa excluyendo el módulo de incrustación del modelo propuesto. El mecanismo de incrustación ayuda al modelo propuesto a encontrar vecinos cercanos en el espacio y reduce la cantidad de datos necesarios.

Machine Translated by Google

6302, 2022, 1, Descargado de https://onlinelibrary.wiley.com/doi/10.1155/2022/4222827 por Cochrane Perú, Wiley Online Library el [02/05/2026]. Consulte los Términos y condiciones (https://onlinelibrary.wiley.com/terms-and-conditions) en Wiley Online Library para conocer las reglas de uso; los artículos de acceso abierto se rigen por la Licencia Creative Commons aplicable.

Tabla 4: Combinación óptima de hiperparámetros.

Variable	Valor
Tasa de aprendizaje	0,001
Tamaño del lote	32
Épocas	100
Optimizador	Administración
Función de activación	LeakyReLu
Incrustar dim	32
Topk	6
Ventanas corredizas	48

Tabla 5: Resultados de la detección de anomalías comparados con la línea de base. modelos.

Método	Exactitud	Detección tasa	Falsa alarma tasa
LOF	0,80	0,89	0,09
IFOREST	0,83	0,80	0,08
OCSVM	0,82	0,84	0,08
HBOS	0,87	0,31	0,03
COPOD	0,82	0,82	0,08
LSTM-VAE	0,97	0,97	0,03
MAD-GAN	0,91	0,35	0,16
GDN (el seleccionado) modelo)	0,97	0,97	0,02

Tabla 6: Resultados de los experimentos de ablación.

Modelo	Tasa de detección	Tasa de falsas alarmas	Exactitud
GDN	97,49%	2,51%	97,01%
Variante 1	99,96%	49,97%	50,46%
Variante 2	89,25%	39,14%	61,13%
Variante 3	81,80%	18,36%	81,63%

para entrenamiento. Después de eliminar la capa de incrustación y sustituido por g(t) = Wxi , la tasa de detección y la precisión empeora. Esto indica que La presencia de la capa de incrustación ayuda a aprender el relación entre nodos en el grafo atención mecanismo

(3) Variante 3. Para explorar la importancia del módulo de atención, esta variante se implementa eliminando el mecanismo de atención del propuesto. modelo. El mecanismo de atención ayuda al propuesto modelo para mostrar la cercanía de las relaciones entre los nodos y cómo se afectan entre sí. Cuando Establecemos el peso de todos los nodos en 1 (todos los nodos tienen igual peso), el nuevo modelo no funciona tan bien como el modelo original. El resultado muestra que es crucial utilizar el mecanismo de atención para asignar pesos. según la cercanía o el alejamiento de la nodos

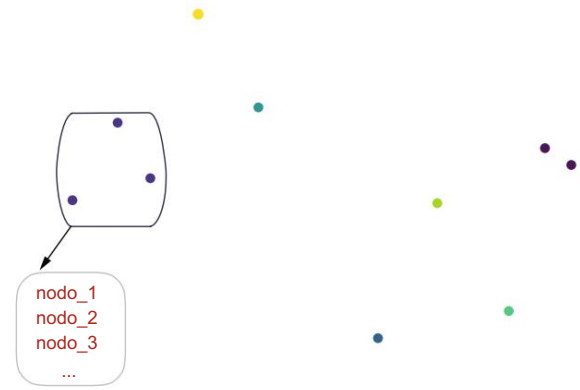


Figura 4: Un gráfico del vector de incrustación de nodos codificado por el modelo. Los diferentes colores denotan cada clase. Utilizamos el t-SNE y Se utiliza DBSCAN para lograr la reducción de dimensionalidad y la agrupación.

Todas las variantes del modelo propuesto se prueban en Pekín. Conjunto de datos para investigar la arquitectura óptima del modelo propuesto. Los resultados se muestran en la Tabla 6.

El modelo que utilizamos se obtiene fusionando varios módulos. Para verificar qué contribución aporta cada módulo hace al modelo propuesto, adaptamos dinámicamente el método que queremos confirmar mientras mantenemos el otro métodos sin cambios. Los detalles de los cambios en el Los resultados nos dan una idea del papel que desempeña el método. La Tabla 4 muestra los resultados obtenidos por los experimentos de ablación. El rendimiento de las variantes en todas las métricas puede se discutirá en comparación con el modelo propuesto. Para variante 1, la precisión disminuye en un 47,98% mientras que la La tasa de falsas alarmas aumenta al 49,97%. Aunque la La tasa de detección mejora, tanto la tasa de falsas alarmas como La precisión se ve reducida a un costo. Al comparar la rendimiento de la variante 1 con el modelo propuesto, nosotros verificar la necesidad de aprender la estructura del grafo de tráfico representaciones. Para la variante 2, la precisión disminuye en un 36,99%. La tasa de detección disminuye en un 8,45%, mientras que La tasa de falsas alarmas aumenta al 39,14%. Al comparar el rendimiento de la variante 2 con el modelo propuesto, Se destaca la importancia del módulo de incrustación de información de tráfico. Para la variante 3, la precisión disminuye. en un 15,85%. La tasa de detección disminuye en un 16,09%. mientras que la tasa de falsas alarmas aumenta al 18,36%. Al comparar el rendimiento de la variante 3 con la propuesta modelo, la efectividad de la integración de la atención Se muestra el módulo. En conjunto, el módulo Topk, la capa de incrustación y el mecanismo de atención. Todos hacen contribuciones únicas a nuestro modelo. Son fusionados para ayudar a nuestro modelo a lograr mejores resultados.

4.8. Interpretabilidad del modelo

4.8.1. Capa de incrustación. En nuestro modelo modificado para anomalías detección de problemas en redes viales, utilizamos un modelo de incrustación capa vectorial para codificar todas las estaciones heterogéneas a mapear el vector de incrustación en un espacio 2D, utilizando la distancia métrica para representar la relación entre diferentes estaciones. Aquí, utilizamos t-SNE para reducir la dimensión y

Machine Translated by Google

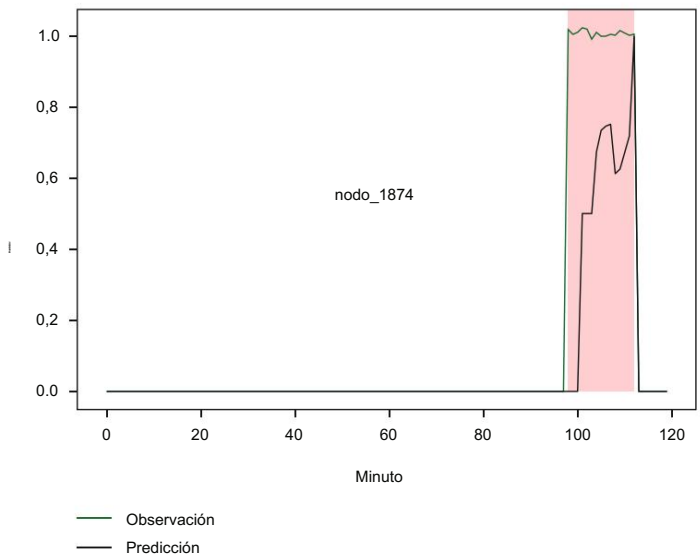


Figura 5: Explique la anomalía comparando los datos esperados con los observados.

Utilizamos DBSCAN para agrupar todos los nodos. Visualizamos los vectores en la Figura 4. Calculamos la similitud de las ubicaciones geográficas mediante la distancia euclidiana para agrupar sitios geográficamente similares. Los nodos con un vector de incrustación similar se agruparán juntos. Los nodos de la misma clase de clústeres pueden estar en intersecciones de carreteras conectadas o tener condiciones de flujo de tráfico similares en la red vial.

4.8.2. Mecanismo de atención para la asociación entre nodos. El modelo que transformamos se basa en la estructura del grafo. Nuestro modelo aprende una estructura de red latente y representa el grafo dirigido. La magnitud de la interacción entre nodos asociados no es la misma. Con los diferentes pesos en el mecanismo de atención, podemos obtener una imagen más clara del grado de influencia de los nodos circundantes al asignar diferentes grados de correlación a los nodos adyacentes en función de la estructura del grafo obtenida mediante el aprendizaje Topk.

La figura 5 muestra la situación de predicción. Cuando se detecta una anomalía en la ubicación objetivo, el peso de la atención puede interpretarse como una distribución de la influencia de difusión del nodo en el área circundante. Mediante esta distribución, podemos comprender la ubicación crítica de la carretera. Cuando se produce una anomalía real, podemos implementar diferentes medidas de protección según esta distribución.

5. Conclusión

En este artículo, proponemos un método automático de detección de anomalías en el tráfico. Podemos determinar si las estaciones están interrelacionadas y la intensidad de dicha relación mediante la integración de los datos recopilados en un grafo y el aprendizaje a partir de su estructura. Con base en esto, predecimos las anomalías en las carreteras y ajustamos el modelo mediante puntuaciones de desviación. Los experimentos realizados con conjuntos de datos reales demuestran que el modelo GDN para predecir eventos anómalos de tráfico supera al modelo de referencia. Nuestro modelo es interpretable, lo que facilita la comprensión por parte del usuario y la investigación en profundidad.

Sin embargo, aún existen algunas limitaciones en la aplicación de nuestro modelo, como lo demuestra lo siguiente: (1) Debido a la estructura de red gráfica, tiene la desventaja de ser computacionalmente intensivo. El largo tiempo de entrenamiento del modelo dificulta su aplicación en escenarios ligeros o en tiempo real. (2) Nuestro modelo modela secuencias temporales multivariadas y utiliza las relaciones entre las posibles estructuras gráficas entre los nodos de aprendizaje para realizar predicciones. Ignoramos la influencia de la estructura en las carreteras de la red vial en condiciones reales, es decir, la influencia del conocimiento previo conocido, como la topología de la carretera y el clima, en el modelo. Sin embargo, esta influencia podría tener un gran impacto en la mejora del modelo.

Para estudios futuros, el método propuesto puede desarrollarse aún más desde las siguientes perspectivas: (1) modelar la heterogeneidad de la topología de la red vial. El modelo actual considera la heterogeneidad de las series temporales de tráfico multivariadas al aprender relaciones ocultas entre diferentes series temporales como un grafo. La topología de la red vial contiene abundante información auxiliar, como la clase de carretera y la geometría.

La integración del regularizador de heterogeneidad de la topología de la red vial en el modelo actual puede ayudar a mejorar el rendimiento de la detección de anomalías de tráfico. (2) Pronosticar simultáneamente el estado del tráfico y las anomalías. El modelo propuesto se entrena tomando la detección de anomalías como objetivo de optimización. El entrenamiento colaborativo para los módulos de predicción del estado del tráfico y detección de anomalías puede ampliar las aplicaciones del modelo en sistemas de transporte inteligentes.

(3) Teniendo en cuenta que estamos utilizando un método de entrenamiento de aprendizaje no supervisado, podemos cambiar la arquitectura del modelo o diseñar algunos métodos de entrenamiento en línea para lograr un mejor rendimiento.

Disponibilidad de datos

Los datos utilizados para respaldar las conclusiones de este estudio se incluyen en el artículo.

6302, 2022, 1, Descargado de https://onlinelibrary.wiley.com/doi/10.1155/2022/4222827 por Cochrane Peru, Wiley Online Library el [02/05/2026]. Consulte los Términos y condiciones (https://onlinelibrary.wiley.com/terms-and-conditions) en Wiley Online Library para conocer las reglas de uso; los artículos de acceso abierto se rigen por la Licencia Creative Commons aplicable.

Machine Translated by Google

Conflictos de intereses

Los autores declaran no tener ningún conflicto de intereses.

Referencias

[1] M. Gori, G. Monfardini y F. Scarselli, "Un nuevo modelo para el aprendizaje en dominios de grafos", en 2005 IEEE international joint conference on neural networks, vol. 2no. 2005, pp. 729–734, Montreal, QC, Canadá, 2005.

[2] J. Bruna, W. Zaremba, A. Szlam y Y. LeCun, "Redes espectrales y redes conectadas localmente en grafos", 2013, https://arxiv.org/abs/1312.6203.

[3] BS Chen, SC Peng y KC Wang, "Modelado, predicción y control de congestión del tráfico para redes de alta velocidad: un enfoque AR difuso", IEEE Transactions on Fuzzy Systems, vol. 8, no. 5, pp. 491–508, 2000.

[4] RP Haining, "El modelo de promedio móvil para la interacción espacial", Transactions of the Institute of British Geographers, vol. 3, no. 2, pp. 202–225, 1978.

[5] GP Zhang, "Pronóstico de series temporales utilizando un modelo híbrido ARIMA y de red neuronal", Neurocomputing, vol. 50, pp. 159–175, 2003.

[6] BM Williams y LA Hoel, "Modelado y pronóstico del flujo de tráfico vehicular como un proceso ARIMA estacional: base teórica y resultados empíricos", Journal of Transportation Engineering, vol. 129, n.° 6, págs. 664–672, 2003.

[7] B. Ghosh, B. Basu y M. O'Mahony, "Modelado de series temporales para la previsión del flujo de tráfico vehicular en Dublín", en 84.ª Reunión Anual de la Junta de Investigación del Transporte, Washington, DC, 2005.

[8] P. Cai, Y. Wang, G. Lu, P. Chen, C. Ding y J. Sun, "Un modelo espaciotemporal correlativo de k vecinos más cercanos para la predicción de múltiples pasos del tráfico a corto plazo", Transportation Research Part C: Emerging Technologies, vol. 62, pp. 21–34, 2016.

[9] B. Lim y S. Zohren, "Pronóstico de series temporales con aprendizaje profundo: una revisión", Philosophical Transactions of the Royal Society A, vol. 379, n.º 2194, pág. 20200209, 2021.

[10] Z. Cui, K. Henrickson, R. Ke y Y. Wang, "Red neuronal recurrente convolucional de grafos de tráfico: un marco de aprendizaje profundo para el aprendizaje y la predicción del tráfico a escala de red", IEEE Transactions on Intelligent Transportation Systems, vol. 21, n.º 11, págs. 4883–4894, 2019.

[11] A. Geiger, D. Liu, S. Alnegheimish, A. Cuesta-Infante y K. Veeramachaneni, "Tad GAN: detección de anomalías de series temporales utilizando redes generativas adversarias", en Conferencia internacional IEEE sobre Big Data (Big Data) de 2020, págs. 33–43, Atlanta, GA, EE. UU., 2020.

[12] F. Carrera, V. Dentamaro, S. Galantucci, A. Iannacone, D. Impedovo y G. Pirlo, "Combinación de enfoques no supervisados para la detección de anomalías en el tráfico de red casi en tiempo real", Applied Sciences, vol. 12, n.º 3, pág. 1759, 2022.

[13] X. Zhu, Detección de anomalías mediante aprendizaje automático basado en estadísticas para redes informáticas, Universidad de Arizona, 2006.

[14] M.-L. Shyu, S.-C. Chen, K. Sarinnapakorn y L. Chang, Un nuevo esquema de detección de anomalías basado en un clasificador de componentes principales, Informe técnico, Universidad de Miami, Coral Gables, Florida, Departamento de Ingeniería Eléctrica e Informática, 2003.

[15] M. Çelik, F. Dadaşer-Çelik y A. Ş. Dokuz, "Detección de anomalías en datos de temperatura mediante el algoritmo DBSCAN", en Simposio internacional de 2011 sobre innovaciones en sistemas y aplicaciones inteligentes, págs. 91–95, Estambul, Turquía, 2011.

[16] MY Su, "Sistemas de detección de anomalías en tiempo real para ataques de denegación de servicio mediante clasificadores de k vecinos más cercanos ponderados", Expert Systems with Applications, vol. 38, n.º 4, págs. 3492–3498, 2011.

[17] T. Wang, W. Zhang, J. Wei y H. Zhong, "Detección de anomalías en línea con conciencia de la carga de trabajo en aplicaciones empresariales con factor de valores atípicos locales", en 2012 IEEE 36th Annual Comp-computer Software and Applications Conference, pp. 25–34, Izmir, Turquía, 2012.

[18] Z. Ding y M. Fei, "Un enfoque de detección de anomalías basado en el algoritmo de bosque de aislamiento para datos en tiempo real mediante ventana deslizante", IFAC Proceedings Volumes, vol. 46, n.º 20, págs. 12–17, 2013.

[19] Q. Wang, W. Lv y B. Du, "Detección de anomalías espaciotemporales en datos de tráfico", en Actas del 2.º Simposio Internacional sobre Ciencias de la Computación y Control Inteligente, págs. 1–5, Estocolmo, Suecia, 2018.

[20] B. Yu, H. Yin y Z. Zhu, "Redes convolucionales gráficas espaciotemporales: un marco de aprendizaje profundo para la previsión del tráfico", 2017, https://arxiv.org/abs/1709.04875.

[21] C. Park y BR Cho, "Desarrollo de un diseño robusto bajo datos contaminados y no normales", Quality Engineering, vol. 15, no. 3, pp. 463–469, 2003.

[22] K. Hundman, V. Constantinou, C. Laporte, I. Colwell y T. Soderstrom, "Detección de anomalías en naves espaciales mediante LSTM y umbralización dinámica no paramétrica", en Actas de la 24.ª conferencia internacional ACM SIGKDD sobre descubrimiento de conocimiento y minería de datos, págs. 387–395, Londres, Reino Unido, 2018.

[23] S. Omar, A. Ngadi y HH Jebur, "Técnicas de aprendizaje automático para la detección de anomalías: una visión general", International Journal of Computer Applications, vol. 79, n.º 2, págs. 33–41, 2013.

[24] S. Agrawal y J. Agrawal, "Revisión sobre la detección de anomalías mediante técnicas de minería de datos", Procedia Computer Science, vol. 60, pp. 708–713, 2015.

[25] Y. Yan, L. Cao y EA Rundensteiner, "Detección escalable de valores atípicos locales Top-N", en Actas de la 23.ª conferencia internacional ACM SIGKDD sobre descubrimiento de conocimiento y minería de datos, Halifax, NS, Canadá, 2017.

[26] M. Goldstein y A. Dengel, "Puntuación de valores atípicos basada en histogramas (HBOS): un algoritmo rápido de detección de anomalías no supervisado", KI-2012: sección de pósteres y demostraciones, vol. 9, 2012.

[27] Z. Li, Y. Zhao, N. Botta, C. Ionescu y X. Hu, "COPOD: detección de valores atípicos basada en cópulas", en 2020 IEEE international conference on data mining (ICDM), pp. 1118–1123, Sorrento, Italia, 2020.

[28] X. Zhao, Y. Wu, DL Lee y W. Cui, "iForest: interpretación de bosques aleatorios mediante análisis visual", IEEE Transactions on Visualization and Computer Graphics, vol. 25, n.º 1, págs. 407–416, 2019.

[29] D. Park, Y. Hoshi y CC Kemp, "Un detector de anomalías multimodal para la alimentación asistida por robot utilizando un autoencoder variacional basado en LSTM", IEEE Robotics and Automation Letters, vol. 3, n.º 3, págs. 1544–1551, 2018.

[30] S. Lin, R. Clark, R. Birke, S. Schönborn, N. Trigoni y S. Roberts, "Detección de anomalías para series temporales usando VAE-

6302, 2022, 1, Descargado de https://onlinelibrary.wiley.com/doi/10.1155/2022/4222827 por Cochrane Peru, Wiley Online Library el [02/05/2026]. Consulte los Términos y condiciones (https://onlinelibrary.wiley.com/terms-and-conditions) en Wiley Online Library para conocer las reglas de uso; los artículos de acceso abierto se rigen por la Licencia Creative Commons aplicable.

Machine Translated by Google

Modelo híbrido LSTM", en ICASSP 2020 - Conferencia Internacional IEEE de Acústica, Habla y Procesamiento de Señales 2020 (ICASSP), págs. 4322–4326, Barcelona, España, 2020.

[31] D. Li, D. Chen, B. Jin, L. Shi, J. Goh y SK Ng, "MAD-GAN: detección de anomalías multivariadas para datos de series temporales con redes generativas antagónicas", en Conferencia Internacional sobre redes neuronales artificiales, págs. 703–716, Cham, 2019.

6302, 2022, 1, Descargado de https://onlinelibrary.wiley.com/doi/10.1155/2022/4223827 por Cochrane Perú, Wiley Online Library el [02/05/2026]. Consulte los Términos y condiciones (https://onlinelibrary.wiley.com/terms-and-conditions) en Wiley Online Library para conocer las reglas de uso; los artículos de acceso abierto se rigen por la Licencia Creative Commons aplicable.