Machine Translated by Google

KICS The Korean Institute of Communications and Information Sciences

Disponible en línea en www.sciencedirect.com

Ciencia Directa

ICT Express 8 (2022) 379–387

www.elsevier.com/locate/icte

Detección y localización de accidentes de tráfico mediante aprendizaje profundo a partir de vídeos de vigilancia del tráfico.

Karishma Pawar1, , Vahida Attar1

Departamento de Ingeniería Informática y Tecnologías de la Información, Facultad de Ingeniería de Pune, Pune, India

Recibido el 13 de junio de 2021; recibido en forma revisada el 8 de septiembre de 2021; aceptado el 7 de noviembre de 2021.
Disponible en línea a partir del 15 de noviembre de 2021.

Abstracto

Los vídeos de vigilancia del tráfico en situaciones reales necesitan una supervisión continua para monitorizar el estado del tráfico y tomar las medidas adecuadas en caso de accidentes mortales. Sin embargo, la supervisión humana continua de estos accidentes es propensa a errores y tediosa. Por lo tanto, se ha propuesto un enfoque de aprendizaje profundo para la detección y localización automática de accidentes de tráfico, formulando el problema como detección de anomalías. El método sigue un enfoque de clasificación de una sola clase y aplica un autoencoder espacio-temporal y un autoencoder de memoria a corto y largo plazo secuencia a secuencia para modelar las representaciones espaciales y temporales en el vídeo. El modelo se ejecuta en conjuntos de datos reales de videovigilancia de tráfico y se han obtenido resultados significativos tanto cualitativa como cuantitativamente. © 2021 Publicado por Elsevier BV en nombre del Instituto Coreano de Ciencias de la Comunicación e Información. Este es un artículo de acceso abierto bajo la licencia CC BY-NC-ND (http://creativecommons.org/licenses/by-nc-nd/4.0/).

Palabras clave: Detección de accidentes; Aprendizaje profundo; Clasificación de una sola clase; Videovigilancia

1. Introducción

La proliferación de la Inteligencia Artificial y el uso ubicuo de dispositivos del Internet de las Cosas han dado como resultado proyectos de ciudades inteligentes para mejorar la calidad de vida [1,2].
El transporte sostenible es una de las dimensiones cruciales en las ciudades inteligentes que busca desarrollar (1) un sistema de transporte inteligente para el sector público basado en datos en tiempo real, (2) plataformas de gestión de tráfico para evitar congestiones y (3) aplicaciones de seguridad y control de tráfico proactivo. El aumento en el número de vehículos en la carretera supone una gran carga para el personal y las autoridades de gestión del tráfico vial para manejar desafíos como los accidentes de tránsito, por lo que se requiere una vigilancia rápida para mitigar las posibilidades de pérdida de vidas y propiedades. Por lo tanto, para detectar y evitar percances como accidentes, las ciudades implementan cámaras de videovigilancia CCTV para fines de monitoreo de tráfico. La revisión manual de los videos de vigilancia en tiempo real para monitorear el tráfico e identificar la ocurrencia de cualquier incidente no deseado por La intervención humana no es una solución viable. Además, las cámaras de videovigilancia transmiten continuamente vídeos, y la vigilancia manual, propensa a errores, puede hacer que se pasen por alto algunas actividades inusuales. Por ello, es necesario desarrollar un modelo automatizado para detectar incidentes inusuales, como accidentes, que permitan un transporte sostenible y una gestión eficaz del tráfico.

Como panacea, las técnicas basadas en visión artificial se han utilizado popularmente para la vigilancia y gestión inteligente del tráfico. El flujo general de las técnicas basadas en visión artificial es el siguiente: (1) Segmentación de vehículos del fondo y otras entidades de la carretera en escenas de vídeo tanto estáticas como en movimiento; (2) Clasificación de todas las categorías de vehículos como autobuses, furgonetas, coches, etc.; (3) Extracción de características espaciotemporales para diferentes operaciones relacionadas con el tráfico, como el conteo de vehículos, el seguimiento de vehículos, el seguimiento de trayectorias y la detección de eventos anómalos como accidentes. Además, estos sistemas basados en visión artificial deben operar bajo condiciones variables de iluminación y tráfico. Motivados por esto, se ha propuesto un enfoque de aprendizaje profundo para la detección y localización de accidentes de tráfico. Específicamente, consideramos la ocurrencia de un accidente de tráfico como un caso especial de actividad inusual, es decir, una anomalía. Detectar y localizar los accidentes de tráfico ayudaría a reducir el tiempo de respuesta de los equipos de rescate y a mejorar la seguridad en los desplazamientos.

Las contribuciones del artículo se exponen a continuación.

Autor correspondiente.
Direcciones de correo electrónico: kvppawar@gmail.com (K. Pawar), vahida.comp@coep.ac.in (V. Attar).

[1] Todos los autores aprobaron la versión del manuscrito que se publicará.
Revisión por pares bajo la responsabilidad del Instituto Coreano de Ciencias de la Comunicación e Información (KICS).

https://doi.org/10.1016/j.icte.2021.11.004 2405-9595/
© 2021 Publicado por Elsevier BV en nombre del Instituto Coreano de Ciencias de la Comunicación e Información. Este es un artículo de acceso abierto bajo la licencia CC BY-NC-ND (http://creativecommons.org/licenses/by-nc-nd/4.0/).

Machine Translated by Google

• Este artículo aborda la detección y localización de accidentes de tráfico como un caso especial de detección de anomalías mediante un enfoque de aprendizaje profundo basado en un autoencoder espacio-temporal y un autoencoder de memoria a corto y largo plazo (LSTM) de secuencia a secuencia. • Para abordar la escasez de datos anómalos etiquetados, el modelo debe entrenarse únicamente con eventos normales y, posteriormente, detectar anomalías como datos fuera de la distribución siguiendo un paradigma de clasificación de una sola clase.

La investigación propuesta en este artículo aborda la detección de accidentes mediante un enfoque de detección de actividades inusuales basado en aprendizaje profundo y un paradigma de clasificación de una sola clase. Hasta donde sabemos, somos los primeros en aplicar la variante de LSTM, concretamente LSTM secuencia a secuencia, para la detección de anomalías mediante una ventana deslizante, lo que justifica su novedad.

El modelo propuesto aplica un autoencoder convolucional y una red LSTM con capacidad de aprendizaje secuencia a secuencia de forma en cascada. La clave del enfoque propuesto reside en que aprende de forma no supervisada, eliminando la necesidad de generar datos etiquetados de accidentes de tráfico anómalos.

El contenido del artículo se describe a continuación.

La Sección 2 analiza los enfoques para la detección de accidentes de tráfico. La Sección 3 describe cómo se ha formulado esta tarea como un problema de detección de anomalías y la metodología detallada. La Sección 4 detalla la experimentación, los conjuntos de datos y las métricas de rendimiento utilizadas para evaluar el modelo propuesto, junto con los resultados cuantitativos y cualitativos y el análisis comparativo correspondiente. La Sección 5 presenta las conclusiones y sugerencias para ampliar la presente investigación.

2. Trabajos relacionados

Se han realizado numerosas investigaciones en el ámbito de la videovigilancia aplicada a la detección de accidentes de tráfico. En [3] se aborda en detalle la detección de anomalías en accidentes de tráfico , ofreciendo pautas para resolver problemas en los Sistemas de Transporte Inteligentes. En general, la detección de accidentes mediante videovigilancia de tráfico se ha formulado en términos de técnicas basadas en patrones de flujo vehicular, seguimiento e interacción de vehículos, correlación espacio-temporal, detección de objetos y detección de actividades inusuales, como se muestra en la Figura 1.

La primera categoría de enfoque se basa en patrones de flujo de tráfico que generalmente modelan los patrones de tráfico normales, como giros a la izquierda válidos, giros a la derecha o ir en línea recta. La desviación de los patrones normales se considera un evento de tráfico anómalo [4,5].

La segunda categoría de enfoque se centra en la detección y extracción de características de vehículos en movimiento, como la distancia entre vehículos, la aceleración, la dirección y el seguimiento [6]. Hui et al. [6] utilizaron un modelo de mezcla gaussiana para la detección de vehículos y un algoritmo de desplazamiento medio para el seguimiento de vehículos. La tercera categoría de enfoque sigue conceptos sociológicos y modela la interacción entre los vehículos para la detección de accidentes.

Sultani y Choi [7] propusieron un modelo inteligente en el que

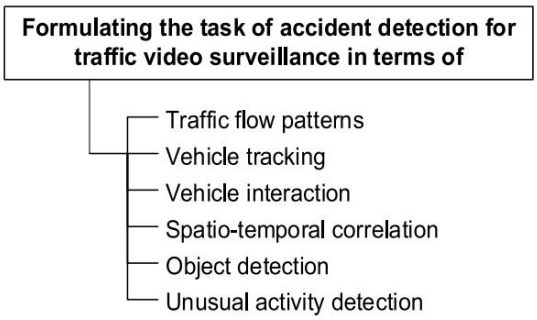


Figura 1. Técnicas para formular la tarea de detección de accidentes para la videovigilancia del tráfico.

La interacción entre los coches se considera un punto de referencia para la detección de anomalías. El tráfico se modela mediante la asignación latente de Dirichlet (LDA). Para la localización, se calculan gradientes espaciales del comportamiento para construir un campo de Lyapunov de tiempo finito y se utiliza el algoritmo de cuencas hidrográficas para localizar las anomalías. Debido a la gran disponibilidad de datos y procesadores de computación a menor coste, la tecnología de aprendizaje profundo ha resurgido y ha demostrado su notable utilidad en muchos dominios como la detección de objetos [8,9], la clasificación de imágenes [10], la detección de anomalías [11], el modelado de temas [12], el aprendizaje de representaciones [13], la segmentación semántica [14], el seguimiento visual [15], etc., y por lo tanto, las técnicas de aprendizaje profundo también se han utilizado para la detección de accidentes.

Ren et al. [16] estudiaron el efecto de la correlación espacio-temporal en los datos de accidentes de tráfico y desarrollaron un modelo basado en redes neuronales recurrentes para la predicción del riesgo de accidentes que puede actuar como un sistema proactivo para alertar sobre los accidentes de tráfico. Para una mayor precisión, también se pueden incorporar más características como las características de la carretera y el flujo de tráfico. Bortnikov et al. [17] implementaron un modelo de detección de accidentes basado en redes neuronales convolucionales (CNN) 3D que aborda diferentes condiciones climáticas y de iluminación. Utilizaron un videojuego para generar tráfico de vídeo y entrenar el modelo. Durante las pruebas, aplicaron dos funciones de pérdida con y sin patrones de flujo óptico para mitigar el efecto de las condiciones de iluminación y las escenas de fondo. El modelo se evaluó en vídeos de tráfico del mundo real.

Tian et al. [18] propusieron un modelo de aprendizaje profundo para accidentes automovilísticos basado en el algoritmo de detección de objetos — You Only Look Once (YOLO) y utilizaron otra información obtenida del sistema de infraestructura del vehículo como la ubicación del accidente, el tipo de accidente y las condiciones de iluminación. Este modelo aprovecha la técnica de fusión de características multiescala y la función de pérdida con pesos dinámicos para una detección precisa y en tiempo real. El enfoque propuesto por Yao et al. [19] sigue técnicas basadas tanto en el seguimiento de objetos como en la actividad inusual. Aplicaron un enfoque de aprendizaje no supervisado para videos de la era de las cámaras montadas en el tablero. En este, se entrena un modelo con eventos normales de objetos y movimientos propios. Durante las pruebas, los patrones que se desvían del modelo normal se consideran anomalías.

Específicamente, su modelo predice la ubicación de los objetos en el

Machine Translated by Google

El proceso procesa el fotograma en curso basándose en los fotogramas anteriores y luego aplica un algoritmo de detección de anomalías.

Además de esto, también existen enfoques de aprendizaje profundo que abordan la vigilancia visual para el tráfico rodado y el monitoreo de la superficie de la carretera [20,21]. Ohgushi et al. [20] propusieron abordar la tarea de detección de obstáculos en la carretera utilizando un autoencoder con segmentación semántica. Específicamente, el autoencoder consta de un generador de imágenes semánticas como parte de codificación y un generador de imágenes fotográficas como decodificador. Su enfoque funciona de manera no supervisada, de modo que el modelo se entrena solo en escenas de carretera normales. Varona et al. [21] propusieron utilizar modelos de aprendizaje profundo basados en redes neuronales convolucionales, redes LSTM y modelos de computación de reservorio para la detección de baches y la clasificación de la superficie de la carretera.

3. Metodología propuesta

3.1. Formulación del problema

Formulamos la tarea de detección de accidentes de tráfico como un problema de detección de anomalías. Los patrones anómalos se desvían de los patrones normales y ocurren durante cortos periodos de tiempo. Sin embargo, debido a la escasez de datos etiquetados para actividades anómalas, un modelo se entrena solo con eventos normales y luego se prueba con datos anómalos; es decir, un modelo aprende patrones de datos normales y los patrones que no se ajustan a la normalidad se consideran anómalos. Este paradigma se denomina clasificación de una clase y se muestra en la Figura 2. El aprendizaje de los patrones normales da como resultado la formación de una hiperesfera y los puntos que se encuentran fuera de dicha hiperesfera son anómalos.
Generalmente, en los problemas de clasificación de una sola clase, se supone que los datos normales son una clase negativa y los datos anómalos una clase positiva [22].

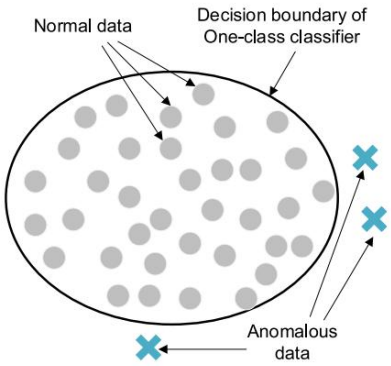


Figura 2. Clasificación de una sola clase.

3.2. Metodología propuesta para la detección y localización de anomalías

Los autoencoders son muy útiles para la representación eficiente de vídeos. Por lo tanto, nuestro trabajo anterior [13] se centró en el análisis riguroso de autoencoders y, en consecuencia, se han utilizado autoencoders convolucionales y autoencoders LSTM con capacidad de aprendizaje secuencia a secuencia para la tarea de aprendizaje de características espaciotemporales en esta investigación. La figura 3 muestra el funcionamiento del modelo propuesto para la detección de anomalías en vídeos de vigilancia de tráfico. Los detalles del autoencoder convolucional y del autoencoder LSTM con capacidad de aprendizaje secuencia a secuencia se muestran en las figuras 4 y 5, respectivamente.
Las figuras 4(a) y 5(a) muestran los detalles de cada capa y las funciones de activación utilizadas en la parte del codificador del autoencoder convolucional y del autoencoder LSTM con capacidad de aprendizaje secuencia a secuencia, respectivamente. De manera similar, las figuras 4(b) y 5(b) muestran los detalles de la parte del decodificador.

Una secuencia de fotogramas de vídeo { f0, f1, . . . , fn} forma un videoclip denotado por f0...n. Se utiliza un codificador convolucional, CAE (.), para obtener la representación codificada de cada fotograma en el videoclip para el aprendizaje espacial. CAE (.) utiliza la distancia L2 para minimizar el error entre el fotograma real y el reconstruido. fotograma. La representación latente de cada fotograma de vídeo de salida del CAE (.) se apila en una ventana de tamaño m aplicando la técnica de ventana deslizante. Esta pila de representaciones latentes se introduce en el autoencoder LSTM con capacidad de aprendizaje secuencia a secuencia, es decir, SLAE (.), para aprender los patrones temporales. Para seguir la clasificación de una clase, ajustamos los fotogramas normales (datos de entrenamiento) a una distribución gaussiana. Para lograr esto, se aplica una capa de función de base radial antes de la capa de cuello de botella en el codificador LSTM con aprendizaje secuencia a secuencia SLAEenc (.). Debido a esto, se forma una hiperesfera al ajustar los datos normales a una distribución gaussiana. Durante la prueba, los datos fuera de distribución (anómalos) caen fuera de dicha hiperesfera, lo que ayuda a detectar las anomalías. Una vez que los datos de entrenamiento se ajustan a una distribución gaussiana con el núcleo RBF, se genera un vector η dimensional para una pila de m fotogramas obtenidos utilizando la técnica de ventana deslizante. Una vez completado el entrenamiento, todas las secuencias (f′ sions como [K, η] donde K denota 0...n) se recolectan teniendo dimensión- el número de secuencias de entrenamiento y η representa la dimensión del vector latente. Luego, para cada dimensión η del vector latente, se calculan la media (μi) y la desviación estándar (σi) de la siguiente manera.

$$\mu i = \frac{1}{K}\sum_{j=1}^{K} F'_{0...n}[j][i] \quad (1)$$

$$\sigma i = \sqrt{\sum_{j=1}^{K} \frac{(f'_{0...n}[j][i] - \mu i)^2}{K}} \quad (2)$$

Después de calcular μi y σi , se aplica el algoritmo 1 para determinar si es detectar si una secuencia de prueba, f Para $f^{prueba}_{0...n}$ anómalo o no. obtener la puntuación de anomalía, se han utilizado los hiperparámetros α y β. El algoritmo 1 muestra los pasos aplicados para la detección de anomalías. Para la localización de anomalías, se toma una ventana móvil de h × w donde h denota altura y w denota ancho, y luego se desliza a través de todo el marco reconstruido obtenido del decodificador convolucional. Si una ventana particular es más que β × η, entonces esa ventana se anota como anómala y se aplica un cuadro delimitador.

Machine Translated by Google

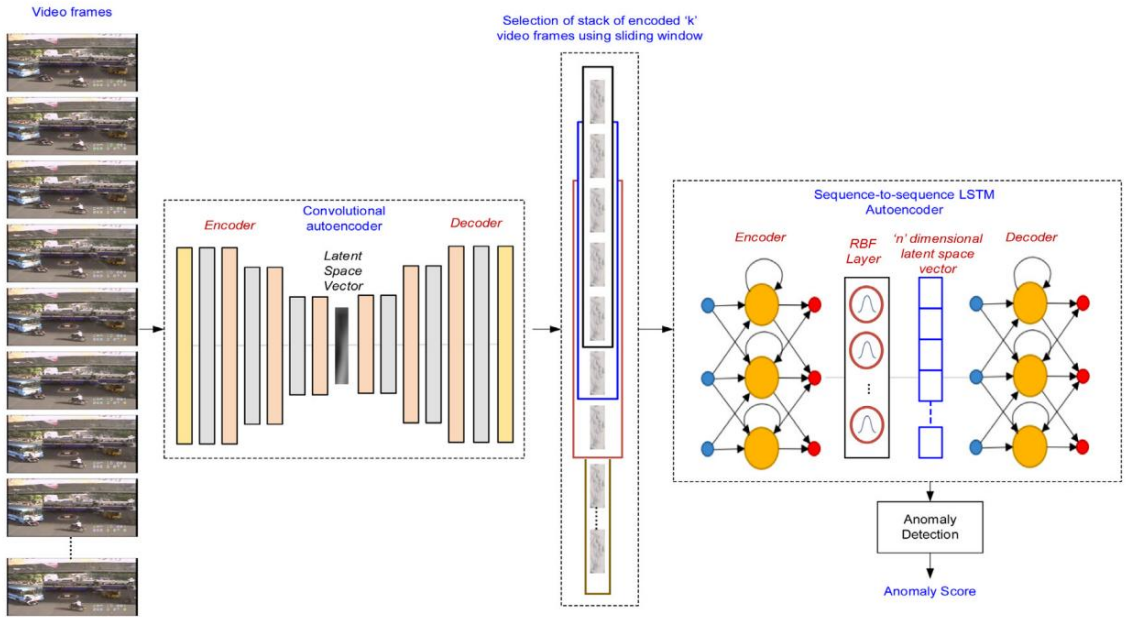


Figura 3. Modelo propuesto para la detección de anomalías en vídeos de vigilancia de tráfico.

Algorithm 1: Anomaly Detection from videos
Input: *Sequence of encoded video frames* - $f_{0\ldots n}^{test}$, *hyperparameters* - α *and* β, *dimension of latent space* $-\eta$
Output: Anomaly score

ANOMALY DETECTION $(f_{0\ldots n}^{test}, \alpha, \beta, \eta)$
1. $score \leftarrow 0$
2. **for** i$\leftarrow 1, \eta$
3. **if** $(f_{0\ldots n}^{test}[i] - \mu_i) \geq \alpha \cdot \sigma_i$
4. $score \leftarrow score + 1$
5. **if** $score \geq \beta \cdot \eta$
6. **return** "anomalous"
7. **else**
8. **return** "not anomalous"

4. Experimentación

Hardware y software. Para realizar los experimentos, se utilizó una máquina con GPU NVIDIA GeForce GTX 940MX con 4 GB de RAM y CPU i7-7500U de 2,9 GHz y que tenía GPU NVIDIA GeForce GTX 940MX y 4 GB de RAM.

Para su implementación se utilizan el framework TensorFlow 2.0.0 y Python 3.7.5.

4.1. Experimentación con el conjunto de datos de accidentes de tráfico del IITH

4.1.1. Detalles del conjunto de datos de accidentes de tráfico del IITH

La efectividad del modelo propuesto se prueba en un video de vigilancia de tráfico real, concretamente, el conjunto de datos de accidentes de tráfico IITH [23]. Este conjunto de datos se ha recopilado de la red de cámaras CCTV instaladas en diferentes plazas que capturan escenas de accidentes de tráfico en la ciudad de Hyderabad, India. La figura 6 muestra fotogramas de vídeo de muestra. Cada escenario en el conjunto de datos comienza con eventos de tráfico normales y termina con el evento de accidentes de tráfico rodado. Los detalles del conjunto de datos se presentan en la Tabla 1.

Tabla 1
Detalles del conjunto de datos de accidentes de tráfico del IITH.

Marcos	Recuento de fotogramas
Fotogramas normales	1,27,138
Marcos anómalos	863
Fotogramas normales utilizados para el entrenamiento	94,720
Marcos utilizados para las pruebas	33,281 (32,418 fotogramas normales + 863 fotogramas de accidentes)

4.1.2. Métricas de evaluación

Tasa de error igual (EER). La EER se puede definir de la siguiente manera.

$$EER = \frac{FP + FN}{norte} \quad (3)$$

donde FP representa un falso positivo, FN un falso negativo y n el número total de fotogramas de vídeo considerados para la detección de anomalías. Un valor menor de EER implica que el modelo detecta mejor las anomalías.

Área bajo la curva ROC (AUC). El valor de AUC se obtiene trazando primero la curva ROC y calculando el área que abarca dicha curva.

La curva ROC muestra la capacidad de clasificación del modelo al representar gráficamente la tasa de falsos positivos (FPR) y la tasa de verdaderos positivos (TPR) en todos los umbrales de clasificación. Un valor más alto del área bajo la curva (AUC) indica que el modelo es mejor.

Precisión media promedio (mAP). En mAP, cada umbral representa el porcentaje de superposición entre el cuadro delimitador predicho y el cuadro delimitador real. Este umbral se denomina Intersección sobre Unión (IoU). Se calcula de la siguiente manera.

$$Yo\ soy = \frac{\text{Área de superposición}}{\text{Área de la Unión}} \quad (4)$$

Machine Translated by Google

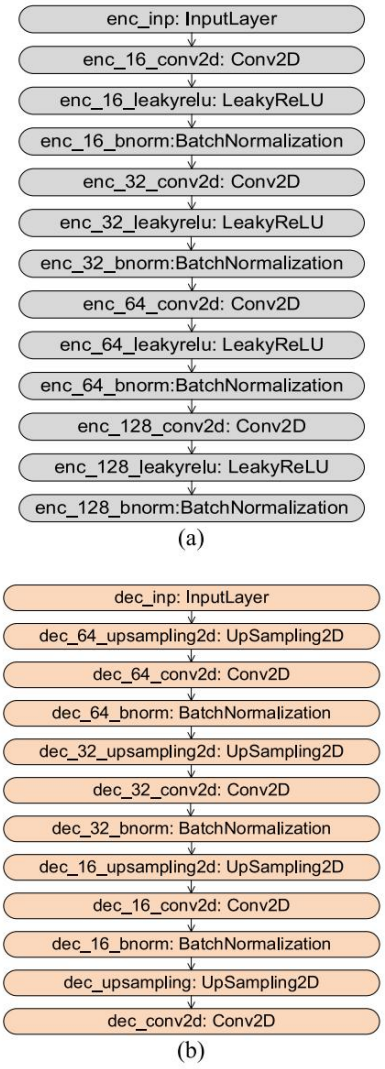


Figura 4. Detalles del autoencoder convolucional (a) Codificador (b) Decodificador.

Cuanto mayor sea el valor de mAP, mejor será el modelo para localizar las regiones de interés.

4.1.3. Discusión de resultados y análisis comparativo

Para comprobar el rendimiento del modelo a nivel de fotograma, es decir, para verificar si un modelo identifica correctamente si un fotograma presenta una anomalía o no, se han utilizado EER y AUC.

De manera similar, para la evaluación a nivel de píxel, es decir, para comprobar si un modelo está localizando correctamente la anomalía en el fotograma, utilizamos mAP como métrica de rendimiento. Para la detección a nivel de fotograma, se ha obtenido la curva ROC como se muestra en la Fig. 7 y el AUC correspondiente es del 79 %. Se ha logrado un EER del 20,50 % para la detección de anomalías a nivel de fotograma. Como el conjunto de datos de accidentes de tráfico de IITH no proporciona datos de referencia para comprobar la eficacia del modelo a nivel de píxel (localización), anotamos manualmente el conjunto de datos con coordenadas de cuadros delimitadores en cada uno de nuestros fotogramas de vídeo extraídos utilizando una herramienta de anotación labellmg y luego se comprueba el rendimiento utilizando mAP.

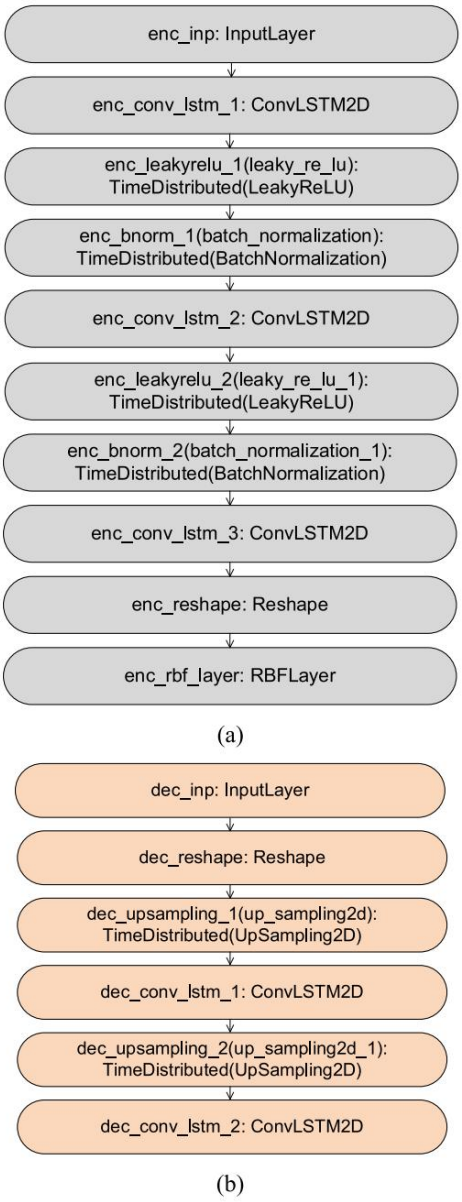


Fig. 5. Detalles del autoencoder LSTM con capacidad de aprendizaje de secuencia a secuencia (a) Codificador (b) Decodificador.

En la figura 8 se muestran los valores de mAP correspondientes a un rango de umbral IoU de 0,1 a 1,0. Con un umbral del 40 %, el modelo propuesto alcanzó el 60 % de mAP para la evaluación a nivel de píxel, como se muestra en la figura 8. Las figuras 9 y 10 muestran el rendimiento cualitativo del modelo en el conjunto de datos de accidentes de tráfico de IITH, en el que el modelo localiza las escenas de los accidentes.

Comparamos el rendimiento con los resultados del artículo de Singh y Mohan [24], como se muestra en la Tabla 2. Este es el único artículo disponible en la literatura en el que se realiza una evaluación a nivel de fotograma en el conjunto de datos de accidentes de tráfico del IITH. Según la comparación realizada en la Tabla 2, el modelo propuesto logró un rendimiento mejorado del 2% en términos de AUC con respecto al método de última generación [22].

Machine Translated by Google



Fig. 6. Fotogramas de vídeo de muestra del conjunto de datos de accidentes de tráfico del IITH [23].

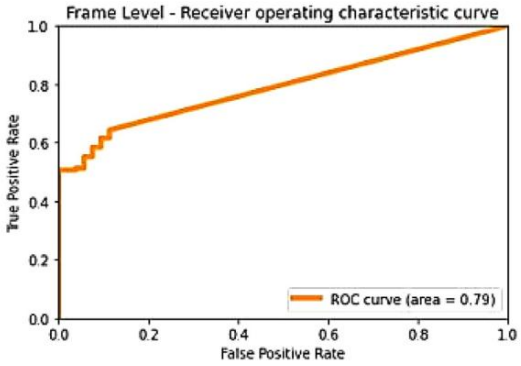


Figura 7. Curva ROC en la evaluación a nivel de fotograma (AUC = 79%).



Figura 9. Localización que muestra una bicicleta colisionando con un autobús.

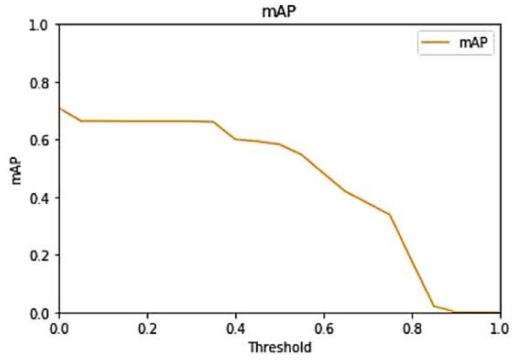


Figura 8. Puntuaciones de mAP con diferentes umbrales.



Figura 10. Localización que muestra un mototaxi chocando con un automóvil.

Tabla 2

Análisis comparativo del conjunto de datos de accidentes de tráfico del IITH.

Método	EER del AUC a nivel de fotograma		mapa
Autoencoder apilado [24]	77%	22,50%	–
Modelo propuesto	79%	20,50%	60%

4.2. Experimentación con el conjunto de datos de anomalías del Departamento de Transporte de Iowa

4.2.1. Detalles del conjunto de datos de anomalías del Departamento de Transporte de Iowa de 2021 (IA) Desafío de la ciudad

El AI City Challenge 2021 está dividido en 5 tareas, a saber: Conteo de vehículos de múltiples clases y movimientos utilizando dispositivos IoT,

Reidentificación de vehículos mediante múltiples cámaras a escala urbana, a escala urbana

Machine Translated by Google

Seguimiento de vehículos con múltiples cámaras, detección de anomalías de tráfico y recuperación de vehículos basada en lenguaje natural [25]. De los cinco desafíos, ejecutamos el modelo propuesto en el conjunto de datos del AI City Challenge 2021 perteneciente a la pista 4 de detección de anomalías de tráfico [26]. Este conjunto de datos fue recopilado por el DOT de Iowa capturado en múltiples autopistas. Las anomalías incluyen choques de uno y varios vehículos, así como la ocurrencia de vehículos detenidos. Hay 100 y 150 videos en el conjunto de entrenamiento y prueba respectivamente en el conjunto de datos de detección de anomalías de tráfico (conjunto de datos de anomalías del DOT de Iowa). Los videoclips se grabaron a 30 fotogramas por segundo con una resolución de 800 × 410. La duración de los videoclips en este conjunto de datos es de aproximadamente 15 min.

Como se mencionó en la Sección 3, el modelo propuesto construye un modelo de normalidad basado únicamente en datos normales y detecta accidentes de tráfico como anomalías (muestras fuera de distribución) mediante aprendizaje de una sola clase. Además, el modelo propuesto permite detectar colisiones individuales y múltiples de vehículos como parte de un accidente; sin embargo, no detecta vehículos averiados. Por lo tanto, para probar el modelo propuesto en el conjunto de datos de detección de anomalías de tráfico del desafío AI City, seleccionamos el conjunto de datos de la siguiente manera: eliminamos los videoclips pertenecientes a vehículos averiados (que no muestran la ocurrencia de un accidente de tráfico) tanto del conjunto de entrenamiento como del de prueba. Además, se eliminaron del conjunto de entrenamiento los videoclips que contenían ocurrencias de accidentes (colisiones individuales y múltiples de vehículos). Luego, el modelo se entrenó con videoclips normales del conjunto de datos seleccionado y se probó en el conjunto de datos que contenía tanto eventos normales como accidentes. De esta manera, el modelo se entrenó de forma no supervisada (entrenamiento con datos normales y pruebas con datos de accidentes de tráfico normales y anómalos).

4.2.2. Métricas de evaluación

Para justificar el rendimiento del modelo en términos de detección de accidentes, se ha utilizado la puntuación F1 como se menciona en el desafío de la ciudad de IA [25]. La puntuación F1 se calcula de la siguiente manera.

$$F1 = 2 \cdot \frac{\text{Precisión} \cdot \text{Recuperación}}{\text{Precisión} + \text{Recuperación}} = \frac{TP}{TP + 2 \quad \frac{1}{2}(FP + FN)} \tag{5}$$

En la ecuación (5), una detección de verdadero positivo (VP) indica que se predice correctamente que un fotograma es anómalo dentro de los 10 s posteriores a un evento anómalo real (evento de accidente). Un falso positivo (FN) indica que el modelo no logra predecir correctamente un evento anómalo real. Un falso positivo (FP) indica que el evento anómalo predicho no es un evento anómalo real.

4.2.3. Discusión de resultados y análisis comparativo

Con referencia a las métricas de evaluación del desafío AI City [25], se utiliza la puntuación F1 para evaluar el rendimiento del modelo en la detección de accidentes. Obtuvimos una puntuación F1 del 78,58 % con base en la estrategia de entrenamiento y prueba mencionada en la Sección 4.2.1. Los resultados se compararon con artículos que abordan la tarea 4 del desafío AI City de detección de anomalías de tráfico. Sin embargo, cabe destacar que las metodologías presentadas en los artículos [27–31] siguen una estrategia de aprendizaje supervisado en la que un modelo se entrena tanto con videoclips normales como con videoclips de accidentes. Por el contrario, el modelo propuesto sigue un aprendizaje no supervisado. La Figura 11 muestra la comparación.

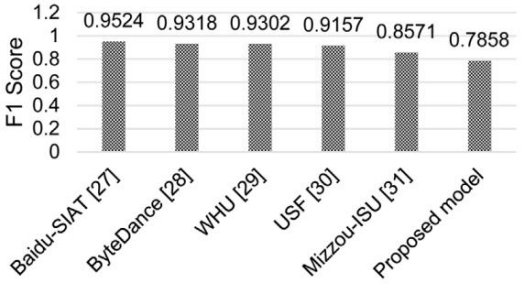


Figura 11. Análisis comparativo del conjunto de datos de anomalías del Departamento de Transporte de Iowa basado en F1 puntaje.

Comparación del enfoque de aprendizaje no supervisado propuesto con los enfoques de aprendizaje supervisado del desafío AI City 2021 (pista 4) según la puntuación F1 . La figura 12 muestra una evaluación cualitativa del modelo en términos de localización del incidente de colisión de automóviles en dos escenas diferentes del conjunto de datos de anomalías del Departamento de Transporte de Iowa.

Se analizan las metodologías adoptadas para abordar la tarea 4 del desafío AI City en los artículos más avanzados [27–31] . Baidu-SIAT [27] sigue un marco de trabajo en cascada que abarca el preprocesamiento, el seguimiento dinámico y el posprocesamiento.

El preprocesamiento incluye el modelado del fondo, la detección de vehículos, la construcción de la máscara de carretera y el seguimiento de vehículos anómalos. El seguimiento dinámico modela los patrones de movimiento y el seguimiento espaciotemporal de los vehículos para localizar el momento de inicio de las anomalías. ByteDance [28] aplica el modelado del fondo, el seguimiento a nivel de caja de tubos anómalos espaciotemporales y refinamientos para detectar con precisión los periodos de tiempo de las anomalías.

WHU [29] utiliza el seguimiento a nivel de caja y a nivel de píxel para la identificación de las anomalías y el trazado de trayectoria bilateral de doble modalidad para extraer las características espaciotemporales de los fotogramas. La metodología de USF [30] implica modelar el fondo de los fotogramas en sentido directo e inverso, seguido de una detección de vehículos en dos etapas y el cálculo de la similitud estructural para las regiones detectadas. Mizzou-ISU [31] sigue el modelado del fondo, la extracción de la máscara de la carretera y el umbral adaptativo para la detección de anomalías. En resumen, los artículos [27–31] implican el uso del detector de objetos YOLO, aprendizaje supervisado, modelado de fondo y seguimiento. Por el contrario, el enfoque propuesto en este artículo sigue una estrategia de aprendizaje no supervisado y, por lo tanto, el rendimiento en el conjunto de datos de anomalías del Departamento de Transporte de Iowa varía. Sin embargo, el enfoque propuesto solo necesita ser entrenado en fotogramas de vídeo precursores previos a los eventos anómalos y funciona eficientemente sin necesidad de datos anómalos etiquetados.

4.3. Experimentación con el conjunto de datos de DoTA

4.3.1. Detalles del conjunto de datos

DoTA La detección de anomalías de tráfico (DoTA) es un conjunto de datos de detección de anomalías de tráfico recopilado de canales de YouTube con numerosos ejemplos de videos de accidentes grabados con cámaras de salpicadero [32]. El conjunto de datos contiene 4677 videos con anotaciones temporales, espaciales y categóricas. Las anomalías en el conjunto de datos son colisiones de vehículos en la carretera debido a accidentes. Para comparar con otros enfoques de vanguardia, seguimos la estrategia

Machine Translated by Google



Figura 12. Localización que muestra un coche chocando contra otro.

Mencionado en [33]. El conjunto de datos se dividió aleatoriamente en 3275 vídeos de entrenamiento y 1402 de prueba. Como se menciona en la Sección 3, el modelo propuesto sigue una estrategia de aprendizaje de una sola clase. Por lo tanto, extrajimos fotogramas normales precursores de cada vídeo para el entrenamiento y construimos un modelo de normalidad. Finalmente, se probó el modelo con datos de prueba para la detección de accidentes de tráfico.

4.3.2. Métricas de evaluación

Evaluamos el rendimiento del modelo a nivel de fotograma. utilizando la curva ROC y el AUC.

4.3.3. Discusión de resultados y análisis comparativo

Logramos un AUC del 84,70% para la detección de carreteras. accidentes a nivel de fotograma. Para comparar, evaluamos el rendimiento del modelo utilizando AUC frente a otros enfoques de aprendizaje no supervisado de última generación, como se muestra en la Fig. 13.
Se presenta un resumen de los enfoques comparados. En ConvLST-MAE [34], se utiliza una CNN 2D para extraer información espacial de los fotogramas y una ConvLSTM multicapa codifica las características temporales de forma recurrente; finalmente, se utiliza un decodificador 2D para reconstruir los fotogramas de entrada. El método ConvAE [35] utiliza un autoencoder espacio-temporal. Codifica imágenes apiladas temporalmente con codificadores convolucionales 2D y las decodifica con capas de deconvolución para reconstruir la entrada.
El método AnoPred [36] acepta cuatro imágenes RGB continuas como entrada y predice imágenes futuras con la ayuda del modelo UNet y utiliza la funcionalidad de pérdida multitarea para mejorar la precisión de la predicción. El método TAD [19] modela las trayectorias de los cuadros delimitadores de vídeos normales con un autoencoder RNN de flujo múltiple. Las trayectorias pasadas y el movimiento propio se codifican para predecir los límites futuros de los objetos. El método Ensemble [33] combina los enfoques propuestos en [19,36] para obtener las ventajas de los métodos centrados en la apariencia y en el objeto para la detección.

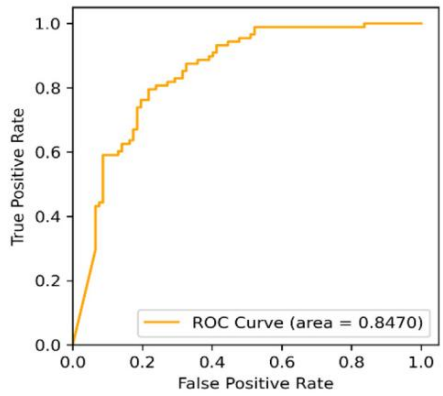


Figura 13. Curva ROC en la evaluación a nivel de fotograma (AUC = 84,70%).

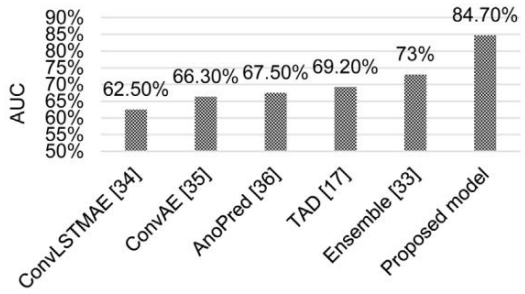


Figura 14. Análisis comparativo del conjunto de datos DoTA basado en el AUC.

Según la comparación representada en la Fig. 14, el modelo propuesto logró una mejora del 11,7% con respecto al método de aprendizaje no supervisado de última generación [33].

5. Conclusión y perspectivas futuras

En este artículo, proponemos un enfoque basado en aprendizaje profundo para la detección y localización de accidentes de tráfico. La ventaja de este enfoque radica en que solo necesitamos entrenar el modelo con eventos de tráfico normales, y las anomalías se detectan como muestras fuera de la distribución gracias al paradigma de aprendizaje de una sola clase. Evaluamos el rendimiento del modelo en tres conjuntos de datos de referencia. Como parte de las futuras líneas de investigación, el código puede implementarse en hardware como PYNQ para un procesamiento más rápido de fotogramas de vídeo para la detección de anomalías. Además, la investigación puede centrarse en el uso del aprendizaje activo para la detección de anoma El aprendizaje activo permitiría actualizar el modelo sobre la marcha, de acuerdo con los nuevos patrones de comportamiento que se encuentren tanto en datos normales como anómalos, gracias a la intervención humana.

Declaración de contribución de autoría CRediT

Karishma Pawar: Concepción y diseño del estudio, adquisición de datos, análisis e interpretación de datos, revisión y edición del texto. Vahida Attar: Concepción y diseño del estudio, análisis e interpretación de datos, revisión y edición del texto.

Declaración de conflicto de intereses

Los autores declaran que no tienen ningún conflicto de intereses financieros ni relaciones personales que pudieran haber influido en el trabajo presentado en este artículo.

Machine Translated by Google

Referencias

[1] A. Zanella, N. Bui, A. Castellani, L. Vangelista, M. Zorzi, Internet de las cosas para ciudades inteligentes, IEEE IoT J. 1 (1) (2014) 22–32.

[2] M. Kumar, KS Raju, D. Kumar, N. Goyal, S. Verma, A. Singh, Un marco eficiente que utiliza reconocimiento visual para la vigilancia de ciudades inteligentes basada en IoT, Multimedia Tools Appl. (2021) 1–19.

[3] KK Santhosh, DP Dogra, PP Roy, Detección de anomalías en el tráfico rodado mediante vigilancia visual: una revisión, ACM Comput. Surv. 53 (2020) 1–26.

[4] W. Hu, X. Xiao, Z. Fu, D. Xie, T. Tan, S. Maybank, Un sistema para aprender patrones de movimiento estadísticos, IEEE Trans. Pattern Anal. Mach. Intel. 28 (2006) 1450–1464.

[5] H. Tan, J. Zhang, J. Feng, F. Li, Medición de la velocidad del vehículo para la investigación de la escena del accidente, en: 2010 IEEE 7th Int. Conf. E-Bus. Eng., 2010, pp. 389–392.

[6] F. Jiansheng, et al., Detección de accidentes de tráfico en tiempo real basada en visión, en: Actas del 11.º Congreso Mundial de Control Inteligente y Automatización, 2014, págs. 1035–1038.

[7] W. Sultani, JY Choi, Detección de tráfico anormal mediante un modelo de conductor inteligente, en: 2010 20th Int. Conf. Pattern Recognit., 2010, pp. 324–327.

[8] AR Pathak, M. Pandey, S. Rautaray, Aplicación del aprendizaje profundo para la detección de objetos, Procedia Comput. Sci. 132 (2018) 1706–1717, http://dx.doi.org/10.1016/j.procs.2018.05.144.

[9] AR Pathak, M. Pandey, S. Rautaray, K. Pawar, Evaluación de la detección de objetos mediante redes neuronales convolucionales profundas, vol. 673, 2018.

[10] G. Algan, I. Ulusoy, Clasificación de imágenes con aprendizaje profundo en presencia de etiquetas ruidosas: una revisión, Knowl.-Based Syst. 215 (2021) 106771.

[11] K. Pawar, V. Attar, Enfoques de aprendizaje profundo para la detección de actividad anómala basada en video, World Wide Web 22 (2) (2019) 571–601, http://dx.doi.org/10.1007/s11280-018-0582-1.

[12] AR Pathak, M. Pandey, S. Rautaray, Análisis de sentimiento a nivel de tema de datos de redes sociales utilizando aprendizaje profundo, Appl. Soft Comput. 108 (2021) 107440.

[13] K. Pawar, VZ Attar, Evaluación de arquitecturas de autoencoders para la representación de datos, en: W. Pedrycz, S.-M. Chen (Eds.), Deep Learning: Concepts and Architectures, Springer International Publishing, 2020, pp. 101–132.

[14] A. Ouahabi, A. Taleb-Ahmed, Aprendizaje profundo para la segmentación semántica en tiempo real : Aplicación en imágenes de ultrasonido, Pattern Recognit. Lett. 144 (2021) 27–34.

[15] SM Marvasti-Zadeh, L. Cheng, H. Ghanei-Yakhdan, S. Kasaei, Aprendizaje profundo para el seguimiento visual: una revisión exhaustiva, IEEE Trans. Sistemas de Transporte Inteligente (2021).

[16] H. Ren, Y. Song, J. Wang, Y. Hu, J. Lei, Un enfoque de aprendizaje profundo para la predicción del riesgo de accidentes de tráfico en toda la ciudad, en: 2018 21st Int. Conf. Intel. Transp. Syst., 2018, págs. 3346–3351.

[17] M. Bortnikov, A. Khan, AM Khattak, M. Ahmad, Reconocimiento de accidentes mediante CNN 3D para el monitoreo automatizado del tráfico en ciudades inteligentes, en: Sci. Inf. Conf., 2019, pp. 256–264.

[18] D. Tian, C. Zhang, X. Duan, X. Wang, Un método automático de detección de accidentes automovilísticos basado en sistemas cooperativos de infraestructura vehicular, IEEE Access 7 (2019) 127453–127463.

[19] Y. Yao, M. Xu, Y. Wang, DJ Crandall, EM Atkins, Detección no supervisada de accidentes de tráfico en vídeos en primera persona, 2019, ArXiv Prepr. arXiv:1903.00618.

[20] T. Ohgushi, K. Horiguchi, M. Yamanaka, Método de detección de obstáculos en la carretera basado en un autoencoder con segmentación semántica, en: Proc. Conferencia Asiática de Visualización por Computación, 2020.

[21] B. Varona, A. Monteserin, A. Teyseyre, Un enfoque de aprendizaje profundo para el monitoreo automático de la superficie de la carretera y la detección de baches, Pers. Computación Ubicua 24 (2020) 519–534.

[22] SS Khan, MG Madden, Un estudio de las tendencias recientes en la clasificación de una clase, en: L. Coyle, J. Freyne (Eds.), Inteligencia artificial y ciencia cognitiva, Springer Berlin Heidelberg, 2010, pp. 188–197.

[23] Conjunto de datos de accidentes de tráfico del IITH, https://sites.google.com/site/dineshsinghindian/iith_accident-dataset.

[24] D. Singh, CK Mohan, Representación espaciotemporal profunda para la detección de accidentes de tráfico mediante autoencoder apilado, IEEE Trans. Intell. Transp. Syst. 20 (3) (2019) 879–887, http://dx.doi.org/10.1109/TITS. 2018.2835308.

[25] M. Naphade, S. Wang, D. C. Anastasiu, Z. Tang, M.-C. Chang, X. Yang, Y. Yao, L. Zheng, P. Chakraborty, C.E. López, A. Sharma, Q. Feng, V. Ablavsky, S. Sclaroff, El 5º desafío de la ciudad de IA, en: IEEE Conf. Comput. Vis. Pattern Recognit. Work., 2021.

[26] Conjunto de datos de anomalías del Departamento de Transporte de Iowa, https://www.aicitychallenge.org/2021-datos-y-evaluación/.

[27] Y. Zhao, W. Wu, Y. He, Y. Li, X. Tan, S. Chen, Buenas prácticas y una base sólida para la detección de anomalías en el tráfico, en: Proc. IEEE/CVF Conf. Comput. Vis. Pattern Recognit., 2021, pp. 3993–4001.

[28] J. Wu, X. Wang, X. Xiao, Y. Wang, Seguimiento y refinamiento de tubos a nivel de caja para la detección de anomalías en vehículos, en: Proc. IEEE/CVF Conf. Comput. Vis. Pattern Recognition., 2021, pp. 4112–4118.

[29] J. Chen, G. Ding, Y. Yang, W. Han, K. Xu, T. Gao, Z. Zhang, W. Ouysang, H. Cai, Z. Chen, Detección de anomalías vehiculares de doble modalidad mediante seguimiento de trayectoria bilateral, en: Proc. IEEE/CVF Conf. Comput. Vis. Reconocimiento de Patrones, 2021, págs. 4016–4025.

[30] K. Doshi, Y. Yilmaz, Un enfoque eficiente para la detección de anomalías en videos de tráfico, en: Proc. IEEE/CVF Conf. Comput. Vis. Pattern Recognit., 2021, pp. 4236–4244.

[31] A. Aboah, Un sistema basado en visión para la detección de anomalías de tráfico utilizando aprendizaje profundo y árboles de decisión, en: Proc. IEEE/CVF Conf. Comput. Vis. Pattern Recognit., 2021, pp. 4207–4212.

[32] Conjunto de datos de DoTA, https://github.com/MoonBlvd/Detection-of-Traffic-Anomalía.

[33] Y. Yao, X. Wang, M. Xu, Z. Pu, E. Atkins, D. Crandall, ¿Cuándo, dónde y qué? Un nuevo conjunto de datos para la detección de anomalías en vídeos de conducción, 2020, ArXiv Prepr. arXiv:2004.03044.

[34] YS Chong, YH Tay, Detección de eventos anormales en videos usando un autoencoder espaciotemporal, 2017, CoRR. abs/1701.0. http://arxiv.org/ abs/1701.01546.

[35] M. Hasan, J. Choi, J. Neumann, AK Roy-Chowdhury, LS Davis, Aprendizaje de regularidad temporal en secuencias de vídeo, en: Comput. Vis. Reconocimiento de patrones. (CVPR), IEEE Conf. 2016, 2016, págs. 733–742.

[36] W. Liu, W. Luo, D. Lian, S. Gao, Predicción de fotogramas futuros para la detección de anomalías: una nueva línea base, en: Proc. IEEE Conf. Comput. Vis. Pattern Recognit., 2018, pp. 6536–6545.