Machine Translated by Google

Check for updates

Recibido: 24 de agosto de 2021 | Revisado: 9 de junio de 2022 | Aceptado: 22 de septiembre de 2022

Sistemas de transporte inteligentes IET

DOI: 10.1049/itr2.12287

The Institution of Engineering and Technology WILEY

INVESTIGACIÓN ORIGINAL

Representación profunda de datos de flujo de tráfico espaciotemporales desequilibrados para la detección de accidentes de tráfico.

Pouya Mehrannia1 | Shayan Shirahmad Gale Bagi2 | Behzad Moshiri1,2 | Otman Adam Al-Basir1

1Departamento de Ingeniería Eléctrica e Informática Ingeniería, Universidad de Waterloo, Waterloo, Ontario, Canadá

2Escuela de Ingeniería Eléctrica e Informática, Facultad de Ingeniería, Universidad de Teherán, Teherán, Irán

Correspondencia:
Behzad Moshiri, Escuela de Ingeniería Eléctrica e Informática, Facultad de Ingeniería, Universidad de Teherán, Teherán, Irán.

Correo electrónico: moshiri@ut.ac.ir

Resumen

La detección automática de accidentes de tráfico tiene un efecto crucial en la mejora del transporte, la seguridad pública y la planificación de rutas. Se pueden salvar muchas vidas gracias a la consiguiente reducción del tiempo entre la ocurrencia de los accidentes y el envío de los equipos de rescate, y se puede ahorrar mucho tiempo de viaje al notificar a los conductores que seleccionen rutas alternativas. Este problema es complejo principalmente debido a la rareza de los accidentes y la heterogeneidad espacial del entorno. Este artículo estudia la representación profunda de datos de detectores de bucle utilizando una red de memoria a largo y corto plazo (LSTM) para la detección automática de accidentes en autopistas. El marco basado en LSTM aumenta la separabilidad de clases en el espacio de características codificado, al tiempo que reduce la dimensión de los datos. Los experimentos con datos reales de accidentes y detectores de bucle recopilados en las autopistas del área metropolitana de las Ciudades Gemelas de Minnesota demuestran que la representación profunda de datos de flujo de tráfico utilizando una red LSTM tiene el potencial de detectar accidentes en autopistas en menos de 18 minutos con una tasa de verdaderos positivos de 0,71 y una tasa de falsos positivos de 0,25, superando a otros métodos de la competencia en la misma configuración.

1. INTRODUCCIÓN

Cada año, 1,35 millones de personas mueren en las carreteras de todo el mundo. Se estima que las lesiones por accidentes de tráfico son la octava causa principal de muerte a nivel mundial para todos los grupos de edad y la principal causa de muerte para niños y jóvenes de 5 a 29 años [1]. Durante el siglo pasado, la seguridad vial ha indicado métodos y medidas para prevenir accidentes de tráfico. Sin embargo, un indicador importante de las tasas de supervivencia después de la ocurrencia de accidentes está subestimado. Ese indicador es el tiempo entre el momento en que ocurre el accidente y el momento en que se envía personal médico de emergencia al lugar. Minimizar el tiempo entre estos dos eventos disminuye las tasas de mortalidad en un 6% [2]. Los investigadores han estado explorando el potencial de la infraestructura vial con la esperanza de encontrar un enfoque confiable para la detección en tiempo real del momento del accidente. Una detección automática de accidentes confiable permite la inmediatez

Se agilizó la notificación al personal de emergencia y, en consecuencia, se redujo el tiempo de despacho. Además, se puede avisar a los conductores que se aproximan al lugar para que utilicen rutas alternativas o, al menos, reduzcan la velocidad por seguridad.

Los datos de flujo de tráfico se han utilizado ampliamente para detectar incidentes de tráfico, ya que las métricas definidas en ellos muestran una gran correlación con dichos incidentes. Una parte considerable de los datos de flujo de tráfico proviene de sensores detectores de bucle. Estos sensores, a pesar de sus datos ruidosos y la falta de una alta cobertura espacial, están instalados en innumerables carreteras. Por lo tanto, desarrollar modelos que puedan generar buenas tasas de detección de incidentes utilizando estos sensores ayuda a los gobiernos a obtener información valiosa hasta que las nuevas tecnologías comiencen a predominar. Los accidentes pueden afectar los patrones de flujo de tráfico aguas arriba y aguas abajo del lugar del accidente. Capturar estos patrones en el flujo de tráfico y asociarlos con la ocurrencia de accidentes no es un problema de clasificación sencillo. El objetivo principal de este estudio es determinar en qué medida la representación profunda de las características obtenidas de los detectores de bucle puede identificar colisiones automáticamente después de que ocurran.

Otro objetivo es manejar datos de flujo de tráfico espaciotemporales desequilibrados. Los accidentes de tráfico son eventos naturalmente raros, por lo que los conjuntos de datos están inevitablemente desequilibrados. El principal problema de entrenar un modelo con conjuntos de datos desequilibrados es que el modelo

Este es un artículo de acceso abierto bajo los términos de la licencia Creative Commons Attribution. Licencia que autoriza el uso, la distribución y la reproducción en cualquier medio, siempre que se cite correctamente la obra original. © 2022 Los autores.

IET Intelligent Transport Systems, publicado por John Wiley & Sons Ltd en nombre de The Institution of Engineering and Technology.

Machine Translated by Google

17519678, 2023, 3, Descargado de https://ietresearch.onlinelibrary.wiley.com/doi/10.1049/itr2.12287 por Cochrane Perú, Wiley Online Library el [02/05/2028]. Consulte los Términos y condiciones (https://onlinelibrary.wiley.com/terms-and-conditions) en Wiley Online Library para conocer las reglas de uso; los artículos de acceso abierto se rigen por la Licencia Creative Commons aplicable.

No puede proporcionar resultados robustos para la clase minoritaria, ya que no está expuesta a una cantidad suficiente de datos en dicha clase para aprender el patrón. Además, el bajo número de muestras de accidentes puede aumentar la posibilidad de sobreajuste en el modelo.

Para cumplir con estos objetivos, investigamos un marco basado en LSTM y exploramos sus diferentes configuraciones para aumentar la separabilidad de las clases de accidentes y no accidentes en el espacio de características codificado y para reducir la dimensionalidad de los datos de flujo de tráfico.

Para probar nuestros experimentos, utilizamos datos de registradores automáticos de tráfico (ATR) proporcionados por el Departamento de Transporte de Minnesota. Estos datos se obtienen de detectores de bucle: dispositivos de conteo continuo con bucles en el pavimento que registran el volumen de tráfico. Otros atributos útiles que se obtienen de los datos agregados de ATR incluyen capacidad, densidad, flujo, intervalo entre vehículos, ocupación y velocidad. Dado que los accidentes interrumpen el flujo normal del tráfico, esperamos poder identificar las interrupciones del flujo atribuibles a accidentes de tráfico después de cierto tiempo, dependiendo de la naturaleza de los mismos. Nuestras principales contribuciones se pueden resumir de la siguiente manera:

· A diferencia de los métodos anteriores que utilizan imágenes, proponemos un nuevo enfoque para detectar accidentes a partir de datos numéricos obtenidos de los ATR.

· Desarrollamos un modelo que aumenta la separabilidad de clases en el espacio de características y supera a los métodos existentes. · Estudio exhaustivo de los métodos de remuestreo para abordar el problema. Desequilibrio entre muestras con y sin fallos.

El resto de este artículo se organiza de la siguiente manera: La sección 2 describe los trabajos previos relacionados con la detección automática de accidentes. La sección 3 describe los datos y los desafíos asociados al uso simultáneo de datos de detectores de colisiones y de bucles. La sección 4 presenta en detalle el enfoque de modelado y ofrece una breve introducción a los métodos incorporados en el modelo. La estrategia de evaluación del modelo también se describe al final de esta sección. La sección 5 presenta e interpreta los resultados. Finalmente, la sección 6 ofrece una discusión sobre los resultados y las conclusiones .

2 TRABAJOS RELACIONADOS

La detección de accidentes se ha estudiado en la comunidad del transporte durante al menos 50 años. El algoritmo de California, desarrollado en 1978, detecta la ocurrencia de accidentes cuando las variables relacionadas con el tráfico superan umbrales específicos basados en la teoría del flujo de tráfico [3]. En las décadas de 1970 y 1980 se desarrollaron algoritmos similares aplicando la desviación normal estándar [4], algoritmos bayesianos [5] y modelos de series temporales [6] a datos históricos de tráfico. La necesidad de una respuesta más rápida y de gestionar las interdependencias entre las características de entrada en presencia de múltiples entradas ha motivado a los investigadores a recurrir a marcos más complejos.

Una amplia gama de estudios se centró en la detección de accidentes en tiempo real utilizando enfoques más sofisticados, incluyendo técnicas estadísticas [7, 8], procesamiento de imágenes [9, 10], reconocimiento de patrones [11, 12] e inteligencia artificial [13–17]. Si bien muchos de los métodos propuestos indican un rendimiento razonable utilizando imágenes,

En cuanto al contenido de las redes sociales y los datos de conteo de tráfico, la viabilidad práctica de estos métodos con datos desequilibrados, heterogéneos y en tiempo real sigue siendo incierta. En muchas aplicaciones de transporte, las técnicas de aprendizaje automático han demostrado su capacidad para manejar datos de alta dimensionalidad, heterogéneos y desequilibrados [18–20]. Sin embargo, aún se busca un modelo práctico con un tiempo de respuesta razonablemente bajo que utilice los datos provenientes de la infraestructura de tráfico ya instalada.

Los datos de flujo de tráfico se registran continuamente desde hace décadas, por lo que normalmente nos enfrentamos a grandes volúmenes de datos en este contexto. Los métodos de aprendizaje avanzados, como el aprendizaje de representaciones y el aprendizaje profundo, han demostrado ser prometedores o muy necesarios para resolver los problemas de los grandes volúmenes de datos, incluida la detección de accidentes de tráfico [21]. Entre estos métodos, las arquitecturas específicas de redes neuronales recurrentes han captado cada vez más atención por su capacidad para exhibir un comportamiento dinámico temporal y procesar secuencias de entrada de longitud variable [22]. A diferencia de clasificadores como las máquinas de vectores de soporte (SVM) y la regresión logística, el aprendizaje profundo no busca relaciones funcionales directas entre las características de entrada y los resultados de la clasificación de salida. En cambio, intenta aprender en múltiples niveles, correspondientes a diferentes niveles de abstracción [23].

Entre todos los métodos de vanguardia, la representación profunda ha ganado mayor popularidad debido a sus capacidades de modelado no lineal.

Uno de los estudios más recientes que emplea representación profunda para la detección de accidentes de tráfico es realizado por Singh et al. utilizando vídeos de vigilancia [24]. Su marco propuesto aprende automáticamente la representación de características a partir de los volúmenes espaciotemporales de intensidad de píxeles sin procesar, lo que supera los enfoques tradicionales basados en características diseñadas manualmente. Otro estudio de Zhang et al. [25] empleó red de creencias profundas (DBN) y memoria a corto y largo plazo (LSTM) para detectar accidentes de tráfico a partir de datos de redes sociales. Sus resultados muestran que su método supera a las máquinas de vectores de soporte (SVM) y a la asignación latente de Dirichlet supervisada (sLDA) probadas en 3 millones de contenidos de tweets en dos áreas metropolitanas en una ventana de tiempo Hunag et al. [26] utilizaron una arquitectura de redes neuronales convolucionales de dos flujos integrada para detectar eventos cercanos a accidentes de usuarios de la vía en datos de video de tráfico. Su método basado en aprendizaje profundo en tiempo real comprende una red de flujo espacial y una red de flujo temporal, y muestra un rendimiento cualitativo y cuantitativo competitivo a altas velocidades de fotogramas. Ghosh et al. [27] también utilizaron videos de una cámara de CCTV instalada en una autopista para entrenar un modelo basado en redes neuronales convolucionales (CNN) para clasificar fotogramas individuales como eventos de choque o no choque.

Las tecnologías de recopilación de datos de tráfico se evalúan principalmente en función de la fiabilidad, el rendimiento en diversas condiciones ambientales, la precisión de los datos obtenidos de los detectores y el rendimiento en tiempo real [28]. El procesamiento de imágenes de vídeo tiene la ventaja de proporcionar imágenes de movimiento en tiempo real y sin interrupción del tráfico para la instalación y reparación. Sin embargo, el contenido de vídeo, al igual que el contenido de las redes sociales, es costoso de acceder y procesar, y el rendimiento de los modelos que funcionan con ellos ha mostrado, en muchos casos, inconsistencias en diversas circunstancias ambientales y de tráfico. El uso de teléfonos inteligentes y aplicaciones basadas en GPS también es popular por su buena precisión y rendimiento en tiempo real, pero los sistemas inteligentes

Machine Translated by Google

Los teléfonos tienen complicaciones de privacidad y, debido al filtro de falsas alarmas, pueden no detectar todos los accidentes [29]. Las tecnologías emergentes en vehículos que aparecen, por ejemplo, en eCall, Onstar y Ford-Sync [30, 31] pueden hacer automáticamente una llamada de emergencia después de un accidente. Estos servicios requieren interoperabilidad transfronteriza, porque los vehículos cruzan fronteras nacionales y debido a la naturaleza global y regional del mercado automotriz. Además, deben ser físicamente robustos para sobrevivir a un accidente, y dado que la vida útil esperada de los vehículos es más larga que la de los teléfonos, se requiere retrocompatibilidad con generaciones anteriores de redes celulares [32]. En este estudio usamos detectores de bucle porque están instalados en abundancia en las carreteras y no son sensibles a factores ambientales y de tráfico como la lluvia, la nieve y los atascos. A pesar de recopilar datos ruidosos y carecer de una alta cobertura espacial, los detectores de bucle, su instalación y su mantenimiento tienen un costo relativamente bajo y proporcionan una gran base de conocimientos con un rendimiento relativamente bueno [28], lo que nos motiva a encontrar enfoques eficientes que puedan funcionar basándose en datos de detectores de bucle.

Existen otros desafíos al trabajar con datos de accidentes. Los conjuntos de datos de accidentes de tráfico están muy desequilibrados, lo que genera sesgos posteriormente durante el entrenamiento del modelo de clasificación. El número de muestras sin accidentes es mucho mayor que el número de casos de accidentes en conjuntos de datos de accidentes reales. La proporción de registros de accidentes y sin accidentes en el conjunto de datos debe asignarse meticulosamente [33], o se deben considerar métodos de sobremuestreo y submuestreo adecuados para tratar con datos desequilibrados [34, 35]. Otro método potente, la técnica de sobremuestreo sintético de la clase minoritaria (SMOTE) [36], ha demostrado ser eficiente cuando solo se dispone de unas pocas muestras de una clase, que es el caso en los conjuntos de datos de accidentes. La síntesis de muestras de la clase minoritaria da como resultado regiones de decisión más grandes y menos específicas que resuelven el problema de sobreajuste del sobremuestreo y el problema de pérdida de puntos de datos del submuestreo. En general, se ha observado que SMOTE es más robusto, especialmente cuando se trata de conjuntos de datos ruidosos, grandes y dispersos [37, 38], pero aún no se ha propuesto ningún método de representación de características satisfactorio en combinación con estas técnicas de remuestreo para procesar datos de sensores de conteo de tráfico. La representación profunda de datos de flujo de tráfico mediante redes neuronales, como LSTM o CNN, permite que los modelos de detección de accidentes aprendan los patrones espaciotemporales de los datos y su relación con los eventos de accidentes [39]. Una aplicación reciente y exitosa de la representación profunda de datos mediante la red LSTM es la de Zhao et al. para la predicción de tráfico a corto plazo [40]. Encontrar la combinación adecuada de métodos de representación profunda y remuestreo, junto con la estructura y configuración de red apropiadas, es fundamental para superar estos desafíos. Hemos investigado y comparado estas combinaciones y proponemos la que ofrece el mejor resultado en la Sección 4.

3. PREPARACIÓN DE DATOS

Los datos para este estudio son proporcionados por el Departamento de Transporte de Minnesota (MnDOT), que incluye los datos de conteo de tráfico y los datos de registros de accidentes [41] durante un período de 10 años, desde 2009 hasta 2019.



FIGURA 1 Un sitio de tráfico bidireccional que contiene 16 sensores

3.1 | Datos de conteo de tráfico

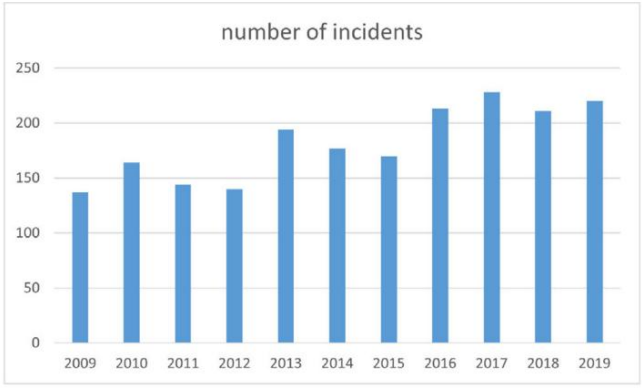
El Centro Regional de Gestión del Transporte (RTMC), una división del Departamento de Transporte de Minnesota (MnDOT), recopila continuamente datos de detectores de bucle a intervalos de 30 segundos desde más de 4500 detectores ubicados alrededor de las autopistas del área metropolitana de las Ciudades Gemelas, los 7 días de la semana y durante todo el año. Todos los detectores generan datos de volumen vehicular; sin embargo, algunas estaciones de registro automático de tráfico recopilan tipos de datos adicionales según su equipo y sensores. En este estudio, utilizamos seis características extraídas de las herramientas de detección del MnDOT, a saber: capacidad, densidad, flujo, intervalo entre vehículos, ocupación y velocidad, descritas a continuación:

– La ocupación es el porcentaje de tiempo que el campo de un detector está ocupado por un vehículo.
– El flujo es el número de vehículos que pasan por un detector por hora (volumen × muestras por hora).
– El intervalo entre vehículos es el número de segundos entre cada vehículo (segundos por hora/flujo).
– La densidad es el número de vehículos por milla – La velocidad es la velocidad promedio de los vehículos que pasan en una milla período de muestreo (caudal/densidad)
– La capacidad es la cantidad de flujo que se puede agregar (o restar) a una carretera antes de alcanzar una alta congestión (o un tráfico bajo).

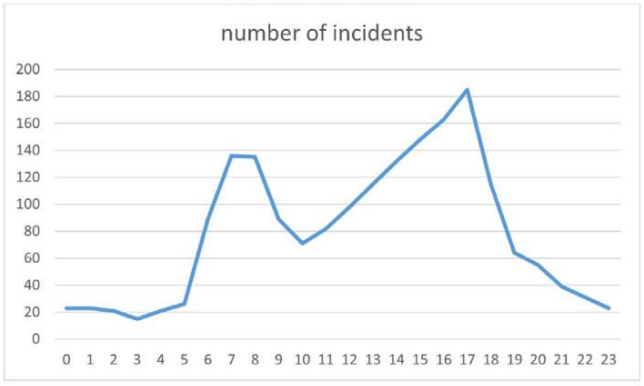
Realizamos nuestros experimentos en secciones de autopistas relativamente alejadas de las rampas. Las estructuras de autopistas más complejas y las carreteras con intersecciones se dejan para trabajos futuros. La Figura 1 muestra un ejemplo de sitio utilizado para recopilar datos de detectores. Este sitio en particular está equipado con 16 sensores, cada uno de los cuales proporciona las características de interés para el carril en el que está instalado. Estos sensores agregan datos en un intervalo preestablecido de 30 s, pero los datos se pueden extraer en intervalos de 0,5, 1, 1,5, 2, 2,5, 3, 4 y 5 min. Las distancias entre detectores a lo largo de la dirección del flujo de tráfico no son las mismas. Sin embargo, la distancia promedio en los sitios de experimento es de aproximadamente 0,8 millas, lo cual es lo suficientemente bajo como para capturar las fluctuaciones en el flujo de tráfico por al menos un sensor en la proximidad poco después de que ocurra un accidente. La gravedad de un accidente también es un factor que

17519878, 2023, 3, Descargado de https://ietresearch.onlinelibrary.wiley.com/doi/10.1049/itr2.12287 por Cochrane Perú, Wiley Online Library el [02/05/2028]. Consulte los Términos y condiciones (https://onlinelibrary.wiley.com/terms-and-conditions) en Wiley Online Library para conocer las reglas de uso; los artículos de acceso abierto se rigen por la Licencia Creative Commons aplicable.

Machine Translated by Google



(a) Annual count



(b) Hourly count

FIGURA 2 Recuento de incidentes en intervalos anuales y horarios durante una década, de 2009 a 2019. Los datos de incidentes se limitan al sitio experimental que se muestra en la Figura 1. La hora N en el recuento horario representa el intervalo de tiempo entre la hora N y N+1.

puede afectar el tiempo de detección del accidente. Lo discutiremos el tiempo de detección en la sección de resultados y también el tipo y la configuración de los accidentes que son difíciles de detectar por los sistemas propuestos.

3.2 Datos sobre accidentes de tráfico

Los registros de accidentes de los sitios experimentales se utilizaron para probar el rendimiento del método propuesto en este estudio. Este conjunto de datos de accidentes contiene los registros de todos los accidentes ocurridos en los sitios experimentales durante los últimos 10 años. Los registros incluyen la fecha y la hora de los accidentes, que se utilizan para evaluar la precisión de la detección de accidentes. Dado que nuestros experimentos se limitan a un tramo específico de la carretera, hemos ilustrado el número de incidentes anuales y por hora para ese tramo en la Figura 2(a,b) para mostrar la distribución y la escasez de incidentes a lo largo de una década (2009 a 2019). Más adelante, en la Sección 4, analizamos los métodos que utilizamos para superar la escasez de datos de accidentes.

Un análisis rápido de las marcas de tiempo de los accidentes en el conjunto de datos reveló que no todas son precisas. Nuestra comprensión-

La diferencia radica en que las marcas de tiempo de los accidentes se registran en función de la evidencia encontrada en el lugar del accidente o informada por los testigos. En ocasiones, no hay suficiente evidencia ni testigos disponibles para registrar con precisión la hora del accidente. Un análisis comparativo de los datos del accidente con los datos de los sensores mostró que, en algunos casos, las marcas de tiempo pueden tener un desfase de decenas de minutos. Lamentablemente, esta imprecisión puede afectar la evaluación del modelo de detección de accidentes, especialmente cuando se busca minimizar el tiempo de detección. Para reducir el efecto de las marcas de tiempo imprecisas, añadimos un parámetro de grado de flexibilidad (DoF) que ayuda a reflejar mejor los accidentes correctamente identificados y las falsas alarmas. Explicamos con más detalle cómo adoptamos el DoF en el capítulo de metodología.

4. METODOLOGÍA

La detección de accidentes de tráfico es un problema de clasificación binaria en el que hay dos clases: accidente y no accidente. Hay dos puntos notables sobre los accidentes de tráfico. Primero, los accidentes de tráfico son eventos naturalmente raros, por lo que los conjuntos de datos están inevitablemente desequilibrados. El principal problema de entrenar una red con un conjunto de datos desequilibrado es que la red puede...

no proporciona resultados óptimos para la clase minoritaria ya que no aprende suficientes patrones en la clase minoritaria.
Para solucionar este problema, aumentamos el peso de las muestras de la clase minoritaria al entrenar la red y volvemos a muestrear el conjunto de datos para generar más instancias de la clase minoritaria.

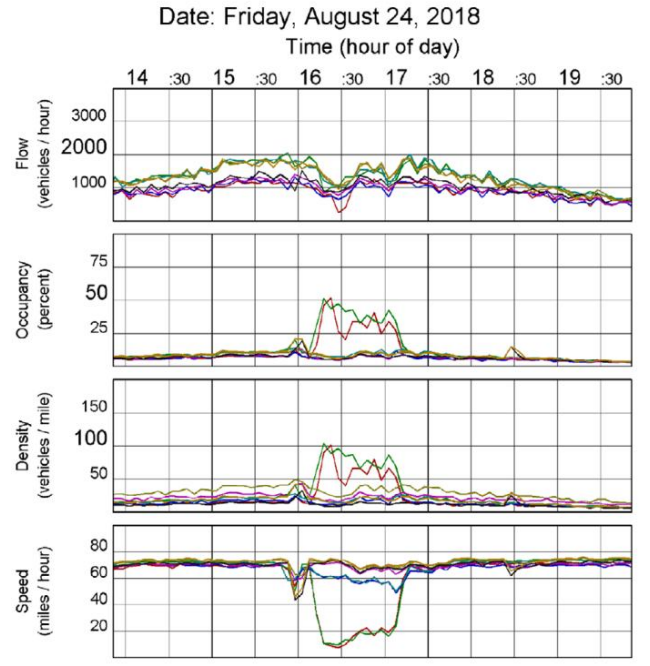
En segundo lugar, cuando ocurre un accidente, la densidad y la velocidad de los automóviles se ven afectadas en ambas direcciones del lugar del accidente [42]. Los patrones que se generan para la velocidad y la densidad a veces se modelan mediante distribuciones simples, por ejemplo, distribución normal o lognormal, y a veces mediante modelos más complejos dependiendo de la importancia de los detalles en la simulación [43]. Si hay sensores de conteo de tráfico instalados en la región donde ha ocurrido un accidente, estos sensores podrían capturar los patrones si su tasa de muestreo es suficientemente alta. La Figura 3 muestra los patrones de velocidad, densidad, ocupación y flujo capturados por ocho sensores adyacentes después de la ocurrencia de un accidente (Figura 3(a)) y un atasco de tráfico en hora punta (Figura 3(b)) en una autopista.

En la Figura 3(a) se aprecian claramente los patrones temporales y espaciales de un accidente . Esta figura ilustra las distintas características de los sensores en el lugar del accidente. Los sensores, representados por diferentes colores, están distribuidos espacialmente, y sus características muestran que la velocidad media de los vehículos en la zona del accidente se redujo drásticamente en el momento del mismo. Además, el accidente de tráfico afecta a los datos de los sensores durante un periodo de tiempo determinado, dependiendo de la naturaleza del accidente y las características del lugar. Los datos de tráfico son espaciotemporales; es decir, los parámetros de tráfico, como el flujo, varían tanto en el tiempo como en el espacio.

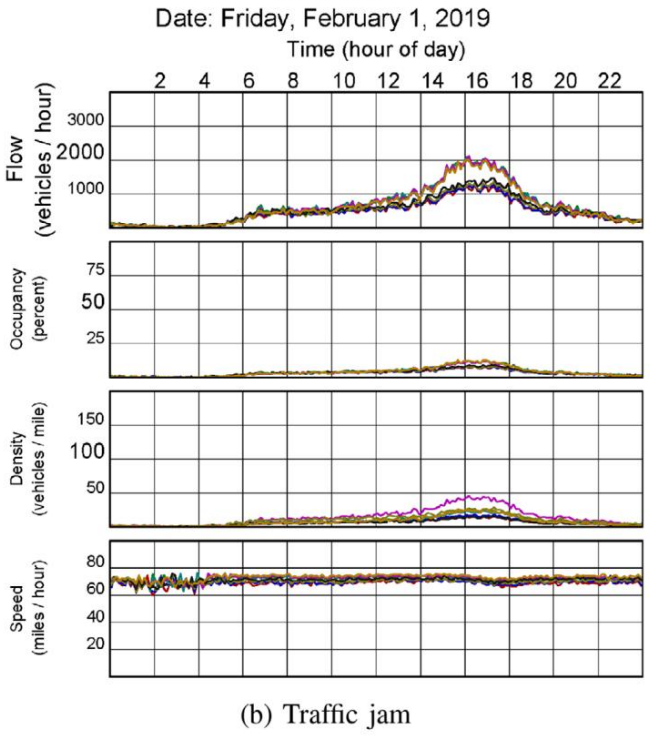
Por lo tanto, sería razonable considerar series temporales de datos de múltiples sensores adyacentes para detectar la ocurrencia de un accidente de tráfico [44]. Hay una diferencia importante entre un atasco de tráfico y un accidente, y es que son sus patrones espaciales. En un atasco de tráfico, causado por las horas pico del día, por ejemplo, todos los carriles de la autopista estarían congestionados, por lo tanto,

17519878, 2023, 3, Descargado de https://ietresearch.onlinelibrary.wiley.com/doi/10.1049/itr2.12287 por Cochrane Perú, Wiley Online Library el [02/05/2028]. Consulte los Términos y condiciones (https://onlinelibrary.wiley.com/terms-and-conditions) en Wiley Online Library para conocer las reglas de uso; los artículos de acceso abierto se rigen por la Licencia Creative Commons aplicable.

Machine Translated by Google



(a) Crash



(b) Traffic jam

FIGURA 3 Patrones de lectura de sensores antes y después de un accidente y un atasco de tráfico en hora punta que ocurrió a las 4:00 p. m. Cada color representa un sensor específico en las proximidades del lugar del accidente

Los parámetros de tráfico de todos los detectores de bucle fluctuarían simultáneamente, como se muestra en la Figura 3(b). Por el contrario, cuando ocurre un accidente Cuando esto ocurre, tiene un efecto exclusivo en cada uno de los detectores de bucle. lecturas. Por ejemplo, en la Figura 3(a), ocupación, densidad y La velocidad medida por dos de los detectores de bucle cambia significativamente después del choque, mientras que cambia solo ligeramente en el otro. dos.

La figura 4 muestra una descripción general de los pasos principales para detectar falla al observar los datos de 16 sensores adyacentes (ocho en cada uno) dirección) en intervalos de tiempo consecutivos. Este problema de clasificación se puede dividir en dos fases: fase de codificación y fase de clasificación. En la fase de codificación, una red neuronal Aprende qué características son más significativas para la clasificación. fase. Esta fase también elimina las correlaciones entre las características con el fin de reducir la dimensión de los datos y obtener una más espacio de características eficiente. Al crear un espacio de características con mejor separabilidad, este paso es crucial en aplicaciones con características complejas. datos. Demostraremos que la red propuesta es capaz de aprender automáticamente las características eficientes comparando las características. espacios antes y después de la codificación. Dado que LSTM tiene una alta capacidad para manejar datos de series temporales, lo incorporamos en nuestro estudio para la fase de codificación. Es evidente en la Figura 3 que los accidentes crear patrones espaciotemporales en los parámetros de tráfico de tal manera que Los datos de los detectores de bucle se ven afectados tanto por el tiempo como por el espacio. Además, estos patrones pueden verse como secuencias, es decir, cuando Los accidentes ocurren, el flujo aumenta con el tiempo y luego permanece constante. y luego se reduce con el tiempo. Cualquier red tiene que aprender estos patrones para poder detectar los accidentes. Las LSTM son capaces de aprender tales dependencias por diseño y se utilizan ampliamente para secuencias de procesamiento.

Otras redes neuronales de memoria, como las redes neuronales recurrentes simples (RNN), no son tan adecuadas para la detección de accidentes. ya que no tienen dependencias a largo plazo de anteriores muestras. Esto se debe al problema del desvanecimiento del gradiente que aparece en retropropagación a través del tiempo. En nuestro estudio, también Codificar el espacio de características utilizando una red neuronal convolucional. (CNN) y otros métodos convencionales para comparar la capacidad de la red propuesta para codificar el espacio de características con la suya. Una breve explicación de los métodos de remuestreo y codificación es Se proporciona en las siguientes secciones.

En la fase de clasificación, la red aprende a clasificar correctamente detectar un accidente de tráfico utilizando las funciones proporcionadas por el fase de codificación. Esta fase se puede implementar utilizando diversas redes neuronales artificiales, como el perceptrón multicapa. (MLP), red neuronal probabilística (PNN) y base radial red de función (RBF). En nuestro estudio, utilizamos la MLP para la tarea de clasificación por varias razones; a diferencia de las redes RBF, las MLP son más fáciles de entrenar y también pueden clasificar no convexas. espacios de características. Además, a diferencia de las PNN que son de alimentación directa. Las redes neuronales, MLP, se entrenan utilizando el algoritmo de retropropagación, por lo que pueden utilizarse en problemas complejos que tratan con Datos de alta dimensión. Nuestro algoritmo propuesto para accidentes La detección se resume en el Algoritmo 1.

Primero, descartamos los fallos que no se han producido en el autopista objetivo, por ejemplo, accidentes en las carreteras que están muy cerca o se cruzan con la autopista. Este paso es necesario ya que el accidente El conjunto de datos utilizado para el entrenamiento se genera en función de la ubicación GPS. En la práctica, para la ejecución del modelo entrenado, este paso se convierte en: innecesario ya que los datos de entrada se obtienen del detector de bucle Solo datos. También limpiamos los datos de los detectores de bucle defectuosos de acuerdo con los rangos aceptables indicados en los documentos. del MnDOT RTMC. El conjunto de datos contiene accidentes con diferentes niveles de gravedad que pueden crear diferentes espacios-temporales. patrones en los datos de los detectores de bucle. Para garantizar que la propuesta

17519578, 2023, 3, Descargado de https://ietresearch.onlinelibrary.wiley.com/doi/10.1049/itr2.12287 por Cochrane Perú, Wiley Online Library el [02/05/2028]. Consulte los Términos y condiciones (https://onlinelibrary.wiley.com/terms-and-conditions) en Wiley Online Library para conocer las reglas de uso; los artículos de acceso abierto se rigen por la Licencia Creative Commons aplicable.

Machine Translated by Google

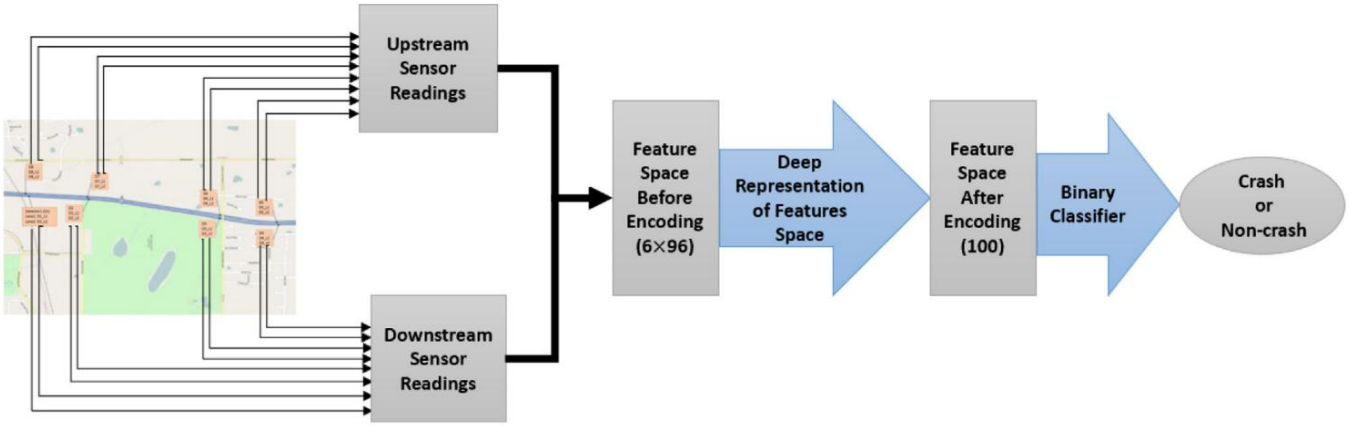


FIGURA 4. Descripción general de los pasos principales para la detección automática de accidentes en autopistas.

ALGORITMO 1 Algoritmo de detección de accidentes

Entrada: Datos brutos de los sensores (flujo, densidad, velocidad, capacidad, intervalo entre vehículos, ocupación)

Salida: Clase de muestra (fallo o no fallo)

1. Descartar fallos irrelevantes y limpiar datos,
2. Particionamiento de datos y división de datos de prueba y entrenamiento,
3 Normalización del conjunto de datos mediante la normalización Z (media cero y varianza unitaria),
4. Remuestreo de datos de entrenamiento,
5 Generación de series temporales,
6. Codificación del espacio de características mediante LSTM
7 Clasificar el espacio de características codificadas y determinar la probabilidad de colisión,
8 Compare la probabilidad de choque con un umbral para decidir si un ¿Ha ocurrido un accidente o no?

Para que el modelo pueda alcanzar el rendimiento deseado en la detección de todo tipo de accidentes, utilizamos la validación cruzada k-fold para dividir el conjunto de datos. De este modo, todos los tipos de accidentes quedarán incluidos en los datos de las pruebas. Tras normalizar los datos, se realiza un remuestreo para equilibrar el número de muestras en cada clase. En el sexto paso, codificamos las características espaciotemporales mediante LSTM para obtener un espacio de características más eficiente. Este paso es crucial, ya que reduce la dimensión de los datos y aumenta la separabilidad de las clases, lo que contribuye a una mayor tasa de detección. Finalmente, determinamos la probabilidad de colisión mediante una función sigmoide en la capa de salida de la red. Si la probabilidad de colisión de una muestra es superior a 0,5, se considera que ha ocurrido un accidente; de lo contrario, la muestra se clasifica como no colisión.

4.1 | Métodos de remuestreo

Los métodos de remuestreo se clasifican en métodos de submuestreo, métodos de sobremuestreo o una combinación de ambos. Los métodos de submuestreo equilibran el conjunto de datos reduciendo el tamaño de las muestras de la clase mayoritaria, mientras que los métodos de sobremuestreo lo equilibran aumentando el tamaño de las muestras de la clase minoritaria [45]. Algunos de estos métodos se explican a continuación.

- Vecino más cercano editado (ENN): En este método, se eliminan los puntos cuya etiqueta de clase es diferente de la mayoría de sus k vecinos más cercanos [46].

- Eliminación de enlaces de Tomek: En este método, los puntos que están próximos entre sí y pertenecen a clases diferentes, lo que se denomina enlace de Tomek, se eliminan del conjunto de datos. Como alternativa, se pueden eliminar únicamente los puntos que pertenecen a la clase principal del enlace de Tomek [46].

- Técnica de sobremuestreo sintético de la clase minoritaria (SMOTE): En este método, primero se calculan los k vecinos más cercanos del punto p que pertenecen a la clase minoritaria. Para generar un punto sintético para cada punto p, se elige aleatoriamente un punto de la clase minoritaria pz de entre los k vecinos más cercanos del punto p y luego se calcula el nuevo punto sintético de la siguiente manera [36]:

$$xnuevo = p + (pz - p) \quad (1)$$

donde es un número aleatorio en el rango [0,1]. Existen algunas variaciones de SMOTE, como SMOTE límite, SVM-SMOTE y muestreo sintético adaptativo (ADASYN), que se analizan en detalle en las referencias [46], [47] y [48].

- Métodos combinacionales: Estos métodos combinan diferentes métodos de remuestreo para mejorar la eficiencia en ciertos escenarios. Ejemplos de métodos combinacionales son SMOTE-ENN [46] y SMOTE-Tomek link removal [46].

4.2 Representación profunda de características

En este estudio, utilizamos LSTM para mapear las características de alta dimensión de los datos del detector de bucle a un nuevo espacio de características optimizado con características reducidas. LSTM consta de dos unidades principales: las compuertas y el estado de la celda. Las compuertas de entrada y salida permiten controlar las entradas y salidas de la celda, protegiéndola de perturbaciones irrelevantes [49]. Por otro lado, el estado de la celda permite un flujo de error constante a través de las unidades para evitar el problema del desvanecimiento del gradiente.

Hay tres operaciones principales en las compuertas de las celdas LSTM. En las compuertas de olvido y de entrada, se decide qué información debe eliminarse o almacenarse en el estado de la celda, respectivamente. Finalmente,

17519878, 2023, 3, Descargado de https://ietresearch.onlinelibrary.wiley.com/doi/10.1049/itr2.12287 por Cochrane Perú, Wiley Online Library el [02/05/2025]. Consulte los Términos y condiciones (https://onlinelibrary.wiley.com/terms-and-conditions) en Wiley Online Library para conocer las reglas de uso; los artículos de acceso abierto se rigen por la Licencia Creative Commons aplicable.

Machine Translated by Google

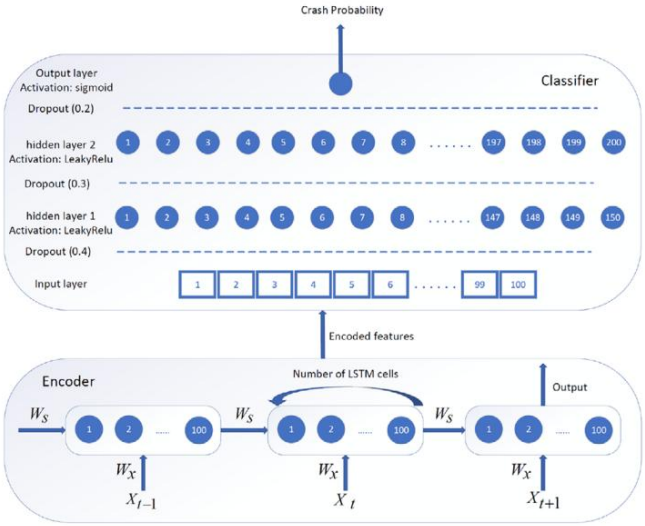


FIGURA 5 Arquitectura de red propuesta

En la puerta de salida, se decide qué va a emitir la celda de memoria [49]:

4.3 Arquitectura de red

Nuestra red propuesta incluye un codificador y un clasificador. Como se explicó anteriormente, utilizamos MLP como clasificador y LSTM como codificador. Cabe destacar que la red propuesta es similar a las conocidas redes LSTM y CNN; sin embargo, la dividimos en una parte de codificador y otra de clasificador para enfatizar que realiza dos tareas diferentes: aprendizaje de características y clasificación. En la Figura 5 se muestra una ilustración de la red propuesta.

La Figura 5 muestra las capas utilizadas en nuestra red propuesta con su tamaño y funciones de activación correspondientes. Hay tres tipos de capas en la red: capa LSTM, capas de abandono (dropout) y capas totalmente conectadas. La principal motivación para usar capas de abandono es evitar el sobreajuste del modelo. Hay algunas razones para elegir Leaky ReLU como función de activación de las capas totalmente conectadas. Primero, ReLU y Leaky ReLU no limitan las salidas de las capas, por lo que pueden reducir el efecto del problema de desaparición del gradiente. Segundo, el conjunto de datos está normalizado usando el método de normalización Z y contiene valores negativos. En consecuencia, al usar ReLU, algunas neuronas pueden estar inactivas independientemente de la entrada que se les proporcione, lo que impide el flujo del gradiente. Por lo tanto, es mejor usar Leaky ReLU en lugar de ReLU como función de activación. Como se muestra en la Figura 5, primero, el espacio de características de entrada se codifica usando LSTM y luego las características codificadas se pasan a las capas MLP totalmente conectadas. Cabe destacar que, dado que nuestro objetivo es detectar accidentes y no predecirlos, los datos de la serie temporal deben transmitirse al codificador en orden cronológico inverso; por ejemplo, la primera entrada al codificador sería el último segmento de tiempo.

En otras palabras, detectamos los accidentes después de que ocurren, por lo tanto, presentamos los datos a la red hacia atrás en el tiempo. El clasificador tiene dos capas ocultas, porque MLP tiene dos capas ocultas. Es más eficaz que una MLP con una capa oculta para clasificar espacios de características no convexos. La dimensión de cada capa del clasificador es mayor que la de la capa anterior, excepto la capa de salida, que solo tiene una neurona, ya que solo hay dos clases. El tamaño de cada capa se ha ajustado empíricamente; sin embargo, según el teorema de Cover, la separabilidad lineal del espacio de características aumenta en relación con la dimensión del espacio.

4.4 Entrenamiento del modelo

La red propuesta se entrena utilizando el algoritmo de retropropagación. Para abordar mejor el conjunto de datos desequilibrado y evitar el sobreajuste, utilizamos la función de pérdida de entropía cruzada binaria ponderada, tal como se expresa en la ecuación (2):

$$L(y, \quad y) = -\frac{1}{\text{norte}} \sum_{i=1}^{N} (w1 \quad yi \quad \log(\hat{y}i) + w2 \quad (1 - yi) \quad \log(1 - \quad yi)) \tag{2}$$

donde yi es la etiqueta verdadera de la i-ésima muestra, ŷi es la probabilidad predicha de accidente, N es el número de muestras, y w1 y w2 son los pesos de clase. Al asignar un peso alto a la clase menor que incluye muestras de accidentes, la red se esfuerza más por clasificar correctamente las muestras de esta clase. La penalización por predecir incorrectamente la etiqueta de estas muestras sería alta al entrenar la red usando retropropagación. En consecuencia, incluso cuando la red puede detectar correctamente las muestras que no son de accidentes, el valor de la función de pérdida no disminuirá, lo cual es deseable para el entrenamiento de la red.

4.5 Evaluación del modelo

En el problema de detección de colisiones, es posible lograr una alta precisión, aunque la tasa de verdaderos positivos sea baja debido al desequilibrio de clases. Sin embargo, es fundamental lograr una alta tasa de verdaderos positivos y una baja tasa de falsos positivos. Por lo tanto, nos centraremos principalmente en la sensibilidad y la especificidad al evaluar los modelo Como se explica en la Sección 3, para compensar cualquier error en el registro de eventos de colisión, consideramos un grado de flexibilidad (GdF) en el cálculo de la matriz de confusión. Al tener en cuenta el GdF, los verdaderos positivos (VP), los falsos negativos (FN), los verdaderos negativos (VN) y los falsos positivos (FP) se calculan de la siguiente manera:

$$\begin{aligned} TPj &= TPj{-}1 + 1 \text{ si } \{t(j) = 1 \text{ y } P > 0\} \\ FNj &= FNj{-}1 + 1 \text{ si } \{t(j) = 1 \text{ y } P = 0\} \\ TNj &= TNj{-}1 + 1 \text{ si } \{t(j) = 0 \text{ y } p(j) = 0 \text{ o } t(j) = 1 \text{ y } T > 0\} \\ FPj &= FPj{-}1 + 1 \qquad \text{si } \{t(j) = 0 \text{ y } p(j) = 1 \text{ y } T = 0\} \end{aligned} \tag{3}$$

dónde

$$P = \sum_{n = j \text{ - grados de libertad}}^{j+ \text{ Probabilidad de colapso}} p(n), \tag{4}$$

17519878, 2023, 3, Descargado de https://ietresearch.onlinelibrary.wiley.com/doi/10.1049/itr2.12287 por Cochrane Peru, Wiley Online Library el [02/05/2026]. Consulte los Términos y condiciones (https://onlinelibrary.wiley.com/terms-and-conditions) en Wiley Online Library para conocer las reglas de uso; los artículos de acceso abierto se rigen por la Licencia Creative Commons aplicable.

Machine Translated by Google

$$T = \sum_{n=\,j-DoF}^{j+\,DoF} t(n), \quad (5)$$

y t (j) y p(j) denotan la etiqueta verdadera y la etiqueta predicha de la j-ésima muestra, respectivamente. La sensibilidad determina la capacidad de la red para predecir correctamente las muestras de accidentes:

$$\text{Sensibilidad} = \frac{\text{Ciudad}}{TP + FN} \quad (6)$$

La especificidad determina la capacidad de la red para predecir correctamente las muestras que no corresponden a accidentes:

$$\text{Especificidad} = \frac{\text{Tennesse}}{TN + FP} \quad (7)$$

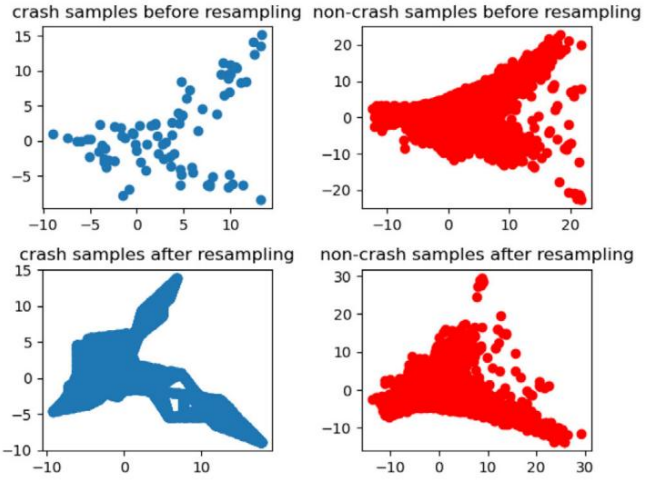


FIGURA 6 Datos de entrenamiento antes y después del remuestreo

5 RESULTADOS EXPERIMENTALES Y DISCUSIÓN

En esta sección, evaluamos el método de detección de accidentes basado en LSTM junto con otros métodos competitivos e informamos sobre su rendimiento desde varios aspectos. Para la fase de implementación del codificador, las redes se entrenan utilizando diferentes algoritmos de optimización, métodos de remuestreo, longitud de la serie temporal e intervalo de agregación de datos. Además, en esta sección se proporciona un análisis de la capacidad de la red basada en LSTM para codificar el espacio de características y una comparación entre la tasa de detección de esta red y otros clasificadores, incluidos CNN, PNN, AdaBoost y GradientBoost. Se aplica un procedimiento de validación cruzada de 5 pliegues a los datos recopilados de los sensores del sitio que se muestra en la Figura 1, de manera que los datos se dividen en cinco particiones aleatoriamente, y cada vez, cuatro de las particiones se utilizan para el entrenamiento y la otra para la prueba. En el proceso de prueba, se genera una matriz de confusión para mostrar el número de accidentes correctamente identificados y falsas alarmas. Se informa la precisión, sensibilidad y especificidad promedio de los cinco pliegues para tener criterios de evaluación imparciales.

5.1 Rendimiento del modelo con diferentes algoritmos de optimización y métodos de remuestreo.

En esta sección, nos centramos únicamente en el rendimiento de los métodos de remuestreo y los algoritmos de optimización. El impacto de otros factores significativos, como la longitud de la serie temporal, se limita ajustándolos a su mejor disposición posible. El primer paso tras el preprocesamiento del conjunto de datos de accidentes es el remuestreo de los datos de entrenamiento para abordar su desequilibrio. Para ello, debemos determinar qué método de remuestreo es más adecuado para el caso de estudio. Para observar el impacto del remuestreo en los datos de entrenamiento, la Figura 6 muestra una visualización bidimensional del espacio de características antes y después del remuestreo mediante análisis de componentes principales (PCA).

Como se explica en la Sección 4, los métodos de remuestreo equilibran el conjunto de datos aumentando las muestras de la clase menor y/o reduciendo ing las muestras de la clase principal. Por eso se han generado algunas muestras de choque como el punto con coordenadas (−10, −5) y algunas muestras que no son de choque han desaparecido como el punto con coordenadas (20, −20). Cabe señalar que también hay algunos valores atípicos generados por los métodos de remuestreo como el punto con coordenadas (10, 30) en las muestras que no son de choque. Se debe determinar qué método de remuestreo funciona mejor en nuestro problema. Para ello, se realiza una comparación entre los resultados de los modelos entrenados con diferentes datos de entrenamiento remuestreados.

Los resultados de los dos mejores modelos (LSTM y CNN) se muestran en la Figura 7. Cabe destacar que los métodos de remuestreo generan datos artificiales, por lo que podrían no ser realistas. Sin embargo, equilibran el conjunto de datos y eliminan el sesgo hacia la clase mayoritaria. Para obtener resultados fiables, hemos dejado los datos de prueba intactos en todos los experimentos.

Como se ilustra en la Figura 7, ADASYN y SMOTE tienen mejor sensibilidad y especificidad en comparación con los otros métodos.
Aunque ADASYN supera a todos los demás métodos en términos de sensibilidad, su especificidad es demasiado baja, lo que aumenta drásticamente el número de falsas alarmas. SMOTE, en cambio, presenta un buen equilibrio entre precisión, sensibilidad y especificidad. Por lo tanto, SMOTE se utilizará para remuestrear los datos de entrenamiento en las siguientes partes. Se observa que una alta precisión no garantiza una alta sensibilidad debido al bajo número de muestras de accidentes. La sensibilidad es una buena métrica para medir la capacidad de la red para clasificar accidentes, pero no proporciona información sobre la tasa de falsas alarmas. Por consiguiente, se requiere la especificidad para medir la capacidad de la red para clasificar muestras que no corresponden a accidentes. Así pues, las siguientes evaluaciones se basarán únicamente en la sensibilidad y la especificidad.

El siguiente paso es decidir qué optimizador proporciona el mejor resultado. Para ello, evaluamos el rendimiento de los métodos de aprendizaje adaptativo y no adaptativo en nuestro caso de estudio de detección de accidentes. El descenso de gradiente estocástico (SGD) con momento se utiliza aquí para representar los métodos de aprendizaje no adaptativo. El motivo por el que utilizamos el momento es para acelerar el proceso de aprendizaje y escapar de los mínimos locales subóptimos de la función de pérdida. De ahora en adelante, nos referiremos al SGD con momento simplemente como SGD.

17519878, 2023, 3, Descargado de https://ietresearch.onlinelibrary.wiley.com/doi/10.1049/itr2.12287 por Cochrane Peru, Wiley Online Library el [02/05/2028]. Consulte los Términos y condiciones (https://onlinelibrary.wiley.com/terms-and-conditions) en Wiley Online Library para conocer las reglas de uso; los artículos de acceso abierto se rigen por la Licencia Creative Commons aplicable.

Machine Translated by Google

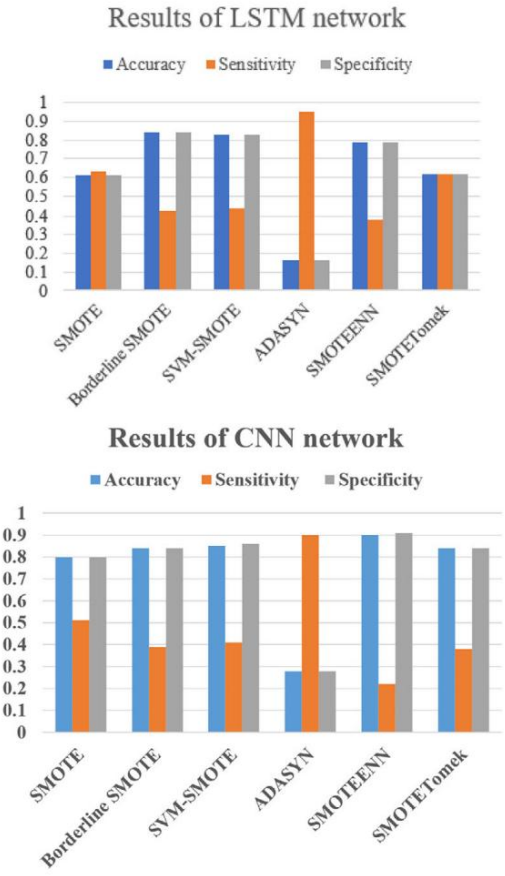


FIGURA 7 Resultados de los modelos basados en LSTM y CNN entrenados utilizando diferentes técnicas de remuestreo

La estimación (ADAM) [50] funciona bien en la práctica y se compara favorablemente con otros métodos de aprendizaje adaptativo como Adagrad [51], Adadelta [52] y RMSprop, por lo tanto, se elige para representar los métodos de aprendizaje adaptativo. El propuesto La red se entrena utilizando los optimizadores ADAM y SGD con un tasa de aprendizaje de 0,00001, momento de 0,8, tamaño del lote de 32, y un peso de clase de 1:100 durante 70 épocas. Los valores de estos Los hiperparámetros se han ajustado empíricamente y se utilizarán en todos los experimentos subsiguientes.

El bajo número de muestras de choques puede aumentar la posibilidad de sobreajuste en los modelos. Según la Tabla 1, La sensibilidad del modelo basado en LSTM se reduce drásticamente cuando utilizando el optimizador ADAM. Esto sucede porque SGD tiene una mejor capacidad de generalización en comparación con ADAM. SGD también es computacionalmente más eficiente que ADAM según los tiempos de entrenamiento informados en la Tabla 1. En las siguientes partes, usamos SGD como el optimizador seleccionado e informe los resultados de la evaluación para los demás criterios.

TABLA 1 Comparación de algoritmos de optimización para LSTM

	Exactitud	Sensibilidad	Especificidad	Tiempo de entrenamiento (s)
SGD	0,61	0,63	0,61	569
ADAM 0,73		0,37	0,73	581

5.2 Rendimiento del modelo con diferentes datos intervalos de agregación y longitud de la serie temporal

El tiempo de detección (TTD) es un aspecto importante de un accidente. modelo de detección. TTD es el tiempo que necesita el modelo para ser capaz de detectar un accidente después de que ocurra. Un valor TTD pequeño es esencial junto con una alta sensibilidad y especificidad en los modelos de detección de accidentes. Los parámetros clave que afectan al TTD son: intervalo de agregación de datos (DAI), longitud de la serie temporal (TSL) y grado de flexibilidad (DoF). El DAI es un parámetro ajustable en el Herramienta de extracción de datos. Tiene un impacto en la suavidad de las fluctuaciones en los datos de tráfico y, junto con TSL, determinan ¿Cuántas muestras temporales se requieren para detectar un accidente? Por otro lado, DoF tiene en cuenta el retraso del modelo en la detección. el tiempo de accidente que puede ser impuesto por un choque inexacto registros en el conjunto de datos.

Según la Figura 8, la especificidad y la sensibilidad de la El modelo basado en LSTM aumenta con los grados de libertad. Esto es trivial ya que más Se aceptan detecciones retardadas a medida que aumenta la profundidad de campo. Ambos modelos han logrado una alta especificidad, por lo que la primera prioridad para determinar los valores óptimos de TSL y DAI es la sensibilidad. Echemos un vistazo en las parcelas con grados de libertad del mismo valor (es decir, grados de libertad = 1 o 6 o 12), Se puede concluir que los modelos entrenados con DAI más alto tienen mayor sensibilidad. Por lo tanto, debe haber una compensación entre TTD y sensibilidad de los modelos. Además, los valores de sensibilidad son funciones no monótonas decrecientes de TSL, por lo tanto, La longitud óptima de la serie temporal sería 6. Por lo tanto, compararemos la curva ROC (característica operativa del receptor) de los modelos en TSL = 6. Máxima sensibilidad y especificidad alcanzadas por la LSTM. El modelo que utiliza parámetros óptimos es 0,8 y 0,7, respectivamente.

5.3 | Capacidad en la codificación del espacio de características

Como se explicó anteriormente, la principal motivación para utilizar la red LSTM en nuestro estudio fue codificar las características espacio-temporales. y obtener un espacio de características más eficiente. En esta sección, van a demostrar la capacidad de esta red para codificar el espacio de características comparando la separabilidad de las clases en tres espacios de características: espacio de características original (antes de la codificación), espacio de características codificado con LSTM y espacio de características codificado con CNN. La razón por la que elegimos CNN para la comparación aquí es que la CNN también puede codificar las características espaciotemporales con Capas convolucionales 1D y pueden manejar datos de series temporales.

Para determinar la separabilidad de clases en cada espacio de características, medir la diferencia entre las distribuciones de muestras de accidentes y no accidentes utilizando distancias estadísticas bien conocidas como Métrica de Wasserstein, distancia de Bhattacharya y Jensen-Shannon divergencia (divergencia JS).

Para obtener las distribuciones, dividimos el rango de valores en muchos intervalos de igual ancho. Luego calculamos el número de muestras en cada intervalo cuyos valores están contenidos en ese intervalo. Finalmente, el número de muestras en cada contenedor se divide por el número total de muestras y el ancho del contenedor de modo que el área bajo el El histograma se integra a 1. En cada espacio de características, la estadística distancia entre las distribuciones de muestras de accidentes y no accidentes

17519578, 2023, 3, Descargado de https://ietresearch.onlinelibrary.wiley.com/doi/10.1049/itr2.12287 por Cochrane Peru, Wiley Online Library el [02/05/2028]. Consulte los Términos y condiciones (https://onlinelibrary.wiley.com/terms-and-conditions) en Wiley Online Library para conocer las reglas de uso; los artículos de acceso abierto se rigen por la Licencia Creative Commons aplicable.

Machine Translated by Google

17519678, 2023, 3, Descargado de https://ietresearch.onlinelibrary.wiley.com/doi/10.1049/itr2.12287 por Cochrane Perú, Wiley Online Library el [02/05/2028]. Consulte los Términos y condiciones (https://onlinelibrary.wiley.com/terms-and-conditions) en Wiley Online Library para conocer las reglas de uso; los artículos de acceso abierto se rigen por la Licencia Creative Commons aplicable.

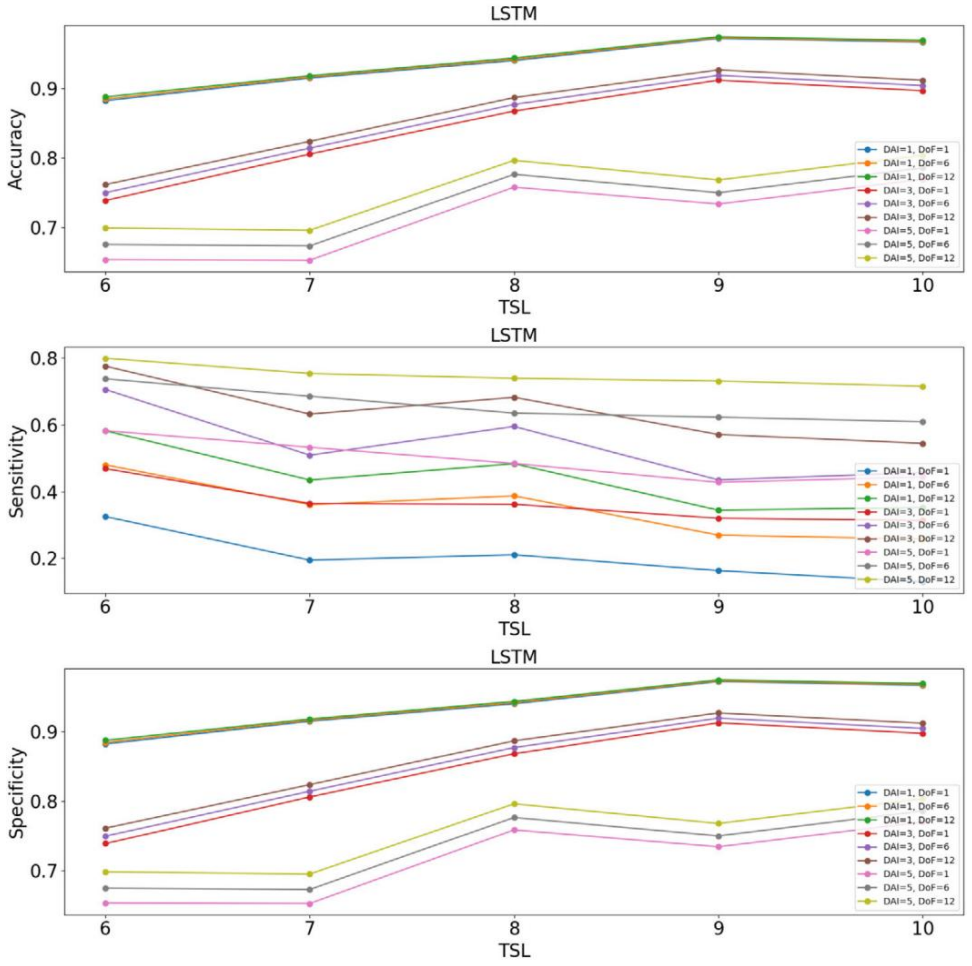


FIGURA 8 Rendimiento de LSTM para varios TSL, DAI y DoF

para cada característica se calcula y el promedio de distancias es informados. Los resultados se muestran en la Tabla 2. Distribuciones de muestras de choque y no choque para tres características aleatorias de cada El espacio de características se ilustra en la Figura 9. Según la Tabla 2 y en la Figura 9, es evidente que las distribuciones tienen mayor diferencia en el espacio de características codificadas con LSTM. Además, Dado que la distancia entre las distribuciones ha aumentado, puede Se puede inferir que la correlación entre las características también ha sido reducido automáticamente. Por ejemplo, el espacio de características original contenía características colineales como velocidad, flujo y densidad, cuyas correlaciones se reducen después de la codificación.

Según la Figura 1, en este caso se utilizan datos de 16 sensores. estudio donde cada sensor proporciona seis características. Además, el En el estudio anterior, se determinó que el valor óptimo de TSL era seis. sección. Por lo tanto, cada muestra tendrá forma de (6,96) que contiene características espaciotemporales. Esto significa que la dimensión El espacio de características originales es 576. Por otro lado, como se muestra En la Figura 5, el codificador genera un espacio de características con una dimensión de 100. Se puede concluir que el codificador no solo aumenta la separabilidad de clases en el espacio de características, pero también reduce la dimensión de los datos.

TABLA 2 Métricas para la separabilidad de clases en cada espacio de características

	Wasserstein distancia (×10−5)(×10−5)(×10−5)	Bhattacharya distancia	divergencia de JS
Artículo original espacio	26	91	165
Característica codificada espacio con CNN	184	761	609
Característica codificada espacio con LSTM	409	1445	707

5.4 Comparación con otros artificiales métodos de inteligencia artificial (IA)

Algunos marcos han reportado un buen rendimiento utilizando otros métodos de IA pero en diferentes datos de entrada. Parsa et al. [20], para Por ejemplo, se ha informado de una precisión relativamente alta utilizando PNN. en datos de condiciones meteorológicas, accidentes y detectores de bucle. Por lo tanto, en esta sección comparamos el método basado en LSTM con

Machine Translated by Google

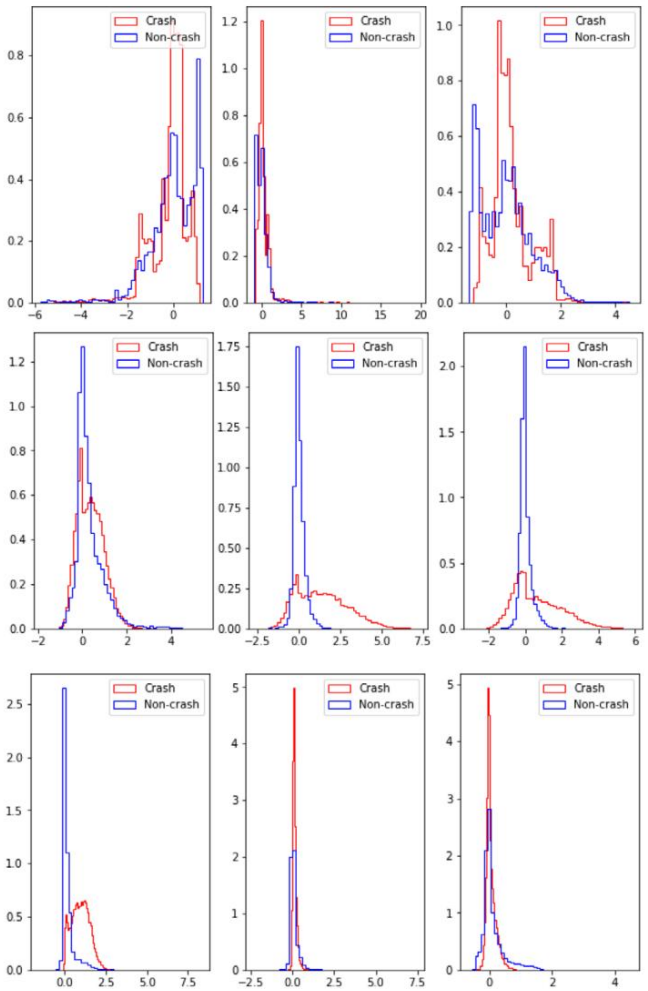


FIGURA 9 Distribuciones de muestras de choques y no choques para tres características aleatorias. La primera fila, la segunda fila y la tercera fila se relacionan con las características de espacio de características original, espacio de características codificado con CNN y característica codificada espacio con LSTM, respectivamente

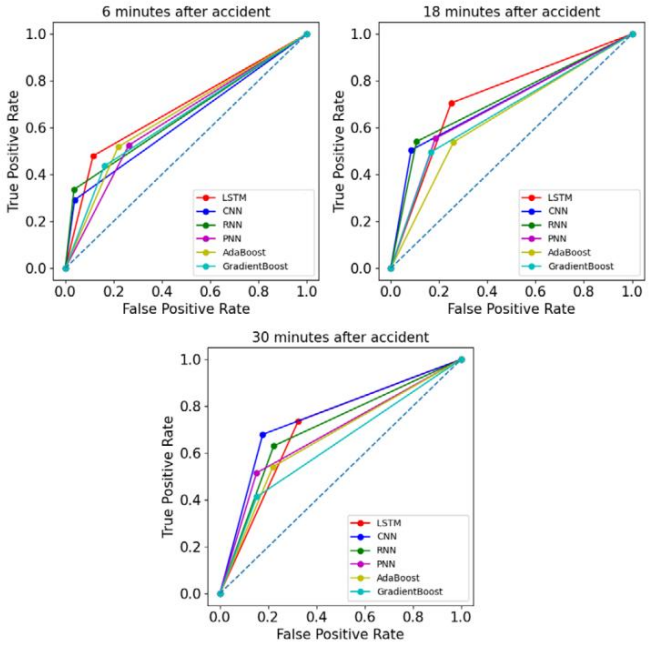


FIGURA 10 Comparación de las curvas ROC para diferentes codificadores

TABLA 3 Rendimiento de los codificadores para varios DAI

	6 minutos después			18 minutos después			30 minutos después	
	FPR	TPR	AUC	FPR	TPR	AUC	FPR	TPR AUC
LSTM	0,115	0,48	0,183	0,25	0,705	0,228	0,325	0,737 0,206
CNN	0,038	0,291	0,127	0,085	0,505	0,21	0,177	0,68 0,252
Red neuronal recurrente	0,036	0,336	0,15	0,107	0,541	0,217	0,223	0,63 0,204
NNP	0,263	0,525	0,130	0,184	0,554	0,185	0,152	0,516 0,182
AdaBoost	0,219	0,518	0,150	0,260	0,539	0,139	0,219	0,541 0,161
GradientBoost	0,162	0,436	0,137	0,167	0,496	0,165	0,153	0,413 0,130

otros métodos de IA que se consideran prometedores en otros accidentes estudios de detección. Para una comparación justa, implementamos todos Los modelos se probaron en el mismo sitio que se muestra en la Figura 1. que es un tramo de autopista sin rampas ni intersecciones. En teoría, la existencia de intersecciones o rampas interrumpirá el tráfico. fluye y hace que los escenarios sean más complicados. Para ser más precisos, El flujo de salida de la carretera no coincide con su flujo de entrada, lo que causa Los recuentos de las lecturas de los sensores en diferentes secciones serán diferentes. Sin embargo, dejamos estos otros escenarios del sitio para nuestro trabajo futuro. Para comparar el rendimiento de la red LSTM con otros métodos de aprendizaje profundo (incluidos CNN, PNN, Métodos RNN y de conjunto, incluidos AdaBoost [53] y Gra-dientBoost [54]), el mejor resultado de cada modelo probado en un variedad de métodos de muestreo, optimizadores y configuraciones de red Se informan las curvas ROC de cada método para TSL óptimo. (TSL = 6) y varios DAI se muestran en la Figura 10. El área bajo la curva (AUC), tasa de falsos positivos (FPR) y verdaderos positivos La tasa de verdaderos positivos (TPR) de la Figura 10 se representa en la Tabla 3. Al comparar el AUC de cada método, se puede concluir que LSTM está funcionando mejor a TTD más bajos. Además, TPR de estos

La actividad de las redes en DAI = 1 (6 minutos después de la detección) es notablemente baja. Por lo tanto, en nuestro estudio de caso, el DAI razonable sería 3 lo que significa que los resultados óptimos se obtienen al observar 18 minutos de datos del detector de bucle después de que ocurre un accidente. Vale la pena mencionar que los resultados para TTD más bajos aún pueden detectar patrones de accidentes con una precisión razonable. Sin embargo, para Con fines comparativos, informamos que han transcurrido 18 minutos desde que se registraron menos falsas alarmas. y en esta configuración se generan más resultados positivos verdaderos.

5.5 | Generalización del modelo

Como se concluyó en la parte anterior, LSTM funciona mejor en Se obtuvo un TTD más bajo y los resultados óptimos en DAI = 3. y TSL = 6. En esta parte, examinaremos la generalizabilidad del codificador LSTM entrenando la red utilizando óptimo parámetros y datos de dos sitios diferentes con características similares. La intención es demostrar que un modelo que se entrena en un sitio con características específicas en términos de tipo de carretera, número de carriles, número de sensores y distancias entre los sensores, pueden

17519878, 2023, 3, Descargado de https://ietresearch.onlinelibrary.wiley.com/doi/10.1049/itr2.12287 por Cochrane Perú, Wiley Online Library el [02/05/2028]. Consulte los Términos y condiciones (https://onlinelibrary.wiley.com/terms-and-conditions) en Wiley Online Library para conocer las reglas de uso; los artículos de acceso abierto se rigen por la Licencia Creative Commons aplicable.

Machine Translated by Google

17519578, 2023, 3, Descargado de https://ietresearch.onlinelibrary.wiley.com/doi/10.1049/itr2.12287 por Cochrane Perú, Wiley Online Library el [02/05/2028]. Consulte los Términos y condiciones (https://onlinelibrary.wiley.com/terms-and-conditions) en Wiley Online Library para conocer las reglas de uso; los artículos de acceso abierto se rigen por la Licencia Creative Commons aplicable.

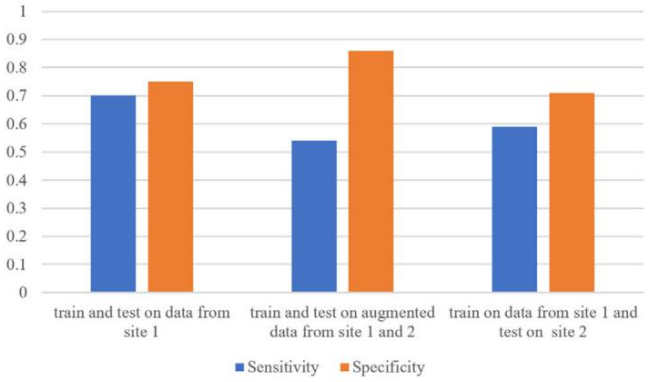


FIGURA 11 Generalización con datos aumentados y uso de un segundo sitio para la prueba

detectar accidentes en otros sitios con características similares.

Para ello, realizamos dos experimentos. En el primero, entrenamos la red utilizando datos del sitio 1 (mostrado en la Figura 1) y la probamos con datos de otro sitio (sitio 2) donde los sensores están colocados de forma similar al sitio 1. El sitio 2 tiene las mismas características que el sitio 1: ambos son tramos de una autopista bidireccional con rampas e intersecciones limitadas, dos carriles y 16 sensores detectores de bucle instalados. Las distancias entre los puntos donde se instalan los sensores no son exactamente iguales, pero sí de la misma escala. En el segundo experimento, entrenamos y probamos la red utilizando la combinación de datos acumulados de ambos sitios.

El primer experimento evalúa la capacidad del modelo para detectar patrones de accidentes en un sitio diferente de aquel en el que fue entrenado. Es obvio que el cambio en la distancia entre sensores afectará el rendimiento del modelo. Sin embargo, nos interesa saber cuán confiable puede ser el modelo cuando
se utiliza para monitorear un sitio diferente que tiene la misma estructura pero La disposición de los sensores es ligeramente diferente. El segundo experimento evalúa el modelo al exponerlo a datos de entrenamiento aumentados con los datos del segundo sitio descrito en el primer experimento. Aumentar los datos es una forma de incrementar la población de muestras en la clase con muestras insuficientes.
Sin embargo, se debe medir la sensibilidad del modelo a los datos aumentados.

La Figura 11 compara la sensibilidad y la especificidad de los tres experimentos para evaluar la generalización del modelo. Como era de esperar, la sensibilidad del modelo disminuye ligeramente en los experimentos que involucran el segundo sitio. La sensibilidad del modelo es ligeramente superior a 0,7 antes de incorporar los datos del segundo sitio. Este valor disminuye a 0,59 y 0,54 en el primer y segundo experimento, respectivamente. Sin embargo, la especificidad aumenta en el tercer experimento de 0,75 a 0,86, lo que significa que podemos prevenir significativamente la aparición de falsas alarmas mediante el uso de datos aumentados.

6. CONCLUSIÓN

Los sensores detectores de bucle, a pesar de sus datos ruidosos y su falta de una amplia cobertura espacial, están instalados en innumerables carreteras. Por lo tanto, desarrollar modelos que puedan producir una buena tasa de detección de incidentes utilizando estos sensores ayuda a los gobiernos, en una medida considerable, a obtener información valiosa hasta que las nuevas tecnologías comiencen a superar en número a los detectores de bucle en las carreteras. Utilizando datos de detectores de bucle, ilustramos que los accidentes pueden afectar los patrones de flujo de tráfico aguas arriba y aguas abajo del lugar del accidente. Capturar estos patrones en el flujo de tráfico y asociarlos a la ocurrencia de accidentes no es un problema de clasificación fácil. En este artículo, investigamos una representación profunda basada en LSTM de datos de flujo de tráfico espacio-temporales desequilibrados, obtenidos de sensores detectores de bucle, para estudiar el grado en que puede aumentar la separabilidad de la clase incidente/no incidente. Comparamos esta representación profunda basada en LSTM con otros métodos populares de IA como CNN, PNN, AdaBoost y Gradient-Boost, y mostramos que el método basado en LSTM aumenta la separabilidad de la clase en el espacio de características codificado, lo que resultó en una tasa de detección más alta y una tasa de falsa alarma más baja.

Un desafío clave fue la rareza de los eventos de accidentes de tráfico, lo que provocó que los conjuntos de datos de colisiones estuvieran muy desequilibrados. Exploramos diferentes técnicas de remuestreo para identificar un método adecuado para tratar los datos de accidentes heterogéneos. También exploramos diferentes configuraciones para la red LSTM como componente principal de codificación de características y aprendizaje de representación. El objetivo principal fue minimizar el tiempo de detección de los accidentes cuando ocurren. Los resultados indicaron que una configuración óptima para la longitud de la serie temporal y el intervalo de agregación de datos son 6 y 3 respectivamente. También demostramos que el marco basado en LSTM supera a otros métodos de IA comúnmente utilizados para detectar accidentes y reduce el tiempo de detección a tan solo 6 minutos después de que ocurran los choques. Se espera que este marco funcione mejor en escenarios en tiempo real ya que la marca de tiempo de los datos de accidentes pregrabados es errática. Hemos demostrado este hecho utilizando un parámetro DoF ajustable que toma en cuenta los patrones de flujo de accidentes tempranos y tardíos. Además, nuestros experimentos que prueban la generalización del modelo muestran que la medida de sensibilidad disminuye ligeramente cuando el modelo se utiliza en un sitio diferente a aquel para el que fue entrenado. Los posibles trabajos futuros pueden ser reducir aún más el tiempo de detección, aplicar este método a datos en tiempo real, mejorar la generalización del modelo y el aumento de datos, probar el modelo en partes de la autopista con rampas e intersecciones, y explotar otros métodos para mapear el espacio de características codificado a salidas de choque/no choque.

CONTRIBUCIONES DE LOS AUTORES Pouya

Mehrannia: Conceptualización, curación de datos, análisis formal, investigación, metodología, recursos, validación, visualización, redacción del borrador original. Shayan Shirahmad Gale Bagi: Análisis formal, metodología, software, visualización, revisión y edición. Behzad Moshiri: Supervisión, revisión y edición. Otman Al-Basir: Supervisión, revisión y edición.

AGRADECIMIENTO Los datos del
detector de bucle y el conjunto de datos de accidentes para esta investigación son proporcionados por el Departamento de Transporte de Minnesota, Oficina de Ingeniería de Tráfico.

Machine Translated by Google

INCOMPATIBILIDAD

Los autores declaran no tener ningún conflicto de intereses.

DECLARACIÓN DE DISPONIBILIDAD DE DATOS

Los datos que respaldan los hallazgos de este estudio están disponibles a través del autor correspondiente previa solicitud razonable.

ORCID

Pouya Mehrannia https://orcid.org/0000-0002-9567-685X Shayan Shirahmad Gale Bagi https://orcid.org/0000-0001-5773-3799 Behzad Moshiri https://orcid.org/0000-0002-8390-4093 Otman Adam Al-Basir https://orcid.org/0000-0002-6454-0538

REFERENCIAS

1. Organización Mundial de la Salud: Informe sobre la situación mundial de la seguridad vial 2018: Resumen. Organización Mundial de la Salud, Ginebra (2018).
2. White, J., Thompson, C., Turner, H., Dougherty, B., Schmidt, DC: Wreckwatch: detección y notificación automática de accidentes de tráfico con teléfonos inteligentes. Mobile Networks Appl. 16(3), 285 (2011)
3. Payne, HJ, Tignor, SC: Algoritmos de detección de incidentes en autopistas basados en árboles de decisión con estados. Transportation Research Board, Washington, DC (1978)
4. Dudek, CL, Messer, CJ, Nuckles, NB: Detección de incidentes en entornos urbanos Autopistas. Transp. Res. Rec. 495, 12–24 (1974)
5. Levin, M., Krause, GM: Detección de incidentes: un enfoque bayesiano. Transp. Res. Rec. 682, 52–58 (1978)
6. Ahmed, S., Cook, AR: Aplicación de técnicas de análisis de series temporales a la detección de incidentes en autopistas. Transportation Research Board, Washington, DC (1982)
7. Khan, SI, Ritchie, SG: Clasificadores estadísticos y neuronales para detectar problemas operativos de tráfico en arterias urbanas. Transp. Res. Part C: Emerg. Tecnología 6(5–6), 291–314 (1998)
8. Zhang, K., Taylor, MA: Hacia algoritmos transferibles de detección de incidentes. J. East. Asia Soc. Transp. Stud. 6, 2263–2274 (2005)
9. Hoose, N., Vicencio, M., Zhang, X.: Detección de incidentes en carreteras urbanas mediante procesamiento de imágenes por computadora. Traffic Eng. Control 33(4), (1992)
10. Zifeng, J.: Métodos de detección automática de incidentes (AID) en autopistas macro y micro basados en procesamiento de imágenes. En: Actas de la Conferencia sobre Sistemas de Transporte Inteligentes, págs. 344–349. IEEE, Piscataway, NJ (1997)
11. Rong, Y., Guoxiang, W., Zheng, J., Haiyan, W.: Reconocimiento de patrones de condiciones de tráfico vial urbano basado en máquinas de vectores de soporte. J. Transp. Syst. Eng. Tecnología de la Información 13(1), 130–136 (2013)
12. Zhang, K., Taylor, M.: Un nuevo método para la detección de incidentes en vías arteriales urbanas. Transportation Research Board, Washington, DC (2004)
13. Abdulhai, B., Ritchie, SG: Mejora de la universalidad y transferibilidad de la detección de incidentes en autopistas mediante una red neuronal basada en Bayesian. Transp. Res. Parte C: Tecnologías Emergentes 7(5), 261–280 (1999)
14. Adeli, H., Karim, A.: Modelo RBFNN de wavelet difusa para incidentes en autopistas detección. J. Transp. Eng. 126(6), 464–471 (2000)
15. Çetiner, BG, Sari, M., Borat, O.: Un modelo de predicción del flujo de tráfico basado en redes neuronales. Math. Comput. Appl. 15(2), 269–278 (2010)
16. Jin, X., Srinivasan, D., Cheu, RL: Clasificación de patrones de tráfico en autopistas para la detección de incidentes mediante redes neuronales probabilísticas constructivas. IEEE Trans. Redes Neuronales 12(5), 1173–1187 (2001)
17. Lu, J., Chen, S., Wang, W., van Zuylen, H.: Un modelo híbrido de mínimos cuadrados parciales y red neuronal para la detección de incidentes de tráfico. Expert Syst. Solicitud 39(5), 4775–4784 (2012)
18. Lee, D., Derrible, S., Pereira, FC: Comparación de cuatro tipos de redes neuronales artificiales y un modelo logit multinomial para la modelización de la elección del modo de transporte. Transp. Res. Rec. 2672(49), 101–112 (2018)
19. Bortnikov, M., Khan, A., Khattak, AM, Ahmad, M.: Reconocimiento de accidentes mediante CNNS 3D para el monitoreo automatizado del tráfico en ciudades inteligentes. En: Science and Information Conference, pp. 256–264. Springer, Cham (2019)
20. Parsa, AB, Taghipour, H., Derrible, S., Mohammadian, AK: Detección de accidentes en tiempo real: cómo lidiar con datos desequilibrados. Accid. Anal. Prev. 129, 202–210 (2019)
21. Qiu, J., Wu, Q., Ding, G., Xu, Y., Feng, S.: Un estudio sobre el aprendizaje automático para el procesamiento de macrodatos. EURASIP J. Adv. Signal Process. 2016(1), 1–16 (2016)
22. Yadav, DK, Anjum, I., et al.: Detección de accidentes mediante aprendizaje profundo. En: 2020 2nd International Conference on Advances in Computing, Com-munication Control and Networking (ICACCCN), pp. 232–235. IEEE, Piscataway, NJ (2020)
23. Deng, L., Yu, D.: Aprendizaje profundo: métodos y aplicaciones. Found. and Trends Signal Process. 7(3-4), 197–387 (2014)
24. Singh, D., Mohan, CK: Representación espaciotemporal profunda para la detección de accidentes de tráfico utilizando un autoencoder apilado. IEEE Trans. Intell. Sistema de Transacciones 20(3), 879–887 (2018)
25. Zhang, Z., He, Q., Gao, J., Ni, M.: Un enfoque de aprendizaje profundo para detectar accidentes de tráfico a partir de datos de redes sociales. Transp. Res. Part C: Emerg. Tecnología 86, 580–596 (2018)
26. Huang, X., He, P., Rangarajan, A., Ranka, S.: Intersección inteligente: redes neuronales convolucionales de dos flujos para la detección en tiempo real de incidentes cercanos a accidentes en vídeo de tráfico. ACM Trans. Spat. Algorithms Syst. (TSAS) 6(2), 1–28 (2020)
27. Ghosh, S., Sunny, SJ, Roney, R.: Detección de accidentes mediante redes neuronales convolucionales. En: Conferencia Internacional de 2019 sobre Ciencia de Datos y Comunicación (IconDSC), págs. 1–6. IEEE, Piscataway, NJ (2019)
28. Nikolaev, AB, Sapego, YS, Ivakhnenko, AM, Mel'nikova, TE, Stroganov, VY: Análisis de las tecnologías y algoritmos de detección de incidentes en sistemas de transporte inteligentes. Int. J. Appl. Eng. Res. 12(15), 4765–4774 (2017)
29. Amin, MS, Jalil, J., Reaz, MBI: Sistema de detección y notificación de accidentes mediante tecnología GPS, GPRS y GSM. En: Conferencia Internacional de Informática, Electrónica y Visión (ICIEV) de 2012, págs. 640–643. IEEE, Piscataway, NJ (2012)
30. Smruthi, K., Yashwanth, K., Vijayalakshmi, M.: Control inteligente de vehículos autónomos mediante un teléfono inteligente. Computación SN. Ciencia. 1(3), 1-10 (2020)
31. Lupinska Dubicka, A., Tabedzki, M., Adamski, M., Rybnik, M., Omieljanowicz, M., Szymkowski, M., et al.: Dispositivo de llamada de emergencia en el automóvil para la detección automática de accidentes, conteo de pasajeros y alarma. En: Transacciones en Ciencias Computacionales XXXV, pp. 36–57. Springer, Cham (2020)
32. Oorni, R., Goulart, A.: Servicios de llamada de emergencia en vehículos: ecall y más allá. IEEE Commun. Mag. 55(1), 159–165 (2017)
33. Katrakazas, C., Quddus, MA, Chen, WH: Clasificación en tiempo real de condiciones de tráfico agregadas mediante máquinas de vectores de relevancia. Transportation Research Board, Washington, DC (2016)
34. Ozbayoglu, M., Kucukayan, G., Dogdu, E.: Un modelo autónomo de detección de accidentes de autopista en tiempo real basado en el procesamiento de macrodatos e inteligencia computacional. En: 2016 IEEE International Conference on Big Data (Big Data), pp. 1807–1813. IEEE, Piscataway, NJ (2016)
35. Mujalli, RO, López, G., Garach, L.: Clasificadores bayesianos para conjuntos de datos de accidentes de tráfico desequilibrados. Acid. Anal. Evidence. 88, 37–51 (2016)
36. Chawla, NV, Bowyer, KW, Hall, LO, Kegelmeyer, WP: Smote: técnica de sobremuestreo de minoría sintética. J. Artif. Intel. Res. 16, 321–357 (2002)
37. Kaur, P., Gosain, A.: Comparación del comportamiento de los enfoques de sobremuestreo y submuestreo en el aprendizaje con desequilibrio de clases mediante la combinación del problema de desequilibrio de clases con ruido. En: Innovaciones basadas en TIC, págs. 23–30. Springer, Cham (2018)
38. Vanhoeyveld, J., Martens, D.: Clasificación desequilibrada en conjuntos de datos de comportamiento dispersos y extensos. Data Min. Knowl. Discov. 32(1), 25–82 (2018)
39. Wang, S., Cao, J., Yu, P.: Aprendizaje profundo para la minería de datos espaciotemporales: una revisión. IEEE Trans. Knowl. Data Eng. 34(8), 3681–3700 (2020)
40. Zhao, Z., Chen, W., Wu, X., Chen, PC, Liu, J.: Red LSTM: un enfoque de aprendizaje profundo para la predicción de tráfico a corto plazo. IET Intel. Transport Syst. 11(2), 68–75 (2017)

17519878, 2023, 3, Descargado de https://ietresearch.onlinelibrary.wiley.com/doi/10.1049/itr2.12287 por Cochrane Perú, Wiley Online Library el [02/05/2028]. Consulte los Términos y condiciones (https://onlinelibrary.wiley.com/terms-and-conditions) en Wiley Online Library para conocer las reglas de uso; los artículos de acceso abierto se rigen por la Licencia Creative Commons aplicable.

Machine Translated by Google

41. Departamento de Transporte de Minnesota, Oficina de Ingeniería de Tráfico: Sistema de registros de accidentes de Minnesota (2020). http://data.dot.state.mn.us/ datatools/ dataextract.html. Consultado el 14 de abril de 2020.
42. Golob, TF, Recker, WW: Un método para relacionar el tipo de accidente con las características del flujo de tráfico en autopistas urbanas. Transp. Res. Part A: Policy Pract. 38(1), 53–80 (2004)
43. Mehrannia, P., Moghadam, AA, Basir, OA: Un enfoque de fusión de sensores Dempster-Shafer para la detección y localización de incidentes de tráfico. En: 2018 21st International Conference on Intelligent Transportation Systems (ITSC), pp. 3911–3916. IEEE, Piscataway, NJ (2018)
44. Kordestani, M., Dehghani, M., Moshiri, B., Saif, M.: Un nuevo método de estimación por fusión para sistemas multisensor multivelocidad con mediciones faltantes. IEEE Access 8, 47522–47532 (2020)
45. Yuan, J., Abdel Aty, M., Gong, Y., Cai, Q.: Predicción del riesgo de colisión en tiempo real mediante una red neuronal recurrente de memoria a corto y largo plazo. Transp. Res. Rec. 2673(4), 314–326 (2019)
46. More, A.: Estudio de técnicas de remuestreo para mejorar el rendimiento de la clasificación en conjuntos de datos desequilibrados. arXiv:160806048 (2016)
47. Nguyen, HM, Cooper, EW, Kamei, K.: Sobremuestreo límite para la clasificación de datos desequilibrados. Int. J. Knowl. Eng. Soft Data Paradigms 3(1), 4–21 (2011)
48. He, H., Bai, Y., Garcia, EA, Li, S.: Adasyn: Enfoque de muestreo sintético adaptativo para el aprendizaje con datos desequilibrados. En: 2008 IEEE International Joint Conference on Neural Networks (IEEE World Congress on Computational Intelligence), pp. 1322–1328. IEEE, Piscataway, NJ (2008)
49. Hochreiter, S., Schmidhuber, J.: Memoria a corto y largo plazo. Neural Comput. 9(8), 1735–1780 (1997)
50. Kingma, DP, Ba, J.: Adam: un método para la optimización estocástica. arXiv:14126980 (2014)
51. Duchi, J., Hazan, E., Singer, Y.: Métodos de subgradiente adaptativos para el aprendizaje en línea y la optimización estocástica. J. Mach. Learn. Res. 12(7), 2121–2159 (2011)
52. Zeiler, MD: Adadelta: un método de tasa de aprendizaje adaptativa. arXiv:12125701 (2012)
53. Freund, Y., Schapire, RE: Una generalización de la teoría de la decisión del aprendizaje en línea y una aplicación al boosting. J. Comput. Syst. Sci. 55(1), 119– 139 (1997)
54. Friedman, JH: Aproximación de funciones voraces: un método de potenciación de gradiente máquina. Ann. Stat. 1189–1232 (2001)

Cómo citar este artículo: Mehrannia, P., Bagi, SSG, Moshiri, B., Al-Basir, OA: Representación profunda de datos de flujo de tráfico espacio-temporales desequilibrados para la detección de accidentes de tráfico. IET Intell. Transp. Syst. 17, 606–619 (2023). https://doi.org/10.1049/itr2.12287

17519578, 2023, 3, Descargado de https://ietresearch.onlinelibrary.wiley.com/doi/10.1049/itr2.12287 por Cochrane Perú, Wiley Online Library el [02/05/2028]. Consulte los Términos y condiciones (https://onlinelibrary.wiley.com/terms-and-conditions) en Wiley Online Library para conocer las reglas de uso; los artículos de acceso abierto se rigen por la Licencia Creative Commons aplicable.