Machine Translated by Google

Detección de eventos de tráfico extremos mediante un contexto aumentado autoencoder de grafos

YUE HU, AO QU, y DAN WORK, Universidad de Vanderbilt

La detección precisa y oportuna de grandes eventos en las redes de transporte urbano permite una gestión de la movilidad más informada. Este trabajo aborda el problema de la detección de eventos extremos en redes de transporte a gran escala utilizando datos de movilidad origen-destino, que actualmente están ampliamente disponibles. Dichos datos presentan una estructura compleja en el tiempo y el espacio, pero son de alta dimensionalidad y escasos. Los métodos actuales de detección de anomalías en series temporales multivariadas no logran abordar completamente estos desafíos. Para aprovechar la estructura de los datos de movilidad, formulamos el problema de detección de eventos de una manera novedosa: como la detección de anomalías en un conjunto de grafos ponderados dirigidos dependientes del tiempo. Además, proponemos un modelo de autoencoder gráfico con contexto aumentado (Con-GAE) para resolver el problema, que aprovecha las técnicas de incrustación de gráficos e incrustación de contexto para capturar los patrones espaciales y temporales.
Con-GAE adopta un marco de autoencoder y detecta anomalías mediante aprendizaje semisupervisado. El rendimiento del método se evalúa en varios conjuntos de datos de tiempos de viaje a escala urbana de Uber Movement, taxis de Nueva York y taxis de Chicago, y se compara con enfoques de vanguardia. El método Con-GAE propuesto logra una mejora en el área bajo la curva de hasta 0,15 con respecto al segundo mejor método. También se analizan anomalías de tráfico reales detectadas por Con-GAE.

Conceptos de CCS: • Computación aplicada → Transporte; • Sistemas de información → Sistemas espacio-temporales; Minería de datos;

Palabras clave y frases adicionales: detección de anomalías, transporte, red neuronal gráfica, autoencoder

Formato de referencia ACM:

Yue Hu, Ao Qu y Dan Work. 2022. Detección de eventos de tráfico extremos mediante un autoencoder gráfico con contexto aumentado. ACM Trans. Intell. Syst. Technol. 13, 6, Artículo 101 (septiembre de 2022), 23 páginas. https://doi.org/10.1145/3539735

1. INTRODUCCIÓN

La detección de eventos extremos ha sido una tarea de larga data en la ciencia del transporte [34] y está adquiriendo cada vez más importancia para la gestión del tráfico. Si no se maneja de manera eficiente, un evento extremo podría causar la interrupción de una gran parte de la red de tráfico urbano, en lugar de tener solo impactos localizados como es común en incidentes menores. La detección precisa y oportuna de tales anomalías de tráfico en toda la red puede ayudar con el análisis de resiliencia, así como con la mitigación de la congestión en tiempo real, lo que permite una gestión informada del tráfico urbano. Por lo tanto, el objetivo de este trabajo es

Este material se basa en un trabajo financiado por la Fundación Nacional de Ciencias bajo la subvención n.° CMMI-1727785.
Direcciones de los autores: Y. Hu y A. Qu, Universidad de Vanderbilt, 1025 16th Ave. S., Nashville, Tennessee, EE. UU., 37212; correos electrónicos: {yue.hu, ao.qu}@vanderbilt.edu; D. Work, Universidad de Vanderbilt, Nashville, Tennessee, EE. UU.; correo electrónico: dan.work@vanderbilt.edu.

Se concede permiso para realizar copias digitales o impresas de la totalidad o parte de esta obra para uso personal o en el aula, sin coste alguno, siempre que dichas copias no se realicen ni distribuyan con fines de lucro o ventaja comercial y que incluyan este aviso y la cita completa en la primera página. Los derechos de autor de los componentes de esta obra que pertenezcan a terceros deben respetarse. Se permite la elaboración de resúmenes con la debida atribución. Para cualquier otro tipo de copia, republicación, publicación en servidores o redistribución a listas, se requiere autorización previa específica y/o el pago de una tarifa. Solicite los permisos a permissions@acm.org. © 2022 Derechos de autor reservados por el/los propietario/s/autor/es. Los derechos de publicación se otorgan bajo licencia a ACM.
2157-6904/2022/09-ART101 $15.00
https://doi.org/10.1145/3539735

Machine Translated by Google

detectar eventos de tráfico extremos, que son anomalías que se manifiestan en grandes porciones de la red.
inmediatamente.

Hoy en día, la gran cantidad de datos de transporte facilita la monitorización del tráfico en tiempo real y la detección de anomalías, con la ayuda de técnicas de aprendizaje automático. Un área prometedora es la movilidad urbana, donde grandes flotas de vehículos instrumentados (por ejemplo, servicios de transporte compartido y taxis) recopilan abundante información de tráfico, que luego se procesa en datos de tiempo de viaje origen-destino (OD) y se pone a disposición del público para ayudar a los gestores de la movilidad urbana. Dada una ciudad dividida espacialmente en diferentes zonas, un registro de tiempo de viaje OD describe el tiempo de viaje desde la zona de origen del viaje hasta la zona de destino. Algunos ejemplos incluyen productos de datos de Uber Movement [47], conjuntos de datos de taxis en Chicago [10] y Nueva York [46], y datos de micromovilidad de operadores de bicicletas compartidas y patinetes (por ejemplo, Referencia [9]). Los datos de tiempo de viaje OD se organizan en una matriz de zona de origen por zona de destino, que a menudo está incompleta debido a la falta de registros.

A pesar de la creciente disponibilidad de datos OD, a menudo resulta difícil para los gestores de movilidad urbana utilizarlos directamente para la monitorización del rendimiento y la detección de eventos. El reto reside en cómo aprovechar al máximo las correlaciones espacio-temporales en la matriz OD del tráfico y, al mismo tiempo, superar la alta dimensionalidad y la extrema escasez de las matrices de datos OD comunes. En estudios anteriores, se han utilizado métodos robustos basados en la descomposición de matrices y tensores para separar el tráfico durante eventos extremos del tráfico normal [24, 43, 58]. Estos métodos aprovechan la correlación multidimensional del tráfico normal en el espacio y el tiempo, pero solo pueden modelar las correlaciones lineales de la dinámica de tráfico no lineal compleja. Con los recientes avances en la detección de anomalías en series temporales multivariadas basadas en aprendizaje profundo, una solución directa consiste en modelar los datos OD del tráfico como una serie temporal multivariada, donde el vector de características se compone aplanando todos los pares OD. Sin embargo, los métodos de detección de anomalías en series temporales disponibles actualmente [2, 33, 62] no pueden capturar la información espacial de la red de tráfico, ni pueden utilizar explícitamente la periodicidad a largo plazo (por ejemplo, diaria y semanal) presente en el tráfico habitual, ya que se basan principalmente en fluctuaciones a corto plazo. Intuitivamente, conocer las condiciones típicas del tráfico (por ejemplo, lunes a las 7 a. m.) resulta más útil para detectar una anomalía que conocer las condiciones del tráfico una hora antes.

Para abordar estos desafíos, proponemos un autoencoder de grafos con contexto aumentado (Con-GAE) que aprovecha las técnicas de incrustación de grafos e incrustación de contexto para capturar los patrones de la red de tráfico espacio-temporal. Modelamos las zonas de origen y destino como nodos en un grafo.
El patrón espacial se captura mediante capas convolucionales de grafos modificadas para tener en cuenta la asimetría en los tiempos de viaje. La periodicidad diaria y semanal de los datos se captura mediante una incrustación de contexto. Finalmente, Con-GAE adopta una estructura jerárquica para agregar las incrustaciones espaciales y temporales de la red de tráfico en cada intervalo de tiempo en una única incrustación gráfica integral, para detectar gráficos de anomalías contextualizados en el tiempo como un todo. Por diseño, nuestro modelo funciona con datos muy dispersos, ya que aprender a partir de pares OD parcialmente observados es esencialmente lo mismo que aprender las reglas comunes de paso de mensajes de una red neuronal convolucional gráfica (GCN) a partir de un subconjunto de todas las aristas. Es equivalente al aprendizaje de descenso de gradiente estocástico por minilotes, donde submuestreamos de todas las muestras para cada paso de actualización. Además, codificamos las características geográficas de cada nodo, que son más completas, para ayudar a estimar el tiempo de viaje. También observamos que nuestro método evita la alta dimensionalidad de la matriz OD, ya que no estamos considerando todas las entradas N2 en cada paso. En cambio, calculamos incrustaciones para cada nodo y los pesos de los bordes escasamente conectados (en el orden de O(N + E)) en cada momento, donde N es el número de nodos y E es el número de bordes.

Ofrecemos una descripción general de alto nivel de la estructura que permite a Con-GAE capturar completamente las correlaciones espaciales de los tiempos de viaje entre zonas. Intuitivamente, si dos zonas (por ejemplo, la zona A y la zona B) están cerca una de la otra en términos de tiempo de viaje (es decir, el tiempo de viaje de la zona A a la zona B es pequeño, y el tiempo de viaje de la zona B a la zona A es pequeño), entonces el tiempo de viaje de A a cualquier otra zona debería ser similar al tiempo de viaje de B a cualquier otra zona. Consideramos la proximidad física

Machine Translated by Google

Al utilizar información geográfica como características de los nodos de entrada, se considera la conexión del tiempo de viaje mediante los pesos de las aristas. Luego, Con-GAE aprende la representación vectorial de cada nodo a partir de la información del nodo y del peso, de manera que la zona A y la zona B tengan incrustaciones similares cuando están físicamente cerca o tienen tiempos de viaje similares. Las incrustaciones de los nodos se utilizan posteriormente para decodificar los pesos de las aristas, de modo que dos zonas de origen con incrustaciones similares darán lugar a tiempos de viaje similares a otros nodos de la red.

Nuestro trabajo se inspira en dos líneas de desarrollo recientes en aprendizaje profundo: las redes neuronales convolucionales de grafos y los detectores de anomalías basados en autoencoders. Las capas convolucionales de grafos en Con-GAE son una modificación de la GCN [27]. Dado un grafo, la GCN aprende una incrustación de los nodos que codifica información estructural sobre el grafo mediante la agregación de las incrustaciones de nodos vecinos. Si bien las capas GCN modificadas pueden capturar la estructura geométrica de la red, la naturaleza dinámica del tráfico requiere una mayor consideración de la dimensión temporal. Los trabajos existentes sobre grafos dinámicos [21, 68] se centran principalmente en modelar las dependencias a corto plazo de instancias consecutivas del grafo. En comparación, nosotros nos centramos en explotar la periodicidad temporal de los grafos de tráfico en horizontes temporales más largos, como patrones diarios o semanales. Hacemos hincapié además en que, si bien algunos enfoques detectan nodos y aristas anómalos en grafos dinámicos [61, 65], nuestra tarea de detección de eventos extremos requiere detectar el grafo anómalo en su conjunto, en lugar de una parte de un grafo como anomalía.

Con-GAE determina anomalías mediante un marco de autoencoder (AE) [38] para la detección de anomalías semisupervisada. Un AE consta de un codificador para comprimir la entrada de alta dimensión en un espacio de baja dimensión, y un decodificador para mapear la representación de baja dimensión de vuelta al espacio de entrada original minimizando el error de reconstrucción. Cuando se entrena solo con datos normales, se supone que el AE codifica y decodifica bien los datos normales, pero no los datos anómalos. Por lo tanto, durante las pruebas, las muestras con grandes errores de reconstrucción se marcan como anomalías. Los detectores de anomalías basados en AE han demostrado éxito en varias tareas de detección de anomalías de alta dimensión [11, 56, 66]. Aquí, especializamos la arquitectura de red AE para explotar la estructura espacio-temporal en los datos de movilidad. También observamos que, como se muestra en la Referencia [7], en los casos en que no tenemos acceso a datos de entrenamiento limpios, el detector de anomalías basado en reconstrucción también puede tolerar una pequeña porción de anomalías en los datos de entrenamiento. Dado que los datos de entrenamiento están dominados por datos normales y los datos anómalos son escasos, el modelo capturará los patrones normales y será incapaz de aprender los patrones anómalos presentes en los datos. Utilizamos experimentos para demostrar la robustez de nuestro modelo ante las anomalías que aparecen en los datos de entrenamiento.

Demostramos la eficacia de nuestro modelo en varios conjuntos de datos reales a gran escala. Aplicamos Con-GAE a conjuntos de datos de tiempo de viaje origen-destino de Uber Movement, taxis de Nueva York y taxis de Chicago para detectar dos tipos de anomalías sintéticas: grandes anomalías espaciales que afectan a la red y condiciones de tráfico que, si bien son normales, no lo son para el momento dado. Estas anomalías temporales se producen, por ejemplo, debido a días festivos. Variamos la magnitud de las anomalías y el número de instancias anómalas, y demostramos que nuestro modelo supera a varios métodos de referencia de última generación para la detección de anomalías de alta dimensión o espacio-temporales. Finalmente, mostramos cómo el modelo revela la influencia de un evento real a gran escala contenido en el conjunto de datos.

En resumen, nuestras contribuciones son las siguientes:

- Formulamos el problema de la detección de anomalías en conjuntos de datos OD de movilidad de una manera novedosa, como la detección de anomalías en un conjunto de grafos dirigidos ponderados dependientes del tiempo. Cada grafo contiene información geográfica en las características de los nodos e información sobre el tiempo de viaje en los pesos de las aristas.
- Proponemos Con-GAE, un detector de anomalías basado en autoencoders. Con-GAE utiliza capas GCN para generar incrustaciones de nodos que capturan las relaciones espaciales e incrustaciones temporales para capturar la periodicidad temporal.

Machine Translated by Google



(a) Traffic network graph (b) Weighted adjacency matrix

Figura 1. Ilustración del grafo de movilidad origen-destino (izquierda) y la matriz de adyacencia ponderada correspondiente (derecha), que representa los tiempos de viaje inversos escalados entre los puntos del grafo. La matriz de adyacencia ponderada puede ser muy dispersa debido a la falta de datos en todos los pares origen-destino.

- Realizamos experimentos con conjuntos de datos de movilidad OD y demostramos que Con-GAE supera a varios métodos de detección de anomalías de última generación.

2. METODOLOGÍA

En esta sección, primero modelamos la red de tráfico como un grafo y formulamos el problema de detección de anomalías. Luego, analizamos las estructuras del codificador y decodificador del grafo. Finalmente, abordamos la función de pérdida y las estrategias de regularización utilizadas.

2.1 Modelado de datos de movilidad como un grafo

Resumimos la matriz origen-destino que contiene los datos de movilidad e introducimos el modelo de grafo de estos datos. A continuación, formulamos el problema de detección de anomalías en el grafo.

Una matriz origen-destino (OD) es una forma de resumir un tipo común de datos de transporte en el que se almacenan los tiempos de viaje entre diferentes regiones de una ciudad. Concretamente, en nuestro caso, la ciudad se divide espacialmente en n zonas geográficas diferentes (por ejemplo, un barrio o un distrito censal). Cada zona sirve tanto de origen, donde comienzan los viajes, como de destino, donde finalizan.
En un momento dado, existen un total de n × n tiempos de viaje desde cada zona de origen a cada una de las demás zonas de destino (incluidos los viajes que comienzan y terminan en la misma zona). Por lo tanto, la matriz OD es una matriz M de n × n en la que el elemento mi,j denota el tiempo de viaje desde la zona de origen i a la zona de destino j.

Los datos OD se pueden modelar como un conjunto de grafos dirigidos ponderados dependientes del tiempo. En un instante discreto t {1, 2,...,T } = ,T, el grafo se denota como G(t) = (V, E(t), W(t)). El conjunto de nodos V es invariante en el tiempo y representa las N = |V| zonas geográficas distintas de la ciudad. Existe una arista eij E(t) si se dispone de información sobre el tiempo de viaje desde el nodo vi V hasta vj V en el instante t. La matriz de adyacencia ponderada se denota como W(t) RN ×N, donde cada elemento wij (t) contiene el inverso escalado del tiempo de viaje desde el nodo vi hasta vj en el instante t, de modo que los valores mayores indican tiempos de viaje más cortos. La información geográfica de cada zona se resume en la matriz de características del nodo X RN ×d, que podría incluir, por ejemplo, la ubicación, el tamaño o el uso del suelo. En la Figura 1(a) se muestra un gráfico OD , y en la Figura 1(b) se ilustra la matriz de adyacencia W(t) correspondiente.

Nuestro objetivo es el siguiente. Dado un conjunto de grafos {G(t)|t T}, encontrar los tiempos anómalos ta T que corresponden a eventos a gran escala que interrumpen la red de transporte. Lo hacemos entrenando un autoencoder de grafos con contexto aumentado que codifica cada grafo como una incrustación de baja dimensión.

Machine Translated by Google

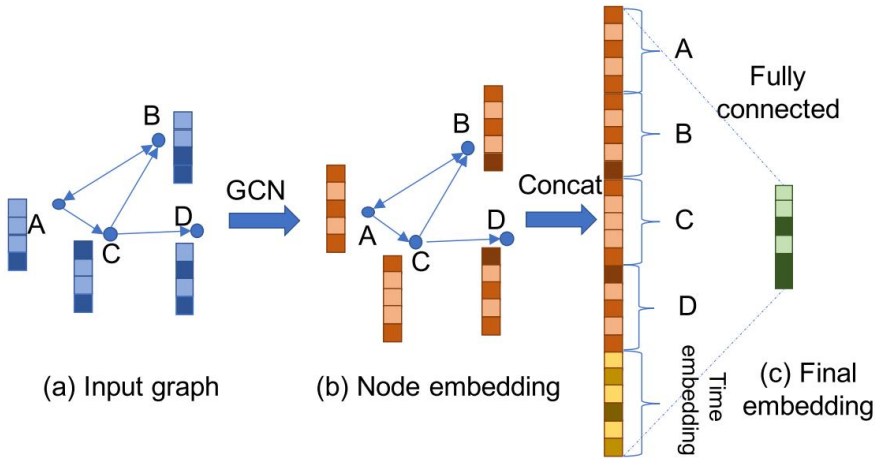


Figura 2. Ilustración del codificador. Primero aplicamos capas GCN para agregar las características de los nodos y el peso de las aristas.
información y calculamos la incrustación del nodo (b). Luego, concatenamos la incrustación del nodo y el tiempo
incrustación, y reducir aún más la dimensión de incrustación, para calcular la incrustación del grafo en su conjunto.
como en el panel (c).

condicionado a la información de tiempo, y decodifica la incrustación para minimizar el promedio
error de reconstrucción de la matriz de adyacencia ponderada W(t). El autoencoder se entrena solo en
datos normales, por lo que produce altos errores de reconstrucción cuando ocurren eventos.

2.2 Codificador

En resumen, el proceso de codificación consta de tres pasos, como se muestra en la Figura 2. Primero aplicamos GCN.
capas para codificar la estructura del grafo y la información de las características de los nodos, y aprender un vector de incrustación
para cada nodo en el grafo. También utilizamos una incrustación de tiempo distinta para cada hora del día y
cada día de la semana para capturar información temporal en la red. Las incrustaciones de nodos y
Las incrustaciones de tiempo se apilan en un vector, que se pasa a través de una capa totalmente conectada a
llegar a una incrustación gráfica de dimensión reducida.

En el primer paso, utilizamos una implementación modificada de GraphSAGE [22] de GCN para aprender el nodo
incrustación, mediante la agregación de la información de nodos adyacentes capa por capa. El número
de capas GraphSAGE apiladas decide cuántos saltos de información de vecindario se pasan a
cada nodo [15]. Sea Ni (t) el conjunto de vecinos del nodo i. GraphSAGE propaga el nodo vi
incrustación $h^l_i(t) \in \mathbb{R}^{d_l}$ en la capa l de la red para incrustar un $h^{l+1}(t) \in \mathbb{R}^{d_{l+1}}$ como

$$h^{l+1}(t) = \text{ReLU}\left(\text{Concatenar}\left(h^l_i(t), \text{Aggv}_{j \in N_i(t)} h^l_j(t)\right)\right), \tag{1}$$

donde $\hat{h}^{l+1}_i(t)$ es la incrustación de nodo no normalizada, Concat es el operador de concatenación y
Agg es un operador de agregación que se describe a continuación. El nodo normalizado vi incrustado en
La capa l + 1 se obtiene proyectando sobre la bola unitaria: $h^{l+1}_i(t) = \hat{h}^{l+1}_i(t)/\|\hat{h}^{l+1}_i(t)\|_2$.

Los operadores de agregación estándar de GraphSAGE [22] para aristas binarias no dirigidas agregan información
de las incrustaciones de los vecinos de vi mediante operaciones de media, agrupación máxima o LSTM.
Para tener en cuenta los bordes dirigidos ponderados que varían con el tiempo, aplicamos una agregación de media ponderada.
función. Tomamos Ni (t) como el conjunto de nodos j para los cuales existe una arista ponderada eji en el tiempo t.
Entonces, el operador de agregación de media ponderada se lee

$$\text{Aggv}_{j \in N_i(t)} h^l_j(t) := \frac{\sum_{j \in N_j(t)} w_{ji}(t) h^l_j(t)}{\sum_{j \in N_j(t)} w_j(t)}. \tag{2}$$

Machine Translated by Google

En el segundo paso, introducimos incrustaciones de contexto que capturan la periodicidad semanal y horaria de los datos de movilidad. Definimos el contexto como información adicional no contenida en los datos de movilidad.
Matriz OD sobre la cual se condicionan el codificador y el decodificador. En nuestro caso, utilizamos información temporal como contexto. El contexto se implementa concatenando dos vectores de longitud fija: uno es el la incrustación de la información del día de la semana, la otra es la incrustación de la hora del día.
Las incrustaciones capturan nuestro conocimiento previo de que las condiciones del tráfico en un momento específico del día o un día específico del día la semana debería ser similar. Observamos que nuestro método no considera la periodicidad estacional (es decir, patrones repetidos en los veranos en comparación con los inviernos), o patrones anuales, aunque tales extensiones se pueden explorar con conjuntos de datos más largos (en duración temporal). La incrustación de la hora es denotado como hhour Rdhour, con una incrustación por hora del día; de manera similar, la incrustación de la semana se denota como hweek Rdweek con una incrustación por día de la semana. Dado el grafo en el tiempo t (por ejemplo, martes 1 de septiembre a las 10 am), usamos la hhour correspondiente (es decir, 10 am) y hweek (es decir, martes). incrustación. Las entradas de cada vector de incrustación se inician a partir de una distribución normal i.i.d., Luego aprendió durante el tiempo de entrenamiento.

En el último paso, combinamos las incrustaciones de nodo y tiempo en una única em- de baja dimensión. El lecho de colchones se conecta mediante una capa totalmente unida:

$$\begin{aligned} h_{G}(t) &= \text{Concatenar}\left(hL_{1}(t), hL_{2}(t), \ldots, hL_{norte}(t), hhora(t), hsemana(t)\right), \\ hG(t) &= \text{ReLU}(UGh\ G(t)), \end{aligned} \tag{3}$$

donde hG (t) Rd es la incrustación final del grafo en el tiempo t, y UG Rd×(NdL+dweek+dhour) es el peso matriz.

2.3 Decodificador

El decodificador funciona de forma opuesta al codificador, como se muestra en la Figura 3. Primero calculamos la incrustación del nodo a partir de la incrustación del grafo. Luego, dado cada par de incrustaciones de nodos correspondientes vi y vj en el tiempo t, calculamos la entrada wij (t) en la matriz de adyacencia ponderada.

Condicionamos explícitamente la decodificación del grafo al tiempo mediante la concatenación de la incrustación del grafo. hG (t) con las incrustaciones de tiempo correspondientes. Luego se utiliza una capa totalmente conectada para recuperar una vector que contiene todas las incrustaciones de nodos:

$$\begin{aligned} h_{\text{ORIGEN}}(t) &= \text{ReLU}(U_{\text{ORIGEN}}\,\text{Concatenar}(hG(t), hhora(t), hsemana(t))), \\ \{h1(t), h2(t), \ldots, hN(t)\} &= \text{Desapilar}(h_{\text{ORIGEN}}(t)), \end{aligned} \tag{4}$$

que posteriormente se desapila para recuperar las incrustaciones de nodos individuales hi (t) RdL . El término EN_{ORIGEN} RNdL×(d+dweek+dhour) es una matriz de pesos que se va a entrenar.

Dado un par de nodos (vi,vj) y las incrustaciones de nodos recuperadas correspondientes (hi (t),hj (t)), Utilizamos un predictor de peso de arista para recuperar el peso de arista wij (t). Nótese que el predominantemente Se utilizó el predictor de borde GAE wij = σ (hT i hj) [26] no se puede adoptar aquí, porque produce resultados simétricos para wij y wji . Debido a que el gráfico correspondiente a los datos de movilidad es dirigido, Forzar que wij y wji sean iguales introduciría sesgos. Un predictor bilineal wij = hT i Qhj con Q que se aprende también es popular para la decodificación asimétrica [57], pero es ligeramente más lento y realiza ligeramente peor en nuestros experimentos. En cambio, utilizamos una MLP parametrizada como predictor de peso, por primero concatenando las dos incrustaciones de nodos y luego aplicando capas totalmente conectadas:

$$\begin{aligned} wij(t) &= \text{ReLU}\left(U^{1}_{\text{decConcat}}(hi(t), hj(t))\right), \\ En_{ij}(t) &= \sigma\left(U^{2}_{\text{decaimiento}}(t)\right), \end{aligned} \tag{5}$$

Machine Translated by Google

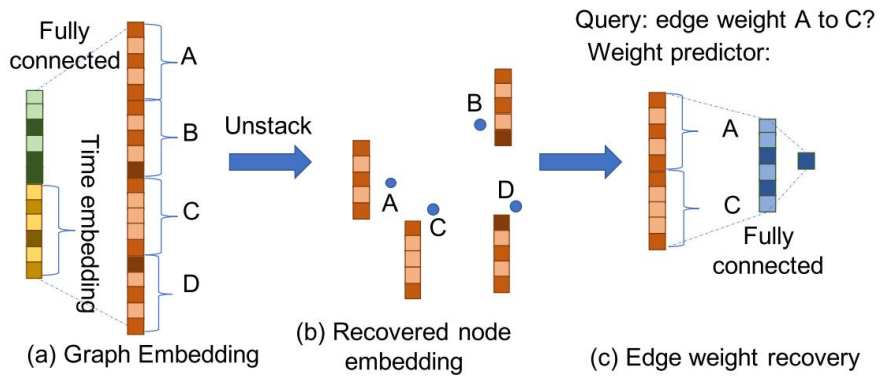


Figura 3. Ilustración del decodificador. Primero calculamos las incrustaciones de nodos a partir de la codificación del grafo condicionada al tiempo como en los paneles (a) y (b). Luego, para cada consulta del peso de la arista de un nodo a otro, usamos un predictor de peso para calcular a partir de las dos incrustaciones de nodos correspondientes (c).

donde U^1_{decide} $R^{de\times 2dL}$ y $U_{dec}(t) \in [0,1]^{2}$. $R^{1\times de}$ son matrices de pesos. La capa sigmoide final σ garantiza En ij

2.4 Función de pérdida

Utilizamos el error cuadrático medio (ECM) entre las entradas del original y recuperado.
matrices de adyacencia ponderadas como función de pérdida. Para una instancia de grafo G(t) en el tiempo t, la pérdida lecturas de funciones

$$L(t) = \frac{1}{|E(t)|}(w_{ij}(t) - \hat{w}_{ij}(t))^2 . \quad (6)$$

Utilizamos el optimizador Adam [25] para minimizar la función de pérdida de la ecuación (6) para las instancias de entrenamiento. en minilotes. Durante el entrenamiento, se actualizan los valores de las incrustaciones de tiempo $U^1_{dic,}$ $U^2_{dic,}$ las 24 horas y las 7 1,...,U L,UG,U ,U dec,U hweek . Durante las pruebas, la función de pérdida de la ecuación (6) para cada prueba La instancia se utiliza como su puntuación de anomalía.

2.5 Regularización

Para regularizar durante el entrenamiento, realizamos un dropout de aristas antes de alimentar los datos del grafo a Con-GAE, eliminando aleatoriamente aristas del conjunto de aristas E(t) con probabilidad pe_drop. Arista El abandono (dropout) consiste en enmascarar una parte de los bordes y dejar que Con-GAE prediga los pesos de los bordes. sin ver los valores. Esto puede ayudar a mejorar la capacidad de generalización y obliga a Con-GAE. para aprender las relaciones entre nodos para predicciones correctas. También aplicamos dropout [41] con probabilidad pdrop en la salida de las capas GraphSAGE, así como en las incrustaciones temporales. Dropout Evita depender excesivamente de características específicas (como la incrustación temporal) que conducen a soluciones de reconstrucción óptimas a nivel local.

3 EXPERIMENTOS

Utilizamos tres conjuntos de datos de transporte del mundo real a gran escala para evaluar Con-GAE. Los experimentos incluir: (1) comparaciones de rendimiento de Con-GAE con otros métodos para análisis espacial y temporal detección de anomalías en términos de puntuación AUC y tiempo de ejecución; (2) un estudio de ablación para comprobar la contribución de cada componente de Con-GAE; (3) un estudio de sensibilidad de los hiperparámetros del modelo; (4) un análisis de robustez ante anomalías en los datos de entrenamiento; y (5) una demostración del mundo real. Rendimiento de Con-GAE. El código se puede encontrar en https://github.com/yuehu9/Con-GAE.

Machine Translated by Google

Tabla 1. Estadísticas del conjunto de datos

Conjunto de	Uber Movement NYC taxi Chicago taxi		
datos # Muestras de	4.331 4.344		2.880
gráficos Tiempo promedio de viaje (min)	5.3	14.8	13.4
Promedio de aristas por grafo	1.471	1.482	440

3.1 Conjunto de datos

Uber Movement [47] proporciona múltiples conjuntos de datos de movilidad disponibles públicamente, incluidos los tiempos de viaje de origen a destino por hora. Utilizamos datos de los dos primeros trimestres de 2019 (enero-Junio) en Nashville, TN para análisis, que son los datos más recientes disponibles. Los datos del primer trimestre se utilizan para entrenamiento, y los datos del segundo trimestre se utilizan para las pruebas. Observamos que se produjo un gran evento conocido durante el período del segundo trimestre en Nashville, es decir, el draft de la NFL del 25 al 27 de abril. En consecuencia, separamos El período de tres semanas que comprende el draft de la NFL, del 15 de abril al 1 de mayo, se utilizó para un estudio de caso cualitativo.

El conjunto de datos de taxis de la ciudad de Nueva York (NYC) [46] es un conjunto de datos de código abierto que registra recogidas y hora y lugar de entrega para cada viaje en taxi en la ciudad de Nueva York. Agregamos la información del viaje en matrices de tiempo de viaje origen-destino para zonas de taxis a una base horaria. Los datos del 1 de enero al 31 de marzo, El año 2019 se utiliza para la formación, y del 1 de abril al 30 de junio de 2019 se utiliza para las pruebas.

El conjunto de datos de taxis de Chicago [10] registra los viajes en taxi en la ciudad de Chicago y se procesa en de la misma manera que el conjunto de datos de taxis de Nueva York para obtener matrices de tiempo de viaje origen-destino en un base horaria. Los datos del 1 de enero al 31 de marzo de 2019 se utilizan para el entrenamiento, y del 1 al 30 de abril de 2019 es utilizado para pruebas.

La Tabla 1 muestra las estadísticas de los tres conjuntos de datos. Los gráficos de las distribuciones del tiempo de viaje se pueden se puede encontrar en el Material Suplementario. Para los tres conjuntos de datos, restringimos nuestro análisis a los superiores 50 zonas, que cubren al menos el 75% de todos los datos. Debido a la falta de disponibilidad de tráfico etiquetado a gran escala conjuntos de datos de anomalías, seguimos el enfoque de inyección de anomalías como en las referencias [1, 6, 17], y agregamos en eventos sintéticos para conjuntos de prueba.

3.2 Líneas de base

Comparamos nuestro método con modelos tradicionales y de última generación para la detección de anomalías que abarcan múltiples estrategias de detección. Las líneas base son: (i) un promedio histórico ingenuo (HA) enfoque que calcula una puntuación de anomalía como el error cuadrático medio entre todas las OD observadas empareja con el valor medio histórico en el día de la semana y la hora del día correspondientes, capturando así la periodicidad de los datos: (ii) un método robusto de recuperación y completitud de tensores (RTC) [24] que utiliza una descomposición tensorial de bajo rango para capturar correlaciones espacio-temporales y detectar valores atípicos; (iii) Un autoencoder [23] que utiliza MLP para el codificador y el decodificador; (iv) el esquema codificador-decodificador basado en redes de memoria a corto y largo plazo para la detección de anomalías (EncDec-AD) [33]; (v) un modelo de mezcla gaussiana de autoencoder profundo (DAGMM) [70]; (vi) un modelo estructurado profundo basado en RNN modelo basado en energía REBM [62]; y dos líneas base basadas en grafos: (vii) GCN [27]; y (viii) Graph-SAGE [22]. Los métodos basados en grafos GCN y GraphSAGE tienen una estructura codificador-decodificador para codificar cada nodo en un espacio de baja dimensión y, por lo tanto, puede servir como un autoencoder para anomalías detección. En el material complementario se puede encontrar una descripción de cada método.

3.3 Configuración del experimento

Consideramos dos tipos de anomalías: (i) anomalías espaciales, donde las condiciones del tráfico se desvían a partir de patrones espaciales normales, y (ii) anomalías temporales, donde las condiciones del tráfico siguen un patrón correcto patrón espacial, pero las condiciones no son típicas para la hora del día correspondiente.

Machine Translated by Google

Las anomalías espaciales se inyectan seleccionando primero aleatoriamente una fracción γ de intervalos de tiempo para contaminarlos. Para cada intervalo de tiempo contaminado, elegimos aleatoriamente una fracción α de los pares origen-destino y perturbamos el tiempo de viaje correspondiente mediante un factor extraído de una distribución uniforme U(−β, β). Las anomalías temporales se introducen seleccionando aleatoriamente una fracción γ de intervalos de tiempo y desplazando la hora asociada a los datos en 12 horas (por ejemplo, las 8 p. m. se convierten en las 8 a. m. y viceversa).

Elegimos generar anomalías sintéticamente debido a la falta de conjuntos de datos OD etiquetados del mundo real que puedan usarse para evaluar el rendimiento de la detección de anomalías de tráfico, a pesar de los conjuntos de datos OD que están surgiendo en los EE. UU. por parte de los principales proveedores de viajes compartidos. Es decir, las ciudades pueden obtener libremente datos históricos (escasos) de tiempo de viaje origen-destino, pero estos datos no han sido etiquetados con eventos pequeños o grandes que pudieron haber ocurrido durante el período en que se recopilaron. En consecuencia, para nuestro trabajo, seguimos un enfoque estándar de inyección de anomalías. De las diferentes estrategias de inyección de anomalías, la referencia [6] señala que superponer anomalías a datos normales proporciona datos de prueba más precisos que simular datos de prueba completamente desde cero. El trabajo de detección de anomalías de tráfico [17] utiliza un enfoque similar, que agrega perturbaciones a los datos de tráfico OD, y los valores se extraen de una distribución uniforme. En términos más generales, la distribución uniforme suele crear grandes corrupciones [17, 20]. En cuanto a las anomalías temporales, optamos por aplicar un desfase de 12 horas, ya que el patrón espacial del tráfico se mantiene físicamente correcto, dado que este patrón se da realmente en la ciudad. El desfase de 12 horas resulta interesante porque, por ejemplo, en un trayecto típico, los tiempos de viaje son direccionales; es decir, los viajeros entran en la ciudad por la mañana y salen por la tarde. El desfase debe ser lo suficientemente grande como para generar condiciones de tráfico distintas; en comparación, un desfase de una sola hora no suele provocar una anomalía. En resumen, estas anomalías presentan condiciones de tráfico reales, pero son inusuales para el momento en cuestión.

En los experimentos, la proporción y la magnitud de la contaminación se establecen para reflejar la suposición de que los eventos de gran magnitud son poco frecuentes, pero contaminan porciones relativamente grandes de la red. También variamos las proporciones y magnitudes de contaminación α, β y γ para comprobar el rendimiento de la detección de anomalías en diversos casos. Para cada caso, generamos aleatoriamente el conjunto de prueba cinco veces y calculamos el rendimiento promedio del modelo.

El área bajo la curva ROC (AUC) se utiliza como métrica para comparar los métodos. Para los métodos de aprendizaje profundo (es decir, Con-GAE, AE, DAGMM, EncDec-AD, REBM, GCN y GraphSAGE), la salida de una muestra dada es una puntuación de anomalía. Utilizando las puntuaciones de anomalía de las muestras de prueba, se calcula el AUC. Para RTC, la salida incluye un tensor disperso que contiene anomalías. La puntuación de anomalía se calcula utilizando la norma l2 del vector correspondiente a cada muestra.

3.4 Configuraciones del modelo

Las configuraciones del modelo para Con-GAE son las siguientes. La matriz de características del nodo $X \in \mathbb{R}^{N \times d}$ con $d = 4$ está construido corresponde a las extensiones mínima y máxima de latitud y longitud de la zona correspondiente al nodo. El codificador utiliza $L = 2$ capas GCN para aprender la incrustación a nivel de nodo.

El modelo se entrena durante 150 épocas con un tamaño de lote de 10. Del conjunto de entrenamiento, el 10 % se reserva como conjunto de validación para el ajuste de hiperparámetros. Otras configuraciones de Con-GAE para diferentes conjuntos de datos son las siguientes.

Para los datos de Uber Movement, la dimensión de las dos incrustaciones de nodos es $h1(t) \in \mathbb{R}^{100}$ y $h2(t) \in \mathbb{R}^{100}$, respectivamente. La dimensión de las incrustaciones de hora y semana es $dweek = dhour = 200$, y la dimensión de la incrustación del grafo es $d_{\text{д}} = 100$. Las tasas de abandono pe_drop y pdrop se establecen en 0,2. La tasa de aprendizaje inicial del optimizador Adam es 1×10^{-5}, y la disminuimos en 0,5 cada 50 épocas.

Machine Translated by Google

Tabla 2. Puntuación AUC para la detección de anomalías espaciales y temporales.
de diferentes conjuntos de datos

Tipo de anomalía	Anomalía espacial			Anomalía temporal		
Conjunto de datos	Uber	NYC	Chicago	Uber	NYC	Chicago
HAR	0,694	0,498	0,570	0,822	0,677	0,658
RTC	0,856	0,795	0,601	0,559	0,247	0,562
AE	0,772	0,671	0,727	0,548	0,592	0,460
EncDec-AD	0,523	0,782	REBM 0,762	0,715	0,481	0,659
0,671	0,759	DAGMM	0,514	0,603	GraphSAGE	0,739
0,484	0,805	0,482	0,679	0,741	0,659	0,593
0,669	0,484	0,397	0,414			
0,674	0,499	0,464	0,426			
GCN	0,765	0,494	0,416	0,421		
Con GAE	0,895	0,837	0,912	0,868	0,895	0,753

Para los datos de taxis de Nueva York, la dimensión de las dos incrustaciones de nodos es $h1_i(t) \in R^{50}$ y $h2_i(t) \in R^{50}$, respectivamente. La dimensión de las incrustaciones de hora y semana es dweek = dhour = 100, y la dimensión de incrustación del gráfico es $d_g = 50$. Las tasas de abandono pe_drop y pdrop están ambas establecidas en 0,2. La tasa de aprendizaje inicial es de 1×10^{-3}, y la disminuimos en 0,5 cada 20 épocas.

Para los datos de taxis de Chicago, la dimensión de las incrustaciones de los dos nodos es $h1_i(t) \in R^{300}$ y $h2_i(t) \in R^{25}$, respectivamente. La dimensión de las incrustaciones de hora y semana es dweek = dhour = 200, y la dimensión de incrustación del gráfico es $d_g = 25$. Las tasas de abandono pe_drop y pdrop están ambas establecidas en 0.1. La tasa de aprendizaje inicial es 1×10^{-3}, y disminuimos la tasa de aprendizaje en 0.5 cada 20 épocas.

Los algoritmos AE, DAGMM, EncDec-AD y REBM se implementan basándose en el código de la Referencia [19]. Los hiperparámetros respectivos para cada modelo se ajustan para lograr el mejor rendimiento. GCN y GraphSAGE tienen la misma dimensión de nodo de codificación que nuestro modelo. Configuraciones detalladas Están disponibles en los Materiales Suplementarios.

3.5 Resultados y análisis

3.5.1 Comparación de modelos. Primero, comparamos Con-GAE con los métodos de referencia para ambos Detección de anomalías espaciales y temporales para diferentes conjuntos de datos. Fijamos la fracción del tiempo. rebanadas elegidas para ser contaminadas $\gamma = 10\%$, magnitud de contaminación $\alpha = 50\%$ y $\beta = 10\%$. Los resultados son mostrado en la Tabla 2. Podemos ver que Con-GAE supera constantemente a los otros métodos, con un mejora en la puntuación AUC de hasta 0,15 con respecto al segundo mejor método. Para anomalías espaciales, Con-GAE es el único método para lograr un AUC cercano o superior a 0,9 para los datos de Uber y el Datos de Chicago, y el único método por encima de 0,8 para los datos de Nueva York. Para anomalías temporales, la mayoría de los demás Los métodos tienen una puntuación AUC de alrededor de 0,5 excepto HA, REBM y EncDec-AD, lo que significa que son no es muy adecuado para detectar anomalías temporales, mientras que Con-GAE alcanza una puntuación AUC de 0,75. o superior. Estos experimentos destacan que al tratar con datos de movilidad a gran escala, tomar La estructura del gráfico, al tenerla en cuenta, puede mejorar sustancialmente el rendimiento. Mientras tanto, directamente La aplicación del modelo GCN y GraphSAGE da como resultado un rendimiento deficiente, lo que demuestra la importancia de diseñar una estructura jerárquica para una incrustación a escala de grafo más allá del nodo individual incrustaciones al detectar anomalías en toda la red. Los experimentos temporales muestran que para datos con periodicidad, es más efectivo considerar la periodicidad a largo plazo como en Con-GAE y HA, que considerar las dependencias a corto plazo como en LSTM-ED y REBM, o ninguna temporal dependencias como en DAGMM, AE, GCN y GraphSAGE.

A continuación, comparamos los métodos de detección de anomalías bajo diferentes tasas de anomalías. Variamos la fracción γ de los intervalos de tiempo elegidos para ser contaminados, fijando $\alpha = 50\%$ y $\beta = 10\%$. El resultado se muestra a continuación.

Machine Translated by Google

Tabla 3. Puntuación AUC para la detección de anomalías espaciales y temporales bajo Diferentes tasas de anomalías

Tipo de anomalía	Anomalía espacial			Anomalía temporal		
Tasa de anomalía γ 5%	10%	20%		5%	10%	20%
HA	0,690	0,694	0,705	0,838	0,822	0,816
RTC	0,896	0,856	0,865	0,671	0,559	0,548
PERO	0,770	0,772	0,757	0,544	0,548	0,514
EncDec-AD	0,576	0,523	0,505	0,499	0,481	0,517
REBM	0,740	0,762	0,737	0,456	0,484	0,501
DAGMM	0,481	0,514	0,538	0,460	0,484	0,479
GraphSAGE	0,730	0,679	0,704	0,569	0,499	0,510
GCN	0,717	0,659	0,689	0,548	0,494	0,514
Con GAE	0,910	0,895	0,909	0,897	0,868	0,865

Variamos la fracción γ de los intervalos de tiempo elegidos para ser contaminados.

Tabla 4. Puntuación AUC para la detección de anomalías espaciales bajo diferentes condiciones Magnitudes de las anomalías

Tasa de anomalía espacial α	25%			50%		
Magnitud de la anomalía β	5%	10%	20%	5%	10%	20%
HA	0,500	0,588	0,812	0,531	0,694	0,942
RTC	0,743	0,798	0,921	0,765	0,856	0,973
PERO	0,570	0,672	0,866	0,606	0,772	0,973
EncDec-AD	0,492	0,505	0,541	0,498	0,523	0,606
REBM	0,607	0,679	0,867	0,634	0,762	0,968
DAGMM	0,509	0,515	0,483	0,507	0,514	0,501
GraphSAGE	0,602	0,638	0,739	0,615	0,679	0,841
GCN	0,594	0,622	0,706	0,606	0,659	0,798
Con GAE	0,681	0,800	0,963	0,729	0,895	1,000

Los resultados se muestran bajo diferentes α que deciden los pares OD contaminados y diferentes β correspondientes a la magnitud de la perturbación.

en la Tabla 3, donde se utilizan los datos de Uber Movement. Podemos ver que la ventaja de nuestro método se mantiene bajo diferentes tasas de anomalías.

También investigamos la influencia de la magnitud de la anomalía. Nos centramos en la detección espacial de anomalías y variamos la fracción α de pares OD contaminados y la distribución uniforme U(−β, β) que controla la magnitud de la contaminación. Fijamos los intervalos de tiempo contaminados en γ = 10%. El resultado es
Como se muestra en la Tabla 4, donde se utilizan datos de Uber Movement, ningún método obtiene el mejor rendimiento. en todos los escenarios. Todos los métodos tienen una puntuación AUC más alta con α y β más grandes, y funcionan peor cuando la contaminación es más compleja. Con-GAE tiene una ventaja significativa sobre los otros métodos. para β = 10% o mayor. Cuando β es menor que 10%, nuestro método es superado por el RTC lineal. método por un pequeño margen de alrededor de 0,05. Dado que nuestro objetivo es detectar grandes eventos que causen una perturbación significativa en las redes viales, concluimos que Con-GAE es el método más competitivo. en general.

Por último, examinamos la eficiencia de los modelos. Comparamos el tiempo de ejecución para una sola muestra, es decir, un segmento de tiempo de una sola hora. Promediamos el tiempo de ejecución en todos los datos de prueba, calculando una muestra de prueba a la vez. El resultado se resume en la Tabla 5. Encontramos que el basado en gráficos

Machine Translated by Google

Tabla 5. Tiempo de ejecución para una sola muestra, es decir, un segmento de tiempo de una sola hora.

Modelo	RTC AE	EncDec-AD	REBM	DAGMM	GraphSAGE	GCN	Con-GAE		
Tiempo de ejecución (s)	244,7	0,0047	0,0413	0,1285	0,0305		0,0012	0,0018	0,0022

Tabla 6. Estudio de ablación

Tipo de anomalía	Anomalía espacial			Anomalía temporal		
Tasa de anomalía γ	5%	10%	20%	5%	10%	20%
Con GAE	0,910	0,895	0,909	0,897	0,868	0,865
Con-GAE-sp	0,877	0,835	0,855	0,552	0,493	0,507
Con-GAE-t	0,820	0,794	0,809	0,798	0,748	0,735
Con-GAE-fc	0,768	0,784	0,741	0,714	0,720	0,736
Con-GAE-NonWeightedEnc	0,830	0,799	0,820	0,810	0,773	0,763

Los métodos tienen el menor tiempo de ejecución, seguidos de las redes neuronales profundas sin estructura de grafo. Esto se debe a que los métodos basados en grafos no necesitan considerar todos los N2 bordes en cada paso. En cambio, al utilizar técnicas de incrustación de nodos y calcular solo los bordes escasamente conectados, La complejidad computacional es del orden de N + E, donde N es el número de nodos y E es el número de aristas. Con 50 nodos, ya podemos ver la ventaja de los métodos basados en grafos. El método de descomposición tensorial robusta tiene el tiempo de ejecución más largo, ya que en cada paso requiere Calcular una descomposición en valores singulares sobre todos los datos históricos.

3.5.2 Estudio de ablación. Comparamos las distintas variantes de Con-GAE para ver cómo cada componente de Con-GAE ayuda en la detección de anomalías. Consideramos las siguientes variantes: (i) Con-GAE-sp: Eliminamos toda la información temporal del autoencoder y solo utilizamos los datos del grafo espacial. para entrenamiento y detección. (ii) Con-GAE-t: Eliminamos las capas GCN y solo usamos la información temporal para entrenamiento y detección. (iii) Con-GAE-fc: Reemplazamos las capas GCN en el autoencoder con capas totalmente conectadas, mientras que se conserva la información temporal. (iv) Con-GAE-NonWeightedEnc: Usamos la implementación estándar de GraphSAGE, ecuación (1), con un agregador de media en el codificador, en lugar del agregador de media ponderada modificado.

El resultado se muestra en la Tabla 6, donde se utilizan los datos de Uber Movement. Podemos ver que el Las capas GCN modificadas desempeñan un papel crucial en la detección de anomalías. La puntuación AUC es de alrededor de 0,1. menor si eliminamos las capas GCN (Con-GAE-t), reemplazamos las capas GCN con capas totalmente conectadas (Con-GAE-fc), o reemplace GCN con capas GraphSAGE estándar (Con-GAE-NonWeightedEnc). Observamos que la información temporal proporciona un beneficio marginal para la detección de anomalías espaciales, pero es crucial para la detección de anomalías temporales. Sin información temporal, es imposible Con-GAE-sp para detectar anomalías temporales, con una puntuación AUC constantemente cercana a 0,5.

3.5.3 Comparación de capas convolucionales de grafos. Con el rápido desarrollo de las redes neuronales de grafos En redes, se han diseñado nuevos mecanismos de convolución de grafos. Estas redes de convolución de grafos Las capas se pueden adaptar fácilmente a nuestro marco Con-GAE en lugar del GraphSAGE ponderado. En esta sección, comparamos el rendimiento de GraphSAGE ponderado con otras redes neuronales convolucionales de grafos. capas que incorporan ponderaciones de aristas al agregar información del vecindario. Incluimos: (i) TransformerConv [40] que utiliza un mecanismo de atención, (ii) ARMAConv [4], que utiliza una formulación recursiva inspirada en el filtro de media móvil autorregresiva (ARMA), (iii) TAGConv [14], que es una red neuronal convolucional gráfica adaptativa a la topología, y (iv) SGCConv [54], que elimina las no linealidades y colapsa las matrices de pesos sucesivamente para reducir la complejidad de la GCN.

Machine Translated by Google

Tabla 7. Rendimiento de otras capas convolucionales de grafos además de Gráfico ponderadoSAGE

Tipo de anomalía	Anomalía espacial			Anomalía temporal		
Tasa de anomalía γ	5%	10%	20%	5%	10%	20%
Gráfico ponderado SAGE	0,910	0,895	0,909	0,897	0,868	0,865
TransformerConv	0,949	0,940	0,950	0,750	0,711	0,692
ARMAConv	0,917	0,902	0,921	0,887	0,869	0,864
TAGConv	0,911	0,896	0,917	0,863	0,852	0,845
SGCConv	0,733	0,712	0,742	0,558	0,516	0,502

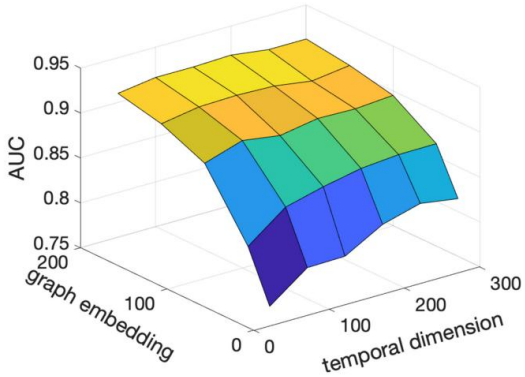


Figura 4. Análisis de sensibilidad de Con-GAE. Puntuación AUC de Con-GAE con diferentes dimensiones del gráfico y tiempo. Se representa gráficamente la incrustación.

Los parámetros de cada uno están ajustados para obtener el mejor rendimiento y se registran en los Materiales Suplementarios.

El resultado se muestra en la Tabla 7, donde se utiliza el conjunto de datos de movimiento de Uber. Podemos ver que todos Las capas convolucionales de grafos alcanzan un rendimiento comparable, excepto SGCConv. TransformerConv. tiene el mejor rendimiento en la detección de anomalías espaciales, pero funciona peor en la detección de anomalías temporales. En comparación, GraphSAGE ponderado funciona mejor en anomalías temporales, y También funciona adecuadamente bien en anomalías espaciales con solo 0,04 menos en la puntuación AUC en comparación con el mejor método. Por lo tanto, elegimos GraphSAGE ponderado en la implementación de nuestro modelo Con-GAE.

3.5.4 Análisis de sensibilidad. A continuación, exploramos cómo cambia el rendimiento de Con-GAE a medida que función de la dimensión de incrustación del gráfico, la dimensión de incrustación de la hora y la semana, y la Profundidad del modelo. Fijamos α = 50%, β = 10% y γ = 10%. Se utilizan datos de Uber Movement.

Primero, exploramos la sensibilidad a las dimensiones de codificación espacial y temporal. Variamos el gráfico. dimensión de incrustación dд entre 25 y 200, y variar la dimensión de incrustación de semana y hora. entre 50 y 300. La dimensión de las incrustaciones de nodos $h1_i$ y $h2_i$ se establece igual que la dimensión de incrustación del grafo dд. Fijamos los demás parámetros para que sean los mismos que los descritos en Configuraciones del modelo. El resultado se muestra en la Figura 4. Podemos ver que a medida que la dimensión del grafo y temporal A medida que aumenta la dimensión, la puntuación AUC primero aumenta rápidamente y luego se mantiene estable con un ligero incremento.

A continuación, investigamos la sensibilidad a la profundidad del modelo. Variamos el número de capas GCN desde 1 a 6, fijando $hl_i(t)$ R100 para todas las capas. El resultado se muestra en la Tabla 8. Podemos ver que cuando el El número de capas es inferior a 4, el modelo tiene aproximadamente el mismo rendimiento. Pero cuando el número de capas es menor que Si el número de capas supera las 4, el rendimiento se degrada con la profundidad.

Machine Translated by Google

Tabla 8. Sensibilidad a la profundidad del modelo

# Capas GCN	1	2	3	4	5	6
puntuación AUC	0,887	0,895	0,895	0,850	0,853	0,785

Tabla 9. Robustez ante la contaminación por anomalías en los datos de entrenamiento.

Tipo de anomalía	Anomalía espacial			Anomalía temporal		
Tasa de anomalía γ	5%	10%	20%	5%	10%	20%
Entrenamiento original	0,9098	0,8954	0,9089	0,8973	0,8679	0,8649
Entrenamiento espacialmente contaminado	0,9096	0,8951	0,9089	0,8979	0,8684	0,8654
Entrenamiento temporalmente contaminado	0,9034	0,8888	0,9035	0,8570	0,8244	0,8221

3.5.5 Análisis de robustez. Por último, estudiamos la tolerancia de Con-GAE a una pequeña cantidad de impurezas. contaminación en los datos de entrenamiento. Esto es para comprender los posibles inconvenientes que podrían ocurrir si la Los datos de entrenamiento no están limpios y, de hecho, contienen anomalías. Corrompemos manualmente el 5% de los datos. datos de entrenamiento espacial o temporalmente, siguiendo el mismo procedimiento que se utiliza en el sintético generación de anomalías en los datos de prueba. Al inyectar anomalías espaciales, establecemos la contaminación. fuerza α = 50%, β = 10%. Presentamos los resultados de las pruebas bajo diferentes tasas de anomalía en la prueba. escenarios dado una tasa de anomalía fija del 5% inyectada en los datos de entrenamiento. Para cada caso, aleatoriamente Generar el conjunto de entrenamiento cinco veces y calcular el rendimiento promedio del modelo. El resultado es Como se muestra en la Tabla 9, encontramos que con datos de entrenamiento espacialmente contaminados, el rendimiento del modelo permanece igual. Con datos de entrenamiento contaminados temporalmente, la puntuación AUC disminuye ligeramente en un la mayoría 0,04. Por lo tanto, encontramos que el método puede tolerar anomalías en los datos de entrenamiento sin notarse impactando el rendimiento.

3.6 Visualización de anomalías de tráfico en el mundo real

En esta sección, demostramos la aplicación en el mundo real de Con-GAE. Usamos el conjunto de prueba 4/27– 5/01 de 2019 Q2, que no se ve durante el entrenamiento y se sabe que contiene un gran evento (la NFL draft). El draft de la NFL atrajo a varios cientos de miles de visitantes a la ciudad, y eventos nocturnos Esto provocó el cierre de carreteras en el centro de Nashville.

La figura 5 muestra la puntuación de anomalía (la pérdida de reconstrucción) para cada hora del período estudiado. Los días en los que se desarrollan las principales actividades del borrador están resaltados en rojo en el Eje Y. Podemos observar que las puntuaciones de anomalía más altas se producen durante el draft, concretamente el 26/4 a las 19:00. hasta la medianoche, así como el 27/4 de 15:00 a 18:00. Estos son los horarios en que se realiza el borrador, el borrador posterior y el borrador posterior. tienen lugar concierto y fuegos artificiales [36].

La Figura 6 muestra los datos de tiempo de viaje OD durante dos períodos con puntuaciones de anomalías altas. Para mayor claridad, Solo se grafica un subconjunto de pares de tiempos de viaje, y solo las desviaciones superiores a 5 minutos de la Se muestran los promedios históricos. La figura 6(a) muestra que los tiempos de viaje desde la región que contiene El desplazamiento hacia otras partes de la ciudad es significativamente más largo de lo habitual. La tercera anomalía más grande El período ocurre en los días consecutivos del 21/4 al 24/4 a las 20:00. Esto coincide con el registro de la Departamento de Transporte de Tennessee [44] que hay mantenimiento nocturno alterno de la carretera cierres de la principal autopista que conecta el centro de la ciudad con el aeropuerto, lo que resulta en una cantidad sustancialmente tiempos de viaje más largos (Figura 6(b)).

4 TRABAJOS RELACIONADOS

En esta sección, revisamos la incrustación de redes gráficas y la detección de anomalías basada en autoencoders. técnicas que inspiran Con-GAE. También revisamos el tema estrechamente relacionado de espaciotemporal. gráficos en el transporte.

Machine Translated by Google

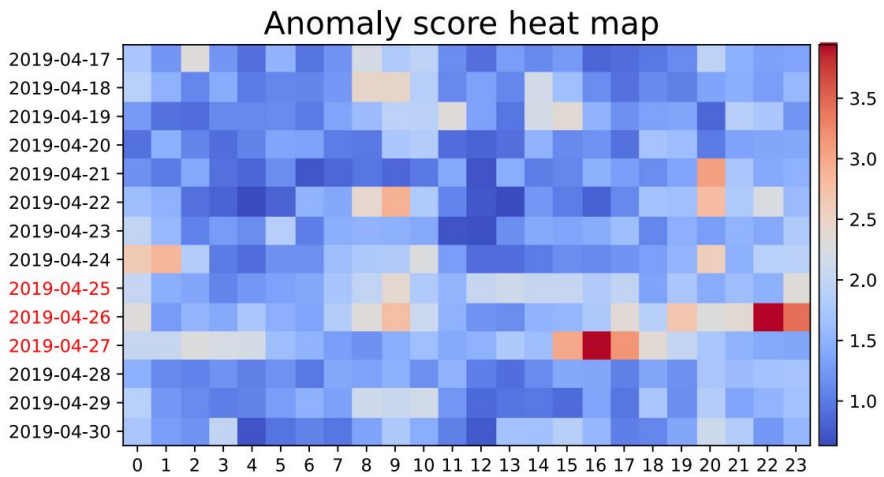


Figura 5. Puntuaciones de anomalías para cada hora. Los días del draft de la NFL están marcados en rojo. La puntuación indica el error de reconstrucción de la ecuación (6).

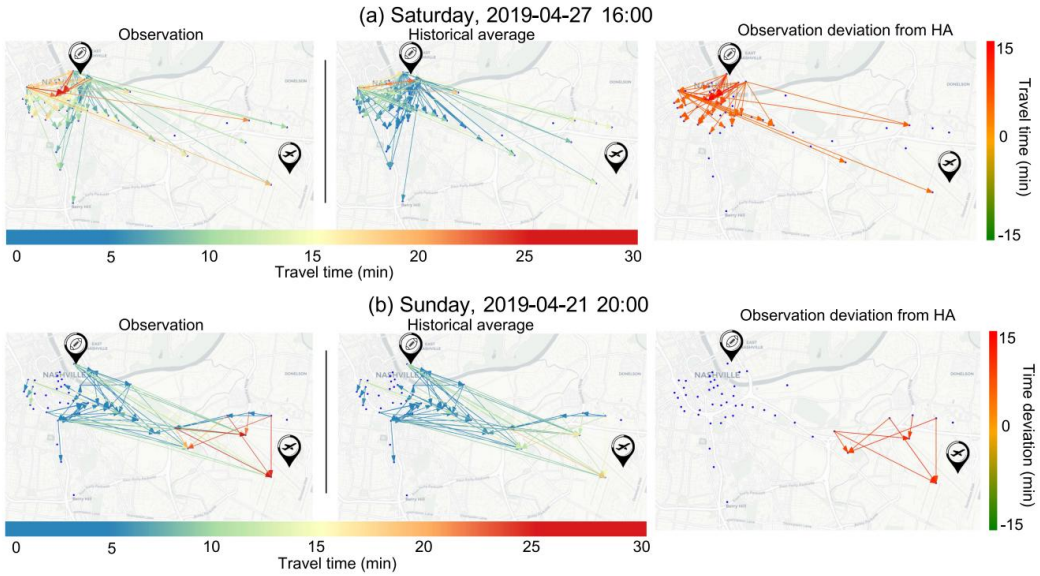


Figura 6. Condiciones del tráfico para los eventos detectados. Se muestra el tiempo de viaje entre el origen y el destino, comparándolo con las condiciones históricas.

4.1 Incrustación de redes gráficas En los

últimos años, se ha producido un rápido desarrollo de los algoritmos de aprendizaje basados en la incrustación de grafos. En particular, GCN ha ganado popularidad debido a su escalabilidad y buen rendimiento [15].
Algunas variantes de referencia de GCN incluyen [22, 27, 48], que se han convertido en el componente básico de muchos modelos complejos de redes neuronales gráficas [55]. Para introducciones y estudios exhaustivos sobre redes neuronales gráficas, se pueden consultar las referencias [55, 67]. Nuestro trabajo se centra en grafos dirigidos ponderados, adecuados para conjuntos de datos de movilidad, en comparación con los grafos binarios no dirigidos del trabajo original de [22, 27].

Machine Translated by Google

Un autoencoder de grafos (GAE) es un enfoque de aprendizaje no supervisado que codifica el grafo en un espacio latente y reconstruye la estructura del grafo a partir de la codificación [55]. Desde la introducción de GAE en las referencias [26, 45], se ha utilizado ampliamente, por ejemplo, en la predicción de enlaces [39, 53, 57], la compleción de matrices [3] y la agrupación de grafos [49]. Si bien los enfoques GAE existentes, como [26], aprenden incrustaciones de nodos durante la codificación, nuestro modelo comprime aún más las incrustaciones de todos los nodos en un grafo a una única incrustación de grafo y la condiciona a información temporal para agregar contexto adicional importante para interpretar los datos de movilidad.

Dada la estructura gráfica intrínseca de las redes de transporte, investigaciones recientes han demostrado las ventajas de aplicar técnicas de incrustación de grafos a los datos de movilidad para la predicción [12, 59], la predicción de la demanda de pasajeros [51], la recomendación de estaciones de bicicletas públicas sin base fija [8], la estimación del tiempo de viaje [50] y la predicción de la trayectoria humana [35]. Si bien la incrustación de grafos para la detección de anomalías en el tráfico ha sido menos estudiada, nuestro trabajo actual muestra la capacidad de las incrustaciones de grafos para aprender patrones en los datos de movilidad origen-destino para la detección de anomalías.

4.2 Detección de anomalías basada en autoencoders

Los métodos basados en autoencoders profundos se han utilizado ampliamente para la detección de anomalías [5, 11, 33, 38, 56, 66]. El codificador y el decodificador pueden tener diversas estructuras según los diferentes tipos de datos de entrada. Además de los codificadores y decodificadores basados en MLP ampliamente utilizados [5, 38, 56], las redes neuronales convolucionales (CNN) se aplican a datos de cuadrícula [11], y las redes neuronales recurrentes (RNN) se aplican a datos de series temporales [33, 42]. Recientemente, los autoencoders basados en GCN se han utilizado para la detección de anomalías en datos de grafos [13, 16, 28, 29, 31, 69], con un énfasis importante en las anomalías a nivel de nodo. En comparación, nuestro trabajo se centra en la detección de anomalías a nivel de grafo, ya que cada grafo corresponde a la condición del tráfico en toda la red en un instante de tiempo específico que puede verse alterado por un evento a gran escala.

4.3 Grafos espaciotemporales en el transporte

La mayoría de los trabajos que utilizan grafos espaciotemporales en el transporte se han centrado en la predicción del tráfico. Una estrategia representativa consiste en combinar GNN y redes neuronales recurrentes para capturar patrones tanto espaciales como temporales [32, 60]. Se emplean mecanismos de atención en los grafos para capturar la varianza en las dependencias espaciotemporales [30, 52, 63]. Se utilizan grafos dinámicos para adaptarse a la naturaleza cambiante del tráfico [37, 64]. Los trabajos existentes sobre grafos espaciotemporales se centran principalmente en modelar las dependencias a corto plazo de instancias consecutivas del grafo. En comparación, nosotros nos centramos en explotar la periodicidad temporal de los grafos de tráfico en horizontes temporales más amplios para nuestro propósito de detección de anomalías.

5. CONCLUSIÓN

En este trabajo, abordamos el problema de detectar eventos en toda la red en grandes conjuntos de datos de movilidad origen-destino. Formulamos el problema de detectar estos eventos como un problema de detección de anomalías en un conjunto de grafos dirigidos dependientes del tiempo que contienen datos de movilidad en la red. Presentamos Con-GAE, un detector de anomalías basado en autoencoders que utiliza capas GCN e incrustaciones temporales para determinar anomalías. Experimentos exhaustivos en tres conjuntos de datos de movilidad del mundo real muestran que Con-GAE supera a varios métodos de detección de anomalías de última generación tanto en la detección de anomalías espaciales como temporales. En trabajos futuros, nos interesa explorar la escalabilidad de Con-GAE a redes con un número significativamente mayor de nodos y para la detección de anomalías en otros conjuntos de datos de red.

Machine Translated by Google

APÉNDICE

MATERIAL COMPLEMENTARIO

A.1 Preparación y simulación de datos experimentales En esta sección,

detallamos los pasos de reprocesamiento y simulación de datos. También mostramos la distribución de los tiempos de viaje para los tres conjuntos de datos utilizados en el artículo.

Como se describe en el texto principal, el conjunto de datos se divide en conjuntos de entrenamiento y prueba. Se supone que el conjunto de entrenamiento no contiene eventos importantes (anomalías). Para comparar los métodos en un entorno controlado, creamos un conjunto de prueba con anomalías sintéticas etiquetadas, que se inyectan en condiciones de tráfico depuradas. Generamos sintéticamente el conjunto de prueba a partir de datos reales debido a la falta de conjuntos de datos de tráfico a escala urbana preetiquetados con anomalías.

Para generar condiciones de tráfico limpias en el conjunto de prueba, que posteriormente se contaminan con anomalías, asumimos que el tiempo de viaje de cada par origen-destino en cada hora del día y cada día de la semana sigue una distribución gaussiana. Calculamos la media y la varianza del tiempo de viaje del par origen-destino en las horas correspondientes a partir de los datos de prueba sin procesar del segundo trimestre de 2019. A continuación, remuestreamos los tiempos de viaje basándonos en la media y la varianza calculadas para obtener un conjunto de datos de prueba limpio y completo. Posteriormente, inyectamos anomalías espaciales y temporales, respectivamente, como se describe en el texto principal, para obtener el conjunto de prueba etiquetado con anomalías.

En el conjunto de datos Uber Movement correspondiente a Nashville, TN, la región se divide en 2219 zonas. Sin embargo, muchos de los pares origen-destino no registran tiempos de viaje. Para obtener la mayor cantidad de información útil posible y garantizar la eficiencia del aprendizaje, seleccionamos las 50 zonas más conectadas, de modo que la zona seleccionada tenga al menos un viaje a un tercio del total de 2219 zonas. Esto resulta en una tasa de datos faltantes del 30 % en el conjunto de entrenamiento y del 41 % en el conjunto de prueba. Las extensiones mínima y máxima de latitud y longitud de cada zona se utilizan como características de los nodos, que se escalan a un rango de 0 a 1 antes de introducirlas en Con-GAE.

La distribución de los tiempos de viaje para los tres conjuntos de datos utilizados en el artículo se muestra en la Figura 7.

Podemos observar que el conjunto de datos Uber Movement contiene viajes de menor duración que los datos de taxis de Nueva York o Chicago. Asimismo, los datos de Uber y los de taxis de Chicago presentan una distribución de tiempos de viaje más concentrada que los de taxis de Nueva York.

A.2 Métodos básicos

En esta sección, ofrecemos una breve introducción a cada método y documentamos las configuraciones del modelo.

- RTC [24]. La recuperación y completación robusta de tensores para la detección de anomalías grupales (RTC) es un método basado en la descomposición de tensores de bajo rango que explota la correlación espacio-temporal.
  Este es un método de referencia que no utiliza aprendizaje profundo. RTC tiene un hiperparámetro λ, que controla el equilibrio entre el rango del tensor normal y el tamaño y la magnitud del tensor de valores atípicos. Establecimos λ = 0,227 para los datos de Uber y Chicago, y λ = 0,390 para los datos de Nueva York.
  El valor se elige empíricamente siguiendo los parámetros descritos en el artículo.
- AE [23]. El autoencoder (AE) es un modelo de red neuronal ampliamente utilizado para la detección de anomalías.
  Utiliza una red neuronal totalmente conectada para construir un codificador y un decodificador que comprimen y reconstruyen los datos. El error de reconstrucción se utiliza como puntuación de anomalía. El tamaño oculto (es decir, la dimensión del estado codificado de baja dimensión) del AE se establece con la misma configuración que en Con-GAE.
  En concreto, el tamaño oculto es de 100 para los datos de Uber, 50 para los de Nueva York y 25 para los de Chicago. La tasa de aprendizaje es de 0,01 para Uber y de 0,0005 para los de Nueva York y Chicago.
  El número de épocas es 150 para Uber y 30 para Nueva York y Chicago. Los valores se determinaron para maximizar el rendimiento mediante búsqueda en cuadrícula. La longitud secuencial se establece en 1, es decir, cada

Machine Translated by Google

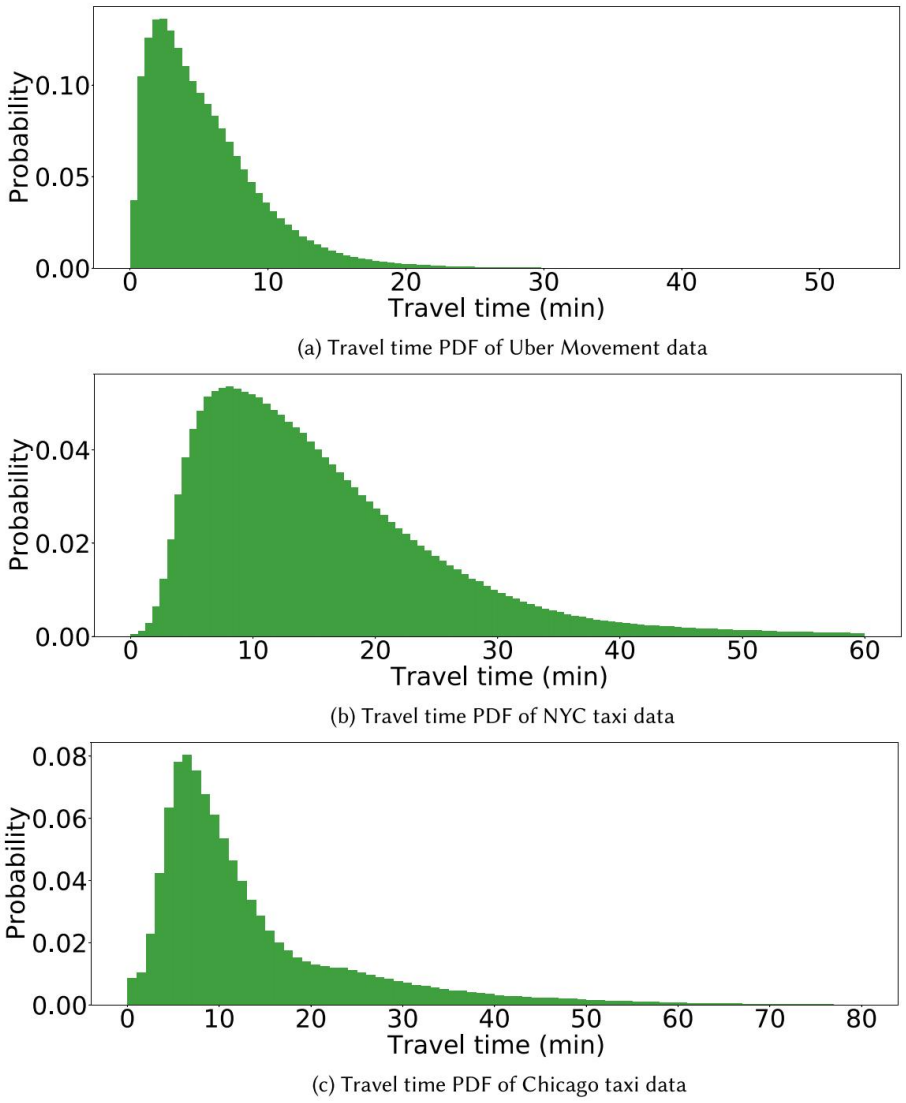


Figura 7. Distribución del tiempo de viaje para tres conjuntos de datos.

La muestra de entrada contiene las condiciones de tráfico de un paso de tiempo. Todos los demás parámetros se establecen como los valores predeterminados, con la semilla aleatoria establecida en 0.

- EncDec-AD [33]. EncDec-AD es un modelo codificador-decodificador basado en LSTM para series temporales.
  detección de anomalías. EncDec-AD aprende el patrón normal de una serie temporal multidimensional y detecta tiempos anómalos que se desvían del patrón normal a través del error de reconstrucción. Establecemos el tamaño oculto (es decir, la dimensión del estado codificado de baja dimensión).
  de EncDec-AD mediante búsqueda en cuadrícula. Es decir, el tamaño oculto es 150 para los datos de Uber, 50 para Nueva York y 25 para los datos de Chicago. La tasa de aprendizaje y el número de épocas son 0,0001 y 120 para Uber.
  datos, 0,0005 y 30 para NYC, y 0,001 y 70 para datos de Chicago. EncDec-AD toma series temporales
  ventanas como entrada, y establecemos la longitud secuencial en 72 para los datos de Uber y NYC, y 24 para

Machine Translated by Google

Datos de Chicago, que también se determinan mediante búsqueda en cuadrícula. Todos los demás parámetros se establecen como valores predeterminados, con semilla aleatoria establecida en 0. • DAGMM [70]. El modelo de mezcla gaussiana de autoencoder profundo (DAGMM) realiza detección de anomalías no supervisada al encontrar representaciones de datos de baja dimensión a través de un autoencoder profundo y modelar la distribución de datos en el espacio de baja dimensión a través de un modelo de mezcla gaussiana. En lugar de establecer el tamaño oculto de DAGMM igual que Con-GAE, una búsqueda en cuadrícula reveló que el mejor rendimiento se logra con un tamaño oculto de 50 para los datos de Uber y los datos de NYC, y 5 para los datos de Chicago. Mientras que los otros métodos (Con-GAE, AE, EncDec-AD) se basan en la reconstrucción, DAGMM se basa en la agrupación en un espacio de baja dimensión. Una dimensión de codificación demasiado baja podría no capturar la información original, mientras que la agrupación de alta dimensión puede encontrar una maldición de dimensionalidad. La tasa de aprendizaje y el número de épocas son 0,001 y 20 para los datos de Uber, 0,0005 y 50 para los datos de Nueva York, y 0,0001 y 20 para los datos de Chicago, lo que proporciona el mejor resultado tras la búsqueda en cuadrícula de parámetros. La longitud secuencial se establece en 1, es decir, cada muestra de entrada contiene las condiciones de tráfico de un paso de tiempo. El resto de los parámetros se establecen en los valores predeterminados, con la semilla aleatoria en 0.

- REBM [62]. REBM es la versión basada en RNN de los modelos de energía estructurada profunda (EBM) para la detección de anomalías en series temporales. REBM modela la distribución de datos con redes neuronales y detecta la anomalía mediante la energía (logaritmo negativo de la probabilidad) y el error de reconstrucción.
  Establecimos el tamaño oculto (es decir, la dimensión del estado codificado de baja dimensión) del AE con la misma configuración que en Con-GAE. En concreto, el tamaño oculto es de 150 para los datos de Uber, 50 para los de Nueva York y 25 para los de Chicago. La tasa de aprendizaje y el número de épocas son 0,0005 y 50 para los datos de Uber, 0,0001 y 100 para los de Nueva York, y 0,001 y 50 para los de Chicago. Todos los demás parámetros se establecen con los valores predeterminados, con la semilla aleatoria fijada en 0.
- GCN [27]. Como formulación básica de red neuronal gráfica, GCN actualiza las características de los nodos promediando las características de los nodos vecinos. Utilizamos la matriz de características final de todos los nodos como codificación para el grafo de tráfico y el mismo decodificador que nuestro modelo Con-GAE para decodificar los pesos de las aristas a partir de la codificación de los nodos. El error de reconstrucción en todas las aristas se utiliza como puntuación de anomalía. Para GCN, utilizamos la misma estructura que el modelo Con-GAE.
  En concreto, utilizamos dos capas de GCN; las incrustaciones de nodos se establecen en 300 y 150 para los datos de Uber; 150 y 50 para los datos de Nueva York; y 300 y 25 para los datos de Chicago. La tasa de abandono se establece en 0,2. La tasa de aprendizaje se establece en 0.0001 para los datos de Uber, 0.001 para los datos de NYC y 0.01 para los datos de Chicago. • GraphSAGE [22] mejora a partir de GCN al concatenar explícitamente la característica del nodo mismo después de agregar las características de los nodos vecinos. Su estructura de codificación-decodificación es la misma que nuestro método de comparación GCN. Es similar a nuestro modelo Con-GAE sin la capa de agregación de incrustación de nodo a incrustación de grafo y sin la incrustación de tiempo. Para GraphSAGE, usamos la misma estructura que el modelo Con-GAE. Es decir, usamos dos capas de GCN, las incrustaciones de nodo para las dos capas se establecen en 300 y 150 para los datos de Uber; 150 y 50 para los datos de NYC, y 300 y 25 para los datos de Chicago. La tasa de abandono se establece en 0.2. La tasa de aprendizaje se establece en 0,0001 para los datos de Uber, 0,0005 para los datos de Nueva York y 0,05 para los datos de Chicago.

Para los métodos que no admiten directamente datos faltantes, a saber, HA, AE, DAGMM, EncDec-AD y REBM, imputamos los datos faltantes mediante interpolación temporal (es decir, mediante interpolación lineal cuando hay valores para interpolar, o mediante un valor medio cuando no se puede realizar la interpolación).

A.3 Configuraciones de modelos para la comparación de capas convolucionales de grafos En esta sección, registramos la configuración de parámetros para los modelos en la Tabla 7, donde comparamos diferentes capas convolucionales de grafos.

Machine Translated by Google

Para todos los métodos, las características de los nodos y la división entre entrenamiento y prueba son las mismas. El codificador utiliza L = 2 capas convolucionales de grafos para aprender la incrustación a nivel de nodo. Las tasas de abandono son pe_drop y pdrop. Ambos están configurados en 0,2.

Para TransformerConv, la dimensión de las dos incrustaciones de nodos es h1 (t) R100 y h2 (t) ¡ R100, respectivamente¡. La dimensión de las incrustaciones de hora y semana es dweek = dhour = 50, y la dimensión de la incrustación del grafo es dд = 100. El número de cabezas de atención multi-cabeza es 10. La tasa de aprendizaje inicial del optimizador Adam es 1 × 10−4, y la tasa de aprendizaje disminuye en 0,5 cada 100 épocas.

Para ARMAConv, la dimensión de las dos incrustaciones de nodos es h1 (t) R300 y h2 (t) ¡ R300, respectivamente¡. La dimensión de las incrustaciones de hora y semana es dweek = dhour = 50, y la dimensión de la incrustación del grafo es dд = 100. La tasa de aprendizaje inicial del optimizador Adam es 5×10−5, y la disminuimos en 0,5 cada 100 épocas.

Para TAGConv, la dimensión de las dos incrustaciones de nodos es h1 (t) R300 y h2 (t) ¡ R300, respectivamente¡. La dimensión de las incrustaciones de hora y semana es dweek = dhour = 50, y la dimensión de la incrustación del grafo es dд = 150. La tasa de aprendizaje inicial del optimizador Adam es 5×10−5, y la disminuimos en 0,5 cada 100 épocas.

Para SGCConv, la dimensión de las dos incrustaciones de nodos es h1 (t) R300 y h2 (t) ¡ R300, respectivamente¡. La dimensión de las incrustaciones de hora y semana es dweek = dhour = 50, y la dimensión de la incrustación del grafo es dд = 150. La tasa de aprendizaje inicial del optimizador Adam es 1×10−4, y la disminuimos en 0,5 cada 100 épocas.

A.4 Reproducibilidad En esta sección, especificamos el hardware y el software informático utilizados para los experimentos, así como la disponibilidad de los datos.

La GPU utilizada para los experimentos es una GTX 1080 (12 GB) que funciona con Ubuntu 18.04.4 LTS. Utilizamos el paquete de Python PyTorch Geometric [18] versión 1.7 para implementar las capas convolucionales del grafo.

Los datos de la serie temporal de Uber Movement provienen de Nashville, TN, y aún no están disponibles públicamente en el portal de Uber Movement [47]. Los datos de Uber Movement están disponibles bajo una licencia Creative Commons, Atribución No Comercial.1

REFERENCIAS

[1] Leman Akoglu, Hanghang Tong y Danai Koutra. 2015. Detección y descripción de anomalías basada en grafos: una revisión. Data Min. Knowl. Discov. 29, 3 (2015), 626–688.

[2] Julien Audibert, Pietro Michiardi, Frédéric Guyard, Sébastien Marti y Maria A. Zuluaga. 2020. USAD: Detección de anomalías no supervisada en series temporales multivariadas. En Actas de la 26.ª Conferencia Internacional ACM SIGKDD sobre Descubrimiento de Conocimiento y Minería de Datos. 3395–3404.

[3] Rianne van den Berg, Thomas N. Kipf y Max Welling. 2018. Completación de matrices convolucionales de grafos. En Actas de la Conferencia Internacional sobre Descubrimiento de Conocimiento y Minería de Datos (KDD'18).

[4] Filippo Maria Bianchi, Daniele Grattarola, Lorenzo Livi y Cesare Alippi. 2022. Redes neuronales gráficas con filtros Arma convolucionales. En IEEE Trans. Pattern Anal. Mach. Intell. 44, 7 (2022), 3496–3507. DOI: 10.1109/TPAMI.2021.3054830

[5] Andrea Borghesi, Andrea Bartolini, Michele Lombardi, Michela Milano y Luca Benini. 2019. Detección de anomalías mediante autoencoders en sistemas de computación de alto rendimiento. En Actas de la Conferencia AAAI sobre Inteligencia Artificial, Vol. 33. 9428–9433.

[6] David L. Buckeridge, Howard Burkom, Murray Campbell, William R. Hogan, Andrew W. Moore, et al. 2005. Algoritmos para la detección rápida de brotes: una síntesis de investigación. J. Biomed. Inform. 38, 2 (2005), 99–113.

1https://movement.uber.com/faqs?lang=en-US.

Machine Translated by Google

[7] Saikiran Bulusu, Bhavya Kailkhura, Bo Li, Pramod K. Varshney y Dawn Song. 2020. Detección de ejemplos anómalos en aprendizaje profundo: una revisión. IEEE Access 8 (2020), 132330–132347.

[8] Jianguo Chen, Kenli Li, Keqin Li, Philip S. Yu y Zeng Zeng. 2021. Planificación dinámica de estaciones de bicicletas en un sistema público de bicicletas compartidas sin estaciones fijas mediante una red neuronal gráfica con compuertas. ACM Trans. Intell. Syst. Technol. 12, 2 (2021), 1–22.

[9] Chicago. 2020. Viajes compartidos. Recuperado en noviembre de 2020 de https://data.cityofchicago.org/Transportation/Divvy-Trips/fg6s-gzvg.

[10] Chicago. 2020. Viajes en taxi. Recuperado en noviembre de 2020 de https://data.cityofchicago.org/Transportation/Taxi-Trips/wrvz-psew.

[11] Yong Shean Chong y Yong Haur Tay. 2017. Detección de eventos anormales en videos usando un autoencoder espaciotemporal. En Actas del Simposio Internacional sobre Redes Neuronales. Springer, 189–196.

[12] Zulong Diao, Xin Wang, Dafang Zhang, Yingru Liu, Kun Xie y Shaoyao He. 2019. Redes neuronales convolucionales de grafos espacio-temporales dinámicos para la predicción del tráfico. En Actas de la Conferencia AAAI sobre Inteligencia Artificial, Vol. 33. 890–897.

[13] Kaize Ding, Jundong Li, Rohit Bhanushali y Huan Liu. 2019. Detección profunda de anomalías en redes con atributos. En Actas de la Conferencia Internacional SIAM sobre Minería de Datos. SIAM, 594–602.

[14] Jian Du, Shanghang Zhang, Guanhang Wu, José MF Moura y Soummya Kar. 2017. Gráfico adaptativo de topología. redes neuronales convolucionales. Recuperado de https://arXiv:1710.10370.

[15] Vijay Prakash Dwivedi, Chaitanya K. Joshi, Thomas Laurent, Yoshua Bengio y Xavier Bresson. 2020. Benchmarking Redes neuronales gráficas. Obtenido de https://arXiv:2003.00982.

[16] Haoyi Fan, Fengbin Zhang y Zuoyong Li. 2020. AnomalyDAE: Autoencoder dual para la detección de anomalías en redes con atributos. En Actas de la Conferencia Internacional IEEE sobre Acústica, Habla y Procesamiento de Señales (ICASSP'20). IEEE, 5685–5689.

[17] Hadi Fanaee-T. y Joao Gama. 2016. Detección de eventos a partir de tensores de tráfico: un modelo híbrido. Neurocomputing 203 (2016), 22–33.

[18] Matthias Fey y Jan E. Lenssen. 2019. Aprendizaje rápido de representación gráfica con PyTorch Geometric. En Actas de el Taller ICLR sobre Aprendizaje de Representaciones en Grafos y Variedades.

[19] Maxi Fischer, Willi Gierke, Thomas Kellermeier, Ajay Kesar, Axel Stebner y Daniel Thevessen. 2019. Detección de anomalías en series temporales: una evaluación de métodos de aprendizaje profundo. Recuperado de https://github.com/KDD-OpenSource/DeepADoTS.

[20] Donald Goldfarb y Zhiwei Qin. 2014. Recuperación robusta de tensores de bajo rango: modelos y algoritmos. SIAM J. Matrix Anal. Appl. 35, 1 (2014), 225–253.

[21] Palash Goyal, Nitin Kamra, Xinran He y Yan Liu. 2018. Dyngem: Método de incrustación profunda para grafos dinámicos. Obtenido de https://arXiv:1805.11273.

[22] Will Hamilton, Zhitao Ying y Jure Leskovec. 2017. Aprendizaje de representación inductiva en grafos grandes. En Advances en Sistemas de Procesamiento de Información Neuronal. MIT Press, 1024–1034.

[23] Simon Hawkins, Hongxing He, Graham Williams y Rohan Baxter. 2002. Detección de valores atípicos mediante redes neuronales replicadoras. En Actas de la Conferencia Internacional sobre Almacenamiento de Datos y Descubrimiento de Conocimiento. Springer, 170–180.

[24] Yue Hu y Daniel B. Work. 2020. Recuperación robusta de tensores con valores atípicos de fibra para eventos de tráfico. ACM Trans. Knowl. Discov. Data 15, 1 (2020), 1–27.

[25] Diederik P. Kingma y Jimmy Ba. 2015. Adam: Un método para la optimización estocástica. En Actas del 3er Inter-Conferencia nacional sobre representaciones de aprendizaje (ICLR'15).

[26] Thomas N. Kipf y Max Welling. 2016. Autoencoders de grafos variacionales. Recuperado de https://arXiv:1611.07308.

[27] Thomas N. Kipf y Max Welling. 2017. Clasificación semisupervisada con redes neuronales convolucionales de grafos. En Pro-Actas de la Conferencia Internacional sobre Representaciones de Aprendizaje (ICLR'17).

[28] Prakhyat G. Kulkarni, SY Praneet, RB Raghav y Bhaskarjyoti Das. 2020. Detección profunda de anomalías en grafos estáticos con atributos. En Actas de la Conferencia Internacional sobre Aprendizaje Automático, Procesamiento de Imágenes, Seguridad de Redes y Ciencias de Datos. Springer, 627–640.

[29] Atsutoshi Kumagai, Tomoharu Iwata y Yasuhiro Fujiwara. 2020. Detección de anomalías semisupervisada en grafos con atributos. Recuperado de https://arXiv:2002.12011.

[30] Duo Li y Joan Lasenby. 2021. Red neuronal convolucional de grafos basada en atención espaciotemporal para la predicción de tráfico a nivel de segmento. IEEE Trans. Intell. Transport. Syst. (2021), 1–9. https://doi.org/10.1109/TITS.2021.3078187 [31] Yuening Li, Xiao Huang, Jundong Li, Mengnan Du y Na Zou. 2019. SpecAE: Autoencoder espectral para la detección de anomalías en redes con atributos. En Actas de la 28.ª Conferencia Internacional ACM sobre Gestión de Información y Conocimiento. 2233–2236.

[32] Zhishuai Li, Gang Xiong, Yuanyuan Chen, Yisheng Lv, Bin Hu, Fenghua Zhu y Fei-Yue Wang. 2019. Un enfoque híbrido de aprendizaje profundo con GCN y LSTM para la predicción del flujo de tráfico. En Actas de la Conferencia de Sistemas de Transporte Inteligentes del IEEE (ITSC'19). 1929–1933. https://doi.org/10.1109/ITSC.2019.8916778

Machine Translated by Google

[33] Pankaj Malhotra, Anusha Ramakrishnan, Gaurangi Anand, Lovekesh Vig, Puneet Agarwal y Gautam Shroff. 2016.
Codificador-decodificador basado en LSTM para la detección de anomalías multisensor. Recuperado de https://arXiv:1607.00148.

[34] Deborah Matherly, Neeli Langdon, Brian Wolshon, Pamela Murray-Tuite, John Renne, Roberta Thomas, Jane Mobley y Kelly Reinhardt. 2014.
Guía para la planificación del transporte regional en caso de desastres, emergencias y eventos significativos. Informe 777 del Programa Nacional Cooperativo de Investigación de Carreteras (NCHRP), Proyecto n.° NCHRP 20-59(42). Publicaciones de la TRB.

[35] Abduallah Mohamed, Kun Qian, Mohamed Elhoseiny y Christian Claudel. 2020. Social-STGCNN: Una red neuronal convolucional de grafos espaciotemporales sociales para la predicción de trayectorias humanas. En Actas de la Conferencia IEEE/CVF sobre Visión por Computadora y Reconocimiento de Patrones. 14424–14432.

[36] Nashville. 2019. Calendario de eventos del Draft de la NFL de 2019. Obtenido de https://www.visitmusiccity.com/nfldraft/nfl-draft-calendario de eventos.

[37] Hao Peng, Bowen Du, Mingsheng Liu, Mingzhe Liu, Shumei Ji, Senzhang Wang, Xu Zhang y Lifang He. 2021.
Red neuronal convolucional gráfica dinámica para la predicción del flujo de tráfico a largo plazo mediante aprendizaje por refuerzo. Info. Sci. 578 (2021), 401–416. https://doi.org/10.1016/j.ins.2021.07.007

[38] Mayu Sakurada y Takehisa Yairi. 2014. Detección de anomalías mediante autoencoders con reducción de dimensionalidad no lineal. En Actas del 2.º Taller de MLSDA sobre Aprendizaje Automático para el Análisis de Datos Sensoriales. 4–11.

[39] Michael Schlichtkrull, Thomas N. Kipf, Peter Bloem, Rianne Van Den Berg, Ivan Titov y Max Welling. 2018. Modelado de datos relacionales con redes neuronales convolucionales de grafos. En Actas de la Conferencia Europea de la Web Semántica. Springer, 593–607.

[40] Yunsheng Shi, Zhengjie Huang, Shikun Feng, Hui Zhong, Wenjin Wang y Yu Sun. 2020. Predicción de etiquetas enmascaradas: modelo unificado de paso de mensajes para clasificación semisupervisada. Recuperado de https://arXiv:2009.03509.

[41] Nitish Srivastava, Geoffrey Hinton, Alex Krizhevsky, Ilya Sutskever y Ruslan Salakhutdinov. 2014. Dropout: Una forma sencilla de evitar el sobreajuste en redes neuronales. J. Mach. Learn. Res. 15, 1 (2014), 1929–1958.

[42] Ya Su, Youjian Zhao, Chenhao Niu, Rong Liu, Wei Sun y Dan Pei. 2019. Detección robusta de anomalías para series temporales multivariadas mediante redes neuronales recurrentes estocásticas. En Actas de la 25.ª Conferencia Internacional ACM SIGKDD sobre Descubrimiento de Conocimiento y Minería de Datos. 2828–2837.

[43] Huachun Tan, Jianshuai Feng, Guangdong Feng, Wuhong Wang y Yu-Jin Zhang. 2013. Datos atípicos sobre el volumen de tráfico Recuperación mediante modelo tensorial. Problemas de ingeniería matemática 2013 (2013).

[44] TDOT. 2019. Informe semanal de construcción del TDOT para el centro de Tennessee. Recuperado de https://preprod.tn.gov/tdot/news/2019/4/17/tdot-weekly-construction-report-for-middle-tennessee--april-18-24--2019.html .

[45] Fei Tian, Bin Gao, Qing Cui, Enhong Chen y Tie-Yan Liu. 2014. Aprendizaje de representaciones profundas para la agrupación de grafos. En Actas de la Asociación para el Avance de la Inteligencia Artificial (AAAI'14), Vol. 14. 1293–1299.

[46] NYC TLC. 2020. Datos de registro de viajes de TLC. Obtenido de https://www1.nyc.gov/site/tlc/index.page.

[47] Uber. 2020. Movimiento Uber. Recuperado de https://movement.uber.com/.

[48] Petar Veličković, Guillem Cucurull, Arantxa Casanova, Adriana Romero, Pietro Lío y Yoshua Bengio. 2017. Gráfico Redes de atención. Recuperado de https://arXiv:1710.10903.

[49] Chun Wang, Shirui Pan, Guodong Long, Xingquan Zhu y Jing Jiang. 2017. Mgae: Autoencoder de grafos marginalizado para agrupamiento de grafos. En Actas de la Conferencia ACM sobre Gestión de Información y Conocimiento. 889–898.

[50] Meng-Xiang Wang, Wang-Chien Lee, Tao-Yang Fu y Ge Yu. 2020. Sobre el aprendizaje de representaciones para redes viales. ACM Trans. Intell. Syst. Technol. 12, 1 (2020), 1–27.

[51] Yuandong Wang, Hongzhi Yin, Hongxu Chen, Tianyu Wo, Jie Xu y Kai Zheng. 2019. Predicción de la matriz origen-destino mediante convolución gráfica: una nueva perspectiva del modelado de la demanda de pasajeros. En Actas de la 25.ª Conferencia Internacional ACM SIGKDD sobre Descubrimiento de Conocimiento y Minería de Datos. 1227–1235.

[52] Yuandong Wang, Hongzhi Yin, Tong Chen, Chunyang Liu, Ben Wang, Tianyu Wo y Jie Xu. 2021. Gallat: Una red de atención gráfica espacio-temporal para la predicción de la demanda de pasajeros. En Actas de la 37.ª Conferencia Internacional IEEE sobre Ingeniería de Datos (ICDE'21). 2129–2134. https://doi.org/10.1109/ICDE51399.2021.00212 [53] Zihan Wang, Zhaochun Ren,
Chunyu He, Peng Zhang y Yue Hu. 2019. Incrustaciones robustas con estructuras multinivel para la predicción de enlaces. En Actas de la Conferencia Conjunta Internacional sobre Inteligencia Artificial (IJCAI'19).
5240–5246.

[54] Felix Wu, Amauri Souza, Tianyi Zhang, Christopher Fifty, Tao Yu y Kilian Weinberger. 2019. Simplificación de redes neuronales convolucionales gráficas. En Actas de la Conferencia Internacional sobre Aprendizaje Automático. PMLR, 6861–6871.

[55] Zonghan Wu, Shirui Pan, Fengwen Chen, Guodong Long, Chengqi Zhang y S. Yu Philip. 2020. Un completo Estudio sobre redes neuronales gráficas. IEEE Trans. Neural Netw. Learn. Syst. 32, 1 (2020), 4–24.

[56] Haowen Xu, Wenxiao Chen, Nengwen Zhao, Zeyan Li, Jiahao Bu, Zhihan Li, Ying Liu, Youjian Zhao, Dan Pei, Yang Feng et al. 2018.
Detección de anomalías no supervisadas mediante codificador automático variacional para KPI estacionales en aplicaciones web.
En Actas de la Conferencia Mundial de la Web. 187–196.

Machine Translated by Google

[57] Bishan Yang, Wen-tau Yih, Xiaodong He, Jianfeng Gao y Li Deng. 2014. Incorporación de entidades y relaciones para Aprendizaje e inferencia en bases de conocimiento. Recuperado de https://arXiv:1412.6575.

[58] Shiming Yang, Konstantinos Kalpakis y Alain Biem. 2014. Detección de eventos de tráfico rodado mediante el acoplamiento de múltiples series temporales con un método bayesiano no paramétrico. IEEE Trans. Intell. Transport. Syst. 15, 5 (2014), 1936–1946.

[59] Bing Yu, Haoteng Yin y Zhanxing Zhu. 2017. Redes neuronales convolucionales espaciotemporales: un marco de aprendizaje profundo para la predicción del tráfico. Actas de la 27.ª Conferencia Internacional Conjunta sobre Inteligencia Artificial (IJCAI'17).

[60] Bing Yu, Haoteng Yin y Zhanxing Zhu. 2018. Redes neuronales convolucionales espaciotemporales: Un marco de aprendizaje profundo para la predicción del tráfico. En Actas de la 27.ª Conferencia Internacional Conjunta sobre Inteligencia Artificial (IJCAI'18). Organización de Conferencias Internacionales Conjuntas sobre Inteligencia Artificial, 3634–3640 . https://doi.org/10.24963/ijcai.2018/505

[61] Wenchao Yu, Wei Cheng, Charu C. Aggarwal, Kai Zhang, Haifeng Chen y Wei Wang. 2018. Netwalk: Un enfoque flexible de incrustación profunda para la detección de anomalías en redes dinámicas. En Actas de la 24.ª Conferencia Internacional ACM SIGKDD sobre Descubrimiento de Conocimiento y Minería de Datos. 2672–2681.

[62] Shuangfei Zhai, Yu Cheng, Weining Lu y Zhongfei Zhang. 2016. Modelos basados en energía estructurada profunda para la detección de anomalías. En Actas de la 33.ª Conferencia Internacional sobre Aprendizaje Automático-Volumen 48. 1100–1109.

[63] Xiyue Zhang, Chao Huang, Yong Xu y Lianghao Xia. 2020. Redes de atención gráfica convolucionales espacio-temporales para la predicción del flujo de tráfico en toda la ciudad. En Actas de la 29.ª Conferencia Internacional ACM sobre Gestión de la Información y el Conocimiento (CIKM'20). ACM, Nueva York, NY, 1853–1862. https://doi.org/10.1145/3340531.3411941 [64] Zikai Zhang, Yidong Li, Haifeng Song y Hairong Dong. 2021. Predicción de la velocidad del tráfico basada en múltiples gráficos dinámicos Método. Neurocomputing 461 (2021), 109–117. https://doi.org/10.1016/j.neucom.2021.07.052

[65] Li Zheng, Zhenpeng Li, Jian Li, Zhao Li y Jun Gao. 2019. AddGraph: Detección de anomalías en grafos dinámicos mediante GCN temporal basada en atención. En Actas de la Conferencia Conjunta Internacional sobre Inteligencia Artificial (IJCAI'19). 4419–4425.

[66] Chong Zhou y Randy C. Paffenroth. 2017. Detección de anomalías con autoencoders profundos robustos. En Actas de la XXIII Conferencia Internacional ACM SIGKDD sobre Descubrimiento de Conocimiento y Minería de Datos. 665–674.

[67] Jie Zhou, Ganqu Cui, Shengding Hu, Zhengyan Zhang, Cheng Yang, Zhiyuan Liu, Lifeng Wang, Changcheng Li y Maosong Sun. 2020. Redes neuronales gráficas: una revisión de métodos y aplicaciones. AI Open 1 (2020), 57–81.

[68] Le-kui Zhou, Yang Yang, Xiang Ren, Fei Wu y Yueting Zhuang. 2018. Integración dinámica de redes mediante el modelado del proceso de cierre triádico. En Actas de la Asociación para el Avance de la Inteligencia Artificial (AAAI'18). 571–578.

[69] Dali Zhu, Yuchen Ma y Yinlong Liu. 2020. DeepAD: Un enfoque de incrustación conjunta para la detección de anomalías en redes con atributos. En Actas de la Conferencia Internacional sobre Ciencias Computacionales. Springer, 294–307.

[70] Bo Zong, Qi Song, Martin Renqiang Min, Wei Cheng, Cristian Lumezanu, Daeki Cho y Haifeng Chen. 2018. Modelo de mezcla gaussiana de autoencoder profundo para detección de anomalías no supervisada. En Actas de la Conferencia Internacional sobre Representaciones de Aprendizaje.

Recibido en julio de 2021; revisado en marzo de 2022; aceptado en mayo de 2022.