Machine Translated by Google

Revista Internacional de Información geográfica

MDPI

Artículo

Detección de anomalías en el tráfico urbano mediante datos de monitorización del tráfico.

Yunkun Mao [1], Yilin Shi [1,2] y Binbin Lu [1,*]

[1] Escuela de Teledetección e Ingeniería de la Información, Universidad de Wuhan, Wuhan 430072, China; maoyunkun@whu.edu.cn (YM); yilinshi@whu.edu.cn (YS)
[2] Facultad de Informática, Universidad de Wuhan, Wuhan 430072, China
* Correspondencia: binbinlu@whu.edu.cn

Resumen: La detección de anomalías en el tráfico es crucial para la gestión urbana, pero la investigación actual suele limitarse a proyectos a pequeña escala. Este estudio recopiló 9 meses de datos de monitorización del tráfico en tiempo real de Wuhan de Amap. Proponemos Traffic-ConvLSTM, una técnica espaciotemporal multiescala basada en redes de memoria a corto y largo plazo (LSTM) y redes neuronales convolucionales (CNN) para lograr de forma eficaz la detección de anomalías a largo plazo a nivel de ciudad. En primer lugar, convertimos los puntos de la trayectoria del tráfico en una representación de imagen, lo que permite capturar la correlación espacial entre el flujo de tráfico y las carreteras , así como las correlaciones entre el flujo de tráfico y las carreteras, y el entorno circundante . En segundo lugar, el modelo utiliza núcleos de convolución de diferentes tamaños para extraer características espaciales a escalas de carretera, regional y de ciudad, al tiempo que incorpora las características temporales de diferentes intervalos de tiempo para capturar la dinámica horaria, diaria y semanal. Además, se asignan diferentes ponderaciones a los núcleos de convolución y a las características temporales de distintas escalas espaciotemporales para capturar la heterogeneidad de las correlaciones espaciotemporales dentro de los patrones de anomalías de tráfico. El modelo Traffic-ConvLSTM propuesto muestra un rendimiento superior al de las técnicas existentes en la identificación de anomalías de tráfico a largo plazo y a gran escala. Asimismo, el análisis revela anomalías de tráfico significativas durante los días festivos y los eventos deportivos urbanos. Los diversos patrones de desplazamiento observados en respuesta a diferentes actividades ofrecen información valiosa para la gestión de anomalías de tráfico urbano a gran escala , proporcionando recomendaciones para estrategias de control de tráfico a nivel municipal.

Palabras clave: anomalías de tráfico; datos de tráfico en tiempo real; aprendizaje profundo; inteligencia artificial; múltiples escalas espacio-temporales

check for updates

Cita: Mao, Y.; Shi, Y.; Lu, B. Detección de anomalías en el tráfico urbano mediante datos de monitorización del tráfico. ISPRS Int. J. Geo-Inf. 2024, 13 , 351. https://doi.org/10.3390/ijgi13100351

Editores académicos: Wolfgang Kainz, Hartwig H. Hochmair, Hao Li y Levente Juhasz

Recibido: 25 de julio de 2024
Revisado: 2 de octubre de 2024
Aceptado: 2 de octubre de 2024
Publicado: 4 de octubre de 2024

Derechos de autor: © 2024 por los autores. Publicado por MDPI en nombre de la Sociedad Internacional de Fotogrametría y Teledetección.
Titular de la licencia: MDPI, Basilea, Suiza.
Este artículo es de acceso abierto. distribuido bajo los términos y condiciones de Creative Commons Licencia de atribución (CC BY) (https:// creativecommons.org/licenses/by/4.0/).

1. Introducción

La congestión del tráfico se ha convertido en un problema cada vez más grave debido a la creciente urbanización global. Estudios previos han demostrado que la congestión anormal del tráfico es la principal causa de la congestión a gran escala [1–3]. Sin embargo, durante mucho tiempo, el sector del transporte se ha centrado más en la predicción y la optimización en condiciones normales. Los eventos de tráfico anómalos reciben relativamente poca atención. Por lo tanto, la identificación oportuna de la congestión anormal del tráfico es necesaria, ya que ayuda a prevenir que los problemas de tráfico se conviertan en problemas a gran escala, mitigando así la congestión urbana y mejorando las condiciones generales del tráfico en una ciudad.

Actualmente, las anomalías de tráfico carecen de una definición clara y unificada. En las grandes ciudades con formas urbanas desarrolladas de manera estable, las actividades urbanas tienden a mostrar patrones espaciales y ciclos temporales regulares. En consecuencia, los flujos de tráfico generados por estas actividades heredan patrones espaciales y temporales similares, lo que da como resultado eventos de tráfico con características periódicas predecibles [4]. En este artículo, definimos los patrones de tráfico periódicos y predecibles como los eventos de tráfico normales de una ciudad. Estos eventos pueden ser la congestión de una carretera popular durante las horas pico de desplazamiento, el flujo constante de tráfico en una circunvalación de la ciudad o la fluidez prolongada de un tramo determinado de una autopista. Basándose en los patrones de incidentes de tráfico en términos de tiempo y lugar de ocurrencia, los investigadores pueden predecir eventos similares futuros con considerable precisión. Por ejemplo, si se sabe que se produce una congestión de

Machine Translated by Google

Si observamos una intersección específica cada día laborable a las 18:00, podemos prever que al día siguiente se producirá una congestión de aproximadamente una hora en esa misma intersección, afectando a los tramos de carretera cercanos. Por el contrario, las anomalías de tráfico se desvían de estos patrones normales en los flujos urbanos cotidianos. Estos eventos anómalos están influenciados por diversos factores como la ubicación espacial, el entorno, la hora y las percepciones subjetivas de los participantes. Presentan variaciones significativas en sus patrones de ocurrencia, duración y extensión espacial, careciendo de la periodicidad espacial y temporal característica de los patrones de tráfico normales. En consecuencia, estas anomalías son particularmente difíciles de predecir con precisión.

Según el alcance del impacto de los eventos de tráfico anómalos en el tráfico urbano, los dividimos en tres niveles: nivel de ciudad, nivel regional y nivel de carretera. Actualmente , las principales ciudades de China se dividen en subregiones administrativas, cada una con sus propias divisiones administrativas, funciones urbanas y estructura demográfica, por lo que las características del flujo de tráfico suelen ser diferentes en cada región. En base a esto, definimos lo siguiente: Cuando un evento de tráfico anómalo genera un flujo de tráfico anómalo en múltiples áreas de la ciudad simultáneamente, se considera un evento de tráfico anómalo a nivel de ciudad.

Por lo tanto, si el flujo de tráfico anómalo causado por el incidente afecta únicamente a una zona determinada, se trata de un incidente de tráfico anómalo de ámbito regional. Si, por el contrario, afecta únicamente al tramo de carretera adyacente, se trata de un incidente de tráfico anómalo de ámbito vial.

Los métodos anteriores para detectar anomalías en el flujo de tráfico se pueden clasificar en tres grandes grupos: series temporales, descomposición tensorial y métodos basados en aprendizaje profundo.
El enfoque de series temporales utiliza principalmente el modelo autorregresivo integrado de media móvil (ARIMA) y sus variantes [5–7]. Estos métodos se centran en los aspectos temporales del flujo de tráfico, pero a menudo pasan por alto las características espaciales, lo que conduce a resultados subóptimos. Los métodos de descomposición tensorial [8–10] pueden capturar eficazmente las anomalías espaciotemporales, pero su rendimiento es susceptible a configuraciones de parámetros complejas, y las configuraciones inadecuadas comprometen fácilmente la precisión del análisis. En los últimos años, los investigadores han recurrido cada vez más a métodos basados en aprendizaje profundo para la detección de anomalías de tráfico, inspirados por el notable éxito del aprendizaje profundo en la visión por computadora y otros dominios. A diferencia de los métodos tradicionales basados en parámetros, los modelos de aprendizaje profundo extraen características intrínsecas de grandes cantidades de datos brutos utilizando una arquitectura de red multicapa. Varios estudios [11–13] se propusieron extraer directamente patrones de tráfico normales de las características clave de los datos originales para predecir el flujo de tráfico. En otros trabajos, combinaron redes neuronales convolucionales y redes de memoria a corto y largo plazo con un mecanismo de atención para construir modelos híbridos de aprendizaje profundo [14–19] que permiten un análisis exhaustivo de las características espaciotemporales de los datos. En general, estos modelos buscan mejorar la comprensión e interpretación de las relaciones espaciotemporales en los datos de flujo de tráfico, abordando los desafíos fundamentales en la detección de anomalías en el tráfico.

Sin embargo, la investigación actual sobre la detección de anomalías en el tráfico se limita principalmente a segmentos viales específicos o áreas pequeñas, centrándose en fluctuaciones a corto plazo en lugar de abordar patrones a escala urbana durante períodos más largos. Esto podría comprometer la capacidad de los modelos para capturar la complejidad total de los diversos patrones y anomalías del tráfico en diferentes contextos urbanos. Para abordar esta brecha, recopilamos 9 meses de datos de monitoreo de tráfico en tiempo real de Wuhan de Amap. Con el fin de lograr una detección de anomalías a largo plazo efectiva a nivel de ciudad, propusimos Traffic-ConvLSTM, una técnica espacio-temporal multiescala basada en redes de memoria a corto y largo plazo (LSTM) y redes neuronales convolucionales (CNN). En este estudio, las principales contribuciones se pueden resumir de la siguiente manera:

- Desarrollamos un algoritmo de procesamiento de datos que convierte datos de trayectoria de baja frecuencia en una estructura de datos similar a una imagen para su posterior análisis.
- Con el fin de identificar eficazmente patrones de anomalías de tráfico en múltiples escalas temporales y espaciales, proponemos una ConvLSTM mejorada [20], y los resultados muestran que el modelo puede identificar eficazmente anomalías de tráfico mediante un estudio de caso en Wuhan.

Machine Translated by Google

Este estudio se estructura de la siguiente manera: La sección 2 revisa los trabajos relacionados con este tema. La sección 3 presenta los datos de monitorización de tráfico y el método Traffic-ConvLSTM propuesto. La sección 4 muestra los resultados del estudio. La sección 5 presenta las conclusiones.

2. Trabajos relacionados

Los métodos principales incluyen el enfoque de series temporales, la técnica de descomposición tensorial y la estrategia de aprendizaje profundo.

El método de series temporales, el más utilizado, se basa en el modelo de media móvil integral autorregresiva. Como modelo clásico de predicción de series temporales, el modelo ARIMA se aplica a la identificación de anomalías en autopistas y vías arteriales urbanas [21,22]. Se han propuesto varias mejoras al modelo ARIMA para optimizar su rendimiento y alcance. Por ejemplo, el modelo KARIMA, que combina la red de Kohonen con el modelo ARIMA [5], y el modelo ARIMAX, que integra el modelo ARIMA con variables explicativas [7], son ejemplos de dichas mejoras. Además, se ha propuesto un modelo espacio-temporal unificado basado en la media móvil integrada autorregresiva espacio-temporal (STARIMA) para capturar las intrincadas estructuras de correlación espacio-temporal del tráfico rodado [6]. Estos avances buscan abordar las limitaciones inherentes del modelo ARIMA, como su incapacidad para manejar datos no lineales y su desprecio por la información espacial.

La metodología de descomposición tensorial tiene como objetivo desarrollar un modelo de series temporales eficaz que capture el patrón espacio-temporal inherente, transforme los datos de tráfico en vectores de alta dimensión e identifique anomalías calculando un buen número de características.
Actualmente, los métodos de reconocimiento de patrones de anomalías de tráfico basados en la descomposición tensorial se clasifican en dos grupos: métodos basados en factores característicos [8,9] y métodos basados en errores de reconstrucción [10]. El método basado en factores característicos descompone los datos originales, los compara con datos históricos e identifica como anomalías cualquier valor que supere un umbral predeterminado [8]. Por otro lado, el método basado en errores de reconstrucción sostiene que los datos de tráfico pueden separarse entre actividades urbanas típicas y perturbaciones causadas por anomalías. Al extraer el tensor anómalo de los datos de tráfico, se puede determinar el tiempo y la ubicación de los eventos anómalos, y estos eventos pueden analizarse posteriormente [23].

Las técnicas de aprendizaje profundo se pueden aplicar ampliamente a la detección de anomalías en el tráfico y se dividen en dos etapas. Los primeros investigadores se propusieron extraer características de los datos de flujo de tráfico para identificar directamente patrones anómalos. Se han propuesto varios métodos, como los autoencoders apilados (SAE) [11], las redes de memoria a corto y largo plazo (LSTM) [12] y las redes neuronales convolucionales (CNN), para analizar los datos de flujo de tráfico [13]. Sin embargo, estos métodos utilizan una estructura de red relativamente simple, lo que dificulta aprovechar eficazmente las intrincadas relaciones espacio-temporales presentes en los datos de flujo de tráfico. Como resultado, su capacidad para detectar patrones de tráfico anómalos es limitada. Trabajos posteriores han buscado integrar las características de los métodos convolucionales y las redes neuronales recurrentes. Estos modelos capturan las características espaciales del flujo de tráfico en una región utilizando redes neuronales convolucionales y luego transfieren las características extraídas a redes LSTM para extraer características temporales. Esto permite crear un modelo híbrido de aprendizaje profundo con un mecanismo de atención [14–16] que analiza exhaustivamente las características espacio-temporales en los datos. Otros trabajos han intentado capturar las características espaciales en los datos utilizando redes generativas antagónicas (GAN) [17–19], lo que ha mejorado enormemente la practicidad y la precisión de detección del modelo. Sin embargo, el reconocimiento de patrones de tráfico anormales es una tarea compleja que difiere de las tareas de clasificación ordinarias. Está influenciado por varios factores, incluyendo la ubicación espacial, el entorno, el tiempo y los sentimientos subjetivos de los participantes, lo que dificulta a los investigadores definir con precisión los eventos de tráfico anormales.
Inspirándonos en trabajos previos sobre detección de anomalías y predicción de fotogramas de vídeo en vídeos de vigilancia [20,24–30], desarrollamos el modelo Traffic-ConvLSTM. Este modelo ConvLSTM no supervisado aprende patrones de tráfico normales a partir del flujo de tráfico diario e identifica patrones de tráfico anormales basándose en esta información. Figura 1

Machine Translated by Google

ilustra la correspondencia espacio-temporal del modelo con los eventos de tráfico del conjunto de datos original. Los eventos con un amplio impacto espacial presentan ciclos de ocurrencia temporal más largos, lo que resulta en una menor frecuencia de dichos eventos en el conjunto de datos. Este diseño se alinea con la menor frecuencia característica de eventos geográficos de alto impacto observados en el mundo real. A diferencia de los trabajos existentes, el modelo emplea un núcleo de convolución variable para extraer las características de los eventos de tráfico en diferentes escalas espaciales y relaciona la escala temporal de los eventos con la escala espacial para analizar las características espacio-temporales de los eventos de manera integrada. Esto permite que el modelo capture características espaciales multiescala y características de ciclo temporal, manteniendo al mismo tiempo la robustez del modelo en cada escala temporal y es Finalmente, el modelo fusiona la información espacio-temporal multiescala para obtener mejor las características generales de los eventos de tráfico.

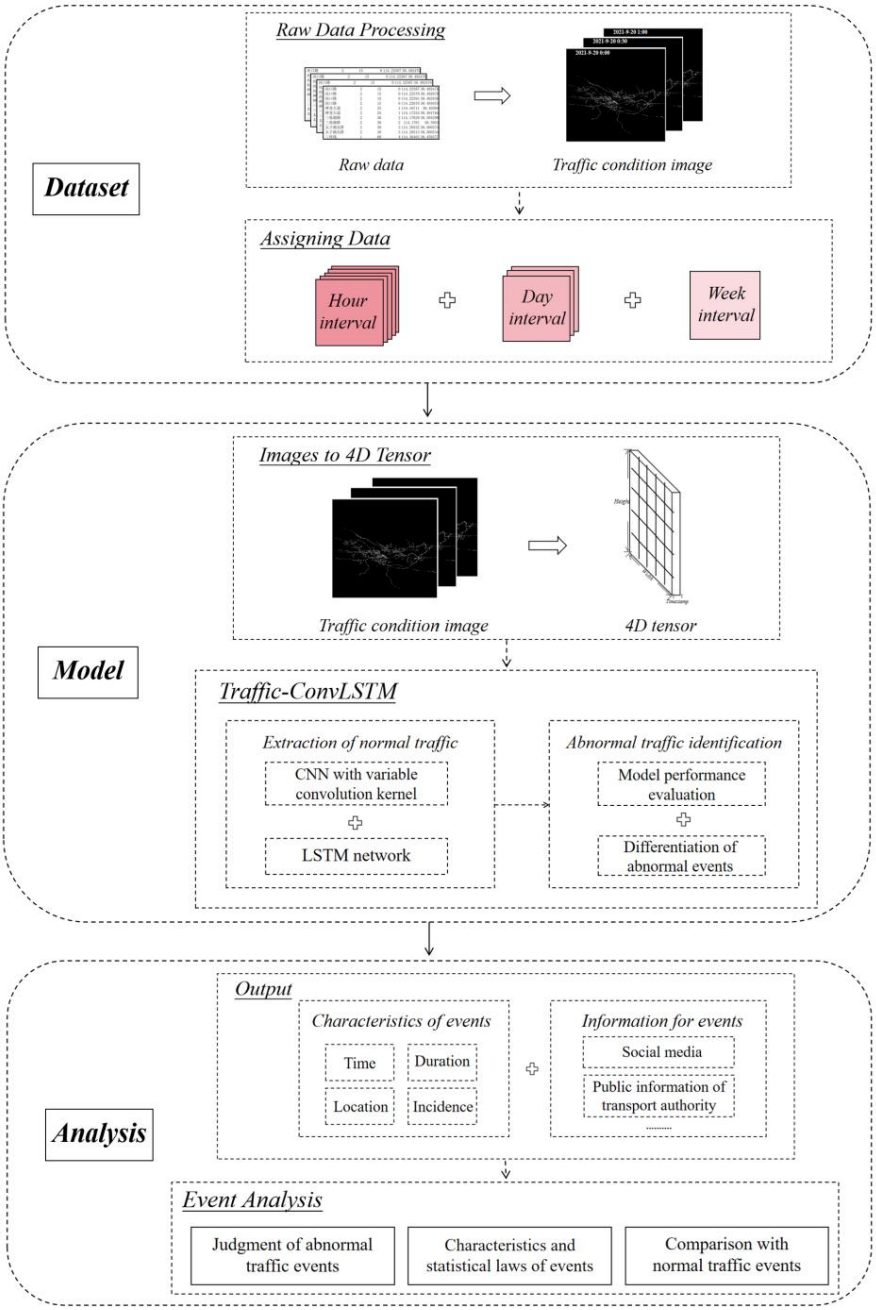


Figura 1. Marco de detección y análisis de anomalías en el tráfico urbano.

Machine Translated by Google

3. Datos y métodos

Los datos tradicionales de flujo de tráfico presentan numerosas deficiencias a la hora de expresar las características espaciales y temporales de los eventos de tráfico. Para extraer mejor las características de estos eventos, transformamos los datos de flujo de tráfico en una imagen de las condiciones del tráfico según ciertas reglas. A partir de este modelo de imagen, aprendemos las características de un patrón de tráfico normal y, posteriormente, detectamos eventos de tráfico anómalos.

3.1. Descripción y preprocesamiento de los datos

Los datos de tráfico en tiempo real de las principales carreteras de Wuhan se obtuvieron a través de la API de Amap durante el período comprendido entre el 20 de septiembre de 2021 y el 17 de junio de 2022. Los datos de trayectoria de múltiples fuentes recopilados provienen principalmente de los datos de crowdsourcing proporcionados por los usuarios y de los propios datos recopilados por Amap. La cobertura de los datos se muestra en la Figura 2. Se desarrolló un sistema de indicadores de cuatro niveles para evaluar la fluidez del tráfico. El sistema clasifica las condiciones del tráfico como: Sin impedimentos, donde los vehículos pueden circular a la velocidad máxima factible para el tramo de carretera dado; Básicamente sin impedimentos, lo que indica que la carretera sigue siendo transitable, pero con velocidades de los vehículos notablemente reducidas; Congestión leve, que describe un tramo de carretera apenas transitable con velocidades medias de los vehículos inferiores a un quinto de la velocidad máxima; y Congestión severa, que denota un tramo de carretera intransitable en el momento dado, con la mayoría de los vehículos detenidos. El rango espacial de los puntos de muestreo es de 30–32°
El conjunto de datos se muestrea uniformemente cada media hora en Wuhan, y se obtienen aproximadamente 60 000 datos de tráfico en tiempo real en cada muestreo, lo que suma aproximadamente 60 millones de registros durante el período de estudio. Como se muestra en la Tabla 1, los detalles del conjunto de datos incluyen el tiempo de muestreo y el tramo de carretera, así como la velocidad del vehículo, la longitud y la latitud.

Para abordar la escasez de datos de puntos de trayectoria necesarios para transmitir las características espaciotemporales del flujo de tráfico, es crucial preprocesar los datos brutos para adaptarlos a los métodos analíticos posteriores. La entrada de un modelo de aprendizaje profundo suele ser datos de imagen o secuencia, lo que requiere el preprocesamiento de los datos de puntos de trayectoria del vehículo obtenidos. Algunos estudios [14,16] esperan utilizar una red de grafos para organizar los datos de trayectoria del tráfico, pero una red de grafos es más adecuada para los datos de trayectoria del vehículo obtenidos por sensores, y los datos de puntos de trayectoria basados en el posicionamiento tienen un rendimiento deficiente en precisión y eficiencia de procesamiento de datos. Un número considerable de estudios [13,17,18,31] han demostrado la eficacia de convertir puntos de trayectoria en imágenes para capturar las características espaciales del flujo de tráfico utilizando técnicas de aprendizaje profundo. Basado en la investigación existente, este artículo propone un método para convertir los datos de puntos de trayectoria del tráfico e

Al utilizar datos de trayectorias de tráfico para evaluar las condiciones del tráfico vial, la velocidad instantánea del vehículo constituye la métrica de evaluación más directa y eficaz. Varios métodos analíticos [13,17,18] también se basan en la velocidad instantánea derivada de los puntos de la trayectoria. Nuestro método también se basa en la velocidad instantánea de los puntos de la trayectoria.
El valor promedio de la velocidad de cada punto de la trayectoria se normalizó y luego el rango se redujo a [0, 255] para construir la imagen de tráfico. Dividimos el área de estudio en I × J , que se marca como S = {si,j}, donde las celdas de de las celdas de la cuadrícula es ls , 1 ≤ i ≤ I, 1 ≤ j ≤ J, y las carreteras la cuadrícula son cuadradas; la longitud del lado en el área de estudio se denotan como R = {rk}. Los valores de píxeles de las imágenes de condiciones de tráfico (TCI) se calculan de la siguiente manera:

$$vr = \frac{\sum_{k=1}^{norte} vk}{norte} \quad (1)$$

$$vn,k = \frac{vr - vk}{vmax - vmin} \quad (2)$$

$$pi,j = \begin{cases} \frac{(vr-vk)}{vmax-vmin} \times 255 \text{ si } vn < vr, n & si,j \\ 0 & \text{de lo contrario} \end{cases} \quad (3)$$

donde vk es la velocidad del punto de la vía y vr es la velocidad de la carretera, que representa el promedio de las velocidades de todos los puntos de la vía en la carretera rk en un momento dado. vn,k es la velocidad relativa

Machine Translated by Google

velocidad de la carretera, que se utiliza para caracterizar el nivel de congestión en el área en la que El punto de seguimiento se encuentra en ese momento, y pi,j es el valor del píxel del tráfico. imágenes de condición en i,j. Se puede ver en la fórmula que cuando la velocidad de la pista Si el punto es menor que la velocidad promedio de la sección de la carretera, el punto de la pista se mostrará en la imagen. Cuanto mayor sea la diferencia entre ambas, mayor será el brillo del píxel. Cuando se acumulan varios puntos de alto brillo, el tramo de carretera puede presentar tráfico anormal. eventos. Después de obtener las imágenes de las condiciones del tráfico, se utilizan técnicas estándar de procesamiento de imágenes. Se puede utilizar para redimensionar las imágenes a las dimensiones deseadas.

Para aprender mejor las características temporales de los eventos de tráfico, construimos tres series temporales con diferentes intervalos de tiempo para representar las características temporales horarias, diarias y semanales de los patrones de tráfico, respectivamente. En general, el impacto entre dos eventos con intervalos de eventos más cortos deberían ser más fuertes. Por lo tanto, combinamos las tres series temporales. en una proporción determinada para construir un conjunto de entrenamiento del modelo para simular el impacto de diferentes características de escala de tiempo en eventos en eventos de tráfico reales. Eventos de tráfico anómalos que ocurren en Los datos de Wuhan durante un período de un año se cuantificaron mediante análisis estadístico de los datos obtenidos. de diversas fuentes, incluidas plataformas de internet, medios de comunicación y fuentes disponibles públicamente Información de la Oficina de Gestión de Tráfico de Wuhan. Este análisis arrojó la frecuencia de ocurrencia de eventos de tráfico anómalos en tres espacios-temporales distintos. escalas. En el nuevo conjunto de datos, la proporción de datos de series temporales horarias, diarias y semanales es de 16:3:1.

Tabla 1. Conjunto de datos de tráfico en tiempo real de Wuhan.

Fecha	Velocidad	Ubicación del vehículo	Velocidad [1]	Longitud	Latitud
21/09/2021	0:00	Tercera carretera de circunvalación	70	114.442	30.467
21/09/2021	0:30	Avenida del lago Zhushan	35	114.133	30.462
22/09/2021	8:30	Avenida Shenlong	25	114.172	30.491

[1] La unidad de velocidad es km/h.

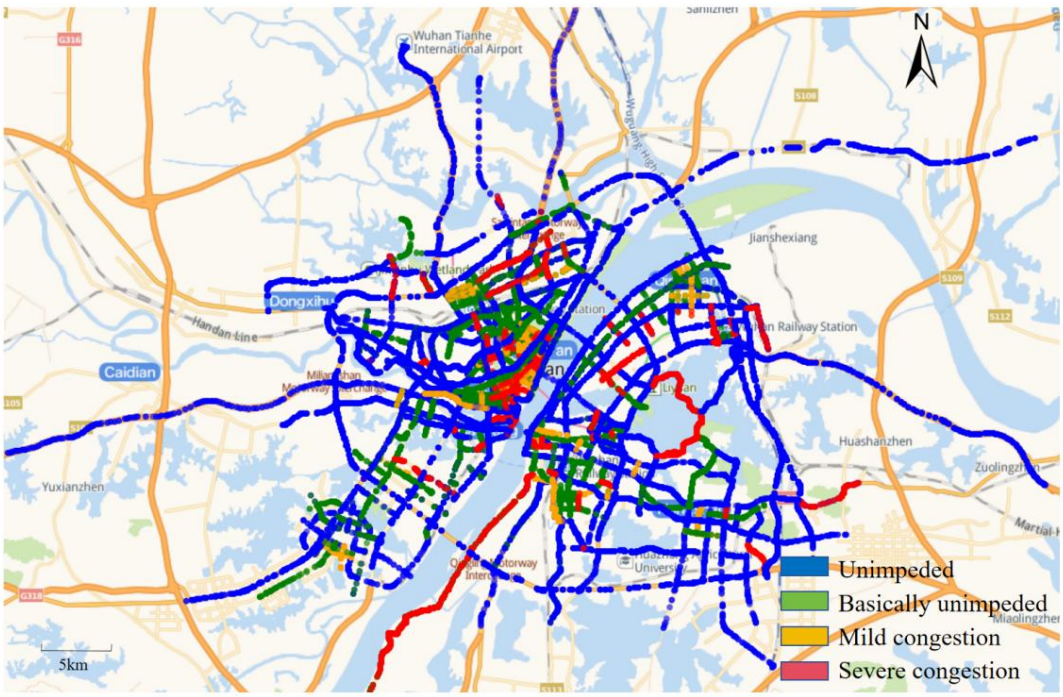


Figura 2. Área de recopilación de datos de tráfico en tiempo real.

3.2. Traffic-ConvLSTM

Varios estudios han demostrado la relación significativa entre la intensidad de los eventos naturales y la probabilidad de su ocurrencia. Generalmente, cuando la Cuanto mayor sea la intensidad, menor será la probabilidad de ocurrencia. Por lo tanto,

Machine Translated by Google

Proponer una hipótesis sobre la relación entre el tamaño de un evento anómalo de tráfico y la frecuencia de los eventos para mejorar la tarea de reconocimiento de patrones de tráfico anómalos. Específicamente, postulamos que, en ausencia de influencia externa, la probabilidad de un evento disminuye a medida que aumenta su escala. En otras palabras, a medida que se expande el impacto temporal y espacial de un evento, disminuye la probabilidad de que ocurra y aumenta el intervalo de tiempo entre eventos. Por lo tanto, si un evento de tráfico se extiende más allá de los límites espaciales normales, se considera un evento de tráfico anómalo. En términos sencillos, si muchas personas en un vecindario extenso modifican sus hábitos de viaje habituales, el evento que provoca este cambio tiene una alta probabilidad de ser un evento de tráfico anómalo.

Con las suposiciones anteriores, proponemos el modelo Trafic-ConvLSTM. Este modelo es una red neuronal generativa no supervisada que aprende espontáneamente las características temporales y espaciales del flujo de tráfico de Wuhan a partir de los datos de trayectoria de los vehículos , considerando los eventos de tráfico anómalos como errores groseros en los eventos de tráfico normales. El resultado es un modelo de flujo de tráfico normal de Wuhan. Al comparar este modelo con el flujo de tráfico real de Wuhan, se pueden identificar eventos de tráfico anómalos. El modelo utiliza una estructura de codificador-pronóstico. En la capa del codificador, se emplean tres núcleos de convolución de diferentes tamaños para extraer las características espaciales a nivel de ciudad, regional y vial, desde la escala más amplia hasta la más pequeña. Las características espaciales extraídas se copian a la capa de predicción, y la predicción de la serie temporal se realiza en función del intervalo de tiempo seleccionado. Finalmente, se genera una imagen de salida del mismo tamaño que la imagen de entrada . A diferencia de la salida separada de la estructura seq2seq, la capa de predicción combinará las tres entradas de características espaciotemporales con diferentes escalas para realizar la predicción final y generar una imagen del mismo tamaño que la entrada. El resultado generado contendrá información sobre características espaciotemporales de múltiples escalas. En la capa de predicción, las características espaciales extraídas por el núcleo de convolución más grande se ubican al principio de la secuencia RNN del decodificador, lo que hará que las características con la mayor escala espacial tengan el menor impacto en los resultados predichos [23]. Esto permite que el modelo aprenda más sobre las características espaciales de pequeña escala y enfatiza la influencia del estado futuro del bloque adyacente. El proceso de filtrado convolucional se puede representar de la siguiente manera:

$$Yt = \sigma(Ws \times Xt + bs) \tag{4}$$

donde σ es el peso del filtro, Ws es la imagen de tráfico de entrada en el instante t, bs es el sesgo y Yt es la salida de la capa de convolución. El siguiente párrafo describe un método para extraer características espaciales de los datos de flujo de tráfico.

La estructura del modelo Traffic-ConvLSTM propuesto en este artículo se muestra en Figura 3, y la fórmula de cálculo en la capa ConvLSTM es la siguiente:

$$\begin{aligned} &it = \sigma(Wxi \times xt + Whi \times ht-1 + bi) \\ &ft = \sigma(Wx f \times xt + Wh f \times ht-1 + bf) \\ &ot = \sigma(Wxo \times xt + Who \times ht-1 + bo) \\ &gt = \tanh(Wxg \times xt + Whg \times ht-1 + bg) \\ &ct = ft \quad ct-1 + it \quad gt \\ &ht = ot \quad \tanh(ct) \end{aligned} \tag{5}$$

El objetivo principal del modelo es disminuir la influencia de las características espaciales obtenidas de grandes núcleos de convolución en las predicciones, así como la proporción de características a gran escala en los datos de series temporales. Este procedimiento tiene dos propósitos. Primero, según la primera ley de la geografía refinada [32], cuanto mayor sea la distancia espacial y el intervalo de tiempo entre dos sucesos geográficos en la misma ciudad, más débil será la asociación entre ambos. Por lo tanto, cuando la proximidad espacio-temporal de dos eventos de tráfico es limitada, el peso de usar el estado del evento A para predecir el evento B debería ser menor. Segundo, según esta suposición, los valores de las características extraídos a una escala espacio-temporal mayor son vulnerables a la interferencia de anomalías de tráfico y a la correlación espacio-te

Machine Translated by Google

Esto se suele pasar por alto a mayor escala, lo que dificulta la precisión del aprendizaje del modelo. En términos de rendimiento del modelo, esto reduce el impacto de eventos anómalos de tráfico significativos en el aprendizaje del modelo, lo que permite que este identifique con precisión dichos eventos en múltiples escalas temporales y espaciales.

El modelo utiliza el índice de similitud estructural (SSIM) como función de pérdida para el entrenamiento . Específicamente, utiliza el SSIM para determinar si se produce una intersección en el instante t. El algoritmo SSIM evalúa la similitud entre dos imágenes analizando su brillo, contraste y estructura. Considera factores como el flujo, la estructura y la permeabilidad del flujo de tráfico regional. Para compensar la distorsión causada por el muestreo de imágenes durante el entrenamiento, el modelo de flujo de tráfico relativo calculó el índice SSIM en 48 puntos temporales para todas las fechas y utilizó el promedio de estos índices en cada punto temporal como índice SSIM estándar para ese punto temporal. En total, se obtuvieron 7 × 48 índices SSIM estándar. Para detectar anomalías de tráfico, el modelo calcula la diferencia entre el índice SSIM de un área determinada en el instante t y el índice SSIM estándar. Si la diferencia supera el umbral, indica la ocurrencia de una anomalía de tráfico en esa área.

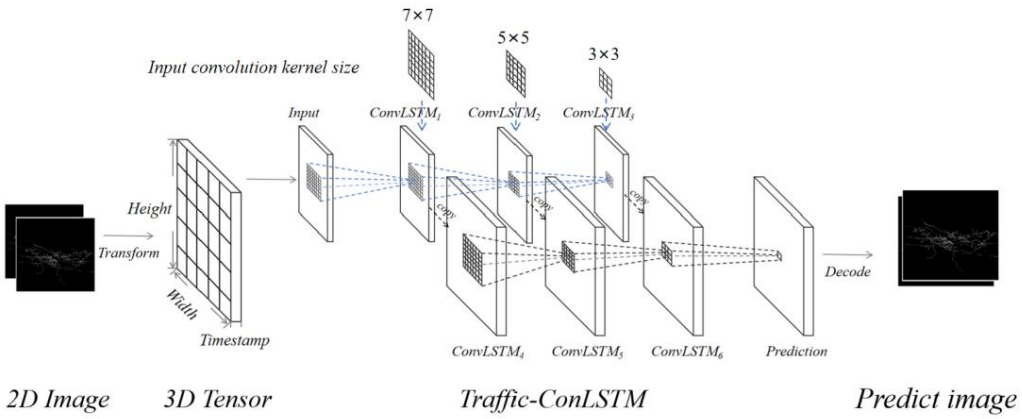


Figura 3. Estructura del modelo Traffic-ConvLSTM.

3.3. Índice de rendimiento

Para evaluar el rendimiento de nuestro modelo propuesto en la identificación de eventos de tráfico inusuales, empleamos dos métricas de evaluación de clasificación de uso común: exactitud y precisión [33]. Las fórmulas específicas para estas métricas de evaluación son las siguientes:

$$\text{Precisión} = \frac{Fp}{Pie} \times 100\% \quad (6)$$

$$\text{Precisión} = \frac{Fp}{Padre} \times 100\% \quad (7)$$

donde Fp denota el número de anomalías de tráfico identificadas correctamente por el modelo, Ft denota el número total de anomalías de tráfico producidas por el modelo, y Fr denota el número total de anomalías de tráfico incluidas en los ejemplos seleccionados.

4. Experimento

Para la construcción del modelo en nuestros experimentos, utilizamos la biblioteca de aprendizaje profundo Keras [34] y TensorFlow [35] para la manipulación de tensores. El modelo procesa imágenes de las condiciones del tráfico muestreadas a intervalos de 30 minutos, generando 48 resultados de detección diarios . Realizamos evaluaciones cuantitativas del rendimiento con base en estos resultados, comparándolos con los métodos de referencia. Además, las anomalías detectadas a largo plazo se analizaron exhaustivamente tanto a nivel de ciudad como de carretera.

4.1. Resultados de la evaluación

Comparamos nuestro modelo Traffic-ConvLSTM propuesto con tres modelos de referencia comunes. modelos para la detección de tráfico anómalo con el fin de validar el rendimiento de los modelos.

Machine Translated by Google

Autoencoder apilado (SAE) [11]: este modelo aprende la información implícita en los datos originales mediante el uso de múltiples codificadores apilados, y utilizamos un algoritmo de aprendizaje no supervisado jerárquico voraz para entrenar la red SAE profunda.

Modelo CNN-LSTM [12]: este modelo combina una red neuronal convolucional (CNN) con una red de memoria a corto y largo plazo (LSTM). Las características espaciales del flujo de tráfico se extraen mediante una red neuronal convolucional y se introducen en la capa LSTM. Las características espaciales y temporales de los datos son procesadas por dos redes neuronales independientes, respectivamente.

Red de memoria a corto y largo plazo bidireccional (bi-LSTM) [15]: este modelo combina las salidas de las redes LSTM hacia adelante y hacia atrás para capturar dependencias bidireccionales en secuencias y utiliza características más periódicas para mejorar el rendimiento predictivo del modelo a través de pasadas hacia adelante y hacia atrás del módulo Bi-LST

La Tabla 2 compara los resultados de detección de diferentes algoritmos de detección de anomalías de tráfico a escalas de ciudad y carretera. Los resultados experimentales muestran que el modelo CNN-LSTM tiene la peor precisión y exactitud de detección en ambas escalas espaciales, lo que se debe a que el modelo utiliza dos módulos de red neuronal independientes para procesar las características espaciotemporales de los datos, lo que impide que aprenda bien la correlación espaciotemporal en los eventos de anomalías de tráfico. El modelo bi-LSTM extrae las características temporales del flujo de tráfico con su unidad neuronal y estructura de red neuronal únicas, lo que mejora la precisión de detección, pero aún así su rendimiento es deficiente en términos de precisión de detección. El modelo de autoencoder apilado (SAE) muestra una gran mejora tanto en la precisión como en la exactitud de detección, y este mejor rendimiento puede deberse a que SAE es capaz de extraer más características no lineales de los datos de tráfico. El modelo de red generativa antagónica (GAN) obtuvo buenos resultados en la precisión de detección, pero la exactitud del modelo es relativamente baja porque no logra integrar las características temporales y espaciales de los eventos geográficos. El modelo Transformer utiliza el mecanismo de atención para lograr la correspondencia entre las características temporales y espaciales, pero su rendimiento es relativamente bajo a escala urbana. Esto puede deberse a que el modelo no logra integrar las características temporales y espaciales de los eventos a diferentes escalas. Sin embargo, al mismo tiempo, también observamos que tanto el modelo GAN como el Transformer requieren mayor tiempo de procesamiento y almacenamiento para obtener buenos resultados. Por lo tanto, la mejora de la ligereza basada en estos dos modelos y la integración de métodos de procesamiento de características espaciotemporales podrían convertirse en importantes líneas de investigación en el futuro. De estos seis modelos, el Traffic-ConvLSTM que propusimos cumple con los requisitos de buen rendimiento y bajo costo computacional en escalas multitemporales y multiespaciales . La Tabla 2 muestra los resultados de la evaluación de las capacidades de detección del modelo; este presenta una alta precisión y una buena exactitud en la identificación de eventos de tráfico anómalos, manteniendo un bajo costo computacional y demostrando su utilidad práctica.

Realizamos un experimento de ablación sobre el efecto de las capas ConvLSTM en el rendimiento del modelo. La Tabla 3 compara los cambios en el rendimiento de los modelos con diferentes capas ConvLSTM. Se puede encontrar que cuando la capa codificadora y la capa de predicción del modelo constituyen una capa ConvLSTM de tres capas, el modelo logra los mejores beneficios en términos de rendimiento y costo de tiempo. Con el aumento en el número de capas, el costo de tiempo de entrenamiento del modelo aumenta rápidamente, y el modelo en sí tiene un cierto fenómeno de sobreajuste , lo que reduce la precisión del modelo de predicción. Cuando se reduce el número de capas , el rendimiento del modelo disminuye significativamente. Se utilizó otro experimento de ablación para determinar si las características espaciales en la capa codificadora se extraían en orden y se ingresaban en la capa de predicción para la predicción. En la secuencia RNN del codificador de la capa de predicción del modelo, las características espaciales extraídas están organizadas en secuencia de escala grande a escala pequeña para que el objeto de predicción pueda aprender más información del rango espacial adyacente. La Tabla 4 refleja el impacto de este orden en el rendimiento del modelo. Cuando el peso de entrada de las características se ajusta mejor a la ley de proximidad espacial de la primera ley de la geografía, el modelo tendrá un mejor rendimiento.

Machine Translated by Google

Tabla 2. Exactitud y precisión de cuatro modelos para la detección de eventos de tráfico inusuales a nivel de ciudad y escalas a nivel de carretera.

	Traffic-ConvLSTM	SAE	CNN+LSTM	Bi-LSTM	GAN	Transformador
Precisión urbana	92,875%	85,714%	67,857%	71,428%	90,124%	87,143%
Precisión de la ciudad	83,871%	75.000%	51,351%	52,778%	69,430%	80,154%
Precisión en carretera	88,889%	83,761%	78,632%	84,615%	92,236%	94,582%
Tiempo de precisión en carretera	92,035%	80,991%	63,889%	70,714%	81,119%	91,715%
	4.88	6.21	3.55	5.18	9,93	11.78

Tabla 3. Experimento de ablación basado en la configuración del número de capas ConvLSTM.

	Capas-5	Capas-4	Capas-3	Capas-2
Precisión urbana	93,007%	93,115%	92,875%	89,294%
Precisión de la ciudad	81,106%	83,712%	83,871%	82,125%
Precisión en carretera	91,113%	90,003%	88,889%	85,127%
Precisión en carretera	89,758%	93,035%	92,035%	83,885%
Tiempo	9,14	6,02	4,88	4.18

Tabla 4. Experimentos de ablación basados en las características temporales y espaciales de diferentes escalas en la secuencia RNN del codificador de la capa de predicción.

	En orden	Fuera de servicio
Precisión urbana	92,875%	91,992%
Precisión de la ciudad	83,871%	83,108%
Precisión en carretera	88,889%	85,019%
Precisión en carretera	92,035%	85,892%

4.2. Descripción y análisis de los resultados

A escala de ciudad, calculamos el recuento diario de estos puntos anómalos. Figura 4 Presenta un diagrama de dispersión que ilustra el número de puntos de anomalía de tráfico diarios en Wuhan. durante el período de estudio, con diferentes colores que resaltan las causas de los más significativos anomalías. Se reconocieron cuatro desencadenantes principales de anomalías de tráfico a gran escala: principales días festivos y un evento público con un gran número de participantes. Como se muestra en la Figura 4, el El feriado del Día Nacional de la República Popular China representó el mayor número de anomalías de tráfico, superando otros días por más del doble. De manera similar, el Día Internacional del Trabajo y el Dragon Boat El festival mostró recuentos de anomalías ligeramente elevados, aunque significativamente inferiores a los nacionales. Día. Curiosamente, el número de anomalías se correlacionó positivamente con la duración de estas días festivos. Esto se evidencia en el Día Nacional, el Día del Trabajo y el Festival del Barco Dragón. vacaciones, con una duración de 7, 5 y 3 días, respectivamente, correspondientes a 20, 7 y 6 anómalos eventos. Este hallazgo sugiere la necesidad de una mayor gestión del tráfico durante los días festivos, con medidas más estrictas implementadas para vacaciones más largas. El 11º Consejo Municipal de Wuhan Los Juegos también dieron como resultado cuatro eventos anómalos, lo que indica que los eventos deportivos a gran escala pueden alterar significativamente los patrones de tráfico urbano.

La Figura 5 muestra el impacto de estas cuatro anomalías de tráfico a nivel urbano en Wuhan. Flujo de tráfico urbano. Cada figura en la Figura 5 corresponde a un evento de tráfico anormal a nivel de ciudad. La leyenda AI de cada figura indica la causa y la ocurrencia del tráfico anormal. evento. Además, la Figura 5 también muestra los eventos de congestión causados por cada nivel urbano. evento de anomalía de tráfico en secciones importantes de Wuhan y utiliza el sello del evento para marcar la ubicación de estos eventos. En el gráfico de ventana de la Figura 5, comparamos el tráfico rodado. condiciones de algunas secciones de nodos en caso de eventos de tráfico anormales a aquellos de días normales. Se puede encontrar que estas anomalías de tráfico son atascos de tráfico anormales causados por un gran número de flujos de tráfico de viajes anormales. El patrón espacial, el alcance del impacto, y el momento en que ocurren estos eventos de congestión es significativamente diferente al convencional. congestión de tráfico observada bajo el patrón de tráfico normal. Esta diferencia resalta la

Machine Translated by Google

Características temporales y espaciales evidentes de los eventos de tráfico anómalos. Además, podemos comparar las similitudes y diferencias entre las cuatro anomalías de tráfico urbano.

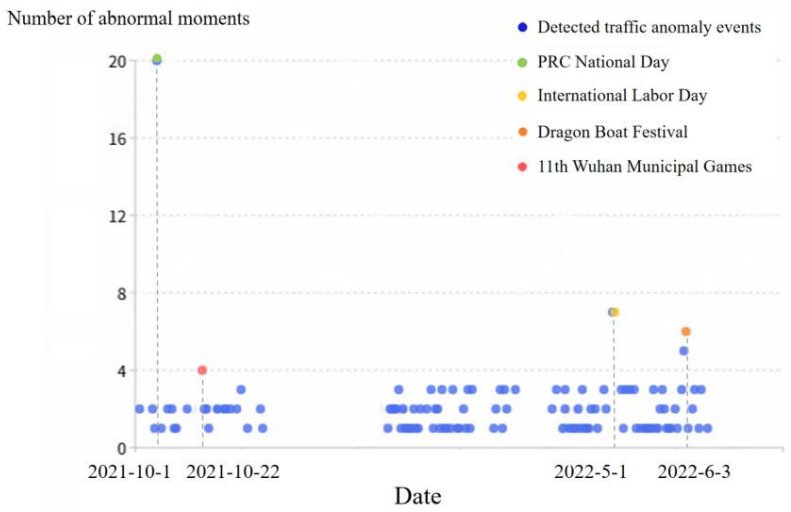


Figura 4. Estadísticas de eventos anómalos de tráfico a nivel de ciudad para el período de septiembre de 2021 a junio de 2021, con las causas típicas de los eventos que desencadenaron anomalías de tráfico a nivel de ciudad durante el período indicadas en la figura.

Además, se observa que los eventos de tráfico anómalos mostrados en las figuras 5a y 5d presentan claras similitudes espaciotemporales. En las imágenes tomadas simultáneamente, estos eventos se produjeron en los peajes y desvíos de la autopista Daihuang (tramo de Wuhan), al norte de Wuhan, y en la entrada a la ciudad de la autopista Shanghai-Yuzhou, al sureste de Wuhan. Es probable que estas similitudes se deban a causas subyacentes comunes.

El Día Nacional y el Festival del Bote del Dragón, el 1 de octubre de 2021 y el 3 de junio de 2022, respectivamente, son festividades tradicionales chinas que se caracterizan por un importante flujo de viajes interurbanos, ya que la gente regresa a sus ciudades de origen para reunirse con sus familias. Las autopistas Daihuang y Shanghai-Yuzhou , que conectan Wuhan con dos zonas densamente pobladas del norte y sureste de China, respectivamente, sirven como principales vías de comunicación para los viajes interurbanos en Wuhan. Por lo tanto, cuando el flujo de tráfico interurbano en Wuhan aumentó significativamente debido al regreso de los residentes, se produjeron anomalías en el tráfico en las zonas de acceso a estas dos autopistas.

En contraste, los eventos de tráfico anómalos presentados en la Figura 5c muestran similitudes y diferencias con respecto a los de las Figuras 5a y 5d. Si bien los eventos de tráfico anómalos ocurrieron de manera similar en la sección de entrada de la Autopista Huyu en el sureste de Wuhan, los otros dos eventos anómalos difieren significativamente en su distribución espacial. Esta distinción también surge de la naturaleza del feriado en cuestión. El Día Internacional del Trabajo (1 de mayo de 2022) es un feriado relativamente corto, no un feriado tradicional chino. En consecuencia, muchas personas optan por actividades de ocio dentro de la ciudad en lugar de viajes interurbanos, lo que resulta en un mayor flujo de tráfico tanto dentro como entre ciudades. El desplazamiento de multitudes se refleja en el flujo de tráfico mediante un aumento significativo en el flujo de tráfico dentro y entre ciudades, lo que desencadena anomalías de tráfico en la región original con malas condiciones de tráfico. En contraste, la Figura 5b ilustra un tipo de anomalía de tráfico fundamentalmente diferente asociada con los XI Juegos Municipales de Wuhan . En esta distribución anómala, se observa un punto de origen claro de la interrupción del tráfico, concretamente la ubicación espacial marcada por el registro del evento, con una congestión que se extiende desde dicho punto a todas las carreteras adyacentes. Esta anomalía de tráfico fue causada por los XI Juegos de la Ciudad de Wuhan , celebrados al este y al oeste del Distrito de los Lagos de la ciudad de Wuhan, donde se congregó un gran número de personas, lo que provocó una importante congestión vehicular en la zona.

Machine Translated by Google

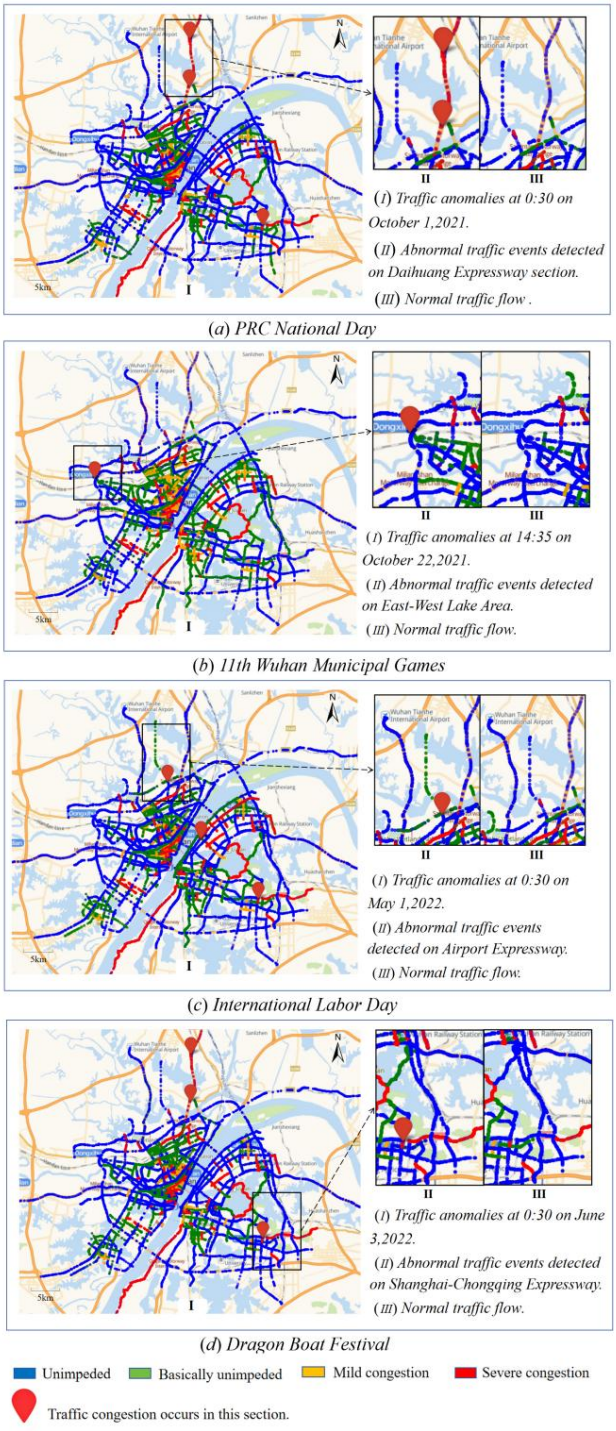


Figura 5. Casos típicos de anomalías de tráfico a nivel de ciudad desde septiembre de 2021 hasta junio de 2022; (izquierda) una visión general de las condiciones del tráfico en Wuhan en ese momento; (derecha) los detalles de un área de anomalía de tráfico correspondiente a (izquierda), que está marcada con un sello de evento.

5. Conclusiones

Este estudio propuso un modelo de aprendizaje profundo para la identificación y el análisis de eventos de tráfico anómalos. Las principales contribuciones incluyen la propuesta de una técnica de procesamiento de datos que transforma datos de trayectorias de múltiples fuentes en visualizaciones de las condiciones del tráfico. Traffic-ConvLSTM, un modelo de aprendizaje profundo, se introdujo para identificar patrones de tráfico anómalos en múltiples dimensiones espaciales y temporales. También se introdujo un método de evaluación de patrones de tráfico basado en el índice de similitud estructural (SSIM). El experi-

Machine Translated by Google

La evaluación mental realizada con conjuntos de datos reales arrojó resultados de reconocimiento satisfactorios tanto a nivel urbano como vial. El desarrollo de estos algoritmos precisos de detección de anomalías de tráfico puede mejorar significativamente la seguridad urbana, optimizar los recursos, mejorar la experiencia del usuario y facilitar la planificación de la respuesta ante emergencias. Además, nuestro análisis de anomalías de tráfico a gran escala reveló patrones distintivos estrechamente relacionados con días festivos importantes y eventos públicos relevantes. Estos hallazgos subrayan la importancia de los enfoques específicos del contexto en la gestión y planificación del tráfico urbano .

Contribuciones de los autores: Conceptualización, Binbin Lu y Yunkun Mao; metodología, Yunkun Mao; software, Yunkun Mao; validación, Yunkun Mao; análisis formal, Yunkun Mao; investigación, Binbin Lu; recursos, Binbin Lu; curación de datos, Yunkun Mao; redacción: preparación del borrador original, Yunkun Mao y Yilin Shi; redacción: revisión y edición, Yunkun Mao; visualización, Yunkun Mao, Yilin Shi y Binbin Lu; supervisión, Binbin Lu; administración de proyectos, Binbin Lu; adquisición de financiación, Binbin Lu Todos los autores han leído y aceptado la versión publicada del manuscrito.

Financiación: Esta investigación fue financiada conjuntamente por la Fundación Nacional de Ciencias Naturales de China (número de subvención: U2033216; 42071368); y los Fondos de Investigación Fundamental para las Universidades Centrales (número de subvención: 2042022dx0001; 2042024kf0005).

Declaración de disponibilidad de datos: Los datos pueden facilitarse previa solicitud.

Conflictos de intereses: Los autores declaran no tener conflictos de intereses.

Referencias

1. Comité Central del Partido Comunista de China, Consejo de Estado de la República Popular China. Esquema para la construcción de un Estado con un sistema de transporte sólido; Editorial del Pueblo: Pekín, China, 2019.
2. Zhang, M.; Li, T.; Yu, Y.; Li, Y.; Hui, P.; Zheng, Y. Análisis de anomalías urbanas: descripción, detección y predicción. IEEE Trans. Big Datos 2022, 8, 809–826. [CrossRef]
3. Parkany, E.; Xie, C. Una revisión completa de los algoritmos de detección de incidentes y su implementación: qué funciona y qué no, Informe No: NETCR37; Consorcio de Transporte de Nueva Inglaterra: Mansfield Center, CT, EE. UU., 2005.
4. Jiang, Z.; Liu, Y.; Fan, X.; Wang, C.; Li, J.; Chen, L. Comprensión de las estructuras urbanas y la dinámica de multitudes mediante datos de movilidad vehicular a gran escala. Front. Comput. Sci. 2020, 14, 145310. [CrossRef]
5. Voort, MVD; Dougherty, M.; Watson, S. Combinación de mapas de Kohonen con modelos de series temporales ARIMA para pronosticar el flujo de tráfico. Transp. Res. Part C Emerg. Technol. 1996, 4, 307–318. [CrossRef]
6. Duan, P.; Mao, G.; Liang, W.; Zhang, D. Un modelo espacio-temporal unificado para la predicción del flujo de tráfico a corto plazo. IEEE Trans. Intell. Sistema de Transacciones 2019, 20, 3212–3223. [CrossRef]
7. Williams, BM; Hoel, LA. Modelado y pronóstico del flujo de tráfico vehicular como un proceso ARIMA estacional: fundamentos teóricos y resultados empíricos. J. Transp. Eng. 2003, 129, 664–672. [CrossRef]
8. Lin, C.; Zhu, Q.; Guo, S.; Jin, Z.; Lin, Y.; Cao, N. Detección de anomalías en datos espaciotemporales mediante análisis de tensores no negativos regularizados . Data Min. Knowl. Discov. 2018, 32, 1056–1073. [CrossRef]
9. Xu, M.; Wu, J.; Wang, H.; Cao, M. Detección de anomalías en redes viales mediante factorización tensorial de ventana deslizante. IEEE Trans. Sistemas de Transacciones Intelectuales 2019, 20, 4704–4713. [CrossRef]
10. Wang, Y.; Zhang, Y.; Piao, X.; Liu, H.; Zhang, K. Reconstrucción de datos de tráfico mediante correlaciones espacio-temporales adaptativas. IEEE Trans. Sistemas de Transacciones Intelectuales 2019, 20, 1531–1543. [CrossRef]
11. Lv, Y.; Duan, Y.; Kang, W.; Li, Z.; Wang, FY Predicción del flujo de tráfico con big data: un enfoque de aprendizaje profundo. IEEE Trans. Intell. Sistemas de Transformación 2014, 6, 865–873. [CrossRef]
12. Chen, X.; Chen, H.; Yang, Y.; Wu, H.; Zhang, W.; Zhao, J.; Xiong, Y. Predicción del flujo de tráfico mediante un marco de conjunto con eliminación de ruido de datos y un modelo de aprendizaje profundo. Phys. A Stat. Mech. Its Appl. 2021, 565, 125574. [CrossRef]
13. Sun, F.; Dubey, A.; White, J. Dxnat: redes neuronales profundas para explicar la congestión de tráfico no recurrente. En Actas de la Conferencia Internacional IEEE de 2017 sobre Big Data (Big Data), Boston, MA, EE. UU., 11-14 de diciembre de 2017.
14. Fang, Z.; Long, Q.; Song, G.; Xie, K. Redes de grafos espacio-temporales para la predicción del flujo de tráfico. En Actas de la 27.ª Conferencia ACM SIGKDD sobre Descubrimiento de Conocimiento y Minería de Datos, Singapur, 14-18 de agosto de 2021.
15. Zheng, H.; Lin, F.; Feng, X.; Chen, Y. Un modelo híbrido de aprendizaje profundo con redes conv-lstm basadas en atención para tráfico a corto plazo Predicción de flujo. IEEE Trans. Intell. Transp. Syst. 2021, 22, 6910–6920.
16. Guo, S.; Lin, Y.; Feng, N.; Song, C.; Wan, H. Redes neuronales convolucionales espaciotemporales basadas en atención para la predicción del flujo de tráfico. En Actas de la Conferencia AAAI sobre Inteligencia Artificial, Honolulu, HI, EE. UU., 27 de enero-1 de febrero de 2019; págs. 922-929.
17. Zhang, Y.; Li, Y.; Zhou, X.; Kong, X.; Luo, J. Curb-gan: Estimación condicional del tráfico urbano mediante redes generativas adversarias espacio-temporales. En Actas de la 26.ª Conferencia Internacional ACM SIGKDD sobre Descubrimiento de Conocimiento y Minería de Datos, Evento Virtual, 6-10 de julio de 2020.

Machine Translated by Google

18. Zhang, Y.; Li, Y.; Zhou, X.; Kong, X.; Luo, J. Trafficgan: Estimación de tráfico fuera de despliegue con redes adversarias generativas de tráfico. En las Actas de la Conferencia Internacional IEEE de Minería de Datos (ICDM) de 2019, Pekín, China, del 8 al 11 de noviembre de 2019.
19. Zhang, Y.; Wang, S.; Chen, B.; Cao, J.; Huang, Z. TrafficGAN: predicción profunda de tráfico a escala de red con adversario generativo Redes. IEEE Trans. Intell. Transp. Syst. 2021, 22, 219–230. [CrossRef]
20. Essien, A.; Giannetti, C. Un modelo de aprendizaje profundo para la fabricación inteligente utilizando autoencoders de redes neuronales convolucionales LSTM. IEEE Trans. Ind. Inform. 2020, 16, 6069–6078.
21. Levin, M.; Tsao, Y.-D. Sobre la previsión de la ocupación y el volumen de las autopistas (resumen). En Transportation Research Record; Trans- Junta de Investigación de Portación: Washington, DC, EE. UU., 1980; págs. 47–49.
22. Hamed, MM; Al-Masaeid, HR; Said, ZMB Predicción a corto plazo del volumen de tráfico en arterias urbanas. J. Transp. Eng. 1995, 121, 249–254. [CrossRef]
23. Zhao, Z.; Tang, L.; Ren, C.; Yang, X.; Kan, Z.; Li, Q. Diagnóstico de anomalías del tráfico urbano mediante la integración del conocimiento geográfico y teoría tensorial. GISci. Remote Sens. 2024, 61, 2290347.
24. Medel, J.; Savakis, A. Detección de anomalías en vídeo mediante redes neuronales convolucionales predictivas de memoria a corto y largo plazo. arXiv 2016, arXiv:1612.00390.
25. Shi, X.; Chen, Z.; Wang, H.; Yeung, Di.; Wong, WC; Woo, W.-C. Red LSTM convolucional: un enfoque de aprendizaje automático para la predicción inmediata de precipitaciones. arXiv 2015, arXiv:1506.04214.
26. Song, H.; Wang, W.; Zhao, S.; Shen, J.; Lam, K.-M. Pyramid Dilated Deeper ConvLSTM para la detección de objetos salientes en vídeo. En Actas de Computer Vision—ECCV 2018, Lecture Notes in Computer Science, Múnich, Alemania, 8-14 de septiembre de 2018; pp. 744-760.
27. Zhao, M.; Luo, T.; Zhou, B.; Pan, JS. Un nuevo algoritmo para la predicción de fotogramas de vídeo basado en redes neuronales convolucionales. En Actas de Advances in Intelligent Information Hiding and Multimedia Signal Processing, Smart Innovation, Systems and Technologies, Daegu, República de Corea, 5-7 de diciembre de 2023; págs. 187-193.
28. Robertson, C.; Wilmoth, J.; Retterer, S.; Fuentes-Cabrera, M. Realización de la predicción del crecimiento microbiano en fotogramas de vídeo con una red neuronal recurrente. arXiv 2022, arXiv:2205.05810.
29. Zhang, Z.; Lv, Z.; Gan, C.; Zhu, Q. Reconocimiento de acciones humanas utilizando LSTM convolucional y LSTM totalmente conectada con diferentes atenciones. Neurocomputing 2020, 410, 304–316.
30. Elsworth, S.; Güttel, S. Pronóstico de series temporales mediante redes LSTM: Un enfoque simbólico. arXiv 2020, arXiv:2003.05672.
31. Ma, X.; Dai, Z.; He, Z.; Na, J.; Wang, Y.; Wang, Y. Aprendizaje del tráfico como imágenes: una red neuronal convolucional profunda para gran escala Predicción de la velocidad de la red de transporte. Sensors 2017, 17, 818. [CrossRef] [PubMed]
32. Li, X.-W. La primera ley de la geografía y la proximidad espacio-temporal. Chin. J. Nat. 2007, 29, 69–71.
33. Wang, Z.; Bovik, AC; Sheikh, HR; Simoncelli, EP. Evaluación de la calidad de la imagen: De la visibilidad del error a la similitud estructural. IEEE Trans. Image Process. 2004, 13, 600–612. [PubMed]
34. Chollet, F. Keras: La biblioteca de aprendizaje profundo de Python; registro ascl:1806.022; Astrophysics Source Code Library: Houghton, MI, EE. UU., 2018.
35. Abadi, M.; Agarwal, A.; Barham, P.; Brevdo, E.; Chen, Z.; Citro, C.; Corrado, GS; Davis, A.; Decano, J.; Devin, M.; et al. Tensorflujo: Aprendizaje automático a gran escala en sistemas distribuidos heterogéneos. arXiv 2016, arXiv:1603.04467.

Aviso legal/Nota del editor: Las declaraciones, opiniones y datos contenidos en todas las publicaciones son responsabilidad exclusiva de sus autores y colaboradores, y no de MDPI ni de sus editores. MDPI y sus editores no se responsabilizan de los daños a personas o bienes que pudieran derivarse de las ideas, métodos, instrucciones o productos mencionados en el contenido.