Machine Translated by Google

scientific reports

Check for updates

ABIERTO

Autoencoder gráfico con redes convolucionales temporales simétricas para la detección de anomalías en el tráfico.

Zhiyu Ren1,4, Xiaojie Li1,4, Jing Peng1 , Ken Chen2*, QushanTan2, XiWu1* y Canghong Shi3

La detección de anomalías en series temporales de tráfico se ha estudiado intensamente durante años debido a sus potenciales aplicaciones en el transporte inteligente. Sin embargo, los métodos clásicos de detección de anomalías de tráfico suelen pasar por alto las asociaciones dinámicas en evolución entre los nodos de la red vial, lo que plantea dificultades para capturar las correlaciones temporales a largo plazo, las características espaciales y los comportamientos anómalos de los nodos en conjuntos de datos con alta periodicidad y tendencias, como los períodos pico de viaje matutinos. En este artículo, proponemos un marco de autoencoder gráfico temporal espejo (MTGAE) para explorar anomalías y capturar nodos no vistos y la correlación espaciotemporal entre nodos en la red de tráfico. Específicamente, proponemos el módulo convolucional temporal espejo para mejorar las capacidades de extracción de características y capturar características ocultas entre nodos en la red de tráfico. Además, proponemos el módulo de celda unitaria recurrente de puerta convolucional gráfica (GCGRU CELL). Este módulo utiliza funciones de núcleo gaussiano para mapear los datos a un espacio de alta dimensión y permite la identificación de información anómala y posibles anomalías dentro de las complejas interdependencias de la red de tráfico, basándose en el conocimiento previo y los datos de entrada. Comparamos nuestro trabajo con otros modelos avanzados de detección de anomalías basados en aprendizaje profundo. Los resultados experimentales obtenidos con el conjunto de datos de la ciudad de Nueva York demuestran que nuestro modelo funciona mejor que otros modelos para la detección de anomalías en el tráfico.

En los últimos años, el transporte inteligente se ha vuelto cada vez más complejo debido a la rápida urbanización y al crecimiento demográfico. Existe una creciente necesidad de detectar eventos anómalos en las redes de transporte. El incidente de la avalancha humana en el Bund de Shanghái, ocurrido el 31 de diciembre de 2014 en China, es una tragedia ampliamente conocida estrechamente relacionada con la detección de anomalías en el tráfico. Además, el 26 de enero de 2017, en Harbin, la ciudad más grande del noreste de China, un único incidente de tráfico provocó una serie de colisiones por alcance, con un saldo de ocho fallecidos y treinta y dos heridos[2] . Estos sucesos demuestran que la detección y predicción tempranas de anomalías antes de que se produzcan son de gran importancia para prevenir incidentes graves. Por lo tanto, un sistema de detección de anomalías eficiente y preciso tiene un gran valor para la investigación, ya que permite la monitorización continua de indicadores específicos y la prevención eficaz de posibles anomalías.

La detección de anomalías se utiliza ampliamente en ciudades inteligentes, especialmente en sistemas de transporte inteligentes. El sistema de transporte inteligente que se analiza en este artículo es una tecnología basada en inteligencia artificial que busca detectar anomalías de tráfico inteligentes. Al aprender las relaciones entre los sensores, podríamos detectar anomalías a partir de los datos de los sensores[3–5]. Sin embargo, las anomalías de tráfico suelen presentar formas complejas debido a dos aspectos: alta dimensionalidad, escasez, falta de datos anormales (es decir, la necesidad de correlacionar tiempo y espacio, incluyendo velocidad o flujo) y dificultad para capturar la relación oculta entre nodos (es decir, modelado espacial frente a diferentes fuentes de datos con distintos grados de anomalías en densidad, distribución y escala)[6,7] . Por lo tanto, es importante explorar formas de capturar relaciones complejas entre sensores y detectar anomalías a partir de las relaciones entre nodos. Varios métodos se basan en redes generativas antagónicas (GAN)[3]. Sin embargo, el generador de GAN puede ser ineficaz para capturar completamente la distribución oculta de los datos, lo que lleva a una alta tasa de falsas alarmas y una alta tasa de alarmas omitidas debido a la combinación de la función de pérdida Binary CrossEntropyLoss (BCE). La mayoría de los métodos anteriores para la detección de anomalías son variantes de Long Short Term Memory (LSTM)[8,9] , como FC-LSTM[10], que se centra en capturar tanto los diversos factores estáticos como las interacciones dinámicas que afectan el flujo de tráfico. Además, existe una categoría de redes, como TCN (redes convolucionales temporales), diseñadas para abordar dependencias temporales, que pueden capturar información temporal global[11]. Sin embargo, las TCN pueden no ser tan flexibles en el contexto de la sincronización del tráfico debido a las variaciones en la cantidad de información histórica necesaria para las predicciones del modelo.

1 Facultad de Ciencias de la Computación, Universidad de Tecnología de la Información de Chengdu, Chengdu 610225, Sichuan Digital Transportation [2]Technology Co., Ltd, Chengdu, China. 3 Escuela de Computación y Software de China.
Ingeniería, Universidad de Xihua, Chengdu 610039, China. 4 Estos autores contribuyeron por igual: Zhiyu Ren y Xiaojie Li.
*Correo electrónico: scsz@scsz.com; xi.wul@cuit.edu.cn

Machine Translated by Google
www.nature.com/scientificreports/

en diferentes dominios. Cuando las TCN (redes convolucionales temporales) se enfrentan a una red de transporte dinámica, su rendimiento puede ser deficiente porque su campo perceptivo no es lo suficientemente grande como para describir la dinámica, la complejidad y capturar la información contextual global12.

El enfoque más avanzado emplea una red neuronal convolucional gráfica (GNN) para la reutilización del modelado espacial y combina LSTM para abordar la predicción de anomalías en series temporales3. También existe un método para superar el entrenamiento adversario, aprendiendo las características espaciotemporales de la dinámica del tráfico y las anomalías del tráfico, respectivamente13. Los métodos existentes de detección de anomalías que utilizan redes neuronales convolucionales gráficas (GCN) no abordan adecuadamente la escasez de datos ni capturan los nodos no vistos y la correlación espacio-temporal entre los nodos en la red de tráfico.

Para resolver el problema anterior, proponemos un módulo convolucional temporal espejo (MTCM) para capturar la información anómala relacionada con los datos de entrada y los nodos dinámicos ocultos en las redes de tráfico. Diseñamos principalmente dos módulos en MTGAE: el módulo convolucional temporal espejo (MTCM) y la celda unitaria recurrente de puerta convolucional gráfica (GCGRU CELL). Gracias a su capacidad de autoaprendizaje, el MTCM puede procesar eficientemente los datos de entrada en sus módulos ante secciones de longitud variable en el conjunto de datos. El MTCM explora la asociación potencial entre nodos mediante el aprendizaje de las complejas relaciones y dependencias ocultas entre ellos en las redes de tráfico.
El módulo GCGRU CELL aprovecha al máximo el conocimiento previo existente (datos históricos). Captura información vial, relaciones entre nodos ocultos y dependencias para la redistribución de información anómala, lo que nos permite obtenerla con mayor facilidad. A continuación, resumimos las contribuciones de este artículo:

- Proponemos un marco de detección de anomalías llamado MTGAE, que maximiza la exploración de posibles anomalías entre nodos en las interdependencias complejas y captura mejor las características ocultas entre nodos en la red de tráfico.
- Construimos un módulo convolucional temporal espejo, que se adapta automáticamente al conjunto de datos y captura y transmite en cascada la información oculta entre nodos maximizando la penetración del campo de visión perceptivo de la TCN.
- Proponemos el módulo GCGRU CELL, que captura anomalías dependientes a largo y corto plazo en el espacio-tiempo de la red de tráfico y maximiza la extracción de características espaciotemporales y posible información sobre anomalías mediante la cooperación con MTCM.

Trabajos relacionados

En esta sección, presentamos las redes neuronales convolucionales gráficas, las redes neuronales convolucionales temporales y la detección de anomalías basada en autoencoders.

Redes neuronales convolucionales de grafos

Recientemente, las variantes de redes neuronales gráficas (GNN), como las redes convolucionales gráficas (GCN), han demostrado un rendimiento revolucionario en muchas tareas de aprendizaje profundo. Además, son modulares, escalables, tienen una mayor capacidad de generalización y exploran perspectivas que orientan futuras investigaciones14. GCN captura las dependencias complejas de las incrustaciones de nodos a través de información entre vértices15. Debido a estas potentes características, en las variantes de GCN, los sensores en la carretera de la red de tráfico se consideran nodos en el transporte inteligente, y la velocidad o tasa de flujo de tráfico de cada nodo se considera una característica de entrada dinámica. Entre ellas, la red de atención gráfica (GAT) actualiza las características de los nodos a través de una función por pares entre los nodos con pesos entrenables16. Sin embargo, solo calcula una forma restringida de atención estática. Para abordar esta limitación, GATv217

Introduce atención dinámica junto con atención estática, lo que permite un cálculo más dinámico y adaptativo de la atención de grafos. En el desarrollo posterior de GCN, CorrSTN18 incorpora eficazmente información de correlación en la estructura espacial. PDFormer19 captura dependencias espaciales de corto y largo alcance mediante el uso de diversas máscaras de grafos, lo que permite el aprendizaje de patrones dinámicos de tráfico urbano y supera la restricción de modelar dependencias espaciales de forma estática. Además, STAEformer20 tiene en cuenta las relaciones espaciotemporales intrínsecas y la información de ordenación temporal en las series temporales de tráfico. Estos métodos se utilizan ampliamente en la predicción del tráfico, mientras que la incrustación de grafos para la detección de anomalías de tráfico está menos estudiada. Por ejemplo, ST-Decompn resuelve el problema legal causado por los cambios de ubicación y tiempo en el tráfico de las ciudades mediante la descomposición, así como las anomalías que pueden aparecer de manera diferente ante distintos conjuntos de datos21. ConGAE detecta anomalías de tráfico utilizando marcos semisupervisados como autoencoders solo para conjuntos de datos OD (pares origen-destino) en el lavado de datos y alta dimensionalidad13. Además, la Red Convolucional Adversaria Gráfica (STGAN) utiliza entrenamiento adversario, que se divide en tres módulos para capturar diferentes características respectivamente: el módulo reciente para lo local, el módulo de tendencia para el largo plazo y el módulo externo para otras dinámicas y anomalías de tráfico, pero el aprendizaje no supervisado, como una red neuronal adversaria, genera inestabilidad para la detección de anomalías3.

Influenciados por el estado del arte, tomamos prestada la unidad recurrente con compuertas convolucionales de grafos (GCGRU)22. Simultáneamente, para resolver el problema de las características espaciotemporales de las anomalías del tráfico. Nuestro trabajo se centra en las capacidades de predicción de anomalías del tráfico de GCN.

Los autoencoders de grafos (GAE) son un tipo de método de aprendizaje no supervisado, lo que significa que asignan nodos a un espacio vectorial potencial a través de un proceso de codificación, reconstruyendo la información del grafo a partir del vector para generar un grafo similar al original (decodificación)15,23. Por ejemplo, ADN24 es una estructura de autoencoder de grafos y logra la difusión de información a través de la autoatención espacial y temporal alternada. Debido a la potencia de GAE25, se utiliza ampliamente en diferentes líneas de investigación, como predicción de enlaces26–30, agrupamiento de grafos31,32, detección de anomalías hiperespectrales33. Mientras que la GCN tradicional toma las características de los nodos y la matriz de adyacencia como entrada y la incrustación de nodos como salida, los GAE comprimen las incrustaciones de todos los nodos en un grafo en una única incrustación de grafo para obtener información sobre el contexto.

Machine Translated by Google
www.nature.com/scientificreports/

Redes convolucionales temporales

Los métodos de investigación anteriores se centraban en problemas relacionados con el tráfico, pero mostraron imprecisiones significativas en la predicción de anomalías. En los últimos años, el aprendizaje profundo ha dominado gradualmente las tareas de predicción de series temporales gracias a sus sofisticadas capacidades de modelado de datos y aprendizaje autónomo. La mayoría de los estudios en el campo del transporte se basan en unidades lineales con compuerta (GLU)34 o unidades recursivas con compuerta (GRU)35 para capturar la correlación temporal dinámica de los datos de series temporales. Además, basándose en la arquitectura Transformer, STGM36 introduce un novedoso mecanismo de atención para capturar dependencias temporales tanto a largo como a corto plazo. Las redes neuronales convolucionales temporales (TCN) también presentan ventajas significativas para abordar las dependencias temporales, especialmente en tareas de predicción de series temporales.
Sin embargo, la mayoría de los marcos de predicción de anomalías en el flujo de tráfico utilizan la estructura original de la Red Convolucional Temporal (TCN)37,38 sin modificaciones, y la detección de anomalías en el tráfico aún no se ha explorado en profundidad. En este estudio, hemos mejorado la TCN para detectar mejor las anomalías en este ámbito, lo que permite un análisis más completo de los datos de series temporales.

Detección de anomalías basada en autoencoders

El autoencoder, una red neuronal no supervisada, ha tenido un éxito significativo en diversos campos. Este éxito se debe en gran medida a su capacidad superior para discriminar entre entradas anormales y regulares, lo que lo hace ampliamente utilizado en la detección de anomalías39–44. En el campo de las redes neuronales convolucionales de grafos (GCN), los autoencoders basados en GCN también se emplean para la detección de anomalías45–48. Se estudian principalmente en la incrustación de grafos, lo cual es consistente con la dirección de nuestro trabajo, gracias a la estructura de red del grafo, que puede conectar varios puntos en el mundo intrincado para la detección de anomalías.

Metodología

Aunque muchos métodos de detección de anomalías de tráfico han alcanzado un rendimiento óptimo, a menudo pasan por alto las relaciones ocultas entre los nodos durante el proceso de detección. Por ejemplo, la congestión del tráfico durante las horas pico en la red de origen puede afectar al tráfico en la red de destino. Esta omisión provoca que muchos modelos carezcan de la capacidad de capturar correlaciones temporales a largo plazo, características espaciales y tendencias periódicas elevadas. Para abordar este problema, nuestro objetivo es identificar información anómala y posibles anomalías en las complejas interdependencias entre los nodos de las redes de tráfico. En consecuencia, proponemos un marco de detección de anomalías de tráfico, MTGAE, con interacción entre nodos (véase la figura 2).

MTGAE consta de dos módulos principales: MTCM y GCGRU CELL. La entrada original pasa primero por un proceso adaptativo. Esto permite que nuestro módulo se adapte mejor a los conjuntos de datos existentes al convertir las señales gráficas en espacios de baja dimensión en vectores potenciales en espacios de alta dimensión. Luego construimos MTCM y GCGRU CELL. Específicamente, construimos MTCM para expandir la información oculta en el espacio-tiempo. MTCM expande internamente x a las variables latentes xm mediante inversión especular, e incrementa los factores de dilatación y genera los estados ocultos H para capturar dependencias complejas espaciotemporales a largo plazo en combinación con TCN. Mientras tanto, construimos el módulo GCGRU CELL para capturar anomalías dependientes a largo y corto plazo en la red de tráfico. Combina las entradas originales y los estados espaciotemporales ocultos H como información previa. Primero la redistribuimos a través del módulo de núcleo gaussiano pero sin cambiar la estructura general de la red de tráfico (ver en la Fig. 2), luego la combinamos con nuestros módulos GCN para extraer más información espaciotemporal. Posteriormente, basándose en la salida de la primera CELDA GCGRU, la información espaciotemporal h(t)
1 Y la información oculta H de MTCM, el segundo módulo GCGRU CELL agrega más detalles ocultos para corregir los defectos generados. Finalmente, vinculamos los resultados reconstruidos con la función de pérdida para determinar si hay anomalías. En esta sección, presentamos los detalles de MTGAE.

Definición del problema

En este artículo, se monitorea y detecta la anomalía del tráfico en series temporales discretas T (t1, t2, ..., tn). Denotamos el grafo de representación de la matriz de adyacencia como G(T) = (V, E, W), donde V indica nodos diferentes, como dos nodos vi y vj, E denota el conjunto de aristas entre dos nodos y W es la matriz de adyacencia ponderada. Un peso mayor entre dos nodos significa que están más cerca en la red vial y viceversa (ver Fig. 1). Dado G(T) = (V, E, W), nuestro objetivo es encontrar el evento anómalo ta T en el grafo G que interrumpe la operación regular del tráfico.

Nuestro objetivo es encontrar el evento ta T en el grafo G que interrumpe el funcionamiento normal del tráfico. Obtenemos el estado oculto mediante un codificador contextual especialmente diseñado, incrustamos la información como una representación codificada de baja dimensión y, posteriormente, la decodificamos para obtener el error de reconstrucción promedio que minimiza la matriz de adyacencia ponderada. Cabe destacar que nuestro modelo se entrena específicamente con datos que representan condiciones normales de tráfico. Por consiguiente, cuando se produce una anomalía en el funcionamiento del tráfico, este se desvía significativamente de esta línea base "normal". Esta desviación es detectada por nuestro modelo como un error de reconstrucción elevado, lo que indica la presencia de una anomalía.

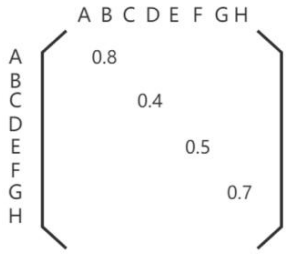
Codificador

Nuestro proceso de codificación comprende tres pasos: el proceso adaptativo, el módulo convolucional temporal espejo (MTCM) y la celda recurrente de red neuronal convolucional gráfica (GCGRU CELL). Inicialmente, los datos originales, denotados como x, pasan por el proceso adaptativo, y se construye MTCM para capturar los estados evolutivos que no son visibles en el continuo espacio-tiempo entre los nodos de la red vial a lo largo del tiempo. En GCGRU CELL, basándose en el conocimiento previo de los estados ocultos H de MTCM, nuestra capa GCN, a través del módulo de núcleo gaussiano, explora posibles anomalías en las complejas interdependencias entre nodos. El codificador se entrena para aprender hasta 24 horas al día y 7 días a la semana, lo que facilita la interacción entre GCGRU CELL y una conexión completa (véase la Fig. 2). Finalmente, la incrustación gráfica h(t)
2 se aplica.

Machine Translated by Google
www.nature.com/scientificreports/



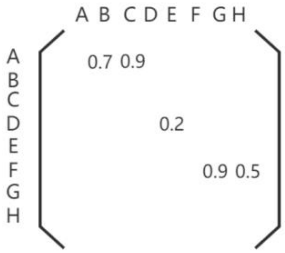
(a) The part 1 of NYC dataset graph



(b) Weighted adjacency matrix to part 1



(c) The part 2 of NYC dataset graph



(d) Weighted adjacency matrix to part 2

Figura 1. Ilustración de dos partes del gráfico del conjunto de datos de la ciudad de Nueva York (primera columna) y la matriz de adyacencia ponderada correspondiente (segunda columna) que corresponde a los tiempos de viaje inversos escalados entre puntos del gráfico. Nótese que los datos de movilidad se modelan como una serie de gráficos ponderados dirigidos dependientes del tiempo. (a) Una parte de los datos de movilidad visualizables de la ciudad de Nueva York. (b) La matriz de adyacencia correspondiente a la subfigura (a). (c) Otra parte de los datos de movilidad visualizables de la ciudad de Nueva York, pero que no forma parte del subgrafo (a). (d) La matriz de adyacencia correspondiente a la subfigura (c).

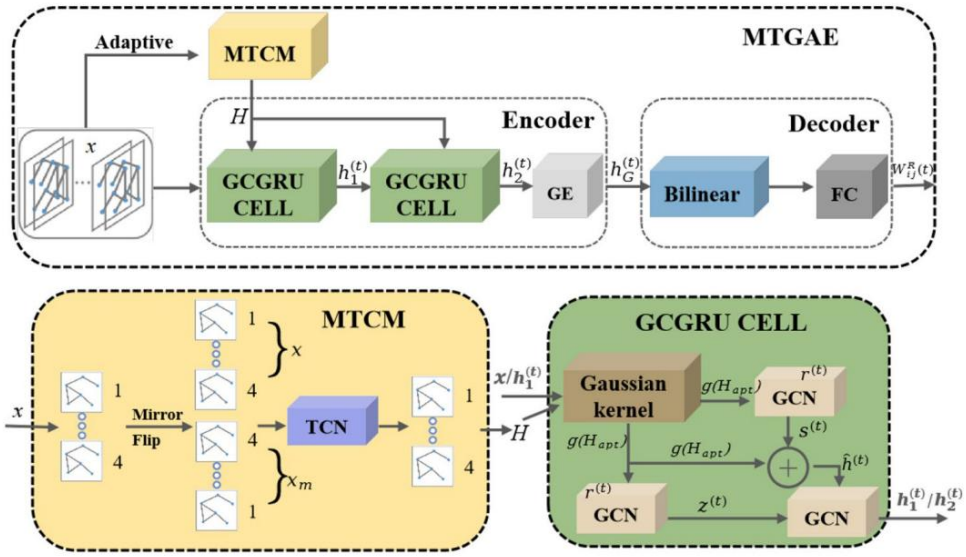


Figura 2. Arquitectura del MTGAE. La arquitectura consta de dos componentes principales: un codificador y un decodificador. El codificador incluye un proceso adaptativo, el MTCM, y la celda GCGRU. El MTCM está diseñado para capturar eficazmente información relevante de datos de longitud variable. Incorpora la TCN para procesar datos que han sufrido una transformación de "reflejo", ajustando la longitud de los datos reflejados a su estado original previo a la entrada. La celda GCGRU, compuesta por un núcleo gaussiano y redes neuronales convolucionales gráficas (GCN), es fundamental para mapear datos de dimensión finita a un espacio de mayor dimensión. Este mapeo ayuda a la detección de anomalías al tiempo que preserva la distribución de los datos. Las GCN dentro de la celda GCGRU aprovechan la arquitectura GRU para extraer dependencias espacio-temporales. Por último, la función principal del decodificador, facilitada por el módulo bilineal, es remuestrear las características derivadas de la salida del codificador, mejorando el proceso general de interpretación de datos.

Machine Translated by Google
www.nature.com/scientificreports/

Módulo convolucional temporal espejo (MTCM)

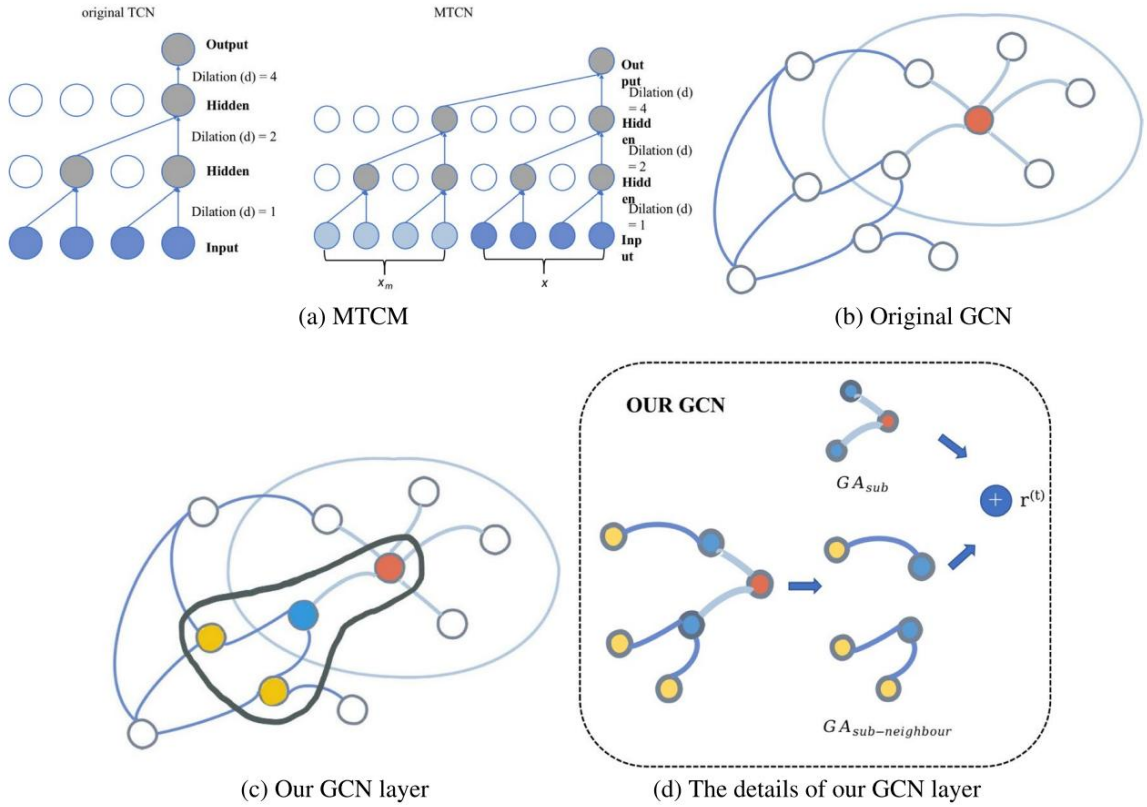
Inspirándonos en TCN11 (véase la figura 3a), propusimos un módulo superior llamado MTCM que amplía su aplicación en la predicción de tráfico. Si bien las TCN pueden usar la convolución extendida para expandir el campo perceptual, son menos potentes que las redes avanzadas (por ejemplo, Transformer), que pueden usar información de correlación de longitud arbitraria. Además, las TCN necesitan una gran adaptabilidad a diferentes datos históricos, lo que puede generar un poder predictivo y un campo perceptual desiguales. Para superar estas situaciones, adaptamos la TCN antes de transmitir las características de la red de tráfico para reducir la fluctuación de diferentes datos históricos en su capacidad. Luego, realizamos una inversión especular para preservar aún más las características y capturar las complejas relaciones y dependencias ocultas entre los nodos de la red de tráfico. Esto permite explorar las posibles asociaciones entre los nodos. Además, gracias a la convolución unidimensional de la TCN, podemos mantener la secuencia de salida consistente con la entrada original en longitud. Finalmente, esta secuencia de salida se pasará como el estado oculto subsiguiente H. Más formalmente, para una secuencia de entrada unidimensional x = {x1, x2, x3, ... xi} Ri y un filtro f : {0, ... , j − 1} → R, k es el tamaño del núcleo (el tamaño del núcleo en la Fig. 3 es 2) y d es el factor causal (véase la Fig. 3a). La operación de convolución dilatada f sobre el elemento x de la secuencia se define como:

$$(xm \quad x) \quad f(j) = \sum_{i=0}^{k-1} f(i) \cdot j - d \cdot i \tag{1}$$

donde xm es la secuencia de entrada en el proceso de inversión de espejo, denota concatenar. Esto aumenta aún más el rango del campo perceptivo y evita que se pierdan más datos históricos en el proceso de convolución inflada.

CÉLULA GCGRU

Incluye principalmente el módulo de núcleo gaussiano y la capa GCN. No adoptamos el modelo GRU (como se muestra en la Fig. 4), sino que construimos el modelo GCN inspirado en GRU después del módulo de núcleo gaussiano. En GCGRU CELL, reemplazamos la unidad cíclica con compuertas original de GRU por nuestra GCN, que tiene las siguientes dos características significativas: la compuerta de reinicio ayuda a capturar dependencias a corto plazo en la secuencia, y la compuerta de actualización ayuda a capturar dependencias a largo plazo en la secuencia. Esto predice eficazmente los ciclos de red de tráfico tanto a largo como a corto plazo, y se combina con



(a) MTCM (b) Original GCN

(c) Our GCN layer (d) The details of our GCN layer

Figura 3. (a) La ilustración explica: MTCM utiliza un núcleo de convolución de agujero con un tamaño de 2. El xm izquierdo es la característica de imagen especular de x, utiliza el factor de expansión K, selecciona la entrada de cada k paso y luego utiliza la convolución 1D. (b) La figura explica cómo un nodo incrustado y los nodos incrustados circundantes están conectados a través de GCN, donde el nodo naranja es el nodo original, y sus nodos vecinos son blancos y están encerrados en la elipse. (c) La figura explica que nuestra capa GCN es diferente de la GCN original, nuestra capa GCN puede asociar más subnodos. (d) El diagrama muestra cómo nuestra capa GCN está asociada con sus nodos hijos (nodos azules) a través del ejemplo del nodo naranja, y luego los nodos hijos (nodos azules) se extienden a sus nodos hijos (nodos amarillos).

Machine Translated by Google
www.nature.com/scientificreports/

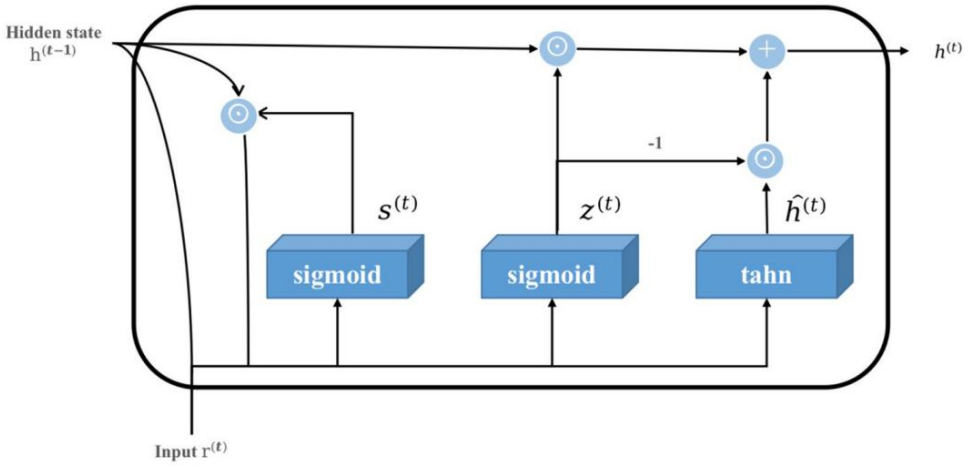


Figura 4. La imagen muestra la arquitectura GRU, en la que nos inspiramos para cambiar la unidad de control de GRU a GCN, otorgándole la misma capacidad que a GRU para capturar dependencias a corto y largo plazo en una secuencia. El control de sactualización (t) y el control de reinicio z(t) se reflejan en las ecuaciones de derivación de GCGRU en este artículo.

Mediante el procesamiento del núcleo gaussiano y el conocimiento previo H (información oculta de MTCM), GCN puede capturar información anómala y posibles anomalías en interdependencias complejas entre nodos durante la predicción. A diferencia de los datos de imagen, la convolución gráfica es una operación esencial para extraer las características de un nodo. La figura 3b muestra ejemplos de un nodo de origen (nodo naranja) para tomar el valor promedio de las características del nodo dentro de sus vecinos (nodos blancos en la elipse).

(1) Módulo de núcleo gaussiano Para mejorar aún más la capacidad de detección de anomalías de nuestro módulo, empleamos la función de núcleo gaussiano. Esto permite mantener la capacidad de las características de distribución de datos de alta dimensión, lo cual es crucial para la detección de anomalías en redes de tráfico. Específicamente, los núcleos gaussianos facilitan el mapeo de datos desde su espacio original a un espacio de características de mayor dimensión donde los patrones complejos de la red de tráfico y las anomalías potenciales se identifican y procesan más fácilmente. Además, el núcleo gaussiano exhibe estabilidad: puede gestionar fluctuaciones menores ajustando el parámetro de escala aprendido σ (ver Ec. 2) o utilizando una estrategia minimax49, lo que garantiza resultados de detección de anomalías más estables. En resumen, la incorporación de núcleos gaussianos en el módulo GCGRU CELL tiene como objetivo mejorar el rendimiento y la precisión del modelo en la detección de anomalías dentro de redes de tráfico complejas. Los datos experimentales demuestran que el uso de núcleos gaussianos para alterar la distribución de datos mejora eficazmente la precisión de la detección de anomalías de tráfico (ver Tabla 3). Partiendo de esta base, exploramos más a fondo las capacidades de detección de anomalías del módulo de núcleo gaussiano. Como se muestra en la Fig. 5, realizamos una exploración de variables intermedias de los ocho puntos característicos generados por 490 bordes que ingresan a la CELDA GCGRU. Esto demuestra la estabilidad y la capacidad de mapeo de datos de nuestro módulo al realizar operaciones de visualización en variables intermedias antes y después de integrar el módulo de núcleo gaussiano en la celda GCGRU. A lo largo de la experimentación, la estructura general de los datos permanece sin cambios, lo que garantiza consistencia y confiabilidad. Nuestra CELDA GCGRU recibe dos modos de entrada. La primera entrada es de la entrada original x después de la adaptación y recibe la información oculta H del MTCM. Luego establece la entrada como Hapt = x + H.

La segunda entrada es la salida de la primera CELDA GCGRU h(t). $_{1}$, que también recibe información oculta H. También establecemos esta entrada como Hapt = h(t). $_{1}$ + H. Entonces, la fórmula calculada por el módulo del núcleo gaussiano es la siguiente:

$$g(Hapt) = \sigma i \frac{1}{\sqrt{2\pi}} y^{-\frac{1}{2}\left(\frac{Hapt-i}{\sigma i}\right)^2}, \quad (2)$$

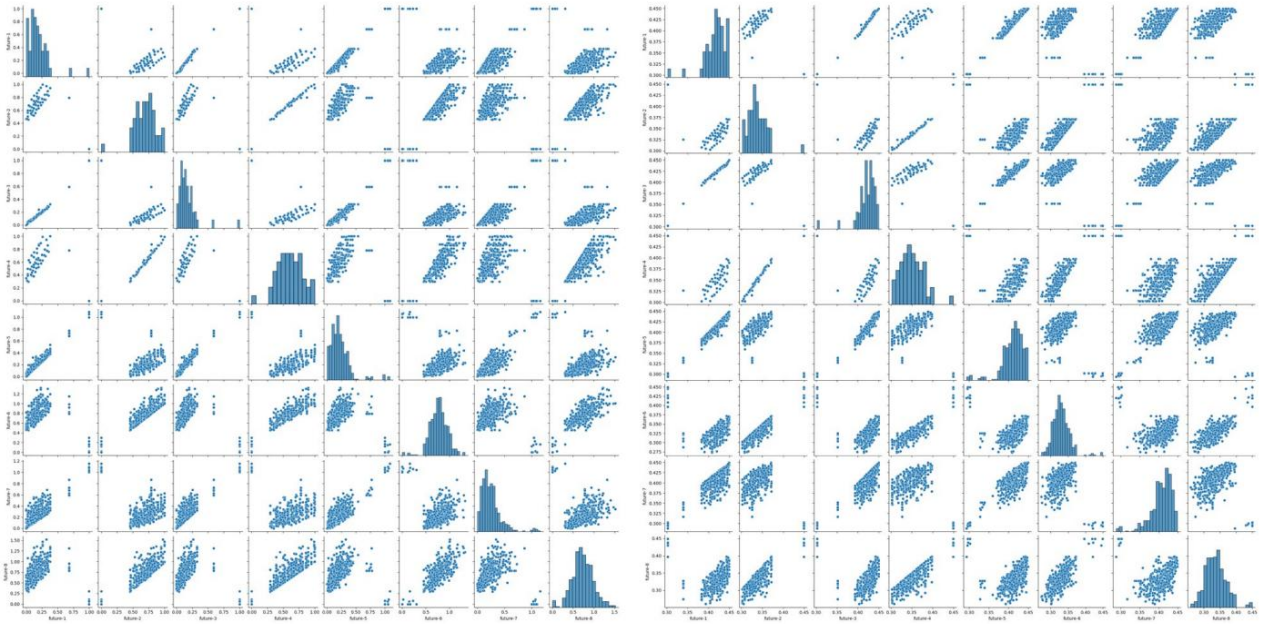
donde g(Hapt) se genera en función de la escala aprendida σ (generalmente establecemos el valor entre 0,5 y 1) y el i-ésimo elemento σi corresponde al i-ésimo punto temporal. Específicamente, para el i-ésimo punto temporal, su peso de asociación con el punto Hapt-ésimo se calcula mediante el núcleo gaussiano.

(2) Capa GCN Generalmente, la red de tráfico se presenta como un digrafo ponderado. Las redes de convolución de grafos tradicionales solo operan en nodos adyacentes, lo que resulta en una mejor predicción a corto plazo que a largo plazo. Por lo tanto, en este artículo se utiliza la teoría de grafos espectrales. Sea G = (V, E, W) y establezca la matriz espectral L = I − Dˆ −1/2Aˆ Dˆ −1/2, donde I es la matriz identidad y Dˆ es la matriz de grados, Aˆ es la matriz de adyacencia. Para explorar redes de tráfico más profundas y complejas, extendemos la red de convolución de grafos a un nivel superior y dividimos el grafo de tráfico g(x) enviado por el módulo de núcleo gaussiano en subgrafos GAsub ={g(Hapt1), g(Hapt2)... g(Haptn)}, y el subgrafo considera sus nodos vecinos GAsub−neighbour, lo que logra una agregación de información de orden superior.

$$r^{(t)} = \mathrm{ReLU}(GA^{(t-1)}_{sub} \cdot W(t)_1 + GA^{(t-1)}_{subvecino} \cdot W(t)_2), \quad (3)$$

donde $W(t)_i$ representa los pesos aprendibles y r(t) denota los resultados calculados de la convolución del grafo a medida que aumenta el tiempo t.

Machine Translated by Google
www.nature.com/scientificreports/



(a) Before (b) After

Figura 5. Extrajimos las variables intermedias antes y después de usar el módulo de núcleo gaussiano para demostrar visualmente la importancia de este módulo en nuestro modelo. (a) Antes del módulo de núcleo gaussiano. (b) Después del módulo de núcleo gaussiano.

Por otro lado, el uso de GRU49 simplifica el modelo, reduciendo su complejidad y permitiendo una caracterización más rápida y eficaz de la semántica de las oraciones. En comparación con LSTM, GRU reduce el número de parámetros de activación, utiliza menos parámetros de entrenamiento, requiere menos memoria y ofrece una ejecución y un entrenamiento más rápidos.
Debido a estas ventajas, nuestro modelo adopta la arquitectura GRU en lugar del enfoque LSTM tradicional. Hemos transformado la unidad de compuerta en una capa de convolución gráfica, como se describe en la ecuación (3). Esta adaptación permite que la arquitectura GRU imite la unidad de compuerta de manera efectiva. En consecuencia, la capa GCN puede discernir más estados ocultos de los datos procesados por el módulo de núcleo gaussiano, capturando las correlaciones espaciales dinámicas dentro de la red de tráfico e identificando conexiones de red previamente no vistas. Formalmente,

$$\begin{aligned} s^{(t)} &= \sigma(Wz\, r(t) + Uzg(Hapt)),\\ z(t) &= \sigma(Wsr(t) + Usg(Hapt)),\\ h(t) &= \tanh\left(Wr(t) + U(s^{(t)} \quad g(Hapt))\right),\\ h(t) &= z(t) \quad h(t-1) + (1 - z(t)) \quad h(t), \end{aligned} \tag{4}$$

donde ht−1 es el estado de memoria anterior, Wz, Ws y Uz, Us, U son los parámetros de ponderación, r(t) es la entrada de características actual y σ es una función de activación sigmoide. Combinamos GCN y GRU para capturar las dependencias a largo plazo entre los nodos del grafo.

(3) Incrustación de grafos (GE) Construimos una incrustación temporal (denominada módulo GE en la Fig. 2) después de la segunda CELDA GCGRU para capturar eficazmente la intrincada periodicidad semanal y horaria inherente a los datos de movilidad. La incrustación temporal consta de dos componentes: hhour Rday representa la incrustación de la hora del día, y hday Rweek representa la incrustación del día de la semana. Por ejemplo, en un momento específico t (p. ej., las 13:00 del sábado 30 de julio), usamos hhour (es decir, las 13:00) y hday (es decir, sábado) como incrustaciones temporales. Estas incrustaciones sirven para incorporar información temporal adicional como contexto para el codificador y decodificador condicionados.
Al incorporar estos factores temporales como incrustaciones de grafos hG(t) , el modelo podría capturar y representar con precisión los patrones y variaciones en los datos de movilidad asociados con diferentes momentos y días.

$$\begin{aligned} \underline{h(t)} &= (h(t)_1, h(t)_2, \ldots, h(t)_n, \text{hhora}(t), \text{hdía}(t)),\\ \underline{Utah)} &= U^{\wedge}(t)\,(U^{\wedge}(t)\,(h(t) \quad \underline{\quad})),\\ hG(t) &= \text{ReLU}(UGu(t)\ \underline{\quad}), \end{aligned} \tag{5}$$

donde hG(t) es la incrustación del gráfico en el tiempo t, Uˆ de la fórmula 4 y UG es la matriz de pesos.

Descifrador

En el decodificador, comenzamos con la extracción de información sobre la incrustación del nodo a partir de la incrustación del grafo hG(t) . Para cada par de incrustaciones de nodos (vi, vj), incrustamos la información de tiempo hhour(t) , hday(t) en la información de

Cada par de nodos y se calcula el peso correspondiente wij en la matriz de adyacencia ponderada. Luego, combinamos estas incrustaciones de nodos e incrustaciones de tiempo para formar una información de incrustación de grafo h′ G(t) que varía a lo largo del tiempo t. Contiene tanto la información de los nodos como la información de tiempo (es decir, la incrustación incluye las características colectivas de todos los nodos en el grafo en ese momento t). Posteriormente, se utiliza una capa totalmente conectada para procesar esta incrustación de grafo, para recuperar representaciones vectoriales útiles a partir de ella. Después del procesamiento por la capa totalmente conectada (t) y hj
capa conectada, los vectores i y j, correspondientes a hi $^{(t)}$, se desapilan para recuperar la incrustación de (t)
cada nodo individual en el instante t. En consecuencia, el resultado de este proceso es la representación de incrustación hn.
de un nodo particular n bajo condiciones de tiempo t específicas. Finalmente, para obtener los pesos de arista reconstruidos, primero usamos la función de activación ReLU para procesar las incrustaciones del grafo, lo que resultó en un vector de características W^ij(t) que ha sufrido una transformación no lineal. Luego, los pesos de arista reconstruidos WR (t) se obtienen a partir del vector de características ij W^ij(t) y la función sigmoide.

La presencia de un módulo bilineal en el decodificador es significativa. El módulo bilineal aplica una transformación a los datos entrantes, lo que proporciona dos beneficios principales: 1) El módulo bilineal garantiza que las predicciones de peso de las aristas consideren la direccionalidad. En el grafo dirigido, el peso de la arista del nodo i al nodo j podría diferir del peso (t).
del nodo j al nodo i. 2) El módulo bilineal emplea la fórmula wij = hi Ah $^{(t)}$ para calcular los pesos de los bordes, donde A es un parámetro aprendido. Este enfoque permite que el modelo distinga los pesos de las aristas según su dirección, representando con mayor precisión las relaciones de los grafos dirigidos.

$$\begin{aligned} h' G(t) &= \mathrm{ReLU}(\mathrm{decGConcat}(hG(t), hhour(t), hday^{(t)})), \\ \{h1^{(t)}, h2^{(t)}, \ldots, h\underline{n}^{(t)}\} &= \mathrm{desapilar}(h' G(t)), \\ W\hat{}ij(t) &= \mathrm{ReLU}(\mathrm{dec1Concat}(hi^{(t)}, hj^{(t)})), \\ WR_{ij}(t) &= \mathrm{Sigmoide}(\mathrm{dec2}W\hat{}ij(t)) \end{aligned} \tag{6}$$

donde decG es la matriz de pesos, dec1 es la matriz de pesos del vector de características W^ij(t) y dec2 es la matriz de pesos de WR
ij (t). La función sigmoide garantiza la salida WR ij (t) [0, 1].

Función de pérdida

Utilizamos el error cuadrático medio (ECM) como función de pérdida, una medida de la diferencia entre el valor real y y el valor predicho y^, para evaluar nuestro modelo. Formalmente:

$$\mathrm{Pérdida}(W^R_{ij}(t), \mathrm{Nosotros}) = \frac{1}{n} \sum_{i=1}^{n} (WR_{ij}(t) - \mathrm{Nosotros})^2, \tag{7}$$

donde i es el valor de cada punto en la secuencia. Y los pesos reconstruidos son WR (t) y los pesos reales
ij son Wij. Durante las pruebas, la función de pérdida Eq. (7) para cada instancia de prueba se utiliza como su puntuación de anomalía.

Experimentos

Conjuntos de datos e implementación

Para garantizar la credibilidad del modelo, en nuestros experimentos nos centramos en conjuntos de datos generales destinados a la detección de anomalías en el tráfico. Verificamos nuestro método MTGAE con dos conjuntos de datos públicos de redes de tráfico.

- Conjunto de datos PEMS-BAY: Se recopila en tiempo real de casi 40.000 detectores individuales que abarcan el sistema de autopistas en todas las principales áreas metropolitanas de California50. El conjunto de datos comprende 365 sensores ubicados en el área de la bahía y contiene datos de tráfico registrados de abril a mayo de 2014. Para nuestro análisis, seleccionamos un subgrafo de seis sensores, cada uno con información registrada de velocidad y flujo de tráfico correspondiente a nuestra red. Además, extendimos la duración de cada incidente de tráfico de CHP (Información de incidentes de tráfico de CHP https://www.chp.ca.gov/traffic), Se añadirá una hora para tener en cuenta el impacto de los accidentes de tráfico.
- Conjunto de datos de taxis de la ciudad de Nueva York (NYC): El conjunto de datos de viajes en taxi de la ciudad de Nueva York (NYC) es publicado públicamente por la Comisión de Taxis y Limusinas (TLC). Lo utilizamos para registrar la hora y el lugar de cada recogida y entrega de taxi y agrupar los registros generados para cada hora de ese taxi en una matriz. Este conjunto de datos incluye seis meses de datos, de enero de 2019 a marzo de 2019. Dado que el conjunto de datos de NYC carece de puntos de etiquetado de excepciones, utilizamos la inyección de excepciones para agregar excepciones en la sincronización del conjunto de datos51,52.

Líneas de base

Para validar la efectividad de nuestro método en la detección de anomalías dentro del conjunto de datos de la ciudad de Nueva York, obtuvimos estos métodos de sus repositorios de código públicos oficiales y empleamos sus configuraciones experimentales óptimas, ejecutando todos los modelos en el conjunto de datos de la ciudad de Nueva York para garantizar la imparcialidad:

- Con-GAE13: Este método se desarrolló para abordar los desafíos que plantean la extrema escasez de datos y la alta dimensionalidad, específicamente para detectar anomalías en las condiciones del tráfico. Además, utiliza autoencoders gráficos con contexto para mejorar la eficacia de la detección de anomalías.
- SuperGAT53: Una red de atención gráfica auto-supervisada que utiliza información de los bordes para guiar el aprendizaje de la atención. SuperGAT analiza dos formas comunes de atención, revelando sus limitaciones para capturar la concordancia de etiquetas y la presencia de aristas, y propone mecanismos de atención mejorados adaptados a las características del grafo.

Machine Translated by Google
www.nature.com/scientificreports/

• EG54: El método de convolución gráfica eficiente (EGC) es una arquitectura de red neuronal gráfica (GNN) isotrópica. EGC supera a modelos anisotrópicos comparables como GAT y PNA en términos de precisión y eficiencia. Este hallazgo cuestiona la creencia generalizada de que las GNN anisotrópicas son inherentemente superiores.
• GraphGPS55: Un marco modular y escalable diseñado para construir transformadores de grafos, que integra el paso de mensajes con la atención global. Este marco también categoriza las codificaciones posicionales y estructurales, inyectando así sesgos inductivos útiles. GraphGPS demuestra un rendimiento de vanguardia en diversas tareas de aprendizaje de grafos y se escala fácilmente a miles de nodos.

• GATv217: Las redes de atención gráfica (GAT) se ven limitadas por su cálculo de atención estática restringida, lo que inhibe su capacidad para priorizar dinámicamente a los vecinos. Para superar esta limitación, GATv2 altera el orden de las operaciones en la función de puntuación, lo que permite una atención dinámica más expresiva.
• Dir-GNN56: Este método mejora las redes neuronales de paso de mensajes (MPNN) al incorporar la direccionalidad de las aristas y realizar agregaciones distintas para las aristas entrantes y salientes. Además, mejora significativamente el aprendizaje en grafos heterofílicos, donde los nodos vecinos suelen tener etiquetas diferentes, y mantiene el rendimiento en grafos homofílicos, caracterizados por vecinos que comparten etiquetas.
• PMLP57: Este método introduce MLP propagativas, que emplean la arquitectura MLP para el entrenamiento y añaden capas de paso de mensajes antes de la inferencia. Este enfoque cierra la brecha entre las MLP y las GNN, logrando un rendimiento comparable o superior al de las GNN. Demuestra la eficacia de las arquitecturas GNN para la generalización, incluso sin entrenamiento en un contexto de grafo. Además, las PMLP ofrecen un entrenamiento más rápido y robusto que las GNN.

Montajes experimentales

Nuestros experimentos se llevaron a cabo utilizando una GPU 2080TI y una CPU Intel(R) Core(TM) i7-7700K a 4,20 GHz.
Considerando el problema de la anomalía, utilizamos experimentalmente la inyección de anomalías, seleccionando aleatoriamente intervalos de tiempo θ. en cada secuencia para inyectar anomalías. Luego extraiga una porción de la serie temporal correspondiente a cortes de tiempo distribuidos uniformemente θ para factores de perturbación para perturbación de anomalía (por ejemplo, 10 am para 10 pm). En este experimento, establecemos tres razones de contaminación y magnitudes α, β y γ en el conjunto de datos NYC. Las anomalías en las redes de tráfico se dividen principalmente en dos tipos58,59: (1) Anomalías espaciales: donde las condiciones de tráfico actuales son inconsistentes con las condiciones de tráfico normales (por ejemplo, el flujo de vehículos de tráfico es inconsistente con el flujo normal de viaje en el pasado). (2) Anomalías temporales: donde las condiciones de tráfico actuales se ajustan al patrón espacial normal, pero no al tiempo actual. En este artículo, realizamos algún manejo de anomalías en el conjunto de datos: Sea γ la proporción de cortes de tiempo seleccionados aleatoriamente para contaminación, que es aplicable a la inyección de anomalías espaciales y temporales; Sea α la proporción de pares origen-destino seleccionados para contaminación; Sea β el rango de la distribución uniforme utilizada para perturbar el tiempo de viaje. De hecho, β define la magnitud de las anomalías espaciales, es decir, el valor máximo posible de la perturbación del tiempo de viaje.

En los experimentos, ajustamos los niveles de las proporciones y magnitudes de contaminación (α, β y γ) para evaluar la efectividad de la detección de anomalías en diferentes escenarios. Los pasos específicos son los siguientes: Para las anomalías espaciales, primero seleccionamos aleatoriamente una cierta proporción (γ) de intervalos de tiempo y elegimos aleatoriamente una cierta proporción (α) de pares origen-destino en cada intervalo de tiempo contaminado, y luego perturbamos el tiempo de viaje de estos pares con factores extraídos de la distribución uniforme U(−β, β). Las anomalías temporales se crean seleccionando aleatoriamente una cierta proporción (γ) de intervalos de tiempo y desplazando el tiempo en los datos en 12 horas (por ejemplo, cambiando las 8 p. m. a las 8 a. m., y viceversa). Establecemos α {25%, 50%}, β {5%, 10%, 20%} y γ {5%, 10%, 20%}.

Para el proceso de entrenamiento, inicialmente establecimos el número de épocas en 150 y el tamaño del lote en 10 por época. En las métricas de día de la semana y hora del día mencionadas anteriormente, establecimos tanto hday como hhour en 100, y la dimensión de la incrustación del gráfico la establecimos en 150 y 50, respectivamente, la tasa de descarte se estableció en 0.2, la tasa de aprendizaje es 0.001 por defecto. Luego, establecimos la disminución de la tasa de aprendizaje en el proceso, cada vez, el crecimiento es 0.1 veces la tasa de aprendizaje anterior para que el modelo pueda aprender mejor los parámetros. Finalmente, seleccionamos los conjuntos de datos de NYC del 8 de enero al 31 de marzo de 2019, como conjunto de entrenamiento y extrajimos el 10% de él para validación. Usamos los conjuntos de datos de NYC del 1 al 7 de enero de 2019, y una parte del Movimiento Uber como conjunto de prueba. Cabe señalar que el proceso de muestreo se basó en un muestreo aleatorio de distribución uniforme, y tanto el conjunto de entrenamiento como el conjunto de prueba eran mutuamente excluyentes (es decir, un mismo dato no aparecía en ambos conjuntos).

Además, se realizaron experimentos de ablación en el conjunto de datos PEMS para verificar la efectividad del módulo propuesto, que se evaluó utilizando métricas MAE. Las funciones de pérdida MAE y RMSE son métodos de prueba más fiables en la detección de anomalías, especialmente en el área de tráfico3. Se establecieron seis épocas para el entrenamiento.
Cada período se dividió en 128 lotes, la función de pérdida del generador fue de 500, la tasa de aprendizaje fue de 0,001 y disminuyó en un factor de 0,1 por época. En este conjunto de datos, establecimos el número de capas de TCN en 9 y transformamos los nodos de cabeza en GCN a GAT para mejorar el paralelismo del modelo. En el aprendizaje, establecimos la capa oculta en 64.

Resultado y análisis

(1) Comparación con trabajos de vanguardia Inicialmente, comparamos nuestro modelo MTGAE con algunos modelos de referencia utilizando el AUC como métrica de evaluación. El cálculo del AUC considera tanto la capacidad de clasificación del clasificador para casos positivos como negativos, lo que permite una evaluación razonable del clasificador incluso en caso de desequilibrio de muestras. Fijamos α = 50 % y β = 10 % en la magnitud de la contaminación y utilizamos la tasa de anomalías para comparar la capacidad del modelo para detectar anomalías. Como se puede observar en la Tabla 1 , nuestro MTGAE es significativamente mejor que los demás modelos. Nuestro modelo supera a los demás en aproximadamente 0,1–0,4 en diferentes tasas de anomalías.

Después, fijamos el intervalo de tiempo γ de la contaminación para estudiar la magnitud anormal y cambiar la magnitud de la contaminación de manera diferente. Como se muestra en la Tabla 2, controlamos α en 25% y 50% respectivamente, y β se controló con la misma magnitud de contaminación que α. Podemos ver que nuestros modelos son superiores a la línea base, pero con un β más alto.
Por ejemplo, el AUC de la mayoría de los modelos con α = 50% y β = 20% está por encima de 0,9, y la mayoría de los modelos de referencia

Machine Translated by Google
www.nature.com/scientificreports/

tasa de anomalía γ	5%	10%	20%	
HA (1981)	0,728	0,687	0,711	
RTC (2020)	0,736	0,765	0,790	
AE (2002)	0,813	0,812	0,806	
EncDec-AD (2016)	0,584	0,582	0,582	
REBM (2018)	0,844	0,859	0,833	
DAGMM (2016)	0,550	0,546	0,507	
GraphSAGE (2017)	0,842	0,840	0,860	
GCN (2016)	0,708	0,717	0,744	
Con-GAE (2021)	0,903	0,908	0,913	
SuperGAT (2021)	0,901	0,908	0,910	
EG (2021)	0,883	0,902	0,912	
GraphGPS (2022)	0,894	0,906	0,911	
GATv2 (2022)	0,887	0,899	0,902	
Director-GNN (2023)	0,882	0,899	0,911	
PMLP-capa128 (2023)	0,960	0,965	0,968	
MTGAE	1.000	1.000	1.000	

Tabla 1. Dados α y β fijos, las puntuaciones AUC de diferentes modelos con la fracción γ de los segmentos de tiempo elegidos para ser contaminados.

Tasa de anomalía espacial α	25%			50%		
Magnitud de la anomalía β	5%	10%	20%	5%	10%	20%
HA (1981)	0,405	0,533	0,804	0,455	0,687	0,934
AE (2002)	0,294	0,572	0,936	0,405	0,812	0,994
EncDec-AD (2016)	0,410	0,483	0,727	0,452	0,582	0,896
GCN (2016)	0,443	0,564	0,844	0,498	0,717	0,966
DAGMM (2016)	0,511	0,527	0,567	0,525	0,546	0,639
GraphSAGE (2017)	0,381	0,627	0,963	0,491	0,840	1,000
REBM (2018)	0,389	0,633	0,958	0,491	0,859	0,997
RTC (2020)	0,626	0,699	0,863	0,648	0,765	0,942
Con-GAE (2021)	0,946	0,755	0,985	0,610	0,908	1,000
SuperGAT (2021)	0,904	0,910	0,911	0,893	0,908	0,911
EG (2021)	0,897	0,904	0,906	0,888	0,902	0,906
GraphGPS (2022)	0,900	0,909	0,911	0,890	0,906	0,911
GATv2 (2022)	0,894	0,901	0,902	0,885	0,899	0,902
Director-GNN (2023)	0,893	0,902	0,904	0,883	0,899	0,904
Capa PMLP-1 (2023)	0,895	0,902	0,905	0,884	0,900	0,905
PMLP-capa2 (2023)	0,880	0,887	0,888	0,871	0,885	0,889
PMLP-layer64 (2023)	0,916	0,924	0,926	0,906	0,922	0,926
PMLP-capa128 (2023)	0,960	0,967	0,968	0,952	0,965	0,968
MTGAE	1.000	1.000	1.000	1.000	1.000	1.000

Tabla 2. Dado un γ fijo , se muestran las puntuaciones AUC para la detección de anomalías. Los resultados se presentan con diferentes valores de α y β.

Los modelos con β = 5% no están funcionando bien. En cambio, todos aumentan gradualmente su capacidad AUC a medida que β aumenta, mientras que nuestro modelo tiene un rendimiento excelente en todos los aspectos, por lo que es un modelo más competitivo.

(2) Estudio de ablación En el estudio de ablación, evaluamos varias variantes de MTGAE para evaluar los efectos de diferentes partes de nuestro MTGAE (ver Tabla 3). Las variantes incluyen: (i) MTGAE-gan: Usamos el marco de GAN en lugar de un autoencoder. (ii) MTGAE-ot: Adoptamos el enfoque de usar un autoencoder y solo empleamos el TCN original en lugar de nuestro MTCM propuesto. (iii) MTGAE-mt: Eliminamos TCN e incorporamos nuestro módulo MTCM propuesto. (iv) MTGAE-lstm: Eliminamos GRU y lo reemplazamos con LSTM. (v) MTGAE-grumt: Eliminamos LSTM y lo reemplazamos con GCGRU CELL. (vi) MTGAE-Transformer: Eliminamos GCGRU CELL y lo reemplazamos con Transformer. (vii) MTGAE-gb: Incorporamos el módulo de núcleo gaussiano en MTCM y GCGRU CELL, ubicándolo en la etapa final de procesamiento de datos de GCGRU CELL. (viii) MTGAE: Nuestro marco de modelo completo. El estudio indica que la variante básica de TCN tiene un rendimiento inferior.

Machine Translated by Google

Modelo	Nota sobre el error cuadrático medio (RMSE) del MAE		
MTGAE-por	3.076	6.770	Reemplazar nuestra arquitectura de modelo con GAN
MTGAE-ot	3.150	6.880	El módulo de convolución temporal sin espejo
MTGAE-montaña	3.019	6.713	El módulo de convolución temporal con espejo
MTGAE-lstm	3.224	6.940	Reemplazar GRU con LSTM
MTGAE-grim	3.052	6.751	Agregar el módulo GCGRU-Cell a la arquitectura
MTGAE-Transformer	17.020	32.507	Reemplazar nuestra arquitectura de modelo con Transformer
MTGAE-gb	3.088	6.780	El módulo del núcleo gaussiano como paso de postprocesamiento
MTGAE	2.990	6.679	Nuestro método

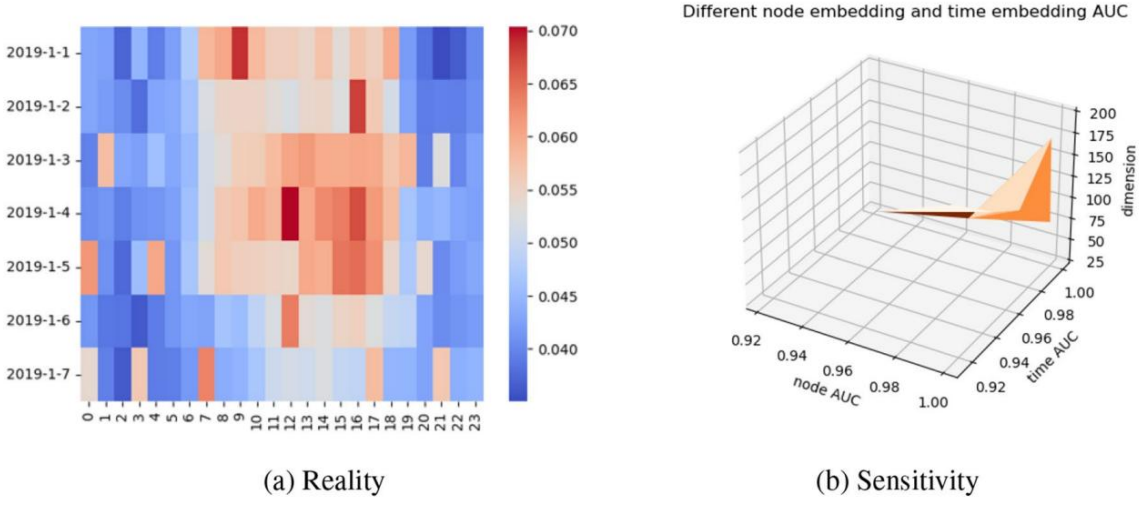
Tabla 3. Estudio de ablación.

a menos que se combine con la función de núcleo gaussiano para el procesamiento, lo que ilustra la importancia de MTCM y GCGRU CELL para la detección de anomalías. Cabe destacar que la incorporación de un espejo en TCN mejora significativamente su eficacia para potenciar el rendimiento de GCGRU CELL, lo que demuestra una capacidad superior para capturar tanto la memoria a corto como a largo plazo y la información temporal en series temporales.

(3) El mundo real refleja el tráfico anormal. Utilizamos el conjunto de datos de la ciudad de Nueva York del 1 al 7 de enero de 2019 para probar la situación del tráfico en el mundo real y demostrar la efectividad de nuestro modelo. Utilizamos la pérdida de reconstrucción para representar la posibilidad de anomalías, como se muestra en la Fig. 6. El 4 de enero es viernes en el mundo real, y podemos ver que la posibilidad de anomalías en la distribución de la tarde de este día es muy alta, de lo cual podemos inferir que las compras del Black Friday son propensas a anomalías de tráfico debido a los atascos.

(4) Análisis de sensibilidad Para estudiar cómo varía MTGAE para la incrustación semanal, horaria y de nodos, colocamos α = 50% y β = 10%γ = 10%. Exploramos la afectividad del modelo en el espacio-tiempo y cambiamos la dimensión de la incrustación de nodos de 25 a 200 (la dimensionalidad es aceptable para el primer GCN y el segundo GCN) y la dimensión semanal y horaria de la incrustación temporal de 10 a 200 para el entrenamiento. Como se muestra en la Fig. 6b, nuestro modelo no cambia mucho y los AUC se mantienen entre 0,9 y 1, lo que indica que nuestro modelo funciona bien en la mayoría de los entornos. Además, podemos ver que el AUC de nuestro modelo es menor cuando la incrustación de nodos de tiempo es grande que cuando la incrustación es pequeña.

(5) Capacidad de generalización Para explorar la capacidad de generalización de MTGAE, realizamos experimentos en un conjunto de datos de grafos dinámicos a gran escala, DGraphFin, en el dominio financiero60. Contiene más de 3,7 millones de nodos y 4,3 millones de aristas dinámicas. Los nodos representan usuarios de préstamos financieros y las aristas dirigidas representan relaciones de contacto de emergencia. Cada dimensión representa 17 elementos diferentes de perfiles personales, como la edad y el género. Entre los nodos del conjunto de datos, 15.509 se clasifican como estafadores, 1.210.092 como usuarios normales y el 66,8% restante de los nodos (2.474.949 nodos) son usuarios registrados que no han solicitado préstamos en la plataforma. Basándonos en la línea base y el código publicados oficialmente, introducimos los datos de DGraphFin en nuestro MTGAE, luego realizamos el aprendizaje de características a través de las 17 características en la estructura de MTGAE y, finalmente, los dividimos en dos categorías (otras líneas base también los dividen en dos categorías) para la detección de anomalías, con los resultados que se muestran en la Tab



(a) Reality (b) Sensitivity

Figura 6. (a) Capacidad de nuestro modelo para detectar anomalías de tráfico. El eje horizontal representa la hora, el eje vertical la fecha y la profundidad de color indica la probabilidad de anomalías de tráfico (pérdida de reconstrucción). (b) Experimento de sensibilidad del modelo. Se garantiza que estará entre 0,9 y 1,0 bajo diferentes configuraciones de incrustación de nodos e incrustación de tiempo.

Machine Translated by Google
www.nature.com/scientificreports/

Modelo AUC	
GCN	0,707
MLP	0,719
PUERTA	0,733
GATv2	0,762
TGN	0,774
SABIO	0,776
MTGAE 0.768	

Tabla 4. Puntuaciones AUC de nuestro modelo y otros modelos de referencia en el conjunto de datos DGraphFin.

Con la red diseñada específicamente para el conjunto de datos DGraphFin, los resultados de los experimentos demuestran que nuestro MTGAE posee ciertas capacidades de generalización.

Conclusiones

Este artículo propone MTGAN, un marco de detección de anomalías espacio-temporales para el tráfico. En el codificador, proponemos dos módulos: Mirror TCN (MTCM) y una variante de GCGRU, denominada GCGRU CELL, que captura correlaciones en las dimensiones espacial y temporal, además de un enfoque práctico: TCN adaptativo. Posteriormente, realizamos una inyección de anomalías en el conjunto de datos mediante tres métricas de contaminación y lo probamos en el conjunto de datos NCY.

Los resultados experimentales demuestran que nuestro marco supera al método de referencia en la detección de anomalías de tráfico, especialmente en aspectos de escasez y alta dimensionalidad, lo que contribuye a futuras investigaciones. En trabajos futuros, exploraremos extensiones adicionales de MTGAE en más conjuntos de datos y profundizaremos en métodos para el aprendizaje de correlaciones espaciales dinámicas.

Disponibilidad de datos

Los conjuntos de datos analizados durante el presente estudio están disponibles en el repositorio de GitHub, incluidos el conjunto de datos de NYC y el conjunto de datos PEMS, que se pueden encontrar en https://github.com/yuehu9/Con-GAE y https://github.com/dleyan/STGAN, respectivamente. Y los conjuntos de datos utilizados para probar las capacidades de generalización: https://dgraph.xinye.com/dataset. Además, recopilamos y analizamos algunos de los datos utilizados en nuestros experimentos. Los datos experimentales recopilados durante el presente estudio están disponibles a solicitud razonable del autor correspondiente.

Recibido: 24 de marzo de 2023; Aceptado: 4 de enero de 2024
Published online: 13 January 2024

Referencias

1. Gao, J., Zheng, D. y Yang, S. Percepción de anomalías de tráfico espaciotemporales a partir de dinámicas urbanas modeladas con representación dispersa. Pers. Computación ubicua 27, 1–14 (2020).
2. Zhang, M. et al. Análisis de anomalías urbanas: descripción, detección y predicción. IEEE Trans. Big Data 8, 809–826 (2020).
3. Deng, L., Lian, D., Huang, Z. y Chen, E. Redes neuronales convolucionales adversarias gráficas para la detección de anomalías espaciotemporales. IEEE Trans. Neural Netw. Learn. Syst. 33, 2416–2428 (2022).
4. Abdallah, M. et al. Detección de anomalías y aprendizaje por transferencia entre sensores en conjuntos de datos de fabricación inteligente. Preimpresión de arXiv arXiv: 2206.06355 (2022).
5. Deng, A. y Hooi, B. Detección de anomalías basada en redes neuronales gráficas en series temporales multivariadas. En Actas de la AAAI Con Conferencia sobre Inteligencia Artificial, vol. 35, 4027–4035 (2021).
6. Zhao, S. et al. GMAT-DU: Predicción de anomalías de tráfico con granularidad espaciotemporal fina en datos dispersos. IEEE Trans. Intell. Transp. Syst. (2023).
7. Kim, H., Lee, B. S., Shin, W.-Y. y Lim, S. Detección de anomalías en grafos con redes neuronales gráficas: estado actual y desafíos. Acceso IEEE (2022).
8. Li, D., Chen, D., Goh, J. y Ng, S.-k. Detección de anomalías con redes generativas adversarias para series temporales multivariadas. arXiv preimpresión arXiv:1809.04758 (2018).
9. Park, D., Hoshi, Y. y Kemp, CC. Un detector de anomalías multimodal para la alimentación asistida por robot mediante un autoencoder variacional basado en LSTM. IEEE Robot. Autom. Lett. 3, 1544–1551 (2018).
10. Liu, X. et al. Predicción de anomalías de tráfico basada en aprendizaje evolutivo espacio-temporal estático-dinámico conjunto. IEEE Trans. Knowl. Ing. de datos. 35, 5356–5370 (2022).
11. Bai, S., Kolter, J. Z. y Koltun, V. Una evaluación empírica de redes convolucionales y recurrentes genéricas para el modelado de secuencias. Preimpresión de arXiv arXiv:1803.01271 (2018).
12. Zhang, R. et al. Modelo de pronóstico de flujo de tráfico a corto plazo basado en GA-TCN. J. Adv. Transp. 2021, 1–13 (2021).
13. Hu, Y., Qu, A. y Work, D. Redes neuronales convolucionales gráficas para anomalías de tráfico. Preimpresión de arXiv arXiv :2012.13637 (2020).
14. Dwivedi, V. P., Joshi, C. K., Laurent, T., Bengio, Y. y Bresson, X. Evaluación comparativa de redes neuronales gráficas. Preimpresión de arXiv arXiv :2003. 00982 (2020).
15. Abadal, S., Jain, A., Guirado, R., López-Alonso, J. y Alarcón, E. Cálculo de redes neuronales gráficas: una revisión desde algoritmos hasta aceleradores. ACM Comput. Surv. (CSUR) 54, 1–38 (2021).
16. Veličković, P. et al. Redes de atención gráfica. Preimpresión de arXiv arXiv:1710.10903 (2017).
17. Brody, S., Alon, U. y Yahav, E. ¿Qué tan atentas son las redes de atención de grafos? Preimpresión de arXiv arXiv:2105.14491 (2021).
18. Zhu, W., Sun, Y., Yi, X., Wang, Y. y Liu, Z. Una red espaciotemporal basada en información de correlación para la predicción del flujo de tráfico. Neural Comput. Appl. 35, 21181–21199 (2023).
19. Jiang, J., Han, C., Zhao, W. X. y Wang, J. PDFormer: Transformador dinámico de largo alcance sensible al retardo de propagación para el flujo de tráfico predicción. Preimpresión de arXiv arXiv:2301.07945 (2023).

20. Liu, H. et al. El incrustamiento adaptativo espaciotemporal convierte al transformador estándar en tecnología de punta para la predicción del tráfico. En Actas de la 32.ª Conferencia Internacional ACM sobre Gestión de la Información y el Conocimiento, 4125–4129 (2023).
21. Zhang, M. et al. Un enfoque de descomposición para la detección de anomalías urbanas en datos espaciotemporales. En IJCAI International Joint Conferencia sobre Inteligencia Artificial (Conferencias Conjuntas Internacionales sobre Inteligencia Artificial, 2019).
22. Seo, Y., Defferrard, M., Vandergheynst, P. y Bresson, X. Modelado de secuencias estructuradas con redes recurrentes convolucionales de grafos. En Conferencia internacional sobre procesamiento de información neuronal, 362–373 (Springer, 2018).
23. Wu, Z. et al. Un estudio exhaustivo sobre redes neuronales gráficas. IEEE Trans. Neural Netw. Learn. Syst. 32, 4–24 (2020).
24. Drakulic, D. y Andreoli, J.-M. Predicción de series temporales estructuradas sin información previa estructural. Preimpresión de arXiv arXiv:2202.03539 (2022).
25. Kipf, T. N. y Welling, M. Autoencoders de grafos variacionales. Preimpresión de arXiv arXiv:1611.07308 (2016).
26. Mathieu, E., Le Lan, C., Maddison, C. J., Tomioka, R. & Teh, Y. W. Representaciones jerárquicas continuas con variaciones de poincaré. autoencoders fisiológicos. En Advances in Neural Information Processing Systems, vol. 32 (2019).
27. Keser, R. K., Nallbani, I., Çalik, N., Ayanzadeh, A. y Töreyin, B. U. Incrustación de grafos para la predicción de enlaces mediante autoencoders de grafos variacionales residuales. En 2020 28th Signal Processing and Communications Applications Conference (SIU), 1–4. (IEEE, 2020).
28. Huang, W. R. Sobre el reponderado de aristas para la predicción de enlaces con autoencoders de grafos (2020).
29. Guo, Z., Wang, F., Yao, K., Liang, J. y Wang, Z. Autoencoder gráfico variacional multiescala para predicción de enlaces. En Actas de la Decimoquinta Conferencia Internacional ACM sobre Búsqueda Web y Minería de Datos, 334–342 (2022).
30. Hu, Y., Qu, A. y Work, D. Detección de eventos de tráfico extremos mediante un autoencoder gráfico con contexto aumentado. ACM Transactions on Sistemas y Tecnología Inteligentes (TIST) (2022).
31. Wang, C., Pan, S., Long, G., Zhu, X. y Jiang, J. MGAE: Autoencoder de grafos marginalizado para agrupamiento de grafos. En Actas de la Conferencia ACM de 2017 sobre Gestión de la Información y el Conocimiento, 889–898 (2017).
32. Fan, S. et al. Autoencoder gráfico One2multi para agrupamiento de gráficos multivista. En Actas de la Conferencia Web, vol. 2020, 3070–3076 (2020).
33. Fan, G. et al. Detección de anomalías hiperespectrales con autoencoders gráficos robustos. IEEE Trans. Geosci. Remote Sens. 60, 1–14 (2021).
34. Dauphin, Y. N., Fan, A., Auli, M. y Grangier, D. Modelado del lenguaje con redes neuronales convolucionales con compuertas. En Conferencia internacional sobre aprendizaje automático, 933–941 (PMLR, 2017).
35. Cho, K. et al. Aprendizaje de representaciones de frases utilizando un codificador-decodificador RNN para traducción automática estadística. Preimpresión de arXiv arXiv: 1406.1078 (2014).
36. Lablack, M. y Shen, Y. Mixformer de grafos espaciotemporales para pronóstico de tráfico. Expert Syst. Appl. 228, 120281 (2023).
37. Wu, Z., Pan, S., Long, G., Jiang, J. y Zhang, C. Graph wavenet para modelado profundo de grafos espacio-temporales. Preimpresión de arXiv arXiv : 1906.00121 (2019).
38. Zhao, W., Zhang, S., Zhou, B. y Wang, B. STCGAT: Redes causales espacio-temporales para la predicción del flujo de tráfico vial urbano complejo. ción. Preimpresión de arXiv arXiv:2203.10749 (2022).
39. Ameli, M., Pfanschilling, V., Amirli, A., Maaß, W. y Kersting, K. Localización de anomalías multisensor sin supervisión con IA explicable. En IFIP International Conference on Artificial Intelligence Applications and Innovations, 507–519 (Springer, 2022).
40. Antwarg, L., Miller, RM, Shapira, B. y Rokach, L. Explicación de anomalías detectadas por autoencoders mediante el modelo aditivo de Shapley. ciones. Expert Syst. Appl. 186, 115736 (2021).
41. Givnan, S., Chalmers, C., Fergus, P., Ortega-Martorell, S. y Whalley, T. Detección de anomalías mediante reconstrucción de autoencoder en Motores industriales. Sensores 22, 3166 (2022).
42. Anand, H., Sammuli, B., Olofsson, K. y Humphreys, D. Detección de anomalías en sensores magnéticos en tiempo real mediante redes neuronales autoencoder. redes en el tokamak DIII-D. IEEE Trans. Plasma Sci. (2022).
43. Tien, C.-W., Huang, T.-Y., Chen, P.-C. y Wang, J.-H. Uso de autoencoders para la detección de anomalías y el aprendizaje por transferencia en IoT. Computadoras 10, 88 (2021).
44. Santhosh, K. K., Dogra, D. P., Roy, P. P. y Mitra, A. Clasificación de trayectorias vehiculares y detección de anomalías de tráfico en videos utilizando una arquitectura híbrida CNN-VAE. IEEE Trans. Intell. Transp. Syst. (2021).
45. Zhang, F., Fan, H., Wang, R., Li, Z. y Liang, T. Descripción de datos de vectores de soporte dual profundo para la detección de anomalías en datos atribuidos redes. Int. J. Intell. Syst. 37, 1509–1528 (2022).
46. Khan, W. y Haroon, M. Un marco eficiente para la detección de anomalías en redes sociales con atributos. Int. J. Inf. Technology 1–8 (2022).
47. Yuan, X. et al. Detección de anomalías basada en estructuras de orden superior en redes con atributos. En 2021 IEEE International Conference on Big Data (Big Data), 2691–2700 (IEEE, 2021).
48. Vaisman, Y., Katz, G., Elovici, Y. y Shabtai, A. Detección de patrones anómalos de comunicación de red mediante redes neuronales convolucionales de grafos redes. Preimpresión de arXiv arXiv:2311.18525 (2023).
49. Xu, J., Wu, H., Wang, J. y Long, M. Transformador de anomalías: detección de anomalías en series temporales con discrepancia de asociación. arXiv preimpresión arXiv:2110.02642 (2021).
50. Li, Y., Yu, R., Shahabi, C. y Liu, Y. Red neuronal recurrente convolucional de difusión: predicción de tráfico basada en datos. Preimpresión de arXiv arXiv:1707.01926 (2017).
51. Yu, W. et al. NetWalk: Un enfoque flexible de incrustación profunda para la detección de anomalías en redes dinámicas. En Actas de la 24.ª Conferencia Internacional ACM SIGKDD sobre Descubrimiento de Conocimiento y Minería de Datos, 2672–2681 (2018).
52. Akoglu, L., Tong, H. y Koutra, D. Detección y descripción de anomalías basada en grafos: una revisión. Data Min. Knowl. Disc. 29, 626–688 (2015).
53. Kim, D. y Oh, A. Cómo encontrar a tu vecindario amigable: diseño de atención de grafos con autosupervisión. Preimpresión de arXiv arXiv: 2204.04879 (2022).
54. Tailor, S. A., Opolka, F. L., Lio, P. y Lane, N. D. ¿Necesitamos redes neuronales gráficas anisotrópicas? Preimpresión de arXiv arXiv:2104.01481 (2021).
55. Rampášek, L. et al. Receta para un transformador de grafos general, potente y escalable. Adv. Neural. Inf. Process. Syst. 35, 14501–14515 (2022).
56. Rossi, E. et al. La direccionalidad de las aristas mejora el aprendizaje en grafos heterofílicos. Preimpresión de arXiv arXiv :2305.10498 (2023).
57. Yang, C., Wu, Q., Wang, J. y Yan, J. Las redes neuronales gráficas son generalizadoras inherentemente buenas: Perspectivas al conectar GNN y MLP. Preimpresión de arXiv arXiv :2212.09034 (2022).
58. Zhang, H. et al. Detección automática de anomalías de tráfico en la red vial con representación de red neuronal gráfica espacio-temporal. aprendizaje automático. Wirel. Commun. Mob. Comput. 2022, 1–12 (2022).
59. Tian, Z., Zhuo, M., Liu, L., Chen, J. y Zhou, S. Detección de anomalías mediante información espacial y temporal en datos multivariados. serie. Sci. Rep. 13, 4400 (2023).
60. Huang, X. et al. DGraph: Un conjunto de datos financieros a gran escala para la detección de anomalías en grafos. Adv. Neural. Inf. Process. Syst. 35, 22765–22777 (2022).

Expresiones de gratitud

Este trabajo fue financiado por el Programa Nacional Clave de Investigación y Desarrollo de China (2022ZD0115604) y la Fundación Nacional de Ciencias Naturales de China (Subvenciones n.° 42130608, 42075142) y la Fundación de Ciencias de Sichuan.

Machine Translated by Google
www.nature.com/scientificreports/

y programa de tecnología (números de subvención 2023ZHCG0018, 2023NSFSC0470, 2021YFQ0053, 2022YFG0152, 23NSFSC2224, 2020JDTD0020, 2022YFG0026, 2021YFG0018, 2020YJ0241).

Contribuciones de los autores

Conceptualización, XL, QT, CS y XW; Curación de datos, ZR; Análisis formal, XL y JP; Investigación, ZR, XL y CS; Metodología, ZR; Administración del proyecto, ZR; Recursos, XL y XW; Software, ZR; Supervisión, XL y KC; Validación, ZR y XL; Visualización, ZR; Redacción del borrador original, ZR; Revisión y edición, XL. Todos los autores revisaron el manuscrito.

Intereses contrapuestos

Los autores declaran no tener ningún conflicto de intereses.

Información adicional

La correspondencia y las solicitudes de materiales deben dirigirse a KC o XW.

La información sobre reimpresiones y permisos está disponible en www.nature.com/reprints.

Nota del editor: Springer Nature mantiene una postura neutral con respecto a las reivindicaciones jurisdiccionales en los mapas publicados y las afiliaciones institucionales.

Acceso abierto. Este artículo está bajo la licencia Creative Commons Atribución 4.0 Internacional, que permite su uso, distribución, adaptación y reproducción en cualquier medio o formato, siempre que se cite adecuadamente al autor o autores originales y la fuente, se proporcione un enlace a la licencia Creative Commons y se indiquen los cambios realizados. Las imágenes u otro material de terceros incluidos en este artículo están sujetos a la licencia Creative Commons del artículo, salvo que se indique lo contrario en la línea de crédito del material. Si el material no está incluido en la licencia Creative Commons del artículo y su uso previsto no está permitido por la normativa vigente o excede el uso permitido, deberá obtener el permiso directamente del titular de los derechos de autor. Para consultar una copia de esta licencia, visite http://creativecommons.org/licenses/by/4.0/.

© El/los autor/es 2024