Machine Translated by Google

IEEE Access
Multidisciplinary | Rapid Review | Open Access Journal

Recibido el 9 de diciembre de 2024, aceptado el 24 de enero de 2025, fecha de publicación el 4 de febrero de 2025, fecha de la versión actual el 12 de febrero de 2025.

Identificador de objeto digital 10.1109/ACCESS.2025.3538836

RESEARCH ARTICLE

Transformador gráfico multirresolución para carreteras Detección de anomalías en el tráfico

PARQUE DONGHYUN, SUNG-SOO CHOI, DONGHYUN LIM,
Y YONG-SHIN KANG (Miembro del IEEE)
Instituto Avanzado de Tecnología de Convergencia, Suwon-si 16229, República de Corea

Autor correspondiente: Yong-Shin Kang (yskang@snu.ac.kr)

Este trabajo fue financiado por el Instituto Coreano de Tecnología Policial (KIPoT) a través de la Agencia Nacional de Policía de Corea (KNPA), mediante el proyecto "Desarrollo de un sistema integrado de control de tráfico vial y tecnología operativa cuando la conducción autónoma se combina con vehículos normales", bajo la subvención 092021C28S01000.

RESUMEN La detección de anomalías en el tráfico se ha vuelto cada vez más vital para garantizar la seguridad, la eficiencia y la resiliencia de los sistemas de transporte urbano. El surgimiento de megaciudades y la integración de vehículos autónomos (VA) plantean nuevos desafíos para la detección de anomalías en entornos de tráfico mixto. Los VA exhiben comportamientos de conducción distintos a los de los conductores humanos, lo que resulta en escenarios de tráfico más complejos que requieren métodos de detección avanzados. Este artículo presenta un novedoso modelo de Transformador Multirresolución de Grafos (GMRT) diseñado para la detección de anomalías en el tráfico en entornos donde coexisten vehículos autónomos y conducidos por humanos. Utilizando datos de simulación de la zona de demostración de conducción autónoma en Corea del Sur, el GMRT captura eficazmente patrones temporales en múltiples resoluciones y aprovecha las relaciones espaciales basadas en grafos para mejorar el rendimiento de la detección de anomalías. A diferencia de los modelos tradicionales que se centran en el flujo de tráfico a nivel macro, nuestro enfoque opera a nivel micro (por carril), lo que permite la identificación precisa de anomalías por carril. Los experimentos comparativos con modelos de series temporales establecidos demuestran la precisión y robustez superiores del GMRT, particularmente en la detección temprana de anomalías en diversos horizontes temporales. Los resultados ponen de relieve el potencial del modelo como una solución sólida para los desafíos actuales y futuros de la gestión del tráfico urbano, especialmente en escenarios que implican una creciente penetración de vehículos autónomos.

TÉRMINOS CLAVE: Aprendizaje profundo, monitorización inteligente del transporte, detección de anomalías en el tráfico rodado, aprendizaje multirresolución, análisis de series temporales.

I. INTRODUCCIÓN

La detección de anomalías en el tráfico rodado se ha convertido en un área de investigación fundamental en los últimos años, debido a su papel esencial en el mantenimiento de la seguridad, la eficiencia y la resiliencia de los sistemas de transporte urbano [1], [2]. Las anomalías del tráfico, incluidos los accidentes, la congestión inesperada y los comportamientos de conducción anormales, pueden perturbar significativamente el flujo de tráfico, lo que conlleva pérdidas económicas considerables y mayores riesgos para la seguridad vial.

usuarios. Para mitigar estos problemas, se ha llevado a cabo una extensa investigación en detección de anomalías de tráfico, lo que ha dado como resultado el desarrollo de varios enfoques estadísticos, de aprendizaje automático y basados en aprendizaje profundo [3], [4].

El rápido crecimiento de las megaciudades y la llegada de los vehículos autónomos (VA) plantean nuevos y complejos desafíos para la detección de anomalías en el tráfico [5]. Los VA exhiben comportamientos de conducción distintos a los de los conductores humanos y se prevé que operen junto con vehículos convencionales en entornos de tráfico mixto. Esta coexistencia genera escenarios de tráfico más complejos, presentando condiciones viales diversas y nunca antes vistas. Este entorno mixto aumenta la posibilidad de anomalías en el tráfico debido a diferencias en los patrones de conducción, como la distancia de seguimiento, el tiempo de reacción y el comportamiento al cambiar de carril. La mayor complejidad exige mantener un flujo de tráfico óptimo y minimizar la posible confusión o los accidentes críticos, ya que incluso las interrupciones menores pueden propagar efectos en cascada por toda la red vial.

El editor asociado que coordina la revisión de este manuscrito y Yanli Xu fue quien aprobó su publicación.

© 2025 Los autores. Esta obra está bajo una licencia Creative Commons Atribución 4.0.
Para obtener más información, consulte https://creativecommons.org/licenses/by/4.0/

Machine Translated by Google

En este contexto, la capacidad de detectar anomalías de forma rápida y precisa cobra importancia en entornos de tráfico mixto que involucran tanto vehículos autónomos como conducidos por humanos. La detección temprana y las respuestas oportunas a las anomalías del tráfico pueden reducir sustancialmente los riesgos y mantener la fluidez del tráfico, especialmente a medida que aumenta la penetración de los vehículos autónomos.

Este artículo presenta un novedoso método de detección de anomalías de tráfico diseñado específicamente para entornos mixtos de vehículos autónomos y conducidos por humanos. Simulamos escenarios de tráfico en la zona de demostración de conducción autónoma de Pangyo, Corea del Sur, que sirve como caso de estudio real. Los datos de simulación de este entorno sustentan nuestro modelo de detección de anomalías. Presentamos un modelo de Transformador Multirresolución de Grafos (GMRT), que considera patrones temporales en diversas resoluciones —como ciclos diarios, semanales y mensuales—, mejorando así el rendimiento de la detección de anomalías.

Además, mientras que los estudios anteriores utilizaron predominantemente modelos de aprendizaje profundo como las Unidades Recurrentes de Puerta (GRU) [6], Memoria a Largo y Corto Plazo (LSTM) [7], y Redes Convolucionales Temporales (TCN) [8], para el análisis de series temporales en la detección de anomalías de tráfico, estos modelos a menudo encuentran pérdida de información al procesar datos de series temporales extensas debido a las dificultades para retener características temporales pasadas. Para superar esta limitación, nuestro modelo aprovecha la arquitectura Transformer [9], reconocida por su capacidad para capturar dependencias de largo alcance de manera más efectiva, mejorando así la precisión de detección para secuencias de tráfico prolongadas.

A diferencia de las investigaciones existentes, que suelen centrarse en el flujo de tráfico a nivel macro (enlace), este artículo propone un enfoque de detección de anomalías de tráfico a nivel micro (carril), lo que facilita la identificación precisa de anomalías en cada carril. Esta metodología a nivel micro cobra cada vez más relevancia a medida que se generalizan los sistemas avanzados de recopilación de datos de tráfico, impulsados por los avances en las tecnologías de sensores y los sistemas de comunicación. Por ejemplo, las intersecciones inteligentes, incluidas las aplicaciones de Internet de las Cosas en el borde [10], [11], facilitarán la adquisición de datos específicos de cada carril, proporcionando una perspectiva más detallada de las condiciones de la carretera.

Las principales contribuciones de este artículo son las siguientes: • Enfoque de multirresolución: Proponemos una metodología de multirresolución para la detección de anomalías en el tráfico rodado que tiene en cuenta los patrones de tráfico a diferentes escalas, como los ciclos diarios y semanales, mejorando así la precisión de detección de diversos tipos de anomalías. • Utilización de la arquitectura Transformer: Empleamos la arquitectura Transformer, reconocida por su capacidad superior para capturar dependencias de largo alcance en datos de series temporales, para superar las limitaciones de los modelos de series temporales tradicionales como LSTM y GRU. • Validación exhaustiva: Validamos nuestro enfoque mediante experimentos con datos simulados de entornos mixtos de vehículos autónomos y conducidos por humanos. El análisis comparativo del rendimiento con respecto a los modelos de series temporales ya establecidos demuestra la eficacia y la robustez del modelo GMRT.

- Detección a nivel micro: Presentamos un método de detección de anomalías de tráfico a nivel micro (carril), que permite la identificación precisa de anomalías a nivel de carril, lo cual es fundamental dados los avances previstos en los sistemas de recopilación de datos de tráfico.

El resto de este artículo está organizado de la siguiente manera. La Sección II revisa trabajos relacionados con la detección de anomalías en el tráfico y el aprendizaje multirresolución. La Sección III define el problema y detalla el modelo GMRT propuesto. La Sección IV describe los datos utilizados y los procedimientos experimentales. La Sección V presenta los resultados experimentales y la Sección VI concluye el estudio.

II. TRABAJOS RELACIONADOS

Esta sección examina investigaciones relacionadas desde dos perspectivas: la detección de anomalías en el tráfico rodado y el análisis multirresolución.

A. DETECCIÓN DE ANOMALÍAS EN EL TRÁFICO RODADO

Las primeras investigaciones sobre la detección de anomalías en el tráfico rodado emplearon principalmente modelos estadísticos. Se utilizaron técnicas como los Modelos de Mezcla Gaussiana (GMM) [2] y el Análisis de Componentes Principales (PCA) [12] para modelar y detectar anomalías en el tráfico. Si bien estos métodos demostraron ser eficaces en escenarios de tráfico sencillos, tuvieron dificultades para gestionar la creciente complejidad de las redes viales modernas, especialmente con la proliferación de datos de tráfico en tiempo real y de alta dimensionalidad.

La llegada del aprendizaje automático introdujo enfoques más sofisticados para la detección de anomalías en sistemas de tráfico. Los modelos de aprendizaje supervisado, incluyendo máquinas de vectores de soporte (SVM), bosques aleatorios [13] y k-vecinos más cercanos (k-NN) [14], se han adoptado ampliamente en este ámbito. Estos modelos se basan en conjuntos de datos etiquetados que contienen datos normales y anómalos para el entrenamiento. Sin embargo, la escasez de datos etiquetados en redes de tráfico a gran escala limita significativamente su aplicabilidad. En consecuencia, las técnicas de aprendizaje no supervisado, en particular los algoritmos de agrupamiento como k-means y DBSCAN, han ganado popularidad. Estos métodos pueden detectar anomalías sin necesidad de datos etiquetados al identificar valores atípicos que se desvían de la distribución aprendida de patrones de tráfico normales.

Los recientes avances en aprendizaje profundo han ampliado aún más las capacidades de los sistemas de detección de anomalías de tráfico. Se han empleado modelos como GRU [6] y redes LSTM [7] para capturar dependencias temporales en los datos de tráfico. Además, se han explorado las redes neuronales convolucionales (CNN) para la detección de anomalías de tráfico [8], particularmente al analizar datos de tráfico provenientes de redes de sensores o cámaras de CCTV, ya que las CNN destacan en la extracción de características espaciales cruciales para comprender la dinámica del tráfico.

Dada la estructura inherentemente espacial de las redes viales, los enfoques basados en grafos han ganado popularidad en los últimos años.

Machine Translated by Google

años. Estos métodos representan la red vial como un grafo, donde los nodos corresponden a segmentos de carretera o intersecciones y las aristas denotan las conexiones entre ellos. Se han empleado técnicas como las redes neuronales convolucionales de grafos (GCN) [15], los autoencoders de grafos [8] y los mecanismos de atención de grafos [6] para capturar las dependencias espaciales en toda la red. Estos modelos facilitan la detección de anomalías al analizar cómo las interrupciones en una parte de la red afectan a los segmentos de carretera conectados.

A pesar del éxito de estos enfoques en la detección de anomalías en el tráfico rodado, a menudo pasan por alto los desafíos asociados a las series temporales extensas. Para abordar esta deficiencia, nuestro modelo propuesto se basa en la arquitectura Transformer, que ha demostrado una capacidad significativa para modelar dependencias temporales de largo alcance, lo que lo hace idóneo para el análisis de series temporales extensas en la detección de anomalías en el tráfico.

B. APRENDIZAJE MULTIRESOLUCIÓN

El concepto de características multirresolución se ha estudiado ampliamente en el campo del análisis de imágenes [16], [17], [18]. En este ámbito, los métodos multirresolución permiten extraer diferentes características de frecuencia de los objetos, lo que posibilita que los modelos capturen simultáneamente detalles gruesos y finos.
Estos métodos procesan las imágenes de entrada a múltiples escalas, lo que mejora la capacidad del modelo para aprender características de alto nivel, como la ubicación de objetos dentro de un contexto más amplio (por ejemplo, el cerebro en imágenes médicas), sin dejar de preservar las estructuras locales detalladas. Este enfoque ofrece varias ventajas, entre ellas una mejor representación de las características, mayor robustez frente al ruido y una mejor generalización en diversos patrones de imagen.

Partiendo de estos éxitos en el análisis de imágenes, las técnicas multirresolución también se han aplicado a datos de series temporales [19], [20], [21], [22]. Tradicionalmente, la descomposición wavelet se ha utilizado para el análisis multirresolución en series temporales [23]. Permite la descomposición de una señal en diferentes componentes de frecuencia, lo que posibilita que los modelos capturen dependencias temporales tanto a corto como a largo plazo, fundamentales para tareas que implican patrones temporales complejos.

En los últimos años, varios modelos avanzados, como TimesNet [19], Pyraformer [21], Scaleformer [20] y MTST [24] (Transformador de series temporales de resolución múltiple), han introducido arquitecturas sofisticadas diseñadas para manejar características de resolución múltiple para la previsión de series temporales.
Estos modelos aprovechan el análisis multirresolución para mejorar la precisión de las predicciones al capturar patrones temporales en diferentes granularidades. Por ejemplo, TimesNet transforma datos de series temporales unidimensionales en tensores bidimensionales, lo que permite al modelo capturar y representar mejor la complejidad temporal. Pyraformer modela dependencias temporales de longitudes variables utilizando mecanismos de atención piramidal, mientras que Scaleformer emplea pesos compartidos y un enfoque innovador. Proceso de normalización para refinar las predicciones a múltiples escalas.

Sin embargo, a pesar de estos avances, la mayoría de los estudios previos se han centrado en aplicar técnicas de análisis multirresolución a la previsión de series temporales, en lugar de a la detección de anomalías.
En este estudio, superamos esta brecha aplicando el análisis multirresolución al contexto de la detección de anomalías en redes de tráfico. Nuestro enfoque aprovecha las ventajas de las características multirresolución para detectar anomalías que, de otro modo, podrían pasar desapercibidas para los modelos de resolución única.

III. MÉTODO

A. PLANTEAMIENTO DEL PROBLEMA

Consideramos una red vial π, compuesta por M enlaces, cada uno con un número variable de carriles. El i-ésimo carril del k -ésimo enlace se denota como v_i^k. Nuestro objetivo es detectar anomalías, utilizando los atributos de tráfico de su en el k-ésimo enlace, v^k carriles constituyentes $\{v_i^k \mid i \quad N, i > 0\}$.

El resultado de la detección de anomalías para el enlace v^k en el momento t está determinado por las puntuaciones de anomalías de los v_i^k en t y a carriles v umbral de detección θ como

$$y_t^k = \begin{cases} 0, \text{ si puntuación}_{él} < \theta \\ 1, \text{ de lo contrario,} \end{cases} \quad (1)$$

donde y_t^k representa la etiqueta de anomalía del enlace v y scorek es la puntuación de anomalía de v^k en el instante t, en el tiempo t. La etiqueta y_t^k es 0 si las puntuaciones de anomalía para todos los carriles en el enlace v k; de lo contrario, la etiqueta es 1, lo que indica que el enlace v en el tiempo t. están por debajo de θ; es anómalo

Las observaciones históricas de los atributos del tráfico en el momento t son: denotado como $x_{t-T+1:t} \quad R^{T\times N\times C}$, donde N es el número total de carriles en la red vial π, C es el número de atributos de tráfico y T es la duración del segmento de tiempo. La puntuación de anomalía, scorek, se obtiene utilizando el segmento de tiempo histórico $x_{t-T+1:t}$ como entrada al modelo de detección de anomalías f , y una función de puntuación g como se muestra como scorek $_{i,t} = g(i, k, f(x_{t-T+1:t}))$.

(2)

En este artículo, el modelo de detección de anomalías f es un modelo basado en reconstrucción. Por lo tanto, la función de puntuación g debe ser capaz de medir las discrepancias entre la entrada original $x_{t-T+1:t}$ y la salida reconstruida $\hat{x}_{t-T+1:t}$. Se pueden emplear diversas funciones para g, como el error cuadrático medio (RMSE), el error absoluto medio (MAE), el error porcentual absoluto medio (MAPE) o la pérdida de Huber.

Si se utiliza RMSE como función de puntuación g, la puntuación de anomalía scorek se calcula como $_{i,t}$

$$g(i, k, f(x_{t-T+1:t})) = \sqrt{\frac{1}{do}\sum_{j=1}^{do} k\, x_{i,j,t-T+1:t} - \hat{x}_{i,j,t-T+1:t}^{\,k}\,{}^{2}}, \quad (3)$$

donde $x^k_{i,j,t-T+1:t}$ representa los valores del atributo j del carril i del enlace k desde el tiempo tT + 1 hasta t. Para

Machine Translated by Google

Para mayor claridad, todas las notaciones utilizadas en este estudio se resumen en la Tabla 1.

B. TRANSFORMADOR DE GRÁFICOS DE RESOLUCIÓN MÚLTIPLE

La arquitectura de GMRT se inspira en MTST, que utilizaba características temporales de multirresolución para pronosticar series temporales a largo plazo. GMRT, en primer lugar, transforma los atributos de tráfico de entrada en datos estructurados en grafos para capturar las relaciones espaciales entre los enlaces de tráfico. Además, para incorporar patrones de tráfico cíclicos, se añade información temporal mediante un proceso de codificación temporal.

En segundo lugar, los datos estructurados en grafos pasan por L capas, cada una con múltiples ramas para extraer características temporales de múltiples resoluciones. Dentro de cada capa, los datos de entrada se tokenizan en varios parches, que se procesan mediante un codificador Transformer con mecanismos de autoatención de múltiples cabezas. Finalmente, las salidas de cada rama se aplanan, concatenan y fusionan mediante una capa de proyección lineal.

TABLA 1. Resumen de notaciones.

Symbol	Description
π	Traffic network
v_i^k	The i-th lane of the k-th link
y_t^k	The anomaly label of the k-th link at time t
N	The total number of lanes
M	The total number of links
C	The number of traffic attributes
T	Length of look-back window
$x_{i,j,t-T+1:t}^k$	The j-th traffic attribute values of the i-th lane of the k-th link from time t-T+1 to t
A	Adjacency matrix
$e_{p\to q}$	Indicator of whether link v^p has a road leading to link v^q
$\tilde{x}_{t-T+1:t}$	Graph-structured traffic attributes at time t
p_b	Patch size of branch b
s_b	Stride size of branch b
$\boldsymbol{Y}^l$	Output of the (l-1)-th layer in GMRT
$\boldsymbol{y}^l_{1+r\times s_b:p_b+r\times s_b}$	The r-th patch in $\boldsymbol{Y}^l$, which has p_b length and s_b stride size

1) REPRESENTACIÓN GRÁFICA DE LA RED DE TRÁFICO Para capturar las relaciones espaciales entre diferentes enlaces, los datos de entrada sin procesar se transforman en una estructura gráfica utilizando una matriz de adyacencia A. La matriz de adyacencia N×N A R se construye en función de la conectividad vial. Si el valor del elemento del enlace A, Apq es 1;

p tiene un camino para conectar v q v ,

de lo contrario 0 como

$$A_{pq} = \begin{cases} 1, & \text{si } p = q \text{ y } e_{p\to q} = \text{Verdadero} \\ 0, & \text{en caso contrario.} \end{cases} \quad (4)$$

Luego, cada atributo de entrada sin procesar en cada paso de tiempo, xt ′ R N×C, se multiplica por la matriz de adyacencia A. Los valores resultantes se concatenan a lo largo de la dimensión de tiempo T como

$$\tilde{x}_{t-T+1:t} = [A \cdot x_{t-T+1} \quad A \cdot x_{t-T+2} \quad \ldots \quad A \cdot x_t], \quad (5)$$

donde x˜t−T+1:t representa los atributos de tráfico estructurados en grafo en el tiempo t, y denota la operación de concatenación.

2) CODIFICACIÓN DE TIEMPO

La información de tiempo es crucial para capturar la dinámica del tráfico y las dependencias a lo largo del tiempo, particularmente debido a la naturaleza cíclica de los patrones de tráfico influenciados por factores como las horas pico. Por lo tanto, en este documento, el día de 24 horas se divide en cinco intervalos: madrugada (00:00 08:00), hora pico de la mañana (08:00 10:00), tarde (10:00 18:00), hora pico de la tarde (18:00 20:00) y noche (20:00 24:00). Cada intervalo de tiempo se codifica utilizando codificación one-hot, lo que resulta en atributos binarios (0 o 1). Luego se concatenan con los atributos de tráfico estructurados en grafo x˜t−T+1:t .

3) APRENDIZAJE DE RESOLUCIÓN MÚLTIPLE

Estudios previos que utilizaron la arquitectura Transformer para el análisis de series temporales trataron cada marca de tiempo como un token (tokenización punto por punto) para la entrada del transformador [25], [26]. Sin embargo, estudios recientes han demostrado que la tokenización punto por punto dificulta la extracción de información semántica local utilizando un único punto de tiempo [27]. En cambio, la agregación de varias marcas de tiempo en parches facilita al modelo el aprendizaje de representaciones semánticas locales (tokenización basada en parches) [28].

La tokenización basada en parches se aplica a cada atributo (canal) de los datos. Esto significa que los tokens de entrada contienen información de un solo atributo, sin mezcla de canales. Los parches tienen diferentes tamaños, lo que crea múltiples ramas para el aprendizaje multirresolución. Los parches más grandes generan mapas de características temporales más generales, capaces de detectar patrones de tráfico cíclicos prolongados en un amplio rango temporal, mientras que los parches más pequeños capturan características temporales más finas, adecuadas para identificar eventos instantáneos en intervalos de tiempo más cortos.

Además, se realiza una tokenización por parches en cada capa del modelo para mejorar el aprendizaje de características multirresolución complejas. Al dividir y combinar repetidamente la entrada en múltiples capas, el modelo captura eficazmente una amplia gama de características temporales en diversas resoluciones.
Al refinar continuamente las representaciones de características en cada capa, el modelo mejora su capacidad para detectar anomalías tanto a largo como a corto plazo, abordando las complejidades inherentes a los entornos mixtos de vehículos autónomos y conducidos por humanos. Este enfoque multicapa basado en parches permite al Transformer gestionar con destreza patrones de tráfico complejos y dinámicos.

El proceso de tokenización basado en parches se formula de la siguiente manera. Aquí, la notación en el atributo se ignora para simplificar la fórmula. La salida de la capa (l − 1)-ésima Y T×N R l−1 Y l−1

se proporciona como entrada de la capa l, y en la capa l, se divide en parches de diferente longitud en ramas B como

$$Y_b^{l-1} = y_{1:pb}^{l-1}, y_{1+sb:pb+sb}^{l-1}, y_{1+2sb:pb+2sb}^{l-1}, \ldots y_{dl-1-pb:dl-1}^{l-1}, \quad (6)$$

Machine Translated by Google

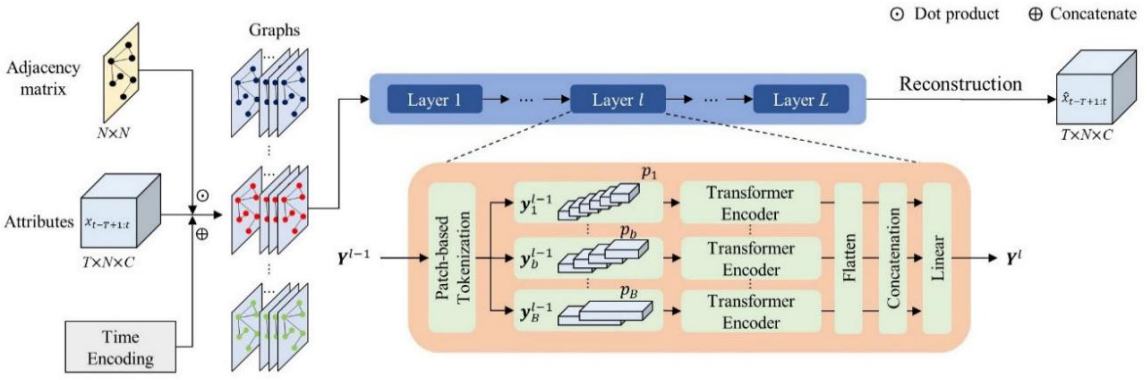


FIGURA 1. Arquitectura del transformador de multirresolución de grafos (GMRT).

donde pb es el tamaño del parche de la rama b, y sb es el tamaño del paso de la rama b.

4) CODIFICADOR TRANSFORMER

El codificador Transformer captura dependencias temporales complejas e interacciones dentro de los datos de tráfico. Utilizando los parches tokenizados generados en cada rama, el codificador Transformer emplea un mecanismo de autoatención para modelar eficazmente las dependencias a corto y largo plazo.

En el codificador Transformer, se calcula el mecanismo de autoatención multi-cabeza que permite al modelo ponderar la importancia de diferentes tokens en relación unos con otros. La puntuación de atención entre el token r y el token s en la rama b, αrs, se calcula como

$$\alpha_{rs} = \text{softmax}\left(\frac{Qb_r \, Kb_s^T}{\sqrt{dk}}\right)$$

$$Q_r^b = WQ \cdot y_{1+r\times sb:pb+r\times sb}^{l-1} + bQ$$

$$K_s^b = WK \cdot y_{1+s\times sb:pb+s\times sb}^{l-1} + bK, \quad (7)$$

donde WQ y WK son las matrices de pesos entrenables para consultas y claves, respectivamente, y bQ y bK son los términos de sesgo. dk representa la dimensionalidad de las consultas y las claves.

Luego, la salida del mecanismo de autoatención para el r-ésimo token en la rama b, $\bar{y}$ se calcula como $1+r\times sb:pb+r\times sb$,

$$\bar{y}_{1+r\times sb:pb+r\times sb}^{l-1} = \alpha_{rs} V \, y_{1+s\times sb:pb+s\times sb}^{l-1} + bV, \quad (8)$$

donde WV es la matriz de pesos entrenable para los valores, y bV es el término de sesgo.

Siguiendo el mecanismo de autoatención, se aplican conexiones residuales, normalización y redes de alimentación directa como el codificador Transformer original. Finalmente, las salidas finales de cada rama se aplanan, concatenan y fusionan utilizando una capa lineal como

$$Y^l = W^{l-1} \circ \left[o_1^{l-1} \; \ldots \; o_2^{l-1} \; \ldots \; o_B^{l-1}\right] + b^{l-1} \quad (9)$$

donde Y^{l-1} es la salida de la l-ésima capa, $W^{l-1} \in \mathbb{R}^{B\times dl-1} \in \mathbb{R}^{1\times dl-1}$ y b^{l-1} para son las matrices de peso y sesgo representa los valores proyección lineal en la capa (l−1), y o codificador.

de salida del transformador

C. FUNCIÓN DE PÉRDIDA Y PUNTUACIÓN DE ANOMALÍA

Nuestro modelo adopta un enfoque basado en la reconstrucción para la detección de anomalías. En consecuencia, la función de pérdida durante el entrenamiento tiene como objetivo minimizar la discrepancia entre la entrada original $x_{i,j,t-T+1:t}$ y la salida reconstruida $\hat{x}_{i,j,t-T+1:t}$. Empleamos el MSE como función de pérdida como

Pérdida

$$= \frac{1}{NCM} \sum_{i=1}^{N} \sum_{j=1}^{D} \sum_{k=1}^{M} \left(x_{i,j,t-T+1:t,k} - \hat{x}_{i,j,t-T+1:t,k}\right)^2. \quad (10)$$

El modelo se entrena mediante un enfoque de aprendizaje no supervisado, que utiliza únicamente datos normales para el entrenamiento y la validación. Tras el entrenamiento, se utilizan datos de prueba que incluyen anomalías para evaluar el rendimiento de detección del modelo.

IV. EXPERIMENTOS A. DATOS

El conjunto de datos utilizado en este estudio se construyó con VISSIM, un software de simulación de tráfico microscópico, debido a las dificultades inherentes a la adquisición de datos de anomalías de tráfico etiquetados a gran escala en entornos reales. La simulación reproduce entornos de tráfico donde coexisten vehículos autónomos y convencionales dentro de la zona de demostración de conducción autónoma en Pangyo, Corea del Sur. El entorno de simulación considera meticulosamente las condiciones físicas reales, incluyendo el número de carriles, el ancho de los carriles, los grados de pendiente y los sistemas de fases de los semáforos.

La Fig. 2 muestra la red de tráfico construida. Tiene 13 intersecciones, 66 enlaces y 256 carriles. El número de vehículos y sus direcciones de conducción se basan en registros de tráfico reales de la red. Durante un período de 24 horas,

Machine Translated by Google

La proporción de vehículos convencionales a vehículos autónomos se mantiene en 7:3, y los vehículos autónomos se configuran para operar con un nivel 4 de autonomía (automatización completa) [29] ajustando los parámetros del modelo Wiedemann 99 dentro de VISSIM. Las limitaciones de velocidad de los vehículos se establecen en 50 km/h en carreteras normales y 30 km/h en callejones.



FIGURA 2. La red de tráfico real (a) y la red de simulación (b) de Pangyo, Corea del Sur.

La simulación abarca 14 días, divididos en 7 días sin anomalías y 7 días con anomalías. Los primeros 7 días sin anomalías representan las condiciones normales de tráfico, mientras que los 7 días restantes con anomalías se utilizan para evaluar el modelo de detección. Las anomalías de tráfico se simulan bloqueando carriles mediante la creación de estacionamientos o reduciendo la velocidad de los vehículos.

En 2023, las anomalías de tráfico en Gyeonggi-do, Corea del Sur, consistieron principalmente en colisiones de automóviles (57%), averías de vehículos (32%), caída de objetos en las carreteras (6%) y actividades de mantenimiento vial (3%) [30]. Estos incidentes suelen causar una congestión de tráfico significativa. Para simular de forma realista estas condiciones basándonos en estas estadísticas, diseñamos tres tipos de anomalías de tráfico que implican bloqueos de carriles (AN1, AN2 y AN3), cada uno de los cuales representa distintos niveles de interrupción del tráfico. Además, se simulan condiciones meteorológicas adversas reduciendo la velocidad de los vehículos para reflejar las ralentizaciones inducidas por el clima (AN4).

Para representar distintos tipos de anomalías, se implementan diferentes niveles de gravedad, tal como se detalla en la Tabla 2. Además, las anomalías ocurren en diferentes momentos y tienen duraciones variables (5, 10, 15, 20 y 60 minutos). Las anomalías se generan en 15 enlaces seleccionados aleatoriamente. Las anomalías generadas durante 7 días se describen en la Tabla 3.

Cada 5 minutos se recopilan cinco atributos de tráfico para cada carril: el número total de vehículos que pasan, la velocidad media armónica de todos los vehículos, la velocidad media aritmética de todos los vehículos, el tiempo total de retraso de todos los vehículos y la tasa de ocupación. Los atributos de tráfico utilizados se detallan en la Tabla 4.

B. MONTAJE EXPERIMENTAL

El conjunto de datos se divide en tres partes: 5 días para entrenamiento (día 1 – día 5), 2 días para validación (día 6 – día 7) y

TABLA 2. Anomalías de tráfico generadas.

Anomaly event	Simulation method	Examples in real world
AN1	Blocking 10% of a lane	minor collision, car breakdown, small/single fallen object
AN2	Blocking 20% of two lanes	serious collision, large/multiple fallen object(s)
AN3	Blocking 10% of the last right lane	road maintenance
AN4	Reducing vehicle speed by 20%	bad weather conditions

Se dedican 7 días a las pruebas (del día 8 al día 14). Los datos de validación se utilizan para calcular la pérdida de validación en cada época, y el entrenamiento se detiene prematuramente si la pérdida de validación no disminuye durante varias épocas consecutivas para evitar el sobreajuste. Los datos de prueba son concurrentes con los de validación, lo que garantiza condiciones ambientales consistentes entre las fases de entrenamiento y prueba. Además, el umbral de detección de anomalías θ se establece en función de la puntuación máxima de anomalía observada en el conjunto de validación.

Los hiperparámetros óptimos del modelo GMRT se buscan mediante un método de búsqueda en cuadrícula con los siguientes parámetros: número de capas = {1, 2, 3}, número de cabezas de atención = {4, 8, 16, 32}, número de parches = {6, 12, 36, 144, 216}. El tamaño del paso se establece en la mitad del tamaño del parche correspondiente. Tanto la dimensión del modelo como la dimensión de la capa totalmente conectada se fijan en 128. Se aplica una tasa de abandono de 0,1, y la tasa de aprendizaje se inicializa en 0,001 y se ajusta mediante un mecanismo de programación basado en meseta, que reduce la tasa de aprendizaje si no se observa ninguna mejora en el rendimiento de validación.

C. EVALUACIÓN

El rendimiento del modelo GMRT propuesto se evalúa comparándolo con varios modelos de referencia: LSTM, GRU, Transformer, Informer y Autoformer. LSTM y GRU son modelos consolidados para datos de series temporales, mientras que Transformer, Informer y Autoformer son arquitecturas avanzadas diseñadas para manejar dependencias de series temporales extensas.

El rendimiento del modelo se calcula mediante el evento anómalo, sin utilizar los puntos temporales, ya que no tiene sentido medir el rendimiento en un punto temporal específico.

Como métrica de rendimiento, utilizamos la exhaustividad, que mide la proporción de anomalías reales que son identificadas correctamente por el modelo.

$$\text{Recordatorio} = \frac{\text{Verdadero positivo}}{\text{Verdadero positivo} + \text{Falso positivo}}. \quad (11)$$

Debido a la naturaleza interconectada de las redes de tráfico, donde las anomalías en un enlace pueden propagarse e influir en otros enlaces, la recuperación se ha adoptado ampliamente como la principal

Machine Translated by Google

TABLA 3. Eventos anómalos generados en diferentes días y franjas horarias.

Link #	Day 8	Day 9	Day 10	Day 11	Day 12	Day 13	Day 14
1		AN2 (10:00-10:20)	AN4 (06:00-07:00)		AN1 (13:00-13:35)		
2			AN4 (06:00-07:00)				
3			AN4 (06:00-07:00)	AN1 (20:30-20:40)		AN3 (14:00-14:20)	
4			AN4 (06:00-07:00)				AN3 (15:30-15:40)
5	AN3 (09:00-09:05)		AN4 (06:00-07:00)		AN1 (09:30-09:40)		
6		AN3 (18:30-19:00)	AN4 (06:00-07:00)				
7			AN4 (06:00-07:00)	AN1 (15:30-15:55)			
8			AN4 (06:00-07:00)			AN2 (17:00-17:15)	
9			AN4 (06:00-07:00)	AN2 (07:00-07:30)			
10	AN1 (14:00-14:30)		AN4 (06:00-07:00)				
11			AN4 (06:00-07:00)		AN3 (21:00-21:15)		AN1 (06:00-06:20)
12		AN1 (22:00-22:20)	AN4 (06:00-07:00)				
13			AN4 (06:00-07:00)				AN2 (16:00-16:20)
14	AN1 (18:00-18:15)		AN4 (06:00-07:00)				
15			AN4 (06:00-07:00)			AN1 (12:00-12:30)	

TABLA 4. Atributos del tráfico.

Attributes	Unit	Range
The total number of passing vehicles	-	[0, ∞]
Harmonic/arithmetic mean of the speed of all vehicles	km/h	[0, ∞]
Total delay time of all vehicles	second	[0, ∞]
Occupancy rate	%	[0, 100]

Métrica de rendimiento en la evaluación de modelos de detección de anomalías de tráfico en estudios previos. Cabe destacar que no se informa la precisión, ya que la complejidad de las redes de tráfico puede generar anomalías no identificadas, y las anomalías en enlaces vecinos aumentan la puntuación de anomalía del enlace analizado.

Para evaluar la capacidad del modelo en la detección temprana de anomalías, se mide su rendimiento en diferentes horizontes de detección: a tiempo, +30 minutos, +60 minutos, +90 minutos y +120 minutos. La detección "a tiempo" se refiere a la identificación inmediata de anomalías en el momento en que ocurren, mientras que "+n minutos" indica que las anomalías se detectan dentro de los n minutos posteriores al evento.

V. RESULTADOS

El rendimiento de detección se presenta como la puntuación media de recuperación junto con la desviación estándar de los resultados de los enlaces probados, como se muestra en la Tabla 5.

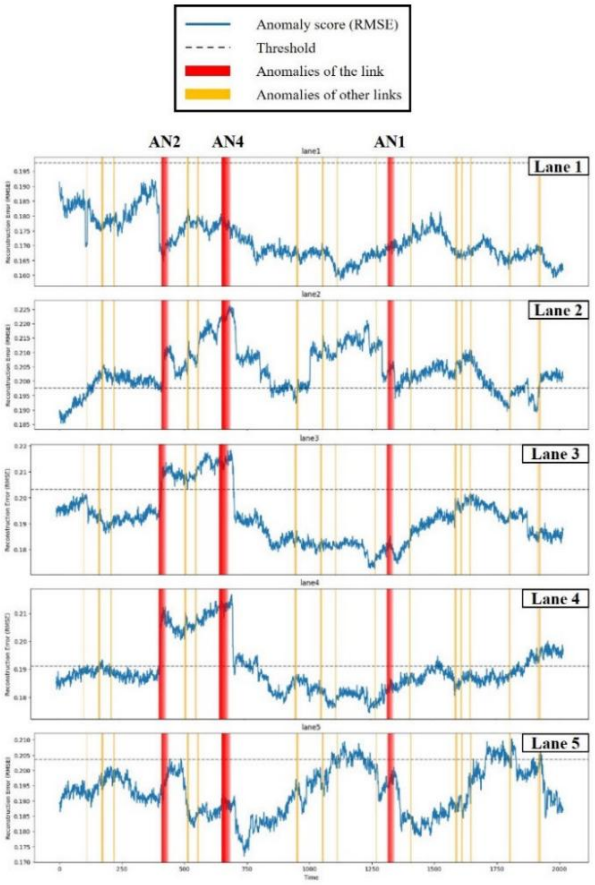


FIGURA 3. Puntuaciones de anomalías en todos los carriles del enlace 1.

A. DETECCIÓN DE ANOMALÍAS DE TRÁFICO

El modelo GMRT supera consistentemente a todos los modelos de referencia en diferentes valores de T (36, 72, 144, 288), lo que demuestra su robustez y eficacia en la detección de anomalías de tráfico. En T = 36, GMRT alcanza una recuperación promedio de 0,5293, superando a LSTM (0,4488), GRU (0,4488), Transformer (0,4773), Informer (0,5000) y Autoformer (0,4911). En T = 72, GMRT registra una recuperación promedio de 0,6369, superando a LSTM (0,4555), GRU (0,5666), Transformer (0,4355), Informer (0,5488) y Autoformer (0,6488). En T = 144, GMRT alcanza una recuperación promedio de 0,7089, superando a LSTM (0,4533), GRU (0,5911), Transformer (0,5622), Informer (0,5666) y Autoformer (0,7011). En T = 288, GMRT logra la recuperación promedio más alta de 0,7755, superando a LSTM (0,6651), GRU (0,6844), Transformer (0,6775), Informer (0,6826) y Autoformer (0,7222).

En todos los valores de T , GMRT mantiene puntuaciones de recuperación superiores en comparación con los modelos de referencia, lo que subraya su eficacia para detectar con precisión anomalías en el tráfico. La integración del análisis temporal multirresolución y el modelado espacial basado en grafos en GMRT le permite capturar patrones de tráfico complejos y dinámicos con mayor eficacia que los modelos que se basan únicamente en características temporales o espaciales.

Machine Translated by Google

TABLA 5. Resultados de la detección de anomalías en el tráfico rodado (sensibilidad).

Models	T	On time	+30 min.	+60 min.	+90 min.	+120 min.	Avg.
LSTM	36	0.4222±0.3861	0.4444±0.3244	0.4444±0.3288	0.4667±0.3408	0.4667±0.3285	0.4488±0.3417
	72	0.3889±0.3792	0.4556±0.3582	0.4556±0.3366	0.4889±0.3280	0.4889±0.3203	0.4555±0.3444
	144	0.3667±0.3821	0.4333±0.3288	0.4889±0.3283	0.4889±0.3208	0.4889±0.3128	0.4533±0.3345
	288	0.6478±0.3191	0.6444±0.3203	0.6778±0.3191	0.6778±0.3191	0.6778±0.3191	0.6651±0.3193
GRU	36	0.4889±0.4582	0.4444±0.3401	0.4444±0.3305	0.4333±0.3271	0.4333±0.2400	0.4488±0.3391
	72	0.5222±0.3950	0.5444±0.3291	0.5667±0.3282	0.6000±0.3309	0.6000±0.2864	0.5666±0.3339
	144	0.5556±0.4180	0.6000±0.3382	0.6000±0.3194	0.6000±0.3288	0.6000±0.2803	0.5911±0.3369
	288	0.6444±0.4027	0.6444±0.3325	0.7000±0.3285	0.7000±0.3285	0.7333±0.2731	0.6844±0.3330
Transformer	36	0.4589±0.3604	**0.4778**±0.3406	0.4778±0.3604	0.4778±0.2638	0.4944±0.2509	0.4773±0.3152
	72	0.4444±0.3325	0.4333±0.3280	0.4333±0.3155	0.4333±0.2513	0.4333±0.2604	0.4355±0.2975
	144	0.5111±0.3408	0.5444±0.3155	0.5444±0.3208	0.5889±0.2812	0.6222±0.2400	0.5622±0.2996
	288	0.6589±0.3325	0.6778±0.3115	0.6733±0.3261	0.6889±0.2395	0.6889±0.2395	0.6775±0.2898
Informer	36	0.4556±0.4680	0.4556±0.4387	0.4889±0.4400	0.5111±0.4601	**0.5889**±0.4283	0.5000±0.4470
	72	0.4889±0.4561	0.5444±0.4222	0.5444±0.4381	0.5333±0.4282	0.6333±0.4190	0.5488±0.4327
	144	0.5222±0.4428	0.5444±0.4209	0.5667±0.4366	0.6000±0.4355	0.6000±0.4157	0.5666±0.4303
	288	0.6222±0.4448	0.6689±0.4247	0.6889±0.4247	0.6889±0.4247	0.7444±0.4247	0.6826±0.4287
Autoformer	36	0.4667±0.3869	0.4333±0.3642	0.5000±0.3762	0.5000±0.3612	0.5556±0.3680	0.4911±0.3713
	72	0.5444±0.3702	0.5889±0.3608	**0.6222**±0.3844	**0.7444**±0.3802	**0.7444**±0.3678	**0.6488**±0.3726
	144	0.6000±0.3811	0.6667±0.3488	**0.6833**±0.3875	0.7667±0.3744	0.7889±0.3608	0.7011±0.3705
	288	0.6778±0.4027	**0.7222**±0.3644	0.7222±0.3644	0.7444±0.3556	0.7444±0.3203	0.7222±0.3614
GMRT	36	**0.4912**±0.3642	0.4667±0.3522	**0.5333**±0.3892	**0.5667**±0.2904	**0.5889**±0.3283	**0.5293**±0.3448
	72	**0.5889**±0.3682	**0.5956**±0.3438	0.6111±0.3011	0.6667±0.2755	0.7222±0.3366	0.6369±0.3250
	144	**0.6222**±0.3544	**0.6689**±0.3422	0.6756±0.3072	**0.7778**±0.2945	**0.8000**±0.3059	**0.7089**±0.3208
	288	**0.7111**±0.3477	**0.7222**±0.3128	**0.7778**±0.2931	**0.8333**±0.2591	**0.8333**±0.2597	**0.7755**±0.2944

Además, el rendimiento de recuperación de GMRT mejora de forma constante a medida que T aumenta, lo que indica su capacidad para aprovechar eficazmente las dependencias temporales más largas para una mejor detección de anomalías. Si bien los modelos de referencia como LSTM y GRU muestran un rendimiento moderado en valores de T más bajos , sus puntuaciones de recuperación no escalan tan eficazmente con el aumento de T como GMRT. Los modelos basados en Transformer exhiben un rendimiento fluctuante, con Autoformer acercándose al rendimiento de GMRT en valores de T más altos , pero aún ligeramente por detrás.

En general, los resultados experimentales destacan la eficacia del modelo GMRT propuesto para lograr una mayor precisión de detección, especialmente en la detección temprana de anomalías.
La incorporación de entradas con estructura de grafo y el aprendizaje multirresolución permiten que el modelo GMRT capture dinámicas de tráfico complejas e interconectadas, lo que lo hace más robusto y fiable para tareas de detección de anomalías de tráfico en el mundo real.

B. ESTUDIO DE CASO

Para ilustrar mejor la eficacia del modelo GMRT en la detección de anomalías en el tráfico, presentamos un estudio de caso detallado que se muestra en la Figura 3. Esta figura muestra las puntuaciones de anomalías en los cinco carriles del enlace 1 en los datos de prueba.

En cada subgráfico, la línea azul representa la puntuación de anomalía para cada carril, mientras que la línea discontinua indica el umbral de detección de anomalías. Las barras verticales rojas resaltan la generada Las anomalías se muestran en los carriles correspondientes, mientras que las barras amarillas indican anomalías en otros enlaces de la red.

La figura muestra que las puntuaciones de anomalía superan el umbral, correspondientes a eventos de tráfico específicos. Por ejemplo, en el primer evento de anomalía (AN2), se generó un bloqueo de carril tanto en el carril 2 como en el carril 3. Se observan puntuaciones de anomalía que superan el umbral en los carriles 2 y 3. Además, en el carril 4, la puntuación de anomalía también supera el umbral. Este resultado demuestra que un evento de anomalía en un carril puede afectar el flujo de tráfico en los carriles adyacentes, lo que lleva a puntuaciones de anomalía elevadas en los carriles conectados. Este hallazgo enfatiza la naturaleza interconectada de la dinámica del tráfico, donde las anomalías en un carril pueden influir en el tráfico

Se analizan los patrones en los carriles adyacentes y se destaca la importancia de considerar las relaciones espaciales al detectar anomalías en el tráfico.

En el segundo evento anómalo (AN4), el evento anómalo generado fue una reducción en la velocidad de los vehículos en todos los enlaces.
Como era de esperar, los índices de anomalías en los carriles 2, 3 y 4 son muy altos y superan el umbral. Por el contrario, el carril 1 está destinado a los vehículos que giran a la izquierda, donde la densidad del tráfico suele ser menor. Por ello, los índices de anomalías se mantienen por debajo del umbral.

En el tercer evento anómalo (AN1), se produjo un bloqueo en el carril 2 durante la simulación. Como era de esperar, la puntuación de anomalía para el carril 2 superó el umbral, detectando con éxito la interrupción del tráfico en dicho carril.

Machine Translated by Google

Este estudio de caso demuestra que el modelo GMRT detecta eficazmente las anomalías del tráfico mediante el uso de información espacial y temporal. El aumento de la puntuación de anomalías en los puntos clave, y la propagación de estas anomalías a través de los carriles subraya la capacidad del modelo para capturar las dependencias espaciales inherentes a las redes viales.

VI. CONCLUSIÓN

Este artículo presenta un novedoso modelo de Transformador Multirresolución de Grafos (GMRT) diseñado para detectar anomalías en el tráfico rodado en entornos mixtos donde coexisten vehículos autónomos y conducidos por humanos. El modelo GMRT propuesto demuestra un rendimiento significativamente superior al de los métodos existentes, gracias al aprovechamiento de características temporales multirresolución y relaciones espaciales basadas en grafos. Mediante experimentos exhaustivos con datos simulados de la zona de demostración de conducción autónoma en Corea del Sur, el modelo GMRT superó sistemáticamente a los modelos tradicionales de series temporales, como LSTM, GRU, Transformer, Informer y Autoformer, en diversos horizontes de detección.

Las principales ventajas del modelo GMRT incluyen su capacidad para detectar anomalías de tráfico a nivel micro (específicas de cada carril) y su robustez en la detección temprana de anomalías, lo cual es fundamental para gestionar redes de tráfico urbano cada vez más complejas. El rendimiento del modelo mejora con dependencias temporales más largas, lo que pone de manifiesto su escalabilidad y eficacia en escenarios de tráfico reales que involucran vehículos autónomos.

En general, el modelo GMRT se presenta como una solución prometedora para la próxima generación de sistemas de transporte inteligentes, especialmente ante el creciente uso de vehículos autónomos. En trabajos futuros se podría ampliar la aplicación del modelo a datos de tráfico reales y explorar su rendimiento en diferentes contextos urbanos.

REFERENCIAS

[1] Y. Li, T. Guo, R. Xia y W. Xie, "Detección de anomalías en el tráfico rodado basada en la teoría difusa", IEEE Access, vol. 6, pp. 40281–40288, 2018, doi: 10.1109/ACCESS.2018.2851747.

[2] M. Riveiro, M. Lebram y M. Elmer, "Detección de anomalías para el tráfico rodado: un marco de análisis visual", IEEE Trans. Intell. Transp. Syst., vol. 18, n.º 8, págs. 2260–2270, agosto de 2017, doi: 10.1109/TITS.2017.2675710.

[3] Y. Djenouri, A. Belhadi, JC Lin, D. Djenouri y A. Cano, "Un estudio sobre algoritmos de detección de anomalías en el tráfico urbano", IEEE Access, vol. 7, pp. 12192–12205, 2019, doi: 10.1109/ACCESS.2019.2893124.

[4] KK Santhosh, DP Dogra y PP Roy, "Detección de anomalías en el tráfico rodado mediante vigilancia visual: una revisión", ACM Comput. Surveys, vol. 53, n.º 6, págs. 1–26, noviembre de 2021.

[5] MA Richter, M. Hagenmaier, O. Bandte, V. Parida y J. Wincent, "Ciudades inteligentes, movilidad urbana y vehículos autónomos: cómo las diferentes ciudades necesitan diferentes estrategias de inversión sostenible", Technolog. Pronóstico del cambio social, vol. 184, noviembre de 2022, art. n.º 121857, doi: 10.1016/j.techfore.2022.121857.

[6] C. Liu, J. Chen, H. Liu, S. Li y S. He, "Hacia una detección eficiente de incidentes de tráfico mediante modelado explícito de incidentes a nivel de borde", IEEE Internet Things J., vol. 11, n.º 11, págs. 20015–20029, junio de 2024, doi: 10.1109/jiot.2024.3371482.

[7] Y. Sun, Y.-C. Lu, K. Fu, F. Chen y C.-T. Lu, "Detección de comportamientos de tráfico anómalos con redes neuronales convolucionales gráficas de filtro de Kalman profundo estacional", J. King Saud Univ. Comput. Inf. Sci., vol. 34, n.º 8, págs. 4729–4742, septiembre de 2022, doi: 10.1016/j.jksuci.2022.05.017.

[8] Z. Ren, X. Li, J. Peng, K. Chen, Q. Tan, X. Wu y C. Shi, "Autoencoder gráfico con redes convolucionales temporales espejo para la detección de anomalías de tráfico", Sci. Rep., vol. 14, n.º 1, enero de 2024, art. n.º 1247, doi: 10.1038/s41598-024-51374-3.

[9] A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, AN Gomez, Ł. Kaiser y I. Polosukhin, Proc. Adv. Sistemas de Procesamiento de Información Neuronal, vol. 30, Long Beach, CA, EE. UU., junio de 2017, págs. 5998–6008.

[10] S. Lee, S. Baek, W.-H. Woo, C. Ahn y J. Yoon, "Intersección inteligente basada en IA de borde y su aplicación para la coordinación de semáforos: un estudio de caso en la ciudad de Pyeongtaek, Corea del Sur", J. Adv. Transp., vol. 2024, n.º 1, enero de 2024, art. n.º 8999086, doi: 10.1155/2024/8999086.

[11] V. Katariya, AD Pazho, GA Noghre y H. Tabkhi, "Veg-aEdge: Confluencia de IA de borde para aplicaciones de IoT en tiempo real en seguridad vial", Internet Things, vol. 27, junio de 2024, art. n.° 101268, doi: 10.1016/j.iot.2024.101268.

[12] S. Chawla, Y. Zheng y J. Hu, "Inferir la causa raíz en anomalías del tráfico rodado", en Proc. IEEE 12th Int. Conf. Data Mining, Bruselas, Bélgica, diciembre de 2012, pp. 141–150, doi: 10.1109/ICDM.2012.104.

[13] N. Dogru y A. Subasi, "Detección de accidentes de tráfico mediante clasificador de bosque aleatorio", en Actas de la 15.ª Conferencia de Tecnología de Aprendizaje (L&T), Jeddah, Arabia Saudita, febrero de 2018, págs. 40–45.

[14] Y. Djenouri, A. Belhadi, JC Lin y A. Cano, "Vecinos K más cercanos adaptados para detectar anomalías en el flujo de tráfico espacio-temporal", IEEE Access, vol. 7, pp. 10015–10027, 2019, doi: 10.1109/ACCESS.2019. 2891933.

[15] Y. Hu, A. Qu y D. Work, "Detección de eventos de tráfico extremos mediante un autoencoder gráfico con contexto aumentado", ACM Trans. Intell. Syst. Technol., vol. 13, n.º 6, págs. 1–23, septiembre de 2022, doi: 10.1145/3539735.

[16] J. Hu, Z. Chen, M. Yang, R. Zhang y Y. Cui, "Una red neuronal convolucional de fusión multiescala para el reconocimiento de hojas de plantas", IEEE Signal Process. Lett., vol. 25, n.º 6, págs. 853–857, junio de 2018, doi: 10.1109/LSP.2018.2809688.

[17] X. Li, L. Shen, X. Xie, S. Huang, Z. Xie, X. Hong y J. Yu, "Redes neuronales convolucionales de multirresolución para la detección de nódulos pulmonares basada en radiografías de tórax", Artif. Intell. Med., vol. 103, marzo de 2020, art. n.º 101744, doi: 10.1016/j.artmed.2019.101744.

[18] K. Kamnitsas, C. Ledig, VFJ Newcombe, JP Simpson, AD Kane, DK Menon, D. Rueckert y B. Glocker, "Efficient multi-scale 3D CNN con CRF totalmente conectado para una segmentación precisa de lesiones cerebrales", Med. Image Anal., vol. 36, pp. 61–78, febrero de 2017, doi: 10.1016/j.media.2016.10.004.

[19] H. Wu, T. Hu, Y. Liu, H. Zhou, J. Wang y M. Long, "TimesNet: Modelado de variación temporal 2D para análisis general de series temporales", 2022, arXiv:2210.02186.

[20] A. Shabani, A. Abdi, L. Meng y T. Sylvain, "Scaleformer: Transformadores de refinamiento multiescala iterativos para pronósticos de series temporales", 2022, arXiv:2206.04038.

[21] S. Liu, H. Yu, C. Liao, J. Li, W. Lin, AX Liu y S. Dustdar, "Pyraformer: Atención piramidal de baja complejidad para el modelado y pronóstico de series temporales de largo alcance", en Proc. Int. Conf. Learn. Represent., 2022.

[22] Z. Cui, W. Chen y Y. Chen, "Redes neuronales convolucionales multiescala para la clasificación de series temporales", 2016, arXiv:1603.06995.

[23] K. Virupakshappa, M. Marino y E. Oruklu, "Una arquitectura de red neuronal convolucional de multirresolución para la detección de defectos ultrasónicos", en Proc. IEEE Int. Ultrason. Symp. (IUS), octubre de 2018, págs. 1–4.

[24] Y. Zhang, L. Ma, S. Pal, Y. Zhang y M. Coates, "Transformador de series temporales de multirresolución para pronósticos a largo plazo", en Proc. Int. Conf. Artif. Intel. Statist., Valencia, España, enero de 2023, págs. 4222–4230.

[25] H. Wu, J. Xu, J. Wang y M. Long, "Autoformer: Transformadores de descomposición con autocorrelación para pronósticos de series a largo plazo", en Proc. Adv. Neural Inf. Process. Syst., enero de 2021, págs. 22419–22430.

[26] H. Zhou, S. Zhang, J. Peng, S. Zhang, J. Li, H. Xiong y W. Zhang, "Informer: Más allá del transformador eficiente para la predicción de series temporales de secuencia larga", en Proc. AAAI Conf. Artif. Intell., mayo de 2021, vol. 35, n.º 12, págs. 11106–11115.

[27] A. Zeng, M. Chen, L. Zhang y Q. Xu, "¿Son efectivos los transformadores para la predicción de series temporales?" en Proc. AAAI Conf. Artif. Intell., junio de 2023, vol. 37, n.º 9, págs. 11121–11128.

Machine Translated by Google

[28] Y. Nie, NH Nguyen, P. Sinthong y J. Kalagnanam, "Una serie temporal vale 64 palabras: Pronóstico a largo plazo con transformadores", 2022, arXiv:2211.14730.

[29] WS Atkins, "Investigación sobre los impactos de los vehículos conectados y autónomos (VCA) en el flujo de tráfico", en Etapa 2: Informe técnico sobre modelado y análisis de tráfico. Epsom, Reino Unido: Atkins Ltd., mayo de 2016. [En línea]. Disponible en: https://assets.publishing.service.gov.uk/media/5a80f34240f0b62305b8e113/impacts-of-connected-and-autonomous-vehicles-on-traffic-flow-technical-report.pdf [30] (2023). Estadísticas de eventos anómalos en 2023, Centro de Información de Tráfico de Gyeonggi-Do, Corea del Sur. [En línea]. Disponible en: https://gits.gg.go.kr/gtdb/ web/trafficDb/trafficSpeed/suddenSituationStatistics.do



DONGHYUN PARK recibió la licenciatura y la maestría. Obtuvo su licenciatura en ingeniería de sistemas industriales y de gestión y su doctorado en análisis de macrodatos por la Universidad Kyung Hee, en Yongin-si, República de Corea, en 2017, 2019 y 2024, respectivamente.

Actualmente trabaja como investigador sénior en el Instituto Avanzado de Tecnología de Convergencia (AICT), en Suwon-si, República de Corea. Sus intereses de investigación incluyen la ingeniería artificial industrial. inteligencia artificial, aprendizaje automático, redes neuronales gráficas e inteligencia artificial explicable.



SUNG-SOO CHOI recibió la licenciatura y la maestría. Obtuvieron sus títulos en informática e ingeniería por la Universidad Nacional de Chungbuk, Cheongju-si, República de Corea, en 2015 y 2017, respectivamente. Actualmente trabaja como investigador sénior en el Instituto Avanzado de Tecnología de Convergencia en Suwon-si, República de Corea. Sus áreas de investigación incluyen inteligencia artificial, macrodatos, descomposición tensorial y aprendizaje profundo.



Donghyun Lim obtuvo la licenciatura en ingeniería de sistemas de transporte y la maestría en ingeniería de transporte en la Universidad de Ajou. Actualmente trabaja en el Instituto Avanzado de Tecnología de Convergencia.

Durante su estancia en el instituto, ha participado en proyectos de investigación relacionados con la conducción autónoma y el flujo de tráfico. Entre sus publicaciones más destacadas se encuentra «Estimación espaciotemporal de la densidad de tráfico basada en datos de sondas ADAS».



YONG-SHIN KANG (miembro del IEEE) obtuvo la licenciatura y la maestría en ingeniería industrial, así como el doctorado en ingeniería industrial y de sistemas, en la Universidad Dongguk de Seúl, Corea del Sur, en 2003, 2005 y 2011, respectivamente. Actualmente, es director del Laboratorio de Inteligencia Industrial del Instituto Avanzado de Tecnología de Convergencia (AICT) y jefe del Centro de Conducción Autónoma de Gyeonggi. Sus intereses de investigación abarcan una amplia gama de campos, incluyendo la detección de anomalías en sistemas espaciotemporales, la infraestructura de tráfico impulsada por IA, los sistemas de fábricas inteligentes y la imputación de datos de IoT a gran escala. Continúa trabajando en la integración de tecnologías de fábricas inteligentes con sistemas de vehículos autónomos, centrándose en el aprovechamiento de la IA para mejorar la automatización industrial y la movilidad autónoma.