Machine Translated by Google

Aprendiendo sobre anomalías de tráfico a partir de Modelos generativos basados en observaciones en tiempo real

Fotis I. Giasemis*
LIP6, LPNHE
Universidad de la
Sorbona, CNRS,
IN2P3 París,
Francia Fotis.Giasemis@cern.ch

Alexandros Sopasakis
Departamento de Matemáticas
Universidad de
Lund Lund, Escania,
Suecia Alexandros.Sopasakis@math.lth.se

Resumen—La detección precisa de anomalías en el tráfico es crucial para una gestión eficaz del tráfico urbano y la mitigación de la congestión.
Utilizamos el marco de Red Generativa Adversaria Espaciotemporal (STGAN), que combina Redes Neuronales Gráficas y Redes de Memoria a Largo y Corto Plazo (LSTM), para capturar dependencias espaciales y temporales complejas en datos de tráfico. Aplicamos STGAN a observaciones en tiempo real, minuto a minuto, de 42 cámaras de tráfico en Gotemburgo, Suecia, recopiladas durante varios meses de 2020. Las imágenes se procesan para calcular una métrica de flujo que representa la densidad vehicular, la cual sirve como entrada para el modelo.

El entrenamiento se realizó con datos de abril a noviembre de 2020, y la validación se llevó a cabo con un conjunto de datos independiente del 14 al 23 de noviembre de 2020. Nuestros resultados demuestran que el modelo detecta eficazmente anomalías de tráfico con alta precisión y bajas tasas de falsos positivos. Las anomalías detectadas incluyen interrupciones de la señal de las cámaras, artefactos visuales y condiciones climáticas extremas que afectan el flujo de tráfico.

Términos de índice: Redes neuronales gráficas, Redes generativas antagónicas, Modelado espaciotemporal, Detección de anomalías de tráfico, Gestión del tráfico urbano

[cs.LG] 2502.01391v5

I. INTRODUCCIÓN

Los sistemas de gestión del tráfico urbano dependen en gran medida de la detección eficaz de anomalías en el tráfico para prevenir la congestión y reducir los accidentes [1]. La rápida urbanización y la creciente complejidad de las redes de tráfico han hecho que los métodos estadísticos tradicionales [2]–[4] resulten insuficientes para una predicción precisa del tráfico. La naturaleza multidimensional y no lineal de los datos de tráfico exige técnicas de modelado avanzadas capaces de capturar dependencias tanto espaciales como temporales [5]–[7].

Los recientes avances en inteligencia artificial, en particular el aprendizaje profundo, han demostrado ser prometedores para mejorar la precisión de la predicción del tráfico mediante el aprovechamiento de grandes volúmenes de datos y recursos computacionales [8]. Estos métodos incluyen modelos de aprendizaje profundo basados en grafos que manejan eficientemente las correlaciones espacio-temporales y modelos de difusión que transforman la predicción del tráfico en una tarea de generación de imágenes condicionales [9]. Además, se han desarrollado enfoques innovadores que incorporan ingeniería de características sin depender de datos en tiempo real para abordar los desafíos de la predicción del flujo de tráfico urbano [10].

Las redes neuronales gráficas (GNN) han surgido como herramientas poderosas para modelar datos estructurados en grafos, capturando eficazmente dependencias espaciales en redes de tráfico [8], [11]. Mientras tanto, las redes neuronales recurrentes (RNN), como las redes de memoria a largo y corto plazo (LSTM), son reconocidas por su capacidad para modelar patrones temporales [12], [13]. Sin embargo, las LSTM independientes a menudo no logran aprovechar las dependencias espaciales inherentes presentes en los datos de tráfico [14].

En esta investigación, utilizamos el marco de la Red Generativa Adversarial Espaciotemporal (STGAN, por sus siglas en inglés) para mejorar la detección de anomalías en los sistemas de tráfico urbano mediante la incorporación de factores externos y su aplicación a datos en tiempo real de la red de tráfico de Gotemburgo.

Además, construimos una simulación dinámica y realista de la red de tráfico urbano de Gotemburgo mediante la representación de cámaras de tráfico en tiempo real como nodos y carreteras como aristas [8]. Este enfoque de modelado detallado permite una representación más precisa de las dependencias espaciales y las variaciones del flujo de tráfico en toda la ciudad. Al aplicar el marco STGAN a este modelo integral, podemos capturar patrones de tráfico tanto a corto como a largo plazo con mayor eficacia que los métodos existentes.

II. TRABAJOS RELACIONADOS

La detección de anomalías en el tráfico es un desafío crucial en la gestión del tráfico y la planificación urbana modernas, donde comprender la evolución espacial y temporal del tráfico es esencial para una toma de decisiones eficaz [5]. Los enfoques de aprendizaje automático, en particular las redes neuronales y los modelos generativos, se han aplicado ampliamente a este problema [7], [15]–[17]. Sin embargo, los métodos existentes a menudo no logran capturar completamente la complejidad de los sistemas de tráfico urbano, que están influenciados tanto por la dinámica temporal como por la topología espacial [8].

Las redes de memoria a corto y largo plazo (LSTM) [12] se han utilizado ampliamente para la predicción del tráfico debido a su capacidad para modelar dependencias temporales a largo plazo. Investigaciones previas sobre el conjunto de datos de Gotemburgo emplearon principalmente redes LSTM para modelar la dinámica temporal de cámaras individuales [13]. Si bien son eficaces para capturar patrones temporales, estos métodos pasan por alto las dependencias espaciales cruciales entre los nodos de tráfico, que son esenciales para predecir con precisión el flujo de tráfico [14], [18].

* Autor correspondiente

Machine Translated by Google

Las redes neuronales gráficas (GNN) proporcionan una extensión natural para la predicción del tráfico al modelar explícitamente las dependencias espaciales entre los nodos de tráfico. Las GNN han demostrado un gran potencial para capturar correlaciones espaciales y la influencia de las condiciones de tráfico cercanas [8], [11]. Por ejemplo, las redes neuronales recurrentes convolucionales de difusión (DCRNN) modelan eficazmente los datos de tráfico espaciotemporales al integrar GNN con redes neuronales recurrentes [14], [18]. Sin embargo, muchos métodos basados en GNN incorporan de forma inadecuada la dinámica temporal, que es esencial para comprender la evolución del tráfico y detectar anomalías derivadas de interacciones espaciotemporales [19].

Para abordar estas limitaciones, investigaciones recientes se han centrado en integrar GNN con modelos temporales dentro de un marco generativo. El marco de Red Generativa Adversaria Espaciotemporal (STGAN) ejemplifica este enfoque al modelar conjuntamente las dependencias espaciales y temporales en los datos de tráfico [10]. STGAN emplea una arquitectura adversaria [20] donde un generador sintetiza secuencias de tráfico plausibles y un discriminador las distingue de los datos reales, mejorando la precisión predictiva y proporcionando un mecanismo robusto para la detección de anomalías [8], [21].

Nuestra investigación se basa en estos trabajos, adoptando el marco STGAN y aplicándolo a datos de tráfico en tiempo real de Gotemburgo. La integración de redes neuronales gráficas (GNN) con redes neuronales de memoria a corto plazo (LSTM) dentro de un marco generativo adversario permite capturar de manera más eficaz la compleja dinámica espaciotemporal del tráfico urbano. Este enfoque puede mejorar la precisión en la detección de anomalías al abordar algunas limitaciones de los métodos anteriores, que o bien pasaban por alto las dependencias espaciales o no modelaban completamente la dinámica temporal.

III. MÉTODOS

En esta sección, presentamos el marco de STGAN, basado en [10]. Nuestro objetivo es mejorar la detección de anomalías en los datos de tráfico capturando eficazmente las dependencias espaciales y temporales.

A. Representación de la red de tráfico

Una red de tráfico se representa como un grafo ponderado $G = (V, E, W)$, donde V es un conjunto finito de N nodos (cámaras de tráfico), E es el conjunto de aristas que representan las conexiones y W es la adyacencia ponderada. entre nodos, y matriz $W \in \mathbb{R}^{N\times N}$ que representa correlaciones espaciales.

La adyacencia entre nodos se determina en función de su proximidad espacial. Dos nodos v_i y v_j se consideran adyacentes si la distancia entre ellos está dentro de un umbral predefinido o si están conectados por un segmento de carretera. El peso de la arista entre los nodos v_i y v_j viene dado por:

$$\text{Nosotros} = \begin{cases} \exp\left(-\dfrac{\text{dist}(v_i, v_j)^2}{\sigma^2}\right), & \text{si } e_{ij} = 1, \\ 0, & \text{de lo contrario,} \end{cases}$$

donde $\text{dist}(v_i, v_j)$ denota la distancia euclidiana entre los nodos v_i y v_j, σ es la desviación estándar de todas las distancias por pares entre nodos, y e_{ij} indica adyacencia.

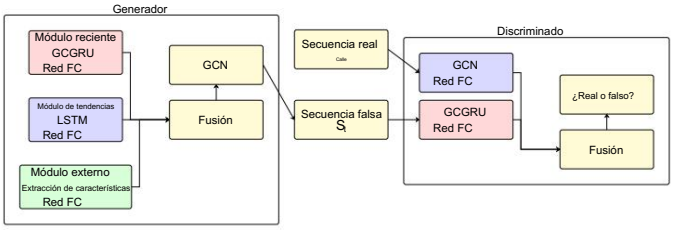


Figura 1. El marco STGAN incluye un generador espaciotemporal (izquierda) y un discriminador espaciotemporal (derecha). El generador procesa tres tipos de datos: datos recientes (patrones temporales a corto plazo) mediante un módulo GCGRU, datos de tendencia (patrones temporales a largo plazo) mediante una red LSTM y factores externos (características contextuales como el clima o eventos) mediante una red de extracción de características. Estas entradas se fusionan y se pasan a través de una GCN para modelar dependencias espaciales, generando una secuencia falsa, Sˆt. El discriminador, utilizando módulos GCGRU y GCN, evalúa la secuencia generada frente a secuencias reales, St, para distinguir entre lo real y lo falso, lo que permite un modelado robusto de la dinámica espaciotemporal. Véase también [10].

B. Representación de datos y definición del problema

Cada punto de datos se representa como la tripleta $s = (v, t, x_{v,t})$, donde $v \in V$ es el índice del nodo, t es el índice del tiempo y $x_{v,t} \in \mathbb{R}^F$ es el vector de características en el nodo v y el tiempo t. Los datos históricos durante T pasos de tiempo se denotan como $S \in \mathbb{R}^{T\times N\times F}$, que representan la dinámica del tráfico de todos los nodos. Dada la red de tráfico G y los datos históricos S, nuestro objetivo es identificar anomalías en el siguiente paso de tiempo $T + 1$ prediciendo las mediciones de tráfico esperadas y detectando desviaciones indicativas de anomalías.

Como se muestra en la Fig. 1, el marco STGAN comprende dos componentes principales:

- Generador espaciotemporal (G_θ): Genera secuencias predichas de datos de tráfico.
- Discriminador espaciotemporal (D): Distingue entre secuencias reales y generadas.

1) Componentes del generador espaciotemporal: El generador espaciotemporal G_θ consta de tres módulos diseñados para capturar diferentes aspectos de los datos de tráfico:

1) Módulo reciente: Captura dependencias espaciotemporales a corto plazo mediante una unidad recurrente con compuerta convolucional gráfica (GCGRU).
2) Módulo de tendencias: Aprende patrones temporales a largo plazo utilizando una red LSTM.
3) Módulo externo: Incorpora factores externos (por ejemplo, hora del día, día de la semana) mediante una capa totalmente conectada.

Las salidas de estos módulos se fusionan utilizando una capa de red neuronal convolucional gráfica (GCN) para producir la predicción final $\hat{X}_{v,t}$ para cada nodo v en el tiempo t.

2) Unidad recurrente convolucional con compuertas de grafos (GCGRU): La GCGRU extiende la GRU tradicional integrando operaciones de convolución de grafos para capturar dependencias espaciales entre

Machine Translated by Google

nodos. Las ecuaciones de actualización para el GCGRU en el instante t son:

$$r_t = \sigma(W_r \; X_t + U_r \; H_{t-1} + b_r), \; z_t = \sigma(W_z \quad (1)$$

$$X_t + U_z \; H_{t-1} + b_z), \quad (2)$$

$$\tilde{H}_t = \tanh(W_h \; X_t + U_h \; (r_t \; H_{t-1}) + b_h), \quad (3)$$

$$H_t = z_t \; H_{t-1} + (1 - z_t) \; \tilde{H}_t, \quad (4)$$

donde $X_t \; R^{N \times F}$ representa las características de entrada en el instante t, $H_t \; R^{N \times D}$ es el estado oculto y σ(·) denota la función de activación sigmoide. La operación de convolución gráfica se denota por .

C. Funciones de pérdida

El generador tiene como objetivo producir secuencias que sean realistas y cercanas a los datos reales. Su función de pérdida combina la pérdida adversaria y la pérdida de reconstrucción:

$$L_G(\theta) = \sum_s - \log(D \; (\hat{S}v,t)) + \lambda_G \; \|G_\theta(v,t) - X_{v,t}\|_2^2, \quad (5)$$

donde $D \; (\hat{S}v,t)$ denota la probabilidad del discriminador de que la secuencia generada sea real, y λG equilibra las pérdidas adversarias y de reconstrucción. El discriminador busca clasificar correctamente las secuencias reales y generadas. Su función de pérdida es:

$$L_D(\;) = \sum_s - \log(D \; (S_v,t)) - \log(1 - D \; (\hat{S}v,t)) \; . \quad (6)$$

D. Cálculo de la puntuación de anomalía

Las anomalías se detectan comparando los datos generados con los datos reales y evaluando la confianza del discriminador. La puntuación de anomalía para un punto de datos $s = v, t, x_{v,t}$ se calcula como:

$$s_G(v,t) = \|G_\theta(v,t) - X_{v,t}\| \; s_D(v,t) \; \|_2^2, \quad (7)$$

$$= D \; (S_v,t) - D \; (\hat{S}v,t), \; score(v,t) = s_G(v, \quad (8)$$

$$t) + \lambda s_D(v,t), \quad (9)$$

donde λ equilibra las contribuciones de sG y sD.

E. Procedimiento de entrenamiento del modelo

La STGAN se entrena mediante un proceso de aprendizaje adversario, donde el generador y el discriminador se actualizan alternativamente [21]. El procedimiento de entrenamiento se resume en el Algoritmo 1.

Algoritmo 1 Procedimiento de entrenamiento de

STGAN Requerido: Datos de entrenamiento {Sv,t}, parámetros iniciales θ y , tasas de aprendizaje ηG,
ηD 1: mientras no converja hacer
2: Actualización del generador:
3: Generar secuencias 4: $\hat{S}_{Vermont} = G_\theta(v,t)$
Calcular la pérdida del generador LG(θ) usando la ecuación (5)
5: Actualizar parámetros del generador: $\theta \leftarrow \theta - \eta_G \; \theta L_G(\theta)$
6: Actualización del discriminador: 7:
Evaluar el discriminador con datos reales: D (Sv,t)
8: Evaluar el discriminador en los datos generados: D (Sˆ v,t)
9: Calcular la pérdida del discriminador LD( ) usando la ecuación (6)
10: Actualizar parámetros del discriminador:
← − ηD LD( ) 11: fin del bucle while

F. Detalles de implementación

1) Arquitectura y parámetros de entrenamiento: La arquitectura del modelo y los parámetros de entrenamiento son cruciales para su rendimiento. Para el módulo reciente, utilizamos dos capas GCGRU con una dimensión oculta de 64, lo que permite al modelo capturar dependencias espaciotemporales complejas. El módulo de tendencias consta de dos capas LSTM con una dimensión oculta de 64 para modelar patrones temporales a largo plazo. El módulo externo procesa las características temporales codificadas de 31 dimensiones a través de una capa totalmente conectada con una dimensión de salida de 64.

Durante el entrenamiento, establecimos la tasa de aprendizaje tanto para el generador como para el discriminador en 0,001 y utilizamos un tamaño de lote de 64. El modelo se entrena durante 6 épocas, lo que se determinó que era suficiente para la convergencia basándose en el rendimiento de validación. Los hiperparámetros λG en la ecuación (5) y λ en el cálculo de la puntuación de anomalía se establecieron en 1 en nuestros experimentos.

La optimización se realiza mediante el optimizador Adam [22], que adapta la tasa de aprendizaje durante el entrenamiento para una convergencia más rápida. Todos los experimentos se llevaron a cabo con PyTorch y el código está disponible en https://github.com/fgias/traffic-anomaly-detection .

2) Conjunto de datos y preprocesamiento: El conjunto de datos proviene de cámaras distribuidas por la ciudad de Gotemburgo, Suecia, proporcionadas por Trafikverket. Los datos de vídeo comprenden imágenes capturadas a intervalos de un minuto. Cada cámara se identifica mediante un ID único y viene acompañada de coordenadas GPS que indican su ubicación y orientación.

Las imágenes se procesan para calcular la métrica de flujo $flow_{v,t}$ para la cámara v en el instante t, que representa la cobertura de las carreteras a las que apunta la cámara. La métrica de flujo se calcula utilizando:

$$flujo_{v,t} = \frac{\text{número de vehículos detectados}}{\text{capacidad máxima del vehículo}}, \quad (10)$$

donde el número de vehículos detectados se obtiene utilizando un algoritmo de detección de vehículos (por ejemplo, YOLOv5 [23]), y la capacidad máxima del vehículo es una constante predefinida basada en las características de la carretera.

Antes de introducir los datos en el algoritmo, se realiza un procesamiento adicional para suavizarlos, completar los minutos faltantes y truncar los periodos anteriores a las 4:53 a. m. y posteriores a las 9:00 p. m. Se utilizan datos del 1 de abril de 2020 al 13 de noviembre de 2020 para el entrenamiento. Los resultados se verifican durante 10 días, del 14 al 23 de noviembre de 2020.

Primero, los datos de todas las cámaras utilizadas, 42 en nuestro caso, se concatenan a lo largo de la dirección del tiempo. Los huecos de minutos faltantes se rellenan propagando la última observación válida a la siguiente válida, utilizando el método de relleno hacia adelante. Los puntos de datos de 1 minuto se reducen luego a intervalos de 5 minutos mediante promediado, para suavizar las variaciones. Se calculan las distancias de los nodos, los subgrafos de nodos Gv y la característica de tiempo. La característica de tiempo, para el módulo externo, en nuestro caso se representa como:

$$E = [\text{Día de la semana; Hora}], \quad (11)$$

donde Oweekday es un vector one-hot de longitud 7 que representa el día de la semana, y Ohour es un vector one-hot de longitud

Machine Translated by Google

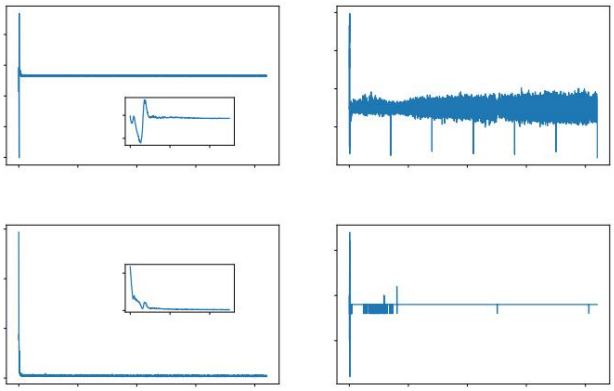


Figura 2. Métricas de entrenamiento para el entrenamiento adversario del discriminador y generador STGAN.

TABLA I
MÉTRICAS DE DISCRIMINACIÓN Y GENERACIÓN PARA LOS ÚLTIMOS 10 PASOS DE PROCESO DE FORMACIÓN.

Paso de época		Discriminado Pérdida	Discriminado Exactitud	Generador MSE	Generador Binario Pérdida
6	6992	0,693070	53,12%	0,007648	0,693215
6	6993	0,693185	43,95%	0,007306	0,693100
6	6994	0,693192	48,44%	0,007066	0,693192
6	6995	0,693146	48,44%	0,006912	0,693143
6	6996	0,693195	45,12%	0,007161	0,693341
6	6997	0,693172	49,80%	0,008960	0,693488
6	6998	0,693201	51,17%	0,008466	0,693458
6	6999	0,693100	54,49%	0,008442	0,693006
6	7000	0,693140	47,27%	0,008975	0,692538
6	7001	0,693116	23,83%	0,009361	0,692604

24 representando la hora del día. Las características meteorológicas fueron no se considera para nuestro conjunto de datos y, por lo tanto, la característica es 31 dimensiones. Finalmente, dado que las cámaras están activas solo entre las 4:53 am y las 9:00 pm, datos anteriores a las 4:55 y datos posteriores Las 9:00 p. m. se truncan. La función de hora debe truncarse. De la misma manera. Los datos están entonces listos para ser transmitidos a STGAN para entrenamiento.

IV. RESULTADOS

Métricas de entrenamiento como discriminador y generador binario la pérdida, así como la precisión del discriminador y el MSE del generador, son presentados en la Figura 2. Los últimos 10 valores de estas métricas son resumido en la Tabla I. Las bajas precisiones del discriminador sugiere que el generador se ha vuelto bueno en generar falsos secuencias que son difíciles de distinguir de los datos reales.

Siguiendo [10], calculamos las puntuaciones de anomalía de todos los datos en el conjunto de prueba. Etiquetamos los puntos de datos con el K% superior. puntuaciones anómalas como anomalías.

Evaluar la detección de anomalías en escenarios del mundo real sigue siendo un desafío abierto, ya que obtener un conjunto completo de datos de campo es un reto. Los datos veraces son difíciles de obtener. Dado que no pudimos hacerlo, tomamos la salida del algoritmo y verificar manualmente cada elemento marcado anomalía. La precisión se calcula mediante:

TABLA II
PRECISIÓN DE STGAN EN EL CONJUNTO DE DATOS DE PRUEBA PARA VARIOS VALORES DE K.

K (%)	Positivos	Verdaderos positivos	Falsos positivos	8	20	40	61	81	Precisión (%)
0,01			0						100
0,025		8	0						100
0,05		20	0						100
0,075		40	2						96.7
0,1		59	75	6					92.6

$$\text{precisión} = \frac{\text{verdaderos positivos}}{\text{verdaderos positivos} + \text{falsos positivos}}. \quad (12)$$

La Tabla II presenta la precisión del algoritmo STGAN en el conjunto de datos de prueba para diferentes valores de K. Para valores bajos de K Hay muy pocos aspectos positivos, y todos ellos son verdaderos positivos. anomalías cuyas causas pudimos identificar. A medida que aumenta K, tenemos un mayor número de anomalías, algunas de los cuales, sin embargo, son falsos positivos, lo que significa que estábamos incapaces de explicar su origen.

La Tabla III muestra los distintos tipos de anomalías detectadas para un valor específico de K, clasificándolos en tres tipos de anomalías. El primer tipo, “corte/reinicio de la señal de la cámara”, se refiere a las señales debido a problemas con el funcionamiento de la cámara, tales como: el corte o reinicio de la señal, cortes de energía, etc. El segundo tipo, “artefactos visuales”, se refiere a anomalías que fueron activado debido a la calidad visual de la entrada, como por ejemplo Degradación de la nitidez de la imagen debido a la humedad/gotas. por la lluvia en la lente de la cámara o el intenso reflejo de luz en carreteras mojadas. Por lo tanto, no se detectaron anomalías en esta categoría. identificado con cambios en el flujo de tráfico. Por último, “extremo Las “condiciones meteorológicas” son el tipo de anomalías que se deben a cambios en el clima que, de hecho, producen perturbaciones en el flujo de tráfico.

La figura 3 ilustra las anomalías identificadas para la cámara 25. durante un período de prueba de 10 días en noviembre de 2020, con K = 0,1%. Las anomalías, los días 16, 21 y 23 de noviembre, son: anomalías del tipo “corte/reinicio de la señal de la cámara”. En el primer caso, La cámara no funcionaba durante el tiempo normal de funcionamiento. ventana y activó una señal cuando comenzó a funcionar. En los dos últimos casos, la señal de la cámara se cortó antes. más de lo esperado, desencadenando anomalías. El caso más interesante, Sin embargo, es la del 19 de noviembre. Esta anomalía es de tipo “condiciones meteorológicas extremas”. En el momento de la anomalía, fuertes Comenzó a nevar, lo que a su vez perturbó el tráfico normal. flujo, que eventualmente desencadena una anomalía. La figura 4 muestra el cambio drástico del tiempo entre las 14:10 y las 14:20 Cámara 14.

V. DISCUSIÓN

Los resultados presentados proporcionan evidencia convincente de la eficacia del marco STGAN para anomalías de tráfico detección. La Tabla I ilustra las métricas de rendimiento de ambos. el generador y el discriminador durante el entrenamiento. El relativamente Los valores de pérdida estables para ambos componentes indican que el modelo

Machine Translated by Google

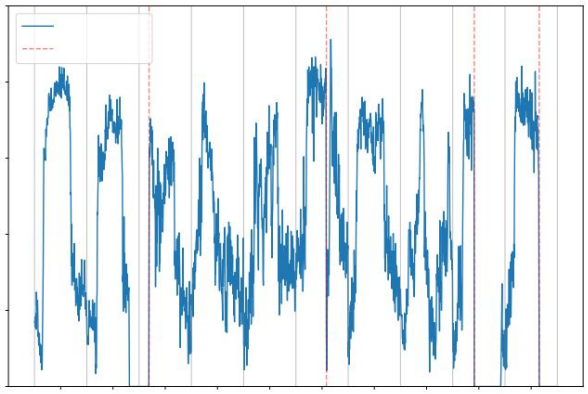


Figura 3. Anomalías detectadas para la cámara 25, durante 10 días de prueba en noviembre de 2020, calculadas para K = 0,1%.



Figura 4. Detección del inicio de una fuerte nevada. Imágenes de la cámara 14 del 19 de noviembre de 2020, a las 14:10 (arriba) y a las 14:20 (abajo).

TABLA III
ANOMALÍAS IDENTIFICADAS Y TIPOS DE ANOMALÍAS PARA K = 0,1%.

Tipo de anomalía	Número de anomalías
Corte/reinicio de la señal de la cámara	71
artefactos visuales	2
Condiciones climáticas extremas	2
Verdaderos positivos	75
Falsos positivos	6
Total	81

Se trata, en esencia, de aprender a generar secuencias de tráfico realistas, distinguiéndolas de los datos reales.

Los valores de precisión que se muestran en la Tabla II corroboran la eficacia de nuestro modelo. Alcanzar una precisión del 100 % con umbrales bajos demuestra que nuestro método puede identificar anomalías con exactitud sin generar falsos positivos. Sin embargo, a medida que K aumenta, una ligera disminución en la precisión pone de manifiesto una disyuntiva común en los sistemas de detección de anomalías: el equilibrio entre sensibilidad y especificidad.

La diversidad de anomalías identificadas, descritas en la Tabla III, revela información crucial sobre la naturaleza de las interrupciones del tráfico. La predominancia de anomalías de "corte/reinicio de señal de cámara" sugiere que la fiabilidad de la infraestructura es una preocupación importante en la monitorización del tráfico urbano. Además, la presencia de artefactos visuales y condiciones meteorológicas extremas como factores contribuyentes subraya la necesidad de modelos adaptativos capaces de distinguir entre anomalías de tráfico reales e influencias ambientales.

Los resultados revelan que las condiciones meteorológicas, como la lluvia y la nieve, influyen considerablemente en las métricas de flujo derivadas de las observaciones de las cámaras de tráfico. Por ejemplo, durante condiciones climáticas adversas, los artefactos visuales pueden confundir a los algoritmos de detección de tráfico, lo que resulta en recuentos erróneos de la densidad vehicular. Nuestro modelo identifica con precisión estas anomalías, demostrando su robustez ante las variaciones ambientales.

Además, estudios recientes, como [8], resaltan la eficacia de las redes neuronales gráficas espacio-temporales en la detección de anomalías en el tráfico. Su trabajo enfatiza la importancia de modelar características tanto espaciales como temporales; sin embargo, no aprovechan plenamente las capacidades generativas de las redes adversarias para mejorar la precisión de la detección de anomalías. Nuestro enfoque no solo modela estas características, sino que también incorpora factores externos como las condiciones climáticas y eventos especiales, que a menudo se pasan por alto en otros estudios.

VI. CONCLUSIONES

Nuestros hallazgos indican que el marco STGAN captura eficazmente patrones espaciotemporales complejos en los datos de tráfico, lo que conlleva un mejor rendimiento en la detección de anomalías en comparación con los métodos tradicionales.

En comparación con las metodologías existentes que utilizan únicamente redes LSTM [13], el marco STGAN demuestra una precisión superior al capturar tanto las dependencias espaciales como la dinámica temporal. Por ejemplo, si bien las LSTM pueden modelar eficazmente las dependencias temporales a largo plazo, a menudo pasan por alto las relaciones espaciales críticas entre los nodos de tráfico [14].

Machine Translated by Google

Por el contrario, la integración de las GNN permite una representación más completa de las redes de tráfico urbano.

Si bien el marco STGAN demuestra mejoras significativas en la detección de anomalías de tráfico, también cabe señalar varias limitaciones. En primer lugar, la incorporación de características temporales externas, como la hora del día y el día de la semana, no tiene en cuenta otros factores influyentes, como eventos especiales u obras viales, que pueden afectar significativamente el flujo de tráfico y el rendimiento de la detección de anomalías. Además, la dependencia de la métrica de flujo derivada de los algoritmos de detección de vehículos introduce una dependencia de la precisión de estos pasos de preprocesamiento; las imprecisiones o sesgos en la detección de vehículos podrían propagarse a través del modelo, afectando su robustez. La ausencia de etiquetas de referencia completas para las anomalías requirió una verificación manual, lo que puede introducir subjetividad y limita la escalabilidad del proceso de evaluación. Finalmente, la complejidad computacional del marco STGAN también es un factor a considerar para su implementación en tiempo real en redes de tráfico a gran escala, lo que subraya la necesidad de optimización para mejorar la eficiencia sin comprometer la precisión.

Nuestros hallazgos no solo validan el potencial del marco STGAN para la detección de anomalías de tráfico en tiempo real, sino que también señalan áreas para futuras mejoras, como el aumento de la robustez del modelo frente a factores ambientales y la optimización de la selección de hiperparámetros para diferentes contextos urbanos.

EXPRESIONES DE GRATITUD

Este trabajo forma parte de la red SMARTHEP, financiada por el programa de investigación e innovación Horizonte 2020 de la Unión Europea bajo el Acuerdo de Subvención n.º 956086. El trabajo de AS también cuenta con el apoyo parcial de subvenciones de eSSENCE n.º 138227, FORMAS n.º 2022-151862, Rymdstyrelsen n.º 2022-00282 y AgTech Sweden. Los cálculos fueron posibles gracias a los recursos proporcionados por la Infraestructura Académica Nacional para la Supercomputación en Suecia (NAISS), financiada parcialmente por el Consejo Sueco de Investigación mediante el Acuerdo de Subvención n.º 2022-06725. Los autores agradecen a Trafikverket y a la ciudad de Gotemburgo el acceso a sus datos de cámaras de tráfico. Asimismo, agradecen al laboratorio LIP6 el acceso a su clúster de GPU, donde se realizó la mayor parte del entrenamiento de los modelos.

REFERENCIAS

[1] L. Zhao, Y. Song, C. Zhang, Y. Liu, P. Wang, T. Lin, M. Deng y H. Li, “T-gcn: Una red neuronal convolucional de grafos temporales para la predicción del tráfico”, IEEE Transactions on Intelligent Transportation Systems, vol. 21, no. 9, pp. 3848–3858, 2020.

[2] X. Yin, G. Wu, J. Wei, Y. Shen, H. Qi y B. Yin, “Aprendizaje profundo en la predicción del tráfico: métodos, análisis y direcciones futuras”, IEEE Transactions on Intelligent Transportation Systems, vol. 23, n.º 6, págs. 4927–4943, 2022.

[3] A. Sopasakis y MA Katsoulakis, “Métricas de información para mejorar la fidelidad del modelo de tráfico mediante análisis de sensibilidad y asimilación de datos”, Transportation Research Part B: Methodological, vol. 86, pp. 1–18, 2016.

[4] RB Benarmas y KB Bey, “Un marco basado en aprendizaje profundo para la predicción del tráfico rodado”, Journal of Supercomputing, vol. 79, pp. 12 345– 12 360, 2023.

[5] P. Patil, “Aplicaciones del aprendizaje profundo en la gestión del tráfico: una revisión”, International Journal of Business Intelligence and Big Data Analytics, vol. 16, pp. 1–16, 2022. [En línea]. Disponible en: https://research.tensorgate.org/index.php/IJBIBDA/article/download/26/24 [6] T. Alperovich y A. Sopasakis, “Descripción estocástica del flujo de tráfico”, Revista de Física Estadística, vol. 133, n.º 6, págs. 1083–1105, 2008.

[7] K. Sakurada y T. Okatani, “Detección de cambios a partir de un par de imágenes de calles utilizando características de CNN y segmentación de superpíxeles”. en BMVC, X. Xie, MW Jones y GKL Tam, Eds. BMVA Press, 2015, pp. 61.1–61.12. [En línea]. Disponible en: http://dblp.uni-trier.de/db/conf/bmvc/bmvc2015.html#SakuradaO15

[8] H. Zhang, S. Zhao, R. Liu, W. Wang, Y. Hong y R. Hu, “Detección automática de anomalías de tráfico en la red vial con aprendizaje de representación de red neuronal gráfica espacio-temporal”, Wireless Communications and Mobile Computing, vol. 2022, n.° 1, pág. 4222827, 2022. [En línea]. Disponible en: https://onlinelibrary.wiley.com/doi/abs/10.1155/2022/4222827 [9] Y. Lv, Y. Duan, W. Kang, Z. Li y F.-Y. Wang, “Predicción del flujo de tráfico con big data: un enfoque de aprendizaje profundo”, IEEE Transactions on Intelligent Transportation Systems, vol. 16, n.° 2, págs. 865–873, 2015.

[10] L. Deng et al., “Redes neuronales convolucionales adversarias gráficas para la detección de anomalías espaciotemporales”, IEEE Transactions on Neural Networks and Learning Systems, vol. 33, no. 6, pp. 2416–2428, 2022.

[11] Z. Wu, S. Pan, F. Chen, G. Long, C. Zhang y PS Yu, “Una revisión exhaustiva sobre redes neuronales gráficas”, IEEE Transactions on Neural Networks and Learning Systems, vol. 32, n.° 1, págs. 4–24, 2021. [En línea]. Disponible en: https://arxiv.org/abs/1901.00596 [12] S. Hochreiter y J. Schmidhuber, “Memoria a largo y corto plazo”, Neural Computation, vol. 9, n.° 8, págs. 1735–1780, 1997.

[13] A. Sopasakis, “Demanda de tráfico y pronóstico a largo plazo a partir de observaciones en tiempo real”, en Actas de la Conferencia Internacional sobre Series Temporales y Pronósticos (ITISE 2019), Volumen 2, JM Corchado et al., Eds. ITISE, 2019, págs. 101-1 345–356. [En línea]. Disponible: https://itise.ugr.en/ITISE2019 Vol2.pdf

[14] B. Yu, H. Yin y Z. Zhu, “Redes convolucionales de grafos espaciotemporales: un marco de aprendizaje profundo para la predicción del tráfico”, en Actas de la 27.ª Conferencia Internacional Conjunta sobre Inteligencia Artificial (IJCAI), 2018, págs. 3634–3640.

[15] Y. Wang, Y. Zhang, X. Piao, H. Liu y K. Zhang, “Reconstrucción de datos de tráfico mediante correlaciones espacio-temporales adaptativas”, IEEE Transactions on Intelligent Transportation Systems, vol. 20, pp. 1531–1543, 2019.

[16] E. Norlander y A. Sopasakis, “Acondicionamiento del espacio latente para una mejor clasificación y detección de anomalías”, preimpresión de arXiv arXiv:1911.10599, 2019. [En línea]. Disponible en: https://arxiv.org/abs/1911.10599 om y A. Sopasakis, “Detección mejorada de anomalías mediante conjuntos de espacios latentes condicionados”, preimpresión de arXiv arXiv:2410.12328, 2024. [En línea]. Disponible en: https://arxiv.org/abs/2410.12328 [18] Y. Li, R. Yu, C. Shahabi y Y. Liu, “Red neuronal recurrente convolucional de difusión: pronóstico de tráfico basado en datos”, en Conferencia Internacional sobre Representaciones de Aprendizaje (ICLR), 2018.

[19] J. Zhou, G. Cui, S. Hu, Z. Zhang, C. Yang, Z. Liu, L. Wang, C. Li y M. Sun, “Redes neuronales gráficas: una revisión de métodos y aplicaciones”, Abierto de IA, vol. 1, págs. 57–81, 2020.

[20] P. Wang, Y. Zhang, S. Wang, L. Li y X. Li, “Pronóstico de la velocidad de viaje en días de lluvia para desarrollar una estrategia de control de límites de velocidad variables adecuada para un menor riesgo de conducción”, Journal of Advanced Transportation, vol. 2021, n.° 1, pág. 6639559, 2021. [En línea]. Disponible en: https://onlinelibrary.wiley.com/doi/abs/10.1155/2021/6639559 [21] IJ Goodfellow, J. Pouget-Abadie, M. Mirza, B. Xu, D. Warde-Farley, S. Ozair, A. Courville y Y. Bengio, “Redes generativas adversarias”, en Advances in Neural Information Processing Systems 27 (NIPS), 2014, págs. 2672–2680. [En línea]. Disponible en: https://papers.nips.cc/paper/5423-generative-adversarial-nets.pdf

[22] DP Kingma y J. Ba, “Adam: Un método para la optimización estocástica”, preimpresión de arXiv arXiv:1412.6980, 2014. [En línea]. Disponible en : https://arxiv.org/abs/1412.6980 [23] G. Jocher, “YOLOv5 de Ultralytics”, mayo de 2020. [En línea]. Disponible en: https://github.com/ultralytics/yolov5