Machine Translated by Google

ciencias aplicadas

MDPI

Artículo

# Trayectoria de conducción peligrosa basada en múltiples cámaras adyacentes Reconocimiento a las autopistas de ultralarga distancia

Liguo Zhao 1,2,3, Zhipeng Fu 2,3, Jingwen Yang 4,* Ziqiao Zhao 5 y Ping Wang 6

1 Escuela de Ingeniería Civil, Universidad Sun Yat-sen, Guangzhou 510275, China; zhaoliguo@ccccltd.cn
2 CCCC First Highway Consultants Co., Ltd., Xi'an 710065, China; fucccc2024@163.com
3 Laboratorio Estatal Clave de Ingeniería de Carreteras Verdes y de Larga Duración en Entornos Extremos, Xi'an
4 710065, China Escuela de Ingeniería Electrónica y de Control, Universidad Chang'an, Xi'an
710054, China 5 Escuela de Ingeniería de Transporte, Universidad Chang'an, Xi'an 710054, China;
17791977995@163.com 6 Escuela de Ingeniería de Sistemas Inteligentes, Universidad Sun Yat-sen,
Shenzhen 510006, China;
wangp358@mail.sysu.edu.cn * Correspondencia: 2020032001@chd.edu.cn

Resumen: La detección rápida de la trayectoria es clave para mejorar la propuesta de emergencia futura. Especialmente en autopistas de gran longitud, la detección inmediata requiere mucho trabajo. Sin embargo, la detección automática depende de la precisión y la velocidad de detección y seguimiento de vehículos. En sistemas de vigilancia multicámara para autopistas de gran longitud, suele ser difícil capturar el mismo vehículo sin interrupciones, lo que hace que el re-reconocimiento de vehículos sea crucial. En este artículo, presentamos un marco que incluye detección y seguimiento de vehículos mediante DeepSORT mejorado, re-reidentificación de vehículos, extracción de características basada en reglas de trayectoria y reconocimiento de comportamiento basado en análisis de trayectoria. En particular, diseñamos una arquitectura de red basada en DeepSORT con YOLOv5s para abordar la necesidad de detección y seguimiento de vehículos en tiempo real en la gestión del tráfico en el mundo real. Además, diseñamos un módulo de reconocimiento de atributos para generar atributos de individualidad coincidentes para los vehículos y así mejorar el rendimiento de la re-reidentificación de vehículos bajo múltiples cámaras vecinas. Asimismo, el uso de LSTM bidireccional mejora la precisión de la predicción de trayectoria, demostrando su robustez frente al ruido y las fluctuaciones. El modelo propuesto presenta una gran ventaja con respecto a la curva de característica de coincidencia acumulativa (CMC) mostrada, e incluso mejora en más del 15,38 % en comparación con otros mét El modelo desarrollado con el conjunto de datos de vehículos de autopistas locales se evalúa exhaustivamente, incluyendo el reconocimiento de trayectorias anómalas, la detección de cambios de carril y el reconocimiento de anomalías de velocidad. Los resultados experimentales demuestran la eficacia del método propuesto para identificar con precisión diversos comportamientos vehiculares, como cambios de carril, paradas e incluso otras conductas de conducción peligrosas.

Palabras clave: detección de vehículos; seguimiento de vehículos; autopistas extralargas

check for updates

Cita: Zhao, L.; Fu, Z.; Yang, J.; Zhao, Z.; Wang, P. Reconocimiento de trayectorias de conducción peligrosas basado en cámaras adyacentes múltiples para autopistas ultralargas. Appl. Sci. 2024, 14, 4593. https://doi.org/10.3390/app14114593

Editor académico: Francesco Liberato Cappiello

Recibido: 24 de abril de 2024
Revisado: 13 de mayo de 2024
Aceptado: 23 de mayo de 2024
Publicado: 27 de mayo de 2024

Derechos de autor: © 2024 por los autores. Titular de la licencia: MDPI, Basilea, Suiza. Este artículo es de acceso abierto. distribuido bajo los términos y condiciones de Creative Commons Licencia de atribución (CC BY) (https://creativecommons.org/licenses/by/4.0/).

## 1. Introducción

La tecnología de visión artificial ha experimentado un rápido desarrollo y se ha aplicado ampliamente en diversos ámbitos de la vida [1,2], especialmente en el sector del transporte [3]. Esta tecnología permite la identificación de vehículos en escenas con una sola cámara, posibilitando la extracción de información como velocidad, ubicación, trayectoria y matrícula [4,5].

Además, en el contexto de la vigilancia multicámara, facilita la asociación de vehículos objetivo específicos, lo que permite tareas como la reconstrucción de la trayectoria del vehículo y el seguimiento continuo [6]. Asimismo, con el avance de la tecnología de vídeo, es posible identificar trayectorias anómalas utilizando este método.

El reconocimiento de trayectorias vehiculares es una tecnología crítica en el campo de la gestión y seguridad del tráfico, incluyendo la identificación de comportamientos de conducción peligrosos, velocidades anormales, estacionamiento anormal y comportamientos de cambio de carril peligrosos, etc. [7]. En entornos de tráfico de la vida real, las anomalías en las trayectorias de los vehículos afectan el comportamiento del resto de los vehículos, a menudo implicando una mayor probabilidad de accidentes de tráfico, como vuelcos de vehículo

Machine Translated by Google



colisiones e incluso víctimas mortales. Por consiguiente, lograr una identificación precisa y rápida de las trayectorias anómalas de los vehículos puede mejorar la seguridad y la eficiencia de los desplazamientos.

Actualmente, la mayoría de las técnicas existentes en este campo se centran en el rendimiento en términos de precisión, mientras que la eficiencia se ve ligeramente descuidada. Por ejemplo, el algoritmo Deep- SORT [8] utiliza un detector de objetivos de dos etapas, R-CNN [9], que no cumple con los requisitos de tiempo real en escenarios reales. Asimismo, a la mayoría de los métodos existentes les resulta difícil monitorizar la trayectoria del vehículo durante todo el trayecto en escenarios de carreteras de ultralarga distancia, lo que dificulta la identificación automática de anomalías en la trayectoria.

Este artículo propone una arquitectura eficiente de reconocimiento de trayectorias anómalas para autopistas de ultralarga distancia. Diseñamos una arquitectura de red basada en DeepSORT con YOLOv5s para el seguimiento eficiente de múltiples vehículos y la adquisición rápida de trayectorias en el área visible. Sin embargo, en escenarios de carreteras de ultralarga distancia, existe un cierto rango de puntos ciegos en el campo de visión de las cámaras vecinas, lo que significa que no podemos acceder directamente a la trayectoria del vehículo durante todo el trayecto. Para superar este problema, aplicamos la estructura LSTM bidireccional para predecir la trayectoria en el área ciega. Además , se propone un módulo de reconocimiento de atributos para implementar eficientemente la reidentificación del vehículo , lo que significa que podemos unir correctamente las trayectorias del mismo vehículo en diferentes tramos de carretera y, finalmente, recuperar la trayectoria completa del vehículo.

Este estudio selecciona la carretera del puente Hong Kong-Zhuhai-Macao como escenario de investigación, con el objetivo de analizar situaciones específicas en los vídeos de vigilancia de la autopista. En este contexto, existen puntos ciegos de corta distancia entre las distintas cámaras de vigilancia. Para abordar esta limitación, el estudio emplea un enfoque de integración de trayectorias de conducción. Esto implica un análisis y procesamiento exhaustivo de los datos de trayectoria de los vehículos registrados por las cámaras de vigilancia, prediciendo y delineando así las trayectorias de movimiento de los vehículos dentro de los puntos ciegos. Mediante este método, el estudio logra la unión y reconstrucción de las trayectorias de movimiento de los vehículos en toda el área, facilitando la identificación efectiva de trayectorias anómalas. La Figura 1 muestra el diagrama de la escena experimental. Las contribuciones de nuestro artículo se pueden resumir de la siguiente manera:

1. Proponemos un marco eficaz para el reconocimiento de trayectorias de vehículos en autopistas ultralargas y diseñamos una arquitectura de red basada en DeepSORT y YOLOv5s para el seguimiento eficiente de objetivos de múltiples vehículos para obtener rápidamente trayectorias dentro del área visible.

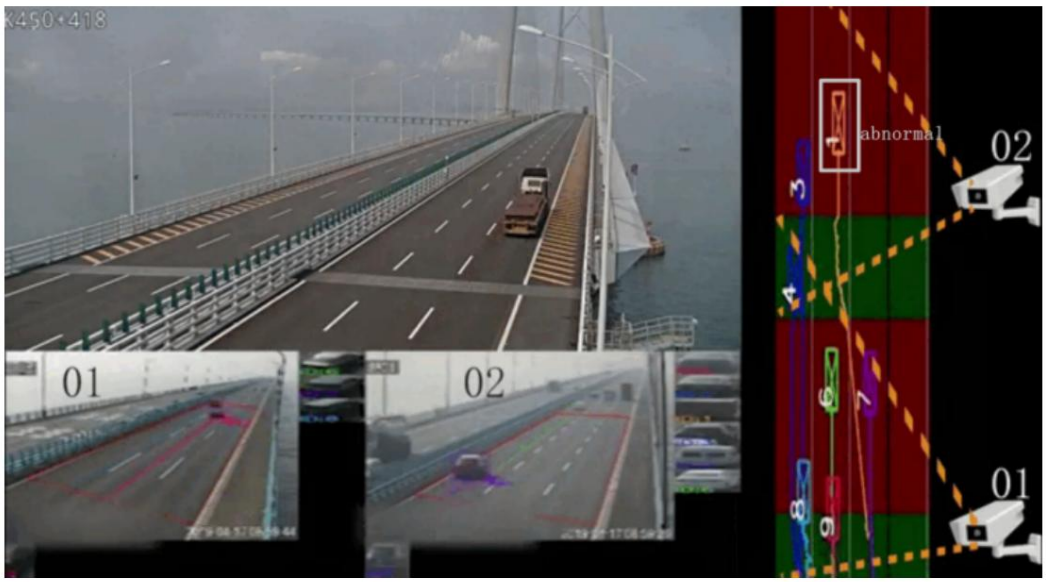



Figura 1. Diagrama de la escena experimental.

2. Proponemos un módulo de reconocimiento de atributos para realizar de manera efectiva la reidentificación de vehículos, uniendo correctamente las trayectorias del mismo vehículo en diferentes tramos de carreter

Machine Translated by Google



y, finalmente, restaurar la trayectoria completa del vehículo. Además, para resolver el problema de un cierto rango de puntos ciegos entre los campos de visión de cámaras adyacentes en escenarios de carreteras de ultralarga distancia, se introduce una estructura LSTM bidireccional en nuestro marco para predecir la trayectoria de los puntos ciegos.

3. El modelo propuesto se evaluó exhaustivamente con el conjunto de datos de reidentificación de la autopista de circunvalación de Xi'an, incluyendo la identificación de trayectorias anómalas, la detección de cambios de carril y la identificación de anomalías de velocidad. Los resultados experimentales demuestran la eficacia de este método para identificar con precisión diversos comportamientos vehiculares, como cambios de carril, estacionamiento e incluso otras conductas de conducción peligrosas.

## 2. Revisión de la literatura

La investigación sobre la tecnología de seguimiento de vehículos en autopistas basada en aprendizaje profundo abarca principalmente tres tareas: detección de vehículos, seguimiento de múltiples vehículos y reidentificación de vehículos mediante imágenes de diferentes cámaras. Esta sección se centra en el estado del arte de las técnicas relacionadas.

### 2.1. Detección y seguimiento de vehículos

La detección y el seguimiento de vehículos se dividen en dos partes importantes: la detección de objetivos y el seguimiento de múltiples objetivos. La detección de objetivos es uno de los problemas básicos en el campo de la visión artificial y también constituye la base de muchos escenarios de aplicación, como el reconocimiento facial, la detección de peatones, la detección de objetivos mediante teledetección, etc. Los detectores de objetos basados en aprendizaje profundo se pueden dividir en cuatro categorías: detección de objetos en dos etapas y en una etapa según el tipo de red, y detección de objetos 2D y detección de objetos 3D según el tipo de datos.

La detección en dos etapas consta de dos procesos: regiones candidatas y clasificación de objetos. En la etapa de regiones candidatas, el detector de objetos selecciona una región de interés (ROI) en la imagen de entrada que contiene el objeto objetivo. En la fase de clasificación de objetos, se selecciona la ROI más probable, se descartan las demás y se clasifica el objeto seleccionado. Algunos detectores comunes son R-CNN, Fast R-CNN [10] y Faster R-CNN [11].

A diferencia de los detectores de dos etapas, los detectores de objetos de una sola etapa crean cuadros delimitadores durante la detección de objetos y realizan operaciones de clasificación sobre los objetos detectados. Algunos ejemplos populares de detectores de una sola etapa son YOLO [12], SSD [13] y RetinaNet [14].

Para la detección de objetos, los datos de imagen 2D se suelen obtener mediante un detector de objetos 2D. La literatura [15] fusiona datos de radar y cámara mediante el aprendizaje de métodos de detección de sensores. Con el auge del aprendizaje profundo, los investigadores están cada vez más interesados en la detección de objetos 3D. Complex-YOLO [16] utiliza una red de propuesta de región de Euler (E-RPN) basada en YOLOv2 para obtener regiones candidatas 3D.

El seguimiento de múltiples objetos (MOT) es una tarea de visión artificial que busca correlacionar los objetos detectados en diferentes fotogramas de vídeo para obtener la trayectoria de movimiento completa. En 2016, Bewley et al. [17] propusieron el algoritmo SORT (Simple Online and Realtime Tracking), que extrae características de los objetivos en secuencias de vídeo combinando redes neuronales convolucionales y recurrentes. Posteriormente, se utiliza el filtro de Kalman para predecir y actualizar la posición del objetivo, y el algoritmo húngaro para asociar los datos de los mismos objetivos detectados. Más tarde, Wojke et al. [8] incorporaron el aprendizaje profundo al algoritmo SORT y propusieron el algoritmo DeepSORT. Mediante el aprendizaje de la representación de características profundas, se utilizó la red neuronal convolucional para extraer las características de apariencia del objetivo y reemplazar las características diseñadas manualmente utilizadas en SORT. Con el desarrollo de la tecnología de detección de objetos, el detector de objetos original de dos etapas Faster R-CNN no destaca por su eficacia en el seguimiento en escenarios de aplicación práctica debido a su lenta velocidad de detección. Por lo tanto, se han propuesto numerosos algoritmos de detección de objetos alternativos para mejorar el algoritmo DeepSORT.

### 2.2. Reidentificación de vehículos

Cuando se proporciona un gráfico de consulta objetivo, la reidentificación de vehículos puede encontrar los vehículos con la misma ID que el gráfico de consulta objetivo en la escena de cámaras adyacentes o varias cámaras adyacentes.

Machine Translated by Google



cámaras cent. Con la continua actualización y desarrollo de algoritmos de aprendizaje profundo, este campo de aplicación se ha vuelto espectacular. Se puede dividir principalmente en métodos de aprendizaje supervisado, métrico y no supervisado. Los métodos basados en aprendizaje supervisado se dividen a su vez en métodos basados en características globales [18,19], características locales [20,21] y mecanismo de atención [22]. El objetivo del aprendizaje métrico es aprender un mapeo de las características originales al espacio de incrustación, de modo que los objetos de la misma categoría estén cerca en el espacio de incrustación y la distancia entre diferentes categorías sea grande. La distancia euclidiana y la distancia coseno se utilizan generalmente en la ecuación de cálculo de distancia. En la tarea de reidentificación basada en el método de aprendizaje profundo, la función de pérdida [23,24] reemplaza el rol del aprendizaje métrico tradicional para guiar el aprendizaje de la representación de características. En contraste con las técnicas supervisadas, el aprendizaje no supervisado tiene como objetivo inferir directamente de datos de entrada sin etiquetar, lo que aborda la capacidad de generalización limitada de los modelos y el alto costo de los datos etiquetados manualmente [25]. Shen et al. [23] utilizaron características de agrupamiento para modelar características globales y locales para mejorar la precisión de la reidentificación de vehículos no supervisada.

### 2.3. Reconocimiento de trayectorias anormales Las

trayectorias de conducción microscópicas de los vehículos están estrechamente relacionadas con el análisis de la seguridad vial. Zhao Youting y colaboradores identificaron estados de conducción anormales, como exceso de velocidad, baja velocidad y parada, basándose en la detección por vídeo.

Existen diversas maneras de obtener información sobre el comportamiento microscópico de los vehículos al volante, incluyendo un gran número de registros de eventos reales, simuladores de conducción y software de simulación de tráfico microscópico . A partir de las trayectorias obtenidas, se pueden asociar los factores de riesgo de los accidentes de tráfico. Entre ellos, Yan et al. [26] estudiaron sistemáticamente la relación entre los factores de intervención y la seguridad del comportamiento al volante, proporcionando una base científica para la toma de decisiones en la gestión de la seguridad vial. Bao et al. [27] utilizaron datos de trayectoria de coches flotantes para analizar los factores de correlación relacionados con las colisiones.

Muchos investigadores han estudiado el control del tráfico para mejorar la seguridad basándose en los resultados de la trayectoria microscópica de los vehículos. Chen et al. [28] estudiaron la tecnología de garantía de seguridad del tráfico. Equipos como la Universidad de Tongji y la Universidad de Jiangsu también establecieron un análisis de correlación espacio-temporal entre accidentes en riesgos multidimensionales, sentando las bases para un control de tráfico proactivo [29].

A pesar de los avances logrados en el campo del reconocimiento de trayectorias anómalas en vídeos de vigilancia, persisten varios desafíos y problemas. En primer lugar, existe un debate continuo sobre la definición de estándares y métricas de evaluación para trayectorias anómalas . Diferentes escenarios y aplicaciones pueden tener definiciones variables de anomalía, lo que exige el establecimiento de un estándar flexible y de aplicación universal para garantizar la idoneidad y comparabilidad de los métodos de reconocimiento. Además, para una evaluación más precisa del rendimiento de los algoritmos, es necesario desarrollar métricas de evaluación más detalladas y objetivas que consideren adecuadamente las características de los diferentes tipos de anomalías.

Además, diversas fuentes de interferencia en los datos de vídeo siguen siendo un obstáculo formidable . Factores como el ruido, la oclusión y las variaciones en la iluminación pueden dificultar el reconocimiento preciso de trayectorias anómalas, lo que exige técnicas de preprocesamiento y mejora de datos más potentes para aumentar la robustez del sistema frente a estas interferencias.
Además, en casos de oclusiones, explorar métodos de fusión de datos de múltiples cámaras o sensores es fundamental para obtener información más completa y precisa. En tercer lugar, el rendimiento en tiempo real, la escalabilidad y la interpretabilidad son aspectos cruciales en los métodos de detección de trayectorias anómalas. La detección rápida de anomalías es esencial en muchas aplicaciones prácticas, lo que exige la exploración de algoritmos eficientes y técnicas de aceleración de hardware para lograr el procesamiento en tiempo real. Al mismo tiempo, con el aumento del número de dispositivos de monitorización, la escalabilidad del sistema se vuelve primordial, lo que requiere el diseño de algoritmos y arquitecturas capaces de operar en entornos a gran escala.

En cuarto lugar, la fusión de información multimodal es una de las direcciones para el desarrollo futuro . La utilización de diversas fuentes de información, como sonido y texto, permite una mayor

Machine Translated by Google



Análisis exhaustivo de escenas y detección de anomalías, lo que mejora la eficacia general de la detección. Sin embargo, la integración y el análisis conjunto de datos tan diversos aún requieren más investigación.

En resumen, a pesar del importante progreso alcanzado en el campo del reconocimiento de trayectorias anómalas en vídeos de vigilancia, aún se requiere la colaboración interdisciplinaria y esfuerzos de investigación continuos para abordar los desafíos y problemas mencionados, promoviendo así un mayor avance y aplicación de este campo.

## 3. Metodología 3.1.

### Detección y seguimiento de vehículos

El algoritmo empleado en este artículo combina principalmente YOLOv5s con DeepSORT. En un entorno de tráfico cerrado, como una autopista, la detección de vehículos en tiempo real mediante cámaras de alta velocidad de fotogramas que vigilan vehículos en movimiento rápido requiere un algoritmo de detección capaz de procesar la información con rapidez y minimizar la posibilidad de pasar por alto detecciones en la secuencia de imágenes. El modelo DeepSORT original, basado en la estrategia de seguimiento por detección (TBD), utiliza el algoritmo de detección de objetos Faster R-CNN.

Si bien ofrece una buena precisión, su velocidad de procesamiento es relativamente lenta, lo que la hace inadecuada para aplicaciones en tiempo real. Por consiguiente, este artículo integra el algoritmo de seguimiento de múltiples objetos DeepSORT con el algoritmo de detección de objetos YOLOv5s para reemplazar Faster R-CNN, mejorando así el rendimiento del modelo en el seguimiento de múltiples vehículos.

El algoritmo consta de dos pasos principales. En primer lugar, implica calcular el coseno.
distancia de vectores de características y la distancia de Mahalanobis entre cuadros de detección y

Se generan cuadros de predicción mediante la red YOLOv5s. Los resultados calculados se someten a una fusión ponderada para generar una matriz de asociación. Posteriormente, se emplea el algoritmo húngaro para emparejar los cuadros de detección de vehículos con los cuadros de seguimiento. Si se establece una coincidencia exitosa, se genera una salida; de lo contrario, se requiere reinicializar el filtro de Kalman .

### 3.2. Reidentificación de vehículos basada en imágenes

La tarea de reidentificación de vehículos busca identificar el mismo vehículo en diferentes cámaras o momentos mediante la comparación de imágenes. La clave para resolver la reidentificación de vehículos reside en la extracción de características y el cálculo de la medición de similitud. La extracción de características basada en aprendizaje profundo es actualmente el enfoque predominante. La medición de similitud generalmente implica mapear imágenes a un espacio de características donde la similitud de imágenes se puede cuantificar directamente, y luego utilizar las diferencias de características extraídas para evaluar la similitud entre dos objetivos. Una distancia menor entre dos objetivos indica mayor similitud y mayor probabilidad de que sean el mismo objetivo; una distancia mayor significa menor similitud y menor probabilidad de que sean el mismo objetivo. Generalmente, se emplean capas totalmente conectadas para aplanar las características de la imagen en vectores unidimensionales, seguido del uso de métricas de distancia adecuadas para calcular las disparidades entre las características de la imagen. Las métricas de distancia comúnmente utilizadas incluyen la distancia euclidiana, la distancia de Manhattan, la distancia coseno y la distancia de Mahalanobis.

En este trabajo, al construir un modelo de reidentificación de vehículos basado en información de atributos, la información de atributos del vehículo extraída de cada rama de atributos se incorpora a las características globales generadas por la red principal. Esta incorporación tiene como objetivo mejorar la interacción entre las características de los atributos y las características de reidentificación de vehículos , produciendo así características más distintivas y representativas [30,31].

Como se muestra en la Figura 2, en la arquitectura de red de reidentificación de vehículos mejorada que se centra en la información de atributos, el modelo de red primero extrae información de características de imagen de la red principal, generando un mapa de características F. Posteriormente, la característica global F se introduce en ramas de atributos basadas en módulos de atención, lo que da como resultado varios mapas de características de atributos A1, A2, ..., At . Estos mapas de características de atributos se combinan luego utilizando un módulo de reponderación de atributos para producir un mapa de características de atributos unificado y completo A, que abarca todos los atributos. El mapa de características de atributos generado A se somete a un promedio global.

Machine Translated by Google



Agrupación y capas totalmente conectadas para generar vectores de características de atributos para el reconocimiento de atributos. Simultáneamente, se extrae información útil de los atributos mediante operaciones convolucionales en el mapa de características de atributos A. Esta información se integra posteriormente en las características globales, dando como resultado el mapa de características de fusión final R. El vector de características de agrupación promedio espacial r de R se utiliza para la tarea final de reidentificación de vehículos.

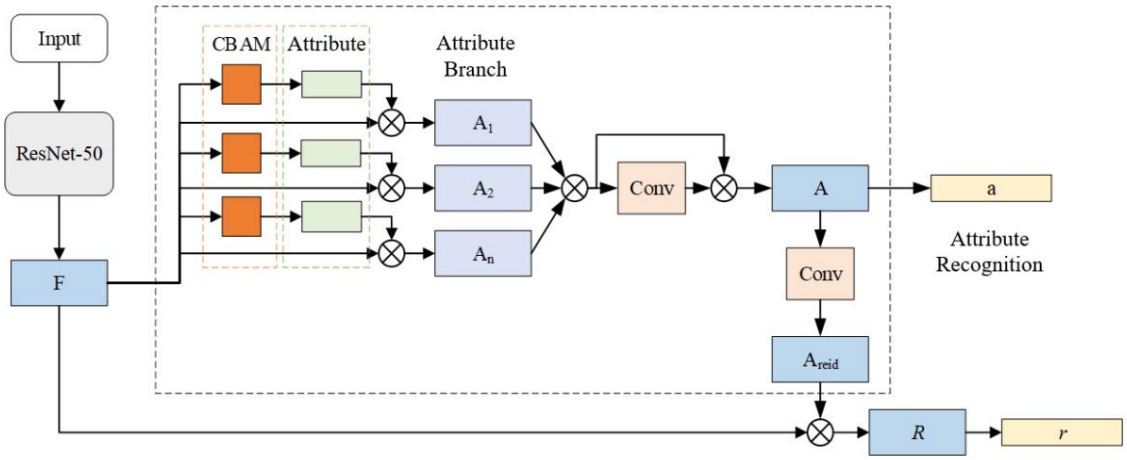



Figura 2. Diagrama de arquitectura de la red de reconocimiento de vehículos basada en información de atributos mejorada.

3.3. Reconocimiento de trayectorias anómalas basado en reglas de trayectoria

En este artículo, el reconocimiento de trayectorias anómalas consta de cinco partes principales: modelado matemático de la información del vehículo, modelado matemático del comportamiento del vehículo, adquisición de la trayectoria en el área visible, predicción de la trayectoria en el área ciega y discriminación de anomalías. En primer lugar, modelamos la información física y el comportamiento de conducción del vehículo para lograr una percepción integral del vehículo en movimiento. Posteriormente, se adquieren y predicen las trayectorias del vehículo en dos regiones de la escena (región visible y dentro del área ciega), respectivamente. Finalmente, de acuerdo con las reglas de anomalía definidas, se determina si la trayectoria del vehículo es anómala o no.

3.3.1. Descripción matemática de la información del vehículo La

información de la trayectoria del vehículo obtenida a partir de los recuadros de seguimiento de una cámara de vigilancia determinada incluye los siguientes aspectos principales: la duración T de la trayectoria, el número total de fotogramas f de la trayectoria durante el tiempo T y las coordenadas del mundo de la posición del vehículo si = (xi , yi) en la secuencia de fotogramas i . Generalmente, se supone que z es 0 o una constante. La descripción de los parámetros del modelo puede ser la siguiente:

1. Conjunto de posiciones del vehículo S = {s1,s2, . . . ,sf }, donde sf = (xf , yf ); 2.
Conjunto de trayectorias de movimiento del vehículo L = {l1, l2, . . . ,lf }, donde li representa el cambio en la posición del vehículo, o la longitud del camino que el vehículo ha recorrido desde el fotograma (i − 1) − th hasta el fotograma i − th. Se calcula como se muestra en la ecuación (1):

$$li = \sqrt{(yi - yi-1)^2 + (xi - xi-1)^2}, i > 1 \quad (1)$$

3. Conjunto de ángulos de movimiento del vehículo A = {θ1, θ2, . . . , θf }, donde θi representa el ángulo de movimiento del vehículo entre el (i − 1) − -ésimo marco y el i − -ésimo marco en un sistema de coordenadas definido por las coordenadas. θi (−π, π) y se calcula como se muestra en la ecuación (2):

$$= \arctan\left(xi - \frac{yi - yi-1}{xi-1}\right), i > 1, i > 1 \quad (2)$$

Machine Translated by Google



4. Conjunto de pendientes de los ángulos de movimiento del vehículo K = {k1, k2, . . . , k f }, donde ki representa la pendiente de la trayectoria del vehículo desde el (i − 1) − th frame hasta el i − th frame. Se calcula como se muestra en la ecuación (3):

$$ki = \frac{yi - yi-1}{xi - xi-1}, \; i > 1 \tag{3}$$

5. Conjunto de velocidades promedio de movimiento del vehículo $\overline{Vk} = \{\overline{v1}, \overline{v2}, \ldots, \overline{vf-k}\}$, donde $\overline{vi}$ representa la velocidad promedio del vehículo durante los últimos k fotogramas, desde el fotograma i − k hasta el fotograma i − th. Se calcula como se muestra en la ecuación (4):

$$\text{nosotros} = \begin{cases} \sqrt{(yi - yi-k)^2 + (xi - xi-k)^2} \cdot \frac{F}{T \cdot K} & i \geq k \\ \sqrt{(yi - y1)^2 + (xi - x1)^2} \cdot \frac{}{T \cdot K} & i < k \end{cases} . \tag{4}$$

En las descripciones matemáticas mencionadas, el parámetro L se utiliza para determinar si el vehículo está en movimiento, mientras que los parámetros A y K se emplean para evaluar si su dirección de desplazamiento es correcta. Además, el parámetro Vk sirve para evaluar si la velocidad del vehículo cumple con las normas de circulación.

#### 3.3.2. Modelo matemático del comportamiento de conducción de vehículos

Considerando las características de los escenarios de carretera y el movimiento de los vehículos , este estudio clasifica los comportamientos comunes de los vehículos en carretera en normales y anormales. Los comportamientos normales abarcan acciones de conducción que cumplen con las normas, como circular en línea recta y cambiar de carril, respetando la seguridad vial. Por otro lado, los comportamientos anormales incluyen acciones como conducir en sentido contrario, exceder el límite de velocidad, circular a baja velocidad, detenerse bruscamente y realizar cambios de carril peligrosos. En la figura 3 se muestra un diagrama esquemático a modo de referencia.

A partir del esquema de comportamiento del vehículo, se observa que los distintos comportamientos anómalos corresponden a características de movimiento específicas en sus trayectorias. Para un modelo de reconocimiento de comportamiento, los factores clave a considerar incluyen cambios en la posición, la velocidad, la dirección y los ángulos de movimiento del vehículo.

Definimos que los vehículos que circulan en la dirección correcta según las normas de tráfico, alejándose del campo de visión de la cámara, se denominan "en dirección descendente", mientras que los que se acercan a la cámara se denominan "en dirección ascendente".

Basándonos en las reglas mencionadas y considerando las limitaciones del escenario de aplicación, se puede establecer un modelo matemático para el comportamiento de conducción de vehículos. El modelo matemático para reconocer el comportamiento descendente de los vehículos se ilustra en la Tabla 1. Con este modelo matemático, podemos establecer un sistema de detección de comportamiento vehicular basado en reglas de trayectoria para analizar las trayectorias de conducción de vehículos en carretera extraídas.

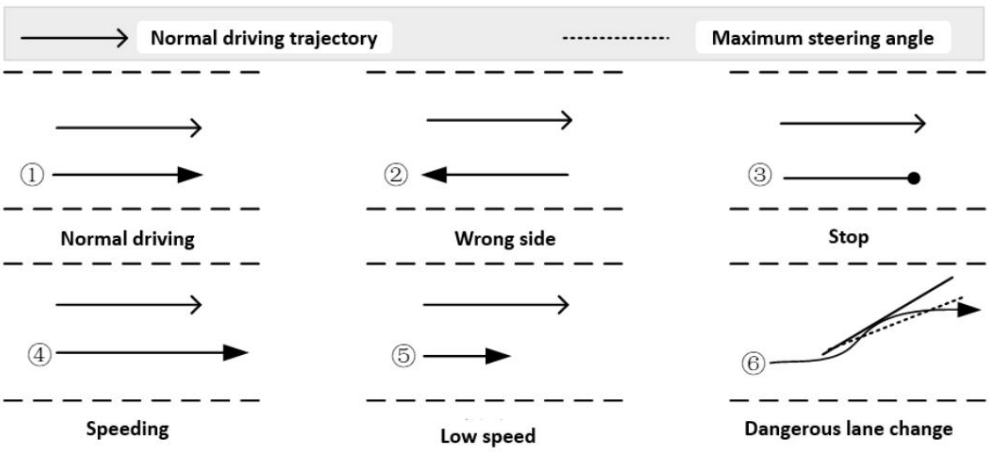



Figura 3. Diagrama esquemático de las trayectorias de comportamiento del vehículo para un comportamiento normal y un comportamiento anormal.

Machine Translated by Google



Tabla 1. Modelo matemático para el descenso del vehículo, u representa el umbral para la pendiente de dirección del vehículo, m es el umbral para la velocidad mínima permitida y n es el umbral para la velocidad máxima permitida.

| Comportamiento del vehículo | Descripción matemática del comportamiento descendente del vehículo |
|---|---|
| Conducción normal | L > 0 y A > 0 y \|ki \| > u y m < Vk < n |
| Lado equivocado | L > 0 y A < 0 |
| Exceso de velocidad | L > 0 y Vk > n |
| Baja velocidad | L > 0 & Vk < mlll · · · = 0 i , |
| Detener | i+1 , i+2 , |
| Cambio de carril peligroso | L > 0 & A > 0 & \|ki \| < u |

3.3.3. Método de adquisición de trayectoria para escenas visibles En

el rango visible de la cámara, basándonos en los resultados del seguimiento del vehículo y la información del modelado del vehículo, podemos obtener información precisa de la posición del vehículo y la trayectoria en la serie temporal. La información de posición de los vehículos en las imágenes de la cámara se representa en forma de coordenadas de píxeles. Estas coordenadas de píxeles no se pueden utilizar directamente para analizar las trayectorias de los vehículos en el mundo real. Por lo tanto, es necesario mapear las coordenadas de píxeles de los vehículos en las imágenes de la cámara a sus coordenadas correspondientes del mundo real, obteniendo así la información de posición de los vehículos en el mundo real. El método de cálculo entre cualquier punto en el sistema de coordenadas del mundo y su punto correspondiente en el sistema de coordenadas de píxeles se muestra en la ecuación (5).

$$Zc \begin{matrix} en \\ en \\ 1 \end{matrix} = M \begin{matrix} Xw \\ Sí \\ Zw \\ 1 \end{matrix} = \begin{matrix} r11\ r12\ r13\ r14 \\ r21\ r22\ r23\ r24 \\ r31\ r32\ r33\ r34 \end{matrix} \begin{matrix} Xw \\ Sí \\ Zw \\ 1 \end{matrix} \quad (5)$$

En la ecuación (5), si se conocen las coordenadas de píxeles y las coordenadas del mundo de cualquier punto, r34 se puede determinar como 1. Por lo tanto, quedan 11 incógnitas en la matriz de transformación de proyección M. En escenarios prácticos, el tablero del puente se puede aproximar como un plano horizontal en el sistema de coordenadas del mundo. Los puntos de referencia de mapeo entre el sistema de coordenadas de píxeles y el sistema de coordenadas del mundo se ilustran en la figura 4.

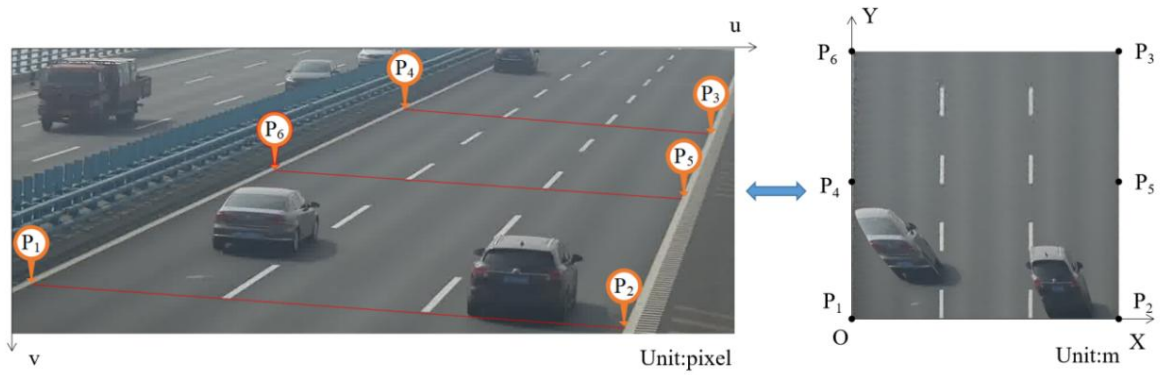



Figura 4. Mapeo de puntos de referencia en el sistema de coordenadas de píxeles y en el sistema de coordenadas del mundo.

Al realizar la detección y el seguimiento de vehículos, ya se ha obtenido información precisa sobre su ubicación . Tras la transformación de coordenadas, las trayectorias de los vehículos se pueden representar con exactitud en un espacio bidimensional. En esta sección, para la extracción de las trayectorias de los vehículos, se selecciona el conjunto de coordenadas centrales inferiores de los cuadros delimitadores del vehículo rastreado en cada fotograma como la trayectoria aproximada del vehícul

El proceso específico de extracción de trayectoria se puede describir de la siguiente manera: Los cuadros delimitadores del vehículo detectados en el k-ésimo fotograma se utilizan como base para la extracción de la trayectoria.

Machine Translated by Google



Las coordenadas del centro inferior se representan como se muestra en la ecuación (6),

$$(xk , yk) = d \cdot x(i) + 2 \quad \frac{d \cdot w(i)}{\quad}, d \cdot y(i) + d \cdot h(i) \tag{6}$$

donde (d · x(i), d · y(i)) representa las coordenadas del origen, es decir, la esquina superior izquierda del rectángulo, y d · w(i) y d · h(i) denotan el ancho y la altura del rectángulo, respectivamente. La trayectoria obtenida se ilustra en la Figura 5.

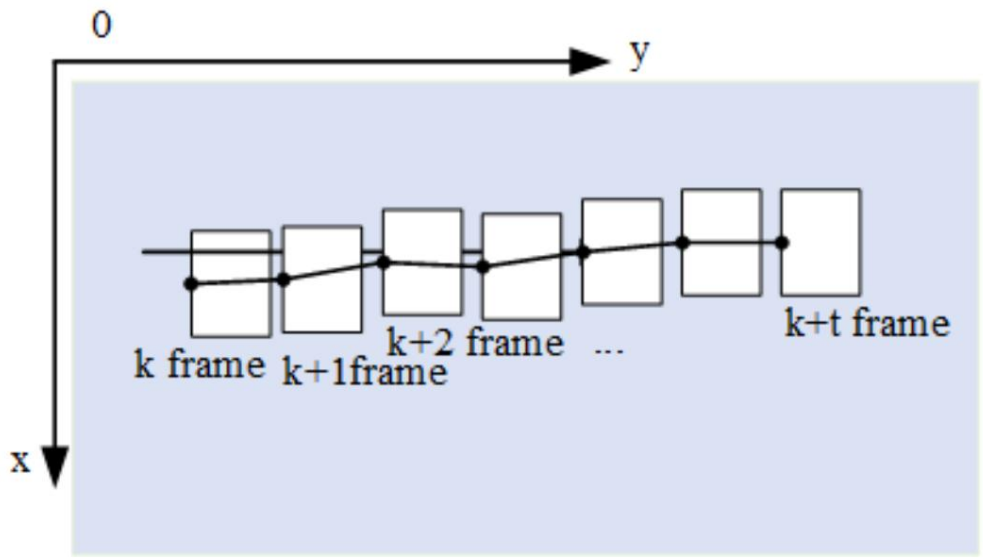



Figura 5. Diagrama esquemático de la trayectoria de movimiento del vehículo.

En la vista de la cámara P, la trayectoria de un vehículo determinado en una secuencia consecutiva de t + 1 fotogramas se puede representar mediante una secuencia de conjuntos que contienen t + 1 puntos de coordenadas de píxeles, como se muestra en la ecuación (7).

$$Pi = \{(xk , yk , CP),(xk+1 , yk+1 , CP), \cdots ,(xk+t , yk+t , CP)\} \tag{7}$$

3.3.4. Predicción de trayectoria en zona ciega basada en LSTM bidireccional En

túneles de larga distancia, existe un punto ciego entre varias cámaras, lo que imposibilita la obtención directa de información sobre la trayectoria del vehículo y supone un riesgo para la seguridad en la gestión del tráfico. La memoria a largo y corto plazo (LSTM) es un tipo especializado de arquitectura de red neuronal recurrente (RNN) que aborda eficazmente los problemas de gradiente evanescente y gradiente explosivo. LSTM incorpora compuertas de entrada, compuertas de olvido y compuertas de salida sobre la estructura básica de la RNN. La arquitectura de LSTM se muestra en la Figura 6.

La red LSTM bidireccional puede considerar simultáneamente la información hacia adelante y hacia atrás de una secuencia, lo que mejora la capacidad de modelado de secuencias. La arquitectura de red de la LSTM bidireccional se ilustra en la Figura 7.

En comparación con las redes LSTM tradicionales, las redes LSTM bidireccionales incorporan una capa LSTM inversa en su estructura. La secuencia de entrada se procesa por separado mediante las capas LSTM directa e inversa, y luego las salidas de ambas capas se concatenan a lo largo de la dimensión temporal. Esto permite que el modelo utilice información tanto anterior como posterior al paso de tiempo actual, lo que posibilita un modelado y predicción de secuencias más completos.

Durante el entrenamiento del modelo de predicción de trayectoria vehicular en el punto ciego basado en LSTM bidireccional, se realiza un preprocesamiento como paso preliminar. Las secuencias de características, compuestas por pasos de tiempo, posiciones laterales y longitudinales de las trayectorias vehiculares, velocidad vehicular, aceleración y otra información, se transforman en matrices. La secuencia de características de cada trayectoria se divide en tres segmentos: los segmentos delantero y trasero se utilizan com

Machine Translated by Google



Las entradas se procesan mediante el segmento central, que sirve como salida esperada. Posteriormente, se entrena el modelo LSTM bidireccional. En cada pasada hacia adelante, se calculan los parámetros ocultos del modelo y se generan predicciones. A continuación, se calcula el error entre las predicciones y el valor real, y este error se utiliza en la pasada hacia atrás.
Los distintos parámetros del modelo se actualizan utilizando el principio de descenso de gradiente para minimizar la función objetivo y completar el proceso de entrenamiento.

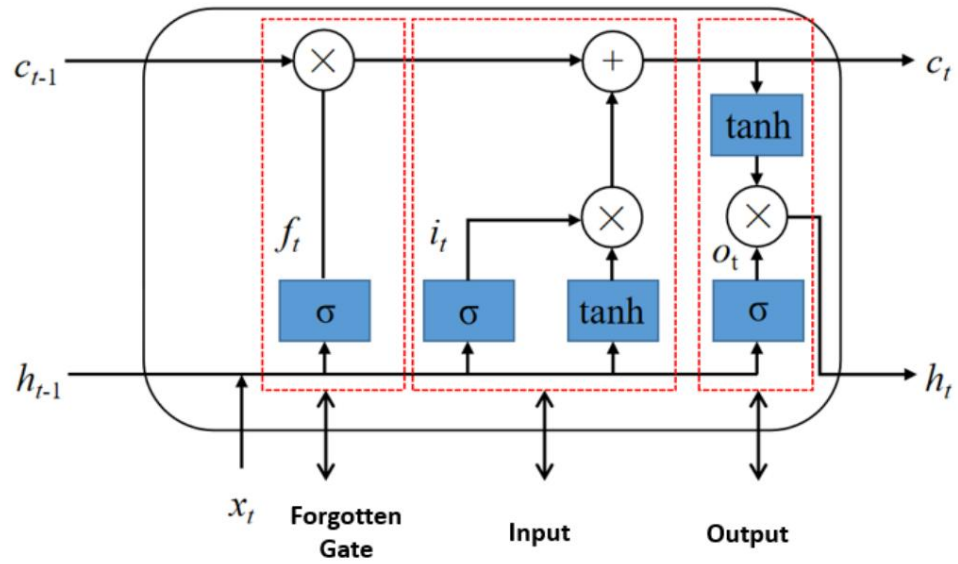



Figura 6. Diagrama de la estructura LSTM. Tres cantidades de entrada: xt es el estado oculto en el momento actual, ht−1 es el estado oculto en el momento anterior y ct−1 es el estado unitario en el momento anterior. Dos cantidades de salida: ht es el estado oculto en el momento actual y ct es el estado unitario en el momento actual.

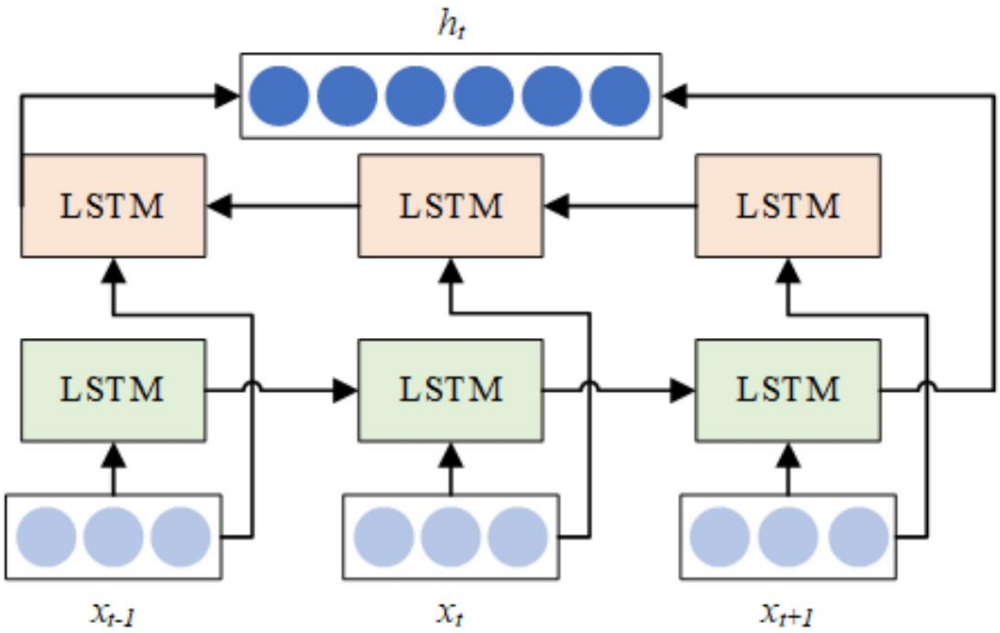



Figura 7. Diagrama de la estructura LSTM bidireccional.

### 3.3.5. Definición de la regla de trayectoria anormal

En este artículo, definimos principalmente cuatro tipos de comportamientos anormales en la trayectoria de los vehículos, que incluyen comportamiento anormal al conducir, velocidad anormal del vehículo, estacionamiento anormal del vehículo y cambio peligroso de carril del vehículo.

Machine Translated by Google



Identificación de la conducción en sentido contrario: Se refiere al comportamiento anormal de un vehículo en el que su dirección real de desplazamiento es opuesta a la dirección prescrita de la carretera.
La determinación del comportamiento de circulación en sentido contrario puede implicar principalmente evaluar tanto la posición como el ángulo del movimiento del vehículo. Para determinar si un vehículo está realizando una circulación en sentido contrario en el fotograma i, primero es necesario determinar si el conjunto de trayectorias de movimiento del vehículo no está vacío. Además, es importante determinar si la cámara de monitoreo está en estado aguas arriba o aguas abajo. Posteriormente, la determinación del comportamiento de circulación en sentido contrario se basa en la recopilación de ángulos de movimiento del vehículo. En el estado aguas abajo, para vehículos de conducción normal, a medida que se alejan de la cámara, las direcciones de las normas de tránsito, el movimiento del vehículo y la dirección positiva del eje y de la calibración de coordenadas son consistentes. El rango de ángulos de movimiento del vehículo es (0, π). Se establece un contador de tasa de fotogramas de circulación en sentido contrario Num, donde un contador aumenta en 1 al detectar un fotograma de circulación en sentido contrario. Cuando Num/ f ≥ 0.2, el vehículo puede clasificarse como realizando una circulación en sentido contrario. Dada la limitada disponibilidad de conjuntos de datos de circulación en sentido contrario, este estudio emplea la configuración opuesta aguas arriba/aguas abajo y utiliza el conjunto de datos normal para detectar el comportamiento en sentido contrario en la dirección opuesta.

Identificación de comportamiento anormal de velocidad vehicular: Se refiere a casos en los que un vehículo no respeta el límite de velocidad establecido, incluyendo tanto el exceso de velocidad como la conducción lenta. Ambos comportamientos representan riesgos significativos para el tráfico en situaciones reales. En el experimento para detectar comportamientos anómalos de velocidad vehicular, dada la diversidad de tipos de vehículos, se aplican distintos umbrales de velocidad permisibles. Por lo tanto, es necesario determinar primero la categoría del vehículo y el carril de circulación, y luego establecer la velocidad mínima "m" y la velocidad máxima "n" permitidas por la carretera. Posteriormente, basándose en el método de cálculo de la velocidad vehicular determinado durante la descripción matemática de las trayectorias vehiculares, se calcula la velocidad vehicular para determinar si existe un comportamiento anómalo de velocidad. Considerando las características de conducción de los vehículos en el escenario de investigación, es improbable que se produzcan cambios bruscos de velocidad vehicular en un breve período. En consecuencia, es improbable que se produzcan simultáneamente anomalías de exceso y lentitud de conducción. Para el cálculo, se calcula el conjunto de velocidades promedio vehiculares "Vk" con k = 10, utilizando el cálculo de la velocidad promedio sobre los últimos 10 fotogramas. Se incrementa un contador en 1 por cada instancia de anomalía de velocidad. Si 5 fotogramas consecutivos muestran anomalías de velocidad, se concluye que el vehículo está realizando un comportamiento anómalo de velocidad.

Identificación de anomalías en el estacionamiento de vehículos: En escenarios de autopista, las velocidades normales de los vehículos son extremadamente altas, lo que hace que el estacionamiento sea muy peligroso. Si bien el estacionamiento es un proceso continuo que implica una reducción gradual de la velocidad y cambios lentos de trayectoria, nos centramos exclusivamente en identificar el resultado final del estacionamiento. El reconocimiento del comportamiento de estacionamiento se logra considerando la condición en la que la posición del vehículo ya no cambia. Establecemos una condición de no cambio de posición durante una secuencia consecutiva de 5 fotogramas. Cuando se supera este umbral de tiempo, se considera que el vehículo se ha estacionado.

Identificación de cambios de carril peligrosos: En el contexto de las autopistas, los cambios de carril peligrosos son comportamientos de conducción altamente riesgosos que suelen provocar accidentes de tráfico graves. La ocurrencia de este tipo de comportamiento generalmente conlleva graves consecuencias.
El reconocimiento basado en reglas de comportamiento peligroso al cambiar de carril se centra principalmente en el ángulo de giro del vehículo durante el trayecto. Detecta principalmente acciones como giros en U y ángulos de giro excesivamente grandes durante los cambios de carril, que tienen una alta probabilidad de generar situaciones peligrosas. Se establece un valor umbral para la pendiente de la trayectoria del vehículo, denotado como "u". Cuando la pendiente supera este umbral, se reconoce que la dirección del vehículo se ha desviado significativamente del eje vertical de coordenadas definido, lo que indica la presencia de un comportamiento peligroso al cambiar de carril. El ángulo de giro máximo durante un cambio de carril generalmente depende de la velocidad y el tipo de vehículo .

Machine Translated by Google



3.4. Funciones de pérdida

El modelo aumenta el vector de características r, que finalmente se utiliza para el vehículo y la pérdida de reidentificación, con la pérdida del triplete $L_{tres}^{r}$ entropía cruzada $L_{IDENTIFICACIÓN}^{r}$. La representación del vector de características r se representa como en la ecuación (8).

$$r = W_r \cdot GR + b_r \quad (8)$$

En la ecuación, GR denota la operación de agrupación promedio global aplicada a la característica compensada, mientras que Wr y br representan los pesos y sesgos de la capa totalmente conectada. Esta sección del modelo de red se entrena minimizando la función de pérdida Lpro. El cálculo de la función de pérdida se muestra en la ecuación (9).

$$L_{pro} = L_{tri}^{r} + L_{___}^{r} + \lambda_R \cdot L_{tri}^{a} \quad (9)$$

donde λR es un hiperparámetro que equilibra la importancia de la pérdida de reidentificación del vehículo compensada y la pérdida relacionada con el atributo.

4. Resultado experimental 4.1.

Construcción de conjuntos de datos para la detección de vehículos

Este estudio crea un conjunto de datos de detección de vehículos específicamente diseñado para escenarios de autopistas, basado en videos de vigilancia de la red vial de la provincia de Shaanxi. El conjunto de datos incluye videos de monitoreo de tráfico capturados por cámaras en diferentes momentos y ubicaciones kilométricas. La información de imagen se extrae de estos videos mediante técnicas de procesamiento de video.

El conjunto de datos abarca vídeos de vigilancia de tráfico capturados por cámaras con distintos números de serie en diferentes momentos, y la información de las imágenes se extrae mediante tecnología de procesamiento de vídeo. A continuación, se utiliza la herramienta de anotación LabelImg para etiquetar los recuadros rectangulares de los vehículos en las imágenes del conjunto de datos, y se anota información como el tipo, la ubicación y el tamaño de los vehículos. En la Figura 8 se muestra un ejemplo del procesamiento de LabelImg, así como un ejemplo del archivo XML generado por la anotación final. De esta forma, se obtiene un conjunto de datos detallado y preciso para la detección de vehículos en autopistas, lo que proporciona un sólido respaldo para el entrenamiento del modelo.




Figura 8. Utilice LabelImg para anotar el tipo, la ubicación y el tamaño del vehículo.

La categorización del conjunto de datos se basa en las diferencias en las formas y tamaños de los vehículos, lo que da como resultado tres categorías principales: automóvil, autobús y camión. Esta categorización, hasta cierto punto, mitiga la complejidad de reconocimiento del modelo. Además, considerando la

Machine Translated by Google



A partir de diferentes escalas de vehículos captados desde distintas perspectivas de vigilancia, cada categoría de vehículos se subdivide en dos direcciones: delantera y trasera. La designación «F» se utiliza para los vehículos que se encuentran en la dirección delantera, mientras que la «B» se utiliza para los que se encuentran en la dirección trasera. En consecuencia, los vehículos que circulan dentro del área de estudio se clasifican en un total de seis categorías, como se ilustra en la Figura 9. Para mantener el equilibrio de las categorías de datos, el número de imágenes en cada categoría es de 500.




Figura 9. Los vehículos se dividen en tres categorías: automóviles, autobuses y camiones, y cada categoría incluye dos direcciones de desplazamiento.

### 4.2. Detección y seguimiento de vehículos

La figura 10 muestra ejemplos de seguimiento de vehículos en videos de vigilancia grabados por una cámara en una autopista de la provincia de Shaanxi. En estos ejemplos, el video de vigilancia tiene una velocidad de fotogramas de 25 fotogramas por segundo, y la parte inferior central del recuadro de seguimiento contiene la identificación única del vehículo rastreado.




(a) Marco 856




(b) Marco 876

Figura 10. Ejemplo del efecto de seguimiento de vehículos en escenas reales.

Machine Translated by Google



El modelo asigna identificadores en función del momento en que se detecta un vehículo por primera vez. Las cuatro imágenes mostradas se tomaron con un intervalo de 80 fotogramas, cubriendo la mayoría de los momentos en que los vehículos se encuentran dentro del campo de visión de la cámara. A partir de los ejemplos de seguimiento, se observa que el modelo mejorado de seguimiento de múltiples vehículos DeepSORT demuestra un rendimiento eficaz, siguiendo y reconociendo con precisión varios vehículos.

### 4.3. Reidentificación de vehículos basada en características

de imagen En este capítulo, realizamos experimentos utilizando el conjunto de datos de reidentificación de la autopista de circunvalación de Xi'an, que se estableció en la autopista de circunvalación de Xi'an en la provincia de Shaanxi. El propósito de estos experimentos fue evaluar la robustez del modelo mejorado de reidentificación de vehículos desarrollado en este artículo.

En el conjunto de datos, recopilamos grabaciones de video continuas capturadas a diferentes intervalos de tiempo a lo largo de varios puntos kilométricos de la autopista. Los segmentos seleccionados no tienen entradas ni salidas. Se capturaron un total de 100 vehículos desde diferentes perspectivas, con puntos kilométricos ubicados en K32 + 900, K33 + 700 y K34 + 600 en dirección ascendente; y en K51 + 610, K51 + 400, K51 + 000 y K50 + 300 en dirección descendente. Un ejemplo se ilustra en la Figura 11.

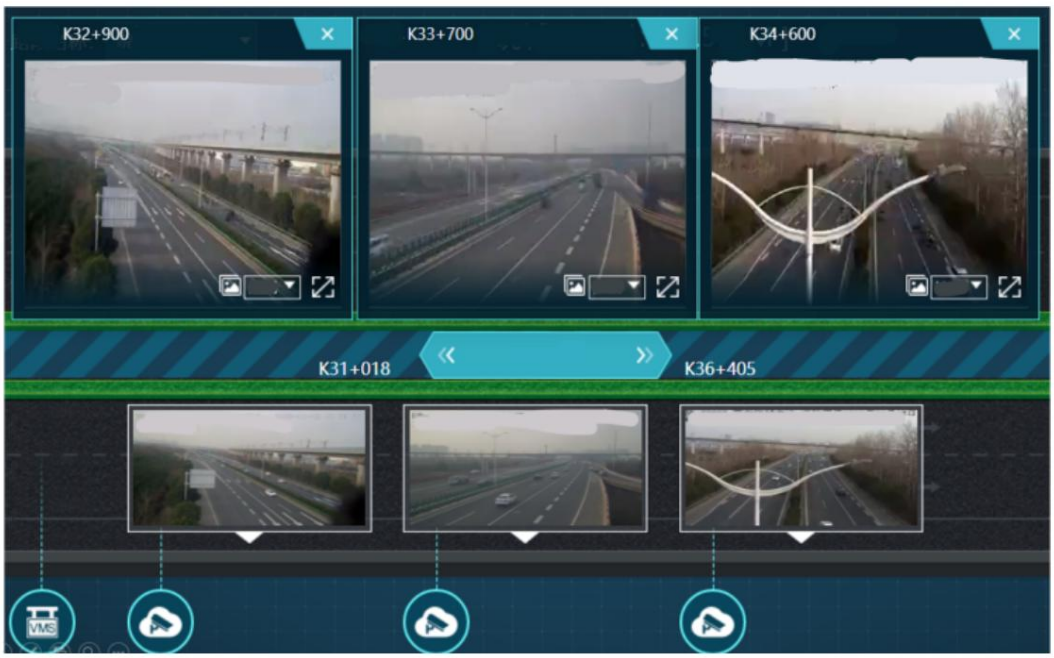



Figura 11. Diagrama esquemático de la trayectoria del comportamiento del vehículo.

Los algoritmos comparativos seleccionados para la evaluación incluyeron modelos que tuvieron un buen desempeño en el conjunto de datos público VeRi-776, a saber: el modelo StRDAN que utiliza métodos basados en atributos [32], el modelo VAnet basado en puntos de vista [33], el modelo PRND basado en componentes del vehículo [34], el modelo SAVER que utiliza GAN [35] y el modelo HPGN basado en redes de grafos [36]. Las curvas de Característica de Coincidencia Acumulativa (CMC) de los resultados experimentales se muestran en la Figura 12.

A partir de los resultados mostrados en la Figura 12, resulta evidente que el modelo de reidentificación de vehículos diseñado en este capítulo, basado en información de atributos mejorada, supera a los modelos que utilizan diferentes métodos de reidentificación. Además, los resultados experimentales indican que el modelo de reidentificación de vehículos basado en información de atributos presenta un rendimiento robusto, lo que lo hace idóneo para la tarea de reidentificar vehículos en diferentes cámaras de la autopista de circunvalación de Xi'an.

Machine Translated by Google



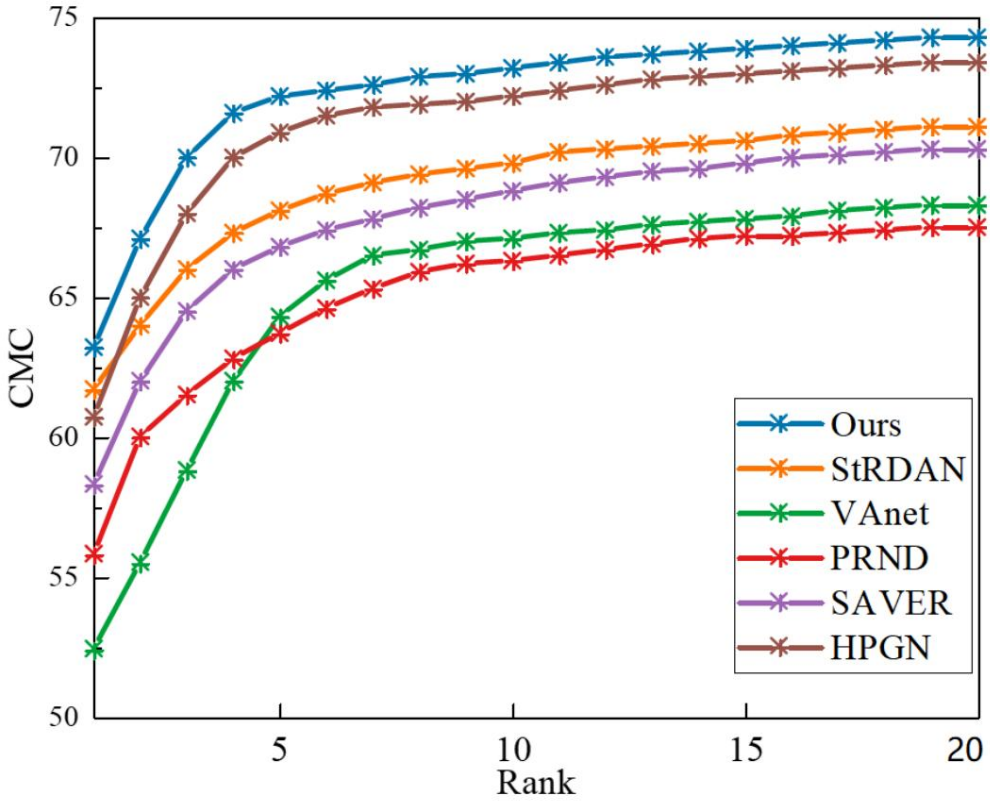



Figura 12. Curvas de características de ajuste acumulativo (CMC) de diferentes modelos.

4.4. Reconocimiento de trayectorias anómalas basado en reglas de trayectoria

En el conjunto de prueba, las trayectorias de los vehículos se seleccionaron entre cámaras adyacentes que tenían se sometieron a reidentificación para extraer trayectorias del mismo ID. Las trayectorias fueron agrupados en función de la predicción y validación de las longitudes traseras de 1/2, 1/3, 1/4 y 1/5 de trayectorias desde la cámara anterior con longitudes correspondientes de la parte frontal de trayectorias desde la cámara actual. Los resultados de la comparación de errores se presentan en la Tabla 2.

Tabla 2. Resultados de la comparación del RMSE para los experimentos de predicción de trayectorias.

| Proporción de trayectoria prevista 1/2 | | 1/3 | 1/4 | 1/5 |
|---|---|---|---|---|
| RMSE transversal (m) | 0,56 | 0,45 | 0,36 | 0,31 |
| DirecciónRMSE (m) | 1,84 | 1.23 | 0,81 | 0,56 |

Del análisis del error de validación en la Tabla 2, se puede observar que a medida que la predicción Aumenta la distancia, tanto el error cuadrático medio lateral como el error cuadrático medio vertical. Los errores siguen aumentando. Sin embargo, el error cuadrático medio vertical es mayor en comparación con el error cuadrático medio de raíz lateral, atribuido a la menor proporción de distancia vertical resolución en coordenadas de píxeles. En general, el modelo LSTM bidireccional funciona bien en predicción de trayectorias de vehículos, con un error cuadrático medio lateral de solo 0,56 m y una error cuadrático medio vertical de 1,84 m cuando se predice la mitad de la trayectoria en ambos Direcciones hacia adelante y hacia atrás. Los errores entre las predicciones del modelo y los datos reales. Los valores son relativamente pequeños.

Para mejorar aún más el seguimiento de vehículos en el contexto de este estudio, el vehículo de punto ciego Se utilizó un modelo de predicción de trayectoria basado en LSTM bidireccional para la concatenación y predicción de trayectorias entre cámaras adyacentes. Este enfoque tenía como objetivo obtener una predicción completa. Trayectorias de desplazamiento de vehículos bajo cámaras adyacentes. Utilizando la autopista de circunvalación de Xi'an como el escenario de aplicación, con un espaciado de cámaras de 450 m y una longitud de trayectoria efectiva de aproximadamente 200 m por cámara, la longitud de trayectoria prevista necesaria para los ciegos

Machine Translated by Google



El punto estaba a unos 250 m, lo que representa aproximadamente el 38,5% del total concatenado.
trayectoria. Antes de la concatenación, se aplicó una reducción de ruido a los puntos de la trayectoria del vehículo.
eliminando puntos con fluctuaciones significativas en los datos de posición. El resultado completo
La trayectoria del vehículo después de la concatenación se ilustra en la Figura 13.

En la Figura 13, los resultados de predicción y concatenación de trayectorias para dos vehículos son:
mostrado. A partir de los resultados generales de predicción de trayectoria, las trayectorias predichas se alinean
bien con el comportamiento de conducción real de los vehículos. Sin embargo, debido a las fluctuaciones en el
Las cajas de seguimiento de vehículos obtenidas, las trayectorias predichas también exhiben cierto grado
de fluctuación. No obstante, la tendencia general se mantiene consistente con el vehículo normal.
comportamiento de conducción. Esto indica que el modelo de predicción de trayectoria es capaz de hacerlo de manera efectiva.
Gestiona el ruido y las fluctuaciones, demostrando un rendimiento predictivo favorable.

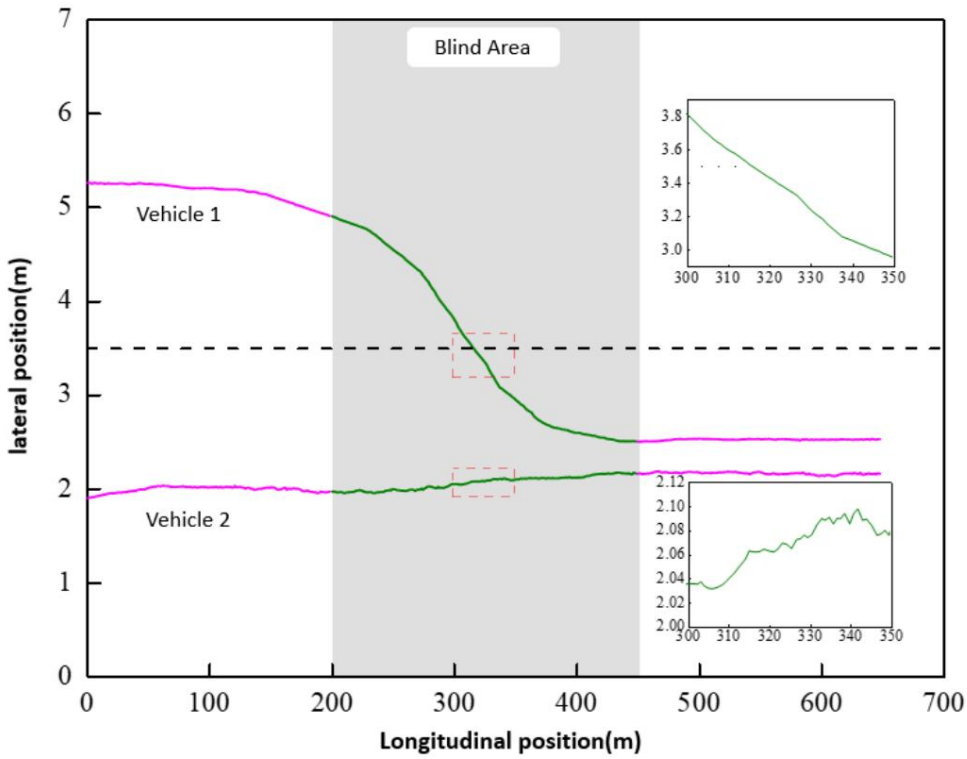



Figura 13. Diagrama esquemático de la trayectoria del comportamiento del vehículo.

En la Tabla 3, evaluamos cuantitativamente el rendimiento del método en este artículo sobre
reconocimiento de comportamiento de conducción incorrecto. Se puede ver que el método de este artículo correctamente
identifica el comportamiento retrógrado en casi todos los datos de vídeo.

Tabla 3. Estadísticas de los resultados del reconocimiento del comportamiento retrógrado del vehículo.

| Video | Trayectoria del vehículo (barra) | Correcto | Detección fallida | Detección falsa |
|---|---|---|---|---|
| 1 | 146 | 146 | 0 | 0 |
| 2 | 90 | 90 | 0 | 0 |
| 3 | 117 | 117 | 0 | 0 |
| 4 | 125 | 123 | 2 | 0 |

De manera similar, evaluamos cuantitativamente el rendimiento de nuestro método en la anomalía de velocidad.
reconocimiento. Los resultados experimentales se presentan en las Tablas 4 y 5. Esto demuestra que
La metodología de este artículo tiene un rendimiento superior.

Machine Translated by Google



Tabla 4. Estadísticas de los resultados de la identificación del comportamiento de exceso de velocidad de los vehículos.

| Trayectoria del vehículo en vídeo (barra) | Comportamientos | Detección fallida | correcta | Detección falsa |
|---|---|---|---|---|
| | 320 | 14 | 14 | 0 | 1 |
| 1 2 | 443 | 20 | 19 | 1 | 2 |
| 3 | 461 | 25 | 25 | 0 | 1 |
| 4 | 112 | 8 | 8 | 0 | 0 |

Tabla 5. Estadísticas de los resultados de reconocimiento del comportamiento de vehículos lentos.

| Trayectoria del vehículo en vídeo (barra) | Comportamientos | Detección fallida | correcta | Detección falsa |
|---|---|---|---|---|
| 1 | 320 | 3 | 3 | 0 | 0 |
| 2 | 443 | 4 | 4 | 0 | 1 |
| 3 | 461 | 3 | 1 | 2 | 0 |
| 4 | 112 | 1 | 1 | 0 | 1 |

De la misma manera, los resultados experimentales para identificar el comportamiento de estacionamiento de los vehículos se presentan en la Tabla 6 y para identificar comportamientos peligrosos de cambio de carril de los vehículos se presentan en la Tabla 7. Además de esto, demostramos cualitativamente el efecto de detección anómala de vehículos en un escenario real en la Figura 14. Es evidente que el método en Este artículo presenta un rendimiento excelente ante múltiples anomalías en la trayectoria del vehículo.

Tabla 6. Estadísticas de los resultados del reconocimiento del comportamiento de estacionamiento de vehículos.

| Trayectoria del vehículo en vídeo (barra) | Comportamientos | Detección fallida | correcta | Detección falsa |
|---|---|---|---|---|
| 1 | 420 | 0 | 0 | 0 | 0 |
| 2 | 628 | 1 | 1 | 0 | 1 |
| 3 | 545 | 0 | 0 | 0 | 2 |
| 4 | 112 | 0 | 0 | 0 | 0 |

Tabla 7. Estadísticas de los resultados de reconocimiento del comportamiento peligroso de cambio de carril de los vehículos.

| Trayectoria del vehículo en vídeo (barra) | Comportamientos | Detección fallida | correcta | Detección falsa |
|---|---|---|---|---|
| 1 | 135 | 8 | 7 | 1 | 0 |
| 2 | 336 | 12 | 10 | 2 | 3 |
| 3 | 143 | 5 | 5 | 0 | 2 |
| 4 | 106 | 6 | 5 | 1 | 1 |

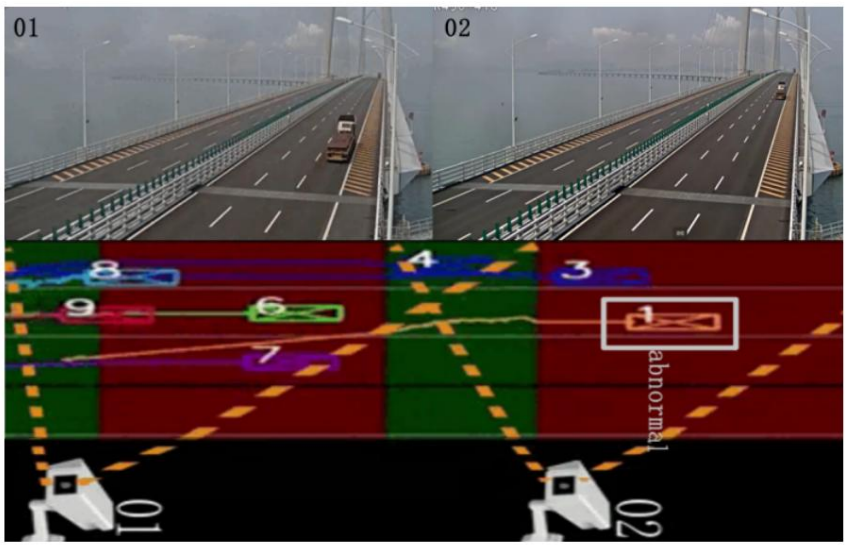



Figura 14. Vista real de la detección de vehículos anómalos.

Machine Translated by Google



## 5. Debate

Para estudiar la tecnología de seguimiento de vehículos en autopistas, el modelo utilizado en este artículo funciona bien en términos de tiempo real, precisión y robustez, y ha logrado resultados de investigación preliminares. Sin embargo, al tratar con algunos escenarios con condiciones de tráfico complejas o un amplio rango de monitoreo, la aplicación de estos modelos requiere una investigación más profunda. Específicamente, este artículo propone los siguientes tres aspectos de mejora y perfeccionamiento: 1.

Los datos de video de vigilancia de alta velocidad utilizados en este artículo no son perfectos, especialmente faltan los datos de vehículos para entrenar el modelo de reidentificación de vehículos en el escenario de estudio. Esto limita la combinación de la red de apariencia profunda para el seguimiento de objetos y la red de extracción de características para la reidentificación de vehículos, lo que aumenta la complejidad del modelo en cierta medida. Por lo tanto, el trabajo futuro recopilará más información de datos relevantes para mejorar el modelo y su rendimiento de generalización.

2. Si bien el método de reidentificación de vehículos basado en información de atributos no requiere considerar factores externos como la coincidencia de información espacio-temporal, y solo necesita centrarse en la extracción de los atributos del vehículo en sí, la detección del comportamiento vehicular basada en reglas de trayectoria separa la relación entre el vehículo y el entorno circundante y otros vehículos al realizar el análisis de extracción de trayectoria y el reconocimiento de comportamiento vehicular anómalo. Por lo tanto, en la investigación posterior, se considerará la adición de información espacio-temporal de los vehículos y se utilizará el método de aprendizaje profundo para agrupar y analizar la trayectoria vehicular con el fin de considerar de manera integral el comportamiento de conducción de
3. En este trabajo, la tarea general de seguimiento de vehículos en autopistas se divide en tres subtareas : detección, seguimiento y reidentificación de vehículos. La trayectoria del vehículo se procesa según los resultados del seguimiento. El resultado de la primera tarea se utiliza como entrada para la segunda, lo que hace que la construcción del modelo y la implementación de la función sean algo laboriosas. Por lo tanto, en investigaciones posteriores, intentaremos construir un modelo integrado, fusionar varios modelos, simplificar la estructura del modelo, mejorar la conveniencia y la eficiencia del seguimiento de vehículos y lograr un seguimiento global de los vehículos en autopistas, así como un sistematizado e inteligente

## 6. Conclusiones

Este artículo propone un marco eficaz para el reconocimiento de trayectorias vehiculares en autopistas de ultralarga distancia y diseña una arquitectura de red basada en DeepSORT y YOLOv5s para el seguimiento eficiente de múltiples vehículos, obteniendo rápidamente trayectorias dentro del área visible. También proponemos un módulo de reconocimiento de atributos para implementar eficazmente la reidentificación vehicular, combinar correctamente las trayectorias del mismo vehículo en diferentes segmentos de carretera y, finalmente, restaurar la trayectoria completa del vehículo. Además, para resolver el problema de un cierto rango de puntos ciegos entre los campos de visión de cámaras adyacentes en escenarios de carreteras de ultralarga distancia, se introduce una estructura LSTM bidireccional en nuestro marco para predecir la trayectoria de los puntos ciegos. Este estudio logra la combinación y reconstrucción de trayectorias de movimiento vehicular en toda el área, lo que facilita la identificación efectiva de trayectorias anómalas. A juzgar por la curva de Característica de Coincidencia Acumulativa (CMC), el modelo propuesto presenta grandes ventajas e incluso mejora en más del 15,38 % en comparación con otros métodos de vanguardia. Los resultados experimentales demuestran la eficacia de este método para identificar con precisión diversos comportamientos de los vehículos, incluidos los cambios de carril, el estacionamiento e incluso otros comportamientos de conducción pe

Contribuciones de los autores: Conceptualización, LZ; Metodología, LZ y ZF; Redacción del borrador original, JY; Revisión y edición, JY, ZZ y PW; Software, LZ; Supervisión, JY. Todos los autores han leído y aprobado la versión publicada del manuscrito.

Machine Translated by Google



Financiación: Este trabajo fue financiado por el Proyecto de Investigación Científica del Departamento de Transporte de la Provincia de Shaanxi (n.º 21-42X) y el Programa de Apoyo a la Capacidad de Innovación de Shaanxi (Programa n.º 2022TD-16).

Declaración del Comité de Ética Institucional: No aplica.

Declaración de consentimiento informado: No aplicable.

Declaración de disponibilidad de datos: El conjunto de datos está disponible previa solicitud a los autores. Los datos brutos que respaldan las conclusiones de este artículo estarán disponibles a solicitud de los autores.

Conflictos de intereses: Los autores Liguo Zhao y Zhipeng Fu trabajaban para la empresa CCCC First Highway Consultants Co., Ltd., en Xi'an, China. Los demás autores declaran que la investigación se llevó a cabo sin que existiera ninguna relación comercial o financiera que pudiera considerarse un posible conflicto de intereses.

## Referencias

1. Moshayedi, AJ; Uddin, NMI; Khan, AS; Zhu, J.; Emadi Andani, M. Diseño y desarrollo de un sistema basado en visión para investigar los efectos emocionales de las noticias en la falta de sueño al mediodía: un estudio de caso experimental. Sensors 2023, 23, 8422. [CrossRef] [PubMed]
2. Moshayedi, AJ; Khan, AS; Yang, S.; Zanjani, SM. Reconocedor de defectos en tuberías (HPD) basado en un clasificador de imágenes personales: diseño y prueba. En Actas de la 7.ª Conferencia Internacional sobre Computación Inteligente y Procesamiento de Señales (ICSP) de 2022, Xi'an, China, 15-17 de abril de 2022; págs. 1721-1728. [CrossRef]
3. Chen, H.; Liu, Y.; Zhao, B.; Hu, C.; Zhang, X. Predicción de trayectorias en tiempo real de participantes vulnerables en el tráfico basada en visión. para Vehículos Autónomos. IEEE Trans. Intell. Veh. 2023, 8, 2110–2122. [CrossRef]
4. Qi, X.; Zhang, L.; Wang, P.; Yang, J.; Zou, T.; Liu, W. MPC basado en aprendizaje para la planificación de movimiento autónomo en la divergencia de la salida de la autopista. IEEE Trans. Intell. Veh. 2024, 1–11. [CrossRef]
5. Liu, C.; Huynh, DQ; Sun, Y.; Reynolds, M.; Atkinson, S. Un sistema basado en visión para el conteo de vehículos, la estimación de velocidad y la clasificación. IEEE Trans. Intell. Transp. Syst. 2021, 22, 7547–7560. [CrossRef]
6. Tang, X.; Zhang, Z.; Qin, Y. Detección y seguimiento de objetos en carretera basados en la fusión de radar y visión: una revisión. IEEE Intell. Transp. Syst. Mag. 2022, 14, 103–128. [CrossRef]
7. Gao, H.; Qin, Y.; Hu, C.; Liu, Y.; Li, K. Un modelo múltiple interactivo para la predicción de trayectorias de vehículos inteligentes en condiciones típicas. Escenario de tráfico rodado. IEEE Trans. Neural Netw. Learn. Syst. 2023, 34, 6468–6479. [CrossRef] [PubMed]
8. Wojke, N.; Bewley, A.; Paulus, D. Seguimiento simple en línea y en tiempo real con una métrica de asociación profunda. En Actas de la Conferencia Internacional IEEE de Procesamiento de Imágenes (ICIP) de 2017, Pekín, China, 17-20 de septiembre de 2017; págs. 3645-3649. [CrossRef]
9. Girshick, R.; Donahue, J.; Darrell, T.; Malik, J. Jerarquías de características enriquecidas para la detección precisa de objetos y la segmentación semántica. En Actas de la Conferencia IEEE sobre Visión por Computadora y Reconocimiento de Patrones, Columbus, OH, EE. UU., 23-28 de junio de 2014; págs. 580-587.
10. Girshick, R. Fast R-CNN. En Actas de la Conferencia Internacional IEEE de Visión por Computadora (ICCV) de 2015, Santiago, Chile, 7–13 de diciembre de 2015; págs. 1440–1448. [CrossRef]
11. Ren, S.; He, K.; Girshick, R.; Sun, J. Faster R-CNN: Hacia la detección de objetos en tiempo real con redes de propuesta de regiones. IEEE Trans. Pattern Anal. Mach. Intell. 2017, 39, 1137–1149. [CrossRef] [PubMed]
12. Wang, CY; Yeh, IH; Liao, HYM YOLOv9: Aprender lo que se quiere aprender utilizando información de gradiente programable. arXiv 2024, arXiv:2402.13616.
13. Liu, W.; Anguelov, D.; Erhan, D.; Szegedy, C.; Reed, S.; Fu, CY; Berg, AC SSD: Detector MultiBox de una sola toma. En Visión por computadora—ECCV 2016; Leibe, B.; Matas, J.; Sebe, N.; Welling, M., Eds.; Notas de clase en ciencias de la computación; Springer: Cham, Suiza, 2016; pp. 21–37. [CrossRef]
14. Lin, TY; Goyal, P.; Girshick, R.; He, K.; Dollár, P. Pérdida focal para la detección densa de objetos. En Actas de la Conferencia Internacional IEEE sobre Visión por Computadora, Venecia, Italia, 22-29 de octubre de 2017; págs. 2980-2988.
15. Guo, Y.; Wang, H.; Hu, Q.; Liu, H.; Liu, L.; Bennamoun, M. Aprendizaje profundo para nubes de puntos 3D: una revisión. IEEE Trans. Pattern Anal. Mach. Intell. 2021, 43, 4338–4364. [CrossRef] [PubMed]
16. Simon, M.; Milz, S.; Amende, K.; Gross, HM Complex-YOLO: Detección de objetos 3D en tiempo real en nubes de puntos. arXiv 2018, arXiv:1803.06199. https://doi.org/10.48550/arXiv.1803.06199.
17. Bewley, A.; Ge, Z.; Ott, L.; Ramos, F.; Upcroft, B. Seguimiento simple en línea y en tiempo real. En Actas de la Conferencia Internacional IEEE de Procesamiento de Imágenes (ICIP) de 2016, Phoenix, AZ, EE. UU., 25-28 de septiembre de 2016; págs. 3464-3468. [CrossRef]
18. Fu, X.; Peng, J.; Jiang, G.; Wang, H. Aprendizaje de características latentes con red de caída de canal local para la reidentificación de vehículos. Ing. Aplica. Artif. Intel. 2022, 107, 104540. [Referencia cruzada]
19. Liu, Y.; Zhang, X.; Zhang, B.; Zhang, X.; Wang, S.; Xu, J. Seguimiento de vehículos con múltiples cámaras basado en información entre vehículos y con detección de oclusiones. En Actas de la Conferencia IEEE/CVF sobre Visión por Computadora y Reconocimiento de Patrones, Nueva Orleans, LA, EE. UU., 18-24 de junio de 2022; págs. 3257-3264.

Machine Translated by Google



20. Zhu, W.; Wang, Z.; Wang, X.; Hu, R.; Liu, H.; Liu, C.; Wang, C.; Li, D. Un mecanismo de autoatención dual para la reidentificación de vehículos . Pattern Recognit. 2023, 137, 109258. [CrossRef]
21. Lian, J.; Wang, D.; Zhu, S.; Wu, Y.; Li, C. Red de atención basada en transformadores para la reidentificación de vehículos. Electronics 2022, 11, 1016. [CrossRef]
22. Bashir, RMS; Shahzad, M.; Fraz, MM VR-PROUD: Reidentificación de vehículos mediante arquitectura profunda no supervisada progresiva ture. Pattern Recognit. 2019, 90, 52–65. [CrossRef]
23. Shen, F.; Du, X.; Zhang, L.; Shu, X.; Tang, J. Aprendizaje de representación contrastiva de tripletes para la reidentificación no supervisada de vehículos. arXiv 2023, arXiv:2301.09498. https://doi.org/10.48550/arXiv.2301.09498.
24. Chai, X.; Wang, Y.; Chen, X.; Gan, Z.; Zhang, Y. TPE-GAN: Cifrado que preserva la miniatura basado en GAN con clave. IEEE Signal Process. Lett. 2022, 29, 972–976. [CrossRef]
25. Wu, Y.; Lin, Y.; Dong, X.; Yan, Y.; Ouyang, W.; Yang, Y. Explotar lo desconocido gradualmente: reidentificación de personas basada en vídeo de una sola toma mediante aprendizaje por etapas. En Actas de la Conferencia IEEE sobre Visión por Computadora y Reconocimiento de Patrones, Salt Lake City, UT, EE. UU., 18-23 de junio de 2018; págs. 5177-5186.
26. Yan, X.; Xue, Q.; Ma, L.; Xu, Y. Prueba basada en simulador de conducción sobre la eficacia del sistema de advertencia auditiva de vehículos que se saltan un semáforo en rojo basado en un sensor de tiempo hasta la colisión. Sensors 2014, 14, 3631–3651. [CrossRef] [PubMed]
27. Bao, J.; Liu, P.; Qin, X.; Zhou, H. Comprensión de los efectos de los patrones de viaje en los accidentes espacialmente agregados a gran escala Taxi GPS Data. Accid. Anal. Prev. 2018, 120, 281–294. [CrossRef] [PubMed]
28. Chen, Jn; Zhang, X.; Zhang, Sr; Jin, YI Análisis comparativo de métodos de evaluación de parámetros en el tiempo de viaje en autopistas Fiabilidad. J. Highw. Transp. Res. Dev. (Ed. en inglés) 2017, 11, 93–99. [CrossRef]
29. Huang, H.; Chang, F.; Zhou, H.; Lee, J. Modelado de la heterogeneidad no observada para las frecuencias de accidentes zonales: un modelo bayesiano multivariado de parámetros aleatorios con componentes de mezcla para datos espacialmente correlacionados. Anal. Methods Accid. Res. 2019, 24, 100105. [CrossRef]
30. Lin, Y.; Zheng, L.; Zheng, Z.; Wu, Y.; Hu, Z.; Yan, J.; Yang, Y. Mejora de la reidentificación de personas mediante el aprendizaje de identidad y atributos. Reconocimiento de patrones. 2019, 95, 151-161. [Referencia cruzada]
31. Quispe, R.; Lan, C.; Zeng, W.; Pedrini, H. AttributeNet: Reidentificación de vehículos mejorada con atributos. Neurocomputing 2021, 465, 84–92. [CrossRef]
32. Lee, S.; Park, E.; Yi, H.; Lee, SH StRDAN: Red de adaptación de dominio sintético a real para la reidentificación de vehículos. En Actas de la Conferencia IEEE/CVF sobre Talleres de Visión por Computadora y Reconocimiento de Patrones, Seattle, WA, EE. UU., 14-19 de junio de 2020; págs. 608-609.
33. Chu, R.; Sun, Y.; Li, Y.; Liu, Z.; Zhang, C.; Wei, Y. Reidentificación de vehículos con aprendizaje métrico sensible al punto de vista. En Actas de la Conferencia Internacional IEEE/CVF sobre Visión por Computadora, Seúl, República de Corea, 27 de octubre-2 de noviembre de 2019; págs. 8282-8291.
34. He, B.; Li, J.; Zhao, Y.; Tian, Y. Reidentificación de vehículos casi duplicados con regularización parcial. En Actas de la Conferencia IEEE/CVF sobre Visión por Computadora y Reconocimiento de Patrones, Long Beach, CA, EE. UU., 15-20 de junio de 2019; págs. 3997-4005.
35. Khorramshahi, P.; Peri, N.; Chen, Jc; Chellappa, R. El diablo está en los detalles: Atención autosupervisada para la reidentificación de vehículos . En Visión por computadora—ECCV 2020; Vedaldi, A., Bischof, H., Brox, T., Frahm, JM, Eds.; Notas de clase en ciencias de la computación; Springer: Cham, Suiza, 2020; pp. 369–386. [CrossRef]
36. Shen, F.; Zhu, J.; Zhu, X.; Xie, Y.; Huang, J. Exploración de la significancia espacial mediante una red piramidal híbrida de grafos para la reidentificación de vehículos. IEEE Trans. Intell. Transp. Syst. 2022, 23, 8793–8804. [CrossRef]

Aviso legal/Nota del editor: Las declaraciones, opiniones y datos contenidos en todas las publicaciones son responsabilidad exclusiva de sus autores y colaboradores, y no de MDPI ni de sus editores. MDPI y sus editores no se responsabilizan de los daños a personas o bienes que pudieran derivarse de las ideas, métodos, instrucciones o productos mencionados en el contenido.