Machine Translated by Google

Detección multiescala de trayectorias espaciotemporales anómalas en conjuntos de datos de trayectorias en evolución.

Chenhao Wang,
Universidad de Ciencia y Tecnología Electrónica de China,
Chengdu, China.
chwang@std.uestc.edu.cn

Lisi Chen,
Universidad de Ciencia y Tecnología Electrónica de China,
Chengdu, China,
lchen012@e.ntu.edu.sg

Shuo Shang
Universidad de Ciencia y Tecnología Electrónica de China,
Chengdu, China
jedi.shang@gmail.com

Christian S. Jensen
Universidad de Aalborg Aalborg,
Dinamarca csj@cs.aau.dk

Panos Kalnis,
Universidad Rey Abdullah de Ciencia y Tecnología,
Thuwal, Arabia Saudita,
panos.kalnis@kaust.edu.sa

ABSTRACTO

Una trayectoria es una secuencia de puntos con marca de tiempo que registra el movimiento de un objeto, como un vehículo. Estas trayectorias codifican patrones espaciales y temporales complejos y proporcionan información valiosa sobre la movilidad del objeto y las infraestructuras subyacentes , generalmente redes viales, dentro de las cuales se producen los movimientos. Un conjunto de datos de trayectorias evoluciona a medida que se incorporan nuevas trayectorias de forma continua. La capacidad de detectar trayectorias anómalas en tiempo real en este contexto es una funcionalidad fundamental y compleja con numerosas aplicaciones, como los servicios basados en la ubicación. Las soluciones de vanguardia determinan las anomalías basándose en la forma o la ruta de las trayectorias, ignorando las posibles anomalías causadas por diferentes frecuencias de muestreo o desfases temporales. Proponemos un modelo multiescala, denominado MST-OATD, para la detección de trayectorias anómalas en tiempo real que considera tanto los aspectos espaciales como temporales de las trayectorias.

Las capacidades multiescala del modelo permiten extraer características de trayectorias a múltiples escalas. Además, para mejorar la capacidad de evolución del modelo y adaptarse a los cambios en los patrones de trayectoria, incorpora un modelo de clasificación basado en aprendizaje automático que actualiza el conjunto de entrenamiento a medida que se incluyen nuevas trayectorias. Los experimentos realizados con conjuntos de datos reales demuestran que el modelo supera a las soluciones más avanzadas y es capaz de detectar anomalías en tiempo real. Además, el modelo de clasificación aprendido logra resultados prometedores al actualizar el conjunto de entrenamiento con trayectorias recién llegadas.

CONCEPTOS DE CCS

• Sistemas de información → Sistemas espacio-temporales; • Metodologías de computación → Inteligencia artificial.

PALABRAS CLAVE

Detección de trayectorias anómalas, espaciotemporal, conjuntos de datos en evolución

Formato de referencia ACM:

Chenhao Wang, Lisi Chen, Shuo Shang, Christian S. Jensen y Panos Kalnis. 2024. Detección multiescala de trayectorias espaciotemporales anómalas en conjuntos de datos de trayectorias en evolución. En Actas de la 30.ª Conferencia ACM SIGKDD sobre Descubrimiento de Conocimiento y Minería de Datos (KDD '24), 25-29 de agosto de 2024, Barcelona, España. ACM, Nueva York, NY, EE. UU., 11 páginas. https://doi.org/10.1145/3637528.3671874

1. INTRODUCCIÓN

Con la difusión de las tecnologías de computación móvil y geoposicionamiento , se están recopilando trayectorias espaciales de objetos en movimiento (por ejemplo, vehículos o peatones) a una escala sin precedentes [23 Estas trayectorias, en forma de secuencias de ubicaciones con marca de tiempo , capturan información de movimiento detallada y alimentan una variedad de aplicaciones de computación urbana, como la minería de patrones de movimiento [31, 32], el control del flujo de tráfico [19, 30], la exploración de eventos locales [9, 26] y otras aplicaciones de computación urbana.

Dada la rica información de movimiento, la detección de trayectorias anómalas tiene aplicaciones importantes en servicios basados en la ubicación. Por ejemplo, las trayectorias anómalas pueden revelar comportamientos de conducción anormales . En plataformas de taxis en línea, detectar dicho comportamiento puede ayudar a evitar que los pasajeros paguen de más debido a desvíos innecesarios [3, 15]. Como otro ejemplo, la detección de trayectorias anómalas puede ayudar a detectar y predecir eventos como accidentes y congestión en redes de carreteras [18, 27], proporcionando así soporte técnico y base para proveedores de servicios basados en la ubicación como navegación en línea y mapas inteligentes. La detección de trayectorias anómalas se refiere al proceso de identificar trayectorias que exhiben desviaciones significativas de las trayectorias normales. Una trayectoria se considera anómala si no sigue una ruta normal [24, 29]. Considere el ejemplo de la Figura 1, donde tenemos un conjunto de trayectorias entre un origen y un destino. Para los fines del ejemplo, asumimos que la trayectoria 1 (roja) es una trayectoria normal, mientras que la trayectoria 2 (azul) es anómala ya que su ruta se desvía significativamente de la de

1.

Si bien la detección de trayectorias anómalas ha atraído a sub-

A pesar de la considerable atención prestada, aún quedan dos desafíos clave por abordar:

Autor correspondiente.

Se concede permiso para realizar copias digitales o impresas de la totalidad o parte de esta obra para uso personal o en el aula, sin coste alguno, siempre que dichas copias no se realicen ni distribuyan con fines de lucro o ventaja comercial y que incluyan este aviso y la cita completa en la primera página. Los derechos de autor de los componentes de esta obra que pertenezcan a terceros deben respetarse. Se permite la elaboración de resúmenes con la debida atribución. Para cualquier otro tipo de copia, republicación, publicación en servidores o redistribución a listas, se requiere autorización previa específica y/o el pago de una tarifa. Solicite los permisos a permissions@acm.org.

KDD '24, del 25 al 29 de agosto de 2024, Barcelona, España

© 2024 Derechos de autor reservados por el/los propietario/s/autor/es. Los derechos de publicación se ceden a ACM.

ACM ISBN 979-8-4007-0490-1/24/08 https://
doi.org/10.1145/3637528.3671874

Machine Translated by Google

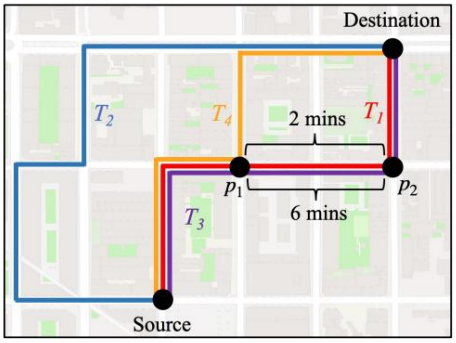


Figura 1: Ilustración de anomalías espacio-temporales. 3 y 4 son trayectorias desde la misma fuente hasta la misma destino.

(1) Incapacidad para detectar anomalías espaciotemporales. La mayoría de los métodos de detección existentes [2, 13, 15, 16, 20, 24, 28, 29] se centran principalmente en detectar trayectorias espacialmente anómalas. Estos métodos consideran que una trayectoria es anómala si se desvía de la ruta tomada por la mayoría de las demás trayectorias. Estos métodos no toman en cuenta las diferencias temporales entre trayectorias que siguen la misma ruta. Sin embargo, poder detectar anomalías temporales también tiene usos importantes y no debe ignorarse. Considérese la Figura 1. La trayectoria 3 (púrpura) sigue la misma ruta que la 1 (roja). Sin embargo, la 3 tarda considerablemente más en viajar de 1 a 2 que la 1 , es decir, 6 minutos frente a 2 minutos. Suponiendo que la 1 es normal, la 3 también debería considerarse una trayectoria anómala. En aplicaciones del mundo real, garantizar intervalos de tiempo de muestreo consistentes es un desafío debido a los diferentes tipos de dispositivos de muestreo y datos faltantes [25]. Aunque una trayectoria se considera normal en términos de sus coordenadas de ubicación, los intervalos de tiempo entre puntos consecutivos pueden diferir significativamente de lo que se observa en una trayectoria normal. Por lo tanto, la trayectoria sigue siendo anómala. Las diferencias en los intervalos de muestreo y los puntos de muestreo faltantes pueden hacer que una trayectoria anómala sea indistinguible de una trayectoria normal. Por lo tanto, es importante considerar las diferencias temporales al detectar trayectorias anómalas.

(2) Sin soporte para actualizaciones. A medida que el aprendizaje automático continúa avanzando, muchos enfoques recientes para la detección de anomalías en trayectorias emplean aprendizaje automático para aprovechar estos avances. El aprendizaje automático utiliza modelos entrenados para extraer características de las trayectorias que pueden usarse para detectar anomalías [7, 15, 20]. Sin embargo, los métodos basados en aprendizaje disponibles actualmente se centran en detectar trayectorias usando pesos preentrenados y no brindan soporte para actualizar los modelos a medida que se recopilan nuevos datos. Los cambios irreversibles en una red vial, como nuevas carreteras y regulaciones de tráfico, por ejemplo, carriles de un solo sentido, límites de velocidad y semáforos, requieren conjuntos de trayectorias y modelos actualizables. Por lo tanto, es esencial poder actualizar los modelos a medida que se dispone de nuevas trayectorias. Para lograr un alto rendimiento en la detección de anomalías en trayectorias, es necesario lograr un entrenamiento actualizable eficiente que mantenga los modelos actualizados con los datos más recientes, al tiempo que se evita el costoso reentrenamiento de modelos completos desde cero.

En este sentido, proponemos el método de detección de trayectorias anómalas en línea espaciotemporal multiescala (MST-OATD). En MST- OATD, una trayectoria se representa mediante una incrustación espaciotemporal. Secuencia. Se propone una estrategia de inferencia multiescala para capturar características de trayectorias espaciotemporales multiescala. Dividimos las trayectorias en segmentos de diferentes tamaños. La estrategia multiescala combina las características espaciales y temporales de los segmentos de trayectoria en diferentes escalas. Al inferir las características de la ruta normal, utilizamos un modelo de mezcla gaussiana para modelar las características, donde diferentes componentes gaussianas pueden representar diferentes tipos de trayectorias. Además , inspirados en la indexación aprendida [12], se introduce un modelo de clasificación aprendida para aprender los rangos de la probabilidad de que una trayectoria siga un tipo particular. Este modelo de clasificación puede obtener rangos con complejidad constante a medida que se recopilan nuevas trayectorias, y los rangos se utilizan para actualizar el conjunto de trayectorias de entrenamiento cuando se recopilan nuevas trayectorias.

Nuestras contribuciones se resumen a continuación. Primero, proponemos un novedoso marco de detección de trayectorias anómalas llamado MST-OATD, capaz de detectar anomalías espaciales y temporales. Segundo, desarrollamos una estrategia eficaz y eficiente para capturar características de trayectorias a múltiples escalas. Las relaciones entre segmentos de trayectoria a diferentes escalas se utilizan para la inferencia y generación de rutas latentes. Tercero, introducimos un modelo de clasificación aprendido para determinar el rango de una trayectoria en función de la probabilidad de seguir cada componente gaussiana. Este modelo se utiliza para actualizar el conjunto de entrenamiento con complejidad constante. Finalmente, presentamos experimentos exhaustivos de detección en línea de trayectorias anómalas en dos conjuntos de datos reales. Los resultados, demostrando que MST-OATD supera a los métodos existentes . Asimismo, observamos que la estrategia de actualización basada en la clasificación permite obtener mejores resultados de detección que otras estrategias de actualización. Nuestro código está disponible en https://github.com/chwang0721/MS

2 TRABAJOS RELACIONADOS

2.1 Detección de trayectorias anómalas

Los métodos existentes para identificar trayectorias espacialmente anómalas se pueden clasificar como métodos basados en métricas o basados en aprendizaje [15]. Los primeros suelen utilizar características diseñadas manualmente y métricas predefinidas como la distancia o la densidad para detectar anomalías. Un estudio temprano [6] identifica trayectorias típicas entre ubicaciones de interés y calcula la distancia de cada segmento de la trayectoria objetivo a trayectorias de referencia. IBAT [29] detecta anomalías al encontrar trayectorias con el mismo par SD que la trayectoria de referencia y emplea la noción de grado de aislamiento. IBOAT [2] es otro método basado en aislamiento para detección en línea. Los métodos basados en aprendizaje aprenden las características de rutas normales y las usan para calcular puntuaciones de anomalía de trayectorias objetivo. El método probabilístico DB-TOD [24] modela el comportamiento/preferencias de conducción a partir de trayectorias históricas usando aprendizaje por refuerzo. El método basado en RNN ATD-RNN [20] caracteriza una trayectoria aprendiendo su incrustación de trayectoria usando una RNN apilada. Recientemente, se ha propuesto el modelo de secuencia generativa GM-VSAE [15] . Inspirado en VAE [10], usa un modelo de mezcla gaussiana para representar características de trayectoria en espacio latente. ATROM [5] es un modelo de aprendizaje métrico probabilístico que se centra en reconocer qué tipo de anomalía presenta una trayectoria. SafeTrip [21] utiliza varios factores , como la distancia y la velocidad, para estimar la probabilidad de eventos de seguridad anormales en un escenario de transporte compartido.

En comparación con la detección de trayectorias espacialmente anómalas, pocos métodos se centran en la información temporal de las trayectorias. TPRO [34]

Machine Translated by Google

desarrolla un gráfico dependiente del tiempo para encontrar rutas populares en un entorno dado.
período de tiempo como rutas de referencia. Una versión mejorada de TPRO,
Se propone TPRRO [35] para acelerar el proceso de detección.
El método reciente dependiente del tiempo DeepTEA [7] utiliza patrones de tráfico como
una referencia y combina estos con patrones de trayectoria. Sin embargo,
Estos métodos son métodos dependientes del tiempo, se centran en
obtener rutas normales en diferentes períodos de tiempo, lo cual es diferente de
Nuestro objetivo es detectar anomalías espacio-temporales.

2.2 Modelo de predicción de rango

El árbol B y sus variantes (por ejemplo, el árbol B+ [1]) son los más comunes.
Utilizaban estructuras de índice para realizar consultas. Dada una consulta, su objetivo es:
Devuelve la posición de un valor dentro de un conjunto ordenado por clave. Un estudio reciente
de indexación aprendida [12] argumenta que el árbol B puede pensarse como
un modelo aprendible. La posición de una clave dentro de una matriz ordenada puede ser
aproximada como una función de distribución acumulativa. Como resultado, la
El modelo se puede implementar utilizando aprendizaje automático, como por ejemplo lineal.
regresión. Inspirado en esto, una búsqueda de similitud llamada LIMS [22]
utiliza una función polinómica para predecir los rangos de los elementos en
grupos. En nuestro estudio, esta técnica se puede utilizar para predecir el
rangos de trayectorias. Aunque la predicción de rango utilizando este método es
no exacto debido a la incertidumbre del aprendizaje automático [4], la necesidad
para una búsqueda exacta no es necesario en la actualización de nuestro conjunto de entrenamiento. Nuestro
El enfoque está en actualizar las distribuciones en lugar de realizar una prueba precisa.
búsqueda. Por lo tanto, la técnica de índice aprendida es adecuada para la clasificación.
predicción en nuestro escenario de aplicación.

3. FORMULACIÓN DEL PROBLEMA

Procedemos a presentar definiciones y a declarar formalmente el concepto en línea.
Problema de detección de trayectorias anómalas.

3.1 Preliminares

Punto de trayectoria. Un punto de trayectoria = (,) captura la trayectoria espacial
ubicación de un objeto móvil en un momento específico.

Trayectoria. Una trayectoria = 1, 2, ..., es una secuencia de puntos de
trayectoria que capturan el movimiento de un objeto a lo largo del tiempo.
Dada una trayectoria, ( ) y ( ) denotan su espacio y tiempo
aspectos, respectivamente: ( ) 1y2( ).=, .1, 2, ..., =

Segmento de trayectoria. Un segmento de trayectoria [ ] es un segmento consecutivo
subsecuencia de trayectoria = 1, 2, ..., desde hasta 1 ≤ ,
≤ ≤ .

Tipo de ruta. Dado un conjunto de trayectorias { 1, 2, ..., } desde diferentes
regiones de una ciudad (por ejemplo, el centro o los suburbios) y utilizando diferentes
tipos de carreteras (por ejemplo, autopistas o calles), utilizamos esta información para
Asignar un tipo de ruta a cada trayectoria.

Rango de trayectoria. El rango ( ) de una trayectoria se define
como el rango de probabilidad entre todas las trayectorias de que una
La trayectoria tiene, o sigue, un tipo de ruta. En el ejemplo de la Figura 1,
Suponemos que 1 (rojo) representa una trayectoria que sigue la ruta.
tipo . Entonces asumimos que las probabilidades de 2 (azul), 3 (púrpura),
y 4 (naranja) siguiendo el tipo de ruta son 0, 1 y 0,5, respectivamente.
Por lo tanto, (3) = 1, (4) = 2 y (2) = 3. El
Las probabilidades se calculan en función de un modelo de mezcla gaussiana, para
se describirá en la Sección 4.2.2.

3.2 Planteamiento del problema

Detección en línea de trayectorias anómalas. Una trayectoria se considera anómala si su ruta
se desvía significativamente de la normal.
rutas o su consumo de tiempo difiere significativamente de los de
trayectorias normales con la misma ruta. El objetivo de en línea
La detección de trayectorias anómalas consiste en adquirir conocimiento de la regularidad.
trazar patrones de ruta y actualizar la puntuación de anomalías en cada punto temporal.
La sección 5 describe la metodología para calcular la anomalía.
puntaje ( ). El rango de la puntuación es [0, 1], y ( ) puede
reflejan la combinación de anomalías espaciales y temporales de .

4. EL MODELO MST-OATD

A continuación, presentamos el método MST-OATD. La arquitectura general de
MST-OATD se ilustra en la Figura 2.

4.1 Cálculo de incrustación de trayectorias

Para extraer características de trayectoria, es esencial representar las trayectorias.
utilizando incrustaciones de baja dimensión. Para lograr esto, calculamos
incrustaciones espaciales y temporales y realización de fusión multiescala.

4.1.1 Incrustación espacial. Mapeamos las ubicaciones espaciales de las trayectorias.
a celdas en una cuadrícula uniforme siguiendo un estudio previo [14]. Dado un
trayectoria, la secuencia espacial = 1, 2, ..., se transforma ( )
en la secuencia g = 1, 2, ..., , donde denota una celda de la cuadrícula. Nosotros
usar para representar la incrustación del ID de celda de la cuadrícula de . Sin embargo, la cuadrícula
La incrustación del identificador de celda no es una representación completa de una trayectoria.
punto porque ignora las relaciones posicionales entre los
celdas de cuadrícula. Inspirados en las redes neuronales convolucionales de grafos [11], nosotros
Generar una matriz de agregación para las celdas de la cuadrícula:

$$= \quad ^{-\frac{1}{2}} \quad ^{-\frac{1}{2}}, \tag{1}$$

donde es la matriz de adyacencia. En el mapeo de cuadrícula, adyacente
Las celdas de la cuadrícula son celdas con bordes comunes y = + se utiliza para
características agregadas de una celda de cuadrícula y sus celdas de cuadrícula adyacentes. A continuación,
La matriz de grados se calcula como y es un peso =
matriz para , que se aprende para obtener los pesos de la cuadrícula adyacente
celdas ya que la influencia de las celdas de la cuadrícula adyacentes varía. Por ejemplo,
Las células conectadas por una carretera se influyen entre sí más que las células.
sin conexión por carretera.

Por lo tanto, la incrustación espacial ( ) se puede calcular multiplicando
la matriz de agregación y la incrustación del ID de celda de la cuadrícula:

$$( ) = = \quad ^{-\frac{1}{2}} \quad ^{-\frac{1}{2}} \tag{2}$$

Basándonos en el método anterior, la trayectoria espacial ( ) puede ser
incrustado como una secuencia de vectores e( ) = ( ) ( ) ( ) .
1 , 2 , ...,

4.1.2 Incrustación temporal. En comparación con la incrustación espacial,
La incrustación temporal es más difícil de calcular porque
El método utilizado para la incrustación espacial puede no lograr capturar características
periódicas, que son una característica importante de la información temporal.
En cambio, inspirados por Time2Vec [8], aprendemos incrustaciones temporales
utilizando una red neuronal con una función de activación periódica para extraer
características periódicas y no periódicas. Para cada marca de tiempo en una
La trayectoria la representamos mediante una tupla que consta de valores para
diferentes niveles de unidades de tiempo (por ejemplo, fechas, horas, minutos y segundos).

Machine Translated by Google

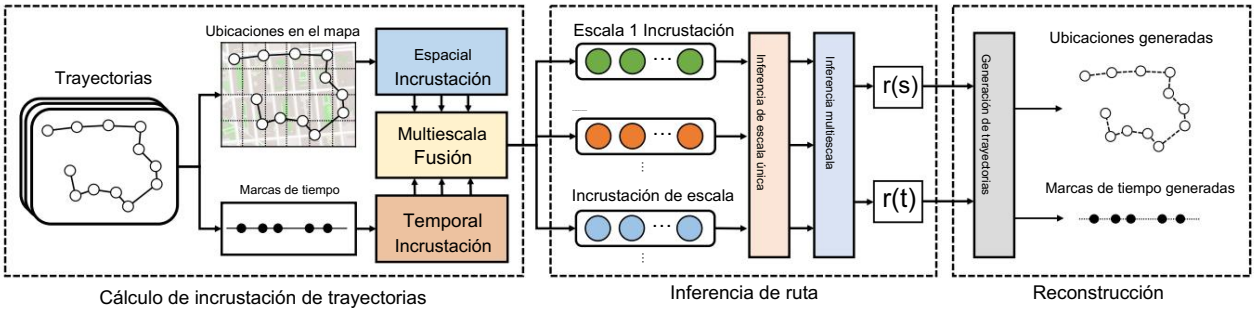


Figura 2: Una descripción general de MST-OATD. Consta de tres etapas: cálculo de incrustación de trayectoria, inferencia de ruta y reconstrucción de trayectoria.

La incrustación temporal ( ) se da en la ecuación 3:

$$ ( ) = [1 ( ) \quad F (2 ( ))], \tag{3}$$

dónde $1(\cdot)$ y $2(\cdot)$ son capas totalmente conectadas entrenables, F denota una función de activación periódica que ayuda a capturar periódica comportamientos en diferentes niveles sin necesidad de ingeniería de características , $[\cdot \ \cdot]$ es el operador de concatenación. En MST-OATD, elegimos la función como F, que representa la periodicidad en diferentes momentos unidades. Con la ecuación 3, la información temporal de una trayectoria $ ( ) = 1, 2, ..., $ se puede incrustar en una secuencia de vectores $y ( ) = \ . ( ) ( ) ( ) 1 , 2 , ..., $

4.1.3 Fusión multiescala. Una trayectoria es una secuencia de trayectorias Los puntos y las conexiones entre los diferentes segmentos de una trayectoria juegan un papel crucial en la representación de las características de la trayectoria. Como los métodos de escala única se centran principalmente en puntos individuales dentro una trayectoria, se enfrentan a desafíos para lograr una integral representación de una trayectoria completa. Además, es esencial integrar información espacial y temporal. Para abordar estos problemas, proporcionamos un módulo de fusión multiescala que captura eficazmente Características espacio-temporales en múltiples escalas.

Específicamente, se adopta un módulo de atención cruzada para fusionar las incrustaciones espaciales y temporales. La atención espacial y temporal resultados $e^ ( )$ y $e^ ( )$ se calculan de la siguiente manera:

$$\begin{aligned} e^ ( ) &= \text{Softmax}(e ( ) \quad ( ) \ y ( ) \quad ( ) \ / \sqrt{\ })e ( ) / \quad ( ) \\ e^ ( ) &= \text{Softmax}(e ( ) \quad ( ) \ y ( ) \quad ( ) \ \sqrt{\ })e ( ) \quad ( ) , \end{aligned} \tag{4}$$

dónde $ ( )$, $ ( )$, y $ ( )$ son los pesos para la intersección espacial atención; $ ( )$, $ ( )$, y $ ( )$ son los pesos para el cruce temporal $ ( )$ atención; y la dimensionalidad de la incrustación de $ $ y $ ( )$. El trayectoria e se calcula entonces como se muestra en la ecuación 5:

$$e = [(\text{Norm}(\text{FFN} (e^ ( )) + e \quad ( )) \quad \text{Norma}(\text{FFN} (e^ ( )) + e \ ( )))] \tag{5}$$

Aquí, FFN denota una red de alimentación directa y Norm es la capa Operación de normalización. Usamos e para representar una incrustación de trayectoria a escala . Específicamente, dado que tenemos una secuencia de incrustaciones $e = 1, 2, ..., $ de longitud , e se calcula de la siguiente manera:

$$e = \ ^ \ 1 , \ 2 , ..., \ / \ , \tag{6}$$

donde denota el tamaño del segmento de valores de , $^$ es la media de la escala de las incrustaciones en el -ésimo segmento de la , $\cdot$ denota el operación de redondeo de escala, es el último segmento de la trayectoria / porque la longitud de una trayectoria no es necesariamente divisible por la tamaño del segmento, que se calcula como se muestra a continuación:

$$^ = \begin{cases} \times +1 & < \ / \\ =(-1) +1 & / / \quad = \ / \\ =(-1) +1 & \end{cases} \tag{7}$$

Para capturar la correlación entre los segmentos en un trayectoria, utilizamos una capa de atención para incrustaciones en diferentes escalas, cuyo objetivo es calcular la puntuación de atención de los segmentos en la misma trayectoria. El cálculo se muestra en la ecuación 8:

$$\tilde{} = \text{Softmax}(\text{donde} \ , \ ) \ , \tag{8}$$

$= \cdot \tanh(\cdot$ y son el $+ \cdot \ ^ \ ^);$, , parámetros a aprender; y $\tilde{}$ es la incrustación del -ésimo segmento a escala después de la capa de atención.

Usamos $e\tilde{}$ para representar la incrustación de la trayectoria a escala después de la fusión multiescala, y $e\tilde{}$ se calcula usando el método anterior. Las diferentes escalas capturan diferentes características de las trayectorias. Para Por ejemplo, las escalas más pequeñas pueden capturar detalles intrincados como las esquinas. Por el contrario, se requieren escalas mayores para capturar las características de la trayectoria. como su forma general.

4.2 Inferencia de ruta

Para extraer características espaciotemporales de la trayectoria en múltiples puntos escalas, proponemos una red de inferencia $(( ) , ( ) |)$ para inferir vectores de ruta latentes dada una trayectoria. Aquí, denota los parámetros de $(( ) , ( ) |)$ que debe aprenderse, donde $( )$ y $( )$ son Vectores latentes espaciales y temporales. Para hacer frente a la incertidumbre de trayectorias, modelamos $( )$ y $( )$ usando distribuciones gaussianas:

$$\begin{aligned} ( ) \quad (( ) |) &= \mathcal{N} (( ) \quad , \ ^2 ( ) \ ) \\ ( ) \quad (( ) |) &= \mathcal{N} (( ) \quad , \ ^2 ( ) \ ), \end{aligned} \tag{9}$$

dónde $( )$, $^2 ( )$, $ ( )$, y $^2 ( )$ son parámetros del espacio y distribuciones gaussianas temporales.

La etapa de inferencia de ruta consiste en inferencia de escala única y multiescala . La inferencia de escala única adquiere vectores latentes en una escala particular, mientras que la inferencia multiescala combina vectores en diferentes escalas.

Machine Translated by Google

4.2.1 Inferencia a escala única. Proporcionamos un módulo especializado para la inferencia de rutas, centrado en una escala específica. Nuestro enfoque emplea redes neuronales recurrentes (RNN) para permitir la inferencia a escala única. Las RNN operan en cada marca de tiempo, tomando la incrustación de trayectoria ˜ y generando un estado oculto de la siguiente manera:

$$= 1 (\tilde{}, -1), = 1, 2, ..., (10)$$

Aquí, 1 (·) representa el módulo RNN, mientras que −1 denota el estado oculto Usando este método, se pueden obtener y −1 . Usamos ( ) y ( ) para de las , ( ) ( ) y −1 , referirnos a los estados ocultos finales dados derivados incrustaciones espaciales y temporales, respectivamente.

4.2.2 Inferencia multiescala. Para combinar características de trayectoria de escala única, proponemos un módulo de inferencia multiescala basado en probabilidad para la inferencia de rutas latentes. Se utilizan modelos de mezcla gaussiana para modelar los vectores latentes espaciales y temporales para lidiar con la complejidad de las trayectorias. Los parámetros de las distribuciones de mezcla gaussianas espaciales y temporales a escala se pueden obtener realizando transformaciones lineales en ( ) y ( ) ( ) ( ) :

$$\begin{aligned} ( ) &= 3 (( )), \quad ( )) \quad 2 ( ) = 4 (\\ ( ) &= 5 (( ) ( )), \quad 2 ( ) = 6 (( ) ( )), \end{aligned} \tag{11}$$

donde ( ) y ( ) son los estados ocultos finales de los espaciales y ( ) son las incrustaciones temporales a escala , ( ) y espaciales y y 3 (·), 4 parámetros temporales a escala capas , (·), 5 (·) y 6 (·) son 2 ( ) 2 ( ) son los totalmente conectadas. Además, ( ) parámetros , , ( ) , y procesados multiescala de distribuciones de mezcla gaussiana espacial y temporal. Estas dos distribuciones contienen información sobre rutas espacial y temporalmente normales.

Además, dado que los vehículos pueden circular por diferentes regiones de una ciudad (por ejemplo, el centro o los suburbios) y por diferentes tipos de carreteras (por ejemplo, autopistas o calles), no es razonable modelar todas las trayectorias con una única distribución. Del mismo modo, las trayectorias normales son diferentes en distintos momentos; por ejemplo, las trayectorias de las horas punta de la mañana y de la tarde difieren de las de otros momentos, por lo que también tiene sentido categorizar temporalmente las trayectorias en diferentes tipos. Motivados por esto, asumimos que existen tipos de rutas tanto espacial como temporalmente. Utilizamos una distribución multinomial ( ) = Mult( ) para representar la distribución de los tipos de ruta, donde es una variable que determina el tipo de trayectoria y es el parámetro de distribución . Para cada tipo, se utiliza una distribución gaussiana para modelar el vector latente, como se muestra en las ecuaciones 12:

$$(( ) | ( )) = N (( ) ( ), \ 2 ( ) ( )), \quad (( ) | ( )) = N (( ) ( ), \ 2 ( ) ( )) \tag{12}$$

Aquí, (|) denota la probabilidad de que un tipo de ruta sea recorrido por las trayectorias, y ( ) y ( ) son los vectores de ruta latente espacial y temporal 2 ( ) . A continuación,( ) ( ) ( ) y denotan el media y varianza de la distribución espacial de tipo , y ( ) ( ) y 2 ( ) ( ) denotan los parámetros de la distribución temporal de y ( ) y los tipos de ( ) se ( )). Los vectores latentes ( ) tipo y , ruta ( ) , pueden inferir de la ecuación 13: (( ) ( ) |) = (( ) ( ) |) (( )

$$, ( ) , ( ) , , , ( ) |) \tag{13}$$

Básicamente, (( ) ( ) |,) puede considerarse como la probabilidad de ( ) y tipo espacial . temporal ( ) dada la ruta de una proyección de tipo trans- Dado que la trayectoria puede codificarse en espacial y ( ) (( ) ( ) |) también escrito como (( ) ( ) |). Entonces ( ) puede ser vectores latentes temporales y ( ) ( ) puede convertirse mediante la fórmula bayesiana como se muestra en la ecuación 14:

$$(( ) ( ) |) = (( ) ( ) | (( )) , \ , \ ( ) , \ ( )) = \frac{(( )) (( )) | ( ) |)}{=1 \ ( ) \ (} \cdot \frac{(( ) | ( )) ( )}{=1 \ ( ) (\ |)} \tag{14}$$

Por lo tanto, los vectores latentes espaciales y temporales y sus tipos se pueden inferir usando (|) y ( ), que se definen arriba.

4.3 Reconstrucción de trayectorias Para permitir la detección en línea, diseñamos una red de generación (|), donde representa los parámetros de la red. La distribución (|) denota la probabilidad de que una trayectoria siga una distribución normal . También se utilizan RNN rutas contenidas en para generar trayectorias.

Dada una secuencia de incrustaciones e< = 1, 2, ..., −1 y un la el estado vector de ruta de tienda de campaña , oculto se actualiza como se muestra en Ecuación 15:

$$= 2 (, -1) = 1, 2, ..., \quad 0 = , \tag{15}$$

donde 2 (·) es una RNN que se va a entrenar, y 0 es el estado oculto inicial , que también es el vector de ruta latente espacial. El en el paso -ésimo se genera de acuerdo con la ecuación 16:

$$(| e< ,) = (| -1). \tag{16}$$

Con este método, ( ) se puede calcular dada una secuencia de incrustaciones y ( ) se puede calcular dada una secuencia de incrustaciones espaciales ( ) y el vector de ruta latente espacial ( ) , y el vector de ruta latente temporal ( ) .

Utilizando la red de generación, los aspectos espaciales y temporales ( ) y ( ) de la trayectoria pueden generarse secuencialmente mediante (( ) | ( )) y (( ) | ( )).

4.4 Optimización Los parámetros que se deben aprender incluyen las incrustaciones espaciales y temporales , para la inferencia de rutas y para la generación de trayectorias. El objetivo del entrenamiento es maximizar la verosimilitud logarítmica marginal de las trayectorias generadas:

$$\text{registro} (1, 2, ..., \ ) = \sum_{=1} \text{registro} (\ ( )) \ (\ ( )), \tag{17}$$

donde es el número de trayectorias utilizadas para el entrenamiento. La log-verosimilitud marginal se optimiza maximizando el límite inferior de ( )) y L verosimilitudes marginales L (, El , ; (, ( )). la suma de las apéndice proporciona los detalles sobre el cálculo del límite inferior.

5 TRAYECTORIAS ANÓMALAS EN LÍNEA DETECCIÓN POR MST-OATD

Para detectar trayectorias anómalas, utilizamos la estrategia de detección por generación. Dados una trayectoria y vectores de ruta latentes ( ) y ( ), las redes generativas (( ) | , ( )) y (( ) | ( )) se utilizan para

Machine Translated by Google

Calculamos la probabilidad que se generó a partir del vector latente . Para encontrar el tipo de ruta más probable en el espacio latente espacial y temporal para cada trayectoria, calculamos la probabilidad de que la trayectoria siga todos los tipos y seleccionamos el tipo más alto como el tipo final. La puntuación de anomalía de una trayectoria se define en la ecuación 18:

$$\text{Puntuación}() = 1 - \arg\max_{(),\,()} \exp\Big[\frac{\text{registro}(()\,|\,()) \quad (()\,|\,())}{}\Big], \tag{18}$$

donde arg max es la operación que encuentra el argumento que maximiza la función argumento, es la longitud de la trayectoria, que se utiliza para normalizar la puntuación de anomalía de trayectorias con diferentes longitudes, y ( ) y ( ) son los tipos de incrustaciones espaciales y temporales. Aquí, usamos para aproximar los vectores latentes de cada tipo.

Para la detección en línea, la puntuación de anomalía Score(≤) se determina mediante la log-verosimilitud en la marca de tiempo anterior y el punto de trayectoria siguiente:

$$\text{Puntuación}(\le) = 1 - \arg\max_{(),\,()} \exp\Big[\frac{\text{registro}(\,|\le\,())\quad(\,|\le,\,())}{+1} + \frac{\text{registro}(\,|\le\,())\quad(\,|\le,\,())}{+1}\Big] \tag{19}$$

6. ACTUALIZACIÓN DEL CONJUNTO DE DATOS EN EVOLUCIÓN

Las secciones 4 y 5 presentan el modelo MST-OATD y su aplicación a la detección en línea. Sin embargo, dado que las condiciones de la carretera cambian con el tiempo y se recopilan nuevas trayectorias, las características espaciales y temporales preentrenadas pueden no coincidir con los patrones de trayectoria actuales. Por lo tanto, se necesita un método para actualizar el modelo con nuevos datos.

Un enfoque natural consiste en actualizar los pesos del modelo con un número constante de trayectorias recién recopiladas, reemplazando las más antiguas . Sin embargo, este enfoque no siempre es óptimo. Por ejemplo, si todas las trayectorias más recientes pertenecen a un tipo específico, simplemente reemplazar las más antiguas podría no resultar en un cambio rápido en la distribución de los datos. Nuestro objetivo es asegurar que las distribuciones de datos de entrenamiento y de destino se mantengan consistentes, ya que esto permite ajustar el modelo con mayor eficiencia. Para lograrlo, proponemos una estrategia de actualización basada en la clasificación que prioriza las actualizaciones del conjunto de entrenamiento según la distribución espacial de las trayectorias.

Dado que el proceso de actualización es inherentemente un problema temporal, nos centramos en actualizar el conjunto de entrenamiento de acuerdo con la distribución espacial . Más específicamente, supongamos que tenemos un conjunto de trayectorias que siguen espacialmente una distribución de mezcla gaussiana con componentes.

Como se discutió en la Sección 4.2.2, la probabilidad de que una trayectoria sea ( ) de tipo en el dominio espacial se expresa como (|) = (|), dónde es el vector latente espacial de . Calculamos la probabilidad de que cada trayectoria siga un tipo particular y luego las clasificamos en orden descendente. Colocamos una trayectoria en el tipo con el rango más alto y reemplazamos la trayectoria más temprana en el tipo con el rango más bajo.

Además, considerando que nuestro modelo admite la detección en línea, la eficiencia de las actualizaciones también es fundamental. La entrada a nuestro modelo basado en clasificación es la probabilidad de que la trayectoria tenga un tipo particular, como se discute en la Sección 4.2.2, y la salida es el rango de la probabilidad de la trayectoria en ese tipo. Las estructuras de búsqueda tradicionales como los árboles B pueden manejar este problema con una complejidad temporal de O(log) . Inspirado en la indexación aprendida [12], es posible ver el rango de una trayectoria como una estimación de la función de distribución acumulativa (CDF). La ecuación 20 modela la relación entre ( ) y espacial de tipo : la probabilidad de tener un rango de trayectoria

$$() = (\,(\,|\,())) \tag{20}$$

donde (·) es la función de distribución acumulativa estimada y es el número total de trayectorias.

Específicamente, utilizamos regresión logística para implementar el modelo de la siguiente manera: ( ) = [ )] · (|

$$() = [1 + \quad ^{-(\quad\quad)^{-1}}, \tag{21}$$

donde y son el peso y el sesgo. El uso de la función de activación sigmoide permite restringir la salida a [0, 1], lo cual es consistente con el rango de salida de la distribución acumulativa.

El modelo de regresión aprende la distribución de los datos minimizando el error cuadrático de la función. La pérdida de categoría se calcula de la siguiente manera:

$$(;) = \quad =1 \ (\ - \tag{22}$$

donde ( ) es el rango real de la trayectoria . Usando este método, el rango de la trayectoria de se puede obtener dentro de una operación constante.

El apéndice proporciona el pseudocódigo para la actualización del conjunto de datos en evolución utilizando el método de clasificación aprendido.

7 EXPERIMENTOS

7.1 Configuración experimental Conjuntos

de datos: Realizamos experimentos con dos conjuntos de datos de trayectorias de taxis reales , denominados Porto1 y Chengdu2 . Porto contiene un año completo de trayectorias de 442 taxis en Porto, Portugal, donde las posiciones se muestrean cada 15 segundos. Chengdu contiene más de 1400 millones de puntos de trayectoria de aproximadamente 14 000 taxis en Chengdu, China, desde el 3 de agosto de 2014 hasta el 30 de agosto de 2014. En Chengdu, la frecuencia de muestreo no es uniforme. En nuestros experimentos, utilizamos un subconjunto de diez días del conjunto de datos de Chengdu.

Prepossessing: Siguiendo un estudio previo [14], convertimos los espacios geográficos subyacentes de Porto y Chengdu en cuadrículas de 100 m × 100 m . En Porto, las trayectorias con más de 50 puntos se dividen en trayectorias con longitudes entre 20 y 50, y también eliminamos aleatoriamente el 30 % de los puntos en cada trayectoria para que las duraciones entre puntos sean desiguales. En Chengdu, las trayectorias de más de 100 puntos se dividen aleatoriamente en trayectorias con longitudes entre 30 y 100. La Tabla 1 proporciona información sobre los dos conjuntos de datos ajustados. Para Porto, utilizamos los datos de los dos primeros meses para evaluar la efectividad y eficiencia de MST-OATD y para entrenar el modelo de clasificación. Los datos restantes se utilizan para evaluar el rendimiento con el algoritmo de actualización del conjunto de datos evolutivo. De manera similar, los datos de los tres primeros días en Chengdu se utilizan para evaluar la efectividad y eficiencia y para entrenar el modelo de clasificación.

1https://www.kaggle.com/c/pkdd-15-predict-taxi-service-trajectory-i/data 2https://js.dclab.run/v2/cmptDetail.html?id=175

Machine Translated by Google

Los siete días restantes de trayectorias se utilizan para actualizar el entrenamiento.
conjunto. Para cada conjunto de datos, seleccionamos aleatoriamente el 80% de las trayectorias para
formación y 20% para pruebas.

Tabla 1: Estadísticas del conjunto de datos

Conjunto de datos	# Trayectorias	# Puntos de trayectoria	# Tamaño de la cuadrícula
Puerto	1.198.551	35.274.322	[51, 119]
Chengdu	2.124.763	128.837.312	[167, 154]

Verdad fundamental: En ausencia de un conjunto de datos de etiquetas para la detección
de anomalías , algunos estudios intentan etiquetar las anomalías manualmente. Sin embargo,
El etiquetado manual consume mucho tiempo y carece de estándares uniformes.
En cambio, generamos muestras anómalas de acuerdo con reglas específicas.
Siguiendo estudios previos, utilizamos un esquema de perturbación para generar anomalías
espaciales y temporales. Específicamente, utilizamos parámetros
y , donde es la fracción de valores atípicos continuos y es la
distancia de desplazamiento de los valores atípicos. En GM-VSAE [15], una
trayectoria espacialmente anómala se genera moviendo una parte de una trayectoria por una
cierta distancia. Sin embargo, en este método, la parte movida de la
La trayectoria no es continua. Nuestro método mueve una parte continua.
de una trayectoria. Por ejemplo, = 0,1; = 3 significa que el 10% de una
La trayectoria se desvía en 3 celdas de la cuadrícula. También cabe señalar que
las perturbaciones de la trayectoria afectan a las marcas de tiempo de las trayectorias.
Supongamos que la velocidad de una trayectoria es constante, de modo que la distancia
A medida que aumentan los viajes, el intervalo de tiempo cambiará para mantener el número
de puntos de trayectoria constantes. La proporción de muestras anómalas
El valor generado se establece en un 5% en todos los experimentos.
Métrica de evaluación: Utilizamos el AUC de precisión-exhaustividad (PR-AUC) para
evaluar el rendimiento de la detección de trayectorias anómalas. Dado que
Las muestras anómalas constituyen una pequeña proporción de los conjuntos de datos,
Las muestras positivas y negativas están desequilibradas. El objetivo de la
La evaluación de la detección de anomalías consiste en evaluar la capacidad de descubrir
muestras positivas, para las cuales PR-AUC es adecuado.
Líneas base: Consideramos seis métodos existentes para análisis anómalos en línea.
detección de trayectoria:

- iBAT [29]. Este método de trayectoria anómala basado en el aislamiento
  Detecta trayectorias anómalas comprobando hasta qué punto una trayectoria
  objetivo puede aislarse de las trayectorias de referencia.
- SAE [17]. El autoencoder de secuencia es un modelo de secuencia a secuencia basado
  en RNN aprendido minimizando una reconstrucción.
  error. La puntuación de anomalía también se define en función del recon-
  error de instrucción.
- VSAE [10]. El autoencoder de secuencia variacional es un modelo GM-VSAE
  degenerado, donde la distribución de ruta latente
  es una gaussiana.
- TPRRO [35]. Este método distingue los valores atípicos de las rutas populares
  dependientes del tiempo mediante una transferencia dependiente del tiempo.
  gráfico.
- GM-VSAE [15]. Esta secuencia variacional de mezcla gaussiana
  El autoencoder es un modelo de secuencia a secuencia basado en RNN.
  Este método puede manejar distribuciones de trayectorias complejas mediante
  considerando el espacio latente como un modelo de mezcla gaussiana.
- DeepTEA [7] Este es un método dependiente del tiempo de última generación.
  que combina las condiciones dinámicas del tráfico y los patrones de trayectoria
  para detectar anomalías.

7.2 Evaluación de la eficacia

La tabla 2 muestra los resultados experimentales en Porto y Chengdu.
conjuntos de datos. Para evaluar la capacidad de detección en línea, variamos el
relación observada de las trayectorias, es decir, solo una parte de la trayectoria
se observan durante la detección. Podemos encontrar que en comparación con la
Método basado en métricas iBAT y TPRRO, métodos basados en aprendizaje
tienen ventajas significativas. El MST-OATD propuesto supera
todos los valores de referencia. MST-OATD tiene una promoción promedio del 18,6% en
Porto y 2,9% en Chengdu en comparación con el mejor método existente,
DeepTEA. La promoción promedio es el valor medio del PR-AUC.
mejoras sobre DeepTEA divididas por el PR-AUC de DeepTEA en
cada conjunto de experimentos. Para la detección completa de trayectorias, MST-OATD
logra altos resultados de PR-AUC incluso cuando la distancia de desplazamiento es
pequeño, lo que significa que es capaz de detectar valores atípicos incluso cuando
Las partes anómalas no son obvias. Por ejemplo, cuando = 0,2 y
= 2, el PR-AUC puede ser tan alto como 0,892 y 0,949 en Porto y
Chengdu, respectivamente. Para la detección en línea, establecemos la observada
relación a 0,5 y 0,7, lo que significa que solo el primer 50% y el 70%
Se puede observar la trayectoria. MST-OATD puede volver a superar
Todas las líneas base, incluidos dos métodos que aprovechan la
información temporal, TPRRO y DeepTEA. En Chengdu, las mejoras son:
más pequeño que en Porto debido a los valores PR-AUC más altos, lo que hace que
Las mejoras lo hacen más difícil. Además, el horizonte temporal es más corto.
La política de Chengdu limita el uso de información temporal.

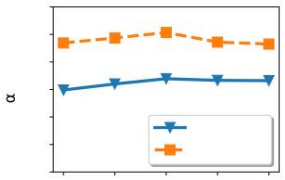


Figura 3: Efecto del número de componentes gaussianas.

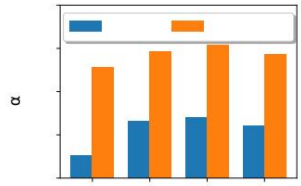


Figura 4: Efecto de la dimensión del estado oculto.

7.3 Análisis de sensibilidad de hiperparámetros

Realizamos experimentos de sensibilidad de parámetros en los dos conjuntos de datos.
y presentamos nuestro análisis. Dos hiperparámetros influyen más en el
rendimiento de MST-OATD: la dimensión de la capa oculta de la RNN
estado y el número de componentes gaussianas. El parámetro de perturbación de la
trayectoria se establece en = 0,1, = 3 en el estudio de ablación,
y nos centramos en el resultado de detectar trayectorias completas.
El número de componentes gaussianas varía de 5 a 100, y el
La dimensionalidad del estado oculto varía de 128 a 1024.
Los resultados experimentales se muestran en las Figuras 3 y 4. Encontramos que la
El PR-AUC es más alto cuando el número de componentes gaussianas es
20 tanto en Porto como en Chengdu. El mejor rendimiento de detección es
Se logra cuando la dimensionalidad del estado oculto se establece en 512.
tanto en Oporto como en Chengdu.

7.4 Estudio de ablación

Realizamos un estudio de ablación en Porto y Chengdu para evaluar la
eficacia de los dos módulos de MST-OATD. Por lo tanto, comparamos
MST-OATD con dos variantes:

Machine Translated by Google

Tabla 2: Comparación del rendimiento en los conjuntos de datos de Porto y Chengdu (PR-AUC)

Conjunto de datos	Puerto									Chengdu								
Parámetros	= 0,1; = 3			= 0,2; = 2			= 0,3; = 2			= 0,1; = 3			= 0,2; = 2			= 0,3; = 2		
Relación observada ( )	0,5	0,7	1.0	0,5	0,7	1.0	0,5	0,7	1.0	0,5	0,7	1.0	0,5	0,7	1.0	0,5	0,7	1.0
iBAT [29]	0,126	0,157	0,199	0,161	0,213	0,304	0,195	0,278	0,331	0,154	0,233	0,409	0,217	0,313	0,504	0,254	0,326	0,585
SAE [17]	0,234	0,316	0,331	0,227	0,589	0,654	0,577	0,831	0,893	0,514	0,658	0,836	0,579	0,771	0,913	0,638	0,891	0,918
VSAE [10]	0,255	0,293	0,306	0,475	0,611	0,649	0,584	0,823	0,871	0,513	0,676	0,831	0,559	0,782	0,907	0,632	0,899	0,924
TPRRO [35]	0,278	0,289	0,292	0,285	0,297	0,303	0,312	0,324	0,322	0,517	0,518	0,553	0,524	0,539	0,551	0,519	0,537	0,543
GM-VSAE [15]	0,305	0,358	0,374	0,509	0,667	0,722	0,606	0,853	0,910	0,522	0,687	0,858	0,573	0,798	0,919	0,654	0,914	0,947
DeepTEA [7]	0,347	0,366	0,408	0,496	0,685	0,736	0,588	0,863	0,921	0,531	0,693	0,875	0,582	0,812	0,931	0,664	0,919	0,935
MST-OATD sin T	0,372	0,464	0,507	0,535	0,720	0,808	0,609	0,880	0,947	0,523	0,694	0,872	0,598	0,804	0,926	0,681	0,929	0,953
MST-OATD sin M	0,411	0,575	0,683	0,526	0,742	0,847	0,618	0,865	0,951	0,538	0,715	0,878	0,581	0,806	0,936	0,669	0,923	0,962
MST-OATD	0,431	0,590	0,739	0,539	0,752	0,892	0,621	0,884	0,970	0,547	0,724	0,907	0,605	0,821	0,949	0,688	0,933	0,969

- MST-OATD sin T: Esta variante solo utiliza información espacial para el entrenamiento y detecta trayectorias anómalas espaciales.
- MST-OATD sin M: Esta variante utiliza la inferencia de escala única, no la inferencia de escala múltiple, tanto en la escala espacial como en la espacial. dimensiones temporales.

MST-OATD supera a las dos variantes, lo que confirma la efectividad de la inferencia multiescala y la incrustación temporal. Encontramos que la incrustación temporal tiene un impacto sustancialmente mayor en el rendimiento de la detección que la inferencia multiescala en general. sugiere que la combinación de incrustación espacial y temporal es fundamental para la detección de trayectorias anómalas. Además, La mejora debida al uso de incrustaciones espaciales y temporales es más significativo cuando la distancia de la anomalía es corta o la anomalía La fracción es pequeña. Esto indica que las anomalías temporales de una Las trayectorias son más pronunciadas que las anomalías espaciales. La inferencia multiescala produce mejoras casi idénticas para cada conjunto. de experimentos realizados tanto en Oporto como en Chengdu.

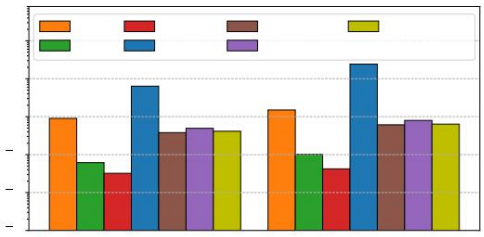


Figura 5: Comparación del tiempo de detección.

7.5 Evaluación de la eficiencia

La figura 5 muestra el tiempo de ejecución promedio por trayectoria. La eficiencia Las pruebas se realizan en una sola GPU NVIDIA RTX 3090. En la evaluación de eficiencia, los números de componentes gaussianas de GM- VSAE, DeepTEA y MST-OATD se establecen en 10. TPRRO y iBAT son los métodos que consumen más tiempo ya que extraen datos normales. Primero se trazan las rutas y luego se compara una trayectoria con estas rutas. VSAE es el método de aprendizaje profundo más rápido porque no necesita codifica trayectorias en un espacio latente como lo hace SAE. Debido al paralelismo generación espacial y temporal, las velocidades de detección de MST-OATD y GM-VSAE son básicamente lo mismo. Sin embargo, debido al uso de Distribuciones de mezcla gaussiana, el tiempo de detección es proporcional al número de componentes gaussianas, lo que hace que estos dos métodos más lento que VSAE y SAE. La velocidad de detección de DeepTEA es inferior a la de los otros métodos basados en el aprendizaje, ya que necesita para capturar patrones de tráfico antes de generar trayectorias. Vale la pena Cabe destacar que MST-OATD solo tarda 0,413 ms en detectar una trayectoria. en Porto y 0,636 ms en Chengdu, lo cual es suficiente para tiempo real. detección.

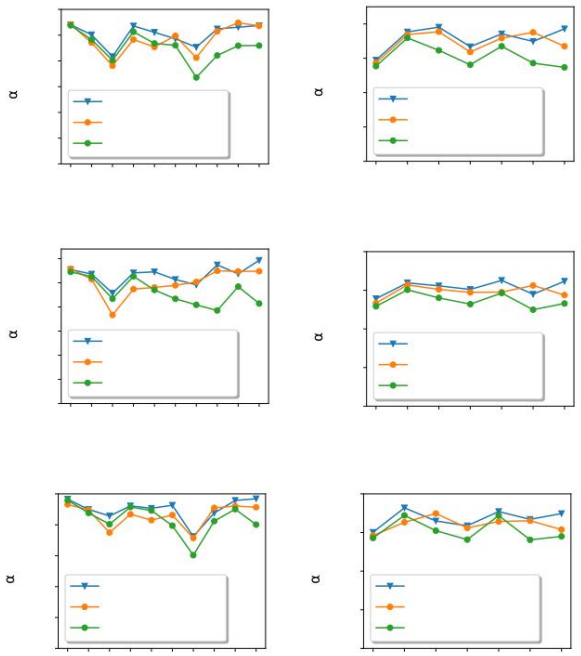


Figura 6: Comparación PR-AUC del entrenamiento actualizable.

7.6 Evaluación de la formación actualizable

Además, evaluamos la efectividad de nuestro método basado en la clasificación. al realizar un entrenamiento actualizable. La Figura 6 muestra el PR-AUC

Machine Translated by Google

al detectar trayectorias anómalas en Porto y Chengdu. Comparamos el enfoque basado en clasificación con otros dos métodos: actualización temporal y un modelo preentrenado, denominados temporal y preentrenado en la figura. La actualización temporal reemplaza las trayectorias más antiguas en el conjunto de entrenamiento cuando llegan nuevas trayectorias, y el modelo preentrenado mantiene el peso del modelo sin cambios. También informamos el PR-AUC promedio para los tres métodos en la Figura 6. Podemos ver que nuestro método propuesto basado en clasificación supera al modelo preentrenado y a la estrategia de actualización temporal. Con el paso del tiempo, hay cierta degradación en la efectividad del modelo preentrenado, ya que las características de las trayectorias cambian con el tiempo. Sin embargo, el rendimiento del entrenamiento con actualización temporal y actualización basada en clasificación no muestra una disminución significativa.

8. CONCLUSIÓN

Proponemos MST-OATD, un modelo multiescala para la detección en línea de trayectorias espaciales anómalas. MST-OATD utiliza incrustaciones espaciales y temporales, y se ha diseñado una estrategia de inferencia multiescala para mejorar el rendimiento de la representación de la trayectoria. MST-OATD puede detectar anomalías espaciales y temporales, y admite la detección en línea. También introducimos un modelo de clasificación aprendido para actualizar el conjunto de entrenamiento de trayectorias basado en la distribución de las trayectorias entrantes. Presentamos experimentos exhaustivos en dos conjuntos de datos de trayectorias de taxis a gran escala del mundo real. Los resultados demuestran que cada componente de MST-OATD es eficaz y eficiente, y muestran que MST-OATD es capaz de superar a seis métodos de referencia. El entrenamiento actualizable también demuestra que nuestra estrategia de actualización basada en clasificación propuesta es capaz de lograr un rendimiento de vanguardia . En futuras investigaciones, sería interesante extender nuestro modelo para admitir otras tareas de minería de datos de trayectorias.

RECONOCIMIENTO

Este trabajo fue financiado por la NSFC (n.º U22B2037, U2001212, U21B2046, 62032001 y 61932004).

REFERENCIAS

[1] Rudolf Bayer y Edward M. McCreight. 1972. Organización y mantenimiento de grandes índices ordenados. Acta Informatica 1 (1972), 173–189.

[2] Chao Chen, Daqing Zhang, Pablo Samuel Castro, Nan Li, Lin Sun, Shijian Li y Zonghui Wang. 2013. iBOAT: Detección de trayectorias anómalas en línea basada en aislamiento . IEEE Trans. Intell. Transp. Syst. 14, 2 (2013), 806–818.

[3] Bin Cheng, Shiyou Qian, Jian Cao, Guangtao Xue, Jiadi Yu, Yanmin Zhu, Minglu Li y Tao Zhang. 2019. STL: Detección en línea de anomalías en la trayectoria del taxi basada en leyes espacio-temporales. En DASFAA (Apuntes de conferencias sobre informática, vol. 11447). Saltador, 764–779.

[4] Jialin Ding, Umar Farooq Minhas, Jia Yu, Chi Wang, Jaeyoung Do, Yinan Li, Hantian Zhang, Badrish Chandramouli, Johannes Gehrke, Donald Kossmann, David B. Lomet y Tim Kraska. 2020. ALEX: Un índice de aprendizaje adaptativo actualizable. En SIGMOD. ACM, 969–984.

[5] Qiang Gao, Xiaohan Wang, Chaoran Liu, Goce Trajcevski, Li Huang y Fan Zhou. 2023. Reconocimiento abierto de trayectorias anómalas mediante aprendizaje métrico probabilístico. En Actas de la Trigésimo Segunda Conferencia Internacional Conjunta sobre Inteligencia Artificial, IJCAI 2023, 19-25 de agosto de 2023, Macao, RAE, China. ijcai.org, 2095-2103.

[6] Yong Ge, Hui Xiong, Chuanren Liu y Zhi-Hua Zhou. 2011. Un sistema de detección de fraude en la conducción de taxis. En ICDM. Sociedad de Computación IEEE, 181–190.

[7] Xiaolin Han, Reynold Cheng, Chenhao Ma y Tobias Grubenmann. 2022. DeepTEA: Detección eficaz y eficiente de valores atípicos en trayectorias dependientes del tiempo en línea . Proc. VLDB Endow. 15, 7 (2022), 1493–1505.

[8] Seyed Mehran Kazemi, Rishab Goel, Sepehr Eghbali, Janahan Ramanan, Jaspreet Sahota, Sanjay Thakur, Stella Wu, Cathal Smyth, Pascal Poupart y Marcus A. Brubaker. 2019. Time2Vec: Aprendizaje de una representación vectorial del tiempo. CoRR abs/1907.05321 (2019).

[9] Seokyeon Kim, Seongmin Jeong, Insoo Woo, Yun Jang, Ross Maciejewski y David S. Ebert. 2018. Análisis y visualización del flujo de datos para el espacio-temporal Datos estadísticos sin información de trayectoria. IEEE Trans. Vis. Comput. Graph. 24, 3 (2018), 1287–1300.

[10] Diederik P. Kingma y Max Welling. 2014. Bayes variacionales de codificación automática. En ICLR.

[11] Thomas N. Kipf y Max Welling. 2017. Clasificación semisupervisada con redes neuronales convolucionales de grafos. En ICLR. OpenReview.net.

[12] Tim Kraska, Alex Beutel, Ed H. Chi, Jeffrey Dean y Neoklis Polyzotis. 2018. Argumentos a favor de las estructuras de índices aprendidas. En SIGMOD. ACM, 489–504.

[13] Jae-Gil Lee, Jiawei Han y Xiaolei Li. 2008. Detección de valores atípicos en trayectorias: un marco de partición y detección. En ICDE. IEEE Computer Society, 140–149.

[14] Xiucheng Li, Kaiqi Zhao, Gao Cong, Christian S. Jensen y Wei Wei. 2018. Aprendizaje de representación profunda para el cálculo de similitud de trayectorias. En ICDE. IEEE Computer Society, 617–628.

[15] Yiding Liu, Kaiqi Zhao, Gao Cong y Zhifeng Bao. 2020. Detección en línea de trayectorias anómalas con modelado de secuencias generativas profundas. En ICDE. IEEE, 949–960.

[16] Zhongjian Lv, Jiajie Xu, Pengpeng Zhao, Guanfeng Liu, Lei Zhao y Xiaofang Zhou. 2017. Detección de trayectorias atípicas: un enfoque basado en análisis de trayectorias. En DASFAA, Vol. 10177. Springer, 231–246.

[17] Pankaj Malhotra, Anusha Ramakrishnan, Gaurangi Anand, Lovekesh Vig, Puneet Agarwal y Gautam Shroff. 2016. Codificador-decodificador basado en LSTM para detección de anomalías multisensor. CoRR abs/1607.00148 (2016).

[18] Yue Ning, Liang Zhao, Feng Chen, Chang-Tien Lu y Huzefa Rangwala. 2019. Predicción de eventos espaciotemporales e identificación de precursores. En KDD. ACM, 3237–3238.

[19] Xuan Rao, Hao Wang, Liang Zhang, Jing Li, Shuo Shang y Peng Han. 2022. FOGS: Supervisión de gradiente de primer orden con grafo basado en aprendizaje para la predicción del flujo de tráfico. En IJCAI. ijcai.org, 3926–3932.

[20] Li Song, Ruijia Wang, Ding Xiao, Xiaotian Han, Yanan Cai y Chuan Shi. 2018. Detección de trayectorias anómalas mediante redes neuronales recurrentes. En ADMA, vol. 11323. Springer, 263–277.

[21] Yueyang Su, Di Yao, Xiaolei Zhou, Yuxuan Zhang, Yunxia Fan, Lu Bai y Jingping Bi. 2023. TripSafe: Recuperación en tiempo real de viajes anómalos relacionados con la seguridad mediante datos de trayectoria. En Actas de la 46.ª Conferencia Internacional ACM SIGIR sobre Investigación y Desarrollo en Recuperación de Información, SIGIR 2023, Taipéi, Taiwán, 23-27 de julio de 2023. ACM, 2446–2450.

[22] Yao Tian, Tingyun Yan, Xi Zhao, Kai Huang y Xiaofang Zhou. 2023. Un índice aprendido para la búsqueda de similitud exacta en espacios métricos. IEEE Trans. Knowl. Data Eng. Rev. 35, 8(2023), 7624–7638.

[23] Sheng Wang, Zhifeng Bao, J. Shane Culpepper y Gao Cong. 2022. Un estudio sobre la gestión, el análisis y el aprendizaje de datos de trayectoria. ACM Comput. Surv. 54, 2 (2022), 39:1–39:36.

[24] Hao Wu, Weiwei Sun y Baihua Zheng. 2017. Un enfoque rápido para la detección de anomalías en la trayectoria mediante el modelado del comportamiento de conducción. En CIKM. ACM, 837–846.

[25] Dongbo Xi, Fuzhen Zhuang, Yanchi Liu, Jingjing Gu, Hui Xiong y Qing He. 2019. Modelado de la dependencia espacio-temporal bidireccional y las preferencias dinámicas de los usuarios para la identificación de puntos de interés faltantes en el registro de entrada. En AAAI. AAAI Press, 5458–5465.

[26] Chuang Yang, Zhiwen Zhang, Zipei Fan, Renhe Jiang, Quanjun Chen, Xuan Song y Ryosuke Shibasaki. 2023. EpiMob: Análisis visual interactivo de restricciones de movilidad humana en toda la ciudad para el control de epidemias. IEEE Trans. Vis. Comput. Gráfico 29, 8 (2023), 3586–3601.

[27] Zhuoning Yuan, Xun Zhou y Tianbao Yang. 2018. Hetero-ConvLSTM: Un enfoque de aprendizaje profundo para la predicción de accidentes de tráfico en datos espaciotemporales heterogéneos. En KDD. ACM, 984–992.

[28] Dongxiang Zhang, Zhihao Chang, Sai Wu, Ye Yuan, Kian-Lee Tan y Gang Chen. 2022. Búsqueda continua de similitudes de trayectorias para la detección de valores atípicos en línea. IEEE Trans. Knowl. Data Eng. 34, 10 (2022), 4690–4704.

[29] Daqing Zhang, Nan Li, Zhi-Hua Zhou, Chao Chen, Lin Sun y Shijian Li. 2011. iBAT: detección de trayectorias de rodaje anómalas a partir de trazas de GPS. En UbiComp. ACM, 99-108.

[30] Huichu Zhang, Chang Liu, Weinan Zhang, Guanjie Zheng y Yong Yu. 2020. GeneraLight: Mejora de la generalización ambiental del control de semáforos mediante aprendizaje por refuerzo meta. En CIKM. ACM, 1783–1792.

[31] Kai Zheng, Yu Zheng, Nicholas Jing Yuan y Shuo Shang. 2013. Sobre el descubrimiento de patrones de recolección a partir de trayectorias. En ICDE. Sociedad de Computación IEEE, 242–253.

[32] Kai Zheng, Yu Zheng, Nicholas Jing Yuan, Shuo Shang y Xiaofang Zhou. 2014. Descubrimiento en línea de patrones de recolección a lo largo de trayectorias. IEEE Trans. Knowl. Ing. de datos. 26, 8 (2014), 1974–1988.

[33] Yu Zheng. 2015. Minería de datos de trayectoria: una visión general. ACM Trans. Intell. Syst. Tecnología 6, 3 (2015), 29:1–29:41.

[34] Jie Zhu, Wei Jiang, An Liu, Guanfeng Liu y Lei Zhao. 2015. Detección de valores atípicos de trayectoria basada en rutas populares dependientes del tiempo. En WISE, vol. 9418. Saltador, 16–30.

[35] Jie Zhu, Wei Jiang, An Liu, Guanfeng Liu y Lei Zhao. 2017. Detección de valores atípicos de trayectoria eficaz y eficiente basada en rutas populares dependientes del tiempo. World Wide Web 20, 1 (2017), 111–134.

Machine Translated by Google

TABLA DE NOTACIÓN

A modo de referencia, la Tabla 3 resume las notaciones clave y sus descripciones en este documento.

Tabla 3: Tabla de notación

Descripción de la notación	
	Punto de trayectoria
	Trayectoria
( ) / ( )	Trayectoria espacial/temporal
y	Incrustación de trayectorias
y ( ) / e ( )	Incrustación de trayectorias espacio-temporales
	Un tipo de ruta
( )	Rango de trayectoria de tipo
	Una escala de trayectoria
y	Incrustaciones de trayectorias a escala
	vector latente
( ) / ( )	Vector latente espacio-temporal
	Vector latente de trayectoria
(·)	Red de inferencia
(·)	Distribución de los tipos de ruta
(·)	Red generativa
,	Parámetros de la distribución gaussiana
(·)	capas totalmente conectadas
(·)	módulos RNN
,	Estados ocultos de las RNN
	Número de trayectorias

B. DETALLES ADICIONALES DE OPTIMIZACIÓN

La log-verosimilitud marginal se optimiza maximizando el límite inferior límite de la suma de las verosimilitudes marginales L (, ( )), , ; ( )) y L (, , ; como se especifica en la ecuación 23:

$$\begin{aligned}\text{registro}\,(\,(\,)\,) \quad (\,(\,)\,) &\geq L\,(\,, \quad , \; ; \; (\,)\,) + L\,(\,, \,, \,; (\,)\,) \\ &= E_{(\,(\,)\,,\,(\,)\,|\,(\,)\,)}\left[\frac{\log \;\; , \,(\,(\,) \;\; , \,(\,)\,, \,(\,)\,)}{(\,(\,) \;\; , \,(\,)\,|\,(\,)\,)}\right] \\ &\quad Y_{(\,(\,)\,,\,(\,)\,|\,\text{registro}\,(\,)\,)}\left[\frac{\;\; , \,(\,(\,) \;\; , \,(\,)\,, \,(\,)\,)}{(\,(\,) \;\; , \,(\,)\,|\,(\,)\,)}\right]\end{aligned} \tag{23}$$

El límite inferior se puede convertir a la forma de la ecuación 24:

$$\begin{aligned}Y_{(\,,\,|\,)}\left[\text{registro}\,\frac{\;\; , \,(\,, \;\; , \,)}{(\,, \,|\,)}\right] &= E_{(\,|\,)}\,\text{registro}\,(\,|\,) \\ - Y_{(\,|\,)}\left[\;\; (\,(\,|\,)\|\;\; (\,)\right] - E_{\;\; |\,)}\left[\,(\;\; (\,(\,|\,)\|\;\; (\,|\,)\right],\end{aligned} \tag{24}$$

donde E log (|) denota el error de reconstrucción. (·||·) es la divergencia KL entre dos distribuciones. El primer término es la pérdida de reconstrucción. Refleja la pérdida entre la generada y las trayectorias reales. La segunda es la pérdida de categoría, que es la pérdida entre la distribución de tipos de trayectoria y la distribución multinomial. La tercera es la pérdida gaussiana, que es la pérdida entre el vector latente y una distribución gaussiana específica.

C DETALLES SOBRE LA ACTUALIZACIÓN DEL CONJUNTO DE DATOS EN EVOLUCIÓN

Algoritmo 1: El algoritmo de actualización de conjuntos de datos en evolución

Entrada: Conjunto de entrenamiento = { 1, 2, ..., };
Una nueva trayectoria recopilada }
Salida: Conjunto de entrenamiento actualizado

1: Construir un conjunto de rangos R ← ;
2: para cada tipo de ruta hacer
3: Calcular la probabilidad del siguiente tipo (|);
4: Obtener ( )}; ( ) basado en el modelo de clasificación aprendido;
5: R ← R { 6: fin para
7: Obtener la categoría mejor clasificada: ← arg max R;
8: ← { };
9: Obtener la categoría de menor rango: ← arg min R;
10: mientras = hacer
11: R ← R − { ( )};
12: ← enojado mi R;
13: fin mientras
14: ← − { ← { 1, 2, ..., }; _ };
15: ~
16: regreso ;

Se muestra todo el proceso de actualización de un conjunto de datos en evolución. en el Algoritmo 1. La entrada es el conjunto de entrenamiento original y un trayectoria recién recopilada, y se puede dividir en categorías, = { 1, 2, ..., conjunto ~ }. La salida es el entrenamiento actualizado Primero, para cada tipo de ruta, calculamos la probabilidad. esa trayectoria sigue el tipo y utiliza la probabilidad para obtener la trayectoria de clasificación ( ) basada en el modelo de clasificación aprendido, Se utiliza un conjunto R para almacenar todos los rangos de la trayectoria (líneas 1-6). Después de obtener las clasificaciones de cada tipo, calculamos la más alta. categoría clasificada y agregar trayectoria al subconjunto (líneas 8-9). Usando el mismo método, calculamos la categoría clasificada más baja categoría y eliminar la trayectoria más antigua en la categoría , que denota como . Durante el proceso de actualización, como eliminar la trayectoria más antigua del conjunto de categorías de menor rango cuando se dispone de una nueva trayectoria, puede haber casos en los que El conjunto de categorías de menor rango, denotado como, queda vacío. En tales casos, en su lugar eliminamos la trayectoria más antigua de la la segunda categoría de menor rango, siempre que no esté vacía, y así ~ adelante (líneas 9-14). Finalmente, obtenemos el conjunto de entrenamiento actualizado y devolvemos como resultado (líneas 15-16).

EXPERIMENTOS D

D.1 Detalles de implementación

Implementamos MST-OATD utilizando Python 3.10.12 y PyTorch 2.0.1. Los experimentos se realizan en una máquina con una CPU Intel Xeon de 40 núcleos, una GPU NVIDIA RTX 3090 y 128 GB de RAM. El AdamW optimizador, inicializado con una tasa de aprendizaje de 0,002 y decreciente por 0,9 después de cada 2 épocas, se utiliza para el entrenamiento del modelo. El tamaño del lote está configurado en 1600 para el conjunto de datos de Porto y en 300 para el conjunto de datos de Chengdu. La dimensión de incrustación es 128 y la dimensión del estado oculto es

Machine Translated by Google

512 en nuestro método, se aplican los mismos ajustes a las líneas base. Utilizamos 3 escalas diferentes para la inferencia multiescala, con tamaños de escala de 1, 2 y 4. Para el entrenamiento en conjuntos de datos en evolución, el tamaño de la El conjunto de entrenamiento está fijado en 80.000 para Porto y 200.000 para Chengdu. Nosotros Repita los experimentos 5 veces con diferentes semillas aleatorias y Informar sobre el rendimiento promedio.

D.2 Experimentos para trayectorias más largas en conjunto de datos de Oporto

Para evaluar la efectividad de nuestro método en la detección de más tiempo trayectorias, recortamos las trayectorias a un máximo de 100 puntos en la Conjunto de datos de Porto y realizar experimentos. El conjunto de datos preprocesado Contiene 1.162.423 trayectorias y 37.856.009 puntos. La comparación del rendimiento con GM-VSAE y DeepTEA se muestra en la tabla. 4. Tenemos dos observaciones: Primero, nuestro MST-OATD propuesto aún supera a los métodos de última generación, DeepTEA y GM-VSAE, cuando la longitud máxima de la trayectoria se establece en 100; Segundo, configuración La longitud máxima de la trayectoria a 50 y 100 mantiene casi el El mismo rendimiento de detección indica que nuestro método es aplicable a la detección de anomalías de trayectoria de diferentes longitudes.

Tabla 4: Rendimiento para trayectorias más largas en el conjunto de datos de Porto

Parámetros	= 0,1; = 3			= 0,2; = 2			= 0,3; = 2		
Relación observada	0,5	0,7	1,0	0,5	0,7	1.0	0,5	0.7	1.0
GM-VSAE	0,345	0,396	0,382	0,514	0,667	0,709	0,614	0,845	0,904
DeepTEA	0,374	0,404	0,413	0,506	0,679	0,729	0,596	0,848	0,921
MST-OATD	0,419	0,619	0,744	0,528	0,754	0,887	0,616	0,891	0,974