Machine Translated by Google

scientific reports

Check for updates

ABIERTO

Clasificación multietapa de eventos de tráfico anómalos mediante una arquitectura multi-cabezal+LSTM.

Pratik Jadhav1,2, Abderrahim Benslimane3, Deepali R.Vora4 y Shruti Patil5

La congestión del tráfico, las anomalías y los incidentes impactan significativamente la eficiencia del transporte urbano y la seguridad vial. La detección y clasificación precisas de estos eventos son cruciales para una gestión eficaz del tráfico, la respuesta a emergencias y la planificación de infraestructuras. Los enfoques tradicionales basados en modelos estadísticos y de aprendizaje automático convencionales suelen tener dificultades para generalizar a través de los patrones de tráfico dinámicos y complejos que evolucionan con el tiempo. Para abordar estas limitaciones, proponemos un modelo multi-cabeza + LSTM en un marco de clasificación multietapa. Este marco propuesto detecta sistemáticamente anomalías mediante un bosque de aislamiento, clasifica la congestión en baja, media y alta mediante agrupamiento K-means y determina si un incidente causó una anomalía mediante un enfoque basado en un umbral espacial (1,5 km). El modelo se entrena con 15 días de datos de tráfico PeMS integrados con información meteorológica para mejorar la precisión predictiva. Mediante la clasificación jerárquica, el modelo propuesto captura dependencias temporales, integra información meteorológica contextual y garantiza una detección robusta de anomalías, clasificación de la congestión e identificación de incidentes. Los resultados experimentales demuestran que el modelo multi-cabeza supera significativamente a los métodos existentes, logrando mayor precisión, exhaustividad, puntuación F1 y ROC-AUC en todas las etapas de clasificación. Los resultados ponen de relieve el potencial del análisis de tráfico basado en el aprendizaje profundo para los sistemas de transporte inteligentes (ITS, por sus siglas en inglés), lo que permite la toma de decisiones basada en datos para la gestión del tráfico urbano.

Palabras clave: Predicción del flujo de tráfico, Clasificación de la congestión, Detección de anomalías, Identificación de incidentes, Atención multi-cabeza, LSTM, Sistemas de transporte inteligentes (ITS)

La congestión del tráfico, las anomalías y los incidentes son factores críticos que influyen significativamente en la eficiencia del transporte urbano y la seguridad vial¹ . Identificar con precisión eventos como congestiones, incidentes y anomalías es esencial para la gestión del tráfico, la respuesta ante emergencias y la planificación de infraestructuras² . Los métodos tradicionales para la detección de anomalías del tráfico y el análisis de la congestión suelen basarse en modelos estadísticos o técnicas convencionales de aprendizaje automático, que pueden tener dificultades para generalizar a patrones de tráfico complejos y dinámicos³ .
Por lo tanto, los modelos basados en aprendizaje profundo a menudo dan resultados prometedores que mejoran la precisión y la eficiencia de los modelos de clasificación de eventos de tráfico4 .

En este estudio, desarrollamos un marco de clasificación basado en aprendizaje profundo de múltiples etapas para detectar sistemáticamente las anomalías, clasificar los niveles de congestión para las anomalías detectadas y clasificar los incidentes, determinando si un incidente ha causado o no una anomalía. Nuestro enfoque se basa en el conjunto de datos de tráfico PEMS de California; para este trabajo, consideramos 15 días de datos y los integramos con datos externos de clima e incidentes.
La clasificación se estructura en tres etapas principales:

- Detección de anomalías: Identificación de patrones de tráfico irregulares mediante el algoritmo de bosque de aislamiento y, en función de ello, etiquetado de cada punto de datos como anomalía (Sí/No).
- Clasificación de la congestión: Categorización de la congestión vial en tres clases: Baja, Media y Alta utilizando Agrupamiento k-means basado en las características del flujo de tráfico.

1Departamento de Inteligencia Artificial y Aprendizaje Automático, Instituto de Tecnología Symbiosis, Universidad Internacional Symbiosis (considerada universidad), Pune 412115, India. 2Centro de Educación e Investigación en Ciencias de la Computación (CERI), Universidad de Aviñón, Aviñón, Francia. 3Ciencias de la Computación e Ingeniería, Universidad de Aviñón, Aviñón, Francia. 4Instituto de Tecnología Symbiosis Pune, Universidad Internacional Symbiosis (considerada universidad), Pune, India. 5Instituto de Inteligencia Artificial Symbiosis, Centro Symbiosis para la Inteligencia Artificial Aplicada, Universidad Internacional Symbiosis (considerada universidad), Pune, India. Correo electrónico: deepali.vora@sitpune.edu.in

Machine Translated by Google
www.nature.com/scientificreports/

• Clasificación de incidentes: Determinar si un incidente desencadenó una anomalía o no utilizando un criterio de selección basado en umbrales donde hemos tenido en cuenta un umbral espacial de 1,5 km que asocia el incidente con anomalías cercanas.

Para lograr resultados precisos en la tarea de clasificación, hemos desarrollado un modelo multi-cabeza inspirado en LSTM, entrenado en un formato multietapa donde cada etapa se basa en la predicción anterior, lo que permite un proceso de clasificación jerárquico y estructurado. El modelo propuesto integra información pasada y contextual de manera oportuna para una clasificación eficaz de anomalías de tráfico y condiciones de congestión.

Trabajos relacionados

Detección de anomalías en redes de tráfico

La detección de anomalías en las redes viales es una tarea crucial en los sistemas de transporte inteligentes (ITS). Se utiliza principalmente para identificar patrones irregulares en las redes de tráfico, como anomalías de congestión, errores de sensores o accidentes . Los métodos tradicionales de detección de anomalías se basan en gran medida en técnicas estadísticas y sistemas basados en reglas, pero con el avance del aprendizaje automático y los métodos basados en aprendizaje profundo, han surgido modelos más avanzados que pueden analizar grandes volúmenes de datos de tráfico en tiempo real . Este enfoque aprovecha los datos de tráfico estructurados, las técnicas de visión artificial y el análisis de series temporales para mejorar la precisión en la identificación de anomalías.

La creciente disponibilidad de datos de sensores de tráfico, grabaciones de CCTV y redes de comunicación vehicular (VANET) ha propiciado un buen desarrollo de nuevos modelos de detección de anomalías basados en datos7 . Estos modelos se centran principalmente en detectar desviaciones repentinas en los patrones de tráfico utilizando técnicas de agrupamiento, redes neuronales y arquitecturas híbridas de aprendizaje profundo8 . En estudios recientes, las técnicas de aprendizaje no supervisado y semisupervisado han ganado prominencia debido a su capacidad de generalizar en diferentes condiciones de tráfico sin necesidad de conjuntos de datos etiquetados extensos.9

Djenouri et al.10 proponen un marco basado en aprendizaje profundo para detectar anomalías en redes de tráfico urbano. Su método emplea una red neuronal convolucional (CNN) con una estrategia de descomposición para particionar los datos de flujo de tráfico en clústeres con patrones similares, entrenando la CNN por separado en cada clúster. El modelo logra buenos resultados en la detección de anomalías al centrarse en los patrones locales en lugar de los patrones globales en las tendencias de tráfico. Gracias al enfoque basado en la descomposición, el modelo supera a los métodos tradicionales de detección de anomalías, particularmente en entornos urbanos a gran escala. Los desafíos que enfrenta este método son el proceso de descomposición, que aumenta la sobrecarga computacional, y las dificultades de generalización cuando los patrones de tráfico cambian dinámicamente.

Lei et al.11 proponen un modelo de detección de anomalías basado en la descomposición espectral para datos de tráfico de series temporales. Su método descompone los datos de tráfico en tendencias, tendencias estacionales y componentes residuales mediante la transformada discreta de Fourier (DFT) antes de implementar modelos predictivos basados en LSTM y CNN. Al reconstruir la serie temporal original e identificar desviaciones, este modelo ha demostrado ser eficaz para detectar anomalías en sistemas de monitorización de tráfico en tiempo real. El uso del aprendizaje no supervisado permite que el modelo se generalice a través de diferentes redes viales urbanas. Debido a la dependencia de la descomposición en el dominio de la frecuencia, el modelo es sensible al ruido de alta frecuencia y, debido a su naturaleza no supervisada, puede generar falsos positivos en condiciones de tráfico de baja varianza.

Aboah et al.12 proponen un sistema de detección de anomalías basado en visión que aprovecha el aprendizaje profundo para el análisis en tiempo real de las grabaciones de cámaras de tráfico. El enfoque de Aboah combina la detección de objetos YOLOv5 con un árbol de decisión, un modelo de clasificación de aprendizaje automático, para detectar y clasificar anomalías en vídeos de tráfico. Los sistemas propuestos estiman el fondo de la carretera, extraen los objetos en primer plano y aplican un mecanismo de filtrado basado en árboles de decisión para identificar anomalías como vehículos detenidos o accidentes. Su método ha dado resultados efectivos para la detección de anomalías en aplicaciones de monitorización de tráfico en tiempo real. Si bien el modelo ofrece resultados efectivos, depende en gran medida de la calidad del vídeo y los ángulos de la cámara, lo que lo hace propenso a fallar en condiciones de baja visibilidad (lluvia, niebla, nieve, escenarios nocturnos).

Laanaoui et al.13 presentan un sistema inteligente de detección de anomalías de tráfico diseñado para el balanceo de carga de tráfico en tiempo real. El estudio utiliza principalmente redes vehiculares y de acceso público (VANET) y datos de sensores en tiempo real para identificar anomalías y ajustar dinámicamente las rutas de los vehículos. Mediante la implementación de análisis de big data y aprendizaje automático, su sistema optimiza el flujo de tráfico, lo que ayuda a reducir la congestión y las interrupciones relacionadas con incidentes. El modelo demuestra una alta precisión en la detección de anomalías de tráfico manteniendo una baja latencia, lo que lo hace adecuado para su implementación en aplicaciones de ciudades inteligentes. Debido a que su enfoque depende de las VANET, el modelo tiene un rendimiento deficiente en áreas con baja congestión, lo que limita su efectividad en regiones rurales o con menor desarrollo tecnológico.

Congestión del tráfico en las redes de transporte

La movilidad urbana es quizás uno de los problemas más acuciantes de la congestión del tráfico que, además de aumentar el tiempo de viaje, el consumo de combustible y la contaminación ambiental, también contribuye a muchos accidentes de tráfico14. La clasificación de los niveles de congestión juega un papel importante para ayudar a la gestión del tráfico a mitigar sus efectos adversos15. En el método tradicional de clasificación de la congestión se basa principalmente en sistemas basados en reglas y modelos estáticos que a menudo no logran generalizar a través de diversas condiciones de tráfico16. En los avances recientes en aprendizaje automático y aprendizaje profundo se han permitido enfoques de clasificación más robustos, escalables y precisos que aprovechan los datos de tráfico en tiempo real de sensores, GPS y redes de comunicaciones vehiculares.

Las técnicas modernas de clasificación de la congestión utilizan medidores de flujo de tráfico, velocidad y densidad para categorizar los niveles de congestión[1] . Estas técnicas se pueden clasificar en términos generales en métodos basados en visión, clasificación basada en sensores y enfoques basados en aprendizaje automático. Sin embargo, desafíos como la heterogeneidad de los datos, la escalabilidad en tiempo real y la necesidad de conjuntos de datos etiquetados extensos siguen siendo obstáculos importantes.

Machine Translated by Google

Bereczki y Simon et al.18 han utilizado un sistema híbrido de detección de congestión basado en ML que compara modelos de aprendizaje supervisado y no supervisado. El sistema procesa y compara vehículos habilitados para V2X y sensores de infraestructura, lo que permite la detección de congestión en tiempo real. El trabajo propuesto consiste en el uso de múltiples modelos de ML, como regresión lineal, bosque aleatorio y potenciación de gradiente extremo, para identificar patrones de congestión con alta precisión. Además, su modelo también pronostica congestiones en segmentos de carretera próximos, lo que lo hace adecuado para aplicaciones de ciudades inteligentes, ya que el modelo depende principalmente de comunicaciones V2X. El modelo tiene dificultades en áreas donde hay baja conectividad vehicular y escasez de datos en áreas menos densamente pobladas.

Shah et al.19 proponen una clasificación de congestión basada en aprendizaje automático para redes vehiculares ad hoc (VANET). Su estudio utiliza datos de flujo y velocidad del tráfico para estimar la densidad vehicular y clasifica el tráfico en tres estados: flujo libre, denso y congestionado. El sistema evalúa múltiples modelos de clasificación de aprendizaje automático, como árboles de decisión, k-vecinos más cercanos, bosques aleatorios y perceptrones multicapa, y este clasificador de votación suave en conjunto demuestra un rendimiento superior en diversos escenarios de congestión. La variación espacial y temporal de la densidad vehicular afecta la precisión del modelo, y sus sistemas requieren un ajuste fino para diferentes entornos urbanos y de autopista.

Liu et al.20 proponen un marco de clasificación de congestión basado en grafos que modela las dependencias espacio-temporales en las redes de tráfico. Su enfoque emplea autoencoders de grafos variacionales espacio-temporales (ST-VGAE), que ayudan a extraer la incrustación de redes viales y clasificar los niveles de congestión. Al implementar datos históricos de accidentes y flujo de tráfico, el sistema proporciona una visión holística de los patrones de congestión. El trabajo propuesto tiene algunas limitaciones, ya que la complejidad computacional del modelo basado en grafos es alta y el modelo tiene dificultades para ofrecer buenos resultados con datos de sensores incompletos o faltantes.

Clasificación de anomalías en redes de tráfico

La clasificación de incidentes de tráfico es un componente vital de los sistemas de transporte inteligentes (ITS), ya que permite la detección en tiempo real de accidentes, averías de vehículos y otras interrupciones que afectan al flujo de tráfico21. La clasificación eficaz de los incidentes mejora la gestión del tráfico, la respuesta ante emergencias y la mitigación de la congestión. La clasificación tradicional de incidentes se basa en métodos estadísticos y reglas de selección basadas en umbrales, lo que a menudo resulta en una alta tasa de falsas alarmas y una adaptabilidad limitada. Los avances recientes en aprendizaje automático y aprendizaje profundo han permitido enfoques más precisos y escalables que aprovechan el análisis de series temporales de datos de sensores y las redes neuronales profundas22.

Lu et al.[23] proponen un modelo híbrido de detección de incidentes de tráfico que combina redes generativas de asesoramiento (GAN) y transformadores para abordar el desequilibrio de los conjuntos de datos y mejorar la precisión de la detección. Las GAN generan muestras sintéticas de incidentes para equilibrar los conjuntos de datos, mientras que los transformadores capturan dependencias temporales para una mejor clasificación. Su propuesta de trabajo se basa en datos sintéticos generados por GAN, lo que introduce sesgos, y en un modelo de transformadores que requiere una gran capacidad de cálculo, lo que limita su aplicación en tiempo real.

Xie et al.[2] proponen un modelo de detección de incidentes basado en aprendizaje conjunto que utiliza Random Forest y el algoritmo de k vecinos más cercanos en subespacio aleatorio (RSKNN). El estudio emplea el sobremuestreo SASYNO para mitigar el desequilibrio del conjunto de datos y mejorar la fiabilidad de la clasificación. El modelo depende en gran medida de las técnicas de selección de características y su rendimiento varía según el tipo de red vial, lo que requiere un ajuste específico del conjunto de datos.

Gurusamy et al.25 desarrollaron un marco de clasificación para la detección de incidentes basado en LSTM-SE que utiliza autoencoders apilados (SAE) para la extracción de características y LSTM para capturar patrones temporales. El modelo demuestra una precisión superior en la detección de incidentes a partir de datos de tráfico en tiempo real. La sobrecarga computacional de LSTM dificulta su implementación en entornos de baja latencia y, por lo tanto, el modelo tiene dificultades con condiciones de tráfico altamente dinámicas.

Zhu et al.26 proponen un marco de detección de incidentes de tráfico descentralizado basado en el método network lasso, que optimiza los modelos de clasificación en un sistema de monitorización de tráfico distribuido. Este enfoque reduce el uso del ancho de banda de la red y mejora la detección en múltiples regiones de tráfico. El complejo proceso de optimización conlleva tiempos de entrenamiento más largos y el rendimiento del modelo depende en gran medida de la calidad de los datos descentralizados.

Metodología

Esta sección describe la metodología implementada en el estudio con respecto al proceso de recopilación de datos, las estrategias de etiquetado y el marco del modelo para la detección de anomalías de tráfico, la clasificación de la congestión y la identificación de incidentes. Nuestro enfoque integra datos de tráfico de múltiples fuentes, etiquetado basado en aprendizaje automático y clasificación mediante aprendizaje profundo para crear un sistema de clasificación robusto y escalable.

Recopilación y preprocesamiento de datos

Hemos utilizado el conjunto de datos PEMS California, que abarca del 1 al 15 de enero de 2024, y que consta de datos de estaciones, metadatos de estaciones, informes de incidentes y datos meteorológicos. Los datos de estaciones incluyen observaciones de tráfico con marca de tiempo, como flujo, ocupación y velocidad, mientras que los metadatos de estaciones incluyen detalles geográficos como latitud, longitud e información de autopistas. Los datos de incidentes registran información sobre incidentes de tráfico, como el ID del incidente, la marca de tiempo, la ubicación y el tipo de incidente (por ejemplo, accidente, avería u obras viales). También hemos integrado datos meteorológicos obtenidos a través de una API, que incluyen temperatura, velocidad del viento, precipitaciones y humedad, lo que proporciona un contexto ambiental para el análisis del tráfico. Estos conjuntos de datos se combinan mediante alineación espaciotemporal, formando una base sólida para la detección de anomalías, la clasificación de la congestión y la identificación de incidentes en nuestro marco de clasificación multietapa.

La Figura 1 muestra la detección y eliminación de valores atípicos utilizando el método IQR para detectar y eliminar los valores atípicos en los valores de latitud y longitud.

Para garantizar la coherencia de los datos, se eliminaron columnas redundantes, como las estadísticas específicas de carril, y se rellenaron los valores faltantes en el flujo de tráfico, la ocupación y la velocidad utilizando la imputación a nivel de estación y la media global. La columna de marca de tiempo se convirtió a formato de fecha y hora, como día, hora y minuto; estas características se extrajeron.

Machine Translated by Google
www.nature.com/scientificreports/

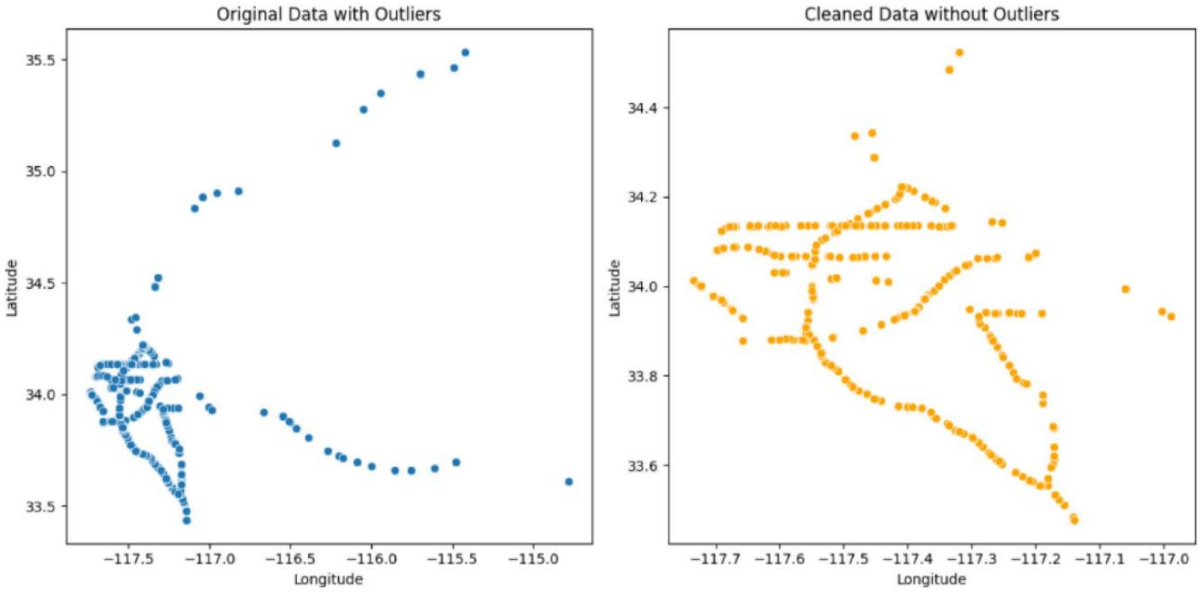


Figura 1. Limpieza de datos de la estación mediante el rango intercuartílico (IQR).

Se aplicó una transformación seno-coseno para capturar los patrones temporales cíclicos. Los valores atípicos de latitud y longitud se filtraron como se muestra en la Fig. 1 utilizando el método IQR y se fusionaron los metadatos de las estaciones para proporcionar contexto geoespacial.

Se recuperaron datos meteorológicos históricos (temperatura, velocidad del viento, precipitación y humedad) mediante una API y se alinearon con los registros de tráfico según la fecha y hora y la ubicación. Las variables categóricas, como la dirección del viaje y el tipo de carril, se codificaron y las características numéricas se estandarizaron mediante la normalización de la puntuación z. En las últimas ventanas deslizantes (pasos = 6), se aplicaron para capturar relaciones espaciales, optimizando el conjunto de datos para la clasificación multietapa.

Para abordar el problema del desequilibrio de clases, se aplicó SMOTE (técnica de sobremuestreo sintético de la clase minoritaria) a las clases de anomalías e incidentes, asegurando una representación suficiente de la clase minoritaria. A diferencia del sobremuestreo ingenuo, SMOTE genera muestras sintéticas basadas en las similitudes del espacio de características en lugar de la duplicación aleatoria, preservando así la estructura temporal de los datos. Para la clasificación de congestión, no se realizó sobremuestreo, ya que la distribución de clases estaba equilibrada. Además, se llevó a cabo una evaluación del modelo en el archivo CSV no visto, asegurando que no hubiera fugas de datos durante el sobremuestreo, lo que mantuvo la integridad de las dependencias de las series temporales durante las pruebas.

Estrategia de etiquetado

• Estrategia de etiquetado para la detección de anomalías

Las anomalías en los datos de tráfico se etiquetaron utilizando el algoritmo de bosque de aislamiento con una tasa de contaminación del 1%, lo que significa que el 1% de los datos se clasificó como una anomalía. Este umbral se seleccionó mediante pruebas iterativas y validación estadística utilizando métodos como el rango intercuartílico (IQR) y el análisis de puntuación Z para garantizar que las anomalías se desviaran significativamente de los patrones de tráfico normales. Las predicciones del modelo se verificaron además con informes históricos e inspección visual para mejorar la fiabilidad. Las anomalías se etiquetaron como anomalía 1 y 0, y sin anomalía. Este enfoque captura eficazmente las irregularidades y detecta picos de congestión precisos, caídas repentinas de velocidad y otros comportamientos inesperados cruciales para una gestión inteligente del tráfico. Métodos como IQR/puntuación Z y SVM de una clase no se consideraron en lugar del bosque de aislamiento, ya que estas técnicas asumen la normalidad en los datos y tienen problemas de escalabilidad, mientras que el bosque de aislamiento detecta eficazmente anomalías en alta dimensión, como los datos de tráfico del mundo real, sin necesidad de muestras etiquetadas.

• Estrategia de etiquetado para la clasificación de la congestión

La congestión del tráfico se etiquetó utilizando el agrupamiento de medias, un enfoque de aprendizaje automático no supervisado que segmentó los datos en tres grupos correspondientes a niveles de congestión Bajo, Medio y Alto. El agrupamiento se realizó utilizando características clave como el flujo de tráfico, la ocupación promedio y la velocidad promedio que se normalizaron antes de aplicarlas al modelo. Una vez formados los grupos, sus centroides se analizaron para derivar una regla basada en umbrales para la clasificación. Luego, en función de este umbral, se etiquetaron las clases de congestión. Estos niveles de congestión etiquetados proporcionan información valiosa para las predicciones y la gestión del tráfico, lo que permite una mejor toma de decisiones para la planificación vial de mitigación de la congestión. K-means es computacionalmente eficiente. Interpretable y naturalmente identifica patrones de congestión distintos en comparación con otros métodos como DBSCAN, que es sensible al ruido, y GMM (modelos de mezcla gaussiana), que asumen una distribución.

• Estrategia de etiquetado para la clasificación de incidentes

Las etiquetas de incidentes se asignaron comparando los incidentes reportados con las estaciones de tráfico cercanas que se encuentran dentro del umbral de un radio de 1,5 km utilizando consultas espaciales con cKD Tree. Si un incidente ocurrió dentro de este umbral y coincidió con la marca de tiempo de las estaciones, se etiquetó como un incidente (anomalía causada por un incidente); si el ID del incidente no cae dentro del umbral, entonces se marcó como no incidente (la anomalía no fue causada por un incidente). Este método garantiza una asociación precisa entre las interrupciones del tráfico y las anomalías detectadas, lo que permite una mejor clasificación y análisis de incidentes. cKD Tree proporciona búsquedas rápidas y precisas del vecino más cercano para una unión precisa incidente-estación en comparación con otros métodos tradicionales como el cálculo de distancia por fuerza bruta, que son computacionalmente costosos.

Si bien se validaron umbrales fijos (por ejemplo, contaminación, radio de 1,5 km) para los datos de PeMS, su transferibilidad a otras redes puede ser limitada. En futuras ampliaciones se considerarán estrategias de umbralización adaptativas o basadas en el aprendizaje para mejorar la generalización.

El diseño secuencial de tres etapas refleja la progresión natural de los eventos de tráfico: primero se detectan anomalías como irregularidades, luego se clasifican según los niveles de congestión y, finalmente, se vinculan con incidentes cercanos. Este orden simplifica la clasificación al filtrar el tráfico normal en una etapa temprana, reduciendo así los cálculos innecesarios.

Modelo multietapa

• Arquitectura del modelo híbrido multietapa

La Figura 2 muestra la canalización del modelo multi-cabezal con LSTM, que es una clasificación de tráfico multietapa, que progresa a través de la detección de anomalías, la clasificación de congestión y la identificación de incidentes. La canalización comienza con el preprocesamiento de datos, donde se integraron y transformaron datos de múltiples fuentes, como datos de estaciones, metadatos de estaciones y datos meteorológicos de API, utilizando técnicas de ingeniería de características, incluyendo codificación temporal e incrustación espacial. Como los datos no estaban etiquetados, hemos utilizado diferentes estrategias de etiquetado para etiquetar los datos. Para la detección de anomalías, hemos utilizado el bosque de Solation; para la clasificación de congestión, las etiquetas se generaron en función del valor umbral de k-means y las etiquetas de incidentes se decidieron en función del umbral de distancia espacial. El modelo multi-etapa+LSTM primero determina si hay una anomalía presente en el flujo de tráfico o no; si es así, el modelo clasifica la anomalía en la clase de congestión y, finalmente, el modelo predice si una congestión fue causada por un incidente o no.

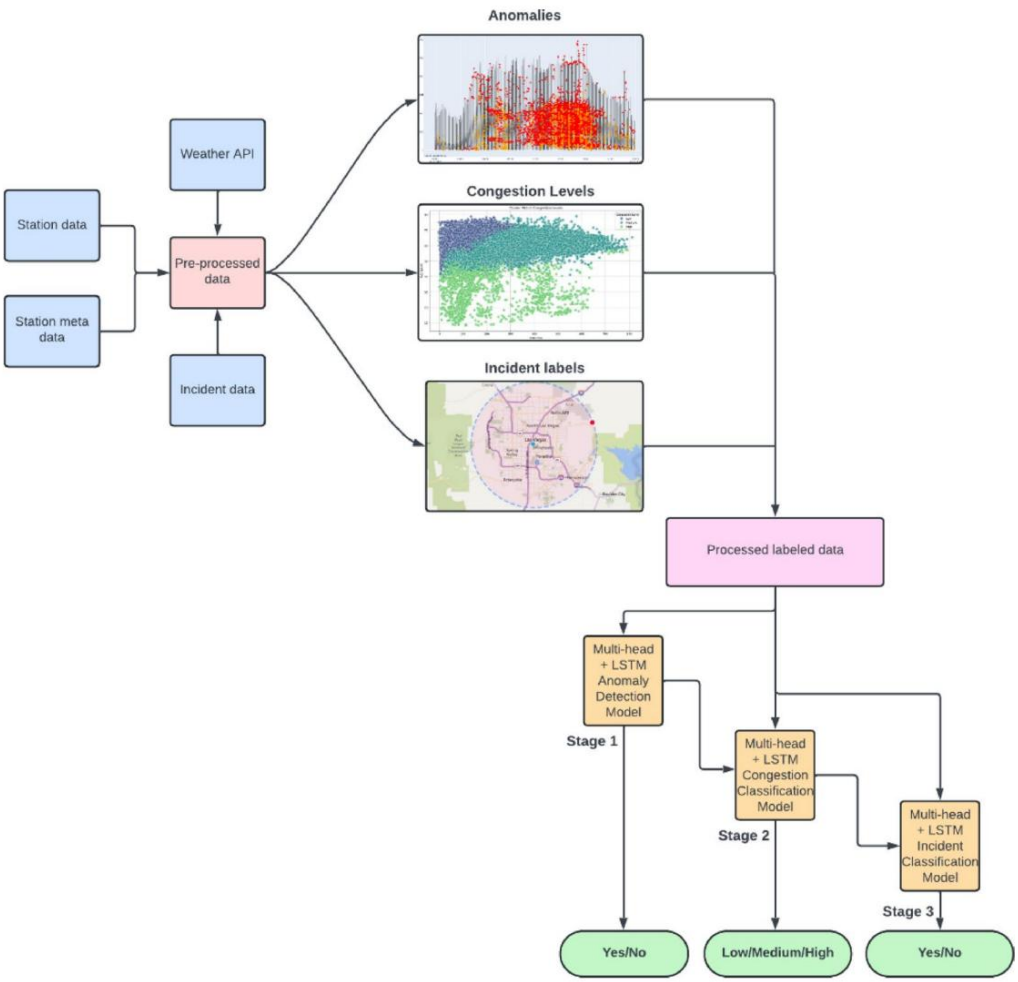


Figura 2. Arquitectura propuesta de la arquitectura de la canalización del modelo LSTM con múltiples cabezas.

La atención de la cabeza captura dependencias complejas en datos secuenciales, mientras que las capas LSTM mejoran la extracción de características temporales, lo que garantiza una clasificación robusta de cada etapa con una mayor conciencia contextual.

Esta integración se diferencia de los enfoques híbridos anteriores (por ejemplo, CNN+LSTM o modelos basados en Transformers) ya que equilibra explícitamente las dependencias a largo plazo mediante la atención multi-cabeza y la dinámica temporal a corto plazo mediante LSTM. La novedad de nuestro enfoque reside en su integración dentro de una secuencia de clasificación por etapas (anomalía-congestión-incidente).

A diferencia de los modelos anteriores de una sola tarea, nuestra innovación radica en integrar la detección de anomalías, la clasificación de la congestión y la identificación de incidentes en un proceso secuencial de múltiples etapas, enriquecido con el contexto meteorológico y el entrenamiento incremental, lo que proporciona una contribución única a la investigación de los sistemas de transporte inteligentes (ITS).

La arquitectura de atención multi-cabeza con LSTM que se muestra en la Fig. 3 combina un mecanismo de autoatención con un modelado secuencial basado en LSTM para una extracción de características mejorada en la clasificación de redes de tráfico. Primero, el modelo toma datos de entrada secuenciales (en 6 pasos de tiempo, 31 características por paso) y los pasa a través de un bloque de atención multi-cabeza con una representación de 128 dimensiones que ayuda a capturar una dependencia compleja a través de diferentes pasos de tiempo. La capa densa de normalización y de alimentación directa que está presente desde allí pasa los datos más adelante que refinan el espacio de características, seguido de una capa de abandono para evitar el sobreajuste. Luego, una pila de unidades LSTM procesa las características refinadas que aprovecha las dependencias temporales para mejorar la precisión de la clasificación. Finalmente, el agrupamiento promedio global reduce la dimensionalidad antes de pasar la salida a través de capas totalmente conectadas que culminan en una capa de salida de una sola unidad con una función de activación para anomalías e incidentes la neurona de salida es una función de activación sigmoide con pérdida de entropía cruzada binaria y para congestión es una función de activación SoftMax con entropía cruzada categórica dispersa. La atención multi-cabeza con LSTM permite capturar dependencias tanto a corto como a largo plazo, donde las primeras son capturadas por la LSTM y las segundas por la atención multi-cabeza. El enfoque multietapa garantiza un proceso de predicción gradual e interpretable, lo que ayuda a mejorar la precisión mediante el refinamiento secuencial de la clasificación de anomalías, congestión e incidentes. Otros modelos, como las CNN, carecen de conciencia temporal, mientras que otros, como los transformadores, requieren una gran cantidad de datos y potencia computacional. Por ello, el modelo propuesto ofrece el mejor equilibrio entre eficiencia y rendimiento.

• Entrenamiento de modelos

El proceso de entrenamiento es multietapa y comienza con la detección de anomalías, seguida de la clasificación de la congestión y, finalmente, la identificación de incidentes para refinar las predicciones paso a paso. El desequilibrio de clases se maneja mediante el sobremuestreo SMOTE, lo que garantiza el equilibrio de las muestras de entrenamiento sin fugas de datos al reservar un archivo CSV no visto para las pruebas. El modelo se entrena con 15 días de CSV y luego se prueba con el CSV del día 16 del conjunto de datos, que no había sido visto por el modelo. El entrenamiento del modelo utiliza el optimizador Adam con una tasa de aprendizaje de 0,001 y se ha aplicado la parada temprana.

Para evitar el sobreajuste, se registraron métricas de evaluación como precisión, exhaustividad y puntuación F1 durante el entrenamiento.

Cada etapa refina su predicción antes de pasar la representación de características enriquecidas a la siguiente, lo que permite un marco de clasificación jerárquico y robusto.

montaje experimental

• Entorno de hardware y software

El modelo se entrenó en unidades de cómputo GPU P100 para gestionar eficientemente conjuntos de datos de tráfico a gran escala. La implementación se realizó utilizando TensorFlow y Keras para el aprendizaje profundo, con herramientas adicionales como Scikit-learn, NumPy, pandas y optuna para el preprocesamiento de datos, la ingeniería de características y el ajuste de hiperparámetros.

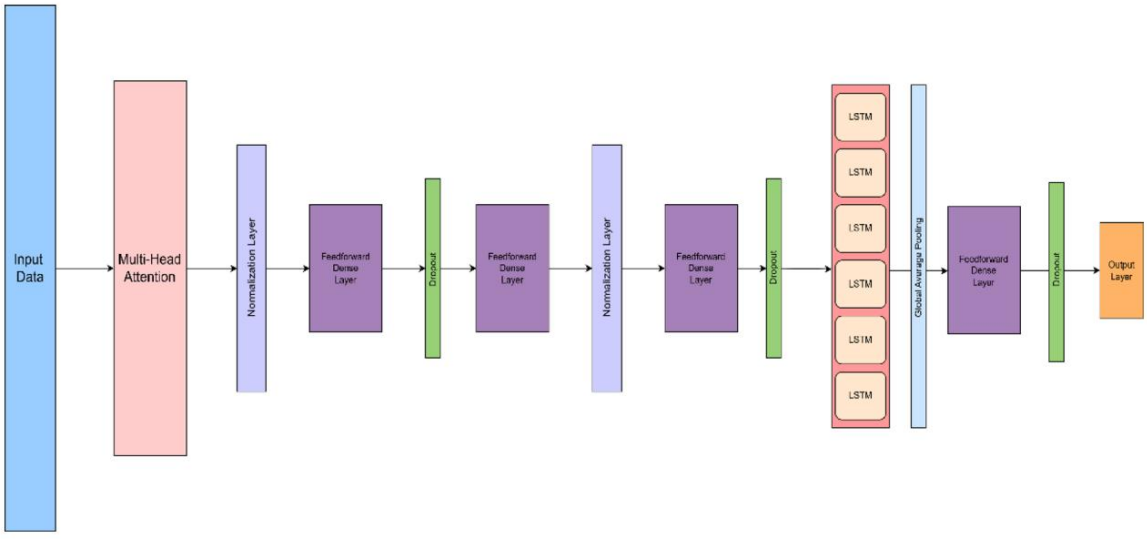


Figura 3. Atención multi-cabeza con arquitectura de modelo LSTM.

Machine Translated by Google
www.nature.com/scientificreports/

• Métricas de rendimiento

Los valores óptimos de los hiperparámetros se determinaron mediante una optimización bayesiana con Optuna. Para evaluar el rendimiento del modelo, se consideraron la matriz de confusión, la precisión, la exhaustividad, la puntuación F1 y el coeficiente de correlación de Matthews (MCC). Los verdaderos positivos (TP) representan anomalías, niveles de congestión o incidentes detectados correctamente, mientras que los verdaderos negativos (TN) corresponden a condiciones normales identificadas correctamente. Los falsos positivos (FP) indican detecciones incorrectas donde no existe ningún problema, y los falsos negativos (FN) ocurren cuando el modelo no detecta anomalías, congestión o incidentes reales.

(1) Precisión

$$\text{Precisión} = \frac{\text{Ciudad}}{\text{TP} + \text{FP}} \tag{1}$$

La precisión (ecuación 1) mide las predicciones, que son cruciales para minimizar las falsas alarmas en la detección de incidentes.

(2) Recuerdo (sensibilidad)

$$\text{Recordatorio} = \frac{\text{Ciudad}}{\text{TP} + \text{FN}} \tag{2}$$

La función Recall (Ec. 2) refleja qué tan bien el modelo ha detectado incidentes reales o congestión, evitando así la omisión de eventos.

(3) Puntuación F1

$$\text{F1} - \text{Puntuación} = 2 \times \frac{\text{Precisión} \quad \text{Recuperación}}{\text{Precisión} + \text{Recuperación}} \tag{3}$$

La puntuación F1 (ecuación 3) calcula la media armónica de la precisión y la exhaustividad, asegurando un equilibrio entre ellas.

(4) Coeficiente de correlación de Matthews (MCC):

$$\text{MCC} = \frac{\text{TP} \quad \text{TN} - \text{FP} \quad \text{FN}}{\sqrt{(\text{TP} + \text{FP})(\text{TP} + \text{FN})(\text{TN} + \text{FP})(\text{TN} + \text{FN})}} \tag{4}$$

El MCC (Ec. 4) se utiliza para evaluar el desequilibrio de clases presente en el conjunto de datos, lo que proporciona una medida robusta del rendimiento de la clasificación.

Resultados y discusión

El modelo se entrenó con los datos de tráfico en formato CSV de 15 días y se probó con los datos CSV del día 16. A continuación se muestran los resultados y se discute la comparación con trabajos existentes con respecto a cada objetivo del modelo multietapa.

Resultados de la detección de anomalías

La figura 4b muestra el resultado del modelo de detección de anomalías en forma de matriz de confusión, que representa la predicción de las muestras correctamente frente a las incorrectamente. La figura 4a representa la curva ROC de la tasa de verdaderos positivos frente a la tasa de falsos positivos con una puntuación AUC.

El modelo de detección de anomalías ha alcanzado un alto rendimiento con una precisión del 99,46%, una exactitud del 99,98% para el tráfico normal y del 0,74% para las anomalías, y una puntuación F1 de 0,81 para las anomalías. El coeficiente de correlación de Matthews de 0,81 indica un sólido rendimiento predictivo. La curva ROC lo confirma con una puntuación AUC de 0,98, lo que resalta la capacidad del modelo para distinguir eficazmente entre tráfico normal y anómalo. La matriz de confusión mostrada en la figura a indica que el modelo identificó correctamente 508.711 instancias normales y 6.027 anomalías con un mínimo de falsos positivos y negativos.

Las gráficas anteriores muestran los registros de entrenamiento, ya que el modelo se entrenó con archivos CSV de varios días. Cada línea punteada horizontal roja representa un nuevo archivo CSV introducido en el modelo mediante aprendizaje incremental. La figura 4c muestra las tendencias de precisión de entrenamiento y validación a lo largo de las épocas. La figura 4d muestra la pérdida de entrenamiento y validación del modelo a lo largo de las épocas. La figura 4e muestra cómo evolucionaron la precisión y la exhaustividad a lo largo del entrenamiento. La figura 4f registra la progresión de la puntuación F1 a lo largo de las épocas de entrenamiento. Los registros de entrenamiento ilustran la progresión del aprendizaje del modelo, mostrando una precisión estable, una reducción de la pérdida y fuertes tendencias de precisión, exhaustividad y puntuación F1 a lo largo de las épocas. Esto demuestra que los resultados del modelo se generalizan bien, ya que el modelo de detección de anomalías captura eficazmente los patrones de tráfico.

Comparación del modelo con trabajos existentes

La Tabla 1 muestra la comparación con los trabajos existentes para la detección de anomalías. El modelo multietapa con LSTM propuesto muestra buenos resultados que superan a los enfoques existentes en todas las métricas clave. A diferencia de los trabajos existentes que se basan en CNN, YOLO o sistemas de aprendizaje automático, el modelo multietapa con LSTM captura eficazmente las dependencias temporales e integra factores climáticos externos, logrando la mayor precisión (99,53 %), exhaustividad (99,46 %) y puntuación F1 (99,48). Además, el AUC-ROC (99,08) y la tasa de verdaderos negativos (0,9959) demuestran sólidas capacidades de detección de anomalías, superando a los modelos tradicionales que carecen de un enfoque de aprendizaje secuencial multietapa.

Machine Translated by Google
www.nature.com/scientificreports/

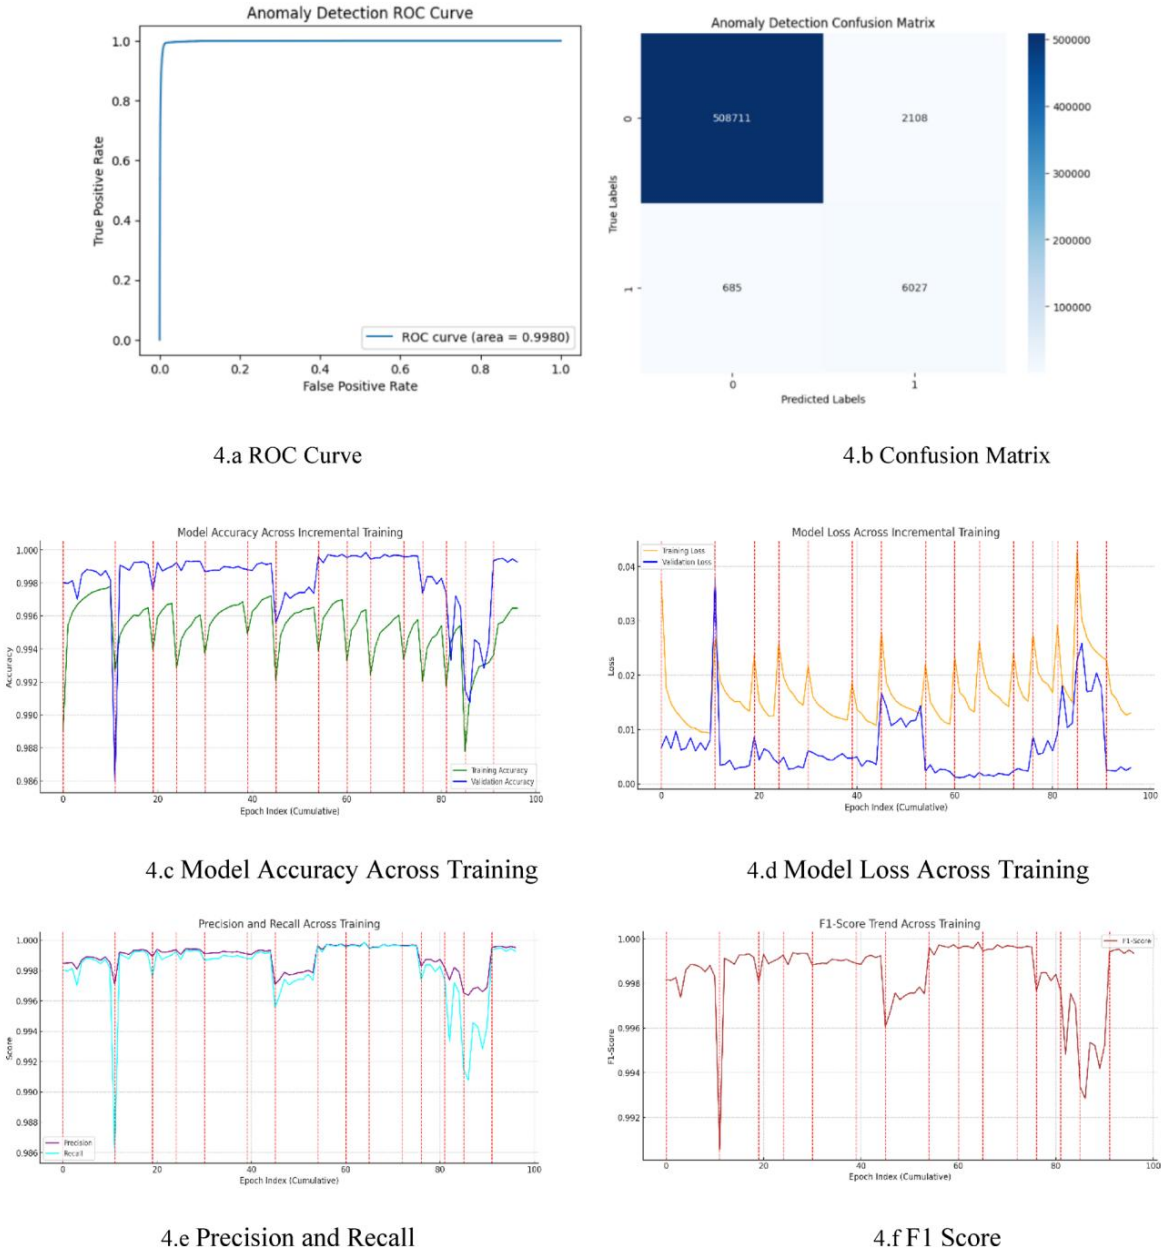


Figura 4. Evaluación del rendimiento del modelo propuesto.

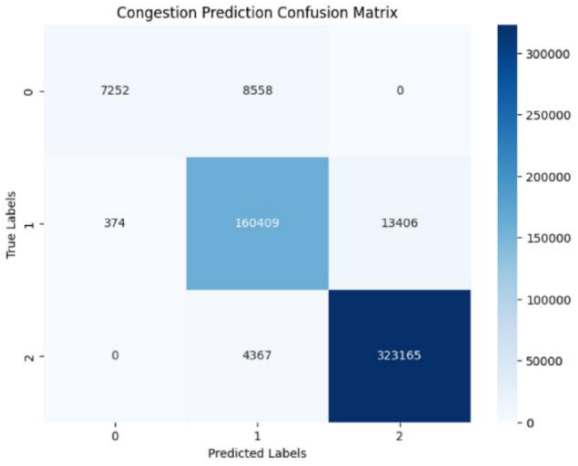
Primer autor (año)	Modelo	Conjunto de datos	Precisión, Recuperación, Puntuación F1, AUC-ROC, TPR, TNR					
Youcef Djenouri (2022)10 CNN con descomposición Armstrong		Datos de flujo de tráfico urbano (odense)	N/A	N/A/N/A		0,72	0,89	0,94
Aboah (2021)12 YOLOv5 + árbol de decisión My Driss Laanaoui		Desafío urbano de IA de NVIDIA	N / A	N/A 0,8571	N/A		N/A/N/A	
(2024)13 Sistema basado en aprendizaje automático Tianyang Lei (2023)11		Datos de tráfico en tiempo real	0,93	0,92	0,925	N / A	N/A/N/A	
LSTM + CNN + descomposición espectral Series temporales de flujo de tráfico (Pems) 0.89				0,7	0,78	0,98	N/A/N/A	
Trabajo propuesto	Multi-head + LSTM	PeMS + clima	99,53	99,46	99,48	99.8	0,8979	0,9959

Tabla 1. Comparación de la detección de anomalías con trabajos existentes. Los valores significativos están en negrita.

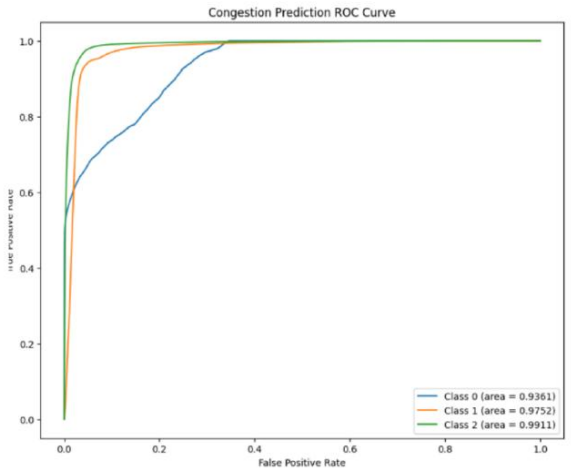
Resultados de la clasificación de la congestión

La figura 5a muestra el resultado del modelo de detección de clasificación de congestión en forma de matriz de confusión, que representa la predicción de las muestras correctamente predichas frente a las incorrectamente predichas. La figura 5b representa la curva ROC de la tasa de verdaderos positivos frente a la tasa de falsos positivos con una puntuación AUC para cada clase.

Machine Translated by Google
www.nature.com/scientificreports/



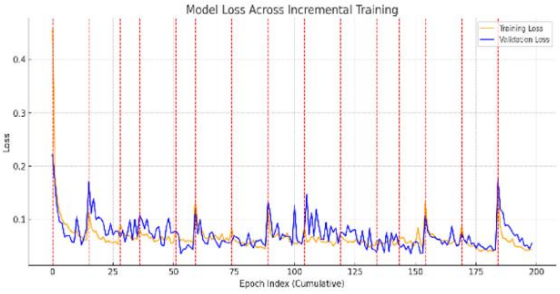
5.a Confusion Matrix



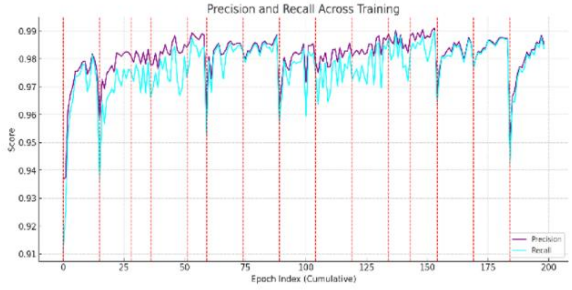
5.b ROC Curve



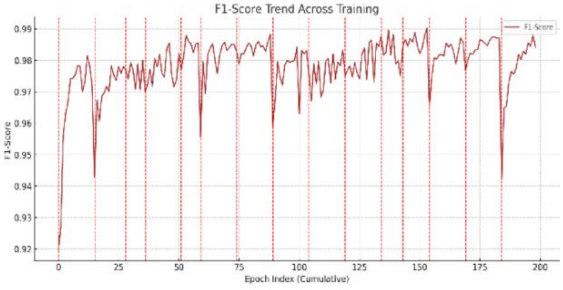
5.c Model Accuracy Across Training



5.d Model Loss Across Training



5.e Precision & Recall Across Training



5.f F1-Score Across Training

Figura 5. Evaluación del rendimiento del modelo propuesto.

El modelo de clasificación de congestión ha obtenido buenos resultados con una precisión general del 94,84% con una alta puntuación F1 del 94,55% y un MCC de 0,8922, lo que demuestra su eficacia en la clasificación de diferentes niveles de congestión. La matriz de confusión mostrada arriba en la Fig. 5a indica que el modelo clasifica correctamente la mayoría de las instancias con una clasificación errónea mínima en los tres niveles de congestión. La puntuación ROC-AUC de 0,9675 sugiere una excelente capacidad de discriminación entre las clases. Los altos valores de recuperación para los niveles de congestión medio y alto son 0,92 y 0,99 respectivamente, lo que indica que el modelo es capaz de clasificar eficazmente los escenarios de congestión significativos. Sin embargo, la menor recuperación de 0,46 para la congestión baja sugiere que la clasificación errónea se debe potencialmente a la superposición de las características.

Los gráficos anteriores son los registros de entrenamiento, ya que el modelo se entrenó con archivos CSV de varios días. Cada línea punteada horizontal roja representa un nuevo archivo CSV proporcionado de forma incremental. La figura 5c muestra las tendencias de precisión de entrenamiento y validación a lo largo de las épocas. La figura 5d muestra la pérdida de entrenamiento y validación del modelo a lo largo de las épocas. La figura 5e demuestra cómo evolucionaron la precisión y la exhaustividad durante el entrenamiento. La figura 5f muestra la progresión de la puntuación F1 a lo largo de las épocas de entrenamiento. Los gráficos de pérdida de entrenamiento y validación demuestran una convergencia estable a lo largo de las épocas sin sobreajuste significativo, mientras que las tendencias de precisión muestran mejoras consistentes en las tendencias de precisión-exhaustividad y puntuación F1 para reforzar la capacidad del modelo de mantener una gran generalización.

Comparación de modelos con trabajos existentes

La Tabla 2 muestra la comparación con trabajos existentes para la clasificación de la congestión. El modelo multi-Head+LSTM propuesto alcanza una precisión competitiva del 94,84%, que supera a los modelos basados en bosques aleatorios y demuestra una buena recuperación del 95% en comparación con trabajos existentes, lo que garantiza una detección eficaz de la congestión. La puntuación ROC-AUC del 98,41% indica una fuerte capacidad discriminatoria que supera significativamente la espacial.

El modelo de autoencoder de grafos temporales alcanza un AUC de 0,62, lo que demuestra su robustez. Si bien el modelo TAP logra una precisión superior del 96%, nuestro enfoque equilibra la precisión, la exhaustividad y la puntuación F1, lo que lo convierte en un modelo de clasificación de congestión altamente fiable.

Resultados de la clasificación de incidentes

La figura 6a muestra el resultado del modelo de detección de incidentes en forma de matriz de confusión, que representa la predicción de las muestras: las predichas correctamente y las predichas incorrectamente. La figura 6b representa la curva ROC de la tasa de verdaderos positivos frente a la tasa de falsos positivos, con una puntuación AUC para cada clase.

Para la tarea de clasificación de incidentes, el modelo demuestra un rendimiento excepcional, logrando buenos resultados de clasificación, como se muestra en la Fig. 6. La matriz de confusión mostrada en la Fig. 6b indica una clasificación errónea mínima, con solo 57 falsos positivos y 5 falsos negativos, lo que resalta la capacidad del modelo para detectar incidentes con precisión. El informe de clasificación muestra una alta precisión, exhaustividad y puntuación F1, lo que demuestra que el modelo es robusto para identificar la clase de incidente. La curva ROC-AUC en la Fig. 6a otorga una puntuación perfecta de 1, lo que demuestra el gran poder discriminatorio del modelo para separar los incidentes de los no incidentes.

Los gráficos anteriores muestran los registros de entrenamiento, ya que el modelo se entrenó con archivos CSV de varios días. Cada línea punteada horizontal roja representa un nuevo archivo CSV introducido en el modelo mediante aprendizaje incremental. La figura 6c muestra las tendencias de precisión de entrenamiento y validación a lo largo de las épocas. La figura 6d muestra la pérdida de entrenamiento y validación del modelo a lo largo de las épocas. La figura 6e muestra cómo evolucionaron la precisión y la exhaustividad a lo largo del entrenamiento. La figura 6f registra la progresión de la puntuación F1 a lo largo de las épocas de entrenamiento. Los registros indican las mejoras en la precisión y las tendencias de pérdida a lo largo de las épocas, con métricas de validación que se alinean estrechamente con las métricas de entrenamiento, lo que indica que el modelo generaliza bien a datos no vistos. Se observa una convergencia gradual de los valores de pérdida y la estabilidad de la precisión, la exhaustividad y la puntuación F1 a lo largo del entrenamiento.

Comparación del modelo con trabajos existentes

La Tabla 3 muestra la comparación con trabajos existentes para la clasificación de incidentes. El modelo propuesto supera a los métodos existentes en la clasificación de incidentes, logrando una buena precisión del 99,99% con una precisión, exhaustividad y puntuación F1 de 0,99, en comparación con trabajos anteriores como SAE (precisión del 92,72%) y network lasso (AUC-ROC de 1,0), y una tasa de falsas alarmas significativamente menor (0,011), lo que resalta la capacidad excepcional del modelo para minimizar las clasificaciones erróneas manteniendo una alta fiabilidad de detección.

Conclusión y trabajo futuro

Este estudio propone un modelo multi-cabeza con LSTM para la detección de anomalías, la clasificación de congestión y la clasificación de incidentes, entrenado con datos de tráfico PeMS e integrado con datos meteorológicos. El modelo superó consistentemente a los métodos existentes, logrando mayor precisión, exhaustividad, puntuación F1 y AUC-ROC en los tres objetivos.

La estrategia de entrenamiento incremental ayudó a mantener un aprendizaje estable y a prevenir el sobreajuste. Para la detección de anomalías, el modelo identificó con precisión las irregularidades con una curva de pérdida optimizada. La clasificación de congestión alcanzó una precisión del 94,84 % con una puntuación F1 del 95 %, superando trabajos anteriores como bosques aleatorios y autoencoders gráficos. De manera similar, el modelo de clasificación de incidentes también obtuvo resultados excepcionales con una precisión del 99,99 %, superando a modelos como Network Lasso, GAN-Transformers y enfoques basados en SAE.

Los resultados demuestran la importancia de integrar datos de tráfico y medioambientales para una monitorización precisa del tráfico en tiempo real, lo que convierte al modelo propuesto en un firme candidato para un sistema de transporte inteligente.

El modelo multi-cabeza con LSTM propuesto enfrenta algunos desafíos clave, algunos de los cuales son el desequilibrio de datos y donde las anomalías e incidentes son raros, lo que lleva a un posible sesgo en la predicción La diversidad limitada de datos meteorológicos es una limitación clave ya que el estudio consideró solo 15 días de datos. En consecuencia, el modelo no ha estado expuesto a variaciones estacionales o de días festivos a largo plazo, lo que podría llevar a una deriva conceptual con el tiempo. Como extensión futura, planeamos incorporar conjuntos de datos multimensuales y multitemporales para validar la robustez del marco propuesto bajo diversas condiciones de tráfico. La interpretabilidad del modelo, ya que el modelo de aprendizaje profundo funciona como una caja negra, hace que sea difícil confiar en las predicciones del modelo. Para superar esto, se pueden utilizar técnicas de reequilibrio adaptativo como Temporally Constrained SMOTE (TCSMOTE) o aumento de datos basado en GANs se explorará en trabajos futuros, ya que estos enfoques respetan mejor las dependencias secuenciales en comparación con SMOTE estándar.

Las estrategias de aprendizaje en línea, el umbral de detección de anomalías autoajustable y las arquitecturas más ligeras pueden utilizarse para lograr un rendimiento en tiempo real y escalabilidad para su implementación en diversas condiciones de tráfico. El trabajo futuro también ampliará

Primer autor (año)	Modelo	Conjunto de datos	Precisión (%)	Exactitud	Recuperación	Puntuación F1	AUC
Syed Ammad Ali Shah (2024) 19	Bosque aleatorio,	Sistema de gestión de riesgos de Caltrans	93.33	93,34	93.33	N/A	0,99
Zhiliu (2023)20	Autoencoders gráficos variacionales espaciotemporales	pems 8	xgb	96	0,95	93	94.4	0,62
Norman Bereczki18		Conjunto de datos de simulación	0.9	0,84	0,88	0,86	0,96
Trabajo propuesto	Multi-head + LSTM	PeMS + clima	94,84	95	95	95	98.41

Tabla 2. Comparación de la clasificación de la congestión con trabajos existentes. Los valores significativos están en negrita.

Machine Translated by Google
www.nature.com/scientificreports/

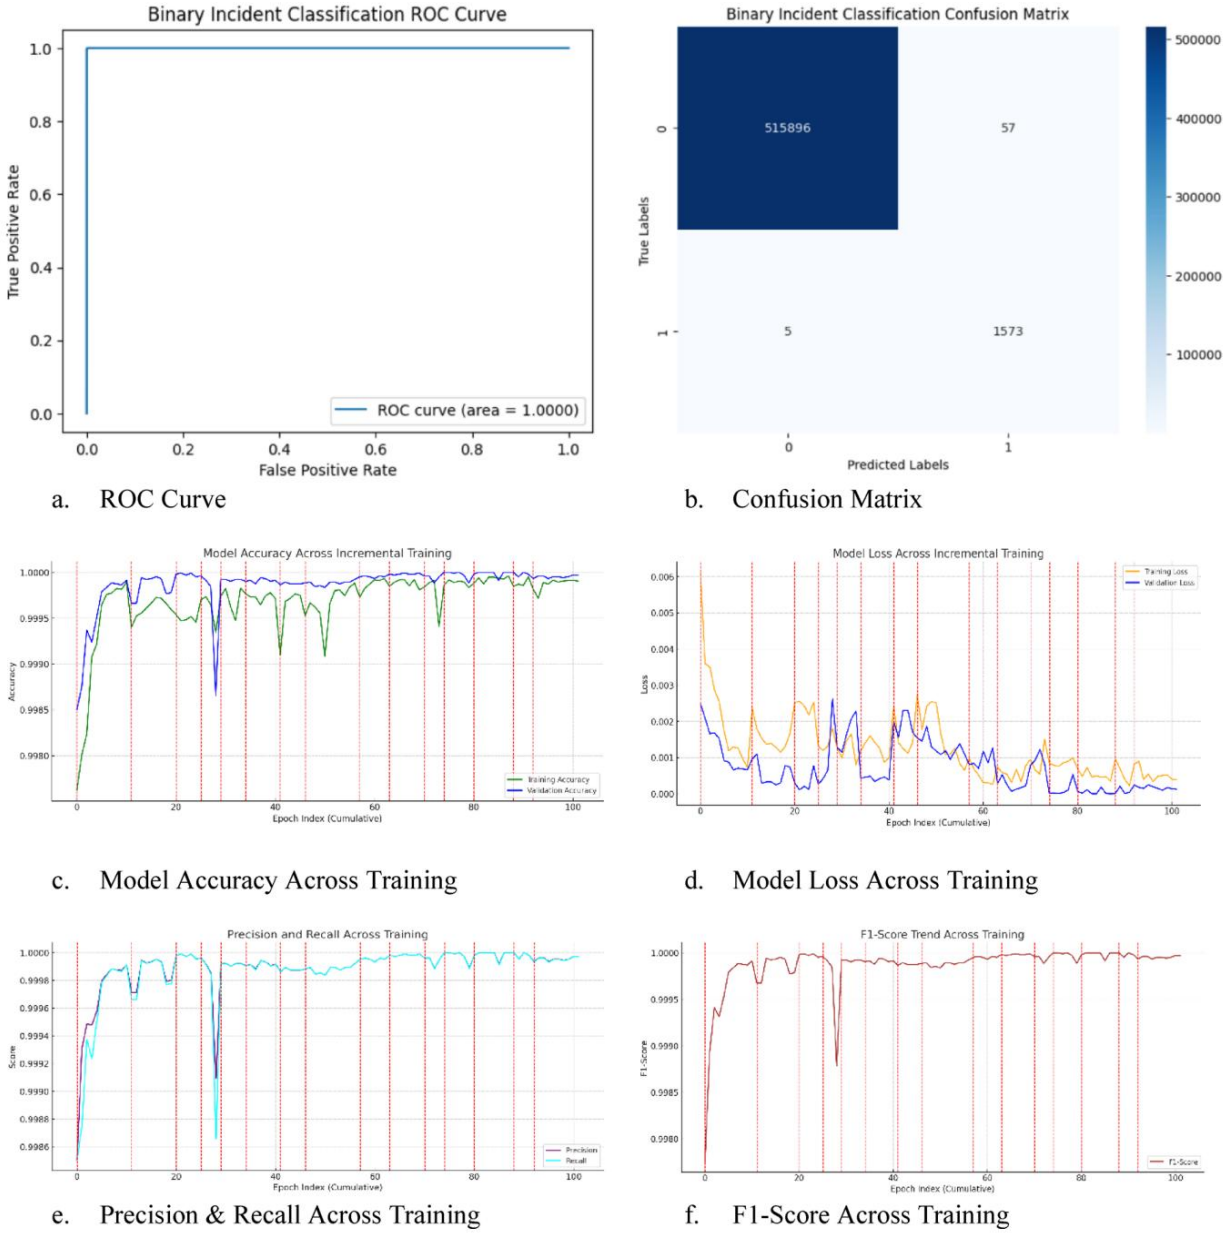


Figura 6. Evaluación del rendimiento del modelo propuesto.

Primer autor (año)	Modelo	Conjunto de datos	Exactitud	Precisión	Exhaustividad	Puntuación F1	AUC-ROC	DR	FAR	CR	MCC
Qiyuan Zhu (2024)26	Lazo de red	Datos de tráfico personalizados	0,97	N / A	N/A 0,79		0,94	0,88	N/AN/AN/A		
Xinying Lu (2024)23	GAN + Transformador PeMS PORTAL	Autopista	N / A	N / A	N/A/N/A		0,99	0,98	0,021	0,96	N/A
Tian Xie (2022) 24	SASYNO-RF-RSKNN	I-205.	N / A	0,94	N/A 0,96		N / A	0,97	0,061	No disponible	0,91
Rajalakshmi Gurusamy (2023)25	SAE	Sistema de gestión de riesgos de Caltrans	92,73	0,98	0,89	0,85	0,94	N/AN/AN/A			
Trabajo propuesto	PeMS multicabezal +LSTM + información meteorológica		99,99	0,99	0,99	0,99	1	0,9968	0,011	0,99	0,98

Tabla 3. Comparación de la clasificación de incidentes con trabajos previos. Los valores significativos están en negrita.

Machine Translated by Google
www.nature.com/scientificreports/

La comparación incluirá modelos avanzados basados en Transformer para evaluar nuestro marco de trabajo frente a las arquitecturas SOTA más recientes.

Disponibilidad de datos

Los conjuntos de datos generados y/o analizados durante el presente estudio están disponibles en el repositorio PeMS, [https://dot.ca.gov/programs/traffic-operations/mpr/pems-source].

Recibido: 11 de junio de 2025; Aceptado: 3 de diciembre de 2025
Published online: 08 December 2025

Referencias

1. Adewopo, VA y Elsayed, N. Transporte en ciudades inteligentes: Enfoque de aprendizaje profundo en conjunto para la detección de accidentes de tráfico. IEEE Acceso (2024).
2. Abraham, A., Zhang, Y. y Prasad, S. Marco de gestión de evacuación para un sistema inteligente de respuesta interactiva ante emergencias en toda la ciudad. Preimpresión de arXiv: arXiv:2403.07003 (2024).
3. Almukhalfi, H., Noor, A. y Noor, TH Enfoques de gestión del tráfico utilizando técnicas de aprendizaje automático y aprendizaje profundo: Un Encuesta. Eng. Appl. Artif. Intell. 133, 108147 (2024).
4. Azfar, T. et al. Métodos de visión artificial basados en aprendizaje profundo para la percepción de entornos de tráfico complejos: una revisión. Data Sci. Transp. 6, 1 (2024).
5. Fährmann, D. Martín, L. Sánchez, L. y Damer, N. Detección de anomalías en entornos inteligentes: una revisión exhaustiva. En IEEE Acceso. 12, 64006–64049, (2024).
6. Iqbal, A. y Amin, R. Pronóstico de series temporales y detección de anomalías mediante aprendizaje profundo. Comput. Chem. Eng. 182, 108560 (2024).
7. Kong, X. et al. Detección de anomalías en trayectorias móviles: taxonomía, metodología, desafíos y direcciones. IEEE Internet Things J. 11, 19210 (2024).
8. Kun Wang, YuFu., Duan, X., Liu, T. y Jianqiao, Xu. Sistema de detección de tráfico anómalo en SDN basado en aprendizaje profundo híbrido modelos. Comput. Commun. 216, 183–194 (2024).
9. Van Engelen, JE y Hoos, HH Un estudio sobre el aprendizaje semisupervisado. Mach. Learn. 109(2), 373–440 (2020).
10. Djenouri, Y., Belhadi, A., Chen, HC y Lin, JCW Red inteligente de fusión profunda para la identificación de anomalías en el flujo de tráfico urbano. Comput. Commun. 189, 175–181 (2022).
11. Lei, T. et al. Un nuevo marco no supervisado para la detección de anomalías en datos de series temporales mediante descomposición espectral. Knowl. Based Syst. 280, 111002 (2023).
12. Aboah, A. Un sistema basado en visión para la detección de anomalías de tráfico utilizando aprendizaje profundo y árboles de decisión. En Actas del IEEE/ Conferencia CVF sobre Visión por Computadora y Reconocimiento de Patrones. (2021).
13. Laanaoui, MD, Lachgar, M., Mohamed, H., Hamid, H., Villar, SG y Ashraf, I. Mejora de la gestión del tráfico urbano mediante Detección de anomalías en tiempo real y equilibrio de carga. En IEEE Access, vol. 12, pp. 63683–63700, (2024).
14. Butler, L., Yigitcanlar, T. y Paz, A. Innovaciones en movilidad urbana inteligente: una revisión y evaluación exhaustivas. IEEE Access 8, 196034–196049 (2020).
15. Xu, S., Sun, C. y Liu, N. Congestión vial y contaminación del aire: análisis de los efectos de la congestión espacial y temporal. Sci. Total Environ. 945, 173896 (2024).
16. Buiya, MR et al. Detección de ciberataques de IoT: modelos avanzados de aprendizaje automático para una mayor seguridad en el tráfico de red. J. Computadora. Ciencia. Tecnología. Estudio. 6(4), 142-152 (2024).
17. Kumar, K., Kumar, M. y Das, P. Pronóstico de congestión de tráfico mediante redes neuronales profundas multicapa. Transp. Lett. 16(6), 516–526 (2024).
18. Bereczki, N. y Simon, V. Un novedoso sistema de reconocimiento de congestión de tráfico basado en aprendizaje automático. En 2023 22nd International Symposium INFOTEH-JAHORINA (INFOTEH). IEEE (2023).
19. Shah, SAA, Fernando, X. y Kashef, R. Clasificación mejorada de la congestión vehicular mediante aprendizaje automático para VANETs. En Conferencia Internacional de Sistemas IEEE 2024 (SysCon). IEEE (2024).
20. Liu, Z. et al. TAP: Perfilado de accidentes de tráfico mediante aprendizaje de representación gráfica espaciotemporal multitarea. ACM Trans. Knowl. Discov. Data 17(4), 1–25 (2023).
21. Olugbade, S., Ojo, S., Imoize, AL, Isabona, J. y Alaba, MO Una revisión de la inteligencia artificial y el aprendizaje automático para incidentes Detectores en sistemas de transporte por carretera. Math. Comput. Appl. 27(5), 77 (2022).
22. Remil, Y., Bendimerad, A., Mathonat, R. y Kaytoue, M. Soluciones Aiops para la gestión de incidentes: Directrices técnicas y un Revisión bibliográfica exhaustiva. Preimpresión de arXiv arXiv:2404.01363 (2024).
23. Lu, X., Zhang, D. y Xiao, J. Un modelo híbrido para la detección de incidentes de tráfico basado en redes generativas antagónicas y transformador modelo. Preimpresión de arXiv arXiv:2403.01147 (2024).
24. Xie, T., Shang, Q. y Yang, Yu. Detección automatizada de incidentes de tráfico: Cómo lidiar con conjuntos de datos pequeños y desequilibrados. IEEE Access 10, 35521–35540 (2022).
25. Gurusamy, R., Mahalakshmi, M., Divya Bharathi, M. y Harishmaashree, G. Detección de incidentes mediante LSTM y SAE. Int. J. Ciencias. Res. Comput. Sci. Eng. Inf. Technol. IJSRCSEIT 9(8), 138–145 (2023) (ISSN : 2456-3307).
26. Zhu, Q., Qin, AK, Abeysekara, P., Dia, H. y Grzybowska H. "Detección descentralizada de incidentes de tráfico mediante Network Lasso", arXiv preimpresión arXiv:2402.18167 (2024).

Expresiones de gratitud

Todos los autores aprobaron la versión del manuscrito que se publicará.

Contribuciones de los autores

1. Pratik Jadhav—Conceptualización, Metodología; Administración del proyecto; Supervisión; Roles/Redacción—borrador original; Redacción—revisión y edición. 2. Abderrahim Benslimane—Curación de datos, Análisis formal, Investigación, Validación; Visualización; Roles/Redacción—borrador original. 3. Dra. Deepali Vora—Curación de datos, Análisis formal, Metodología; Administración del proyecto; Supervisión; Redacción—revisión y edición. 4. Dra. Shruti Patil—
Metodología; Administración del proyecto; Recursos; Validación; Visualización; Redacción: revisión y edición.

Fondos

Financiación de acceso abierto proporcionada por Symbiosis International (Universidad reconocida).

Machine Translated by Google
www.nature.com/scientificreports/

Declaraciones

Intereses contrapuestos

Los autores declaran no tener ningún conflicto de intereses.

Información adicional

La correspondencia y las solicitudes de materiales deben dirigirse a DRV.

La información sobre reimpresiones y permisos está disponible en www.nature.com/reprints.

Nota del editor: Springer Nature mantiene una postura neutral con respecto a las reivindicaciones jurisdiccionales en los mapas publicados y las afiliaciones institucionales.

Acceso abierto. Este artículo está bajo la licencia Creative Commons Atribución-NoComercial-SinDerivadas 4.0 Internacional, que permite cualquier uso no comercial, compartir, distribuir y reproducir en cualquier medio o formato, siempre que se dé el crédito correspondiente al autor o autores originales y a la fuente, se proporcione un enlace a la licencia Creative Commons y se indique si se ha modificado el material licenciado. Bajo esta licencia, no se tiene permiso para compartir material adaptado derivado de este artículo o partes del mismo. Las imágenes u otro material de terceros incluidos en este artículo están sujetos a la licencia Creative Commons del artículo, a menos que se indique lo contrario en la línea de crédito del material. Si el material no está incluido en la licencia Creative Commons del artículo y su uso previsto no está permitido por la normativa vigente o excede el uso permitido, deberá obtener el permiso directamente del titular de los derechos de autor. Para ver una copia de esta licencia, visite http://creativecommo
ns.org/licenses/by-nc-nd/4.0/.

© El/los autor/es 2025