Machine Translated by Google

Transportation Research Part C 184 (2026) 105536

Los índices de contenidos están disponibles en ScienceDirect.

Investigación en transporte, parte C

Página principal de la revista: www.elsevier.com/locate/trc

Sobre la aplicabilidad de los métodos de detección de anomalías en series temporales a datos de volumen de tráfico del mundo real

Iman Taheri Sarteshnizi, Majid Sarvi, Saeed Asadi Bagloee, Neema Nassir

Departamento de Infraestructura, Universidad de Melbourne, Melbourne, Australia

información del artículo

Palabras clave:
Detección de anomalías
detección de valores atípicos
Aprendizaje automático
Aprendizaje profundo
Datos de series temporales
Datos de volumen de tráfico
etiquetas de verdad fundamental

abstracto

La detección de anomalías en series temporales (TSAD o TAD) se refiere a la identificación automática y basada en datos de segmentos anómalos en datos de series temporales, una tarea que se ha estudiado ampliamente durante décadas. A pesar de los recientes hallazgos transformadores y novedosos revelados por los esfuerzos en este campo, la literatura sobre La detección de anomalías en el tráfico aún no ha reflejado completamente estas tendencias emergentes para extraer conclusiones prácticas. conclusiones. En este artículo, nos centramos en la aplicabilidad de tecnologías de vanguardia y bien establecidas. Los métodos TAD para los datos de volumen de tráfico rodado hacen contribuciones de dos maneras principales. Primero, dado La contribución probada y importante de los datos de evaluación a los resultados de TAD, argumentamos que los existentes Los conjuntos de datos etiquetados con anomalías de los sistemas de transporte y tráfico requieren mejoras sustanciales en términos tanto del tamaño de los datos como de la calidad de las etiquetas. Para abordar esto, proponemos una nueva plataforma para inspeccionar y etiquetar grandes volúmenes de datos de áreas urbanas en función de sus características únicas y la taxonomía más reciente de anomalías de series temporales. En segundo lugar, basándonos en el marco establecido, también formulamos el problema TAD en datos de volumen de tráfico e introducimos un enfoque basado en discordancia, incrustado en el contexto, y un método ligero de detección de anomalías de tráfico, llamado Step-isolated Traffic Discords Discovery (Si-TDD), para abordar este problema. Beneficiándonos de nuestra plataforma de etiquetado, AnoLT (Anomaly Labeled Traffic) se presenta en este documento por primera vez como una herramienta integral de código abierto, y un conjunto de datos espaciotemporales etiquetados con anomalías recopilados de 147 ubicaciones en Melbourne, Australia. Los resultados comparativos con más de 20 líneas base también indican que Si-TDD considerablemente Supera a las soluciones TAD recientes en lo que respecta a los datos de volumen de tráfico, logrando una puntuación F1 del 67%. con el conjunto de datos AnoLT. Este documento destaca el papel clave de incorporar información relacionada con el contexto en las soluciones TAD existentes para aumentar su eficacia en la detección de anomalías de tráfico, una un factor que a menudo se pasa por alto en la literatura actual.

1. Introducción

Los datos de series temporales de conteo/volumen de tráfico rodado se encuentran entre los recursos más vitales utilizados en la gestión de las redes de tráfico. La detección automática de valores atípicos (o anomalías) en estos datos es esencial, ya que puede contribuir tanto a la seguridad como a la eficiencia del sistema. (Wang y Sun, 2021; Sarteshnizi et al., 2023). La detección de anomalías de tráfico no solo proporciona información valiosa para comprender y Gestiona el rendimiento del tráfico tanto en situaciones en tiempo real como fuera de línea, pero también ayuda a mantener la fiabilidad de la información registrada. a partir de detectores, lo cual es esencial para un modelado y predicción de tráfico eficaces.

Autor correspondiente.
Direcciones de correo electrónico: itaherisarte@student.unimelb.edu.au (I. Taheri Sarteshnizi), majid.sarvi@unimelb.edu.au (M. Sarvi), saeed.bagloee@unimelb.edu.au (SA Bagloee), neema.nassir@unimelb.edu.au (N. Nassir).

https://doi.org/10.1016/j.trc.2026.105536
Recibido el 14 de febrero de 2025; Recibido en forma revisada el 16 de diciembre de 2025; Aceptado el 18 de enero de 2026.
Disponible en línea a partir del 27 de enero de 2026.
0968-090X/© 2026 El/los autor(es). (http://creativecommons.org/licenses/by/4.0/). Publicado por Elsevier Ltd. Este es un artículo de acceso abierto bajo la licencia CC BY.

Machine Translated by Google

A diferencia de los estudios de detección de incidentes, que en su mayoría identifican interrupciones operativas en redes equipadas continuamente con detectores y se basan principalmente en información sobre la velocidad del tráfico (Kalair y Connaughton, 2021; Chakraborty et al., 2019), está surgiendo un creciente conjunto de trabajos que examinan las anomalías de los datos de tráfico desde una perspectiva más centrada en los datos. Esta línea de investigación, incluido el presente estudio, tiene como objetivo detectar todas las inconsistencias de los datos, definidas como segmentos que se desvían considerablemente de los patrones históricos dominantes de los datos, independientemente de sus causas subyacentes o de si realmente corresponden a incidentes de tráfico (Sarteshnizi et al., 2023; Deng et al., 2022). Si bien la detección de eventos operativos en los datos de tráfico (como incidentes) es valiosa, cabe señalar que los datos de tráfico pueden presentar diversos tipos de anomalías, incluidos picos o caídas puntuales abruptas, cambios repentinos o moderados en subsecuencias y/o desviaciones prolongadas de los perfiles típicos, lo que a su vez puede proporcionar información adicional o incluso complicar los procesos de detección de eventos. Estas inconsistencias pueden deberse a diversos factores, como incidentes, condiciones climáticas extremas, sensores defectuosos y fluctuaciones impredecibles de la demanda. La detección automática de anomalías en los datos también ofrece oportunidades para una amplia gama de tareas posteriores. Estas abarcan desde revelar patrones ocultos en grandes conjuntos de datos y facilitar a los analistas el acceso a intervalos sospechosos durante los análisis exploratorios, hasta gestionar la calidad de los datos para los procesos automatizados de modelado o simulación y habilitar activadores operativos cuando se observan ciertos tipos de patrones. Por lo tanto, detectar estas anomalías en grandes conjuntos de datos de forma no supervisada, antes de explorar sus causas y consecuencias, es fundamental y ha cobrado nueva relevancia recientemente, especialmente con el rápido crecimiento de la investigación en Detección de Anomalías en Series Temporales (Zamanzadeh Darban et al., 2024).

La detección de anomalías en series temporales (TSAD o TAD), como tema general, ha sido ampliamente investigada durante muchos años, lo que ha dado lugar a diversas soluciones para abordar sus desafíos únicos (Schmidl et al., 2022). Recientemente, el progreso en esta área ha revelado algunos supuestos fundamentalmente erróneos utilizados en los procesos de evaluación de los trabajos de vanguardia (Nakamura et al., 2023; Kim et al., 2022; Hwang et al., 2022). Estos descubrimientos están cobrando prominencia, enfatizando la importancia de adoptar nuevas perspectivas en los "procesos de evaluación" en lugar de centrarse únicamente en los avances "metodológicos" (Lai et al., 2021b). El componente principal criticado en estos procesos son los datos en sí, ya que se ha demostrado que, con nuevas configuraciones de datos, no se puede afirmar la superioridad de los métodos avanzados sobre los algoritmos clásicos (Liu y Paparrizos, 2024). Tanto en entornos supervisados como no supervisados, los profesionales requieren datos etiquetados para validar soluciones hipotéticas. Sin embargo, obtener dichos datos es un desafío, especialmente porque a menudo se desconocen las ocurrencias exactas de las anomalías. Si bien existen varios conjuntos de datos de referencia TAD del mundo real, algunos relacionados con el tráfico urbano, se ha observado que se desvían significativamente del estándar ideal. Por ejemplo, Wu y Keogh (2021) demostraron que muchos de estos conjuntos de datos, incluida la demanda de taxis de la ciudad de Nueva York (Ahmad et al., 2017), presentan fallas y crean una ilusión de progreso. Como resultado, los investigadores han comenzado a desarrollar nuevos conjuntos de datos, a menudo sintetizados, para abordar estas deficiencias de evaluación (Wang y Sun, 2021). Este enfoque en conjuntos de datos sintetizados también está generando una comprensión limitada del desempeño de las soluciones propuestas en escenarios del mundo real. Las anomalías en los datos del mundo real son inherentemente más complejas debido a la presencia de ruido, diversas calidades de datos y distintos niveles de variabilidad.
Según estudios recientes, los indicadores de rendimiento suelen experimentar una caída significativa cuando las soluciones existentes se evalúan con conjuntos de datos del mundo real (Paparrizos et al., 2022; Lai et al., 2021b).

Además de estos desafíos relacionados con los datos, que siguen siendo frecuentes y requieren atención, surgen otros puntos de los estudios centrados específicamente en la detección de anomalías en los datos de tráfico. Primero, los datos de evaluación en varios trabajos provienen de recursos privados y no pueden aprovecharse en esfuerzos futuros (Kalair y Connaughton, 2021; Parsa et al., 2019). Segundo, a menudo utilizan informes de incidentes o información de eventos públicos como etiquetas de referencia para los datos de tráfico. Esto introduce nuevos desafíos en los experimentos de evaluación, ya que los recursos públicos no informan sobre todas las anomalías existentes (Chakraborty et al., 2019; Sarteshnizi et al., 2023). Tercero, los métodos de referencia empleados en el dominio del tráfico urbano suelen ser incompatibles entre diferentes trabajos, lo que da lugar a afirmaciones variadas y a la falta de conclusiones claras sobre el mejor método (He et al., 2023; Wang y Sun, 2021; Deng et al., 2022). Los investigadores suelen centrarse en perspectivas específicas para la detección de anomalías, con la necesidad de profundizar en la justificación de estos enfoques y su valor añadido en comparación con trabajos anteriores. Por último, pero no menos importante, se observan pocos esfuerzos para conectar los hallazgos de los estudios generales de TAD con las perspectivas del tráfico urbano. Si bien ha resurgido el interés por los métodos univariados clásicos en TAD a raíz de una revisión del problema y las definiciones (Nakamura et al., 2023; Liu y Paparrizos, 2024), su transferibilidad aún no se ha explorado completamente en el contexto de los datos de tráfico. Por otro lado, a pesar de la disponibilidad de diversos conjuntos de datos de tráfico urbano en TAD (Zamanzadeh Darban et al., 2024), la calidad y la idoneidad de estos conjuntos de datos representativos aún no se han analizado desde la perspectiva de la ingeniería de tráfico.

Para avanzar en las lagunas de investigación mencionadas, nos centramos en explorar la aplicabilidad de los métodos TAD a los datos de volumen de tráfico y profundizamos en el modelado univariado , ya que este aún no se ha explorado. Las razones principales para esto son dos. Primero, a pesar de ser reconocido como un tipo de solución TAD competitivo e incluso más exitoso (Nakamura et al., 2023; Tafazoli y Keogh, 2023), existe una comprensión limitada del rendimiento de las soluciones univariadas cuando se aplican a datos de tráfico reales y a gran escala (Sarteshnizi et al., 2023). Evidencia sustancial sugiere que generalizar los enfoques univariados a entornos multivariados ofrece una vía más robusta para abordar TAD en diversos contextos, ya que permite soluciones más perspicaces, inclusivas de escenarios y ligeras (Wu y Keogh, 2021; Yeh et al., 2024). En segundo lugar, los estudios relevantes en el ámbito del tráfico urbano suelen considerar el aprendizaje profundo o los métodos espaciotemporales avanzados como soluciones predeterminadas, sin comparar ni justificar sus ideas frente a métodos univariados más personalizados (Deng et al., 2022; Wang y Sun, 2021). Según las definiciones de anomalías existentes hasta el momento, los tipos de anomalías se definen únicamente en función de la progresión de la serie, lo que permite detectarlas teóricamente si el patrón univariado se refleja con precisión. Por lo tanto, nuestro objetivo es garantizar que se aprovechen al máximo las soluciones univariadas existentes, especialmente las ya consolidadas, antes de abordar el modelado complejo en la detección de anomalías en series temporales de tráfico.

En este trabajo, nuestro objetivo es establecer una base en la detección de anomalías de tráfico, adaptando primero las definiciones de anomalías basadas en datos y luego examinando y refinando los métodos univariados actuales. Partiendo de una taxonomía reciente de anomalías en datos de series temporales y las características del flujo de tráfico, diseñamos un marco de etiquetado visual y centrado en datos para anotar rigurosamente todas las anomalías de datos en un conjunto de datos de volumen de tráfico a gran escala. Esta plataforma permite la creación de etiquetas completas de referencia para datos de tráfico del mundo real.

Machine Translated by Google

de una manera basada en datos, facilitando su uso en estudios comparativos. Luego, proporcionamos una formulación sistemática del problema para evaluar varios métodos TAD de última generación en la automatización del proceso de etiquetado utilizando los datos obtenidos. Inspirados por el concepto de discordancia de series temporales, que ha mostrado un éxito notable en muchos problemas (Wu y Keogh, 2021), también presentamos un método de detección personalizado, ligero y efectivo llamado Step-isolated Traffic Discords Discovery (Si-TDD). Este método luego se muestra y discute que supera a las líneas base de última generación de la literatura. Beneficiándonos de nuestra plataforma de etiquetado, también presentamos AnoLT (Anomaly Labeled Traffic), un nuevo conjunto de datos de volumen de tráfico etiquetado de código abierto, del mundo real y de grano fino.1 Este conjunto de datos ha sido monitoreado meticulosamente por dos expertos independientes y ofrece una nueva perspectiva basada en datos para la evaluación TAD en datos de tráfico urbano. AnoLT incluye más de 3 millones de puntos de datos etiquetados de 147 secciones de carretera ubicadas en intersecciones semaforizadas en Melbourne, Australia.

En resumen, las principales contribuciones de este artículo se pueden enumerar de la siguiente manera:

- Hasta donde sabemos, este artículo es uno de los primeros en analizar la aparición de diferentes tipos de anomalías en series temporales.
  datos de volumen de tráfico y derivar etiquetas de referencia completas para ellos utilizando enfoques de observación rigurosos.
- Se presenta un nuevo conjunto de datos de volumen de tráfico a gran escala y de código abierto (AnoLT) con dos conjuntos independientes de etiquetas de anomalías, desarrollado utilizando la taxonomía de anomalías basada en datos más reciente. • Se evalúan varios
  métodos de detección de anomalías con AnoLT por primera vez, discutiendo la aplicabilidad de los métodos TAD en
  datos de tráfico y haciendo hincapié en la importancia de su adaptación personalizada antes de su implementación en este dominio.
- En este trabajo se demuestra la eficacia de un método personalizado y ligero (Si-TDD), mostrando su capacidad para resaltar anomalías en un conjunto de datos de volumen de tráfico grande y etiquetado explícitamente, con un rendimiento que supera al de los métodos de aprendizaje automático y aprendizaje profundo más avanzados.

En el resto del artículo, primero analizamos trabajos recientes en la Sección 2. Los tipos de anomalías, nuestro marco de etiquetado de datos y los métodos de detección se explican en la Sección 3. Los resultados y el análisis pertinente se presentan en la Sección 4. Finalmente, un resumen del artículo, junto con las conclusiones, se presenta en la Sección 5.

2. Trabajos relacionados

2.1. Detección de anomalías en series temporales (TAD)

La investigación sobre la detección de anomalías/valores atípicos en datos de series temporales univariadas y multivariadas se ha llevado a cabo durante varias décadas (Fox, 1972). Comenzó con el aprovechamiento de medidas estadísticas, como la mediana y los umbrales (Basu y Meckesheimer, 2007). Posteriormente, surgieron enfoques más avanzados para aplicaciones específicas, como métodos de suavizado (Chen et al., 2010), métodos predictivos clásicos (ARIMA) (Akouemo y Povinelli, 2014) y modelos de mezcla gaussiana (GMM) (Reddy et al., 2017). Con la llegada de la era del big data y el surgimiento de métodos de aprendizaje automático y aprendizaje profundo, numerosos estudios han buscado abordar la detección de anomalías/valores atípicos utilizando estas técnicas innovadoras (Aggarwal, 2016; Du et al., 2017; Liu et al., 2019; Geiger et al., 2020). A pesar de las ventajas atribuidas a los métodos basados en el aprendizaje TAD, ha surgido un nuevo enfoque de investigación que enfatiza el proceso de evaluación por encima de la metodología en sí. Por ejemplo, Wu y Keogh (2021) analizaron la calidad de los conjuntos de datos de referencia existentes, destacando varios problemas, incluyendo conjuntos de etiquetas inexactos y una falta de diversidad entre ellos. Kim et al. (2022) también argumentaron que el método de ajuste de puntos utilizado para mitigar los problemas de verdad fundamental en estudios anteriores resulta en una sobreestimación del rendimiento. Inspirados por los resultados de estos artículos, los investigadores han iniciado nuevos estudios comparativos exhaustivos para abordar los sesgos y reevaluar las soluciones existentes (Lai et al., 2021b; Paparrizos et al., 2022; Nakamura et al., 2023; Liu y Paparrizos, 2024). Sorprendentemente, los hallazgos de estos trabajos no demostraron ninguna superioridad significativa de los enfoques recientes de aprendizaje profundo en comparación con los métodos clásicos en TAD cuando se aplican a diversas aplicaciones. De hecho, revelaron que el resultado de TAD varía según la aplicación específica y las características de los datos, y que los métodos clásicos demuestran una mayor tasa de éxito en muchos escenarios diferentes.

Desde la perspectiva de los datos , una revisión de la literatura también resalta la necesidad crítica de desarrollar nuevos conjuntos de datos. Los conjuntos de datos de Yahoo (Laptev et al., 2015), NAB (Ahmad et al., 2017), NASA (Hundman et al., 2018) y OMNI (Su et al., 2019) se encuentran entre los principales en este ámbito. Si bien varios estudios se han beneficiado de estos conjuntos de datos (Geiger et al., 2020), presentan una serie de problemas, como trivialidad, datos mal etiquetados, densidad de anomalías problemática y sesgo de ejecución hasta el fallo (Wu y Keogh, 2021). Para mitigar estos desafíos, algunos científicos comenzaron a utilizar conjuntos de datos recién sintetizados para sus evaluaciones, lo que permite una comparación más justa de los métodos TAD (Lai et al., 2021b; Zhang et al., 2019a; Ren et al., 2019; Feremans et al., 2020). En algunos casos, también se explora el desarrollo de nuevos conjuntos de datos del mundo real. WADI (Ahmed et al., 2017) y SWaT (Goh et al., 2017) son dos conjuntos de datos del mundo real destacados recopilados de sensores en un banco de pruebas de distribución y tratamiento de agua, respectivamente. SMD (Su et al., 2019) es otro conjunto de datos que contiene datos de máquinas servidoras. En estos conjuntos de datos, los datos de entrenamiento están libres de anomalías y las etiquetas de verdad fundamental en los datos de prueba se registran a partir de cambios del sistema planificados previamente. Aunque estos conjuntos de datos se utilizan ampliamente en TAD, cabe señalar que los datos de entrenamiento libres de anomalías se alinean más con la rama de detección de novedades que con la de detección de anomalías. También se puede observar una colección de los últimos conjuntos de datos públicos de diversos dominios en los trabajos de Paparrizos et al. (2022) y Zamanzadeh Darban et al. (2024). Si bien en sus colecciones se puede observar una amplia gama de dominios como la salud (Moody y Mark, 2001), los datos de telemetría de naves espaciales (Hundman et al., 2018), el reconocimiento de la actividad humana (Roggen et al., 2010; Bachlin et al., 2009), así como el tráfico y el transporte (Ihler et al., 2006; Ahmad et al., 2017) , han proporcionado a sus colecciones varios otros conjuntos de datos sintéticos para ofrecer una oportunidad de evaluación comparativa más completa. Todos estos hallazgos enfatizan la falta de contribuciones a TAD con nuevos conjuntos de datos del mundo real . El reciente

[1] https://github.com/imaantaheri/AnoLT

Machine Translated by Google

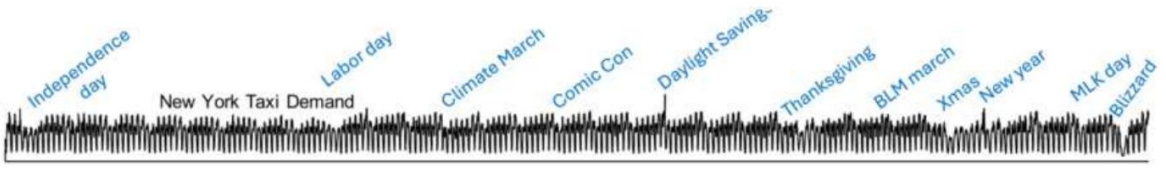


Figura 1. Vista general de un conjunto de datos de referencia de tráfico de muestra y sus etiquetas de referencia en estudios TAD. Los datos muestran seis meses de demanda de tráfico en la ciudad de Nueva York (Ahmad et al., 2017; Nakamura et al., 2023).

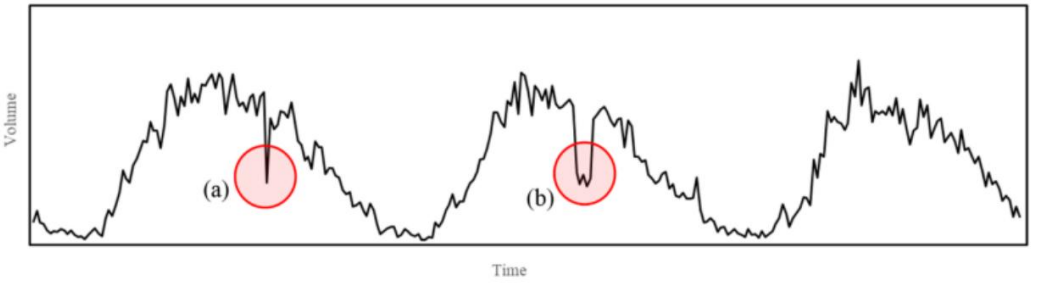


Figura 2. Anomalías inesperadas (a) puntuales y (b) subsecuencias detectadas en los datos de volumen de tráfico en días laborables típicos, sin eventos específicos vinculados a estos patrones.

El éxito de los modelos de lenguaje a gran escala (LLM, por sus siglas en inglés) (Touvron et al., 2023) también subraya con fuerza que el acceso a datos amplios y de alta calidad puede dar lugar igualmente a avances significativos.

Los conjuntos de datos relacionados con el transporte y el tráfico también se han utilizado en muchos estudios generales de TAD. La demanda de taxis de la ciudad de Nueva York (Ahmad et al., 2017), el conjunto de datos de los Dodgers (Ihler et al., 2006), el conjunto de datos CalIt2 (Hutchins, 2006) y el conjunto de datos del Metro (Hogue, 2019) son los ejemplos más destacados. Sin embargo, estos conjuntos de datos tienen limitaciones en cuanto a tamaño y tipo de anomalías. Además, las etiquetas de referencia en estos conjuntos de datos se basan únicamente en el conocimiento previo de eventos como días festivos y congestión planificada de la red (Nakamura et al., 2023).
En la Figura 1 se muestra una muestra de dichos datos y sus etiquetas de referencia. Se observa que las anomalías anotadas solo se relacionan con eventos que suelen alterar el patrón diario de la serie temporal. Sin embargo, al examinar con mayor detalle los datos de la serie temporal de tráfico, como se muestra en la Figura 2, se pueden identificar claramente otras anomalías durante los días típicos de la semana, las cuales no se pueden vincular a eventos predecibles. Desde un punto de vista práctico, es crucial detectar y anotar este tipo de anomalías con puntos de inicio y fin específicos, en lugar de centrarse únicamente en subsecuencias de larga duración, ya que esto ofrecería más oportunidades a los planificadores y modeladores de tráfico para aprovechar los datos. Esta perspectiva detallada se ignorará si solo nos basamos en los eventos registrados públicamente en los conjuntos de datos de tráfico.

2.2. Detección de anomalías en series temporales de tráfico/transporte

La detección de patrones anómalos en datos de tráfico urbano ha sido durante mucho tiempo un foco central de la investigación. Si bien algunos estudios abordaron la detección de anomalías en datos de tráfico microscópicos (Zarei Yazd et al., 2022; Sarteshnizi et al., 2022; Kazemeini et al., 2022), muchos otros se han concentrado en identificar anomalías, valores atípicos o eventos en datos de series temporales de tráfico macroscópicos, recopilados principalmente a partir de detectores de bucle fijos integrados en la superficie de las carreteras. La Tabla 1 proporciona una descripción detallada de estudios recientes en este último ámbito, que está estrechamente relacionado con nuestro enfoque. Según la tabla, la investigación existente se puede clasificar en dos ramas principales: una centrada en la detección de incidentes de tráfico y la otra en la detección de anomalías basada en datos, que investiga inconsistencias o irregularidades en los datos de una manera más exploratoria y generalizada.

Los estudios de detección de incidentes buscan alertar cuando el flujo normal de un segmento de carretera, generalmente una autopista o autovía, se ve interrumpido como resultado de incidentes. Se han explorado diversos métodos en este contexto, desde técnicas clásicas de umbralización robusta (Balke et al., 1996; Chakraborty et al., 2019) hasta arquitecturas avanzadas de aprendizaje profundo (Duan et al., 2024; Coursey et al., 2024). Dado que el objetivo en esta categoría es detectar incidentes con precisión y minimizar las falsas alarmas, a menudo se emplean datos de tráfico de alta resolución (a veces a nivel de carril), con un fuerte énfasis en la "velocidad" del tráfico aguas arriba y aguas abajo (Chakraborty et al., 2019; Coursey et al., 2024). En línea con este enfoque, los informes de incidentes se utilizan ampliamente como datos de referencia en los procesos de evaluación de estos estudios (Kalair y Connaughton, 2021). Sin embargo, también se han reconocido las limitaciones de dichos registros, ya que a menudo carecen de precisión temporal y espacial debido a la naturaleza impredecible de los incidentes. Recientemente, también se han utilizado patrones en los datos de velocidad del tráfico para refinar manual o automáticamente las etiquetas de incidentes incompletas, aprovechando diagramas espacio-temporales o aplicando umbrales empíricos a las desviaciones de los perfiles de velocidad históricos (Coursey et al., 2024; Duan et al., 2024; Grigorev et al., 2023).

Por otro lado, también están surgiendo nuevos esfuerzos que se centran exclusivamente en la detección de anomalías no supervisada basada en datos en series temporales de tráfico. En lugar de limitar la atención a eventos o incidentes, estos enfoques buscan identificar inconsistencias que se desvían de los patrones dominantes, siguiendo un proceso más exploratorio que permite que los datos revelen anomalías por sí mismos. Por eso, como se muestra en la Tabla 1, en su mayoría generan anomalías sintéticas y producen puntuaciones de anomalía generalizables, como sus objetivos de detección.

Machine Translated by Google

Tabla 1

Resumen de trabajos de investigación recientes centrados en la detección de anomalías e incidentes de tráficoa .

Árbitro	Enfocar	Método	Datos de entrada	Datos GT	Producción	Métodos de referenciab
Chakraborty y otros (2019)	detección de incidentes ción	Velocidad robusta Umbrales	Datos de velocidad espaciotemporales	Incidente verificado informes	Etiquetas de anomalías (TIC)	SND (Balke et al., 1996); MAD (Hampel, 1974); RI (Pearson, 2005)
Kalair y Connaughton (2021)	Detección de anomalías/incidentes	Desviación KDE	Datos de volumen y velocidad (no espaciales)	Informe de incidentes y tiempos de viaje relacionados	Puntuaciones y etiquetas de anomalías (TIC)	SND robusto (Chakraborty et al., 2019); algoritmo de McMaster (Persaud y Hall, 1989)
Grigorev y otros (2023)	detección de incidentes ción y duración predicción	Perfil De-viaje & Segmentación	Datos de velocidad (no espaciales)	Informes de incidentes y perturbaciones de velocidad señalizadas por expertos.	Puntuaciones de anomalías y etiquetas (ET)	Comparación realizada con interrupciones etiquetadas (la predicción de la duración se comparó con las técnicas más avanzadas).
Duan y otros (2024)	detección temprana de incidentes	G-Trans entrenado por eliminación de ruido de etiquetas datos	Niveles de velocidad y densidad de datos de la sonda, informes de incidentes, datos meteorológicos	Informes de incidentes sin ruido basados en la ralentización	Etiquetas de anomalías (ST)	Los métodos no supervisados incluyen: OOD (predictivo) (Bahdanau et al., 2014); Desviación media del perfil (Grigorev et al., 2023)
Coursey y otros (2024)	Detección de incidentes	Evaluación del autoencoder estructuras	Volumen, velocidad y ocupación espaciotemporales	Informes de incidentes y perturbaciones de velocidad señalizadas por expertos.	Puntuaciones y etiquetas de anomalías (TIC)	Se evaluaron 6 autoencoders profundos diferentes basados en reconstrucción.
Zhang y otros (2018)	Detección de anomalías basada en datos	Verificación de similitud entre regiones + OC-SVM	Datos de tráfico espaciotemporales	Anomalías sintéticas y Tasa de aciertos (HR) con evento informes	Anomalía montones	EE (Estimador, 1999); Desviación de la media de las regiones cercanas; Prueba de razón de verosimilitud (Doraiswamy et al., 2014)
Wang y Domingo (2021)	Basado en datos detección de anomalías	Rango bajo Autorregresión tensorial	Datos de tráfico espaciotemporales	anomalías sintéticas	Red anomalía montones	Tres factores basados en Kalman y métodos basados en filtros (Ting et al., 2017)
Deng y otros (2022)	Detección de anomalías basada en datos	Espacio-Temporal Convolución de grafos Adversario Red (STGAN)	Datos de tráfico espaciotemporales	Tasa de aciertos (HR) con informes de incidentes y eventos	Anomalía montones	iForest (Liu et al., 2008); LOF (Breunig et al., 2000); EE (Estimator, 1999); Autorregresión vectorial (Rousseeuw y Leroy, 2005); CIAS&AIAS (Zhang et al., 2018); ST-Decompn (Zhang et al., 2019b); y dos métodos predictivos avanzados
Sarteshnizi y otros (2023)	Detección de anomalías basada en datos	TP-FDS y Rápido-ABOD	Datos de volumen y velocidad (no espaciales)	Desviaciones de la densidad del flujo etiquetadas por expertos	Anomalía montones	Se evaluaron 19 detectores de anomalías de aprendizaje automático y aprendizaje profundo no supervisados dentro del TP-FDS 2D. espacio.
He et al. (2023)	Detección de anomalías basada en datos	Automático Reforzamiento Aprendiendo	Datos volumétricos (no espaciales)	Anomalías de subsecuencia sintética	Anomaly la-bels	Telemanom (Hundman et al., 2018); DeepAnt (Munir et al., 2018); Detección de fugas (Vallis et al., 2014)
Ren y otros. (2024)	Basado en datos detección de anomalías	Codificador automático de gráficos temporales en espejo	Datos de tráfico espaciotemporales	Informes de incidentes Sintéticos y anomalías	Anomalía montones	Desviación promedio histórica, junto con otros 3 modelos de aprendizaje profundo basados en autoencoders y 10 basados en GNN. Más de 20 líneas base de estudios TAD (univariados) y trabajos previos relevantes sobre AD de tráfico.
El presente estudio	Detección de anomalías basada en datos	Si-TDD (basado en Discord)	Datos volumétricos (no espaciales)	Series temporales etiquetadas por expertos inconsistencias	Anomalía montones	

[a] GT: Ground Truth, ICT: Umbrales calibrados basados en incidentes utilizados, ET: Umbrales empíricos utilizados, ST: Entrenamiento supervisado.

[b] Para obtener descripciones detalladas de las líneas de base individuales, se pueden utilizar los artículos citados correspondientes.

ir más allá de ciertas etiquetas de incidentes o eventos (Wang y Sun, 2021; Ren et al., 2024). Este campo está en desarrollo activo, con investigaciones en curso desde diferentes puntos de vista que continúan expandiendo el cuerpo de conocimiento. Por ejemplo, Zhang et al. (2018) propusieron un método basado en similitud de ventana para identificar regiones de tráfico que muestran diferencias mínimas entre sí, y utilizaron un OC-SVM para detectar interrupciones en estos patrones de similitud. Wang y Sun (2021) introdujeron un método para la detección de anomalías en datos de tráfico espaciotemporales utilizando autorregresión tensorial de bajo rango, validando su enfoque a través de conjuntos de datos sintéticos y visualizaciones de algunos escenarios de datos del mundo real. Junto con la realización de varios experimentos, su trabajo enfatizó principalmente la detección de cambios abruptos como anomalías dentro de los datos de tráfico, poniendo mayor énfasis en capturar teóricamente dependencias espaciotemporales. Deng et al. (2022) y Ren et al. (2024) también propusieron arquitecturas profundas basadas en grafos para la detección de anomalías en datos de tráfico espaciotemporales. Para la evaluación, utilizaron informes de incidentes y eventos sociales registrados junto con conjuntos de datos de PeMS y taxis de la ciudad de Nueva York. Para derivar métricas de rendimiento finales, aplicaron estrategias como la superposición de etiquetas, la inyección de anomalías sintéticas y la evaluación basada en la tasa de aciertos (recall) para abordar la falta de etiquetas de verdad fundamental completas. He et al. (2023) también sugirieron una técnica de detección de anomalías para datos de series temporales de flujo de tráfico (volumen) que emplea aprendizaje por refuerzo (RL) y redes de memoria a largo y corto plazo (LSTM), sin requerir conocimiento previo durante la calibración. Su enfoque se centró únicamente en anomalías de subsecuencia, excluyendo anomalías puntuales, y se validó utilizando datos sintéticos junto con varios casos del mundo real. Sarteshnizi et al. (2023) también se concentraron en identificar desviaciones en el posicionamiento temporal de muestras de flujo y densidad, argumentando que estas desviacione

Machine Translated by Google

y anomalías de subsecuencia. Además, compararon varios métodos de detección de anomalías para detectar desviaciones en su espacio de datos TP-FDS con un conjunto de datos de volumen y velocidad totalmente supervisado y etiquetado por expertos de diez ubicaciones diferentes.

Según la Tabla 1, estos trabajos suelen basarse en datos sintetizados con anomalías inyectadas o realizar comparaciones dirigidas utilizando incidentes reportados o eventos públicos. Sin embargo, se ha argumentado que los datos sintéticos se producen para respaldar afirmaciones específicas (Paparrizos et al., 2022), y también se ha demostrado que los informes de incidentes/eventos no reflejan completamente todos los tipos de anomalías de datos registradas en los datos de tráfico (Sarteshnizi et al., 2023). Además, las soluciones para mitigar las deficiencias de los conjuntos de etiquetas incompletos también han demostrado ser problemáticas en estudios recientes de TAD (Kim et al., 2022). Otro aspecto destacable en la Tabla 1 es la selección de líneas base en los estudios comparativos. Aunque muchos artículos afirman abordar la detección de anomalías, y las etiquetas de verdad fundamental indican un alcance más amplio que los informes de incidentes, existe una consistencia limitada en la selección de líneas base, con un fuerte énfasis en métodos avanzados de aprendizaje profundo y una atención comparativamente menor a los enfoques clásicos y univariados (Ren et al., 2024; He et al., 2023). Como se ha comentado, los métodos clásicos han demostrado recientemente ser competitivos y robustos en TAD con procesos de evaluación refinados (Mejri et al., 2024), pero esto no se refleja ni se investiga completamente aquí.

Este estudio se diferencia de los trabajos anteriores en dos aspectos principales. Primero, a diferencia de muchos estudios de detección de anomalías que se basan en informes de eventos o datos sintéticos para su evaluación, nuestro estudio adopta una perspectiva diferente. Abordamos este desafío mediante la anotación visual de todos los tipos de anomalías basadas en patrones directamente a partir de los datos y el uso de estas etiquetas para evaluar las soluciones existentes. Este enfoque centrado en los datos, que identifica anomalías basándose únicamente en inconsistencias observadas en series temporales, no se ha explorado en trabajos previos, a pesar de su potencial para respaldar una amplia gama de análisis exploratorios posteriores y aplicaciones automatizadas. Segundo, a diferencia de los estudios de detección de incidentes, nos centramos en la detección de anomalías en datos de volumen de tráfico urbano. Si bien existen conjuntos de datos de referencia y experimentos para la detección de incidentes en autopistas (Coursey et al., 2024), faltan estudios comparables para datos de volumen de detectores de bucle de línea de parada en vías arteriales. Esto es particularmente importante, ya que los datos recopilados por los sistemas de control de señales, como SCATS, son intrínsecamente diferentes de los datos de las autopistas y siguen aumentando (Dakic y Stevanovic, 2018; Yazdani et al., 2023). La ubicación espacial de estos detectores dentro de la red también difiere de la de las autopistas, puesto que se encuentran en la línea de detención de los accesos a las intersecciones, lo que hace que las técnicas de etiquetado espaciotemporales basadas en la velocidad existentes no sean aplicables en este contexto.

3. Método

En esta sección, primero estudiamos la taxonomía de los tipos de anomalías en datos de series temporales arbitrarias y luego analizamos su aparición en datos de volumen de tráfico. Posteriormente, desarrollamos nuestro marco propuesto para el etiquetado de anomalías en datos de tráfico reales. A continuación, profundizamos en nuestra formulación de detección de anomalías y analizamos nuestra solución Si-TDD propuesta.

3.1. Anomalías en los datos de series temporales

En numerosos estudios recientes, se definen distintos tipos de anomalías/valores atípicos como contextuales, puntuales y colectivas (Pang et al., 2021; Li et al., 2020a). Sin embargo, Lai et al. (2021b) argumentaron recientemente que esta categorización no refleja con precisión todos los tipos de anomalías en los datos de series temporales y propusieron nuevas definiciones basadas en el análisis espectral (Shumway et al., 2000) para ofrecer una clasificación más inclusiva de los tipos de anomalías. Aquí profundizamos en esta nueva taxonomía y la retomaremos posteriormente en el contexto de los datos de volumen de tráfico.
Es importante destacar que esta taxonomía refleja los hallazgos de un trabajo fundamental reciente en TAD. Por lo tanto, nuestro objetivo es basar tanto nuestro marco de etiquetado como el desarrollo de nuestra metodología en ella para garantizar que se consideren todos los tipos de anomalías más avanzados.

Según Lai et al. (2021b), una serie temporal general multivariada, denominada , puede representarse mediante la siguiente ecuación:

$$A(A) = \{ A1 , A2 ,\dots , A , \dots, A \} \tag{1}$$

donde es un vector -dimensional registrado en el paso de tiempo , y {1, 2,… , } siendo la longitud de la serie. Para datos de series temporales univariadas, tenemos = 1, y por lo tanto, cada en la ecuación (1) denota un valor escalar. El objetivo principal en TAD es asignar un valor binario o etiqueta a cada observación ( ) registrada en la serie, indicando si el dato registrado en el tiempo es una anomalía o no.
Desde la perspectiva del análisis espectral, el patrón de una univariada (denominada) también se puede escribir como sigue:

$$( ) = (,) = (2) + ( ) \tag{2}$$

donde y son las funciones que representan los componentes cíclicos y de tendencia de la serie, y es el conjunto de índices de frecuencia del comportamiento cíclico (número de ciclos por unidad de tiempo). En esta representación, la función de tendencia muestra la dirección de la serie, y el comportamiento cíclico se puede mostrar mediante la suma de ondas sinusoidales diferentes, como sigue:

$$(2) = \sum_{=1} (2) \tag{3}$$

dónde

$$(2) = (2) + (2), \tag{4}$$

y en las ecuaciones anteriores, es el índice de frecuencia de cada componente, y y controlan la amplitud (desplazamiento máximo) de la onda.

Considerando ambas formulaciones anteriores de datos de series temporales, Lai et al. (2021b) definieron anomalías puntuales y por patrón.
como en la Fig. 3. En anomalías puntuales, un valor puntual específico de una serie es considerablemente diferente del valor esperado, como se muestra a continuación:

$$\left| \quad - \quad | > ( ) | \tag{5}$$

Machine Translated by Google

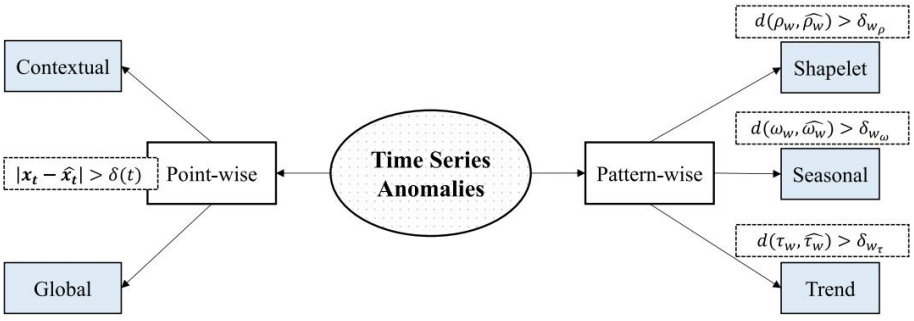


Figura 3. Descripción general de la taxonomía de tipos de anomalías en datos de series temporales, derivada del trabajo de Lai et al. (2021b). La aparición de estos tipos de anomalías se estudiará en datos de volumen de tráfico.

donde es el valor esperado del punto, y ( ) es un umbral discriminatorio sensible al tiempo. Se pueden aplicar dos conjuntos de ( ) para diferenciar entre anomalías puntuales globales y contextuales : uno basado en los puntos circundantes (− , − +1,..., + −1, +) para anomalías contextuales, y el otro basado en los valores completos de la serie ( ) para las globales.

Además de este tipo de anomalías, las subsecuencias de datos con comportamiento anómalo también pueden etiquetarse como anomalías basadas en patrones. Si definimos una ventana o una subsecuencia, denotada como , con una longitud de de la siguiente manera:

( ) = [, +] (6)

y supongamos que los componentes espectrales locales de esta ventana se extraen y se muestran mediante ( ) , esta subsecuencia puede considerarse una anomalía cuando se cumple la siguiente condición:

(,) > (7)

donde es una función de medición de disimilitud, es un umbral y es uno de los elementos incluidos en ( ) que puede ser igual a , o . En caso de disimilitud entre la función cíclica ( ) de la subsecuencia real y esperada, se observa una anomalía shapelet ya que la forma básica de la serie temporal está perturbada. La anomalía estacional también ocurre cuando la ecuación (7) se satisface con (,) = (,). En este caso, solo la frecuencia de la serie es anormal y no está alineada con la expectativa (no la forma).

Por último, se habla de anomalía de tendencia cuando el componente de tendencia de la serie ( ) cambia drásticamente mientras que los demás componentes permanecen inalterados. En otras palabras, una subsecuencia de datos que provoca un cambio permanente en la serie puede denominarse anomalía de tendencia.

Según la taxonomía descrita anteriormente, se entiende que los tipos de anomalías se definen únicamente a partir de la progresión univariada de los datos. Cabe mencionar que este enfoque no es exclusivo del trabajo de Lai et al. (2021b) y prevalece en numerosos trabajos previos (Blázquez-García et al., 2021; Zamanzadeh Darban et al., 2024). Hasta donde sabemos, ningún tipo de anomalía descrito en la literatura sobre TAD ha demostrado ser teóricamente indetectable al centrarse únicamente en el registro univariado de datos (Sarteshnizi et al., 2023). La razón subyacente para adoptar el modelado multivariado en trabajos anteriores es principalmente mejorar la capacidad de identificar dichas anomalías (Tian et al., 2023). Sin embargo, por definición, se espera que las anomalías sean fundamentalmente evidentes a partir de la progresión univariada de los datos en sí. Esta es también la razón principal por la que nos centramos en el modelado univariado de datos de tráfico en este trabajo. Si bien los investigadores en diversos dominios de TAD logran un éxito significativo con soluciones univariadas y las consideran un enfoque prometedor incluso para el manejo de datos multidimensionales (Nakamura et al., 2023; Lai et al., 2021b; Liu y Paparrizos, 2024; Paparrizos et al., 2022), su capacidad aún no se ha investigado en el contexto del tráfico urbano. Además de sus propias aplicaciones, el modelado univariado debe realizarse antes de cualquier modelado espaciotemporal de datos para que el valor añadido del modelado avanzado (si lo hay) sea más evidente y discutible al compararlo. A pesar de la importancia de esta perspectiva, aún faltan debates sobre la naturaleza y la ocurrencia de anomalías en los datos de series temporales de tráfico, así como esfuerzos para desarrollar métodos de detección alineados con estas características subyacentes.

3.2. Anomalías en los datos de volumen de tráfico

De forma similar a la formulación de datos generales de series temporales, un conjunto de datos de volumen de tráfico, que refleja el número total de vehículos que pasan por un tramo específico de la carretera en un período de tiempo determinado, también puede mostrarse desde el punto de vista del análisis espectral como se muestra a continuación:

(,) = (2) + ( ) (8)

donde se refiere a los datos de volumen, y todas las demás notaciones se definieron previamente. Dos factores principales en los datos de volumen/flujo de tráfico deben analizarse de acuerdo con sus características intrínsecas:

En primer lugar, el componente de tendencia en los datos de tráfico puede considerarse insignificante (( ) ≈ 0). La justificación de esta suposición radica en que el número de vehículos que transitan por un tramo de carretera no puede exceder su capacidad ni ser inferior a cero. Por lo tanto, se espera que el rango completo de datos varíe entre cero y la capacidad de la carretera.

Machine Translated by Google

• En segundo lugar, también está demostrado que la hora del día y el día de la semana son siempre dos factores externos sustanciales y constantes. que contribuyen significativamente al patrón cíclico ( ) de los datos en cada ubicación.

Por lo tanto, basándonos en las características anteriores, la ecuación (8) puede revisarse de la siguiente manera:

$$(,) = + ^{a} + \quad (9)$$

donde es una colección de componentes periódicos que reflejan un comportamiento cíclico diario y constante, ajusta ^{a} es una colección de componentes es para incluir los efectos del día de la semana (como la diferencia entre días laborables y fines de semana), y sustituye a los componentes restantes. En este una trabajo, asumimos que los cambios reflejados por puede incluir los efectos de otros factores, como los patrones estacionales o propios del mes del año. se deben a dos razones principales: no son intensos y, por lo tanto, ≈ 0. Esta también es una suposición realista.

1. Estos patrones estacionales (o a largo plazo) de datos de tráfico son tan sutiles que la literatura anterior utiliza métodos complejos para descubrirlos. ellos (Taheri Sarteshnizi et al., 2023).
2. Tampoco es teóricamente posible observar variaciones considerables en la demanda de tráfico en un tramo de carretera durante un período prolongado (como un mes). Los viajeros suelen ajustar sus tiempos de viaje evitando las carreteras congestionadas, lo que genera un equilibrio a largo plazo en cualquier red vial que no haya sufrido modificaciones (Sarteshnizi et al., 2023; Chiu et al., 2011).

Considerando la formulación y las justificaciones anteriores, se puede afirmar que los datos de volumen de tráfico se ven afectados principalmente por un patrón semanal repetitivo y se pueden representar de la siguiente manera:

$$(,) = + ^{a} \quad (10)$$

Según las definiciones primarias de los tipos de anomalías, se pueden enunciar varias conclusiones: (1) No se puede observar una anomalía de tendencia en los datos de volumen de tráfico, ya que ( ) ≈ 0, (2) Tampoco se pueden definir anomalías estacionales (cambios de frecuencia anormales en los datos) para los datos de volumen de tráfico, puesto que la colección de y en ^{a} es solo una función del comportamiento diario y semanal constante de datos, y (3) las anomalías de puntos y formas globales o contextuales son los únicos tipos que se pueden observar en los datos de tráfico ya que no hay garantía de que un punto de datos o subsecuencia siempre siga el comportamiento esperado representado por y ^{a} En la ecuación

Con base en los puntos anteriores, si un reflejo decente de y ^{a} (10), si se proporciona, cualquier desviación de este patrón debe marcarse como una anomalía puntual o de subsecuencia. Cabe señalar también que las anomalías de subsecuencia en los datos de volumen pueden durar desde unos minutos hasta varios días (como cuando se produce un fallo en un sensor). Una anomalía de subsecuencia larga en los datos de tráfico no debe interpretarse erróneamente como una anomalía de tendencia. Una anomalía de tendencia se produce cuando toda la serie se desplaza a un nuevo rango, y este rango se considera entonces como una nueva representación normal del sistema. Dado que se espera que los fallos prolongados de los sensores terminen en un punto, todos los datos deben etiquetarse como anomalía hasta que regresen a su rango normal.

3.3. Marco de etiquetado de datos volumétricos

En este trabajo, partimos de la base de que se dispone de una cierta cantidad de datos históricos (de entre 4 y 6 meses) de cualquier ubicación, y que la mayoría de estos datos (al menos más del 50%) siguen un comportamiento normal. Teniendo en cuenta estos requisitos previos, desarrollamos nuestro marco conceptual en el resto de esta sección.

Supongamos que el volumen total de datos recopilados de una ubicación específica ( ) es el siguiente:

$$CL = \{ C \quad \{1, 2, ., 7\}, \quad \{0, 1, 2, \dots , \} \} \quad (11)$$

donde es el -ésimo conjunto de puntos de datos (o perfil de volumen) recopilado el -ésimo día de la semana. Por ejemplo, $^{1}_{1}$ son los datos del primero (= 1) lunes (= 1), y también se $^{2}_{1}$ es el dato del segundo (= 2) lunes (= 1) dentro de todo el archivo de datos históricos. Cualquier poder define como se indica a continuación:

$$= \{ ^{1}_{(,)}, ^{2}_{(,)}, \dots, ^{c}_{(,)}, \dots ^{M}_{(,)} \} \quad (12)$$

con (,) es el punto de datos recopilado en el paso de tiempo durante el día. también es siempre un valor fijo que indica la cantidad de puntos recopilados en un día, y su valor está determinado por el intervalo de tiempo de recopilación de datos. Por ejemplo, para una resolución de datos de 15 minutos, tenemos = 96.

A partir de la formulación anterior, diseñamos una plataforma de etiquetado (como se muestra en la Fig. 4) y sus características (indicadas por números en la figura) se describen a continuación:

1. En nuestro marco, los datos de cada ubicación ( ) se analizan por separado ya que las anomalías deberían ser evidentes en los datos de tráfico, dado el comportamiento periódico que se produce únicamente en esa ubicación específica (como se mencionó anteriormente).
2. En cada vista de datos, un específico y dirigido (denominado) se muestra al inspector junto con otros perfiles que tienen el mismo valor de (día de la semana). Esto permite comparar con sus contrapartes (perfiles que poseen la misma característica de día de la semana).
3. se muestra con un color diferente y llamativo en comparación con los demás, ya que es la única parte de datos que requiere inspección y etiquetado en cada vista. Otros perfiles con el mismo que se muestran en un color único y claro para facilitar la comparación.
4. El inspector también puede hacer clic en cualquier punto de datos del (llamado) que parezca anómalo, considerando el patrón (,) de otros perfiles relacionados (que tengan el mismo valor).

Machine Translated by Google

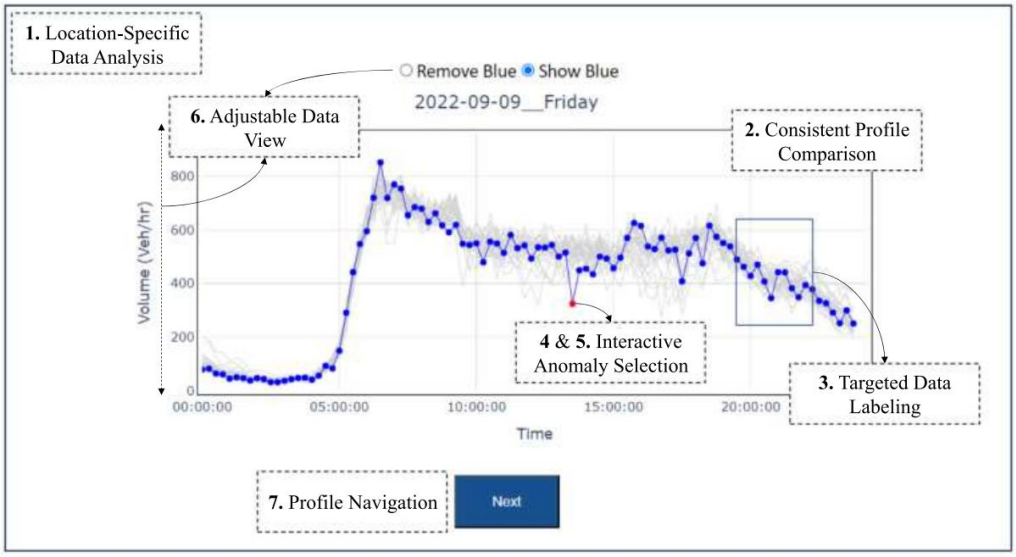


Figura 4. Ejemplo de gráfico de datos en nuestro marco de etiquetado de datos propuesto. Cada número hace referencia a las características descritas en el texto principal.

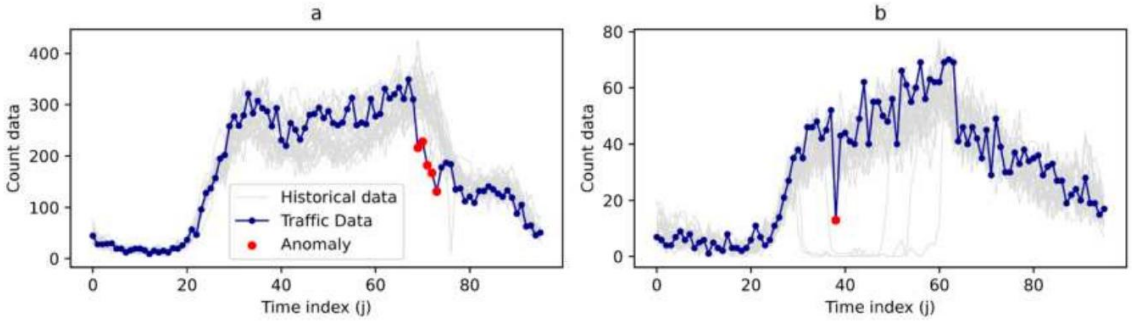


Figura 5. Dos perfiles de datos de tráfico junto con sus correspondientes anomalías. Las anomalías de tipo shapelet (a) y de tipo point (b) seleccionadas por el inspector se muestran en rojo.

5. Todos los puntos ( ) de cada vista son clicables y, al seleccionarlos, cambian de color de azul a rojo, lo que indica que el inspector los ha seleccionado como una anomalía (,) . Los inspectores también tienen la opción de deseleccionar esos puntos haciendo clic de nuevo, devolviéndolos a su estado normal si es necesario.

6. Se proporciona la posibilidad de desplazarse sobre el eje Y (valores de volumen), así como la posibilidad de ocultar el . Por lo tanto, en el caso de un global Ante cualquier anomalía o desviación sutil, los inspectores pueden acercar o alejar la imagen para seleccionar datos con mayor precisión y análisis.

7. También se muestra un botón "Siguiente" debajo de cada vista de datos, lo que permite a los inspectores pasar al siguiente una vez que se haya completado su etiquetado. Todos los perfiles están organizados para ser presentados al inspector de forma secuencial hasta que se haya monitoreado completamente la totalidad de los datos de la ubicación.

La figura 5 ilustra dos vistas adicionales de los datos en nuestra plataforma de etiquetado, donde se pueden observar las muestras , junto con las anomalías seleccionadas por un inspector. Cuando se completa el monitoreo de datos, se genera un nuevo conjunto de etiquetas para todas las muestras de una ubicación, como se muestra a continuación, de forma similar a la formulación de datos de tráfico:

$$= \{ \quad \{1, 2, ., 7\}, \quad \{0, 1, 2, \ldots , \quad \} \} \tag{13}$$

con definido como:

$$= \{ g \quad (\ , \ ), \quad 2 (\ , \ ), \ldots , \quad (\ , \ ), \ldots , \quad (\ , \ ) \} . \tag{14}$$

De manera similar, representa el conjunto de etiquetas binarias recopiladas para el perfil del día de la semana. también es un valor binario (,) que indica si el punto de datos recopilado en el paso de tiempo del día es normal o anómalo (0 = normal y 1 = anómalo). se utilizará posteriormente en estudios experimentales para comparar el rendimiento de diferentes detectores de anomalías con datos de volumen de tráfico.

Como se muestra en la Fig. 5, monitorear los datos de esta manera proporciona al inspector estimaciones de ambos y), [a] Esto está garantizado. al mostrar los datos en perfiles diarios (( ). Como donde las comparaciones solo se realizan con otras registradas el mismo día de la semana. resultado, ambos tipos de anomalías (punto y forma) pueden identificarse de manera eficiente durante la inspección visual. Los inspectores son

Machine Translated by Google

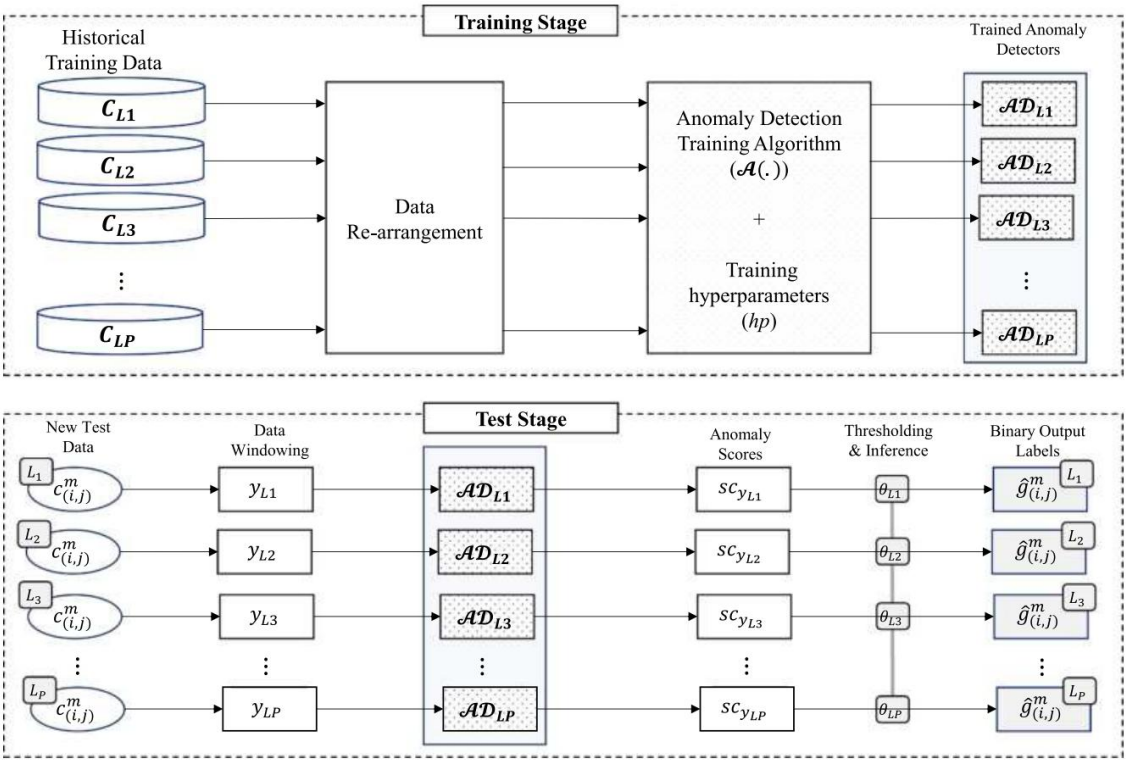


Figura 6. Descripción general de los procedimientos de entrenamiento y prueba empleados en este estudio para la detección de anomalías en datos de volumen de tráfico.

Se ofrece continuamente la oportunidad de comparar un punto de datos con sus puntos circundantes (Ec. (5)) y de comparar una subsecuencia de datos con la función cíclica esperada de la serie (Ec. (7)). Otro aspecto importante de este marco es su capacidad para mejorar la precisión del proceso de juicio en comparación con el análisis de datos brutos de series temporales de tráfico, un método comúnmente utilizado en la literatura (Fig. 1). Por ejemplo, la anomalía shapelet en la Fig. 5(a) podría pasar desapercibida sin la posibilidad de compararla con datos históricos similares. Estas anomalías no están vinculadas a eventos específicos, sino que representan situaciones no recurrentes e impredecibles, lo que enfatiza la importancia de un monitoreo exhaustivo para una evaluación efectiva.

3.4. Detección de anomalías en el tráfico: formulación del problema

El procedimiento general empleado para la detección de anomalías en series temporales de tráfico se ilustra en la Fig. 6. Como se mencionó anteriormente, este trabajo se centra en la detección de anomalías univariada. Por lo tanto, se incluyen etapas separadas de entrenamiento y prueba, donde los datos de cada ubicación se modelan individualmente utilizando el mismo algoritmo de entrenamiento. En la etapa de entrenamiento, dados los datos históricos de cada ubicación (, donde se refiere a la ubicación), se entrena un modelo específico utilizando el algoritmo ((.)) junto con sus hiperparámetros requeridos ( ). Luego, se obtienen detectores de anomalías específicos para cada ubicación ((.)) como se muestra a continuación:

(.) = (,) (15)

Durante la fase de prueba, cuando llegan nuevas muestras de datos, se suministran junto con una porción de datos recientes en una ventana ( ) a sus modelos correspondientes. Este concepto también puede utilizarse durante la fase de entrenamiento (en la parte de reorganización de datos de la figura 6). A continuación, se calculan las puntuaciones de anomalía ( ) en función de mediante: =

( ). (16)

Se espera que las puntuaciones de la ecuación (16) sean significativamente más altas cuando hay una anomalía presente en . Dependiendo de la estructura del modelo, las puntuaciones de anomalía de las muestras individuales ((,)) luego se interpretan a partir de estas puntuaciones de ventana ( ). En el paso final, los) se puntuaciones de muestra ((i,j) convierten en etiquetas binarias, utilizando la siguiente función de umbral:

$$\text{(.)} = \begin{cases} 0 \text{ si } & \text{(i,j)} < \\ 1 \text{ si } & \text{(,)} \geq \end{cases} \quad , \tag{17}$$

donde denota el umbral constante y definido por el usuario para cada ubicación. Aprovechando la recopilación de , se puede realizar una comparación punto por punto con las etiquetas de verdad fundamental obtenidas (Ec. (14)) para calcular métricas de rendimiento como AUC-ROC y puntuación F1 (Lai et al., 2021b).

Machine Translated by Google

En esta formulación, el objetivo principal es identificar un detector de anomalías óptimo ( ) capaz de mapear datos brutos ( ) a puntuaciones de anomalías ((,)), una tarea que no es trivial y que ha demostrado ser desafiante en muchas aplicaciones (Blázquez-García et al., (,) 2021). se puede representar de la siguiente manera:

$$= \arg\min \quad (, \quad) \tag{18}$$

donde (.) es la función de pérdida que cuantifica las discrepancias entre las etiquetas de verdad fundamental reales ( ) y predichas ( ). En este trabajo, nos centramos en investigar la ecuación (18) en el contexto de la detección de anomalías de volumen de tráfico de grano fino . También asumimos que el conjunto de en la etapa final lo determina el usuario. Esto se debe a que (1) es un enfoque ampliamente adoptado tanto en la literatura de tráfico como en la de detección de anomalías en general (Tabla 1), lo que permite a los usuarios seleccionar umbrales en función de sus preferencias, y (2) extraer puntuaciones de anomalía óptimas de datos de series temporales sin procesar es una tarea no trivial en sí misma, que requiere estudios específicos para abordarla. El impacto de la configuración de los umbrales y su aplicabilidad se examinarán mejor en trabajos futuros una vez que se hayan extraído con éxito puntuaciones razonables.

3.5. Detección de anomalías en el tráfico: metodología

Para desarrollar nuestro método propuesto ( ), comenzamos con una descripción general de los procedimientos que sustentan las soluciones TAD existentes. A continuación, nos centramos en la discordancia de series temporales, un concepto que constituye la base de nuestro enfoque. Finalmente, presentamos nuestro método Si-TDD y analizamos cómo mejora las soluciones de detección de discordancias para abordar los requisitos específicos de los datos de volumen de tráfico.

3.5.1. Soluciones TAD

Se pueden aplicar varios métodos TAD a la formulación anterior como sustituto de (.). Estas soluciones se clasifican en dos grupos distintos: enfoques basados en predicción y enfoques basados en similitud (Blázquez-García et al., 2021). La principal diferencia entre estos métodos radica en cómo plantean el problema y lo interpretan. La ecuación (19) representa la ventana (con una longitud de + 1) en +1 dos pasos de tiempo consecutivos (y + 1), donde y denotan los datos más recientes en la ubicación : (,) (,)

$$= \{\{ \; _{(i,j)}^{-}, \ldots, \; _{-1}, \quad \} \quad \text{en} \quad = \quad , \quad = \{\{ \; _{(i,j)}^{-+1}, \ldots, \; c_{(i,j)}, (,) \quad +1 \} \text{ en } \quad = \quad +1. \tag{19}$$

Los métodos basados en predicciones suelen utilizar datos recientes en para predecir el valor actual de la , utilizando el modelo entrenado. Luego, el puntuación de anomalía (o +1) se calcula directamente comparando el valor estimado ((,)) con los datos recopilados, como se muestra a continuación (lo mismo se puede derivar para + 1):

$$= \quad (,) \quad = \quad |- \quad |(,) \tag{20}$$

Sin embargo, en los métodos basados en similitud , la puntuación de anomalía de la ventana de tiempo ( ) se calcula primero aprovechando el grado de disimilitud entre la ventana y la colección de todas las demás ventanas de tiempo históricas ( ), como en la siguiente ecuación:

$$= \quad (\quad , \quad) \tag{21}$$

donde (.) es una función de medición de disimilitud. Esta función puede variar desde una simple distancia euclidiana hasta un límite de disimilitud complejo definido en un sistema avanzado de representación de datos. Luego, la puntuación final de la muestra ( ) se extrae de la puntuación de la ventana (,) de una manera específica, dependiendo de la aplicación y los requisitos del usuario .

Dado que los métodos basados en similitud proporcionan puntuaciones de anomalías para toda la secuencia de entrada (≠), en algunos casos se requieren pasos adicionales de posprocesamiento (,) para obtener las etiquetas de anomalías puntuales. Si bien esto es específico de los enfoques basados en similitud, cabe destacar que los métodos basados en predicción también se entrenan para minimizar el error de predicción, lo que puede no coincidir directamente con el objetivo de una detección precisa de anomalías. Como resultado, su rendimiento en la identificación de anomalías también puede ser subóptimo.

3.5.2. Discrepancia en series temporales para la detección de

anomalías A pesar del progreso significativo con los enfoques de aprendizaje profundo, estudios comparativos recientes han demostrado que los métodos clásicos, principalmente del grupo basado en similitud, siguen siendo herramientas de vanguardia para la detección de anomalías en series temporales (Paparrizos et al., 2022; Lai et al., 2021b; Liu y Paparrizos, 2024). El descubrimiento de la discrepancia es una de las soluciones más estudiadas en los problemas de detección de anomalías en series temporales. La discrepancia en series temporales se refiere a una subsecuencia de datos de series temporales que es significativamente diferente de todas las demás subsecuencias de la misma longitud dentro de la serie, y esta diferencia se suele medir utilizando la función de distancia euclidiana (Nakamura et al., 2023). Para ser más específicos, si definimos una serie temporal univariad como en la ecuación (1), una subsecuencia de datos con una longitud de y cuyo último punto de datos se registró en el tiempo {1, 2, 3,… , } (denotado aquí por) se considera la discordancia de la serie si satisface la siguiente condición:

$$(\quad (\quad ,),) > \quad (\quad ^{o} \quad (\quad ,)) \quad \{1, 2, \ldots, \quad \}, \quad \neq \quad . \tag{22}$$

En esta condición, (.) representa la función de medición de distancia euclidiana, ^{o} denota otras subsecuencias de datos con el tienen la misma longitud en el tiempo , y son las subsecuencias vecinas más cercanas a . y ^{o}, respectivamente.

Basándonos en lo anterior, para determinar si una subsecuencia es una discordancia de series temporales, se debe comparar su distancia al vecino más cercano; este concepto con la de otras subsecuencias. Aunque la definición se centra en la primera discordancia superior (para clasificar y detectar se utiliza ampliamente. todas las anomalías en los datos de series temporales. Para lograr esto, una forma es calcular medidas de distancia por pares entre

Machine Translated by Google

todas las subsecuencias dentro de la serie y luego considerar las puntuaciones de discordancia (distancias a los vecinos más cercanos) como puntuaciones de anomalía. El algoritmo 1 presenta este enfoque predeterminado de transformar el concepto en un generador práctico de puntuaciones de anomalía. En este método, sin necesidad de entrenamiento, se calculan las puntuaciones de discordancia para todas las subsecuencias de longitud en una serie temporal X( ) , con una complejidad computacional de) (todas las subsecuencias analizadas (2 entre sí). Estas puntuaciones, como se discute en la Sección 3.5.1, están asociadas con subsecuencias de datos y puede que sea necesario procesarlos mediante criterios basados en la aplicación para clasificar las anomalías en los datos de series temporales.

Algoritmo 1 Detección de anomalías en series temporales con descubrimiento de discordancias.

Requerido: Datos de series temporales: X( ), longitud de subsecuencia:
Asegurar: Subsecuencias clasificadas con puntuaciones de discordancia 1:
Extraer subsecuencias de longitud de los datos de series temporales X: 2: para =
hasta hacer ← X[−
3: + 1,] 4: fin para Extraer la subsecuencia que termina en el tiempo
5: _ Inicializa la lista para almacenar las puntuaciones de Discord.
← [] 6: para cada subsecuencia hacer
7: Inicializar la lista para almacenar distancias
8: ← [] para cada subsecuencia donde ≠ hacer
9: ← (, Calcular la distancia euclidiana entre subsecuencias
) agregar a
10: 11: fin para
12: _ ← Encuentra la distancia máxima (puntuación de discordia)
max( ) 13: agregar _ a
_ 14: fin para
15: devolver (_ ,) Devuelve las subsecuencias de datos junto con sus puntuaciones.

En el descubrimiento de discrepancias en series temporales, seleccionar el tamaño óptimo de la ventana suele considerarse un desafío importante. La figura 7 profundiza en este tema en el contexto de los datos de volumen de tráfico. En esta figura, se pueden encontrar las posiciones de ventanas de tiempo representativas de tres tamaños (≈ un día, una hora y unas pocas horas) que se superponen a los datos de volumen (1 y 3). En el caso de perfiles diarios anómalos o , 2 , anomalías de larga duración , como en la figura 7(a), tamaño de ventana grande de aproximadamente un día es muy efectivo. Se produce una puntuación de discrepancia alta al comparar el día anómalo con su vecino más cercano, una ventana de datos similar a la siguiente. La detección de tales anomalías (por ejemplo, días festivos o grandes eventos) se ha abordado muchas veces anteriormente (Fig. 1). Sin embargo, para anomalías puntuales más sutiles o subsecuencias de corta duración , como en las figuras 7(b) y (c), existen situaciones que pueden no reflejarse con precisión. Por ejemplo, en la figura 7(c), se observa que una ventana grande o mediana (> unas pocas horas) puede no diferenciar con exactitud entre anomalías puntuales muy próximas. Esto se debe a que el segmento normal entre ellas, que podría ser más corto que la longitud de la ventana, no tiene la oportunidad de ser reconocido como una parte normal aislada. Además, las ventanas más pequeñas, como en la figura 7(b), pueden carecer del contexto necesario, lo que provoca puntuaciones de discordancia bajas para algunas anomalías reales. A pesar de estos desafíos, las variantes de los métodos de detección de discordancia se han mantenido como la tecnología de vanguardia en varias aplicaciones de TAD (Lin et al., 2005; Yeh et al., 2024).

3.5.3. Detección de discordancias de tráfico aisladas por pasos (Si-TDD)

Si-TDD sigue la senda de los métodos de detección de discordancia, extendiendo la aplicación de este enfoque intuitivo y práctico a los datos de volumen de tráfico. La idea central de Si-TDD es transformar el método de detección de discordancia basado en ventanas descrito anteriormente en un proceso por etapas. Esta adaptación no solo se alinea más estrechamente con las características únicas de los datos de volumen de tráfico, sino que también aborda los desafíos relacionados con la complejidad y la selección del tamaño de la ventana. Recordemos nuestra formulación principal en las Secciones 3.4 y 3.5.1. En Si-TDD, se aplican dos modificaciones importantes para adaptar el concepto. Primero, siempre establecemos = 1 en Si-TDD, lo que significa que cada punto de datos de prueba en la ubicación es el único elemento incluido en la ventana que se etiquetará en cada intervalo de tiempo:

$$= \{ \ _{(a,b)} \} . \tag{23}$$

En segundo lugar, en lugar de calcular las puntuaciones de discordancia de frente a todas las subsecuencias, como en las ecuaciones (21) y (22), comparamos los datos exclusivamente con su vecino más cercano dentro de un subconjunto designado de datos históricos. Este subconjunto consta de puntos de datos recopilados a la misma hora del día y el mismo día de la semana que los datos entrantes. En otras palabras, aprovechamos las características temporales cíclicas de los datos de volumen (discutidas anteriormente) para facilitar y mejorar la detección de discordancias, centrándonos únicamente en las partes más relevantes de los datos en cada ocasión.

La figura 8 proporciona una visión general de todo el procedimiento de detección de anomalías utilizando Si-TDD. Al principio, se construye una colección específica de) agrupando los Datos históricos (valores Y puntos de datos que comparten el mismo (día de la semana) y (hora del día) (,). Lp , como se muestra a continuación:

$$= \{ \ ^{(i,m)} \quad \{1, 2, \ldots, 7\}; \quad \{1, 2, \ldots , \ \} \} , \tag{24}$$

(,) donde cada colección incluye los siguientes elementos:

$$y \ ^{(i,m)}_{Lp} = \{ \ _{(i,j)} \mid j \ \{1, 2, \ldots , N\} \} \tag{25}$$

Machine Translated by Google

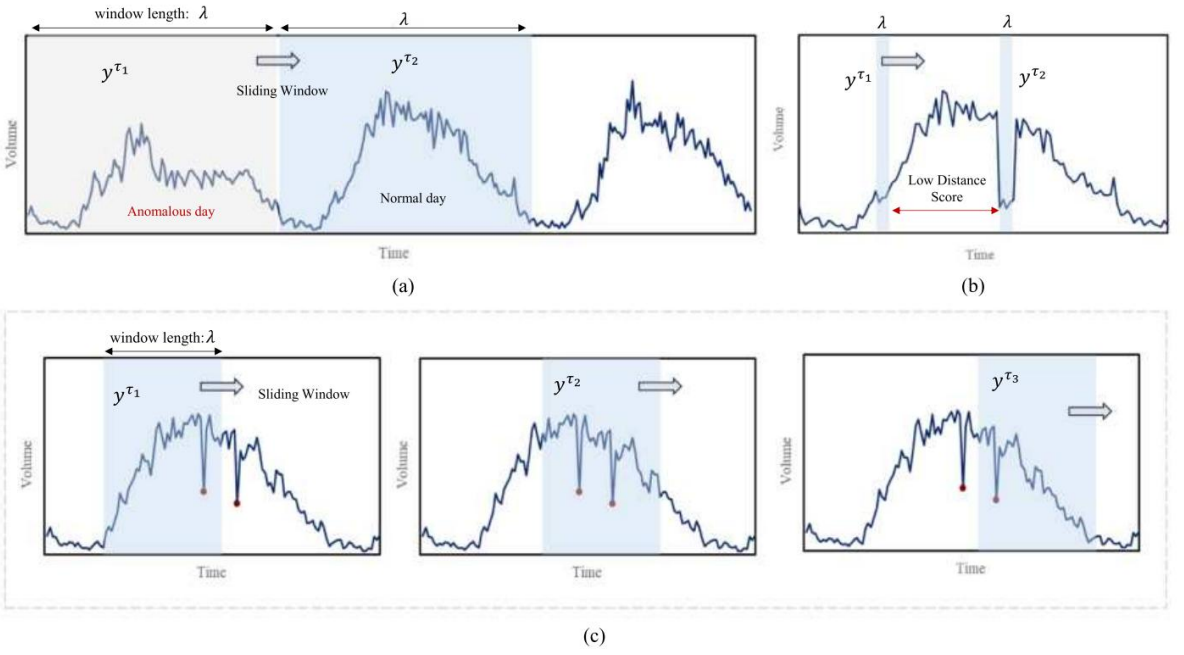


Fig. 7. Apariencia de anomalías en el volumen de tráfico en ventanas deslizantes de detección de discordia en función de la duración de la ventana de tiempo: (a) grande: ≈ un día, (b) pequeña: ≈ una hora y (c) mediana: ≈ unas pocas horas.

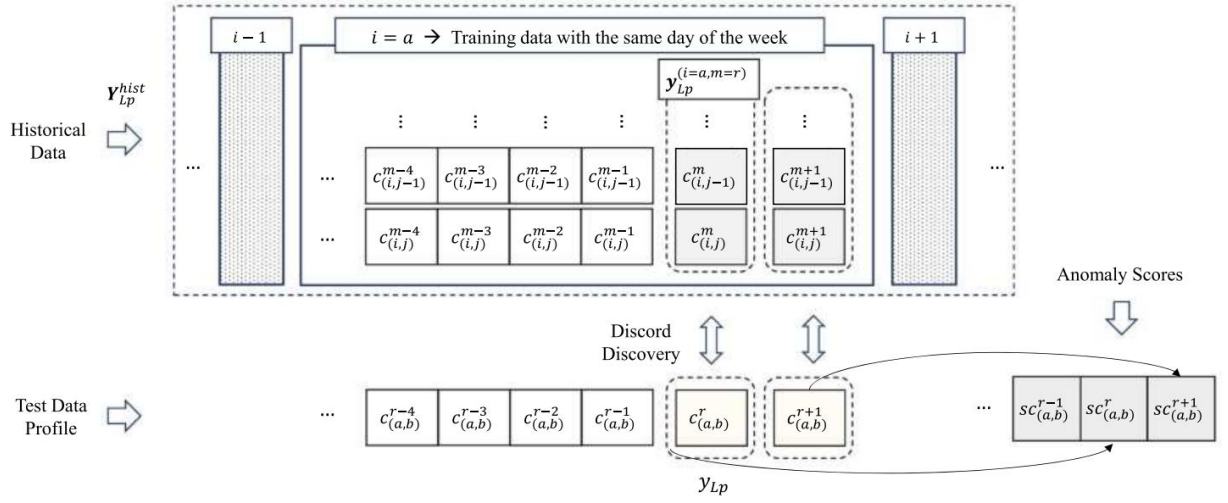


Figura 8. Demostración del procedimiento de cálculo de la puntuación de anomalías con el método Si-TDD.

con todas las notaciones definidas previamente. Luego, la puntuación de anomalía de , que también es equivalente a la puntuación de anomalía de (a,b), se calcula como la distancia euclidiana entre y su ésimo vecino más cercano en (i,m), donde = y = (denotado por =):

$$(.) = = ((.),(= ,)) \quad (26)$$

La razón para seleccionar el vecino más cercano ( ) aquí es evitar usar una anomalía similar de los datos de entrenamiento como base para el cálculo de la distancia. Según esta formulación, las puntuaciones de anomalía en Si-TDD están vinculadas a la distancia entre las muestras de prueba y sus datos históricos homogéneos. Por lo tanto, aumentan a medida que las muestras se desvían del rango esperado, y las puntuaciones más altas reflejan mayores desviaciones. El algoritmo completo para la detección de anomalías basado en Si-TDD se puede encontrar en el Algoritmo 2. Este algoritmo transforma el problema de descubrimiento de discordancia para datos de volumen de tráfico en un procedimiento más directo pero preciso, que requiere la configuración de un solo hiperparámetro ( ).

Machine Translated by Google

Es necesario mencionar varios puntos clave sobre Si-TDD. Según los métodos y las líneas base que se enumeran en la Tabla 1, se puede inferir que el potencial del descubrimiento de discordancias por pasos en los datos de volumen de tráfico ha recibido poca o ninguna atención en estudios previos, a pesar de la naturaleza intuitiva de su idea central. Enfoques similares de desviación de perfil, como variantes tipo SND (Kalair y Connaughton, 2021) y métodos de desviación de perfil medio (Grigorev et al., 2023; Ren et al., 2024), se han utilizado ampliamente como métodos clásicos para comparar con etiquetas de verdad fundamental basadas en eventos. Sin embargo, Si-TDD difiere significativamente de estos métodos, ofreciendo una perspectiva robusta que permite la generación efectiva de puntuaciones para todos los tipos de anomalías. En primer lugar, Si-TDD no se ve afectado por la presencia de grandes desviaciones en los datos de entrenamiento, ya que se sabe que tales anomalías distorsionan los perfiles convencionales basados en promedios (Chakraborty et al., 2019). En segundo lugar, a diferencia de otros métodos de detección robustos similares a SND, no presupone ninguna distribución subyacente ni tendencia central para los datos de tráfico en cada paso de tiempo, ya que la evidencia empírica sugiere que tales suposiciones no siempre son válidas (Kalair y Connaughton, 2021). Además, demostraremos que las puntuaciones de anomalía generadas por Si-TDD crean una base más precisa y fiable para la selección de umbrales en la detección de anomalías binarias que los métodos paramétricos y basados en desviación existentes, incluso cuando se utilizan parámetros optimizados junto con dichos métodos. En la siguiente sección se proporcionan evaluaciones experimentales relevantes para respaldar estas afirmaciones y demostrar la eficacia de Si-TDD.

Algoritmo 2 Detección de anomalías con descubrimiento de discordancias de tráfico aisladas por pasos (Si-TDD).

Requisitos: datos históricos , datos recién llegados Asegurar: = (= , =) , º vecino más cercano a considerar .
Puntuación de anomalía de datos nuevos: (a,b) .

(,) 1: y [] Inicializar la lista para almacenar muestras homogéneas
2: para todos los puntos de datos ( ) en la colección CLP hacer
3: (,) si = y = entonces
4: (,) 5: fin si agregar muestra a y (a,r) lista.
6: fin para
7: [] Inicializar la lista para almacenar la distancia a datos homogéneos
8: para todo (,) (,) muestras en la lista y hacen
9: Distancia euclidiana de a (, 10:) agregar .
a la lista . 11: fin para
12: _ orden descendente de valores en la lista . º elemento en la lista Ordenar la lista de distancias a los candidatos
_ . 13: (,) 14: return (,) Encontrar el -ésimo vecino más cercano
Devolver la nueva puntuación de anomalía de datos

4. Resultados experimentales

4.1. Conjunto de datos AnoLT

Para establecer el conjunto de datos AnoLT (Tráfico Etiquetado por Anomalías) utilizando nuestra plataforma de etiquetado, aprovechamos los detectores de bucle de barra de parada SCATS (Sydney Coordinated Adaptive Traffic System) de 147 secciones de carretera (sitios) conectados espacialmente dentro de Melbourne, Australia.[2] Estos sitios son parte de dos redes hipotéticas diferentes, como en la Fig. 9(a), donde cada punto representa una intersección equipada con detectores de bucle. Puede observarse en la Fig. 9(b), que estos detectores se instalan típicamente por carril en cada dirección de entrada de las intersecciones como resultado del sistema SCATS, utilizado principalmente para sistemas de control de tráfico y gestión de señales (Yazdani et al., 2023). El conjunto de datos AnoLT abarca datos de todos los enlaces dentro de las redes objetivo, con observaciones de volumen agregadas desde el nivel de carril hasta el nivel de enlace en cada intersección. El conjunto de datos contiene siete meses de datos para cada una de las redes especificadas, registrados con una resolución temporal de 15 minutos. Los datos de la red de Dandenong Road abarcan desde febrero hasta agosto de 2019, y los de la red AIMES, desde mayo hasta diciembre de 2022. Para garantizar la fiabilidad de los datos, realizamos un proceso de monitorización primaria en todos los emplazamientos, confirmando que el conjunto de datos consistía principalmente en datos operativos normales. Se excluyeron del conjunto de datos los enlaces que presentaban periodos consecutivos de datos erróneos —caracterizados por valores negativos o extremadamente altos— durante un tiempo prolongado (por ejemplo, de tres a cuatro meses).

Desarrollamos una aplicación web interactiva con Dash de Plotly (Hossain et al., 2019) para diseñar e implementar nuestra plataforma de etiquetado (como se muestra en la figura 4), lo que permitió recopilar datos de referencia. Para iniciar el proceso de etiquetado, dos expertos se familiarizaron con el sistema y recibieron instrucciones sobre los distintos tipos de anomalías que pueden presentarse en los datos de volumen de tráfico.
Antes del experimento principal de etiquetado, se realizó una sesión de prueba en la que se proporcionaron a los inspectores datos de volumen no incluidos en el conjunto de datos principal final. Durante esta sesión, se animó a los inspectores a etiquetar los datos de forma colaborativa, discutir sus hallazgos y armonizar sus estándares para el etiquetado de anomalías. Sin embargo, en el experimento principal, cada inspector etiquetó los datos de forma independiente sin la intervención de la otra persona para evitar cualquier posible sesgo. La tarea de etiquetado de cada inspector se completó durante

[2] Los datos de volumen de tráfico de SCATS para el estado de Victoria en Australia son de acceso público. Consulte la siguiente URL: https://discover.data.vic.gov.au/dataset/traffic-signal-volume-data/historical

Machine Translated by Google

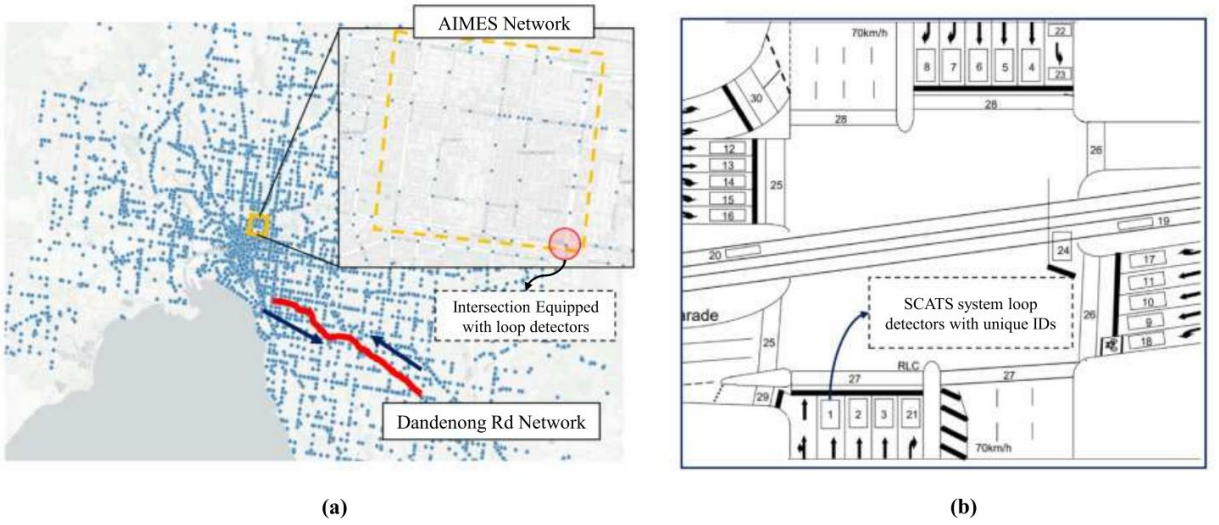


Figura 9. Visualización de (a) las redes viales objetivo en Melbourne, Australia, y (b) un ejemplo de la disposición de los detectores de bucle en una intersección dentro del sistema SCATS. En este estudio se utilizan datos volumétricos de las redes AIMES y Dandenong Road.

un período de aproximadamente tres meses, con cargas de trabajo diarias que superaban las dos horas. Al final, para cada enlace (o ubicación), se dispuso de dos conjuntos de etiquetas binarias diferentes ( ), que indicaban si el inspector había reconocido muestras individuales como una anomalía o no (como en las ecuaciones (13) y (14)). Además, se obtuvieron conjuntos de etiquetas de verdad fundamental en el conjunto de datos AnoLT. También se generaron para cada ubicación, lo que dio como resultado cuatro diferentes

La tabla 2 resume las características generales del conjunto de datos AnoLT, que incluye más de 3 millones de puntos de datos de volumen monitorizados.
La tabla también resalta las diferencias clave entre los dos conjuntos de etiquetas, señalando que el conjunto contiene un mayor número de etiquetas de anomalías en comparación con . Un análisis y comparación más detallados de las etiquetas en AnoLT se presentan en la Tabla 3, que categoriza las anomalías etiquetadas en cuatro tipos distintos según su duración (anomalía puntual, así como anomalías de subsecuencia cortas, medianas y largas). La tabla indica que, si bien las proporciones promedio de anomalías son del 3,20 % en y del 2,76 % en , estos valores varían considerablemente en diferentes ubicaciones. En algunos casos, supera el 10 %, mientras que en otros, cae por debajo del 1 %. Cabe destacar que las anomalías de shapelet cortas también son la categoría más frecuente en todo el conjunto de datos.

El grado de coherencia o concordancia entre los dos conjuntos de etiquetas, que se muestran en la Tabla 2, requiere mayor atención y análisis.
Medimos esta consistencia, también conocida como fiabilidad entre evaluadores (Saal et al., 1980), utilizando la métrica de puntuación F1, cuyo valor promedio es de 0,78. Se ha demostrado que F1 es una métrica adecuada y rigurosa para la evaluación de TAD cuando no se requiere un ajuste sistemático entre los datos y las etiquetas de referencia (Kim et al., 2022). Dado que no se espera que las etiquetas de referencia en AnoLT presenten ninguna desalineación debido a nuestro enfoque de recopilación punto por punto, la puntuación F1 se puede calcular directamente como se muestra a continuación y se utilizará en esta sección para comparar etiquetas de diferentes fuentes:

$$1 = 2 \quad \frac{\text{Precisión} \quad \text{Recuperación}}{\text{Precisión} + \text{Recuperación}} \tag{27}$$

donde la precisión se define como:

$$\text{Precisión} = \frac{\text{Verdaderos positivos}}{\text{Verdaderos positivos} + \text{Falsos positivos}} \tag{28}$$

y Recall se define como:

$$\text{Recordatorio} = \frac{\text{Verdaderos positivos}}{\text{Verdaderos positivos} + \text{Falsos negativos}}. \tag{29}$$

La Tabla 2 indica que existe un nivel promedio de alineación del 78% entre las etiquetas recopiladas en AnoLT. Este es un valor relativamente alto, ya que las puntuaciones F1 más cercanas a uno representan una mayor consistencia. La distribución detallada de esta comparación cruzada entre las etiquetas derivadas para todas las ubicaciones en AnoLT se muestra en la Figura 10. Se observa que esta métrica varía de 0,45 a 0,96, y la mayoría de las muestras o ubicaciones (>90%) alcanzan valores superiores a 0,6. Con base en este nivel de concordancia observado, concluimos que tener dos conjuntos de etiquetas distintos en nuestro conjunto de datos es suficiente para realizar un análisis comparativo exhaustivo entre varios métodos. También se demostrará que muchos métodos de vanguardia, en su forma original, presentan dificultades para alcanzar un nivel de rendimiento siquiera comparable, mientras que el método Si-TDD ofrece una alineación significativamente más razonable con estos conjuntos de etiquetas.

Además de la evaluación estadística, también visualizamos aleatoriamente los datos junto con los conjuntos de etiquetas en más de 200 casos, como se muestra en la Fig. 11, para explorar con mayor detalle las causas fundamentales de las diferencias. Descubrimos que la selección de puntos límite fue el factor principal que contribuyó a la mayoría de las diferencias entre los dos conjuntos de etiquetas. Esto era particularmente esperado y también inevitable, ya que se instruyó a los etiquetadores para que prestaran mucha atención a las anomalías "sutiles" de puntos y formas, como la segunda

Machine Translated by Google

Tabla 2

Descripción general de las características generales del conjunto de datos AnoLT.

Métrico	Primer conjunto de etiquetas ( )	Segundo conjunto de etiquetas ( )
Serie temporal total etiquetada	147	147
Número total de observaciones	3.125.856 7	3.125.856
Duración de la serie temporal por ubicación ≈	meses 15	7 meses
Resolución de recopilación de series temporales	min	15 minutos
Número total de anomalías identificadas	98.476	85.684
Número total de etiquetas conflictivas	25.303	12.511
Porcentaje de anomalías promedio por serie temporal	3,2%	2,76%
Nivel medio de acuerdo (medido mediante la puntuación F1)	0,78 (desviación estándar: 0,12)	

Tabla 3

Estadísticas básicas relacionadas con la proporción de diferentes tipos de anomalías en el conjunto de datos AnoLT (Porcentajes representan su valor asociado por ubicación en cada conjunto de etiquetas).

Tipo de anomalía	Razón en			Razón en		
	Mínimo	Máximo	Media	Mínimo	Máximo	Media
Anomalías puntuales (%)	0,13	3.15	0,93	0,09	1,63	0,60
Anomalías de formas pequeñas (%, 2-8 puntos)	0,30	3,77	1.23	0,29	2,65	1.04
Anomalías de formas medianas (%, 8-32 puntos) 0,00		2.50	0,60	0.00	2,98	0,65
Anomalías de formas largas (%, >32 puntos) 0,00		6,87	0,43	0.00	6,69	0,46
Todas las anomalías (%)	0,69	10.28	3.20	0,70	11.01	2,76

Nota: Las anomalías Shapelet (subsecuencia) se clasifican en función de su longitud: cortas (2-8 puntos, con una duración de hasta 2 h), media (8-32 puntos, 2-8 h) y larga (> 32 puntos o > 8 h).

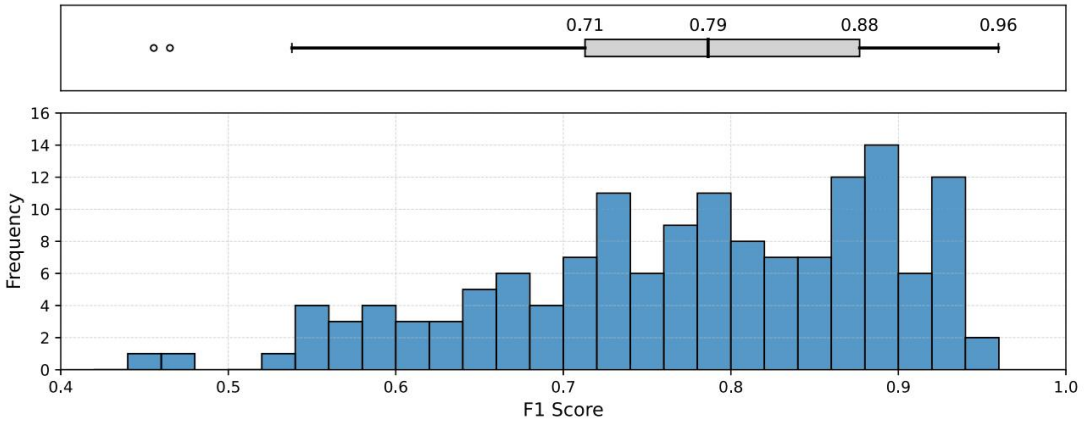


Figura 10. Histograma de las puntuaciones F1 observadas en diferentes ubicaciones, comparando las etiquetas proporcionadas por los inspectores del conjunto de datos AnoLT (entre evaluadores). fiabilidad).

anomalía en la Fig. 11(a) o la primera en la Fig. 11(e), y mantener sus estándares de manera consistente durante todo el experimento. Este fenómeno también se observa al principio o al final de anomalías notables de subsecuencias, como se muestra en la Fig. 11(b) o (g), y en puntos singulares que potencialmente indican el comienzo de una anomalía continua importante, pero los datos han vuelto a la normalidad. comportamiento posterior (por ejemplo, la tercera anomalía en la Fig. 11(e)). A pesar de la existencia de estas diferencias resultantes del nivel utilizado de sensibilidad, se registró un nivel de alineación muy alto para anomalías notables donde una anomalía está claramente presente dentro de la datos, como en la Fig. 11(c).

4.2. Líneas de base

En nuestro estudio comparativo incluimos una amplia gama de métodos, que abarcan desde enfoques clásicos hasta otros desarrollados recientemente. utilizando el conjunto de datos AnoLT. Las soluciones basadas en similitud han recibido una atención significativa tanto históricamente como en estudios recientes, con Se han propuesto numerosas técnicas de medición de similitud (Liu y Paparrizos, 2024). Una parte de esta categoría contiene métodos originalmente diseñado para datos no secuenciales que han sido adaptados por el enfoque de ventanas para abordar TAD. LOF (Breunig et al., 2000), OCSVM (Schölkopf et al., 2001), COF (Tang et al., 2002), PCA (Shyu et al., 2003), iForest (Liu et al., 2008), ABOD (Kriegel et al., 2008), HBOS (Goldstein y Dengel, 2012), LODA (Pevny`, 2016) y COPOD (Li et al., 2020b) se seleccionan de esta rama de

Machine Translated by Google

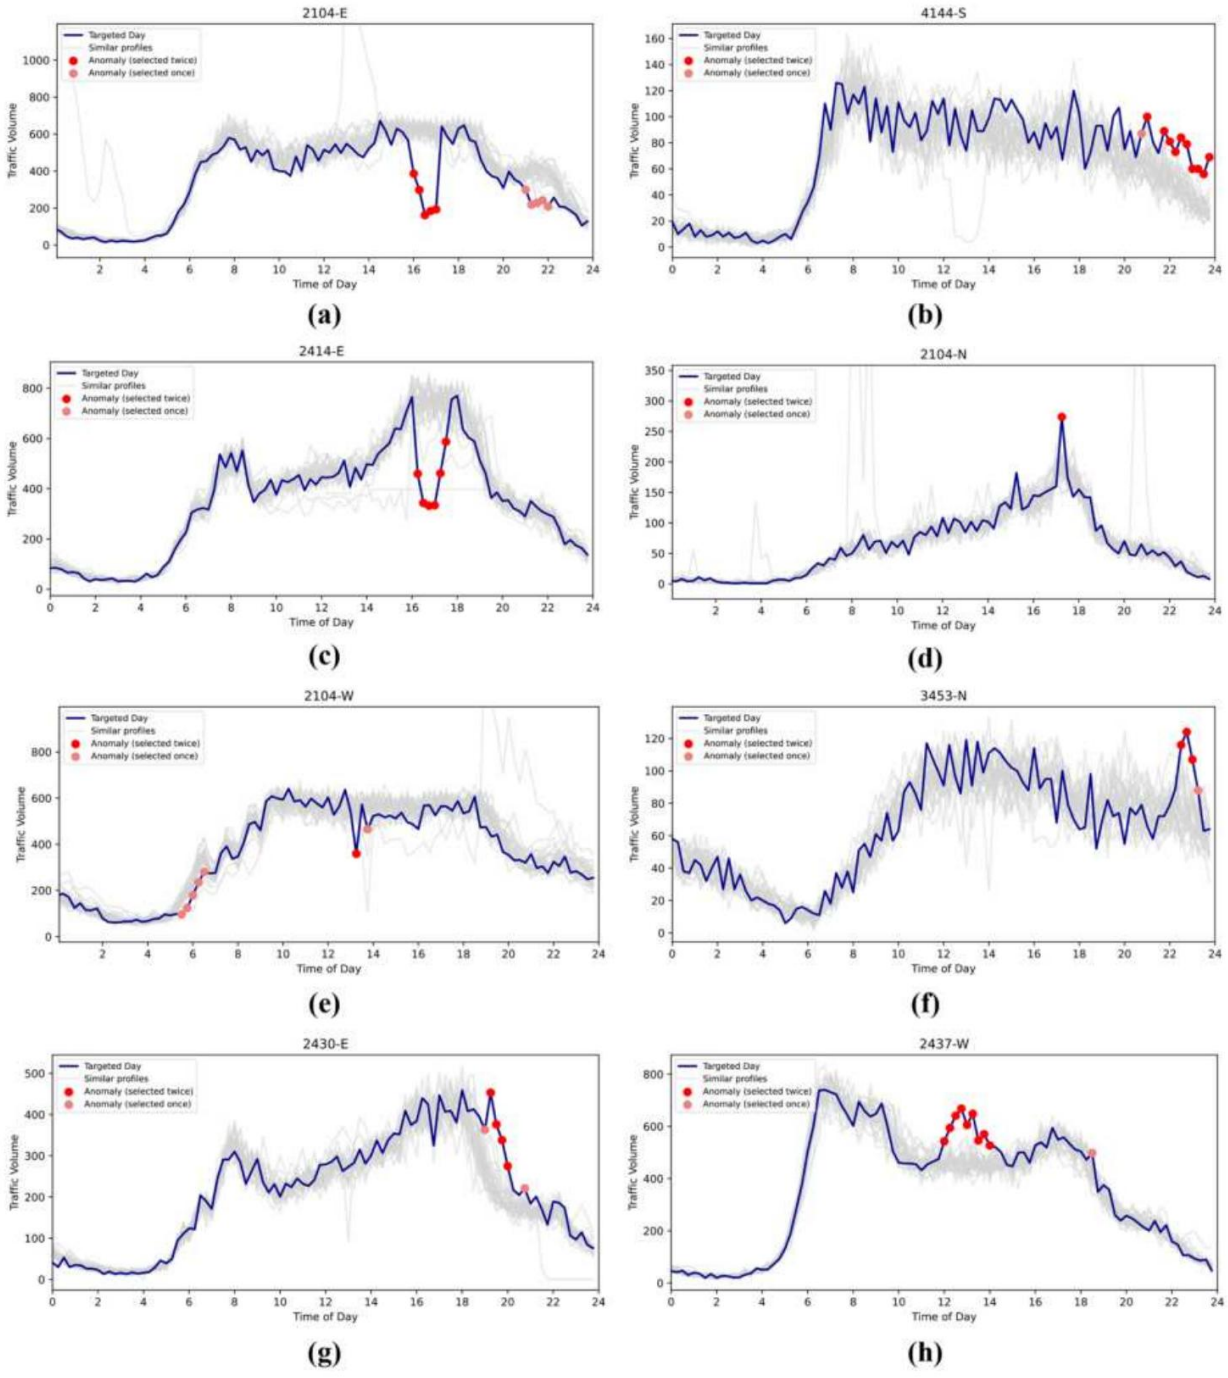


Figura 11. Vista general de las anomalías registradas en el conjunto de datos AnoLT. Los datos seleccionados por un solo inspector están resaltados en color rojo claro.

métodos. También agregamos series temporales Discord (Angiulli y Pizzuti, 2002; Nakamura et al., 2023) y su variante, el método STUMPY Matrix Profile (MP) (Law, 2019), a esta lista como representantes de enfoques basados en discord. De la intersección del aprendizaje profundo y la medición de similitud, elegimos Deep Autoencoder (AE), Variational Autoencoder (VAE) (Aggarwal, 2016) y redes generativas adversarias, como SO-GAAL y MO-GAAL (Liu et al., 2019). Estos métodos suelen estimar la distribución subyacente de secuencias normales y la aprovechan durante la etapa de prueba para identificar datos anómalos. También incluimos STGAN (Deng et al., 2022) y Auto-RL (He et al., 2023) en este grupo para reflejar también el progreso específico del dominio en estudios de tráfico. En la categoría de métodos basados en predicción , consideramos la autorregresión (AR) (Rousseeuw y Leroy, 2005), un algoritmo clásico y ampliamente reconocido que ha demostrado resultados prometedores en aplicaciones TAD específicas. Adicionalmente, incluimos LSTM (Bontemps et al., 2016), ju

Machine Translated by Google

Tabla 4

Espacios de búsqueda de hiperparámetros para las líneas base (los valores en negrita dieron como resultado el mejor rendimiento).

Método	Hiperparámetro	Espacio de búsqueda
diputado	tamaño_ventana y tamaño_paso	[3, 4, 5, …, 10] y [1, 2, 3]
LOF	n_vecinos	5, 7, 10, 15, 20
	tamaño_ventana	3, 4, 5, 7, 10
PCA	estructura_capas	[3, 2], [3, 1], [4, 2], [4, 3], [5, 3], [5, 4], [5, 3], [5, 2], [7, 4], [7, 3], [7, 2], [10, 7], [10, 5], [10, 3], [10, 2]
COF	n_vecinos	5, 7, 10, 15, 20
	tamaño_ventana	3, 4, 5, 7, 10
ABOD	n_vecinos	5, 7, 10, 15, 20
	tamaño_ventana	3, 4, 5, 7, 10
HBOS	n_bins y tolerancia	[5, 7, 10, 15, 20] y [0.1, 0.2, 0.3, 0.5]
	alfa y tamaño_ventana n_bins	[0,1, 0,2, 0,3, 0,5] y [3, 4, 5, 7, 10]
CARGA		5, 7, 10, 15, 20, 25, 30
	n_cortes_aleatorios y tamaño_ventana	[20, 50, 70, 100, 120, 150, 200] y [3, 4, 5, 7, 10]
iForest		Verdadero, Falso
	comportamiento de arranque y	['viejo', 'nuevo'] y [3, 4, 5, 7, 10]
Discordia	tamaño_ventana tamaño_ventana	[3, 4, 5, 6, 7, 8, 9, 10] y ['mayor', 'media', 'mediana']
	y método tamaño_paso y	[1] y [5, 7, 10, 15, 20]
OCSVM	n_vecinos kernel	['lineal', 'poli', 'rbf', 'sigmoide'] y [0,4, 0,5, 0,6]
	y tolerancia nu, reducción y tamaño_ventana	[0,001] [Verdadero] y [3, 4, 5, 7, 10]
COPOD	tamaño_ventana	3, 4, 5, 7, 10
PERO	estructura_capas	[3, 2, 1, 2, 3], [3, 2, 2, 2, 3], [4, 3, 2, 3, 4], [4, 3, 2, 1, 2, 3, 4], [5, 4, 3, 4, 5], [5, 4, 3, 2, 3, 4], [7, 5, 4, 3, 4, 5, 7], [7, 5, 3, 5, 7], [7, 4, 3, 2, 3, 4, 7], [10, 7, 4, 7, 10], [10, 5, 4, 3, 4, 5, 10], [10, 5, 4, 3, 2, 3, 4, 5]
PIES	estructura_de_capas	[3, 2, 1, 2, 3], [3, 2, 2, 3], [4, 3, 2, 3, 4], [4, 3, 3, 3, 4], [5, 4, 3, 3, 3, 4, 5], [5, 4, 3, 2, 3, 4, 5], [7, 5, 4, 3, 4, 5, 7], [7, 5, 4, 2, 4, 5, 7], [7, 4, 3, 4, 7], [10, 7, 4, 4, 7, 10], [10, 5, 4, 3, 4, 5, 10], [10, 5, 4, 3, 2, 3, 4, 5, 10]
SO-G y MO-G	n_épocas y k para MO-G tamaño de ventana	20 y 10 3, 4, 5, 7, 10
CON	window_size y step_size	[3, 4, 5, 6, 7, 8, 9, 10] y 1
LSTM	hidden_dim y n_epochs	[32, 64] y 20
	window_size y n_hidden_layer	[3, 5, 7, 10] y [3, 5, 10]
	min_anomaly_time	1, 2, 3, 4
DeepLog	hidden_dim	32, 64
	n_epochs y dropout_rate	20 y 0,1
	window_size	3, 5, 7, 10
	stacked_layers	2, 3, 4
Teleman	smoothing y n_prediction n_epochs	0,05 y 1
	y dropout_rate window_size	20 y 0,1
	layers for	3, 5, 7, 10
	anomaly	[10, 10], [10, 10, 10], [10, 10, 10, 10]
STGAN	score recent_time, y	[rango de 0 a 1]
	num_feature timestamp, y	1 h (predeterminado) y 1 (solo volumen)
	n_subgraph_nodes time_feature state_len	4 (muestras de 15 minutos por hora) y 9 (predeterminado)
	y	31 (24 h + 7 días por semana)
Auto-RL	window_smoothing kde_timesteps_included	[15, 20, 25] y [1, 2, 3, ., 10]
	n_neighbors	[aislado, ± 2 pasos]
Si-TDD		1, 2, 3, 4, 5, 6, 7, 8, 9, 10

con sus avances recientes, DeepLog (Du et al., 2017) y Telemanom (Hundman et al., 2018), como métodos basados en aprendizaje para detección de anomalías basada en predicciones.

Los métodos descritos anteriormente se implementaron utilizando TODS (Lai et al., 2021a) y PyOD (Zhao et al., 2019), dos herramientas de vanguardia. Paquetes de Python diseñados específicamente para la evaluación comparativa de métodos de detección de anomalías. Para STGAN, también aprovechamos las relaciones espaciales de las redes viales incluidas en AnoLT, según lo requiere la arquitectura de detección, utilizando la implementación de código proporcionada. en el artículo principal (Deng et al., 2022). También implementamos Auto-RL basado en la arquitectura descrita por He et al. (2023), como el El código original no estaba disponible públicamente. Para cada ubicación, el conjunto de datos se dividió en subconjuntos de entrenamiento (70%) y prueba (30%). y la evaluación se logró registrando la puntuación F1 más alta punto por punto del conjunto de prueba derivado de diferentes umbrales aplicados. a puntuaciones de anomalías. También se realizó un ajuste de hiperparámetros utilizando una búsqueda en cuadrícula sobre un espacio de búsqueda predefinido y razonable, que también incluía los valores predeterminados. Estos espacios de búsqueda de líneas base se describen en la Tabla 4, donde el hiperparámetro óptimo Las combinaciones identificadas para el conjunto de datos AnoLT están resaltadas en negrita.

Machine Translated by Google

Para analizar con mayor detalle la eficacia de Si-TDD, también evaluamos exclusivamente su rendimiento en comparación con los métodos existentes basados en perfiles. Estos métodos, también conocidos como enfoques tipo SND, siguen los principios de los métodos basados en similitud y provienen de la investigación clásica sobre detección de incidentes. Si bien los trabajos de detección de incidentes se han orientado hacia análisis ascendentes y descendentes en autopistas para reducir las falsas alarmas (una capacidad posibilitada por detectores de bucle adyacentes instalados a lo largo de la carretera o datos de vehículos conectados), los métodos tipo SND siguen siendo referencias eficaces para tareas específicas de cada sitio, particularmente en contextos que carecen de fuertes conexiones espaciales entre sitios (Chakraborty et al., 2019; Kalair y Connaughton, 2021). Estos métodos calculan las desviaciones en cada momento del día y día de la semana, con diferentes variantes que se describen a continuación:

- SND (Balke et al., 1996): Calcula la desviación normal estándar, señalando anomalías cuando el valor observado supera la media. por veces la desviación estándar.
- IQR (Pearson, 2005): Señala anomalías cuando el valor observado es menor que 1 − × IQR o mayor que 3 + × IQR, donde 1 y 3 denotan el primer y tercer cuartil, e IQR = 3 − 1 . • SND-R (Kalair y Connaughton, 2021): Una variante robusta de SND que utiliza la mediana en lugar de la media y el rango intercuartil (IQR) en lugar de la desviación estándar, señalando anomalías cuando el valor observado excede la mediana en veces el IQR.

- MAD (Hampel, 1974): Utiliza la mediana y la desviación absoluta media (MAD) como medida de dispersión, señalando anomalías. cuando el valor observado supera la mediana en veces la MAD.
- Med-D: Una adaptación robusta de los métodos de distancia de perfil promedio (Grigorev et al., 2023; Ren et al., 2024) (ya que los promedios son sensibles a los valores atípicos grandes), utilizando la distancia absoluta entre el valor observado y el perfil mediano en cada momento del día y día de la semana directamente como puntuación de anomalía.

Para los métodos pertinentes, el parámetro de escalado de umbral se optimiza completamente para cada ubicación probando valores en el rango de 0,05 a 10, con un tamaño de paso de 0,001, lo que garantiza que el rendimiento óptimo en todos los casos se encuentre dentro de este rango.

4.3. Estudios comparativos

Las tablas 5 y 6 presentan las métricas de rendimiento de todas las líneas base evaluadas frente a las etiquetas de referencia en AnoLT (, , ∩ y). La figura 12 complementa estas tablas al visualizar la distribución de las puntuaciones F1 en diferentes ubicaciones para varios métodos seleccionados, incluido Si-TDD. Los resultados demuestran claramente que Si-TDD supera significativamente a otras líneas base en términos de cálculo de puntuación de anomalía, alcanzando una puntuación F1 superior al 67 % y un AUC-ROC del 97 %. Esto también se ve respaldado por la figura 12, que muestra que Si-TDD alcanza puntuaciones superiores a 0,4 en diversas ubicaciones, lo que subraya su rendimiento robusto y su fiabilidad en todos los escenarios. En contraste, otros métodos de vanguardia, tanto basados en predicciones como en similitud, demuestran ser considerablemente menos efectivos al aplicarse a datos de volumen de tráfico, obteniendo la mayoría puntuaciones F1 promedio de aproximadamente el 45 % o menos. Las distribuciones de la Figura 12 también resaltan este bajo rendimiento en diferentes ubicaciones en comparación con Si-TDD.

Se pueden identificar factores específicos para explicar los resultados obtenidos. Para los métodos TAD basados en similitud , el principal desafío reside en el comportamiento cíclico único inherente a los datos de volumen de tráfico, que difiere significativamente de muchos otros tipos de conjuntos de datos. Los métodos de esta categoría son capaces de ofrecer resultados satisfactorios en otros contextos, ya que el comportamiento cíclico de los datos en estos escenarios se repite a menudo varias veces en un corto período. Por ejemplo, en los datos de ECG, se puede generar una serie temporal completa en tan solo unos segundos, y las anomalías suelen manifestarse como patrones anormales distintos (Wu y Keogh, 2021). En tales casos, cualquier subsecuencia a corto plazo (como se mencionó anteriormente), incluso con una duración de tan solo unos segundos, generalmente contiene al menos algunos ciclos completos y significativos, lo que hace que las comparaciones de similitud basadas en ventanas sean una solución eficaz. En los datos de volumen de tráfico, sin embargo, un ciclo completo abarca un día entero (24 h), lo que significa que las ventanas de entre 3 y 10 muestras (equivalentes a entre 45 y 150 min) no logran capturar un patrón distinguible o significativo. En consecuencia, se espera un rendimiento bajo al utilizar métodos basados en similitud con datos de tráfico estructurados en ventanas de este tipo. Si bien aumentar la longitud de la ventana a un día ofrece una solución viable para detectar perfiles diarios anómalos, aquí se demuestra que no es adecuada para detectar anomalías finas (dentro del día) en los datos de volumen de tráfico (como se analiza en la Fig. 7 para el método de detección de discordancia).

Aunque desarrollados para datos de tráfico, STGAN y Auto-RL no arrojaron resultados de detección comparables en esta categoría. Para STGAN, se observó que la estructura propuesta, en particular los componentes generador y discriminador, no pudo aprender eficazmente el comportamiento subyacente de los datos de tráfico en AnoLT, a pesar de la entrada completa de características temporales y espaciales y ajustes de hiperparámetros. Esto se debe a factores como la disponibilidad de solo una serie de volumen por ubicación (en lugar de series adicionales como velocidad y ocupación) y diferencias en la ubicación del detector, tamaño de los datos y características en comparación con el estudio original. Trabajos anteriores también han demostrado que las arquitecturas avanzadas de aprendizaje profundo, si bien logran un alto rendimiento en entornos específicos, pueden no generalizarse bien a otros contextos (Lai et al., 2021b). También se ha demostrado que Auto-RL detecta desviaciones de subsecuencia sustanciales y prolongadas en conjuntos de datos experimentales que contienen al menos un 10 % de anomalías (He et al., 2023). En contraste, observamos que AnoLT contiene, en promedio, entre un 2 % y un 3,5 % de anomalías (Tabla 2), con algunas anomalías importantes en subsecuencias que abarcan solo entre 5 y 6 muestras (equivalente a entre 75 y 90 minutos, dado nuestro intervalo de recolección de 15 minutos). Esto plantea desafíos adicionales para entrenar eficazmente el componente de aprendizaje por refuerzo dentro de este método para diferenciar entre muestras normales y anormales en AnoLT.

Los métodos basados en predicciones no sufren el problema de la longitud de la ventana que presentan los métodos basados en similitud; sin embargo, su enfoque en reducir el error de predicción en lugar de detectar anomalías los hace menos efectivos para identificar anomalías en formas o subsecuencias.
Cuando se enfrentan a tales anomalías, a menudo predicen la siguiente observación basándose en valores anómalos recientes para minimizar el error de predicción, lo que limita principalmente su aplicabilidad en TAD. Dado que las anomalías de subsecuencia constituyen una porción considerable de todas las anomalías, es evidente a partir de las Tablas 5 y 6 que los métodos basados en predicción no son suficientemente efectivos para AnoLT. Esta justificación

Machine Translated by Google

Tabla 5

Métricas de precisión de los métodos TAD con los conjuntos de etiquetas y en AnoLT.

Nombre	Resultados basados en				Resultados basados en				
	Precisión AUC		Rec	F1	Precisión AUC F-SD		Rec	F1	F-SD
diputado	0,567	0,157	0,760	0,260	0,095	0,559	0,126	0,720	0,214	0,092
LOF	0,774	0,418	0,483	0,449	0,090	0,784	0,418	0,444	0,431	0,104
PCA	0,466	0,187	0,793	0,303	0,106	0,478	0,181	0,711	0,288	0,111
COF	0,723	0,348	0,479	0,403	0,075	0,732	0,342	0,435	0,383	0,089
ABOD	0,789	0,406	0,519	0,456	0,093	0,793	0,413	0,470	0,440	0,091
HBOS	0,624	0,211	0,663	0,320	0,108	0,634	0,192	0,585	0,289	0,110
CARGA	0,614	0,233	0,639	0,342	0,103	0,630	0,230	0,575	0,329	0,109
iForest	0,588	0,212	0,635	0,317	0,098	0,605	0,186	0,559	0,279	0,108
Discord	0,774	0,398	0,527	0,454	0,093	0,778	0,406	0,478	0,439	0,093
OCSVM	0.634	0,259	0,555	0,353	0,094	0,646	0,257	0,490	0,337	0,110
COPOD	0.525	0,188	0,712	0,270	0,105	0,534	0,165	0,675	0,238	0,107
PERO	0,457	0,189	0,840	0,309	0,105	0,471	0,180	0,779	0,293	0,111
PIES	0,450	0,190	0,826	0,309	0,103	0,461	0,179	0,771	0,290	0,109
SO-G	0,420	0,140	0,920	0,243	0,093	0,430	0,117	0,914	0,207	0,104
GATITO	0,412	0,139	0,925	0,241	0,093	0,423	0,116	0,911	0,206	0,104
STGAN	0.671	0,120	0,268	0,166	0,065	0,672	0,122	0,262	0,166	0,071
Auto-RL	0,729	0,238	0,289	0,261	0,139	0,743	0,231	0,321	0,268	0,143
CON	0,663	0,192	0,254	0,219	0,069	0,656	0,198	0,241	0,217	0,085
LSTM	0,620	0,071	0,400	0,120	0,064	0,612	0,058	0,390	0,101	0,064
DeepL	0,722	0,264	0,293	0,278	0,083	0,721	0,265	0,294	0,279	0,091
Telecomunicaciones	0,629	0,149	0,319	0,203	0,083	0,631	0,141	0,336	0,199	0,094
Si-TDD	0,976	0,684	0,668	0,676	0,075	0,971	0,680	0,649	0,664	0,086

Notas: SO-G: SO-GAAL, MO-G: MO-GAAL, DeepL: DeepLog, Telem: Telemanom, AUC: AUC-ROC, Prec: Precisión, Rec: Recuperación, F1: Puntuación F1, F-SD: Desviación estándar de la puntuación F1.

También se menciona anteriormente en los hallazgos de otros estudios comparativos de TAD (Liu y Paparrizos, 2024). Otro punto destacable también Se refiere específicamente a los enfoques de aprendizaje profundo dentro de esta categoría, y potencialmente a otras. Si bien los métodos avanzados demuestran A pesar de su excepcional rendimiento en diversas tareas de autoaprendizaje, como la predicción de series temporales, siguen siendo menos populares para estas aplicaciones. Dado que TAD es una tarea de investigación, intuitiva y explicativa, a menudo existe una preferencia por lo directo y autoexplicativo. métodos que se alinean más estrechamente con estas características (Nakamura et al., 2023). Además, desafíos como el sobreajuste y Las arquitecturas altamente parametrizadas limitan aún más la aplicabilidad de estos métodos a las aplicaciones TAD (Wu y Keogh, 2021).

La figura 13 se proporciona para ilustrar la sensibilidad del tamaño de la ventana a la precisión final de los métodos TAD. Como se ha señalado, para los métodos basados en similitud, las longitudes de ventana de tamaño medio producen un rendimiento superior en comparación con las más pequeñas, ya que los intervalos más grandes representan más información relacionada con patrones. Los métodos basados en predicción, por otro lado, muestran baja sensibilidad al tamaño de la ventana, con su menor El rendimiento se atribuye principalmente a factores como la limitación en la captura de información de contexto y anomalías en la subsecuencia. Debería Cabe señalar que no se evaluaron tamaños de ventana mayores de 10 puntos (2,5 h), ya que asignar etiquetas de ventanas grandes a individuos Los puntos en los métodos basados en similitud no se pueden realizar con precisión y son incompatibles con la naturaleza de las anomalías en AnoLT (Fig. 7). Para los métodos basados en predicciones, el rango seleccionado también se ajusta a las prácticas estándar de trabajos anteriores (Qi et al., 2022).

Los resultados comparativos con enfoques basados en perfiles (tipo SND) también se resumen en las Tablas 7 y 8. Como se mencionó anteriormente, para Para lograr estos resultados, seleccionamos el valor umbral óptimo para cada ubicación basándonos en las etiquetas de AnoLT. Para los métodos que requieren Para el coeficiente , empleamos una búsqueda en cuadrícula amplia y fina (de 0,05 a 10 en incrementos de 0,001). Para Med-D, umbrales se aplicaron sistemáticamente en función de las medidas de distancia derivadas. Los resultados muestran que Si-TDD sigue superando a estos enfoques, y esto puede atribuirse a diferentes factores. Primero, los supuestos estadísticos subyacentes de SND, IQR, SND-R y MAD parece no ser adecuado para los datos de tráfico en AnoLT. Incluso con pruebas exhaustivas de umbrales finamente incrementados dentro de estos métodos (valores), los resultados resultantes siguen siendo considerablemente inferiores a los obtenidos mediante el umbralizado de las puntuaciones Si-TDD. Fig. 14 Muestra las estimaciones de densidad de los datos recopilados en una ubicación específica durante diferentes intervalos de tiempo en un día seleccionado de la semana. Se puede observar que la distribución de los datos de volumen de tráfico varía en intervalos de tiempo y días, lo que refleja la variabilidad inherente. en condiciones normales de tráfico. Esto desafía la suposición de tendencias centrales estables en los métodos tipo SND, que suponen que Las desviaciones simétricas de estos indicadores centrales representan anomalías.

Además, los valores más altos de F1 de Med-D y Si-TDD también indican que el uso de mediciones basadas en la distancia a una referencia El punto crea un espacio de búsqueda más optimizado para la selección del umbral final, lo que conduce a etiquetas binarias de anomalías más precisas. La superioridad de Si-TDD sobre Med-D radica además en su capacidad para tener en cuenta la variabilidad normal presente en los datos. La importancia Esto se evidencia en la Fig. 14, que muestra que las muestras normales no siempre están distribuidas simétricamente alrededor de la mediana. lo que conduce a un rendimiento más bajo en lugares donde esta asimetría es más intensa (como también lo indica la columna FM en las Tablas 7 y 8). Esto se vuelve aún más crítico en situaciones donde existen patrones de tráfico bimodal, con variaciones de tráfico en ciertos momentos. intervalos que exhiben dos regímenes distintos (Kalair y Connaughton, 2021). En tales casos, el valor mediano puede estar ubicado cerca de uno

Machine Translated by Google

Tabla 6

Métricas de precisión de los métodos TAD con los conjuntos de etiquetas ∩ y en AnoLT.

Nombre	Resultados basados en ∩					Resultados basados en				
	Precisión AUC		Rec	F1		Precisión AUC F-SD		Rec	F1	F-SD
diputado	0,560	0,107	0,672	0,184	0,077	0,567	0,178	0,777	0,289	0,091
LOF	0,796	0,419	0,423	0,421	0,112	0,765	0,415	0,513	0,459	0,084
PCA	0,486	0,181	0,653	0,283	0,111	0,459	0,195	0,841	0,316	0,100
COF	0,744	0,345	0,408	0,374	0,094	0,715	0,349	0,506	0,413	0,069
ABOD	0,807	0,423	0,445	0,433	0,098	0,780	0,410	0,546	0,469	0,088
HBOS	0,638	0,169	0,568	0,261	0,110	0,621	0,225	0,694	0,339	0,101
CARGA	0,640	0,221	0,544	0,314	0,109	0,606	0,235	0,678	0,349	0,099
iForest	0,616	0,178	0,506	0,263	0,107	0,580	0,218	0,696	0,332	0,094
Discord	0,792	0,399	0,455	0,425	0,100	0,764	0,392	0,560	0,462	0,089
OCSVM 0.660		0,259	0,466	0,333	0,111	0,623	0,259	0,601	0,362	0,092
COPOD 0.541		0,149	0,637	0,212	0,106	0,519	0,207	0,739	0,294	0,098
PERO	0,478	0,174	0,735	0,282	0,110	0,450	0,190	0,881	0,313	0,100
PIES	0,469	0,177	0,720	0,285	0,107	0,443	0,193	0,881	0,316	0,097
SO-G	0,430	0,095	0,910	0,172	0,088	0,419	0,161	0,921	0,274	0,094
GATITO	0,423	0,094	0,905	0,171	0,088	0,412	0,160	0,933	0,273	0,094
STGAN 0.681		0,121	0,241	0,161	0,076	0,664	0,123	0,293	0,173	0,060
Auto-RL 0,756		0,209	0,342	0,260	0,145	0,719	0,260	0,273	0,266	0,137
CON	0,659	0,205	0,216	0,211	0,088	0,661	0,192	0,272	0,225	0,068
LSTM	0,612	0,053	0,374	0,092	0,062	0,622	0,073	0,431	0,125	0,063
DeepL	0,728	0,274	0,277	0,275	0,095	0,718	0,253	0,311	0,279	0,081
Telecomunicaciones	0,637	0,149	0,289	0,197	0,098	0,624	0,136	0,362	0,198	0,080
Si-TDD	0,978	0,690	0,666	0,678	0,089	0,971	0,676	0,668	0,672	0,072

Notas: SO-G: SO-GAAL, MO-G: MO-GAAL, DeepL: DeepLog, Telem: Telemanom, AUC: AUC-ROC, Prec: Precisión, Rec: Recuperación, F1: Puntuación F1, F-SD: Desviación estándar de la puntuación F1.

Tabla 7

Comparación de precisión con métodos basados en perfiles utilizando los conjuntos de etiquetas y en AnoLT.

Nombre	Resultados basados en						Resultados basados en					
	AUC	Prec	Rec	F1	F-SD	FM	AUC	Prec	Rec	F1	F-SD	FM
SND	0,785	0,548	0,585	0,566	0,097	0,239	0,774	0,537	0,561	0,549	0,110	0,238
IQR	0,770	0,474	0,557	0,512	0,104	0,284	0,760	0,472	0,536	0,502	0,121	0,241
SND-R	0,762	0,487	0,543	0,513	0,104	0,294	0,753	0,477	0,521	0,498	0,122	0,246
MAD	0,764	0,463	0,548	0,502	0,104	0,255	0,754	0,467	0,525	0,494	0,121	0,259
Med-D	0,966	0,611	0,596	0,603	0,091	0,296	0,962	0,612	0,579	0,595	0,101	0,331
Si-TDD	0,976	0,684	0,668	0,676	0,075	0,449	0,971	0,680	0,649	0,664	0,086	0,423

Nota: AUC: AUC-ROC, Prec: Precisión, Rec: Recuperación, F1: Puntuación F1, F-SD: Desviación estándar de la puntuación F1, FM: F1 mínimo Puntuación observada.

Tabla 8

Comparación de precisión con métodos basados en perfiles utilizando los conjuntos de etiquetas ∩ y en AnoLT.

Nombre	Resultados basados en ∩						Resultados basados en					
	AUC	Prec	Rec	F1	F-SD	FM	AUC	Prec	Rec	F1	F-SD	FM
SND	0,776	0,545	0,564	0,554	0,112	0,240	0,780	0,558	0,576	0,567	0,094	0,250
IQR	0,759	0,472	0,531	0,499	0,123	0,241	0,773	0,482	0,568	0,521	0,102	0,305
SND-R	0,753	0,475	0,519	0,496	0,124	0,248	0,770	0,485	0,561	0,520	0,102	0,305
MAD	0,750	0,472	0,513	0,492	0,123	0,248	0,774	0,461	0,574	0,511	0,102	0,275
Med-D	0,970	0,626	0,590	0,607	0,107	0,255	0,961	0,604	0,592	0,598	0,085	0,373
Si-TDD	0,978	0,690	0,666	0,678	0,089	0,432	0,971	0,676	0,668	0,672	0,072	0,444

Nota: AUC: AUC-ROC, Prec: Precisión, Rec: Recuperación, F1: Puntuación F1, F-SD: Desviación estándar de la puntuación F1, FM: F1 mínimo Puntuación observada.

régimen, lo que provoca que las observaciones normales del otro se marquen incorrectamente como anomalías. Medir distancias a los vecinos, como en Si-TDD se adapta mejor a estas situaciones al capturar la dispersión local y la posible agrupación inherente dentro de los datos.

Machine Translated by Google

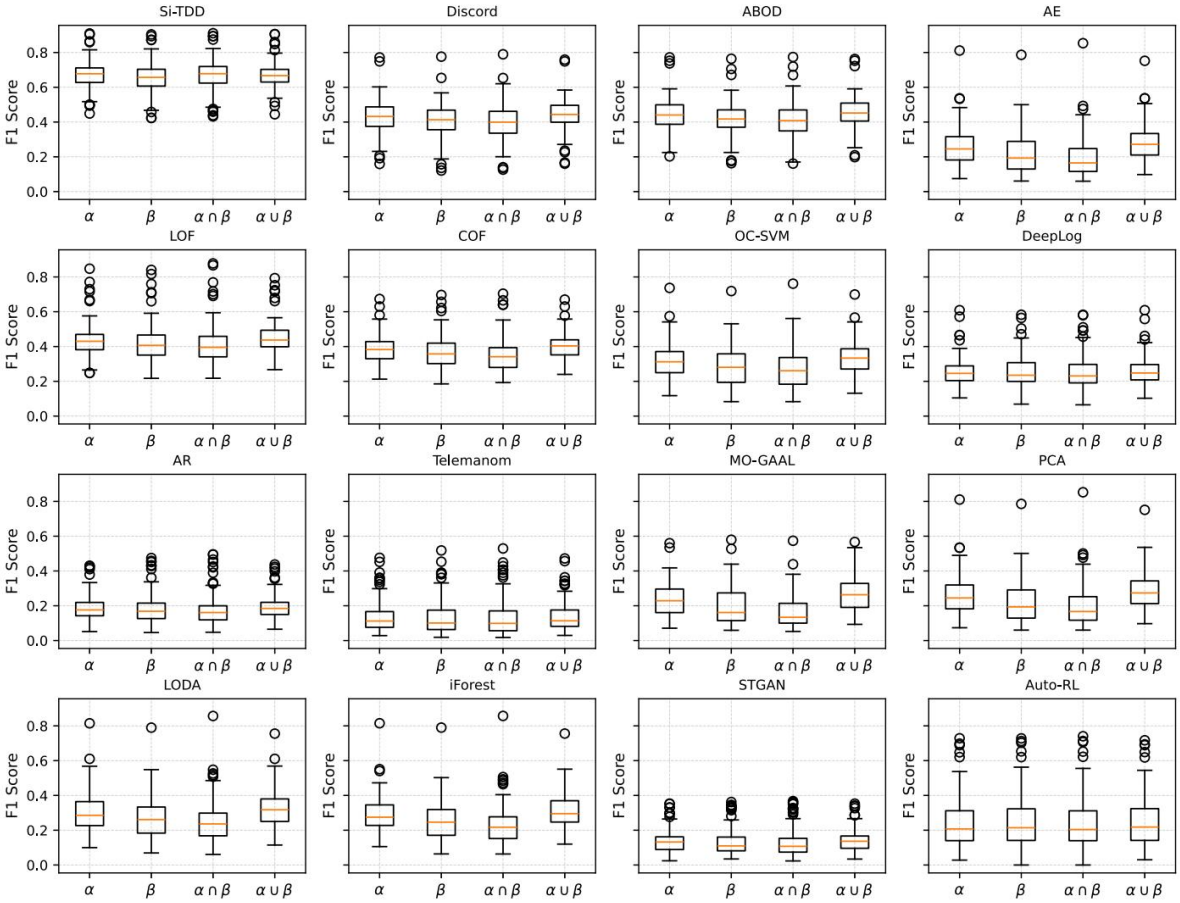


Figura 12. Comparación de las distribuciones de la puntuación F1 en todas las ubicaciones para los métodos seleccionados.

4.4. Análisis del rendimiento de Si-TDD

Como se indicó anteriormente, se pueden observar varios tipos de anomalías en los datos de volumen de tráfico al investigar las desviaciones de los patrones periódicos esperados inherentes a los datos. Si-TDD aprovecha el mismo principio al cuantificar el grado en que cada punto de datos se desvía de otras observaciones temporalmente similares, proporcionando un mecanismo robusto para intensificar las anomalías que alteran estos patrones. La figura 15 muestra el rendimiento de Si-TDD en algunos casos del conjunto de datos AnoLT. Como se muestra, este método identifica eficazmente una amplia gama de anomalías en los datos de tráfico, desde anomalías puntuales sutiles (Fig. 15 (b, d, f y g)) hasta desviaciones largas e importantes (Fig. 15 (c, e y h)), requiriendo solo la configuración de un hiperparámetro ( ). Esto contrasta con otros métodos de referencia de última generación, que a menudo carecen de la capacidad de capturar anomalías tan sutiles e incluso importantes en algunos casos, mientras que requieren la configuración de varios hiperparámetros. Este requisito se mantiene a pesar de que se espera que estos métodos, como Si-TDD, produzcan puntuaciones de anomalías (Tabla 1) que aún deben convertirse en etiquetas binarias para su uso práctico.

Si bien Si-TDD muestra una mejor alineación con las etiquetas de referencia en AnoLT, se observa que aún no se logra una coincidencia perfecta y completa. Investigamos varias situaciones donde existen inconsistencias entre las anomalías predichas y las etiquetas en nuestros datos. Algunos ejemplos de estos casos, incluyendo ciertas muestras de falsos positivos (FP) y falsos negativos (FN), se muestran en la Fig. 16. Basándonos en esta figura, y como se observa en muchos otros casos, todas las inconsistencias pueden atribuirse al concepto de punto límite mencionado anteriormente. Dado nuestro objetivo de etiquetar meticulosamente las anomalías en los datos volumétricos, este requisito fue, en algunos casos, difícil de cumplir.

Debido a la variación significativa en los patrones de datos entre los días de la semana y entre diferentes ubicaciones, mantener un rendimiento de etiquetado consistente durante todo el experimento resultó un desafío para los etiquetadores. Como resultado, esto generó algunas discrepancias tanto entre los etiquetadores como entre sus etiquetas y los resultados del método. Sin embargo, la intuición y la interpretabilidad de Si-TDD proporcionan información valiosa que aumenta la confianza en su rendimiento en tales casos. Si-TDD detecta anomalías al identificar puntos de datos que se encuentran suficientemente lejos de sus respectivos vecinos más cercanos. El umbral discriminatorio también se aplica constantemente.

Machine Translated by Google

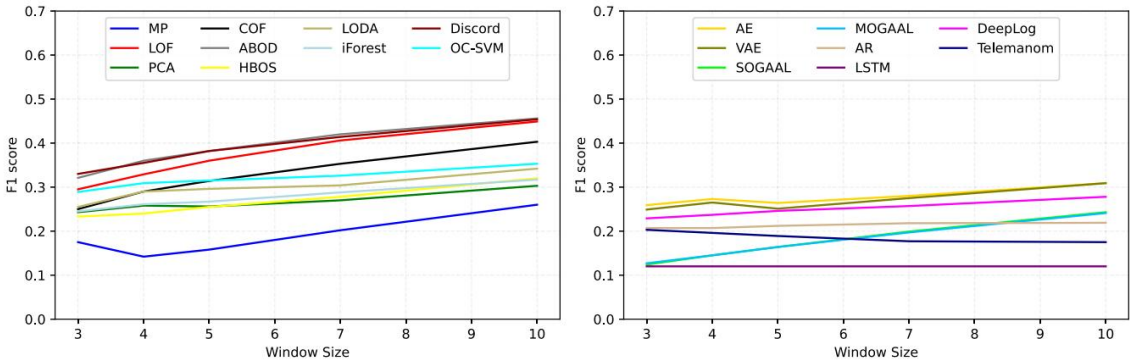


Figura 13. Variaciones de la puntuación F1 según el tamaño de la ventana en los métodos TAD basados en ventanas (basados en el conjunto de etiquetas).

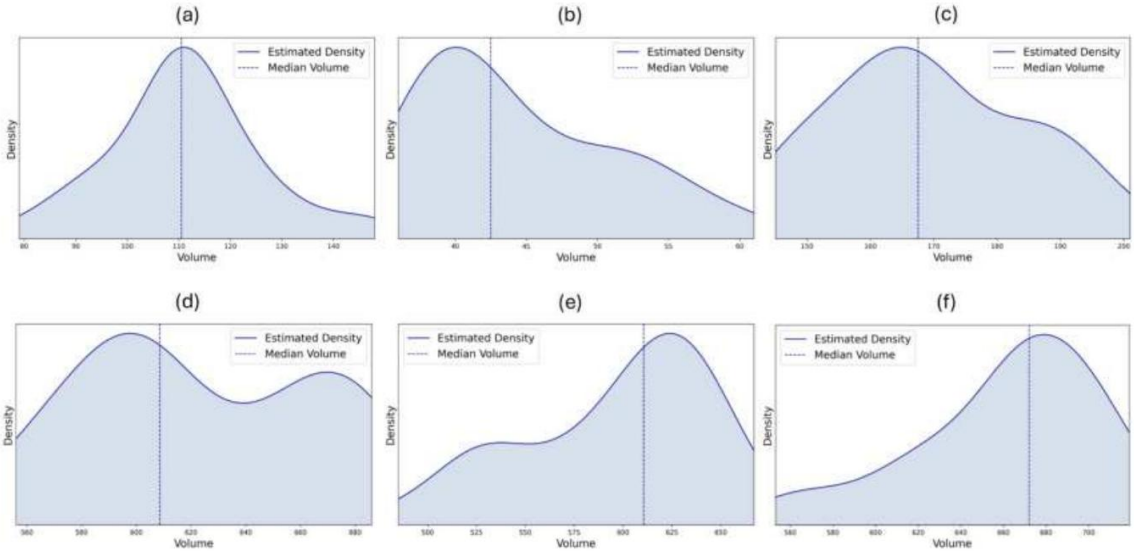


Figura 14. Gráficos de densidad de kernel de muestra que muestran la distribución de los datos de volumen de tráfico en diferentes intervalos de tiempo en un día específico de la semana en una ubicación específica.

en cada ubicación. Por lo tanto, cualquier muestra FP o FN puede atribuirse a inconsistencias en los estándares del etiquetador durante el proceso de etiquetado, como también lo demuestran los ejemplos mostrados en la Fig. 16.

Cabe destacar que las anomalías etiquetadas en el conjunto de datos AnoLT están diseñadas para servir como etiquetas representativas para un nivel de análisis completamente detallado. Si-TDD ha demostrado una superioridad significativa sobre los métodos de referencia al generar puntuaciones de anomalía que se alinean estrechamente con los datos etiquetados. Se pueden producir etiquetas de anomalía con distintos niveles de conservadurismo ajustando los umbrales aplicados en el último paso. Al aplicar umbrales para la detección de anomalías con Si-TDD, es importante tener en cuenta la compensación entre la detección temprana de anomalías de subsecuencias largas y la identificación de desviaciones puntuales extremadamente finas . Priorizar la detección temprana puede llevar a la identificación de anomalías puntuales menores que pueden tener una aplicabilidad limitada en algunas tareas posteriores. Esto se debe a que cualquier punto anómalo sutil podría indicar el inicio de una anomalía de subsecuencia larga. Sin embargo, dichos puntos pueden volver rápidamente al rango normal y representar simplemente una desviación menor con menor relevancia práctica.

Dada la capacidad de Si-TDD para asignar puntuaciones de anomalías continuas a muestras de datos, el proceso de generación de etiquetas de anomalías finales para ubicaciones individuales en una red extensa también puede optimizarse mediante la automatización guiada. Un enfoque práctico consiste en visualizar un único perfil de datos representativo junto con sus patrones históricos similares para cada ubicación. En lugar de requerir que el usuario etiquete todas las anomalías, como se ha descrito, el sistema puede solicitarle que seleccione o inserte un único punto que considere representativo del límite entre el comportamiento normal y el anómalo para un intervalo de tiempo específico. La puntuación de este punto límite puede servir como referencia para esa ubicación, y todos los puntos con puntuaciones más altas se etiquetan automáticamente como anomalías. Además, se pueden utilizar otras técnicas, como el método del punto de inflexión (Yu et al., 2019) , para determinar puntos de inflexión naturales en la distribución de puntuaciones de anomalías orde

La sensibilidad del rendimiento de Si-TDD a su único hiperparámetro, , así como a diferentes tamaños de datos de referencia, se analiza y se muestra en las figuras 17 y 18. puede interpretarse como el número mínimo de observaciones necesarias para establecer un clúster normal dentro de los datos de cada intervalo de tiempo. En primer lugar, los resultados de la figura 17 indican que la variación en el rendimiento con diferentes valores de

Machine Translated by Google

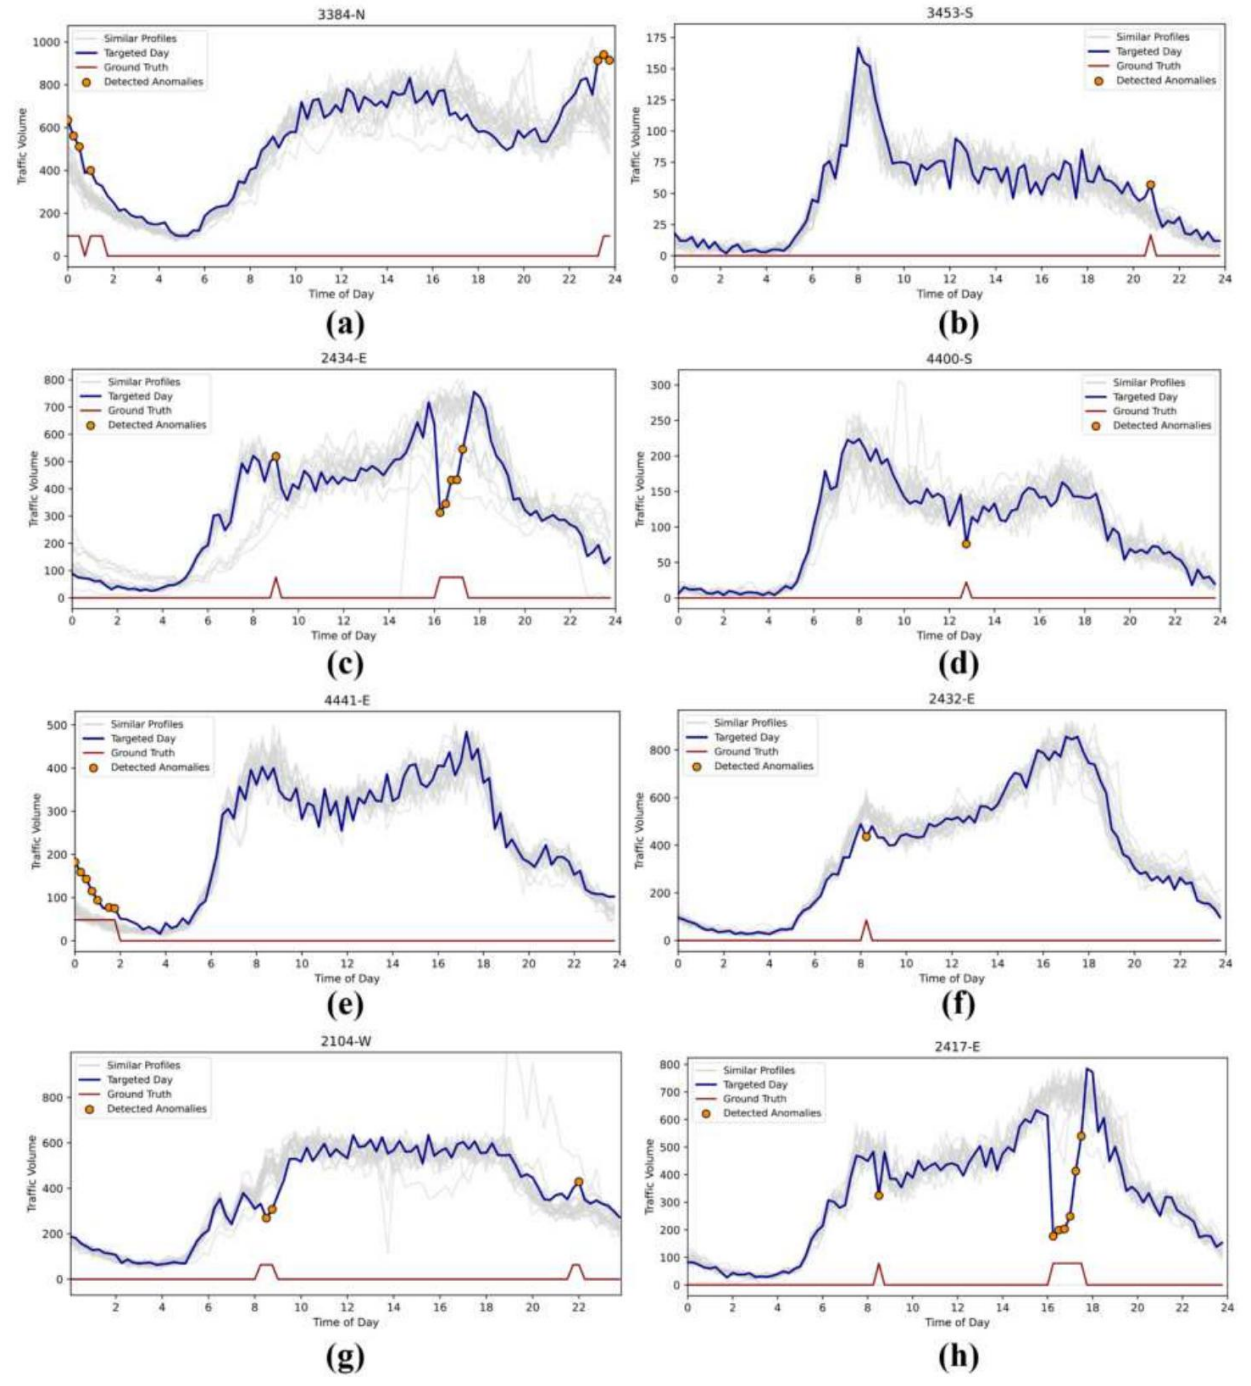


Figura 15. Visualización del rendimiento de detección de Si-TDD con el conjunto de datos AnoLT. La línea roja continua en la parte inferior de cada gráfico representa el conjunto de etiquetas de referencia .

no es sustancial. Por lo tanto, se puede concluir que Si-TDD no es muy sensible al valor de este hiperparámetro. Sin embargo, el mejor rendimiento se registra cuando se usa = 2 o = 3, y el rendimiento disminuye a medida que el valor de se aleja de estos valores. Tampoco se recomienda usar = 1 en este contexto, ya que se pueden encontrar dos anomalías similares muy cerca unas de otras y etiquetarlas como normales, un efecto cuyo impacto se registra experimentalmente en la Fig. 17. Además, la tendencia en la Fig. 18, obtenida al disminuir el tamaño de los datos de entrenamiento, muestra que Si-TDD mantiene un rendimiento razonable incluso con cantidades limitadas de datos históricos.

Para ser más específicos, utilizando el mismo valor de , una reducción del 60% en el tamaño de los datos de referencia (de cinco meses a dos meses) disminuyó la puntuación F1 de alrededor de 0,67 a 0,58, con un comportamiento casi similar en diferentes valores de . Sin embargo, esta tendencia no se mantuvo con un

Machine Translated by Google

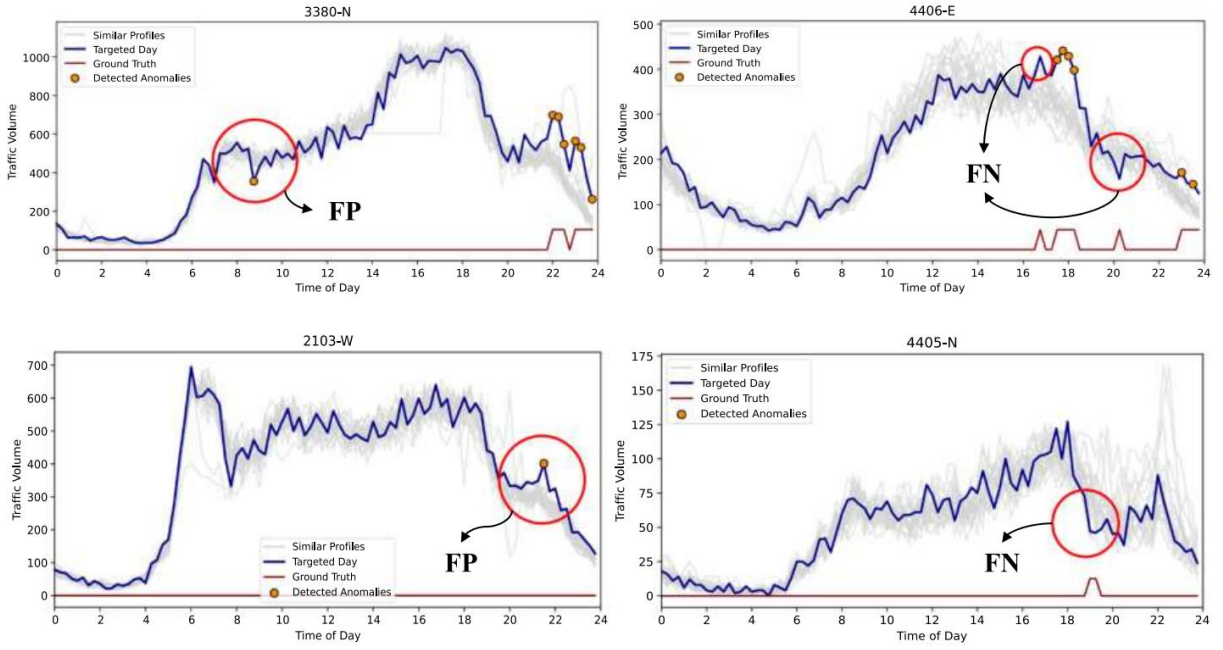


Figura 16. Visualización de los falsos positivos (FP) y falsos negativos (FN) seleccionados en el rendimiento de detección de Si-TDD con el conjunto de datos AnoLT. La línea roja continua representa las etiquetas de referencia.

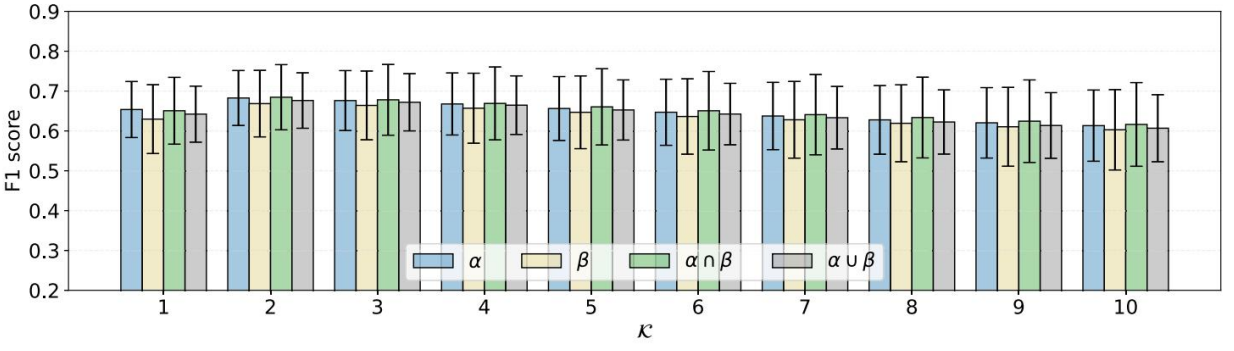


Figura 17. Análisis de sensibilidad del rendimiento con respecto a (-ésimo vecino más cercano a considerar), el único hiperparámetro en Si-TDD. Las barras de error indican la desviación estándar.

mes de datos de referencia, mostrando una caída más pronunciada y mayor sensibilidad a . La tendencia decreciente principal puede atribuirse en gran medida a cambios en el límite que separa los datos normales y anormales a medida que se reduce el tamaño de los datos. Como varias anomalías etiquetadas en AnoLT son sutiles, se espera cierto nivel de disminución del rendimiento cuando se utilizan conjuntos de datos de referencia más pequeños, y volver a etiquetar las anomalías de verdad fundamental basándose en la nueva referencia puede recuperar la pérdida de rendimiento. No obstante, los resultados demuestran que una gran parte de las anomalías se siguen detectando en diferentes tamaños de datos de referencia.

Basándonos en los resultados de estas figuras y considerando el concepto subyacente de Si-TDD, se recomienda usar = 3, siempre que se disponga de una cantidad adecuada de datos históricos, como tres o más meses. Aunque = 2 ofreció un rendimiento competitivo en nuestros experimentos (incluso con un mes de datos), = 3 es una opción más segura cuando se dispone de más datos históricos. Esto se debe a que ocasionalmente pueden aparecer dos anomalías similares en los datos de entrenamiento en el mismo paso de tiempo. Si también se produce una nueva anomalía similar a estas dos, lo cual es una situación poco frecuente, usar = 2 puede provocar que el método la clasifique incorrectamente como normal, mientras que = 3 ayuda a evitar este problema. El impacto de este problema para = 1 comenzó a hacerse evidente con cinco meses de datos (Fig. 18), a pesar de que = 1 parecía competitivo cuando se utilizaban cuatro meses de datos o menos. Por lo tanto, un fenómeno similar también puede ocurrir para = 2 cuando se consideran mayores cantidades de datos históricos o cuando el método se aplica bajo nuevas condiciones de tráfico. Con = 3, se requiere la presencia de tres muestras vecinas, en lugar de dos, para establecer una región normal dentro de los datos. Sin embargo, con tamaños de datos limitados de un mes, se demuestra que = 2 proporciona un mejor rendimiento, pero cabe señalar que con dicho tamaño de datos, la variación completa del rango normal no se captura adecuadamente.

Machine Translated by Google

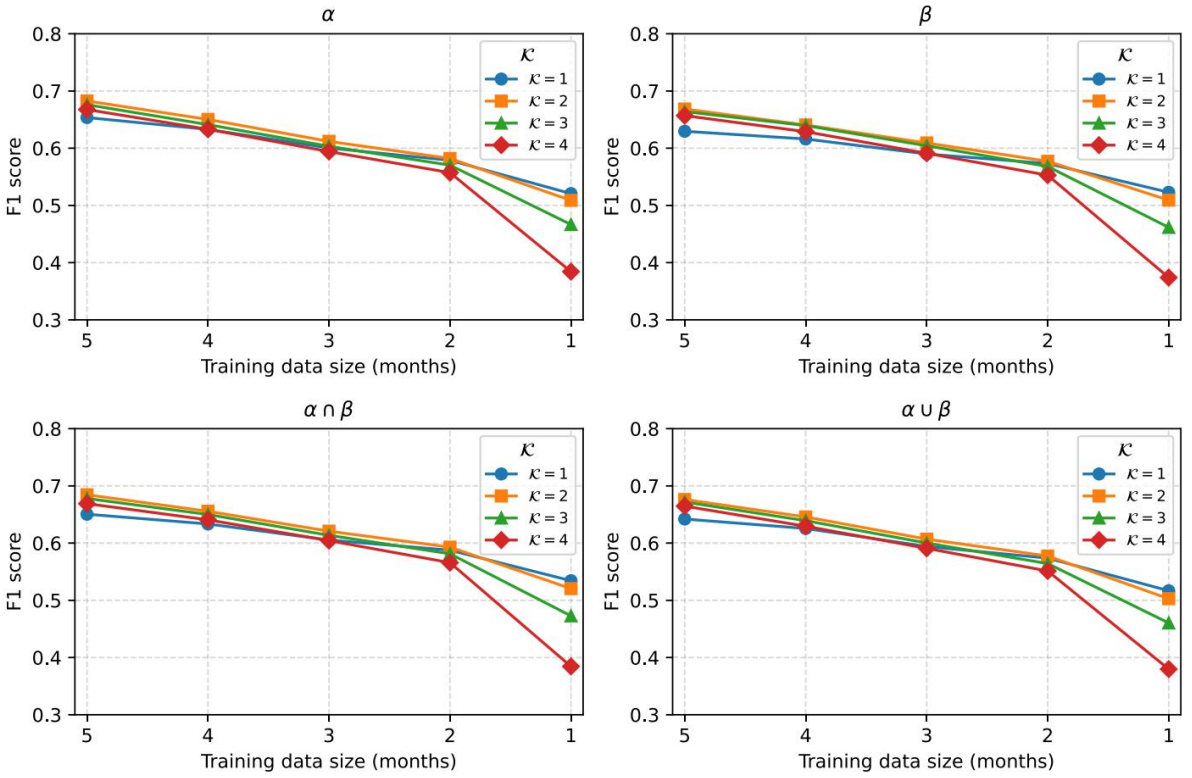


Fig. 18. Análisis de sensibilidad del rendimiento de Si-TDD con respecto al tamaño de los datos de referencia (entrenamiento) para diferentes valores de bajo conjuntos de etiquetas AnoLT.

5. Resumen y conclusión

En este artículo, investigamos la aplicabilidad de los métodos de detección de anomalías en series temporales (TAD o TSAD) de última generación a datos reales de volumen de tráfico. En primer lugar, se destaca la importancia de definir claramente las anomalías y utilizar conjuntos de datos de alta calidad en TAD, resaltando cómo esto ha renovado recientemente el interés en los métodos clásicos frente a las alternativas más recientes. Posteriormente, argumentamos que estos aspectos cruciales permanecen en gran medida inexplorados en el contexto de los datos de tráfico y transporte, sin que se hayan extraído conclusiones claras. Para abordar esta brecha, utilizamos una taxonomía reciente de anomalías en series temporales para detallar los tipos de anomalías más probables en los datos de volumen de tráfico e identificamos los puntos y las subsecuencias (shapelets) como las principales categorías que requieren atención. A partir de estos hallazgos, diseñamos una plataforma de monitorización de datos de volumen de tráfico para inspeccionar visualmente y etiquetar interactivamente las anomalías en conjuntos de datos reales. Inspirándonos en las discordancias de series temporales —un enfoque de vanguardia en aplicaciones TAD— proponemos un método personalizado y ligero llamado Si-TDD (Step-isolated Traffic Discords Discovery), diseñado específicamente para detectar anomalías en datos de volumen de tráfico. Como parte de este trabajo, también presentamos AnoLT (Anomaly Labeled Traffic), un conjunto de datos de código abierto que comprende datos de volumen de tráfico vial etiquetados con anomalías, recopilados en 147 ubicaciones en dos redes urbanas de Melbourne, Australia. Estudios comparativos con más de 20 métodos TAD de vanguardia con el conjunto de datos AnoLT muestran que Si-TDD supera significativamente a las soluciones existentes, logrando una puntuación F1 del 67 % para la detección de anomalías de volumen de tráfico con granularidad fina.

Con base en la discusión y los resultados, los siguientes puntos pueden enumerarse como los hallazgos clave de este trabajo:

1. Los conjuntos de datos de tráfico vial con etiquetas de anomalías existentes suelen basarse en incidentes reportados o registros públicos. Sostenemos que las anomalías van más allá de estos eventos y que depender únicamente de dicha información como etiquetas de referencia puede no reflejar la totalidad de las anomalías. Por lo tanto, es necesario explorar perspectivas alternativas sobre el etiquetado de datos reales.
2. El desarrollo de soluciones eficaces para la detección de anomalías requiere una comprensión clara de las anomalías objetivo y sus características únicas. Esta claridad es crucial para lograr resultados exitosos en las aplicaciones de detección de anomalías, como se demuestra en este artículo.
3. El conjunto de datos AnoLT proporciona una base más completa y detallada para evaluar soluciones de detección mediante datos de volumen de tráfico. Combina etiquetas de anomalías precisas con observaciones de volumen reales, lo que mejora su fiabilidad y utilidad en este ámbito.
4. Aunque los métodos TAD clásicos muestran una eficacia limitada en su forma original cuando se aplican a datos de tráfico, este estudio demuestra... estrategias que, con la adaptación al contexto, pueden perfeccionarse hasta convertirse en soluciones altamente competitivas y fiables.

Machine Translated by Google

5. El método Si-TDD propuesto (implementación paso a paso del descubrimiento de discrepancias en datos de series temporales de volumen) se establece como una solución de vanguardia para la detección de anomalías en el volumen de tráfico. Si-TDD demostró capacidades de detección robustas e intuitivas, superando significativamente los métodos de referencia TAD existentes en la literatura.
6. De acuerdo con estudios comparativos recientes, los métodos clásicos siguen siendo viables y pueden lograr un rendimiento de vanguardia en la detección de anomalías en el volumen de tráfico. Para futuras soluciones, se recomienda encarecidamente analizar explícitamente las ventajas que ofrecen frente a estos enfoques bien establecidos, intuitivos y sencillos.

En consonancia con trabajos previos y evidencia empírica, este estudio se basa en la perspectiva de que las anomalías en los datos de tráfico son aquellos segmentos de datos que se desvían considerablemente de la variación típica observada en los patrones de tráfico históricos disponibles. En trabajos futuros se podría investigar si ciertas anomalías están integradas en la variación normal del tráfico, lo que dificulta su detección visual o su distinción algorítmica dentro del marco actual. Además, también es valioso explorar hasta qué punto los cambios subyacentes en los patrones de datos a lo largo del tiempo (por ejemplo, la deriva conceptual) pueden afectar el rendimiento de la detección de anomalías en la práctica, y si las actualizaciones periódicas de los datos de entrenamiento pueden abordar adecuadamente este problema. De ser así, identificar la configuración de parámetros adecuada, como la frecuencia de actualización o el tamaño de los datos base, se convertiría en otra área de investigación relevante. Otra posible línea de investigación podría desarrollarse a partir de los hallazgos de este estudio explorando soluciones para la calibración de umbrales única en toda una red. Este enfoque tendría como objetivo abordar la variabilidad de escala observada en diferentes ubicaciones, reduciendo al mismo tiempo la necesidad de ajustes específicos para cada ubicación.

Si bien la literatura existente a menudo se basa en fuentes externas, como informes de incidentes o conocimientos previos, para generar etiquetas binarias, los hallazgos de este artículo sugieren que se puede derivar un espacio de búsqueda de umbral efectivo directamente de cada serie temporal individual.
Una investigación más profunda podría explorar si las estrategias de umbralización dinámica pueden generalizar el nivel de rigor calibrado para una ubicación a otras en toda la red.

Declaración de contribución de autoría CRediT

Iman Taheri Sarteshnizi: Redacción – borrador original, Visualización, Validación, Software, Metodología, Investigación, Análisis formal, Curación de datos, Conceptualización; Majid Sarvi: Redacción – revisión y edición, Validación, Supervisión, Recursos, Metodología, Investigación, Conceptualización; Saeed Asadi Bagloee: Redacción – revisión y edición, Supervisión, Software, Metodología, Investigación, Conceptualización; Neema Nassir: Redacción – revisión y edición, Validación, Supervisión, Metodología, Conceptualización.

Disponibilidad de datos

Se proporciona un enlace a los datos.

Referencias

Aggarwal, CC, 2016. Introducción al análisis de valores atípicos. Cham: Springer International Publishing. 1–34.

Ahmad, S., Lavin, A., Purdy, S., Agha, Z., 2017. Detección de anomalías en tiempo real sin supervisión para datos en flujo continuo. Neurocomputing 262, 134–147.

Ahmed, CM, Palleti, VR, Mathur, AP, 2017. Wadi: un banco de pruebas de distribución de agua para la investigación en el diseño de sistemas ciberfísicos seguros. En: Actas de la Tercer Taller Internacional sobre Sistemas Ciberfísicos para Redes Inteligentes de Agua, págs. 25-28.

Akouemo, HN, Povinelli, RJ, 2014. Detección e imputación de valores atípicos en series temporales. En: 2014 IEEE PES General Meeting | Conference & Exposition. IEEE, pp. 1–5.

Angiulli, F., Pizzuti, C., 2002. Detección rápida de valores atípicos en espacios de alta dimensión. En: Conferencia Europea sobre Principios de Minería de Datos y Descubrimiento de Conocimiento. Springer, págs. 15–27.

Bachlin, M., Plotnik, M., Roggen, D., Maidan, I., Hausdorff, JM, Giladi, N., Troster, G., 2009. Asistente portátil para pacientes con enfermedad de Parkinson con congelación de Síntoma de la marcha. IEEE Trans. Inf. Technol. Biomed. 14 (2), 436–446.

Bahdanau, D., Cho, K., Bengio, Y., 2014. Traducción automática neuronal mediante el aprendizaje conjunto de alineación y traducción. Preimpresión de arXiv arXiv:1409.0473.

Balke, K., Dudek, CL, Mountain, CE, 1996. Uso de tiempos de viaje medidos con sonda para detectar incidentes importantes en autopistas en Houston, Texas. Transp. Res. Rec. 1554 (1), 213–220.

Basu, S., Meckesheimer, M., 2007. Detección automática de valores atípicos en series temporales: una aplicación a datos de sensores. Knowl. Inf. Syst. 11, 137–154.

Blázquez-García, A., Conde, A., Mori, U., Lozano, JA, 2021. Una revisión sobre la detección de valores atípicos/anomalías en datos de series temporales. ACM Comput. Surv. 54 (3), 1–33.

Bontemps, L., Cao, VL, McDermott, J., Le-Khac, N.-A., 2016. Detección colectiva de anomalías basada en redes neuronales recurrentes de memoria a corto y largo plazo. En: Future Data and Security Engineering: Third International Conference, FDSE 2016, Can Tho City, Vietnam, 23-25 de noviembre de 2016, Actas 3. Springer, pp. 141–152.

Breunig, MM, Kriegel, H.-P., Ng, RT, Sander, J., 2000. LOF: identificación de valores atípicos locales basados en la densidad. En: Actas de la Conferencia Internacional ACM SIGMOD de 2000 sobre Gestión de Datos, págs. 93–104.

Chakraborty, P., Hegde, C., Sharma, A., 2019. Detección de incidentes de tráfico paralelizable basada en datos utilizando umbrales robustos espacio-temporales sin ruido. Transp. Res. Parte C Tecnologías Emergentes 105, 81–99.

Chen, J., Li, W., Lau, A., Cao, J., Wang, K., 2010. Limpieza automatizada de datos de curvas de carga en sistemas de energía. IEEE Trans. Smart Grid 1 (2), 213–221.

Chiu, Y.-C., Bottom, J., Mahut, M., Paz, A., Balakrishna, R., Waller, S., Hicks, J., 2011. Asignación dinámica de tráfico: una introducción (Transportation Research Circular) e-c153). Junta de Investigación del Transporte.

Coursey, A., Ji, J., Quinones Grueiro, M., Barbour, W., Zhang, Y., Derr, T., Biswas, G., Work, D., 2024. FT-AED: conjunto de datos de referencia para anomalías tempranas del tráfico en autopistas Detección de eventos. Avances en Sistemas de Procesamiento de Información Neuronal 37, 15526–15549.

Dakic, I., Stevanovic, A., 2018. Sobre el desarrollo de diagramas fundamentales arteriales basados en medidas de densidad sustitutas de sistemas de control de tráfico adaptativos que utilizan Detección de líneas de parada. Transp. Res. Part C Emerging Technol. 94, 133–150.

Deng, L., Lian, D., Huang, Z., Chen, E., 2022. Redes neuronales convolucionales adversarias gráficas para la detección de anomalías espaciotemporales. IEEE Trans. Neural Netw. Learn. Syst. 33 (6), 2416–2428.

Doraiswamy, H., Ferreira, N., Damoulas, T., Freire, J., Silva, CT, 2014. Uso del análisis topológico para apoyar la exploración guiada por eventos en datos urbanos. IEEE Trans. Vis. Comput. Graph. 20 (12), 2634–2643.

Du, M., Li, F., Zheng, G., Srikumar, V., 2017. Deeplog: detección y diagnóstico de anomalías a partir de registros del sistema mediante aprendizaje profundo. En: Actas de la Conferencia ACM SIGSAC de 2017 sobre Seguridad Informática y de las Comunicaciones, págs. 1285–1298.

Duan, H., Wu, H., Qian, S., 2024. Conozca los incidentes de tráfico no reportados en tiempo real: un marco de aprendizaje profundo para la detección temprana de anomalías en el tráfico. Preimpresión de arXiv arXiv:2412.10892.

Estimator, D., 1999. Un algoritmo rápido para la covarianza mínima. Technometrics 41 (3), 212.

Machine Translated by Google

Feremans, L., Vercruyssen, V., Cule, B., Meert, W., Goethals, B., 2020. Detección de anomalías basada en patrones en series temporales de tipo mixto. En: Machine Learning and Knowledge Discovery in Databases: European Conference, ECML PKDD 2019, Würzburg, Alemania, 16-20 de septiembre de 2019, Actas, Parte I. Springer, pp. 240-256.
Fox, AJ, 1972. Valores atípicos en series temporales. JR Stat. Soc. Ser. B Stat. Methodol. 34 (3), 350–363.
Geiger, A., Liu, D., Alnegheimish, S., Cuesta-Infante, A., Veeramachaneni, K., 2020. En: Conferencia Internacional IEEE de 2020 sobre Big Data (Big Data), págs. 33–43.
Goh, J., Adepu, S., Junejo, KN, Mathur, A., 2017. Un conjunto de datos para apoyar la investigación en el diseño de sistemas seguros de tratamiento de agua. En: Infraestructuras de información crítica. Seguridad: 11.ª Conferencia Internacional, CRITIS 2016, París, Francia, 10-12 de octubre de 2016, Artículos seleccionados revisados 11. Springer, págs. 88-99.
Goldstein, M., Dengel, A., 2012. Puntuación de valores atípicos basada en histogramas (HBOS): un algoritmo rápido de detección de anomalías no supervisado. KI-2012: póster y demostración, sección 1, 59-63.
Grigorev, A., Mihai¸t ˘ a,˘ A.-S., Saleh, K., Chen, F., 2023. Detección automática de accidentes, segmentación y predicción de duración mediante aprendizaje automático. IEEE Trans. Intell. Sistema de Transacciones 25 (2), 1547–1568.
Hampel, FR, 1974. La curva de influencia y su papel en la estimación robusta. J. Am. Stat. Assoc. 69 (346), 383–393.
He, D., Kim, J., Shi, H., Ruan, B., 2023. Detección autónoma de anomalías en series temporales de flujo de tráfico con aprendizaje por refuerzo. Transp. Res. Part C Emerging Technol. 150, 104089.
Hogue, J., 2019. Volumen de tráfico interestatal metropolitano. Repositorio de aprendizaje automático de la UCI. DOI: https://doi.org/10.24432/C5X60B.
Hossain, S., Calloway, C., Lippa, D., Niederhut, D., Shupe, D., 2019. Visualización de datos bioinformáticos con dash bio. En: SciPy, pp. 126–133.
Hundman, K., Constantinou, V., Laporte, C., Colwell, I., Soderstrom, T., 2018. Detección de anomalías en naves espaciales mediante LSTM y umbralización dinámica no paramétrica. En: Actas de la 24ª Conferencia Internacional ACM SIGKDD sobre Descubrimiento de Conocimiento y Minería de Datos, págs. 387–395.
Hutchins, J., 2006. CalIt2 building people counts. UCI Machine Learning Repository. DOI: https://doi.org/10.24432/C5NG78.
Hwang, W.-S., Yun, J.-H., Kim, J., Min, BG, 2022. ¿Sabe usted que las métricas de precisión existentes sobreestiman las detecciones de anomalías en series temporales? En: Actas de la 37.ª Simposio ACM/SIGAPP sobre Computación Aplicada, págs. 403–412.
Ihler, A., Hutchins, J., Smyth, P., 2006. Detección adaptativa de eventos con procesos de Poisson variables en el tiempo. En: Actas de la 12.ª Conferencia Internacional ACM SIGKDD. sobre Descubrimiento de Conocimiento y Minería de Datos, págs. 207–216.
Kalair, K., Connaughton, C., 2021. Detección y clasificación de anomalías en datos de flujo de tráfico a partir de fluctuaciones en la relación flujo-densidad. Transp. Res. Part C Tecnologías Emergentes 127, 103178.
Kazemeini, A., Taheri, I., Samimi, A., 2022. Un algoritmo basado en GPS para la detección de frenado y giro. Int. J. Intell. Transp. Syst. Res. 20 (2), 433–445.
Kim, S., Choi, K., Choi, H.-S., Lee, B., Yoon, S., 2022. Hacia una evaluación rigurosa de la detección de anomalías en series temporales. En: Actas de la Conferencia AAAI sobre Inteligencia Artificial, págs. 7194–7201.
Kriegel, H.-P., Schubert, M., Zimek, A., 2008. Detección de valores atípicos basada en ángulos en datos de alta dimensión. En: Actas de la 14.ª Conferencia Internacional ACM SIGKDD sobre Descubrimiento de Conocimiento y Minería de Datos, págs. 444–452.
Lai, K.-H. , Zha, D., Wang, G., Xu, J., Zhao, Y., Kumar, D., Chen, Y., Zumkhawaka, P., Wan, M., Martinez, D., et al., 2021a. Tods: un valor atípico de series temporales automatizadas sistema de detección. En: Actas de la Conferencia AAAI sobre Inteligencia Artificial, págs. 16060–16062.
Lai, K.-H., Zha, D., Xu, J., Zhao, Y., Wang, G., Hu, X., 2021b. Revisión de la detección de valores atípicos en series temporales: definiciones y puntos de referencia. En: Trigésimo quinta Conferencia sobre Neurociencia Sistemas de procesamiento de información: Conjuntos de datos y puntos de referencia (Ronda 1), págs. 1–13.
Laptev, N., Amizadeh, S., Billawala, Y., 2015. Conjunto de datos de detección de anomalías etiquetados S5-A, versión 1.0 (16m) https://webscope.sandbox.yahoo.com/catalog.php..
Law, SM, 2019. STUMPY: una biblioteca de Python potente y escalable para la minería de datos de series temporales. J. Open Source Softw. 4 (39), 1504.
Li, Y., Zha, D., Venugopal, P., Zou, N., Hu, X., 2020a. Pyodds: un sistema de detección de valores atípicos de extremo a extremo con aprendizaje automático automatizado. En: Companion Proceedings de la Conferencia Web 2020, págs. 153–157.
Li, Z., Zhao, Y., Botta, N., Ionescu, C., Hu, X., 2020b. Copod: detección de valores atípicos basada en cópulas. En: 2020 IEEE International Conference on Data Mining (ICDM). IEEE, págs. 1118–1123.
Lin, J., Keogh, E., Fu, A., Van Herle, H., 2005. Aproximaciones a la magia: encontrar series temporales médicas inusuales. En: 18º Simposio IEEE sobre Medicina Basada en Computadoras Sistemas (CBMS'05). IEEE, págs. 329–334.
Liu, FT, Ting, KM, Zhou, Z.-H., 2008. Bosque de aislamiento. En: Octava Conferencia Internacional IEEE de Minería de Datos de 2008. IEEE, págs. 413–422.
Liu, Q., Paparrizos, J., 2024. El elefante en la habitación: hacia un punto de referencia fiable para la detección de anomalías en series temporales. En: The Thirty-eight Conference on Neural Information Processing Systems Datasets and Benchmarks Track, pp. 1–10.
Liu, Y., Li, Z., Zhou, C., Jiang, Y., Sun, J., Wang, M., He, X., 2019. Aprendizaje activo generativo adversarial para la detección no supervisada de valores atípicos. IEEE Trans. Knowl. Data Inglés 32 (8), 1517–1528.
Mejri, N., Lopez-Fuentes, L., Roy, K., Chernakov, P., Ghorbel, E., Aouada, D., 2024. Detección de anomalías no supervisada en series temporales: una evaluación y análisis exhaustivos. de métodos de vanguardia. Expert Syst. Appl. ,256 124922.
Moody, GB, Mark, RG, 2001. El impacto de la base de datos de arritmias MIT-BIH. IEEE Eng. Med. Biol. Mag. 20 (3), 45–50.
Munir, M., Siddiqui, SA, Dengel, A., Ahmed, S., 2018. Deepant: un enfoque de aprendizaje profundo para la detección no supervisada de anomalías en series temporales. IEEE Access 7, 1991–2005.
Nakamura, T., Mercer, R., Imamura, M., Keogh, E., 2023. Merlin++: descubrimiento sin parámetros de anomalías en series temporales. Data Min. Knowl. Discov. ,37 1–40.
Pang, G., Shen, C., Cao, L., Hengel, AVD, 2021. Aprendizaje profundo para la detección de anomalías: una revisión. ACM Comput. Surv. 54 (2), 1–38.
Paparrizos, J., Kang, Y., Boniol, P., Tsay, RS, Palpanas, T., Franklin, MJ, 2022. TSB-UAD: un conjunto de pruebas de referencia integral para la detección de anomalías en series temporales univariadas. Proc. VLDB Endow. 15 (8), 1697–1711.
Parsa, AB, Taghipour, H., Derrible, S., Mohammadian, AK, 2019. Detección de accidentes en tiempo real: cómo lidiar con datos desequilibrados. Accid. Anal. Prev. 129, 202–210.
Pearson, RK, 2005. Minería de datos imperfectos: cómo lidiar con la contaminación y los registros incompletos. SIAM.
Persaud, BN, Hall, FL, 1989. Teoría de catástrofes y patrones en datos de tráfico de autopistas de 30 segundos: implicaciones para la detección de incidentes. Transp. Res. Part A Gen. 23 (2), 103–113.
Pevny, T., 2016. Loda: detector ligero en línea de anomalías. Mach. Learn. 102, 275–304.
Qi, J., Zhao, Z., Tanin, E., Cui, T., Nassir, N., Sarvi, M., 2022. Una red neuronal convolucional multipath con grafo y atención para la predicción del tráfico. IEEE Trans. Knowl. Data Inglés 35 (7), 6548–6560.
Reddy, A., Ordway-West, M., Lee, M., Dugan, M., Whitney, J., Kahana, R., Ford, B., Muedsam, J., Henslee, A., Rao, M., 2017. Uso de modelos de mezcla gaussiana para detectar valores atípicos en el tráfico de red univariado estacional. En: Talleres de seguridad y privacidad de la IEEE de 2017 (SPW). IEEE, págs. 229-234.
Ren, H., Xu, B., Wang, Y., Yi, C., Huang, C., Kou, X., Xing, T., Yang, M., Tong, J., Zhang, Q., 2019. Servicio de detección de anomalías en series temporales en Microsoft. En: Actas de la 25ª Conferencia Internacional ACM SIGKDD sobre Descubrimiento de Conocimiento y Minería de Datos, págs. 3009–3017.
Ren, Z., Li, X., Peng, J., Chen, K., Tan, Q., Wu, X., Shi, C., 2024. Autoencoder gráfico con redes convolucionales temporales espejo para la detección de anomalías de tráfico. Sci. Rep. 14 (1), 1247.
Roggen, D., Calatroni, A., Rossi, M., Holleczek, T., Förster, K., Tröster, G., Lukowicz, P., Bannach, D., Pirkl, G., Ferscha, A., et al., 2010. Recopilación de conjuntos de datos de actividad complejos en entornos de sensores en red altamente ricos. En: Séptima Conferencia Internacional sobre Sistemas de Detección en Red (INSS) de 2010. IEEE, págs. 233–240.
Rousseeuw, PJ, Leroy, AM, 2005. Regresión robusta y detección de valores atípicos. John Wiley & Sons.
Saal, FE, Downey, RG, Lahey, MA, 1980. Calificando las calificaciones: evaluando la calidad psicométrica de los datos de calificación. Psychol. Bull. 88 (2), 413.
Sarteshnizi, IT, Bagloee, SA, Sarvi, M., Nassir, N., 2023. Detección de anomalías de tráfico: explotación del posicionamiento temporal de muestras de densidad de flujo. IEEE Trans. Intell. Sistema de Transformación 25 (5), 4166–4180
Sarteshnizi, IT, Tavakkoli Khomeini, F., Khedri, B., Samimi, A., 2022. Análisis de sensibilidad de la clasificación de eventos de conducción utilizando datos de movimiento de teléfonos inteligentes: caso de tipo de clasificador, agrupamiento de sensores y tasa de adquisición de datos. J. Intell. Transp. Syst. ,25 (4) 476–493.
Schmidl, S., Wenig, P., Papenbrock, T., 2022. Detección de anomalías en series temporales: una evaluación exhaustiva. Proc. VLDB Endow. 15 (9), 1779–1797.
Schölkopf, B., Platt, JC, Shawe-Taylor, J., Smola, AJ, Williamson, RC, 2001. Estimación del soporte de una distribución de alta dimensión. Neural Comput. 13 (7), 1443–1471.
Shumway, RH, Stoffer, DS, Stoffer, DS, 2000. Análisis de series temporales y sus aplicaciones. Vol. 3. Springer.

Machine Translated by Google

Shyu, M.-L., Chen, S.-C., Sarinnapakorn, K., Chang, L., 2003. Un nuevo esquema de detección de anomalías basado en un clasificador de componentes principales. En: Actas del IEEE Taller sobre Fundamentos y Nuevas Direcciones de la Minería de Datos. IEEE Press, págs. 172–179.

Su, Y., Zhao, Y., Niu, C., Liu, R., Sun, W., Pei, D., 2019. Detección robusta de anomalías para series temporales multivariadas mediante redes neuronales recurrentes estocásticas. En: Actas de la 25.ª Conferencia Internacional ACM SIGKDD sobre Descubrimiento de Conocimiento y Minería de Datos, págs. 2828–2837.

Tafazoli, S., Keogh, E., 2023. Perfil matricial XXVIII: descubrimiento de anomalías en series temporales multidimensionales con detección de anomalías k de n. En: Actas de la Conferencia Internacional SIAM de 2023 sobre Minería de Datos (SDM). SIAM, págs. 685–693.

Taheri Sarteshnizi, I., Sarvi, M., Bagloee, SA, Nassir, N., 2023. Minería de patrones temporales de datos de volumen de tráfico urbano: un método de agrupación híbrida por pares. Trans-Portmetrica B: Transport Dyn. 11 (1), 2185496.

Tang, J., Chen, Z., Fu, AW-C., Cheung, DW, 2002. Mejora de la eficacia de la detección de valores atípicos para patrones de baja densidad. En: Avances en el descubrimiento del conocimiento y Minería de datos: 6.ª Conferencia Asia-Pacífico, PAKDD 2002, Taipéi, Taiwán, 6-8 de mayo de 2002. Actas 6. Springer, págs. 535-548.

Tian, Z., Zhuo, M., Liu, L., Chen, J., Zhou, S., 2023. Detección de anomalías mediante información espacial y temporal en series temporales multivariadas. Sci. Rep. 13 (1), 4400.

Ting, C.-M., Ombao, H., Samdin, SB, Salleh, S.-H., 2017. Estimación de la conectividad efectiva variable en el tiempo en datos de fMRI de alta dimensión utilizando el factor de cambio de régimen. modelos. Preimpresión de arXiv arXiv:1701.06754.

Touvron, H., Lavril, T., Izacard, G., Martinet, X., Lachaux, M.-A., Lacroix, T., Rozière, B., Goyal, N., Hambro, E., Azhar, F., Rodriguez, A., Joulin, A., Grave, E., Lample, G., 2023. Llama: modelos de lenguaje de base abiertos y eficientes. 2302.13971. https://arxiv.org/abs/2302.13971.

Vallis, O., Hochenbaum, J., Kejariwal, A., 2014. Una nueva técnica para la detección de anomalías a largo plazo en la nube. En: 6.º Taller USENIX sobre temas candentes en la nube. Informática (HotCloud 14).

Wang, X., Sun, L., 2021. Diagnóstico de anomalías de tráfico espaciotemporales con autorregresión tensorial de bajo rango. IEEE Trans. Intell. Transp. Syst. 22 (12), 7904–7913.

Wu, R., Keogh, E., 2021. Los métodos de referencia actuales para la detección de anomalías en series temporales son defectuosos y crean la ilusión de progreso. IEEE Trans. Knowl. Data Eng. 35 (3) 2421–2429.

Yazdani, M., Sarvi, M., Bagloee, SA, Nassir, N., Price, J., Parineh, H., 2023. Luz inteligente para vehículos y peatones (IVPL): un enfoque de aprendizaje profundo por refuerzo para el control de señales de tráfico. Transp. Res. Part C Emerging Technol. 149, 103991.

Yeh, C.-CM, Der, A., Saini, US, Lai, V., Zheng, Y., Wang, J., Dai, X., Zhuang, Z., Fan, Y., Chen, H., Aboagye, PO, Wang, L., Zhang, W., Keogh, E., 2024. Matrix Perfil para la detección de anomalías en series temporales multidimensionales. 2409.09298. https://arxiv.org/abs/2409.09298.

Yu, G., Cai, Z., Wang, S., Chen, H., Liu, F., Liu, A., 2019. Detección de anomalías en línea no supervisada con adaptación de parámetros para cambios abruptos de KPI. IEEE Trans. Netw. Serv. Manage. 17 (3), 1294–1308.

Zamanzadeh Darban, Z., Webb, GI, Pan, S., Aggarwal, C., Salehi, M., 2024. Aprendizaje profundo para la detección de anomalías en series temporales: una revisión. ACM Comput. Surv. 57 (1), 1–42.

Zarei Yazd, M., Taheri Sarteshnizi, I., Samimi, A., Sarvi, M., 2022. Una estructura robusta de aprendizaje automático para el reconocimiento de eventos de conducción utilizando sensores de movimiento de teléfonos inteligentes. J. Intel. Transp. Sistema. 28 (1), 54–68.

Zhang, C., Song, D., Chen, Y., Feng, X., Lumezanu, C., Cheng, W., Ni, J., Zong, B., Chen, H., Chawla, NV, 2019a. Una red neuronal profunda para la detección de anomalías no supervisadas. Detección y diagnóstico en datos de series temporales multivariadas. En: Actas de la Conferencia AAAI sobre Inteligencia Artificial, págs. 1409–1416.

Zhang, H., Zheng, Y., Yu, Y., 2018. Detección de anomalías urbanas utilizando múltiples fuentes de datos espacio-temporales. Proc. ACM Interact. Mobile Wearable Ubiquitous Technol. 2 (1), 1–18.

Zhang, M., Li, T., Shi, H., Li, Y., Hui, P., 2019b. Un enfoque de descomposición para la detección de anomalías urbanas en datos espaciotemporales. En: 28.ª Reunión Conjunta Internacional Conferencia sobre Inteligencia Artificial (IJCAI 2019). Conferencias Conjuntas Internacionales sobre Inteligencia Artificial, págs. 6043–6049.

Zhao, Y., Nasrullah, Z., Li, Z., 2019. Pyod: una caja de herramientas de Python para la detección escalable de valores atípicos. Preimpresión de arXiv arXiv:1901.01588.