Machine Translated by Google

Detección de cierres de carreteras basada en la fusión de múltiples características

Shengcheng Cai
51195100041@stu.ecnu.edu.cn
Universidad Normal del Este de China, Shanghái, China

Tao Wu
52195100007@stu.ecnu.edu.cn
Universidad Normal del Este de China, Shanghái, China

Jiali Mao
jlmao@dase.ecnu.edu.cn
Universidad Normal del Este de China, Shanghái, China

Cheqing Jin
cqjin@dase.ecnu.edu.cn
Universidad Normal del Este de China, Shanghái, China

ABSTRACTO

La detección tardía o incompleta del cierre de carreteras influye considerablemente en la calidad del mapa digital. Las soluciones existentes que utilizan datos de trayectoria buscan identificar las carreteras cerradas según la drástica caída del flujo de tráfico. Sin embargo, en aplicaciones reales, estos métodos pueden confundir un atasco con un cierre y no detectar eventos como el cierre de un carril en una carretera de doble sentido o el cierre en el centro de la vía. Con el cierre de una carretera, se producen variaciones en el volumen de giros de las carreteras vecinas y un aumento en la frecuencia de giros en U en las carreteras cerradas, además de la drástica caída del flujo de tráfico. En este artículo, presentamos un marco de detección de cierres de carreteras de alta eficiencia basado en la fusión de múltiples características, denominado RCDM. Este marco consta de una parte de modelado de características de cierre de carreteras fuera de línea y una parte de identificación en línea. En la fase fuera de línea, primero dividimos la red vial en cuadrículas y luego extraemos las características de cierre de carreteras de las cuadrículas y de las carreteras a partir de datos históricos. En la fase en línea, basándonos en las predicciones de las características de cierre de carreteras, seleccionamos las posibles zonas de la cuadrícula cerrada en función de la caída del flujo de tráfico y, además, identificamos los tramos de carretera cerrados según las variaciones en el comportamiento de giro de las carreteras. Los exhaustivos resultados experimentales obtenidos con tres conjuntos de datos reales de Chengdu, Shanghái y Pekín validan que nuestro método ofrece una mayor precisión y eficiencia en la detección en comparación con los métodos existentes.

CONCEPTOS DE CCS

• Sistemas de información → Servicios basados en la ubicación.

PALABRAS CLAVE

cierre de carretera, flujo de tráfico, volumen de giros, cambio de sentido, cuadrícula

Formato de referencia ACM:

Shengcheng Cai, Tao Wu, Jiali Mao y Cheqing Jin. 2021. Detección de cierres de carreteras basada en la fusión de múltiples características. En la 29.ª Conferencia Internacional sobre Avances en Sistemas de Información Geográfica (SIGSPATIAL '21), noviembre.

Se concede permiso para realizar copias digitales o impresas de la totalidad o parte de esta obra para uso personal o en el aula, sin coste alguno, siempre que dichas copias no se realicen ni distribuyan con fines de lucro o ventaja comercial y que incluyan este aviso y la cita completa en la primera página. Los derechos de autor de los componentes de esta obra que pertenezcan a terceros ajenos a ACM deben respetarse. Se permite la elaboración de resúmenes con la debida atribución. Para cualquier otro tipo de copia, republicación, publicación en servidores o redistribución a listas de correo, se requiere autorización previa específica y/o el pago de una tarifa. Solicite los permisos a permissions@acm.org.

SIGSPATIAL '21, del 2 al 5 de noviembre de 2021, Pekín, China ©

2021 Association for Computing Machinery.

ACM ISBN 978-1-4503-8664-7/21/11. . . $15.00
https://doi.org/10.1145/3474717.3483975



(a) Cierre de la carretera en el centro de la carretera (b) Cierre de un lado de una carretera de doble sentido

Figura 1: Dos tipos especiales de cierres de carreteras

2–5, 2021, Pekín, China. ACM, Nueva York, NY, EE. UU., 11 páginas. https://doi.org/10.1145/3474717.3483975

1. INTRODUCCIÓN

Con el uso generalizado de equipos GPS, los residentes dependen cada vez más de diversas aplicaciones de navegación para sus desplazamientos diarios. Esto exige actualizaciones de mapas para garantizar su alta calidad. Como una de las principales causas de los cambios en la red vial, los cierres de carreteras son frecuentes debido a eventos como controles de tráfico temporales, maratones y obras viales, entre otros. La detección tardía o la falta de detección de cierres de carreteras no solo genera inconvenientes para los desplazamientos, sino que también ocasiona pérdidas económicas considerables a los usuarios. Por ejemplo, el 10 de octubre de 2019, el colapso de un puente en la Carretera Nacional 312, en la ciudad de Wuxi, provocó el cierre de la carretera que pasaba por debajo del puente y grandes atascos en las vías aledañas durante un largo período.[1]

Se recopila una enorme cantidad de trayectorias mediante diferentes tipos de dispositivos de posicionamiento, lo que nos brinda la oportunidad de actualizar el mapa. En los últimos años, las investigaciones existentes sobre la actualización de mapas se han centrado más en la detección de carreteras faltantes y menos en la detección de eventos de cierre de carreteras [1]. Debido a los desafíos derivados de los cambios dinámicos de la red vial, así como a la interacción entre las situaciones de tráfico de las carreteras adyacentes y la naturaleza de distribución asimétrica de los datos, solo se han realizado unas pocas investigaciones sobre el tema de la detección de cierres de carreteras [17, 21, 22, 31]. Los métodos mencionados identifican el cierre de la carretera en términos de la caída en el flujo de tráfico, pero que pueden llevar a la detección errónea de atascos de tráfico que tienen la misma propiedad. Además, no son adecuados para detectar el cierre de un lado de una carretera de doble sentido y el cierre que

1http://www.chinanews.com/sh/2019/10-10/8975525.shtml

Machine Translated by Google

El cierre se produjo en la parte central de la carretera. Como se ilustra en la Figura 1, ambos son casos de cierres de carreteras debido a obras. En la Figura 1(a), el cierre en la parte central obliga a los vehículos a dar la vuelta en U hacia la carretera original, lo que provoca un aumento en la frecuencia de giros en U. En la Figura 1(b), un lado de la carretera está completamente cerrado al tráfico, pero el otro carril puede circular con normalidad, lo que conlleva una reducción del volumen de giros en las carreteras adyacentes. Sin embargo, en ambos casos, el flujo de tráfico en las carreteras cerradas no se reduce a cero.

A la luz de las observaciones anteriores, presentamos un marco de detección de cierres de carreteras en dos fases basado en la fusión de múltiples características, denominado RCDM. En la fase de modelado de características de cierre de carreteras fuera de línea, dividimos la red vial en cuadrículas. Basándonos en el análisis de datos históricos, primero extraemos la fuerza de correlación de las situaciones de tráfico entre todas las carreteras. Luego obtenemos tres características importantes que se utilizarán para la detección en línea, que incluyen el flujo de tráfico de todas las cuadrículas, el volumen de giros de las carreteras adyacentes y la frecuencia de giros en U en cada período de tiempo. En la fase en línea, diseñamos un mecanismo de detección de dos pasos que consiste en la detección de candidatos a cuadrículas cerradas y la identificación de cierres de carreteras. En vista de la Dependencia espacio-temporal de la característica de cierre de carretera, se introduce una técnica de aprendizaje profundo para predecir los valores de las características de cierre de cada cuadrícula (o carretera) en el período de tiempo actual [25, 28]. Calculando las diferencias entre las predicciones y los valores reales de las características de cierre de cada cuadrícula (o carretera), y comparándolas con los umbrales predefinidos, se encuentran los candidatos a cuadrícula cerrada (o cierres de carreteras).

En resumen, este artículo hace las siguientes contribuciones: (1) Hasta donde sabemos, el nuestro es el primer trabajo que detecta el cierre de carreteras basándose en múltiples características, que se compone de modelado de características fuera de línea e identificación en línea de cierres de carreteras. (2) Para mejorar la eficacia de la detección en línea, se utiliza una técnica de aprendizaje profundo (que incluye la combinación de CNN y LSTM, así como la de GCN y LSTM) para predecir los valores de múltiples características de cierre de carreteras. (3) Los resultados experimentales con datos reales de trayectorias de taxis de Chengdu, Shanghái y Pekín demuestran que nuestra propuesta supera a los métodos de última generación.

El resto del artículo se estructura de la siguiente manera: la Sección 2 revisa los trabajos más relevantes; la Sección 3 introduce los conceptos preliminares ; la Sección 4 describe en detalle el marco RCDM; la Sección 5 presenta los resultados experimentales, seguida de las conclusiones en la Sección 6.

2 TRABAJOS RELACIONADOS

Detección de anomalías de tráfico. Recientemente, como uno de los componentes vitales de la actualización de mapas, la detección de cierres de carreteras ha atraído una amplia atención tanto del ámbito académico como de la industria. Algunos investigadores también consideraron el cierre de carreteras como un tipo de anomalía de tráfico y lo detectaron de acuerdo con cambios anormales en las situaciones de tráfico dentro de las regiones [2, 8, 11, 12, 16, 26, 30]. Chawla et al. emplearon el Análisis de Componentes Principales (o PCA, por sus siglas en inglés) para extraer anomalías de tráfico basadas en las desviaciones del flujo de tráfico de los perfiles de tráfico históricos [2]. Kuang et al. combinaron la transformada wavelet con PCA para detectar anomalías de tráfico en regiones urbanas debido a tasas bajas (o altas) de cambio en el flujo de tráfico [8]. Liu et al. propusieron una detección de anomalías modelo construyendo primero un gráfico de región y luego detectando los valores atípicos del flujo de tráfico mediante el cálculo de la distancia de Mahalanobis [11]. Pang y Wang et al. utilizaron el método estadístico de prueba de razón de verosimilitud (o LRT, por sus siglas en inglés) para identificar el conjunto contiguo de regiones e intervalos de tiempo que tienen la mayor desviación estadísticamente significativa del comportamiento esperado según el número de taxis en las regiones [16, 30]. Zhang et al. propusieron un método de dos pasos para detectar anomalías urbanas empleando el método de máquinas de vectores de soporte [26]. Luo et al. adoptaron la divergencia relativa para calcular la fluctuación anormal de cada región [12]. Zhang et al. propusieron un método de detección de trayectorias anormales basado en el aislamiento. Este método puede filtrar el flujo de tráfico con cambios repentinos comparando rutas anormales con rutas históricamente normales e identificarlo como cierre de carretera [3].

Detección de cierres de carreteras. Debido al cambio dinámico de la red vial y la distribución asimétrica de los datos de trayectoria, y las interacciones entre las situaciones de tráfico de las carreteras adyacentes, solo unas pocas investigaciones han abordado el problema de la detección de cierres de carreteras. Se pueden agrupar en dos categorías: métodos basados en umbrales y métodos basados en estadísticas [21, 22, 31]. Wang et al. propusieron un método basado en umbrales para aprender los umbrales superior e inferior a partir de datos históricos [22]. Este método identificó el cierre de la carretera al detectar la anormalidad de la secuencia del flujo de tráfico en la dimensión temporal. Stanojevic et al. introdujeron la centralidad de intermediación para indicar la importancia de las carreteras en la fase de arranque en frío y detectaron el cierre de la carretera entre esas carreteras importantes [21]. Zhu et al. agregaron carreteras con un grado de nodo menor a 3 en un conjunto de carreteras y determinaron el cierre de la carretera basándose en la variación en la relación de la tasa de flujo de la carretera con respecto a la tasa de flujo establecida [31]. Debido a la limitación de un umbral fijo, la precisión del método basado en umbral es baja especialmente cuando los datos de trayectoria están sesgados en la red vial. Pietrobon et al. propusieron un método basado en estadísticas para detectar el cierre de carreteras estableciendo un proceso de Poisson [17]. Pero tiene menor precisión de detección debido a que ignora la correlación espacio-temporal entre carreteras.

Predicción de tráfico. R. Fu et al. utilizaron redes neuronales recurrentes (RNN) y redes de memoria a corto y largo plazo (LSTM) para predecir el flujo de tráfico y el tiempo de viaje, logrando un mejor rendimiento predictivo gracias al mecanismo de autocirculación para aprender la dependencia temporal [6, 18]. Dado que el tráfico está condicionado por las zonas urbanas y las carreteras, es fundamental comprender las dependencias espaciales y temporales para la predicción del tráfico. Para aprovechar al máximo las características espaciales, Wu y Tan propusieron una arquitectura llamada CLTFP. Esta predice el flujo de tráfico combinando una CNN unidimensional con dos LSTM, que extraen la dependencia espacial y la variabilidad a corto plazo respectivamente [24]. Sin embargo, la CNN tiene limitaciones para capturar características (por ejemplo, imágenes y cuadrículas regulares) del espacio euclidiano, lo que impide su uso en estructuras de redes viales complejas. Recientemente, algunos estudios convirtieron la CNN basada en cuadrículas a una estructura basada en grafos para la predicción del tráfico. Seo et al. introdujeron la red recurrente convolucional de grafos en la predicción [20]. Zhao y Li combinaron unidades recurrentes con compuertas con convolución de grafos para predecir el tráfico respectivamente [10, 29]. Zhang et al. presentaron un método de predicción basado en atención de grafos [27].

Los métodos mencionados de detección de anomalías y predicción del tráfico tenían un problema en común: detectaban el cierre de carreteras según la variación del flujo de tráfico. Pero en aplicaciones reales , pueden confundir la congestión con el cierre de carreteras. Más importante aún, no pueden utilizarse para identificar algunos tipos especiales de cierres de carreteras, como el cierre de una vía en un solo sentido o el cierre causado por carriles.

Machine Translated by Google

La fusión y el cierre de tramos dentro de la carretera son procesos frecuentes. Por lo tanto, se requiere un método de cierre de carreteras de alta eficiencia basado en múltiples características para identificar todos los cierres de manera rápida y precisa. Además , para aumentar la precisión de la detección, es necesario considerar la dependencia espacio-temporal y diseñar modelos de captura espacial adecuados para diferentes objetos de predicción (por ejemplo, cuadrículas y carreteras) al predecir los valores de las características de cierre de carreteras.

3. DETECCIÓN DE CIERRE DE CARRETERAS

En esta sección, introducimos algunos conceptos preliminares y definimos formalmente el problema de la detección de cierres de carreteras basándonos en datos de trayectoria.

Definición 1 (Mapa de carreteras) : Un mapa de carreteras se representa típicamente como un grafo M = (V, E), donde el conjunto de vértices (denotado como V y v V) incluye todas las carreteras. El conjunto de aristas (denotado como E) representa la relación de accesibilidad entre las carreteras.

Definición 2 (Trayectoria) : Una trayectoria Tr se refiere a una serie de puntos de posición generados por un objeto en movimiento en orden cronológico, denotados como Tr = < tp1, tp2, ..., tpn >. Cada punto de posición tpi = < lnдi , lati , ti , idi >, donde lnдi y lati denotan la longitud y la latitud de un punto de posición en el instante ti respectivamente, idi denota a qué vehículo pertenece esta trayectoria.

Para detectar de forma eficiente los cierres de carreteras, diseñamos un mecanismo de detección en línea que consiste en la identificación de candidatos a la cuadrícula cerrada y la detección de carreteras cerradas.

Primero dividimos una ciudad en cuadrículas según la longitud y la latitud, y obtenemos un mapa de cuadrícula (denominado G). Luego, obtenemos las secuencias de carreteras coincidentes mediante la comparación de mapas con datos de trayectoria.

Definición 3 (Candidato a cuadrícula cerrada) : Dado un conjunto de cuadrículas y un umbral de valores atípicos del flujo de tráfico thf , una cuadrícula se identifica como candidata a cuadrícula cerrada GC si y solo si la diferencia entre el valor predicho y el valor real del flujo de tráfico de la cuadrícula supera thf .

Al hacerlo, un área de detección, denominada DA, está compuesta por GC y redes circundantes.

Definición 4 (Fuerza de correlación) : Dada una serie de secuencias de carreteras coincidentes, la fuerza de correlación entre dos carreteras adyacentes cualesquiera, denotada como CS, es la frecuencia con la que dichas dos carreteras aparecen juntas en todas las secuencias de carreteras coincidentes.

Para cualquier carretera objetivo, la carretera adyacente con la máxima fuerza de correlación se considera su carretera fuertemente correlacionada.

Definición 5 (Carretera cerrada) : Dado un umbral de valores atípicos del volumen de giro tht y un umbral de valores atípicos del número de giros en U thu , una carretera se identifica como una carretera cerrada VC, si la diferencia entre la predicción y el valor real del volumen de giro de la carretera fuertemente correlacionada de VC (o el número de giros en U de VC) supera tht (o thu).

Finalmente, resumimos el problema de la siguiente manera.

Planteamiento del problema : Dado un conjunto de carreteras y una colección de trayectorias, el objetivo es encontrar la Carretera Cerrada (VC) basándose en una caída brusca del flujo de tráfico, así como en la caída del volumen de giros de las carreteras fuertemente correlacionadas con VC y el incremento del número de giros en U de VC.

4. DESCRIPCIÓN GENERAL DEL MARCO RCDM

Proponemos un marco de detección de cierres de carreteras basado en la fusión de múltiples características (o RCDM por sus siglas en inglés) utilizando datos de trayectoria. Como se muestra en la Figura 2, RCDM se compone de características de cierre de carreteras fuera de línea.

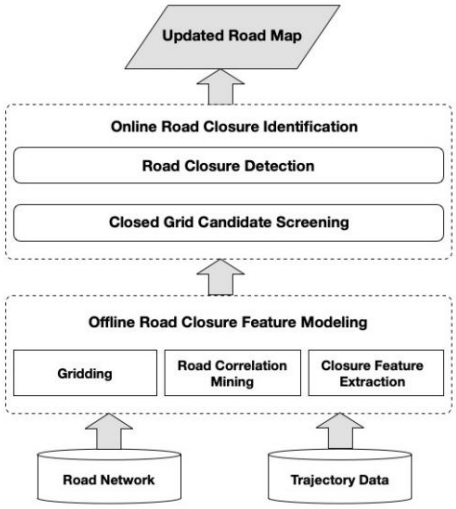


Figura 2: Marco de referencia de RCDM

Fase de modelado y fase de identificación de cierres de carreteras en línea. En la fase fuera de línea, primero dividimos la región en cuadrículas y luego extraemos la fuerza de correlación de las carreteras y las características de los cierres de carreteras a partir de datos históricos. En la fase en línea, seleccionamos las cuadrículas candidatas a cierres basándonos en una caída significativa del flujo de tráfico dentro de las cuadrículas. Y sobre esta base, intentamos encontrar carreteras cerradas según la caída del volumen de giros de carreteras fuertemente correlacionadas o el aumento de la frecuencia de giros en U.

4.1 Modelado de características de cierre de carreteras fuera de línea

Se observa que el cierre de una carretera no es un evento aislado. Específicamente , el cierre de cualquier carretera afectaría las situaciones de tráfico de sus regiones vecinas. Dado esto, en la fase de modelado fuera de línea, primero dividimos la región a detectar en cuadrículas e intentamos extraer la fuerza de correlación de las carreteras. Con base en datos históricos, intentamos extraer una serie de características de cierre de carreteras para fines de detección en línea. Estas incluyen el flujo de tráfico de las cuadrículas, así como el volumen de giros de las carreteras fuertemente correlacionadas y la frecuencia de giros en U de la carretera objetivo, como se muestra en el Algoritmo 1.

Inicialmente, dividimos la región a detectar en un conjunto de cuadrículas G de igual tamaño (en la línea 2), como se muestra en la Figura 3. Luego, numeramos cada cuadrícula según su fila y columna, y sobre esta base construimos el índice invertido para la red vial y los datos de trayectoria, respectivamente. La adopción del método de división en cuadrículas tiene la ventaja adicional de reducir la sobrecarga de detección en línea al descartar candidatos a cuadrículas cerradas. Además, considerando que la longitud promedio de las carreteras y una cuadrícula excesivamente grande pueden ignorar la fluctuación de las trayectorias locales, establecimos el tamaño del lado de la cuadrícula en 500 metros después de realizar pruebas con datos reales.

Minería de la fuerza de correlación para las carreteras. La situación del tráfico de cada carretera suele verse afectada por las carreteras anteriores (también llamadas carreteras correlacionadas). Intentamos contar la frecuencia con la que los vehículos viajan sucesivamente a través de dos carreteras adyacentes cualesquiera para extraer su fuerza de correlación (denotada como CS) basándonos en datos históricos de trayectoria (en las líneas 3-4). Para ser más específicos, primero empleamos

Machine Translated by Google

Algoritmo 1: Modelado de características de cierre de carreteras fuera de línea

Entrada: El conjunto de trayectorias Trs , el mapa de carreteras M, el rango de la región de detección DR;
Salida: la serie temporal del flujo de tráfico por hora de cada cuadrícula. T Fh, la frecuencia de giros en U a nivel horario y la serie temporal del volumen de giros de tráfico de cada carretera RUh,TVh;

1 S ← , G ← ; //S denota las secuencias de carreteras coincidentes mediante la correspondencia de mapas
2 G ← дriddinд(DR); //divide las regiones a detectar en cuadrículas
3 S ← mapMatchinд(Trs ,M);
4 CS ← дetCorrelationStrenдth(S); //obtener la fuerza de correlación de las carreteras en el aspecto de la situación del tráfico 5 para д en G hacer
6 T Fh ← Flujo de tráfico por hora (д, Trs); 7 fin

8 por cada hora hacer
9 RUh ← RUh Extracción de frecuencia de giro en U(Trs ,M)
10 fin
11 por cada hora hacer
12 TVh ← TVh дetT ra ff icTurninд(S, CS) 13 fin 14 retornar T Fh,
RUh, TVh

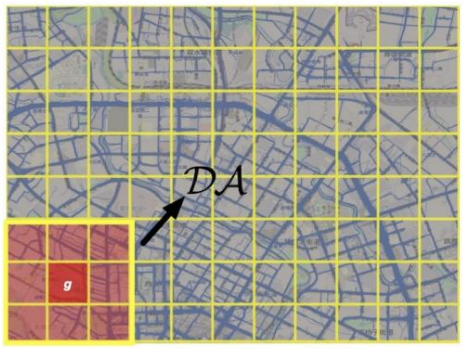


Figura 3: Rejilla

Algoritmo de coincidencia de mapas basado en Markov oculto [15] para obtener las secuencias de carreteras coincidentes (denotadas como S) para cada trayectoria. Posteriormente, contamos el número de pares de carreteras sucesivas que coocurren para todas las trayectorias para derivar la fuerza de correlación de dicho par de carreteras. Por ejemplo, cuando una trayectoria Tr coincide con la secuencia de carreteras S = < v1,v2,v3,v4 > mediante la coincidencia de mapas, se contaría el número de ocurrencias de cualquier par de carreteras < v1,v2 > que el vehículo recorre sucesivamente. De esta manera, la fuerza de correlación entre la carretera v1 y su carretera adyacente se puede obtener analizando todas las trayectorias. Además, la carretera adyacente con la máxima fuerza de correlación se considera la carretera fuertemente correlacionada de v1. Para cualquier carretera de doble sentido, hay una carretera fuertemente correlacionada en cada dirección. En comparación con otras carreteras relacionadas, los cambios en el volumen de giro de la carretera fuertemente correlacionada después del cierre son más drásticos. Por lo tanto, una carretera fuertemente correlacionada es suficiente para

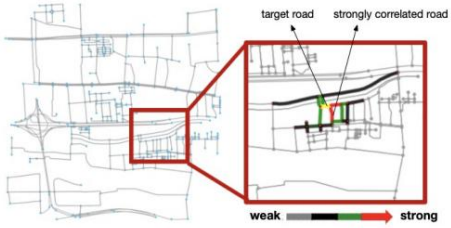


Figura 4: Ilustración de la fuerza de correlación de las carreteras

Capturar los cambios de tráfico durante el cierre de la carretera. Como se ilustra en la Figura 4, para la carretera objetivo resaltada en amarillo, sus carreteras adyacentes tienen diferentes niveles de correlación, es decir, el nivel de correlación aumenta gradualmente desde la línea gris hasta la roja.

Extracción de características de cierre de carreteras. Para extraer características de cierre para Para cada cuadrícula (o carretera) de los datos históricos de trayectoria, primero dividimos la trayectoria Tr en segmentos a nivel horario. Luego contamos la cantidad de vehículos que transitan por cada cuadrícula para obtener sus estadísticas normales de flujo de tráfico horario (denotadas como T Fh) (en las líneas 5-7).

Proponemos un algoritmo llamado U turnFrequencyExtraction (en las líneas 8-10) para obtener la frecuencia normal de giros en U para todas las carreteras en cada hora, basándonos en datos históricos. Específicamente, primero calculamos la diferencia angular entre cada punto de posición y el anterior para cada trayectoria, con el fin de identificar los puntos de giro. Si esta diferencia angular es mayor que el umbral angular preestablecido thanдle1 (aquí thanдle1 se establece en 35), dicho punto de posición se marca como un punto de giro. Utilizamos el método DBSCAN [4] para agrupar todos los puntos de giro y representamos los resultados de la agrupación en forma de envolvente convexa. DBSCAN no necesita predefinir el número de clases. Es insensible al ruido y puede encontrar grupos de diferentes formas. Luego, tratamos el primer punto de una trayectoria determinada que entra en la envolvente convexa como punto de entrada y el último punto que sale de ella como punto de salida. Si la diferencia angular entre el punto de entrada y el punto de salida es mayor que el umbral angular preestablecido thanдle2 (aquí thanдle2 se establece en 150), la trayectoria se considera una trayectoria de giro en U. Mediante la comparación de mapas, obtenemos las carreteras donde se ubican las trayectorias de giro en U y obtenemos la frecuencia normal (denotada como RUh) de giros en U que ocurren en esas carreteras. Como se ilustra en la Figura 5, una envoltura convexa está marcada por un óvalo irregular verde, que contiene algunos puntos de giro (resaltados con puntos rellenos amarillos). Una trayectoria (resaltada con una línea gruesa roja) cuyo punto de entrada y punto de salida tienen una diferencia angular relativamente grande se considera una trayectoria de giro en U.

Además, intentamos obtener el volumen de giro normal de la carretera fuertemente correlacionada cada hora. Primero obtenemos la secuencia de carreteras coincidentes (denotada como S) para cada trayectoria a través de la coincidencia de mapas. Luego, filtramos las carreteras fuertemente correlacionadas para cada carretera mediante la minería de la fuerza de correlación. Al contar el número de ocurrencias del par de carreteras que el vehículo recorre sucesivamente, podemos obtener el volumen de giro (denominado TVh) para cualquier carretera fuertemente correlacionada de cada carretera en cada hora (en las líneas 11-13).

4.2 Identificación de cierres de carreteras en línea

Aunque la situación del tráfico tiene periodicidad y tendencia (o conocida como dependencia temporal), por ejemplo, la hora punta de la mañana y

Machine Translated by Google

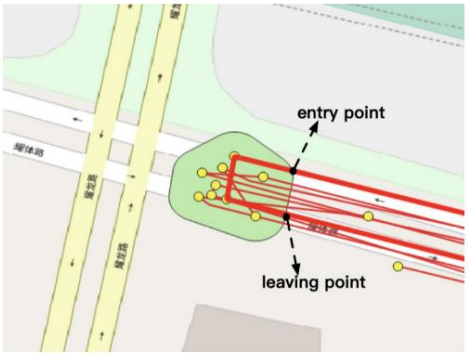


Figura 5: Extracción de giro en U

Durante la hora punta de la tarde, la red vial cambia de forma dinámica. Es probable que se juzgue erróneamente un evento como un atasco de tráfico como un cierre de carretera al comparar los valores de las características de cierre con valores normales históricos para identificar los valores atípicos. Como se indicó anteriormente, cualquier cierre de carretera tendrá un impacto en la situación del tráfico de su área circundante (también conocida como propiedad de dependencia espacial). Dado esto, en la fase de detección en línea, primero aprovechamos la técnica de aprendizaje profundo para predecir los valores de las características de cierre para cada cuadrícula o carretera en el período de tiempo actual en lugar de usar sus valores normales históricos. Con base en eso, comparamos los valores reales con las predicciones para encontrar las cuadrículas o carreteras que tienen diferencias significativas en las características de cierre en el período de tiempo actual, como se muestra en el Algoritmo 2. En nuestro modelo de predicción, se toma en cuenta la dependencia espacio-temporal compleja de los datos de trayectoria. Para lograr el objetivo de identificar primero los candidatos a cuadrícula cerrada y luego los cierres de carreteras, adoptamos la estrategia que consiste en dos combinaciones diferentes de modelos de redes neuronales para extraer la dependencia espacio-temporal de dos niveles de región (es decir, cuadrícula y carretera) respectivamente, como se muestra en la Figura 6.

Selección de candidatos para cuadrículas cerradas. En una red vial real, el flujo de tráfico de cada tramo suele ser constante , determinado principalmente por la longitud de la carretera y la velocidad de los vehículos. Para evaluar el impacto del cierre de una carretera en el tráfico de las vías vecinas, primero se descartan las cuadrículas que podrían presentar un cierre, según la drástica disminución de su flujo de tráfico. Este método ofrece la ventaja adicional de reducir costos, ya que no requiere la comparación de mapas al inicio de la detección en línea.

Adoptamos la combinación de modelos CN N y LSTM [25] para predecir los valores de las características de cierre en el período de tiempo actual. Si la diferencia entre la predicción y el valor real supera el umbral de valores atípicos predefinido, la cuadrícula se considerará candidata a cuadrícula cerrada. CN N es un modelo de inspiración biológica que se ha utilizado ampliamente para procesar imágenes, voz y series temporales [28]. Es bien sabido que la cuadrícula es una estructura espacial regular (es decir, estructura euclidiana) con invariancia de traslación, y el cambio del flujo de tráfico en cada cuadrícula se ve afectado principalmente por las cuadrículas circundantes. Una red neuronal convolucional (CN N) con un núcleo de convolución de tamaño fijo es adecuada para capturar eficientemente la correlación espacial de los datos que se pueden expresar como una matriz bidimensional. Para ser más específicos,

Algoritmo 2: Identificación en línea de cierres de carreteras

Entrada: El conjunto de trayectorias en tiempo real Trs ;
Salida: un conjunto de carreteras cerradas VC;
un conjunto de candidatos a cuadrícula cerrada: GC ← ;
un conjunto de carreteras cerradas: VC ← ;
para д en G hacer
T Fc ← detT F actual (d)
Ef ← дetEastimate(T Fh) // Modelo CN N y LSTM si (Ef − T Fc)
> thf entonces
GC ← GC d fin
fin
DA = дetDetectionAreas(GC) para
da en DA hacer para v
en M(da) hacer
TVc ← дetCurrentTV (Trs (da),M(da), CS)) // coincidencia de mapas
RUc ← дetCurrentRU (Trs (da),M(da)))// DBSCAN
Et ← дetEastimate(TVh) // GCN y LSTM modelo
Eu ← дetEastimate(RUh) // GCN y LSTM modelo
si (Et − TVc > tht) o (RUc − Eu > thu) entonces
VC ← VC v
fin
fin
fin
retorno VC

El flujo de tráfico histórico por hora de cada cuadrícula se convierte en una matriz X similar a una imagen [28] , que es una matriz bidimensional que contiene el flujo de tráfico. En vista de que una convolución solo considera la propiedad de correlación espacial cercana, diseñamos una CN N con múltiples capas. La conversión de cada capa se define como:

$$X^{k}_{i,t} = f\left(W^{kk-1\,k} + b \quad X_{i,t}\right) \qquad (1)$$

donde denota la operación convolucional y f es la función de activación ReLU . La función ReLU se prefiere a las funciones sigmoide/tanh tradicionales porque: a) es computacionalmente más eficiente, b) puede ayudar a evitar los problemas de explosión y desaparición del gradiente [14] .

él representa la salida del área i de la capa k en el período de tiempo t, y W , b son parámetros aprendidos. Después de K capas de convolución, usamos una capa de aplanamiento para transformar la salida en un vector de características 1 − D con atributos espaciales y lo enviamos a través de una capa totalmente conectada para obtener el resultado final.

Dado que el flujo de tráfico actual se ve afectado por las condiciones de tráfico del momento anterior o incluso anterior, es necesario capturar la dependencia temporal del flujo de tráfico. Para ello, empleamos el modelo LSTM [5] , que utiliza un mecanismo de compuerta para memorizar la mayor cantidad posible de información a largo plazo. Se aplica ampliamente para abordar el problema del gradiente explosivo y evanescente de las redes neuronales recurrentes tradicionales [19]. Con este modelo, el componente principal de la capa de memoria a largo y corto plazo es la celda de memoria que registra

Machine Translated by Google

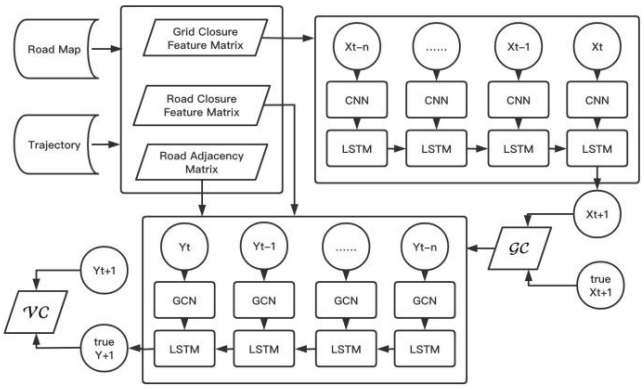


Figura 6: Modelo de predicción

El estado de cada celda. Una celda de memoria consta de cuatro elementos: el valor actualizado del estado de la celda, una puerta de entrada, una puerta de olvido y una puerta de salida. Estos elementos determinan cuánta información anterior y actual debe conservarse y cuánta debe olvidarse.

Además, tenemos en cuenta los cambios periódicos a nivel diario y semanal. LSTM abarca los datos característicos de los siete días anteriores.

El resultado final contiene información espacial y temporal a corto plazo , obtenida mediante una capa totalmente conectada. A partir del flujo de tráfico horario histórico extraído T Fh, predecimos el flujo de tráfico Ef de cada cuadrícula en el período actual. Si la diferencia entre la predicción y el valor real del flujo de tráfico de alguna cuadrícula en el período actual es mayor que el umbral de valores atípicos del flujo de tráfico thf , esa cuadrícula se marca como candidata a cuadrícula cerrada que podría tener cierre de carretera. Al hacer esto, obtenemos un conjunto de candidatos a cuadrículas cerradas GC (en las líneas 3-9). En vista de la distribución asimétrica de los datos de trayectoria en la red vial, el valor de thf debe ser adaptativo.
Ajustamos su valor en términos de la densidad de distribución de trayectoria dд dentro de la cuadrícula objetivo д utilizando el método propuesto en [13].
Se puede expresar como:

$$thf = \frac{dд}{avд(dд)} \times a \quad (2)$$

Aquí , avд(dд) es la densidad promedio de datos de trayectoria dentro de cada cuadrícula en los datos históricos, y α es un umbral aprendido evaluado por la parte experimental.

Considerando que algunos cierres de carreteras ocurren donde se encuentran dos o más cuadrículas, extraemos todas las cuadrículas candidatas a cierre y sus cuadrículas adyacentes para formar una región de detección de cierre de carretera (denominada DA, en la línea 10). Como se muestra en la Figura 3, una cuadrícula candidata a cierre д y sus cuadrículas vecinas forman una región resaltada en rojo. cuadrado.

Detección de cierre de carretera. Para obtener los valores de cierre de carretera.

En el período de tiempo actual, los datos de la red vial M(da) y los datos de trayectoria Trs (da) en cada región de detección candidata se obtienen respectivamente en función de las estructuras de índice invertidas. Luego obtenemos la secuencia de carreteras coincidentes para cada trayectoria mediante la coincidencia de mapas [15]. De acuerdo con la fuerza de correlación de cada CS de carretera, obtenemos el volumen de giro de la carretera fuertemente correlacionada. de cada carretera en el período de tiempo actual TVc . Además, obtenemos la frecuencia de U-turn RUc en el período de tiempo actual basándonos en la agrupación de puntos de inflexión (en las líneas 13-14).

En realidad, la situación del tráfico de cada carretera no solo se ve afectada por las carreteras vecinas, sino también influenciada por la de periodos de tiempo anteriores. En otras palabras, existen dependencias espacio-temporales en las situaciones de tráfico de las carreteras. Dado esto, adoptamos la combinación de modelos de redes neuronales para capturar la dependencia espacial y la dependencia temporal respectivamente. Como la red de carreteras tiene la forma de un grafo (estructura no euclidiana), el modelo CNN ordinario no puede obtener bien sus complejas características topológicas espaciales debido a su núcleo de convolución de tamaño fijo. Como resultado, la Red Neuronal Convolucional Gráfica (GCN) toma el lugar de CNN y trabaja con LSTM [29] para capturar la dependencia espacio-temporal de las situaciones de tráfico de las carreteras. Para ser específicos, primero establecemos la matriz de adyacencia A para las carreteras en función de sus relaciones aguas arriba y aguas abajo con las carreteras adyacentes. Cada nodo contiene dos atributos, que incluyen el volumen de giro de la carretera fuertemente correlacionada y la frecuencia de giros en U. Luego construimos la matriz de características para estas dos características respectivamente, denotada como Y. El modelo GCN une la teoría de grafos espectrales y las redes neuronales profundas mediante la construcción de un filtro en el dominio de Fourier . El filtro actúa sobre los nodos del grafo y captura características espaciales entre los nodos a través de sus vecindarios de primer orden. El GCN con múltiples capas convolucionales se define como se muestra a continuación:

$$H^{l+1} = \sigma(D^{-} - (3) \text{ donde } A^{-} = A + I \text{ es la matriz con autoconexiones añadidas e I es l}$$

la matriz identidad. D¯ es la matriz de grados de la capa , H es la salida de l A¯ , l es una matriz de pesos entrenada y σ es una activación no lineal función W. Luego construimos una GCN de dos capas [7] cuya fórmula de propagación hacia adelante global se define como:

$$Z = f(Y,A) = \text{entonces f tmax(AReLU (AYW}^{(0)})W^{(1)}) \quad (4)$$

donde Aˆ = D¯ − 1 2A¯D¯ − 1 2 actúa como preprocesamiento, la función de activación usa ReLU y softmax respectivamente. W (0) es la matriz de pesos de la entrada a la capa oculta y su tamaño es la longitud de la matriz de características por el número de unidades ocultas. W (1) es la matriz de pesos de la capa oculta a la capa de salida, cuyo tamaño es el número de unidades ocultas por la longitud de predicción. Usamos el modelo GCN para obtener la relación topológica entre la carretera objetivo y sus carreteras adyacentes, y codificamos la estructura topológica así como los atributos de la carretera de la red vial. Posteriormente, el resultado con propiedad espacial también se introduce en LSTM para capturar atributos ter

Después de obtener la predicción Et basada en TVh, calculamos la diferencia entre la predicción Et y el TVc actual . Cuando esa diferencia es mayor que el umbral de valores atípicos del volumen de giro tht , se identifica la carretera a cerrada VC . Además, una carretera puede verificarse como de un solo sentido o de doble sentido basándose en los metadatos de OSM2 . En el caso de que un lado de una carretera de doble sentido esté cerrado, se reconoce cuando la diferencia entre la predicción Et y el TVc actual con una dirección de la carretera es mayor que tht pero la otra no (en las líneas 15,17). Se observa que la frecuencia de giros en U aumentará cuando la parte central de la carretera esté cerrada. Obtenemos la predicción Eu basada en RUh y juzgamos la carretera como cerrada cuando la diferencia entre la predicción

2http://wiki.openstreetmap.org/

Machine Translated by Google

Eu y el valor verdadero RUc es mayor que el umbral de valores atípicos de cambio de sentido thu (en las líneas 16 y 17). Aquí, tht y thu son umbrales adaptativos y se pueden expresar como:

$$\text{tht} = \beta \times \frac{\text{avä}(TV(v))}{\text{avä}(TV)} \quad (5)$$

donde avд(TV) es el TV promedio por hora de todas las carreteras en los datos históricos y avд(TV(v)) es el promedio de la carretera v.

$$\text{thu} = \gamma \times \frac{\text{avd}(EN(v))}{\text{avd}(EN)} \quad (6)$$

donde avд(RU) es el RU promedio por hora de todas las carreteras en los datos históricos y avд(RU(v)) es el promedio de la carretera v. β y γ son los umbrales aprendidos evaluados en experimentos posteriores.

5. EVALUACIÓN EXPERIMENTAL

En esta sección, realizamos experimentos exhaustivos para evaluar la efectividad y eficiencia de RCDM. Primero, describimos tres conjuntos de datos de trayectorias reales utilizados en este artículo. Luego, presentamos las métricas de evaluación para los resultados experimentales. Posteriormente, proporcionamos una comparación de la efectividad y eficiencia entre diferentes métodos de referencia y RCDM. Finalmente, se presentan un conjunto de estudios de caso reales y el experimento de ablación para demostrar la efectividad de nuestra propuesta. Todos los experimentos se realizan en un clúster de 5 nodos que ejecuta Spark 2.2.0 sobre Ubuntu 12.0.4. Cada nodo está equipado con un procesador Intel E5335 de 8 núcleos a 2.0 GHz y 16 GB de memoria. El programa y los métodos de referencia están implementados en Python 3.7.

5.1 Descripción de los datos Elegimos

conjuntos de datos de tres ciudades principales para evaluar nuestros experimentos, que pueden representar la compleja red vial de la mayoría de las ciudades de China. Contiene el conjunto de datos de trayectorias de taxis de 2018 en Shanghái (o Shanдhai2018 para abreviar), el conjunto de datos de trayectorias de taxis de 2013 en Pekín (o Beijinд2013 para abreviar) y el conjunto de datos de trayectorias de taxis de 2018 en Chengdu (o Chengdu2018 para abreviar). El propósito de esto es cubrir más escenarios de tráfico en diferentes lugares, y los parámetros de los modelos de detección pueden ser más aplicables a otras ciudades o países. Además, elegimos un mapa de código abierto, OpenStreetMap (OSM), como nuestros datos cartográficos.

Shanдhai2018 es un conjunto de datos públicos derivado de un concurso de innovación y aplicaciones (conocido como Shanghai Open Data Apps, o SODA). SODA es un evento anual que permite a los analistas de datos utilizar una gran cantidad de datos para desarrollar aplicaciones útiles que aborden diversos problemas de la ciudad. Shanдhai2018 es el conjunto de datos de trayectorias de taxis de la compañía Shanghai Qiangsheng Taxi, correspondiente al período del 1 al 30 de abril de 2018.
Se registran aproximadamente 200.000 trayectorias y 100 millones de puntos de trayectoria cada día. La frecuencia de muestreo promedio es de 10 segundos. Cada punto de la trayectoria contiene atributos como el número de vehículo, la marca de tiempo, la longitud y la latitud, etc.

Chengdu2018. Contiene los datos de trayectoria de Chengdu obtenidos de la plataforma Didi en octubre y noviembre de 2018. Didi genera más de 106 TB de datos de trayectoria de vehículos a escala global y gestiona más de 40 mil millones de solicitudes de ruta cada día. Contiene aproximadamente 2 mil millones de coordenadas de puntos de trayectoria, más de 10 millones de trayectorias, aproximadamente 24,7 GB, y una frecuencia de muestreo promedio de 3 segundos. Cada punto de trayectoria contiene cuatro atributos: ID del conductor, marca de tiempo, longitud y latitud, etc.

Beijing 2013. Se trata de un conjunto de datos de trayectorias de taxis desde el 1 de octubre de 2013 hasta el 1 de noviembre de 2013 en Beijing. Se registran aproximadamente 50 000 trayectorias diarias, con una frecuencia de muestreo promedio de 10 segundos.

Datos de OSM. La red vial de Beijing proviene de OSM con 150.183 nodos y 169.294 aristas, la red vial de Shanghai proviene de OSM con 191.684 nodos y 210.909 aristas, y la red vial de Chengdu proviene de OSM con 168.216 nodos y 187.444 aristas.

Dado que los intervalos de muestreo de los tres conjuntos de datos son diferentes, para garantizar la consistencia condicional, primero realizamos un submuestreo del conjunto de datos Chenдdu2018 para mantener la uniformidad del intervalo de muestreo. También utilizamos el 60 % de los datos (sin cierres de carreteras) de los tres conjuntos de datos como datos de entrenamiento para la construcción de los modelos de predicción. Además, para garantizar la imparcialidad y la precisión de la evaluación de la eficiencia en comparación con los métodos de referencia, tomamos las trayectorias de los tres conjuntos de datos de manera equitativa para el experimento de eficiencia.

5.2 Método de evaluación

Utilizamos tres métricas de evaluación (precisión, exhaustividad y puntuación F1) para evaluar la efectividad de nuestros experimentos de ablación, y evaluamos la eficiencia del experimento mediante el tiempo de ejecución. Sea TP el número de carreteras cerradas identificadas correctamente por el algoritmo de detección, FP el número de carreteras cerradas identificadas incorrectamente por el algoritmo de detección, y FN el número de carreteras cerradas en el conjunto de cierres de carreteras etiquetados manualmente pero no identificadas por el algoritmo de detección. La precisión, la exhaustividad y la puntuación F1 se calculan respectivamente de la siguiente manera:

$$\text{Precisión} = \frac{TP}{TP + FP} \quad (7)$$

$$\text{Recordatorio} = \frac{TP}{TP + FN} \quad (8)$$

$$\text{F 1 − puntuación} = \frac{2 \times \text{Precisión} \times \text{Recuperación}}{\text{Precisión} + \text{Recuperación}} \quad (9)$$

La precisión indica cuántos de los cierres de carreteras detectados que

La precisión coincide con los cierres de la verdad fundamental, la exhaustividad indica cuántos de los cierres de la verdad fundamental han sido identificados correctamente por los algoritmos de detección, y la puntuación F1 es el promedio armónico ponderado de la precisión y la exhaustividad.

5.3 Evaluación de la eficacia

En esta subsección, evaluamos la efectividad de RCDM. Primero, describimos el proceso de etiquetado manual de datos y, a continuación, presentamos el proceso de selección de umbrales para la fase de detección. Finalmente, comparamos nuestra propuesta con tres métodos de referencia.

Extracción de etiquetas. De acuerdo con el alcance temporal y espacial de tres conjuntos de datos, recopilamos 65 eventos de cierre de carreteras a través de noticias, anuncios gubernamentales y sitios web de gestión de tráfico. Estos incluyen, entre otros, cierres de carreteras debido a grandes eventos deportivos y de entretenimiento, accidentes de tráfico, obras de reparación de carreteras y eventos políticos, etc.

3http://shanghai.sodachallenges.com/

Machine Translated by Google

Selección de umbrales. En nuestra implementación, hemos probado posibles umbrales del flujo de tráfico de la cuadrícula, el volumen de giros en carretera fuertemente correlacionado y la frecuencia de giros en U. Para determinar los umbrales más apropiados, verificamos el resultado de la detección con los cierres de carreteras reales. La precisión, la exhaustividad y la puntuación F1 se calculan por separado para reflejar la efectividad de nuestro método propuesto al establecer diferentes umbrales.

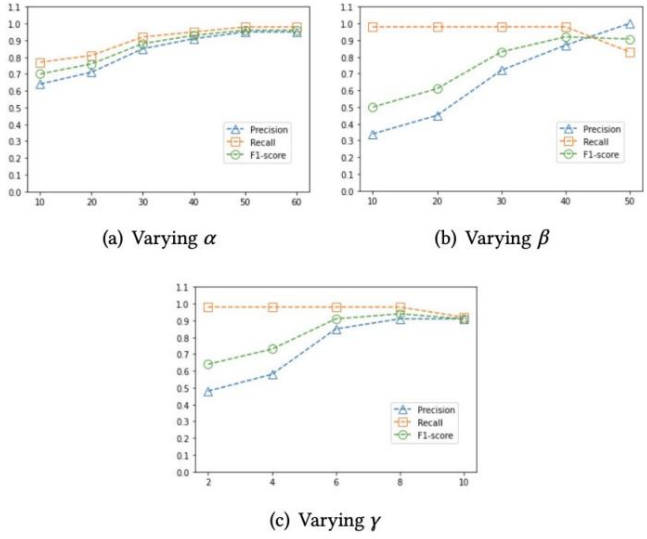


Figura 7: Evaluación de parámetros

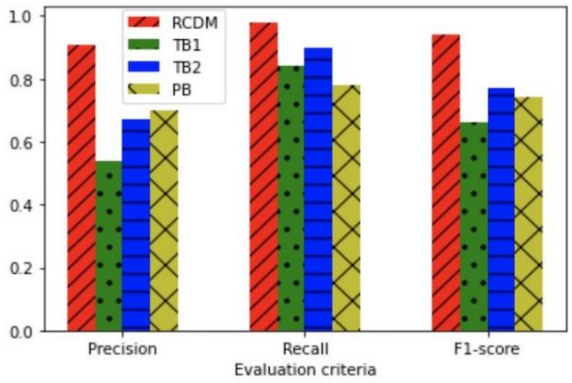


Figura 8: Evaluación de la efectividad

Como se ilustra en la Figura 7, cuando α, β y γ siguen aumentando, la puntuación F1 alcanza un punto de estrangulamiento en 50, 40 y 8 respectivamente. Por lo tanto, determinamos que RCDM logra el mejor rendimiento cuando α = 50, β = 40 y γ = 8 tras varios ajustes. Cabe señalar que valores mayores de β y γ pueden provocar que se omitan algunos cierres de carreteras, lo que conlleva una disminución de la precisión (Recall), por lo que no se recomienda establecerlos en valores demasiado altos.

Comparación con métodos de referencia. En este experimento, comparamos RCDM con tres enfoques para verificar la superioridad de RCDM:

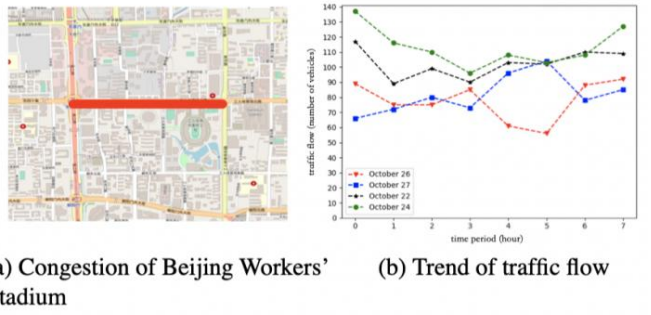


Figura 9: Caso de congestión

(i) método basado en umbrales [31] (o T B1 para abreviar), que agrega carreteras con un grado de nodo menor a 3 en un conjunto de carreteras y determina los cierres de carreteras en función del cambio en la relación de la tasa de flujo de la carretera a la tasa de flujo del conjunto de carreteras.

(ii) Método de detección de cierre de carreteras en arranque en frío [21] (o T B2 para abreviar), que introduce la definición de centralidad de intermediación para indicar la importancia de las carreteras en la fase de arranque en frío y determina el cierre en función del intervalo de tiempo del vehículo que pasa por la carretera. (iii)

Método basado en el proceso de Poisson [17] (o PB para abreviar), que es un método estadístico para determinar el cierre de carreteras estableciendo un proceso de Poisson y ejecutando una prueba de valor p en una distribución chi-cuadrado.

Como se ilustra en la Figura 8, RCDM presenta un buen rendimiento, excepto en las regiones donde la distribución de trayectorias es dispersa. A continuación, ilustramos la eficacia de nuestra propuesta con numerosos ejemplos reales .

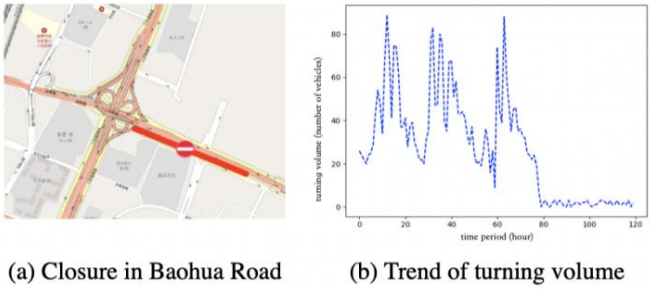
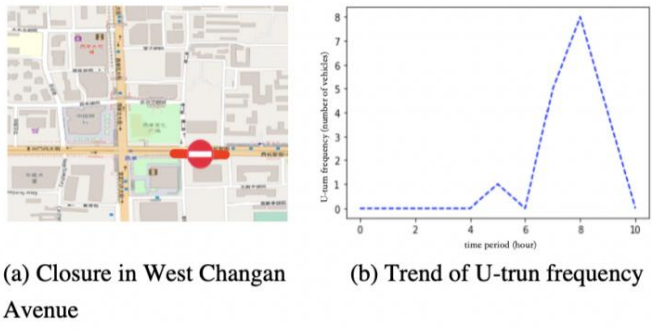


Figura 10: Cierre lateral

Se puede observar que los métodos de referencia detectan el cierre de carreteras solo en función de una caída drástica del flujo de tráfico y simplemente registran el intervalo de tiempo de los vehículos que pasan por la carretera. Como se muestra en la Figura 9, el 26 de octubre de 2013 a las 18:30 se celebró un concierto en el Estadio de los Trabajadores de Pekín, lo que provocó una rápida disminución del flujo de tráfico debido a la congestión extrema. Por lo tanto, es fácil que se produzcan errores al juzgar los eventos de congestión y no se pueden identificar algunos eventos especiales de cierre de carreteras. Además, nuestra propuesta puede detectar el cierre de un lado de la carretera de doble sentido y el cierre de la parte central de la carretera. Como se muestra en la Figura 10, debido a la construcción de la carretera Chengdu Baohua el 31 de octubre de 2018, el volumen de giro de una sola

Machine Translated by Google



(a) Closure in West Changan Avenue (b) Trend of U-trun frequency

Figura 11: Cierre en medio de la carretera

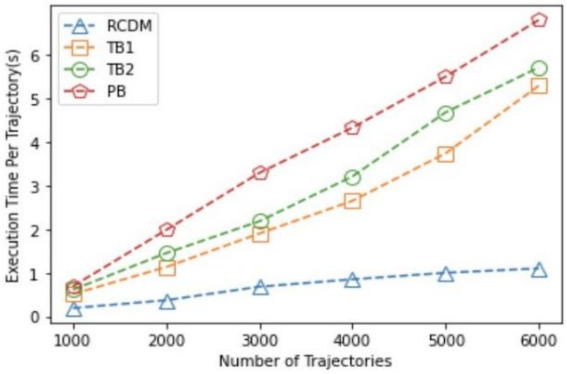


Figura 12: Evaluación de la eficiencia

En su carretera fuertemente correlacionada, la frecuencia de giros en U cae repentinamente a cero. Asimismo, como se muestra en la Figura 11, el 20 de octubre de 2013 se celebró un maratón cerca de la Avenida Changan Oeste de Pekín. Se observa que la frecuencia de giros en U en esta carretera experimenta inicialmente un incremento repentino, para luego volver a su estado original tras el cierre de la vía. Estos cierres de carretera no pueden identificarse únicamente mediante la detección de caídas bruscas en el flujo de tráfico.

5.4 Evaluación de la eficiencia Dado que la cantidad de datos de trayectoria es diferente según el cambio de área o tiempo durante la detección en línea, elegimos un número diferente de trayectorias para evaluar la eficiencia de nuestra propuesta.

Como se muestra en la Figura 12, el tiempo de ejecución de nuestra propuesta aumenta con el número de trayectorias. Cuando el número de trayectorias es pequeño, la diferencia entre RCDM y los métodos de referencia no es evidente. Sin embargo, a medida que el número de trayectorias sigue aumentando, el tiempo de ejecución de RCDM es mucho menor que el de los algoritmos de comparación. Esto se debe a que RCDM primero descarta los candidatos a cuadrícula cerrada, lo que reduce el costo computacional en la detección de carreteras cerradas específicas. En resumen, RCDM puede ejecutarse de manera eficiente al procesar una gran cantidad de datos de trayectoria, lo que demuestra que nuestro método tiene un mejor rendimiento.

5.5 Estudios de caso

En los experimentos, seleccionamos dos casos especiales de cierre: cierre periódico y cierre de carretera provocado por la incorporación de carriles. Como se ilustra en las figuras 13(a) y (b), en la avenida Changan Este se celebra un izamiento de bandera en la plaza de Tiananmen. Este evento provoca regularmente una disminución significativa del flujo de tráfico alrededor de las 6:00 de la mañana debido al cierre de la carretera. Además, algunos trenes de mercancías circulan diariamente por ciertas vías urbanas a intervalos regulares, lo que provoca el cierre temporal de estas vías, como se muestra en la figura 13(c).

El cierre provocado por la fusión de carriles es una situación particular del cierre unilateral, como se ilustra en la Figura 14(a). En algunos casos de cierre unilateral, observamos que el volumen de giros de la vía con mayor correlación no ha disminuido significativamente, pero sus trayectorias presentan una desviación evidente en comparación con la ruta normal histórica. Por consiguiente, analizamos estos ejemplos por separado para detectar este tipo de cierre de vía.

El análisis preliminar de datos y la observación diaria muestran que este tipo de carretera cerrada tiene una reducción en el flujo de tráfico y el volumen de giros de las carreteras adyacentes, excepto que no hay un cambio significativo en la frecuencia de giros en U. Intentamos calcular el desplazamiento de las trayectorias en la carretera para detectar el cierre causado por la fusión de carriles. Este tipo de cierre de carretera muestra el fenómeno de que los dos carriles originales se cambian a un solo carril, lo que lleva a que las trayectorias se inclinen hacia el lado opuesto de la carretera. Para abordar esto, necesitamos extraer el desplazamiento promedio de las trayectorias coincidentes de cada carretera a partir de datos históricos. Luego inferimos la línea central de cada carretera y

Se obtiene el conjunto de trayectorias en la carretera mediante la correspondencia de mapas. Se recorren los puntos de cada trayectoria y su distancia vertical desde el eje central de la carretera se considera el desplazamiento de cada punto. Finalmente, se extrae el desplazamiento promedio de las trayectorias coincidentes de cada carretera .

En la fase de detección, primero calculamos el desplazamiento de la trayectoria actual en la carretera Oc basándonos en la línea central de la carretera. Luego calculamos la distancia de Wasserstein [23] calculando la distribución de desplazamiento promedio de la trayectoria histórica Oh y la distribución de desplazamiento de la trayectoria que se va a detectar en el período de tiempo actual Oc .

La distancia de Wasserstein también se llama distancia de Earth Mover, que es una medida de la distancia entre dos distribuciones. Por ejemplo, Tr1 el desplazamiento de Tr1 es O = {p1, p2, ..., pn } y el desplazamiento de Tr2 es O i Tr2 i = {q1, q2, ..., qm }. Si m y n no son iguales, tomamos la longitud menor. Además, necesitamos calcular la suma de Tr1 Tr2, los costos necesarios para convertir de O a O. La fórmula para calcular el costo de cada paso es la siguiente: i

$$Tr1\ \delta_{i+1} = \delta_i + O - O^{Tr2}_{i} \quad (10)$$

donde δ0 es igual a 0. Podemos obtener el costo total final, es decir, la distancia de Asserstein W es W = |δi |.

Aplicamos esta medida de distancia para calcular los desplazamientos de los puntos de trayectoria discretos. A diferencia de la divergencia KL [9], la distancia de Wasserstein es más adecuada para puntos de trayectoria distribuidos discretamente en una carretera. Cuando dos distribuciones se encuentran en una dimensión inferior En variedades sin solapamientos, la distancia de Wasserstein aún puede proporcionar una representación significativa y fluida de la distancia entre ellas. Nos referimos a la distancia calculada como el grado de variación VD.

Si VD es mayor que el umbral de valores atípicos de desplazamiento , esta carretera se identifica como una carretera cerrada debido a la fusión de carriles.

Machine Translated by Google

En la elección del umbral de valores atípicos de desplazamiento , utilizamos una combinación de etiquetado manual y búsqueda en sitios web para realizar pruebas. Teniendo en cuenta que el cierre de la carretera causado por la fusión de carriles suele ocurrir en los carriles anchos de doble sentido, la mayor parte de la conducción normal se incluye cuando el umbral es pequeño (es decir, la distancia de Wasserstein es pequeña). El mejor rendimiento se obtiene cuando el umbral se establece en 11, que es el valor que utilizamos para el umbral de valores atípicos de desplazamiento, como se ilustra en la Figura 14(b).

5.6 Experimento de ablación Finalmente,

realizamos un experimento de ablación en el que utilizamos tres características para la detección de cierres de carreteras: volumen de giros en carreteras con alta correlación, frecuencia de giros en U y desviación de la trayectoria. Como se muestra en la Tabla 1, se observa que la puntuación F1 mejora continuamente a medida que se añaden las características, lo que demuestra aún más la eficacia del experimento.

girando el volumen	Cambio de sentido	desplazamiento de la trayectoria	Puntuación F1
√			0,69
√	√		0,88
√	√	√	0,94

Tabla 1: Experimento de ablación

6. CONCLUSIÓN

En este artículo, proponemos un marco RCDM para detectar cierres de carreteras basado en múltiples características. RCDM se compone de una fase de modelado de características de cierre fuera de línea y una fase de detección de cierres de carreteras en línea. Para identificar los cierres de carreteras de manera eficiente, diseñamos una estrategia que primero identifica candidatos a cuadrícula cerrada y luego detecta los cierres de carreteras. Además, para mejorar la precisión de la detección, se aprovecha la técnica de aprendizaje profundo para predecir los valores de las características de cierre de carreteras en la fase de detección en línea. Se proponen un modelo combinado que consta de CNN y LSTM y un modelo combinado que consta de GCN y LSTM para capturar la dependencia espacio-temporal de la situación del tráfico a nivel de cuadrícula y a nivel de carretera, respectivamente . Los experimentos con conjuntos de datos reales demuestran la efectividad y eficiencia de RCDM. En el futuro, abordaremos más a fondo el problema de la anotación semántica para eventos de cierre de carreteras, para garantizar una alta calidad del servicio de navegación.

EXPRESIONES DE GRATITUD

Esta investigación fue financiada por la NSFC (números 62072180, U1911203 y U1811264).

REFERENCIAS

[1] Pingfu Chao, Wen Hua y Xiaofang Zhou. 2020. Las trayectorias saben dónde falla el mapa: un marco iterativo para la cooptimización de mapas y trayectorias. World Wide Web 23, 1 (2020), 47–73.

[2] Sanjay Chawla, Yu Zheng y Jiafeng Hu. 2012. Inferencia de la causa raíz en anomalías del tráfico rodado. En ICDM. IEEE Computer Society, 141–150.

[3] Chao Chen, Daqing Zhang, Pablo Samuel Castro, Nan Li, Lin Sun, Shijian Li y Zonghui Wang. 2013. iBOAT: Detección de trayectorias anómalas en línea basada en aislamiento . IEEE Trans. Intell. Transp. Syst. 14, 2 (2013), 806–818.

[4] Martin Ester, Hans-Peter Kriegel, Jörg Sander y Xiaowei Xu. 1996. Un algoritmo basado en densidad para descubrir clústeres en grandes bases de datos espaciales con ruido. En KDD. Prensa AAAI, 226–231.

[5] Sepp Hochreiter y Jürgen Schmidhuber. 1997. Memoria a largo plazo. Neural Comput. 9, 8 (1997), 1735–1780.

[6] HJ van Zuylen JWC van Lint, SP Hoogendoorn, SP Hoogendoorn y Hjv Zuylen. [s.f.]. Predicción del tiempo de viaje en autopista con redes neuronales de espacio de estados: modelado de la dinámica del espacio de estados con redes neuronales recurrentes. Transportation Research Record Journal of the Transportation Research Board 1811, 1 ([s.f.]), 347–369.

[7] Thomas N. Kipf y Max Welling. 2017. Clasificación semisupervisada con redes neuronales convolucionales gráficas. En ICLR (póster). OpenReview.net.

[8] Kuang, Weiming, An y Shi. 2015. Detección de anomalías de tráfico en áreas urbanas utilizando datos GPS de taxis. Problemas matemáticos en ingeniería (2015).

[9] Ska Leibler. 1951. Sobre la información y la suficiencia. Anales de matemáticas Estadísticas 22, 1 (1951), 79–86.

[10] Yaguang Li, Rose Yu, Cyrus Shahabi y Yan Liu. 2018. Red neuronal recurrente convolucional de difusión: pronóstico de tráfico basado en datos. En ICLR (póster). OpenReview.net.

[11] Wei Liu, Yu Zheng, Sanjay Chawla, Jing Yuan y Xing Xie. 2011. Descubrimiento de interacciones causales espacio-temporales en flujos de datos de tráfico. En KDD. ACM, 1010–1018 .

[12] Huaishao Luo, Chuishi Meng, Bowen Wu, Junbo Zhang, Tianrui Li y Yu Zheng. 2020. ReAD: Un marco de detección de anomalías regionales basado en partición dinámica. CoRR abs/2007.06794 (2020).

[13] Jiali Mao, Tao Wang, Cheqing Jin y Aoying Zhou. 2017. Detección de valores atípicos basada en agrupamiento de características en trayectorias de transmisión. IEEE Trans. Knowl. Data Eng. 29, 12 (2017), 2696–2709.

[14] Adriana Simona Mihaita, Haowen Li y Marian-Andrei Rizoiu. 2020. Detección y predicción de anomalías de congestión de tráfico mediante aprendizaje profundo. CoRR abs/2006.13215 (2020).

[15] Paul Newson y John Krumm. 2009. Emparejamiento de mapas ocultos de Markov mediante Ruido y escasez. En SIG. ACM, 336–343.

[16] Linsey Xiaolin Pang, Sanjay Chawla, Wei Liu y Yu Zheng. 2013. Sobre la detección de patrones de tráfico anómalos emergentes utilizando datos GPS. Data Knowl. Eng. 87 (2013), 357–373.

[17] Davide Pietrobon, Andrew P. Lewis y Gavin S. Heverly-Coulson. 2019. Un algoritmo para la detección de cierres de carreteras a partir de datos de sondas vehiculares. ACM Trans. Sistemas de algoritmos espaciales 5, 2 (2019), 12:1–12:13.

[18] F. Rui, Z. Zuo y L. Li. 2016. Uso de métodos de redes neuronales LSTM y GRU para la predicción del flujo de tráfico. En 2016 31.ª Conferencia Anual Académica Juvenil de la Asociación China de Automatización (YAC).

[19] J. Schmidhuber. 2001. Flujo de gradiente en redes recurrentes: la dificultad de aprender dependencias a largo plazo. Flujo de gradiente en redes recurrentes: la dificultad de aprender dependencias a largo plazo.

[20] Youngjoo Seo, Michaël Defferrard, Pierre Vandergheynst y Xavier Bresson. 2018. Modelado de secuencias estructuradas con redes recurrentes convolucionales de grafos . En ICONIP (1) (Lecture Notes in Computer Science), Vol. 11301. Springer, 362–373.

[21] Rade Stanojevic, Sofiane Abbar, Saravanan Thirumuruganathan, Gianmarco De Francisci Morales, Sanjay Chawla, Fethi Filali y Ahid Aleimat. 2018. Fusión de redes viales para actualizaciones incrementales de mapas. En LBS (Lecture Notes in Geoinformation and Cartography). Springer, 91–109.

[22] Yin Wang, Xuemei Liu, Hong Wei, George Forman, Chao Chen y Yanmin Zhu. 2013. CrowdAtlas: mapas autoactualizables para uso personal y en la nube. En MobiSys. ACM, 27–40.

[23] Lilian Weng. 2019. De GAN a WGAN. CoRR abs/1904.08994 (2019).

[24] Yuankai Wu y Huachun Tan. 2016. Pronóstico del flujo de tráfico a corto plazo con correlación espacio-temporal en un marco de aprendizaje profundo híbrido. CoRR abs/1612.01022 (2016).

[25] Huaxiu Yao, Xianfeng Tang, Hua Wei, Guanjie Zheng y Zhenhui Li. 2019. Revisión de la similitud espacio-temporal: un marco de aprendizaje profundo para la predicción del tráfico. En AAAI. AAAI Press, 5668–5675.

[26] Huichu Zhang, Yu Zheng y Yong Yu. 2018. Detección de anomalías urbanas mediante múltiples fuentes de datos espaciotemporales. Proc. ACM Interact. Mob. Wearable Ubiquitous Technol. 2, 1 (2018), 54:1–54:18.

[27] Jiani Zhang, Xingjian Shi, Junyuan Xie, Hao Ma, Irwin King y Dit-Yan Yeung. 2018. GaAN: Redes de atención controlada para el aprendizaje en grafos grandes y espaciotemporales. En UAI. AUAI Press, 339–349.

[28] Junbo Zhang, Yu Zheng y Dekang Qi. 2017. Redes residuales espaciotemporales profundas para la predicción de flujos de multitudes en toda la ciudad. En AAAI. AAAI Press, 1655–1661.

[29] Ling Zhao, Yujiao Song, Chao Zhang, Yu Liu, Pu Wang, Tao Lin, Min Deng y Haifeng Li. 2020. T-GCN: Una red neuronal convolucional de grafos temporales para la predicción del tráfico. IEEE Trans. Intell. Transp. Syst. 21, 9 (2020), 3848–3858.

[30] Yu Zheng, Huichu Zhang y Yong Yu. 2015. Detección de anomalías colectivas a partir de múltiples conjuntos de datos espaciotemporales en diferentes dominios. En SIGSPATIAL/GIS. ACM, 2:1–2:10.

[31] Yanmin Zhu, Yin Wang, George Forman y Hong Wei. 2015. Minería de flujos GPS a gran escala para el refinamiento de la conectividad de mapas de carreteras. Comput. J. 58, 9 (2015), 2109–2119.

Machine Translated by Google

APÉNDICES

Descripción de los símbolos
V el vértice incluye todas las carreteras
E el borde representa la relación de accesibilidad de la carretera
M El mapa de carreteras se representa como un gráfico.
Trazar la trayectoria
ciudad el punto de posición
G la cuadrícula
GC, el candidato a red cerrada
DA el área de detección
M(da) el mapa de ruta del área de detección
CS la fuerza de correlación entre caminos sucesivos
VC la carretera cerrada
T Fh el flujo de tráfico por hora de cada cuadrícula
RUh la frecuencia horaria de los giros en U de cada carretera
TVh el volumen de tráfico por hora de cada carretera
La secuencia de carreteras coincide con el resultado

Tabla 2: Resumen de notaciones

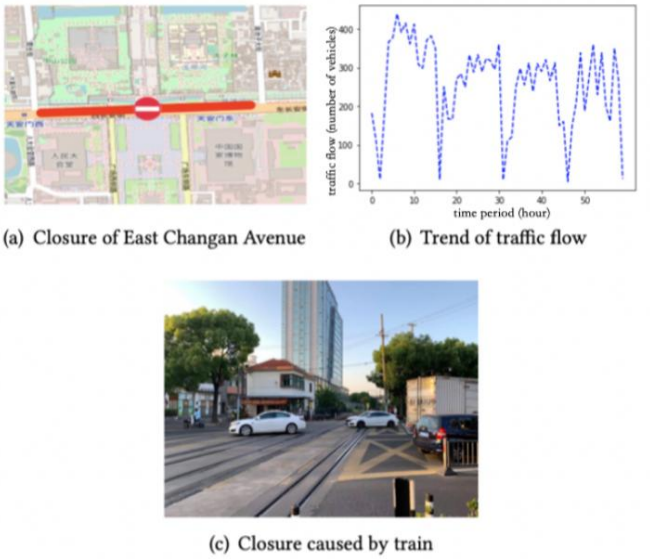


Figura 13: Cierre periódico

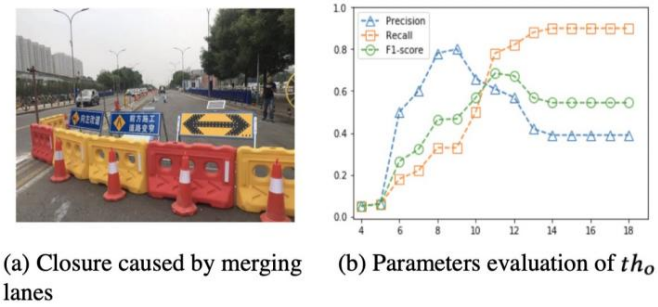


Figura 14: Cierre provocado por la fusión de carriles y parámetros evaluación