Machine Translated by Google

sensores

MDPI

Artículo

Detección de anomalías en el tráfico rodado mediante asistencia de la atención humana. Aprendizaje de texto y visión

Yachuang Chai 1,* y Wushouer Silamu 1,2

1 Facultad de Informática y Tecnología, Universidad de Xinjiang, Urumqi 830046, China
2 Laboratorio Clave de Tecnología de la Información Multilingüe de Xinjiang, Urumqi 830046, China
* Correspondencia: cyc@stu.xju.edu.cn

Abstracto

Con el rápido desarrollo de la sociedad, el número de vehículos en carretera ha aumentado significativamente, lo que ha conllevado una creciente gravedad de los accidentes de tráfico. La detección oportuna y precisa de anomalías o accidentes de tráfico es crucial para reducir las víctimas mortales y aliviar la congestión del tráfico. Por consiguiente, la detección de anomalías de tráfico se ha convertido en un punto central de la investigación en los últimos años. Con la ayuda de tecnologías informáticas como el aprendizaje profundo, los investigadores han desarrollado métodos más precisos y eficaces para detectar anomalías de tráfico. Sin embargo, la pequeña proporción de áreas propensas a anomalías en los fotogramas de vídeo de vigilancia, junto con los patrones complejos y difíciles de capturar de los accidentes, plantea nuevos desafíos para la aplicación de modelos profundos a la detección de anomalías de tráfico desde una perspectiva de vigilancia. En vista de esto, este artículo anota el conjunto de datos TADS que propusimos anteriormente, un método popular de aprendizaje de representación de vídeo asistido por texto , para desarrollar un método de detección más eficiente. Utilizando el conocido modelo de vídeo-texto CLIP, hemos desarrollado un modelo de detección que aprovecha los datos únicos de anotación de texto y seguimiento ocular del conjunto de datos TADS para aprender representaciones de anomalías de forma más eficaz, mejorando así la detección de anomalías en el tráfico rodado desde una perspectiva de vigilancia. Los resultados experimentales demuestran la superioridad de nuestro modelo para detectar anomalías en el tráfico desde una perspectiva de vigilancia, así como la utilidad de los datos de texto y seguimiento ocular incluidos en el conjunto de datos.

Palabras clave: detección de anomalías de tráfico; aprendizaje multimodal; vídeo de vigilancia de tráfico; detección de anomalías de vídeo

1. Introducción

Con el continuo desarrollo de la sociedad, el número de vehículos de carretera ha aumentado constantemente, lo que ha provocado un incremento significativo de los accidentes de tráfico. Estos accidentes se han convertido en una gran preocupación para el desarrollo social y representan graves amenazas para la vida humana. En los últimos años, numerosos expertos y académicos han avanzado en la investigación sobre la detección de accidentes de tráfico. Sin embargo, influenciados por el creciente campo de la conducción inteligente, la mayoría de los estudios se han centrado principalmente en la perspectiva del conductor [1–3]. Aunque el uso de equipos de monitorización de carreteras se ha generalizado y las tecnologías de computación inteligente han logrado avances significativos, la investigación sobre la detección de accidentes desde una perspectiva de vigilancia sigue siendo relativamente escasa en comparación con la que se realiza desde la perspectiva del conductor. La detección oportuna de accidentes de tráfico en una amplia gama de perspectivas de vigilancia puede facilitar medidas de respuesta inmediatas, como el bloqueo de las carreteras afectadas y el envío de equipos médicos y de rescate. Estas respuestas son crucia

Check for updates

Editor académico: Qiuqi Ruan

Recibido: 12 de marzo de 2026

Revisado: 17 de abril de 2026

Aceptado: 20 de abril de 2026

Publicado: 24 de abril de 2026

Derechos de autor: © 2026 por los autores.
Titular de la licencia: MDPI, Basilea, Suiza.

Este artículo es de acceso abierto.
distribuido bajo los términos y
condiciones de Creative Commons
Licencia de atribución (CC BY).

Machine Translated by Google

congestión de tráfico y reducción de víctimas. Por lo tanto, avanzar en la investigación sobre detección de accidentes de tráfico desde perspectivas de vigilancia es de gran importancia. Sin embargo, no es apropiado aplicar directamente el método de detección desde la perspectiva de conducción a la perspectiva de vigilancia, porque existen diferencias notables en la información visual bajo ambas perspectivas. Por ejemplo, las escenas de tráfico desde perspectivas de vigilancia suelen mostrar un fondo fijo, mientras que las perspectivas de conducción se caracterizan por cambios constantes en el entorno del vehículo central. Además, el área de un accidente de tráfico desde una perspectiva de vigilancia generalmente ocupa una región espacial más pequeña dentro de todo el encuadre de la cámara, mientras que los accidentes desde una perspectiva de conducción a menudo cubren un área más grande y pueden presentar fluctuaciones significativas o incluso temblores, particularmente en accidentes que involucran al propio vehículo. En consecuencia, para promover la investigación sobre detección de accidentes desde perspectivas de vigilancia, propusimos un conjunto de datos de accidentes de tráfico a gran escala, TADS, en nuestro artículo [4].

Este conjunto de datos no solo consta de un volumen considerable y una amplia variedad de tipos de accidentes, sino también de datos de seguimiento ocular cuyo tamaño es equivalente al de los fotogramas de vídeo. Cabe destacar que existe una ligera diferencia entre anomalías y accidentes de tráfico según [5], y este artículo no profundizará en las diferencias detalladas entre ambos. Por lo tanto, en este documento, el término «accidentes de tráfico» se refiere a «anomalías de tráfico», cuyo objetivo es detectar ventanas temporales de anomalías de tráfico que contengan escenas de accidentes.

Actualmente, los métodos para detectar anomalías en el tráfico desde una perspectiva de vigilancia se pueden clasificar en dos tipos principales según el número de modalidades: métodos de modalidad visual única y métodos de representación multimodal. Los métodos de modalidad visual única se basan exclusivamente en datos de vídeo para entrenar los modelos, sin proporcionar datos de otras modalidades.
Estos modelos detectan fotogramas anómalos en el conjunto de prueba aprovechando las diferencias de representación visual entre los fotogramas anómalos y los fotogramas normales presentes en el conjunto de entrenamiento, de forma similar a la detección universal de anomalías en vídeo. Sin embargo, es importante señalar que los objetivos de detección en la detección de anomalías en vídeo [6] son más amplios que los de la detección de anomalías en el tráfico rodado, por lo que es posible que no capture adecuadamente las características únicas de las anomalías en el tráfico rodado. Si bien los métodos de detección de anomalías en vídeo pueden utilizarse para análisis comparativos con los métodos de detección de anomalías en el tráfico rodado, no son adecuados para su aplicación directa en la detección de anomalías en el tráfico rodado.

En los últimos años, se han propuesto numerosos modelos preentrenados de lenguaje visual [7–11] , que han logrado resultados notables en tareas visuales aprovechando el conocimiento del lenguaje natural , como la clasificación de imágenes [12], la detección de objetos [13,14], la segmentación semántica [15,16] y la recuperación de imágenes [17,18], y en el dominio del vídeo, como el reconocimiento de vídeo [19,20], la recuperación de vídeo [21,22], etc. Entre estos modelos, el modelo CLIP [23] destaca como un representante significativo, sobresaliendo en varias tareas visuales a través de la alineación semántica entre textos e imágenes. Para la tarea de detección de anomalías de tráfico, la introducción de la modalidad de texto permite a los modelos aprender mejor información clave sobre anomalías de tráfico a partir de un gran volumen de datos visuales complejos [24–27], mejorando así la precisión de la detección de anomalías. Sin embargo, la investigación sobre la detección de anomalías de tráfico desde una perspectiva multimodal textual-visual sigue siendo insuficiente, como lo demuestra el artículo [27], que, basado en el modelo CLIP, alinea datos visuales con datos textuales correspondientes desde la perspectiva de la conducción para detectar anomalías en el tráfico rodado. No obstante, como se mencionó anteriormente, existen diferencias significativas entre los datos de anomalías de tráfico desde las perspectivas de vigilancia y conducción. Por lo tanto, sigue siendo necesario explorar y validar si el modelo CLIP podría mejorar sus capacidades de aprendizaje con respecto a los datos de anomalías de tráfico desde una perspectiva de vigilancia mediante la incorporación de información textual, y si los datos de seguimiento ocular desde una perspectiva de vigilancia podrían ayudar al modelo visual-lingüístico a mejorar sus capacidades de representación para la detección de anomalías de tráfico.

Machine Translated by Google

Basándose en el análisis anterior, este artículo proporciona en primer lugar anotaciones textuales del conjunto de datos de anomalías del tráfico rodado propuesto anteriormente desde una perspectiva de vigilancia, TADS [4]. En detalle, para que el modelo aprenda mejor las diferencias entre vídeos anómalos y normales con ayuda de texto, anotamos cada segmento de vídeo en TADS con dos tipos de descripciones de texto: una para las ventanas de tiempo antes de que comience la anomalía (parte de vídeo normal) y otra para las ventanas de tiempo durante las cuales ocurre la anomalía (parte de vídeo anómala). Además, construimos dos mecanismos para el aprendizaje asistido por texto: de grano grueso y de grano fino. Asimismo, basándonos en el modelo CLIP, proponemos un nuevo método para detectar anomalías en el tráfico rodado desde una perspectiva de vigilancia utilizando datos multimodales visuales y lingüísticos. En general, este método codifica los fotogramas de vídeo y el texto correspondiente utilizando el modelo CLIP, luego realiza una fusión temporal de las características de los fotogramas de vídeo y, finalmente, calcula la pérdida contrastiva entre las características de vídeo y sus características de texto correspondientes dentro de cada grupo. Por último, para investigar si se podrían introducir datos de seguimiento ocular para ayudar al aprendizaje del modelo, calculamos los mapas de atención cruzada entre el último fotograma (fotograma objetivo) y el texto correspondiente en cada grupo, asegurándonos de que estos mapas de atención se alineen con los mapas de seguimiento ocular correspondientes, incorporando así datos de seguimiento ocular para ayudar al aprendizaje del modelo.

Las principales contribuciones de este artículo son las siguientes: Se realizó la anotación de texto en el conjunto de datos de detección de accidentes de tráfico desde la perspectiva de vigilancia mencionado anteriormente, TADS. En concreto, se han anotado dos tipos de descripciones textuales para cada segmento de vídeo del conjunto de datos, que abarcan tanto la parte anterior a la anomalía como la parte posterior, para proporcionar información textual que facilite el aprendizaje de la representación del modelo. Basándonos en el modelo CLIP y el conjunto de datos TADS con anotaciones textuales, hemos desarrollado un método para detectar anomalías en el tráfico rodado desde la perspectiva de la vigilancia. Este método incorpora la fusión temporal al modelo CLIP original, lo que permite su uso para el aprendizaje de la representación de vídeos de anomalías de tráfico en la vigilancia vial de forma multimodal visual-textual. Además, mediante la introducción de un mecanismo de atención cruzada vídeo-texto, exploramos si los datos de seguimiento ocular del conjunto de datos TADS pueden mejorar la capacidad de aprendizaje de la representación del modelo.

El resto de este artículo se organiza de la siguiente manera: la Sección 2 revisa trabajos relacionados con la detección de anomalías en el tráfico rodado; la Sección 3 describe los pasos específicos involucrados en la anotación de texto del conjunto de datos TADS; la Sección 4 describe la estructura específica del modelo de detección propuesto en este artículo; la Sección 5 compara el rendimiento de detección de nuestro método con otros métodos de uso común y valida la efectividad de cada componente de nuestro modelo a través de experimentos de ablación, e introduce algunas discusiones sobre la velocidad de inferencia del modelo; la Sección 6 concluye el artículo y analiza las investigaciones relacionadas que podemos emprender en el futuro.

2. Trabajos relacionados

2.1. Métodos de detección de anomalías en el tráfico rodado

El objetivo principal de la detección de anomalías en el tráfico rodado es proporcionar alertas en tiempo real sobre anomalías o accidentes detectados en vídeos de vigilancia. Debido a la similitud conceptual entre la detección de anomalías en vídeo y la detección de anomalías en el tráfico rodado, se han empleado numerosos métodos de detección de anomalías en vídeo para la detección de anomalías en el tráfico r

Los métodos comunes aplicables para la detección de anomalías en el tráfico rodado incluyen métodos de clasificación supervisada y métodos de detección de anomalías en vídeo no supervisados. Los métodos de clasificación supervisada categorizan directamente los fotogramas anómalos o de accidentes y los fotogramas normales o sin accidentes en un vídeo como dos clases distintas, entrenando el modelo utilizando principios de clasificación binaria tradicionales. Por ejemplo, Nejdet Dogru et al. [28] utilizaron datos de posición y velocidad del vehículo, empleando redes neuronales artificiales, máquinas de vectores de soporte (SVM) y bosques aleatorios para detectar accidentes. Wei Wang et al. [29] llevaron a cabo experimentos

Machine Translated by Google

Validación de la detección de accidentes mediante regresión de mínimos cuadrados parciales (PLSR) y máquinas de vectores de soporte (SVM) en el conjunto de datos de la autopista I-880 en California. La mayoría de estos métodos de detección adoptan un enfoque relativamente directo y estructuras de modelos simples, comparando únicamente las dos categorías de fotogramas con accidentes y fotogramas sin accidentes presentes en el conjunto de datos. En consecuencia, sus capacidades de representación son limitadas, lo que resulta en un rendimiento de detección relativamente subóptimo.

Los métodos de detección de anomalías de vídeo no supervisados suelen implementarse utilizando modelos autoencoder, que se entrenan para reconstruir datos normales en el conjunto de entrenamiento e identificar datos anómalos que se desvían de la distribución normal de datos en el conjunto de prueba. Debido a la proximidad de la detección de anomalías de tráfico a la detección de anomalías de vídeo, este enfoque también puede aplicarse a la detección de anomalías de tráfico rodado. Por ejemplo, Liu W. et al. [30] consideraron las características espaciotemporales de fotogramas de vídeo consecutivos, empleando entrenamiento adversario para predecir fotogramas de vídeo e identificando como anómalos los fotogramas que se desvían significativamente de los fotogramas predichos. Este método se verificó en varios conjuntos de datos de vídeo de vigilancia de uso común. Chong et al. [31] emplearon ConvLSTM para extraer características espaciotemporales de datos de vídeo. Entrenaron un autoencoder en segmentos de vídeo normales y posteriormente lo aplicaron para detectar anomalías en vídeos que contenían segmentos anómalos, aprovechando las ventajas y características de la detección no supervisada. Estos métodos de detección de anomalías en vídeo sin supervisión presentan ventajas como un procesamiento rápido y menores requisitos de anotación de datos (la mayoría solo requiere fotogramas de vídeo normales para el entrenamiento). Sin embargo, basarse en el error de reconstrucción para determinar si un resultado es anómalo suele generar una alta tasa de falsos positivos. Además, este enfoque de entrenamiento sin supervisión tiene dificultades para aprender las características únicas de tipos específicos de anomalías (como los accidentes de tráfico), lo que afecta seriamente la precisión de detección del modelo en aplicaciones prácticas.

2.2. Aprendizaje multimodal de texto visual para la detección de anomalías en vídeo

En los últimos años, el aprendizaje multimodal de texto visual [7–10] ha alcanzado un éxito significativo en diversas tareas visuales, como la clasificación de imágenes, la detección de objetos, la segmentación semántica y la recuperación de imágenes. En consecuencia, muchos investigadores han realizado estudios sobre tareas visuales utilizando modelos preentrenados de texto visual. Actualmente, el modelo CLIP [23] destaca como un modelo preentrenado importante que logra la alineación semántica entre datos visuales y textuales al contrastar una gran cantidad de pares imagen-texto. Numerosos investigadores han realizado estudios exhaustivos sobre diversas tareas relacionadas con lo visual basándose en este modelo similar a CLIP.

M. Wang et al. [32] formularon el reconocimiento de acciones de video como un problema de coincidencia de video-texto y propusieron ActionCLIP, que emplea aprendizaje multimodal para permitir el reconocimiento de acciones de cero disparos. H. Luo et al. [33] introdujeron CLIP4Clip, que transfiere el conocimiento aprendido del modelo CLIP de manera de extremo a extremo para abordar tareas de recuperación de lenguaje de video. W. Wu et al. [19] aprovecharon el conocimiento de grandes modelos preentrenados de lenguaje visual de código abierto para abordar tareas de reconocimiento de video. Este tipo de estudios demuestran que los grandes modelos preentrenados de lenguaje visual, debido a su incorporación de conocimiento asociativo esencial de lenguaje visual, ayudan significativamente a las tareas posteriores relacionadas con lo visual. Como resultado, algunos investigadores han comenzado a explorar si estos modelos preentrenados de lenguaje visual también podrían ayudar en tareas de detección de anomalías de video [24–26]. P. Wu et al. [34] propusieron VadCLIP, que utiliza plenamente las asociaciones de grano fino entre datos visuales y textuales inherentes al modelo CLIP, diseñando una estructura de detección de doble rama para la detección de anomalías de vídeo débilmente supervisada. Los resultados experimentales en dos conjuntos de datos públicos indican que VadCLIP logra un rendimiento óptimo tanto en la detección de anomalías de vídeo débilmente supervisada de grano grueso como de grano fino . Rongqin Liang et al. [27] desarrollaron TTHF basado en el modelo CLIP, centrándose en la detección de anomalías de tráfico desde la perspectiva del conductor, evaluando la correlación entre características visuales y textu

Machine Translated by Google

Si bien se están aplicando modelos preentrenados a tareas de detección de anomalías en vídeo, el uso cada vez mayor del modelo CLIP en importantes tareas visuales posteriores aún no ha dado lugar a una investigación significativa que aproveche las asociaciones entre datos textuales y visuales para la detección de anomalías en el tráfico, especialmente en el contexto de escenarios de vigilancia. Todavía es necesario investigar si los modelos preentrenados de lenguaje visual podrían contribuir a la detección de anomalías en el tráfico rodado desde la perspectiva de la vigilancia y cómo diseñar métodos de detección que aprovechen mejor estos modelos para una detección eficaz de anomalías en el tráfico en dichos contextos.

3. Anotación de texto en el conjunto de datos TADS

Para aprovechar mejor el conocimiento asociativo entre datos visuales y textuales, aprendido a partir de modelos preentrenados visuales y textuales, para distinguir fotogramas con anomalías de tráfico de fotogramas normales en vídeos, este artículo introduce anotaciones textuales para el conjunto de datos de detección de anomalías de tráfico desde la perspectiva de vigilancia mencionado anteriormente, TADS [4]. La información de las anotaciones textuales se proporciona en dos niveles de granularidad: grueso y fino.

Anotaciones de texto de grano grueso: Con el objetivo de distinguir entre fotogramas con anomalías de tráfico y fotogramas normales en el vídeo, estos últimos , junto con sus descripciones de texto correspondientes, se alinean dentro del conjunto de datos. Dado que este tipo de descripción de texto tiene como único fin diferenciar entre anomalías de tráfico y condiciones normales, y no está específicamente relacionada con una escena de tráfico concreta del vídeo, se denomina anotación de texto de grano grueso. Para mayor brevedad, véase el artículo [27].

Las descripciones de texto de grano grueso utilizadas en este documento constan de los dos tipos siguientes:

(1) Descripción de la anomalía de tráfico: “Se produjo una anomalía de tráfico en la escena”. Para alinear las representaciones de vídeo anómalas con las representaciones de texto durante el proceso de entrenamiento, todas las características de los vídeos de anomalías de tráfico se alinean con las características de texto de esta frase.

(2) Descripción de escena normal: “El tráfico en este escenario es normal”. Para alinear las representaciones de vídeo normales con las representaciones de texto durante el proceso de entrenamiento, todas las características de los vídeos anteriores a la aparición de cualquier anomalía en el tráfico se alinean con las características de texto de esta frase.

Al emplear este enfoque de configuración y alineación de texto, el modelo puede centrarse en las diferencias en las representaciones de vídeo entre anomalías de tráfico y escenarios normales, logrando así una distinción general entre anomalías de tráfico y normalidad.

Anotaciones de texto de grano fino: Si bien las anotaciones de texto de grano grueso mencionadas anteriormente facilitan la diferenciación básica entre anomalías de tráfico y escenas de tráfico normales, adolecen de la limitación de una sola descripción de texto (ya que todos los datos de vídeo del conjunto de datos corresponden únicamente a estas dos frases). Esta falta de diversidad en las descripciones de texto dificulta la capacidad del modelo para aprender los ricos contextos semánticos presentes en los vídeos. Por lo tanto, para ayudar al modelo a aprender la abundante información visual contenida en los extensos datos de vídeo del conjunto de datos, y para verificar si esta rica información visual ayuda al modelo a distinguir entre anomalías de tráfico y normalidad con la ayuda de los textos, este artículo anota cada segmento de los vídeos de entrenamiento del conjunto de datos con dos tipos de descripciones de texto: una para la escena normal (la parte del vídeo anterior a la aparición de la anomalía de tráfico) y otra para la anomalía de tráfico (la parte del vídeo desde el principio hasta el final de la anomalía de tráfico). Dado que estas descripciones textuales detallaban la información específica de la escena de tráfico para cada segmento de vídeo y se correspondían directamente con cada uno de ellos, se las denomina anotaciones textuales detalladas. Es importante destacar que las descripciones detalladas de escenas normales no incluyen términos relacionados con anomalías de tráfico . En la Figura 1 se muestran ejemplos de anotaciones textuales detalladas y de grano grueso .

https://doi.org/10.3390/s26092638

Machine Translated by Google



Figura 1. Ejemplos de anotaciones de texto de grano grueso y grano fino. Nota: Los textos en chino en los recuadros representan información relacionada con la cámara de vigilancia o la escena específica.

Siguiendo este enfoque y configuración de anotación de texto, este artículo ha proporcionado al conjunto de datos TADS un total de 1448 descripciones de texto detalladas, que comprenden 648 descripciones de escenas de tráfico normales y 800 descripciones de anomalías de tráfico. Es importante señalar que el número de descripciones de escenas normales no es igual al número de descripciones de anomalías de tráfico , ya que algunos segmentos de vídeo no incluyen una parte de la escena de tráfico normal previa a la aparición de la anomalía. Además, hay dos descripciones de texto de grano grueso , lo que da como resultado un total de 1450 anotaciones de texto.

Entre las 1450 anotaciones de texto, la longitud de las oraciones y el vocabulario utilizado se determinan a partir de las escenas reales capturadas en los segmentos de vídeo del conjunto de datos TADS. Con base en esto, este artículo analiza estadísticamente la longitud de las oraciones (representada por el número de palabras) y la distribución de las palabras de alta frecuencia en las 1450 anotaciones de texto, como se ilustra en la Figura 2. Para su análisis estadístico, se seleccionaron las 10 oraciones y palabras de mayor frecuencia con mayor frecuencia de ap

La parte izquierda de la Figura 2 muestra la distribución estadística de la longitud de las oraciones en los textos anotados. En la leyenda, la oración de longitud 9 corresponde al área azul en la esquina superior derecha del gráfico circular, que representa el 19%, y así sucesivamente en sentido horario. La parte derecha de la Figura 2 muestra la distribución estadística de la frecuencia de las palabras en los textos anotados; cuanto mayor sea el área del círculo, mayor será la frecuencia de la palabra.

https://doi.org/10.3390/s26092638

Machine Translated by Google

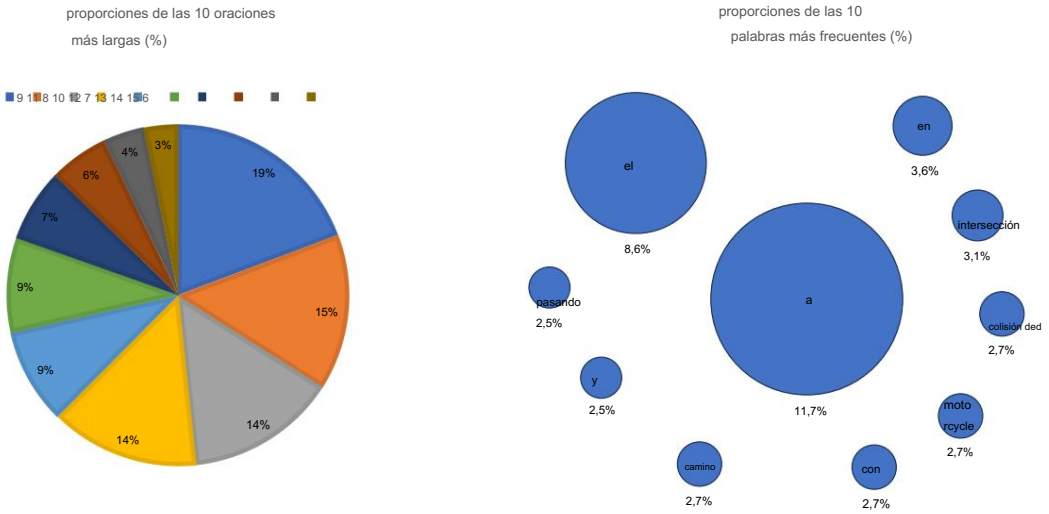


Figura 2. Distribución de la longitud de las oraciones y la frecuencia de las palabras anotadas en el conjunto de datos TADS.

4. El método de detección

Este artículo extrae vídeos y sus características textuales correspondientes utilizando principalmente el modelo preentrenado de lenguaje visual CLIP. A diferencia del modelo CLIP original, que procesa una sola imagen, el módulo de codificación visual de este artículo maneja fotogramas de vídeo continuos, por lo que realizamos algunas modificaciones para adaptarlo a nuestra aplicación específica en comparación con el CLIP original. En la Figura 3 se muestra una descripción general del modelo .

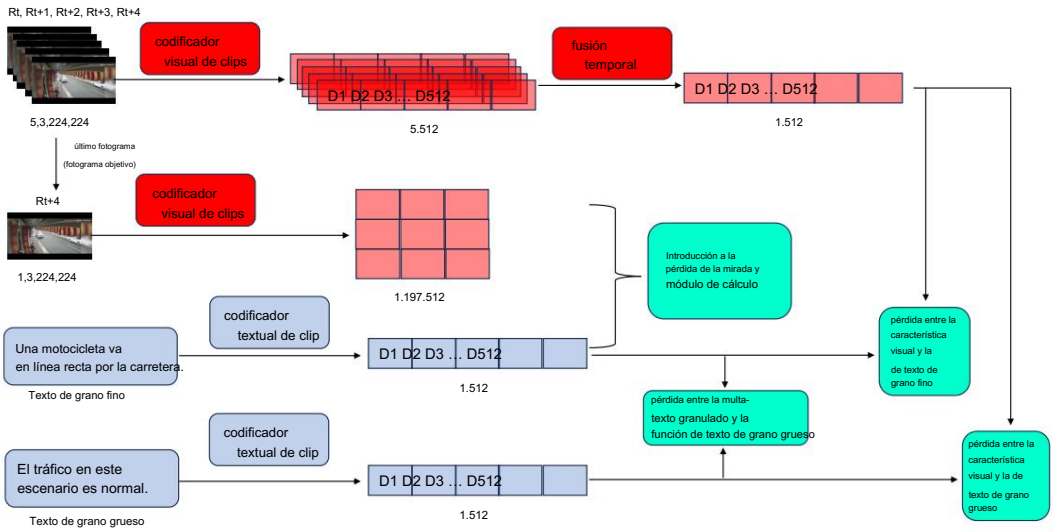


Figura 3. Descripción general de nuestro modelo de detección propuesto. Los números debajo de cada característica en la figura representan la información dimensional correspondiente.

4.1. Extracción de características multimodales

Específicamente, para una secuencia de cinco fotogramas de video consecutivos en el conjunto de datos Ft , Ft+1, Ft+2, Ft+3, Ft+4, se aplica el componente de codificación visual del modelo CLIP para obtener las características visuales $F_{t}, F_{t+1}, F_{t+2}, F_{t+3}, F_{t+4}$, respectivamente) para cada fotograma. correspondientes (F Dado que la entrada de video consiste en fotogramas de video continuos, las relaciones temporales entre estos fotogramas son cruciales. Este artículo emplea un enfoque de fusión basado en transformadores para integrar temporalmente las características de fotogramas consecutivos en el video de entrada [32], lo que da como resultado la representación final de características visuales E. Los experimentos de ablación presentados en la Sección 5.4 validan aún más la efectividad del módulo de fusión temporal. Para el componente de extracción de características de texto, los dos tipos de descripciones de texto (grano grueso y g

Machine Translated by Google

Los datos correspondientes al vídeo de entrada son procesados por la parte de codificación de texto de CLIP para obtener la característica de texto de grano grueso CG_t y la característica de texto de grano fino FG_t.

4.2. Introducción del mapa de seguimiento ocular

Dados los datos únicos de atención visual mediante la mirada que contiene el conjunto de datos TADS, este artículo exploró si estos datos visuales de atención visual podrían ayudar a alinear las características visuales y de texto, mejorando así el rendimiento del modelo en la detección de anomalías de tráfico.

Dado que los mapas de calor de atención visual representan las áreas de enfoque espacial de los observadores mientras ven videos de vigilancia, es lógico esperar que, para los fotogramas de video dentro del rango de anomalías de tráfico, las áreas de atención indicadas por los mapas de calor a menudo se superpongan con las regiones espaciales donde ocurren anomalías de tráfico o accidentes. Por el contrario, para los fotogramas de video anteriores al intervalo de anomalía de tráfico, es decir, el intervalo de escena normal, las áreas de atención en los mapas de calor generalmente no son significativas o no están relacionadas con el contexto de la anomalía de Para investigar si los datos de seguimiento ocular visual pueden mejorar el rendimiento de detección, este artículo define primero el último de los cinco fotogramas consecutivos como el "fotograma objetivo". Posteriormente, el "fotograma objetivo" y su texto de grano fino correspondiente se introducen en los módulos de codificación visual y textual del modelo CLIP para extraer la característica visual V_t y la característica textual de grano fino FG_t, respectivamente. La característica visual V_t obtenida se fusiona con la característica textual de grano fino FG_t correspondiente mediante un módulo de atención cruzada. Es importante señalar que este módulo de fusión de atención cruzada no está diseñado para mejorar la representación de la característica visual V_t en función de su relación con la característica textual de grano fino FG_t correspondiente; más bien, su objetivo es generar el mapa de atención cruzada G ′_t entre V_t y FG_t. Una vez obtenido el mapa de atención G ′_t correspondiente al fotograma objetivo, se puede calcular la pérdida entre el mapa de calor de la mirada G_t correspondiente al fotograma objetivo y el G ′_t mencionado anteriormente. Este proceso guía al modelo para que se centre en regiones específicas de anomalías de tráfico dentro de los fotogramas de vídeo durante el intervalo de anomalías de tráfico, explorando así la eficacia del mapa de calor de la mirada para mejorar el rendimiento de detección del modelo. Los detalles de la introducción del mapa de calor de la mirada se ilustran en la Figura 4.

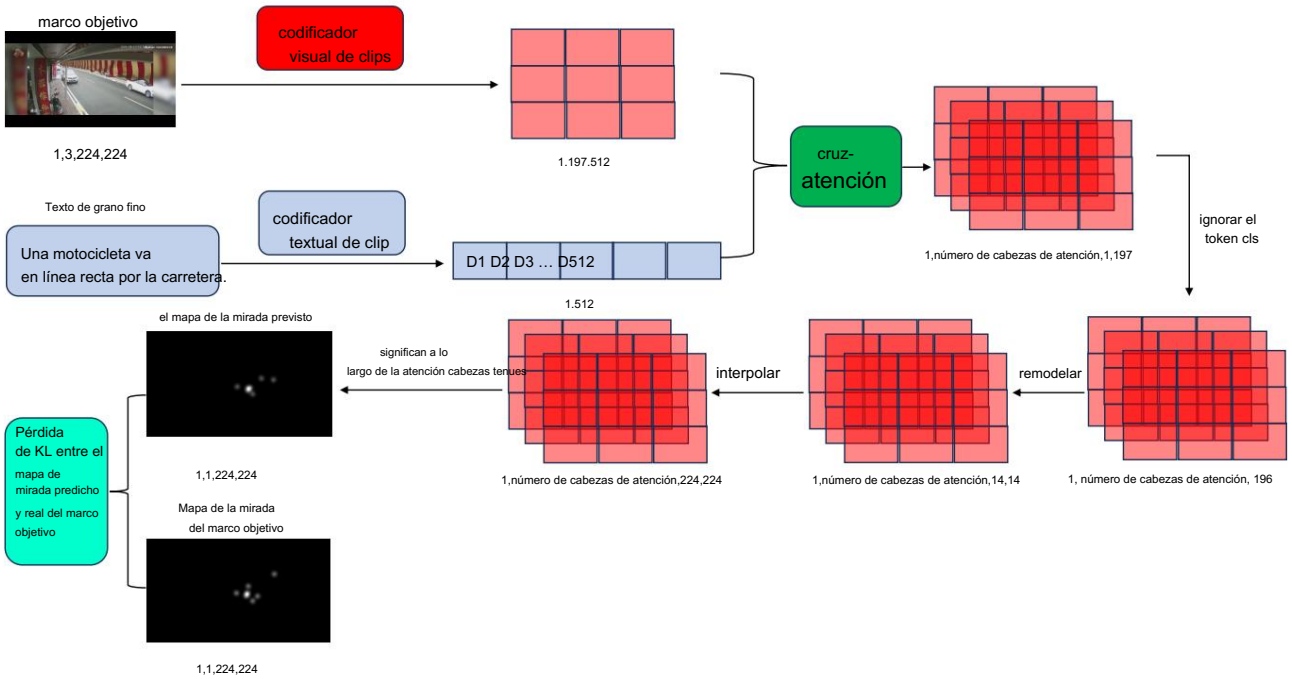


Figura 4. Diagrama de aprendizaje asistido por seguimiento ocular. Los números que aparecen debajo de cada elemento de la figura representan la información dimensional correspondiente.

Machine Translated by Google

4.3. Función de pérdida y discriminación de anomalías de tráfico

Nuestro método de detección consideró las relaciones entre las características visuales, las características de texto en diferentes granularidades y los mapas de atención de salida. En consecuencia, consideramos cuatro tipos de funciones de pérdida a continuación:

4.3.1. Pérdida entre características visuales y de texto de grano grueso

Después de derivar las características visuales E del video de entrada que consta de cinco fotogramas consecutivos y las características de texto de grano grueso correspondientes CG_t como se describe en la Sección 4.1, necesitamos alinear E con CG_t. Dado que solo hay dos tipos de textos de grano grueso, en esta situación, el mismo tipo de texto de grano grueso dentro del mismo lote puede corresponder a múltiples entradas de video diferentes. Por lo tanto, siguiendo el enfoque descrito en el artículo [32], empleamos la divergencia KL de Kullback-Leibler para alinear las características visuales E de diferentes videos de entrada dentro del mismo lote con sus características de texto de grano grueso CG_t correspondientes. Esta pérdida se puede expresar como

$$\text{pérdida} - \text{v2c} = \frac{1}{2} E(v,c) \quad D_{KL}\left(p^{\text{v2c}}(v), q^{\text{v2c}}(v)\right) + KL\left(p^{\text{c2v}}(c), q^{\text{c2v}}(do)\right) \tag{1}$$

4.3.2. Pérdida entre texto de grano fino y texto de grano grueso.

Dado que este documento utiliza textos tanto de grano grueso como de grano fino, diseñamos una función de pérdida que permite al módulo de extracción de características de texto aprender la diferencia semántica. Diferencias entre condiciones de tráfico anómalas y normales dentro de una misma modalidad de texto. Esta función de pérdida alinea las características de texto de grano fino con los dos tipos de características de texto de grano grueso.

De forma similar al enfoque descrito en la Sección 4.3.1, el mismo tipo de texto de grano grueso dentro del mismo lote puede corresponder a varios textos de grano fino diferentes, por lo que también empleamos la divergencia de Kullback-Leibler (KL) para alinear las características de texto de grano fino FG_t con sus correspondientes características de texto de grano grueso CG_t. Por lo tanto, el cálculo de esta pérdida es el siguiente:

$$\text{pérdida} - \text{f2c} = \frac{1}{2} E(f,c) \quad D_{KL}\left(p^{\text{f2c}}(c), q^{\text{c2f}}(f)\right) + KL\left(p^{\text{c2f}}(f), q^{\text{c2f}}(f)\right) \tag{2}$$

En las ecuaciones (1) y (2), v2c y f2c denotan la correspondencia entre las características visuales y textuales de grano grueso, y entre las características textuales de grano fino y grueso, respectivamente. D representa el conjunto de datos de entrenamiento completo, mientras que p y q representan los valores de similitud y la verdad fundamental empleados en el cálculo de alineación de las diferentes características, respectivamente.

4.3.3. Pérdida entre características visuales y de texto de grano fino

Las características visuales E de cinco fotogramas consecutivos del vídeo de entrada y las correspondientes características de texto de grano fino FG_t se derivan según el proceso descrito en la Sección 4.1. Posteriormente, consideramos alinear E con FG_t. Esta alineación permite que los módulos de extracción de características visuales y textuales comprendan mejor las relaciones semánticas entre los factores visuales y textuales en escenarios de tráfico. A diferencia del proceso descrito en las Secciones 4.3.1 y 4.3.2, cada texto detallado sirve como la única descripción de la entrada de vídeo correspondiente, por lo que, en este caso, cada característica visual E de los vídeos de entrada dentro del mismo lote se corresponde uno a uno con su respectiva característica de texto detallado FG_t .

Por lo tanto, haciendo referencia a la pérdida utilizada en el modelo CLIP original [23] donde las diferentes entradas se asignan a los diferentes textos de grano fino, empleamos la pérdida de entropía cruzada.

https://doi.org/10.3390/s26092638

Machine Translated by Google

función para alinear las características visuales E de diferentes videos de entrada dentro del mismo lote con sus características de texto finas FG_t. Por lo tanto, esta pérdida se puede expresar de la siguiente manera:

$$\text{pérdida} - \text{v2 f} = \frac{1}{2}\ \text{entropía cruzada f@v , etiquetas} + \text{entropía cruzada v@f , etiquetas} \quad (3)$$

En la ecuación (3) anterior, v2 f representa la correspondencia entre las características visuales y de texto de grano fino, y las etiquetas representan la verdad fundamental en el cálculo de alineación en la situación uno a uno.

4.3.4. Pérdida entre la atención y los mapas de seguimiento ocular

Los mapas de seguimiento ocular son componentes importantes del conjunto de datos TADS. Se obtienen registrando las áreas de enfoque ocular de múltiples observadores humanos mientras visualizan el conjunto de datos con un registrador de movimientos oculares, y luego se procesan mediante la operación de desenfoque gaussiano promedio. A diferencia del mecanismo de atención convencional, que trata los fotogramas de vídeo como anotaciones espaciales, los mapas de seguimiento ocular representan las áreas de enfoque de los observadores humanos y proporcionan información previa útil. Los detalles sobre los mapas de seguimiento ocular en el conjunto de datos se pueden encontrar en [4].

Para aprovechar los extensos datos de seguimiento ocular del conjunto de datos TADS, este artículo investiga si las regiones de estos mapas de seguimiento ocular pueden influir en la fusión de características visuales y textuales, mejorando así el rendimiento de detección del modelo. Como se menciona en la Sección 4.2, realizamos una fusión de atención cruzada entre las características visuales V_t del fotograma objetivo y las características de texto de grano fino FG_t correspondientes. Los mapas de atención multi-cabeza resultantes se convierten luego en el mapa de atención fusionado final G ′_t mediante interpolación, escalado y promediado en las operaciones de dimensión multi-cabeza. Finalmente, haciendo referencia a la investigación y las prácticas en la predicción de la atención [35], empleamos la pérdida de divergencia de Kullback-Leibler (KL) para aproximar el mapa de atención fusionado G ′_t con el mapa de seguimiento ocular de referencia G_t del fotograma objetivo correspondiente. Esto se puede expresar de la siguiente manera:

$$\text{pérdida} - \text{mirada G_t, G}'\text{_t} = \sum_{i} \text{G_t(i)log } \varepsilon + \varepsilon + \frac{\text{G_t(i)}}{\text{G}'\text{_t(i)}} \quad (4)$$

A diferencia del uso en [35], para simplificar el cálculo, solo utilizamos la divergencia KL, que se emplea para aproximar dos distribuciones, para aproximar los dos tipos de mapas. Así, en la ecuación (4), G_t y G ′_t representan el mapa de atención fusionado y la verdad fundamental, respectivamente. El índice de suma i abarca los píxeles de la imagen, y es una pequeña constante que garantiza la estabilidad numérica.

Basándonos en las fórmulas y la descripción anteriores, incluimos el pseudocódigo del núcleo de la implementación de nuestro método en el Algoritmo 1.

En el Algoritmo 1, los datos de entrada constan de cuatro tipos de datos , como se mencionó anteriormente: t fotogramas consecutivos del grupo de fotogramas de vídeo, los mapas de la mirada, textos de grano fino y textos de grano grueso correspondientes a los fotogramas objetivo. CLIP_visual, CLIP_text, temporal_fusion y cross_ttn_i2t en el pseudocódigo representan los módulos de codificación visual y de texto del modelo CLIP en este artículo, el módulo de fusión temporal para la representación temporal de grupos de fotogramas y el módulo de atención cruzada para fusionar características visuales y de texto , respectivamente. Obtenemos y remodelamos los mapas de atención mediante la función attn_transfer. Loss-v2c, loss-v2f, loss-f2c y KL-loss son las cuatro funciones de pérdida descritas en la Sección 4.3, que se ponderan y suman para obtener la pérdida de entrenamiento.

Machine Translated by Google

Algoritmo 1. El pseudocódigo del proceso de entrenamiento.

```
Requerido: frames_group;                                                    (b,t,c,h,w)
Requerido: gaze_map;                                                        (b,1,h,w)
Requerido: fine_grained_texts;                                              (b,77)
Requerido: textos_de_grano_grueso;                                          (b,77)
  para cada input_data en dataLoader hacer
    frame_target = frames_group[:, -1, :, :, :]   tomar el último fotograma como objetivo
    frame_emb_f, _ = CLIP_visual(frames_group) frame_emb
    = temporal_fusion(frame_emb_f) _, frame_emb_withpn =
    CLIP_visual(frame_target) coarse_emb =
    CLIP_text(coarse_grained_texts) fine_emb =
    CLIP_text(fine_grained_texts) fine_grained_out,
    the_atten = cross_attn_i2t(frame_emb_withpn, fine_emb) atten_calcul = attn_transfer(the_atten)
    loss_coarse = loss-v2c(frame_emb, coarse_emb)
    loss_fine = loss-v2f((frame_emb, fine_emb)) loss_coarse2fine
    = loss-f2c(fine_emb, coarse_emb) loss_gaze = KL-
    loss(gaze_map, atten_calcul) loss = weighted_sum(loss_coarse,
    loss_fine, loss_coarse2fine, loss_gaze) loss.train() fin para
```

4.3.5. Puntuación y discriminación de anomalías de tráfico

Durante la fase de inferencia/prueba, no hay descripciones de texto detalladas ni mapas de seguimiento ocular de los fotogramas objetivo en el vídeo de entrada. Por lo tanto, como se describe en la Sección 4.1, extraemos características del vídeo de entrada y realizamos una fusión temporal para obtener las características visuales E. A continuación, extraemos características de texto de dos frases de grano grueso que representan anomalías y normalidad del tráfico, respectivamente: «Se produjo una anomalía de tráfico en la escena» y «El tráfico en este escenario es normal». Estas dos frases dan como resultado un par de características de texto (a_t, n_t). Normalizamos las características E y el par de características de texto (a_t, n_t), y luego calculamos sus similitudes de coseno como (sim_a,sim_n) respectivamente. Finalmente, las similitudes de coseno (sim_a,sim_n) se convierten en el par (s_a,s_n) mediante la operación softmax . Aquí, s_a se considera la puntuación de anomalía de tráfico del fotograma objetivo en el vídeo de entrada. Los fotogramas objetivo con puntuaciones de anomalías de tráfico superiores a 0,5 se clasifican como fotogramas con tráfico anómalo. El proceso se puede representar de la siguiente manera:

$$(s_a,s_n) = F.\ softmax\ (\ similitud\ (E, a_t)\ ,\ similitud\ (E, n_t)) \quad (5)$$

5. Experimentos y análisis

5.1. Métricas de evaluación

Este artículo utiliza el Área Bajo la Curva (AUC) como principal métrica de evaluación. El AUC representa el área bajo la curva ROC (Receiver Operating Characteristic), que se calcula utilizando la matriz de confusión en todos los umbrales para obtener la tasa de verdaderos positivos (TPR) y la tasa de falsos positivos (FPR). Un área mayor bajo la curva ROC indica un AUC más alto para el modelo, lo que significa un mejor rendimiento. Además, cuando hay varios segmentos de vídeo en el conjunto de prueba, nos remitimos a [36] para adoptar dos tipos de métricas de AUC: el AUC calculado al concatenar todos los fotogramas en el conjunto de prueba se denomina "micro AUC", mientras que los valores de AUC calculados para cada segmento de vídeo, seguidos del promedio en todos los segmentos, se denominan "macro AUC". El uso de "micro AUC" y "macro AUC" puede proporcionar una evaluación más completa del rendimiento de detección del modelo.

Además del AUC, este artículo utiliza la precisión como métrica de evaluación. El valor de precisión se calcula como la proporción de fotogramas de vídeo de anomalías de tráfico que son clasificados correctamente por el modelo. El umbral de decisión se establece en 0,5 en nuestros experimentos, por lo que

Machine Translated by Google

Clasificar los fotogramas con puntuaciones de anomalías de tráfico superiores a 0,5 como fotogramas con anomalías de tráfico. Por lo tanto, la precisión de detección se define como la proporción de fotogramas detectados correctamente con respecto al número total de fotogramas en el conjunto de prueba, lo que se puede escribir de la siguiente manera:

$$\text{Precisión} = \frac{\text{Número de fotogramas detectados correctamente.}}{\text{número total de fotogramas en el conjunto de prueba.}} \quad (6)$$

5.2. Configuración experimental

Todos los experimentos realizados en este artículo se basaron en el sistema operativo Ubuntu 20.04, implementado con el marco PyTorch 1.10, con una GPU Nvidia 3090. Una secuencia de cinco fotogramas consecutivos de la misma categoría se combina en un grupo de fotogramas de vídeo de entrada, lo que significa que el fotograma objetivo (el último fotograma del grupo de fotogramas de vídeo) y los fotogramas precedentes pertenecen ambos a la normalidad del tráfico o ambos pertenecen a la anomalía del tráfico. Tanto los fotogramas de vídeo de entrada como los mapas de mirada se redimensionaron a 224 × 224 píxeles, con un tamaño de lote de 8. Se empleó el optimizador AdamW junto con la estrategia de ajuste de tasa de aprendizaje WarmupCosineAnnealingLR. Dado que este artículo extrae las características visuales-textuales iniciales de los datos de entrada basándose en el modelo CLIP, se estableció una tasa de aprendizaje inicial más pequeña de 5 × 10−5 para los componentes basados en CLIP del modelo. En contraste, la tasa de aprendizaje inicial para las partes restantes del modelo se estableció en 1×10^{-3}. El número total de épocas de entrenamiento se fijó en 10. A las cuatro funciones de pérdida descritas en la Sección 4.3 se les asignaron pesos de 1.0, 0.3, 0.15 y 0.8, respectivamente. Cabe destacar que este trabajo construyó una estructura de datos especial que consta del grupo de fotogramas de video, el mapa de la mirada y los textos de grano grueso y fino, respectivamente, para acelerar el proceso de obtención de datos por parte de dataLoader y, por lo tanto, agilizar el proceso de entrenamiento.

5.3. Comparación y análisis del rendimiento

5.3.1. Competidores

Con base en las discusiones de la Sección 2, se pueden seleccionar varios modelos de métodos de clasificación de aprendizaje supervisado y métodos de detección de anomalías de video no supervisados para la comparación del rendimiento. Este documento elige dos métodos representativos para la clasificación de aprendizaje supervisado: ResNet50, que extrae características espaciales de los fotogramas de video utilizando la arquitectura ResNet50 [37] y posteriormente emplea una capa totalmente conectada para la clasificación binaria; y LS-ResNet50, que utiliza características espaciales extraídas por ResNet50 y emplea una red LSTM para la extracción de características temporales, seguida de una capa totalmente conectada para la clasificación binaria. Para los métodos de detección de anomalías de video no supervisados o detección de anomalías de tráfico, seleccionamos tres enfoques representativos: MNAD [38], que mejora el rendimiento del modelo al introducir un mecanismo de memoria basado en un autoencoder, con dos modos de detección: MNAD basado en reconstrucción (recon) y MNAD basado en predicción (pred); OLP-TAD [30], que emplea una arquitectura U-Net para la predicción de fotogramas teniendo en cuenta la información del flujo óptico en la dimensión temporal, entrenada utilizando una forma de red generativa antagónica (GAN); y RF-RG [4], que primero captura objetos importantes en fotogramas de vídeo utilizando detección de objetos, como vehículos y peatones, y luego predice fotogramas basándose en los objetos capturados teniendo en cuenta la información del flujo óptico como una característica temporal y prediciendo simultáneamente los mapas de mirada de los objetos durante el entrenamiento, y algunos resultados experimentales en este artículo se remiten al artículo [4].

5.3.2. Comparación del rendimiento general

Después del entrenamiento, las métricas de detección y la comparación del rendimiento de cada modelo en El conjunto de datos de prueba del conjunto de datos TADS se presenta en la Tabla 1.

Machine Translated by Google

Tabla 1. Rendimiento general de varios modelos en el conjunto de prueba TADS. Los números en negrita indican los mejores resultados.

Modelos	Métricas de evaluación (%)		
	Micro AUC	AUC macro	Exactitud
Resnet50 [37]	52,7	50,3	55.4
LS-Resnet50	59,0	47,2	61.8
MNAD(recon) [38]	54,1	58,0	53.0
MNAD(pred) [38]	66,8	66,6	63,7
OLP-TAD [30]	61,3	63,7	63.2
RF-RG [4]	68,6	69,1	62.8
Nuestro	74,3	76,0	66.4

Los resultados de varios modelos presentados en la Tabla 1 indican que el método propuesto En este artículo se mejora significativamente el rendimiento de detección de anomalías de tráfico. una perspectiva de vigilancia. Comparado con el mejor método anterior, RF-RG, en el TADS conjunto de datos, nuestro enfoque mejora la métrica micro AUC en aproximadamente un 6%, la macro La métrica AUC en aproximadamente un 7%, y la métrica de precisión en alrededor de un 4%. Consideramos que esto La mejora significativa puede atribuirse a varios factores que se detallan a continuación:

Fundamento del modelo preentrenado de texto visual: El modelo CLIP es un modelo de texto visual grande. modelo entrenado en una gran cantidad de pares imagen-texto, demostrando una poderosa capacidad para Extraer características que capturen las relaciones semánticas entre factores visuales y textuales. Su eficacia ha sido validada en diversas tareas visuales posteriores. Mediante el ajuste fino los componentes de extracción de características visuales y textuales del modelo CLIP en TADS conjunto de datos, podemos extraer características semánticas que relacionen videos de escenas de tráfico con detalles finos y descripciones de texto de grano grueso. Esta relación semántica es intuitivamente muy útil para el modelo para distinguir entre vídeos de anomalías de tráfico y vídeos de tráfico normal.

La introducción de múltiples granularidades de texto: Intuitivamente, los vídeos de escenas de tráfico contienen información semántica más compleja que las imágenes individuales. Para diferenciar eficazmente entre tramas de anomalías de tráfico y tramas de tráfico normal, basándose únicamente en texto de grano grueso puede llevar al modelo a pasar por alto la rica información semántica relacionada con las anomalías del tráfico. presente en los fotogramas de vídeo de entrada. Esta información puede ser crucial para facilitar la modelo para detectar anomalías de tráfico. Por el contrario, si solo el texto detallado asociado con Cuando se introduce el vídeo de entrada, el modelo puede desviarse de su objetivo de distinguir entre anomalías de tráfico y normalidad de tráfico, quedando enredados en la compleja tarea de alinear videos con texto de grano fino, lo que podría afectar negativamente la detección del modelo. rendimiento. La introducción de múltiples granularidades de texto permite el texto de grano fino. información correspondiente a cada vídeo para complementar los dos tipos de texto de grano grueso relevante para la tarea de detección, mejorando así en última instancia la detección de anomalías de tráfico del modelo. rendimiento de detección.

Asistencia de los mapas de seguimiento ocular: Como se analizó en la Sección 1, las áreas donde el tráfico Las anomalías o accidentes que ocurren suelen ocupar una región espacial más pequeña dentro de todo el marco. desde la perspectiva de vigilancia. Por lo tanto, utilizar eficazmente los mapas de mirada (observador Los mapas de atención podrían ayudar al modelo a centrarse en áreas importantes dentro del marco, reduciendo la inutilidad y redundancia de la información de fondo. El enfoque de emplear La detección de objetos primero, seguida de la detección de anomalías en estudios previos [39], puede haber Demostramos este principio. En nuestros experimentos, no realizamos primero la detección de objetos. en los fotogramas de vídeo de entrada, como en métodos anteriores; sin embargo, aún logramos resultados favorables. resultados de detección, probablemente debido al uso de mapas de seguimiento ocular del conjunto de datos TADS. Los mapas de seguimiento ocular a menudo se alinean estrechamente con el texto de anomalía de tráfico en el punto semántico durante incidentes, y nuestro enfoque también se basa en la correlación semántica entre lo visual y

https://doi.org/10.3390/s26092638

Machine Translated by Google

factores textuales para detectar anomalías en el tráfico. Por lo tanto, el uso de mapas de seguimiento ocular como auxiliar
La información adicional puede mejorar aún más el rendimiento de detección del modelo.

5.3.3. Comparación del rendimiento en diversas categorías de anomalías de tráfico

Para evaluar exhaustivamente el rendimiento del modelo propuesto, este artículo
lo compara en varias categorías de anomalías de tráfico y selecciona el segundo mejor modelo,
RF-RG, de la Tabla 1 para análisis comparativo. Es importante señalar que el conjunto de datos TADS
Clasifica las anomalías de tráfico en 12 tipos diferentes según los objetos anómalos involucrados.
Por ejemplo, la categoría 1 se refiere a "colisiones entre vehículos pequeños e infraestructura vial",
mientras que la categoría 2 se refiere a "colisiones entre vehículos grandes e infraestructura vial",
entre otros. Las definiciones detalladas de cada categoría se pueden encontrar en [4]. La comparación
Los resultados de la detección para cada categoría de anomalía de tráfico se ilustran en la Figura 5, con
La métrica de evaluación es Micro AUC (%).

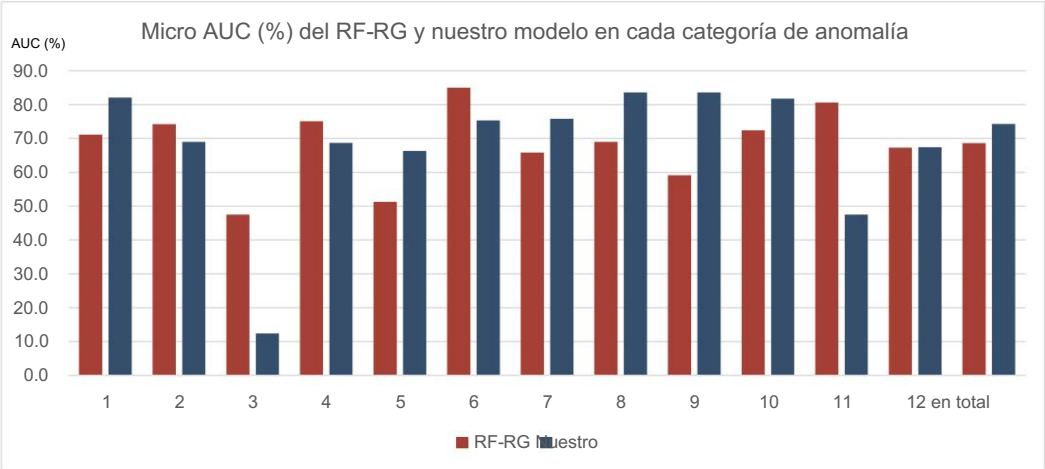


Figura 5. Comparación del rendimiento en diversas categorías de anomalías de tráfico.

Como se muestra en la Figura 5, el modelo propuesto en este artículo demuestra un rendimiento
sólido en la mayoría de las categorías anómalas presentes en el conjunto de datos TADS. Entre las
Se observaron mejoras en el rendimiento en 7 categorías de 12 tipos diferentes de anomalías.
(categorías anómalas 1, 5, 7, 8, 9, 10 y 12), con distintos grados de mejora. Para
Por ejemplo, la categoría anómala 1 mejoró en un 9% y la categoría 5 en un 15%, lo que resultó en una
Mejora general de aproximadamente el 6%.

De hecho, las diferentes categorías anómalas suelen exhibir características de movimiento distintas.
Mejorar el rendimiento de detección del modelo centrándose únicamente en los datos visuales puede conducir a
a resultados de métricas altas para categorías de anomalías específicas, mientras que produce un rendimiento
insatisfactorio para otras. Emplear un enfoque de aprendizaje visual-textual multimodal puede ayudar a
El modelo captura características semánticas comunes de anomalías de tráfico tanto visuales como textuales.
perspectivas, mejorando así la capacidad de detección en múltiples categorías anómalas.

Sin embargo, también se demuestra que el modelo propuesto en este artículo logró un rendimiento menor.
rendimiento de detección para ciertas categorías anómalas, como las categorías 2, 3, 4, 6 y
11. Suponemos que esto puede atribuirse no solo a los desafíos inherentes a la detección del tráfico.
anomalías en el escenario de vigilancia o dentro del conjunto de datos TADS, pero también a la limitada
cantidad y proporción de esas categorías anómalas específicas en el conjunto de datos. Por ejemplo,
las proporciones de categorías anómalas 2, 3 y 11 en el conjunto de entrenamiento son solo 2%, 0,25%,
y 2%, respectivamente. Una proporción de cantidad tan baja podría no ser propicia para el texto visual.
método de aprendizaje multimodal, que es más complejo y generalmente necesita más datos de entrenamiento para
trabajo, que en última instancia afecta al rendimiento de detección del modelo en estas categorías.

Machine Translated by Google

En resumen, las métricas de detección para la mayoría de las categorías anómalas indican que el enfoque de aprendizaje multimodal visual-textual propuesto en este artículo logra un mejor rendimiento de detección. Esto también demuestra la viabilidad de incorporar información y conocimiento textual para la detección de anomalías en el tráfico rodado desde una perspectiva de vigilancia.

5.3.4. Resultados cualitativos

Este artículo selecciona el segundo mejor modelo, RF-RG, de la Tabla 1 para una comparación cualitativa que ilustre aún más la capacidad de detección de nuestro modelo. Se eligen cinco segmentos de vídeo del conjunto de prueba como ejemplos cualitativos. Los resultados se presentan como curvas de puntuación de anomalías para los modelos en estos ejemplos, junto con fotogramas de muestra específicos, como se muestra en la Figura 6.

En la Figura 6, los fotogramas correspondientes a los intervalos de anomalías de tráfico están marcados con un recuadro rojo para indicar las regiones espaciales de anomalía, y nos referimos a las muestras de prueba en la Figura 6 como muestras de prueba 1, 2, 3, 4 y 5, respectivamente, de arriba a abajo. De la comparación cualitativa en la Figura 6 se pueden observar los siguientes puntos : El modelo RF-RG, identificado como el segundo mejor método en la Tabla 1, alcanza un valor AUC de detección encomiable del 68,6 %. Sin embargo, las curvas de puntuación de anomalía RF-RG en estas muestras de prueba no son óptimas, lo que indica que este método no ha capturado completamente las características distintivas entre los videos de anomalías de tráfico y los videos normales. El método propuesto en este artículo no solo alcanza un alto valor de AUC de detección, sino que también produce curvas de puntuación de anomalía que se alinean estrechamente con las etiquetas de la verdad fundamental. En muchos casos, las tendencias de las curvas de nuestro método también son consistentes con la verdad fundamental, lo que sugiere que el método propuesto aprende eficazmente las características discriminativas . Sin embargo, es notable que en ciertos intervalos de las muestras de prueba, las curvas de puntuación de anomalía producidas por el método propuesto muestran discrepancias significativas con respecto a las etiquetas de la verdad fundamental. Por ejemplo, en el intervalo normal que precede a la anomalía de tráfico en la muestra de prueba 1, el método propuesto también produce una puntuación de anomalía alta. De manera similar, en las muestras de prueba 2 y 3, al pasar del intervalo de anomalía de tráfico al intervalo normal, el método propuesto no produce inmediatamente una puntuación de anomalía más baja. Suponemos que hay dos posibles razones para estos resultados. En primer lugar, detectar anomalías de tráfico desde una perspectiva de vigilancia es inherentemente complejo. Como se mencionó en la introducción (Sección 1), las anomalías de tráfico suelen ocupar un área espacial reducida en los fotogramas de vídeo de vigilancia, lo que plantea importantes desafíos para el entrenamiento del modelo. En segundo lugar, la semántica particular asociada a las anomalías de tráfico es su naturaleza. Al ser un tipo específico de anomalía de vídeo, las anomalías de tráfico suelen presentar características espaciotemporales distintas a las de otras anomalías de vídeo generales. Además, el inicio y el final de las anomalías de tráfico son difíciles de definir con precisión en términos de sus implicaciones semánticas, lo que dificulta que el modelo se ajuste perfectamente a las etiquetas de referencia durante los intervalos cercanos a la aparición y la finalización de la anoma

5.4. Experimento de ablación

5.4.1. Rendimiento general de la ablación

Para investigar el impacto de los distintos componentes del modelo propuesto en los resultados de detección, este artículo elimina secuencialmente los mapas de seguimiento ocular, los textos detallados y el módulo de fusión temporal de forma sucesiva, y observa los cambios en el rendimiento de la detección. Las descripciones detalladas de las variantes del modelo son las siguientes:

https://doi.org/10.3390/s26092638

Machine Translated by Google

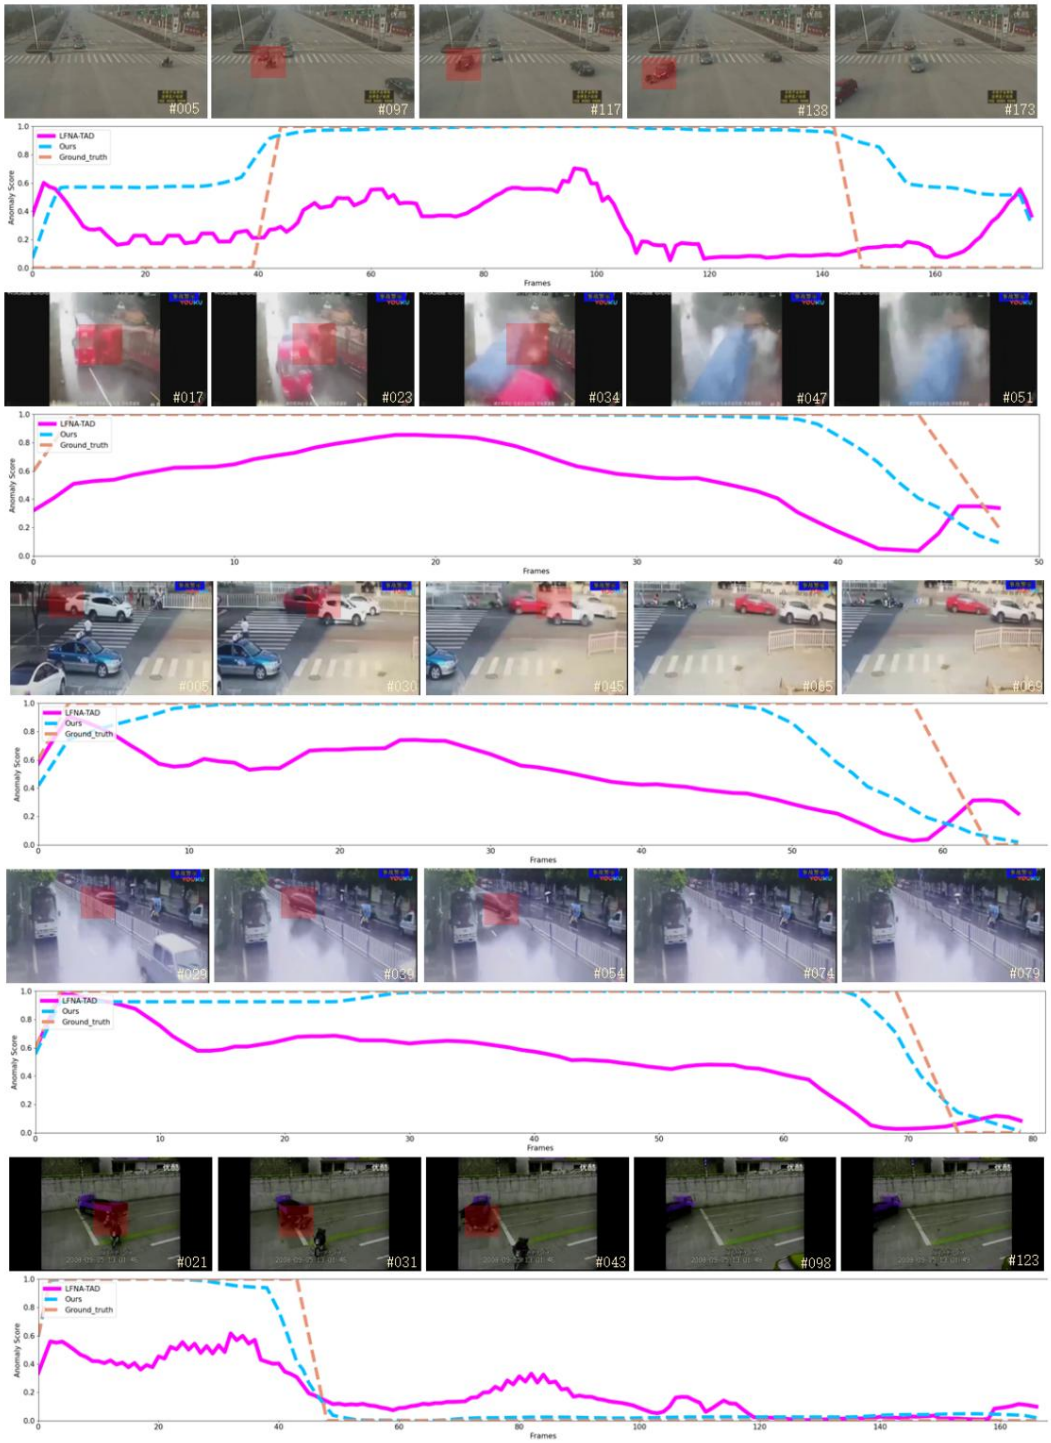


Figura 6. Visualización de las curvas de puntuación de anomalías para la detección de anomalías de tráfico de estos dos modelos en el conjunto de datos TADS. Nota: Los términos en otros idiomas que aparecen en los recuadros representan información relacionada con la cámara de vigilancia o el propio conjunto de datos TADS; consulte [4] para obtener más detalles.

base-tf: Esta variante se basa en la versión final del modelo propuesto, pero excluye la entrada de entrenamiento de los mapas de mirada. En este caso, la pérdida de entrenamiento ya no incluye la pérdida de mirada y, en su lugar, se compone de una suma ponderada de tres pérdidas: la pérdida entre características visuales y características de texto de grano grueso, la pérdida entre características visuales y características de texto de grano fino, y la pérdida entre características de texto de grano fino y características de texto de grano grueso. Los pesos entre las pérdidas

permanecen sin cambios. base-t: Basándose en el modelo base-tf, esta versión elimina aún más la entrada de entrenamiento de los textos de grano fino. En consecuencia, la pérdida de entrenamiento solo incluirá la

Machine Translated by Google

características visuales y características de texto de grano grueso. Específicamente, se extraen las características visuales.
a partir de los cinco fotogramas continuos de vídeo utilizando el modelo CLIP, y después de la fusión temporal,
Las características visuales fusionadas se combinan con las características de texto de grano grueso correspondientes.
para calcular la pérdida.

base: Este modelo se deriva del modelo base-t eliminando la fusión temporal.
módulo. En este caso, para la entrada de los cinco fotogramas continuos, solo se envía el último fotograma.
al módulo de codificación visual del modelo CLIP, y las características resultantes son directamente
junto con las características de texto de grano grueso correspondientes para calcular la pérdida.

Es importante señalar que, en esta ablación, el modelo final se denomina base-tfg.
Dado que ninguno de los modelos de ablación incluye texto detallado o mapas de seguimiento ocular durante las pruebas,
Los procesos son consistentes en los modelos base-t, base-tf y base-tfg. Específicamente, todos
Los modelos introducen los cinco fotogramas consecutivos en la parte de codificación visual del modelo CLIP,
seguido de la fusión de características a través del módulo de fusión de características temporales, con el resultado
características que sirven como características visuales para el marco objetivo. Estas características se utilizan luego para
calcular la similitud con las características de texto de grano grueso para derivar la puntuación de anomalía para
el marco objetivo. El modelo base, que carece del componente de fusión de características temporales, directamente
introduce el último de los cinco fotogramas consecutivos en la parte de codificación visual del modelo CLIP.
para obtener características visuales para el fotograma objetivo, que luego se acoplan con grano grueso
características de texto para calcular la puntuación de anomalía.

Los resultados de detección para cada modelo de ablación se presentan en la Tabla 2.

Tabla 2. Comparación del rendimiento general de cada modelo de ablación. Los números en negrita indican el
mejores resultados.

Modelos	Métricas de evaluación (%)		
	Micro AUC	AUC macro	Exactitud
base	69,3	67,8	62.3
base-t	71,0	73,0	64.6
base-tf	72,4	71,4	67.2
base-tfg	74,3	76.0	66.4

Los resultados presentados en la Tabla 2 indican que el modelo final, base-tfg, alcanzó
Excelente desempeño en las tres métricas de evaluación. Aunque la métrica de precisión
para base-tfg no es el más alto, también está muy cerca del mejor: base-tf. En el campo de
detección de anomalías, la métrica AUC se usa más comúnmente que la métrica de precisión,
con micro AUC ligeramente más común que macro AUC. Por lo tanto, según el
Resultados de micro-AUC, el componente de fusión temporal, textos detallados y mapas de seguimiento ocular.
Son realmente beneficiosos.

5.4.2. Rendimiento en diversas categorías de anomalías de tráfico para la ablación

Para realizar una comparación de ablación más completa de las variantes del modelo, se necesitan modelos similares.
En la Sección 5.3.3, este documento realizó un análisis de ablación de los resultados de detección para
varias categorías de anomalías de tráfico en el conjunto de pruebas TADS. Los resultados se presentan en
Figura 7. Cabe destacar que entre las tres métricas de evaluación utilizadas en este artículo,
El micro AUC es el más utilizado en el campo de la detección de anomalías, por lo que todos los resultados
Los valores mostrados en la Figura 7 se presentan como valores de micro AUC.

Basándose en los resultados de detección en varias categorías de anomalías de tráfico, el base-tfg
El modelo logró el mejor rendimiento para la mayoría de ellos, incluidas las categorías 1, 2, 4, 6,
7, 8, 9 y 10. Para las categorías con resultados de detección menos satisfactorios, como las categorías 3,
5, 11 y 12, creemos que las razones son multifacéticas. Como se analiza en la Sección 5.3.3, además
a los desafíos inherentes a la detección de anomalías de tráfico desde una perspectiva de vigilancia, el

Machine Translated by Google

La cantidad limitada de datos para ciertas categorías de anomalías en el conjunto de datos TADS también podría ser un problema. razón importante. Creemos que este enfoque de aprendizaje multimodal visual-textual puede tener dificultades. para aprender eficazmente las características visuales y textuales deseadas cuando el volumen de datos es insuficiente. En general, los resultados de la ablación en varias categorías de anomalías de tráfico indican que El componente de fusión temporal, el texto de grano fino y los mapas de seguimiento ocular son beneficiosos para rendimiento de detección.

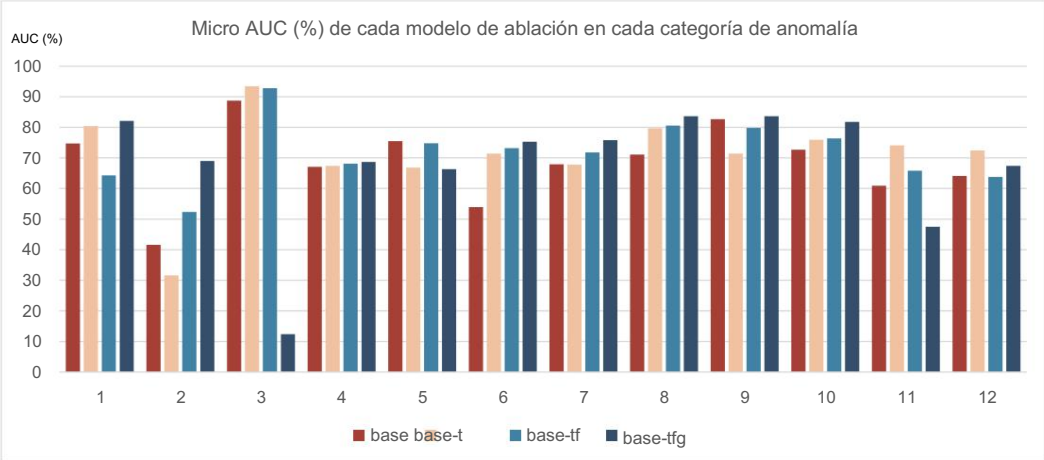


Figura 7. Comparación del rendimiento de la ablación en diversas categorías de anomalías de tráfico.

5.5. Velocidad de inferencia y de disparo cero

5.5.1. Puesta a cero y ajuste fino

Como modelo preentrenado popular de lenguaje visual, CLIP ha sido entrenado con una gran cantidad de datos. número de pares imagen-texto, lo que le permite desempeñarse bien en tareas visuales generales como clasificación de imágenes, incluso de forma de cero disparos. Para comprender mejor el problema de investigación En este artículo, se realizaron experimentos en el conjunto de prueba TADS utilizando el modelo CLIP en un Método de cero disparos en esta sección. Los módulos de codificación visual y de texto del modelo CLIP. fueron consistentes con las variantes utilizadas en los experimentos de la Sección 5.3.2. La comparación Los resultados se muestran en la Tabla 3.

Tabla 3. Comparación del rendimiento y la velocidad de inferencia de CLIP(zero_shot) y el nuestro.

Modelos	Métricas de evaluación (%)			Velocidad de inferencia (FPS)
	Micro AUC	Macro AUC	Precisión	
CLIP(cero_disparo)	38,6	39,6	39,4	83
Nuestro	74,3	76,0	66,4	54

A partir de los resultados de la Tabla 3, se puede observar que los resultados del modelo CLIP con zero_shot en el conjunto de prueba TADS no son suficientemente satisfactorios, comparado con el rendimiento del modelo que han entrenado, y sus dos tipos de resultados AUC son bajos, incluso más bajos que el rendimiento del modelo de variante base en la sección del experimento de ablación en la Sección 5.4.1. Consideramos que Esto puede atribuirse a los desafíos del problema de la detección de anomalías en el tráfico rodado. una perspectiva de vigilancia en el conjunto de datos TADS. En comparación, el rendimiento de detección de El modelo después del entrenamiento ha mejorado significativamente, lo que indica la necesidad de entrenamiento en el tarea posterior al introducir el modelo CLIP en nuestro problema.

5.5.2. Velocidad de inferencia

El procesamiento y la tasa de respuesta en entornos de uso reales también son muy importante para aplicaciones desde la perspectiva de vigilancia, especialmente para la detección de anomalías del tráfico rodado. Por lo tanto, la velocidad de procesamiento del modelo en la etapa de prueba es

Machine Translated by Google

medidas estadísticamente en esta sección, con velocidades de procesamiento y respuesta reportadas en FPS (fotogramas por segundo), como se muestra en la Tabla 3.

Como se muestra en la Tabla 3 sobre la velocidad de inferencia, el valor de FPS de nuestro modelo durante las pruebas no es muy alto, pero el valor de 54 podría cumplir aproximadamente con los requisitos de procesamiento en tiempo real. Sin embargo, cabe destacar que el procesamiento de fotogramas durante las pruebas en el artículo se realiza fuera de línea; la velocidad de procesamiento de fotogramas (FPS) generalmente se reduce aún más en el modo de procesamiento en línea en entornos de aplicaciones del mundo real. Atribuimos el menor rendimiento de FPS de nuestro modelo a la mayor complejidad introducida por los módulos adicionales, en particular el módulo de fusión temporal y el módulo de cálculo de pérdida de mirada , en comparación con el modelo CLIP original en una configuración de cero disparos. Es obvio que el modelo basado en transformadores suele ser inherentemente pesado, por lo que el módulo de fusión temporal basado en transformadores y el módulo de atención cruzada integrados en el cálculo de pérdida de mirada en este trabajo aumentan significativamente la complejidad final del modelo, aumentando así el tiempo de ejecución y afectando negativamente el rendimiento en tiempo real del modelo. En consecuencia, el trabajo futuro podría centrarse en la ligereza y el rendimiento en tiempo real del modelo. Por ejemplo, intentar reemplazar la fusión temporal basada en transformadores con una alternativa basada en redes neuronales convolucionales (CNN); o rediseñar una arquitectura totalmente ligera para la tarea de detección en este artículo, reduciendo el número de submódulos y entrenando dicho modelo ligero mediante destilación de conocimiento, con la guía de la salida del modelo actual. Se espera que estas medidas mejoren la capacidad de inferencia en tiempo real del pipeline general, haciéndolo más adecuado para su despliegue e implementación en escenarios de aplicación prácticos. Según los resultados de la Tabla 3, aunque el valor FPS del modelo CLIP cuando se ejecuta de manera zero_shot ha aumentado en comparación con nuestro modelo, su rendimiento de detección también ha disminuido significativamente, lo que refleja una compensación entre las dos métricas.

6. Conclusiones

Este artículo exploró la viabilidad del aprendizaje multimodal visual-textual para detectar anomalías de tráfico desde una perspectiva de vigilancia. Específicamente, primero realizamos una anotación textual detallada en el conjunto de datos TADS, diseñado para la detección de anomalías de tráfico desde una perspectiva de vigilancia. Esto implicó agregar descripciones textuales para intervalos normales (antes de la ocurrencia de una anomalía) y para intervalos durante anomalías de tráfico en cada muestra de video. Posteriormente, utilizamos el modelo CLIP para extraer características visuales y textuales. Al emplear textos tanto generales como detallados, construimos cuatro funciones de pérdida para alinear mejor las características visuales con sus correspondientes características textuales. Además, entrenamos un módulo de atención cruzada entre los fotogramas objetivo durante los intervalos de anomalía y sus correspondientes textos detallados, con el objetivo de acercar sus interrelaciones a los mapas de seguimiento ocular asociados con los fotogramas objetivo, aprovechando los datos de seguimiento ocular disponibles en el conjunto de datos TADS para ayudar al aprendizaje del modelo. Los resultados experimentales demuestran la efectividad del modelo propuesto.

Sin embargo, según los resultados experimentales, existen al menos dos vías para mejorar aún más la capacidad de detección del modelo. En primer lugar, a partir de los resultados generales de detección, el modelo alcanzó un valor AUC de detección del 74,3 %, lo que indica un margen de mejora significativo en comparación con los resultados en la mayoría de los problemas generales de detección de anomalías en vídeos de vigilancia . Creemos que esto se debe a los escenarios diversos y complejos presentes en los vídeos de vigilancia de tráfico. En segundo lugar, para ciertas categorías específicas de anomalías de tráfico, los resultados de los experimentos de ablación no coincidieron completamente con las expectativas. Atribuimos esto a la limitación de la capacidad de aprendizaje del modelo y a la cantidad insuficiente de datos para las categorías de anomalías correspondientes. Por lo tanto, los esfuerzos futuros podrían centrarse en mejorar la capacidad de aprendizaje del modelo y aumentar el volumen de datos para ciertas categorías de anomalías de tráfico para mejorar aún más el rendimiento de la detección.

https://doi.org/10.3390/s26092638

Machine Translated by Google

Contribuciones de los autores: Conceptualización, YC y WS; metodología, YC; redacción del borrador original, YC; revisión y edición, WS. Todos los autores han leído y aprobado la versión publicada del manuscrito.

Financiación: Este trabajo fue financiado en parte por la Fundación Nacional de Ciencias Naturales de China (Subvención U1911401, Subvención 62137002).

Declaración sobre la disponibilidad de datos: Los datos que respaldan los hallazgos de este estudio están disponibles a solicitud razonable del autor Yachuang Chai.

Conflictos de intereses: Los autores declaran no tener conflictos de intereses.

Referencias

1. Fang, J.; Qiao, J.; Bai, J.; Yu, H.; Xue, J. Detección de accidentes de tráfico mediante aprendizaje de consistencia autosupervisado en escenarios de conducción. IEEE Trans. Intell. Transp. Syst. 2022, 23, 9601–9614. [CrossRef]
2. Fang, J.; Yan, D.; Qiao, J.; Xue, J.; Wang, H.; Li, S. Dada-2000: ¿Se puede predecir un accidente de tráfico mediante la atención del conductor? Análisis mediante un estudio comparativo. En Actas de la Conferencia de Sistemas de Transporte Inteligentes (ITSC) de la IEEE de 2019; IEEE: Piscataway, NJ, EE. UU., 2019; págs. 4303–4309.
3. Cui, X.; Li, LL; Chai, Y.; Fang, J.; Silamu, W. Detección de accidentes de tráfico autosupervisada mediante predicción de marcos difusivos condicionados por el movimiento. En Actas de la Conferencia Internacional sobre Sistemas Autónomos No Tripulados; Springer: Berlín/Heidelberg, Alemania, 2023; págs. 292–303.
4. Chai, Y.; Fang, J.; Liang, H.; Silamu, W. TADS: Un nuevo conjunto de datos para la detección de accidentes de tráfico desde una perspectiva de vigilancia. J. Supercomput. 2024, 80, 26226–26249. [CrossRef]
5. Fang, J.; Qiao, J.; Xue, J.; Li, Z. Detección y anticipación de accidentes de tráfico basadas en visión: una revisión. IEEE Trans. Circuits Syst. Video Technol. 2023, 34, 1983–1999. [CrossRef]
6. Sultani, W.; Chen, C.; Shah, M. Detección de anomalías en el mundo real en vídeos de vigilancia. En Actas de la Conferencia IEEE sobre Visión por Computadora y Reconocimiento de Patrones; IEEE: Piscataway, NJ, EE. UU., 2018; págs. 6479–6488.
7. Li, L.; Chen, YC; Cheng, Y.; Gan, Z.; Yu, L.; Liu, J. Hero: Codificador jerárquico para preentrenamiento omnirrepresentación de video+lenguaje . arXiv 2020, arXiv:2005.00200. [Referencia cruzada]
8. Xu, H.; Ghosh, G.; Huang, PY; Arora, P.; Aminzadeh, M.; Feichtenhofer, C.; Metze, F.; Zettlemoyer, L. Vlm: independiente de la tarea Preentrenamiento de un modelo de lenguaje de vídeo para la comprensión de vídeos. arXiv 2021, arXiv:2105.09996.
9. Fu, TJ; Li, L.; Gan, Z.; Lin, K.; Wang, WY; Wang, L.; Liu, Z. Violet: Transformadores de lenguaje de vídeo de extremo a extremo con modelado de tokens visuales enmascarados. arXiv 2021, arXiv:2111.12681.
10. Xu, P.; Zhu, X.; Clifton, DA Aprendizaje multimodal con transformadores: una revisión. IEEE Trans. Pattern Anal. Mach. Intell. 2023, 45, 12113–12132. [CrossRef] [PubMed]
11. Nag, S.; Zhu, X.; Song, YZ; Xiang, T. Detección de acciones temporales sin entrenamiento previo mediante indicaciones visuales y lingüísticas. En Actas de la Conferencia Europea sobre Visión por Computadora; Springer: Berlín/Heidelberg, Alemania, 2022; págs. 681–697.
12. Jia, C.; Yang, Y.; Xia, Y.; Chen, YT; Parekh, Z.; Pham, H.; Le, Q.; Sung, YH; Li, Z.; Duerig, T. Ampliación del aprendizaje de representación visual y visuo-lingüística con supervisión de texto ruidoso. En Actas de la Conferencia Internacional sobre Aprendizaje Automático; PMLR: Cambridge, MA, EE. UU., 2021; págs. 4904–4916.
13. Gu, X.; Lin, TY; Kuo, W.; Cui, Y. Detección de objetos de vocabulario abierto mediante la destilación del conocimiento del lenguaje y la visión. arXiv 2021, arXiv:2104.13921.
14. Yao, L.; Han, J.; Liang, X.; Xu, D.; Zhang, W.; Li, Z.; Xu, H. Detclipv2: Preentrenamiento escalable para la detección de objetos con vocabulario abierto mediante alineación de regiones de palabras. En Actas de la Conferencia IEEE/CVF sobre Visión por Computadora y Reconocimiento de Patrones; IEEE: Piscataway, NJ, EE. UU., 2023; págs. 23497–23506.
15. Xu, J.; De Mello, S.; Liu, S.; Byeon, W.; Breuel, T.; Kautz, J.; Wang, X. Groupvit: La segmentación semántica surge de la supervisión de texto. En Actas de la Conferencia IEEE/CVF sobre Visión por Computadora y Reconocimiento de Patrones; IEEE: Piscataway, NJ, EE. UU., 2022; págs. 18134–18144.
16. Zhou, Z.; Lei, Y.; Zhang, B.; Liu, L.; Liu, Y. Zegclip: Hacia la adaptación de clip para la segmentación semántica de cero disparos. En Actas de Conferencia IEEE/CVF sobre Visión por Computadora y Reconocimiento de Patrones; IEEE: Piscataway, NJ, EE. UU., 2023; págs. 11175–11185.
17. Baldrati, A.; Agnolucci, L.; Bertini, M.; Del Bimbo, A. Recuperación de imágenes compuestas sin datos previos mediante inversión textual. En Actas de la Conferencia Internacional IEEE/CVF sobre Visión por Computadora; IEEE: Piscataway, NJ, EE. UU., 2023; págs. 15338–15347.
18. Tschannen, M.; Mustafa, B.; Houlsby, N. Clippo: Comprensión de imágenes y lenguaje a partir únicamente de píxeles. En Actas de la Conferencia IEEE/CVF sobre Visión por Computadora y Reconocimiento de Patrones; IEEE: Piscataway, NJ, EE. UU., 2023; págs. 11006–11017.
19. Wu, W.; Sun, Z.; Ouyang, W. Revisando el clasificador: Transferencia de modelos de visión-lenguaje para el reconocimiento de vídeo. En Actas de la Conferencia AAAI sobre Inteligencia Artificial; AAAI: Palo Alto, CA, EE. UU., 2023; Volumen 37, págs. 2847–2855.

Machine Translated by Google

20. Ni, B.; Peng, H.; Chen, M.; Zhang, S.; Meng, G.; Fu, J.; Xiang, S.; Ling, H. Ampliación de modelos preentrenados de lenguaje e imagen para el reconocimiento general de vídeo. En Actas de la Conferencia Europea sobre Visión por Computadora; Springer: Berlín/Heidelberg, Alemania, 2022; págs. 1-18.

21. Chen, S.; Xu, Q.; Ma, Y.; Qiao, Y.; Wang, Y. Solicitud atenta de fragmentos para la recuperación de vídeo. IEEE Trans. Multimed. 2023, 26, 4348–4359. [CrossRef]

22. Ma, Y.; Xu, G.; Sun, X.; Yan, M.; Zhang, J.; Ji, R. X-clip: Aprendizaje contrastivo multigrano de extremo a extremo para la recuperación de texto en vídeo. En Actas de la 30.ª Conferencia Internacional ACM sobre Multimedia; ACM: Nueva York, NY, EE. UU., 2022; págs. 638–647.

23. Radford, A.; Kim, JW; Hallacy, C.; Ramesh, A.; Goh, G.; Agarwal, S.; Sastry, G.; Askell, A.; Mishkin, P.; Clark, J.; et al. Aprendizaje de modelos visuales transferibles a partir de la supervisión del lenguaje natural. En Actas de la Conferencia Internacional sobre Aprendizaje Automático; PmLR: Cambridge, MA, EE. UU., 2021; págs. 8748–8763.

24. Wu, P.; Zhou, X.; Pang, G.; Sun, Y.; Liu, J.; Wang, P.; Zhang, Y. Detección de anomalías en vídeo con vocabulario abierto. En Actas de la Conferencia IEEE/CVF sobre Visión por Computadora y Reconocimiento de Patrones; IEEE: Piscataway, NJ, EE. UU., 2024; págs. 18297–18307.

25. Zanella, L.; Menapace, W.; Mancini, M.; Wang, Y.; Ricci, E. Aprovechamiento de grandes modelos de lenguaje para la detección de anomalías en vídeo sin entrenamiento. En Actas de la Conferencia IEEE/CVF sobre Visión por Computadora y Reconocimiento de Patrones; IEEE: Piscataway, NJ, EE. UU., 2024; págs. 18527–18536.

26. Fang, J.; Li, Ll; Zhou, J.; Xiao, J.; Yu, H.; Lv, C.; Xue, J.; Chua, TS Comprensión abductiva de vídeo de accidentes desde la perspectiva del observador para la percepción de una conducción segura. En Actas de la Conferencia IEEE/CVF sobre Visión por Computadora y Reconocimiento de Patrones; IEEE: Piscataway, NJ, EE. UU., 2024; págs. 22030–22040.

27. Liang, R.; Li, Y.; Zhou, J.; Li, X. Detección de anomalías de tráfico basada en texto con modelado temporal de alta frecuencia en vídeos de conducción. IEEE Trans. Circuits Syst. Video Technol. 2024, 34, 8684–8697. [CrossRef]

28. Dogru, N.; Subasi, A. Detección de accidentes de tráfico mediante clasificador de bosque aleatorio. En Actas de la 15.ª Conferencia de Aprendizaje y Conferencia de Tecnología (L&T); IEEE: Piscataway, NJ, EE. UU., 2018; págs. 40–45.

29. Wang, W.; Chen, S.; Qu, G. Comparación entre la regresión de mínimos cuadrados parciales y la máquina de vectores de soporte para la detección de incidentes en autopistas. En Actas de la Conferencia IEEE sobre Sistemas de Transporte Inteligentes de 2007; IEEE: Piscataway, NJ, EE. UU., 2007; págs. 190–195.

30. Liu, W.; Luo, W.; Lian, D.; Gao, S. Predicción de fotogramas futuros para la detección de anomalías: una nueva línea base. En Actas del IEEE Conferencia sobre Visión por Computadora y Reconocimiento de Patrones; IEEE: Piscataway, NJ, EE. UU., 2018; págs. 6536–6545.

31. Chong, YS; Tay, YH Detección de eventos anormales en videos usando un autoencoder espaciotemporal. En Actas del Avances en Redes Neuronales-ISNN 2017: 14.º Simposio Internacional, ISNN 2017, Sapporo, Hakodate y Muroran, Hokkaido, Japón, 21-26 de junio de 2017; Actas, Parte II 14; Springer: Berlín/Heidelberg, Alemania, 2017; págs. 189-196.

32. Wang, M.; Xing, J.; Liu, Y. Actionclip: Un nuevo paradigma para el reconocimiento de acciones en vídeo. arXiv 2021, arXiv:2109.08472. [CrossRef]

33. Luo, H.; Ji, L.; Zhong, M.; Chen, Y.; Lei, W.; Duan, N.; Li, T. Clip4clip: Un estudio empírico de Clip para la recuperación de videoclips de extremo a extremo y subtitulado. Neurocomputing 2022, 508, 293–304. [CrossRef]

34. Wu, P.; Zhou, X.; Pang, G.; Zhou, L.; Yan, Q.; Wang, P.; Zhang, Y. Vadclip: Adaptación de modelos de visión y lenguaje para la detección de anomalías en vídeo con supervisión débil. En Actas de la Conferencia AAAI sobre Inteligencia Artificial; AAAI: Palo Alto, CA, EE. UU., 2024; Volumen 38, págs. 6074–6082.

35. Fang, J.; Yan, D.; Qiao, J.; Xue, J.; Yu, H. DADA: Predicción de la atención del conductor en escenarios de accidentes de conducción. IEEE Trans. Intell. Sistemas de Transformación 2021, 23, 4959–4971. [CrossRef]

36. Ristea, NC; Croitoru, FA; Ionescu, RT; Popescu, M.; Khan, FS; Shah, M. Los autoencoders enmascarados autodestilados son detectores de anomalías de vídeo eficientes. En Actas de la Conferencia IEEE/CVF sobre Visión por Computadora y Reconocimiento de Patrones; IEEE: Piscataway, NJ, EE. UU., 2024; págs. 15984–15995.

37. He, K.; Zhang, X.; Ren, S.; Sun, J. Aprendizaje residual profundo para el reconocimiento de imágenes. En Actas de la Conferencia IEEE sobre Computación Visión y reconocimiento de patrones; IEEE: Piscataway, NJ, EE. UU., 2016; págs. 770–778.

38. Park, H.; Noh, J.; Ham, B. Aprendizaje de normalidad guiada por memoria para la detección de anomalías. En Actas de la Conferencia IEEE/CVF sobre Visión por Computadora y Reconocimiento de Patrones; IEEE: Piscataway, NJ, EE. UU., 2020; págs. 14372–14381.

39. Liu, Z.; Nie, Y.; Long, C.; Zhang, Q.; Li, G. Un marco híbrido para la detección de anomalías en vídeo mediante reconstrucción de flujo con memoria aumentada y predicción de fotogramas guiada por flujo. En Actas de la Conferencia Internacional IEEE/CVF sobre Visión por Computadora; IEEE: Piscataway, NJ, EE. UU., 2021; págs. 13588–13597.

Aviso legal/Nota del editor: Las declaraciones, opiniones y datos contenidos en todas las publicaciones son responsabilidad exclusiva de sus autores y colaboradores, y no de MDPI ni de sus editores. MDPI y sus editores no se responsabilizan de los daños a personas o bienes que pudieran derivarse de las ideas, métodos, instrucciones o productos mencionados en el contenido.