Machine Translated by Google

Autoencoder variacional recurrente basado en atención estructural para la detección de anomalías en vehículos de carretera.

Neeloy Chakraborty,
Universidad de Illinois,
Urbana, IL, Estados Unidos
neeloyc2@illinois.edu

Aamir Hasan*
Universidad de Illinois
Urbana, IL, Estados Unidos
aamirh2@illinois.edu

Shuijing Liu*
Universidad de Illinois
Urbana, IL, Estados Unidos
sliu105@illinois.edu

Tianchen Ji*
Universidad de Illinois
Urbana, IL, Estados Unidos
tj12@illinois.edu

Weihang Liang,
Universidad de Illinois,
Urbana, IL, Estados Unidos
weihang2@illinois.edu

D. Livingston McPherson,
Universidad de Illinois,
Urbana, IL, Estados Unidos,
dlivm@illinois.edu

Katherine Driggs-Campbell,
Universidad de Illinois,
Urbana, IL, Estados Unidos,
krdc@illinois.edu

ABSTRACTO

En la conducción autónoma, la detección de comportamientos de conducción anómalos es esencial para garantizar la seguridad de los controladores del vehículo. Trabajos previos en detección de anomalías vehiculares han demostrado que modelar las interacciones entre agentes mejora la precisión de la detección, pero ciertos comportamientos anómalos donde la información estructurada de la carretera es primordial se identifican de manera deficiente, como la conducción en sentido contrario y fuera de la carretera. Proponemos un nuevo marco no supervisado para la detección de anomalías en autopistas llamado SABeR-VAE (Structural Attention-Based Recurrent VAE), que utiliza explícitamente la estructura del entorno para ayudar a la identificación de anomalías. Específicamente, utilizamos un módulo de autoatención vehicular para aprender las relaciones entre los vehículos en una carretera, y un módulo de atención vehicular-carril separado para modelar la importancia de los carriles permitidos para ayudar en la predicción de trayectorias. Condicionado a las salidas de los módulos de atención, una arquitectura recurrente codificador-decodificador con un espacio latente propagado por el operador de Koopman estocástico predice los siguientes estados de los vehículos. Nuestro modelo se entrena de extremo a extremo para minimizar la pérdida de predicción en comportamientos vehiculares normales y se implementa para detectar anomalías en escenarios (anormales). Al combinar la información heterogénea del vehículo y del carril, SABeR-VAE y su variante determinista, SABeR-AE, mejoran el AUPR anormal en un 18 % y un 25 % respectivamente en el conjunto de datos simulado de la autopista MAAD en comparación con STGAE-KDE. Además, demostramos que el operador de Koopman aprendido en SABeR-VAE impone una estructura interpretable en el espacio latente variacional. Los resultados de nuestro método demuestran que modelar los factores ambientales es esencial para detectar un conjunto diverso de anomalías en la implementación. Para la implementación del código, visite https://sites.google.com/illinois.edu/saber-vae.

PALABRAS CLAVE

Detección de anomalías; Vehículos autónomos; Aprendizaje no supervisado; Modelado del comportamiento humano

Formato de referencia ACM:
Neeloy Chakraborty, Aamir Hasan*, Shuijing Liu*, Tianchen Ji*, Weihang Liang, D. Livingston McPherson y Katherine Driggs-Campbell. 2023. Autoencoder variacional recurrente basado en atención estructural para la detección de anomalías en vehículos de carretera. En Actas de la 22.ª Conferencia Internacional sobre Agentes Autónomos y Sistemas Multiagente (AAMAS 2023), Londres, Reino Unido, del 29 de mayo al 2 de junio de 2023, IFAAMAS, 10 páginas.

1. INTRODUCCIÓN

Los vehículos autónomos tienen el potencial de crear un sistema de transporte rápido, seguro y sin necesidad de mano de obra. Un vehículo autónomo fiable debe ser capaz de operar de forma segura en situaciones normales y, lo que es aún más importante, de percibir y reaccionar con rapidez y eficacia ante situaciones de conducción anómalas (por ejemplo, derrapes y conducción en sentido contrario de otros vehículos). La detección de estas situaciones anómalas puede ayudar a identificar accidentes de tráfico y conductas de conducción peligrosas, proporcionando así información valiosa a los operadores para que actúen con seguridad.

Los algoritmos de detección de anomalías (AD) basados en aprendizaje profundo han demostrado ser muy prometedores en aplicaciones de vehículos inteligentes [7]. Muchos trabajos anteriores utilizan trayectorias de vehículos como señal de anomalía [2, 12, 43]. Sin embargo, solo existen unos pocos conjuntos de datos de trayectorias de vehículos con suficientes etiquetas de anomalía para métodos de aprendizaje supervisado [18, 43, 47]. Para aprovechar el mayor almacén de datos de conducción sin etiquetar, investigadores como Yao y Wiederer han empleado métodos de aprendizaje no supervisado [42, 44, 45]. Específicamente, una red neuronal, que generalmente sigue una arquitectura codificador-decodificador para la reconstrucción o predicción de trayectorias, aprende una distribución subyacente de trayectorias normales de vehículos en el espacio latente. Luego se detecta una anomalía cuando la trayectoria está fuera de la distribución y produce un gran error de reconstrucción o predicción. En escenarios de conducción interactiva, Wiederer et al. [42] demostraron que modelar las interacciones entre agentes puede mejorar en gran medida la precisión de la reconstrucción y, posteriormente, el rendimiento de AD. Sin embargo, estos métodos que tienen en cuenta la interacción siguen ignorando el efecto de las estructuras viales en el comportamiento de los vehículos y, por lo tanto, pueden pasar por alto escenarios anormales como la circulación en sentido contrario.

Actas de la 22.ª Conferencia Internacional sobre Agentes Autónomos y Sistemas Multiagente (AAMAS 2023), A. Ricci, W. Yeoh, N. Agmon, B. An (eds.), 29 de mayo - 2 de junio de 2023, Londres, Reino Unido. © 2023 Fundación Internacional para Agentes Autónomos y Sistemas Multiagente (www.ifaamas.org). Todos los derechos reservados.

*Estos autores contribuyeron por igual a este trabajo.

Machine Translated by Google

trayectorias de conducción que parecen normales cuando se pasa por alto el contexto ambiental.

Además de la precisión del rendimiento, las decisiones tomadas por AD
Los algoritmos deben ser interpretables para las partes interesadas. Redes neuronales profundas
Las redes son cajas negras por naturaleza. Sin embargo, las decisiones de las redes profundas
Las redes impactan a diversas partes interesadas, como los responsables políticos y
usuarios finales. Diseñar métodos con características interpretables para las
partes interesadas es un desafío clave en AD y en el campo del aprendizaje automático.
en general [5, 16, 37, 39]. En vehículos AD más específicamente, interpretable
Los algoritmos deben tener en cuenta la amplia distribución de los humanos.
conductores que actúan de acuerdo con sus propias políticas [6]. Por ejemplo,
Los distintos conductores pueden optar por adelantar a otros vehículos en diferentes momentos.
tiempos y velocidades. Para garantizar la interpretabilidad, utilizamos variacional
Autoencoder (VAE) para agrupar características útiles de comportamientos similares.
juntos en un espacio latente continuo y estocástico [26]. Nuestros resultados
indican que las trayectorias de los vehículos transitan a un estado anormal
Los estados se codifican explícitamente mediante transformaciones interpretables en el
espacio latente aprendido.

En este artículo, presentamos nuestro novedoso método estructural no supervisado.
Autoencoder variacional recurrente basado en atención (SABeR-VAE)
para la detección de anomalías en vehículos de carretera. Dado que los vehículos
contemporáneos tienen información de mapas disponible sobre su entorno cercano.
En cuanto al entorno y los carriles, utilizamos la información ambiental que trabajos
anteriores [29, 36, 42] han ignorado para explícitamente
modelar el efecto de la estructura de los carriles en el comportamiento normal de los vehículos.
Específicamente, tratamos un escenario de autopista como un grafo de interacción estructurado
donde los nodos representan vehículos y posiciones de carril, y
Los bordes conectan los vehículos cercanos y los carriles permitidos. Dos separados
Los módulos de atención aprenden relaciones entre vehículos (vehículo-vehículo)
autoatención) y trayectorias de ruta legalmente permisibles (carril-vehículo
atención) respectivamente. Una secuencia de incrustaciones del módulo de atención vehículo-
vehículo se codifica en un espacio latente gaussiano.
para capturar la aleatoriedad de las trayectorias de los vehículos con una red recurrente y
agrupar comportamientos similares cerca unos de otros en un
de forma interpretable. Nuestro trabajo es más eficiente desde el punto de vista computacional.
que STGAE-KDE [42], que tiene un espacio latente determinista y
requiere el costoso proceso de ajustar un estimador de densidad de kernel
(KDE) para aprender una distribución significativa de comportamientos normales.
Luego utilizamos un operador de Koopman aprendido para propagar las
distribuciones latentes actuales hacia adelante en el tiempo condicionado a la útil
incrustaciones de carriles. Mostramos que el operador de Koopman explícitamente
impone transformaciones interpretables en el espacio latente que los autoencoders estándar
como STGAE no pueden incorporar, y es capaz
para modelar la dinámica compleja y no lineal de los conductores. Finalmente, nosotros
decodificar un punto muestreado de la distribución propagada para predecir
estados siguientes de los vehículos. Entrenamos nuestro método para predecir trayectorias a
partir de escenarios normales en la detección de anomalías multiagente.
(MAAD) conjunto de datos [42], y comparar las métricas de precisión con las lineales,
Enfoques recurrentes y convolucionales de grafos en trayectorias anómalas [34, 36,
42]. Nuestro SABeR-VAE mejora AUPR-Anormal
y la detección de conducción en sentido contrario sobre el STGAE-KDE en un 18% y
35% respectivamente, y tiene un espacio latente interpretable.

Nuestras contribuciones se pueden resumir de la siguiente manera: (1) Presentamos una
(1) Nuevo enfoque variacional no supervisado para la detección de anomalías condicionado a
información de carril estructurada; (2) Demostramos cuantitativamente
que la incorporación de la información estructurada aumenta la anomalía
precisión de detección, en comparación con los métodos de referencia más avanzados y

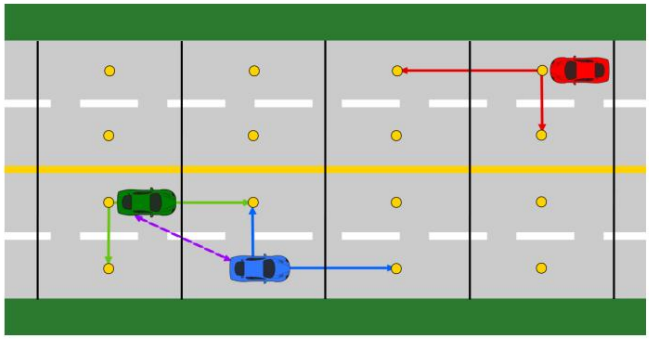


Figura 1: Discretización del mapa y aristas de interacción. Modelamos
el problema AD del vehículo como un grafo de interacción con el vehículo y
nodos de carril. Un mapa continuo de la carretera se discretiza en bloques.
Los bordes de carril dirigidos entre los nodos de carril codifican las rutas permitidas.
para vehículos. El vehículo rojo tiene un borde dirigido hacia el carril.
nodos delante y a su izquierda porque el conductor puede continuar legalmente
avanzar o incorporarse a la izquierda. Por el contrario, el vehículo verde no tiene ventaja.
se conecta a un nodo del carril izquierdo ya que no puede cruzar la mediana de la carretera.
Los bordes de los vehículos, mostrados en púrpura, existen para los vehículos que están cerca.
suficiente para interactuar entre sí.

ablaciones utilizando el conjunto de datos MAAD; (3) Mostramos que el operador
estocástico de Koopman aprende características interpretables de (ab)normal
comportamientos en el espacio latente.

Nuestro documento está organizado de la siguiente manera: la Sección 2 analiza temas relevantes
Trabaja en las áreas de modelado estructurado y detección de anomalías.
La formulación del problema y los métodos empleados se presentan en la Sección 3.
Analizamos los resultados en la Sección 4. Finalmente, concluimos el artículo y
En la Sección 5 se analizarán las futuras líneas de actuación.

2 OBRAS RELACIONADAS

2.1 Aprovechamiento de la información cartográfica

La calidad de la información sobre un entorno proporcionada por High
Los mapas de definición (mapas HD) han aumentado drásticamente y han dado lugar a
su uso generalizado debido a los recientes avances en sistemas autónomos
conducción [30, 46]. Actualmente, la mayoría de los métodos de vanguardia para vehículos
predicción de trayectorias, pronóstico de movimiento y detección de anomalías,
no hacen un uso efectivo de la rica información proporcionada en estos
mapas HD, y solo se basan en modelar las interacciones entre
vehículos en la carretera [9, 27, 38]. Por lo tanto, estos métodos ignoran aspectos vitales
información como el movimiento plausible de vehículos en el
el entorno, que puede ser primordial para identificar anomalías
como conducir en sentido contrario.

Sin embargo, los métodos de predicción de trayectorias como los propuestos
Deo et al. y Liang et al. sí aprovechan la información en estos
Los mapas HD superan significativamente a sus homólogos [17, 28].
Al proponer LaneGCN, Liang et al. codifican diferentes tipos de interacciones entre agentes en
la carretera con información de carril extraída.
a partir de mapas. [28]. Demuestran que los modelos basados en atención pueden ser
se utilizan para codificar las interacciones entre vehículos y carriles, que son
aprendido mediante la construcción de una representación gráfica de la carretera. PGP,
propuesto por Deo et al. ries , Además produce trayectorias compatibles con la escena.
mediante muestreo de una distribución de perfiles de conducción condicionados
sobre las interacciones entre el medio ambiente y el vehículo [17]. Corroboramos la

Machine Translated by Google

la utilidad de estas representaciones basadas en la atención al vehículo y al carril y demostrar que tales incrustaciones sí proporcionan información significativa Información relevante para la detección de anomalías en vehículos de carretera en SABeR-VAE.

2.2 Autocodificadores variacionales para secuencias

Los autoencoders variacionales (VAE) se han aplicado a secuencias datos combinados con redes neuronales recurrentes (RNN) en campos como como síntesis de voz e imagen y conducción autónoma [8, 13– 15, 19, 29, 34]. Liu et al. intentan inferir los rasgos de los conductores a partir de trayectorias codificadas en un espacio latente variacional [29]. Sin embargo, solo dos clases de rasgos y un conjunto restringido de trayectorias definidas fueron considerados, mientras que los conductores reales tienen una gama mucho más amplia de comportamientos en la carretera. Además, no utilizan la información de los mapas en su proceso de aprendizaje, que proporciona un contexto relevante. para rasgos. También se ha descubierto que las formulaciones VAE condicionales ser capaz de generar trayectorias con diferentes estilos de conducción, pero no lograr producir consistentemente trayectorias factibles sin necesidad contexto ambiental [22, 35, 40]. También se han observado VAE recurrentes. aplicados a la detección de anomalías en robots, pero limitados por la simplicidad. del enunciado del problema del agente único [34]. Estos enfoques de modelado generativo secuencial funcionan razonablemente bien en su simple tareas, pero no logran generar muestras realistas a partir de puntos en la fase latente. espacio en áreas más complejas, debido a las limitaciones de su RNN componentes [13, 14, 20].

Para cerrar la brecha entre los comportamientos humanos complejos y la En un entorno estructurado, y para superar los obstáculos de la propagación temporal en las RNN simplistas, proponemos el uso de un operador de Koopman condicionado por carril para modelar las relaciones temporales en el espacio latente. Nos inspiramos específicamente en usar el Koopman operador para propagar el espacio latente debido a su capacidad de modelar la dinámica de datos complejos y no lineales, incluyendo la dinámica de fluidos, propiedades de la batería y tareas de control [1, 3, 4, 31].

2.3 Detección de anomalías

La detección de anomalías se estudia ampliamente en diversas áreas de investigación y dominios de aplicación [11, 32]. En robótica y vehículos automatizados, La AD se ha utilizado para detectar patrones anormales como fallas de robots [24, 33] y escenarios de conducción peligrosos [42, 45].

Park et al. proponen un modelo variacional basado en la memoria a corto y largo plazo. autoencoder (LSTM-VAE) para reconstruir la distribución esperada de señales de sensores de robot. Se obtiene una puntuación de anomalía basada en la reconstrucción. luego se utiliza para la detección de anomalías [34]. Además, Ji et al. adoptan un mecanismo de atención para fusionar señales multisensoriales para una mayor robustez detección de anomalías en entornos inciertos [23]. Si bien estos nuestros enfoques se centran en AD para enunciados de problemas de agente único, nuestro Los escenarios de autopista consisten en interacciones sociales complejas entre múltiples agentes que involucran vehículos, y deben modelarse como tales.

En el ámbito de la detección de anomalías de tráfico mediante sistemas multiagente trayectorias, el trabajo más similar al nuestro es el espacio-temporal autoencoder gráfico (STGAE) propuesto con el conjunto de datos MAAD [42]. La arquitectura sigue una estructura codificador-decodificador para recon- trayectorias de vehículos estructurales, donde interacciones y movimientos de vehículos Se consideran utilizando capas de convolución de grafos espaciales y capas de convolución temporal, respectivamente. Se ha demostrado que el método es eficaz mediante el modelado de interacciones entre vehículos para detectar maniobras anómalas en el tráfico. Sin embargo, dicha red ignora la restricciones impuestas por las estructuras viales en las trayectorias de los vehículos y la variabilidad de los comportamientos de los conductores humanos. En este trabajo, explícitamente modelar tanto las interacciones vehículo a vehículo como las interacciones carril a vehículo. acciones para mejorar el rendimiento y utilizar una variación interpretable. arquitectura para aprender una distribución continua sobre comportamientos.

3. METODOLOGÍA

En esta sección, primero presentamos nuestra formulación del problema de detección de anomalías a partir de trayectorias de vehículos y luego explicamos nuestro marco SABeR-VAE propuesto.

3.1 Formulación del problema

Supongamos que [1,] vehículos se encuentran en un segmento de carretera en , cualquier momento y cada vehículo realiza una acción de aceleración y dirección cada vez paso de tiempo según políticas desconocidas. Deje $( ) = ( ), ( )$ ser las 2 coordenadas de la ^{el} vehículo en ese momento , donde [1, ...,]. Cada vehículo también tiene un conjunto de posiciones de carril permitidas correspondientes delante, a la izquierda y a la derecha del vehículo, siempre que en forma de una representación cartográfica discretizada que se muestra en la Fig. 1. En En cada paso de tiempo, se utiliza la posición de cada vehículo dentro del mapa para identificar sus nodos de carril delantero, izquierdo y derecho correspondientes. define una tupla = (frente, izquierda, derecha) $( )$ de tres 2 coordenadas que contiene la información del carril para el vehículo en el tiempo . La discretización ( ) El paso de ción solo impacta. En conjunto, la información observada de cada vehículo en cualquier momento es el desplazamiento relativo de coordenadas Nates $( ) = ( ) - ( ) \quad ( ) - ( ) = ( ), ( )$ $_{-1}$, · Una trayectoria de La longitud de cualquier vehículo se representa como $( ) \quad ( ) \quad ( )$ $_{0}$, $_{1}$, ..., $_{-1}$. Nosotros se supone que cualquier vehículo que esté dentro de una distancia de otro El vehículo en ese momento puede detectar y rastrear con precisión la coor- relativa (dinatos $( ) -) = (,)$. La flecha morada entre la verde y el vehículo azul en la Fig. 1 representa este tipo de interacción vehicular. Para el -ésimo coche, el número de coches observables es [0, − 1]. Dadas todas las trayectorias de los vehículos en una escena, nuestro objetivo es proporcionar una puntuación de anomalía AS R≥0 para cada tiempo .

3.2 Arquitectura

La figura 2 contiene el diagrama de arquitectura completo de SABeR-VAE, que analizaremos en esta sección.

3.2.1 Red de autoatención vehículo-vehículo. Nuestro objetivo es

aprender una representación de las interacciones espaciales entre vehículos. Más bien que utilizando métodos convolucionales como los de trabajos anteriores [28, 42], codificamos las posiciones de los vehículos en la carretera en cada momento con autoatención multi-cabeza de producto escalar a escala, que permite que cada dirigirse a aprender diferentes características de los datos [41].

Integramos el desplazamiento de cada automóvil con una capa múltiple. perceptrón (MLP) para obtener consultas :

$$( ) = \quad R^{1\times} , \tag{1}$$

donde es el tamaño de atención. Sea R = $(,1)$, ..., $(,)$ ser el desplazamientos de todos los coches vecinos para el -ésimo coche. Usamos dos otros MLP, para incrustar R para obtener claves y

Machine Translated by Google

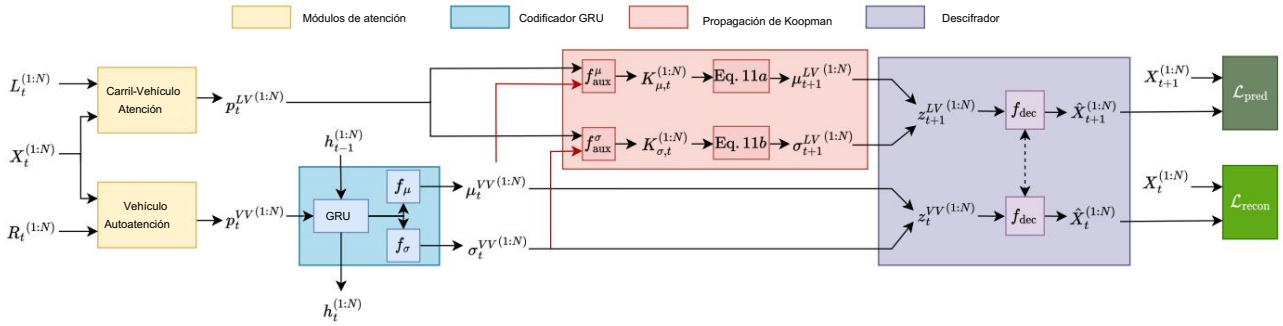


Figura 2: Arquitectura SABeR-VAE. La arquitectura SABeR-VAE intenta predecir los estados futuros de un paso de los vehículos condicionados a Posiciones actuales de los vehículos e información estructural del carril. Las interacciones de los vehículos se modelan mediante el módulo de autoatención mientras se permiten Las rutas son codificadas por el módulo de atención carril-vehículo. Un codificador GRU procesa las incrustaciones de autoatención a través del tiempo para producir una distribución latente. Luego, el operador de Koopman condicionado a las incrustaciones de carril propaga las distribuciones latentes hacia adelante, que Finalmente, se decodifica para predecir los siguientes estados. La red decodificadora comparte parámetros para la reconstrucción y la predicción.

valores respectivamente:

$$(R) = R \times$$
$$(R) = R \times \quad (2)$$

La codificación final de la posición de cada vehículo a partir de esta autoatención

La capa para el tiempo se calcula como:

$$\text{softmax} \frac{}{\sqrt{}} = R^{1\times} \quad (3)$$

Los vehículos inexistentes o no observados que se encuentren a una distancia mayor a la establecida no pueden contribuir a la puntuación de atención de los demás. vehículos. Por lo tanto, usamos una máscara para establecer la puntuación aportada por vehículos no observados a −∞.

3.2.2 Red de atención de carriles y vehículos. Utilizamos el mapa disponible. y la información del carril en una capa de atención de carril-vehículo separada. modelar maniobras legales en entornos estructurados. Similar a atención vehículo-vehículo, la consulta es una incrustación de . La información del carril de cada vehículo se utiliza para producir claves y valores. :

$$( ) = R^{1\times}$$
$$( ) = R^{3\times}$$
$$( ) = R^{3\times} \quad (4)$$

Las incrustaciones de vehículos condicionadas por carril se calculan de la siguiente manera:

$$\text{softmax} \frac{}{\sqrt{}} = R^{1\times} \quad (5)$$

Tenga en cuenta que no siempre se permitirán los tres nodos de carril. un vehículo. Por ejemplo, un automóvil en el carril más a la izquierda de una carretera no puede para girar legalmente a la izquierda. Por lo tanto, enmascaramos los nodos de carril no permitidos. como en la capa de autoatención.

3.2.3 Codificador recurrente. Una red de unidades recurrentes controladas (GRU). codifica la secuencia de características de autoatención para cada vehículo $_{0,1}$, ⋯, $_{-1}$ en una secuencia de distribuciones gaussianas en el espacio latente con correlación temporal. Por lo tanto, el espacio latente captura la naturaleza estocástica de los comportamientos humanos. Específicamente, después de incorporar la característica de atención vehículo-vehículo con una red , Pasamos la incrustación a través de la GRU para obtener el estado oculto. de cada vehículo para el intervalo de tiempo actual:

$$= \text{GRU} \quad -1, \quad (6)$$

Redes neuronales de media y varianza y producen parámetros para una distribución normal latente de dimensión condicionada a el estado oculto de un vehículo en cualquier momento:

$$= ( ) , \quad = ( ) . \quad (7)$$

3.2.4 Propagación latente con operador de Koopman. Mientras El codificador GRU codifica los comportamientos del vehículo en el espacio latente. condicionado únicamente a las interacciones pasadas y presentes de los vehículos, necesitamos un método para propagar las distribuciones latentes en el tiempo para predecir los estados futuros de los vehículos. Para ello, aprendemos un modelo estocástico. Operador de Koopman condicionado a las incrustaciones de vehículos en carriles para realizar esta tarea, como Balakrishnan y Upadhyay [4]. El El operador de Koopman es responsable del razonamiento temporal (modelado dinámica del estado del vehículo), mientras que los módulos de atención precedentes toman responsabilidad del razonamiento espacial.

En la teoría de operadores de Koopman, un sistema de tiempo discreto evoluciona Según la dinámica potencialmente no lineal +1 = ( ). Sin embargo, una función mapea el estado a un espacio donde evolucionan las dinámicas linealmente con el operador de Koopman K [4]:

$$K( ) = (( )) = (+1) \quad (8)$$

De manera similar, la inversa de la función traslada un observable de de vuelta al espacio dinámico original [4]:

$$^{-1} (K ( )) = \quad +1 \quad (9)$$

En nuestro caso, la función está representada por el codificador GRU y redes neuronales y , que en conjunto producen una dis- latente atribución N (,) condicionada a incrustaciones entre vehículos .

Al igual que el modelo de Koopman adversario estocástico (SAK) [4], nosotros Utilice redes neuronales auxiliares, $_{a}$ y $_{a}$ para predecir tridiagonal matrices de Koopman y forme la , en lugar de resolver sus problemas cerrados solución. Las salidas de $_{a}$ y $_{a}$ están condicionados a la distribuciones latentes actuales N , y las características del carril

Machine Translated by Google

, para que los operadores de Koopman capturen maniobras de ruta legales
en la propagación del espacio latente:

$$= \quad , \quad a \quad , \qquad = \quad , \quad a \quad , \tag{10}$$

Las matrices de Koopman predichas se aplican a la interacción entre vehículos.
distribuciones para propagar linealmente la media y la varianza de la
distribuciones latentes hacia adelante en el tiempo:

$$+1 = \quad , \quad + \tag{11a}$$

$$+1 = \quad , \quad + \tag{11b}$$

Intuitivamente, podemos interpretar el codificador GRU como una predicción de un
distribución de los comportamientos de los vehículos a partir de sus trayectorias actuales, y
El operador de Koopman se propaga a una distribución futura de un paso.
de comportamientos basados en la información del carril.

3.2.5 La red decodificadora. En este punto, tenemos dos conjuntos de
distribuciones en el espacio latente de dimensión para los estados actuales
y predicciones futuras de vehículos en cada momento: N , y
norte
+1 , +1 . Utilizamos el truco de reparametrización para muestrear un
punto de cada una de las distribuciones:

$$\begin{matrix} \text{N (0, 1)} & = & + \\ \text{N (0, 1)} & = & + \end{matrix} \qquad \begin{matrix} & & \\ +1 & +1 & +1 +1 \end{matrix} \tag{12}$$

Se utiliza un perceptrón multicapa dec como red decodificadora, similar a la de la
ecuación 9, para predecir un cambio de coordenadas del vehículo a partir de la
puntos latentes muestreados:

$$\hat{} = \quad , \quad \hat{} = \quad +1 . \tag{13}$$
dic dic

3.3 Formación y evaluación

3.3.1 Entrenamiento de extremo a extremo. Para comparar de manera justa nuestro método con
En comparación con los enfoques convolucionales previos, utilizamos una ventana deslizante similar.
enfoque de entrenamiento realizado por Wiederer et al. [42]. Específicamente,
trayectorias completas de longitud se dividen en pequeños segmentos superpuestos
segmentos, o ventanas, de longitud constante .

En nuestro objetivo de entrenamiento, minimizamos la pérdida de reconstrucción actual y la
pérdida de predicción futura de un paso del modelo dividiendo nuestras trayectorias de verdad
fundamental de entrada en estados actuales y estados futuros de un paso 1: −1. También
0: −2 regularizamos
las distribuciones actuales N , y se propagó de forma distribuida.
ciones N seguir una distribución normal estándar.
+1 , +1

Sea KL(,) la divergencia KL entre cualquier distribución gaussiana.
N (,) y la distribución normal estándar N (0, 1). Entonces la
Las pérdidas de predicción y reconstrucción regularizadas son:

$$\text{Lpred} = \quad 1 \cdot \text{KL} \quad , \quad + \quad + \quad + \quad 2$$

$$\text{Lrecon} = \quad 2 \cdot \text{KL} \quad , \quad + \quad - \quad - \quad 2, \tag{14}$$

dónde 1 y 2 son pesos ajustables que se aplican a la regularización.
de las distribuciones latentes similares a beta-VAE [21].

El objetivo general que optimizamos es:

$$L = \text{Lpred} + \text{Lrecon} \tag{15}$$

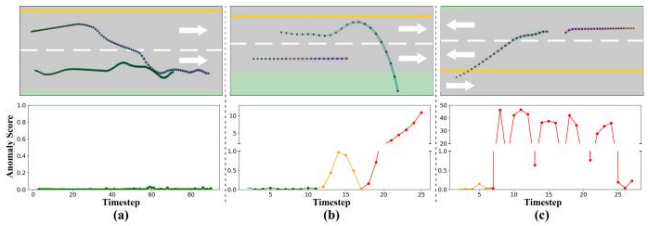


Figura 3: Trayectorias y puntuaciones de anomalías SABeR-VAE. (arriba)
fila) Ejemplos de escenarios de adelantamiento normal (a), conducción anormal
fuera de carretera (b) y conducción en sentido contrario (c) en el conjunto de datos MAAD.
Las flechas blancas apuntan hacia la dirección del flujo normal del tráfico. (fila inferior)
Curvas de puntuación de anomalía previstas para cada escenario anterior.
Los colores de las líneas dentro de las curvas muestran las etiquetas de referencia de
pasos de tiempo normales (verde), ignorados (amarillo) y anormales (rojo).

Volvemos a enmascarar las coordenadas de los vehículos no observados para que no se vean.
no contribuir a la pérdida.

Mientras que SAK [4] aplica la discrepancia media máxima (MMD) a
Sincronizar las distribuciones actuales y propagadas de su modelo de Koop-man con cualquier distribución general, fomentamos
explícitamente la sincronización de las distribuciones actuales y propagadas de su modelo de Koop-man con cualquier distribución general.
Las distribuciones del espacio latente siguen la distribución gaussiana estándar. Dejamos
experimentación de varios métodos de sincronización de Koopman para
La tarea de detección de anomalías como futura línea de investigación.

3.3.2 Evaluación de detección de anomalías. En el momento de la prueba, seguimos
La misma práctica de ventana deslizante que se realiza en la capacitación. Primero,
calculamos la pérdida de predicción futura de un paso Lpred, +1 = $\quad ( ) - \hat{} ( )$
+1 2 para cada vehículo en cada paso de tiempo, dentro de cada ventana de
una trayectoria completa.

Luego, promediamos la pérdida de predicción de los pasos de tiempo superpuestos.
entre todas las ventanas de la secuencia, para cada vehículo por separado.
Supongamos que W(,) es el conjunto de todas las ventanas en la trayectoria completa
que contienen el tiempo en el que se observa el vehículo. El promedio
El error de predicción para el automóvil es:

$$\bar{L}_{\text{antes},} ( ) = \frac{\text{W(,) Lpred, ( )}}{|\text{En(,)}|}, \tag{16}$$

donde Lpred, ( ) es el error de predicción del tiempo para el vehículo en
ventana del conjunto W(,) .

Finalmente, elegimos que la puntuación de anomalía AS sea la máxima.
Pérdida de predicción promedio en todos los vehículos en un paso de tiempo determinado:

$$\text{AS} = \text{máximo} \quad \bar{L}_{\text{antes},} ( ) \tag{17}$$
$$=1,...,$$

4. MONTAJE EXPERIMENTAL Y RESULTADOS

En esta sección, primero describimos el conjunto de datos MAAD en el que nos basamos.
Realizamos experimentos y detallamos las líneas base y las ablaciones. También
Presentamos nuestros resultados cuantitativos e interpretaciones del espacio latente.

4.1 Conjunto de datos MAAD y su aumento

El conjunto de datos MAAD [42] consta de 2 trayectorias de dos vehículos.
en una carretera recta de dos carriles con un separador que divide los dos
posibles direcciones, como se visualiza en la fila superior de la Fig. 3. Hay
80 trayectorias de entrenamiento y 66 trayectorias de prueba divididas con una longitud que varía desde 25

Machine Translated by Google

Tabla 1: Resultados de precisión de los métodos de referencia, ablación y SABeR en diez ejecuciones.

Método	Tipo de detección	AUROC ↑	AUPR-Anormal ↑	AUPR-Normal ↑	FPR @ 95%-TPR ↓
CVM	Pérdida de reconstrucción	83,1 ± 0,0	54,5 ± 0,0	96,0 ± 0,0	74,6 ± 0,0
RAE-Recon*	Pérdida de reconstrucción	56,2 ± 0,7	16,9 ± 1,0	89,5 ± 0,1	84,6 ± 0,3
STGAE*	Pérdida de reconstrucción	74,8 ± 5,1	37,8 ± 7,2	94,1 ± 1,3	77,8 ± 9,8
STGAE-KDE*	Una clase	86,3 ± 1,7	55,2 ± 7,7	97,2 ± 0,5	50,0 ± 7,9
RAE-Pred	Pérdida de predicción	72,5 ± 15,3	43,5 ± 17,4	92,9 ± 4,4	75,8 ± 10,6
VV-RAE	Pérdida de predicción	54,2 ± 4,9	14,8 ± 0,9	89,5 ± 2,4	77,1 ± 7,3
Att-LSTM-VAE	Pérdida de predicción	85,8 ± 0,7	64,9 ± 0,9	96,5 ± 0,3	66,6 ± 5,9
SABeR-AE	Pérdida de predicción	87,2 ± 0,4	69,0 ± 0,5	96,9 ± 0,2	64,1 ± 5,0
SABeR-VAE	Pérdida de predicción	87,0 ± 1,5	65,5 ± 2,9	96,9 ± 0,5	57,7 ± 7,6

* Estos resultados se presentan en [42].

hasta 127 pasos de tiempo. Para comparar de manera justa con las líneas base, estos dinámicos
Las trayectorias de longitud se submuestrean para producir aproximadamente 6,3 K
ventanas de entrenamiento y 3.1K de prueba de longitud constante = 15. ′Como
Las secuencias del conjunto de datos original no incluían detalles de mapa o carril.
ampliamos los datos para incluir esta información. Específicamente,
Discretizó la autopista en la dirección de la coordenada - en bloques de
longitud cinco metros como se muestra en la Fig. 1, y se almacenaron las 2 coordenadas
de los bloques delantero, izquierdo y derecho para cada vehículo en cada paso de tiempo
en todas las trayectorias. Elegimos un factor de discretización de cinco metros porque los
vehículos viajaban en promedio cinco metros o menos en cada paso de tiempo.
Todas las secuencias de entrenamiento consisten en comportamientos normales del vehículo, como
conducir uno al lado del otro, adelantar, seguir y conducir en sentido contrario
direcciones. En contraste, la división de prueba contiene tanto normales como 11
Clases de comportamiento anómalo como adelantamientos agresivos, empujones
aparte de conducir demasiado cerca del vehículo de adelante, conducir fuera de la carretera y en sentido contrario.

4.2 Métodos de referencia

Comparamos con las líneas base implementadas por Wiederer et al. que
depende de la pérdida de reconstrucción en lugar del error de predicción futura [42]. (1) El
modelo de velocidad constante (CVM) es un estándar
línea base que predice los siguientes estados de los vehículos asumiendo cada
El vehículo viaja a la misma velocidad que en el último paso de tiempo, sin
modelando cualquier relación entre vehículos. (2) Autoencoder recurrente
(RAE-Recon) utiliza una red LSTM para codificar y decodificar una secuencia de
coordenadas de un espacio latente no regularizado, intentando minimizar la pérdida de
reconstrucción. (3) Grafo espacio-temporal
El autoencoder (STGAE) es un método convolucional que modela los comportamientos entre
vehículos y genera parámetros para una distribución bivariada que describe el estado estimado
de la pose reconstruida.
de vehículos, y está entrenado para maximizar la probabilidad logarítmica de la
distribución de probabilidad estimada. Finalmente, (4) el STGAE-KDE
La línea base ajusta un estimador de densidad de núcleo (KDE) a la distribución no regularizada.
espacio latente de un modelo STGAE entrenado para predecir la clase única
probabilidad de que un conjunto de puntos se origine a partir de un comportamiento normal
ventana. A diferencia del STGAE-KDE, nuestro SABeR-VAE no requiere
un costoso procedimiento de ajuste KDE ya que nuestra puntuación de anomalía únicamente
Se basa en el error de predicción y seguimos modelando las relaciones entre vehículos.
a diferencia de CVM y RAE-Recon.

Además, entrenamos modelos de ablación con predicción futura.
pérdida para identificar el impacto de diferentes componentes en nuestro método.
Entrenamos (5) un autoencoder recurrente no regularizado (RAE-Pred)
utilizando un MLP determinista estándar para propagar puntos latentes
hacia adelante en el tiempo, sin modelar explícitamente ningún
comportamiento entre vehículos , como el RAE-Recon. (6) Un autoencoder recurrente con un
El módulo de autoatención vehículo-vehículo (VV-RAE) minimiza el error de predicción al
modelar las relaciones entre vehículos. También entrenamos (7)
una variante determinista de SABeR-VAE sin una latente regularizada
espacio, SABeR-AE. SABeR-AE utiliza tanto la autoatención del vehículo como la atención del vehículo.
y atención del vehículo al carril como SABeR-VAE, pero codifica trayectorias
en un espacio latente no regularizado (no interpretable). (8) Para probar el
eficacia del operador de Koopman en SABeR-VAE, entrenamos
un modelo de ablación (Att-LSTM-VAE) que reemplaza al modelo de Koopman
módulo de propagación con un decodificador recurrente como el de Park et al. [34].

4.3 Métricas de evaluación cuantitativa

Evaluamos cuantitativamente la efectividad de los modelos en el MAAD.
conjunto de datos utilizando cuatro métricas. (1) Área bajo la curva ROC
La curva característica (AUROC) se calcula graficando la tasa de falsos
positivos (FPR) y la tasa de verdaderos positivos (TPR) de un modelo sobre
varios umbrales de decisión y el cálculo del área bajo la
curva. Un modelo con mayor AUROC funciona mejor, y un modelo perfecto
El clasificador tiene un AUROC del 100%. Sin embargo, el AUROC está sesgado en
conjuntos de datos donde hay muy pocas etiquetas positivas, como en el campo
de identificación de valores atípicos. Por lo tanto, el FPR puede ser engañosamente bajo,
produciendo un valor AUROC optimista. Calculamos (2) el Área
Bajo la curva de precisión-exhaustividad (AUPR) con los puntos anómalos
siendo la clase positiva (AUPR-Anormal) y (3) con normal
puntos siendo positivos (AUPR-Normal). La métrica AUPR se ajusta
para distribuciones de conjuntos de datos sesgadas, y evaluamos la efectividad del modelo
para clasificar anomalías y no clasificar erróneamente puntos normales.
con AUPR-Anormal y AUPR-Normal respectivamente. Finalmente, nosotros
usar (4) FPR @ 95%-TPR para comprobar la tasa de etiquetado erróneo normal
puntos en los que TPR es alto.

4.4 Resultados de precisión

Cada modelo fue entrenado durante 500 épocas en la división de entrenamiento con un
GPU Tesla V100 [25]. Al igual que Wiederer et al., cada , calculamos métricas para
elección de hiperparámetro en una división de validación del 20% del total.
datos de prueba y elegir evaluar el mejor conjunto de hiperparámetros
para cada método respectivo en la división de prueba completa [42]. Más
Los detalles sobre el entrenamiento y las opciones de hiperparámetros se proporcionan en
el material complementario [10]. La Tabla 1 contiene los resultados de precisión de

Machine Translated by Google

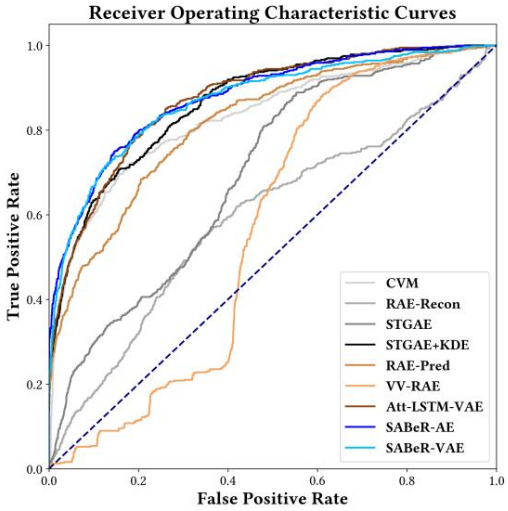


Figura 4: Curvas ROC de los métodos probados.

Tabla 2: AUROC (↑) de los métodos por tipo de anomalía.

Tipo de anomalía	CVM	STGAE-KDE*	SABeR-AE	SABeR-VAE
Reeving	96.7	94.6	87.9	89.5
Empujando A un lado	91.5	90.4	88.6	91.3
Se extiende a la derecha	87.7	96.2	86.7	95.2
Se extiende a la izquierda	90.9	96.6	96.2	95.9
Derrape fuera	88.7	98.2	98.2	99.7
de la carretera	96.9	99.7	100.0	99.8
En sentido contrario	63.2	73.2	100.0	99.3

* Estos resultados se presentan en [42].

líneas base, ablaciones y los métodos SABeR en la división de prueba de el conjunto de datos MAAD. Cada método, excepto CVM, fue entrenado diez veces. tiempos separados con los mismos hiperparámetros, y reportamos el promedio y desviación estándar de los resultados de cada método a lo largo del tiempo diez ejecuciones. La figura 4 muestra las curvas ROC para cada método.

Entre los modelos de referencia, el modelo CVM simple ya funciona así como un detector de anomalías, ya que su AUROC es solo un 3% menor que que el del método STGAE-KDE. CVM tampoco tiene variación de resultados ya que es un modelo determinista que no está entrenado. El El modelo RAE-Recon basado en LSTM no puede distinguir eficazmente entre anomalías y escenarios normales utilizando la pérdida de reconstrucción, ya que no modela la información del vehículo o del carril. Si bien es recurrente Los modelos codifican las características del paso de tiempo actual basándose únicamente en datos anteriores. pasos de tiempo, los métodos de convolución temporal extraen información de toda la trayectoria, lo que ayuda a predecir una reconstrucción más precisa . Por lo tanto, el método STGAE convolucional drásticamente Mejora las puntuaciones AUROC y AUPR con respecto a RAE-Recon.

Sin embargo, una vez que incorporamos una red de propagación latente y Predice pasos de tiempo futuros, la ablación RAE-Pred aumenta el AUROC Supera a RAE-Recon en un 29 % e incluso supera a STGAE en la métrica AUPR-Anormal, sin siquiera modelar los comportamientos entre vehículos.
Este resultado sugiere la idea de que las redes recurrentes aprenden a modelar. comportamientos normales con mayor precisión con error de predicción futuro, que el error de reconstrucción de los pasos de tiempo observados, lo que ayuda a rendimiento de AD. Además, los métodos recurrentes son capaces de alcanzando el mismo rendimiento que los métodos convolucionales, mientras que basándose únicamente en datos pasados. Aun así, se ha demostrado que RAE-Pred es inestable ya que produce una alta varianza en los resultados a lo largo de los diez entrenados modelos. Esta varianza fue causada por dos de las diez ejecuciones que lograron Solo 45% AUROC. STGAE también tiene la mayor varianza en los resultados. entre líneas base ya que es un método estocástico que reconstruye un distribución sobre estados, en lugar del CVM determinista y RAE-Recon se aproxima, pero es más estable que RAE-Pred.

Vemos que agregar una capa de autoatención vehículo-vehículo en el modelo VV-RAE en realidad perjudica el rendimiento y da resultados similares. a RAE-Recon. Efectivamente, la capa de autoatención vehículo-vehículo no aprendió características útiles para la tarea de predicción futura, y confundió a las generaciones del modelo. Este resultado podría ser consecuencia de una red neuronal de baja complejidad o una opción potencialmente mala para distancia de enmascaramiento.

El modelo de predicción de una clase STGAE-KDE ajusta un KDE a la espacio latente del STGAE para aprender una distribución de latente normal comportamientos. Como tal, este enfoque de clasificación de una sola clase mejora tasas de detección y estabilidad del entrenamiento en el STGAE de tal manera que supera a otras líneas base. Sin embargo, el proceso de ajuste de un La KDE a un espacio de gran dimensión es computacionalmente compleja y parte restrictiva del método. Con regularización gaussiana de la espacio latente, nuestro SABeR-VAE agrupa comportamientos similares y aprende una distribución latente sin ajustar una KDE, que nosotros Discutir en el apartado 4.5.

Finalmente, SABeR-AE y SABeR-VAE incorporan un vehículo de carril. Módulo de atención para capturar el efecto de la estructura del entorno en los comportamientos normales. Vemos que SABeR-AE supera todos los métodos en AUROC y AUPR-Anormal con baja varianza, mostrando la importancia de modelar la estructura del entorno en Este campo. SABeR-VAE funciona ligeramente mejor que STGAE-KDE. en AUROC, y aumenta significativamente la puntuación AUPR-Anormal en un 18%. Sin embargo, la estocasticidad del método SABeR-VAE dificulta su reproducibilidad, y las puntuaciones AUROC oscilaron entre el 84% y el 18%. 89% durante las diez sesiones de entrenamiento. SABeR-VAE reduce aún más el FPR promedio al 95%-TPR de SABeR-AE en un 10%. STGAE-KDE y el Dos enfoques SABeR tienen AUPR-Normal similar. SABeR-VAE también supera a Att-LSTM-VAE, lo que significa que un decodificador recurrente es innecesario cuando se utiliza el operador Koopman.

Presentamos ejemplos de cómo SABeR-VAE puntúa los pasos de tiempo anómalos. en la Fig. 3. Allí, una maniobra de adelantamiento normal fue calificada como muy bajo durante toda la trayectoria, mientras que salirse de la carretera o conducir en la dirección equivocada obtuvieron puntuaciones altas. También podemos ver en Figura 3.b que pasos de tiempo donde los vehículos actúan normalmente antes de Los comportamientos erráticos siguen puntuándose correctamente como bajos. La Tabla 2 muestra el AU- ROC por tipo de anomalía para los métodos CVM, STGAE-KDE y SABeR. SABeR-VAE mejora la detección de conducción en sentido contrario en un 35 % con respecto a STGAE- KDE, mientras que su rendimiento es comparable en otras métricas. El análisis completo La versión de la Tabla 2 se proporciona en el material complementario [10].

4.5 Interpretación del espacio latente

SABeR-VAE es un modelo variacional con un espacio latente continuo. de tal manera que las observaciones con características aprendidas similares se agrupen. se acercaron más entre sí en el espacio latente. En la Fig. 5.a, trazamos el Espacio latente de prueba-dividido de uno de los modelos SABeR-VAE evaluado en la Tabla 1. Los puntos se agrupan en tres regiones distintas en la espacio latente, al que nos referiremos como “inferior”, “medio” y “superior” grupos respectivamente. Vemos a partir de las trayectorias muestreadas que el

Machine Translated by Google

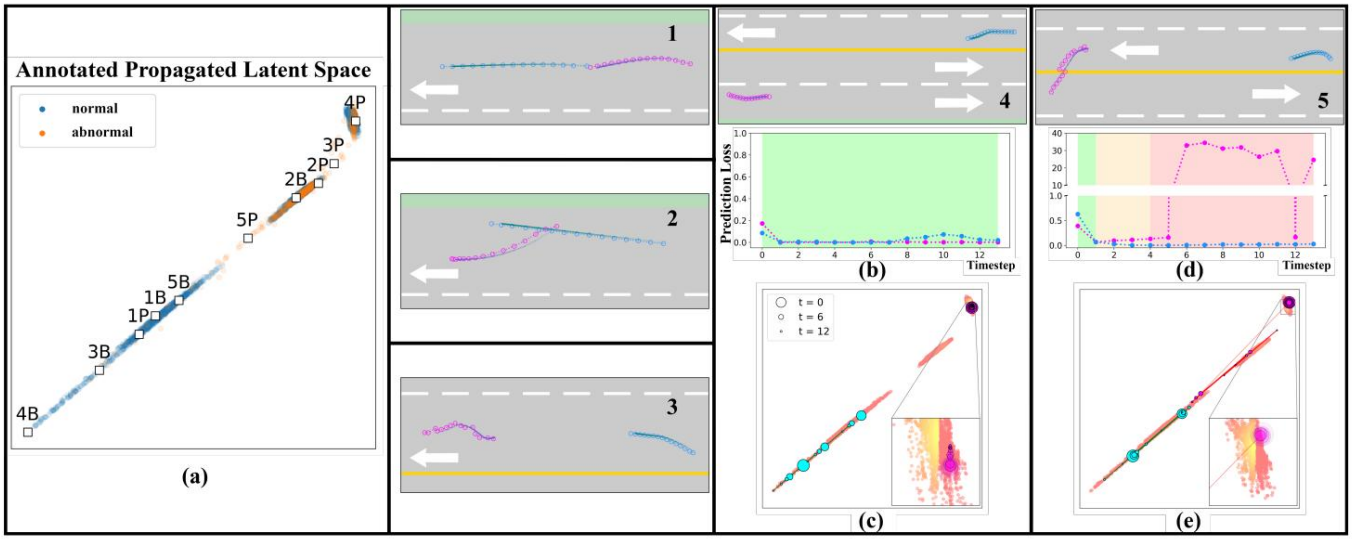


Figura 5: Espacio latente propagado de Koopman y trayectorias correspondientes. (a) Codificamos cada trayectoria de ventana en la división de prueba del conjunto de datos MAAD y graficamos las 2 posiciones latentes muestreadas del paso de tiempo final de las ventanas. Los puntos azules corresponden a ventanas normales de verdad fundamental, mientras que los naranjas son anormales. (1-5) Cinco ventanas de escenario están codificadas en el espacio latente y están anotadas explícitamente en (a). Cada una de las cinco ventanas tiene dos puntos latentes para los vehículos rosa y azul respectivamente. (p. ej., las anotaciones “1B” y “1P” son los puntos latentes de los vehículos azul y rosa en la ventana de trayectoria de la carretera (1). Dentro de las cinco ventanas de trayectoria, las líneas continuas son la trayectoria real del vehículo, mientras que los círculos abiertos son predichos por SABeR-VAE. Las flechas blancas indican la dirección del flujo de tráfico. (b y d) Las curvas de error de predicción para las trayectorias 4 y 5 respectivamente. (c y e) La trayectoria de los puntos latentes para las ventanas de vehículos 4 y 5 respectivamente. Un mapa de calor del espacio latente original se traza en naranja en el fondo. Los círculos azules y rosas son las trayectorias latentes del coche azul y rosa a lo largo del tiempo. Los círculos más grandes codifican el paso de tiempo inicial de la ventana y disminuyen de tamaño a medida que avanza la ventana.

Los clústeres inferior y medio codifican los vehículos que viajan hacia la dirección − (izquierda) en cualquiera de los dos carriles superiores de la autopista, mientras que el clúster superior codifica los vehículos que viajan hacia la derecha en los dos carriles inferiores. Por ejemplo, los puntos 1P, 2P, 3B, 4B y 5B corresponden a los autos azules (B) y rosas (P) que viajan hacia la izquierda en los carriles superiores. De manera similar, la trayectoria del auto rosa que conduce hacia la derecha en la ventana 4 se codifica en el punto 4P en el clúster superior del espacio latente. Los vehículos que también están físicamente cerca e interactúan entre sí se codifican cerca en el espacio latente, como se muestra con los puntos latentes correspondientes a las ventanas 1 y 2. El clúster medio incrusta escenarios anómalos de los carriles superiores donde los vehículos están lo suficientemente cerca como para interactuar entre sí, como la ventana 2.

Además, las trayectorias anómalas y no interactivas, mal predichas, se codifican en las afueras de las distribuciones de clústeres principales. Por ejemplo, los coches rosas en las trayectorias 3 y 5 circulan en la dirección equivocada. Estas trayectorias presentan un alto error de predicción, como se observa en la escasa superposición entre las posiciones predichas de los círculos abiertos y las trayectorias reales. Por consiguiente, esos puntos mal predichos se codifican en los espacios entre los clústeres inferior y medio, y medio y superior, respectivamente.

En cambio, las trayectorias 1 y 4 presentan bajas pérdidas y se codifican en posiciones dentro de los clústeres primarios. Por lo tanto, el espacio latente ha aprendido una correspondencia entre las rutas de carril permitidas y el comportamiento esperado del vehículo.

Finalmente, visualizamos la transformación del espacio latente a lo largo del tiempo dentro de una ventana de trayectoria para mostrar el impacto interpretable del operador de Koopman aprendido. Las figuras 5.c y 5.e muestran la transformación del espacio latente a medida que avanza el tiempo en la trayectoria ventanas 4 y 5. Podemos ver en la Fig. 5.c que las trayectorias latentes azul y rosa permanecen en los clústeres inferior y superior respectivamente, ya que los vehículos siguen la dirección correcta en la carretera durante toda la ventana 4. Por el contrario, vemos en la Fig. 5.e que la trayectoria latente rosa comienza en el clúster superior ya que el vehículo rosa en la trayectoria 5 está en uno de los dos carriles inferiores de la carretera. Pero, en el paso de tiempo 6, el coche rosa cruza la mediana de la carretera hacia el carril de dirección incorrecta. Por lo tanto, vemos un salto en la trayectoria latente del coche rosa en la Fig. 5.e desde el clúster superior a los clústeres inferior y medio que corresponden a los dos carriles superiores. Al mismo tiempo, la Fig. 5.d tiene un pico en la pérdida de predicción del vehículo rosa. Para el resto de la ventana de trayectoria, el coche rosa oscila drásticamente en el espacio latente alrededor del clúster medio, ya que el modelo espera que el vehículo viaje hacia la izquierda. Cabe destacar que, si bien el vehículo rosa en la trayectoria 5 se comporta de forma anómala, esto no afecta la trayectoria latente del vehículo azul en la misma ventana, ya que los vehículos no están lo suficientemente cerca como para colisionar. En resumen, el operador de Koopman modela explícitamente esta transición de estados normales a anómalos en el espacio latente, de manera interpretable.

5. CONCLUSIONES Y TRABAJOS FUTUROS

En este artículo, proponemos un nuevo marco para la detección de anomalías con una red VAE recurrente no supervisada condicionada a información estructurada del entorno e interacciones vehiculares. Mostramos

Modelar esta información estructurada es fundamental para lograr una alta precisión en una amplia gama de tipos de anomalías y estudiar la interpretabilidad de la arquitectura. El trabajo futuro incluye el uso de datos brutos de sensores para la detección y su integración con un controlador de vehículo.

Machine Translated by Google

EXPRESIONES DE GRATITUD

Agradecemos a Julian Wiederer por facilitarnos el acceso al conjunto de datos MAAD y a Kaushik Balakrishnan por sus valiosas aportaciones. Este trabajo se basa en investigaciones financiadas por la Fundación Nacional de Ciencias (NSF) bajo la subvención n.º 2143435. Asimismo, utiliza recursos del programa de Instrumentación para la Investigación a Gran Escala de la NSF (NSF) , subvención n.º 1725729, y de la Universidad de Illinois en Urbana-Champaign.

REFERENCIAS

[1] Hassan Arbabi e Igor Mezić. 2017. Estudio de la dinámica en flujos post-transitorios mediante la descomposición de modos de Koopman. Phys. Rev. Fluids 2 (dic. 2017), 124402. Número 12. https://doi.org/10.1103/PhysRevFluids.2.124402 [2] Davide
Azzalini, Alberto Castellini, Matteo Luperto, Alessandro Farinelli y Francesco Amigoni. 2020. Hmms para detección de anomalías en robots autónomos.
En Conferencia Internacional sobre Agentes Autónomos y Sistemas Multiagente. ACM, 105–113.

[3] Kaushik Balakrishnan y Devesh Upadhyay. 2020. Modelo de Koopman adversario profundo para sistemas de reacción-difusión. Preimpresión de arXiv arXiv:2006.05547 (2020).
[4] Kaushik Balakrishnan y Devesh Upadhyay. 2021. Modelo estocástico adversario de Koop-man para sistemas dinámicos. CoRRabs/2109.05095 (2021). arXiv:2109.05095 https://arxiv.org/abs/ 2109.05095 [5] Umang Bhatt, McKane
Andrus, Adrian Weller y Alice Xiang. 2020. Explicabilidad del aprendizaje automático para las partes interesadas externas. Preimpresión de arXiv arXiv:2007.05408 (2020).

[6] Raunak P Bhattacharyya, Derek J Phillips, Changliu Liu, Jayesh K Gupta, Katherine Driggs-Campbell y Mykel J Kochenderfer. 2019. Simulación de propiedades emergentes del comportamiento de conducción humana mediante aprendizaje por imitación aumentado con recompensa multiagente . En 2019 International Conference on Robotics and Automation (ICRA). IEEE, 789–795.

[7] Daniel Bogdoll, Maximilian Nitsche y J Marius Zöllner. 2022. Detección de anomalías en la conducción autónoma: una revisión. En Actas de la Conferencia IEEE/CVF sobre Visión por Computadora y Reconocimiento de Patrones. 4488–4499.
[8] Nicolas Boulanger-Lewandowski, Yoshua Bengio y Pascal Vincent. 2012. Modelado de dependencias temporales en secuencias de alta dimensión: aplicación a la generación y transcripción de música polifónica. En Actas de la 29.ª Conferencia Internacional sobre Aprendizaje Automático (Edimburgo, Escocia) (ICML'12). Omnipress, Madison, WI, EE. UU., 1881-1888.

[9] Yuning Chai, Benjamin Sapp, Mayank Bansal y Dragomir Anguelov. 2020.
MultiPath: Múltiples hipótesis probabilísticas de trayectorias de anclaje para la predicción del comportamiento. En Actas de la Conferencia sobre Aprendizaje Robótico (Actas de Investigación en Aprendizaje Automático, Vol. 100), Leslie Pack Kaelbling, Danica Kragic y Komei Sugiura (Eds.). PMLR, 86–99. https://proceedings.mlr.press/v100/chai20a. html

[10] Neeloy Chakraborty, Aamir Hasan, Shuijing Liu, Tianchen Ji, Weihang Liang, D. Livingston McPherson y Katherine Driggs-Campbell. 2023. Autoencoder variacional recurrente basado en atención estructural para la detección de anomalías en vehículos de carretera. https://doi.org/10.48550/ ARXIV.2301.03634 [11] Varun Chandola, Arindam Banerjee y Vipin
Kumar. 2009. Detección de anomalías: una revisión. ACM computing surveys (CSUR) 41, 3 (2009), 1–58.

[12] Jingyuan Chen, Guanchen Ding, Yuchen Yang, Wenwei Han, Kangmin Xu, Tianyi Gao, Zhe Zhang, Wanping Ouyang, Hao Cai y Zhenzhong Chen. 2021. Detección de anomalías en vehículos de modalidad dual mediante seguimiento de trayectoria bilateral. En actas de la conferencia IEEE/CVF sobre visión por computadora y reconocimiento de patrones. 4016–4025 .

[13] Taesung Choi, Dongkun Lee, Yuchae Jung y Ho-Jin Choi. 2022. Detección de anomalías en series temporales multivariadas mediante un modelo híbrido SeqVAE-CNN.
En la Conferencia Internacional de Redes de Información (ICOIN) de 2022. 250–253. https://doi.org/ 10.1109/ICOIN53446.2022.9687205 [14] Junyoung Chung,
Kyle Kastner, Laurent Dinh, Kratarth Goel, Aaron C Courville y Yoshua Bengio. 2015. Un modelo recurrente de variables latentes para datos secuenciales. En Advances in Neural Information Processing Systems, C. Cortes, N. Lawrence, D. Lee, M. Sugiyama y R. Garnett (Eds.), Vol. 28. Curran Associates, Inc. https://proceedings.neurips.cc/paper/2015/file/ b618c3210e934362ac261db280128c22-Paper.pdf [15] Nahuel Costa, Luciano Sánchez e Inés Couso. 2021. Enfoque de autoencoder variacional
recurrente semisupervisado para el diagnóstico visual de la fibrilación auricular.

IEEE Access 9 (2021), 40227–40239. https://doi.org/10.1109/ACCESS.2021.3064854 [16] Oliver
De Candido, Maximilian Binder y Wolfgang Utschick. 2021. Un algoritmo interpretable de detección de cambios de carril basado en la detección de anomalías mediante autoencoder profundo. En 2021 IEEE Intelligent Vehicles Symposium (IV). 516–523. https://doi.org/10.1109/IV48863.2021.9575599

[17] Nachiket Deo, Eric Wolff y Oscar Beijbom. 2021. Predicción de trayectorias multimodales condicionada a recorridos de grafos de carriles. En la 5.ª Conferencia Anual sobre
Aprendizaje de robots. https://openreview.net/forum?id=hu7b7MPCqiC
[18] Yongqi Dong, Kejia Chen, Yinxuan Peng y Zhiyuan Ma. 2022. Estudio comparativo sobre aprendizaje automático supervisado versus semisupervisado para la detección de anomalías en la red CAN del vehículo. https://doi.org/10.48550/ARXIV.2207. 10286

[19] Karol Gregor, Ivo Danihelka, Alex Graves, Danilo Rezende y Daan Wierstra.
2015. DRAW: Una red neuronal recurrente para la generación de imágenes. En Actas de la 32.ª Conferencia Internacional sobre Aprendizaje Automático (Actas de Investigación en Aprendizaje Automático, vol. 37), Francis Bach y David Blei (eds.). PMLR, Lille, Francia, 1462–1471. https:// proceedings.mlr.press/v37/gregor15.html [20] Peihua Han, André Listou
Ellefsen, Guoyuan Li, Finn Tore Holmeset y Houxi -ang Zhang. 2021. Detección de fallos con un autoencoder variacional basado en LSTM para componentes marítimos. IEEE Sensors Journal 21, 19 (2021), 21903–21912. https://doi.org/10.1109/JSEN.2021.3105226

[21] Irina Higgins, Loïc Matthey, Arka Pal, Christopher P. Burgess, Xavier Glorot, Matthew M. Botvinick, Shakir Mohamed y Alexander Lerchner. 2017. beta- VAE: Aprendizaje de conceptos visuales básicos con un marco variacional restringido.
En ICLR.

[22] Boris Ivanovic, Karen Leung, Edward Schmerling y Marco Pavone. 2020. Modelos generativos profundos multimodales para la predicción de trayectorias: un enfoque de autoencoder variacional condicional. IEEE Robotics and Automation Letters 6, 2 (2020), 295–302.
[23] Tianchen Ji, Arun Narenthiran Sivakumar, Girish Chowdhary y Katherine Driggs-Campbell. 2022. Detección proactiva de anomalías para la navegación de robots con fusión multisensorial. IEEE Robotics and Automation Letters 7, 2 (2022), 4975–4982.
[24] Tianchen Ji, Sri Theja Vuppala, Girish Chowdhary y Katherine Driggs- Campbell. 2021. Detección de anomalías multimodales para entornos no estructurados e inciertos. En Conferencia sobre aprendizaje robótico. PMLR, 1443–1455.
[25] Volodymyr Kindratenko, Dawei Mu, Yan Zhan, John Maloney, Sayed Hadi Hashemi, Benjamin Rabe, Ke Xu, Roy Campbell, Jian Peng y William Gropp.
2020. HAL: Sistema informático para aprendizaje profundo escalable. Práctica y experiencia en computación avanzada para la investigación (Portland, OR, EE. UU.) (PEARC '20). Asociación para la Maquinaria Informática, Nueva York, NY, EE. UU., 41–48. https: //doi.org/ 10.1145/3311790.3396649 [26] DP Kingma
y M. Welling. 2014. Auto-encoding variational bayes.. En 2nd International Conference on Learning Representations, ICLR 2014 - Conference Track Proceedings. Machine Learning Group, Universiteit van Amsterdam.
[27] Namhoon Lee, Wongun Choi, Paul Vernaza, Christopher B. Choy, Philip HS Torr y Manmohan Chandraker. 2017. DESIRE: Predicción de futuro lejano en escenas dinámicas con agentes interactivos. En 2017 IEEE Conference on Computer Vision and Pattern Recognition (CVPR). 2165–2174. https://doi.org/10.1109/CVPR.2017.233 [28] Ming Liang, Bin Yang, Rui Hu, Yun Chen, Renjie
Liao, Song Feng y Raquel Urtasun. 2020. Aprendizaje de representaciones gráficas de carriles para la predicción de movimiento. En Computer Vision – ECCV 2020, Andrea Vedaldi, Horst Bischof, Thomas Brox y Jan-Michael Frahm (Eds.). Springer International Publishing, Cham, 541–556.

[29] Shuijing Liu, Peixin Chang, Haonan Chen, Neeloy Chakraborty y Katherine Driggs-Campbell. 2022. Aprendizaje para navegar intersecciones con inferencia no supervisada de rasgos del conductor. En 2022 International Conference on Robotics and Automation (ICRA). 3576–3582. https://doi.org/10.1109/ICRA46639.2022.9811635 [30] Lu Mi, Hang Zhao, Charlie Nash, Xiaohan Jin, Jiyang Gao, Chen Sun, Cordelia Schmid, Nir
Shavit, Yuning Chai y Dragomir Anguelov. 2021. HDMapGen: un modelo generativo de grafos jerárquico de mapas de alta definición. En Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 4227–4236.

[31] Jeremy Morton, Freddie D. Witherden y Mykel J. Kochenderfer. 2019. Modelos de Koopman variacionales profundos: inferencia de observaciones de Koopman para modelado y control de dinámicas conscientes de la incertidumbre. En Actas de la Vigésimo Octava Conferencia Internacional Conjunta sobre Inteligencia Artificial, IJCAI-19. Conferencias Internacionales Conjuntas sobre la Organización de Inteligencia Artificial, 3173–3179. https: //doi.org/10.24963/ijcai.2019/440 [32] Guansong Pang, Chunhua Shen,
Longbing Cao y Anton Van Den Hengel. 2021.
Aprendizaje profundo para la detección de anomalías: una revisión. ACM Computing Surveys (CSUR) 54, 2 (2021), 1–38.
[33] Daehyung Park, Zackory Erickson, Tapomayukh Bhattacharjee y Charles C Kemp. 2016. Monitoreo de ejecución multimodal para la detección de anomalías durante la manipulación robótica. En 2016 IEEE International Conference on Robotics and Automation (ICRA). IEEE, 407–414.

[34] Daehyung Park, Yuuna Hoshi y Charles C Kemp. 2018. Un detector de anomalías multimodal para la alimentación asistida por robot utilizando un autoencoder variacional basado en lstm. IEEE Robotics and Automation Letters 3, 3 (2018), 1544–1551.
[35] Tim Salzmann, Boris Ivanovic, Punarjay Chakravarty y Marco Pavone. 2020.
Trajectron++: Predicción de trayectorias dinámicamente factibles con datos heterogéneos. En Conferencia Europea sobre Visión por Computadora. Springer, 683–700.
[36] Christoph Schöller, Vincent Aravantinos, Florian Lay y Alois Knoll. 2020. Lo que el modelo de velocidad constante puede enseñarnos sobre la predicción del movimiento de los peatones. IEEE Robotics and Automation Letters 5, 2 (2020), 1696–1703.
[37] Jonas Herskind Sejr y Anna Schneider-Kamp. 2021. Detección explicable de valores atípicos : ¿Qué, para quién y por qué? Machine Learning with Applications 6 (2021), 100172. https://doi.org/10.1016/ j.mlwa.2021.100172

Machine Translated by Google

[38] Conozca a Shah, Zhi ling Huang, Ankita Gajanan Laddha, Matthew Langford, Blake Barber, Sidney Zhang, Carlos Vallespi-Gonzalez y Raquel Urtasun. 2020. Li- RaNet: Predicción de trayectorias de extremo a extremo mediante fusión espacio-temporal de radar. En CoRL.

[39] John Sipple y Abdou Youssef. 2022. Un método de propósito general para aplicar la IA explicable a la detección de anomalías. En Simposio Internacional sobre Metodologías. para sistemas inteligentes. Springer, 162–174.

[40] Kihyuk Sohn, Honglak Lee y Xinchen Yan. 2015. Aprendizaje de salida estructurada Representación mediante modelos generativos condicionales profundos. En Avances en redes neuronales. Sistemas de procesamiento de información, C. Cortes, N. Lawrence, D. Lee, M. Sugiyama y R. Garnett (Eds.), Vol. 28. Curran Associates, Inc. https://proceedings.neurips.cc/ papel/2015/archivo/8d55a249e6baa5c06772297520da2051-Paper.pdf

[41] Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N. Gómez, Lukasz Kaiser e Illia Polosukhin. 2017. La atención lo es todo Lo necesitas. https://doi.org/10.48550/ARXIV.1706.03762

[42] Julian Wiederer, Arij Bouazizi, Marco Troina, Ulrich Kressel y Vasileios Belagiannis . 2022. Detección de anomalías en trayectorias de múltiples agentes para automatización Conducción. En Conferencia sobre Aprendizaje Robótico. PMLR, 1223–1233.

[43] Chule Yang, Alessandro Renzaglia, Anshul Paigwar, Christian Laugier y Dan -wei Wang. 2019. Evaluación del comportamiento de conducción y detección de anomalías para Vehículos inteligentes. En la Conferencia Internacional IEEE de 2019 sobre Cibernética y Sistemas Inteligentes (CIS) y Conferencia IEEE sobre Robótica, Automatización y Mecatrónica (RAM). 524–529. https://doi.org/10.1109/CIS-RAM47153.2019.9095790

[44] Yu Yao, Xizi Wang, Mingze Xu, Zelin Pu, Yuchen Wang, Ella Atkins y David Crandall. 2022. DoTA: detección no supervisada de anomalías de tráfico en vídeos de conducción. Transacciones IEEE sobre análisis de patrones e inteligencia artificial (2022).

[45] Yu Yao, Mingze Xu, Yuchen Wang, David J Crandall y Ella M Atkins. 2019. Detección no supervisada de accidentes de tráfico en vídeos en primera persona. En 2019 IEEE/RSJ Conferencia Internacional sobre Robots y Sistemas Inteligentes (IROS). IEEE, 273–280.

[46] Jun Yong Yoon, Jinseop Jeong y Woosuk Sung. 2022. Diseño e implementación de mapeo HD, control de vehículos y comunicación V2I para robotaxis Servicios. Sensores 22, 18 (2022). https://doi.org/10.3390/s22187049

[47] Xinhai Zhang, Jianbo Tao, Kaige Tan, Martin Törngren, José Manuel Gaspar Sánchez, Muhammad Rusyadi Ramli, Xin Tao, Magnus Gyllenhammar, Franz Wotawa, Naveen Mohan, Mihai Nica y Hermann Felbinger. 2021. Búsqueda de escenarios críticos para sistemas de conducción automatizada: una revisión sistemática de la literatura. ArXiv abs/2110.08664 (2021).