Machine Translated by Google

teledetección

MDPI

Artículo

Sistema de predicción de anomalías de tráfico mediante redes predictivas

Waqar Riaz 1,* Chenqiang Gao 1, Abdullah Azeem 2, Saifullah 1 Jamsaid Allah Bux 3 y Asif Ullah 4

1 Escuela de Ingeniería de la Comunicación y la Información, Universidad de Correos y Transporte de Chongqing Telecomunicaciones, Chongqing 400065, China; gaocq@cqupt.edu.cn (CG); saif07.786@gmail.com (S.)
2 Escuela de Microelectrónica e Ingeniería de Comunicaciones, Universidad de Chongqing, Chongqing 400030, China; abdullahazeem06@outlook.com
3 Departamento de Ciencias de la Computación, Universidad Indus, Karachi 75300, Pakistán; jsoomro@hec.gov.pk
4 Instituto de Ciencias e Ingeniería de Control, Universidad de Zhejiang, Hangzhou 321001, China; asifkh@zju.edu.cn
* Correspondencia: l201810020@stu.cqupt.edu.cn

Resumen: La anticipación de anomalías en escenarios de tráfico es uno de los principales desafíos en el reconocimiento de acciones . Se cree que se puede obtener una mayor precisión mediante el uso de detalles semánticos y movimiento. información junto con los fotogramas de entrada. La mayoría de los modelos de última generación extraen detalles semánticos y Flujo óptico predefinido a partir de fotogramas RGB y combinarlos mediante redes neuronales profundas. Muchos Los modelos anteriores no lograron extraer información de movimiento del flujo óptico preprocesado. Nuestro estudio muestra que el flujo óptico proporciona una mejor detección de objetos en la transmisión de video, lo cual es esencial característica en la predicción de accidentes futuros. Además de este problema, proponemos un modelo que utiliza el red neuronal recurrente que propaga instantáneamente los errores de codificación predictiva a través de las capas y pasos de tiempo. Al evaluar a lo largo del tiempo las representaciones del reconocimiento de acciones preentrenado modelar a partir de un video dado, el uso de flujos ópticos preprocesados como entrada es redundante. Basado En la puntuación predictiva final, mostramos la efectividad de nuestro modelo propuesto en tres diferentes tipos de clases de anomalías como Vehículo a exceso de velocidad, Accidente vehicular y Vehículo que se incorpora peligrosamente Conjuntos de datos KITTI, D2City y HTA de última generación.

Palabras clave: anticipación de anomalías; flujo óptico; extracción de características; red predictiva

Cita: Riaz, W.; Gao, C.; azeem, A.; Saifullah; Bux, JA; Ullah, A. (1999). Sistema de predicción de anomalías de tráfico Uso de redes predictivas. Remoto Senados 2022, 14, 447. https://doi.org/10.3390/rs14030447

Editor académico: Lefei Zhang

Recibido: 16 de diciembre de 2021
Aceptado: 13 de enero de 2022
Publicado: 18 de enero de 2022
Corregido: 9 de junio de 2023

Nota del editor: MDPI mantiene una postura neutral. con respecto a las reclamaciones jurisdiccionales en mapas publicados y afiliación institucional citas.

Derechos de autor: © 2022 por los autores. Titular de la licencia: MDPI, Basilea, Suiza. Este artículo es de acceso abierto. distribuido bajo los términos y condiciones de Creative Commons Licencia de atribución (CC BY) (https://creativecommons.org/licenses/by/4.0/).

1. Introducción

Cualquier cosa que sea radicalmente diferente del comportamiento normal puede considerarse anómala , como la aparición de coches en las aceras, una dispersión abrupta de personas en una multitud, una una persona que se resbala inesperadamente al caminar, conducir descuidadamente o no respetar las señales de tránsito en un cruce de tráfico. La disponibilidad de conjuntos de datos de vídeo públicos mejoró significativamente la investigación. resultados para el procesamiento de vídeo y la detección de anomalías [1]. Sistemas de detección de anomalías Por lo general, se entrenan aprendiendo el comportamiento esperado de los entornos de tráfico. Las anomalías se clasifican típicamente como anomalías puntuales, anomalías contextuales y anomalías colectivas. anomalías [2–4].

El desarrollo hacia los vehículos sin conductor ha atraído cada vez más atención y ha hecho posible que progreso significativo en la última década [5,6]. Si bien este avance brinda conveniencia a las personas y aborda las necesidades emergentes de la industria, también plantea preocupaciones con accidentes de tráfico. Como resultado, es necesario seguir avanzando hacia la prevención de accidentes. predicción utilizando los componentes de tiempo y fotograma de los videoclips. Dado este objetivo, nuestro El trabajo busca demostrar el poder de PredNet (Red Predictiva) [7] para accidentes anticipación en los conjuntos de datos HTA (Highway Traffic Anomaly), KITTI (Karlsruhe Institute of Technology and Toyota Technological Institute) y D2city (Didi Dashcam City) [8–10] . Específicamente, estos conjuntos de datos consisten en videos de cámaras de tablero capturados desde vehículos que circulan en varios escenarios de tráfico. Los videos contenidos en los conjuntos de datos muestran que no solo la cámara en movimiento, pero otros vehículos y elementos de fondo también varían. Los conjuntos de datos consisten en:

Machine Translated by Google

de tres clases de anomalías: vehículo a exceso de velocidad, accidente de tráfico y vehículo que se incorpora peligrosamente. Sin embargo, obtener datos etiquetados es costoso y requiere mucho tiempo. Además, los conjuntos de datos recientes obtenidos mediante crowdsourcing son de calidad cuestionable. Por lo tanto, el aprendizaje no supervisado se presenta como una opción prometedora.

El movimiento y el componente temporal de los videos juegan un papel significativo en la anticipación de anomalías de tráfico en comparación con los sistemas que trabajan solo con imágenes fijas. La predicción de video es una de las posibles formas de aprender de datos sin etiquetar [11–13]. Por esta razón, la mayoría de los modelos avanzados actuales extraen el flujo óptico de fotogramas de video contiguos y luego usan LSTM (redes de memoria a largo y corto plazo), RNN (redes neuronales recurrentes) o redes de alimentación directa para ingerir secuencias [14–20]. Con respecto al flujo óptico preprocesado , se observa que no proporciona información de movimiento para los modelos. En cambio, produce más información semántica, ya que los flujos ópticos pueden percibirse como máscaras de objetos. Dos observaciones en el experimento descrito en [21], demuestran que: (1) En apariencia, el flujo óptico es invariante y permite a los modelos reconocer la acción sin evaluar el color del objeto. (2) Los pequeños movimientos de los objetos y la precisión de borde del flujo óptico están estrechamente correlacionados con el rendimiento del reconocimiento de acciones. En este artículo, examinamos y ampliamos la Red de Codificación Predictiva (una arquitectura de red neuronal profunda), diseñada según los principios de PredNet [7]. Parece que, para predecir con precisión cómo cambiará un mundo visual con el tiempo, el modelo necesita aprender sobre la estructura del objeto y las posibles transformaciones que este podría sufrir [7].

En este trabajo, el objetivo es analizar la arquitectura de las redes neuronales para la recopilación directa de datos de movimiento a partir de fotogramas de vídeo. El modelo también puede aprender a centrarse en regiones que cambian entre fotogramas consecutivos, lo que resulta más eficiente en cuanto al uso de muestras, ya que permite al modelo aprender a partir de un número mucho menor de muestras de datos. PredNet entrena el modelo a nivel de píxel para predecir el siguiente fotograma de un vídeo. Por lo tanto, diseñamos un nuevo modelo combinado que involucra CNN (Redes Neuronales Convolucionales) y PredNet. CNN procesa los fotogramas RGB (Rojo, Azul, Verde), mientras que PredNet toma las características de CNN y predice anomalías en características posteriores

La predicción de anomalías y accidentes mediante flujo óptico suele requerir un tiempo de procesamiento elevado. Nuestros resultados demuestran que, incluso sin flujo óptico, es posible obtener resultados productivos en comparación con modelos de vanguardia que implican el preprocesamiento de los campos de flujo óptico a partir de fotogramas de vídeo. Según nuestra hipótesis, extraer información de movimiento directamente de los fotogramas de vídeo para el reconocimiento de acciones sin flujo óptico es eficaz, ya que, para PredNet, las conexiones recurrentes profundas ascendentes y descendentes se asemejan a la forma en que se genera el flujo óptico, pero son más informativas puesto que estos movimientos de píxeles se capturan en el proceso recurrente (PredNet). Nuestro modelo propuesto (FWPredNet), que es una combinación del modelo CNN GoogleNet [22] con swish [23] y PredNet [7], para realizar tareas de reconocimiento de acciones sin utilizar directamente el flujo óptico.

PredNet recibe como entrada las características extraídas de la CNN y predice las características en el siguiente paso temporal. Luego, las características concatenadas de la CNN y PredNet se introducen en el clasificador de predicción de acciones y se obtienen los resultados en función de la puntuación de predicción.

En el método que presentamos, el modelo logra resultados competitivos en comparación con otros modelos de última generación que no utilizan como entrada el flujo óptico precalculado a partir de fotogramas de vídeo.
La inmersión técnica en este trabajo se puede resumir de la siguiente manera:

- Combinamos la predicción de vídeo no supervisada, es decir, PredNet, y la clasificación de acciones supervisada . Nuestra novedosa idea es predecir fotogramas futuros basándonos en características extraídas utilizando CNN con sus etiquetas.
- El modelo utiliza únicamente fotogramas de vídeo como entrada y no requiere flujos ópticos preprocesados . Este enfoque predice y propaga el error a nivel de características, en lugar de a nivel de píxeles.

En las secciones subsiguientes del artículo, presentamos las siguientes estructuras. La Sección 2 se centra en trabajos relacionados que describen la investigación asociada para determinar los métodos avanzados actuales. Además, la Sección 3 introduce un nuevo marco propuesto para la anticipación de accidentes. Los detalles de implementación y la evaluación experimental del marco propuesto

Machine Translated by Google

El marco conceptual se presenta en la Sección 4. La sección de conclusiones y trabajo futuro resume los hallazgos y las líneas de investigación futuras.

2. Trabajos relacionados

Aquí, analizamos brevemente algunos de los enfoques, distinguiendo antes y después de la introducción de los modelos de redes neuronales profundas en el ámbito de la predicción de anomalías y accidentes. Se ha propuesto un algoritmo de seguimiento de vehículos, basado en campos aleatorios de Markov espaciotemporales, para la detección de accidentes de tráfico en intersecciones [24]. El modelo puede rastrear vehículos individuales de forma robusta, sin verse afectado por efectos de oclusión y desorden, que son características principales en la mayoría de las intersecciones concurridas. De manera similar, se utilizaron sensores puntuales como principio para sistemas de detección de incidentes [25]; sin embargo, su alcance tiende a ser bastante trivial para sistemas de detección de anomalías.

Los sistemas basados en visión se utilizan ampliamente en diversas aplicaciones, principalmente debido a sus capacidades superiores de reconocimiento de eventos. Sería sencillo extraer información de los sistemas basados en visión sobre atascos, infracciones de tráfico, accidentes y otros temas relevantes. Se utilizan cámaras CCTV estáticas para detectar vehículos en una autopista en [26]. Para detectar infracciones de tráfico en intersecciones, Lai et al. [27] también propusieron un método que se implementó en las carreteras de Hong Kong para que pudieran detectar vehículos en movimiento cuando el semáforo está en rojo. La agregación de características fue propuesta por Fatima et al. [28] junto con DSA, en contraste con la interacción entre agentes. Se propuso un algoritmo distribuido basado en la detección de anomalías para predecir y clasificar anomalías de tráfico en diversas escenas de tráfico [29]. Utilizando tecnología de procesamiento de imágenes, Ikeda et al. [30] pudieron detectar incidentes de tráfico anormales automáticamente. En su estudio, observaron varios tipos de anomalías de tráfico, que su método es capaz de detectar, incluyendo vehículos que se mueven lentamente , vehículos detenidos, objetos caídos y vehículos que intentan cambiar d
Michalopoulos et al. en [31] desarrollaron un sistema de predicción basado en video con autoscopio para rastrear incidentes. En su trabajo, propusieron un método para rastrear accidentes a una distancia de hasta 2 millas. Propusieron un algoritmo de detección de accidentes que utiliza las características de los vehículos en movimiento para detectar y registrar automáticamente la imagen de la escena del accidente antes y después del mismo [32].

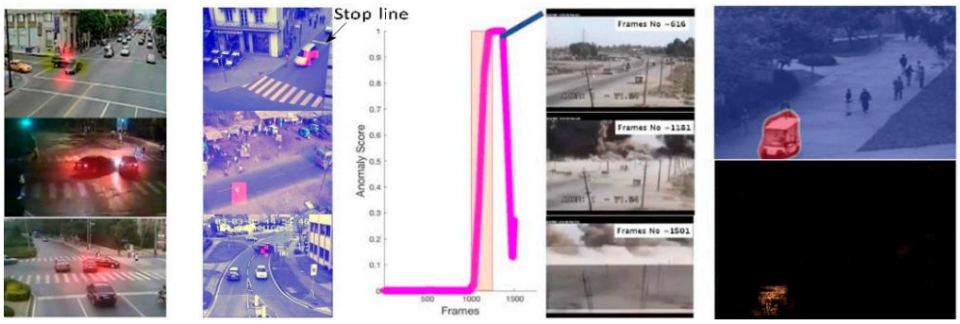
2.1. Aprendizaje predictivo de vídeo

El aprendizaje se puede caracterizar aproximadamente en tres grupos: supervisado, semi- supervisado o no supervisado [5,21–24]. El aprendizaje del comportamiento normal no solo es crucial para la identificación de anormalidades sino también para numerosas aplicaciones. Wei et al. en [33] utilizaron Faster R-CNN para detectar vehículos e introdujeron un sistema de detección de anomalías no supervisado basado en el modelado de fondo. Liu et al. [34] propusieron un modelo profundo consciente de la región que extrajo características locales discriminativas de una serie de regiones locales de un vehículo. Se introdujo un enfoque basado en redes generativas adversarias utilizando datos normales para detectar anomalías en imágenes [35]. Se informa que ciertos algoritmos utilizaron sistemas de múltiples cámaras empleando un sistema de sensores de video para identificar vehículos estacionarios. Un método que combina el seguimiento basado en visión con Intersection over Union permitiría una técnica real de seguimiento de múltiples objetos que podría escalarse para detectar anomalías de tráfico [36]. En [37], se afirmó una técnica de aprendizaje automático para analizar comportamientos de tráfico y detectar la ubicación de vehículos propensos a colisiones con alta precisión. De manera similar, Yun et al. en [38] aplicaron una interfaz de interacción de movimiento para analizar comportamientos anormales y detectar accidentes de tráfico. Finn et al. [12] prediciendo una distribución del movimiento de píxeles a partir de fotogramas anteriores y condicionando las acciones futuras de un robot, produjeron un modelo de movimiento a nivel de píxeles.
Srivastava et al. [39] demostraron que la predicción no supervisada de secuencias futuras de representaciones de alto nivel de fotogramas mejoró los resultados de la clasificación de vídeo. Villegas et al. [40] analizaron tanto los fotogramas sin procesar como sus representaciones de alto nivel, que son las poses humanas correspondientes a los fotogramas , para predecir los fotogramas futuros.

El método propuesto para ayudar a las personas en el trabajo diario fue implementado por un marco robótico real en [41], y las trayectorias del vehículo se utilizaron para predecir la

Machine Translated by Google

El método propuesto para ayudar a las personas en el trabajo diario se implementó mediante un marco robótico real en [41], y las trayectorias del vehículo se utilizaron para predecir la intención de cambio de carril o rotación. Otro enfoque utilizó múltiples cámaras basadas en la intención sensorial para el cambio de carril o fusión para explorar la predicción de fotogramas futuros utilizando GPS y dinámica del vehículo [42]. Sin embargo, Varias estrategias presuponen que los detalles valiosos a menudo llegan antes de la acción en un punto fijo. en un marco temporal fijo. Además, hay dos exclusiones que aplicaron HMM y RNN entrada- para diseñar y modelar el orden temporal de las indicaciones [39]. Algunas ilustraciones son salida para diseñar y modelar el orden temporal de las indicaciones [39]. Algunas ilustraciones se muestran en la siguiente Figura 1. como se muestra en la siguiente Figura 1.



(a) (b) (do) (d)

Figura 1. Instantáneas de ciertas estrategias especializadas para identificar anomalías en un resumen de la ner. Las imágenes se toman de [43]. (a) Campo de interacción de movimiento (MIF) [38] detección de accidentes. (b) manera. Las imágenes se toman de [43]. (a) Campo de interacción de movimiento (MIF) [38] detección de accidentes. Detección de anomalías del modelo basado en temas [44]. Un coche que ha cruzado la línea de parada aparece en la parte superior (b) Detección de anomalías del modelo basado en temas [44]. Un coche que ha cruzado la línea de parada aparece en de la fila, una fila central es un híbrido, y un vehículo que toma un giro extraño está en la parte inferior de la fila. arriba de la fila, una fila central es un híbrido, y un vehículo que toma un giro extraño está en la parte inferior de la (c) Detección de anomalías de aprendizaje multiinstancia (MIL) en el ejemplo en tiempo real [45]. El uso de una fila. (c) Detección de anomalías de aprendizaje multiinstancia (MIL) en el ejemplo en tiempo real [45]. El uso de una La clasificación de anomalías determina la detección de anomalías. (d) Se identifica un vehículo en una pasarela. La clasificación de anomalías determina la detección de anomalías. (d) Se identifica un vehículo en una pasarela. con el método STAN [46]. como la fila superior es la visualización de anomalías del generador, y la fila inferior con el método STAN [46]. como la fila superior es la visualización de anomalías del generador, y la fila inferior representa la visualización de anomalías del discriminador [47]. representa la visualización de anomalías del discriminador [47].

2.1.1. Codificación predictiva en la predicción de anomalías y accidentes

2.1.1. Codificación predictiva en la predicción de anomalías y accidentes

Lotter et al. [7] describieron PredNet, una red que aprende a predecir fotogramas futuros mediante al realizar predicciones locales con cada capa y reenviar las desviaciones de esas predicciones previas. diccionarios a las siguientes capas de la red. Los autores afirman que PredNet aprende inter- a las siguientes capas de la red. Los autores afirman que PredNet aprende internamente representaciones finales de los objetos y es capaz de capturar características importantes. Sus representaciones de los objetos y es capaz de capturar características importantes. Su trabajo El trabajo sirvió como punto de partida para varios investigadores diferentes. Por ejemplo, se desarrolló AFA- PredNet, que incorpora la acción motora como una señal adicional que modula modula el proceso generativo descendente a través de un mecanismo de atención [48] . Además , Thermore, otro método propuso un predictor artificial jerárquico utilizando diferentes otro método propuso un predictor artificial jerárquico utilizando diferentes escalas de tiempo de escalas de tiempo de predicción para diferentes niveles de codificación jerárquica, que se definen mediante la predicción para diferentes niveles de codificación jerárquica, que se definen mediante las neuronas. los parámetros temporales de las neuronas [49]. Wen et al. [50] extendieron este modelo creando parámetros temporales [49]. Wen et al. [50] extendieron este modelo creando un bidireccional, red neuronal dinámica bidireccional con procesamiento recurrente local, que se refería a una red neuronal dinámica con procesamiento recurrente local, que se refería a una predictiva una red de codificación predictiva. Para recuperar pistas de manera eficiente, el trabajo presentado adopta la red de codificación. Para recuperar pistas de manera eficiente, el trabajo presentado adopta la avanzada técnicas avanzadas para extraer elementos en movimiento de forma eficaz [50] y lo representa técnicas para extraer elementos en movimiento de forma eficaz [50] y lo representa mediante técnicas aprendidas mediante características profundas aprendidas como una observación en nuestro modelo FWPredNet. Finalmente, igualamos las características profundas como una observación en nuestro modelo FWPredNet. Finalmente, igualamos la anomalía la recopilación de datos de anomalías y anticipación de accidentes con tres conjuntos de datos de vídeo de cámaras de salpicadero grandes y separados. conjuntos de datos de vídeo.

2.2. Conjuntos de datos relacionados

2.2. Conjuntos de datos

relacionados Se recopilaron videos de cámaras de salpicadero o videos de cámaras en vehículos para revisar una variedad de desafíos de localización y reconocimiento, como el análisis basado en la percepción semántica de Se recopilaron videos de cámaras de salpicadero o de cámaras en vehículos para revisar una variedad escenas urbanas, la segmentación compatible [51], los [52] y Caltech [53]. Además, de desafíos de localización y reconocimiento, como el análisis basado en la percepción semántica de KITTI [9] y D2city [10] también pueden detectar objetos, seguimiento de múltiples objetos, escenas urbanas, la segmentación compatible [51], los [52] y Caltech [53]. Además, odometría visual de gran reputación para la detección de objetos en carreteras/carriles, etc. KITTI [9] y D2city [10] también pueden detectar objetos, seguimiento de múltiples objetos, Los conjuntos de datos utilizados para analizar tareas de video como la detección de objetos, el seguimiento de odometría visual de gran reputación para la detección de objetos en carreteras/carriles, etc. múltiples objetos, los videos están segmentados semánticamente y la dominancia visual para la detección de objetos en Los conjuntos de datos utilizados para analizar tareas de video como la detección de objetos, el seguimiento de condiciones normales de conducción. La mayoría de los conjuntos de datos utilizados para el reconocimiento de acciones anómalas múltiples objetos, los videos están segmentados semánticamente y la dominancia visual para la detección de objetos en

Machine Translated by Google

Consiste en vídeos grabados en zonas rurales y carreteras cercanas a ciudades medianas. Se publicó un amplio conjunto de datos de cámaras de salpicadero [54] para probar la segmentación semántica. Las fotografías se capturaron en 50 ciudades diferentes. Entre ellas, 5k fotogramas y 30k fotogramas están etiquetados con marcas semánticas detalladas y generales [55]. Aunque la recopilación de datos incluye hallazgos diversos, la mayoría de los fotogramas se tomaron y capturaron en un entorno de conducción típico.

2.3. Motivación

La anticipación de anomalías en videovigilancia se define como la detección de eventos poco frecuentes que no se ajustan a los eventos que ocurren en situaciones normales. Nuestro estudio se basa en los siguientes requisitos críticos para un detector de anomalías de video exitoso: • Extraer características importantes de la secuencia de video. • Decodificar el mapa de características y calcular la puntuación de predicción final mediante la función IOU para la predicción de anomalías y accidentes.

3. Materiales y métodos

En esta sección explicamos brevemente nuestra arquitectura FWPredNet para la anticipación de anomalías, el módulo de clasificación y la predicción de fotogramas futuros.

3.1. Arquitectura de PredNet

La Figura 2 muestra la arquitectura de PredNet [7]. La estructura de la red se crea en capas jerárquicas ponderadas. Cada uno de los componentes de la red intenta crear predicciones locales sobre sus entradas. A continuación, esta predicción y la diferencia con respecto a la entrada real se transfieren hacia arriba en la jerarquía hacia la capa siguiente. Aquí, la información se transfiere de tres maneras a través de la red: (1) La señal de error fluye de abajo hacia arriba como lo indican las flechas rojas en el lado derecho de la Figura 2. (2) Una flecha verde en el lado izquierdo indica que la señal de predicción fluye de arriba hacia abajo. (3) Hay un flujo constante de señales de error locales y señales de estimación de predicción dentro de las capas individuales. En cada capa, hay cuatro unidades, una unidad de convolución de entrada (Ai), una unidad de representación recurrente (Ri), una unidad de predicción (Ahati) y una unidad de cálculo de errores (Ei), como se indica en la Figura 2.

ConvLSTM [56] se utiliza para crear la unidad de representación (Ri), que estima la entrada para el siguiente paso de tiempo y luego se introduce en la unidad de predicción (Ahati), que consta de una capa de convolución que produce la predicción. Mediante unidades de error (Ei), puede calcular la diferencia entre una predicción y la entrada. Para añadir aún más no linealidad, las divide en poblaciones de error positivas y negativas. Este error se pasa posteriormente a la siguiente capa como parámetro de entrada. Una copia de la señal de error (flecha roja) y la entrada sobremuestreada (flecha verde) de la unidad de representación de nivel superior son recibidas por la unidad de representación, y se utilizan junto con su memoria recurrente para realizar predicciones.

3.2. Método propuesto

Inspirándonos en [57], utilizamos un modelo CNN preentrenado [22] para extraer las características a nivel de fotograma, y luego una versión propuesta de PredNet [7], denominada FWPredNet, se utiliza para predecir la representación de características del siguiente fotograma de vídeo. Nuestra idea es condicionar las predicciones de fotogramas futuros a las etiquetas de clase de acción predichas. La siguiente sección describe la funcionalidad de la arquitectura FWPredNet propuesta.

Machine Translated by Google

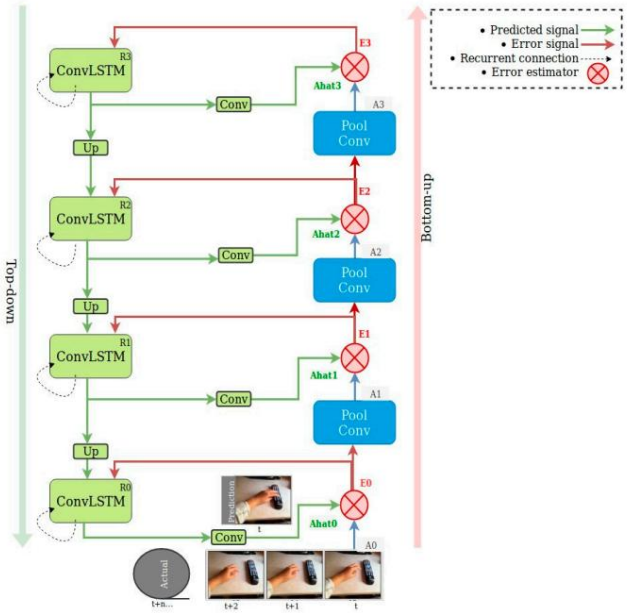


Figura 2. Arquitectura PredNet [7,58].

Figura 2. Arquitectura PredNet [7,58].

3.2.1. Extracción de características semánticas

Nuestro trabajo propuesto considera la misma red que GoogleNet [22]. Sin embargo, organizamos las capas de acuerdo a nuestras necesidades mediante la convolución con un paso de dos, agregando siete capas de agrupación. El módulo de inicio se redujo a seis capas. Los conjuntos de datos (HTA, KITTI, D2city) que consisten en imágenes de video tienen diferentes resoluciones. Para unificar el procedimiento de entrenamiento, todas las imágenes se redimensionaron a [224, 224] y se introdujeron en el clasificador como entrada. El tamaño original de una imagen se muestra como un octavo en los mapas resultantes como [2048 × 3 × 3]. Esto nos ayuda a detectar incluso objetos pequeños con una detección de grano fino manteniendo una baja carga computacional. Para la detección y el reconocimiento, utilizamos el mapa de características como base.

Para abordar las situaciones antes mencionadas, utilizamos la novedosa función de activación "Swish" que se propuso en [23]. Sugerido a partir de los estudios de Google Brain, donde la entrada x se multiplica por la función sigmoide, esta es una característica razonablemente simple (la función de activación Swish se muestra en la Figura 3).

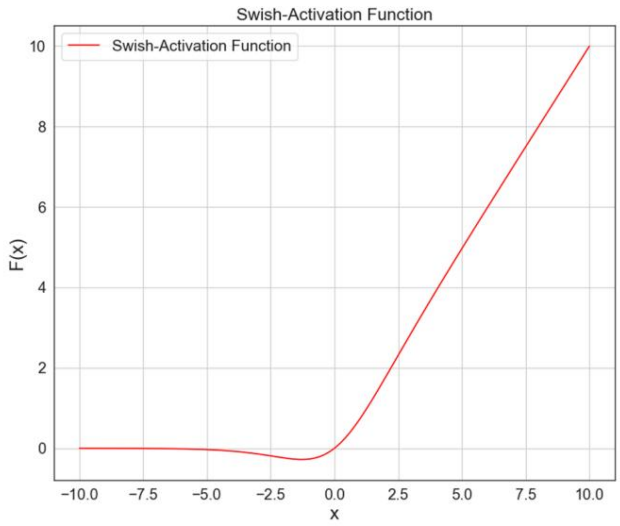


Figura 3. Representación gráfica de la función de activación Swish.

Figura 3. Gráfica de representación de la función de activación Swish.

Figura 3. Representación gráfica de la función de activación de Swish.

Machine Translated by Google

La definición matemática [23] de 'Swish' se presenta utilizando (1):

$$f(x) = x \times \text{sigmoide}(x) \quad (1)$$

En la imagen superior se muestra la función Swish, que presenta una gráfica suave; no cambia de dirección bruscamente, como ocurre con RELU cerca de κ = 0. Por el contrario, disminuye suavemente de 0 a valores menores que 0, para luego aumentar poco después. Esta información también indica la naturaleza no monótona de la función. De manera similar a RELU, esta función no se mantiene estable ni unidireccior De acuerdo con el estudio experimental realizado en [23], la función Swish parece funcionar mejor en conjuntos de datos más complejos que RELU en modelos más profundos. Ofrece la misma eficacia computacional, pero supera a RELU.

3.2.2. Arquitectura FW-PredNet

La teoría de la codificación predictiva se basa en que el cerebro genera continuamente predicciones descendentes a partir de información ascendente. La representación de un nivel superior predice la representación de su nivel inferior. Una diferencia entre la representación predicha y la real provoca un error de predicción. Este error se propaga a los niveles superiores para actualizar sus representaciones y así lograr una predicción mejorada. El proceso se repite a lo largo de la jerarquía hasta que el error de predicción disminuye o hasta que los procesos ascendentes dejan de transmitir información nueva (o imprevista) para actualizar las representaciones ocultas. Por lo tanto, la codificación predictiva es un mecanismo computacional mediante el cual el modelo actualiza recursivamente su representación interna de la información visual hasta alcanzar la convergencia.

La entrada a PredNet [7] son datos de imagen a nivel de píxel y los autores utilizaron una arquitectura de cuatro capas. En cambio, nosotros utilizamos la característica extraída de la capa superior de CNN que contiene la información semántica necesaria para realizar la detección de anomalías. A diferencia del reconocimiento en imágenes fijas, el movimiento y los aspectos temporales de los vídeos juegan un papel importante en el reconocimiento de acciones. En consecuencia, la mayoría de los modelos de última generación disponibles actualmente utilizan el preprocesamiento de vídeo para adquirir campos de flujo óptico entre fotogramas de vídeo contiguos y modelos que pueden consumir secuencias de vídeo. Por lo tanto, en lugar de propagar errores a nivel de píxel, predecimos el error a nivel de característica. Además, para hacer la predicción más robusta, utilizamos una unidad de clasificación (C) que está conectada a la parte superior de la capa de representación. Esta unidad consta de una sección de codificador y una sección de decodificador. La compilación de FWPredNet incluye cuatro componentes principales que se pueden ver en la Figura 4, en los que las unidades R, Aˆ , A, E y C denotan la unidad de representación, predicción, entrada, error y unidad de clasificación, respectivamente.

Como lo mencionan Wen et al. [50], en FWPrednet la representación de nivel superior R_l^t donde l se denota como capa y t se denota como paso de tiempo predice su representación de bajo nivel $\hat{A}_{l-1}^t$ mediante ponderación lineal Wl,l−1 donde los pesos de la capa l − 1, a la capa l, se denotan como W. El error de predicción El−1 es la diferencia entre $\hat{A}_{l-1}^t$ y R_{l-1}^t.

$$\hat{A}_{l-1}^t = (W_{l,l-1})\, TR_l^t(t) \quad (2)$$

$$Y_{l-1}^t = R_{l-1}(t) - \hat{A}_{l-1}^t \quad (3)$$

Durante el proceso de alimentación directa, el error de predicción en la capa l − 1, E_{l-1}^t, se propaga a la capa superior l, para actualizar su capa de representación R reducida R_l^t; por lo tanto, el error de predicción es con la representación actualizada. Podemos minimizar E_{l-1}^t, definiendo las pérdidas como la suma de los errores al cuadrado normalizados por la varianza de la representación σ_{l-1}^2 como:

$$Y_{l-1}^t = \frac{1}{2\sigma_{l-1}^2} \left\| Y_{l-1}^t \right\|_2^2 \quad (4)$$

Machine Translated by Google

Sea = un 9 se reescribe como oows:

$$= (1-) + \tag{10}$$

Aquí, la ecuación (10) ilustra un proceso de retroalimentación donde la representación en la capa superior causó una predicción de arriba hacia abajo e impacta la representación de la capa inferior.

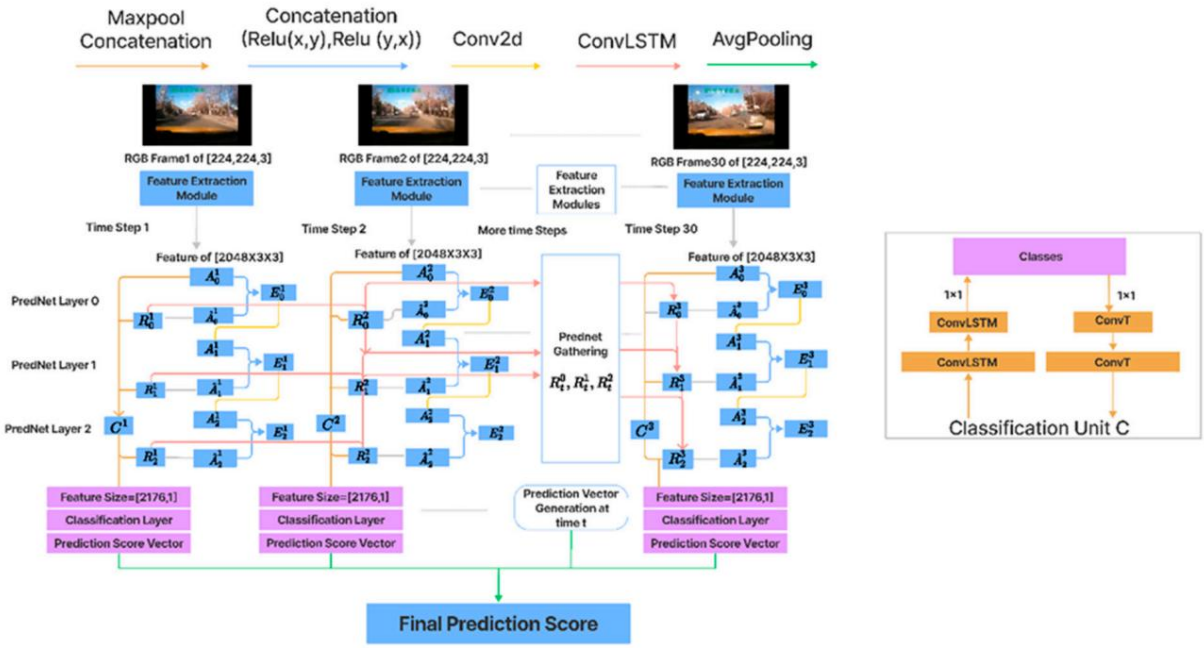


Figura 4. Izquierda: Arquitectura FWPredNet para nuestro modelo propuesto, en el que cada paso de tiempo consta de cinco componentes importantes: A la unidad de entrada, Aˆ la unidad de predicción, R la unidad de representación y E la unidad de error. Derecha: arquitectura de la unidad de clasificación C.

El gradiente de E ^{t} t en contraste con R l−1 l se da en la ecuación (5):

$$\frac{\partial E^{t}_{l-1}}{\partial R^{t}_{l}} = \frac{2}{2\sigma_{l-1}} W_{l,l-1} E^{t}_{l-1} \tag{5}$$

Para disminuir E $^{t}_{l-1}$, mediante el uso del descenso de gradiente, ^{t} se actualiza con una tasa de actualización, αl , R dado en (6):

$$R^{t+1}_{l} = R^{t}_{l} - \alpha_{l} \frac{\partial E^{t}_{l-1}}{\partial R^{t}_{l}} = R^{t}_{l} + \frac{2\alpha_{l}}{2\sigma_{l-1}} W_{l,l-1} E^{t}_{l-1} \tag{6}$$

Si los pesos de las conexiones de retroalimentación son la transpuesta de los de alimentación directa, es conexiones $W_{l,l-1} = (W_{l-1,l})^{T}$, posible reescribir (6) como una operación de alimentación directa, como

$$R^{t+1}_{l} = R^{t}_{l} + \alpha_{l} (W_{l-1,l})^{T} Y^{t}_{l-1} \tag{7}$$

Este método implica reenviar el error de predicción de la capa l − 1 a la capa l, para . Durante actualizando la representación con una tasa de actualización de αl = la $\frac{2\alpha_{l}}{2\sigma_{l-1}}$ el proceso de retroalimentación, predicción de arriba hacia abajo se utiliza para actualizar las representaciones en la capa l, R^{t}_{l} para reducir error de predicción E^{t}_{l}. De manera similar al proceso de alimentación directa, el descenso de gradiente se minimizar error, donde el gradiente de E con una $^{t}_{l}$ utiliza para actualizar ^{t} con respecto a R^{t}_{l} es como en (8), y R tasa de actualización de βl , como en (9):

$$\frac{\partial E^{t}}{\partial R^{t}_{l}} = \frac{2}{2\sigma_{l}} R^{t}_{l} - \hat{A}^{t}_{l} \tag{8}$$

$$R^{t+1}_{l} = R^{t}_{l} - \beta_{l} \frac{\partial E^{t}}{\partial R^{t}_{l}} = 1 - \frac{2\beta_{l}}{2\sigma_{l}} R + \left\| \frac{2\beta_{l}}{2\sigma_{l}} A^{t} \right. \tag{9}$$

Machine Translated by Google

contexto para hacer predicciones significativas y, por lo tanto, la ponderación a lo largo del tiempo se realiza utilizando una función exponencial, como se muestra en la Figura 5. Observe cómo las predicciones en los primeros fotogramas tienen un peso bajo, mientras que los pesos para las predicciones posteriores se estabilizan en 1.0 y todos se inicializan como 0 en el paso uno. Luego, desde la

En primer lugar, cero, después de la convolución R_0^1 produce $\hat{A}_0^1$ así como $A_{0,0}^1$ y $\hat{A}_0^1$. Más adelante, la convolución se produce como entrada para la siguiente capa de un mismo paso de tiempo. El mismo principio se aplica a la capa uno, donde se genera mediante convolución y se deriva de sub- tracciones entre $y = \frac{2\beta}{s_2^l}$. Después de la convolución R_1^1 se produce como entrada para la siguiente capa de un mismo paso de tiempo. Como en la capa dos, se produce usando convolución, mientras que se deriva mediante restas entre $y = (1 + b)^{R_l^{t-1}}$, (10)

. Esto representa la conclusión del proceso ascendente. Para el paso de tiempo uno en la capa uno, basado en la convolución LSTM, e inicializar en la capa uno para el paso de tiempo dos. R_2^1 con y^{l+1}, una capa R más alta predicción de abajo hacia arriba R_1^1 estación R_t.

Aquí, la ecuación (10) muestra un proceso de retroalimentación de la representación en el R_1^1 representando el proceso de abajo hacia arriba. Este proceso de $\hat{A}_1^1$ impacta la capa inferior. El proceso se produce de forma continua a lo largo de un intervalo de tiempo.

El codificador está compuesto por dos capas ConvLSTM que convierten la entrada en R_2^1 probabilidades de clase. El decodificador está compuesta por capas de convolución transpuestas que transforman las clases de nuevo en características de la imagen, que luego se retroalimentan al proceso descendente. La unidad de clasificación realiza una predicción en cada fotograma entrante. Una ponderación La suma de estas puntuaciones de predicción se calcula y se pasa a través de la función softmax para obtener probabilidad de clase predicha. En los primeros fotogramas del video, el modelo no tiene suficiente contexto para hacer predicciones significativas y, por lo tanto, la ponderación a lo largo del tiempo se realiza utilizando una función exponencial, como se muestra en la Figura 5. Observe cómo las predicciones en los primeros fotogramas tienen un peso bajo, mientras que los pesos para las predicciones posteriores se estabilizan en 1.0.

El codificador está compuesto por dos capas ConvLSTM que convierten la entrada en R_2^1 probabilidades de clase. El decodificador está compuesto por capas de convolución transpuestas que aumentan el tamaño de los datos. y transforma las clases de nuevo en características de la imagen, que luego se retroalimentan al proceso descendente. La unidad de clasificación realiza una predicción en cada fotograma entrante. Una ponderación La suma de estas puntuaciones de predicción se calcula y se pasa a través de la función softmax para obtener probabilidad de clase predicha. En los primeros fotogramas del video, el modelo no

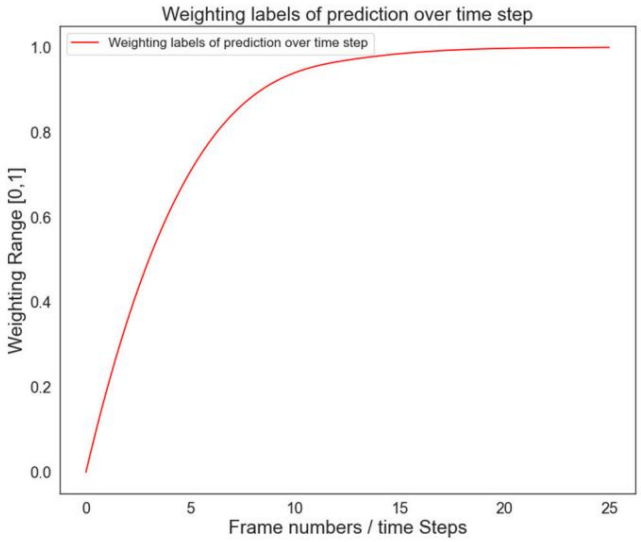


Figura 5. Ponderación de la predicción de etiquetas a lo largo del intervalo de tiempo.
Ponderación de la predicción de etiquetas a lo largo del intervalo de tiempo.

Machine Translated by Google

tener suficiente contexto para hacer predicciones significativas y por lo tanto la ponderación sobre
El tiempo se realiza utilizando una función exponencial, como se muestra en la Figura 5. Observe cómo
Las predicciones en los primeros fotogramas tienen un peso bajo, mientras que los pesos para las predicciones posteriores
estabilizarse en 1.0.

El número de clases reconocidas por la unidad de clasificación (C) depende del conjunto de datos, El número de clases
reconocidas por la unidad de clasificación (C) depende del conjunto de datos,
es decir, 2 clases para KITTI y D2City y 3 en el caso de HTA. Estas clases se interpretan como es decir, 2 clases para KITTI y
D2city y 3 en el caso de HTA. Estas clases se interpretan
etiquetas para predicción de fotogramas futuros. El codificador-decodificador primero transforma la salida de como etiquetas para
predicción de fotogramas futuros. El codificador-decodificador primero transforma la salida
representación de la unidad en probabilidades de clase de etiqueta donde el decodificador transforma la
de representación R
Salida de vuelta a las modalidades de imagen.
Salida de vuelta a las modalidades de imagen.

3.2.3. Parámetros de entrenamiento de la red
3.2.3. Parámetros de entrenamiento de la red

Utilizamos el descenso de gradiente estocástico estándar (SGD) para entrenar redes neuronales profundas, con un
Utilizamos el descenso de gradiente estocástico (SGD) estándar para entrenar redes neuronales profundas, con
momento establecido en 0,75 y la disminución del peso en 0,001 en cada caso. La tasa de aprendizaje inicial es de 0,0057.
El valor de Nesterov se establece en 0,75 y la disminución del peso en 0,001 en cada caso. La tasa de aprendizaje inicial es de
0,0057 y el tamaño del lote es 8. Tan pronto como la pérdida de validación alcanza la saturación, se aplica una reducción de 10x en la
tasa de aprendizaje. Nuestro modelo FAPredNet se entrena utilizando el modelo de capa de clasificación de acciones
se aplica la tasa de aprendizaje. Nuestro modelo FAPredNet se entrena utilizando el modelo de capa de clasificación de acciones
durante 10 épocas para 40 épocas de datos KITTI. Nuestro entrenamiento de ajuste fino de momentos utiliza
Modelo de 10 capas para 40 épocas de datos KITTI. Nuestro entrenamiento de ajuste fino de momentos utiliza
solo 10 épocas debido a limitaciones de memoria y tiempo. Todos los modelos están implementados
Utiliza sólo 10 épocas o más debido a limitaciones de memoria y tiempo. Todos los modelos están implementados en PyTorch
con una tarjeta gráfica 2080Ti.
en PyTorch usando una 2080Ti.

3.3. Conjuntos de datos
3.3. Conjuntos de datos

Nuestro método de análisis propuesto se lleva a cabo en tres HTA a gran escala diferentes [8],
Nuestro método de análisis propuesto se lleva a cabo en tres conjuntos de datos de videos de cámaras
de tablero a gran escala diferentes: HTA KITTI [9] y D2city [10] . Además, la Figura 6 muestra el resultado real.
[8], KITTI [9] y D2city [10] conjuntos de datos de vídeos de cámaras de salpicadero. Además, la Figura 6 muestra ejemplos de
vídeo de estos conjuntos de datos de última generación.
Ejemplos de video reales de estos conjuntos de datos de última generación.

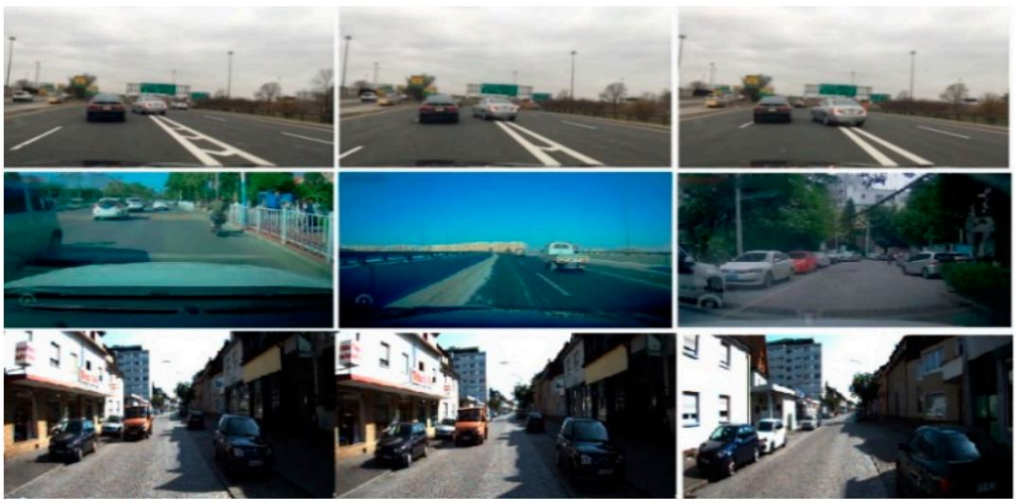


Figura 6. Algunos ejemplos de fotogramas de vídeo reales de tres conjuntos de datos a gran escala diferentes que estamos utilizando en la
Figura 6. Algunos ejemplos de fotogramas de vídeo reales de tres conjuntos de datos a gran escala diferentes que estamos utilizando en nuestra
nuestros experimentos. Estas imágenes se han tomado de [8–10,59].
experimentos. Estas imágenes se han tomado de [8–10,59].

3.3.1. HTA
3.3.1. AH

La colección de videos incluye videos de cámara de tablero de 1280 × 720 de autos grabados en
La colección de videos incluye videos de cámara de tablero de 1280 × 720 de autos grabados en La
Nueva York y el Área de la Bahía [8]. Se han excluido de este subconjunto los videos que son
Nueva York y el Área de la Bahía [8]. Se han excluido de este subconjunto los videos que son
borroso o mostrar condiciones visualmente degradadas. En resumen, esta colección de conjuntos de datos contiene videos de
borroso o mostrar condiciones visualmente degradadas. En resumen, esta colección de conjuntos de datos contiene videos de
tráfico (condiciones climáticas despejadas, nubladas, nubladas) en áreas urbanas, que contienen
Videos de tráfico (condiciones climáticas despejadas, nubladas, nubladas) en áreas urbanas, que contienen
(debido a vehículos grandes), incluyendo también tráfico circulando por las carreteras. Este conjunto de datos
Coches borrosos (debido a vehículos grandes) que también incluyen tráfico en movimiento en las carreteras. Este conjunto
no está libre de ruido o, dicho de otro modo, es un poco imperfecto debido a la naturaleza defectuosa de los datos
de datos no está exento de ruido o dicho de otro modo presenta algunas imperfecciones debido a la naturaleza imperfecta de la
grabación. Por ejemplo, los baches y las grietas en la carretera provocan temblores transitorios en los vídeos.
recopilación de datos. Por ejemplo, los baches y grietas en la carretera hacen que los videos tengan transitorios Estas
características hacen que el conjunto de datos sea más realista y, al mismo tiempo, más desafiante
sacudidas. Estas características hacen que el conjunto de datos sea más realista y, al mismo tiempo, más difícil de manejar con
presentando para lidiar con anomalías. Los videos se encuentran en el conjunto de estos de características
apenalías. Los videos se encuentran en las condiciones de conducción estándar caracterizadas por este
conducción estándar como vehículos que no perturban el movimiento de una cámara de tablero. El conjunto de entrenamiento incluye
En este conjunto de datos, se considerarán vehículos aquellos que no interfieren con el movimiento de la cámara del salpicadero.
El conjunto de entrenamiento consta de 286 vídeos de tráfico normales, con una duración media de 40 s y un total de 321 102
fotogramas.

3.3.2. GATITO

Machine Translated by Google

286 vídeos de tráfico habituales, con una duración media de 40 segundos y un total de 321.102 fotogramas .

3.3.2. GATITO

Este conjunto de datos seleccionado comprende 600 fotogramas de vídeo (con un valor de píxel de 375 × 1242) [9] extraídos a una distancia mínima de 20 m del conjunto de datos a gran escala de KITTI. Los vídeos presentados corresponden a 5 escenarios diferentes y se realizaron en condiciones de tráfico relativamente bajas, es decir, la carretera o el camino suelen ser completamente visibles. Se recopilaron datos específicos del sitio web de KITTI y se seleccionaron para nuestro trabajo (incluidas fotos estereoscópicas en color, escaneos láser como Velodyne e información obtenida por GPS).

3.3.3. El conjunto

de datos D2city [10] es una versión específica en la que se registran todos los videos y varios escenarios de incidentes, como una motocicleta chocando contra un vehículo o un automóvil colisionando con otro, como se muestra en la Figura 6. Además, la mayoría de los videos provienen de diferentes ciudades de Taiwán. Generalmente se trata de calles concurridas con varios objetos en movimiento y señales/paneles viales complejos en condiciones de visibilidad reducida para la conducción. Registramos manualmente los cuadros delimitadores del vehículo, la motocicleta, la bicicleta, la persona y la hora del accidente para cada video. Se utilizaron 58 videos de un total de 678 para el entrenamiento del detector de objetos. Los 620 archivos restantes se seleccionaron aleatoriamente de entre 620 clips positivos y 1130 negativos, cada uno compuesto por entre 60 y 70 fotogramas.

4. Experimentos y resultados

Evaluamos el enfoque propuesto en varios conjuntos de datos. Para comprender mejor la función de cada módulo en cada capa de nuestro modelo, realizamos extensos experimentos de visualización. En esta sección, dedicamos un párrafo a cada una de las evaluaciones en tres conjuntos de datos diferentes (HTA, KITTI, D2city), estimando la precisión promedio (AP), con una figura y una tabla para facilitar la discusión de los resultados.

Cabe mencionar que, debido a la falta de disponibilidad de conjuntos de datos para la anticipación de anomalías, hemos tomado conjuntos de datos disponibles públicamente y los hemos adaptado para dicho fin. En el caso de HTA, pudimos clasificar los conjuntos de datos en tres clases diferentes, es decir, Vehículo a exceso de velocidad, Fusión cercana y Accidente mientras que, en el caso de KITTI y D2City, clasificamos los conjuntos de datos en dos clases, es decir, Fusión cercana y Accidente. Se proporcionan algunos métodos de referencia para la comparación de nuestro método propuesto. Etiquetamos el conjunto de datos con 3 clases diferentes, es decir, Accidente, Fusión cercana y Vehículo a exceso de velocidad. Informamos la precisión top1 para la clasificación de eventos anormales. Usando una CNN, se pasa una secuencia de imágenes que posteriormente se codifica en mapas de características. Para la clasificación de eventos anormales, la característica de contexto se pasa a través de una capa de agrupación espacial junto con una capa totalmente conectada seguida de una capa SoftMax multi-vía al final. Dado que estamos prediciendo fotogramas (N + 10), el evento anormal se activa inmediatamente tan pronto como el fotograma se clasifica como una de las clases etiquetada En este artículo, hemos presentado el marco FWPredNet para la anticipación de accidentes y anomalías, y hemos superado el estado del arte anterior por un margen mayor en las tareas posteriores de precisión de clasificación en los conjuntos de datos KITTI, D2city y HTA.

4.1. Línea de base

La base de referencia para la comparación del método propuesto se analiza en subsecciones posteriores.

4.1.1. CGAN

Los modelos generativos pueden aprender a predecir el flujo óptico denso a partir de modelos de movimiento normales, ya que una anomalía se describe como un movimiento irregular [44]. Para el entrenamiento del flujo óptico, la verdad fundamental se evalúa utilizando la implementación de flujo óptico de OpenCV. GAN se puede generalizar a un modelo condicionado (CGAN) con información adicional sobre G o D para obtener detalles adicionales como etiquetas de clase u otras metodologías [60].
Al alimentar y al discriminador D y al generador G, el acondicionamiento se lleva a cabo en

Machine Translated by Google

una capa de entrada adicional. El ruido previo pz(z) e y se combinan mediante el generador G, en una representación oculta conjunta. El marco de entrenamiento adversario ofrece una estabilidad excepcional en el formato de esta representación oculta. x e y se presentan como entrada a una función discriminadora en el discriminador D. La función objetivo para la condición se muestra a continuación en (11):

$$\min_G \max_D V(D, G) = \mathbb{E}_{x \sim pdata(x|y)}[\log D(x)] + \mathbb{E}_{z \sim pz(z)}[\log(1 - D(z|y))] \quad (11)$$

Para anticipar el flujo óptico entre dos fotogramas consecutivos, se entrena la CGAN [61]. Las entradas del generador son dos imágenes RGB concatenadas en profundidad, que se utilizan para predecir el flujo óptico. Un método para detectar movimiento anómalo consiste en utilizar la diferencia entre el flujo óptico predicho por el generador y el flujo óptico real de la verdad fundamental. Mediante una ventana deslizante, se promedia la diferencia y el fotograma se considera anómalo si supera el umbral en cualquiera de las componentes x o y.

4.1.2. FlowNet

FlowNet [62] comparó dos arquitecturas: FlowNet Simple y FlowNetCorr; ambas son enfoques de aprendizaje de extremo a extremo. El sistema genera inicialmente dos imágenes distintas y luego las fusiona en una capa de correlación, aprendiendo la representación superior. Además, se utilizan contrastes de parches multiplicativos entre dos mapas de funciones con la capa de correlación. Más precisamente, dos mapas multicanal m1 y m2 tienen el número de canales, altura y anchura como c, h y w. La correlación de los dos parches mencionados en el primer mapa basado en a1 y el segundo mapa a2 se describe entonces como (12):

$$C(A1, A2) = \sum_{o \in [-k,k] \times [-k,k]} m1(a1 + o), m2(a2 + o) \quad (12)$$

En el método [63] sobre el diseño de redes neuronales para cámaras de eventos se describen dos tendencias mediante variantes recurrentes (de picos) de EV-FlowNet y FireNet. En este estudio, los autores proponen un enfoque novedoso para la estimación del flujo óptico basado en eventos mediante aprendizaje autosupervisado (SSL), que enfatiza la capacidad de las redes para integrar datos temporales de segmentos sucesivos de eventos. En el proceso de entrenamiento, la función de pérdida autosupervisada se reformuló para mejorar su convexidad.

4.2. Análisis del modelo

Diseñamos nuestros experimentos para analizar cada parte de nuestro modelo de la siguiente manera:

- La última capa de CNN preentrenada en ImageNet se ajusta en HTA.
- La última capa de CNN preentrenada en KITTI se ajusta en HTA.
- Fijar los pesos de CNN preentrenada en el conjunto de datos ImageNet y entrenar PredNet en HTA.
- Fijar los pesos de la CNN preentrenada en el conjunto de datos KITTI y entrenar la PredNet en HTA.

Los experimentos 1 y 2 examinan el rendimiento de la CNN con diferentes pesos preentrenados y sin características temporales. Los experimentos 3 y 4 muestran la eficacia de PredNet con dos modelos CNN preentrenados, respectivamente. Aquí presentamos los resultados de nuestro análisis para el conjunto de datos HTA. El uso de una CNN preentrenada en el conjunto de datos KITTI produce una mayor precisión que el uso de un modelo preentrenado en el conjunto de datos imageNet, tras ajustar la capa de clasificación en HTA. La precisión del primer resultado es del 5,71%, mientras que la del segundo es del 56 Esto indica que el uso de características del modelo preentrenado para la clasificación de objetos no es una buena representación para la clasificación de anomalías de tráfico. Si añadimos PredNet a ambos escenarios y entrenamos PredNet desde cero en HTA, se observa una mejora significativa en la precisión de ambas CNN preentrenadas, con un aumento del 13 % para la CNN preentrenada en ImageNeT y de más del 4 % para la preentrenada en KITTI. Esto indica que nuestra variación propuesta en FWPredNet es capaz de capturar información adicional de las secuencias de vídeo generadas.

Machine Translated by Google

La Tabla 1 proporciona la precisión de clasificación para el análisis de los resultados experimentales de nuestro modelo. como sigue.

Tabla 1. Análisis de los resultados experimentales de nuestra FWPredNet en HTA. La CNN tiene dos versiones: preentrenada en ImageNet o KITTI. FWPredNet está entrenada en el conjunto de datos HTA.

Estructura del modelo	Preentrenado en		Ajuste fino/Entrenamiento		Exactitud
	CNN	FWPredNet	CNN	FWPredNet	
CNN	ImagenNet		Capa de clasificación		5,71%
CNN KITTI			Capa de clasificación		56,2%
CNN + PredNet	ImagenNet		Pesos fijos	Desde cero	18,44%
CNN + PredNet	BOTE	Subconjunto de KITTI	Pesos fijos utilizados como entrada del sistema. Su modelo alcanza una tasa de precisión significativamente mayor que la de nuestro modelo, que solo tiene entradas de fotogramas RGB como en la Tabla 2.	Desde cero	60,3%

PARA REVISIÓN POR PARES Remote Sens. 2021, 13, x 14 de 19

4.2.1. Evaluación de la HTA

Aquí, analizamos los resultados de nuestro modelo en comparación con otros modelos de referencia en la HTA. Tabla 2. Comparación entre CGAN, Flownet, PredNet y nuestro modelo FWPredNet para el conjunto de datos descrito en la Figura 7. Observamos que nuestro modelo supera a la mayoría de los conjuntos de datos HTA de vanguardia por un amplio margen, a saber, CGAN [60], FlowNet [62] y PredNet [7], por

Acción	FlowNet	PredNet	FWPredNet
Vehículo a velocidad excesiva	0,49	0,608	0,629
Accidente	0,55	0,607	0,675
Cerrar fusión	0,422	0,531	0,19	0,651

fotogramas RGB, un modelo de dos flujos basado en la red neuronal convolucional bidimensional que tiene explícitamente el flujo óptico que se utiliza como tasa de precisión significativamente mayor que la de entrada del sistema. Su modelo alcanza una en la Tabla 2. nuestro modelo, que solo tiene entradas de fotogramas RGB como

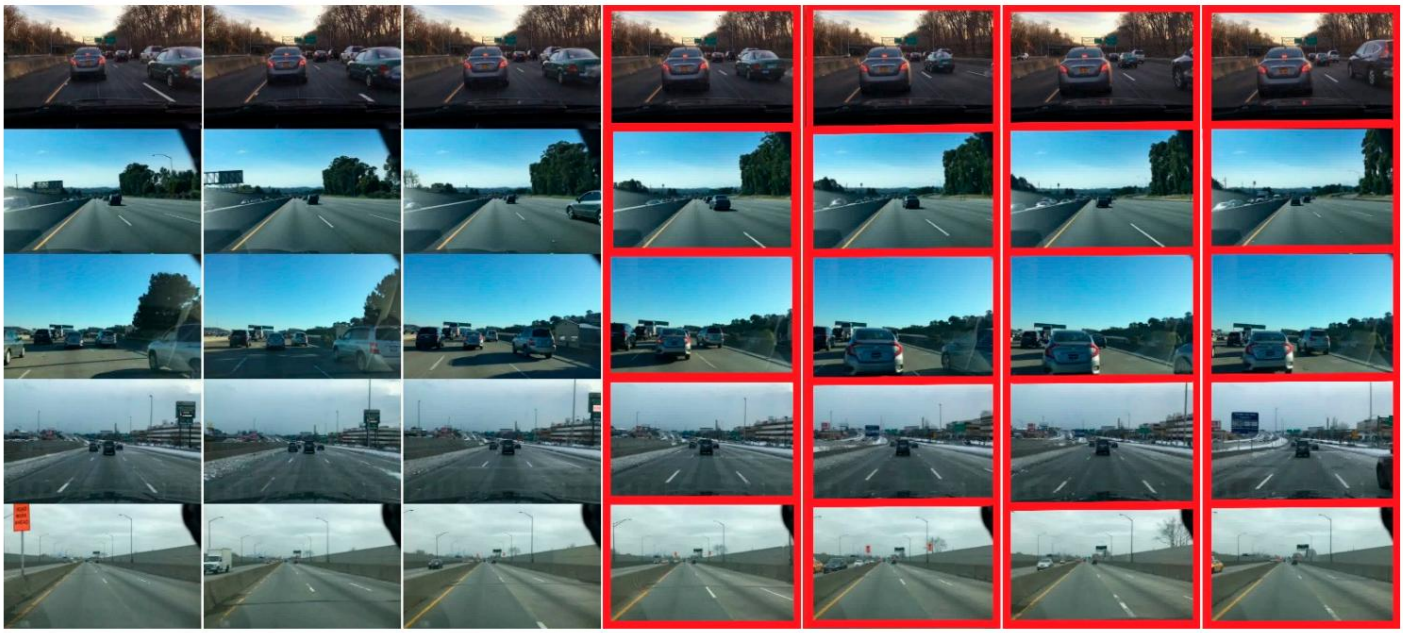


Figura 7. Jugando de izquierda a derecha según la ilustración anterior se muestra una anomalía exitosa y acci- Figura 7. Jugando de izquierda a derecha según la ilustración anterior se muestra una anomalía exitosa y Anticipación de abolladuras en el conjunto de datos de vídeos de cámaras de salpicadero HTA. Anticipación de accidentes en el conjunto de datos de vídeos de cámaras de salpicadero HTA.

4.2.2. Evaluación en KITTI Tabla 2.

Comparación entre CGAN, Flownet, PredNet y nuestro modelo FWPredNet para conjuntos de datos HTA.

También realizamos resultados en KITTI como anomalía y los resultados de anticipación se pueden ver en la Figura 8. En la Tabla 3, presentamos nuestros resultados en el conjunto de datos KITTI. Acción, Action CGAN FlowNet PredNet , FWPredNet

modelo solo Speeding Vehicle	0,608	0.623	0,49	0,629
Accidente	0,607	0,657	0,55	0,675
Cerrar fusión	0,422	0,531	0,19	0,651

utiliza fotogramas RGB como entrada y logró 0.578 y 0.724 en Accident y Close Merge, respectivamente.

Tabla 3. Muestra la comparación resultante entre CGAN, Flownet, Prednet y nuestro modelo FWPredNet para los conjuntos de datos KITTI.

ACCIÓN	CGAN	FlowNet	PredNet	FWPredNet
Accidente	0,439	0,541	0,38	0,578
Cerrar fusión	0,526	0,685	0,45	0,724

Machine Translated by Google

4.2.2. Evaluación de KITTI

También realizamos análisis de resultados sobre KITTI como anomalía y se pueden observar resultados de anticipación.
en la Figura 8. En la Tabla 3 se presenta una comparación de nuestro sistema con esquemas de última generación.
mostrando los mismos resultados que los extraídos del conjunto de datos KITTI. Nuestro modelo solo utiliza RGB.
Se utilizaron fotogramas como entrada y se obtuvieron 0,578 y 0,724 en Accidente y Close Merge, respectivamente.



Figura 8. Jugando de izquierda a derecha según la ilustración anterior se muestra una anomalía exitosa y acci-
Figura 8. Jugando de izquierda a derecha según la ilustración anterior se muestra una anomalía exitosa y
Anticipación de abolladuras en el conjunto de datos de vídeos de cámaras de salpicadero
KITTI. Anticipación de accidentes en el conjunto de datos de vídeos de cámaras de salpicadero KITTI.

4.2.3. Evaluación en D2city Tabla 3.
Muestra la comparación resultante entre CGAN, Flownet, Prednet y nuestro modelo FWPredNet.
conjuntos de datos KITTI.
En comparación con otros modelos, nuestro modelo ofrece un mejor rendimiento en la predicción de accidentes para los
y detección de fusión cercana en detección D2City, como se muestra en la Figura 9. Nuestra arquitectura FlowNet PredNet
para el modelo de dos flujos. El modelo puede lograr una precisión significativamente mayor que los resultados de otros
modelos, como se muestra en la Tabla 4 a continuación.

ACCIÓN	CGAN	FlowNet	PredNet	FWPredNet
Accidente	0,439	0,541	0,38	0,578
Cerrar fusión	0,526	0,685	0,45	0,724

Tabla 4. Comparación entre CGAN, Flownet, PredNet y nuestro modelo FWPredNet para D2city da-
nivel.

4.2.3. Evaluación de D2city

Action CGAN	FlowNet	PredNet	FWPredNet
Accidente 0,439	0,541	0,38	0,718
Close Merge 0,685 0,47	0,526		0,704

En comparación con otros modelos, nuestro modelo tiene un mejor rendimiento en la predicción de accidentes.
y detección de fusión cercana en la detección de D2City, como se muestra en la Figura 9. Nuestra arquitectura
flujos. El modelo puede lograr significativamente utiliza el flujo óptico como entrada para el modelo de dos
mayor precisión que los resultados de otros modelos, como se muestra en la Tabla 4 a continuación.

Tabla 4. Comparación entre CGAN, Flownet, PredNet y nuestro modelo FWPredNet para D2city.
conjunto de datos.

Acción	CGAN	FlowNet	PredNet	FWPredNet
Accidente	0,439	0,541	0,38	0,718
Cerrar fusión	0,526	0,685	0,47	0,704

Machine Translated by Google

Tabla 4. Comparación entre CGAN, Flownet, PredNet y nuestro modelo FWPredNet para el conjunto de datos D2city.

Acción	CGAN	FlowNet	PredNet	FWPredNet
Accidente	0,439	0,541	0,38	0.718
Cerrar fusión	0,526	0,685	0,47	0,704



Figura 9. Jugando de izquierda a derecha según la ilustración anterior se muestra una anomalía exitosa y acci- Figura 9. Jugando de izquierda a derecha según la ilustración anterior se muestra una anomalía exitosa y Anticipación de abolladuras en el conjunto de datos de vídeos de cámaras de salpicadero de D2city. Anticipación de accidentes en el conjunto de datos de vídeos de cámaras de salpicadero de D2city.

5. Debate

Implementamos un modelo que se denomina informalmente FWPredNet que no produce no solo los resultados de la clasificación, sino que también condiciona las predicciones futuras a sus etiquetas previas. etiquetas de clase. Para todos los experimentos anteriores, informamos la precisión top1 para el aprendizaje supervisado. Clasificación del aprendizaje para la acción en KITTI, HTA y D2City en la columna de la derecha. Se presentan las divisiones de entrenamiento y prueba de KITTI, HTA y D2City. Las tablas 2 a 4 presentan Precisión top1 para la clasificación de acciones en los conjuntos de datos KITTI, HTA y D2City.

Además, evaluamos la versión estándar de PredNet y la comparamos con nuestro modelo propuesto. En comparación con los modelos tradicionales, nuestro modelo tiene un mejor rendimiento tanto en Accidentes como en Cierres Fusionar clases pero tiene problemas con los vehículos a alta velocidad debido a la capacidad de aprendizaje de la El modelo es sensible a la continuidad del movimiento. Nuestro modelo supera a Flownet en 32,96%, con un 7,4% en detección de accidentes y supera marginalmente a Flownet en un 3,03% en HTA debido al tipo de conjunto de datos y la capacidad de aprendizaje de nuestro modelo, que es sensible a la continuidad del movimiento. Varias de las técnicas presentadas para extraer movimiento Los elementos se adoptan para recuperar señales de manera eficiente [50] y luego representar estas características. como observaciones en nuestro modelo FWPredNet mediante el aprendizaje de características profundas. En comparación con Estudios previos, Villegas et al. [40] predijeron el futuro utilizando tanto fotogramas sin procesar como sus representaciones de alto nivel, que es la pose humana correspondiente del fotograma. Sin embargo, esto Solo funciona con fondos estáticos y requiere información de pose etiquetada. Además, Vondrick et al. [13] extendieron este trabajo y continuaron la tradición de codificar imágenes en un un nivel superior al de los píxeles. Para anticipar objetos y acciones, utilizaron el reconocimiento. algoritmos en la representación predicha. En contraste, el modelo PredNet [7] que nosotros extendido y denominado informalmente como FWPredNet, aprende directamente del espacio de píxeles y funciona con vídeos que tienen fondos dinámicos y escenarios del mundo real. Además, esto El modelo es un tipo de marco neurocientífico que puede aprender características en diferentes niveles jerárquicos. niveles sin estar específicamente ajustados para ello.

Comparación de parámetros de la línea base (CGAN, FlowNet y PredNet) con nuestra propuesta FWPredNet se muestra en la Tabla 5 a continuación. El modelo Prednet estándar es aproximadamente 3,9 millones de parámetros menos que el modelo FWPrednet, pero funciona significativamente mejor en cada clase y conjunto de datos. Es un compromiso que debemos alcanzar para obtener mejores resultados de Rendimiento de clasificación de Prednet. Por lo tanto, adoptamos una especie de compromiso para la “precisión”. sobre el costo computacional”, lo cual será interesante explorar para una mejor clasificación. desempeño en trabajos futuros.

Machine Translated by Google

Tabla 5. Comparación de parámetros para el costo computacional de FWPredNet con nuestro modelo de referencia.

	Modelo	VRAM de entrenamiento (GB)	Modelo Parámetros (en Millones)	Tamaño del lote
Resolución: 224	PredNet [7]	3.8	7.2	8
	CGAN [60]	10.1	45	4
	FlowNet [62]	9.5	39	4
	Red predictora FW	5.3	11.1	8

6. Conclusiones y trabajo futuro

- En este artículo, hemos presentado el marco FWPredNet para accidentes y anomalías. anticipación, y superó el estado del arte anterior por un margen mejor en el Tareas posteriores de precisión de clasificación en los conjuntos de datos KITTI, D2city y HTA.
- Se puede deducir que nuestra variación propuesta en FWPredNet es capaz de capturar información adicional de secuencias de video generadas mientras entrenamos PredNet desde Rasca el conjunto de datos proporcionado.
- Evaluamos PredNet estándar [7] y luego lo comparamos con nuestro modelo FWPredNet. En comparación con los modelos tradicionales (CGAN, Flownet, PredNet), FWPredNet tiene un mejor rendimiento en las clases Accidente y Fusión cerrada. Una limitación del rendimiento de la prueba es que tiene problemas con los vehículos que van a alta velocidad porque la capacidad de aprendizaje del modelo es sensible a la continuidad del movimiento pero aún así logra mejores resultados en comparación con los otros tres métodos.
- Finalmente, en el frente de ingeniería, la implementación actual de FWPredNet toma El tiempo de entrenamiento es muy largo y se puede trabajar para lograr un uso más eficiente de las GPU. El costo computacional de FWPredNet es 3,9M más que el PredNet estándar, pero Lo aceptamos como una compensación por "precisión sobre costo computacional". Un sucesor de Se puede diseñar FWPredNet, que no tiene las limitaciones mencionadas anteriormente y es más rápido en la implementación del modelo propuesto.

Contribuciones de los autores: Conceptualización, WR y GC; metodología, WR; software S. y WR; validación, AA; análisis formal, WR; investigación, GC; recursos, AA y AU; datos curación, WR y GC; redacción: preparación del borrador original, WR; redacción: revisión y edición, GC, JAB y S.; visualización, AU; supervisión, GC; administración del proyecto, WR y AU; financiación Adquisición, GC. Todos los autores han leído y aprobado la versión publicada del manuscrito.

Financiación: Este trabajo cuenta con el apoyo de la Fundación Nacional de Ciencias Naturales de China (n.º 62176035), el Programa de Investigación Científica y Tecnológica de la Comisión de Educación Municipal de Chongqing bajo la Subvención (No.KJZD-K202100606).

Declaración del Comité de Ética Institucional: No aplica.

Declaración de consentimiento informado: No aplicable.

Declaración de disponibilidad de datos: No aplicable.

Agradecimientos: Los autores desean agradecer al editor y a los revisores anónimos por su colaboración. Comentarios valiosos sobre este artículo.

Conflictos de intereses: Los autores declaran no tener ningún conflicto de intereses.

Referencias

1. Shirazi, MS; Morris, BT Observando las intersecciones: Un estudio sobre el monitoreo, el comportamiento y el análisis de seguridad de las intersecciones recientes Estudios. IEEE Trans. Intell. Transp. Syst. 2017, 18, 4–24. [CrossRef]
2. Yuan, Y.; Fang, J.; Wang, Q. Detección de anomalías en línea en escenas de multitudes mediante análisis de estructura. IEEE Trans. Cybern. 2015, 45, 548–561. [CrossRef] [PubMed]
3. Cheng, K.-W.; Chen, Y.-T.; Fang, W.-H. Detección y localización de anomalías de vídeo basadas en regresión de procesos gaussianos con Representación jerárquica de características. IEEE Trans. Image Process. 2015, 24, 5288–5301. [CrossRef] [PubMed]

Machine Translated by Google

4. Zhao, M.; Chen, J. Una revisión de métodos para detectar anomalías puntuales en conjuntos de datos numéricos. En Actas de la 4.ª Conferencia IEEE de Tecnología de la Información, Redes, Electrónica y Control de Automatización (ITNEC) de 2020, Chongqing, China, 12-14 de junio de 2020; págs. 559-565.

5. Janai, J.; Güney, F.; Behl, A.; Geiger, A. Visión por computadora para vehículos autónomos: Problemas, conjuntos de datos y estado del arte. En Foundations and Trends® in Computer Graphics and Vision; Now Publishers: Boston, MA, EE. UU., 2021; Volumen 12, pp. 1–308.

6. Mahoma, K.; Ullah, A.; Lloret, J.; Del Ser, J.; de Albuquerque, VHC Aprendizaje profundo para una conducción autónoma segura: actual Desafíos y direcciones futuras. IEEE Trans. Intell. Transp. Syst. 2020, 22, 4316–4336. [CrossRef]

7. Lotter, W.; Kreiman, G.; Cox, D. Redes de codificación predictiva profunda para predicción de vídeo y aprendizaje no supervisado. arXiv 2016, arXiv:1605.0810.

8. Yu, F.; Xian, W.; Chen, Y.; Liu, F.; Liao, M.; Madhavan, V.; Darrell, T. Bdd100k: Una base de datos de vídeo de conducción diversa con escalabilidad herramientas de anotación. arXiv 2018, arXiv:1805.04687.

9. Geiger, A.; Lenz, P.; Urtasun, R. ¿Estamos preparados para la conducción autónoma? El conjunto de pruebas de visión KITTI. En Actas de la Conferencia IEEE sobre Visión por Computadora y Reconocimiento de Patrones (CVPR), Providence, RI, EE. UU., 16-21 de junio de 2012; págs. 3354-3361. [CrossRef]

10. Che, Z.; Li, G.; Li, T.; Jiang, B.; Shi, X.; Zhang, X.; Ye, J. D2City: Un conjunto de datos de vídeo de cámaras de salpicadero a gran escala de diversos escenarios de tráfico. arXiv 2019, arXiv:1904.01975.

11. Wang, Y.; Gao, Z.; Long, M.; Wang, J.; Yu, PS Predrnn++: Hacia una resolución del dilema de la profundidad temporal en el aprendizaje predictivo espaciotemporal. En Actas de la Conferencia Internacional sobre Aprendizaje Automático, Estocolmo, Suecia, 10-15 de julio de 2018.

12. Finn, C.; Goodfellow, I.; Levine, S. Aprendizaje no supervisado para la interacción física mediante predicción de vídeo. En Advances in Neural Information Processing Systems 29; Lee, DD, Sugiyama, M., Luxburg, UV, Guyon, I., Garnett, R., Eds.; Curran Associates, Inc.: Red Hook, NY, EE. UU., 2016; pp. 64–72.

13. Vondrick, C.; Pirsiavash, H.; Torralba, A. Anticipando el futuro viendo vídeos sin etiquetar. 2015. Disponible en línea: http://www.cs.columbia.edu/~vondrick/prediction/paper.pdf (Consultado el 15 de diciembre de 2021).

14. Sutskever, I.; Vinyals, O.; Le, QV Aprendizaje secuencia a secuencia con redes neuronales. En Avances en información neuronal Sistemas de procesamiento; Curran Associates, Inc.: Red Hook, NY, EE. UU., 2014; págs. 3104–3112.

15. Hochreiter, S.; Schmidhuber, J. Memoria a corto y largo plazo. Neural Comput. 1997, 9, 1735–1780. [CrossRef] [PubMed]

16. Riaz, W.; Azeem, A.; Chenqiang, G.; Yuxi, Z.; Saifullah; Khalid, W. Método de reconocimiento basado en YOLO para el reconocimiento automático de matrículas. En Actas de la Conferencia Internacional IEEE de 2020 sobre Avances en Ingeniería Eléctrica y Aplicaciones Informáticas (AEECA), Dalian, China, 25-27 de agosto de 2020; págs. 87-90.

17. Bao, W.; Yu, Q.; Kong, Y. Anticipación de accidentes de tráfico basada en la incertidumbre con aprendizaje relacional espacio-temporal. En Actas de la 28.ª Conferencia Internacional ACM sobre Multimedia, Seattle, WA, EE. UU., 16-18 de octubre de 2020; págs. 2682-2690.

18. Carreira, J.; Zisserman, A. ¿Quo vadis, action recognition? Un nuevo modelo y el conjunto de datos kinetics. En Actas de la Conferencia IEEE sobre Visión por Computadora y Reconocimiento de Patrones, Honolulu, HI, EE. UU., 21-26 de julio de 2017; págs. 6299-6308.

19. Zhu, J.; Zhu, Z.; Zou, W. Aprendizaje de representación de extremo a extremo a nivel de vídeo para el reconocimiento de acciones. En Actas de la 24.ª Conferencia Internacional sobre Reconocimiento de Patrones (ICPR), Pekín, China, 20-24 de agosto de 2018; págs. 645-650.

20. Wang, L.; Xiong, Y.; Wang, Z.; Qiao, Y.; Lin, D.; Tang, X.; Van Gool, L. Redes de segmentos temporales: hacia buenas prácticas para el reconocimiento profundo de acciones. En Actas de la Conferencia Europea sobre Visión por Computadora (ECCV), Ámsterdam, Países Bajos, 8-16 de octubre de 2016; Leibe, B., Matas, J., Sebe, N., Welling, M., Eds.; Springer: Cham, Suiza, 2016; pp. 20-36.

21. Sevilla-Lara, L.; Liao, Y.; Güney, F.; Jampani, V.; Geiger, A.; Black, MJ Sobre la integración del flujo óptico y el reconocimiento de acciones. En Actas de la Conferencia Alemana sobre Reconocimiento de Patrones, Stuttgart, Alemania, 9-12 de octubre de 2018; Springer: Cham, Suiza, 2018; págs. 281-297.

22. Szegedy, C.; Liu, W.; Jia, Y. Profundizando con convoluciones. En Actas de la Conferencia IEEE sobre Visión por Computadora y Reconocimiento de Patrones, Boston, MA, EE. UU., 7–12 de junio de 2015; págs. 1–9.

23. Ramachandran, P.; Zoph, B.; Le, QV Swish: Una función de activación autocontrolada. arXiv 2017, arXiv:1710.059417.

24. Kamijo, S.; Matsushita, Y.; Ikeuchi, K.; Sakauchi, M. Monitoreo del tráfico y detección de accidentes en intersecciones. IEEE Trans. Intell. Sistema de Transacciones 2000, 1, 108–118. [CrossRef]

25. Rojas, JC; Crisman, JD Detección de vehículos en imágenes en color. En Actas de la Conferencia sobre Transporte Inteligente Sistemas, Boston, MA, EE. UU., 12 de noviembre de 1997.

26. Leibe, B.; Schindler, K.; Cornelis, N.; Van Gool, L. Detección y seguimiento de objetos acoplados desde cámaras estáticas y vehículos en movimiento. IEEE Trans. Pattern Anal. Mach. Intell. 2008, 30, 1683–1698. [CrossRef] [PubMed]

27. Lai, AHS; Yung, NHC. Metodología de sistema basada en video para detectar conductores que se saltan semáforos en rojo. En Actas de la IAPR. Taller sobre aplicaciones de visión artificial, Chiba, Japón, 17-19 de noviembre de 1998; págs. 23-26.

28. Fatima, M.; Khan, MUK; Kyung, CM Agregación global de características para la anticipación de accidentes. arXiv 2020, arXiv:2006.08942.

29. Thajchayapong, S.; Garcia-Trevino, ES; Barria, JA Clasificación distribuida de anomalías de tráfico mediante tráfico microscópico Variables. IEEE Trans. Intell. Transp. Syst. 2012, 14, 448–458. [CrossRef]

30. Ikeda, H.; Kaneko, Y.; Matsuo, T.; Tsuji, K. Sistema de detección de incidentes anormales que emplea tecnología de procesamiento de imágenes. En Actas de la Conferencia Internacional IEEE/IEEJ/JSAI de 1999 sobre Sistemas de Transporte Inteligentes (Cat. No. 99TH8383), Tokio, Japón, 5-8 de octubre de 1999; págs. 748-752.

Machine Translated by Google

31. Michalopoulos, P.; Jacobson, R. Implementación y pruebas de campo de un sistema de detección de incidentes basado en visión artificial. En Actas de la Conferencia Pacific Rim TransTech: Volumen I: Tecnologías avanzadas, Washington, DC, EE. UU., 25-28 de julio de 1993; págs. 1-7.
32. Ki, YK; Kim, JW; Baik, DK Un modelo de detección de accidentes de tráfico mediante un registro de metadatos. En Actas de la Cuarta Conferencia Internacional sobre Investigación, Gestión y Aplicaciones de Ingeniería de Software, IEEE (SERA'06), Seattle, WA, EE. UU., 9-11 de agosto de 2006; págs. 255-259.
33. Wei, J.; Zhao, J.; Zhao, Y.; Zhao, Z. Detección de anomalías no supervisada para la vigilancia del tráfico basada en el modelado del fondo. En Actas de los Talleres de la Conferencia IEEE sobre Visión por Computadora y Reconocimiento de Patrones, Salt Lake City, UT, EE. UU., 18-22 de junio de 2018; págs. 129-136.
34. Liu, X.; Zhang, S.; Huang, Q.; Gao, W. Ram: Un modelo profundo sensible a la región para la reidentificación de vehículos. En Actas de la Conferencia Internacional IEEE de Multimedia y Exposición (ICME) de 2018, San Diego, CA, EE. UU., 23-27 de julio de 2018; págs. 1-6.
35. Schlegl, T.; Seeböck, P.; Waldstein, SM; Schmidt-Erfurth, U.; Langs, G. Detección de anomalías no supervisada con redes generativas antagónicas para guiar el descubrimiento de marcadores. En Actas de la Conferencia Internacional sobre Procesamiento de Información en Imágenes Médicas, Boone, NC, EE. UU., 25-30 de junio de 2017; págs. 146-157.
36. Bochinski, E.; Senst, T.; Sikora, T. Extensión del seguimiento de múltiples objetos basado en IOU mediante información visual. En Actas de la 15.ª Conferencia Internacional IEEE sobre Vigilancia Avanzada Basada en Vídeo y Señales (AVSS), IEEE, Auckland, Nueva Zelanda, 27-30 de noviembre de 2018; págs. 1-6.
37. Dogru, N.; Subasi, A. Detección de accidentes de tráfico mediante métodos de aprendizaje automático. En Actas del Tercer Simposio Internacional sobre Desarrollo Sostenible (ISSD'12), Sarajevo, Bosnia y Herzegovina, 31 de mayo-1 de junio de 2012; pág. 467.
38. Yun, K.; Jeong, H.; Yi, KM; Kim, SW; Choi, JY Campo de interacción de movimiento para la detección de accidentes en vídeo de vigilancia de tráfico. En Actas de la 22.ª Conferencia Internacional sobre Reconocimiento de Patrones, Estocolmo, Suecia, 24-28 de agosto de 2014; págs. 3062-3067. [CrossRef]
39. Srivastava, N.; Mansimov, E.; Salakhutdinov, R. Aprendizaje no supervisado de representaciones de vídeo mediante LSTM. En Actas de 32ª Conferencia Internacional sobre Aprendizaje Automático, Lille, Francia, 7-9 de julio de 2015.
40. Villegas, R.; Yang, J.; Zou, Y.; Sohn, S.; Lin, X.; Lee, H. Aprendizaje para generar futuros a largo plazo mediante predicción jerárquica. En Actas de la 34.ª Conferencia Internacional sobre Aprendizaje Automático, Sídney, Nueva Gales del Sur, Australia, 6-11 de agosto de 2017.
41. Morris, B.; Doshi, A.; Trivedi, M. Predicción de la intención de cambio de carril para la asistencia al conductor: diseño y evaluación en carretera. En Actas del Simposio IEEE sobre Vehículos Inteligentes (IV), Baden-Baden, Alemania, 5-9 de junio de 2011; págs. 895-901. [CrossRef]
42. Jain, A.; Koppula, HS; Raghavan, B.; Soh, S.; Saxena, A. Un coche que sabe antes que tú: Anticipación de maniobras mediante el aprendizaje de modelos de conducción temporales. En Actas de la Conferencia Internacional IEEE sobre Visión por Computadora (ICCV), Santiago, Chile, 7-13 de diciembre de 2015; pp. 3182-3190. [CrossRef]
43. Santhosh, KK; Dogra, DP; Roy, PP Detección de anomalías en el tráfico rodado mediante vigilancia visual: una revisión. ACM Comput. Surv. (CSUR) 2020, 53, 1–26. [CrossRef]
44. Pathak, D.; Sharang, A.; Mukerjee, A. Localización de anomalías en el análisis basado en temas de vídeos de vigilancia. En Actas de la Conferencia de Invierno del IEEE sobre Aplicaciones de la Visión por Computadora, Waikoloa, HI, EE. UU., 5-9 de enero de 2015; págs. 389-395. [CrossRef]
45. Sultani, W.; Chen, C.; Shah, M. Detección de anomalías en el mundo real en vídeos de vigilancia. En Actas de la Conferencia de la Sociedad de Computación del IEEE sobre Visión por Computadora y Reconocimiento de Patrones, Salt Lake City, UT, EE. UU., 18-22 de junio de 2018; págs. 6479-6488.
46. Lee, S.; Kim, HG; Ro, YM STAN: Redes adversarias espaciotemporales para la detección de eventos anormales. En Actas de la Conferencia Internacional IEEE sobre Acústica, Habla y Procesamiento de Señales (ICASSP), Calgary, AB, Canadá, 15-20 de abril de 2018; págs. 1323–1327. [CrossRef]
47. Scharwächter, T.; Enzweiler, M.; Franke, U.; Roth, S. Segmentación eficiente de escenas con múltiples señales. En Actas de la Conferencia Alemana DAGM sobre Reconocimiento de Patrones, Saarbrücken, Alemania, 3-6 de septiembre de 2013; Volumen 8142, pp. 435-445. [CrossRef]
48. Zhong, J.; Cangelosi, A.; Zhang, X.; Ogata, T. AFA-PredNet: Modulación de la acción dentro de la codificación predictiva. En Actas de la Conferencia Internacional Conjunta sobre Redes Neuronales (IJCNN), Río de Janeiro, Brasil, 8-13 de julio de 2018; págs. 1-8. [CrossRef]
49. Zhong, J.; Ogata, T.; Cangelosi, A. Codificación de información multimodal contextual a largo plazo en un modelo de codificación predictiva. arXiv 2018, arXiv:1804.06774.
50. Wen, H.; Han, K.; Shi, J.; Zhang, Y.; Culurciello, E.; Liu, Z. Red de codificación predictiva profunda para el reconocimiento de objetos. En Actas de la 35ª Conferencia Internacional sobre Aprendizaje Automático, Estocolmo, Suecia, del 10 al 15 de julio de 2018.
51. Scharwächter, T.; Enzweiler, M.; Franke, U.; Roth, S. Stixmantics: Un modelo de nivel medio para la comprensión semántica de escenas en tiempo real . En Conferencia Europea sobre Visión por Computadora; Springer: Cham, Suiza, 2014.
52. Leibe, B.; Cornelis, N.; Cornelis, K.; Van Gool, L. Análisis dinámico de escenas 3D desde un vehículo en movimiento. En Actas de la Conferencia IEEE de 2007 sobre Visión por Computadora y Reconocimiento de Patrones, Minneapolis, MN, EE. UU., 17-22 de junio de 2007; págs. 1-8.
53. Brostow, GJ; Shotton, J.; Fauqueur, J.; Cipolla, R. Segmentación y reconocimiento mediante nubes de puntos de estructura a partir del movimiento. En Actas de la Conferencia Europea de Visión por Computadora, Marsella, Francia, 12-18 de octubre de 2008; Volumen 5302, pp. 44-57.
54. Cordts, M.; Omran, M.; Scharwächter, T.; Rehfeld, T.; Enzweiler, M.; Benenson, R.; Franke, U.; Roth, S.; Schiele, B. El conjunto de datos de paisajes urbanos para la comprensión semántica de escenas urbanas. En Actas de la Conferencia IEEE sobre Visión por Computadora y Reconocimiento de Patrones (CVPR), Las Vegas, NV, EE. UU., 6 de abril de 2016; págs. 3213–3223.

Machine Translated by Google

55. Chan, F.-H.; Chen, Y.-T.; Xiang, Y.; Sun, M. Anticipación de accidentes en vídeos de cámaras de salpicadero. En Actas de la 13.ª Conferencia Asiática sobre Visión por Computadora, Taipéi, Taiwán, 20-24 de noviembre de 2016; Springer: Cham, Suiza, 2017; págs. 136-153. [CrossRef]
56. Shi, X.; Chen, Z.; Wang, H.; Yeung, D.; Wong, W.; Woo, W. Red LSTM convolucional: un enfoque de aprendizaje automático para la predicción inmediata de precipitaciones. En Advances in Neural Information Processing Systems; Curran Associates, Inc.: Red Hook, NY, EE. UU., 2015.
57. Huang, X.; Mousavi, H.; Roig, G. Redes de codificación predictiva y reconocimiento de acciones. En Actas de la Conferencia Internacional IEEE de Procesamiento de Imágenes (ICIP) de 2020, Abu Dabi, Emiratos Árabes Unidos, 25-28 de octubre de 2020; págs. 793-797.
58. Rane, RP; Szügyi, E.; Saxena, V.; Ofner, A.; Stober, S. Prednet y codificación predictiva: una revisión crítica. En Actas de la Conferencia Internacional de Recuperación Multimedia 2020, Dublín, Irlanda, 8-11 de junio de 2020; págs. 233-241.
59. Singh, H.; Hand, EM; Alexis, K. Detección de movimiento anómalo en autopista mediante aprendizaje profundo. En Actas de la Conferencia Internacional IEEE de Procesamiento de Imágenes (ICIP) de 2020, Abu Dabi, Emiratos Árabes Unidos, 25-28 de octubre de 2020; págs. 1901-1905.
60. Mirza, M.; Osindero, S. Redes generativas adversarias condicionales. arXiv 2014, arXiv:1411.1784.
61. Ravanbakhsh, M.; Sangineto, E.; Nabi, M.; Sebe, N. Entrenamiento de discriminadores adversarios para la detección de eventos anormales entre canales en multitudes. En Actas de la Conferencia de Invierno del IEEE sobre Aplicaciones de Visión por Computadora (WACV), Waikoloa, HI, EE. UU., 7-11 de enero de 2019; págs. 1896-1904. [CrossRef]
62. Fischer, P.; Dosovitsky, A. FlowNet: Aprendizaje de flujo óptico con redes neuronales convolucionales. arXiv 2015, arXiv:1504.06852v2.
63. Hagenaars, JJ; Paredes-Vallés, F. Aprendizaje autosupervisado de flujo óptico basado en eventos con redes neuronales de impulsos. arXiv 2021, arXiv:2106.01862v.