Machine Translated by Google

Intersección inteligente: Convolución de dos flujos Redes para la detección en tiempo real de incidentes cercanos a accidentes en vídeo de tráfico

XIAOHUI HUANG, PAN HE, ANAND RANGARAJAN y SANJAY RANKA, Universidad de Florida, Estados Unidos

Los sistemas basados en cámaras se utilizan cada vez más para recopilar información sobre intersecciones y vías principales. A diferencia de los controladores de bucle, que generalmente solo se pueden usar para la detección y el movimiento de vehículos, las cámaras pueden proporcionar información detallada sobre el comportamiento del tráfico. Se han desarrollado marcos basados en visión para la detección de múltiples objetos, el seguimiento de objetos y la detección de cuasi accidentes para obtener esta información. Sin embargo, gran parte de este trabajo actualmente se centra en el procesamiento de vídeos en línea. En este artículo, proponemos una arquitectura integrada de redes neuronales convolucionales de dos flujos que realiza la detección, el seguimiento y la detección de cuasi accidentes en tiempo real de usuarios de la vía en datos de vídeo del tráfico. El modelo de dos flujos consta de una red de flujo espacial para la detección de objetos y una red de flujo temporal para aprovechar las características de movimiento para el seguimiento de múltiples objetos. Detectamos cuasi accidentes incorporando características de apariencia y de movimiento de estas dos redes. Además, demostramos que nuestros enfoques se pueden ejecutar en tiempo real y a una velocidad de fotogramas superior a la velocidad de fotogramas del vídeo en una variedad de vídeos recopilados por cámaras de vigilancia y aéreas.

Conceptos de CCS: • Organización de sistemas informáticos → Redes neuronales; Arquitectura de sistemas en tiempo real;

Palabras clave y frases adicionales: Sistemas de transporte inteligentes, ITS, detección de incidentes cercanos, seguimiento de múltiples objetos, redes neuronales convolucionales

Formato de referencia ACM:
Xiaohui Huang, Pan He, Anand Rangarajan y Sanjay Ranka. 2020. Intersección inteligente: redes neuronales convolucionales de dos flujos para la detección en tiempo real de incidentes cercanos a accidentes en vídeo de tráfico. ACM Trans. Spatial Algorithms Syst. 6, 2, artículo 10 (enero de 2020), 28 páginas. https://doi.org/10.1145/3373647

1. INTRODUCCIÓN

Los rápidos cambios en el crecimiento de datos explotables y, en muchos casos, abiertos, tienen el potencial de mitigar la congestión del tráfico y mejorar la seguridad. A pesar de los avances significativos en la tecnología vehicular, las prácticas de ingeniería del tráfico y los análisis basados en datos de accidentes, el número de accidentes y muertes en el tráfico sigue siendo demasiado alto. Muchos conductores están frustrados debido a los largos (pero potencialmente evitables)

Esta investigación fue financiada, en parte, por el Departamento de Transporte de Florida (FDOT) y la NSF CNS 1922782. Las opiniones, hallazgos y conclusiones expresadas en esta publicación son las del autor o autores y no necesariamente las del Departamento de Transporte de Florida o del Departamento de Transporte de los Estados Unidos. Dirección de los autores: X. Huang, P. He, A. Rangarajan y S. Ranka, Universidad de Florida, 432 Newell Drive, Gainesville, FL, 32611, EE. UU.; correos electrónicos: {xiaohuihuang, pan.he}@u.edu, {anand, ranka}@cise.u.edu.
Se concede permiso para realizar copias digitales o impresas de la totalidad o parte de esta obra para uso personal o en el aula, sin coste alguno, siempre que dichas copias no se realicen ni distribuyan con fines de lucro o ventaja comercial y que incluyan este aviso y la cita completa en la primera página. Los derechos de autor de los componentes de esta obra que pertenezcan a terceros deben respetarse. Se permite la elaboración de resúmenes con la debida atribución. Para cualquier otro tipo de copia, republicación, publicación en servidores o redistribución a listas, se requiere autorización previa específica y/o el pago de una tarifa. Solicite los permisos a permissions@acm.org. © 2020 Derechos de autor reservados por el/los propietario/s/autor/es. Los derechos de publicación se otorgan bajo licencia a ACM.
2374-0353/2020/01-ART10 $15.00
https://doi.org/10.1145/3373647

Machine Translated by Google

Retrasos en las intersecciones. El uso de procesamiento de vídeo o detección y medición de luz (LIDAR), análisis de macrodatos, inteligencia artificial y aprendizaje automático puede mejorar significativamente la capacidad para abordar estos desafíos. La recopilación y explotación de grandes conjuntos de datos no es nueva en el sector del transporte. Sin embargo, la omnipresencia de dispositivos y sensores digitales, la considerable reducción de los costes de hardware para computación y almacenamiento, las tecnologías mejoradas de detección y comunicación, y las soluciones analíticas de código abierto han posibilitado nuevas aplicaciones. Estas últimas pueden ofrecer información sobre patrones que de otro modo pasarían desapercibidos y que podrían influir positivamente en las personas y la sociedad.

Las tecnologías de inteligencia artificial (IA) e Internet de las Cosas (IoT) están dando paso a una nueva y prometedora era de "Ciudades Inteligentes", donde miles de millones de personas en todo el mundo pueden mejorar su calidad de vida en aspectos como el transporte, la seguridad, la información, las comunicaciones, etc. Un ejemplo de soluciones de IA centradas en datos son las tecnologías de visión artificial, que permiten la inteligencia basada en visión para dispositivos periféricos en múltiples arquitecturas. Los datos de sensores de dispositivos inteligentes o cámaras de vídeo se pueden analizar inmediatamente para proporcionar análisis en tiempo real para sistemas de transporte inteligentes (ITS). En las intersecciones de tráfico, hay un mayor volumen de usuarios de la vía (peatones y vehículos), movimiento de tráfico, eventos dinámicos de tráfico, cuasi accidentes, etc. Es una aplicación de vital importancia para permitir la monitorización global del flujo de tráfico, el análisis local de los usuarios de la vía y la detección automática de cuasi accidentes.

Como tecnología novedosa, la inteligencia basada en visión tiene muchas aplicaciones en la vigilancia y gestión de rutas [Buch et al. 2011; Coifman et al. 1998; He et al. 2017; Kamijo et al. 2000; Valera y Velastin 2005; Veeraraghavan et al. 2003]. Entre ellas, muchos trabajos de investigación se han centrado en la adquisición de datos de rutas con vídeos aéreos [Angel et al. 2002; Salvo et al. 2017]; la vista aérea proporciona mejores perspectivas para cubrir una gran área y concentrar los recursos en las tareas de vigilancia.

Los vehículos aéreos no tripulados (VANT) y las cámaras omnidireccionales pueden obtener vídeos aéreos útiles para la vigilancia del tráfico, especialmente en intersecciones, con una perspectiva más amplia de la escena y con la ventaja de ser móviles y espaciotemporales. Una tendencia reciente en inteligencia basada en visión consiste en aplicar tecnologías de visión artificial a estos vídeos aéreos de intersecciones [Scotti et al. 2005; Wang et al. 2006] y procesarlos en el extremo de la red a través de múltiples arquitecturas de sistemas de transporte inteligentes (ITS).

La detección de objetos y el seguimiento de múltiples objetos son aplicaciones muy utilizadas en el transporte, y las soluciones en tiempo real son importantes, especialmente para el área emergente de los macrodatos de transporte.

Un incidente evitado por poco es un evento que tiene el potencial de convertirse en una colisión entre dos vehículos o entre un vehículo y un peatón o ciclista. Es importante monitorear y analizar estos eventos para prevenir colisiones futuras. También sirven como indicador de posibles problemas de sincronización y diseño en la intersección. Las intersecciones monitoreadas por cámaras generan datos de video en gigabytes por cámara por día. Analizar miles de trayectorias recopiladas por hora en una intersección desde diferentes fuentes para identificar incidentes evitados por poco se vuelve rápidamente complejo, dada la cantidad de datos a examinar y la relativa poca frecuencia de tales eventos.

En este artículo, investigamos el uso de datos de vídeo de seguimiento para la detección de situaciones de riesgo de accidente. Sin embargo, hasta donde sabemos, no existe un sistema unificado que realice la detección y el seguimiento en tiempo real de usuarios de la vía y la detección de situaciones de riesgo de accidente en vídeos aéreos. Por lo tanto, hemos recopilado conjuntos de datos de vídeo y presentado un método en tiempo real basado en aprendizaje profundo para abordar estos problemas.

En general, una herramienta de vigilancia basada en visión para ITS debe cumplir varios requisitos: (1) segmentar los vehículos de su entorno (incluidos otros objetos de la carretera y el fondo) para detectar todos los objetos de la carretera (estables o en movimiento); (2) clasificar los vehículos detectados en categorías: automóviles, autobuses, camiones, motocicletas, etc.; (3) extraer características espaciales y temporales (movimiento, velocidad y trayectoria) para permitir tareas más específicas, incluido el seguimiento de vehículos, el análisis de trayectorias, la detección de casi accidentes, la detección de anomalías, etc.; (4) funcionar bajo diversas condiciones de tráfico y condiciones de iluminación; y (5) operar en tiempo real.

Machine Translated by Google

A lo largo de las décadas, aunque se ha propuesto una cantidad creciente de investigación sobre sistemas basados en visión para vigilancia de tráfico, muchos de los criterios enumerados anteriormente todavía no se pueden cumplir. Las primeras soluciones [Hoose 1992] no identifican vehículos individuales como objetivos únicos y rastrean progresivamente sus movimientos. Se han propuesto métodos para abordar los problemas de detección y seguimiento de vehículos individuales [Coifman et al. 1998; Koller et al. 1993; McLauchlan et al. 1997] con estrategias de seguimiento y despliegue de flujo óptico. En comparación con las características tradicionales hechas a mano, los métodos de aprendizaje profundo [Girshick et al. 2016; He et al. 2019a, 2019b; Redmon et al. 2016; Ren et al.

2015; Tian et al. 2016] en detección de objetos han ilustrado la robustez de la especialización del detector genérico a una escena específica. Recientemente, la detección automática de accidentes de tráfico se ha convertido en un tema importante. Antes de detectar eventos de accidentes [Hommes et al. 2011; Jiang et al. 2007; Jiansheng et al. 2014; Kamijo et al. 2000; Sadeky et al. 2010], un enfoque típico es aplicar métodos de detección o seguimiento de objetos, utilizando histograma de gradiente de flujo (HFG), modelo oculto de Markov (HMM) o modelo de mezcla gaussiana (GMM). Otros enfoques [Chen et al. 2010, 2016; Ihaddadene y Djeraba 2008; Karim y Adeli 2002; Liu et al. 2010; Tang y Gao 2005; Wang y Dong 2012; Wang y Miao 2010; Xia et al. 2015] utilizan características de bajo nivel (por ejemplo, características de movimiento) para demostrar una mayor robustez. También se han empleado redes neuronales para la detección automática de accidentes [Ghosh-Dastidar y Adeli 2003; Ohe et al. 1995; Srinivasan et al. 2004; Yu et al. 2008].

Las intersecciones tienden a experimentar más incidentes cercanos a accidentes, y potencialmente más graves, debido a factores como los ángulos y las colisiones al girar. El primer tipo de video de intersecciones que se considera aquí es el video de drones, que monitorea una intersección desde una vista superior. El segundo tipo es el video de tráfico real adquirido por cámaras omnidireccionales Sheye que monitorean intersecciones pequeñas o grandes.
Esto se utiliza ampliamente en la vigilancia del transporte. Estos datos pueden utilizarse directamente como entradas para cualquier sistema basado en visión artificial.

Proponemos un marco unificado basado en visión para la detección de incidentes cercanos que presenta las siguientes ideas novedosas:

(1) Una arquitectura de redes convolucionales de flujo espacial y temporal combinada que realiza detección, clasificación y seguimiento de objetos. La red de flujo espacial detecta vehículos individuales y regiones probables cercanas a accidentes a nivel de fotograma único capturando características de apariencia con un método de detección de objetos de última generación. La red de flujo temporal aprovecha las características de movimiento extraídas de los candidatos detectados para realizar el seguimiento de múltiples objetos y genera trayectorias correspondientes de cada objetivo rastreado;

(2) Un enfoque de segmentación espacial de píxeles basado en fotogramas para derivar cuadros delimitadores precisos para múltiples objetos. Este enfoque es considerablemente más preciso en comparación con los enfoques de cuadros delimitadores rectangulares; (3) Un enfoque de aprendizaje métrico para un seguimiento mejorado en presencia de oclusión.
La oclusión puede provocar que en varios fotogramas el objeto pase desapercibido; (4) Una nueva medida de distancia entre trayectorias para detectar casi colisiones entre objetos.
Esta medida detecta situaciones de riesgo de accidente mediante la incorporación de características de apariencia y de movimiento para calcular las probabilidades de las regiones candidatas a sufrir un accidente.

Además, demostramos que esto se puede ejecutar en una GPU a una velocidad de más de 33 fotogramas por segundo, lo cual resulta útil en aplicaciones de vídeo en tiempo real. Cabe destacar que estos métodos se ejecutan en vídeo basado en lentes Sheye, lo cual es considerablemente más complejo que la geometría estándar de fotogramas de vídeo rectilíneos. Los experimentos demuestran la ventaja de nuestro marco de trabajo, con un rendimiento competitivo general a altas velocidades de fotogramas. El flujo de trabajo general de nuestro método se muestra en la Figura 1.

La organización del artículo es la siguiente. La Sección 2 describe los antecedentes de las redes neuronales convolucionales, la detección de objetos y los métodos de seguimiento de múltiples objetos. La Sección 3 describe los

Machine Translated by Google

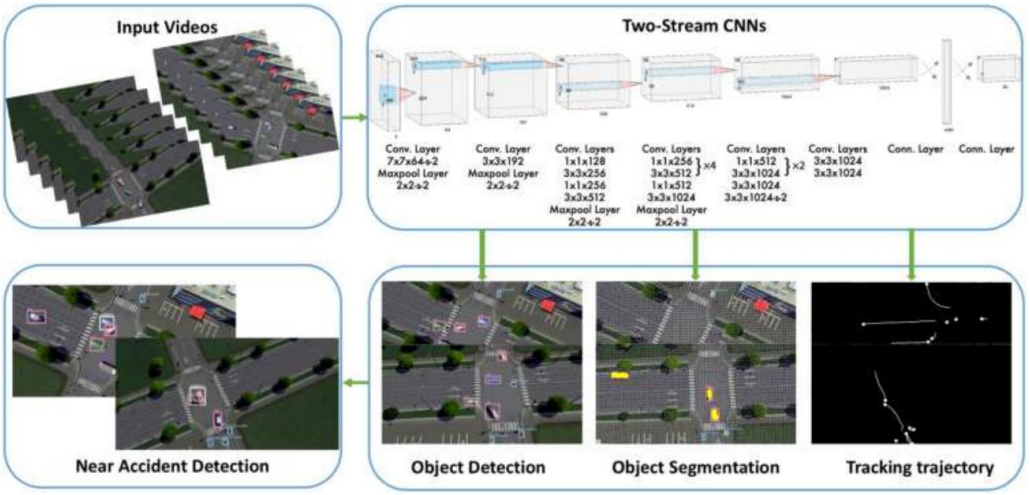


Figura 1. Diagrama general de la arquitectura de nuestras redes neuronales convolucionales de dos flujos para la detección de situaciones cercanas a accidentes.

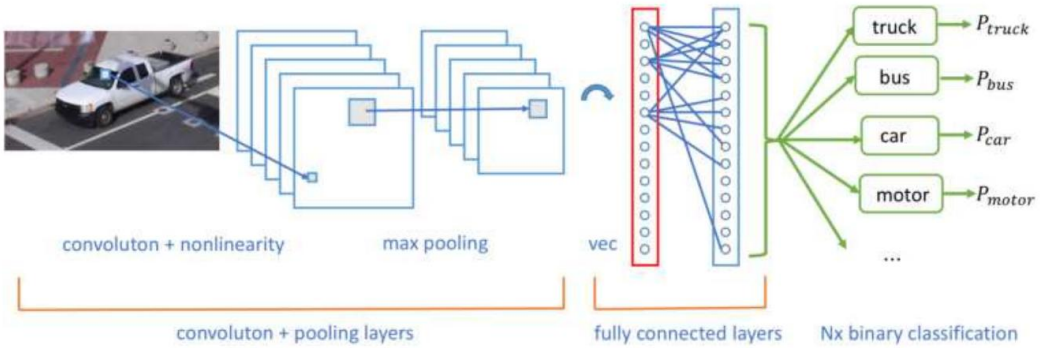


Figura 2. Arquitectura de redes neuronales convolucionales para la clasificación de imágenes.1

La sección 4 presenta la arquitectura general, las metodologías y la implementación de nuestro método. A continuación, se introduce nuestro conjunto de datos de detección de casi accidentes (TNAD) y se presenta una evaluación exhaustiva de nuestro enfoque y otros métodos de detección de casi accidentes de última generación, tanto cualitativa como cuantitativamente. La sección 5 describe la literatura reciente sobre detección de objetos, seguimiento de múltiples objetos y detección de casi accidentes. La sección 6 resume nuestras contribuciones y analiza el alcance del trabajo futuro.

2. BREVE DESCRIPCIÓN DE LOS ENFOQUES ESTÁNDAR DE VISIÓN POR COMPUTADORA

2.1 Redes neuronales convolucionales (CNN)

Las CNN han demostrado una gran capacidad para representar objetos, lo que impulsa el rendimiento de numerosas tareas de visión, especialmente en comparación con las características tradicionales [Dalal y Triggs 2005].
Una CNN es una clase de red neuronal profunda que se aplica ampliamente en el análisis de imágenes y la visión por computadora. Una CNN estándar generalmente consta de una capa de entrada y una capa de salida, así como de múltiples capas ocultas (por ejemplo, capas convolucionales, capas totalmente conectadas, capas de agrupación), como se muestra en la Figura 2. La entrada a una capa convolucional es la imagen original X. Denotamos el mapa de características

1Figura basada en el artículo del blog publicado en https://adeshpande3.github.io/.

Machine Translated by Google

de la i-ésima capa convolucional como Hi y H0 = X. Entonces Hi se puede describir como

$$\text{Hola} = f\,(\text{Hi}-1 \quad \text{Wi} + \text{bi}\,), \tag{1}$$

donde Wi es el peso para el i-ésimo núcleo convolucional para la i-ésima imagen o mapa de características y es la operación de convolución. La salida de la operación de convolución incluye un sesgo bi . Luego, el mapa de características para la i-ésima capa se puede calcular aplicando una función de activación no lineal estándar. Describimos brevemente una imagen RGB de 32 × 32 con una ConvNet simple para la clasificación de imágenes CIFAR-10 [Krizhevsky et al. 2009]:

- Capa de entrada: la imagen original de 32 × 32 con tres canales de color (R, G, B).
- Capa convolucional: operaciones locales en la imagen pasadas a través de activación no lineal funciones. Si usamos 12 filtros, el tamaño del resultado es [32 × 32 × 12].
- Capa de agrupación: una operación de submuestreo, que resulta en un volumen como [16 × 16 × 12].
- Capa totalmente conectada: genera puntuaciones para cada clase, lo que resulta en un volumen de tamaño [1 × 1 × 10]. para 10 clases.

De esta forma, las CNN transforman la imagen original en múltiples representaciones de características de alto nivel, capa por capa, obteniendo finalmente resultados o puntuaciones específicas de cada clase.

2.2 Detección de objetos YOLO El

detector en tiempo real You Only Look Once (YOLO), propuesto en Redmon et al. [2016], es un enfoque de aprendizaje profundo de última generación de extremo a extremo sin utilizar propuestas de región. La canalización de YOLO [Redmon et al. 2016] es bastante sencilla: dada una imagen de entrada, YOLO [Redmon et al. 2016] la pasa a través de la red neuronal solo una vez, como su nombre lo indica (You Only Look Once), y genera los cuadros delimitadores detectados y las probabilidades de clase en la predicción. La Figura 4 demuestra el modelo de detección y el sistema de YOLO [Redmon et al. 2016]. YOLO [Redmon et al. 2016] es órdenes de magnitud más rápido (45 fotogramas por segundo) que otros enfoques de detección de objetos, lo que significa que puede procesar vídeo en streaming en tiempo real. En comparación con otros sistemas, también logra una mayor precisión media promedio. En este trabajo, aprovechamos la extensión de YOLO [Redmon et al.
2016], Darknet-19, un modelo de clasificación utilizado como base de YOLOv2 [Redmon y Farhadi 2017].
Darknet-19 [Redmon y Farhadi 2017] consta de 19 capas convolucionales y cinco capas de max-pooling, donde se utiliza la normalización por lotes para estabilizar el entrenamiento, acelerar la convergencia y regularizar el modelo [Ioe y Szegedy 2015].

2.3 Seguimiento sencillo en línea en tiempo real (SORT)

SORT [Bewley et al. 2016] es un algoritmo de seguimiento de múltiples objetos (MOT) simple, popular y rápido.
La idea central es una combinación del filtrado de Kalman [Kalman 1960] y la asociación de datos fotograma a fotograma. La asociación de datos se implementa con el método húngaro [Kuhn 1955], midiendo la superposición de los cuadros delimitadores. Con esta combinación rudimentaria, SORT [Bewley et al. 2016] logra un rendimiento de vanguardia en comparación con otros rastreadores en línea. Además, debido a su simplicidad, SORT [Bewley et al. 2016] puede actualizarse a una velocidad de 260 Hz en una sola máquina, lo que es más de 20 veces más rápido que otros rastreadores de última generación.

2.4 DeepSORT

DeepSORT [Wojke et al. 2017] es una extensión de SORT [Bewley et al. 2016]. DeepSORT integra información de apariencia para mejorar el rendimiento de SORT [Bewley et al. 2016], agregando una métrica de asociación preentrenada. DeepSORT [Wojke et al. 2017] ayuda a resolver una gran cantidad de problemas de cambio de identidad en SORT [Bewley et al. 2016], y puede rastrear objetos ocluidos en

Machine Translated by Google

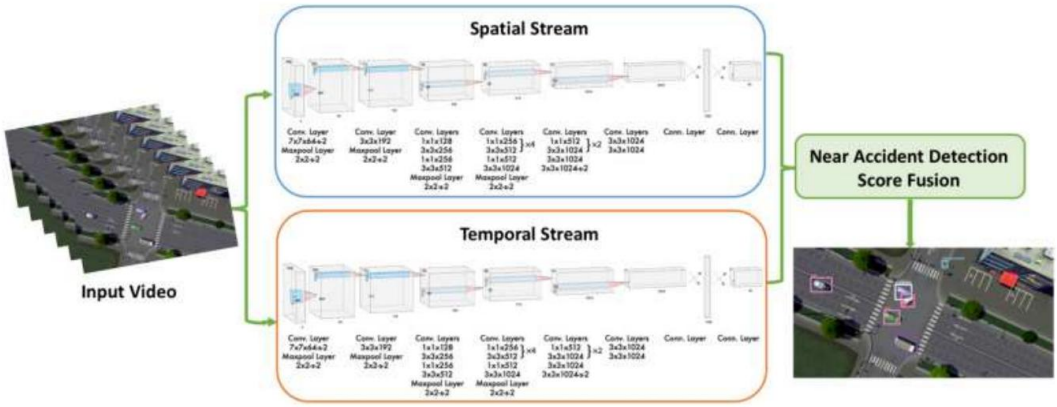


Figura 3. Arquitectura de redes neuronales convolucionales de dos flujos para la detección de situaciones cercanas a accidentes.

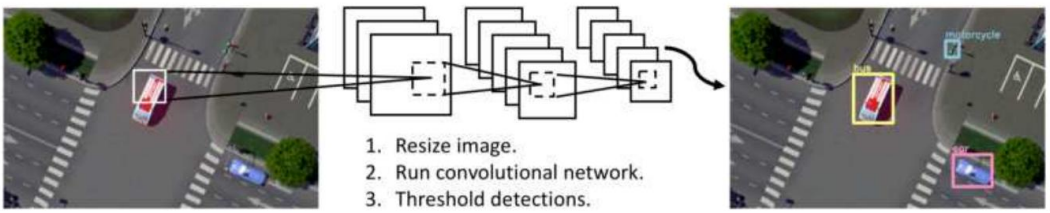


Figura 4. Proceso de detección de objetos de nuestro flujo espacial [Redmon et al. 2016]: (1) redimensiona el vídeo de entrada.
(1) procesa el fotograma, (2) ejecuta una red convolucional en el fotograma y (3) aplica un umbral a la detección resultante del modelo.
confianza.

a más largo plazo. Durante la aplicación en línea, la asociación de medición a seguimiento se establece en
espacio de apariencia visual, utilizando consultas de vecino más cercano.

3. ARQUITECTURA DE DOS FLUJOS PARA LA DETECCIÓN DE ACCIDENTES CERCANOS

En esta sección, presentamos nuestra arquitectura de dos flujos basada en visión artificial para la detección de casi accidentes en tiempo real. La arquitectura se basa principalmente en la detección de objetos en tiempo real y el seguimiento de múltiples objetos (MOT). El objetivo de la detección de casi accidentes es detectar posibles escenarios de colisión en fotogramas de vídeo e informar sobre estos registros de casi accidentes. Debido a que los vídeos tienen tanto información espacial como visual. y componentes temporales, dividimos nuestro marco en una arquitectura de dos flujos como se muestra en
Figura 3. El aspecto espacial comprende información de apariencia de fotogramas individuales sobre escenas y objetos. El aspecto temporal comprende información de movimiento de los objetos. Para la red neuronal convolucional de flujo espacial, utilizamos una red convolucional estándar diseñada para la detección de objetos de última generación [Redmon et al. 2016] para detectar vehículos individuales y marcar casi accidentes.
regiones a nivel de fotograma único. La red de flujo temporal aprovecha los candidatos a objetos de
CNN de detección de objetos e integra su información de apariencia con un método MOT rápido para
Extraemos características de movimiento y calculamos trayectorias. Cuando dos trayectorias de objetos individuales se intersecan o se acercan más de un cierto umbral (cuya estimación se describe a continuación), las etiquetamos.
la región que cubre los dos objetos como una región cercana al accidente de alta probabilidad. Finalmente, tomamos
la probabilidad promedio de casi accidente tanto de la red de flujos espaciales como del flujo temporal
conectar con la red e informar sobre el historial de incidentes cercanos a accidentes.

Machine Translated by Google

3.1 Detección y clasificación de objetos En nuestro

marco, cada flujo se implementa utilizando una red neuronal convolucional profunda. Las puntuaciones de casi accidentes se combinan mediante promediado. Dado que nuestra ConvNet de flujo espacial es esencialmente una arquitectura de detección de objetos, la basamos en los avances recientes en detección de objetos —esencialmente el detector YOLO [Redmon et al. 2016]— y preentrenamos la red desde cero en nuestro conjunto de datos que contiene videos de drones, sheeye y simulaciones a múltiples escalas. Como la mayoría de nuestros videos contienen escenas de tráfico con vehículos y movimiento de tráfico capturado en una vista desde arriba, especificamos diferentes clases de vehículos como motocicleta, automóvil, autobús y camión como clases de objetos para entrenar el detector. Además, los casi accidentes o colisiones se pueden detectar a partir de fotogramas individuales incluso al comienzo de un video o de vehículos detenidos asociados a un accidente después de una colisión. Por lo tanto, entrenamos nuestro detector para localizar estos posibles escenarios de casi accidentes. Dado que la apariencia estática es una pista útil, la red de flujo espacial realiza la detección de objetos operando únicamente sobre fotogramas de vídeo individuales.

La red de flujo espacial realiza una regresión de los cuadros delimitadores y predice las probabilidades de clase asociadas a estos cuadros, utilizando una red convolucional simple de extremo a extremo. Primero toma la imagen y la divide en una cuadrícula S × S. Para cada celda de la cuadrícula,

- Predice B cuadros delimitadores, y cada cuadro tiene una puntuación de confianza.
- Detecta un solo objeto, independientemente del número de cuadros B. •

Predice C probabilidades de clase condicionales (una por clase para la probabilidad del objeto).
clase)

Para cada cuadro delimitador, la CNN genera una probabilidad de clase y valores de oset para el cuadro delimitador. Luego, selecciona los cuadros delimitadores cuya probabilidad de clase supera un valor umbral y los utiliza para localizar el objeto dentro de la imagen. En esencia, cada cuadro delimitador contiene cinco elementos: (x, y, w, h) y una confianza de cuadro. Las coordenadas (x, y) representan el centro del cuadro con respecto a los límites de la celda de la cuadrícula. Los parámetros (w, h) son el ancho y la altura del objeto. Estos elementos se normalizan de manera que x, y, w y h se encuentren en el intervalo [0, 1]. La intersección sobre unión (IoU) entre el cuadro delimitador predicho y el cuadro real se utiliza en la predicción de confianza, que refleja la probabilidad de que el cuadro contenga un objeto (objetualidad) y la precisión del cuadro delimitador. Las definiciones matemáticas de los términos de puntuación y probabilidad son:

$$\text{Puntuación de confianza de la caja } \Pr(\text{objeto}) \cdot \quad ,$$
$$\text{IoU probabilidad de clase condicional } \Pr(\text{clase} \mid \text{objeto}),$$
$$\text{puntuación de confianza de la clase } \Pr(\text{clase}) \cdot \quad ,$$
$$\text{IoU puntuación de confianza de la clase} = \text{puntuación de confianza de la caja} \times \text{probabilidad de clase condicional},$$

donde Pr (objeto) es la probabilidad de que la caja contenga un objeto. IoU es la intersección sobre unión (IoU) entre la caja predicha y la caja real. Pr (clase i) es la probabilidad de que el objeto pertenezca a la clase i . Pr (clase i | objeto) es la probabilidad de que el objeto pertenezca a la clase i dado que hay un objeto presente. La arquitectura de red del flujo espacial simplemente contiene 24 capas convolucionales seguidas de dos capas totalmente conectadas, reminiscentes de AlexNet e incluso arquitecturas convolucionales anteriores. La última capa de convolución es atendida, que produce un tensor (7, 7, 1024) . Realiza una regresión lineal utilizando dos capas totalmente conectadas para hacer predicciones de cajas de contorno y para hacer una predicción final utilizando el umbral de puntuaciones de confianza de la caja. La pérdida final suma la localización (el primer y el segundo término), la confianza (el tercero y el cuarto).

Machine Translated by Google

términos), y la clasificación (el término f) pierde en conjunto. La función objetivo es

$$
\begin{aligned}
L_{multi} = {} & \lambda_{coordenada} \sum_{i=0}^{S^2} \sum_{j=0}^{B} 1_{ij}^{obj} \left[(x_i - \hat{x}_i)^2 + (y_i - \hat{y}_i)^2 \right] + \lambda_{coord} \sum_{i=0}^{S^2} \sum_{j=0}^{B} 1_{ij}^{obj} \left[\left(\sqrt{w_i} - \sqrt{\hat{w}_i} \right)^2 + \left(\sqrt{h_i} - \sqrt{\hat{h}_i} \right)^2 \right] \\
& + \sum_{i=0}^{S^2} \sum_{j=0}^{B} 1_{ij}^{obj} (C_i - \hat{C}_i)^2 + \lambda_{noobj} \sum_{i=0}^{S^2} \sum_{j=0}^{B} 1_{ij}^{novato} (C_i - \hat{C}_i)^2 + \sum_{i=0}^{S^2} 1_i^{obj} \sum_{c \in clases} (p_i(c) - \hat{p}_i(c))^2, \quad (2)
\end{aligned}
$$

objeto donde 1_i^{obj} indica si el objeto aparece en celli y 1_{ij}^{obj} en celli es "responsable" denota que el predictor de cuadro delimitador j de esa predicción.

3.2 Seguimiento de múltiples objetos En

general, el seguimiento de múltiples objetos (MOT) puede considerarse un problema de estimación multivariable [Luo et al. 2014], y el objetivo del MOT puede modelarse realizando una estimación MAP (máxima a posteriori) para encontrar los estados secuenciales óptimos de todos los objetos a partir de la distribución condicional de los estados secuenciales, dadas todas las observaciones:

$$
S_{1:t} = \arg\max_{S_{1:t}} P(S_{1:t} | O_{1:t}), \quad (3)
$$

donde s_t^i denota el estado del i-ésimo objeto en el t-ésimo fotograma, $S_t = (s_t^1, s_t^2, \ldots, s_t^{M_t})$ denota estados de todos los Mt objetos en el t-ésimo fotograma, y $S_{1:t} = \{S_1, S_2, \ldots, S_t\}$ denota todos los estados secuenciales de todos los objetos desde el rst fotograma hasta el t-ésimo fotograma. En el seguimiento por detección, o_t^i denota el t recopilado o observaciones para el i-ésimo objeto en el t-ésimo fotograma. $O_t = (o_t^1, o_t^2, \ldots, o_t^{M_{Monte}})$ denota los objetos recolectados observaciones para todos los Mt objetos en el t-ésimo fotograma. $O_{1:t} = \{O_1, O_2, \ldots, O_t\}$ denota todas las observaciones secuenciales recopiladas de todos los objetos desde el rst fotograma hasta el t-ésimo fotograma.

La red de flujo espacial no puede extraer características de movimiento y calcular trayectorias debido a las entradas de un solo fotograma. Para aprovechar esta información útil, presentamos nuestra red de flujo temporal, un modelo ConvNet que implementa un algoritmo MOT de seguimiento por detección [Bewley et al. 2016; Wojke et al. 2017] con una métrica de asociación de datos que combina características de apariencia profunda. Las entradas son idénticas a la red de flujo espacial que utiliza el vídeo original. Los candidatos a objetos detectados (solo clases de vehículos) se utilizan para el seguimiento, la estimación de estado y la asociación de datos fotograma a fotograma mediante SORT [Bewley et al. 2016] y DeepSORT [Wojke et al. 2017], el método MOT en tiempo real. MOT modela el estado de cada objeto y describe su movimiento a lo largo de los fotogramas del vídeo. La información de seguimiento permite apilar trayectorias de objetos en movimiento a lo largo de varios fotogramas consecutivos, lo que proporciona pistas útiles para la detección de situaciones cercanas a accidentes.

Modelo de estimación. Para cada objetivo, su estado se modela como

$$
x = [u, v, s, r, \dot{u}, \dot{v}, \dot{s}]^T, \quad (4)
$$

donde u,v denota la ubicación en píxeles 2D del centro del objetivo, s denota la escala del cuadro delimitador del objetivo y r es la relación de aspecto (generalmente considerada constante). El estado del objetivo se actualiza cuando se le asocia un nuevo cuadro delimitador detectado, resolviendo la velocidad mediante un filtro de Kalman [Kalman 1960]. El estado del objetivo se predice simplemente (sin corrección mediante el filtro de Kalman) si no se le asocia ningún cuadro delimitador.

Asociación de datos. Para asignar todos los nuevos cuadros de detección a los objetivos existentes, predecimos la nueva ubicación de cada objetivo (un cuadro predicho) en el fotograma actual y comparamos la distancia IoU entre los nuevos cuadros de detección y todos los cuadros predichos (las superposiciones de detección a objetivo), formando así la matriz de costos de asignación. La matriz se utiliza posteriormente en el algoritmo húngaro [Kuhn 1955] para

Machine Translated by Google

Se resuelve el problema de asignación. Una asignación se rechaza si la superposición entre la detección y el objetivo es menor que un umbral (IoU mínimo). Las distancias IoU de los cuadros delimitadores se utilizan para gestionar la oclusión causada por el paso de objetivos a corto plazo.

Creación y eliminación de identidades de seguimiento. Cuando aparecen nuevos objetos o desaparecen otros en los fotogramas de vídeo, es necesario añadir o eliminar ciertas pistas (u objetos) según sus identidades únicas principales. Cualquier detección que no se asocie con objetivos existentes se considera un posible objeto no rastreado. Este objetivo pasa por un periodo de prueba para acumular suficiente evidencia, asociándolo con la detección. Esta estrategia evita el seguimiento de falsos positivos. El objeto rastreado se elimina de la lista si no se detecta en los fotogramas TLost , lo que permite mantener un número relativamente ilimitado de rastreadores y reduce los errores de localización acumulados durante un largo periodo.

Manejo de pistas y estimación de estado. Esta parte es prácticamente idéntica a SORT [Bewley et al. 2016]. El escenario de seguimiento se representa como un espacio de estados de ocho dimensiones (u,v,γ ,h, x˙,y˙,γ˙, ˙h). (u,v) representa la ubicación del centro del cuadro delimitador. γ es la relación de aspecto y h es la altura. El resto son sus velocidades relativas a otros cuadros delimitadores. Esta representación se utiliza para describir el movimiento de velocidad constante (x˙,y˙,γ˙, ˙h) y el modelo de observación lineal (u,v,γ ,h) en el filtrado de Kalman [Kalman 1960].

Asociación de datos. Para resolver el problema de asociación fotograma a fotograma, SORT utiliza el algoritmo húngaro. algoritmo [Kuhn 1955] donde se considera tanto la información de movimiento como la de apariencia.

Para manejar la información de movimiento, se utiliza la distancia de Mahalanobis (al cuadrado) para medir la distancia entre las mediciones recién llegadas y los estados de Kalman: $d^{(1)}(i, j) = (d_j - y_i)^T (Y)^{-1} (d_j - y_i)$, (5)

donde yi y dj denotan la distribución de la i-ésima pista y la detección del j-ésimo cuadro delimitador, respectivamente. Se considera la distancia coseno más pequeña entre la i-ésima pista y la j-ésima detección para manejar la información de apariencia:

$$d^{(2)}(i, j) = \min\left\{1 - r_j^T R_i^{(i)} r_k^{(i)} \right\} \quad (6)$$

Tanto el movimiento como la apariencia se combinan mediante una combinación lineal donde la influencia de cada uno está controlada por un hiperparámetro λ:

$$c_{i,j} = \lambda d^{(1)}(i, j) + (1 - \lambda) d^{(2)}(i, j). \quad (7)$$

Cascada de coincidencia. Los métodos anteriores intentan resolver las asociaciones de medición a trayectoria de forma global, mientras que SORT adopta una cascada de coincidencia, introducida en Wojke et al. [2017], para resolver una serie de subproblemas. En algunas situaciones, cuando un objeto está ocluido durante un período de tiempo prolongado, las predicciones subsiguientes del filtro de Kalman [Kalman 1960] aumentarían la incertidumbre asociada con la ubicación del objeto. Como consecuencia, la masa de probabilidad se extenderá en el espacio de estados y la probabilidad de observación será menos pronunciada. La distancia de medición a trayectoria debe incrementarse considerando la dispersión de la masa de probabilidad. Por lo tanto, los objetos vistos con mayor frecuencia reciben mayor prioridad en la estrategia de cascada de coincidencia para codificar la noción de dispersión de probabilidad en la probabilidad de asociación.

3.3 Aprendizaje métrico para la reidentificación de vehículos

El aprendizaje métrico y diversas características diseñadas manualmente se utilizan ampliamente en problemas de reidentificación de personas. Aplicamos un método de aprendizaje métrico de coseno para entrenar una red neuronal para la reidentificación de vehículos y la utilizamos para hacer que nuestro flujo temporal sea más robusto en términos de rendimiento de seguimiento. El aprendizaje métrico tiene como objetivo resolver el problema de agrupamiento mediante la construcción de una incrustación en la que la distancia métrica correspondiente a la misma identidad es probable que sea más cercana que las característica

Machine Translated by Google



Figura 5. Muestras de vehículos seleccionadas del conjunto de datos VeRi [Liu et al. 2016b]. Todas las imágenes tienen el mismo tamaño y se redimensionan a 64 × 128 para el entrenamiento. Izquierda: Diversidad de colores y tipos de vehículos; derecha: variación de los puntos de vista, la iluminación, la resolución y las oclusiones de los vehículos.

de identidades diferentes. La métrica del coseno mide el grado de similitud calculando la distancia del coseno entre dos objetos. Observamos que en el video de seguimiento, especialmente en escenas de seguimiento concurridas o escenas con oclusión fuerte, nuestro algoritmo de seguimiento produce identidades de usuarios de la carretera intercambiadas. Para generar datos de seguimiento precisos y consistentes, introducimos un método de aprendizaje de métrica de coseno profundo para aprender la distancia del coseno entre objetos. La distancia del coseno involucra información de apariencia que proporciona pistas útiles para recuperar identidades en escenas concurridas o después de una oclusión prolongada cuando la información de movimiento es menos discriminativa. A través de esta red profunda, el vector de expresión de características obtenido por cualquier objeto se coloca en el clúster correspondiente al vecino más cercano. Entrenamos la red en un conjunto de datos de reidentificación de vehículos (conjunto de datos VeRi) [Liu et al. 2016b] (Figura 5) y lo integramos como la segunda medida métrica para el problema de asignación de nuestro flujo temporal.

Nuestra idea es utilizar un marco de trabajo unificado de extremo a extremo que aprenda automáticamente las mejores métricas. Comparado con la métrica de distancia estándar (L1, L2), la métrica aprendida puede obtener características más discriminativas para Re-ID y es más robusta a imágenes de vehículos de vista cruzada. Adoptamos la arquitectura de [Wojke y Bewley 2018] y entrenamos una red profunda con un clasificador softmax de coseno, que puede generar vectores de características de longitud fija (128) para las imágenes de entrada (vehículos). La métrica de coseno encuentra el ejemplar de clúster más cercano y hace coincidir el vehículo en diferentes fotogramas de vídeo (a veces lejanos) para resolver problemas de seguimiento en presencia de una fuerte oclusión. de N imágenes de entrenamiento xi RD y etiquetas de clase asociadas Dado {1, . . . ,C}, el aprendizaje de métricas profundas es para $_{i=1}^{norte}$ un conjunto de datos de reidentificación D = {(xi ,yi)} yi encontrar una función de codificador parametrizada. La red neuronal métrica profunda es r = fΘ(x) con parámetros Θ, que proyecta las imágenes de entrada x RD en una representación de características r Rd que sigue una noción predefinida de similitud del coseno.

El clasificador softmax de coseno se puede adaptar a partir de un clasificador softmax estándar y se expresa como

$$p(y = k|r) = \frac{\exp \kappa \cdot \tilde{w}_k^T r}{\sum_{n=1}^{do} \exp \kappa \cdot \tilde{w}_{\text{nota}}^T r}, \tag{8}$$

donde κ es un parámetro de escala libre. Para generar clústeres compactos en el espacio de representación de características, la primera modificación es aplicar la normalización a la capa final de la red codificadora de modo que la representación tenga longitud unitaria fΘ(x)2 = 1, x RD . La segunda modificación es normalizar los pesos a longitud unitaria también, es decir, w˜ la red codificadora se puede llevar a cabo utilizando la pérdida de entropía k = sem /sem 2, k = 1, . . . ,C. El entrenamiento de cruzada, como es habitual. En particular, los autores en Salimans y Kingma [2016] han propuesto una forma de acelerar la convergencia del descenso de gradiente estocástico desacoplando la longitud del vector de peso κ de su dirección.

Machine Translated by Google

3.4 Uso de la segmentación de imágenes para determinar las brechas entre objetos

Para presentar nuestro método de forma integral, aplicamos un umbral de distancia dinámico basado en aprendizaje en lugar de uno definido manualmente para determinar la detección de casi accidentes. Se detecta un casi accidente si la distancia entre dos objetos en el espacio de la imagen es inferior al umbral. Introducimos un método de aprendizaje de umbral estimando la brecha entre objetos mediante la segmentación de objetos. Presentamos un método de aprendizaje supervisado, utilizando la distancia de brecha entre usuarios de la vía en el flujo temporal para determinar un casi accidente mientras continuamos actualizando el umbral para una mayor convergencia y precisión. La forma directa es calcular la brecha utilizando cuadros delimitadores de las detecciones, pero los cuadros delimitadores no son precisos en términos de representar los límites de los objetos, particularmente cuando hay rotación involucrada. Necesitamos una representación más compacta y, por lo tanto, combinamos las detecciones con la segmentación de superpíxeles en el fotograma de video para obtener una máscara de objeto para la estimación de la distancia de brecha.

Los pasos principales de nuestro método de estimación de brechas se pueden resumir de la siguiente manera:

(1) Extraer detecciones de objetos (cuadros delimitadores) de la red de flujo espacial.
(2) Teselar el fotograma de vídeo en superpíxeles homogéneos.
(3) Calcular la métrica de Intersección sobre Unión (IoU) de cuadros delimitadores y superpíxeles en nivel de fotograma.
(4) Generar máscara de objeto por detecciones (usando la métrica IoU) y calcular la separación entre objetos usando la máscara y los cuadros delimitadores.
(5) Actualizar el umbral de separación mientras se procesa el video.

En nuestro método de estimación de brechas, la métrica de Intersección sobre Unión (IoU) de cajas y superpíxeles viene dada por

$$\text{IoU} = \frac{\text{área}(B1{:}t) \cap \text{área}(S1{:}t)}{\text{área}(B1{:}t) \quad \text{área}(S1{:}t)}, \tag{9}$$

donde b_t^i denota la detección del i-ésimo objeto en el t-ésimo fotograma, Bt = ($b_{t,}^1 b_{t,\ldots,}^2$ Monte b_t) denota el observaciones de detección recopiladas para todos los Mt objetos en el fotograma t, y B1:t = {B1, B2, . . . , Bt } denota todas las observaciones de detección secuenciales recopiladas de todos los objetos desde el primer fotograma hasta el fotograma t. De manera similar, s_t^i denota el i-ésimo superpíxel en el t-ésimo fotograma. St = (s^1 2 ss t , t , . . . , t denota s son todos los Nt superpíxeles en el fotograma t. S1:t = {S1, B2, . . . , St } denota todos los superpíxeles secuenciales recopilados desde el primer fotograma hasta el fotograma t.

En la segmentación de superpíxeles 2D, los populares métodos SLIC (agrupamiento iterativo lineal simple) [Achanta et al. 2012] y mapa de contorno ultramétrico (UCM) [Arbelaez et al. 2010] se han consolidado como el estado del arte. Recientemente, hemos visto redes neuronales profundas [Jampani et al. 2018] y redes generativas antagónicas (GAN) [Yan et al. 2018] integradas con estos métodos. En nuestra arquitectura, adoptamos el enfoque SLIC basado en GPU (gSLICr) [Ren et al. 2015] para producir la teselación de los datos de imagen y lograr una excelente velocidad de fotogramas (400 fps). SLIC es ampliamente aplicable a muchas aplicaciones de visión artificial, como segmentación, clasificación y reconocimiento de objetos, logrando a menudo un rendimiento de vanguardia. En la Figura 6 se muestran los contornos que forman los superpíxeles homogéneos. En la Figura 7, mostramos una ilustración de la definición de intersección y unión, y presentamos algunas máscaras de objetos que generamos a partir de detecciones y superpíxeles.

3.5 Detección de incidentes cercanos a un accidente

La señal de movimiento más típica es el flujo óptico, que se utiliza ampliamente en tareas de procesamiento de vídeo como la segmentación de vídeo [Huang et al. 2018]. Una trayectoria se define como una secuencia de datos.

Machine Translated by Google

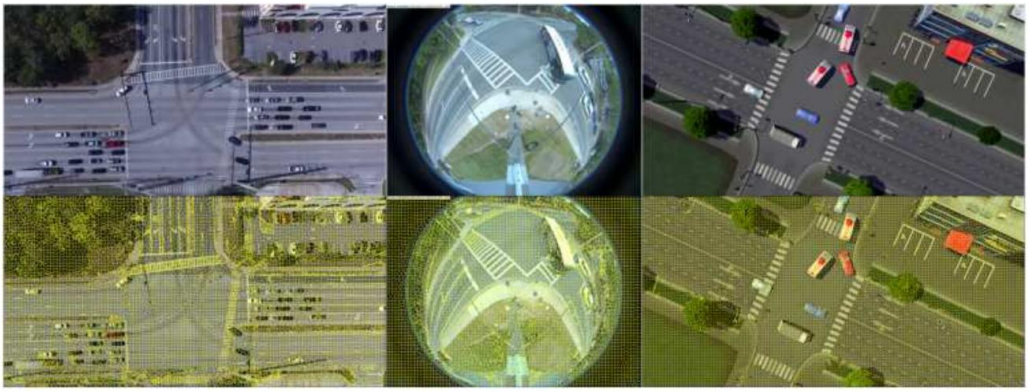


Figura 6. Segmentación de superpíxeles de imágenes 2D mediante SLIC [Achanta et al. 2012]. Arriba: imagen original; boom-le: segmentación SLIC para vídeo de dron (1600 superpíxeles); boom-middle: segmentación SLIC para vídeo ojo de pez (1600 superpíxeles); boom-right: segmentación SLIC para vídeo de simulación (1600 superpíxeles).

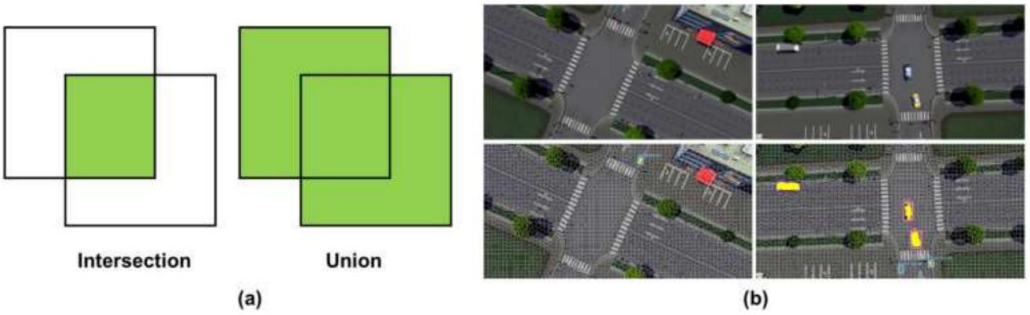


Figura 7. (a) Ilustración que muestra las definiciones de intersección y unión. (b) Arriba: fotogramas de vídeo originales; abajo: detecciones de objetos y máscaras de objetos producidas por nuestro método.

que contiene varios vectores de estado concatenados procedentes del seguimiento y una secuencia indexada de posiciones y velocidades durante una ventana de tiempo determinada.

Al utilizar el algoritmo de seguimiento de múltiples objetos, calculamos el centro de cada objeto en varios fotogramas consecutivos para formar trayectorias apiladas que representan su movimiento. Estas trayectorias apiladas proporcionan información acumulada a través de los fotogramas, como el número de objetos, su historial de movimiento y la sincronización de sus interacciones, por ejemplo, en situaciones de riesgo.

Apilamos las trayectorias de todos los objetos para L fotogramas consecutivos, como se ilustra en la Figura 8, donde) denota las trayectorias p t de todos los Mt objetos en el fotograma t. P1:t = {P1, la ^{i} denota la posición central del i-ésimo objeto en el t-ésimo fotograma. Pt = (p $^{1}_{\text{Monte}}$ t , p $^{2}_{t}$ t , . . . p P2, . . . , Pt } denota secuencia de trayectorias de todos los objetos desde el primer fotograma hasta el fotograma t. Para L fotogramas consecutivos, las trayectorias apiladas se definen mediante la secuencia

$$P_{1:L} = \{P_1, P_2, \ldots, P_L\}, P_{L+1:2L} = \{P_{L+1}, P_{L+2}, \ldots, P_{2L}\}, \ldots \tag{10}$$

donde Ot = (o $^{1}_{o\,t}$,2 ,t , . . . , o $^{\text{Monte}}_{t}$) denota las observaciones recopiladas para todos los Mt objetos en el fotograma t, y O1:t = {O1, O2, . . . , Ot } denota todas las observaciones secuenciales recopiladas de todos los objetos desde el primer fotograma hasta el fotograma t. Usamos un algoritmo de detección simple que encuentra colisiones entre formas simplificadas de los objetos, usando el centro de los cuadros delimitadores.

Machine Translated by Google

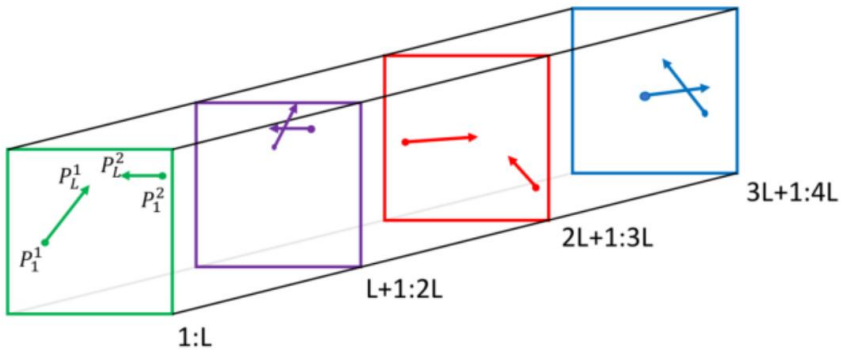


Figura 8. Trayectorias de apilamiento extraídas del seguimiento de múltiples objetos en el flujo temporal. Los fotogramas consecutivos y los vectores de desplazamiento correspondientes se muestran con el mismo color.

ALGORITMO 1: Detección de colisiones

Entrada: fotograma actual tcur r ent , lista de estados de colisión Colisión
Salida: lista de estados de colisión Colisión
para tL ← tprevious a tcurrent en pasos de L fotogramas hacer para
  cada par de trayectorias de objetos (p :tL , p $^{1}_{:tL}$ $^{2}_{:tL}$) hacer
    si (p $^{1}_{:tL}$ interseca p $^{2}_{:tL}$ a partir de tL) entonces
      agregar o1, o2 a Colisión
    fin
  fin si
  (Colisiones) entonces
    tpr evious ← tL; devolver
  VERDADERO fin
fin
tpr evious ← td ; devolver FALSO

Nuestro algoritmo se describe en el Algoritmo 1. Una vez detectada una colisión, definimos la región que abarca los objetos asociados a la colisión como un nuevo cuadro delimitador con una probabilidad de casi accidente de 1. Al promediar las probabilidades de casi accidente de la red de flujo espacial y la red de flujo temporal, podemos obtener una medida de confianza final en la detección de casi accidentes.

4 EXPERIMENTOS

En este trabajo, presentamos una evaluación cualitativa y cuantitativa en términos del rendimiento de la detección de objetos, el seguimiento de objetos móviles (MOT) y la detección de situaciones cercanas a accidentes, así como una comparación entre otros métodos y nuestro marco de trabajo.

4.1 Un conjunto de datos de incidentes cercanos a accidentes de Traic (TNAD)

Hasta donde sabemos, no conocemos ningún conjunto de datos completo de casi accidentes en el tráfico que contenga vídeos con vista cenital, como vídeos de drones o UAV, o vídeos de cámaras omnidireccionales para el análisis del tráfico. Por lo tanto, hemos creado nuestro propio conjunto de datos, el conjunto de datos de casi accidentes en el tráfico (TNAD), que se muestra en la Figura 9. Las intersecciones tienden a experimentar más casi accidentes y los potencialmente más graves se deben a factores como los ángulos y las colisiones al girar. El conjunto de datos de casi accidentes en el tráfico contiene tres tipos de datos de vídeo de intersecciones del tráfico que podrían utilizarse no solo para la detección de casi accidentes, sino también para otras tareas de vigilancia del tráfico, incluido el conteo de movimientos de giro.

Machine Translated by Google



Figura 9. Muestras de incidentes cercanos a accidentes: Nuestros datos consisten en una gran cantidad de videos de vigilancia de intersecciones y diversos incidentes cercanos a accidentes (automóviles y motocicletas). Los rectángulos y líneas amarillas representan el mismo objeto en videos grabados con múltiples cámaras. Los círculos blancos representan las zonas donde ocurrieron los incidentes cercanos a accidentes.

El primer tipo es un video de dron que monitorea una intersección con una vista desde arriba. El segundo tipo de video de intersección es un video de tráfico real adquirido por cámaras omnidireccionales Sheye que monitorean intersecciones pequeñas o grandes. Se utilizan ampliamente en la vigilancia del transporte. Estos datos de video se pueden usar directamente como entrada para nuestro marco inteligente basado en visión. Además, se puede aplicar preprocesamiento y corrección Sheye para un mejor rendimiento de vigilancia. El tercer tipo de video son simulaciones de motor de videojuegos que se entrenan con muestras de casi accidentes a medida que se acumulan. El conjunto de datos consta de 106 videos con una duración total de más de 75 minutos, con velocidades de fotogramas entre 20 y 50 fps. Los videos de vigilancia de dron y Sheye se grabaron en Gainesville, Florida, en varias intersecciones diferentes. Nuestros videos son más desafiantes que los videos en otros conjuntos de datos por las siguientes razones:

- Diversidad de escenas de intersección y perspectivas de cámara: Las intersecciones en los vídeos de drones, de vigilancia con cámara sh-eye y de simulación son muy diversas. Además, el vídeo de vigilancia con cámara sh-eye presenta distorsión, por lo que se requiere una técnica de fusión para vídeos con múltiples cámaras sh-eye.
- Intersección concurrida y objetos pequeños: La cantidad de coches y motocicletas en movimiento por fotograma es grande, y estos objetos son relativamente más pequeños que en un vídeo de tráfico normal.
- Diversos accidentes: Se incluyen accidentes que involucran automóviles y motocicletas. •

Diversas condiciones de iluminación: Se incluyen condiciones de iluminación como la luz del día y la puesta del sol.

En cada vídeo, se anotó manualmente la ubicación espacial y temporal de los incidentes cercanos, así como de los objetos estáticos o en movimiento y su tipo de vehículo. Se utilizaron treinta y dos vídeos con un número reducido de fotogramas (solo el 20 % de los fotogramas de estos 32 vídeos se utilizaron para la supervisión), pero únicamente para entrenar el detector de objetos. Los 74 vídeos restantes se utilizaron para las pruebas.

4.2 Vídeo ojo de pez y multicámara Tenemos

grandes cantidades de vídeos de sheye trac de toda la ciudad. Los vídeos de vigilancia sheye se grabaron a partir de datos trac reales en Gainesville. Recopilamos 29 vídeos de vigilancia sheye de una sola cámara y 19 vídeos de vigilancia sheye multicámara que monitoreaban una gran intersección.

Machine Translated by Google

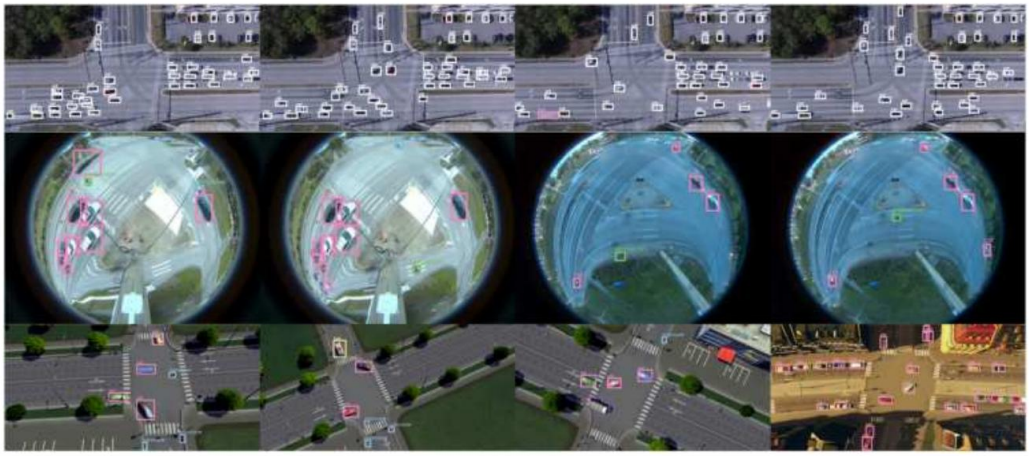


Figura 10. Ejemplos de resultados de detección de objetos de nuestra red espacial en el conjunto de datos TNAD. Arriba: ejemplos de vídeo de dron; en el medio: ejemplos de vídeo ojo de pez; abajo: ejemplos de vídeo de simulación.

Realizamos dos experimentos: uno utilizando directamente estos vídeos sin procesar como entrada para nuestro sistema y otro en el que preprocesamos el vídeo para corregir la distorsión de la imagen y luego lo introdujimos en nuestro sistema. Dado que el vídeo de vigilancia original presenta numerosas distorsiones visuales, especialmente cerca de los límites circulares de las cámaras, nuestro sistema obtuvo mejores resultados tras el preprocesamiento. En este artículo, no abordamos los problemas relacionados con la corrección de la distorsión de la imagen, dejándolos para trabajos futuros.

Para intersecciones grandes, se utilizan dos cámaras Sheye colocadas una frente a la otra para la vigilancia, y cada una muestra casi la mitad de las carreteras y el tráfico real. Aplicamos un método sencillo de unión de objetos asignando la identidad de los mismos objetos en los vídeos izquierdo y derecho mediante características similares y posiciones de aparición y desaparición.

4.3 Entrenamiento del modelo

Adoptamos Darknet-19 [Wojke et al. 2017] para la clasificación y detección con DeepSORT, utilizando una métrica de asociación de datos que combina características de apariencia profunda. Implementamos nuestro marco en Tensorow y realizamos entrenamiento y pruebas multiescala con una sola GPU (Nvidia Titan X Pascal). Entrenar una sola red convolucional espacial toma un día en nuestro sistema con una tarjeta Nvidia Titan X Pascal. Para el entrenamiento de clasificación y detección, utilizamos la misma estrategia de entrenamiento que YOLO9000 [Wojke et al. 2017]. Entrenamos la red en nuestro conjunto de datos con cuatro clases de vehículos (motocicleta, autobús, coche y camión) durante 160 épocas, utilizando descenso de gradiente estocástico con una tasa de aprendizaje inicial de 0,1 para clasificación y 10−3 para detección (dividiéndola por 10 en las épocas 60 y 90), decaimiento de peso de 0,0005 y momento de 0,9 utilizando el marco de red neuronal Darknet [Wojke et al. 2017].

4.4 Resultados alternativos

Presentamos algunos ejemplos de resultados experimentales de detección de objetos, MOT y detección de casi accidentes en nuestro conjunto de datos de casi accidentes de Trac (TNAD) para videos de drones, videos de sheye y videos de simulación. Para la detección de objetos (Figura 10), presentamos algunos resultados de detección de nuestra red espacial con entrenamiento multiescala basado en YOLOv2 [Redmon y Farhadi 2017]. Estos resultados visuales demuestran que el flujo espacial es capaz de detectar y clasificar a los usuarios de la carretera con buena precisión incluso si los videos de sheye originales tienen grandes distorsiones y oclusiones. A diferencia de los videos de drones y simulación, hemos añadido la detección de peatones en videos de sheye reales de Trac.

Machine Translated by Google



Fig. 11. Comparación de seguimiento y trayectoria con Urban Tracker [Jodoin et al. 2014] y TraicIntelligence [Jackson et al. 2013] en videos de drones del conjunto de datos TNAD. Izquierda: resultados de seguimiento de Urban Tracker [Jodoin et al. 2014] (BSG con Multicapa y Modelo Lobster); centro: resultados de seguimiento de TraicIntelligence [Jackson et al. 2013]; derecha: resultados de seguimiento de nuestra red de flujo temporal.

En la Figura 10, observamos que nuestro detector ofrece un buen rendimiento en la detección de peatones en vídeos grabados con luz diurna y al amanecer. La detección de vehículos es eficaz en vídeos de vigilancia con vista cenital, incluso para objetos pequeños. Además, podemos alcanzar una alta tasa de detección de entre 20 y 30 fotogramas por segundo. En definitiva, esto demuestra la eficacia de nuestra red neuronal espacial.

Para MOT (Figura 11), presentamos una comparación de nuestra red temporal basada en DeepSORT [Wojke et al. 2017] con Urban Tracker [Jodoin et al. 2014] y TracIntelligence [Jackson et al. 2013]. También presentamos comparaciones MOT más visuales de nuestro flujo temporal de referencia (DeepSort) con el flujo temporal basado en aprendizaje de métrica de coseno (Figura 12). Para la parte de seguimiento, utilizamos un paradigma de seguimiento por detección, por lo que nuestros métodos pueden manejar objetos estáticos y medir su estado. Esto es especialmente útil, ya que Urban Tracker [Jodoin et al. 2014] y TracIntelligence [Jackson et al. 2013] solo pueden rastrear objetos en movimiento. Sin embargo, Urban Tracker [Jodoin et al. 2014] y TracIntelligence [Jackson et al. 2013] pueden calcular trayectorias densas de objetos en movimiento con buena precisión, pero tienen una velocidad de seguimiento más lenta, alrededor de un fotograma por segundo. Para la detección de accidentes, nuestras redes convolucionales de dos flujos pueden realizar localización espacial y localización temporal para diversas regiones de accidentes que involucran automóviles y motocicletas. Las tres subtareas (detección de objetos, MOT y detección de casi accidentes) pueden lograr siempre un rendimiento en tiempo real a una alta velocidad de fotogramas (de 40 a 50 fotogramas por segundo), y esto depende de la resolución del fotograma (por ejemplo, 50 fps para fotogramas de imagen de 960×480).

En la Figura 12, demostramos la efectividad de aplicar el aprendizaje de métrica de coseno con el flujo temporal para resolver el cambio de ID (y para el caso en que surgen nuevos ID de objeto). Por ejemplo, la primera fila muestra que el ID de la tarjeta verde (dentro del círculo rojo) cambió de 32 a 41.
La tercera fila muestra que los ID del coche rojo y del peatón (dentro del círculo rojo) se modificaron (de 30 a 43 y de 38 a 44, respectivamente). La segunda y la cuarta fila demuestran que, con el aprendizaje de la métrica del coseno, los ID de las trayectorias se mantienen consistentes. En la Figura 13, mostramos un ejemplo de una máscara de usuario de la vía más precisa y compacta, generada mediante segmentación y detección de superpíxeles para la estimación de la brecha basada en el aprendizaje. Con una máscara de segmentación, podemos estimar la distancia de la brecha entre los usuarios de la vía de forma más precisa que utilizando directamente la detección de objetos.
La segmentación sería más útil para videos de ojos donde la distorsión es grande y la oclusión es más intensa. Para la detección de casi accidentes (Figura 14), presentamos los resultados finales de detección de casi accidentes junto con el seguimiento y las trayectorias utilizando nuestro método de redes neuronales convolucionales de dos flujos.
En general, los resultados cualitativos demuestran la eficacia de nuestras redes espaciales y temporales.

Machine Translated by Google

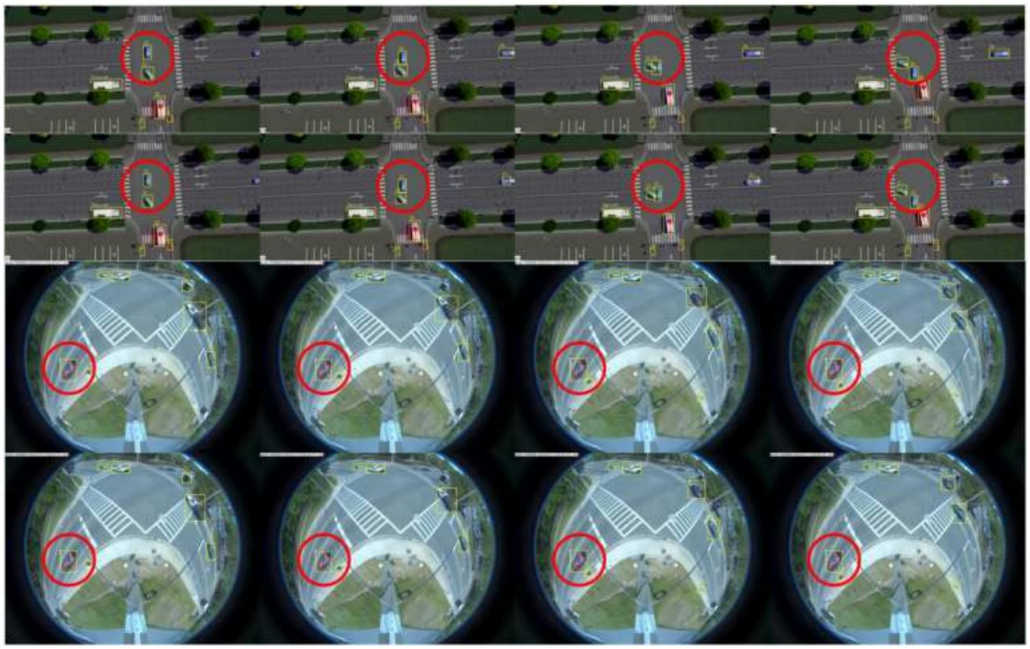


Figura 12. Comparaciones de seguimiento de múltiples objetos de nuestro flujo temporal de referencia (SORT) con la métrica del coseno. flujo temporal basado en aprendizaje. Fila 1: resultados de SORT (problema de cambio de ID); fila 2: resultados de coseno aprendizaje métrico + SORT (consistencia de ID); fila 3: resultados de SORT (problema de cambio de ID); fila 4: resultados de Aprendizaje de métrica de coseno + SORT (consistencia de ID).

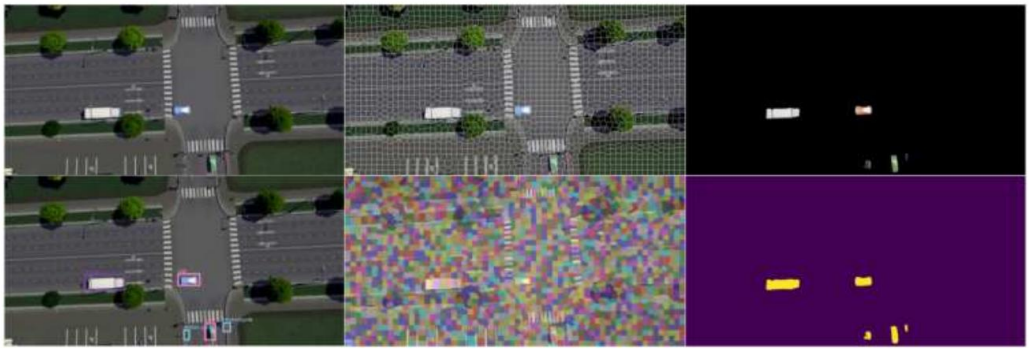


Fig. 13. Segmentación de objetos mediante detecciones y superpíxeles. Arriba a la izquierda: imagen original; arriba en el medio: superpíxeles generados por SLIC [Achanta et al. 2012]; arriba a la derecha: máscara final del objeto; abajo a la izquierda: detecciones del objeto; boom-middle: superpíxeles coloreados generados por SLIC [Achanta et al. 2012]; boom right: objeto binario final mascarilla.

4.5 Resultados antitativos

4.5.1 Rendimiento de velocidad. Presentamos los resultados de tiempo para los métodos probados en la Tabla 1. Todos los experimentos se han realizado en una sola GPU (NVIDIA TITAN V). La segmentación SLIC basada en GPU [Achanta et al. 2012] tiene una velocidad excelente y se ejecuta de 110 a 400 fps en vídeos de diferentes resoluciones. Las CNN de dos flujos generales (detección de objetos, MOT y casi accidentes)

Machine Translated by Google



Figura 14. Resultados de muestra del seguimiento, trayectoria y detección de casi accidentes de nuestra red neuronal convolucional de dos flujos.
redes en videos de simulación del conjunto de datos TNAD. Izquierda: resultados de seguimiento del flujo temporal; centro:
Resultados de la trayectoria a partir del flujo temporal; derecha: resultados finales de la detección de casi accidentes a partir del flujo doble.
redes neuronales convolucionales.

Tabla 1. Evaluación antitativa de los resultados de sincronización para los métodos probados

Métodos	GPU	Zumbido	Simulación		ojo de pez
		1920 × 960 2560 × 1280 3360 × 1680 1280 × 960			
Segmentación SLIC	NVIDIA TITAN V	300 fps	178 fps	110 fps	400 fps
CNN de doble flujo	NVIDIA TITAN V	43 fps	38 fps	33 fps	50 fps

detección) puede lograr un rendimiento en tiempo real a una alta velocidad de fotogramas, de 33 a 50 fps, dependiendo de la resolución de fotograma.

4.5.2 Seguimiento mejorado de múltiples objetos con aprendizaje de métrica de coseno. Presentamos algunos Resultados cuantitativos para la estimación de brechas y el aprendizaje de la métrica del coseno en la Figura 15. Los resultados para Se ha establecido el aprendizaje de la métrica del coseno después de entrenar la red para un número fijo de pasos (100.000 iteraciones). El tamaño del lote se estableció en 120 imágenes y la tasa de aprendizaje fue de 0,001. Todas las configuraciones después del entrenamiento han convergido completamente como se muestra en la Figura 15.

Pérdida de tripletas. La pérdida de tripletas para la red de aprendizaje de métrica de coseno [Weinberger y Saul 2009] es definido por

$$Lt(r_a, r_p, r_n) = r_a - r_n 2 - r_a - R_p 2 + m_+ \quad (11)$$

donde r y r_a, r_p, r_n tres muestras en las que un par positivo, ya = yp , y un par negativo, ya yn están incluidos. Con un margen predefinido m R, la pérdida de triplete exige la distancia entre lo positivo y lo negativo es mayor que eso. En este experimento, introducimos una pérdida de triplete basada en margen suave donde reemplazamos la bisagra de la pérdida de triplete original [Hermans et al. 2017] por una función suave más, {x + m}+ = log(1 + exp(x)), para resolver la falta de suavidad [Rippel et al. 2015] problemas. Además, para evitar posibles problemas en la estrategia de muestreo, generamos directamente los tripletes. en GPU como proponen [Hermans et al. 2017].

Machine Translated by Google

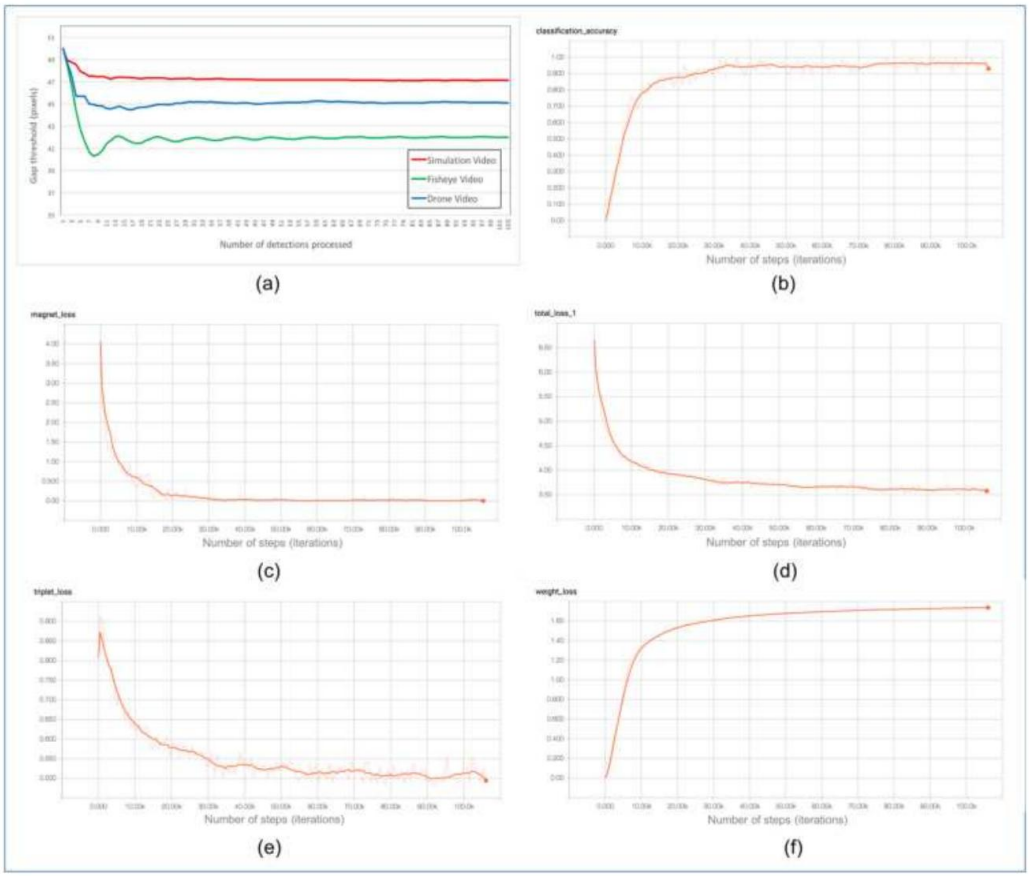


Fig. 15. Estimación de brecha y aprendizaje de métrica de coseno. (a) Evolución del umbral de brecha para tres tipos de videos; (b) precisión de clasificación para el conjunto de datos de entrenamiento VeRi; (c) evolución de la pérdida total para el entrenamiento; (d) evolución de la pérdida magnética para el entrenamiento; (e) evolución de la pérdida triplete para el entrenamiento; (f) evolución de la pérdida de peso para el entrenamiento.

Pérdida magnética. La pérdida magnética se define como una medida de razón de verosimilitud que exige la separación de todas las muestras de las medias de otras clases. En lugar de utilizar una forma multimodal en su propuesta original [Rippel et al. 2015], utilizamos una versión unimodal y adaptada de esta pérdida para el problema de reidentificación de vehículos:

$$Lm(y, r) = -\log \frac{y^{-\frac{1}{2\sigma^2}\,\|r-\mu\hat{}_y\|_2^2-m^2}}{\sum_{k\,\bar{C}(y)} y^{-\frac{1}{2\sigma^2}\,\|r-\mu\hat{}_k\|_2^2}} + , \tag{12}$$

donde $\bar{C}(y) = \{1, \ldots, C\} \setminus \{y\}$, y m es el parámetro de margen predefinido, $\mu\hat{}_y$ representa la media muestral se utiliza para de la clase y, y $\sigma\hat{}$ la media de su clase. Todos se ^{2} denota la varianza de cada muestra separada establecen para cada lote individualmente en la GPU.

4.5.3 Segmentación de objetos. Para aprender el umbral de separación con segmentación y detección de superpíxeles, el gráfico (arriba a la izquierda) muestra la evolución convergente de la distancia de separación para tres tipos de vídeo. El umbral de separación inicial se establece en 50 píxeles, y los umbrales de separación promedio de los experimentos son de aproximadamente 47 píxeles, 45 píxeles y 42 píxeles para vídeo de simulación, vídeo de Sheye y vídeo de dron, respectivamente.

Machine Translated by Google

Tabla 2. Evaluación antitativa de todas las tareas para nuestro método de dos flujos

Tarea o métodos	Datos	Puntuación F1 de precisión y exhaustividad		
Detección de objetos	Simulación	0,92670	0,95255	0,93945
	ojo de pez	0,93871	0,87978	0,90829
Seguimiento de múltiples objetos	Simulación	0,89788	0,86617	0,88174
	ojo de pez	0,91239	0,84900	0,87956
Seguimiento de múltiples objetos (métrica coseno)	Simulación	0,91913	0,90310	0,91105
	ojo de pez	0,92663	0,87725	0,90127
Máscara de segmentación SLIC	Simulación	0,93089	0,81321	0,86808
Detección de incidentes cercanos a accidentes (flujo espacial)	Simulación	0,90395	0,86022	0,88154
Simulación de detección de incidentes cercanos (flujo temporal)		0,83495	0,92473	0,84108
Detección de incidentes cercanos (dos flujos)	Simulación	0,92105	0,94086	0,93085

El método de evaluación que utilizamos para la segmentación de instancias es bastante similar al de la de-
protección, con la excepción de que ahora calculamos IoU de máscaras en lugar de cuadros delimitadores.

Calculando la precisión, la exhaustividad y la puntuación F1 de las máscaras. Para evaluar nuestra colección de máscaras predichas, comparará cada una de nuestras máscaras predichas con cada una de las máscaras objetivo disponibles para una entrada determinada.

- Se observa un verdadero positivo cuando un par de máscaras de predicción-objetivo tiene una puntuación IoU que supera algún umbral predefinido (lo establecimos en 0,7).
- Un falso positivo indica que una máscara de objeto predicha no tenía un objeto de referencia asociado. mascarilla.
- Un falso negativo indica que una máscara de objeto de referencia no tenía ningún objeto predicho asociado. mascarilla.

4.5.4 Precisión, exhaustividad y puntuación F1. Dado que nuestro marco tiene tres tareas y nuestro conjunto de datos es bastante diferente de otros conjuntos de datos de detección de objetos, conjuntos de datos de seguimiento y conjuntos de datos de casi accidentes. como el conjunto de datos de accidentes de dashcam [Chan et al. 2016], es difícil comparar el rendimiento cuantitativo individual para las tres tareas con otros métodos. Una de nuestras motivaciones fue proponer una solución basada en visión para ITS; por lo tanto, nos centramos más en la detección de accidentes cercanos y presentamos Análisis cuantitativo de nuestras redes convolucionales de dos flujos. En la Tabla 2, presentamos evaluaciones cuantitativas de tres subtareas: detección de objetos; seguimiento de múltiples objetos (con y sin aprendizaje de métrica de coseno); segmentación SLIC (máscara vs. cuadro delimitador); y detección de casi accidentes (solo flujo espacial, solo flujo temporal y modelo de dos flujos). Para el video de sheye, Presentamos evaluaciones sobre detección de objetos y seguimiento de múltiples objetos. Los vídeos de simulación Estos videos tienen como objetivo el entrenamiento y las pruebas con más ejemplos de situaciones cercanas a accidentes, y contamos con 57 videos de simulación que suman más de 51.123 fotogramas. Seleccionamos de forma dispersa solo 1.087 fotogramas de ellos. para el procesamiento del entrenamiento. Presentamos el análisis de la detección de casi accidentes para 30 videos de prueba. (18 tuvieron un incidente casi fatal positivo; 12 tuvieron un incidente casi fatal negativo).

Cálculo de la precisión, la exhaustividad y la puntuación F1 de la detección de casi accidentes. Para evaluar nuestra predicción de En los cuasi accidentes, compararemos cada una de nuestras detecciones predichas con cada verdad fundamental para un caso dado. aporte.

- Se observa un verdadero positivo cuando un par de predicción-detección de objetivo tiene una puntuación IoU que supera un umbral predefinido (lo hemos fijado en 0,7).
- Un falso positivo indica que un casi accidente predicho no tenía un casi accidente real asociado. accidente.
- Un falso negativo indica que un casi accidente real no tuvo un accidente predicho asociado. detecciones.

Machine Translated by Google

5 TRABAJOS RELACIONADOS

5.1 Detección de objetos La

detección de objetos ha logrado mejoras notables en los últimos años, como se demuestra en competiciones populares de detección de objetos como el desafío de detección PASCAL VOC [Everingham et al. 2015, 2010], el desafío de detección a gran escala ILSVRC [Russakovsky et al. 2015] y el desafío de detección a gran escala MS COCO [Lin et al. 2014]. La detección de objetos tiene como objetivo generar instancias de objetos semánticos con una etiqueta de clase determinada, como "humanos" o "coche". Tiene amplias aplicaciones en muchas tareas de visión, incluyendo detección de peatones, detección de rostros, reconocimiento facial, cosegmentación de objetos de vídeo, recuperación de imágenes, seguimiento de objetos y videovigilancia. A diferencia de la clasificación de imágenes, la detección de objetos no tiene como objetivo clasificar la imagen completa. Se necesita información tanto de posición como de categoría de los objetos, lo que significa que tenemos que segmentar instancias de objetos del fondo y etiquetarlas con posición y clase. Las entradas son imágenes o fotogramas de vídeo, mientras que las salidas son listas donde cada elemento representa la posición y la categoría de los objetos candidatos. En general, la detección de objetos busca extraer características distintivas para ayudar a diferenciar las clases.

Los métodos para la detección de objetos generalmente se dividen en tres categorías: (1) enfoques tradicionales basados en aprendizaje automático; (2) enfoques de aprendizaje profundo basados en propuestas de regiones; y (3) enfoques de aprendizaje profundo de extremo a extremo. Para los enfoques tradicionales basados en aprendizaje automático, uno de los pasos importantes es el diseño de características. Se han propuesto muchos métodos para diseñar primero las características [Dalal y Triggs 2005; Lowe 1999; Viola y Jones 2001, 2004] y aplicar técnicas como la máquina de vectores de soporte (SVM) [Hearst et al. 1998] para realizar la clasificación. Los pasos principales de los enfoques tradicionales basados en aprendizaje automático son:

- Selección de región: utilizando ventanas deslizantes de diferentes tamaños para seleccionar regiones candidatas. imágenes completas o fotogramas de vídeo
- Extracción de características: extraer características visuales de las regiones candidatas utilizando técnicas como la característica de Harr para la detección de rostros, la característica HOG para la detección de peatones o la detección general de objetos;
- Classier: entrena y prueba Classier utilizando técnicas como SVM.

Los enfoques tradicionales basados en aprendizaje automático tienen sus limitaciones. El método que utiliza ventanas deslizantes para seleccionar regiones de interés (ROI) aumenta el tiempo de cálculo debido a la redundancia de ventanas. Sin embargo, estas características diseñadas manualmente no son robustas, debido a la diversidad de objetos, deformaciones, condiciones de iluminación, fondo, etc., mientras que la selección de características tiene un gran impacto en el rendimiento de clasificación de las regiones candidatas.

Los recientes avances en aprendizaje profundo, especialmente en visión artificial, han demostrado que las CNN tienen una gran capacidad para representar objetos y ayudan a mejorar el rendimiento de numerosas tareas de visión, en comparación con las características heurísticas tradicionales [Dalal y Triggs 2005]. Para los enfoques basados en aprendizaje profundo, existen CNN para extraer características de propuestas de regiones o detección de objetos de extremo a extremo sin definir específicamente características de una clase determinada. Los enfoques de detección de objetos basados en aprendizaje profundo de buen rendimiento incluyen R-CNN [Girshick et al. 2014], Fast R-CNN [Girshick 2015], Faster R-CNN [Ren et al. 2015]), SSD [Liu et al. 2016a] y YOLO [Redmon et al. 2016].

Por lo general, adoptamos métodos de propuesta de región (Categoría 2) para producir propuestas de múltiples objetos y luego aplicamos un clasificador robusto para refinar aún más las propuestas generadas; esto se conoce como un método de dos etapas. El primer ejemplo de un enfoque de aprendizaje profundo basado en propuestas de región fue R-CNN [Girshick et al. 2014]. El flujo principal de R-CNN [Girshick et al. 2014] es (1) recopilar imágenes de entrada, (2) generar una cantidad de propuestas de región (por ejemplo, 2000), (3) extraer características de CNN y (4) clasificar regiones usando SVM. Por lo general, adopta búsqueda selectiva (SS), uno de los métodos de vanguardia.

Machine Translated by Google

Métodos de propuesta de objetos [Uijlings et al. 2013], que se aplican en numerosas tareas de detección en varios sistemas fascinantes [Girshick 2015; Girshick et al. 2014; Ren et al. 2015] para extraer estas regiones de una imagen y designar propuestas de región. En lugar de intentar clasificar todas las propuestas posibles, R-CNN selecciona un conjunto fijo de propuestas (por ejemplo, 2000) para trabajar con ellas. El algoritmo de búsqueda selectiva utilizado para generar estas propuestas de región incluye (1) generar una subsegmentación inicial, generar muchas regiones candidatas, (2) usar un algoritmo voraz para combinar recursivamente regiones similares en otras más grandes, y (3) usar las regiones generadas para producir las propuestas de región candidatas finales.

Estas propuestas de regiones candidatas se transforman en un cuadrado y se introducen en una CNN, que actúa como extractor de características. La capa densa resultante consta de las características extraídas, que se introducen en una SVM [Hearst et al. 1998] para clasificar la presencia del objeto dentro de dicha propuesta de región candidata. El principal problema de R-CNN [Girshick et al. 2014] radica en su limitada velocidad de inferencia, debido al gran tiempo que se invierte en extraer las características de cada propuesta de región individual. Esto impide su aplicación en sistemas que requieren rendimiento en tiempo real (como el análisis de vídeo en línea). Posteriormente, se propuso Fast R-CNN [Girshick 2015] para mejorar la velocidad, evitando la introducción de propuestas de región sin procesar en cada iteración. En su lugar, la operación de convolución se realiza una sola vez por imagen, generando regiones de interés (RoI) sobre el mapa de características. Faster-R-CNN [Ren et al. 2015] aprovecha aún más las características convolucionales compartidas para extraer las propuestas de región utilizadas por el detector. Compartir las características convolucionales permite una velocidad considerablemente mayor en el sistema de detección de objetos.

El tercer tipo es el enfoque de aprendizaje profundo de extremo a extremo, que no requiere propuestas de región (también conocido como método de una etapa). Los trabajos pioneros son SSD [Liu et al. 2016a] y YOLO [Redmon et al. 2016]. Un detector SSD [Liu et al. 2016a] funciona añadiendo una secuencia de mapas de características con resolución espacial progresivamente decreciente para reemplazar la segunda etapa de clasificación del método de dos etapas, lo que permite un cálculo rápido y una detección multiescala en una sola entrada.
El detector YOLO es un algoritmo de detección de objetos muy diferente de los algoritmos basados en regiones.
En YOLO [Redmon et al. 2016], la detección de objetos se considera un problema de regresión de extremo a extremo y utiliza una única red neuronal convolucional para predecir los cuadros delimitadores y las probabilidades de clase correspondientes. Primero, toma la imagen y la divide en una cuadrícula S × S; dentro de cada celda de la cuadrícula, toma m cuadros delimitadores. Para cada cuadro delimitador con múltiples escalas, la red neuronal convolucional genera una probabilidad de clase y valores de oset para el cuadro delimitador. Luego, selecciona los cuadros delimitadores que tienen una probabilidad de clase superior a un valor umbral y los utiliza para localizar el objeto dentro de la imagen. YOLO [Redmon et al. 2016] es órdenes de magnitud más rápido (45 fotogramas por segundo) que otros enfoques de detección de objetos, pero la limitación es que tiene dificultades con objetos pequeños dentro de la imagen.

5.2 Seguimiento de objetos múltiples El

seguimiento de objetos en vídeo intenta localizar objetos en fotogramas sucesivos y tiene diversas aplicaciones importantes en robótica, videovigilancia y comprensión de escenas de vídeo. Según el número de objetos en movimiento que se deseen rastrear, existen el problema del seguimiento de un solo objeto (SOT) y el del seguimiento de múltiples objetos (MOT). Además de detectar objetos en el fotograma de vídeo, la solución MOT requiere una asociación robusta de los múltiples objetos detectados entre fotogramas para obtener un seguimiento consistente, y esta asociación de datos sigue siendo un gran desafío. En las tareas MOT, para cada fotograma de un vídeo, el objetivo es localizar e identificar todos los objetos de interés, de modo que sus identidades sean consistentes a lo largo del vídeo. Normalmente, los principales desafíos son la velocidad, la asociación de datos, los cambios de apariencia, las oclusiones, la desaparición y reaparición de objetos, etc. En la práctica, es deseable que el seguimiento se realice en tiempo real, a la misma velocidad que la del fotograma del vídeo. Además, resulta complicado proporcionar un etiquetado coherente de los objetos detectados en escenarios complejos, como cuando los objetos cambian de apariencia, desaparecen o presentan oclusiones severas.

Machine Translated by Google

Los enfoques MOT se pueden categorizar según sus diferentes modelos. Una distinción basada en el método de inicialización es la del seguimiento basado en detección (DBT) frente al seguimiento sin detección (DFT). En DBT, la detección de objetos se realiza en los fotogramas de vídeo antes del seguimiento. Los métodos DBT implican dos tareas distintas: detección de objetos y seguimiento de objetos. En este artículo, nos centramos en DBT (también conocido como seguimiento por detección en MOT). Esto se debe a que los métodos DBT se utilizan ampliamente debido a su excelente rendimiento con detectores de objetos basados en aprendizaje profundo, mientras que los métodos DFT requieren anotaciones manuales de los objetivos, lo que podría generar malos resultados si aparece un objeto nuevo y no visto previamente. Otra distinción importante basada en el modo de procesamiento es la de los modelos en línea frente a los modelos en línea. Un modelo en línea recibe la entrada de vídeo fotograma a fotograma y proporciona una salida por fotograma. Esto significa que solo se puede utilizar la información de los fotogramas anteriores y del fotograma actual. Los modelos en línea tienen acceso a todo el vídeo, lo que significa que se puede utilizar la información de los fotogramas anteriores y futuros.

Los métodos de seguimiento por detección se utilizan habitualmente en modelos de seguimiento en línea. Un proceso sencillo y clásico consiste en: (1) detectar objetos de interés, (2) predecir nuevas ubicaciones de los objetos a partir de fotogramas anteriores y (3) asociar objetos entre fotogramas según la similitud entre las ubicaciones detectadas y las predichas. Las arquitecturas CNN de alto rendimiento, como Faster R-CNN [Ren et al. 2015], YOLO [Redmon et al. 2016] y SSD [Liu et al. 2016a], pueden utilizarse para la detección de objetos. Para la predicción de nuevas ubicaciones de objetos rastreados, los enfoques modelan la velocidad de los objetos y predicen sus posiciones en fotogramas futuros utilizando flujo óptico, redes neuronales recurrentes o filtros de Kalman. La tarea de asociación consiste en determinar si una detección está asociada con un objeto detectado previamente o con un objeto nuevo.

Un conjunto de datos popular para MOT es MOTChallenge [Leal-Taixé et al. 2015]. En MOTChallenge [Leal-Taixé et al. 2015], se proporcionan detecciones para cada fotograma en el conjunto de datos y se mide la capacidad de seguimiento, en lugar de la calidad de detección. Las secuencias de vídeo están etiquetadas con cuadros delimitadores para cada peatón, recopilados de múltiples fuentes. Esto motiva el uso del paradigma de seguimiento por detección. MDP [Xiang et al. 2015] es un método de seguimiento por detección que logró un rendimiento de vanguardia en el Benchmark MOTChallenge [Leal-Taixé et al. 2015] cuando se propuso. Las principales contribuciones pueden ser resolver MOT aprendiendo una política MDP aprovechando tanto el aprendizaje fuera de línea como el aprendizaje en línea para la asociación de datos. SORT [Bewley et al. [2016] es un método MOT simple y en tiempo real, que solo aplica métodos de seguimiento clásicos para lograr un rendimiento de vanguardia. Es el método MOT en línea en tiempo real más utilizado y es muy eficiente para aplicaciones en tiempo real en la práctica. En el MOTChallenge [Leal-Taixé et al. 2015], SORT [Bewley et al. 2016] logra un mejor rendimiento que MHT [Kim et al. 2015] en detecciones estándar al combinarse con un detector de personas de alto rendimiento. DeepSort [Wojke et al. 2017] es una extensión de SORT [Bewley et al. 2016] que mejora aún más el rendimiento.

5.3 Detección de incidentes cercanos a un accidente

Además de la detección y el seguimiento de vehículos, el análisis de la interacción y el comportamiento de los vehículos desempeña un papel importante en el modelado de trazas [Hermes et al. 2009; Sivaraman et al. 2011; Wiest et al. [2012]. La detección de cuasi accidentes es uno de los niveles más altos de interpretación semántica para caracterizar las interacciones de los vehículos en la carretera. La tarea básica de la detección de cuasi accidentes es localizar las zonas cercanas a un accidente e informarlas en los fotogramas de vídeo. Para detectar cuasi accidentes en escenas de tráfico, son requisitos previos una detección y un seguimiento robustos de los vehículos.

La mayoría de los métodos de detección de casi accidentes se basan en señales de movimiento y trayectorias. Las señales de movimiento más típicas son el flujo óptico y la trayectoria. El flujo óptico se utiliza ampliamente en tareas de procesamiento de vídeo, como la segmentación de vídeo [Huang et al. 2018]. En los últimos años, los investigadores han trabajado en la predicción del movimiento de vehículos a largo plazo. Basándonos en algoritmos de seguimiento como el filtrado de Kalman, podemos estimar el estado futuro del movimiento del vehículo. El movimiento del vehículo se puede estimar para un período más largo.

Machine Translated by Google

duración con enfoques de modelado de trayectorias [Hermes et al. 2009; Sivaraman et al. 2011; Wiest et al. 2012]. Las trayectorias típicas de autopista se modelan usando agrupamiento y se clasifican a través de modelado oculto de Markov en Sivaraman et al. [2011]. En Hermes et al. [2009], se utiliza la subsecuencia común más larga basada en invariante de rotación para medir la similitud entre trayectorias. Wiest et al. [2012] clasifican y predicen trayectorias de vehículos a largo plazo aplicando modelado de mezcla gaussiana variacional.

Se han aplicado enfoques como árboles de decisión, filtros de Kalman o análisis de series temporales en la detección de accidentes de tráfico o casi accidentes [Bhonsle et al. 2000; Jiansheng et al. 2014; Shuming et al. 2002; Srinivasan et al. 2001, 2003; Xu et al. 1998]. La red neuronal se utiliza en Ohe et al. [1995] para detectar incidentes de tráfico. En Ikeda et al. [1999], los autores proponen un sistema para clasificar diferentes tipos de incidentes para la detección automática de incidentes. Kimachi et al. [1994] investigaron el comportamiento anormal de los vehículos relacionados con accidentes, basándose en los conceptos de la teoría difusa, donde la ocurrencia de accidentes está relacionada con la anormalidad del comportamiento de múltiples imágenes continuas. Zeng et al. [2008] integra SVM multiclase con fusión de datos de la teoría de la evidencia DS. Sadeky et al. [2010] presenta un método en tiempo real utilizando trayectoria e histograma de gradiente de flujo (HFG). Kamijo et al. [2000] desarrolla un sistema de reconocimiento de eventos basado en el modelo oculto de Markov (HMM), que es robusto para el monitoreo de tráfico y la detección de accidentes. Chen et al. [2010] propusieron un método basado en SVM para la medición del flujo de la vía. Un enfoque similar que utiliza BP-ANN para la detección de accidentes se ha propuesto en Ghosh-Dastidar y Adeli [2003] y Srinivasan et al. [2004]. La interacción del usuario de la carretera se analiza utilizando un marco probabilístico refinado, donde las probabilidades de colisión se estiman identificando puntos de colisión potenciales. También se han presentado otros métodos para la detección de accidentes de vía utilizando aproximación matricial [Xia et al. 2015], flujo óptico y transformación de características invariantes a la escala (SIFT) [Chen et al. 2016], hidrodinámica de partículas suavizadas (SPH) [Ullah et al. 2015] y modelado adaptativo del flujo de movimiento de la vía [Maaloul et al. 2017]. Con los avances en la detección de objetos con redes neuronales profundas, varios métodos automáticos de detección de accidentes de vía basados en CNN [Singh y Mohan 2018; Sultani et al. 2018] y métodos de anticipación de accidentes trac basados en redes neuronales recurrentes (RNN) [Chan et al. 2016; Suzuki et al. 2018] se han propuesto junto con conjuntos de datos de accidentes trac [Kataoka et al. 2018; Shah et al. 2018; Sultani et al. 2018; Suzuki et al. 2018] de videos de vigilancia o videos de dashcam [Chan et al. 2016]. Sin embargo, estos métodos no tienen rendimiento en tiempo real para la detección de accidentes en línea sin usar fotogramas futuros o dan resultados insatisfactorios. Además, ningún conjunto de datos propuesto contiene videos con vistas desde arriba como videos de drones o vehículos aéreos no tripulados (UAV) o videos de cámaras omnidireccionales para análisis trac.

6. CONCLUSIÓN

Hemos propuesto una arquitectura de red convolucional de dos flujos que realiza detección, seguimiento y detección de casi accidentes en tiempo real para vehículos en datos de vídeo de seguimiento. La red convolucional de dos flujos comprende una red de flujo espacial y una red de flujo temporal. La red de flujo espacial detecta vehículos individuales y regiones con alta probabilidad de casi accidente a nivel de fotograma único mediante la captura de características de apariencia con un método de detección de objetos de última generación. La red de flujo temporal aprovecha las características de movimiento de los candidatos detectados para realizar el seguimiento de múltiples objetos y genera trayectorias individuales de cada objetivo rastreado. Detectamos casi accidentes incorporando características de apariencia y de movimiento para calcular las probabilidades de las regiones candidatas a casi accidentes. Los experimentos han demostrado la ventaja de nuestro marco con un rendimiento general competitivo cualitativo y cuantitativo a altas velocidades de fotogramas. El trabajo futuro incluirá métodos de unión de imágenes que se implementarán en vídeos de múltiples cámaras

Machine Translated by Google

RECONOCIMIENTO

Los autores agradecen a la ciudad de Gainesville el acceso a los datos de vídeo de Sheye que se utilizaron en este artículo.

REFERENCIAS

Radhakrishna Achanta, Appu Shaji, Kevin Smith, Aurelien Lucchi, Pascal Fua y Sabine Süsstrunk. 2012. Superpíxeles SLIC comparados con métodos de superpíxeles de última generación. Traducción IEEE. Patrón Anal. Mach. Intel. 34, 11 (2012), 2274–2282.

Alejandro Angel, Mark Hickman, Pitu Mirchandani y Dmesh Chandnani. 2002. Métodos de recopilación de datos de seguimiento mediante vídeo aéreo. En Actas de la 5.ª Conferencia Internacional IEEE sobre Sistemas de Transporte Inteligentes. IEEE, 31-36.

Pablo Arbelaez, Michael Maire, Charless Fowlkes y Jitendra Malik. 2010. Detección de contornos e imagen jerárquica segmentación. IEEE Trans. Pattern Anal. Mach. Intell. 33, 5 (2010), 898–916.

Alex Bewley, Zongyuan Ge, Lionel Ott, Fabio Ramos y Ben Upcroft. 2016. Seguimiento sencillo en línea y en tiempo real. En Actas de la Conferencia Internacional de Procesamiento de Imágenes del IEEE (ICIP'16). IEEE, 3464–3468.

Shailendra Bhonsle, Mohan Trivedi y Amarnath Gupta. 2000. Arquitectura centrada en bases de datos para la detección, gestión y análisis de incidentes de tráfico. En Actas de la Conferencia IEEE sobre Sistemas de Transporte Inteligentes (ITSC'00). IEEE, 149-154.

Norbert Buch, Sergio A. Velastin y James Orwell. 2011. Una revisión de las técnicas de visión por computadora para el análisis de entornos urbanos. trac. IEEE Trans. Intell. Transport. Syst. 12, 3 (2011), 920–939.

Fu-Hsiang Chan, Yu-Ting Chen, Yu Xiang y Min Sun. 2016. Anticipación de accidentes en videos de cámaras de salpicadero. En Actas de La Conferencia Asiática sobre Visión por Computadora. Springer, 136–153.

Lairong Chen, Yuan Cao y Ronghua Ji. 2010. Algoritmo de detección automática de incidentes basado en máquinas de vectores de soporte. En Actas de la 6ª Conferencia Internacional sobre Computación Natural, Vol. 2. IEEE, 864–866.

Yu Chen, Yuanlong Yu y Ting Li. 2016. Un método de detección de accidentes de tráfico basado en visión artificial mediante aprendizaje extremo. En Actas de la Conferencia Internacional sobre Robótica y Mecatrónica Avanzadas (ICARM'16). IEEE, 567–572.

Benjamin Coifman, David Beymer, Philip McLauchlan y Jitendra Malik. 1998. Un sistema de visión por computadora en tiempo real para Seguimiento de vehículos y vigilancia de tráfico. Transport. Res. Part C: Emerg. Technol. 6, 4 (1998), 271–288.

Navneet Dalal y Bill Triggs. 2005. Histogramas de gradientes orientados para la detección humana. En Actas de la Conferencia IEEE sobre Visión por Computadora y Reconocimiento de Patrones, Vol. 1. IEEE, 886–893.

Mark Everingham, SM Ali Eslami, Luc Van Gool, Christopher KI Williams, John Winn y Andrew Zisserman. 2015. El desafío de las clases de objetos visuales de PASCAL: una retrospectiva. Int. J. Comput. Vision 111, 1 (2015), 98–136.

Mark Everingham, Luc Van Gool, Christopher KI Williams, John Winn y Andrew Zisserman. 2010. La imagen de PASCAL Desafío de las clases de objetos (VOC). Int. J. Comput. Vision 88, 2 (2010), 303–338.

Samanwoy Ghosh-Dastidar y Hojjat Adeli. 2003. Modelo de red neuronal de agrupación de ondas para la detección de incidentes en autopistas. Infraestructura Civil Asistida por Computadora. Eng. 18, 5 (2003), 325–338.

Ross Girshick. 2015. Fast R-CNN. En Actas de la Conferencia Internacional IEEE sobre Visión por Computadora. 1440–1448.

Ross Girshick, Je Donahue, Trevor Darrell y Jitendra Malik. 2014. Jerarquías de características enriquecidas para la detección precisa de objetos y la segmentación semántica. En Actas de la Conferencia IEEE sobre Visión por Computadora y Reconocimiento de Patrones. 580–587.

Ross Girshick, Je Donahue, Trevor Darrell y Jitendra Malik. 2016. Redes neuronales convolucionales basadas en regiones para una detección precisa. Detección y segmentación de objetos. IEEE Trans. Pattern Anal. Mach. Intell. 38, 1 (2016), 142–158.

Pan He, Weilin Huang, Tong He, Qile Zhu, Yu Qiao y Xiaolin Li. 2017. Detector de texto de un solo disparo con atención regional. En Actas de la Conferencia Internacional IEEE sobre Visión por Computadora. 3047–3055.

Pan He, Aotian Wu, Xiaohui Huang, Jerry Scott, Anand Rangarajan y Sanjay Ranka. 2019a. Características geométricas basadas en aprendizaje profundo para la selección y clasificación efectiva de camiones a partir de videos de autopistas. En Actas de la Conferencia Internacional IEEE sobre Sistemas de Transporte Inteligentes (ITSC'19). IEEE, 824–830.

Pan He, Aotian Wu, Anand Rangarajan y Sanjay Ranka. 2019b. Taxonomía y clasificación de camiones mediante tecnología de vídeo y pesaje en movimiento (WIM). Informe final. Informe técnico. Informe final de investigación preparado para: Departamento de Transporte de Florida.

Marti A. Hearst, Susan T. Dumais, Edgar Osuna, John Platt y Bernhard Scholkopf. 1998. Máquinas de vectores de soporte. IEEE Intell. Syst. Appl. 13, 4 (1998), 18–28.

Alexander Hermans, Lucas Beyer y Bastian Leibe. 2017. En defensa de la pérdida de tripletes para la reidentificación de personas. arXiv preimpresión arXiv:1703.07737.

Christoph Hermes, Christian Wohler, Konrad Schenk y Franz Kummert. 2009. Predicción del movimiento de vehículos a largo plazo. En Actas del Simposio de Vehículos Inteligentes del IEEE. IEEE, 652–657.

Stefan Hommes, Radu State, Andreas Zinnen y Thomas Engel. 2011. Detección de comportamiento anómalo en un entorno de vigilancia mediante gráficos de control. En Actas de la 8.ª Conferencia Internacional IEEE sobre Vigilancia Avanzada Basada en Vídeo y Señales (AVSS'11). IEEE, 113-118.

Neil Hoose. 1992. IMPACTOS: Una herramienta de análisis de imágenes para la vigilancia de autopistas. Trac Eng. Control 33, 3 (1992).

Machine Translated by Google

Xiaohui Huang, Chengliang Yang, Sanjay Ranka y Anand Rangarajan. 2018. Segmentación basada en supervóxeles de imágenes 3D con integración de flujo óptico para procesamiento espaciotemporal. IPSJ Trans. Comput. Vision Appl. 10, 1 (2018), 9.

Nacim Ihaddadene y Chabane Djeraba. 2008. Análisis del movimiento de multitudes en tiempo real. En Actas de la 19ª Conferencia Internacional Conferencia sobre Reconocimiento de Patrones. IEEE, 1–4.

Hiromi Ikeda, Yukihiro Kaneko, Toshihiro Matsuo y Kunihiko Tsuji. 1999. Sistema de detección de incidentes anómalos mediante tecnología de procesamiento de imágenes. En Actas de la Conferencia Internacional IEEE/IEEJ/JSAI sobre Sistemas de Transporte Inteligentes. IEEE, 748–752.

Sergey Ioe y Christian Szegedy. 2015. Normalización por lotes: Aceleración del entrenamiento de redes neuronales profundas mediante la reducción de la variabilidad interna. Cambio de covariable. Preimpresión de arXiv arXiv:1502.03167.

Stewart Jackson, Luis F. Miranda-Moreno, Paul St-Aubin y Nicolas Saunier. 2013. Sistema de cámara de video móvil y flexible y software de análisis de video de código abierto para seguridad vial y análisis del comportamiento. Transport. Res. Rec. 2365, 1 (2013), 90–98.

Varun Jampani, Deqing Sun, Ming-Yu Liu, Ming-Hsuan Yang y Jan Kautz. 2018. Redes de muestreo de superpíxeles. En Actas de la Conferencia Europea sobre Visión por Computadora (ECCV'18). 352–368.

Fan Jiang, Ying Wu y Aggelos K. Katsaggelos. 2007. Detección de eventos anómalos en vídeo de vigilancia mediante agrupamiento jerárquico dinámico. En Actas de la Conferencia Internacional IEEE sobre Procesamiento de Imágenes, vol. 5. IEEE, V–145.

Fu Jiansheng et al. 2014. Detección de accidentes de tráfico en tiempo real basada en visión. En Actas del 11.º Congreso Mundial sobre Control Inteligente y Automatización. IEEE, 1035–1038.

Jean-Philippe Jodoin, Guillaume-Alexandre Bilodeau y Nicolas Saunier. 2014. Urban tracker: Seguimiento de múltiples objetos en entornos urbanos mixtos. En Actas de la Conferencia de Invierno del IEEE sobre Aplicaciones de la Visión por Computadora. IEEE, 885–892.

Rudolph Emil Kalman. 1960. Un nuevo enfoque para problemas de filtrado y predicción lineal. J. Basic Eng. 82, 1 (1960), 35–45.

Shunsuke Kamijo, Yasuyuki Matsushita, Katsushi Ikeuchi y Masao Sakauchi. 2000. Vigilancia de tráfico y accidentes. Detección en intersecciones. IEEE Trans. Intell. Transport. Syst. 1, 2 (2000), 108–118.

Asim Karim y Hojjat Adeli. 2002. Algoritmo de detección de incidentes utilizando la representación de energía wavelet de patrones de trazas. J. Transporte. Ing. 128, 3 (2002), 232–242.

Hirokatsu Kataoka, Teppei Suzuki, Shoko Oikawa, Yasuhiro Matsui y Yutaka Satoh. 2018. Impulsar el análisis de vídeo para el Detección de incidentes de casi colisión en el sistema de seguimiento de accidentes. Preimpresión de arXiv arXiv:1804.02555.

Chanho Kim, Fuxin Li, Arridhana Ciptadi y James M. Rehg. 2015. Seguimiento de hipótesis múltiples revisado. En Actas de la Conferencia Internacional IEEE sobre Visión por Computadora. 4696–4704.

Masatoshi Kimachi, Kenji Kanayama y Kenbu Teramoto. 1994. Predicción de incidentes mediante análisis de secuencias de imágenes difusas. En Actas de la Conferencia sobre Sistemas de Información y Navegación de Vehículos (VNIS'94). IEEE, 51–56.

Dieter Koller, Kostas Daniilidis y Hans-Hellmut Nagel. 1993. Seguimiento de objetos basado en modelos en secuencias de imágenes monoculares de escenas de tráfico vial. Int. J. Comput. 10, 3 (1993), 257–281.

Alex Krizhevsky, Georey Hinton y otros. 2009. Aprendizaje de múltiples capas de características a partir de imágenes pequeñas. Informe técnico. Universidad de Toronto.

Harold W. Kuhn. 1955. El método húngaro para el problema de asignación. Naval Res. Logist. Quart. 2, 1-2 (1955), 83–97.

Laura Leal-Taixé, Anton Milan, Ian Reid, Stefan Roth y Konrad Schindler. 2015. MOTChallenge 2015: Hacia un banco- Marca para seguimiento de múltiples objetivos. Preimpresión de arXiv arXiv:1504.01942.

Tsung-Yi Lin, Michael Maire, Serge Belongie, James Hays, Pietro Perona, Deva Ramanan, Piotr Dollár y C. Lawrence Zitnick. 2014. Microsoft COCO: Objetos comunes en contexto. En Actas de la Conferencia Europea sobre Visión por Computadora. Springer, 740–755.

Chang Liu, Guijin Wang, Wenxin Ning, Xinggang Lin, Liang Li y Zhou Liu. 2010. Detección de anomalías en vídeo de vigilancia utilizando estadísticas de dirección de movimiento. En Actas de la Conferencia Internacional IEEE sobre Procesamiento de Imágenes. IEEE, 717–720.

Wei Liu, Dragomir Anguelov, Dumitru Erhan, Christian Szegedy, Scott Reed, Cheng-Yang Fu y Alexander C. Berg. 2016a. SSD: Detector multibox de una sola pasada. En Actas de la Conferencia Europea sobre Visión por Computadora. Springer, 21–37.

Xinchen Liu, Wu Liu, Huadong Ma y Huiyuan Fu. 2016b. Reidentificación de vehículos a gran escala en vídeos de vigilancia urbana. En Actas de la Conferencia Internacional IEEE sobre Multimedia y Exposición (ICME'16). IEEE, 1–6.

David G. Lowe. 1999. Reconocimiento de objetos a partir de características locales invariantes a la escala. En Actas de la 7.ª Conferencia Internacional IEEE sobre Visión por Computadora, vol. 2. IEEE, 1150–1157.

Wenhan Luo, Junliang Xing, Anton Milan, Xiaoqin Zhang, Wei Liu, Xiaowei Zhao y Tae-Kyun Kim. 2014. Objeto múltiple Seguimiento: Una revisión de la literatura. Preimpresión de arXiv arXiv:1409.7618.

Boutheina Maaloul, Abdelmalik Taleb-Ahmed, Smail Niar, Naim Harb y Carlos Valderrama. 2017. Algoritmo adaptativo basado en vídeo para la detección de accidentes en autopistas. En Actas del 12.º Simposio Internacional IEEE sobre Sistemas Integrados Industriales (SIES'17). IEEE, 1–6.

Philip McLauchlan, David Beymer, Benn Coifman y Jitendra Malik. 1997. Un sistema de visión artificial en tiempo real para la medición de parámetros de trazado. En Actas de la Conferencia de la Sociedad de Computación del IEEE sobre Visión Artificial y Reconocimiento de Patrones. IEEE, 495–501.

Machine Translated by Google

Iwao Ohe, Hironao Kawashima, Masahiro Kojima y Yukihiro Kaneko. 1995. Un método para la detección automática de incidentes de tráfico mediante redes neuronales. En Actas de la 6.ª Conferencia Internacional Pacific Rim TransTech: Sistemas de Navegación e Información para Vehículos (VNIS'95). IEEE, 231-235.

Joseph Redmon, Santosh Divvala, Ross Girshick y Ali Farhadi. 2016. Solo miras una vez: Unificado, de objetos en tiempo real-protección. En Actas de la Conferencia IEEE sobre Visión por Computadora y Reconocimiento de Patrones. 779–788.

Joseph Redmon y Ali Farhadi. 2017. YOLO9000: Mejor, más rápido, más fuerte. En Actas de la Conferencia IEEE sobre Computación. Visión y reconocimiento de patrones. 7263–7271.

Shaoqing Ren, Kaiming He, Ross Girshick y Jian Sun. 2015. Faster R-CNN: Hacia la detección de objetos en tiempo real con Redes de propuestas de regiones. En Avances en sistemas de procesamiento de información neuronal. MIT Press, 91–99.

Oren Rippel, Manohar Paluri, Piotr Dollar y Lubomir Bourdev. 2015. Aprendizaje métrico con discriminación de densidad adaptativa. Preimpresión de arXiv arXiv:1511.05939.

Olga Russakovsky, Jia Deng, Hao Su, Jonathan Krause, Sanjeev Satheesh, Sean Ma, Zhiheng Huang, Andrej Karpathy, Aditya Khosla, Michael Bernstein et al. 2015. Desafío de reconocimiento visual a gran escala de Imagenet. Int. J. Computación. Visión 115, 3 (2015), 211–252.

Samy Sadeky, Ayoub Al-Hamadiy, Bernd Michaelisy y Usama Sayed. 2010. Reconocimiento automático de accidentes de tráfico en tiempo real mediante HFG. En Actas de la 20.ª Conferencia Internacional sobre Reconocimiento de Patrones. IEEE, 3348–3351.

Tim Salimans y Durk P. Kingma. 2016. Normalización de peso: una reparametrización simple para acelerar el entrenamiento de movimientos profundos. Redes neuronales. En Avances en sistemas de procesamiento de información neuronal. MIT Press, 901–909.

Giuseppe Salvo, Luigi Caruso, Alessandro Scordo, Giuseppe Guido y Alessandro Vitale. 2017. Adquisición de datos de seguimiento. mediante vehículo aéreo no tripulado. Eur. J. Remote Sens. 50, 1 (2017), 343–351.

G. Scotti, L. Marcenaro, C. Coelho, F. Selvaggi y C.S. Regazzoni. 2005. Sensor inteligente de doble cámara para alta definición. Vigilancia de 360 grados. IEE Proc.-Vision Image Signal Process. 152, 2 (2005), 250–257.

Ankit Shah, Jean Baptiste Lamare, Tuan Nguyen Anh y Alexander Hauptmann. 2018. Predicción de accidentes en vídeos de cámaras de vigilancia CCTV. Preimpresión de arXiv: arXiv:1809.05782.

Tang Shuming, Gong Xiaoyan y Wang Feiyue. 2002. Algoritmo de detección de incidentes de Trac basado en regresión sin parámetros. En Actas de la 5.ª Conferencia Internacional IEEE sobre Sistemas de Transporte Inteligentes. IEEE, 714–719.

Dinesh Singh y Chalavadi Krishna Mohan. 2018. Representación espacio-temporal profunda para la detección de accidentes de tráfico. utilizando un autoencoder apilado. IEEE Trans. Intell. Transport. Syst. 20, 3 (2018), 879–887.

Sayanan Sivaraman, Brendan Morris y Mohan Trivedi. 2011. Aprendizaje de trayectorias de varios carriles mediante visión basada en vehículos. En Actas de los Talleres de la Conferencia Internacional IEEE sobre Visión por Computadora (ICCV'11). IEEE, 2070–2076.

Dipti Srinivasan, Ruey Long Cheu y Young Peng Poh. 2001. Técnica híbrida de lógica difusa y algoritmo genético para la detección automatizada de incidentes de tráfico en autopistas. En Actas de la Conferencia de Sistemas de Transporte Inteligentes del IEEE (ITSC'01). IEEE, 352–357.

Dipti Srinivasan, Xin Jin y Ruey Long Cheu. 2004. Evaluación de modelos de redes neuronales adaptativas para incidentes en autopistas. detección. IEEE Trans. Intell. Transport. Syst. 5, 1 (2004), 1–11.

Dipti Srinivasan, Wee Hoon Loo y Ruey Long Cheu. 2003. Detección de incidentes en Trac mediante optimización por enjambre de partículas. En Actas del Simposio de Inteligencia de Enjambre del IEEE (SIS'03). IEEE, 144–151.

Waqas Sultani, Chen Chen y Mubarak Shah. 2018. Detección de anomalías en el mundo real en videos de vigilancia. Centro para Investigación en Visión por Computadora, Universidad de Florida Central (2018).

Tomoyuki Suzuki, Hirokatsu Kataoka, Yoshimitsu Aoki y Yutaka Satoh. 2018. Anticipación de accidentes de tráfico con adaptativo pérdida y base de datos de incidentes a gran escala. Preimpresión de arXiv arXiv:1804.02675.

Shuming Tang y Haijun Gao. 2005. Algoritmo de detección de incidentes de tráfico basado en regresión no paramétrica. IEEE Trans. Sistemas de Transporte Inteligentes 6, 1 (2005), 38–42.

Zhi Tian, Weilin Huang, Tong He, Pan He y Yu Qiao. 2016. Detección de texto en imágenes naturales con texto conexionista. Red de propuestas. En Actas de la Conferencia Europea sobre Visión por Computadora. Springer, 56–72.

Jasper RR Uijlings, Koen EA Van De Sande, Theo Gevers y Arnold WM Smeulders. 2013. Búsqueda selectiva de reconocimiento de objetos. Int. J. Computación. Visión 104, 2 (2013), 154–171.

Habib Ullah, Mohib Ullah, Hina Afridi, Nicola Conci y Francesco GB De Natale. 2015. Detección de accidentes de tráfico mediante una lente hidrodinámica. En Actas de la Conferencia Internacional IEEE sobre Procesamiento de Imágenes (ICIP). IEEE, 2470–2474.

Maria Valera y Sergio A. Velastin. 2005. Sistemas de vigilancia distribuidos inteligentes: una revisión. IEE Proc.-Vision Image Signal Process. 152, 2 (2005), 192–204.

Harini Veeraraghavan, Osama Masoud y Nikolaos P. Papanikolopoulos. 2003. Algoritmos de visión por computadora para intersec-monitoreo de ción. IEEE Trans. Intell. Transport. Syst. 4, 2 (2003), 78–89.

Paul Viola y Michael Jones. 2001. Detección rápida de objetos mediante una cascada potenciada de características simples. En Actas de la Conferencia IEEE sobre Visión por Computadora y Reconocimiento de Patrones, Vol. 1. IEEE, 3.

Paul Viola y Michael J. Jones. 2004. Detección robusta de rostros en tiempo real. Int. J. Comput. Vision 57, 2 (2004), 137–154.

Machine Translated by Google

Lijun Wang y Ming Dong. 2012. Detección en tiempo real de comportamiento anómalo en multitudes mediante un método de aproximación matricial. En Actas de la 19.ª Conferencia Internacional IEEE sobre Procesamiento de Imágenes. IEEE, 2701–2704.

Ming-Liang Wang, Chi-Chang Huang y Huei-Yung Lin. 2006. Un sistema de vigilancia inteligente basado en un sensor de visión omnidireccional. En Actas de la Conferencia IEEE sobre Cibernética y Sistemas Inteligentes. IEEE, 1–6.

Shu Wang y Zhenjiang Miao. 2010. Detección de anomalías en escenas con multitudes. En Actas de la 10ª Conferencia Internacional del IEEE. Actas de la Conferencia sobre Procesamiento de Señales. IEEE, 1220–1223.

Kilian Q. Weinberger y Lawrence K. Saul. 2009. Aprendizaje de métricas de distancia para la clasificación del vecino más cercano con margen amplio. J. Mach. Learn. Res. 10, febrero (2009), 207–244.

Jürgen Wiest, Matthias Höken, Ulrich Kreßel y Klaus Dietmayer. 2012. Predicción probabilística de trayectorias con modelos de mezcla gaussiana. En Actas del Simposio IEEE sobre Vehículos Inteligentes. IEEE, 141–146.

Nicolai Wojke y Alex Bewley. 2018. Aprendizaje profundo de métrica de coseno para la reidentificación de personas. En Actas del IEEE Conferencia de Invierno sobre Aplicaciones de Visión por Computadora (WACV'18). IEEE, 748–756.

Nicolai Wojke, Alex Bewley y Dietrich Paulus. 2017. Seguimiento sencillo en línea y en tiempo real con una métrica de asociación profunda. En Actas de la Conferencia Internacional de Procesamiento de Imágenes del IEEE (ICIP'17). IEEE, 3645–3649.

Siyu Xia, Jian Xiong, Ying Liu y Gang Li. 2015. Detección de accidentes de tráfico basada en visión mediante aproximación matricial. En Actas de la 10.ª Conferencia Asiática de Control (ASCC'15). IEEE, 1–5.

Yu Xiang, Alexandre Alahi y Silvio Savarese. 2015. Aprender a rastrear: Seguimiento en línea de múltiples objetos mediante la toma de decisiones. En Actas de la Conferencia Internacional IEEE sobre Visión por Computadora. 4705–4713.

Hongli Xu, CM Kwan, L. Haynes y JD Pryor. 1998. Detección adaptativa en tiempo real de incidentes en línea. Conjuntos difusos y Sistemas 93, 2 (1998), 173–183.

Yupeng Yan, Xiaohui Huang, Anand Rangarajan y Sanjay Ranka. 2018. Etiquetado denso de imágenes satelitales a gran escala con redes generativas antagónicas. En Actas de la 16.ª Conferencia Internacional IEEE sobre Computación Confiable, Autónoma y Segura, 16.ª Conferencia Internacional sobre Inteligencia y Computación Ubicuas, 4.ª Conferencia Internacional sobre Inteligencia y Computación de Big Data y Congreso de Ciencia y Tecnología Cibernética (DASC/PiCom/DataCom/CyberSciTech'18). IEEE, 927–934.

Liu Yu, Lei Yu, Jianquan Wang, Yi Qi y Huimin Wen. 2008. Red neuronal de retropropagación para la detección de incidentes de tráfico basada en la fusión de datos de detectores de bucle y vehículos de sondeo. En Actas de la 4.ª Conferencia Internacional sobre Computación Natural, vol. 3. IEEE, 116-120.

Dehuai Zeng, Jianmin Xu y Gang Xu. 2008. Fusión de datos para la detección de incidentes de rastreo utilizando la teoría de la evidencia DS con Máquinas de vectores de soporte probabilísticas. J. Comput. 3, 10 (2008), 36–43.

Recibido en diciembre de 2018; revisado en junio de 2019; aceptado en noviembre de 2019.