Machine Translated by Google

Computers, Materials & Continua

Prensa de Ciencias Tecnológicas

DOI: 10.32604/cmc.2024.050865

ARTÍCULO

Detección de comportamiento anómalo de vehículos basada en bloques densos y umbralización suave.

Yuanyao Lu1,*, weichen2 , Zhanhe Yu1Jingxuan Wang1 y Chaochao Yang2

[1]Facultad de Ciencias y Tecnologías de la Información, Universidad Tecnológica del Norte de China, Pekín, 100144, China

[2]Facultad de Ingeniería Eléctrica y de Control, Universidad Tecnológica del Norte de China, Pekín, 100144, China

*Autor correspondiente: Yuanyao Lu. Correo electrónico: luyy@ncut.edu.cn

Recibido: 20 de febrero de 2024 Aceptado: 8 de mayo de 2024 Publicado: 20 de junio de 2024

ABSTRACTO

Con el rápido avance de las economías sociales, los sistemas de transporte inteligentes están captando cada vez más atención. Un aspecto central de estos sistemas es la detección de comportamientos vehiculares anómalos, lo cual sigue siendo un desafío crítico debido a la complejidad de las vías urbanas y la variabilidad de las condiciones externas. La investigación actual sobre la detección de comportamientos de tráfico anómalos aún se encuentra en sus inicios, con un margen significativo de mejora en la precisión del reconocimiento. Para abordar este problema, esta investigación ha desarrollado un nuevo modelo para el reconocimiento de comportamientos de tráfico anómalos. Este modelo emplea la red R3D como su arquitectura central, incorporando un bloque denso para facilitar la reutilización de características. Este enfoque no solo mejora el rendimiento con menos parámetros y menores demandas computacionales, sino que también permite la adquisición de nuevas características al tiempo que simplifica la estructura general de la red. Además, esta investigación integra un método auto-atentivo que se ajusta dinámicamente a las condiciones de tráfico predominantes, optimizando la relevancia de las características para la tarea en cuestión. Para el análisis temporal, se utiliza una capa Bi-LSTM para extraer y aprender de los matices de los datos basados en el tiempo. Esta investigación realizó una serie de experimentos comparativos utilizando el conjunto de datos UCF-Crime, logrando una notable precisión del 89,30 % en nuestro conjunto de prueba. Nuestros resultados demuestran que nuestro modelo no solo opera con menos parámetros, sino que también alcanza una precisión de reconocimiento superior en comparación con modelos anteriores.

PALABRAS CLAVE

Comportamiento anómalo del vehículo; aprendizaje profundo; ResNet; bloque denso; umbralización suave

1 Introducción

Con el rápido desarrollo de la economía nacional y el rápido aumento de la propiedad de automóviles en el país, los vehículos no solo facilitan los desplazamientos, sino que también conllevan numerosos riesgos para la seguridad. Una gestión eficaz del sistema de tráfico es fundamental para garantizar tanto la seguridad como la eficiencia del transporte. En los últimos años, el rápido avance de la inteligencia artificial en diversos sectores ha impulsado a los investigadores a explorar métodos basados en IA para la gestión de sistemas de tráfico. El Sistema Inteligente de Transporte (ITS) [1–3] es una medida importante de gestión del tráfico, que puede integrar eficazmente el procesamiento avanzado de visión artificial y la tecnología de comunicación en todo el sistema de gestión del tráfico. Este sistema de gestión integrado permite la monitorización y gestión integral, en tiempo real, precisa y eficiente de varios tipos de vehículos, y también puede predecir el

Esta obra está bajo una licencia Creative Commons Atribución 4.0 Internacional, que permite su uso, distribución y reproducción sin restricciones en cualquier medio, siempre que se cite correctamente la obra original.

Machine Translated by Google

trayectorias futuras de los participantes del tráfico basadas en datos reales [4]. Como tecnología importante de gestión del tráfico, la detección de comportamiento anómalo de los vehículos es una parte indispensable del sistema de transporte inteligente. Por un lado, la tecnología de reconocimiento de comportamiento anómalo de los vehículos puede reducir la presión sobre el personal de gestión del tráfico y disminuir el desperdicio de recursos humanos. Por otro lado, puede mejorar la eficiencia, la precisión y la puntualidad de la monitorización del tráfico.

La detección de comportamiento anómalo de vehículos [5,6], un subconjunto de la detección de incidentes de tráfico, identifica incidentes como infracciones de tráfico y accidentes. Actualmente, los métodos de detección de comportamiento anómalo de vehículos se basan principalmente en el reconocimiento de vídeo. Estos métodos [7,8] utilizan cámaras para capturar datos de vídeo en tiempo real del tráfico, que luego se analizan mediante procesamiento de vídeo e imágenes para detectar el flujo de tráfico o para rastrear e identificar objetivos. El método de detección de vehículos basado en el procesamiento de imágenes de vídeo ofrece un amplio rango de detección y abundante información. El sistema de detección en sí solo necesita una cámara, un procesador y otras unidades básicas; el equipo de hardware es simple, fácil de instalar y mantener, rentable, duradero y fácil de actualizar. Por lo tanto, la detección del flujo de tráfico basada en imágenes de vídeo se ha convertido en un foco de investigación a nivel mundial.

Debido a la complejidad del tráfico urbano, los algoritmos avanzados de detección del comportamiento vehicular se aplican principalmente a autopistas y autovías. Sin embargo, la mayoría de los accidentes de tráfico ocurren en vías urbanas, donde el entorno es más propenso a eventos anómalos, lo que puede tener graves consecuencias.
Por lo tanto, la detección rápida y precisa de comportamientos vehiculares anómalos en vías urbanas es fundamental para salvar vidas, reducir pérdidas materiales, aliviar la congestión y proporcionar alertas oportunas. Para abordar estos desafíos, diseñamos un nuevo modelo de reconocimiento de comportamiento vehicular anómalo. Las principales contribuciones de este artículo se resumen a continuación:

1. Utilizamos R3D como red base para la extracción de características espaciales y mejoramos la precisión del modelo mediante el aprendizaje completo de las características espacio-temporales 3D dentro de los fotogramas de vídeo de entrada.
2. Mediante experimentos, encontramos un método de extracción de características espaciales más adecuado para la detección de comportamientos anómalos en vídeos de vigilancia. Empleamos bloques densos para extraer características espaciales de los vídeos. Esto permite que la red aproveche al máximo las características existentes y aprenda otras nuevas sin necesidad de cálculos adicionales. A continuación, filtramos el ruido mediante umbrales suaves y pasamos las características extraídas a la siguiente etapa de la red. Los umbrales suaves se adaptan según las condiciones de tráfico actuales, lo que mejora la flexibilidad de la red.

3. Utilizamos Bi-LSTM para recibir las características espaciales extraídas de la capa superior y, a partir de ellas, extraer información temporal. El entrenamiento de Bi-LSTM mejora aún más la capacidad de reconocimiento de la red y la tasa de precisión del reconocimiento, y finalmente proporciona el resultado del reconocimiento.

4. El resto del artículo se describe a continuación. El Capítulo 2 presenta los métodos de investigación existentes, basados en métodos tradicionales y aprendizaje profundo. También se señalan las limitaciones y las posibles mejoras de estos métodos. El Capítulo 3 describe los principios de las redes, los algoritmos y las técnicas utilizadas en este artículo. En el Capítulo 4, se presenta el conjunto de datos utilizado en este trabajo y se comparan y analizan todos los experimentos.

2 Trabajos relacionados

La detección de comportamientos anómalos en vehículos se puede clasificar, a grandes rasgos, en métodos indirectos y directos.
Entre ellos, el método indirecto consiste en utilizar el sensor terrestre [9,10] para obtener cambios en los parámetros del tráfico e identificar indirectamente los eventos de tráfico mediante métodos como el reconocimiento de patrones o el análisis estadístico. Este tipo de método es más adecuado para eventos de congestión de tráfico con alto flujo de tráfico. Sin embargo, debido a la influencia de la ubicación de instalación del detector, es débil en el

Machine Translated by Google

El método indirecto permite reconocer comportamientos anómalos de los vehículos en otros lugares, como estacionamiento ilegal, exceso de velocidad, marcha atrás y otras conductas específicas. Por lo tanto, no satisface las diversas aplicaciones de reconocimiento de eventos de tráfico que se producen en las vías urbanas.

El método de identificación directa de eventos de comportamiento anómalo de vehículos mediante tecnología de procesamiento de imágenes de video se denomina método directo. Con el desarrollo del procesamiento de imágenes, el reconocimiento de patrones y la inteligencia artificial, los métodos de reconocimiento de comportamiento anómalo de vehículos basados en el procesamiento de imágenes [11–13] pueden adquirir información de imágenes de la escena vial a través de sensores visuales. La tecnología de procesamiento de imágenes por computadora y la tecnología de reconocimiento de patrones se utilizan para analizar las imágenes recopiladas para su procesamiento en tiempo real y extraer información de tráfico. Esta información se transmite a los clientes, como el centro de control de tráfico, a través del sistema de transmisión de red mediante máquinas de señalización. Esto proporciona información completa y en tiempo real sobre el estado del tráfico para la gestión y el control del tráfico urbano.

El método directo basado en el procesamiento de imágenes presenta ventajas como una gran intuición, un buen rendimiento en tiempo real y una alta fiabilidad en comparación con el método indirecto. Además, permite detectar una amplia gama de eventos, ofrece una gran variedad de eventos reconocibles y presenta repetibilidad y reproducibilidad. Por consiguiente, ha recibido gran atención por parte de investigadores nacionales e internacionales.

Wang et al. combinaron el análisis de series temporales (TSA) con una máquina de vectores de soporte (SVM) [14–16] en 2013. El componente de series temporales predice los volúmenes de tráfico, y el componente SVM detecta eventos basándose en los volúmenes de tráfico en tiempo real, los volúmenes de tráfico normales predichos y la diferencia entre ambos. Los resultados muestran que este algoritmo tiene una alta tasa de detección, pero también una alta tasa de falsas alarmas, y la estructura de la red neuronal es demasiado grande, lo que requiere un gran espacio de almacenamiento y un largo tiempo de cálculo. En 2019, Li et al. propusieron un modelo de detección de eventos basado en GAN-RF-SVM [17] en condiciones de muestra pequeña. Se generan nuevas muestras de eventos utilizando una red generativa antagónica (GAN) y se seleccionan variables utilizando un algoritmo de bosque aleatorio (RF). Finalmente, se utiliza SVM como modelo de detección de eventos. Esto resuelve los problemas de tamaño de muestra pequeño, tamaño de muestra desequilibrado y rendimiento deficiente en tiempo real en los sistemas de detección de accidentes, y reduce la tasa de falsas alarmas en la detección de accidentes de tráfico. El principal inconveniente de este algoritmo es que la portabilidad es baja y el rendimiento de la prueba de detección en diferentes secciones de carretera se reduce significativamente. En la detección de vídeos de tráfico, la detección de objetos pequeños siempre ha sido uno de los desafíos clave en la detección de vehículos. Li et al. [18] propusieron una novedosa red de detección multiescala basada en un criterio de segmentación diferencial, que mejora significativamente la tasa de detección de objetos pequeños en comparación con los métodos tradicionales. La implementación de métodos indirectos y directos requiere la recopilación de datos por parte de los detectores. Para abordar el problema de la escasa adaptabilidad de los detectores modernos a entornos de tráfico complejos reales, Zhang et al. [19] introdujeron un método de Enfoque de Adaptación de Dominio de Grueso a Fino Inducido por Categoría (C2FDA) que mejora significativamente la adaptabilidad de los detectores en dominios nuevos y no vistos.

La investigación basada en el análisis de series temporales de alta dimensión y la detección de anomalías [20] representa un avance reciente en la identificación de comportamientos de tráfico anómalos. Este estudio propone un método para abordar el desafío de garantizar la fiabilidad de los sistemas vehiculares ante la creciente complejidad de los vehículos modernos. Al combinar una red de memoria a largo y corto plazo multicapa (LSTM) con una arquitectura de autoencoder (ML-LSTMAE), el enfoque analiza con precisión el funcionamiento de diversos subsistemas vehiculares mediante el entrenamiento de un esquema de codificación-decodificación utilizando datos de series temporales multivariadas. Además, el método emplea una máquina de vectores de soporte de una clase (OCSVM) para analizar los errores de reconstrucción y establecer un límite de soporte que permita diferenciar entre estados normales y anómalos. La validación con datos reales de vehículos y datos de orientación de la NASA confirma la alta precisión y eficacia del enfoque propuesto.

Machine Translated by Google

3 Método propuesto 3.1
Bloqueo DRN

Basándonos en experimentos previos sobre aprendizaje profundo, podemos concluir que la precisión de reconocimiento de la red está relacionada con el número de capas. Generalmente, las redes más profundas tienden a tener un mejor rendimiento debido a su mayor capacidad de aprendizaje. Sin embargo, las redes excesivamente profundas son propensas al problema del gradiente evanescente, donde los gradientes disminuyen a medida que se propagan hacia atrás a través de las capas durante el entrenamiento. Este problema puede detener la actualización de los parámetros de la red, lo que conlleva una disminución en la precisión de reconocimiento. Para solucionar este problema, introdujimos el bloque residual [21,22], como se muestra en la Fig. 1.

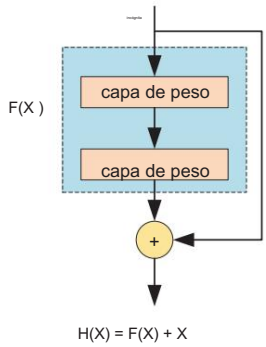


Figura 1: Bloque residual

H(X) = F(X) + X es la función objetivo del bloque residual. Cuando la red presenta un gradiente evanescente, F(X) tiende a cero y la función objetivo puede aproximarse como H(X) = X. Esto permite una correspondencia constante entre la salida de la red y X, manteniendo la red inalterada y evitando su degradación. Dado que la derivada de X es igual a 1, la derivada de H(X) siempre es mayor o igual que 1 durante la retropropagación de los parámetros de la red. Esto evita la aparición de un gradiente evanescente y permite actualizar los parámetros de la red.

Las redes residuales profundas tradicionales requieren un gran número de capas convolucionales para producir buenos resultados de reconocimiento. Sin embargo, a medida que aumenta el número de capas convolucionales, la red sufre de un número excesivo de parámetros y altos costos computacionales, lo que incrementa considerablemente el tiempo de entrenamiento. Además, las redes residuales tradicionales utilizan una convolución 2D. Esta solo puede extraer características espaciales en la imagen, pero no características temporales en el video. Para que la red comprenda mejor la información del video, también necesitamos que extraiga las características temporales. Para resolver este problema, este artículo utiliza una red R3D en lugar de la convolución 2D e incorpora bloques densos [23,24]. La red Dense-R3D (DRN) se muestra en la Fig. 2.

Como se muestra en la figura, hemos añadido un bloque denso al bloque residual. Dejamos que cada grupo de mapas de características converja en la dimensión del canal antes de que entren en la capa de convolución. Esto logra la reutilización de características y permite que la red utilice un número menor de características para lograr mejores resultados de reconocimiento. En la convergencia de mapas de características, utilizamos la concatenación en la dimensión del canal en lugar de la suma. Y estos nuevos mapas de características son necesarios para que el modelo aprenda nuevas características, no podemos descartarlos. Por lo tanto, aunque cada capa convolucional solo genera un número muy pequeño de nuevos mapas de características, el modelo sigue produciendo un gran número de parámetros a medida que aumenta el número de capas en la red. Y debido a que para que los mapas de características estén conectados en la dimensión del canal, necesitamos asegurarnos de que los mapas de características sean del mismo tamaño. No podemos utilizar la convolución arbitrariamente.

Machine Translated by Google

y agrupamiento para cambiar el tamaño de los mapas de características, por lo que usamos capas de cuello de botella al final del modelo para cambiar uniformemente el tamaño de los mapas de características. Como la red reutiliza el mismo mapa de características varias veces, esto hace que la red sea propensa al sobreajuste durante el entrenamiento. Por lo tanto, usamos Dropout para hacer que algunos parámetros se desactiven aleatoriamente durante el proceso de entrenamiento. Durante la fase de entrenamiento, ciertos parámetros se hacen dejar de funcionar con una cierta probabilidad durante la propagación hacia adelante del modelo, lo que puede evitar eficazmente el sobreajuste del modelo.

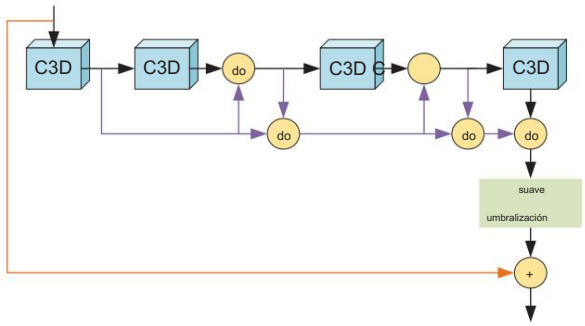


Figura 2: Bloqueo del DRN

Al clasificar muestras, inevitablemente habrá algo de ruido en ellas, y este ruido tiende a ser diferente entre muestras incluso para el mismo conjunto de datos. Por lo tanto, al final del bloque, también utilizamos el método de umbralización suave [25]. Al eliminar características con valores absolutos menores que un cierto umbral y comprimir características con valores absolutos mayores que ese umbral en la dirección de cero, como se muestra en la ecuación (1).

$$y = \begin{cases} x - \tau & x > \tau \\ 0 & -\tau \le x \le \tau \\ x + \tau & x < -\tau \end{cases} \tag{1}$$

Como se puede observar en la ecuación, las derivadas de los umbrales suaves son 0 y 1. Por lo tanto, el uso de este método evita el desvanecimiento del gradiente y la explosión del gradiente que ocurren en los algoritmos de aprendizaje profundo.

Para evitar que la función de umbral suave genere valores cero o distintos de cero, es necesario establecer todos los umbrales en valores positivos, y estos valores no deben ser demasiado grandes. Asimismo, para garantizar la portabilidad del modelo, los umbrales deben ser adaptativos. Cada muestra debe tener un valor de umbral independiente, que depende de su contenido de ruido, y este valor debe ser diferente para cada una.
Por ejemplo, la muestra A contiene menos ruido, mientras que la muestra B contiene más ruido en el mismo conjunto de datos. Por lo tanto, al aplicar un umbral suave, se debe usar un umbral mayor para la muestra A y uno menor para la muestra B. El proceso de implementación específico se muestra en la Figura 3.

Primero, tomamos el valor absoluto del mapa de características de entrada, de modo que se garantiza que el mapa de características tenga todos valores positivos. Registramos el nuevo mapa de características resultante como A. A continuación, enviamos A a una pequeña red completamente conectada cuya capa de salida es una función sigmoide. Usando una pequeña cantidad de cálculos, la salida se normaliza a un número entre 0 y 1. Registramos este coeficiente como α. α × A es el umbral final. Usando este método, se garantiza que el umbral sea positivo y no demasiado grande en valor. Dado que el umbral para cada muestra se calcula a partir de su mapa de características, diferentes muestras tienen diferentes umbrales. Esto le da al modelo un alto grado de auto-adaptabilidad. Este algoritmo puede entenderse como un tipo especial de mecanismo de atención. Detecta características que no son relevantes para la

Machine Translated by Google

tarea actual y las elimina mediante umbralización suave. Al mismo tiempo, se detectan las características relevantes para la tarea actual y se adaptan adecuadamente.

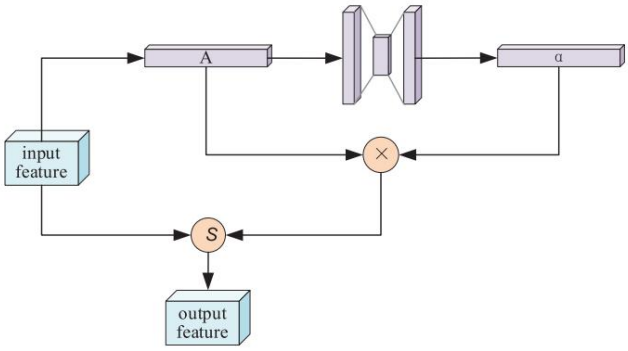


Figura 3: Método de umbralización suave

3.2 LSTM

La red de memoria a corto y largo plazo (LSTM) [26–28] es una red neuronal recurrente eficiente que permite extraer mejor la información de las características temporales. Para extraer mejor las características temporales a largas distancias, agregamos la salida del bloque DRN a la LSTM. Una de las unidades LSTM se muestra en la Fig. 4. El mapa de características de entrada se reescribe en una dimensión. Para conservar las características importantes, introducimos todas las características directamente en la LSTM para su extracción.

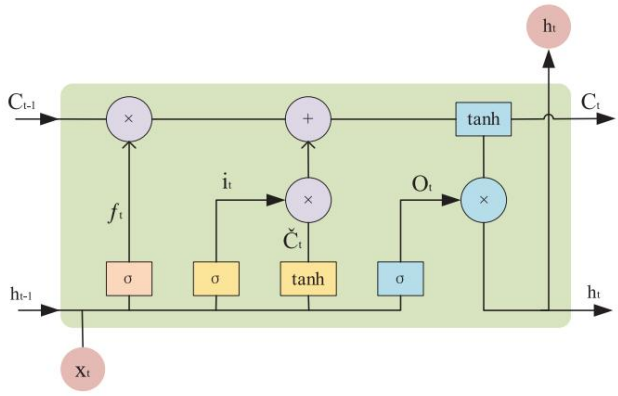


Figura 4: Una unidad de LSTM

La red LSTM consta de tres pasos: olvidar parte del estado anterior, actualizar la celda de memoria y generar el estado actual. El primer paso en la red LSTM consiste en decidir qué información debemos olvidar. Este proceso se realiza mediante una puerta de olvido. Esta puerta lee la información de ht−1 y xt y genera un valor entre 0 y 1 para cada dato en el estado de la celda Ct−1. 1 significa retención completa y 0 significa descarte completo, como se muestra en la ecuación (2).

$$ft = \sigma(Wf \times [ht-1, xt] + bf) \quad (2)$$

El siguiente paso es determinar la información que necesitamos actualizar. σ determina el estado que queremos que para actualizar, y luego tanh crea un nuevo vector de valores candidatos. $C\hat{}_t$ se agregue al estado y nosotros

Machine Translated by Google

utilice estas dos piezas de información para implementar la actualización de estado como se muestra en las ecuaciones (3) y (4).

$$es = \sigma (Wi \cdot [ht-1,xt] + b) \quad (3)$$

$$^{DO}_{t} = \tanh(WC \cdot [ht-1,xt] + bC) \quad (4)$$

Luego, Ct−1 se actualiza a Ct. Multiplicamos el estado anterior por ft y descartamos la información que tenemos. previamente identificado como necesita ser descartado. Luego, agréguelo × Cˆ $_{t}$ para formar un nuevo valor candidato. Y actualizado de acuerdo con el valor candidato calculado, como se muestra en la ecuación (5).

$$Ct = ft \times Ct-1 + it \times \hat{C}_{t} \quad (5)$$

Finalmente, la salida del estado de la célula está determinada por σ. Procesamos los estados de la célula con tanh y Multiplícalos por la salida de σ. La salida obtenida se muestra en las ecuaciones (6) y (7).

$$Ot = \sigma(WO\ [ht-1] + bO) \quad (6)$$

$$ht = Ot \times \tanh(Ct) \quad (7)$$

3.3 DRN + Bi-LSTM

La LSTM tradicional solo puede predecir la salida del siguiente momento basándose en la anterior. información de características. Sin embargo, en algunos problemas prácticos, el estado en el momento actual no es solo relacionado con el estado anterior pero también puede estar relacionado con el estado futuro. También necesitamos centrarnos en información después de que se haya producido la situación actual. Por lo tanto, construimos una red Bi-LSTM [29,30] , como se muestra en la Fig. 5, donde tanto A como A' denotan una celda LSTM.

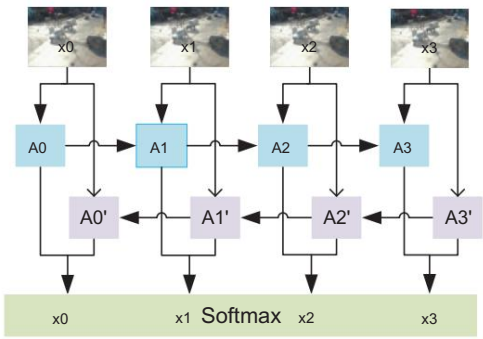


Figura 5: Red Bi-LSTM

La información de la imagen de entrada se somete a múltiples capas de convolución para producir una imagen unidimensional. vector de características, que luego se utiliza como entrada para la Bi-LSTM. La primera capa de la Bi-LSTM recibe las características extraídas del lado izquierdo, lo que permite al modelo comprender la situación actual por aprendiendo las características espaciotemporales previas. La segunda capa recibe las características extraídas de el lado derecho, lo que permite que el modelo determine los eventos actuales a partir de las condiciones futuras. La segunda capa es procesado de la misma manera que la primera capa pero en la dirección opuesta. Finalmente, los resultados obtenidos Se juzgan y analizan las dos capas.

La estructura general del modelo de red se muestra en la Fig. 6. Primero utilizamos convolución 3D y max operaciones de agrupación para transformar las imágenes de la secuencia de video de entrada en mapas de características que contienen información espaciotemporal y para cambiar el tamaño de los mapas de características de la secuencia. Luego, procesamos Los mapas de características de entrada utilizan múltiples módulos DRN, manejando la información espaciotemporal.

Machine Translated by Google

contenido en los mapas de características de entrada. Dado que la convolución 3D utilizada por DRN procesa principalmente información temporal a corto plazo, para mejorar aún más el procesamiento de la información temporal de la Para introducir y mejorar la capacidad del modelo para manejar información temporal a largo plazo, se utiliza Bi-LSTM. El modelo para extraer la información temporal de la secuencia de mapas de características de entrada. Al utilizar La estructura de doble capa de Bi-LSTM, la información temporal bidireccional en los mapas de características de entrada es Se extraen y se realiza un análisis exhaustivo de los dos resultados obtenidos. Finalmente, se realiza el reconocimiento. y la clasificación se lleva a cabo en función de la información de ponderación de características espaciotemporales procesadas, y se muestran los resultados del reconocimiento. La estructura específica de la red se muestra en la Tabla 1.

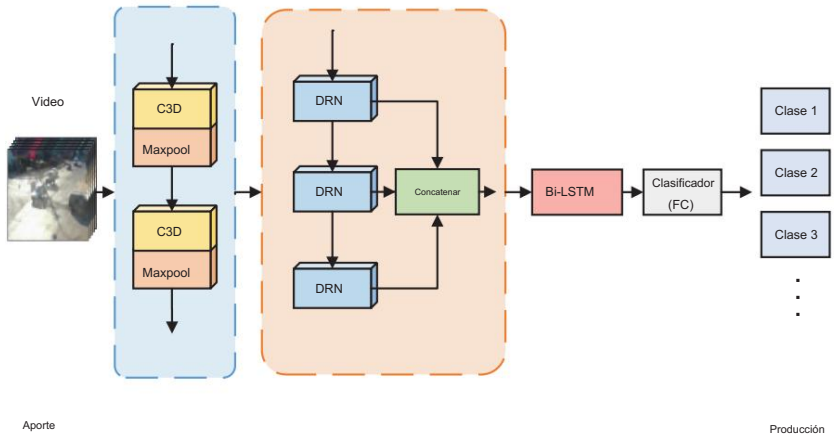


Figura 6: Modelo de red general

Tabla 1: Parámetros de la red general

Nombre de la capa	Tamaño de salida	Parámetros de red
C3D_1	112 × 112 × 8 × 64	3 × 3 × 3, 64
Maxpool_1	56 × 56 × 8 × 64	2 × 2 × 1, 64
C3D_2	56 × 56 × 8 × 96	3 × 3 × 3, 96
Maxpool_2	28 × 28 × 4 × 96	2 × 2 × 2, 96
DRN_1	28 × 28 × 4 × 96	3 × 3 × 3, 32 3 × 3 × 3, 32 3 × 3 × 3, 32 1 × 1 × 1, 96
DRN_2	14 × 14 × 2 × 96	3 × 3 × 3, 32 3 × 3 × 3, 32 3 × 3 × 3, 32 1 × 1 × 1, 96
DRN_3	7 × 7 × 1 × 96	3 × 3 × 3, 32 3 × 3 × 3, 32 3 × 3 × 3, 32 1 × 1 × 1, 96
Concatenar	7 × 7 × 1 × 384	-

Machine Translated by Google

4 Resultados experimentales

Utilizamos el gran conjunto de datos de comportamiento anormal UCF-Crime para entrenamiento y prueba, que contiene muchas categorías de videos de comportamiento anormal y una gran cantidad de videos normales. Los tipos de Los comportamientos anormales incluyen arresto, incendio provocado, robo, accidentes de tránsito, etc. Los datos específicos se muestran en Tabla 2. El conjunto de datos contiene un total de 1900 datos de vídeo de vigilancia. Todos los experimentos se llevaron a cabo En una CPU Intel Xeon y una GPU 2080Ti.

Tabla 2: Detalles del conjunto de datos UCF-Crimen

Categoría de comportamiento	Número de vídeos
Abuso	50
Detención	50
Incendio provocado	50
Agresión	50
Robo con fractura	100
Explosión	50
Lucha	50
Evento de videos normales	950
accidentes de tráfico	150
Robo	150
Tiroteo	50
Hurto	50
Robo	100
Vandalismo	50

El conjunto de datos UCF-Crime es un gran conjunto de datos de vídeo destinado a la investigación en detección de eventos anómalos. Este conjunto de datos contiene vídeos de vigilancia del mundo real, que cubren una amplia variedad de delitos y comportamientos anómalos, incluyendo diversas actividades vehiculares inusuales como la dispersión de carga, vehículos combustión, colisiones de vehículos, etc. En nuestro estudio, extraemos videos relacionados con colisiones vehiculares inusuales. comportamientos para crear un nuevo conjunto de datos de video, utilizando este nuevo conjunto de datos para realizar investigaciones sobre la detección de actividades vehiculares inusuales. Para evitar la influencia de la edición manual en los resultados del entrenamiento, Los videos del conjunto de datos se filtran para que todos los videos del conjunto de datos no estén editados. En este conjunto de datos, Hay 150 videos con comportamientos anormales de tráfico graves y 950 videos normales sin anomalías. comportamientos, como se muestra en la Fig. 7.

Para comparar nuestros modelos con otros modelos, construimos seis modelos y los comparamos. experimentalmente. Son R3D, R3D + LSTM, R3D + Bi-LSTM, DRN, DRN + LSTM y DRN + Bi-LSTM. La detección del comportamiento anormal del vehículo puede verse como un problema dicotómico, por lo que utilice la fórmula de precisión dicotómica como criterio de evaluación, como se muestra en la ecuación (8).

$$\text{Precisión} = \text{Tp} \frac{\text{Ciudad} + \text{Condado}}{+ \text{Tn} + \text{Fp} + \text{Fn}} \tag{8}$$

donde Tp es la muestra positiva que el modelo predice que será positiva, Tn es la muestra negativa. que el modelo predice que será negativo, Fp es la muestra negativa que se predice que será positiva. Según el modelo, Fn es la muestra positiva que el modelo predice que será negativa.

Machine Translated by Google



Figura 7: Muestreo de imágenes con el conjunto de datos

La precisión de nuestro modelo en los conjuntos de entrenamiento y validación se muestra en la Figura 8. En la figura, se observa que la precisión de reconocimiento aumenta gradualmente durante las primeras 15 épocas y luego tiende a estabilizarse. Además, después de 10 épocas, la diferencia de precisión entre los conjuntos de entrenamiento y validación no es significativa, lo que indica que nuestro modelo no parece estar sobreajustado y posee una buena capacidad de generalización.

Para comparar la precisión de reconocimiento de los diferentes modelos, utilizamos los seis modelos mencionados anteriormente para entrenarlos, validarlos y probarlos en el mismo entorno. El proceso de entrenamiento constó de 25 épocas, todas con una tasa de aprendizaje inicial de 0,01. La tasa de aprendizaje disminuyó en un factor de 10 después de cada 5 épocas. Cada época proporciona la precisión de reconocimiento actual, y los resultados experimentales se muestran en la Figura 9.

Los resultados experimentales finales se muestran en la Tabla 3. En ella, se observa que la precisión de reconocimiento del R3D en el conjunto de datos UCF-Crime no es alta, alcanzando solo el 65,73%. En contraste, la red neuronal recurrente (DRN) + Bi-LSTM presenta la mayor precisión de reconocimiento, con un 85,43%, en el mismo entorno. Además, en comparación con el R3D, la DRN tiene menos parámetros de modelo, menor tiempo de cálculo y mayor eficiencia.

Machine Translated by Google

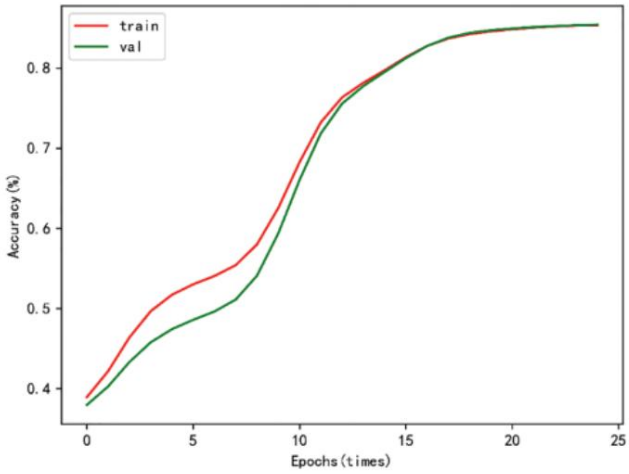


Figura 8: Precisión de DRN + Bi-LSTM en el conjunto de entrenamiento y el conjunto de validación.

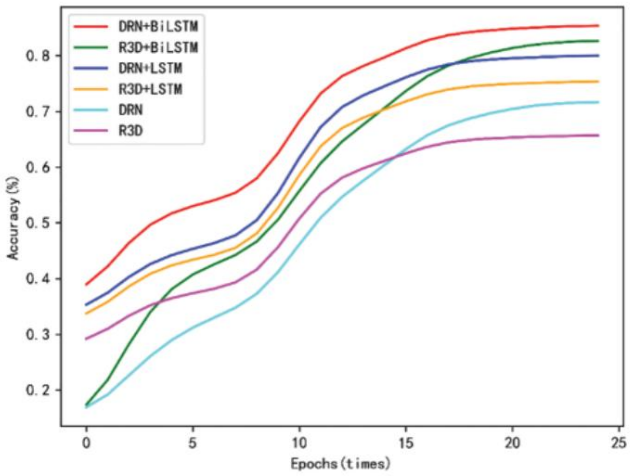


Figura 9: Precisión de cada modelo en el conjunto de prueba

Tabla 3: Resultados y parámetros de cada modelo

Modelos	Parámetros del modelo de precisión		Tiempo de cálculo
DRN + Bi-LSTM 85,43% R3D + Bi-		25,67 M	121 s
LSTM 82,73% DRN + LSTM 80,15%		37,51 M	181 s
R3D + LSTM DRN R3D		23,89 M	106 s
	75,50%	35,36 M	167 s
	71,75%	21,66 M	91 s
	65,73%	33,23 M	152 s

Machine Translated by Google

Para verificar el efecto del número de DRN en nuestro modelo, diseñamos una ablación Experimentar para ver el rendimiento del modelo aumentando o disminuyendo el número de DRN. módulos en el modelo. Los resultados se muestran en la Tabla 4. Se puede observar que a medida que aumenta el número de DRN A medida que aumentan los módulos en el modelo, la tasa de reconocimiento del modelo también aumenta. Sin embargo, puede Se observa que cuando el número de módulos DRN es mayor que 3, la precisión de reconocimiento del modelo aumenta. mejora en una medida limitada y el tiempo de cálculo aumenta significativamente. Por lo tanto, tomar teniendo en cuenta la consideración general y el equilibrio entre la precisión del reconocimiento y la capacidad computacional. Para mejorar la eficiencia del modelo, añadimos 3 módulos DRN al mismo.

Tabla 4: Impacto del número de DRN en el modelo

Número de DRN	Precisión	Tiempo de cálculo
0	64,51%	77 s
1	77,24%	años 90
2	81,81%	108 s
3	85,43%	121 s
4	85,67%	142 s
5	85,91%	171 s

Para evaluar más a fondo la precisión de los modelos anteriores en la detección de comportamiento anormal del vehículo, Se utilizaron por separado diferentes comportamientos anormales en el conjunto de datos para la comparación experimental. Las etiquetas de comportamiento aberrante en el conjunto de prueba incluyen arresto, incendio provocado, robo, accidentes de tráfico, robo, hurto en tiendas y vandalismo. Registramos la precisión de reconocimiento de cada modelo en diferentes conjuntos de datos. por separado, como se muestra en la Tabla 5. Como podemos ver en la tabla, ninguno de los seis modelos es adecuado para detectar Algunos comportamientos anormales, como arrestos y hurtos en tiendas, pero funcionan bien en la detección de accidentes de tráfico. Entre ellos, DRN + Bi-LSTM tiene el mejor resultado de reconocimiento con 89,30%. Esto sugiere que nuestro Este modelo es más adecuado para la identificación y detección de comportamientos anormales en los vehículos.

Tabla 5: Precisión de diferentes comportamientos anormales en cada modelo

Modelos	R3D	DRN	R3D + LSTM	DRN + LSTM	R3D + Bi-LSTM	DRN + Bi-LSTM
Detención	42,86%	45,62%	57,14%	57,10%	59,82%	59,71%
Incendio	63,29%	62,44%	67,54%	72,50%	67,75%	71,68%	72,43%
provocado	73,85%	74,50%	75,85%	78,32%	76,71%
Robo Accidentes de tráfico	73,58%	76,58%	83,92%	86,92%	85,65%	89,30%
Robo	69,81%	70,84%	71,43%	71,43%	72,84%	73,33%
Hurto	43,63%	42,68%	45,73%	75,71%	45,45%	52,86%	54,34%
Vandalismo	76,54%	77,14%	85,71%	86,42%	88,33%
Normal	65,75%	66,84%	75,91%	74,65%	85,49%	87,50%

Machine Translated by Google

Para evaluar el rendimiento de nuestros modelos (Dense Block y Soft Thresholding para la red de extracción de características local y Bi-LSTM para la red de extracción de características global), realizamos un experimento comparativo con redes de extracción de características de buena calidad (P3D, I3D y R(2 + 1)D) en el conjunto de prueba. El resultado experimental se muestra en la figura 10.

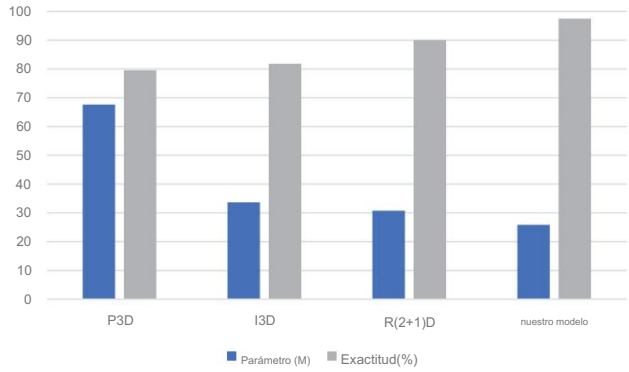


Figura 10: Comparación de la sobrecarga de parámetros y la precisión

5. Conclusión

En resumen, para la red propuesta en este artículo, primero utilizamos convolución 3D y agrupamiento máximo para reducir el tamaño del mapa de características, expandir el dominio perceptual y disminuir el número de parámetros. Luego, utilizamos bloques DRN para mejorar la utilización de características de la red y la eficiencia computacional. Esto facilita el entrenamiento de la red sin añadir cálculos adicionales. Para resolver el problema del sobreajuste, utilizamos Dropout y umbrales suaves para eliminar el ruido y ajustar las características necesarias. Finalmente, se utiliza Bi-LSTM para optimizar aún más la extracción de características temporales.
Los resultados experimentales demuestran que el modelo puede mejorar la precisión de reconocimiento del conjunto de datos UCF-crime. Este modelo es más adecuado para el reconocimiento de comportamientos anómalos de vehículos. La simulación de la aplicación real se muestra en la Fig. 11, donde "Frames" en el eje de coordenadas representa el número de fotogramas en un vídeo, y "Score" indica la puntuación de anomalía. Una puntuación de anomalía más alta indica una mayor probabilidad de comportamiento anómalo del vehículo en el fotograma actual. Como se puede observar en la figura, nuestro modelo puede detectar con precisión el momento en que se produce el comportamiento anómalo del vehículo. Si la anomalía persiste, el modelo continúa considerándola como tal. Solo cuando la anomalía desaparece, el modelo determina que la situación es normal en ese momento. El experimento demuestra que el modelo puede integrarse en el sistema inteligente de gestión del tráfico, mejorando la precisión, la puntualidad y la eficiencia de la monitorización del tráfico.

Machine Translated by Google

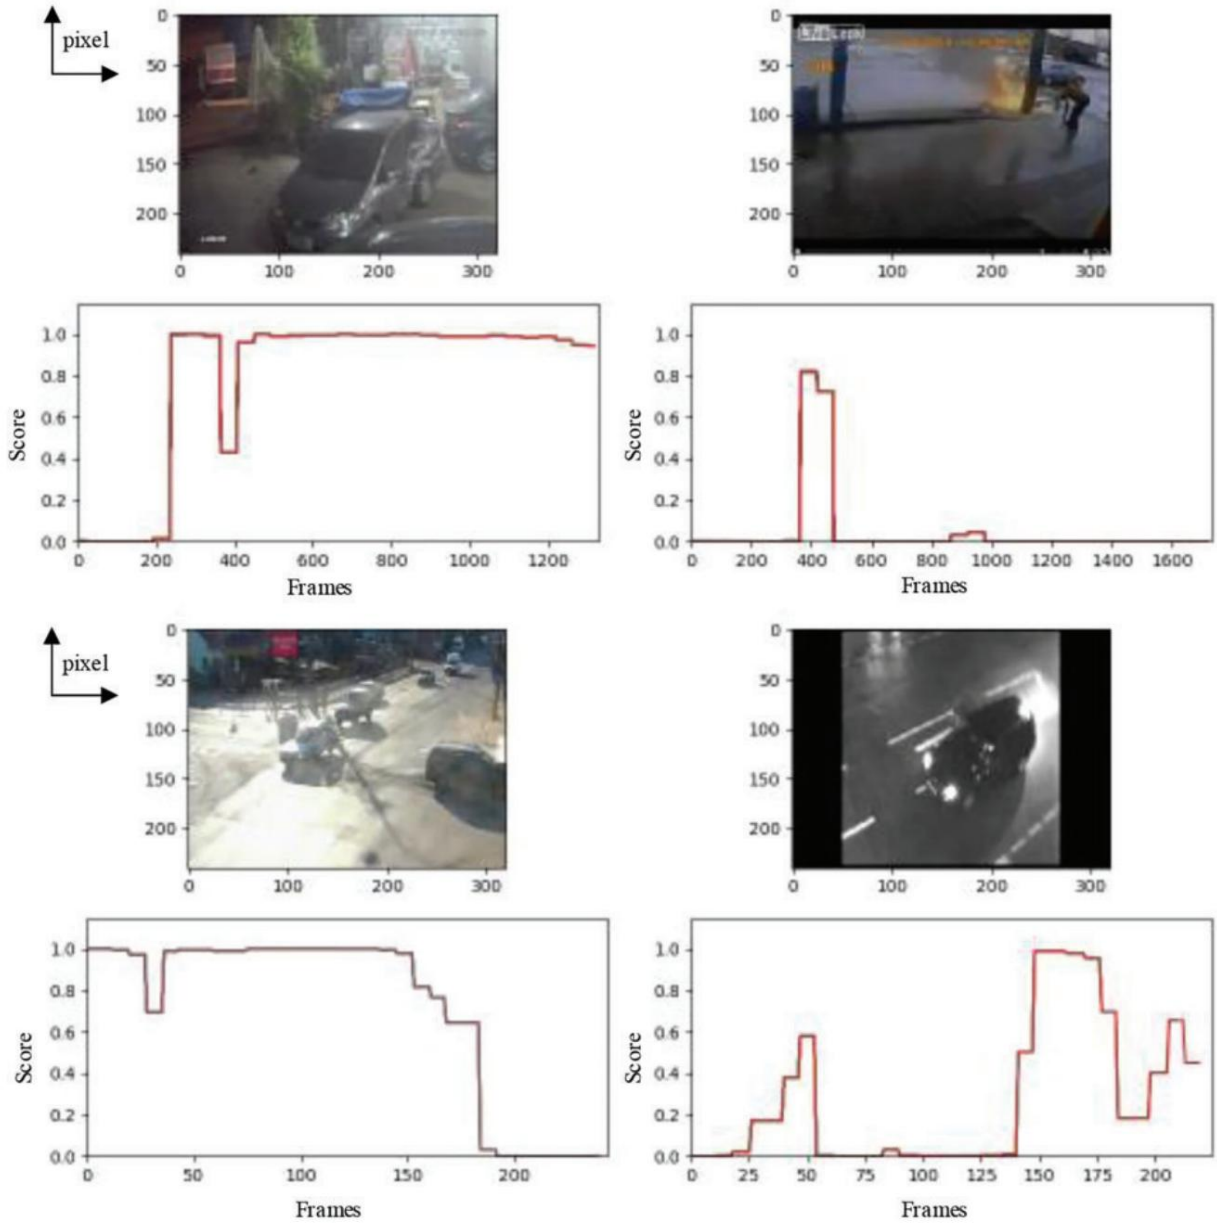


Figura 11: Simulación de aplicaciones

Agradecimientos: Los autores desean agradecer a la Fundación Nacional de Ciencias Naturales de China y a la Universidad Tecnológica del Norte de China por el valioso apoyo brindado a esta investigación. Asimismo, agradecen al editor, Ramey Jue, y a todos los revisores anónimos por sus sugerencias, que han contribuido a mejorar la calidad del manuscrito.

Declaración de financiación: Este trabajo fue financiado por la Fundación Nacional de Ciencias Naturales de China (61971007 y 61571013).

Machine Translated by Google

Contribuciones de los autores: Concepción y diseño del estudio: Wei Chen, Yuanyao Lu, Zhanhe Yu; recopilación de datos: Chaochao Yang; análisis e interpretación de los resultados: Zhanhe Yu, Jingxuan Wang; preparación del borrador del manuscrito: Zhanhe Yu, Chaochao Yang. Todos los autores revisaron los resultados y aprobaron la versión final del manuscrito.

Disponibilidad de datos y materiales: Los datos están disponibles previa solicitud a los autores.

Conflictos de intereses: Los autores declaran que no tienen ningún conflicto de intereses que declarar en relación con el presente estudio.

Referencias

[1] L. Zhu, FR Yu, Y. Wang, B. Ning y T. Tang, “Análisis de macrodatos en sistemas de transporte inteligentes: una revisión”, IEEE Trans. Intell. Transp. Syst., vol. 20, n.º 1, págs. 383–398, enero de 2019. doi: 10.1109/TITS.2018.2815678.

[2] M. Veres y M. Moussa, “Aprendizaje profundo para sistemas de transporte inteligentes: una revisión de las tendencias emergentes”, IEEE Trans. Intell. Transp. Syst., vol. 21, n.° 8, págs. 3152–3168, agosto de 2020. doi: 10.1109/TITS.2019.2929020.

[3] F. Zhu, Y. Lv, Y. Chen, X. Wang, G. Xiong y FY Wang, “Sistemas de transporte paralelos: Hacia un control y gestión del tráfico urbano inteligente habilitado por IoT”, IEEE Trans. Intell. Transp. Syst., vol. 21, n.º 10, págs. 4063–4071, octubre de 2020. doi: 10.1109/TITS.2019.2934991.

[4] Y. Ren, Z. Lan, L. Liu y H. Yu, “EMSIN: Red de interacción multi-flujo mejorada para la predicción de trayectorias de vehículos”, IEEE Trans. Fuzzy Syst., págs. 1–15, 2024. doi: 10.1109/TFUZZ.2024.3360946.

[5] W. Huang, X. Liu, M. Luo, P. Zhang, W. Wang y J. Wang, “Detección de comportamiento de conducción anormal basada en vídeo mediante fusiones de aprendizaje profundo”, IEEE Access, vol. 7, pp. 64571–64582, 2019. doi: 10.1109/AC-CESS.2019.2917213.

[6] J. Hu, L. Xu, X. He y W. Meng, “Detección de conducción anormal basada en el comportamiento de conducción normalizado”, IEEE Trans. Veh. Technol., vol. 66, no. 8, pp. 6645–6652, agosto de 2017. doi: 10.1109/TVT.2017.2660497.

[7] HF Sang, H. Wang y DY Wu, “Sistema de detección de comportamiento anormal de vehículos basado en video”, en Actas del Quinto Simposio Internacional de Diseño de Inteligencia Computacional de 2012, Hangzhou, China, 2012, págs. 132–135. doi: 10.1109/IS-CID.2012.41.

[8] J. Hu, X. Zhang y S. Maybank, “Detección de conducción anormal con datos de comportamiento de conducción normalizados: un enfoque de aprendizaje profundo”, IEEE Trans. Veh. Technol., vol. 69, n.º 7, págs. 6943–6951, julio de 2020. doi: 10.1109/TVT.2020.2993247.

[9] S. Liang et al., “Nervio auditivo de fibra óptica del suelo en el suburbio: para el monitoreo del flujo de tráfico”, IEEE Access, vol. 7, pp. 166704–166710, 2019. doi: 10.1109/ACCESS.2019.2952999.

[10] Z. Luo, MV Mohrenschildt y S. Habibi, “Un enfoque basado en cuadrículas de ocupación de probabilidad para la segmentación terrestre LiDAR en tiempo real”, IEEE Trans. Intell. Transp. Syst., vol. 21, n.° 3, págs. 998–1010, marzo de 2020. doi: 10.1109/TITS.2019.2900548.

[11] Y. Li et al., “Seguimiento de granularidad múltiple con componentes modularizados para la detección de anomalías en vehículos no supervisados”, en Proc. 2020 IEEE/CVF Conf. Comput. Vis. Pattern Recognit. Workshops (CVPRW), Seattle, WA, EE. UU., 2020, pp. 2501–2510. doi: 10.1109/CVPRW50498.2020.00301.

[12] Q. Hao y L. Qin, “El diseño de un sistema inteligente de procesamiento de vídeo de transporte en un entorno de big data”, IEEE Access, vol. 8, pp. 13769–13780, 2020. doi: 10.1109/ACCESS.2020.2964314.

[13] S. Wan, X. Xu, T. Wang y Z. Gu, “Un método inteligente de análisis de vídeo para la detección de eventos anormales en sistemas de transporte inteligentes”, IEEE Trans. Intell. Transp. Syst., vol. 22, n.º 7, págs. 4487–4495, julio de 2021. doi: 10.1109/TITS.2020.3017505.

[14] J. Wang, X. Li, SS Liao y Z. Hua, “Un enfoque híbrido para la detección automática de incidentes”, IEEE Trans. Intel. Transp. Sistema, vol. 14, núm. 3, págs. 1176–1185, septiembre de 2013. doi: 10.1109/TITS.2013.2255594.

Machine Translated by Google

[15] K. Zhang y MAP Taylor, “Detección eficaz de incidentes en carreteras arteriales: un algoritmo basado en redes bayesianas”, Transp Res. C, Emerg. Technol., vol. 14, n.º 6, págs. 403–417, dic. 2006. doi: 10.1016/j.trc.2006.11.001.

[16] Q. Liu, J. Lu, S. Chen y K. Zhao, “Conjunto de clasificadores Naïve Bayes múltiples para incidentes de tráfico detección”, Math. Problems Eng., vol. 2014, pp. 1–16, abril de 2014.

[17] L. Li, Y. Lin, B. Du, F. Yang y B. Ran, “Detección de incidentes de tráfico en tiempo real basada en un modelo híbrido de aprendizaje profundo”, Transportmetrica A, vol. 18, n.º 1, págs. 78–98, 2020. doi: 10.1080/23249935.2020.1813214.

[18] S. Li, J. Chen, W. Peng, X. Shi y W. Bu, “Un método de detección de vehículos basado en la segmentación de disparidad”, Multimed. Tools Appl., vol. 82, n.º 13, pp. 19643–19655, 2023. doi: 10.1007/s11042-023-14360-x.

[19] H. Zhang, G. Luo, J. Li y F. Wang, “C2FDA: Adaptación de dominio de lo grueso a lo fino para la detección de objetos de tráfico”, IEEE Trans. Intell. Transp. Syst., vol. 23, n.º 8, págs. 12633–12647, agosto de 2022. doi: 10.1109/TITS.2021.3115823.

[20] K. He, X. Zhang, S. Ren y J. Sun, “Aprendizaje residual profundo para el reconocimiento de imágenes”, en Proc. 2016 IEEE Conf. Comput. Vis. Pattern Recognit. (CVPR), Las Vegas, NV, EE. UU., 2016, pp. 770–778. doi: 10.1109/CVPR.2016.90.

[21] Y. Ibrahim et al., “Resiliencia a errores suaves de redes residuales profundas para el reconocimiento de objetos”, IEEE Access, vol. 8, pp. 19490–19503, 2020. doi: 10.1109/ACCESS.2020.2968129.

[22] G. Huang, Z. Liu, L. van der Maaten y KQ Weinberger, “Redes neuronales convolucionales densamente conectadas”, en Actas de la Conferencia IEEE de 2017 sobre Visión por Computación y Reconocimiento de Patrones (CVPR), Honolulu, HI, EE. UU., 2017, págs. 2261–2269. doi: 10.1109/CVPR.2017.243.

[23] T. Li, W. Jiao, LN Wang y G. Zhong, “Automatic DenseNet sparsification,” IEEE Access, vol. 8, págs. 62561–62571, 2020. doi: 10.1109/ACCESS.2020.2984130.

[24] S. Zhai, D. Shang, S. Wang y S. Dong, “DF-SSD: Un algoritmo mejorado de detección de objetos SSD basado en DenseNet y fusión de características”, IEEE Access, vol. 8, pp. 24344–24357, 2020. doi: 10.1109/AC-CESS.2020.2971026.

[25] L. Yuan, FEH Tay, P. Li y J. Feng, “Resumen de video no supervisado con redes LSTM adversarias consistentes en ciclos”, IEEE Trans. Multimed., vol. 22, n.° 10, págs. 2711–2722, octubre de 2020. doi: 10.1109/TMM.2019.2959451.

[26] E. Ahmadzadeh, H. Kim, O. Jeong, N. Kim e I. Moon, “Un modelo de red LSTM-GRU bidireccional profundo para la clasificación automatizada de texto cifrado”, IEEE Access, vol. 10, pp. 3228–3237, 2022. doi: 10.1109/ACCESS.2022.3140342.

[27] P. Limcharoen, N. Khamsemanan y C. Nattee, “Reconocimiento y reidentificación de la marcha basados en LSTM regional para caminatas de 2 segundos”, IEEE Access, vol. 9, pp. 112057–112068, 2021. doi: 10.1109/AC-CESS.2021.3102936.

[28] R. Zhong, R. Wang, Y. Zou, Z. Hong y M. Hu, “Redes de atención gráfica Bi-LSTM ajustadas para resumen de vídeo”, IEEE Signal Process. Lett., vol. 28, pp. 663–667, 2021. doi: 10.1109/LSP.2021.3066349.

[29] H. Zhang, S. Sun, Y. Hu, J. Liu y Y. Guo, “Clasificación de sentimientos para texto chino basada en aprendizaje multitarea interactivo”, IEEE Access, vol. 8, pp. 129626–129635, 2020. doi: 10.1109/ACCESS.2020.3007889.

[30] M. Alizadeh y J. Ma, “Análisis de series temporales de alta dimensión y detección de anomalías: un estudio de caso de modelado del comportamiento vehicular y detección de estados no saludables”, Adv Eng. Informatics., vol. 57, n.° 1, págs. 102041, 2023. doi: 10.1016/j.aei.2023.102041.