Detección de anomalías en tráfico vehicular mediante *Deep Learning* a partir de datos de sensores, trayectorias y video: una revisión sistemática de la literatura

Wilbert Alex Mayta Arotaype

Escuela Profesional de Ingeniería de Sistemas, Universidad Peruana Unión, Juliaca, Perú.

wilbert.mayta@upeu.edu.pe

Resumen

Antecedentes: la detección de anomalías en tráfico vehicular (accidentes, congestión no recurrente, conducción peligrosa o disrupciones) se aborda cada vez más con *Deep Learning* (DL) sobre datos de sensores, trayectorias y video. Las revisiones previas son narrativas, se limitan a un tipo de dato o no cubren el periodo reciente. **Objetivo:** sintetizar los modelos de DL empleados para detectar anomalías en tráfico vehicular urbano y de autopista, junto con las métricas y los protocolos de evaluación, los tipos de anomalía, los conjuntos de datos, las líneas base de comparación y las limitaciones reportadas. **Método:** revisión sistemática según Kitchenham y Charters, reportada conforme a PRISMA 2020 y PRISMA-S. Se buscaron estudios de 2020 a 2026 en Scopus, Web of Science, IEEE Xplore, ScienceDirect y ACM Digital Library (última búsqueda: 19/10/2026). Un revisor seleccionó los estudios con el apoyo de un asistente de cribado basado en reglas y verificó su consistencia mediante un recribado ciego (κ intra-revisor = **[0,xx]**). La calidad metodológica se evaluó con un instrumento de ocho ítems adaptado a estudios de aprendizaje automático (procedencia de etiquetas, partición sin fuga, líneas base, variabilidad, disponibilidad de código y datos, validación externa, protocolo y limitaciones). Protocolo registrado en **[OSF, DOI 10.17605/OSF.IO/XXXXX]**. **Resultados:** se incluyeron 72 estudios primarios (2020–2026). Predominan las arquitecturas recurrentes (34 estudios), convolucionales (43) y de atención o Transformer (34); 36 estudios combinan varias familias. La categoría de anomalía más estudiada es accidentes e incidentes (43 estudios, 60 %). Solo 30 estudios evalúan con etiquetas reales verificadas; 18 usan anomalías inyectadas, pseudo-etiquetas o ninguna etiqueta. Solo 45 reportan la proporción de anomalías, 8 reportan variabilidad entre ejecuciones y 11 publican su código. La puntuación media de calidad fue 4.88 sobre 8 (rango 1.0–7.0). **Conclusiones:** el tipo de dato condiciona la familia de arquitectura más que el tipo de anomalía. La comparabilidad entre estudios está limitada sobre todo por la procedencia heterogénea de las etiquetas y por protocolos

de evaluación incompletos, más que por la elección del modelo. Se requieren benchmarks con etiquetas verificadas y un reporte mínimo del protocolo de evaluación.
Palabras clave: detección de anomalías; tráfico vehicular; *Deep Learning*; sistemas inteligentes de transporte; revisión sistemática.

Abstract

Background: anomaly detection in vehicular traffic (crashes, non-recurrent congestion, dangerous driving or disruptions) is increasingly addressed with Deep Learning (DL) on sensor, trajectory and video data. Prior reviews are narrative, limited to a single data type, or do not cover the recent period. **Objective:** to synthesize the DL models used to detect anomalies in urban and highway traffic, together with the evaluation metrics and protocols, anomaly types, datasets, comparison baselines and reported limitations. **Method:** systematic review following Kitchenham and Charters, reported according to PRISMA 2020 and PRISMA-S. Studies from 2020 to 2026 were searched in Scopus, Web of Science, IEEE Xplore, ScienceDirect and the ACM Digital Library (last search: 19 October 2026). A single reviewer selected the studies, supported by a rule-based screening assistant, and checked consistency through blinded re-screening (intra-rater κ = [0,xx]). Methodological quality was assessed with an eight-item instrument adapted to machine learning studies (label provenance, leakage-free split, baselines, variability, code and data availability, external validation, protocol, and limitations). Protocol registered at [OSF, DOI 10.17605/OSF.IO/XXXXX]. **Results:** 72 primary studies (2020–2026) were included. Recurrent (34 studies), convolutional (43) and attention/Transformer (34) architectures predominate; 36 studies combine several families. The most studied anomaly category is crashes and incidents (43 studies, 60 %). Only 30 studies evaluate on verified real labels; 18 use injected anomalies, pseudo-labels or no labels at all. Only 45 report the anomaly ratio, 8 report run-to-run variability and 11 release their code. The mean quality score was 4.88 out of 8 (range 1.0–7.0). **Conclusions:** the data type shapes the choice of architecture more than the anomaly type does. Comparability across studies is limited mainly by heterogeneous label provenance and incomplete evaluation protocols rather than by model choice. Benchmarks with verified labels and minimum reporting of the evaluation protocol are needed.
Keywords: anomaly detection; vehicular traffic; Deep Learning; intelligent transportation systems; systematic review.

1. Introducción

El crecimiento de las ciudades y del parque automotor ha aumentado la complejidad de la gestión del tráfico vehicular, tanto en redes urbanas como en autopistas. El flujo

vehicular presenta alta variabilidad temporal, ruido de medición y dependencia espacial entre vías, sensores e intersecciones, por lo que debe analizarse como un fenómeno temporal y espacio-temporal y no como una secuencia aislada de mediciones [1, 2].

Los Sistemas Inteligentes de Transporte (*Intelligent Transportation Systems*, ITS) integran detectores de lazo y de microondas, cámaras de vigilancia, dispositivos GPS y plataformas de monitoreo. Sus datos se representan como series temporales (flujo, velocidad u ocupación en un punto), como datos espacio-temporales (varias ubicaciones conectadas por la red vial), como trayectorias o como secuencias de video [1, 3]. En este contexto, la *detección de anomalías* busca identificar desviaciones relevantes respecto al comportamiento esperado: accidentes, congestión no recurrente, cierres de vías, conducción peligrosa o disrupciones causadas por eventos extremos. Detectarlas a tiempo mejora la respuesta a incidentes y la seguridad vial [4, 5].

Tradicionalmente, este problema se abordó con algoritmos comparativos y de umbral, modelos autorregresivos y aprendizaje automático convencional [4, 6]. Estos enfoques encuentran dificultades con el desbalance entre eventos normales y anómalos, con la dependencia espacial y con los datos incompletos o ruidosos. El *Deep Learning* (DL) ofrece arquitecturas capaces de aprender representaciones temporales (redes recurrentes), espaciales (redes de grafos), visuales (redes convolucionales) o de reconstrucción (auto-encoders), y su uso para detectar anomalías en series temporales se ha generalizado [7].

1.1. Revisiones previas y vacío que aborda esta revisión

Existen revisiones previas sobre el tema, pero ninguna cubre a la vez el periodo reciente, los distintos tipos de dato y el análisis del protocolo de evaluación (Tabla 1). Los *surveys* de Djenouri et al. [1] y Zhang et al. [2] cubren la literatura anterior a 2020, con predominio de métodos estadísticos y de minería de datos. Santhosh et al. [3], Fang et al. [8] y Lin et al. [9] se limitan al video. Belhadi et al. [10] se limitan a trayectorias. Darban et al. [7] tratan series temporales genéricas, no específicas de tráfico. La única revisión sistemática identificada, la de ElSahly y Abdelfatah [4], trata la detección automática de incidentes en general, no se centra en DL y no cubre el periodo 2022–2026. Ninguna de ellas examina cómo se obtienen las etiquetas de anomalía ni cómo se fijan el umbral y la unidad de evaluación, aspectos que en detección de anomalías pueden cambiar los resultados más que la propia arquitectura [7].

Tabla 1: Revisiones previas sobre detección de anomalías de tráfico y su diferencia con esta revisión.

Revisión	**Año**	**Tipo**	**Datos cubiertos**	**Vacío respecto a esta RSL**
Djenouri et al. [1]	2019	Survey narrativo	Sensores y trayectorias	Literatura previa a 2019; escaso DL; sin video; no analiza etiquetas ni protocolo
Santhosh et al. [3]	2020	Survey narrativo	Video de vigilancia	Solo video; literatura hasta 2019; no sistemática
Belhadi et al. [10]	2020	Survey con benchmark	Trayectorias	Solo trayectorias, no exclusivo de tráfico; predominan métodos no profundos
Zhang et al. [2]	2020	Survey narrativo	Datos urbanos multifuente	Anomalías urbanas en general; no cubre 2021–2026
ElSahly y Abdelfatah [4]	2022	Sistemática (PRISMA)	Detectores de flujo	Detección de incidentes en general, no centrada en DL; sin video ni trayectorias; no cubre 2022–2026
Olugbade et al. [6]	2022	Survey narrativo	Incidentes (IA/ML general)	Enfoque amplio en IA/ML; no sistemática; no cubre 2023–2026
Razi et al. [5]	2023	Survey narrativo	Video (seguridad vial)	Centrado en video; no trata series de sensores; no sistemática
Fang et al. [8]	2024	Survey narra-	Video (acciden-	Solo video y solo

Esta revisión se diferencia de las anteriores en tres aspectos: (i) es sistemática y reproducible (PRISMA 2020 y PRISMA-S) y cubre 2020–2026; (ii) integra en un mismo análisis los estudios basados en sensores, trayectorias, movilidad agregada y video, lo que permite relacionar el tipo de dato con la familia de arquitectura; y (iii) extrae y sintetiza, para cada estudio, la procedencia de las etiquetas, el protocolo de evaluación y las líneas base, y evalúa la calidad metodológica con un instrumento específico para estudios de aprendizaje automático.

Las contribuciones son: (1) una matriz de extracción abierta de los estudios incluidos, de la que se derivan con un script todas las cifras de este artículo; (2) un análisis cruzado entre tipo de dato, familia de arquitectura, tipo de anomalía y periodo; (3) una síntesis del protocolo de evaluación (procedencia de etiquetas, umbral, unidad de evaluación y partición) y de las líneas base; y (4) una agenda de investigación basada en esas brechas.

Preguntas de investigación

RQ1: ¿Qué técnicas de *Deep Learning* se han utilizado para detectar anomalías en tráfico vehicular urbano y de autopista, y cómo se relacionan con el tipo de dato?

RQ2: ¿Qué métricas y qué protocolos de evaluación (procedencia de etiquetas, umbral, unidad de evaluación y partición) se emplean para medir el rendimiento de estos modelos?

RQ3: ¿Qué tipos de anomalías de tráfico se han abordado?

RQ4: ¿Qué conjuntos de datos se han utilizado y con qué tipo de etiquetas?

RQ5: ¿Qué limitaciones y desafíos reportan los estudios?

RQ6: ¿Contra qué líneas base se comparan los modelos de *Deep Learning* y qué ventaja reportan?

El resto del artículo se organiza así: la Sección 2 presenta el marco conceptual; la Sección 3, el método; la Sección 4, los resultados por pregunta; la Sección 5, la discusión y las amenazas a la validez; y la Sección 6, las conclusiones.

2. Marco conceptual

2.1. Datos de tráfico y su representación

Una *serie temporal de tráfico* es una secuencia de observaciones de una variable de movilidad (flujo, velocidad u ocupación) registrada por un detector en un punto de la red; puede ser univariada o multivariada. Cuando se observan simultáneamente

varias ubicaciones, los datos son *espacio-temporales* y suelen representarse como un grafo cuyos nodos son sensores, segmentos o zonas, y cuyas aristas son conexiones viales o relaciones origen-destino [1]. Las *trayectorias* son secuencias de posiciones de un vehículo obtenidas por GPS o por seguimiento en video [10]. El *video de vigilancia* es una secuencia de imágenes de cámaras fijas o a bordo [3]. El tipo de dato condiciona qué anomalías son observables y qué arquitectura es adecuada.

2.2. Anomalías de tráfico

Una *anomalía de tráfico* es un evento o patrón que se aparta del comportamiento esperado de la red o de un vehículo. En esta revisión se agrupan en cuatro categorías: (i) accidentes e incidentes; (ii) congestión o flujo anómalo no recurrente; (iii) trayectorias o conducción peligrosa (contramano, exceso de velocidad, maniobras de riesgo); y (iv) disrupciones y eventos extremos (cierres de vías, eventos meteorológicos, fallos de infraestructura). Las anomalías son poco frecuentes, lo que produce conjuntos de datos desbalanceados y dificulta tanto el entrenamiento como la evaluación [7].

2.3. Enfoques de *Deep Learning* para la detección de anomalías

Los modelos de DL detectan anomalías mediante cuatro mecanismos, que no dependen de la arquitectura concreta [7]:

- **Predicción:** el modelo (p. ej., LSTM, GRU, TCN o Transformer) pronostica el comportamiento esperado y marca como anómalas las desviaciones grandes entre lo predicho y lo observado.
- **Reconstrucción:** un autoencoder, posiblemente de grafos o variacional, aprende a reconstruir datos normales y usa el error de reconstrucción como puntuación de anomalía. Es útil cuando hay pocas etiquetas.
- **Clasificación supervisada:** con etiquetas de eventos normales y anómalos, una red (CNN, LSTM, GNN o híbrida) aprende directamente la frontera entre clases. Es frecuente en video y en detección de incidentes con registros históricos.
- **Similitud o contraste:** el modelo compara representaciones (por ejemplo, de video y de texto) y decide por similitud.

Los tres primeros mecanismos requieren un *umbral* o una regla de decisión para convertir la puntuación en una alarma. La elección del umbral, junto con la *unidad de evaluación* (punto, ventana, frame, evento o trayectoria), determina las métricas resultantes; por eso esta revisión los extrae de cada estudio.

3. Método

La revisión sigue las directrices de Kitchenham y Charters [12] y se reporta conforme a PRISMA 2020 [13] y a su extensión para la búsqueda, PRISMA-S [14]. La lista de verificación PRISMA 2020 con la ubicación de cada ítem se presenta en el Anexo D.

3.1. Protocolo y registro

El protocolo (PICOC, preguntas, criterios, estrategia de búsqueda, instrumento de calidad y plan de síntesis) se gestionó en Parsif.al y se registró en Open Science Framework (**[OSF, DOI 10.17605/OSF.IO/XXXXX]**). Las desviaciones respecto de la versión inicial (ampliación del alcance a video y autopistas, sustitución de MDPI y Taylor & Francis por IEEE Xplore, regla general sobre *preprints*, nuevo instrumento de calidad y nueva pregunta RQ6) se documentan en el historial del protocolo (Anexo A, Tabla 21).

3.2. PICOC y alineamiento del alcance

Tabla 2: Marco PICOC de la revisión.

Elemento	Descripción
Población	Tráfico vehicular en redes urbanas y autopistas, observado mediante sensores fijos, trayectorias GPS, datos de movilidad agregada o video de vigilancia
Intervención	Modelos de *Deep Learning* (recurrentes, convolucionales, autoencoders, grafos, Transformers, generativos o híbridos) usados como método principal para detectar anomalías
Comparación	Líneas base reportadas por cada estudio: otros modelos de DL, aprendizaje automático convencional, métodos estadísticos o reglas (RQ6)
Resultado	Desempeño de detección y protocolo con que se mide (métricas, procedencia de etiquetas, umbral, unidad de evaluación, partición)
Contexto	Sistemas inteligentes de transporte; estudios revisados por pares publicados entre 2020 y 2026

Para evitar que el alcance declarado difiera del corpus, el título, las preguntas, el PICOC, la cadena de búsqueda y los criterios se alinearon explícitamente (Tabla 3).

Tabla 3: Alineamiento del alcance entre los componentes del protocolo.

Componente	**Entorno vial**	**Tipo de dato**	**Método**
Título y RQ1	Urbano y autopista	Sensores, trayectorias y video	DL
PICOC (P, I)	Redes urbanas y autopistas	Sensores, GPS, movilidad agregada, video	DL como método principal
Cadena (bloque C)	*road, urban, vehicular, highway* o *freeway traffic*	*traffic flow, speed, data, video, surveillance* o *camera*; *vehicle trajector**; *taxi**	Bloque B (arquitecturas de DL)
Criterios	CI-4, CE-2	CI-4	CI-5, CE-4

3.3. Fuentes de información y estrategia de búsqueda

Se consultaron cinco bases bibliográficas: Scopus, Web of Science Core Collection, IEEE Xplore, ScienceDirect y ACM Digital Library. Se incorporó IEEE Xplore por su peso en el área de transporte inteligente y visión por computador. MDPI y Taylor & Francis Online, que figuraban en la versión anterior del protocolo, se retiraron como fuentes porque son plataformas editoriales y no bases bibliográficas. Sus revistas indexadas (p. ej., *Sensors* o *Applied Sciences*) se recuperan a través de Scopus y Web of Science, de modo que su retiro no excluye esos artículos. Se usó Parsif.al para gestionar los registros.

La cadena se construyó a partir del PICOC con tres bloques unidos por AND: (A) términos de detección de anomalías, incidentes o accidentes; (B) términos de DL y de sus arquitecturas; y (C) términos de tráfico vehicular, incluidos los de video y vigilancia. La cadena anterior exigía además *time series* o *spatio-temporal*, lo que recuperaba solo parcialmente los estudios basados en video. Ese bloque se eliminó al ampliar el alcance. En todas las bases se buscó en título, resumen y palabras clave, salvo en ACM (resumen) e IEEE Xplore (*All Metadata*). Se filtró por año de publicación (2020–2026), por tipo de documento (artículo de revista o de conferencia) y por idioma (inglés o español). En Web of Science y ScienceDirect estos filtros se aplicaron en la interfaz. Scopus, IEEE Xplore y ACM se exportaron sin filtros y los mismos filtros se aplicaron con un script sobre los metadatos exportados (123 registros fuera de periodo o de tipo de documento), con un registro de cada exclusión. El acceso abierto no se filtró en las interfaces, porque cada base lo marca de forma distinta y ScienceDirect y ACM no lo exportan; se verificó

registro por registro como parte del criterio CI-2 (Sección 3). Las cadenas exactas por base, con sus campos y filtros, se presentan en el Anexo A; la fecha de ejecución y el número de registros de cada base se reportan en la Tabla 4. Como el periodo incluye el año en curso, los resultados de 2026 son parciales hasta la fecha de búsqueda.

La cadena fue elaborada por el autor; no fue validada por un especialista en información externo, lo que se discute en la Sección 5.4. La cadena se validó con un conjunto de control formado por los estudios incluidos: se comprobó de forma automática si el título, el resumen y las palabras clave de cada uno satisfacen los tres bloques (script `prueba_sensibilidad_cadena.py`). La primera formulación de la versión 2 recuperaba 13 de 21 estudios. Se añadieron sinónimos (*anomal**, *abnormal**, *road closure*, *expressway*, *vehicle*, entre otros) y la cadena recuperó 19 de 21. Una prueba en Scopus mostró que los términos sueltos del bloque C (*vehicle**, *highway**) traían mucho ruido (vehículos aéreos no tripulados, vehículos eléctricos). Por eso, en la versión definitiva (v2.1) se sustituyeron por frases ancladas al tráfico vial (*traffic speed*, *traffic monitoring*, *vehicle trajector**, entre otras), y la cadena mantiene la recuperación de 19 de 72. Los dos restantes (S03, S14) no mencionan ningún término de DL en el título, el resumen ni las palabras clave. Se identificaron en la búsqueda de la versión 1 en ACM Digital Library, que no restringía el campo y por tanto buscaba en el texto completo, y se reportan en la rama "otros métodos" del diagrama PRISMA (Figura 1).

Tabla 4: Bases consultadas: fecha de ejecución, campos y registros recuperados.

Base	**Campos y filtros**	**Fecha**	**Registros**
Scopus	TITLE-ABS-KEY; 2020–2026; artículo y conferencia; inglés/español	19/10/2026	498
Web of Science	TS (título, resumen, palabras clave y Keywords Plus); mismos filtros	19/10/2026	193
IEEE Xplore	*All Metadata*; tres consultas (límite de 25 términos); revistas y conferencias	19/10/2026	152
ScienceDirect	Título, resumen y palabras clave; cinco consultas (límite de 8 operadores, sin comodines)	19/10/2026	337
ACM Digital Library	Resumen; artículos de investigación	19/10/2026	397
Total			1577

3.4. Criterios de elegibilidad

Tabla 5: Criterios de inclusión (CI) y exclusión (CE), con su fundamento en el protocolo.

Cód.	Criterio	Fundamento
Inclusión		
CI-1	Artículo de revista o de conferencia revisado por pares	Calidad mínima de la evidencia
CI-2	En inglés o español, con texto completo en acceso abierto	Viabilidad y reproducibilidad: la extracción exige el texto completo y cualquier lector debe poder verificarla sin suscripción
CI-3	Publicado entre 2020 y 2026	Contexto (C): periodo del DL reciente; vacío de las revisiones previas
CI-4	Aborda la detección de anomalías en tráfico vehicular (urbano o de autopista) a partir de sensores, trayectorias, datos de movilidad o video	Población (P) y alcance; RQ3, RQ4
CI-5	Usa *Deep Learning* como método principal de la detección; en modelos híbridos, la componente profunda aprende la representación sobre la que se decide la anomalía	Intervención (I); RQ1
CI-6	Reporta una evaluación cuantitativa de la tarea de detección (no solo de una tarea auxiliar como pronóstico o reconocimiento de acciones)	Resultado (O); RQ2 y RQ6
Exclusión		
CE-1	Duplicado entre bases, o versión menos completa del mismo estudio (p. ej., conferencia ampliada luego en revista); se conserva la más completa	Evitar doble conteo
CE-2	No trata de tráfico vehicular por carretera (p. ej., tráfico de red, ciberseguridad del vehículo, peatones, transporte marítimo, aéreo o ferroviario, estado del pavimento, monitoreo del conductor)	Población (P)
CE-3	Solo pronostica o clasifica tráfico, o estima riesgo a largo plazo, sin detectar ni anticipar anomalías	Resultado (O); objetivo de la RSL
CE-4	La detección no se basa en DL (SVM, ARIMA, reglas o umbrales sin componente profunda entrenada)	Intervención (I)

Los criterios se aplicaron como un árbol de decisión en orden fijo (CE-1, CE-5, CI-3, CI-2, CE-2, CE-3, CE-4 y, a texto completo, CI-6 y CE-6), de modo que cada exclusión se asigna al primer criterio que no se cumple. Las definiciones operativas, con ejemplos de inclusión y de exclusión, se recogen en el manual de cribado del material suplementario. Los casos límite (estudios en los que el DL no decide directamente la anomalía o en los que la evaluación cuantitativa corresponde a otra tarea) se resolvieron con CI-5 y CI-6, y la decisión se documenta estudio por estudio en el Anexo C.

3.5. Proceso de selección

Los registros exportados de las cinco bases se unificaron y se deduplicaron con un script (coincidencia de DOI o de título normalizado con año igual o contiguo), cuyo registro de duplicados forma parte del material suplementario; los registros únicos se importaron en Parsif.al. Al ser una revisión de autor único, la selección la realizó un solo revisor (W. A. M. A.), con tres medidas para controlar el sesgo de selección. Primero, un asistente de cribado basado en reglas transparentes (derivadas de la cadena de búsqueda y del árbol de criterios) pre-clasificó cada registro como "excluir por regla", "probable inclusión" o "revisar". Solo propuso exclusiones por criterios objetivos (tipo de documento, año, idioma o dominio claramente no vial), y el revisor verificó cada una (100 de 100 confirmadas); Además, un asistente de IA generativa (Claude, Anthropic) leyó el título y el resumen de cada registro, aplicó el mismo árbol de criterios y propuso una decisión con su criterio y una justificación breve. El revisor verificó cada propuesta leyendo el título y el resumen y tomó la decisión final; cambió 62 propuestas (acuerdo revisor–IA de 93 %, $\kappa = 0{,}77$). Las propuestas originales de la IA se conservan en el material suplementario. El acuerdo entre el revisor y el asistente por reglas fue de 31 % ($\kappa = 0{,}06$). El requisito de acceso abierto de CI-2 se verificó para cada registro el 19/10/2026 con OpenAlex, que integra los datos de Unpaywall, y con el indicador de acceso abierto de Scopus, Web of Science e IEEE Xplore. Se consideró de acceso abierto todo texto completo legible sin suscripción (*gold*, *diamond*, *hybrid*, *bronze* o *green*) según cualquiera de las fuentes; 577 registros se excluyeron por no cumplirlo. Segundo, en título y resumen se excluyó solo cuando el incumplimiento era claro, y los casos dudosos pasaron a texto completo. A texto completo, un script extrajo de cada PDF las frases candidatas (métricas de detección, método propuesto y términos de DL) con su página, y el revisor decidió leyendo el artículo; cada exclusión se registró con su criterio y con la cita que la justifica. Tercero, la consistencia del revisor se midió mediante un re-cribado ciego, al menos siete días después, de una muestra aleatoria: κ intra-revisor = **[0,xx]** (n = **[n]**) en título y resumen y **[0,xx]** (n = **[n]**) en texto completo, con el coeficiente kappa de Cohen [15]. Las decisiones finales se consignaron en Parsif.al y los motivos de exclusión a texto completo se reportan en la Figura 1.

3.6. Extracción de datos

Los datos de cada estudio se extrajeron con el formulario de la Tabla 6. La extracción inicial se hizo con asistencia de inteligencia artificial (lectura del texto completo de cada estudio) y el autor la verificó contra el PDF, corrigiendo las discrepancias; las fichas individuales conservan la evidencia de cada dato. Además de los campos descriptivos, se extrajeron la procedencia de las etiquetas, la proporción de anomalías, la unidad de evaluación, el criterio de umbral, la partición de los datos y las líneas base, porque son los elementos que determinan la comparabilidad entre estudios. La matriz completa (un registro por estudio) se publica como material suplementario y todas las cifras de este artículo se generan a partir de ella con un script (`generar_conteos.py`).

Tabla 6: Formulario de extracción de datos.

Campo	**Contenido**
Identificación	ID, autores, año, título, revista o conferencia, DOI, base de recuperación
Contexto	Entorno (urbano, autopista), país o región de los datos
Datos	Tipo de dato, variables de entrada, datasets (real, simulado o mixto; público o no)
Etiquetas	Procedencia (registros reales, anotación experta, benchmark de terceros, inyectadas), proporción de anomalías
Modelo	Familias de arquitectura, híbrido o no, multimodal o no, paradigma (supervisado, semisupervisado, no supervisado) y mecanismo (predicción, reconstrucción, clasificación, similitud)
Protocolo	Partición entrenamiento/prueba, unidad de evaluación, criterio de umbral
Resultados	Métricas, resultado principal, líneas base y ventaja frente a la mejor
Anomalía	Categoría principal y secundaria
Limitaciones	Limitaciones declaradas por los autores (codificadas en seis categorías)
Reproducibilidad	Disponibilidad de código y datos

3.7. Evaluación de la calidad metodológica

La versión anterior del instrumento repetía los criterios de elegibilidad, de modo que todo estudio incluido los cumplía por definición. Se sustituyó por un instrumento de ocho ítems, adaptado de la lista de calidad de Kitchenham y Charters [12] y de las recomendaciones REFORMS para estudios basados en aprendizaje automático [16]. Los

ítems evalúan riesgos de sesgo propios de este tipo de estudios (Tabla 7). Cada ítem se puntúa como Sí (1), Parcial (0,5) o No (0), con un máximo de 8. La puntuación **no** se usó para excluir estudios: se reporta por ítem y por estudio, y se usa en la síntesis para contrastar los hallazgos principales con el subconjunto de calidad alta (≥ 6.0). Para cada estudio se propuso un puntaje por ítem con la evidencia del texto (asistido), y el autor lo verificó leyendo el artículo, confirmando o corrigiendo cada puntaje con su justificación; el acuerdo entre el puntaje propuesto y el verificado fue de [**xx %**].

Tabla 7: Instrumento de evaluación de calidad metodológica (QA).

Ítem	**Criterio**	**Sí (1) / Parcial (0,5) / No (0)**
QA1	Procedencia de etiquetas	1: registros reales o anotación verificada; 0,5: mixtas, automáticas o verificación parcial; 0: solo inyectadas o no reportado
QA2	Partición sin fuga	1: partición temporal o prueba independiente descrita; 0,5: partición aleatoria o descripción incompleta; 0: no reportada
QA3	Líneas base comparables	1: dos o más líneas base con el mismo protocolo, incluida una del estado del arte o no DL; 0,5: una sola o solo ablación; 0: ninguna
QA4	Variabilidad	1: varias ejecuciones con dispersión, intervalos o pruebas de significancia; 0,5: parcial; 0: una sola ejecución
QA5	Código y datos	1: ambos públicos; 0,5: uno de los dos; 0: ninguno
QA6	Más de un escenario	1: dos o más datasets, ciudades o vías independientes; 0,5: varios subconjuntos de un dataset; 0: un único escenario
QA7	Protocolo explícito	1: reporta la unidad de evaluación y el criterio de umbral o decisión; 0,5: solo uno; 0: ninguno
QA8	Limitaciones	1: sección o párrafo explícito; 0,5: mención breve; 0: ninguna

3.8. Síntesis

Los estudios se agruparon por familia de arquitectura, tipo de dato, categoría de anomalía y periodo de publicación. Para sustentar las tendencias se construyeron tablas cruzadas (tipo de dato × familia, anomalía × familia y periodo × familia). Se identificaron los conjuntos de datos usados por más de un estudio para comparar su desempeño bajo el protocolo de cada uno. No se realizó metaanálisis porque los estudios difieren en tarea, datos, etiquetas, unidad de evaluación y métrica, y ningún par de

estudios comparte a la vez dataset y protocolo. Por la misma razón no se aplicó GRADE para valorar la certeza de la evidencia ni se evaluó formalmente el sesgo de publicación (PRISMA, ítems 14 y 15). Como aproximación, se registró si cada estudio compara contra líneas base y si reporta resultados desfavorables para su propuesta (Sección 4.9).

4. Resultados

4.1. Selección de estudios

La Figura 1 resume el proceso de selección según PRISMA 2020. De 1577 registros identificados en las cinco bases se eliminaron 337 duplicados y se cribaron 1240 por título y resumen. Se evaluaron 92 textos completos, de los que se excluyeron 20 con los motivos indicados en la figura. A los estudios procedentes de las bases se sumaron 0 estudios identificados en la búsqueda de la versión 1 en ACM Digital Library (S03, S14). En total se incluyeron 72 estudios. 5 estudios incluidos en la versión anterior de esta revisión o en la planilla de Parsif.al se excluyeron al aplicar los criterios actualizados; estas exclusiones y las 0 inclusiones dudosas se justifican estudio por estudio en el Anexo C.

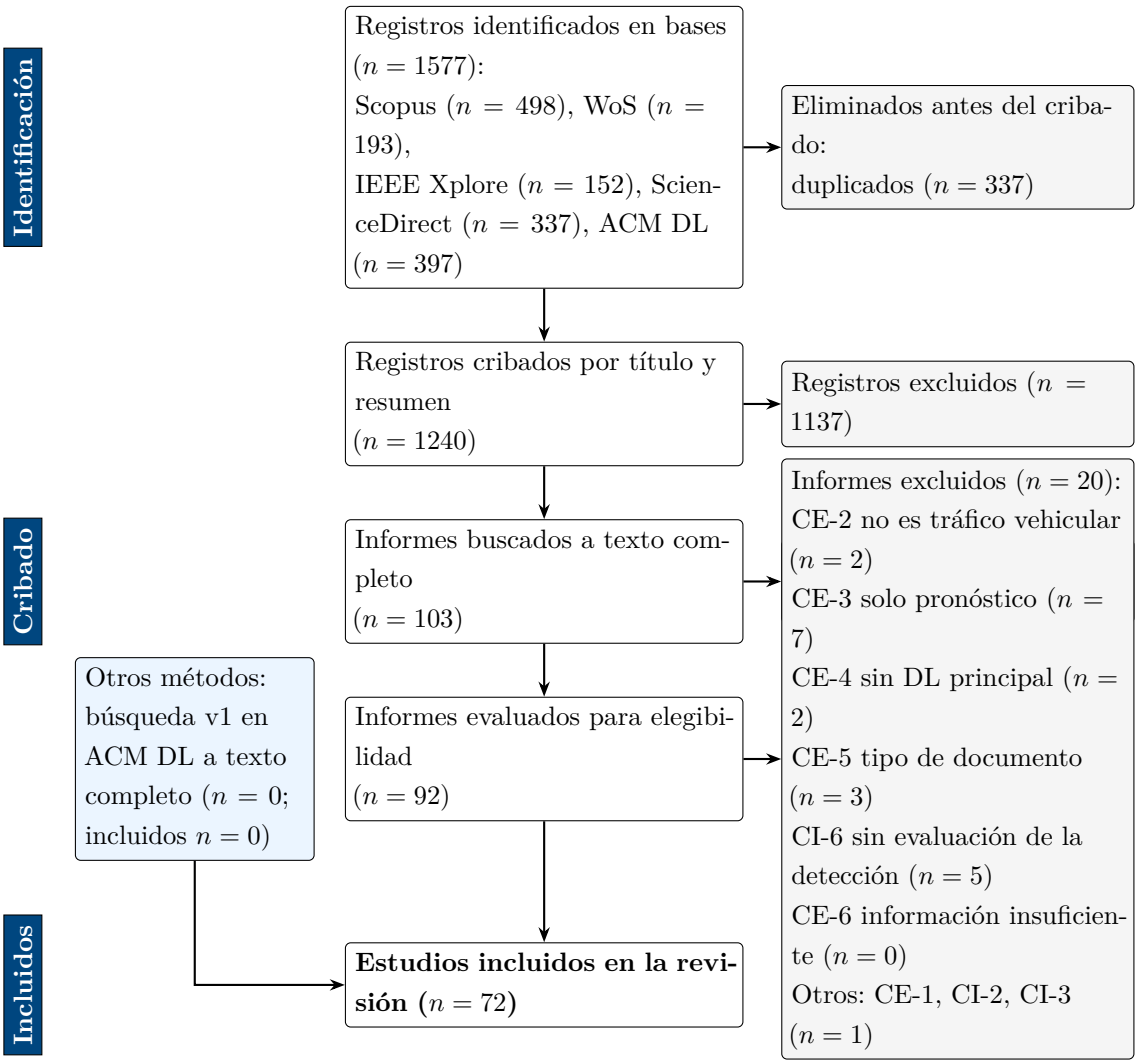


Figura 1: Diagrama de flujo PRISMA 2020 de la selección de estudios.

4.2. Características de los estudios

Los 72 estudios se publicaron entre 2020 y 2026: 3 en 2020, 2 en 2021, 7 en 2022, 14 en 2023, 8 en 2024, 20 en 2025 y 18 en 2026 (año parcial, hasta la fecha de búsqueda). 46 estudios son de 2024 en adelante. Por entorno, 29 estudios analizan tráfico urbano, 17 tráfico de autopista, 16 ambos y 10 no lo especifican. Por tipo de dato, 29 usan video o imágenes, 17 series de sensores, 13 trayectorias, 2 datos de movilidad agregada u origen-destino, 11 combinan varias fuentes y 0 usan exclusivamente datos simulados. La Tabla 8 presenta las características y el resultado principal de cada estudio.

Tabla 8: Características de los estudios incluidos.

ID	Ref.	Año	Tipo de dato	Entorno	Datasets	Etiquetas	Anomalía	Modelo	Resultado principal
S01	[17]	2020	Sensores	urbano	Detectores de microondas de Tangqiao...	Registros reales	Accidentes e incidentes	DELM	DR = 98.42 %; FAR = 0.56 %; MTTD = 0.68 min en Hangzhou
S02	[18]	2020	Sensores	no especificado	Safety Pilot Model Deployment Data (SPMD)...	Anotación manual	Conducción peligrosa	LSTM-CNN secuencial	Tasa media de reconocimiento LSTM-CNN: 95,684 % en...
S03	[19]	2020	Trayectorias	urbano	Porto taxi (Portugal); Didi Chuxing privado...	Anotación manual	Trayectoria anómala	GCM	PR-AUC = 0.8075 en Porto; 0.8497 en Didi Chuxing
S04	[20]	2021	Video/imágenes	urbano	CADP + UA-DETRAC + imágenes web scraping	Registros reales	Accidentes e incidentes	InceptionV4 transfer learning + 2 ConvLSTM +...	F1=0.98; Accuracy=98 %
S05	[21]	2021	Sensores	autopista	I-880 traffic incident dataset; 45...	Registros reales	Accidentes e incidentes	Modelo híbrido RF-RFE-BOA-LSTM con SMOTE	Accuracy=98.07 %; DR=96.76 %; FAR=1.61 %...
S06	[22]	2022	Video/imágenes	ambos	80 secuencias de video con aproximadamente...	Registros reales	Accidentes e incidentes	DNN multicapa totalmente conectada con...	TP-r=98.5 %; FP-r=4.2 %; tiempo medio de...

ID	Ref.	Año	Tipo de dato	Entorno	Datasets	Etiquetas	Anomalía	Modelo	Resultado principal
S07	[23]	2022	Video/imágenes	urbano	TAD (país no reportado)	Anotación manual	Accidentes e incidentes	T-CAD	AUC = 0.9171 en TAD overall; 0.6309 en anomaly subset
S08	[24]	2022	Sensores	urbano	Odense: datos reales proporcionados por...	No reportado	Congestión atípica	DCNN-TFO (Deep Convolutional Neural Network...	Con el 100 % de los datos, la Figura 2 (p. 5) muestra...
S09	[25]	2022	Video/imágenes	ambos	IITH Road Accident Dataset: videos CCTV de...	Benchmark anotado	Accidentes e incidentes	Arquitectura en cascada formada por un...	IITH: AUC 79 %, EER 20,50 % y mAP 60 % con umbral IoU...
S10	[26]	2022	Sensores	autopista	PeMS I-80, California (EE. UU.)	Pseudo-etiquetas	Accidentes e incidentes	Snorkel + LSTM + deep ensemble de 25 modelos	DR = 0.90 y FAR = 0.08 con deep ensemble en PeMS I-80
S11	[27]	2022	Trayectorias	urbano	Taxis de Pekín, China; 21,339 taxis, junio...	Registros reales	Conducción peligrosa	STDTB-AD	ACC=0.964; P=0.956; R=0.860; F1=0.905 (NS=100; 20 %...
S12	[28]	2022	Sensores	urbano	Dataset real de tráfico de Pekín; nombre...	Registros reales	Congestión atípica	GDN con embeddings de nodos + TopK + GAT +...	Detection Rate=97.49 %; FAR=2.51 %; Accuracy=97.01 %

ID	Ref.	Año	Tipo de dato	Entorno	Datasets	Etiquetas	Anomalía	Modelo	Resultado principal
S13	[29]	2023	Sensores	urbano	SUMO (Simulation of Urban Mobility)...	Inyectadas o sintéticas	Accidentes e incidentes	Red neuronal LSTM para clasificación binaria...	LSTM, incidentes de duración inferior a 6 minutos: DR...
S14	[30]	2023	Trayectorias	autopista	MAAD (Multi-Agent Anomaly Detection)...	Inyectadas o sintéticas	Conducción peligrosa	SABeR-VAE (Structural Attention-Based...	SABeR-VAE: AUROC 87,0 ± 1,5 %, AUPR-Abnormal 65,5 ±...
S15	[31]	2023	Trayectorias	urbano	Dos conjuntos reales de trayectorias de...	Registros reales	Trayectoria anómala	Autoencoder sequence-to-sequence GRU	VMT: Detection Rate 0,9167, equivalente a 91,67 %...
S16	[32]	2023	Sensores	urbano	Detectores de lazo de Brisbane (Australia)...	Inyectadas o sintéticas	Evento u otro	Deep Q-Network con LSTM apilada de 2 capas...	F1=87,23 %; Precision=92,94 %; Recall=82,48 % (datos...
S17	[33]	2023	Video/imágenes	no especificado	DoTA, Detection of Traffic Anomaly...	Benchmark anotado	Accidentes e incidentes	TempoLearn	DoTA: AUC de localización 92,4 %, Tabla 3, p. 8; top-1...
S18	[34]	2023	Trayectorias	autopista	TransModeler, simulador microscópico de...	Sin etiquetas	Conducción peligrosa	Detecting Socially Abnormal Behaviors...	En el escenario simulado combinado, DSAB obtiene...

ID	Ref.	Año	Tipo de dato	Entorno	Datasets	Etiquetas	Anomalía	Modelo	Resultado principal
S19	[35]	2023	Video/imágenes	autopista	Dataset propio de eventos viales reales...	Anotación manual	Accidentes e incidentes	Tres enfoques comparados	Mejor clasificación de escenas: algoritmo C, ResNet-34...
S20	[36]	2023	Trayectorias	no especificado	Entrenamiento: Next Generation Simulation...	Inyectadas o sintéticas	Trayectoria anómala	RETAD (Reconstruction Error-based Trajectory...	Mejor F1 de RETAD: 0,9629 (96,29 %) en Traj-3, con ACC...
S21	[37]	2023	Sensores	autopista	MnDOT / Regional Transportation Management...	Registros reales	Accidentes e incidentes	Modelo de dos etapas	Tabla 3, p. 616: LSTM a 18 minutos del accidente, TPR...
S22	[38]	2023	Multimodal	urbano	Driving Anomaly Dataset (DAD), recopilado...	Registros reales	Conducción peligrosa	Cinco GAN condicionales independientes, uno...	El resultado principal es superioridad visual de la...
S23	[39]	2023	Trayectorias	urbano	Porto Taxi Trajectory (Portugal)	No reportado	Trayectoria anómala	VAE-LSTM + ventanas deslizantes +...	Precision=0.960; Recall=0.965; F1=0.963; PR-AUC=0.943
S24	[40]	2023	Trayectorias	urbano	Dos conjuntos reales de trayectorias de...	Anotación manual	Trayectoria anómala	RL4OASD	Tabla III: Chengdu, F1 global 0,854 y TF1 global...

ID	Ref.	Año	Tipo de dato	Entorno	Datasets	Etiquetas	Anomalía	Modelo	Resultado principal
S25	[41]	2023	Video/imágenes	ambos	Car Accident Detection and Prediction...	Registros reales	Accidentes e incidentes	Arquitectura secuencial de cuatro etapas	Exactitud de validación de aproximadamente 95,87 % y...
S26	[42]	2023	Video/imágenes	no especificado	Car Crash Dataset (CCD), conjunto público de...	Registros reales	Accidentes e incidentes	Arquitectura de dos etapas	Con sustracción de fondo: precisión 0,98; recall 0,98...
S27	[43]	2024	Video/imágenes	urbano	Dataset recopilado por los autores a partir...	Benchmark anotado	Accidentes e incidentes	I3D-ConvLSTM2D RGB + Optical Flow (Trainable)	Tabla 2, p. 11: I3D-ConvLSTM2D RGB Only, mAP 0,78...
S28	[44]	2024	Multimodal	ambos	UAH-DriveSet, dataset público de conducción...	Pseudo-etiquetas	Conducción peligrosa	Sistema jerárquico de dos etapas	Detección inicial normal/anómala mediante LSTM: mejor...
S29	[45]	2024	Video/imágenes	urbano	UCF-Crime, conjunto público de videos de...	Registros reales	Accidentes e incidentes	Modelo DRN + Bi-LSTM	Mejor resultado global de DRN + Bi-LSTM: accuracy...
S30	[46]	2024	Movilidad agregada	urbano	Dataset real de monitoreo de tráfico de...	Sin etiquetas	Congestión atípica	Traffic-ConvLSTM	La Tabla 2, p. 10, informa para Traffic-ConvLSTM...

ID	Ref.	Año	Tipo de dato	Entorno	Datasets	Etiquetas	Anomalía	Modelo	Resultado principal
S31	[47]	2024	Sensores	autopista	Dataset real de la Agencia de Carreteras y...	Inyectadas o sintéticas	Accidentes e incidentes	Sistema de detección basado en predicción...	Mejor ROC-AUC: DONE 0,98 ± 0,018, con tiempo de...
S32	[48]	2024	Movilidad agregada	ambos	NYC Taxi Trips, publicado por New York City...	Inyectadas o sintéticas	Congestión atípica	MTGAE (Mirror Temporal Graph Autoencoder)	MTGAE obtiene AUC-ROC = 1,000 para $\gamma = 5\,\%$, 10 % y 20 %...
S33	[49]	2024	Trayectorias	urbano	Datasets de trayectorias vehiculares de...	No reportado	Conducción peligrosa	Deformation Gated Recurrent Network (DF-GRN)...	Micro F1-score de 90.6 % en Chengdu con todas las...
S34	[50]	2024	Trayectorias	ambos	Dos conjuntos reales: Porto, Portugal, un...	Inyectadas o sintéticas	Trayectoria anómala	MST-OATD, Multi-scale Spatio-temporal Online...	Tabla 2 (p. 8): mejor PR-AUC de MST-OATD en Porto =...
S35	[51]	2025	Video/imágenes	urbano	357231 instancias obtenidas de 52 horas de...	Registros reales	Accidentes e incidentes	Modelo ensemble de dos Time-Embedded...	Ensemble MTTC+DRAC con SMOTE: Recall=86 %, FAR=23 %...
S36	[52]	2025	Multimodal	ambos	Driver Behavior and Route Anomaly Dataset...	Registros reales	Conducción peligrosa	GNN-RMNet	GNN-RMNet: accuracy 98 %, precision 98 %, recall 97 %...

ID	Ref.	Año	Tipo de dato	Entorno	Datasets	Etiquetas	Anomalía	Modelo	Resultado principal
S37	[53]	2025	Video/imágenes	ambos	Conjunto propio de 9000 imágenes de...	Anotación manual	Accidentes e incidentes	Comparación de tres arquitecturas YOLO para...	Tabla 3, p. 9: YOLOv9 precision=1,0000, recall=0,8209...
S38	[54]	2025	Sensores	autopista	FT-AED (Freeway Traffic Anomalous Event...	Registros reales	Accidentes e incidentes	Modelo BiLSTM-LSTM supervisado	Accuracy de validación 0.9118; precision de anomalías...
S39	[55]	2025	Multimodal	urbano	Cuatro conjuntos públicos descritos en la...	Benchmark anotado	Conducción peligrosa	MMVAD	En el conjunto vial UIT-ADrone: AUC 69,56 % con MMVAD...
S40	[56]	2025	Multimodal	autopista	METR-LA y PEMS-BAY; conjuntos públicos de...	Registros reales	Accidentes e incidentes	MHGNN-CPLE	Detección estática: Accuracy=0.980, Precision=0.975...
S41	[57]	2025	Sensores	autopista	El artículo declara datos de condiciones de...	Registros reales	Accidentes e incidentes	IRF-HTID-BO-LSTM	IRF-HTID-BO-LSTM: DR 98,45 %; FAR 1,82 %; accuracy...
S42	[58]	2025	Video/imágenes	urbano	DAD: 1750 videos, 620 con accidente y 1130...	Benchmark anotado	Accidentes e incidentes	El sistema procesa fotogramas dashcam...	DAD: AP 87,7 % y mTTA 4,47 s. CCD: AP 99,7 % y mTTA...

ID	Ref.	Año	Tipo de dato	Entorno	Datasets	Etiquetas	Anomalía	Modelo	Resultado principal
S43	[59]	2025	Video/imágenes	urbano	Conjunto propio de 350 imágenes recopiladas...	Anotación manual	Accidentes e incidentes	Se comparan YOLOv8n, YOLOv8s y YOLOv8m para...	Tabla 2, p. 73: YOLOv8n, batch 16 y 500 épocas...
S44	[60]	2025	Video/imágenes	ambos	594 imágenes recopiladas de múltiples...	Registros reales	Accidentes e incidentes	YOLO11-AMF	Precision=0.965; Recall=0.829; F1=0.892; mAP50=0.900...
S45	[61]	2025	Video/imágenes	ambos	Dataset propio de imágenes de accidentes...	Anotación manual	Accidentes e incidentes	DSGF-YOLO, detector de objetos de una etapa...	DSGF-YOLO alcanza Precision 92.7 %, Recall 90.8 %, mAP50...
S46	[62]	2025	Video/imágenes	no especificado	DoTA: 4677 clips de video, resolución...	Registros reales	Accidentes e incidentes	MAMTCF	DoTA: AUC=76.6 %; DADA-2000: AUC global=70.2 %...
S47	[63]	2025	Video/imágenes	urbano	4M-TAD (4 Multi-View Traffic Accident...	Benchmark anotado	Accidentes e incidentes	MDTS-ADNet (Multi-View Dual-Stream...	4M-TAD: AUC 84.33 %, precisión 76.59 %, recall 75.36 %...
S48	[64]	2025	Trayectorias	urbano	Dos conjuntos: Porto Taxi Dataset, con...	Inyectadas o sintéticas	Trayectoria anómala	GETAD (Graph Enhanced Trajectory Anomaly...	Simulation: desvíos restringidos, F1 = 0,955 y PR-AUC...

ID	Ref.	Año	Tipo de dato	Entorno	Datasets	Etiquetas	Anomalía	Modelo	Resultado principal
S49	[65]	2025	Video/imágenes	no especificado	Fuentes declaradas: UCF-Crime, IITH y...	Benchmark anotado	Accidentes e incidentes	RIDS (Road Incident Detection System)	Accidentes: accuracy = 93 % en la identificación de...
S50	[66]	2025	Multimodal	no especificado	Dataset propio de conducción vehicular...	Pseudo-etiquetas	Conducción peligrosa	Arquitectura híbrida de detección de...	Giros bruscos izquierda/derecha: accuracy 99,70 %...
S51	[67]	2025	Sensores	urbano	Dataset de simulación microscópica VISSIM de...	Inyectadas o sintéticas	Accidentes e incidentes	Graph Multi-Resolution Transformer (GMRT)	Mejor resultado de GMRT: recall promedio reportado de...
S52	[68]	2025	Video/imágenes	ambos	HWID12 (Highway Incidents Detection...	Benchmark anotado	Accidentes e incidentes	Detector FCOS (Fully Convolutional...	Tabla 6, p. 981: FCOS propuesto mAP 96,91 % y 46 FPS...
S53	[69]	2025	Multimodal	ambos	Dos conjuntos reales descritos en la sección...	Registros reales	Accidentes e incidentes	MoTIF	MoTIF: accuracy 83,33 %, precision 84,01 % y F1-score...
S54	[70]	2025	Trayectorias	autopista	ETC Shanghai, propio (China)	No reportado	Conducción peligrosa	CPE + Compressed Transformer Encoder +...	AUC = 0.98; F1 = 0.95 en ETC Shanghai

ID	Ref.	Año	Tipo de dato	Entorno	Datasets	Etiquetas	Anomalía	Modelo	Resultado principal
S55	[71]	2026	Video/imágenes	autopista	HWID12 (Highway Incidents Detection)...	Benchmark anotado	Accidentes e incidentes	YOLOv9-t con backbone GELAN	YOLOv9-t+CSP: Precision=0.601, Recall=0.377, F1=0.463...
S56	[72]	2026	Video/imágenes	ambos	Conjunto de 3300 clips de video y...	Registros reales	Accidentes e incidentes	Framework híbrido RSU basado en extracción...	Accuracy=95.8 %; Precision=95.0 %; Recall=94.6 %...
S57	[73]	2026	Trayectorias	urbano	No especificado; se utilizan datos simulados...	Inyectadas o sintéticas	Conducción peligrosa	Personalized Lightweight Federated Learning...	Precision=89.3 %, Recall=84.7 %, ROC-AUC=0.921; PLFL...
S58	[74]	2026	Multimodal	ambos	Conjunto integrado de 12 586 muestras...	Registros reales	Conducción peligrosa	ADID+ (Anomaly Driving Intent Detection+)...	Tabla 1, p. 5: ADID+ obtiene F1 MCI 95,4 %, IOT 91,7...
S59	[75]	2026	Multimodal	urbano	TADS (Traffic Accident Detection Dataset...	Registros reales	Accidentes e incidentes	Modelo propuesto sin acrónimo específico	Modelo completo sobre TADS: micro AUC = 74,3 %, macro...
S60	[76]	2026	Video/imágenes	urbano	IITH Road Accident Dataset: videos de CCTV...	Benchmark anotado	Accidentes e incidentes	CVAE-ADS utiliza un Variational Autoencoder...	IITH: Accuracy 93,5 %, Precision 0,874, Recall 0,801...

ID	Ref.	Año	Tipo de dato	Entorno	Datasets	Etiquetas	Anomalía	Modelo	Resultado principal
S61	[77]	2026	Video/imágenes	ambos	TRAF, conjunto de videos de tráfico real...	Anotación manual	Conducción peligrosa	Multi-Speed Transformer adaptado al...	Multi-Speed Transformer con entrenamiento balanceado...
S62	[78]	2026	Multimodal	autopista	California PeMS, Estados Unidos. Periodo...	Pseudo-etiquetas	Congestión atípica	Arquitectura multi-head attention + LSTM...	Anomalías: texto de p. 7 reporta exactitud 99,46 %...
S63	[79]	2026	Sensores	autopista	Freeway Traffic Anomalous Event Detection...	Registros reales	Accidentes e incidentes	CCB-GraphGAN (Cycle-Consistent Bidirectional...	CCB-GraphGAN: AUC=0.73 y MSE=0.0061. Con FPR=5 %...
S64	[80]	2026	Video/imágenes	urbano	Dataset UIT-ADrone, utilizado para evaluar...	Benchmark anotado	Accidentes e incidentes	Sistema modular de dos etapas SBAF-CNN	Modelo SBAF-CNN: Detection Rate 98,00 %, Accuracy...
S65	[81]	2026	Sensores	autopista	Dataset principal de accidentes: 49...	Registros reales	Accidentes e incidentes	SWencoder propone una codificación Z basada...	Tabla 4, p. 23: Sparse-LSTM con codificación Z (S-Z)...

ID	Ref.	Año	Tipo de dato	Entorno	Datasets	Etiquetas	Anomalía	Modelo	Resultado principal
S66	[82]	2026	Video/imágenes	no especificado	Car Crash Dataset (CCD), introducido por...	Registros reales	Accidentes e incidentes	Detector LSTM de dos capas recurrentes...	Resultados detallados reportados para LSTM en la Tabla...
S67	[83]	2026	Video/imágenes	no especificado	Traffic-Net: 4420 imágenes JPG obtenidas de...	Registros reales	Accidentes e incidentes	TriNet-RTAD procesa cada imagen mediante...	Traffic-Net: TriNet-RTAD accuracy 96.18 %, precision...
S68	[84]	2026	Video/imágenes	no especificado	CarCrash: 105,000 fotogramas, 83,999 de...	Registros reales	Accidentes e incidentes	Framework de detección de accidentes en...	CarCrash: Accuracy=98.65 %, Precision=0.95...
S69	[85]	2026	Sensores	urbano	Open ITS Open Traffic Data Consortium...	Inyectadas o sintéticas	Congestión atípica	MS-NaN convierte el volumen vehicular en...	Mejor configuración principal DB-CGNet con Tw = 24...
S70	[86]	2026	Multimodal	autopista	VTAD-highway, conjunto elaborado por los...	Registros reales	Evento u otro	VTAD-FL	VTAD-FL: AP@50 = 89,05 %, AP@75 = 78,24 %, AP@90 =...
S71	[87]	2026	Video/imágenes	ambos	Car Crash Dataset (CCD): 1500 videos de...	Benchmark anotado	Accidentes e incidentes	ViT-B/16	CCD prueba, Caso 1: Swin Transformer con Stages 3-4...

ID	Ref.	Año	Tipo de dato	Entorno	Datasets	Etiquetas	Anomalía	Modelo	Resultado principal
S72	[88]	2026	Sensores	autopista	Dataset sintético generado con PTV Vissim...	Inyectadas o sintéticas	Accidentes e incidentes	Tres modelos independientes	Tabla 4, p. 10, resolución de 1 segundo: RC binario...

4.3. Calidad metodológica

La puntuación media fue 4.88 sobre 8 (desviación estándar 1.11; rango 1.0–7.0). El instrumento discrimina entre estudios, a diferencia de la versión anterior (Tabla 9). Los ítems con menor cumplimiento son la variabilidad entre ejecuciones (QA4: 8 estudios con Sí) y la disponibilidad de código y datos (QA5: 5), seguidos de la procedencia verificada de las etiquetas (QA1: 30). Los de mayor cumplimiento son las líneas base (QA3: 56) y el protocolo explícito (QA7: 47). 17 estudios alcanzan la calidad alta (≥ 6.0): S05, S10, S17, S18, S21, S24, S39, S40, S42, S44, S46, S47, S58, S60, S63, S68, S71.

Tabla 9: Evaluación de calidad por ítem y estudio (1 = Sí, 0.5 = Parcial, 0 = No).

ID	QA1	QA2	QA3	QA4	QA5	QA6	QA7	QA8	Total
S01	1	0.5	1	0.5	0	0.5	1	0.5	5.0
S02	1	0.5	0.5	0.5	0.5	0	1	0.5	4.5
S03	1	0.5	1	0	0.5	1	1	0	5.0
S04	0.5	0.5	0.5	0.5	0.5	1	1	1	5.5
S05	1	1	1	0.5	0.5	0	1	1	6.0
S06	1	0	0.5	0.5	0	0.5	1	0.5	4.0
S07	0.5	1	1	0	0.5	0.5	1	0.5	5.0
S08	0	0.5	1	0.5	0	1	0.5	0.5	4.0
S09	1	0.5	1	0	0.5	1	1	0.5	5.5
S10	1	1	1	1	0.5	0	1	1	6.5
S11	1	0.5	1	0.5	0	0.5	1	0.5	5.0
S12	0.5	0.5	1	0.5	0.5	0.5	1	1	5.5
S13	0	0.5	1	0	0	0.5	1	0	3.0
S14	0	0	1	1	0.5	0.5	1	0.5	4.5
S15	0.5	0	1	0	0.5	1	1	0.5	4.5
S16	0	0	1	0.5	0	0.5	1	0.5	3.5
S17	1	0.5	1	0.5	0.5	1	1	0.5	6.0
S18	1	1	1	0	0.5	1	1	0.5	6.0
S19	0.5	0.5	0.5	0	0	0.5	1	1	4.0
S20	0	0.5	1	0	0.5	0.5	1	0.5	4.0
S21	1	0.5	1	0.5	0	1	1	1	6.0
S22	1	0.5	1	0.5	0	0.5	1	1	5.5
S23	0.5	0.5	1	0.5	0.5	0.5	1	1	5.5
S24	1	0.5	1	0.5	0.5	1	1	0.5	6.0
S25	0.5	0.5	1	0	0.5	0	1	0.5	4.0
S26	0.5	0.5	1	0	0.5	0.5	1	0.5	4.5
S27	1	0.5	0.5	0	0.5	0.5	1	1	5.0
S28	0.5	1	1	0.5	0.5	0.5	1	0.5	5.5
S29	0.5	0.5	1	0.5	0.5	0	0.5	0	3.5
S30	0.5	0	1	0	0.5	0.5	0.5	0.5	3.5
S31	0	0	0.5	1	0	0.5	0.5	1	3.5
S32	0	0.5	1	0.5	0.5	0.5	0.5	0.5	4.0
S33	0	0	1	0	0	1	1	0.5	3.5

4.4. RQ1: Técnicas de *Deep Learning* y su relación con el tipo de dato

La Tabla 10 muestra la presencia de cada familia de arquitectura. Predominan las redes recurrentes (34 estudios), las convolucionales (43) y los mecanismos de atención o Transformer (34), seguidos de las redes de grafos (11), los autoencoders (13) y los modelos generativos (8). La mayoría de los estudios (36 de 72) combina dos o más familias, por lo que la clasificación en una sola familia, usada en la versión anterior, ocultaba esta composición. Se distingue entre modelos *híbridos*, que combinan arquitecturas, y *multimodales*, que integran varias modalidades de datos (11 estudios). Según el mecanismo de detección, 53 estudios clasifican de forma supervisada, 5 detectan por error de predicción y 14 por error de reconstrucción.

Tabla 10: Familias de arquitectura presentes en los estudios (RQ1).

Familia	**n**	**%**	**Estudios**
Recurrentes (LSTM, GRU, Bi-LSTM)	34	47 %	S02, S03, S04, S05, S09, S10, S13, S14, S15, S16, S18, S20, S21, S22, S23, S24, S27, S28, S29, S30, S32, S33, S34, S38, S40, S41, S46, S47, S50, S62, S65, S66, S69, S72
Convolucionales (CNN, TCN, 3D-CNN)	43	60 %	S01, S02, S03, S04, S08, S09, S17, S19, S22, S25, S26, S27, S28, S29, S30, S32, S36, S37, S39, S40, S42, S43, S44, S45, S46, S47, S49, S50, S52, S53, S55, S56, S57, S58, S60, S61, S64, S66, S67, S68, S70, S71, S72
Autoencoders y reconstrucción	13	18 %	S09, S11, S14, S15, S18, S20, S23, S31, S32, S47, S50, S60, S63
Grafos (GNN, GCN, GAT)	11	15 %	S12, S18, S31, S32, S36, S40, S48, S51, S57, S58, S63
Transformers y atención	34	47 %	S07, S12, S14, S17, S18, S22, S26, S27, S29, S34, S35, S39, S40, S42, S44, S45, S46, S47, S48, S49, S50, S51, S53, S54, S57, S58, S59, S61, S62, S63, S68, S69, S70, S71
Generativos (GAN, VAE, difusión)	8	11 %	S11, S14, S22, S23, S34, S47, S60, S63
Combinan dos o más familias (híbridos)	36	50 %	S02, S03, S04, S09, S12, S14, S17, S18, S20, S22, S23, S24

El cruce entre tipo de dato y familia (Tabla 11) muestra que la arquitectura depende sobre todo del dato disponible. En video, 26 de 29 estudios usan redes convolucionales, frecuentemente combinadas con redes recurrentes para la dimensión temporal (7), y ninguno usa grafos. Los 11 estudios con redes de grafos trabajan con sensores, movilidad agregada, trayectorias, datos multimodales o simulados, es decir, con datos que tienen una estructura de red vial explícita [28, 48, 67, 89]. Los autoencoders aparecen sobre todo cuando no hay etiquetas suficientes: con matrices origen-destino [48, 89], con trayectorias [50] o con video entrenado solo con datos normales [25].

Tabla 11: Cruce tipo de dato × familia de arquitectura (n.º de estudios).

	Rec.	**Conv.**	**AE**	**Grafo**	**Transf.**	**Gen.**	**Total**
Series de sensores	11	4	2	4	4	1	17
Movilidad agregada/OD	2	2	1	1	0	0	2
Trayectorias	9	2	6	3	6	4	13
Video e imágenes	7	26	3	0	15	2	29
Multimodal	5	9	1	3	9	1	11

Un estudio puede usar varias familias, por lo que las filas no suman el total.

El cruce por periodo (Tabla 12) sustenta la tendencia temporal con datos y no solo con impresiones. Ninguno de los 5 estudios de 2020–2021 usa atención o Transformers, mientras que 27 de los 46 estudios de 2024–2026 los incorporan. Las redes de grafos pasan de 0 estudio en 2020–2021 a 9 en 2024–2026. Las redes convolucionales y recurrentes siguen presentes en todos los periodos. Dado el tamaño del corpus, estas diferencias son descriptivas y no permiten inferir una tendencia estadística.

Tabla 12: Cruce periodo de publicación × familia de arquitectura.

	Rec.	**Conv.**	**AE**	**Grafo**	**Transf.**	**Gen.**	**Total**
2020–2021	4	4	0	0	0	0	5
2022–2023	12	7	7	2	7	4	21
2024–2026	18	32	6	9	27	4	46

2026 es parcial (búsqueda cerrada en la fecha indicada en la Sección 3.3).

Hallazgo

El tipo de dato condiciona la arquitectura: las redes convolucionales dominan en video y las de grafos solo aparecen cuando el dato tiene estructura de red vial. La

mayoría de los modelos son híbridos, y desde 2024 la atención o los Transformers están presentes en la mayoría de los estudios.

4.5. RQ2: Métricas y protocolos de evaluación

Métricas. La Tabla 13 muestra las métricas reportadas. La más frecuente es la *accuracy* (43 estudios), seguida de recall (63), AUC-ROC (52), precision (52) y F1-score (60). Solo 32 estudios reportan PR-AUC [30, 50], pese a ser más informativa que la AUC-ROC con clases desbalanceadas. Las métricas propias de la detección de incidentes (tasa de detección, tasa de falsas alarmas y tiempo medio de detección) aparecen en pocos estudios [17, 28, 37]. 22 estudios informan alguna métrica operativa (latencia, FPS, tiempo de inferencia o energía). Varios estudios usan definiciones no estándar: por ejemplo, Mao et al. [46] llaman *accuracy* a lo que corresponde a la precisión, y Park et al. [67] llaman *recall* a una fórmula de precisión.

Tabla 13: Métricas reportadas por los estudios (RQ2).

Métrica	**n**	**%**	**Estudios**
Accuracy	43	60 %	S02, S03, S04, S05, S10, S11, S12, S17, S19, S20, S21, S22, S25, S26, S27, S28, S29, S30, S33, S34, S36, S38, S40, S41, S43, S49, S50, S53, S54, S56, S58, S59, S60, S61, S62, S64, S65, S66, S67, S68, S70, S71, S72
Precision	52	72 %	S02, S03, S05, S07, S08, S10, S11, S14, S15, S16, S19, S20, S22, S23, S24, S25, S26, S29, S31, S32, S33, S34, S35, S36, S38, S40, S41, S43, S44, S45, S47, S48, S49, S50, S51, S53, S54, S55, S56, S57, S59, S60, S61, S62, S63, S64, S65, S67, S68, S69, S71, S72
Recall	63	88 %	S02, S03, S07, S08, S10, S11, S14, S15, S16, S17, S18, S19, S20, S21, S22, S23, S24, S25, S26, S27, S28, S29, S30, S31, S32, S33, S34, S35, S36, S37, S38, S39, S40, S41, S42, S43, S44, S45, S46, S47, S48, S49, S50, S51, S52, S54, S55, S56, S57, S58, S59, S60, S61, S62, S64, S65, S66, S67, S68, S69, S70, S71, S72
F1-score	60	83 %	S02, S04, S05, S07, S09, S10, S11, S14, S15, S16, S17, S18, S19, S20, S22, S23, S24, S25, S26, S27, S28, S29, S30, S31, S32, S33, S35, S36, S37, S38, S39, S40, S41, S42, S43, S44, S47, S48, S49, S50, S51, S52, S53, S54, S55, S56, S58, S59, S60, S61, S62, S64, S65, S66, S67, S68, S69, S70, S71, S72
AUC-ROC	52	72 %	S02, S05, S06, S07, S08, S09, S14, S15, S17, S18, S19, S20, S21, S22, S23, S24, S25, S27, S28, S29, S30, S31, S32, S35, S36, S37, S38, S39, S40, S41, S42, S43, S46, S47, S49, S50, S51, S53, S56, S57, S58, S59, S60, S61, S62, S63, S65, S66, S67, S69, S70, S72
PR-AUC	32	44 %	S03, S09, S15, S18, S19, S20, S22, S23, S27, S28, S29, S30, S34, S37, S39, S42, S43, S45, S48, S49, S50, S51, S52, S54, S59, S61, S65, S66, S67, S69, S70, S72
Tasa de detección (DR)	9	12 %	S01, S05, S10, S12, S13, S15, S41, S62, S64
FAR / FPR	34	47 %	S01, S05, S06, S10, S12, S13, S14, S15, S17, S19, S20, S21, S22, S27, S29, S35, S37, S39, S41, S43, S46, S49, S50, S51, S59, S61, S62, S63, S64, S65, S66, S67, S70, S72

Procedencia de las etiquetas. En detección de anomalías, el origen de las etiquetas de prueba condiciona el resultado tanto como el modelo. Solo 29 estudios evalúan con registros reales de incidentes y 9 con anotación manual propia (Tabla 14). 12 estudios evalúan únicamente con anomalías inyectadas o sintéticas [48, 50, 67, 89], 4 con pseudo-etiquetas generadas automáticamente (por ejemplo, con Isolation Forest o con un autoencoder previo) [56, 78, 90] y 2 sin etiquetas, contrastando sus detecciones con el consenso de otros detectores [91].

Tabla 14: Origen de las etiquetas de anomalía (RQ2, protocolo).

Origen de las etiquetas	**n**	**%**	**Estudios**
Registros reales de incidentes	29	40 %	S01, S04, S05, S06, S11, S12, S15, S21, S22, S25, S26, S29, S35, S36, S38, S40, S41, S44, S46, S53, S56, S58, S59, S63, S65, S66, S67, S68, S70
Anotación manual o experta	9	12 %	S02, S03, S07, S19, S24, S37, S43, S45, S61
Benchmark anotado por terceros	12	17 %	S09, S17, S27, S39, S42, S47, S49, S52, S55, S60, S64, S71
Anomalías inyectadas o sintéticas	12	17 %	S13, S14, S16, S20, S31, S32, S34, S48, S51, S57, S69, S72
Mixto o automático (pseudo-etiquetas)	4	6 %	S10, S28, S50, S62
Sin etiquetas	2	3 %	S18, S30
No reportado	4	6 %	S08, S23, S33, S54

Protocolo. La Tabla 15 muestra qué elementos del protocolo reporta cada estudio. Casi todos indican la unidad de evaluación (72 de 72) y la partición de los datos (53), aunque varios usan particiones aleatorias sobre series temporales, con riesgo de fuga de información (QA2). Del criterio de decisión, 48 estudios describen explícitamente cómo fijan el umbral y 24 usan clasificadores que deciden sin umbral explícito o evalúan con métricas independientes del umbral. En varios casos el umbral se ajusta sobre los mismos eventos etiquetados que se usan para evaluar [92] o sobre una parte del conjunto de prueba [30]. Solo 45 estudios reportan la proporción de anomalías en los datos de evaluación, un dato necesario para interpretar precision, F1 y PR-AUC.

Tabla 15: Elementos del protocolo de evaluación que reporta cada estudio (RQ2).

Elemento del protocolo reportado	**n**	**Estudios**
Tasa de anomalías en los datos	45	S01, S02, S04, S05, S06, S07, S09, S11, S13, S15, S16, S17, S18, S20, S22, S23, S24, S25, S26, S27, S28, S29, S30, S32, S34, S35, S37, S40, S41, S42, S44, S46, S47, S48, S56, S57, S58, S60, S61, S62, S66, S67, S68, S69, S71
Unidad de evaluación (punto, ventana, frame, evento…)	72	S01, S02, S03, S04, S05, S06, S07, S08, S09, S10, S11, S12, S13, S14, S15, S16, S17, S18, S19, S20, S21, S22, S23, S24, S25, S26, S27, S28, S29, S30, S31, S32, S33, S34, S35, S36, S37, S38, S39, S40, S41, S42, S43, S44, S45, S46, S47, S48, S49, S50, S51, S52, S53, S54, S55, S56, S57, S58, S59, S60, S61, S62, S63, S64, S65, S66, S67, S68, S69, S70, S71, S72
Criterio de umbral o decisión	72	S01, S02, S03, S04, S05, S06, S07, S08, S09, S10, S11, S12, S13, S14, S15, S16, S17, S18, S19, S20, S21, S22, S23, S24, S25, S26, S27, S28, S29, S30, S31, S32, S33, S34, S35, S36, S37, S38, S39, S40, S41, S42, S43, S44, S45, S46, S47, S48, S49, S50, S51, S52, S53, S54, S55, S56, S57, S58, S59, S60, S61, S62, S63, S64, S65, S66, S67, S68, S69, S70, S71, S72
Partición entrenamiento/prueba	53	S01, S02, S03, S05, S07, S09, S10, S12, S13, S14,

Desempeño sobre datasets compartidos. Ningún par de estudios comparte a la vez dataset, etiquetas y protocolo, lo que impide un metaanálisis. Dos casos ilustran el problema. Primero, cuatro estudios usan datos de PeMS (PEMS-BAY, METR-LA, PEMS04/08 o estaciones de PeMS), pero cada uno define las anomalías de forma distinta: pseudo-etiquetas de un autoencoder (F1 = 0,93 en PEMS-BAY) [90], registros de eventos combinados con patrones detectados automáticamente (F1 = 0,967) [56], ninguna etiqueta [91] y anomalías generadas con Isolation Forest al 1 % (F1 = 0,81) [78]. Las cifras no son comparables entre sí. Segundo, en NYC taxi con anomalías inyectadas, Hu et al. [89] obtienen AUC entre 0,84 y 0,90 con Con-GAE, mientras que Ren et al. [48] reportan AUC = 1,000 en todas las configuraciones, con un protocolo de inyección distinto. Un AUC perfecto con anomalías sintéticas sugiere que la tarea de evaluación es demasiado fácil y no que el problema esté resuelto.

Hallazgo

La comparabilidad entre estudios está limitada sobre todo por la procedencia de las etiquetas y por el protocolo, no por la arquitectura. Menos de un tercio de los estudios evalúa con etiquetas reales verificadas y pocos reportan la proporción de anomalías o la variabilidad entre ejecuciones.

4.6. RQ3: Tipos de anomalías

Según la categoría principal (Tabla 16), la más estudiada es accidentes e incidentes (43 estudios, 60 %), seguida de congestión o flujo anómalo (6, 8 %), trayectorias o conducción peligrosa (21, 29 %) y disrupciones y eventos extremos (2, 3 %). Si se cuentan también las categorías secundarias, los accidentes aparecen en 43 estudios y la congestión en 6. A diferencia de la versión anterior, cada estudio se asigna a una sola categoría principal, de modo que los porcentajes suman 100 %.

Tabla 16: Categorías de anomalía abordadas (RQ3).

Categoría	**n**	**%**	**Estudios (principal)**	**Secundaria**
Accidentes e incidentes	43	60 %	S01, S04, S05, S06, S07, S09, S10, S13, S17, S19, S21, S25, S26, S27, S29, S31, S35, S37, S38, S40, S41, S42, S43, S44, S45, S46, S47, S49, S51, S52, S53, S55, S56, S59, S60, S63, S64, S65, S66, S67, S68, S71, S72	—
Congestión o flujo anómalo	6	8 %	S08, S12, S30, S32, S62, S69	—
Trayectorias o conducción peligrosa	21	29 %	S02, S03, S11, S14, S15, S18, S20, S22, S23, S24, S28, S33, S34, S36, S39, S48, S50, S54, S57, S58, S61	—
Disrupciones y eventos extremos	2	3 %	S16, S70	—
Total	72	100 %		

El cruce con la familia de arquitectura (Tabla 17) refleja la relación con el tipo de dato. Los accidentes se estudian sobre todo con video y redes convolucionales. La congestión y las disrupciones se estudian con series de sensores, movilidad agregada o trayectorias, y con modelos recurrentes o de grafos. Las trayectorias peligrosas concentran los modelos generativos y de reconstrucción [30, 50].

Tabla 17: Cruce categoría principal de anomalía × familia de arquitectura.

	Rec.	**Conv.**	**AE**	**Grafo**	**Transf.**	**Gen.**	**Total**
Accidentes e incidentes	16	29	5	4	19	3	43
Congestión o flujo anómalo	4	3	1	2	3	0	6
Trayectorias o conducción peligrosa	13	10	7	5	11	5	21
Disrupciones y eventos extremos	1	1	0	0	1	0	2

Clasificación por categoría principal (una por estudio).

4.7. RQ4: Conjuntos de datos

La Tabla 18 agrupa los conjuntos de datos por tipo de dato. Los más reutilizados son los de PeMS (PEMS-BAY, METR-LA, PEMS04 y PEMS08) y los de taxis (NYC, Chicago, Porto y Chengdu). En video predominan los conjuntos específicos de cada estudio o de competiciones (TNAD, VAID, IITH, DoTA, TADS, HTA y AI City Challenge). 29 estudios usan exclusivamente datos no públicos y 11 usan datos simulados, en dos de ellos de forma exclusiva [30, 67]. Ninguno de los datasets de sensores más usados (PeMS) incluye etiquetas de anomalía verificadas, lo que explica el recurso a anomalías inyectadas o a pseudo-etiquetas.

Tabla 18: Tipo de dato y conjuntos de datos utilizados (RQ4).

Tipo de dato	**n**	**Estudios**	**Datasets**
Series de sensores	17	S01, S02, S05, S08, S10, S12, S13, S16, S21, S31, S38, S41, S51, S63, S65, S69, S72	13 intersecciones, 66. . . , 45 incidentes reales, 4136. . . , 59 accidentes en el área de. . . , Dataset de simulación. . . , Dataset principal de. . . , Dataset real de la Agencia. . . , Dataset real de tráfico de. . . , Dataset sintético generado. . . , Detectores de lazo de. . . , Detectores de microondas de. . . , El artículo declara datos. . . , FT-AED, Freeway Traffic Anomalous. . . , I-880 traffic incident. . . , MnDOT / Regional. . . , Odense, Open ITS Open Traffic Data. . . , PeMS I-80, California, SUMO, Safety Pilot Model. . . , cada día contiene 480. . . , datos históricos de. . . , el número exacto de. . . , escenario sintético de red. . . , frecuencia de muestreo de. . . , más de 3.7 millones de. . . , no debe confundirse con el. . . , no se indican las fechas. . . , nombre público no reportado, país de la red simulada no. . . , series sintéticas derivadas. . . , velocidad y longitud). Los. . .
Movilidad agregada/OD	2	S30, S32	Dataset real de monitoreo. . . , NYC Taxi Trips, publicado. . . , el artículo declara un. . . , se selecciona un subgrafo. . .
Trayectorias	13	S03, S11, S14, S15, S18, S20, S23, S24, S33, S34, S48, S54, S57	21,339 taxis, junio de 2013, Chengdu 2124763. . . , Chengdu, China. . . , Datasets de trayectorias. . . , Didi Chuxing privado, Dos

4.8. RQ5: Limitaciones reportadas

La limitación más declarada es la generalización a otros escenarios (34 estudios), seguida del etiquetado de anomalías (16), el costo computacional y de despliegue (29) y el uso de datos propios o de acceso limitado (22; Tabla 19). Llama la atención lo que los autores casi no declaran: solo 6 estudio menciona la falta de comparabilidad de las métricas y solo 4 la interpretabilidad, aunque ambas aparecen como problemas en esta síntesis (Sección 5).

Tabla 19: Limitaciones reportadas por los estudios primarios (RQ5).

Limitación declarada por los autores	**n**	**%**	**Estudios**
Datos propios o de acceso limitado	22	31 %	S02, S05, S13, S14, S19, S20, S29, S30, S31, S32, S33, S40, S41, S44, S46, S54, S55, S56, S57, S59, S64, S69
Etiquetado de anomalías	16	22 %	S02, S06, S08, S11, S16, S17, S18, S30, S31, S34, S41, S50, S51, S55, S63, S71
Generalización a otros escenarios	34	47 %	S02, S05, S13, S15, S18, S21, S23, S24, S25, S26, S27, S29, S36, S37, S41, S42, S45, S47, S49, S50, S52, S53, S56, S58, S60, S62, S63, S66, S67, S68, S69, S70, S71, S72
Métricas no comparables	6	8 %	S26, S29, S41, S49, S56, S66
Costo computacional y despliegue	29	40 %	S02, S08, S09, S12, S17, S21, S22, S29, S35, S36, S37, S38, S40, S41, S43, S44, S45, S46, S47, S53, S57, S60, S61, S62, S64, S66, S68, S70, S72
Interpretabilidad	4	6 %	S22, S32, S62, S67
Sin limitaciones declaradas	9	12 %	S01, S03, S04, S07, S10, S28, S39, S48, S65

Un estudio puede declarar varias limitaciones.

4.9. RQ6: Líneas base y ventaja reportada

Todos los estudios comparan su propuesta con alguna línea base, pero con alcance desigual (Tabla 20). 40 estudios incluyen al menos una línea base que no es DL

(estadística, de aprendizaje automático convencional o basada en reglas), lo que permite valorar el aporte del DL frente a alternativas más simples. En otros casos, la comparación se limita a ablaciones del propio modelo [93, 94], a cifras copiadas de artículos con otros datos [78] o a un componente auxiliar y no a la detección [95]. Las ventajas reportadas frente a la mejor línea base suelen ser moderadas (de 1 a 6 puntos porcentuales en la métrica principal) cuando la comparación es con modelos recientes bajo el mismo protocolo [56, 67, 75, 90], y mayores en algunos casos, como +0,15 de AUC frente a redes de grafos genéricas [89] o $\approx$+17 puntos de F1 frente a métodos de umbral [92]. Hay resultados desfavorables que los estudios reportan, pero no destacan: con ventanas cortas, Autoformer supera al modelo propuesto por Park et al. [67], y el FPR de Chakraborty et al. [30] es peor que el de su mejor línea base. Fuera del corpus, Taheri Sarteshnizi et al. [96] evalúan detectores de DL sobre datos reales de volumen vehicular con etiquetas expertas y encuentran que un método simple basado en distancias supera a todos ellos (F1 = 0,676 frente a 0,278 del mejor detector profundo). Este estudio se excluyó por CE-4, pero es relevante para valorar la ventaja del DL.

Tabla 20: Líneas base y ventaja frente a la mejor de ellas (RQ6).

ID	Líneas base	No DL	Ventaja frente a la mejor línea base
S01	4: LSTM, DBN, CNN, GBDT	Sí	+2.01 puntos de DR frente a DBN (96.41 %); FAR...
S02	LSTM independiente como único modelo comparativo con...	No	Mejora absoluta de 11,532 puntos porcentuales en...
S03	4: iBOAT, SAE, GM-VSAE, SD-VSAE	Sí	+0.1599 PR-AUC frente a SD-VSAE en Porto; +0.0989...
S04	Variantes internas de arquitectura y segmentación; sin...	Sí	No reportada frente a detector externo
S05	KNN-SVM; FDL; WT-LR; GAN-SVM; TSA-SVM; RF-RFE-LSTM...	Sí	El método propuesto obtiene Accuracy=98.07 % y...
S06	Chen et al. (2016); Ren et al. (2016); Arceda y Riveros...	Sí	TP-r=98.5 % frente a 96.8 % de Chen et al. y 94.6 %...
S07	5: Luo et al., Liu et al., Sultani et al., Zhu et al., Lv...	No	+2.07 puntos de AUC frente a Lv et al. en TAD...
S08	CNN mejorada de Javed et al. (referencia 31) y un método...	Sí	Con el 100 % de los datos, las Figuras 2-4...
S09	Stacked Autoencoder de Singh y Mohan en IITH (tabla 2)...	No	En IITH, AUC 79 % frente a 77 % de Stacked...
S10	3: Random Forest, KNN-SVM ensemble, LSTM convencional	Sí	-0.04 FAR y -0.06 DR frente a LSTM convencional
S11	LOF, iForest, OC-SVM, TPRRO, AE, OT-AD y OS-AD	Sí	F1=0.905 frente a 0.767 del AE (NS=100; 20 %...

ID	Líneas base	No DL	Ventaja frente a la mejor línea base
S12	LOF, IFOREST, OCSVM, HBOS, COPOD, LSTM-VAE, MAD-GAN	Sí	+10 puntos porcentuales de accuracy frente a…
S13	SVM y Random Forest, comparados con LSTM en el mismo…	Sí	Para incidentes inferiores a 6 minutos, LSTM…
S14	Baselines: CVM (modelo de velocidad constante, no…	Sí	Frente a STGAE-KDE, el mejor baseline profundo de…
S15	Cinco métodos comparativos de la Tabla 1 y Tabla 2: HMM…	Sí	Frente al mejor comparador por ROC-AUC, Dist-RNN…
S16	3: DeepAnt; Telemon; BreakoutDetection	Sí	Aproximadamente +10 puntos porcentuales de F1…
S17	DoTA, Tabla 3, p. 8, localización: ConvAE con escala de…	Sí	DoTA localización, Tabla 3, p. 8: TempoLearn AUC…
S18	LTI (Linear Temporal Interpolation), CVM (Constant Velocity…	Sí	En detección individual del escenario combinado…
S19	Comparación directa entre algoritmo A (YOLOv5 con cajas…	No	ResNet-34 modificada C supera a YOLOv5 +…
S20	Cinco baselines explícitos de detección de anomalías: LCSS…	Sí	Frente al mejor baseline por F1, ATD-RNN, RETAD…
S21	Comparaciones de detección sobre el mismo tramo con CNN…	Sí	Tabla 3, p. 616, a 18 minutos: LSTM TPR 0,705…
S22	Tres baselines principales: CNN-LSTM conditional GAN con…	No	No se puede calcular una mejora porcentual…
S23	6: DTW, Hausdorff, KNN, Deep Clustering, SAE, GM-VSAE	Sí	+0.047 F1 frente a Hausdorff; +0.072 PR-AUC…

ID	Líneas base	No DL	Ventaja frente a la mejor línea base
S24	Siete métodos comparativos implementados para la tarea…	Sí	Tabla III: frente a CTSS, mejor línea base en F1…
S25	Detector CNN convencional sobre imágenes CCTV, comparado…	No	Frente al detector CNN convencional, 95,87 % −…
S26	DCNN/DNN, LSTMDTR y ViT-TA, comparados en curvas de pérdida…	No	Exactitud de validación 0,96 frente a DCNN/DNN…
S27	Comparación cuantitativa con DenseNet-Transformer RGB Only…	No	Frente a DenseNet-Transformer RGB Only, la mejor…
S28	Comparación interna entre LSTM-HT, LSTM-CNN y LSTM-LSTM…	Sí	Para la segunda etapa agresiva/inatenta, LSTM-HT…
S29	Seis configuraciones comparadas: R3D, R3D + LSTM, R3D +…	No	Para Road accidents, DRN + Bi-LSTM obtiene 89.30 %…
S30	Stacked Autoencoder (SAE), CNN-LSTM, Bidirectional LSTM…	Sí	En City-precision, Traffic-ConvLSTM obtiene…
S31	DONE, AdOne, AnomalyDAE y DOMINANT se comparan directamente…	No	DONE obtiene ROC-AUC de 0,98 frente a 0,81 de…
S32	Comparadores principales de las Tablas 1-2 (p. 10): HA…	Sí	En NYC, con $\alpha = 50\,\%$ y $\beta = 10\,\%$, MTGAE obtiene AUC…
S33	MAM, ConvGRU, ST-LSTM, SR-LSTM y CNN-BiGRU; comparados…	No	En Chengdu con todas las características, DF-GRN…
S34	Seis métodos comparativos en sección 7.1 y Tabla 2 (pp.…	Sí	Los autores reportan una mejora relativa promedio…
S35	Parallel LSTM-CNN; LSTM; CNN; XGBoost; Time-Embedded…	Sí	El ensemble mejora el Recall respecto al…

ID	Líneas base	No DL	Ventaja frente a la mejor línea base
S36	La Tabla 4 (p. 22) compara GNN-RMNet con DenseNet, ResNet...	Sí	GNN-RMNet obtiene accuracy 98 % frente a 95 % del...
S37	YOLOv9c y YOLOv10 son líneas base profundas entrenadas y...	No	Frente a YOLOv9, YOLOv11 mejora recall de 0,8209...
S38	STG-RGCN AE, STG-GAT AE, GCN-LSTM AE, GCN AE, Transformer...	No	La Tabla 2 informa AUC-ROC de 0.9607 para el LSTM...
S39	Comparadores de detección: TEVAD, MGFN, VadCLIP, ANDT y...	No	En UIT-ADrone, MMVAD obtiene 69,56 % AUC frente...
S40	AGC-LSTM; AttentionDeepST; variantes sin HGNN, sin atención...	Sí	MHGNN-CPLE supera a AGC-LSTM y AttentionDeepST en...
S41	VRT (Video Recognition Technology), 3D-CNN, Wavelet...	Sí	En AUC, IRF-HTID-BO-LSTM obtiene 0,982 frente a...
S42	Tabla 3, página 9: DSA, ACRA, AdaLEA, UString, DSTA, GSC...	No	En DAD, frente a THAT-NET, mejor AP de la Tabla 3...
S43	YOLOv8n, YOLOv8s y YOLOv8m se comparan experimentalmente...	No	Respecto de YOLOv8s en las configuraciones...
S44	DETR, Faster R-CNN, YOLOv5n, YOLOv8n y YOLO11	Sí	mAP50-95=66.0 % frente a 59.7 % de YOLO11...
S45	Seis modelos de detección comparados experimentalmente...	No	Frente a YOLOv13n, DSGF-YOLO mejora mAP50 de...
S46	ConvAE; ConvLSTMAE; AnoPred; FOL-STD; FOL-Ensemble; DMMNet...	Sí	En DoTA, MAMTCF alcanza AUC=76.6 % frente a...
S47	Conv-AE, MemAE, MNAD-P, MNAD-R, HF2VAD, ASTNET, ADA-VAD...	No	En 4M-TAD, el mejor AUC entre los métodos...

ID	Líneas base	No DL	Ventaja frente a la mejor línea base
S48	SAE (Sequence Autoencoder), VSAE (Variational Sequence...	No	Frente al mejor baseline por métrica y escenario...
S49	No reportados para la evaluación experimental propia — La...	No	No calculable — No existe tabla de comparación de...
S50	RF (Random Forest), XGBoost, FCDNN, 1D-CNN y LSTM; todos se...	Sí	Para giros bruscos, el mejor F1 de los baselines...
S51	LSTM, GRU, Transformer, Informer y Autoformer; cinco...	No	Comparación del recall promedio de GMRT con el...
S52	YOLOv4, SSD y Faster R-CNN evaluados sobre HWID12 (tabla 6...	No	Tabla 6, p. 981: mAP 96,91 % frente a YOLOv4...
S53	Qwen-VL (7B), MiniGPT4-Video (7B), GLM4-V (9B), VideoLLaVA...	No	Frente al mejor comparador en accuracy...
S54	6: Naive Bayes, Decision Tree, Random Forest, SVM, KNN...	Sí	+0.02 AUC frente a Naive Bayes (0.96); +0.05 F1...
S55	YOLOv9-t; YOLOv9-s; YOLOv5-s; YOLOv5-n; YOLOv8-n; YOLO26n...	No	Frente al mejor baseline externo por mAP50...
S56	CNN-only basada en características espaciales; Motion-only...	Sí	El framework híbrido supera a CNN-only...
S57	Centralized MGTGCN; Federated Learning FedAvg; Personalized...	Sí	PLFL mejora ADE frente a FedAvg de 2.35 m a 1.98...
S58	LSTM, TSA-Transformer y Dual-TF son comparadores...	Sí	Frente al mejor comparador de la Tabla 1...
S59	Seis configuraciones de referencia en TADS, Tabla 1, p. 13...	No	Micro AUC: 74,3 % frente a 68,6 % de RF-RG = +5,7...

ID	Líneas base	No DL	Ventaja frente a la mejor línea base
S60	IITH y UCF-Crime se comparan con métodos publicados como...	Sí	En la comparación bibliográfica de la tabla 6...
S61	Random Forest, clasificador tradicional basado en árboles...	Sí	Respecto del mejor baseline directamente...
S62	La Tabla 1 (p. 8) compara resultados publicados de Djenouri...	No	Sin mejora cuantitativa directamente comparable...
S63	Cinco modelos de referencia de Deep Learning: STG-RGCN AE...	No	Frente al mejor baseline en AUC, GCN AE con 0.70...
S64	Baselines de clasificación: CNN convencional, RNN, LSTM y...	Sí	Frente a CNN convencional en la Tabla 5, p. 16...
S65	Baselines directamente comparables de detección de...	No	Frente al mejor baseline de exactitud V-Z, S-Z...
S66	SVM, CNN-only y CNN-LSTM, evaluados con las mismas...	Sí	El LSTM propuesto supera a CNN-only en F1 por...
S67	Comparación experimental directa con ResNet50, ResNet101 y...	No	En Traffic-Net, el mejor baseline por accuracy es...
S68	ViT-B/16 individual y EfficientNet-B0 individual como...	Sí	El ensamble obtuvo F1=0.96 en CarCrash y CADP...
S69	Ocho arquitecturas neuronales de comparación bajo...	Sí	Con Tw = 24, DB-CGNet supera al mejor F1 de los...
S70	RetinaNet, EfficientDet, Deformable DETR, BEiT3...	No	Frente al competidor más fuerte FM-FSOD, VTAD-FL...
S71	Comparación entre ViT-B/16, Swin Transformer y ResNet-50...	No	En CCD Caso 1, Swin Stages 3-4 supera a ResNet-50...

ID	Líneas base	No DL	Ventaja frente a la mejor línea base
S72	CNN-1D y TCN son los dos comparadores experimentales del...	No	A 1 segundo, RC frente a TCN obtiene igual F1...

Análisis de sensibilidad por calidad. Restringida a los 17 estudios de calidad alta (S05, S10, S17, S18, S21, S24, S39, S40, S42, S44, S46, S47, S58, S60, S63, S68, S71), la síntesis mantiene sus conclusiones principales: 11 de ellos son híbridos y la arquitectura sigue el tipo de dato. Sin embargo, solo 15 evalúan con etiquetas reales o anotadas, de modo que la escasez de etiquetas verificadas afecta también a los mejores estudios del corpus.

5. Discusión

5.1. Interpretación de los hallazgos y contraste con revisiones previas

El dato antes que el modelo. El hallazgo principal es que la familia de arquitectura se explica mejor por el tipo de dato que por el tipo de anomalía. Las revisiones previas trataban por separado el video [3, 8], las trayectorias [10] y las series de sensores [1], por lo que no podían observar esta relación. Al integrarlos, esta revisión muestra que no existe una arquitectura dominante para el problema en general: las redes convolucionales son la opción natural cuando la anomalía es visible en la imagen, las de grafos cuando el dato tiene estructura de red y los autoencoders cuando faltan etiquetas. Este resultado coincide con la observación de Darban et al. [7] para series temporales genéricas: la idoneidad de un detector depende de la estructura de los datos y del tipo de anomalía, no de su complejidad.

Hibridación y atención. La hibridación es la norma y no la excepción, y la atención o los Transformers se han generalizado desde 2024. Djenouri et al. [1] y Zhang et al. [2] reportaban un campo dominado por métodos estadísticos y de minería de datos, por lo que el cambio hacia modelos profundos híbridos es claro. Sin embargo, la evidencia de que esta complejidad mejore la detección en condiciones reales es limitada: las ventajas frente a líneas base recientes son moderadas, y Taheri Sarteshnizi et al. [96] encuentran que, con etiquetas reales, métodos simples pueden superar a los profundos.

Etiquetas y protocolo. La aportación más específica de esta revisión es mostrar que la comparabilidad depende de la procedencia de las etiquetas y del protocolo. Ninguna de las revisiones previas analiza estos aspectos de forma estructurada. Que un mismo dataset (PeMS) se use con cuatro definiciones distintas de anomalía, y que con anomalías inyectadas se obtengan AUC perfectos, indica que las cifras de desempeño publicadas no pueden ordenarse en un ranking. Esto coincide con la crítica de Darban et al. [7] sobre los benchmarks de series temporales y con las recomendaciones REFORMS para estudios de aprendizaje automático [16].

Alcance de las conclusiones. Los estudios incluidos aplican DL con resultados favorables en escenarios controlados, pero con validación limitada en contextos reales: 11 usan datos simulados, 18 no evalúan con etiquetas reales y solo 20 validan en más de un escenario independiente. Por tanto, no se puede afirmar que el DL haya alcanzado madurez operativa para la detección de anomalías de tráfico.

5.2. Implicaciones para sistemas inteligentes de transporte

Para un operador de tráfico, la elección del modelo debería partir del dato disponible: video en intersecciones y túneles, detectores en autopistas, trayectorias de flotas en redes urbanas. Antes de adoptar un modelo publicado, conviene verificar con qué etiquetas se evaluó, con qué proporción de anomalías y con qué unidad de evaluación, porque un F1 obtenido con anomalías inyectadas no anticipa el desempeño con incidentes reales. Las métricas operativas (latencia, tiempo medio de detección, tasa de falsas alarmas por hora) se reportan poco y son las que determinan el valor práctico de una alerta.

5.3. Brechas y agenda de investigación

(1) **Benchmarks con etiquetas verificadas.** Solo 30 estudios evalúan con etiquetas reales verificadas. Se necesitan conjuntos de datos públicos de sensores y trayectorias con incidentes registrados por operadores, en la línea de AnoLT [96].

(2) **Reporte mínimo del protocolo.** Se propone reportar siempre la procedencia de las etiquetas, la proporción de anomalías, la unidad de evaluación, el criterio de umbral, la partición temporal y la variabilidad entre ejecuciones, junto con PR-AUC cuando las clases estén desbalanceadas.

(3) **Validación externa.** Pocos estudios evalúan en más de una ciudad o vía. La transferencia entre ciudades y la adaptación de dominio siguen sin evaluarse sistemáticamente.

(4) **Reproducibilidad.** Solo 11 estudios publican su código. La publicación de código y datos debería acompañar a los resultados.

(5) **Interpretabilidad.** Casi ningún estudio la aborda ni la declara como limitación, pese a que los operadores necesitan entender el origen de una alerta.

5.4. Amenazas a la validez

Validez de construcción (búsqueda). La cadena no fue validada por un especialista en información externo. Para mitigarlo, se validó con un conjunto de control (19 de 72 estudios recuperados por la cadena definitiva). Dos estudios solo se recuperan con búsqueda en texto completo, lo que indica que pueden existir otros estudios relevantes

que no mencionan DL en el resumen. La revisión se limita a cinco bases y no incluye literatura gris ni *preprints*, lo que excluye trabajos recientes aún no publicados. Además, solo se incluyen estudios de acceso abierto: esto garantiza que cualquier lector pueda verificar la extracción, pero deja fuera estudios relevantes publicados bajo suscripción, y la proporción de acceso abierto varía entre editoriales y países, por lo que el corpus puede no representar por igual a toda la literatura.

Validez interna (selección y extracción). La versión anterior de la revisión aplicó los criterios de forma no uniforme: incluyó un *preprint* como excepción y estudios sin evaluación cuantitativa de la detección. En esta versión los criterios se aplicaron a todos los estudios y los casos límite se documentan en el Anexo C. La principal amenaza de esta versión es que la selección, la extracción y la evaluación de calidad las realizó un solo revisor, lo que PRISMA y AMSTAR 2 consideran un riesgo de sesgo de selección. Se mitigó con criterios operativos aplicados en orden fijo, exclusiones a texto completo respaldadas por citas, un asistente de cribado basado en reglas cuyo acuerdo con el revisor se reporta, y un re-cribado ciego para medir la consistencia intra-revisor (Sección 3). Estas medidas no sustituyen a un segundo revisor independiente. La extracción se verificó contra el texto completo, y durante esa verificación se encontraron errores en las fichas iniciales (fichas duplicadas, categorías y datasets mal asignados), que se corrigieron.

Validez externa. El corpus es pequeño (72 estudios), está concentrado en datos de China y Estados Unidos y se limita a estudios en inglés. El año 2026 es parcial. Las proporciones deben interpretarse como descripción del corpus y no como estimaciones de la literatura completa.

Validez de conclusión. La heterogeneidad de tareas, datos, etiquetas y protocolos impide el metaanálisis y la valoración formal de la certeza de la evidencia. Por ello, las conclusiones sobre la ventaja del DL se formulan con prudencia. Varios estudios presentan inconsistencias internas entre texto y tablas, registradas en la matriz de extracción, que reducen la confianza en sus resultados numéricos.

6. Conclusiones

Esta revisión sistemática analizó 72 estudios (2020–2026) que aplican *Deep Learning* a la detección de anomalías en tráfico vehicular urbano y de autopista a partir de sensores, trayectorias, movilidad agregada y video.

RQ1. Predominan las redes recurrentes, convolucionales y de atención, casi siempre combinadas en modelos híbridos. La familia de arquitectura sigue al tipo de dato:

convolucionales en video, grafos en datos con estructura de red y autoencoders cuando faltan etiquetas. Desde 2024 la atención y los Transformers están presentes en la mayoría de los estudios.

RQ2. Las métricas más usadas son *accuracy*, recall, AUC-ROC, precision y F1, con definiciones a veces no estándar. El principal obstáculo para comparar estudios es el protocolo: la procedencia de las etiquetas (reales, inyectadas o pseudo-etiquetas), la proporción de anomalías y el criterio de umbral varían entre estudios y a menudo no se reportan.

RQ3. Las anomalías más estudiadas son los accidentes e incidentes (60 %), seguidos de la congestión o flujo anómalo, las trayectorias peligrosas y las disrupciones.

RQ4. Los datasets más reutilizados (PeMS y taxis) carecen de etiquetas de anomalía verificadas. En video predominan conjuntos específicos de cada estudio, y una parte del corpus depende de datos simulados o no públicos.

RQ5. Los autores declaran sobre todo problemas de generalización, etiquetado y costo computacional. Casi ninguno declara la falta de comparabilidad de las métricas o la interpretabilidad.

RQ6. Todos los estudios comparan con líneas base, pero solo 40 de 72 incluyen una alternativa no profunda y varios se limitan a ablaciones o a cifras de otros artículos. Las ventajas frente a modelos recientes son moderadas.

Como implicación práctica, la elección del modelo debería partir del dato disponible y de cómo se evaluó el modelo, no solo de la cifra de desempeño reportada. Como trabajo futuro se proponen benchmarks públicos con etiquetas verificadas, un reporte mínimo del protocolo de evaluación y la validación entre ciudades.

Declaraciones

Registro y protocolo: protocolo registrado en **[OSF, DOI 10.17605/OSF.IO/XXXXX]**. La lista de verificación PRISMA 2020 se presenta en el Anexo D.

Disponibilidad de datos y código: la matriz de extracción, la evaluación de calidad por ítem y estudio, las cadenas de búsqueda, la planilla de cribado y los scripts que generan todas las cifras (`generar_conteos.py` y `prueba_sensibilidad_cadena.py`) están disponibles en `https://github.com/ClaudioB12/rsl-wilbert`.

Conflicto de intereses: el autor declara no tener conflicto de intereses.

Financiamiento: esta investigación no recibió financiamiento externo.

Uso de inteligencia artificial generativa: el autor utilizó Claude (Anthropic) como asistente para verificar la extracción de datos contra los textos completos, proponer una decisión justificada para cada registro en el cribado por título y resumen, proponer los puntajes de calidad con su evidencia, elaborar los scripts de deduplicación, cribado

asistido y conteo, y revisar la redacción. Todas las decisiones de inclusión, los puntajes y el texto fueron revisados y validados por el autor, que asume la responsabilidad del trabajo.

Contribuciones (CRediT): Mayta Arotaype, W. A.: conceptualización, metodología, búsqueda, selección de estudios, curación de datos, análisis formal, visualización y redacción.

Referencias

[1] Y. Djenouri, A. Belhadi, J. C.-W. Lin, D. Djenouri, and A. Cano, "A survey on urban traffic anomalies detection algorithms," *IEEE Access*, vol. 7, pp. 12 192–12 205, 2019.

[2] M. Zhang, T. Li, Y. Yu, Y. Li, P. Hui, and Y. Zheng, "Urban anomaly analytics: Description, detection, and prediction," *IEEE Transactions on Big Data*, vol. 8, no. 3, pp. 809–826, 2022, publicado en línea en 2020.

[3] K. K. Santhosh, D. P. Dogra, and P. P. Roy, "Anomaly detection in road traffic using visual surveillance: A survey," *ACM Computing Surveys*, vol. 53, no. 6, 2020.

[4] O. ElSahly and A. Abdelfatah, "A systematic review of traffic incident detection algorithms," *Sustainability*, vol. 14, no. 22, p. 14859, 2022.

[5] A. Razi, X. Chen, H. Li, H. Wang, B. Russo, Y. Chen, and H. Yu, "Deep learning serves traffic safety analysis: A forward-looking review," *IET Intelligent Transport Systems*, vol. 17, no. 1, pp. 22–71, 2023.

[6] S. Olugbade, S. Ojo, A. L. Imoize, J. Isabona, and M. O. Alaba, "A review of artificial intelligence and machine learning for incident detectors in road transport systems," *Mathematical and Computational Applications*, vol. 27, no. 5, p. 77, 2022.

[7] Z. Zamanzadeh Darban, G. I. Webb, S. Pan, C. C. Aggarwal, and M. Salehi, "Deep learning for time series anomaly detection: A survey," *ACM Computing Surveys*, vol. 57, no. 1, 2024.

[8] J. Fang, J. Qiao, J. Xue, and Z. Li, "Vision-based traffic accident detection and anticipation: A survey," *IEEE Transactions on Circuits and Systems for Video Technology*, vol. 34, no. 4, pp. 1983–1999, 2024.

[9] R. Lin, T. Tang, Y. Liu, W. Zhou, X. Yang, H. Zheng, J. Lin, and Y. Zhang, "Deep learning advances in vision-based traffic accident anticipation: A comprehensive review of methods, datasets, and future directions," arXiv preprint arXiv:2505.07611, 2025.

[10] A. Belhadi, Y. Djenouri, J. C.-W. Lin, and A. Cano, "Trajectory outlier detection: Algorithms, taxonomies, evaluation, and open challenges," *ACM Transactions on Management Information Systems*, vol. 11, no. 3, pp. 1–29, 2020.

[11] G. Alinezhad Noghre, A. Danesh Pazho, and H. Tabkhi, "A survey on video anomaly detection via deep learning: Human, vehicle, and environment," arXiv preprint arXiv:2508.14203, 2025.

[12] B. Kitchenham and S. Charters, "Guidelines for performing systematic literature reviews in software engineering," Keele University and Durham University Joint Report, Tech. Rep. EBSE 2007-001, 2007.

[13] M. J. Page, J. E. McKenzie, P. M. Bossuyt, I. Boutron, T. C. Hoffmann, C. D. Mulrow *et al.*, "The PRISMA 2020 statement: an updated guideline for reporting systematic reviews," *BMJ*, vol. 372, p. n71, 2021.

[14] M. L. Rethlefsen, S. Kirtley, S. Waffenschmidt, A. P. Ayala, D. Moher, M. J. Page, J. B. Koffel, and PRISMA-S Group, "PRISMA-S: an extension to the PRISMA statement for reporting literature searches in systematic reviews," *Systematic Reviews*, vol. 10, p. 39, 2021.

[15] J. Cohen, "A coefficient of agreement for nominal scales," *Educational and Psychological Measurement*, vol. 20, no. 1, pp. 37–46, 1960.

[16] S. Kapoor, E. M. Cantrell, K. Peng, T. H. Pham, C. A. Bail, O. E. Gundersen *et al.*, "REFORMS: Consensus-based recommendations for machine-learning-based science," *Science Advances*, vol. 10, no. 18, p. eadk3452, 2024.

[17] Y. Fang, Q. Yang, L. Zheng, X. Zhou, and B. Peng, "A deep cycle limit learning machine method for urban expressway traffic incident detection," *Mathematical Problems in Engineering*, vol. 2020, p. 5965089, 2020.

[18] S. Jia, F. Hui, S. Li, X. Zhao, and A. J. Khattak, "Long short-term memory and convolutional neural network for abnormal driving behaviour recognition," *IET Intelligent Transport Systems*, 2020.

[19] H. Wang, J. Feng, L. Sun, K. An, G. Liu, X. Wen, R. Hu, and H. Chai, "Abnormal trajectory detection based on geospatial consistent modeling," *IEEE Access*, 2020.

[20] S. Robles-Serrano, G. Sanchez-Torres, and J. Branch-Bedoya, "Automatic detection of traffic accidents from video using deep learning techniques," *Computers*, 2021.

[21] Q. Shang, L. Feng, and S. Gao, "A hybrid method for traffic incident detection using random forest-recursive feature elimination and long short-term memory network with bayesian optimization algorithm," *IEEE Access*, 2021.

[22] S. Bakheet and A. Al-Hamadi, "A deep neural framework for real-time vehicular accident detection based on motion temporal templates," *Heliyon*, 2022.

[23] J. Chen, J. Wang, J. Pu, and R. Zhang, "A three-stage anomaly detection framework for traffic videos," *JOURNAL OF ADVANCED TRANSPORTATION*, 2022.

[24] Y. Djenouri, A. Belhadi, H.-C. Chen, and J. C.-W. Lin, "Intelligent deep fusion network for urban traffic flow anomaly identification," *Computer Communications*, 2022.

[25] K. Pawar and V. Attar, "Deep learning based detection and localization of road accidents from traffic surveillance videos," *ICT Express*, vol. 8, no. 3, pp. 379–387, 2022.

[26] Y. Sun, T. Mallick, P. Balaprakash, and J. Macfarlane, "A data-centric weak supervised learning for highway traffic incident detection," *Accident Analysis and Prevention*, 2022.

[27] W. Yu and Q. Huang, "A deep encoder-decoder network for anomaly detection in driving trajectory behavior under spatio-temporal context," *INTERNATIONAL JOURNAL OF APPLIED EARTH OBSERVATION AND GEOINFORMATION*, 2022.

[28] H. Zhang, S. Zhao, R. Liu, W. Wang, Y. Hong, and R. Hu, "Automatic traffic anomaly detection on the road network with spatial-temporal graph neural network representation learning," *Wireless Communications and Mobile Computing*, vol. 2022, p. 4222827, 2022.

[29] M. Ayou, Y. Trardi, L. Chakir, and J. Boumhidi, "Data-driven traffic incident detection in urban roads based on machine learning algorithms," in *E3S Web of Conferences*, 2023.

[30] N. Chakraborty, A. Hasan, S. Liu, T. Ji, W. Liang, D. L. McPherson, and K. Driggs-Campbell, "Structural attention-based recurrent variational

autoencoder for highway vehicle anomaly detection," in *Proceedings of the 22nd International Conference on Autonomous Agents and Multiagent Systems (AAMAS 2023)*. IFAAMAS, 2023, pp. 1125–1134. [Online]. Available: https://www.ifaamas.org/Proceedings/aamas2023/pdfs/p1125.pdf

[31] Y. Cheng and M. Li, "Pattern anomaly detection based on sequence-to-sequence regularity learning," *Tehnicki Vjesnik*, 2023.

[32] D. He, J. Kim, H. Shi, and B. Ruan, "Autonomous anomaly detection on traffic flow time series with reinforcement learning," *Transportation Research Part C: Emerging Technologies*, 2023.

[33] S. S. Htun, J. S. Park, K.-W. Lee, and J.-H. Han, "Tempolearn network: Leveraging spatio-temporal learning for traffic accident detection," *IEEE Access*, 2023.

[34] Y. Hu, Y. Zhang, Y. Wang, and D. Work, "Detecting socially abnormal highway driving behaviors via recurrent graph attention networks," in *ACM Web Conference 2023 - Proceedings of the World Wide Web Conference, WWW 2023*, 2023.

[35] S. Lee, S. Lee, J. Noh, J. Kim, and H. Jeong, "Special traffic event detection: Framework, dataset generation, and deep neural network perspectives," *Sensors*, 2023.

[36] C. Li, G. Feng, Y. Jia, Y. Li, J. Ji, and Q. Miao, "Retad: Vehicle trajectory anomaly detection based on reconstruction error," *International Journal of Data Warehousing and Mining*, 2023.

[37] P. Mehrannia, S. S. G. Bagi, B. Moshiri, and O. A. Al-Basir, "Deep representation of imbalanced spatio-temporal traffic flow data for traffic accident detection," *IET Intelligent Transport Systems*, vol. 17, no. 3, pp. 606–619, 2023.

[38] Y. Qiu, T. Misu, and C. Busso, "Unsupervised scalable multimodal driving anomaly detection," *IEEE Transactions on Intelligent Vehicles*, 2023.

[39] L. Zhang, W. Lu, F. Xue, and Y. Chang, "A trajectory outlier detection method based on variational auto-encoder," *Mathematical Biosciences and Engineering*, 2023.

[40] Q. Zhang, Z. Wang, C. Long, C. Huang, S.-M. Yiu, Y. Liu, G. Cong, and J. Shi, "Online anomalous subtrajectory detection on road networks with deep reinforcement learning," in *Proceedings - International Conference on Data Engineering*, 2023.

[41] Y. Zhang and Y. Sung, "Traffic accident detection method using trajectory tracking and influence maps," *Mathematics*, 2023.

[42] ——, "Traffic accident detection using background subtraction and cnn encoder–transformer decoder in video frames," *Mathematics*, 2023.

[43] V. A. Adewopo and N. Elsayed, "Smart city transportation: Deep learning ensemble approach for traffic accident detection," *IEEE Access*, 2024.

[44] F. Barreno, M. Santos, and M. Romana, "Driving behaviour estimation system considering the effect of road geometry by means of deep nn and hotelling transform," *Electronics (Switzerland)*, 2024.

[45] Y. Lu, W. Chen, Z. Yu, J. Wang, and C. Yang, "Vehicle abnormal behavior detection based on dense block and soft thresholding," *Computers, Materials & Continua*, vol. 79, no. 3, pp. 5051–5066, 2024.

[46] Y. Mao, Y. Shi, and B. Lu, "Detecting urban traffic anomalies using traffic-monitoring data," *ISPRS International Journal of Geo-Information*, vol. 13, no. 10, p. 351, 2024.

[47] A. Michielsen, M. Rahimiasl, Y. Vanderhoydonc, and S. Mercelis, "History-based road traffic anomaly detection using deep learning and real-world data," in *International Conference on Vehicle Technology and Intelligent Transport Systems, VEHITS - Proceedings*, 2024.

[48] Z. Ren, X. Li, J. Peng, K. Chen, Q. Tan, X. Wu, and C. Shi, "Graph autoencoder with mirror temporal convolutional networks for traffic anomaly detection," *Scientific Reports*, vol. 14, p. 1247, 2024.

[49] G. Shen, J. Wang, X. Kong, Z. Ji, B. Zhu, and T. Qiu, "Deformation gated recurrent network for lane-level abnormal driving behavior recognition," *ACM Transactions on Spatial Algorithms and Systems*, 2024.

[50] C. Wang, L. Chen, S. Shang, C. S. Jensen, and P. Kalnis, "Multi-scale detection of anomalous spatio-temporal trajectories in evolving trajectory datasets," in *Proceedings of the 30th ACM SIGKDD Conference on Knowledge Discovery and Data Mining (KDD '24)*. ACM, 2024, pp. 2980–2990.

[51] M. J. Ahsan, M. Abdel-Aty, B. M. T. H. Anik, and Z. Islam, "An ensemble time-embedded transformer model for traffic conflict prediction at rrfb pedestrian crossings," *Transportation Engineering*, 2025.

[52] E. A. Aldhahri, A. A. Almazroi, M. H. Alkinani, M. Alqarni, E. A. Alghamdi, and N. Ayub, "Gnn-rmnet: Leveraging graph neural networks and gps analytics for driver behavior and route optimization in logistics," *PLOS ONE*, 2025.

[53] M. S. Arefin, M. I. S. Mahin, and F. A. Mily, "Real-time rapid accident detection for optimizing road safety in bangladesh," *Heliyon*, 2025.

[54] I. Aslam and S. Mahfuz, "Enhancing freeway safety: Lstm-based detection of traffic anomalies," in *Procedia Computer Science*, 2025.

[55] D. Biswas and J. Tesic, "Mmvad: A vision–language model for cross-domain video anomaly detection with contrastive learning and scale-adaptive frame segmentation," *Expert Systems with Applications*, 2025.

[56] M. Duan, S. Sun, and M. Liu, "A multimodal deep fusion framework for highway traffic anomaly detection," *Scientific Reports*, vol. 15, p. 33573, 2025.

[57] X. Gu and S. Dai, "Irf-htid-bo-lstm: Classification model of curve shape index for mountainous highways and intelligent traffic incident detection method," *Informatica (Slovenia)*, 2025.

[58] Y. Guan, H. Liao, C. Wang, B. Wang, J. Zhang, J. Hu, and Z. Li, "Domain-enhanced dual-branch model for efficient and interpretable accident anticipation," *Communications in Transportation Research*, 2025.

[59] Q. N. Huy Minh, N. N. Dinh, L. V. Ho, and C. P. Huu, "Real-time traffic accident detection using yolov8," in *Transportation Research Procedia*, 2025.

[60] W. Li, L. Huang, and X. Lai, "A deep learning framework for traffic accident detection based on improved yolo11," *Vehicles*, 2025.

[61] W. Li, H. Xie, and P. Lin, "Dsgf-yolo: A lightweight deep neural network for traffic accident detection and severity classifications," *Vehicles*, 2025.

[62] R. Liang, Y. Li, Y. Yi, J. Zhou, and X. Li, "A memory-augmented multi-task collaborative framework for unsupervised traffic anomaly detection in driving videos," *Pattern Recognition*, 2025.

[63] H. Liu, X. Hu, G. Sun, W. Zhang, J. Zhan, H. Fang, Y. Li, and W. Ma, "Intelligent traffic accident detection system in complex dynamic scenarios based on the dual-stream spatiotemporal-fusion model," *Engineering Applications of Artificial Intelligence*, 2025.

[64] J. Mbuya, D. Pfoser, and A. Anastasopoulos, "Graph enhanced trajectory anomaly detection," in *33rd ACM SIGSPATIAL International Conference on Advances in Geographic Information Systems, ACM SIGSPATIAL 2025*, 2025.

[65] Nallapula *et al.*, "Road incident detection system," in *Proceedings of the 2025 14th International Conference on Software and Computer Applications (ICSCA 2025)*. ACM, 2025, pp. 67–71.

[66] M. A. Onsu, M. Simsek, M. Fobert, and B. Kantarci, "Intelligent multi-sensor fusion and anomaly detection in vehicles via deep learning," *Internet of Things*, 2025.

[67] D. Park, S.-S. Choi, D. Lim, and Y.-S. Kang, "Graph multi-resolution transformer for road traffic anomaly detection," *IEEE Access*, vol. 13, pp. 27 428–27 437, 2025.

[68] Y. Said, Y. Alassaf, R. Ghodbani, T. Saidani, and O. Ben Rhaiem, "Deep learning-driven pattern recognition for real-time traffic incident detection in complex urban environments," *TRAITEMENT DU SIGNAL*, 2025.

[69] Z. Wang, H. Yu, C. Chen, Z. Cui, Y. Bi, Y. Ren, Z. Wang, D. Kong, J. Tian, S. Yuan, and Z. Li, "Motif: An end-to-end multimodal road traffic scene understanding foundation model," *Communications in Transportation Research*, 2025.

[70] Y. Wu and J. Wang, "Abnormal vehicle toll evasion detection based on an improved transformer," in *ACM conference proceedings (verificar en el PDF)*. ACM, 2025.

[71] S. Ahmed, T. Tabassum, M. C. Das, U. Hussain, and V. Pham, "Backbone-level enhancements in yolov9 for traffic accident detection from video footage," *Electronics (Switzerland)*, 2026.

[72] D. Ather and M. Talipov, "An efficient computer vision framework for rsu-based accident recognition and v2x communication," *Mathematical Models in Engineering*, 2026.

[73] S. Bano and I. Kashif, "A personalized federated learning framework for post-event forensic traffic analysis in autonomous vehicle systems," *Journal of Computing and Biomedical Informatics*, 2026.

[74] W. Ben, B. Li, and G. Yin, "Recognition of surrounding vehicle anomalous intent in the vehicle-road-cloud environment for autonomous driving," *Chinese Journal of Mechanical Engineering*, 2026.

[75] Y. Chai and W. Silamu, "Road traffic anomaly detection by human-attention-assisted text–vision learning," *Sensors*, vol. 26, no. 9, p. 2638, 2026.

[76] A. Chauhan and S. Vegad, "Cvae-ads: A deep learning framework for traffic accident detection and video summarization," *Journal of Electronics, Electromedical Engineering, and Medical Informatics*, 2026.

[77] V. Dentamaro, L. Di Maggio, S. Galantucci, D. Impedovo, and G. Pirlo, "Safety in smart cities—automatic recognition of dangerous driving styles," *Information (Switzerland)*, 2026.

[78] P. Jadhav, A. Benslimane, D. R. Vora, and S. Patil, "Multi-stage classification of abnormal traffic events using a multi-head + LSTM," *Scientific Reports*, vol. 16, p. 1516, 2026.

[79] M. Nouri and M. Ilbeigi, "Early detection of freeway traffic anomalies with a cycle-consistent bidirectional generative adversarial network," *IEEE Access*, 2026.

[80] R. K. Patra, S. Bhattacharya, M. R. Mahmood, N. K. Kar, P. Dubey, R. Raja, and S. Agrawal, "Suspicious detection in road traffic based on kd-slic-k-means and sbaf-cnn using aerial view surveillance video," *Scientific Reports*, 2026.

[81] C. Pu and L. Du, "Swencoder: a succinct shockwave diagram encoding and interpretable deep learning model design to enhance learning efficiency and assurance," *Transportation Research Part C: Emerging Technologies*, 2026.

[82] H. Saini, D. K. Saini, and S. Johari, "Intelligent surveillance system for accident detection using machine learning," *Transportation Research Interdisciplinary Perspectives*, 2026.

[83] G. Sathish and S. Murali, "Trinet-rtad: An efficient ensemble-based deep cnn framework for road traffic anomaly detection," *Array*, 2026.

[84] Z. Seghir, L. Guezouli, K. Barka, D. E. Boubiche, H. Toral-Cruz, and R. Martínez-Peláez, "A real-time consensus-free accident detection framework for internet of vehicles using vision transformer and efficientnet," *AI (Switzerland)*, 2026.

[85] L. Wang, C. Kang, Y. Qiu, Y. Shang, X. Wang, and Q. Yu, "Traffic-prior-guided state-aware framework for robust urban traffic anomaly detection," *Urban Science*, 2026.

[86] H. Wei, Y. Yang, K. Guo, Y. Bu, X. Song, H. Liang, S. Sun, H. Hu, R. Wang, and N. Akhtar, "Traffic anomaly detection by fusing spatiotemporal graphs and visual

perception," *International Journal of Transportation Science and Technology*, 2026.

[87] C.-C. Wu and W.-C. Chen, "Feasibility analysis of static-image-based traffic accident detection under domain shift for edge-ai surveillance systems," *Electronics (Switzerland)*, 2026.

[88] A. Zaitouny, A. Krishnan, M. Sherif, H. Abdul-Rahman, A. Albalushi, S. Alakbari, R. Alsada, R. Alkalbani, S. Al Ghailani, and A. R. Masoud, "Simulation-based early detection and classification of severity of traffic incident using deep learning and dynamical reservoir features," *Transportation Research Interdisciplinary Perspectives*, 2026.

[89] Y. Hu, A. Qu, and D. Work, "Detecting extreme traffic events via a context augmented graph autoencoder," *ACM Transactions on Intelligent Systems and Technology*, vol. 13, no. 6, p. 101, 2022.

[90] W. Abdallah and M. Alghamdi, "AIP-Urban: Edge-enabled deep learning framework for predictive maintenance and anomaly detection in urban traffic infrastructure," *Systems*, vol. 13, no. 12, p. 1117, 2025.

[91] X. Jia, J. Qu, Y. Lyu, M. Guo, J. Zhang, and F. Guo, "A prediction-based anomaly detection method for traffic flow data with multi-domain feature extraction," *Applied Sciences*, vol. 15, no. 6, p. 3234, 2025.

[92] S. Cai, T. Wu, J. Mao, and C. Jin, "Road closure detection based upon multi-feature fusion," in *Proceedings of the 29th International Conference on Advances in Geographic Information Systems (SIGSPATIAL '21)*. ACM, 2021, pp. 354–364.

[93] X. Huang, P. He, A. Rangarajan, and S. Ranka, "Intelligent intersection: Two-stream convolutional networks for real-time near-accident detection in traffic video," *ACM Transactions on Spatial Algorithms and Systems*, vol. 6, no. 2, p. 10, 2020.

[94] S. W. Khan, Q. Hafeez, M. I. Khalid, R. Alroobaea, S. Hussain, J. Iqbal, J. Almotiri, and S. S. Ullah, "Anomaly detection in traffic surveillance videos using deep learning," *Sensors*, vol. 22, no. 17, p. 6563, 2022.

[95] L. Zhao, Z. Fu, J. Yang, Z. Zhao, and P. Wang, "Multi-adjacent camera-based dangerous driving trajectory recognition for ultra-long highways," *Applied Sciences*, vol. 14, no. 11, p. 4593, 2024.

[96] I. Taheri Sarteshnizi, M. Sarvi, S. Asadi Bagloee, and N. Nassir, "On the applicability of time series anomaly detection methods to real-world traffic volume data," *Transportation Research Part C: Emerging Technologies*, vol. 184, p. 105536, 2026.

[97] M. Nouri and M. Ilbeigi, "A self-imputing deep multitask sequence model for traffic disruption detection in extreme conditions," *IEEE Access*, vol. 13, pp. 165 873–165 886, 2025.

[98] D. Feng, M. Liang, and G. Wang, "A traffic anomaly detection and identification approach based on multi-instance learning," in *The 2nd International Conference on Computing and Data Science (CONF-CDS 2021)*. ACM, 2021.

[99] H. Choudhary and M. Hassani, "Autoencoder-based continual outlier correlation detection for real-time traffic flow prediction," in *Proceedings of the 39th ACM/SIGAPP Symposium on Applied Computing (SAC '24)*. ACM, 2024, pp. 218–220.

[100] F. I. Giasemis and A. Sopasakis, "Learning traffic anomalies from generative models on real-time observations," arXiv preprint arXiv:2502.01391, 2025.

A. Protocolo de revisión

Cadena de búsqueda por base de datos

Las cadenas se reproducen literalmente. Los filtros de año, tipo de documento e idioma se aplicaron con las opciones de la interfaz en Web of Science y ScienceDirect, y con un script sobre los metadatos exportados en Scopus, IEEE Xplore y ACM (Tabla 4).

Scopus (búsqueda avanzada)

```
TITLE-ABS-KEY ( ( anomal* OR abnormal* OR "outlier detection" OR "incident
 detection" OR "accident detection" OR "accident prediction" OR "accident
 anticipation" OR "road closure*" OR "dangerous driving" OR "near-accident*"
 OR "near-miss*" OR "extreme event*" ) AND ( "deep learning" OR "deep neural"
 OR "neural network*" OR lstm OR gru OR cnn OR convolutional OR autoencoder*
 OR transformer* OR "graph neural" OR "self-attention" OR "attention
 mechanism" ) AND ( "road traffic" OR "urban traffic" OR "vehicular traffic"
 OR "highway traffic" OR "freeway traffic" OR "expressway traffic" OR "traffic
 flow*" OR "traffic speed" OR "traffic volume*" OR "traffic data" OR "traffic
 monitoring" OR "traffic video*" OR "traffic surveillance" OR "traffic
 camera*" OR "traffic scene*" OR "traffic scenario*" OR "traffic event*" OR
 "traffic incident*" OR "traffic accident*" OR "traffic anomal*" OR "traffic
 congestion" OR "road accident*" OR "road closure*" OR "intelligent
 transportation" OR "transportation network*" OR "road network*" OR "vehicle
 trajector*" OR "vehicle behavio*" OR "driving behavio*" OR taxi* ) ) AND
```

```
 PUBYEAR > 2019 AND PUBYEAR < 2027 AND ( LIMIT-TO ( DOCTYPE , "ar" ) OR
 LIMIT-TO ( DOCTYPE , "cp" ) ) AND ( LIMIT-TO ( LANGUAGE , "English" ) OR
 LIMIT-TO ( LANGUAGE , "Spanish" ) )
```

Web of Science Core Collection (TS = título, resumen, palabras clave y Keywords Plus)

```
TS=((anomal* OR abnormal* OR "outlier detection" OR "incident detection" OR
 "accident detection" OR "accident prediction" OR "accident anticipation" OR
 "road closure*" OR "dangerous driving" OR "near-accident*" OR "near-miss*" OR
 "extreme event*") AND ("deep learning" OR "deep neural" OR "neural network*"
 OR LSTM OR GRU OR CNN OR convolutional OR autoencoder* OR transformer* OR
 "graph neural" OR "self-attention" OR "attention mechanism") AND ("road
 traffic" OR "urban traffic" OR "vehicular traffic" OR "highway traffic" OR
 "freeway traffic" OR "expressway traffic" OR "traffic flow*" OR "traffic
 speed" OR "traffic volume*" OR "traffic data" OR "traffic monitoring" OR
 "traffic video*" OR "traffic surveillance" OR "traffic camera*" OR "traffic
 scene*" OR "traffic scenario*" OR "traffic event*" OR "traffic incident*" OR
 "traffic accident*" OR "traffic anomal*" OR "traffic congestion" OR "road
 accident*" OR "road closure*" OR "intelligent transportation" OR
 "transportation network*" OR "road network*" OR "vehicle trajector*" OR
 "vehicle behavio*" OR "driving behavio*" OR taxi*))
Filtros (panel izquierdo): Publication Years 2020-2026; Document Types:
 Article, Proceeding Paper; Languages: English, Spanish.
```

IEEE Xplore (Command Search, *All Metadata*; máximo 25 términos por consulta)

```
Consulta 1: ("All Metadata":anomal* OR "All Metadata":abnormal* OR "All
 Metadata":"incident detection" OR "All Metadata":"accident detection" OR "All
 Metadata":"accident prediction" OR "All Metadata":"road closure" OR "All
 Metadata":"dangerous driving" OR "All Metadata":"near-miss" OR "All
 Metadata":"extreme event") AND ("All Metadata":"deep learning" OR "All
 Metadata":"neural network" OR "All Metadata":LSTM OR "All Metadata":CNN OR
 "All Metadata":convolutional OR "All Metadata":autoencoder OR "All
 Metadata":transformer OR "All Metadata":"graph neural") AND ("All
 Metadata":"road traffic" OR "All Metadata":"urban traffic" OR "All
 Metadata":"highway traffic" OR "All Metadata":"traffic flow" OR "All
 Metadata":"traffic video" OR "All Metadata":"traffic surveillance" OR "All
 Metadata":"traffic incident" OR "All Metadata":"traffic accident")
Consulta 2: ("All Metadata":anomal* OR "All Metadata":abnormal* OR "All
 Metadata":"incident detection" OR "All Metadata":"accident detection" OR "All
 Metadata":"accident prediction" OR "All Metadata":"road closure" OR "All
 Metadata":"dangerous driving" OR "All Metadata":"near-miss" OR "All
 Metadata":"extreme event") AND ("All Metadata":"deep learning" OR "All
 Metadata":"neural network" OR "All Metadata":LSTM OR "All Metadata":CNN OR
 "All Metadata":convolutional OR "All Metadata":autoencoder OR "All
 Metadata":transformer OR "All Metadata":"graph neural") AND ("All
 Metadata":"traffic anomaly" OR "All Metadata":"traffic congestion" OR "All
 Metadata":"traffic data" OR "All Metadata":"traffic monitoring" OR "All
```

```
 Metadata":"intelligent transportation" OR "All Metadata":"road network" OR
 "All Metadata":"vehicle trajectory" OR "All Metadata":"driving behavior")
Consulta 3: ("All Metadata":anomal* OR "All Metadata":abnormal* OR "All
 Metadata":"incident detection" OR "All Metadata":"accident detection" OR "All
 Metadata":"accident prediction" OR "All Metadata":"road closure" OR "All
 Metadata":"dangerous driving" OR "All Metadata":"near-miss" OR "All
 Metadata":"extreme event") AND ("All Metadata":"deep learning" OR "All
 Metadata":"neural network" OR "All Metadata":LSTM OR "All Metadata":CNN OR
 "All Metadata":convolutional OR "All Metadata":autoencoder OR "All
 Metadata":transformer OR "All Metadata":"graph neural") AND ("All
 Metadata":"vehicular traffic" OR "All Metadata":"freeway traffic" OR "All
 Metadata":"traffic speed" OR "All Metadata":"traffic volume" OR "All
 Metadata":"traffic scene" OR "All Metadata":"traffic event" OR "All
 Metadata":"road accident" OR "All Metadata":taxi)
Filtros: Year 2020-2026; Content Type: Journals, Conferences.
```

ScienceDirect (título, resumen y palabras clave; máximo 8 operadores, sin comodines)

```
Consulta 1: ("anomaly detection" OR "incident detection" OR "accident
 detection") AND ("deep learning" OR "neural network") AND ("road traffic" OR
 "urban traffic" OR "traffic flow")
Consulta 2: ("anomaly detection" OR "incident detection" OR "accident
 detection") AND ("deep learning" OR "neural network") AND ("traffic video" OR
 "traffic surveillance" OR "traffic accident")
Consulta 3: ("anomaly detection" OR "incident detection" OR "accident
 detection") AND ("deep learning" OR "neural network") AND ("traffic incident"
 OR "traffic congestion" OR "intelligent transportation")
Consulta 4: ("anomaly detection" OR "incident detection" OR "accident
 detection") AND ("deep learning" OR "neural network") AND ("vehicle
 trajectory" OR "road network" OR "highway traffic")
Consulta 5: ("abnormal" OR "anomalous") AND ("deep learning" OR "neural
 network") AND ("road traffic" OR "traffic flow" OR "vehicle trajectory")
Filtros: Years 2020-2026; Article type: Research articles.
```

ACM Digital Library (campo Abstract)

```
[[Abstract: anomal*] OR [Abstract: abnormal*] OR [Abstract: "outlier
 detection"] OR [Abstract: "incident detection"] OR [Abstract: "accident
 detection"] OR [Abstract: "accident prediction"] OR [Abstract: "road
 closure*"] OR [Abstract: "dangerous driving"] OR [Abstract: "near-accident*"]
 OR [Abstract: "near-miss*"] OR [Abstract: "extreme event*"]] AND [[Abstract:
 "deep learning"] OR [Abstract: "deep neural"] OR [Abstract: "neural
 network*"] OR [Abstract: lstm] OR [Abstract: gru] OR [Abstract: cnn] OR
 [Abstract: convolutional] OR [Abstract: autoencoder*] OR [Abstract:
 transformer*] OR [Abstract: "graph neural"] OR [Abstract: "attention
 mechanism"]] AND [[Abstract: "road traffic"] OR [Abstract: "urban traffic"]
 OR [Abstract: "vehicular traffic"] OR [Abstract: "highway traffic"] OR
 [Abstract: "freeway traffic"] OR [Abstract: "traffic flow*"] OR [Abstract:
```

```
"traffic speed"] OR [Abstract: "traffic volume*"] OR [Abstract: "traffic
data"] OR [Abstract: "traffic monitoring"] OR [Abstract: "traffic video*"] OR
[Abstract: "traffic surveillance"] OR [Abstract: "traffic camera*"] OR
[Abstract: "traffic scene*"] OR [Abstract: "traffic event*"] OR [Abstract:
"traffic incident*"] OR [Abstract: "traffic accident*"] OR [Abstract:
"traffic anomal*"] OR [Abstract: "traffic congestion"] OR [Abstract: "road
accident*"] OR [Abstract: "intelligent transportation"] OR [Abstract: "road
network*"] OR [Abstract: "vehicle trajector*"] OR [Abstract: "driving
behavio*"] OR [Abstract: taxi*]] AND [E-Publication Date: (01/01/2020 TO
12/31/2026)]
Filtros: Content type: Research Article.
```

Historial del protocolo

Tabla 21: Historial de versiones del protocolo.

Versión	Fecha	Cambio
V1.0	[fecha]	Definición del tema, preguntas de investigación y PICOC.
V1.1	[fecha]	Cadenas por base (seis fuentes, incluidas MDPI y Taylor & Francis).
V1.2	[fecha]	Cribado y eliminación de duplicados en Parsif.al.
V1.3	[fecha]	Evaluación de calidad (instrumento de 6 ítems) y extracción; 25 estudios.
V2.1	[fecha]	Bloque C de la cadena acotado a frases ancladas al tráfico vial (se retiran *vehicle**, *highway**, *freeway**, *expressway** y *outlier** sueltos) para reducir el ruido; la recuperación del conjunto de control se mantiene (19 de 21).
V2.0	[fecha]	Respuesta a la revisión: alcance ampliado a video y autopistas; cinco bases (se añade IEEE Xplore y se retiran MDPI y Taylor & Francis por ser editoriales); cadena validada con un conjunto de control; regla general para *preprints* (CE-5); CI-5 y CI-6 precisados; nuevo instrumento de calidad de 8 ítems; nueva RQ6; cribado por un revisor con asistente basado en reglas y re-cribado ciego.

B. Estudios incluidos

Tabla 22: Estudios incluidos con su identificador en la versión anterior, DOI y base de recuperación.

ID	ID v1	Ref.	Autores	Año	Editorial	DOI	Base de recuperación
S01	R0049	[17]	Fang et al.	2020	Mathematical Problems in Engineering	10.1155/2020/5965089	Scopus, Web of Science
S02	R0637	[18]	Jia et al.	2020	IET Intelligent Transport Systems	10.1049/iet-its.2019.0200	Scopus, Web of Science
S03	R0024	[19]	Wang et al.	2020	IEEE Access	10.1109/access.2020.3028847	Scopus, Web of Science
S04	R0239	[20]	Robles-Serrano et al.	2021	Computers	10.3390/computers10110148	Scopus, Web of Science
S05	R0080	[21]	Shang et al.	2021	IEEE Access	10.1109/access.2020.3047340	Scopus, Web of Science, IEEE Xplore
S06	R0052	[22]	Bakheet et al.	2022	Heliyon	10.1016/j.heliyon.2022.e11397	ScienceDirect
S07	R0221	[23]	Chen et al.	2022	JOURNAL OF ADVANCED TRANSPORTATION	10.1155/2022/9463559	Web of Science
S08	R0596	[24]	Djenouri et al.	2022	Computer Communications	10.1016/j.comcom.2022.03.021	ScienceDirect
S09	R0341	[25]	Pawar et al.	2022	ICT Express	10.1016/j.icte.2021.11.004	ScienceDirect

ID	ID v1	Ref.	Autores	Año	Editorial	DOI	Base de recuperación
S10	R0045	[26]	Sun et al.	2022	Accident Analysis and Prevention	10.1016/j.aap.2022.106779	Scopus, Web of Science, ScienceDirect
S11	R0050	[27]	Yu et al.	2022	INTERNATIONAL JOURNAL OF APPLIED EARTH...	10.1016/j.jag.2022.103115	Web of Science
S12	R0243	[28]	Zhang et al.	2022	Wireless Communications and Mobile...	10.1155/2022/4222827	Scopus, Web of Science
S13	R0329	[29]	Ayou et al.	2023	E3S Web of Conferences	10.1051/e3sconf/202346900102	Scopus
S14	R1082	[30]	Chakraborty et al.	2023	Proceedings of the International Joint...	Sin DOI (actas IFAAMAS)	Scopus, ACM Digital Library
S15	R0721	[31]	Cheng et al.	2023	Tehnicki Vjesnik	10.17559/tv-20230325000479	Scopus, Web of Science
S16	R0244	[32]	He et al.	2023	Transportation Research Part C...	10.1016/j.trc.2023.104089	ScienceDirect
S17	R1100	[33]	Htun et al.	2023	IEEE Access	10.1109/access.2023.3343410	Scopus, Web of Science
S18	R0379	[34]	Hu et al.	2023	ACM Web Conference 2023 - Proceedings...	10.1145/3543507.3583452	Scopus, ACM Digital Library

ID	ID v1	Ref.	Autores	Año	Editorial	DOI	Base de recuperación
S19	R1074	[35]	Lee et al.	2023	Sensors	10.3390/s23198129	Scopus, Web of Science
S20	R1000	[36]	Li et al.	2023	International Journal of Data...	10.4018/ijdwm.316460	Scopus, Web of Science
S21	R0356	[37]	Mehrannia et al.	2023	IET Intelligent Transport Systems	10.1049/itr2.12287	Scopus, Web of Science
S22	R1202	[38]	Qiu et al.	2023	IEEE Transactions on Intelligent...	10.1109/tiv.2022.3160861	Scopus
S23	R0227	[39]	Zhang et al.	2023	Mathematical Biosciences and Engineering	10.3934/mbe.2023675	Scopus
S24	R0702	[40]	Zhang et al.	2023	Proceedings - International Conference...	10.1109/icde55515.2023.00026	Scopus
S25	R1137	[41]	Zhang et al.	2023	Mathematics	10.3390/math11071743	Scopus, Web of Science
S26	R1138	[42]	Zhang et al.	2023	Mathematics	10.3390/math11132884	Scopus, Web of Science
S27	R1052	[43]	Adewopo et al.	2024	IEEE Access	10.1109/access.2024.3387972	Scopus, Web of Science, IEEE Xplore
S28	R0428	[44]	Barreno et al.	2024	Electronics (Switzerland)	10.3390/electronics13030637	Scopus

ID	ID v1	Ref.	Autores	Año	Editorial	DOI	Base de recuperación
S29	R1214	[45]	Lu et al.	2024	Computers, Materials and Continua	10.32604/cmc.2024.050865	ScienceDirect
S30	R0380	[46]	Mao et al.	2024	ISPRS International Journal of...	10.3390/ijgi13100351	Scopus, Web of Science
S31	R0561	[47]	Michielsen et al.	2024	International Conference on Vehicle...	10.5220/0012565500003702	Scopus
S32	R0539	[48]	Ren et al.	2024	Scientific Reports	10.1038/s41598-024-51374-3	Scopus, Web of Science
S33	R0360	[49]	Shen et al.	2024	ACM Transactions on Spatial Algorithms...	10.1145/3635141	ACM Digital Library
S34	R0674	[50]	Wang et al.	2024	No reportado	10.1145/3637528.3671874	ACM Digital Library
S35	R0121	[51]	Ahsan et al.	2025	Transportation Engineering	10.1016/j.treng.2025.100318	ScienceDirect
S36	R0537	[52]	Aldhahri et al.	2025	PLOS ONE	10.1371/journal.pone.0328899	Scopus, Web of Science
S37	R0938	[53]	Arefin et al.	2025	Heliyon	10.1016/j.heliyon.2025.e42432	ScienceDirect
S38	R0465	[54]	Aslam et al.	2025	Procedia Computer Science	10.1016/j.procs.2025.07.188	Scopus, ScienceDirect

ID	ID v1	Ref.	Autores	Año	Editorial	DOI	Base de recuperación
S39	R0658	[55]	Biswas et al.	2025	Expert Systems with Applications	10.1016/j.eswa.2025.127857	ScienceDirect
S40	R0102	[56]	Duan et al.	2025	Scientific Reports	10.1038/s41598-025-18671-x	Scopus, Web of Science
S41	R0615	[57]	Gu et al.	2025	Informatica (Slovenia)	10.31449/inf.v49i11.7449	Scopus
S42	R0403	[58]	Guan et al.	2025	Communications in Transportation...	10.1016/j.commtr.2025.100214	ScienceDirect
S43	R0943	[59]	Huy Minh et al.	2025	Transportation Research Procedia	10.1016/j.trpro.2025.03.135	Scopus
S44	R0051	[60]	Li et al.	2025	Vehicles	10.3390/vehicles7030081	Scopus, Web of Science
S45	R0438	[61]	Li et al.	2025	Vehicles	10.3390/vehicles7040153	Scopus, Web of Science
S46	R0097	[62]	Liang et al.	2025	Pattern Recognition	10.1016/j.patcog.2025.111789	ScienceDirect
S47	R0601	[63]	Liu et al.	2025	Engineering Applications of Artificial...	10.1016/j.engappai.2025.112675	Scopus, Web of Science, ScienceDirect
S48	R0543	[64]	Mbuya et al.	2025	33rd ACM SIGSPATIAL International...	10.1145/3748636.3762752	Scopus
S49	R1010	[65]	Nallapula et al.	2025	Proceedings of the 2025 14th...	10.1145/3731806.3731847	ACM Digital Library

ID	ID v1	Ref.	Autores	Año	Editorial	DOI	Base de recuperación
S50	R0598	[66]	Onsu et al.	2025	Internet of Things	10.1016/j.iot.2025.101561	ScienceDirect
S51	R0545	[67]	Park et al.	2025	IEEE Access	10.1109/access.2025.3538836	Scopus, Web of Science, IEEE Xplore
S52	R0349	[68]	Said et al.	2025	TRAITEMENT DU SIGNAL	10.18280/ts.420231	Web of Science
S53	R0664	[69]	Wang et al.	2025	Communications in Transportation...	10.1016/j.commtr.2025.100227	ScienceDirect
S54	R0025	[70]	Wu et al.	2025	ACM conference proceedings (verificar...	10.1145/3776865.3776937	ACM Digital Library
S55	R0255	[71]	Ahmed et al.	2026	Electronics (Switzerland)	10.3390/electronics15102178	Scopus, Web of Science
S56	R0119	[72]	Ather et al.	2026	Mathematical Models in Engineering	10.21595/mme.2026.26075	Scopus
S57	R0167	[73]	Bano et al.	2026	Journal of Computing and Biomedical...	10.56979/1002/2026/1147	Scopus
S58	R0958	[74]	Ben et al.	2026	Chinese Journal of Mechanical...	10.1016/j.cjme.2025.100169	ScienceDirect
S59	R1013	[75]	Chai et al.	2026	Sensors	10.3390/s26092638	Scopus, Web of Science

ID	ID v1	Ref.	Autores	Año	Editorial	DOI	Base de recuperación
S60	R0313	[76]	Chauhan et al.	2026	Journal of Electronics, Electromedical...	10.35882/jeeemi.v8i1.1139	Scopus
S61	R1029	[77]	Dentamaro et al.	2026	Information (Switzerland)	10.3390/info17010044	Scopus, Web of Science
S62	R0682	[78]	Jadhav et al.	2026	Scientific Reports	10.1038/s41598-025-31470-8	Scopus
S63	R0444	[79]	Nouri et al.	2026	IEEE Access	10.1109/access.2026.3660765	Scopus, Web of Science, IEEE Xplore
S64	R1092	[80]	Patra et al.	2026	Scientific Reports	10.1038/s41598-026-51420-2	Scopus, Web of Science
S65	R1094	[81]	Pu et al.	2026	Transportation Research Part C...	10.1016/j.trc.2026.105648	Scopus, Web of Science
S66	R0600	[82]	Saini et al.	2026	Transportation Research...	10.1016/j.trip.2026.102192	Scopus, Web of Science
S67	R1185	[83]	Sathish et al.	2026	Array	10.1016/j.array.2026.100920	Scopus, Web of Science, ScienceDirect
S68	R0175	[84]	Seghir et al.	2026	AI (Switzerland)	10.3390/ai7010004	Scopus, Web of Science
S69	R1172	[85]	Wang et al.	2026	Urban Science	10.3390/urbansci10080457	Scopus, Web of Science

ID	ID v1	Ref.	Autores	Año	Editorial	DOI	Base de recuperación
S70	R1148	[86]	Wei et al.	2026	International Journal of Transportation...	10.1016/j.ijtst.2025.11.002	ScienceDirect
S71	R0501	[87]	Wu et al.	2026	Electronics (Switzerland)	10.3390/electronics15091803	Scopus, Web of Science
S72	R1049	[88]	Zaitouny et al.	2026	Transportation Research...	10.1016/j.trip.2026.102269	Scopus, Web of Science, ScienceDirect

C. Decisiones sobre casos límite

Tabla 23: Decisiones de elegibilidad sobre estudios dudosos, con el criterio aplicado.

Estudio	Decisión	Justificación
— [96]	Excluido (CE-4)	El método propuesto (Si-TDD) no es DL: se basa en la distancia al K-ésimo vecino histórico. Los modelos de DL aparecen solo como líneas base. Se usa en la discusión como evidencia sobre etiquetas reales y desempeño comparado.
— [97]	Excluido (CI-6)	La detección de disrupciones solo se muestra de forma cualitativa (coincidencia visual con fechas de eventos); la única evaluación cuantitativa es de imputación.
— [98]	Excluido (CI-6)	La única evaluación cuantitativa es de reconocimiento de acciones en Kinetics; la detección de anomalías de tráfico solo se ilustra cualitativamente.
— [99]	Excluido (CE-3)	Las puntuaciones de atípicos del autoencoder solo ponderan un modelo de pronóstico; la evaluación es exclusivamente de RMSE de predicción, sin métricas de detección.
— [100]	Excluido (CE-5)	Preprint de arXiv (CE-5); la versión anterior lo incluía como excepción ad hoc. La planilla de Parsif.al enlaza un documento de IEEE Xplore (n.º 11171552): si corresponde a una versión revisada por pares recuperada por la búsqueda en IEEE Xplore, debe reincorporarse citando esa versión.

D. Lista de verificación PRISMA 2020

Tabla 24: Ubicación de los ítems de PRISMA 2020 en el manuscrito.

Ítem	Requisito	Ubicación
1	Título que identifica el trabajo como revisión sistemática	Título
2	Resumen estructurado (PRISMA for Abstracts)	Resumen

Ítem	Requisito	Ubicación
3	Justificación en relación con el conocimiento existente	Sec. 1, 1.1; Tabla 1
4	Objetivos o preguntas	Sec. 1 (RQ1–RQ6)
5	Criterios de elegibilidad	Tabla 5
6	Fuentes de información y fecha de última búsqueda	Sec. 3.3; Tabla 4
7	Estrategia de búsqueda completa	Anexo A
8	Proceso de selección	Sec. 3 (Proceso de selección)
9	Proceso de extracción	Sec. 3 (Extracción de datos)
10	Variables extraídas	Tabla 6
11	Evaluación del riesgo de sesgo	Sec. 3; Tabla 7
12	Medidas de efecto	No aplica (síntesis sin metaanálisis); Sec. 3 (Síntesis)
13a–f	Métodos de síntesis	Sec. 3 (Síntesis)
14	Sesgo de reporte	Sec. 3 (Síntesis), justificación
15	Certeza de la evidencia	Sec. 3 (Síntesis), justificación
16a	Resultados de la búsqueda y selección	Figura 1
16b	Estudios excluidos que parecían cumplir los criterios	Anexo C
17	Características de los estudios	Tabla 8
18	Riesgo de sesgo por estudio	Tabla 9
19	Resultados de cada estudio	Tablas 8 y 20
20a–d	Resultados de las síntesis	Sec. 4 (RQ1–RQ6)
21	Sesgo de reporte en la síntesis	Sec. 4.9
22	Certeza de la evidencia	Sec. 5.4
23a–d	Discusión, limitaciones e implicaciones	Sec. 5
24a–c	Registro y protocolo	Declaraciones; Anexo A
25	Financiamiento	Declaraciones
26	Conflicto de intereses	Declaraciones

Ítem	**Requisito**	**Ubicación**
27	Disponibilidad de datos, código y materiales	Declaraciones