Detección de anomalías en tráfico vehicular mediante *Deep Learning* a partir de datos de sensores, trayectorias y video: una revisión sistemática de la literatura

Wilbert Alex Mayta Arotaype[1]

Wrangler Choquechambi Luque[1]

Ender Prieto Quispe[1]

[1]Escuela Profesional de Ingeniería de Sistemas, Universidad Peruana Unión, Juliaca, Perú.

wilbert.mayta@upeu.edu.pe wrangler.choquechambi@upeu.edu.pe **[correo institucional del tercer autor]**

Resumen

Antecedentes: la detección de anomalías en tráfico vehicular (accidentes, congestión no recurrente, conducción peligrosa o disrupciones) se aborda cada vez más con *Deep Learning* (DL) sobre datos de sensores, trayectorias y video. Las revisiones previas son narrativas, se limitan a un tipo de dato o no cubren el periodo reciente. **Objetivo:** sintetizar los modelos de DL empleados para detectar anomalías en tráfico vehicular urbano y de autopista, junto con las métricas y los protocolos de evaluación, los tipos de anomalía, los conjuntos de datos, las líneas base de comparación y las limitaciones reportadas. **Método:** revisión sistemática según Kitchenham y Charters, reportada conforme a PRISMA 2020 y PRISMA-S. Se buscaron estudios de 2020 a 2026 en Scopus, Web of Science, IEEE Xplore, ScienceDirect y ACM Digital Library (última búsqueda: **[dd/mm/2026]**). Dos revisores seleccionaron los estudios de forma independiente. La calidad metodológica se evaluó con un instrumento de ocho ítems adaptado a estudios de aprendizaje automático (procedencia de etiquetas, partición sin fuga, líneas base, variabilidad, disponibilidad de código y datos, validación externa, protocolo y limitaciones). Protocolo registrado en **[OSF, DOI 10.17605/OSF.IO/XXXXX]**. **Resultados:** se incluyeron 21 estudios primarios (2020–2026). Predominan las arquitecturas recurrentes (14 estudios), convolucionales (12) y de atención o Transformer (10); 17 estudios combinan varias familias. La categoría de anomalía más estudiada es accidentes e incidentes (9 estudios, 43 %). Solo 6 estudios evalúan con etiquetas reales verificadas; 8 usan anomalías inyectadas, pseudo-etiquetas o ninguna etiqueta. Solo 9 reportan la proporción de anomalías, 2 reportan variabilidad entre ejecuciones y 3 publican su código. La puntuación media de calidad fue 4.38 sobre 8 (rango 2.0–6.0).

Conclusiones: el tipo de dato condiciona la familia de arquitectura más que el tipo de anomalía. La comparabilidad entre estudios está limitada sobre todo por la procedencia heterogénea de las etiquetas y por protocolos de evaluación incompletos, más que por la elección del modelo. Se requieren benchmarks con etiquetas verificadas y un reporte mínimo del protocolo de evaluación.
Palabras clave: detección de anomalías; tráfico vehicular; *Deep Learning*; sistemas inteligentes de transporte; revisión sistemática.

Abstract

Background: anomaly detection in vehicular traffic (crashes, non-recurrent congestion, dangerous driving or disruptions) is increasingly addressed with Deep Learning (DL) on sensor, trajectory and video data. Prior reviews are narrative, limited to a single data type, or do not cover the recent period. **Objective:** to synthesize the DL models used to detect anomalies in urban and highway traffic, together with the evaluation metrics and protocols, anomaly types, datasets, comparison baselines and reported limitations. **Method:** systematic review following Kitchenham and Charters, reported according to PRISMA 2020 and PRISMA-S. Studies from 2020 to 2026 were searched in Scopus, Web of Science, IEEE Xplore, ScienceDirect and the ACM Digital Library (last search: **[dd Month 2026]**). Two reviewers independently selected the studies. Methodological quality was assessed with an eight-item instrument adapted to machine learning studies (label provenance, leakage-free split, baselines, variability, code and data availability, external validation, protocol, and limitations). Protocol registered at **[OSF, DOI 10.17605/OSF.IO/XXXXX]**. **Results:** 21 primary studies (2020–2026) were included. Recurrent (14 studies), convolutional (12) and attention/Transformer (10) architectures predominate; 17 studies combine several families. The most studied anomaly category is crashes and incidents (9 studies, 43 %). Only 6 studies evaluate on verified real labels; 8 use injected anomalies, pseudo-labels or no labels at all. Only 9 report the anomaly ratio, 2 report run-to-run variability and 3 release their code. The mean quality score was 4.38 out of 8 (range 2.0–6.0). **Conclusions:** the data type shapes the choice of architecture more than the anomaly type does. Comparability across studies is limited mainly by heterogeneous label provenance and incomplete evaluation protocols rather than by model choice. Benchmarks with verified labels and minimum reporting of the evaluation protocol are needed.
Keywords: anomaly detection; vehicular traffic; Deep Learning; intelligent transportation systems; systematic review.

1. Introducción

El crecimiento de las ciudades y del parque automotor ha aumentado la complejidad de la gestión del tráfico vehicular, tanto en redes urbanas como en autopistas. El flujo vehicular presenta alta variabilidad temporal, ruido de medición y dependencia espacial entre vías, sensores e intersecciones, por lo que debe analizarse como un fenómeno temporal y espacio-temporal y no como una secuencia aislada de mediciones [1, 2].

Los Sistemas Inteligentes de Transporte (*Intelligent Transportation Systems*, ITS) integran detectores de lazo y de microondas, cámaras de vigilancia, dispositivos GPS y plataformas de monitoreo. Sus datos se representan como series temporales (flujo, velocidad u ocupación en un punto), como datos espacio-temporales (varias ubicaciones conectadas por la red vial), como trayectorias o como secuencias de video [1, 3]. En este contexto, la *detección de anomalías* busca identificar desviaciones relevantes respecto al comportamiento esperado: accidentes, congestión no recurrente, cierres de vías, conducción peligrosa o disrupciones causadas por eventos extremos. Detectarlas a tiempo mejora la respuesta a incidentes y la seguridad vial [4, 5].

Tradicionalmente, este problema se abordó con algoritmos comparativos y de umbral, modelos autorregresivos y aprendizaje automático convencional [4, 6]. Estos enfoques encuentran dificultades con el desbalance entre eventos normales y anómalos, con la dependencia espacial y con los datos incompletos o ruidosos. El *Deep Learning* (DL) ofrece arquitecturas capaces de aprender representaciones temporales (redes recurrentes), espaciales (redes de grafos), visuales (redes convolucionales) o de reconstrucción (auto-encoders), y su uso para detectar anomalías en series temporales se ha generalizado [7].

1.1. Revisiones previas y vacío que aborda esta revisión

Existen revisiones previas sobre el tema, pero ninguna cubre a la vez el periodo reciente, los distintos tipos de dato y el análisis del protocolo de evaluación (Tabla 1). Los *surveys* de Djenouri et al. [1] y Zhang et al. [2] cubren la literatura anterior a 2020, con predominio de métodos estadísticos y de minería de datos. Santhosh et al. [3], Fang et al. [8] y Lin et al. [9] se limitan al video. Belhadi et al. [10] se limitan a trayectorias. Darban et al. [7] tratan series temporales genéricas, no específicas de tráfico. La única revisión sistemática identificada, la de ElSahly y Abdelfatah [4], trata la detección automática de incidentes en general, no se centra en DL y no cubre el periodo 2022–2026. Ninguna de ellas examina cómo se obtienen las etiquetas de anomalía ni cómo se fijan el umbral y la unidad de evaluación, aspectos que en detección de anomalías pueden cambiar los resultados más que la propia arquitectura [7].

Tabla 1: Revisiones previas sobre detección de anomalías de tráfico y su diferencia con esta revisión.

Revisión	**Año**	**Tipo**	**Datos cubiertos**	**Vacío respecto a esta RSL**
Djenouri et al. [1]	2019	Survey narrativo	Sensores y trayectorias	Literatura previa a 2019; escaso DL; sin video; no analiza etiquetas ni protocolo
Santhosh et al. [3]	2020	Survey narrativo	Video de vigilancia	Solo video; literatura hasta 2019; no sistemática
Belhadi et al. [10]	2020	Survey con benchmark	Trayectorias	Solo trayectorias, no exclusivo de tráfico; predominan métodos no profundos
Zhang et al. [2]	2020	Survey narrativo	Datos urbanos multifuente	Anomalías urbanas en general; no cubre 2021–2026
ElSahly y Abdelfatah [4]	2022	Sistemática (PRISMA)	Detectores de flujo	Detección de incidentes en general, no centrada en DL; sin video ni trayectorias; no cubre 2022–2026
Olugbade et al. [6]	2022	Survey narrativo	Incidentes (IA/ML general)	Enfoque amplio en IA/ML; no sistemática; no cubre 2023–2026
Razi et al. [5]	2023	Survey narrativo	Video (seguridad vial)	Centrado en video; no trata series de sensores; no sistemática
Fang et al. [8]	2024	Survey narra-	Video (acciden-	Solo video y solo

Esta revisión se diferencia de las anteriores en tres aspectos: (i) es sistemática y reproducible (PRISMA 2020 y PRISMA-S) y cubre 2020–2026; (ii) integra en un mismo análisis los estudios basados en sensores, trayectorias, movilidad agregada y video, lo que permite relacionar el tipo de dato con la familia de arquitectura; y (iii) extrae y sintetiza, para cada estudio, la procedencia de las etiquetas, el protocolo de evaluación y las líneas base, y evalúa la calidad metodológica con un instrumento específico para estudios de aprendizaje automático.

Las contribuciones son: (1) una matriz de extracción abierta de los estudios incluidos, de la que se derivan con un script todas las cifras de este artículo; (2) un análisis cruzado entre tipo de dato, familia de arquitectura, tipo de anomalía y periodo; (3) una síntesis del protocolo de evaluación (procedencia de etiquetas, umbral, unidad de evaluación y partición) y de las líneas base; y (4) una agenda de investigación basada en esas brechas.

Preguntas de investigación

RQ1: ¿Qué técnicas de *Deep Learning* se han utilizado para detectar anomalías en tráfico vehicular urbano y de autopista, y cómo se relacionan con el tipo de dato?

RQ2: ¿Qué métricas y qué protocolos de evaluación (procedencia de etiquetas, umbral, unidad de evaluación y partición) se emplean para medir el rendimiento de estos modelos?

RQ3: ¿Qué tipos de anomalías de tráfico se han abordado?

RQ4: ¿Qué conjuntos de datos se han utilizado y con qué tipo de etiquetas?

RQ5: ¿Qué limitaciones y desafíos reportan los estudios?

RQ6: ¿Contra qué líneas base se comparan los modelos de *Deep Learning* y qué ventaja reportan?

El resto del artículo se organiza así: la Sección 2 presenta el marco conceptual; la Sección 3, el método; la Sección 4, los resultados por pregunta; la Sección 5, la discusión y las amenazas a la validez; y la Sección 6, las conclusiones.

2. Marco conceptual

2.1. Datos de tráfico y su representación

Una *serie temporal de tráfico* es una secuencia de observaciones de una variable de movilidad (flujo, velocidad u ocupación) registrada por un detector en un punto de la red; puede ser univariada o multivariada. Cuando se observan simultáneamente

varias ubicaciones, los datos son *espacio-temporales* y suelen representarse como un grafo cuyos nodos son sensores, segmentos o zonas, y cuyas aristas son conexiones viales o relaciones origen-destino [1]. Las *trayectorias* son secuencias de posiciones de un vehículo obtenidas por GPS o por seguimiento en video [10]. El *video de vigilancia* es una secuencia de imágenes de cámaras fijas o a bordo [3]. El tipo de dato condiciona qué anomalías son observables y qué arquitectura es adecuada.

2.2. Anomalías de tráfico

Una *anomalía de tráfico* es un evento o patrón que se aparta del comportamiento esperado de la red o de un vehículo. En esta revisión se agrupan en cuatro categorías: (i) accidentes e incidentes; (ii) congestión o flujo anómalo no recurrente; (iii) trayectorias o conducción peligrosa (contramano, exceso de velocidad, maniobras de riesgo); y (iv) disrupciones y eventos extremos (cierres de vías, eventos meteorológicos, fallos de infraestructura). Las anomalías son poco frecuentes, lo que produce conjuntos de datos desbalanceados y dificulta tanto el entrenamiento como la evaluación [7].

2.3. Enfoques de *Deep Learning* para la detección de anomalías

Los modelos de DL detectan anomalías mediante cuatro mecanismos, que no dependen de la arquitectura concreta [7]:

- **Predicción:** el modelo (p. ej., LSTM, GRU, TCN o Transformer) pronostica el comportamiento esperado y marca como anómalas las desviaciones grandes entre lo predicho y lo observado.
- **Reconstrucción:** un autoencoder, posiblemente de grafos o variacional, aprende a reconstruir datos normales y usa el error de reconstrucción como puntuación de anomalía. Es útil cuando hay pocas etiquetas.
- **Clasificación supervisada:** con etiquetas de eventos normales y anómalos, una red (CNN, LSTM, GNN o híbrida) aprende directamente la frontera entre clases. Es frecuente en video y en detección de incidentes con registros históricos.
- **Similitud o contraste:** el modelo compara representaciones (por ejemplo, de video y de texto) y decide por similitud.

Los tres primeros mecanismos requieren un *umbral* o una regla de decisión para convertir la puntuación en una alarma. La elección del umbral, junto con la *unidad de evaluación* (punto, ventana, frame, evento o trayectoria), determina las métricas resultantes; por eso esta revisión los extrae de cada estudio.

3. Método

La revisión sigue las directrices de Kitchenham y Charters [12] y se reporta conforme a PRISMA 2020 [13] y a su extensión para la búsqueda, PRISMA-S [14]. La lista de verificación PRISMA 2020 con la ubicación de cada ítem se presenta en el Anexo D.

3.1. Protocolo y registro

El protocolo (PICOC, preguntas, criterios, estrategia de búsqueda, instrumento de calidad y plan de síntesis) se gestionó en Parsif.al y se registró en Open Science Framework (**[OSF, DOI 10.17605/OSF.IO/XXXXX]**). Las desviaciones respecto de la versión inicial (ampliación del alcance a video y autopistas, sustitución de MDPI y Taylor & Francis por IEEE Xplore, regla general sobre *preprints*, nuevo instrumento de calidad y nueva pregunta RQ6) se documentan en el historial del protocolo (Anexo A, Tabla 21).

3.2. PICOC y alineamiento del alcance

Tabla 2: Marco PICOC de la revisión.

Elemento	Descripción
Población	Tráfico vehicular en redes urbanas y autopistas, observado mediante sensores fijos, trayectorias GPS, datos de movilidad agregada o video de vigilancia
Intervención	Modelos de *Deep Learning* (recurrentes, convolucionales, autoencoders, grafos, Transformers, generativos o híbridos) usados como método principal para detectar anomalías
Comparación	Líneas base reportadas por cada estudio: otros modelos de DL, aprendizaje automático convencional, métodos estadísticos o reglas (RQ6)
Resultado	Desempeño de detección y protocolo con que se mide (métricas, procedencia de etiquetas, umbral, unidad de evaluación, partición)
Contexto	Sistemas inteligentes de transporte; estudios revisados por pares publicados entre 2020 y 2026

Para evitar que el alcance declarado difiera del corpus, el título, las preguntas, el PICOC, la cadena de búsqueda y los criterios se alinearon explícitamente (Tabla 3).

Tabla 3: Alineamiento del alcance entre los componentes del protocolo.

Componente	**Entorno vial**	**Tipo de dato**	**Método**
Título y RQ1	Urbano y autopista	Sensores, trayectorias y video	DL
PICOC (P, I)	Redes urbanas y autopistas	Sensores, GPS, movilidad agregada, video	DL como método principal
Cadena (bloque C)	*road/urban/vehicular/highway/freeway traffic*	*traffic flow*, *traffic video*, *traffic surveillance*, *traffic camera*	Bloque B (arquitecturas de DL)
Criterios	CI-4, CE-2	CI-4	CI-5, CE-4

3.3. Fuentes de información y estrategia de búsqueda

Se consultaron cinco bases bibliográficas: Scopus, Web of Science Core Collection, IEEE Xplore, ScienceDirect y ACM Digital Library. Se incorporó IEEE Xplore por su peso en el área de transporte inteligente y visión por computador. MDPI y Taylor & Francis Online, que figuraban en la versión anterior del protocolo, se retiraron como fuentes porque son plataformas editoriales y no bases bibliográficas. Sus revistas indexadas (p. ej., *Sensors* o *Applied Sciences*) se recuperan a través de Scopus y Web of Science, de modo que su retiro no excluye esos artículos. Se usó Parsif.al para gestionar los registros.

La cadena se construyó a partir del PICOC con tres bloques unidos por AND: (A) términos de detección de anomalías, incidentes o accidentes; (B) términos de DL y de sus arquitecturas; y (C) términos de tráfico vehicular, incluidos los de video y vigilancia. La cadena anterior exigía además *time series* o *spatio-temporal*, lo que recuperaba solo parcialmente los estudios basados en video. Ese bloque se eliminó al ampliar el alcance. En todas las bases se buscó en título, resumen y palabras clave, salvo en ACM (resumen) e IEEE Xplore (*All Metadata*). Se filtró por año de publicación (2020–2026), por tipo de documento (artículo de revista o de conferencia) y por idioma (inglés o español). Las cadenas exactas por base, con sus campos y filtros, se presentan en el Anexo A; la fecha de ejecución y el número de registros de cada base se reportan en la Tabla 4. Como el periodo incluye el año en curso, los resultados de 2026 son parciales hasta la fecha de búsqueda.

La cadena fue elaborada por el primer autor y revisada por los otros dos; no fue validada por un especialista en información externo, lo que se discute en la Sección 5.4.

La cadena se validó con un conjunto de control formado por los estudios incluidos: se comprobó de forma automática si el título, el resumen y las palabras clave de cada uno satisfacen los tres bloques (script `prueba_sensibilidad_cadena.py`). La primera formulación de la versión 2 recuperaba 13 de 21 estudios. Tras añadir sinónimos (*anomal**, *abnormal**, *expressway*, *highway*, *vehicle*, *road closure*, entre otros), la cadena definitiva recupera 19 de 21. Los dos restantes (S03, S14) no mencionan ningún término de DL en el título, el resumen ni las palabras clave. Se identificaron en la búsqueda de la versión 1 en ACM Digital Library, que no restringía el campo y por tanto buscaba en el texto completo, y se reportan en la rama "otros métodos" del diagrama PRISMA (Figura 1).

Tabla 4: Bases consultadas: fecha de ejecución, campos y registros recuperados.

Base	**Campos y filtros**	**Fecha**	**Registros**
Scopus	TITLE-ABS-KEY; 2020–2026; artículo y conferencia; inglés/español	**[fecha]**	**[n]**
Web of Science	TS (título, resumen, palabras clave y Keywords Plus); mismos filtros	**[fecha]**	**[n]**
IEEE Xplore	Título, resumen y palabras clave del autor; dos consultas; revistas y conferencias	**[fecha]**	**[n]**
ScienceDirect	Título, resumen y palabras clave; tres consultas (límite de 8 operadores)	**[fecha]**	**[n]**
ACM Digital Library	Resumen; artículos de investigación	**[fecha]**	**[n]**
Total			**[n]**

3.4. Criterios de elegibilidad

Tabla 5: Criterios de inclusión (CI) y exclusión (CE), con su fundamento en el protocolo.

Cód.	Criterio	Fundamento
Inclusión		
CI-1	Artículo de revista o de conferencia revisado por pares	Calidad mínima de la evidencia
CI-2	En inglés o español, con acceso al texto completo	Viabilidad; la extracción exige el texto completo
CI-3	Publicado entre 2020 y 2026	Contexto (C): periodo del DL reciente; vacío de las revisiones previas
CI-4	Aborda la detección de anomalías en tráfico vehicular (urbano o de autopista) a partir de sensores, trayectorias, datos de movilidad o video	Población (P) y alcance; RQ3, RQ4
CI-5	Usa *Deep Learning* como método principal de la detección; en modelos híbridos, la componente profunda aprende la representación sobre la que se decide la anomalía	Intervención (I); RQ1
CI-6	Reporta una evaluación cuantitativa de la tarea de detección (no solo de una tarea auxiliar como pronóstico o reconocimiento de acciones)	Resultado (O); RQ2 y RQ6
Exclusión		
CE-1	Duplicado entre bases, o versión menos completa del mismo estudio (p. ej., conferencia ampliada luego en revista); se conserva la más completa	Evitar doble conteo
CE-2	No trata de tráfico vehicular por carretera (p. ej., tráfico de red, ciberseguridad del vehículo, peatones, transporte marítimo, aéreo o ferroviario, estado del pavimento, monitoreo del conductor)	Población (P)
CE-3	Solo pronostica o clasifica tráfico, o estima riesgo a largo plazo, sin detectar ni anticipar anomalías	Resultado (O); objetivo de la RSL
CE-4	La detección no se basa en DL (SVM, ARIMA, reglas o umbrales sin componente profunda entrenada)	Intervención (I)
CE-5	Revisión, *survey*, capítulo, tesis, resumen, póster, editorial o *preprint*; un *preprint* se incluye solo si existe su versión revisada por pares, y entonces se cita esta última	Solo estudios primarios revisados por pares
CE-6	No describe el modelo, los datos o los resultados de forma suficiente para la extracción	Viabilidad de la extracción (Tabla 6)

Los criterios se aplicaron como un árbol de decisión en orden fijo (CE-1, CE-5, CI-3, CI-2, CE-2, CE-3, CE-4 y, a texto completo, CI-6 y CE-6), de modo que cada exclusión se asigna al primer criterio que no se cumple. Las definiciones operativas, con ejemplos de inclusión y de exclusión, se recogen en el manual de cribado del material suplementario. Los casos límite (estudios en los que el DL no decide directamente la anomalía o en los que la evaluación cuantitativa corresponde a otra tarea) se resolvieron con CI-5 y CI-6, y la decisión se documenta estudio por estudio en el Anexo C.

3.5. Proceso de selección

Los registros exportados de las cinco bases se unificaron y se deduplicaron con un script (coincidencia de DOI o de título normalizado con año igual o contiguo), cuyo registro de duplicados forma parte del material suplementario; los registros únicos se importaron en Parsif.al. Antes del cribado completo, los dos revisores (**[W. A. M. A. y E. P. Q.]**) calibraron la aplicación de los criterios con una muestra aleatoria de 50 registros (κ = **[0,xx]**); los desacuerdos se discutieron y se precisaron las definiciones del manual. Después, ambos examinaron de forma independiente, en hojas separadas, los títulos y resúmenes y luego los textos completos. En título y resumen se excluyó solo cuando el incumplimiento era claro; los casos dudosos pasaron a texto completo. Cada exclusión a texto completo se registró con su criterio y con la cita del artículo que la justifica, y la decisión de consenso de cada registro se consignó en Parsif.al. Las discrepancias se resolvieron por consenso y, de persistir, con un tercer revisor (**[W. C. L.]**). El acuerdo entre revisores se midió con el coeficiente kappa de Cohen [15]: κ = **[0,xx]**en título y resumen, y κ = **[0,xx]**en texto completo. Los motivos de exclusión a texto completo se registraron con el código del criterio correspondiente (Figura 1).

3.6. Extracción de datos

Un revisor extrajo los datos de cada estudio con el formulario de la Tabla 6 y un segundo revisor verificó la extracción contra el texto completo; las discrepancias se resolvieron por consenso. Además de los campos descriptivos, se extrajeron la procedencia de las etiquetas, la proporción de anomalías, la unidad de evaluación, el criterio de umbral, la partición de los datos y las líneas base, porque son los elementos que determinan la comparabilidad entre estudios. La matriz completa (un registro por estudio) se publica como material suplementario y todas las cifras de este artículo se generan a partir de ella con un script (`generar_conteos.py`).

Tabla 6: Formulario de extracción de datos.

Campo	**Contenido**
Identificación	ID, autores, año, título, revista o conferencia, DOI, base de recuperación
Contexto	Entorno (urbano, autopista), país o región de los datos
Datos	Tipo de dato, variables de entrada, datasets (real, simulado o mixto; público o no)
Etiquetas	Procedencia (registros reales, anotación experta, benchmark de terceros, inyectadas), proporción de anomalías
Modelo	Familias de arquitectura, híbrido o no, multimodal o no, paradigma (supervisado, semisupervisado, no supervisado) y mecanismo (predicción, reconstrucción, clasificación, similitud)
Protocolo	Partición entrenamiento/prueba, unidad de evaluación, criterio de umbral
Resultados	Métricas, resultado principal, líneas base y ventaja frente a la mejor
Anomalía	Categoría principal y secundaria
Limitaciones	Limitaciones declaradas por los autores (codificadas en seis categorías)
Reproducibilidad	Disponibilidad de código y datos

3.7. Evaluación de la calidad metodológica

La versión anterior del instrumento repetía los criterios de elegibilidad, de modo que todo estudio incluido los cumplía por definición. Se sustituyó por un instrumento de ocho ítems, adaptado de la lista de calidad de Kitchenham y Charters [12] y de las recomendaciones REFORMS para estudios basados en aprendizaje automático [16]. Los ítems evalúan riesgos de sesgo propios de este tipo de estudios (Tabla 7). Cada ítem se puntúa como Sí (1), Parcial (0,5) o No (0), con un máximo de 8. La puntuación **no** se usó para excluir estudios: se reporta por ítem y por estudio, y se usa en la síntesis para contrastar los hallazgos principales con el subconjunto de calidad alta (≥ 5.0). Dos revisores puntuaron cada estudio de forma independiente ($\kappa =$ **[0,xx]**) y resolvieron las discrepancias por consenso.

Tabla 7: Instrumento de evaluación de calidad metodológica (QA).

Ítem	Criterio	Sí (1) / Parcial (0,5) / No (0)
QA1	Procedencia de etiquetas	1: registros reales o anotación verificada; 0,5: mixtas, automáticas o verificación parcial; 0: solo inyectadas o no reportado
QA2	Partición sin fuga	1: partición temporal o prueba independiente descrita; 0,5: partición aleatoria o descripción incompleta; 0: no reportada
QA3	Líneas base comparables	1: dos o más líneas base con el mismo protocolo, incluida una del estado del arte o no DL; 0,5: una sola o solo ablación; 0: ninguna
QA4	Variabilidad	1: varias ejecuciones con dispersión, intervalos o pruebas de significancia; 0,5: parcial; 0: una sola ejecución
QA5	Código y datos	1: ambos públicos; 0,5: uno de los dos; 0: ninguno
QA6	Más de un escenario	1: dos o más datasets, ciudades o vías independientes; 0,5: varios subconjuntos de un dataset; 0: un único escenario
QA7	Protocolo explícito	1: reporta la unidad de evaluación y el criterio de umbral o decisión; 0,5: solo uno; 0: ninguno
QA8	Limitaciones	1: sección o párrafo explícito; 0,5: mención breve; 0: ninguna

3.8. Síntesis

Los estudios se agruparon por familia de arquitectura, tipo de dato, categoría de anomalía y periodo de publicación. Para sustentar las tendencias se construyeron tablas cruzadas (tipo de dato × familia, anomalía × familia y periodo × familia). Se identificaron los conjuntos de datos usados por más de un estudio para comparar su desempeño bajo el protocolo de cada uno. No se realizó metaanálisis porque los estudios difieren en tarea, datos, etiquetas, unidad de evaluación y métrica, y ningún par de estudios comparte a la vez dataset y protocolo. Por la misma razón no se aplicó GRADE para valorar la certeza de la evidencia ni se evaluó formalmente el sesgo de publicación (PRISMA, ítems 14 y 15). Como aproximación, se registró si cada estudio compara contra líneas base y si reporta resultados desfavorables para su propuesta (Sección 4.9).

4. Resultados

4.1. Selección de estudios

La Figura 1 resume el proceso de selección según PRISMA 2020. De [n] registros identificados en las cinco bases se eliminaron [n] duplicados y se cribaron [n] por título y resumen. Se evaluaron [n] textos completos, de los que se excluyeron [n] con los motivos indicados en la figura. A los estudios procedentes de las bases se sumaron 2 estudios identificados en la búsqueda de la versión 1 en ACM Digital Library (S03, S14). En total se incluyeron 21 estudios. 5 estudios incluidos en la versión anterior de esta revisión o en la planilla de Parsif.al se excluyeron al aplicar los criterios actualizados; estas exclusiones y las 7 inclusiones dudosas se justifican estudio por estudio en el Anexo C.

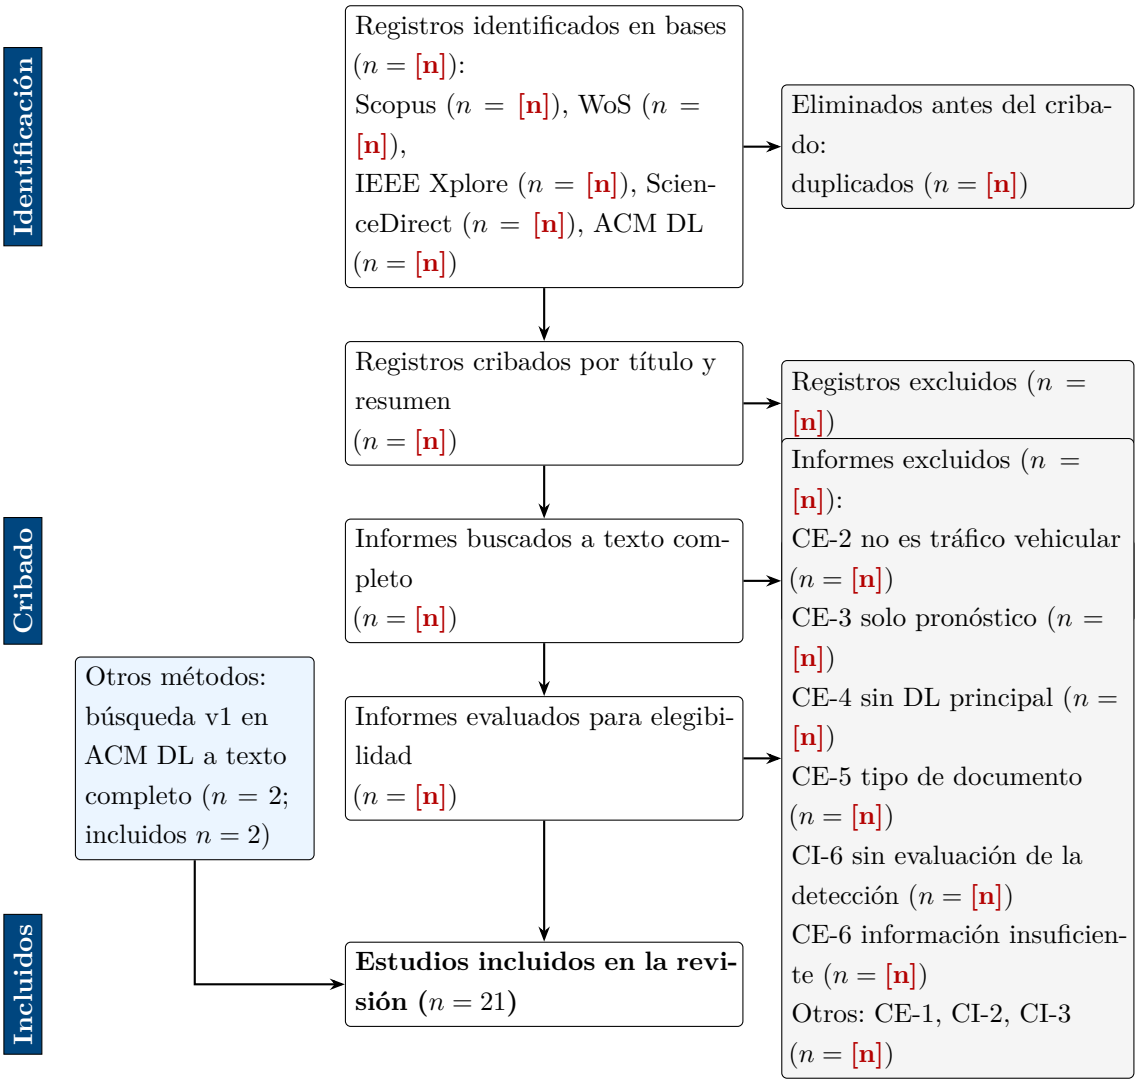


Figura 1: Diagrama de flujo PRISMA 2020 de la selección de estudios.

4.2. Características de los estudios

Los 21 estudios se publicaron entre 2020 y 2026: 2 en 2020, 1 en 2021, 5 en 2022, 2 en 2023, 5 en 2024, 4 en 2025 y 2 en 2026 (año parcial, hasta la fecha de búsqueda). 11 estudios son de 2024 en adelante. Por entorno, 7 estudios analizan tráfico urbano, 7 tráfico de autopista, 5 ambos y 2 no lo especifican. Por tipo de dato, 7 usan video o imágenes, 4 series de sensores, 3 trayectorias, 2 datos de movilidad agregada u origen-destino, 3 combinan varias fuentes y 2 usan exclusivamente datos simulados. La Tabla 8 presenta las características y el resultado principal de cada estudio.

Tabla 8: Características de los estudios incluidos.

ID	Ref.	Año	Tipo de dato	Entorno	Datasets	Etiquetas	Anomalía	Modelo	Resultado principal
S01	[17]	2020	Detectores de microondas	autopista	Viaducto Tangqiao (Hangzhou)	Registros reales	Accidentes e incidentes	CNN cíclica + ELM (DELM)	DR 98,4 %; FAR 0,56 %; MTTD 0,68 min
S02	[18]	2020	Video (dron y simulación)	urbano	TNAD (propio, con videos simulados)	Anotación manual	Conducción peligrosa (casi accidentes)	CNN de dos flujos + seguimiento	F1 0,93 (videos simulados)
S03	[19]	2021	Trayectorias de taxis	urbano	Shanghai, Chengdu y Beijing (taxis)	Registros reales (65 cierres)	Disrupciones (cierres de vías)	CNN+LSTM y GCN+LSTM + reglas	F1 0,94
S04	[20]	2022	Matrices OD de tiempos de viaje	urbano	Uber Movement, NYC taxi, Chicago taxi	Inyectadas	Eventos extremos	Autoencoder de grafos con contexto (Con-GAE)	AUC 0,84–0,91 (espacial)
S05	[21]	2022	Imágenes y video	ambos	VAID (propio)	Anotación manual	Accidentes	ResNet50 + promedio móvil	Accuracy 82 % (30 videos)
S06	[22]	2022	Video de vigilancia y dashcam	ambos	IITH, Iowa DOT, DoTA	Benchmarks de terceros	Accidentes	Autoencoder espacio-temporal (CAE + LSTM-AE)	AUC 84,7 % (DoTA)
S07	[23]	2022	Video dashcam	ambos	HTA, KITTI, D2City	Anotación manual	Accidentes	CNN + PredNet (ConvLSTM)	Top-1 0,68–0,72
S08	[24]	2022	Series de estaciones	urbano	Red vial de Beijing (propio)	Registros reales	Congestión	GNN con aprendizaje de estructura y atención	Accuracy 97,0 %; FAR 2,5 %

ID	Ref.	Año	Tipo de dato	Entorno	Datasets	Etiquetas	Anomalía	Modelo	Resultado principal
S09	[25]	2023	Trayectorias simuladas	autopista	MAAD (simulado)	Benchmark de terceros	Conducción peligrosa	VAE recurrente con atención estructural	AUROC 87,0 %; AUPR 65,5 %
S10	[26]	2023	Detectores de lazo	autopista	MnDOT (Minneapolis)	Registros reales	Accidentes	Codificador LSTM + clasificador	TPR 0,71; FPR 0,25 (18 min)
S11	[27]	2024	Video de vigilancia	no especificado	UCF-Crime (subconjunto)	Benchmark de terceros	Accidentes	CNN 3D densa-residual + Bi-LSTM	Accuracy 85,4 %
S12	[28]	2024	Trayectorias (Amap)	urbano	Wuhan (propio)	Registros reales	Congestión	ConvLSTM multiescala	Precisión 92,9 % (ciudad)
S13	[29]	2024	Matrices OD y sensores	ambos	NYC taxi, PEMS-BAY, Uber Movement	Inyectadas	Congestión	Autoencoder de grafos + TCN (MTGAE)	AUC 1,000 (inyectadas)
S14	[30]	2024	Trayectorias de taxis	urbano	Porto, Chengdu	Inyectadas	Trayectorias anómalas	Codificador multiescala con atención (MST-OATD)	PR-AUC 0,97
S15	[31]	2024	Video de vigilancia	autopista	Xi'an Ring Expressway (propio)	Anotación manual	Conducción peligrosa	YOLOv5 + DeepSORT + re-ID + BiLSTM + reglas	Contramano 99,6 %
S16	[32]	2025	Video, sensores y simulación	ambos	CityCam, UA-DETRAC, PEMS-BAY, SUMO	Mixto (pseudo-etiquetas)	Fallos de infraestructura	CNN + Transformer + LSTM (borde)	F1 0,94; 72 ms

ID	Ref.	Año	Tipo de dato	Entorno	Datasets	Etiquetas	Anomalía	Modelo	Resultado principal
S17	[33]	2025	Sensores (+ multimodal declarado)	autopista	METR-LA, PEMS-BAY	Mixto	Accidentes e incidentes	GNN heterogénea + atención + LSTM	F1 0,967; AUC 0,985
S18	[34]	2025	Detectores (PeMS)	autopista	PEMS04, PEMS08	Sin etiquetas	Flujo anómalo	Bi-LSTM + GAT + Transformer en frecuencia	29/30 anomalías de consenso
S19	[35]	2025	Simulación microscópica	urbano	VISSIM Pangyo (simulado)	Inyectadas	Accidentes e incidentes	Transformer de grafos multirresolución	Recall 0,78 ± 0,29
S20	[36]	2026	Video y texto	no especificado	TADS	Anotación manual	Accidentes e incidentes	CLIP + Transformer temporal + mirada	Micro AUC 74,3 %
S21	[37]	2026	Sensores (PeMS) + clima	autopista	PeMS, datos meteorológicos	Mixto (automáticas)	Congestión	Atención multicabeza + LSTM	F1 0,81 (clase anómala)

4.3. Calidad metodológica

La puntuación media fue 4.38 sobre 8 (desviación estándar 0.96; rango 2.0–6.0). El instrumento discrimina entre estudios, a diferencia de la versión anterior (Tabla 9). Los ítems con menor cumplimiento son la variabilidad entre ejecuciones (QA4: 2 estudios con Sí) y la disponibilidad de código y datos (QA5: 2), seguidos de la procedencia verificada de las etiquetas (QA1: 6). Los de mayor cumplimiento son las líneas base (QA3: 12) y el protocolo explícito (QA7: 11). 6 estudios alcanzan la calidad alta (≥ 5.0): S03, S04, S06, S10, S16, S17.

Tabla 9: Evaluación de calidad por ítem y estudio (1 = Sí, 0.5 = Parcial, 0 = No).

ID	QA1	QA2	QA3	QA4	QA5	QA6	QA7	QA8	Total
S01	1	0.5	1	0	0	0	1	0.5	4.0
S02	0.5	1	0.5	0	0	0.5	1	0.5	4.0
S03	1	0.5	1	0	0.5	1	1	0.5	5.5
S04	0	1	1	0.5	1	1	0.5	0.5	5.5
S05	0.5	0.5	0.5	0	0	0	1	0.5	3.0
S06	1	1	1	0	0.5	1	0.5	0.5	5.5
S07	0.5	0	0.5	0	0.5	1	0.5	0.5	3.5
S08	1	0.5	1	0	0	0	1	1	4.5
S09	0.5	0.5	1	1	0.5	0	0.5	0.5	4.5
S10	1	0.5	1	0.5	0.5	1	1	0.5	6.0
S11	1	0.5	0.5	0	0.5	0.5	0.5	0.5	4.0
S12	0.5	0	0.5	0	0	0.5	0.5	0	2.0
S13	0	1	1	0	0.5	0.5	0.5	0.5	4.0
S14	0	0.5	1	0	1	1	0.5	0.5	4.5
S15	0.5	0	0.5	0	0	0.5	1	1	3.5
S16	0.5	0.5	0.5	1	0.5	1	1	1	6.0
S17	0.5	0.5	1	0.5	0.5	1	0	1	5.0
S18	0	1	0.5	0	0.5	1	1	0.5	4.5
S19	0	1	1	0.5	0	0	1	0.5	4.0
S20	0.5	0.5	1	0	0	0.5	1	1	4.5
S21	0.5	1	0.5	0	0.5	0	0.5	1	4.0
Media	0.52	0.60	0.79	0.19	0.36	0.57	0.74	0.62	4.38

4.4. RQ1: Técnicas de *Deep Learning* y su relación con el tipo de dato

La Tabla 10 muestra la presencia de cada familia de arquitectura. Predominan las redes recurrentes (14 estudios), las convolucionales (12) y los mecanismos de atención o Transformer (10), seguidos de las redes de grafos (8), los autoencoders (6) y los modelos generativos (2). La mayoría de los estudios (17 de 21) combina dos o más familias, por lo que la clasificación en una sola familia, usada en la versión anterior, ocultaba esta composición. Se distingue entre modelos *híbridos*, que combinan arquitecturas, y *multimodales*, que integran varias modalidades de datos (4 estudios). Según el mecanismo de detección, 9 estudios clasifican de forma supervisada, 5 detectan por error de predicción y 5 por error de reconstrucción.

Tabla 10: Familias de arquitectura presentes en los estudios (RQ1).

Familia	**n**	**%**	**Estudios**
Recurrentes (LSTM, GRU, Bi-LSTM)	14	67 %	S03, S06, S07, S09, S10, S11, S12, S13, S14, S15, S16, S17, S18, S21
Convolucionales (CNN, TCN, 3D-CNN)	12	57 %	S01, S02, S03, S05, S06, S07, S11, S12, S13, S15, S16, S17
Autoencoders y reconstrucción	6	29 %	S04, S06, S09, S13, S14, S16
Grafos (GNN, GCN, GAT)	8	38 %	S03, S04, S08, S13, S14, S17, S18, S19
Transformers y atención	10	48 %	S08, S09, S14, S15, S16, S17, S18, S19, S20, S21
Generativos (GAN, VAE, difusión)	2	10 %	S09, S14
Combinan dos o más familias (híbridos)	17	81 %	S01, S02, S03, S04, S06, S07, S09, S11, S12, S13, S14, S15, S16, S17, S18, S19, S21
Integran varias modalidades de datos (multimodales)	4	19 %	S16, S17, S20, S21

Un estudio puede combinar varias familias. “Híbrido” se refiere a la arquitectura y “multimodal” a los datos de entrada.

El cruce entre tipo de dato y familia (Tabla 11) muestra que la arquitectura depende

sobre todo del dato disponible. En video, 6 de 7 estudios usan redes convolucionales, frecuentemente combinadas con redes recurrentes para la dimensión temporal (4), y ninguno usa grafos. Los 8 estudios con redes de grafos trabajan con sensores, movilidad agregada, trayectorias, datos multimodales o simulados, es decir, con datos que tienen una estructura de red vial explícita [20, 24, 29, 35]. Los autoencoders aparecen sobre todo cuando no hay etiquetas suficientes: con matrices origen-destino [20, 29], con trayectorias [30] o con video entrenado solo con datos normales [22].

Tabla 11: Cruce tipo de dato × familia de arquitectura (n.º de estudios).

	Rec.	**Conv.**	**AE**	**Grafo**	**Transf.**	**Gen.**	**Total**
Series de sensores	2	1	0	2	2	0	4
Movilidad agregada/OD	1	1	2	2	0	0	2
Trayectorias	3	2	1	2	1	1	3
Video e imágenes	4	6	1	0	2	0	7
Multimodal	3	2	1	1	3	0	3
Simulado	1	0	1	1	2	1	2

Un estudio puede usar varias familias, por lo que las filas no suman el total.

El cruce por periodo (Tabla 12) sustenta la tendencia temporal con datos y no solo con impresiones. Ninguno de los 3 estudios de 2020–2021 usa atención o Transformers, mientras que 8 de los 11 estudios de 2024–2026 los incorporan. Las redes de grafos pasan de 1 estudio en 2020–2021 a 5 en 2024–2026. Las redes convolucionales y recurrentes siguen presentes en todos los periodos. Dado el tamaño del corpus, estas diferencias son descriptivas y no permiten inferir una tendencia estadística.

Tabla 12: Cruce periodo de publicación × familia de arquitectura.

	Rec.	**Conv.**	**AE**	**Grafo**	**Transf.**	**Gen.**	**Total**
2020–2021	1	3	0	1	0	0	3
2022–2023	4	3	3	2	2	1	7
2024–2026	9	6	3	5	8	1	11

2026 es parcial (búsqueda cerrada en la fecha indicada en la Sección 3.3).

Hallazgo

El tipo de dato condiciona la arquitectura: las redes convolucionales dominan en video y las de grafos solo aparecen cuando el dato tiene estructura de red vial. La

mayoría de los modelos son híbridos, y desde 2024 la atención o los Transformers están presentes en la mayoría de los estudios.

4.5. RQ2: Métricas y protocolos de evaluación

Métricas. La Tabla 13 muestra las métricas reportadas. La más frecuente es la *accuracy* (10 estudios), seguida de recall (8), AUC-ROC (8), precision (7) y F1-score (7). Solo 2 estudios reportan PR-AUC [25, 30], pese a ser más informativa que la AUC-ROC con clases desbalanceadas. Las métricas propias de la detección de incidentes (tasa de detección, tasa de falsas alarmas y tiempo medio de detección) aparecen en pocos estudios [17, 24, 26]. 11 estudios informan alguna métrica operativa (latencia, FPS, tiempo de inferencia o energía). Varios estudios usan definiciones no estándar: por ejemplo, Mao et al. [28] llaman *accuracy* a lo que corresponde a la precisión, y Park et al. [35] llaman *recall* a una fórmula de precisión.

Tabla 13: Métricas reportadas por los estudios (RQ2).

Métrica	n	%	Estudios
Accuracy	10	48 %	S05, S07, S08, S10, S11, S12, S16, S17, S20, S21
Precision	7	33 %	S02, S03, S05, S12, S16, S17, S21
Recall	8	38 %	S02, S03, S05, S10, S16, S17, S19, S21
F1-score	7	33 %	S02, S03, S05, S06, S16, S17, S21
AUC-ROC	8	38 %	S04, S06, S09, S10, S13, S17, S20, S21
PR-AUC	2	10 %	S09, S14
Tasa de detección (DR)	4	19 %	S01, S08, S15, S21
FAR / FPR	5	24 %	S01, S08, S09, S10, S21
Tiempo medio de detección	2	10 %	S01, S10
MAE / RMSE / MAPE	4	19 %	S13, S15, S16, S18
IoU / mAP	1	5 %	S06
Latencia / FPS / energía	11	52 %	S02, S03, S04, S05, S07, S10, S11, S12, S14, S16, S20

Un estudio puede reportar varias métricas.

Procedencia de las etiquetas. En detección de anomalías, el origen de las etiquetas de prueba condiciona el resultado tanto como el modelo. Solo 5 estudios evalúan con registros reales de incidentes y 5 con anotación manual propia (Tabla 14). 4 estudios

evalúan únicamente con anomalías inyectadas o sintéticas [20, 29, 30, 35], 3 con pseudo-etiquetas generadas automáticamente (por ejemplo, con Isolation Forest o con un autoencoder previo) [32, 33, 37] y 1 sin etiquetas, contrastando sus detecciones con el consenso de otros detectores [34].

Tabla 14: Origen de las etiquetas de anomalía (RQ2, protocolo).

Origen de las etiquetas	**n**	**%**	**Estudios**
Registros reales de incidentes	5	24 %	S01, S03, S08, S10, S12
Anotación manual o experta	5	24 %	S02, S05, S07, S15, S20
Benchmark anotado por terceros	3	14 %	S06, S09, S11
Anomalías inyectadas o sintéticas	4	19 %	S04, S13, S14, S19
Mixto o automático (pseudo-etiquetas)	3	14 %	S16, S17, S21
Sin etiquetas	1	5 %	S18

Protocolo. La Tabla 15 muestra qué elementos del protocolo reporta cada estudio. Casi todos indican la unidad de evaluación (20 de 21) y la partición de los datos (18), aunque varios usan particiones aleatorias sobre series temporales, con riesgo de fuga de información (QA2). Del criterio de decisión, 11 estudios describen explícitamente cómo fijan el umbral y 8 usan clasificadores que deciden sin umbral explícito o evalúan con métricas independientes del umbral. En varios casos el umbral se ajusta sobre los mismos eventos etiquetados que se usan para evaluar [19] o sobre una parte del conjunto de prueba [25]. Solo 9 estudios reportan la proporción de anomalías en los datos de evaluación, un dato necesario para interpretar precision, F1 y PR-AUC.

Tabla 15: Elementos del protocolo de evaluación que reporta cada estudio (RQ2).

Elemento del protocolo reportado	**n**	**Estudios**
Tasa de anomalías en los datos	9	S01, S02, S04, S05, S06, S11, S13, S14, S21
Unidad de evaluación (punto, ventana, frame, evento...)	20	S01, S02, S03, S04, S05, S06, S07, S08, S09, S10, S11, S12, S13, S14, S15, S16, S18, S19, S20, S21
Criterio de umbral o decisión	19	S01, S02, S03, S04, S05, S06, S07, S08, S09, S10, S11, S12, S15, S16, S17, S18, S19, S20, S21
Partición entrenamiento/prueba	18	S01, S02, S03, S04, S05, S06, S08, S09, S10, S11, S13, S14, S16, S17, S18, S19, S20, S21

Desempeño sobre datasets compartidos. Ningún par de estudios comparte a la vez dataset, etiquetas y protocolo, lo que impide un metaanálisis. Dos casos ilustran el problema. Primero, cuatro estudios usan datos de PeMS (PEMS-BAY, METR-LA, PEMS04/08 o estaciones de PeMS), pero cada uno define las anomalías de forma distinta: pseudo-etiquetas de un autoencoder (F1 = 0,93 en PEMS-BAY) [32], registros de eventos combinados con patrones detectados automáticamente (F1 = 0,967) [33], ninguna etiqueta [34] y anomalías generadas con Isolation Forest al 1 % (F1 = 0,81) [37]. Las cifras no son comparables entre sí. Segundo, en NYC taxi con anomalías inyectadas, Hu et al. [20] obtienen AUC entre 0,84 y 0,90 con Con-GAE, mientras que Ren et al. [29] reportan AUC = 1,000 en todas las configuraciones, con un protocolo de inyección distinto. Un AUC perfecto con anomalías sintéticas sugiere que la tarea de evaluación es demasiado fácil y no que el problema esté resuelto.

Hallazgo

La comparabilidad entre estudios está limitada sobre todo por la procedencia de las etiquetas y por el protocolo, no por la arquitectura. Menos de un tercio de los estudios evalúa con etiquetas reales verificadas y pocos reportan la proporción de anomalías o la variabilidad entre ejecuciones.

4.6. RQ3: Tipos de anomalías

Según la categoría principal (Tabla 16), la más estudiada es accidentes e incidentes (9 estudios, 43 %), seguida de congestión o flujo anómalo (5, 24 %), trayectorias o conducción peligrosa (4, 19 %) y disrupciones y eventos extremos (3, 14 %). Si se cuentan también las categorías secundarias, los accidentes aparecen en 12 estudios y la congestión en 9. A diferencia de la versión anterior, cada estudio se asigna a una sola categoría principal, de modo que los porcentajes suman 100 %.

Tabla 16: Categorías de anomalía abordadas (RQ3).

Categoría	**n**	**%**	**Estudios (principal)**	**Secundaria**
Accidentes e incidentes	9	43 %	S01, S05, S06, S07, S10, S11, S17, S19, S20	S02, S08, S21
Congestión o flujo anómalo	5	24 %	S08, S12, S13, S18, S21	S04, S16, S17, S19
Trayectorias o conducción peligrosa	4	19 %	S02, S09, S14, S15	S07
Disrupciones y eventos extremos	3	14 %	S03, S04, S16	S12, S18
Total	21	100 %		

El cruce con la familia de arquitectura (Tabla 17) refleja la relación con el tipo de dato. Los accidentes se estudian sobre todo con video y redes convolucionales. La congestión y las disrupciones se estudian con series de sensores, movilidad agregada o trayectorias, y con modelos recurrentes o de grafos. Las trayectorias peligrosas concentran los modelos generativos y de reconstrucción [25, 30].

Tabla 17: Cruce categoría principal de anomalía × familia de arquitectura.

	Rec.	**Conv.**	**AE**	**Grafo**	**Transf.**	**Gen.**	**Total**
Accidentes e incidentes	5	6	1	2	3	0	9
Congestión o flujo anómalo	4	2	1	3	3	0	5
Trayectorias o conducción peligrosa	3	2	2	1	3	2	4
Disrupciones y eventos extremos	2	2	2	2	1	0	3

Clasificación por categoría principal (una por estudio).

4.7. RQ4: Conjuntos de datos

La Tabla 18 agrupa los conjuntos de datos por tipo de dato. Los más reutilizados son los de PeMS (PEMS-BAY, METR-LA, PEMS04 y PEMS08) y los de taxis (NYC, Chicago, Porto y Chengdu). En video predominan los conjuntos específicos de cada estudio o de competiciones (TNAD, VAID, IITH, DoTA, TADS, HTA y AI City Challenge). 6 estudios usan exclusivamente datos no públicos y 3 usan datos simulados, en dos de ellos de forma exclusiva [25, 35]. Ninguno de los datasets de sensores más usados (PeMS) incluye etiquetas de anomalía verificadas, lo que explica el recurso a anomalías inyectadas o a pseudo-etiquetas.

Tabla 18: Tipo de dato y conjuntos de datos utilizados (RQ4).

Tipo de dato	**n**	**Estudios**	**Datasets**
Series de sensores	4	S01, S08, S10, S18	Beijing (propio), MnDOT RTMC, PEMS04, PEMS08, Tangqiao (propio)
Movilidad agregada/OD	2	S04, S13	Chicago taxi, NYC taxi, PEMS-BAY, Uber Movement
Trayectorias	3	S03, S12, S14	Beijing2013, Chengdu taxi, Chengdu2018 (Didi), Porto taxi, Shanghai2018 (SODA), Wuhan/Amap (propio)
Video e imágenes	7	S02, S05, S06, S07, S11, S15, S20	D2City, DoTA, HTA, IITH, Iowa DOT (AI City), KITTI, TADS, TNAD, UCF-Crime, VAID, Xi'an Ring Expressway (propio)
Multimodal	3	S16, S17, S21	CityCam, Clima (API), METR-LA, PEMS-BAY, PeMS, SUMO, UA-DETRAC
Simulado	2	S09, S19	MAAD, VISSIM Pangyo

4.8. RQ5: Limitaciones reportadas

La limitación más declarada es la generalización a otros escenarios (17 estudios), seguida del etiquetado de anomalías (9), el costo computacional y de despliegue (8) y

el uso de datos propios o de acceso limitado (7; Tabla 19). Llama la atención lo que los autores casi no declaran: solo 1 estudio menciona la falta de comparabilidad de las métricas y solo 1 la interpretabilidad, aunque ambas aparecen como problemas en esta síntesis (Sección 5).

Tabla 19: Limitaciones reportadas por los estudios primarios (RQ5).

Limitación declarada por los autores	**n**	**%**	**Estudios**
Datos propios o de acceso limitado	7	33 %	S03, S04, S05, S09, S15, S17, S20
Etiquetado de anomalías	9	43 %	S04, S06, S10, S13, S14, S18, S19, S20, S21
Generalización a otros escenarios	17	81 %	S01, S02, S04, S05, S06, S09, S10, S11, S13, S14, S15, S16, S17, S18, S19, S20, S21
Métricas no comparables	1	5 %	S02
Costo computacional y despliegue	8	38 %	S07, S08, S11, S15, S16, S17, S20, S21
Interpretabilidad	1	5 %	S21
Sin limitaciones declaradas	1	5 %	S12

Un estudio puede declarar varias limitaciones.

4.9. RQ6: Líneas base y ventaja reportada

Todos los estudios comparan su propuesta con alguna línea base, pero con alcance desigual (Tabla 20). 11 estudios incluyen al menos una línea base que no es DL (estadística, de aprendizaje automático convencional o basada en reglas), lo que permite valorar el aporte del DL frente a alternativas más simples. En otros casos, la comparación se limita a ablaciones del propio modelo [18, 21], a cifras copiadas de artículos con otros datos [37] o a un componente auxiliar y no a la detección [31]. Las ventajas reportadas frente a la mejor línea base suelen ser moderadas (de 1 a 6 puntos porcentuales en la métrica principal) cuando la comparación es con modelos recientes bajo el mismo protocolo [32, 33, 35, 36], y mayores en algunos casos, como +0,15 de AUC frente a redes de grafos genéricas [20] o $\approx +17$ puntos de F1 frente a métodos de umbral [19]. Hay resultados desfavorables que los estudios reportan, pero no destacan: con ventanas cortas, Autoformer supera al modelo propuesto por Park et al. [35], y el FPR de Chakraborty et al. [25] es peor que el de su mejor línea base. Fuera del corpus, Taheri Sarteshnizi et al. [38] evalúan detectores de DL sobre datos reales de volumen vehicular con etiquetas expertas y encuentran que un método simple basado en distancias supera

a todos ellos (F1 = 0,676 frente a 0,278 del mejor detector profundo). Este estudio se excluyó por CE-4, pero es relevante para valorar la ventaja del DL.

Tabla 20: Líneas base y ventaja frente a la mejor de ellas (RQ6).

ID	Líneas base	No DL	Ventaja frente a la mejor línea base
S01	LSTM, DBN, CNN, GBDT	Sí	+2,0 pp de DR frente a DBN
S02	Ablaciones (flujo espacial o temporal solo)	Sí	+4,9 pp de F1 frente al flujo espacial solo
S03	TB1, TB2, PB (no DL)	Sí	≈ +17 pp de F1 frente a TB2 (leído del gráfico)
S04	HA, RTC, AE, EncDec-AD, REBM, DAGMM, GraphSAGE, GCN	Sí	Hasta +0,15 de AUC frente a GCN
S05	CNN sin promedio móvil (ablación)	No	+10 pp de accuracy (ablación)
S06	Autoencoders y equipos AI City	No	+2 pp de AUC en IITH
S07	CGAN, FlowNet, PredNet	No	+1,8 a +17,7 pp frente a FlowNet
S08	LOF, iForest, OCSVM, HBOS, COPOD, LSTM-VAE, MAD-GAN	Sí	−1 pp de FAR frente a LSTM-VAE
S09	CVM, RAE, STGAE, STGAE-KDE, VV-RAE	Sí	+10,3 pp de AUPR frente a STGAE-KDE
S10	CNN, RNN, PNN, AdaBoost, GradientBoost	Sí	+0,15 de TPR frente a PNN, con mayor FPR
S11	R3D, P3D, I3D, R(2+1)D	No	+2,7 pp frente a R3D+Bi-LSTM
S12	SAE, CNN+LSTM, Bi-LSTM, GAN, Transformer	No	+3,7 pp frente a Transformer
S13	Con-GAE, GCN, GraphSAGE, GATv2, PMLP, otros	Sí	+3,2 a +4,0 pp de AUC frente a PMLP
S14	iBAT, SAE, VSAE, GM-VSAE, DeepTEA	Sí	+18,6 % relativo de PR-AUC (Porto)
S15	Solo para re-identificación	No	Detección sin línea base
S16	CNN, LSTM, GRU, LSTM federado	No	+1 pp de F1 frente a LSTM federado
S17	AGC-LSTM, AttentionDeepST	No	+2,2 pp de F1 frente a AGC-LSTM

ID	Líneas base	No DL	Ventaja frente a la mejor línea base
S18	iForest, LSTM-VAE, LSTM-NDT	Sí	No comparable (sin etiquetas)
S19	LSTM, GRU, Transformer, Informer, Autoformer	No	+5,3 pp de recall frente a Autoformer (T=288)
S20	ResNet50, MNAD, OLP-TAD, RF-RG	No	+5,7 pp de AUC frente a RF-RG
S21	Cifras de otros artículos	Sí	No comparable

Análisis de sensibilidad por calidad. Restringida a los 6 estudios de calidad alta (S03, S04, S06, S10, S16, S17), la síntesis mantiene sus conclusiones principales: 5 de ellos son híbridos y la arquitectura sigue el tipo de dato. Sin embargo, solo 3 evalúan con etiquetas reales o anotadas, de modo que la escasez de etiquetas verificadas afecta también a los mejores estudios del corpus.

5. Discusión

5.1. Interpretación de los hallazgos y contraste con revisiones previas

El dato antes que el modelo. El hallazgo principal es que la familia de arquitectura se explica mejor por el tipo de dato que por el tipo de anomalía. Las revisiones previas trataban por separado el video [3, 8], las trayectorias [10] y las series de sensores [1], por lo que no podían observar esta relación. Al integrarlos, esta revisión muestra que no existe una arquitectura dominante para el problema en general: las redes convolucionales son la opción natural cuando la anomalía es visible en la imagen, las de grafos cuando el dato tiene estructura de red y los autoencoders cuando faltan etiquetas. Este resultado coincide con la observación de Darban et al. [7] para series temporales genéricas: la idoneidad de un detector depende de la estructura de los datos y del tipo de anomalía, no de su complejidad.

Hibridación y atención. La hibridación es la norma y no la excepción, y la atención o los Transformers se han generalizado desde 2024. Djenouri et al. [1] y Zhang et al. [2] reportaban un campo dominado por métodos estadísticos y de minería de datos, por lo que el cambio hacia modelos profundos híbridos es claro. Sin embargo, la evidencia de que esta complejidad mejore la detección en condiciones reales es limitada: las ventajas frente a líneas base recientes son moderadas, y Taheri Sarteshnizi et al. [38] encuentran que, con etiquetas reales, métodos simples pueden superar a los profundos.

Etiquetas y protocolo. La aportación más específica de esta revisión es mostrar que la comparabilidad depende de la procedencia de las etiquetas y del protocolo. Ninguna de las revisiones previas analiza estos aspectos de forma estructurada. Que un mismo dataset (PeMS) se use con cuatro definiciones distintas de anomalía, y que con anomalías inyectadas se obtengan AUC perfectos, indica que las cifras de desempeño publicadas no pueden ordenarse en un ranking. Esto coincide con la crítica de Darban et al. [7] sobre los benchmarks de series temporales y con las recomendaciones REFORMS para estudios de aprendizaje automático [16].

Alcance de las conclusiones. Los estudios incluidos aplican DL con resultados favorables en escenarios controlados, pero con validación limitada en contextos reales: 3 usan datos simulados, 8 no evalúan con etiquetas reales y solo 9 validan en más de un escenario independiente. Por tanto, no se puede afirmar que el DL haya alcanzado madurez operativa para la detección de anomalías de tráfico.

5.2. Implicaciones para sistemas inteligentes de transporte

Para un operador de tráfico, la elección del modelo debería partir del dato disponible: video en intersecciones y túneles, detectores en autopistas, trayectorias de flotas en redes urbanas. Antes de adoptar un modelo publicado, conviene verificar con qué etiquetas se evaluó, con qué proporción de anomalías y con qué unidad de evaluación, porque un F1 obtenido con anomalías inyectadas no anticipa el desempeño con incidentes reales. Las métricas operativas (latencia, tiempo medio de detección, tasa de falsas alarmas por hora) se reportan poco y son las que determinan el valor práctico de una alerta.

5.3. Brechas y agenda de investigación

(1) **Benchmarks con etiquetas verificadas.** Solo 6 estudios evalúan con etiquetas reales verificadas. Se necesitan conjuntos de datos públicos de sensores y trayectorias con incidentes registrados por operadores, en la línea de AnoLT [38].

(2) **Reporte mínimo del protocolo.** Se propone reportar siempre la procedencia de las etiquetas, la proporción de anomalías, la unidad de evaluación, el criterio de umbral, la partición temporal y la variabilidad entre ejecuciones, junto con PR-AUC cuando las clases estén desbalanceadas.

(3) **Validación externa.** Pocos estudios evalúan en más de una ciudad o vía. La transferencia entre ciudades y la adaptación de dominio siguen sin evaluarse sistemáticamente.

(4) **Reproducibilidad.** Solo 3 estudios publican su código. La publicación de código y datos debería acompañar a los resultados.

(5) **Interpretabilidad.** Casi ningún estudio la aborda ni la declara como limitación, pese a que los operadores necesitan entender el origen de una alerta.

5.4. Amenazas a la validez

Validez de construcción (búsqueda). La cadena no fue validada por un especialista en información externo. Para mitigarlo, se validó con un conjunto de control (19 de 21 estudios recuperados por la cadena definitiva). Dos estudios solo se recuperan con búsqueda en texto completo, lo que indica que pueden existir otros estudios relevantes

que no mencionan DL en el resumen. La revisión se limita a cinco bases y no incluye literatura gris ni *preprints*, lo que excluye trabajos recientes aún no publicados.

Validez interna (selección y extracción). La versión anterior de la revisión aplicó los criterios de forma no uniforme: incluyó un *preprint* como excepción y estudios sin evaluación cuantitativa de la detección. En esta versión los criterios se aplicaron a todos los estudios y los casos límite se documentan en el Anexo C. La selección y la evaluación de calidad se hicieron con dos revisores independientes (κ reportado en la Sección 3). La extracción se verificó contra el texto completo, y durante esa verificación se encontraron errores en las fichas iniciales (fichas duplicadas, categorías y datasets mal asignados), que se corrigieron.

Validez externa. El corpus es pequeño (21 estudios), está concentrado en datos de China y Estados Unidos y se limita a estudios en inglés. El año 2026 es parcial. Las proporciones deben interpretarse como descripción del corpus y no como estimaciones de la literatura completa.

Validez de conclusión. La heterogeneidad de tareas, datos, etiquetas y protocolos impide el metaanálisis y la valoración formal de la certeza de la evidencia. Por ello, las conclusiones sobre la ventaja del DL se formulan con prudencia. Varios estudios presentan inconsistencias internas entre texto y tablas, registradas en la matriz de extracción, que reducen la confianza en sus resultados numéricos.

6. Conclusiones

Esta revisión sistemática analizó 21 estudios (2020–2026) que aplican *Deep Learning* a la detección de anomalías en tráfico vehicular urbano y de autopista a partir de sensores, trayectorias, movilidad agregada y video.

RQ1. Predominan las redes recurrentes, convolucionales y de atención, casi siempre combinadas en modelos híbridos. La familia de arquitectura sigue al tipo de dato: convolucionales en video, grafos en datos con estructura de red y autoencoders cuando faltan etiquetas. Desde 2024 la atención y los Transformers están presentes en la mayoría de los estudios.

RQ2. Las métricas más usadas son *accuracy*, recall, AUC-ROC, precision y F1, con definiciones a veces no estándar. El principal obstáculo para comparar estudios es el protocolo: la procedencia de las etiquetas (reales, inyectadas o pseudo-etiquetas), la proporción de anomalías y el criterio de umbral varían entre estudios y a menudo no se reportan.

RQ3. Las anomalías más estudiadas son los accidentes e incidentes (43 %), seguidos de la congestión o flujo anómalo, las trayectorias peligrosas y las disrupciones.

RQ4. Los datasets más reutilizados (PeMS y taxis) carecen de etiquetas de anomalía verificadas. En video predominan conjuntos específicos de cada estudio, y una parte del corpus depende de datos simulados o no públicos.

RQ5. Los autores declaran sobre todo problemas de generalización, etiquetado y costo computacional. Casi ninguno declara la falta de comparabilidad de las métricas o la interpretabilidad.

RQ6. Todos los estudios comparan con líneas base, pero solo 11 de 21 incluyen una alternativa no profunda y varios se limitan a ablaciones o a cifras de otros artículos. Las ventajas frente a modelos recientes son moderadas.

Como implicación práctica, la elección del modelo debería partir del dato disponible y de cómo se evaluó el modelo, no solo de la cifra de desempeño reportada. Como trabajo futuro se proponen benchmarks públicos con etiquetas verificadas, un reporte mínimo del protocolo de evaluación y la validación entre ciudades.

Declaraciones

Registro y protocolo: protocolo registrado en **[OSF, DOI 10.17605/OSF.IO/XXXXX]**. La lista de verificación PRISMA 2020 se presenta en el Anexo D.

Disponibilidad de datos y código: la matriz de extracción, la evaluación de calidad por ítem y estudio, las cadenas de búsqueda, la planilla de cribado y los scripts que generan todas las cifras (`generar_conteos.py` y `prueba_sensibilidad_cadena.py`) están disponibles en `https://github.com/ClaudioB12/rsl-wilbert`.

Conflicto de intereses: los autores declaran no tener conflicto de intereses.

Financiamiento: esta investigación no recibió financiamiento externo.

Uso de inteligencia artificial generativa: **[Los autores utilizaron [herramienta] como apoyo para [revisar la redacción, verificar la extracción de datos contra los textos completos y generar los scripts de conteo]. Todo el contenido fue revisado y validado por los autores, que asumen la responsabilidad del trabajo.]**

Contribuciones (CRediT):

- **Mayta Arotaype, W. A.**: conceptualización, metodología, curación de datos, análisis formal, redacción del borrador original.
- **Choquechambi Luque, W.**: investigación, validación, visualización, redacción (revisión y edición).

- **Prieto Quispe, E.**: investigación, análisis formal, verificación de resultados, redacción (revisión y edición).

Referencias

[1] Y. Djenouri, A. Belhadi, J. C.-W. Lin, D. Djenouri, and A. Cano, "A survey on urban traffic anomalies detection algorithms," *IEEE Access*, vol. 7, pp. 12 192–12 205, 2019.

[2] M. Zhang, T. Li, Y. Yu, Y. Li, P. Hui, and Y. Zheng, "Urban anomaly analytics: Description, detection, and prediction," *IEEE Transactions on Big Data*, vol. 8, no. 3, pp. 809–826, 2022, publicado en línea en 2020.

[3] K. K. Santhosh, D. P. Dogra, and P. P. Roy, "Anomaly detection in road traffic using visual surveillance: A survey," *ACM Computing Surveys*, vol. 53, no. 6, 2020.

[4] O. ElSahly and A. Abdelfatah, "A systematic review of traffic incident detection algorithms," *Sustainability*, vol. 14, no. 22, p. 14859, 2022.

[5] A. Razi, X. Chen, H. Li, H. Wang, B. Russo, Y. Chen, and H. Yu, "Deep learning serves traffic safety analysis: A forward-looking review," *IET Intelligent Transport Systems*, vol. 17, no. 1, pp. 22–71, 2023.

[6] S. Olugbade, S. Ojo, A. L. Imoize, J. Isabona, and M. O. Alaba, "A review of artificial intelligence and machine learning for incident detectors in road transport systems," *Mathematical and Computational Applications*, vol. 27, no. 5, p. 77, 2022.

[7] Z. Zamanzadeh Darban, G. I. Webb, S. Pan, C. C. Aggarwal, and M. Salehi, "Deep learning for time series anomaly detection: A survey," *ACM Computing Surveys*, vol. 57, no. 1, 2024.

[8] J. Fang, J. Qiao, J. Xue, and Z. Li, "Vision-based traffic accident detection and anticipation: A survey," *IEEE Transactions on Circuits and Systems for Video Technology*, vol. 34, no. 4, pp. 1983–1999, 2024.

[9] R. Lin, T. Tang, Y. Liu, W. Zhou, X. Yang, H. Zheng, J. Lin, and Y. Zhang, "Deep learning advances in vision-based traffic accident anticipation: A comprehensive review of methods, datasets, and future directions," arXiv preprint arXiv:2505.07611, 2025.

[10] A. Belhadi, Y. Djenouri, J. C.-W. Lin, and A. Cano, "Trajectory outlier detection: Algorithms, taxonomies, evaluation, and open challenges," *ACM Transactions on Management Information Systems*, vol. 11, no. 3, pp. 1–29, 2020.

[11] G. Alinezhad Noghre, A. Danesh Pazho, and H. Tabkhi, "A survey on video anomaly detection via deep learning: Human, vehicle, and environment," arXiv preprint arXiv:2508.14203, 2025.

[12] B. Kitchenham and S. Charters, "Guidelines for performing systematic literature reviews in software engineering," Keele University and Durham University Joint Report, Tech. Rep. EBSE 2007-001, 2007.

[13] M. J. Page, J. E. McKenzie, P. M. Bossuyt, I. Boutron, T. C. Hoffmann, C. D. Mulrow *et al.*, "The PRISMA 2020 statement: an updated guideline for reporting systematic reviews," *BMJ*, vol. 372, p. n71, 2021.

[14] M. L. Rethlefsen, S. Kirtley, S. Waffenschmidt, A. P. Ayala, D. Moher, M. J. Page, J. B. Koffel, and PRISMA-S Group, "PRISMA-S: an extension to the PRISMA statement for reporting literature searches in systematic reviews," *Systematic Reviews*, vol. 10, p. 39, 2021.

[15] J. Cohen, "A coefficient of agreement for nominal scales," *Educational and Psychological Measurement*, vol. 20, no. 1, pp. 37–46, 1960.

[16] S. Kapoor, E. M. Cantrell, K. Peng, T. H. Pham, C. A. Bail, O. E. Gundersen *et al.*, "REFORMS: Consensus-based recommendations for machine-learning-based science," *Science Advances*, vol. 10, no. 18, p. eadk3452, 2024.

[17] Y. Fang, Q. Yang, L. Zheng, X. Zhou, and B. Peng, "A deep cycle limit learning machine method for urban expressway traffic incident detection," *Mathematical Problems in Engineering*, vol. 2020, p. 5965089, 2020.

[18] X. Huang, P. He, A. Rangarajan, and S. Ranka, "Intelligent intersection: Two-stream convolutional networks for real-time near-accident detection in traffic video," *ACM Transactions on Spatial Algorithms and Systems*, vol. 6, no. 2, p. 10, 2020.

[19] S. Cai, T. Wu, J. Mao, and C. Jin, "Road closure detection based upon multi-feature fusion," in *Proceedings of the 29th International Conference on Advances in Geographic Information Systems (SIGSPATIAL '21)*. ACM, 2021, pp. 354–364.

[20] Y. Hu, A. Qu, and D. Work, "Detecting extreme traffic events via a context augmented graph autoencoder," *ACM Transactions on Intelligent Systems and Technology*, vol. 13, no. 6, p. 101, 2022.

[21] S. W. Khan, Q. Hafeez, M. I. Khalid, R. Alroobaea, S. Hussain, J. Iqbal, J. Almotiri, and S. S. Ullah, "Anomaly detection in traffic surveillance videos using deep learning," *Sensors*, vol. 22, no. 17, p. 6563, 2022.

[22] K. Pawar and V. Attar, "Deep learning based detection and localization of road accidents from traffic surveillance videos," *ICT Express*, vol. 8, no. 3, pp. 379–387, 2022.

[23] W. Riaz, C. Gao, A. Azeem, Saifullah, J. A. Bux, and A. Ullah, "Traffic anomaly prediction system using predictive network," *Remote Sensing*, vol. 14, no. 3, p. 447, 2022.

[24] H. Zhang, S. Zhao, R. Liu, W. Wang, Y. Hong, and R. Hu, "Automatic traffic anomaly detection on the road network with spatial-temporal graph neural network representation learning," *Wireless Communications and Mobile Computing*, vol. 2022, p. 4222827, 2022.

[25] N. Chakraborty, A. Hasan, S. Liu, T. Ji, W. Liang, D. L. McPherson, and K. Driggs-Campbell, "Structural attention-based recurrent variational autoencoder for highway vehicle anomaly detection," in *Proceedings of the 22nd International Conference on Autonomous Agents and Multiagent Systems (AAMAS 2023)*. IFAAMAS, 2023, pp. 1125–1134. [Online]. Available: https://www.ifaamas.org/Proceedings/aamas2023/pdfs/p1125.pdf

[26] P. Mehrannia, S. S. G. Bagi, B. Moshiri, and O. A. Al-Basir, "Deep representation of imbalanced spatio-temporal traffic flow data for traffic accident detection," *IET Intelligent Transport Systems*, vol. 17, no. 3, pp. 606–619, 2023.

[27] Y. Lu, W. Chen, Z. Yu, J. Wang, and C. Yang, "Vehicle abnormal behavior detection based on dense block and soft thresholding," *Computers, Materials & Continua*, vol. 79, no. 3, pp. 5051–5066, 2024.

[28] Y. Mao, Y. Shi, and B. Lu, "Detecting urban traffic anomalies using traffic-monitoring data," *ISPRS International Journal of Geo-Information*, vol. 13, no. 10, p. 351, 2024.

[29] Z. Ren, X. Li, J. Peng, K. Chen, Q. Tan, X. Wu, and C. Shi, "Graph autoencoder with mirror temporal convolutional networks for traffic anomaly detection," *Scientific Reports*, vol. 14, p. 1247, 2024.

[30] C. Wang, L. Chen, S. Shang, C. S. Jensen, and P. Kalnis, "Multi-scale detection of anomalous spatio-temporal trajectories in evolving trajectory datasets," in *Proceedings of the 30th ACM SIGKDD Conference on Knowledge Discovery and Data Mining (KDD '24)*. ACM, 2024, pp. 2980–2990.

[31] L. Zhao, Z. Fu, J. Yang, Z. Zhao, and P. Wang, "Multi-adjacent camera-based dangerous driving trajectory recognition for ultra-long highways," *Applied Sciences*, vol. 14, no. 11, p. 4593, 2024.

[32] W. Abdallah and M. Alghamdi, "AIP-Urban: Edge-enabled deep learning framework for predictive maintenance and anomaly detection in urban traffic infrastructure," *Systems*, vol. 13, no. 12, p. 1117, 2025.

[33] M. Duan, S. Sun, and M. Liu, "A multimodal deep fusion framework for highway traffic anomaly detection," *Scientific Reports*, vol. 15, p. 33573, 2025.

[34] X. Jia, J. Qu, Y. Lyu, M. Guo, J. Zhang, and F. Guo, "A prediction-based anomaly detection method for traffic flow data with multi-domain feature extraction," *Applied Sciences*, vol. 15, no. 6, p. 3234, 2025.

[35] D. Park, S.-S. Choi, D. Lim, and Y.-S. Kang, "Graph multi-resolution transformer for road traffic anomaly detection," *IEEE Access*, vol. 13, pp. 27 428–27 437, 2025.

[36] Y. Chai and W. Silamu, "Road traffic anomaly detection by human-attention-assisted text–vision learning," *Sensors*, vol. 26, no. 9, p. 2638, 2026.

[37] P. Jadhav, A. Benslimane, D. R. Vora, and S. Patil, "Multi-stage classification of abnormal traffic events using a multi-head + LSTM," *Scientific Reports*, vol. 16, p. 1516, 2026.

[38] I. Taheri Sarteshnizi, M. Sarvi, S. Asadi Bagloee, and N. Nassir, "On the applicability of time series anomaly detection methods to real-world traffic volume data," *Transportation Research Part C: Emerging Technologies*, vol. 184, p. 105536, 2026.

[39] M. Nouri and M. Ilbeigi, "A self-imputing deep multitask sequence model for traffic disruption detection in extreme conditions," *IEEE Access*, vol. 13, pp. 165 873–165 886, 2025.

[40] D. Feng, M. Liang, and G. Wang, "A traffic anomaly detection and identification approach based on multi-instance learning," in *The 2nd International Conference on Computing and Data Science (CONF-CDS 2021)*. ACM, 2021.

[41] H. Choudhary and M. Hassani, "Autoencoder-based continual outlier correlation detection for real-time traffic flow prediction," in *Proceedings of the 39th ACM/SIGAPP Symposium on Applied Computing (SAC '24)*. ACM, 2024, pp. 218–220.

[42] F. I. Giasemis and A. Sopasakis, "Learning traffic anomalies from generative models on real-time observations," arXiv preprint arXiv:2502.01391, 2025.

A. Protocolo de revisión

Cadena de búsqueda por base de datos

Las cadenas se reproducen literalmente. Los filtros de año, tipo de documento e idioma se aplicaron con las opciones de cada interfaz (Tabla 4).

Scopus (búsqueda avanzada)

```
TITLE-ABS-KEY ( ( anomal* OR abnormal* OR outlier* OR "incident detection"
 OR "accident detection" OR "accident prediction" OR "accident anticipation"
 OR "road closure*" OR "dangerous driving" OR "near-accident*" OR "near-miss*"
 OR "extreme event*" )
 AND ( "deep learning" OR "deep neural" OR "neural network*" OR lstm OR gru
 OR cnn OR convolutional OR autoencoder* OR transformer* OR "graph neural"
 OR "self-attention" OR "attention mechanism" )
 AND ( "road traffic" OR "urban traffic" OR "vehicular traffic"
 OR "highway traffic" OR "freeway traffic" OR "traffic flow" OR "traffic video*"
 OR "traffic surveillance" OR "traffic camera*" OR "intelligent transportation"
 OR "transportation network*" OR expressway* OR highway* OR freeway* OR vehicle*
 OR "road network*" OR taxi* OR "traffic event*" OR "traffic scenario*"
 OR "traffic incident*" OR "traffic accident*" OR "traffic anomal*" ) )
 AND PUBYEAR > 2019 AND PUBYEAR < 2027
 AND ( LIMIT-TO ( DOCTYPE , "ar" ) OR LIMIT-TO ( DOCTYPE , "cp" ) )
 AND ( LIMIT-TO ( LANGUAGE , "English" ) OR LIMIT-TO ( LANGUAGE , "Spanish" ) )
```

Web of Science Core Collection (TS = título, resumen, palabras clave y Keywords Plus)

```
TS=((anomal* OR abnormal* OR outlier* OR "incident detection"
 OR "accident detection" OR "accident prediction" OR "accident anticipation"
 OR "road closure*" OR "dangerous driving" OR "near-accident*" OR "near-miss*"
 OR "extreme event*")
 AND ("deep learning" OR "deep neural" OR "neural network*" OR LSTM OR GRU
 OR CNN OR convolutional OR autoencoder* OR transformer* OR "graph neural"
 OR "self-attention" OR "attention mechanism")
 AND ("road traffic" OR "urban traffic" OR "vehicular traffic"
 OR "highway traffic" OR "freeway traffic" OR "traffic flow" OR "traffic video*"
 OR "traffic surveillance" OR "traffic camera*" OR "intelligent transportation"
 OR "transportation network*" OR expressway* OR highway* OR freeway* OR vehicle*
 OR "road network*" OR taxi* OR "traffic event*" OR "traffic scenario*"
 OR "traffic incident*" OR "traffic accident*" OR "traffic anomal*"))
Filtros: 2020-2026; Article, Proceeding Paper; English, Spanish.
```

IEEE Xplore (Command Search; máximo 25 términos por consulta)

```
Consulta 1:
(("Document Title":anomal* OR "Abstract":anomal* OR "Author Keywords":anomal*
 OR "Abstract":abnormal* OR "Abstract":"incident detection"
 OR "Abstract":"accident detection" OR "Abstract":"road closure"
```

```
 OR "Abstract":"dangerous driving" OR "Abstract":"near-accident")
 AND ("Abstract":"deep learning" OR "Abstract":"neural network"
 OR "Abstract":LSTM OR "Abstract":convolutional OR "Abstract":autoencoder
 OR "Abstract":transformer)
 AND ("Abstract":"road traffic" OR "Abstract":"urban traffic"
 OR "Abstract":"traffic flow" OR "Abstract":"traffic video"
 OR "Abstract":"traffic surveillance" OR "Abstract":"intelligent transportation"))
Consulta 2:
(("Document Title":anomal* OR "Abstract":anomal* OR "Abstract":abnormal*
 OR "Abstract":"incident detection" OR "Abstract":"accident detection"
 OR "Abstract":"extreme event")
 AND ("Abstract":"deep learning" OR "Abstract":"neural network"
 OR "Abstract":LSTM OR "Abstract":convolutional OR "Abstract":autoencoder
 OR "Abstract":transformer)
 AND ("Abstract":expressway OR "Abstract":highway OR "Abstract":freeway
 OR "Abstract":vehicle OR "Abstract":taxi OR "Abstract":"road network"))
Filtros: 2020-2026; Journals, Conferences.
```

ScienceDirect (título, resumen y palabras clave; máximo 8 operadores, sin comodines)

```
Consulta 1: ("anomaly detection" OR "incident detection" OR "accident detection")
 AND ("deep learning" OR "neural network")
 AND ("road traffic" OR "urban traffic" OR "traffic flow")
Consulta 2: ("anomaly detection" OR "incident detection" OR "accident detection")
 AND ("deep learning" OR "neural network")
 AND ("traffic video" OR "traffic surveillance" OR "highway")
Consulta 3: ("abnormal" OR "anomalous") AND ("deep learning" OR "neural network")
 AND ("vehicle" OR "expressway" OR "trajectory")
Filtros: 2020-2026; Research articles.
```

ACM Digital Library (campo Abstract)

```
[[Abstract: anomal*] OR [Abstract: abnormal*] OR [Abstract: outlier*]
 OR [Abstract: "incident detection"] OR [Abstract: "accident detection"]
 OR [Abstract: "road closure*"] OR [Abstract: "dangerous driving"]
 OR [Abstract: "near-accident*"] OR [Abstract: "extreme event*"]]
AND [[Abstract: "deep learning"] OR [Abstract: "neural network*"]
 OR [Abstract: lstm] OR [Abstract: convolutional] OR [Abstract: autoencoder*]
 OR [Abstract: transformer*] OR [Abstract: "graph neural"]]
AND [[Abstract: "road traffic"] OR [Abstract: "urban traffic"]
 OR [Abstract: "vehicular traffic"] OR [Abstract: "traffic flow"]
 OR [Abstract: "traffic video*"] OR [Abstract: "traffic surveillance"]
 OR [Abstract: "intelligent transportation"] OR [Abstract: expressway*]
 OR [Abstract: highway*] OR [Abstract: vehicle*] OR [Abstract: taxi*]
 OR [Abstract: "road network*"]]
AND [E-Publication Date: (01/01/2020 TO 12/31/2026)]
```

Historial del protocolo

Tabla 21: Historial de versiones del protocolo.

Versión	Fecha	Cambio
V1.0	[fecha]	Definición del tema, preguntas de investigación y PICOC.
V1.1	[fecha]	Cadenas por base (seis fuentes, incluidas MDPI y Taylor & Francis).
V1.2	[fecha]	Cribado y eliminación de duplicados en Parsif.al.
V1.3	[fecha]	Evaluación de calidad (instrumento de 6 ítems) y extracción; 25 estudios.
V2.0	[fecha]	Respuesta a la revisión: alcance ampliado a video y autopistas; cinco bases (se añade IEEE Xplore y se retiran MDPI y Taylor & Francis por ser editoriales); cadena validada con un conjunto de control; regla general para *preprints* (CE-5); CI-5 y CI-6 precisados; nuevo instrumento de calidad de 8 ítems; nueva RQ6; re-cribado con dos revisores.

B. Estudios incluidos

Tabla 22: Estudios incluidos con su identificador en la versión anterior, DOI y base de recuperación.

ID	ID v1	Ref.	Autores	Año	Editorial	DOI	Base de recuperación
S01	E07	[17]	Fang et al.	2020	Hindawi	10.1155/2020/5965089	[base]
S02	E10	[18]	Huang et al.	2020	ACM	10.1145/3373647	[base]
S03	E13	[19]	Cai et al.	2021	ACM	10.1145/3474717.3483975	[base]
S04	E05	[20]	Hu et al.	2022	ACM	10.1145/3539735	[base]
S05	E18	[21]	Khan et al.	2022	MDPI	10.3390/s22176563	[base]
S06	E06	[22]	Pawar et al.	2022	Elsevier	10.1016/j.icte.2021.11.004	[base]
S07	E20	[23]	Riaz et al.	2022	MDPI	10.3390/rs14030447	[base]
S08	E04	[24]	Zhang et al.	2022	Hindawi	10.1155/2022/4222827	[base]
S09	E17	[25]	Chakraborty et al.	2023	IFAAMAS (actas distribuidas por ACM)	Sin DOI (actas IFAAMAS)	[base]
S10	E08	[26]	Mehrannia et al.	2023	Wiley	10.1049/itr2.12287	[base]
S11	E25	[27]	Lu et al.	2024	Tech Science Press	10.32604/cmc.2024.050865	[base]
S12	E03	[28]	Mao et al.	2024	MDPI	10.3390/ijgi13100351	[base]
S13	E14	[29]	Ren et al.	2024	Springer Nature	10.1038/s41598-024-51374-3	[base]
S14	E22	[30]	Wang et al.	2024	ACM	10.1145/3637528.3671874	[base]
S15	E21	[31]	Zhao et al.	2024	MDPI	10.3390/app14114593	[base]
S16	E02	[32]	Abdallah et al.	2025	MDPI	10.3390/systems13121117	[base]
S17	E12	[33]	Duan et al.	2025	Springer Nature	10.1038/s41598-025-18671-x	[base]
S18	E16	[34]	Jia et al.	2025	MDPI	10.3390/app15063234	[base]

ID	ID v1	Ref.	Autores	Año	Editorial	DOI	Base de recuperación
S19	E11	[35]	Park et al.	2025	IEEE	10.1109/ACCESS.2025.3538836	[base]
S20	E19	[36]	Chai et al.	2026	MDPI	10.3390/s26092638	[base]
S21	E09	[37]	Jadhav et al.	2026	Springer Nature	10.1038/s41598-025-31470-8	[base]

C. Decisiones sobre casos límite

Tabla 23: Decisiones de elegibilidad sobre estudios dudosos, con el criterio aplicado.

Estudio	**Decisión**	**Justificación**
S01 [17]	Incluido	La red convolucional cíclica aprende la representación de las variables de tráfico y la ELM clasifica sobre ella (CI-5, cláusula de híbridos).
S03 [19]	Incluido	Las redes CNN+LSTM y GCN+LSTM predicen el flujo y el volumen de giro; la desviación predicción-observación sobre esa representación decide el cierre (CI-5). Reporta precision, recall y F1 (CI-6), aunque los valores frente a baselines solo aparecen en un gráfico.
S12 [28]	Incluido	A diferencia de lo señalado en la revisión previa, reporta métricas cuantitativas de detección (Tabla 2 del artículo), aunque con definiciones no estándar de accuracy y precision.
S15 [31]	Incluido	El pipeline profundo (detección, seguimiento, re-identificación y BiLSTM) produce las trayectorias sobre las que reglas de umbral deciden la anomalía (CI-5, cláusula de híbridos); la detección se evalúa cuantitativamente (CI-6).
S16 [32]	Incluido	Aunque el objetivo final es el mantenimiento predictivo, el modelo clasifica ventanas como normales o anómalas y la detección se evalúa con precision, recall y F1, por lo que no cae en CE-3.
S17 [33]	Incluido	Cumple CI-4 a CI-6, pero la fuente de los datos multimodales y de las etiquetas no se identifica; se refleja en la evaluación de calidad y en la discusión.
S18 [34]	Incluido	La detección se cuantifica frente a un consenso de tres detectores (29 de 30 anomalías), lo que satisface CI-6 aunque sin etiquetas reales (QA1 = 0).
— [38]	Excluido (CE-4)	El método propuesto (Si-TDD) no es DL: se basa en la distancia al K-ésimo vecino histórico. Los modelos de DL aparecen solo como líneas base. Se usa en la discusión como evidencia sobre etiquetas reales y desempeño comparado.

Estudio	Decisión	Justificación
— [39]	Excluido (CI-6)	La detección de disrupciones solo se muestra de forma cualitativa (coincidencia visual con fechas de eventos); la única evaluación cuantitativa es de imputación.
— [40]	Excluido (CI-6)	La única evaluación cuantitativa es de reconocimiento de acciones en Kinetics; la detección de anomalías de tráfico solo se ilustra cualitativamente.
— [41]	Excluido (CE-3)	Las puntuaciones de atípicos del autoencoder solo ponderan un modelo de pronóstico; la evaluación es exclusivamente de RMSE de predicción, sin métricas de detección.
— [42]	Excluido (CE-5)	Preprint de arXiv (CE-5); la versión anterior lo incluía como excepción ad hoc. La planilla de Parsif.al enlaza un documento de IEEE Xplore (n.º 11171552): si corresponde a una versión revisada por pares recuperada por la búsqueda en IEEE Xplore, debe reincorporarse citando esa versión.

D. Lista de verificación PRISMA 2020

Tabla 24: Ubicación de los ítems de PRISMA 2020 en el manuscrito.

Ítem	Requisito	Ubicación
1	Título que identifica el trabajo como revisión sistemática	Título
2	Resumen estructurado (PRISMA for Abstracts)	Resumen
3	Justificación en relación con el conocimiento existente	Sec. 1, 1.1; Tabla 1
4	Objetivos o preguntas	Sec. 1 (RQ1–RQ6)
5	Criterios de elegibilidad	Tabla 5
6	Fuentes de información y fecha de última búsqueda	Sec. 3.3; Tabla 4
7	Estrategia de búsqueda completa	Anexo A
8	Proceso de selección	Sec. 3 (Proceso de selección)

Ítem	**Requisito**	**Ubicación**
9	Proceso de extracción	Sec. 3 (Extracción de datos)
10	Variables extraídas	Tabla 6
11	Evaluación del riesgo de sesgo	Sec. 3; Tabla 7
12	Medidas de efecto	No aplica (síntesis sin metaanálisis); Sec. 3 (Síntesis)
13a–f	Métodos de síntesis	Sec. 3 (Síntesis)
14	Sesgo de reporte	Sec. 3 (Síntesis), justificación
15	Certeza de la evidencia	Sec. 3 (Síntesis), justificación
16a	Resultados de la búsqueda y selección	Figura 1
16b	Estudios excluidos que parecían cumplir los criterios	Anexo C
17	Características de los estudios	Tabla 8
18	Riesgo de sesgo por estudio	Tabla 9
19	Resultados de cada estudio	Tablas 8 y 20
20a–d	Resultados de las síntesis	Sec. 4 (RQ1–RQ6)
21	Sesgo de reporte en la síntesis	Sec. 4.9
22	Certeza de la evidencia	Sec. 5.4
23a–d	Discusión, limitaciones e implicaciones	Sec. 5
24a–c	Registro y protocolo	Declaraciones; Anexo A
25	Financiamiento	Declaraciones
26	Conflicto de intereses	Declaraciones
27	Disponibilidad de datos, código y materiales	Declaraciones