Detección de Anomalías en Tráfico Vehicular Urbano mediante *Deep Learning*: una Revisión Sistemática de la Literatura

Wilbert Alex Mayta Arotaype[1]

Wrangler Choquechambi Luque[2]

Ender Prieto Quispe[1]

[1]Escuela Profesional de Ingeniería de Sistemas, Universidad Peruana Unión, Juliaca, Perú.

wilbert.mayta@upeu.edu.pe wrangler.choquechambi@upeu.edu.pe juan.prieto@upeu.edu.pe

---

Resumen

Antecedentes: La gestión del tráfico vehicular urbano enfrenta crecientes desafíos debido a la alta variabilidad temporal de los flujos, la presencia de ruido y la complejidad de los patrones espacio-temporales. Los métodos estadísticos y de aprendizaje automático tradicionales muestran limitaciones ante la no linealidad de los datos y el desbalance entre eventos normales y anómalos. **Objetivo:** Analizar y sintetizar los modelos de *Deep Learning* empleados para la detección de anomalías en series temporales de tráfico vehicular urbano, así como las métricas de evaluación, los tipos de anomalías abordadas, los conjuntos de datos utilizados y las limitaciones reportadas en la literatura reciente. **Método:** Se realizó una revisión sistemática de la literatura siguiendo las directrices de Kitchenham y Charters [1]. La búsqueda se ejecutó en seis bases de datos académicas —Scopus, ScienceDirect, ISI Web of Science, ACM Digital Library, MDPI y Taylor & Francis Online— para el periodo 2020–2026. De 758 registros recuperados se seleccionaron 25 estudios primarios tras aplicar criterios de inclusión y exclusión, y una evaluación de calidad metodológica con puntuación media de 5.74 sobre 6.0. **Resultados:** Las técnicas más utilizadas son modelos recurrentes (LSTM, Bi-LSTM), convolucionales (CNN), autoencoders, redes neuronales de grafos (GNN), Transformers y arquitecturas híbridas o multimodales. Las métricas predominantes son *Accuracy*, *Precision*, *Recall*, *F1-score* y *AUC-ROC*, aunque sin protocolo de evaluación uniforme. Las anomalías más abordadas son accidentes e incidentes viales (32 %), congestión anómala (24 %), trayectorias peligrosas (24 %) y disrupciones de infraestructura (20 %). **Conclusiones:** El *Deep Learning* ofrece herramientas potentes para modelar la complejidad del tráfico urbano, con una evolución clara hacia enfoques espacio-temporales y multimodales. Sin embargo, persisten limitaciones en la disponibilidad de benchmarks públicos con etiquetas verificadas, la generalización entre contextos urbanos y la interpretabilidad de

los modelos.

Palabras clave: detección de anomalías, tráfico vehicular urbano, *Deep Learning*, series temporales, revisión sistemática

---

Abstract

Background: Urban vehicular traffic management faces growing challenges due to high temporal variability in traffic flows, noise, and the complexity of spatio-temporal patterns. Traditional statistical and machine learning methods show limitations when applied to nonlinear, imbalanced real-world traffic data. **Objective:** To analyze and synthesize the Deep Learning models used for anomaly detection in urban vehicular traffic time series, as well as the evaluation metrics, anomaly types, datasets, and limitations reported in recent literature. **Method:** A systematic literature review was conducted following Kitchenham and Charters [1] guidelines. The search was carried out in six academic databases —Scopus, ScienceDirect, ISI Web of Science, ACM Digital Library, MDPI, and Taylor & Francis Online— covering the period 2020–2026. From 758 retrieved records, 25 primary studies were selected after applying inclusion and exclusion criteria and a methodological quality assessment with a mean score of 5.74 out of 6.0. **Results:** The most frequently used techniques include recurrent models (LSTM, Bi-LSTM), convolutional networks (CNN), autoencoders, graph neural networks (GNN), Transformers, and hybrid or multimodal architectures. The predominant metrics are *Accuracy*, *Precision*, *Recall*, *F1-score*, and *AUC-ROC*, though without a uniform evaluation protocol. The most studied anomaly types are traffic accidents and incidents (32 %), anomalous flow and congestion (24 %), dangerous trajectories (24 %), and infrastructure disruptions (20 %). **Conclusions:** Deep Learning offers powerful tools for modeling the complexity of urban traffic, with a clear evolution toward spatio-temporal and multimodal approaches. However, limitations persist regarding the availability of public benchmarks with verified labels, generalization across urban contexts, and model interpretability.

Keywords: anomaly detection, urban vehicular traffic, Deep Learning, time series, systematic literature review

1. Introducción

El crecimiento acelerado de las ciudades y el aumento sostenido del parque automotor han incrementado la complejidad de la gestión del tráfico vehicular urbano y de

autopistas.[1] En estos escenarios, el flujo vehicular presenta alta variabilidad temporal, presencia de ruido y patrones difíciles de modelar mediante enfoques tradicionales. Asimismo, la dependencia espacial entre vías, sensores, intersecciones y segmentos de carretera exige considerar el tráfico como un fenómeno temporal y espacio-temporal, no solamente como una secuencia aislada de mediciones [2].

Frente a este problema, los Sistemas Inteligentes de Transporte (*Intelligent Transportation Systems*, ITS) permiten integrar sensores viales, cámaras de vigilancia, dispositivos GPS y plataformas de monitoreo para apoyar la toma de decisiones en movilidad urbana. Los datos generados por estos sistemas pueden representarse como series temporales, cuando describen la evolución de variables como flujo, velocidad u ocupación; o como datos espacio-temporales, cuando incorporan simultáneamente la ubicación de los eventos dentro de la red vial [3].

Dentro de este contexto, la detección de anomalías en el tráfico vehicular busca identificar desviaciones relevantes respecto al comportamiento esperado del sistema vial. Estas anomalías pueden manifestarse como congestiones repentinas, accidentes, cierres de vías, trayectorias peligrosas, cambios abruptos de velocidad o eventos inusuales que afectan la circulación normal. Su detección oportuna resulta importante porque permite mejorar la respuesta frente a incidentes, reducir los efectos de la congestión y fortalecer la seguridad vial [4].

Tradicionalmente, este problema fue abordado mediante métodos estadísticos y técnicas de aprendizaje automático convencional, como modelos autorregresivos, reglas basadas en umbrales, árboles de decisión y máquinas de vectores de soporte. Aunque estos enfoques han sido útiles en escenarios controlados, pueden resultar insuficientes cuando se aplican a datos reales de tráfico, debido al desbalance entre eventos normales y anómalos, la variación temporal, la dependencia espacial entre vías y la presencia de datos incompletos o ruidosos [5].

Ante estas limitaciones, el *Deep Learning* (DL) se ha convertido en una alternativa relevante para analizar datos de tráfico. En la literatura reciente se han empleado arquitecturas como LSTM, CNN, autoencoders, Transformers y redes neuronales de grafos, cada una orientada a distintos tipos de datos y problemas de detección. Por ejemplo, las CNN se han utilizado en datos visuales de vigilancia, los modelos recurrentes en secuencias temporales, las redes neuronales de grafos en la representación de redes viales y los modelos multimodales en la integración de diversas fuentes de información para detectar eventos anómalos con mayor robustez [6].

A pesar de estos avances, los estudios revisados presentan diferencias importantes

[1] Si bien el presente RSL cubre tráfico urbano y de autopistas de manera conjunta, el estudio empírico derivado de esta revisión se centra específicamente en series de flujo vehicular de autopistas (dataset PeMS-D4). Esta delimitación se declara explícitamente para evitar confusiones sobre el alcance del proyecto.

en los modelos utilizados, los tipos de anomalías abordadas, las métricas reportadas y los conjuntos de datos empleados. Esta variedad dificulta comparar directamente los resultados y reconocer qué enfoques son más adecuados para cada escenario. Por ello, se considera necesario desarrollar una Revisión Sistemática de la Literatura (RSL) que organice y analice los estudios recientes sobre detección de anomalías en series temporales de tráfico vehicular urbano mediante *Deep Learning* [1].

El presente estudio realiza cuatro contribuciones principales: (i) sintetiza el estado del arte sobre modelos de *Deep Learning* aplicados a la detección de anomalías de tráfico; (ii) identifica los modelos, datasets y métricas predominantes; (iii) clasifica los tipos de anomalías abordadas por los estudios primarios; y (iv) delimita brechas de investigación relacionadas con benchmarks, generalización, interpretabilidad y evaluación en contextos reales.

Preguntas de Investigación

1. **RQ1:** ¿Qué técnicas de *Deep Learning* han sido utilizadas para la detección de anomalías en series temporales de tráfico vehicular urbano?
2. **RQ2:** ¿Qué métricas de evaluación se han empleado para medir el rendimiento de los modelos de *Deep Learning* en la detección de anomalías de tráfico?
3. **RQ3:** ¿Qué tipos de anomalías en el tráfico vehicular urbano han sido abordadas mediante técnicas de *Deep Learning*?
4. **RQ4:** ¿Qué conjuntos de datos han sido utilizados en los estudios sobre detección de anomalías en tráfico vehicular con *Deep Learning*?
5. **RQ5:** ¿Cuáles son las limitaciones y desafíos reportados en los estudios que aplican *Deep Learning* para la detección de anomalías en series temporales de tráfico?

2. Marco Conceptual

2.1. Sistemas Inteligentes de Transporte y Tráfico Urbano

Los Sistemas Inteligentes de Transporte (*Intelligent Transportation Systems*, ITS) integran tecnologías de información, comunicación y monitoreo para mejorar la gestión de la movilidad urbana. En el contexto de esta revisión, estos sistemas permiten recolectar datos a partir de sensores viales, cámaras de vigilancia, dispositivos GPS y plataformas de monitoreo [7].

Los sensores fijos instalados en la vía suelen registrar variables como flujo, velocidad u ocupación vehicular [5]. Por otro lado, las cámaras de vigilancia se utilizan principal-

mente para analizar eventos visibles en intersecciones, autopistas o corredores urbanos. Asimismo, los datos GPS y de trayectoria permiten estudiar rutas, cierres de vías y cambios inusuales en la movilidad de los vehículos [8].

El análisis de estos datos es importante porque el tráfico urbano genera información continua, variable y dependiente tanto del tiempo como de la ubicación. Por ello, los ITS modernos requieren métodos capaces de procesar datos con alta variabilidad, presencia de ruido y relaciones espacio-temporales entre distintos segmentos de la red vial [3].

2.2. Series Temporales y Representación Espacio-Temporal

Una *serie temporal de tráfico* es una secuencia de observaciones registradas en el tiempo sobre una variable de movilidad, como velocidad, flujo u ocupación vehicular [2]. Este tipo de dato permite analizar cómo cambia el comportamiento del tráfico en un punto específico de la red vial. En algunos estudios, las series se trabajan de forma univariada; en otros, se utilizan señales multivariadas que combinan información de varios sensores o segmentos adyacentes [9].

Cuando los datos incluyen información de varias ubicaciones al mismo tiempo, se habla de una representación *espacio-temporal*. Una forma común de representar esta relación es mediante grafos, donde los nodos pueden ser sensores, intersecciones o segmentos viales, y las aristas representan conexiones entre ellos [10]. La forma en que se representan los datos influye directamente en el modelo de *Deep Learning* que se utiliza: las series temporales suelen procesarse con modelos recurrentes, mientras que los datos con estructura de red vial pueden requerir redes neuronales de grafos [11]; cuando la fuente principal son cámaras, los datos se tratan como imágenes o secuencias de video mediante arquitecturas convolucionales [12].

2.3. Anomalías en el Tráfico Vehicular Urbano

En el contexto de los ITS, una *anomalía de tráfico* puede entenderse como un evento o patrón que se aleja del comportamiento normal esperado del flujo vehicular [3]. Estas anomalías pueden aparecer en forma de accidentes, congestiones no recurrentes, cierres de vías, eventos extremos o trayectorias vehiculares inusuales [13]. Un reto importante en este problema es que las anomalías suelen ser menos frecuentes que los eventos normales, lo que genera conjuntos de datos desbalanceados y puede afectar el entrenamiento y la evaluación de los modelos de detección [14].

2.4. Técnicas de *Deep Learning* para Detección de Anomalías

El *Deep Learning* (DL) agrupa técnicas basadas en redes neuronales profundas que permiten aprender patrones complejos a partir de grandes volúmenes de datos. En la

detección de anomalías de tráfico, se identifican tres enfoques principales:

- **Modelos de predicción**: Aprenden el comportamiento esperado de una serie temporal y detectan anomalías cuando existe una diferencia importante entre el valor esperado y el observado. En este grupo se encuentran LSTM, GRU y Transformers [9].
- **Modelos de reconstrucción**: Como los autoencoders, aprenden a reconstruir datos normales de tráfico y clasifican como posibles anomalías los casos donde el error de reconstrucción es alto [15]. Este enfoque es útil cuando no se cuenta con suficientes etiquetas de eventos anómalos.
- **Modelos de clasificación supervisada**: Cuando los datos incluyen etiquetas de eventos normales y anómalos, las redes CNN se han aplicado al análisis de imágenes y videos de tráfico [4]. Las redes neuronales de grafos (GNN) permiten representar la red vial y resultan adecuadas para analizar relaciones espacio-temporales [11].

La selección de una arquitectura no depende únicamente del rendimiento reportado, sino también del tipo de dato disponible. Por ejemplo, los datos tabulares de sensores suelen favorecer modelos secuenciales o de reconstrucción; los videos de vigilancia requieren arquitecturas convolucionales o modelos de visión; las trayectorias GPS demandan representaciones espacio-temporales; y las redes viales con sensores distribuidos pueden beneficiarse de modelos basados en grafos. Esta relación entre fuente de datos y arquitectura es central para interpretar los resultados de la revisión.

3. Proceso Metodológico

Esta revisión sigue el protocolo de Kitchenham y Charters [1] para la realización de revisiones sistemáticas en ingeniería de software, adaptado al área de detección de anomalías en series temporales de tráfico vehicular urbano mediante *Deep Learning*.

3.1. Protocolo PICOC

Cuadro 1: Marco PICOC de la revisión sistemática.

Elemento	Descripción
Población	Sistemas de tráfico vehicular urbano, redes viales y datos de flujo vehicular provenientes de sensores, cámaras y dispositivos GPS
Intervención	Técnicas de *Deep Learning* aplicadas a la detección de anomalías en series temporales, incluyendo LSTM, GRU, CNN, Autoencoder, Transformer y modelos híbridos
Comparación	Métodos tradicionales de *machine learning*, técnicas estadísticas clásicas (ARIMA, SVM) y enfoques basados en reglas
Resultado	Precisión en la detección de anomalías medida mediante métricas como F1-score, Precision, Recall, AUC-ROC, Accuracy y *False Positive Rate*
Contexto	Entornos urbanos, sistemas inteligentes de transporte (ITS), ciudades inteligentes y monitoreo de tráfico con sensores, cámaras o datos GPS (2020–2026)

3.2. Bases de Datos y Cadena de Búsqueda

La búsqueda bibliográfica se realizó en seis bases de datos académicas seleccionadas por su relación con ingeniería, ciencias de la computación y transporte inteligente:

- Scopus (https://www.scopus.com)
- ScienceDirect/Elsevier (https://www.sciencedirect.com)
- ISI Web of Science (https://www.webofscience.com)
- ACM Digital Library (https://dl.acm.org)
- MDPI (https://www.mdpi.com)
- Taylor & Francis Online (https://www.tandfonline.com)

Como herramienta de apoyo se utilizó Parsif.al (https://parsif.al), donde se registró la cadena de búsqueda, los criterios de selección y las decisiones de inclusión o exclusión de cada estudio.

La cadena de búsqueda se formuló inicialmente en inglés, dado que la mayoría de bases de datos indexadas utilizan este idioma para títulos, resúmenes y palabras clave. Los términos no preseleccionan modelos específicos para evitar sesgo de confirmación, siguiendo la recomendación de Kitchenham y Charters [1].

La cadena de búsqueda fue construida a partir del marco PICOC y ajustada iterativamente en Parsifal de acuerdo con la sintaxis de cada base de datos. Posteriormente, fue revisada por el autor para verificar su coherencia con las preguntas de investigación, los criterios de inclusión y exclusión, y el alcance temático de la revisión. Esta decisión se registra de manera prudente, dado que no se afirma una validación externa formal por un experto independiente.

Cadena base general:

```
("traffic anomaly detection" OR "anomaly detection" OR "incident
detection")
AND ("deep learning" OR LSTM OR GRU OR CNN OR autoencoder OR
transformer OR "graph neural network")
AND ("time series" OR "spatio-temporal" OR "traffic flow")
AND ("urban traffic" OR "vehicular traffic" OR "road traffic" OR
"intelligent transportation")
```

3.3. Criterios de Inclusión y Exclusión

Cuadro 2: Criterios de selección de estudios primarios.

Cód.	Criterio
Inclusión	
CI-1	Estudios publicados en revistas científicas indexadas o conferencias revisadas por pares
CI-2	Estudios publicados en idioma inglés o español con acceso al texto completo
CI-3	Estudios publicados entre 2020 y 2026
CI-4	Estudios que aborden la detección de anomalías en tráfico vehicular urbano, flujo vehicular o sistemas inteligentes de transporte
CI-5	Estudios que utilicen *Deep Learning* como método principal sobre series temporales o datos espacio-temporales de tráfico vehicular
CI-6	Estudios que reporten resultados cuantitativos mediante métricas como Accuracy, Precision, Recall, F1-score, AUC-ROC o *False Positive Rate*
Exclusión	
CE-1	Artículos duplicados entre bases de datos; se conservó la versión más completa del estudio
CE-2	Estudios no relacionados con tráfico vehicular urbano, flujo vehicular o sistemas inteligentes de transporte
CE-3	Estudios que solo realicen predicción de tráfico, clasificación general o *forecasting*, sin abordar explícitamente la detección de anomalías
CE-4	Estudios que no utilicen *Deep Learning* como método principal (SVM, ARIMA, reglas estadísticas, umbrales o métodos tradicionales)
CE-5	Revisiones sistemáticas, *surveys*, metaanálisis, capítulos de libro, tesis, resúmenes, pósteres o literatura gris
CE-6	Estudios sin acceso completo, sin métricas cuantitativas, sin descripción clara del modelo, del conjunto de datos o de los resultados experimentales

3.4. Proceso de Selección y Evaluación de Calidad

El proceso sigue las tres fases de Kitchenham y Charters [1]: Planificación, Ejecución y Documentación. La Figura 1 ilustra el flujo completo.

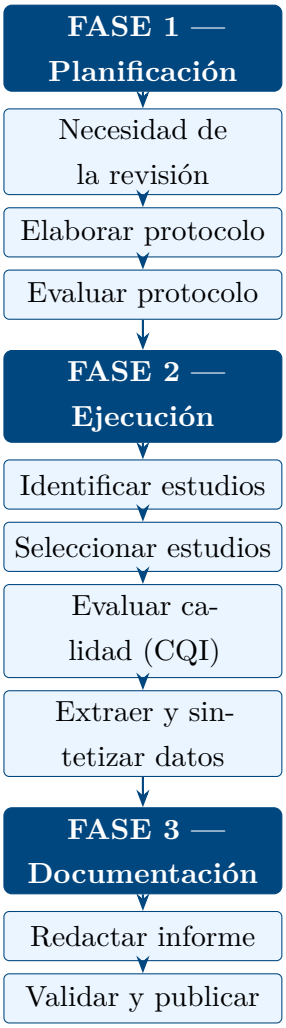


Figura 1: Proceso RSL según Kitchenham y Charters [1].

Cuadro 3: Registros importados por base de datos en Parsifal.

Base de datos	**Registros importados**
ACM Digital Library	92
ISI Web of Science	137
ScienceDirect	318
Scopus	46
Taylor & Francis Online	50
MDPI	115
Total	**758**

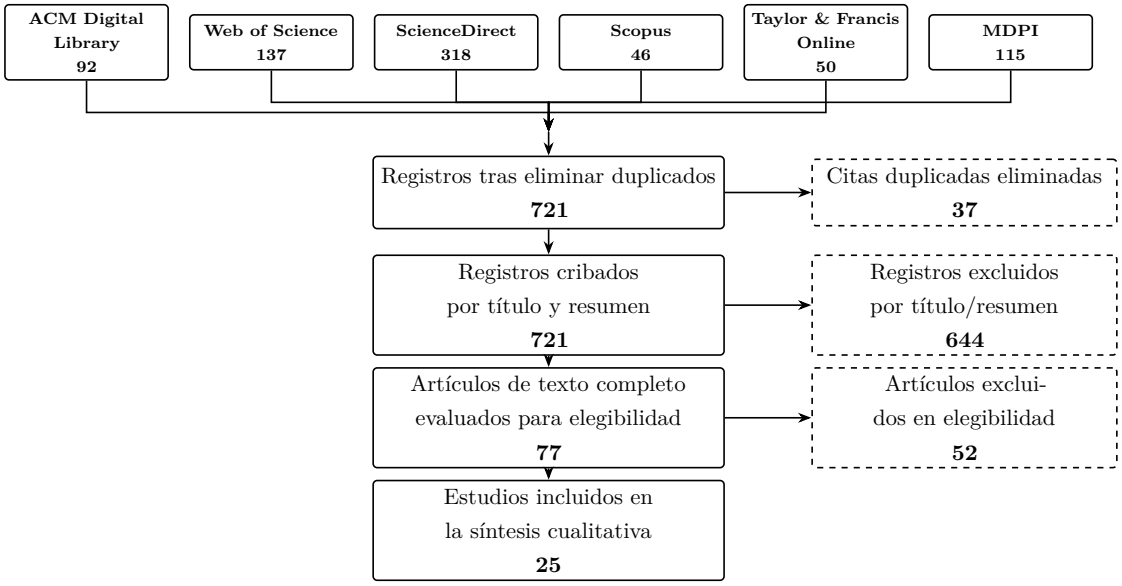


Figura 2: Flujo de selección de estudios registrado en Parsifal.

El proceso de selección inició con 758 registros importados desde seis bases de datos. Luego de eliminar 37 citas duplicadas, se obtuvieron 721 registros. En la fase de cribado se excluyeron 644 registros por no cumplir los criterios de inclusión o por no responder al alcance de la revisión, quedando 77 registros candidatos. Posteriormente, se evaluaron los estudios en función de disponibilidad de texto completo, pertinencia metodológica, uso de *Deep Learning*, tipo de datos y resultados cuantitativos. Finalmente, 25 estudios fueron incluidos en la síntesis cualitativa. La diferencia entre los 77 registros candidatos y los 25 estudios finales corresponde a 52 artículos excluidos en la etapa de elegibilidad.

Para la evaluación de calidad se diseñó un instrumento (CQI) de 6 criterios con la

siguiente escala: Sí cumple (1.0), Parcialmente (0.5), No cumple (0.0). La puntuación máxima posible fue de 6.0 y el umbral mínimo de inclusión se estableció en 4.0.

Aplicación del CQI. Cada estudio primario fue evaluado individualmente por los tres autores siguiendo los 6 criterios. Las discrepancias se resolvieron por consenso en sesiones de revisión conjunta. Las puntuaciones finales se agregaron por estudio y se reportan en la Tabla 6. La dispersión observada en las puntuaciones es reducida (rango 5.5–6.0; desviación estándar $\sigma \approx 0.25$) porque el proceso de cribado previo aplicó los criterios CI/CE de manera estricta: los estudios con puntuaciones inferiores a 5.5 fueron descartados en la etapa de elegibilidad. Esta estrechez del rango no invalida el instrumento, pero se declara explícitamente como limitación de la evaluación de calidad.

Cuadro 4: Instrumento de evaluación de calidad (CQI).

Ítem	**Criterio**	**Descripción**
CQ-1	Enfoque en anomalías	¿El estudio aborda la detección de anomalías en tráfico vehicular urbano como problema principal?
CQ-2	Uso de *Deep Learning*	¿El estudio utiliza DL como método principal (LSTM, CNN, Autoencoder, Transformer o modelos híbridos)?
CQ-3	Datos secuenciales	¿El estudio usa datos de series temporales o espacio-temporales (sensores, GPS, flujo vehicular)?
CQ-4	Métricas cuantitativas	¿El estudio reporta métricas como F1-score, Precision, Recall, AUC-ROC, Accuracy o similares?
CQ-5	Descripción metodológica	¿El estudio describe claramente la arquitectura del modelo y el proceso de preprocesamiento, entrenamiento y evaluación?
CQ-6	Resultados evaluables	¿El estudio presenta resultados claros, evaluación experimental o comparación con otros métodos?
Puntuación máxima		6.0
Umbral de inclusión		≥ 4.0
Puntuación media observada		5.74
Desviación estándar		$\sigma \approx 0.25$
Rango		5.5–6.0

3.5. Extracción de Datos

Los datos de cada estudio primario se extrajeron siguiendo el formulario del Cuadro 5, diseñado conforme a las pautas de Kitchenham y Charters [1].

Cuadro 5: Formulario de extracción de datos.

Campo	**Descripción**
ID	Identificador único del estudio (E01, E02, . . .)
Autor y año	Apellido del primer autor y año de publicación
Título	Título completo del artículo revisado
Fuente	Revista, conferencia o repositorio de publicación
Modelo DL	Arquitectura empleada (LSTM, CNN, Autoencoder, Transformer, GNN o híbridos)
Tipo de datos	Fuente principal (sensores, cámaras, GPS, series temporales)
Conjunto de datos	Nombre del dataset o descripción de la fuente
Tipo de dataset	Clasificación: real, simulado o mixto
Tipo de anomalía	Clase de anomalía abordada (accidentes, congestión, trayectorias, etc.)
Métricas	Indicadores de rendimiento reportados
Resultado principal	Hallazgo o desempeño más relevante reportado
Limitaciones	Restricciones, debilidades o desafíos señalados por los autores

3.6. Estrategia de Síntesis

La síntesis de resultados se realizó de manera descriptiva y comparativa. Primero, los estudios fueron agrupados según la arquitectura principal de *Deep Learning*: modelos recurrentes, convolucionales, autoencoders, redes neuronales de grafos, Transformers y modelos híbridos o multimodales. Segundo, se identificaron las métricas de evaluación reportadas, diferenciando entre métricas de clasificación, error de predicción, localización visual y desempeño operativo. Tercero, se clasificaron los tipos de anomalías abordadas, considerando accidentes, congestión anómala, trayectorias peligrosas, cierres de vías y eventos inusuales. Finalmente, se analizaron las limitaciones reportadas para construir una lectura transversal de las brechas del campo.

No se realizó metaanálisis cuantitativo debido a la heterogeneidad de los datasets,

tareas, métricas y condiciones experimentales. En su lugar, se optó por una síntesis narrativa apoyada en tablas comparativas, lo cual resulta más apropiado cuando los estudios primarios no comparten un protocolo experimental uniforme.

4. Resultados

4.1. Descripción General de los Estudios

Se incluyeron **25 estudios primarios** publicados entre 2020 y 2026. La distribución temporal muestra crecimiento sostenido: 2 estudios en 2020, 2 en 2021, 5 en 2022, 2 en 2023, 5 en 2024, 7 en 2025 y 2 en 2026. Este comportamiento refleja una aceleración reciente del interés investigativo en modelos espacio-temporales, grafos, Transformers y enfoques multimodales [6, 11]. La puntuación media de calidad fue de 5.74/6.0, con 12 estudios (48 %) alcanzando 6.0 y 13 estudios (52 %) obteniendo 5.5.

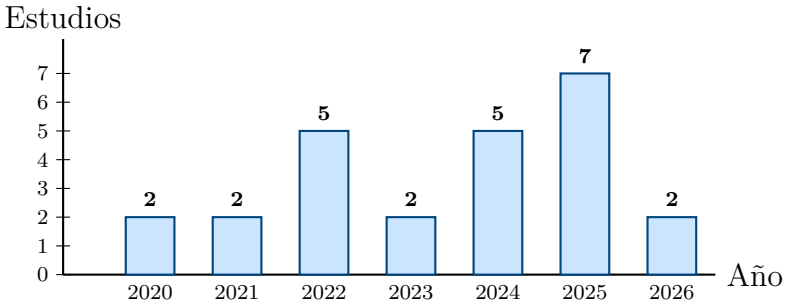


Figura 3: Distribución anual de publicaciones incluidas (N=25).

Cuadro 6: Estudios primarios seleccionados.

ID	Referencia	Objetivo abreviado	Año	CQI	RQ
E01	[2]	Aplicabilidad de métodos de detección en series temporales de volumen vehicular	2026	5.5	RQ1, RQ2, RQ4, RQ5
E02	[7]	Marco DL en borde para mantenimiento predictivo en infraestructura urbana	2025	6.0	RQ1, RQ2, RQ3, RQ4

ID	Referencia	Objetivo abreviado	Año	CQI	RQ
E03	[16]	Detección de anomalías urbanas de tráfico con datos de monitoreo	2024	5.5	RQ1, RQ3, RQ4
E04	[3]	Detección automática de anomalías con ST-GNN	2022	6.0	RQ1, RQ2, RQ3
E05	[13]	Detección de eventos extremos con autoencoder de grafos contextualizado	2022	6.0	RQ1, RQ2, RQ3
E06	[17]	Detección y localización de accidentes viales en video	2022	6.0	RQ1, RQ2, RQ3, RQ4
E07	[5]	Detección de incidentes en vía rápida urbana con ciclo de aprendizaje profundo	2020	5.5	RQ1, RQ2, RQ3, RQ5
E08	[14]	Representación profunda de datos espacio-temporales desbalanceados	2023	6.0	RQ1, RQ2, RQ5
E09	[9]	Clasificación multietapa de eventos anómalos con LSTM y atención	2025	6.0	RQ1, RQ2, RQ3
E10	[12]	Detección de casi accidentes en intersecciones con CNN de dos flujos	2020	6.0	RQ1, RQ2, RQ3
E11	[11]	Transformer multiresolución en grafos para anomalías a nivel carril	2025	6.0	RQ1, RQ2, RQ4

ID	Referencia	Objetivo abreviado	Año	CQI	RQ
E12	[6]	Fusión profunda multimodal para detección de anomalías en autopista	2025	6.0	RQ1, RQ2, RQ3
E13	[8]	Detección de cierres de vías mediante fusión de características	2021	5.5	RQ1, RQ3, RQ4
E14	[10]	Autoencoder de grafos con red de convolución temporal especular	2024	6.0	RQ1, RQ2, RQ3
E15	[18]	Modelo secuencial multitarea auto-imputado para disrupciones extremas	2025	5.5	RQ1, RQ2, RQ4, RQ5
E16	[19]	Detección de anomalías basada en predicción con extracción multidominio	2025	6.0	RQ1, RQ2, RQ4
E17	[15]	Autoencoder variacional recurrente con atención estructural en autopistas	2023	5.5	RQ1, RQ2, RQ4
E18	[4]	Detección de anomalías en video de vigilancia vehicular con DL	2022	6.0	RQ1, RQ2, RQ3
E19	[20]	Detección de anomalías viales con aprendizaje texto-visión y atención humana	2026	5.5	RQ1, RQ2, RQ3
E20	[21]	Sistema predictivo para anomalías de tráfico y conducción peligrosa	2022	5.5	RQ1, RQ2, RQ3

ID	Referencia	Objetivo abreviado	Año	CQI	RQ
E21	[22]	Reconocimiento de trayectorias peligrosas en autopistas ultra-largas	2024	5.5	RQ1, RQ2, RQ3
E22	[23]	Detección multiescala de trayectorias espacio-temporales anómalas	2024	6.0	RQ1, RQ2, RQ3, RQ5
E23	[24]	Aprendizaje de anomalías de tráfico desde modelos generativos	2025	5.5	RQ1, RQ2, RQ4, RQ5
E24	[25]	Detección e identificación de anomalías con aprendizaje multi-instancia	2021	5.5	RQ1, RQ2, RQ3
E25	[26]	Detección de comportamiento vehicular anormal con Dense Block	2024	5.5	RQ1, RQ2, RQ3

4.2. RQ1: Técnicas de *Deep Learning* implementadas

Los 25 estudios revelan seis familias de modelos utilizadas para la detección de anomalías en tráfico vehicular. Los modelos recurrentes (LSTM, Bi-LSTM) son frecuentes en estudios basados en series temporales de flujo, velocidad u ocupación vehicular [14]. Jadhav et al. combinan LSTM con atención multi-cabezal para clasificación multi-etapa de eventos anómalos [9]. Jia et al. emplean Bi-LSTM junto con GAT y Transformer para integrar características temporales, espaciales y frecuenciales [19].

Las arquitecturas convolucionales (CNN) aparecen principalmente en trabajos basados en cámaras o video. Huang et al. proponen una red CNN de dos flujos para detectar casi accidentes en intersecciones [12]. Khan et al. emplean CNN para detectar accidentes en videos de vigilancia [4]. Los modelos basados en grafos (GNN) tienen una presencia importante en los trabajos más recientes: Zhang et al. utilizan ST-GNN para detección automática de anomalías en red vial [3]; Park et al. plantean un Graph Multi-Resolution Transformer para anomalías a nivel de carril [11]. Los enfoques híbridos y multimodales, como el de Abdallah y Alghamdi que integra CNN, Transformer y LSTM [7], y el de Duan et al. con fusión de imagen, flujo, velocidad y clima [6], representan la tendencia más reciente del campo.

Cuadro 7: Familias de modelos de *Deep Learning* identificadas (RQ1).

Familia de modelo	**Menciones**	**Ejemplos representativos**
Modelos recurrentes y secuenciales	7	LSTM, Bi-LSTM, SI-DMSeq
Modelos convolucionales y de video	7	CNN, Two-stream CNN, Dense Block
Autoencoders y modelos de reconstrucción	5	Con-GAE, MTGAE, VAE
Modelos basados en grafos	7	GNN, GAT, HGNN, Graph Autoencoder
Transformers y mecanismos de atención	6	GMRT, CLIP, multi-head attention
Modelos híbridos o multimodales	8	CNN–Transformer–LSTM, STGAN

Hallazgo

Los estudios recientes muestran una transición desde modelos centrados en series temporales individuales hacia enfoques híbridos, espacio-temporales y multimodales. Esta tendencia sugiere que la detección de anomalías de tráfico requiere integrar dependencias temporales, relaciones espaciales de la red vial y fuentes heterogéneas de datos [6, 11].

4.3. RQ2: Métricas de Evaluación

Las métricas reportadas se agrupan en cinco categorías. Las métricas de clasificación son las más frecuentes: *Accuracy*, *Precision*, *Recall*, *F1-score* y *AUC-ROC* aparecen en estudios que formulan la detección como tarea supervisada [4, 6, 9]. En los enfoques de predicción o reconstrucción predominan métricas de error como MAE, RMSE, MAPE y NSE [10, 19]. Algunos estudios reportan métricas específicas de detección de incidentes, como *Detection Rate*, *False Alarm Rate* y *Mean Time to Detection* [5]. Los estudios basados en video emplean métricas de localización como IoU y mAP [12, 17]. Trabajos recientes incluyen métricas operativas como latencia y consumo energético orientadas al despliegue en tiempo real [7].

Cuadro 8: Síntesis de métricas de evaluación identificadas (RQ2).

Tipo de métrica	**Menciones**	**Ejemplos**
Clasificación general	9	Accuracy, Precision, Recall, F1-score, AUC-ROC
Errores de predicción	6	MAE, RMSE, MAPE, NSE
Detección de incidentes	4	Detection Rate, False Positive Rate, MTTD, EER
Localización visual	2	IoU, mAP
Robustez y operación	4	Latencia, consumo energético, tiempo de inferencia

Hallazgo

Accuracy, *Precision*, *Recall*, *F1-score* y *AUC-ROC* son las métricas predominantes. Sin embargo, la literatura carece de un protocolo común de evaluación. Para futuras investigaciones, se recomienda reportar conjuntamente métricas de clasificación, de error y operativas, especialmente cuando el modelo esté orientado a sistemas de monitoreo en tiempo real [2].

4.4. RQ3: Tipos de Anomalías Abordadas

Los estudios revisados agrupan las anomalías en cuatro categorías principales. La más frecuente, accidentes e incidentes viales, aparece en 8 estudios (32 %): incluye accidentes vehiculares, incidentes en autopistas y casi accidentes detectados mediante cámaras o sensores [4, 5, 12, 17]. La congestión o flujo anómalo está presente en 6 estudios (24 %), centrándose en desviaciones del comportamiento esperado del flujo, volumen, velocidad u ocupación vehicular [10, 16, 19]. Los patrones anómalos de trayectoria o comportamiento vehicular representan otro 24 %: exceso de velocidad, conducción peligrosa, rutas inusuales y comportamientos vehiculares anormales [15, 21, 23]. Finalmente, 5 estudios (20 %) abordan eventos inusuales o disrupciones de infraestructura, como cierres de vías, fallos de sensores, condiciones climáticas extremas y eventos de gran escala [8, 13, 18].

Cuadro 9: Categorías de anomalías abordadas en los estudios (RQ3).

Categoría de anomalía	**Estudios**	**%**
Accidentes e incidentes viales	8	32 %
Congestión o flujo anómalo	6	24 %
Patrones anómalos de trayectoria o conducta	6	24 %
Eventos inusuales o disrupciones de infraestructura	5	20 %
Total	**25**	**100 %**

Hallazgo

Las anomalías más estudiadas son accidentes, incidentes viales y congestiones anómalas. No obstante, los trabajos recientes incorporan nuevas categorías: fallos de infraestructura, eventos extremos, trayectorias peligrosas y comportamientos vehiculares anormales. Esta ampliación del concepto de anomalía muestra que la detección en tráfico vehicular urbano está evolucionando hacia enfoques más integrales y multimodales [6, 7].

4.5. RQ4: Conjuntos de Datos Utilizados

Los estudios primarios utilizan conjuntos de datos provenientes de sensores fijos, cámaras de vigilancia, trayectorias GPS, plataformas de monitoreo urbano y entornos simulados. Los sensores fijos y datos de flujo vehicular son una de las fuentes más utilizadas, con datasets como PeMS, PEMS-BAY, PEMS04, PEMS08 y MnDOT [5, 14, 19]. Taheri et al. proponen AnoLT, un dataset etiquetado de volumen vehicular de Melbourne orientado específicamente a la evaluación de métodos de detección [2]. Las cámaras de vigilancia aportan datos en estudios como TNAD, VAID, IITH, Iowa DOT y DoTA [4, 12, 17]. Los datos GPS y trayectorias cubren bases como NYC Taxi, Chicago Taxi, Uber Movement y conjuntos de Shanghai y Chengdu [8, 13, 23]. Un aspecto crítico es que no todos los estudios cuentan con etiquetas de anomalías verificadas por expertos: algunos recurren a anomalías inyectadas [10] o generación controlada [23], lo que limita la comparación entre modelos.

Cuadro 10: Fuentes de datos utilizadas en los estudios primarios (RQ4).

Fuente de datos	**Menciones**	**Ejemplos de datasets**
Sensores fijos y datos de flujo	9	PeMS, PEMS-BAY, PEMS04, AnoLT
Cámaras y video de vigilancia	9	TNAD, VAID, IITH, DoTA, TADS
GPS, taxis y trayectorias	5	NYC Taxi, Chicago Taxi, Porto
Datos simulados	2	MAAD, VISSIM Pangyo
Datos multimodales o mixtos	3	SUMO, UA-DETRAC, clima+imagen

Hallazgo

La mayoría de estudios utiliza datos reales de sensores fijos, cámaras o trayectorias GPS. Sin embargo, la falta de etiquetas verificadas, el uso de anomalías inyectadas y la dependencia de datasets propios limitan la replicabilidad. Esto evidencia la necesidad de benchmarks públicos, multimodales y estandarizados para evaluar modelos de detección de anomalías en tráfico vehicular urbano [2].

4.6. RQ5: Limitaciones y Desafíos Reportados

Los estudios primarios reportan cinco categorías principales de limitaciones. La escasez de datos y la replicabilidad afectan a 7 estudios: el uso de datasets propios, locales o de acceso limitado impide la reproducción de experimentos en otros escenarios [5,16,24]. El etiquetado de anomalías es problemático en 6 estudios, que recurren a anomalías sintéticas, etiquetas automáticas o validación manual parcial, lo que afecta la validez externa de los resultados [9,10,23]. La generalización también aparece en 6 estudios: la evaluación en una sola ciudad, autopista o entorno simulado limita la transferencia de los modelos a nuevos contextos [14,15,18]. La heterogeneidad de métricas en 5 estudios impide la comparación directa entre modelos que abordan problemas similares [2,19,21]. Finalmente, el costo computacional y el despliegue en tiempo real constituyen una limitación en 5 estudios que emplean modelos basados en grafos, Transformers o datos multimodales [6,7,11].

Cuadro 11: Limitaciones y desafíos reportados en los estudios primarios (RQ5).

Tipo de limitación	**Menciones**	**Descripción resumida**
Datos y replicabilidad	7	Datasets propios, locales o de acceso limitado
Etiquetado de anomalías	6	Anomalías sintéticas o validación manual parcial
Generalización	6	Evaluación en ciudad, autopista o entorno único
Métricas no uniformes	5	Ausencia de métricas completas o comparables
Costo computacional y despliegue	5	Modelos pesados o dependientes de infraestructura avanzada

Hallazgo

Las principales limitaciones son la escasez de datasets públicos con etiquetas verificadas, la evaluación en contextos urbanos específicos, el uso de anomalías artificiales, la falta de métricas uniformes y el alto costo computacional de modelos complejos. Estas limitaciones evidencian la necesidad de benchmarks abiertos, protocolos de evaluación comparables y modelos más generalizables para su aplicación en sistemas inteligentes de transporte [2, 7].

4.7. Mapa de Evidencia

La Tabla 12 resume las técnicas y enfoques identificados y su cobertura por pregunta de investigación.

Cuadro 12: Mapa de evidencia: técnicas / enfoques vs. preguntas de investigación.

Técnica / Enfoque	**RQ1**	**RQ2**	**RQ3**	**RQ4**	**RQ5**
Modelos recurrentes (LSTM, Bi-LSTM)	✓	✓	✓	✓	–
Modelos convolucionales (CNN, Two-stream)	✓	✓	✓	✓	–
Autoencoders y modelos de reconstrucción	✓	✓	✓	–	✓
Redes neuronales de grafos (GNN, GAT)	✓	✓	✓	✓	✓
Transformers y mecanismos de atención	✓	✓	–	✓	✓
Arquitecturas híbridas y multimodales	✓	✓	✓	✓	✓
Benchmarks públicos estandarizados	–	✓	–	✓	✓
Despliegue en tiempo real y borde	–	✓	–	–	✓
Modelos generativos y aprendizaje no supervisado	✓	✓	✓	–	✓

5. Discusión

5.1. Interpretación de los Resultados

Los resultados confirman que el *Deep Learning* ha alcanzado un nivel de madurez técnica relevante para la detección de anomalías en tráfico vehicular urbano [3, 11]. La evolución observada no es lineal y no sigue una progresión estrictamente acumulativa: los estudios del periodo 2020–2022 se distribuyen de manera heterogénea entre modelos convolucionales (CNN de dos flujos, redes de video), recurrentes y de reconstrucción, mientras que a partir de 2023 se observa una mayor presencia de arquitecturas basadas en grafos, mecanismos de atención, Transformers y fusión multimodal [6, 11, 20]. Este cambio sugiere que la comunidad investigadora reconoce al tráfico como un fenómeno distribuido, dependiente del tiempo, de la ubicación y del contexto operativo, aunque sin abandonar las familias arquitectónicas previas.

Una primera lectura transversal indica que no existe una arquitectura dominante para todos los escenarios. Las CNN y las redes de video son adecuadas cuando la anomalía es visualmente observable, como accidentes o casi accidentes en intersecciones [4, 12]. Los modelos recurrentes y de predicción son más pertinentes cuando se trabaja con series de velocidad, flujo u ocupación vehicular [9, 19]. Los autoencoders y modelos variacionales resultan útiles cuando se dispone de abundantes datos normales pero pocas etiquetas anómalas [13, 15]. Finalmente, las redes neuronales de grafos y los Transformers ofrecen ventajas cuando se necesita representar relaciones entre segmentos de vía, sensores, carriles o regiones urbanas [10, 11].

La revisión también muestra que la evaluación del rendimiento depende fuertemente del tipo de tarea. En problemas de clasificación supervisada, las métricas como *Accuracy*, *Precision*, *Recall* y *F1-score* permiten comparar modelos bajo un mismo conjunto de datos. Sin embargo, en escenarios con fuerte desbalance, el *F1-score*, el AUC-ROC y el PR-AUC suelen ser más informativos que la exactitud global [2, 23]. En sistemas de monitoreo real, además del rendimiento predictivo, deberían reportarse latencia, tiempo de inferencia, estabilidad temporal y costo computacional, porque una alerta tardía puede tener bajo valor operativo.

Desde una perspectiva metodológica, la heterogeneidad de datasets y métricas impide afirmar de forma absoluta que una arquitectura sea superior a otra. Por ello, los resultados deben interpretarse como evidencia comparativa y no como ranking universal. La contribución más importante de esta RSL consiste en organizar dicha evidencia, mostrando qué técnicas se asocian con qué tipos de datos, qué anomalías se han estudiado con mayor frecuencia y qué limitaciones se repiten en la literatura.

5.2. Implicaciones para Sistemas Inteligentes de Transporte

Para los sistemas ITS, los hallazgos sugieren que la detección de anomalías no debe implementarse como una solución aislada. En aplicaciones reales, un modelo debería integrarse con fuentes de datos confiables, reglas de validación, paneles de monitoreo, protocolos de alerta y mecanismos de explicabilidad. La combinación de datos visuales, sensores de flujo, trayectorias GPS y contexto urbano puede mejorar la robustez del sistema, pero también aumenta la complejidad del procesamiento y del despliegue [6, 7].

Asimismo, los operadores de transporte requieren modelos que no solo indiquen que existe una anomalía, sino que también ayuden a interpretar su posible causa, ubicación, severidad y evolución temporal. Por esta razón, la interpretabilidad debe considerarse un requisito práctico y no solo una característica secundaria. En escenarios urbanos, donde las decisiones pueden afectar la movilidad y la seguridad de muchas personas, la explicabilidad de los modelos es clave para fortalecer la confianza en los sistemas automatizados.

5.3. Brechas de Investigación

Se identifican cuatro brechas principales para futuras investigaciones. La primera es la **ausencia de benchmarks públicos multimodales con etiquetas verificadas**. Aunque existen datasets ampliamente utilizados como PeMS, VAID, TNAD, TADS o AnoLT, no todos fueron diseñados con la misma finalidad ni poseen etiquetas de anomalías verificadas bajo criterios homogéneos [2, 4, 12]. Esto dificulta reproducir experimentos y comparar modelos de manera justa.

La segunda brecha es la **limitada generalización entre contextos urbanos**. Muchos modelos se entrenan y evalúan en una ciudad, autopista o red vial específica. Sin embargo, los patrones de movilidad cambian según infraestructura, cultura vial, densidad vehicular, clima y disponibilidad de sensores. El aprendizaje por transferencia, el aprendizaje federado y la adaptación de dominio representan líneas prometedoras para reducir esta dependencia contextual.

La tercera brecha es el **tratamiento de datos escasos, desbalanceados o incompletos**. Las anomalías reales son poco frecuentes y, en muchos casos, no están etiquetadas con precisión. Esto afecta especialmente a los modelos supervisados, que pueden aprender patrones dominados por la clase normal [14]. Los enfoques no supervisados, semi-supervisados, generativos y basados en reconstrucción ofrecen alternativas relevantes, pero aún requieren validación más amplia en escenarios reales.

La cuarta brecha es la **interpretabilidad y explicabilidad de los modelos**. La mayoría de arquitecturas profundas opera como caja negra, dificultando que un operador comprenda el origen de una alerta antes de tomar decisiones. Algunos trabajos incorporan mecanismos de explicabilidad mediante SHAP o mapas de atención [7], pero esta práctica todavía no es generalizada. En sistemas críticos de transporte, la explicabilidad debe formar parte del diseño del modelo y del reporte experimental.

5.4. Amenazas a la Validez

Siguiendo a Kitchenham y Charters [1], se consideran cuatro amenazas principales. En primer lugar, la **validez de construcción** puede verse afectada por la cadena de búsqueda, ya que algunos estudios relevantes podrían utilizar términos diferentes a los empleados en esta revisión. Para mitigar este riesgo, se combinaron términos relacionados con detección de anomalías, tráfico vehicular, series temporales, datos espacio-temporales y técnicas de *Deep Learning*.

En segundo lugar, la **validez interna** puede estar influida por decisiones de inclusión o exclusión durante la selección de estudios. Esta amenaza se redujo mediante criterios CI/CE definidos previamente, un instrumento de calidad metodológica y el uso de Parsifal para registrar las decisiones de revisión. En tercer lugar, la **validez externa** se encuentra limitada por el periodo 2020–2026, el predominio de estudios en inglés y la concentración de datasets en ciertos países o ciudades. Por tanto, los hallazgos deben interpretarse en relación con el corpus analizado.

Finalmente, la **validez de conclusión** se ve condicionada por la heterogeneidad de métricas, datasets y tipos de anomalías. Para mitigar esta amenaza, la síntesis se realizó de forma narrativa y comparativa, evitando un metaanálisis cuantitativo no sustentado por datos homogéneos. Esta decisión permite presentar conclusiones más prudentes y coherentes con la diversidad metodológica de los estudios primarios.

6. Conclusiones

Esta RSL analizó 25 estudios primarios publicados entre 2020 y 2026, siguiendo las directrices de Kitchenham y Charters [1]. A partir de 758 registros recuperados en seis bases de datos académicas, se aplicaron criterios de inclusión, exclusión y evaluación de calidad, obteniéndose una puntuación media de 5.74/6.0. El corpus final permite caracterizar el estado reciente de la detección de anomalías en tráfico vehicular urbano mediante *Deep Learning*.

En relación con **RQ1**, las técnicas más utilizadas son modelos recurrentes, modelos convolucionales, autoencoders, redes neuronales de grafos, Transformers y arquitecturas híbridas o multimodales. La tendencia más reciente se orienta hacia modelos capaces de integrar dependencias temporales, relaciones espaciales y fuentes heterogéneas de datos [6, 11, 20]. Esta evolución confirma que el tráfico urbano no puede entenderse únicamente como una secuencia temporal, sino como un sistema dinámico, distribuido y condicionado por el contexto.

Respecto a **RQ2**, las métricas predominantes son *Accuracy*, *Precision*, *Recall*, *F1-score* y *AUC-ROC*. Sin embargo, la falta de un protocolo uniforme de evaluación impide comparar de manera directa todos los estudios. En escenarios desbalanceados, se recomienda priorizar métricas como *F1-score*, AUC-ROC o PR-AUC, junto con indicadores operativos como latencia, tiempo de inferencia y estabilidad del sistema.

Sobre **RQ3**, las anomalías más abordadas son accidentes e incidentes viales, congestión anómala, trayectorias peligrosas y disrupciones de infraestructura. Esta clasificación evidencia que el concepto de anomalía se ha ampliado: ya no se limita a accidentes visibles, sino que incluye desviaciones de flujo, comportamientos peligrosos, cierres de vías y patrones atípicos de movilidad.

En cuanto a **RQ4**, los estudios utilizan principalmente datos reales de sensores, cámaras y GPS, aunque también se identifican datasets simulados o mixtos. La diversidad de fuentes permite estudiar el problema desde diferentes perspectivas, pero también genera dificultades para la replicabilidad. La falta de benchmarks públicos, multimodales y etiquetados por expertos sigue siendo una de las principales limitaciones del campo [2].

Finalmente, **RQ5** identifica como desafíos principales la escasez de datos etiquetados, el desbalance de clases, la generalización limitada entre ciudades, la heterogeneidad de métricas y el costo computacional de modelos complejos. Estos aspectos deben ser abordados para avanzar desde modelos experimentales hacia sistemas ITS aplicables en entornos reales.

Como implicación práctica, los desarrolladores de sistemas inteligentes de transporte deberían priorizar modelos interpretables, validación en múltiples escenarios urbanos y protocolos de evaluación reproducibles [7]. Como trabajo futuro, se recomienda

construir benchmarks públicos multimodales con etiquetas verificadas, evaluar modelos transferibles entre ciudades, explorar aprendizaje federado y fortalecer el uso de técnicas explicables para apoyar la toma de decisiones operativas.

Declaraciones

Conflicto de intereses: Los autores declaran no tener conflicto de intereses.
Financiamiento: Esta investigación no recibió financiamiento externo.
Contribuciones (CRediT):

- **Mayta Arotaype, W. A.**: Conceptualización, Metodología, Curación de datos, Análisis formal, Redacción — borrador original.
- **Choquechambi Luque, W.**: Investigación, Validación, Visualización, Redacción — revisión y edición.
- **Prieto Quispe, J. E.**: Investigación, Análisis formal, Verificación de resultados, Redacción — revisión y edición.

Disponibilidad de datos: La cadena de búsqueda, los criterios de evaluación y los datos extraídos de cada estudio primario están disponibles en el repositorio del proyecto: `https://github.com/WilbertAlex/deteccion-anomalias-pems-d4`.

Referencias

[1] B. Kitchenham and S. Charters, "Guidelines for performing systematic literature reviews in software engineering," Keele University and Durham University Joint Report, Tech. Rep. EBSE 2007-001, 2007.

[2] I. Taheri Sarteshnizi, M. Sarvi, S. Asadi Bagloee, and N. Nassir, "On the applicability of time series anomaly detection methods to real-world traffic volume data," *Transportation Research Part C: Emerging Technologies*, vol. 184, p. 105536, 2026. [Online]. Available: https://www.sciencedirect.com/science/article/pii/S0968090X26000240

[3] H. Zhang, S. Zhao, R. Liu, W. Wang, Y. Hong, and R. Hu, "Automatic traffic anomaly detection on the road network with spatial-temporal graph neural network representation learning," *Wireless Communications and Mobile Computing*, vol. 2022, no. 1, p. 4222827, 2022. [Online]. Available: https://onlinelibrary.wiley.com/doi/abs/10.1155/2022/4222827

[4] S. W. Khan, Q. Hafeez, M. I. Khalid, R. Alroobaea, S. Hussain, J. Iqbal, J. Almotiri, and S. S. Ullah, "Anomaly detection in traffic surveillance videos

using deep learning," *Sensors*, vol. 22, no. 17, 2022. [Online]. Available: https://www.mdpi.com/1424-8220/22/17/6563

[5] Y. Fang, Q. Yang, L. Zheng, X. Zhou, and B. Peng, "A deep cycle limit learning machine method for urban expressway traffic incident detection," *Mathematical Problems in Engineering*, vol. 2020, no. 1, p. 5965089, 2020. [Online]. Available: https://onlinelibrary.wiley.com/doi/abs/10.1155/2020/5965089

[6] M. Duan, S. Sun, and M. Liu, "A multimodal deep fusion framework for highway traffic anomaly detection," *Scientific Reports*, vol. 15, 2025.

[7] W. Abdallah and M. Alghamdi, "AIP-Urban: Edge-enabled deep learning framework for predictive maintenance and anomaly detection in urban traffic infrastructure," *Systems*, vol. 13, no. 12, 2025. [Online]. Available: https://www.mdpi.com/2079-8954/13/12/1117

[8] S. Cai, T. Wu, J. Mao, and C. Jin, "Road closure detection based upon multi-feature fusion," in *Proceedings of the 29th International Conference on Advances in Geographic Information Systems*, ser. SIGSPATIAL '21. New York, NY, USA: Association for Computing Machinery, 2021, pp. 354–364. [Online]. Available: https://doi.org/10.1145/3474717.3483975

[9] P. Jadhav, A. Benslimane, D. Vora, and S. Patil, "Multi-stage classification of abnormal traffic events using a multi-head LSTM," *Scientific Reports*, vol. 15, no. 1, p. 1516, 2025. [Online]. Available: https://www.nature.com/articles/s41598-025-31470-8

[10] Z. Ren, X. Li, J. Peng, K. Chen, Q. Tan, X. Wu, and C. Shi, "Graph autoencoder with mirror temporal convolutional networks for traffic anomaly detection," *Scientific Reports*, vol. 14, 2024.

[11] D. Park, S.-S. Choi, D. Lim, and Y.-S. Kang, "Graph multi-resolution transformer for road traffic anomaly detection," *IEEE Access*, vol. 13, pp. 27 428–27 437, 2025.

[12] X. Huang, P. He, A. Rangarajan, and S. Ranka, "Intelligent intersection: Two-stream convolutional networks for real-time near-accident detection in traffic video," *ACM Transactions on Spatial Algorithms and Systems*, vol. 6, no. 2, 2020. [Online]. Available: https://doi.org/10.1145/3373647

[13] Y. Hu, A. Qu, and D. Work, "Detecting extreme traffic events via a context augmented graph autoencoder," *ACM Transactions on Intelligent Systems and Technology*, vol. 13, no. 6, 2022. [Online]. Available: https://doi.org/10.1145/3539735

[14] P. Mehrannia, S. S. G. Bagi, B. Moshiri, and O. A. Al-Basir, "Deep representation of imbalanced spatio-temporal traffic flow data for traffic accident detection," *IET Intelligent Transport Systems*, vol. 17, no. 3, pp. 606–619, 2023. [Online]. Available: https://ietresearch.onlinelibrary.wiley.com/doi/abs/10.1049/itr2.12287

[15] N. Chakraborty, A. Hasan, S. Liu, T. Ji, W. Liang, D. L. McPherson, and K. Driggs-Campbell, "Structural attention-based recurrent variational autoencoder for highway vehicle anomaly detection," in *Proceedings of the International Conference on Autonomous Agents and Multiagent Systems (AAMAS)*, 2023, pp. 1975–1983. [Online]. Available: https://dl.acm.org/doi/10.5555/3545946.3598868

[16] Y. Mao, Y. Shi, and B. Lu, "Detecting urban traffic anomalies using traffic-monitoring data," *ISPRS International Journal of Geo-Information*, vol. 13, no. 10, 2024. [Online]. Available: https://www.mdpi.com/2220-9964/13/10/351

[17] K. Pawar and V. Attar, "Deep learning based detection and localization of road accidents from traffic surveillance videos," *ICT Express*, vol. 8, no. 3, pp. 379–387, 2022. [Online]. Available: https://www.sciencedirect.com/science/article/pii/S2405959521001478

[18] M. Nouri and M. Ilbeigi, "A self-imputing deep multitask sequence model for traffic disruption detection in extreme conditions," *IEEE Access*, vol. 13, pp. 165 873–165 886, 2025.

[19] X. Jia, J. Qu, Y. Lyu, M. Guo, J. Zhang, and F. Guo, "A prediction-based anomaly detection method for traffic flow data with multi-domain feature extraction," *Applied Sciences*, vol. 15, no. 6, 2025. [Online]. Available: https://www.mdpi.com/2076-3417/15/6/3234

[20] Y. Chai and W. Silamu, "Road traffic anomaly detection by human-attention-assisted text–vision learning," *Sensors*, vol. 26, no. 9, 2026. [Online]. Available: https://www.mdpi.com/1424-8220/26/9/2638

[21] W. Riaz, C. Gao, A. Azeem, Saifullah, J. A. Bux, and A. Ullah, "Traffic anomaly prediction system using predictive network," *Remote Sensing*, vol. 14, no. 3, 2022. [Online]. Available: https://www.mdpi.com/2072-4292/14/3/447

[22] L. Zhao, Z. Fu, J. Yang, Z. Zhao, and P. Wang, "Multi-adjacent camera-based dangerous driving trajectory recognition for ultra-long highways," *Applied Sciences*, vol. 14, no. 11, 2024. [Online]. Available: https://www.mdpi.com/2076-3417/14/11/4593

[23] C. Wang, L. Chen, S. Shang, C. S. Jensen, and P. Kalnis, "Multi-scale detection of anomalous spatio-temporal trajectories in evolving trajectory datasets," in *Proceedings of the 30th ACM SIGKDD Conference on Knowledge Discovery and Data Mining*, ser. KDD '24. New York, NY, USA: Association for Computing Machinery, 2024, pp. 2980–2990. [Online]. Available: https://doi.org/10.1145/3637528.3671874

[24] F. I. Giasemis and A. Sopasakis, "Learning traffic anomalies from generative models on real-time observations," 2025, preprint. Excepción al criterio CE-5 declarada en la Sección 3.3 por su relevancia temática directa con la detección de anomalías de tráfico mediante modelos generativos. [Online]. Available: https://arxiv.org/abs/2502.01391

[25] D. Feng, M. Liang, and G. Wang, "A traffic anomaly detection and identification approach based on multi-instance learning," in *The 2nd International Conference on Computing and Data Science*, ser. CONF-CDS 2021. New York, NY, USA: Association for Computing Machinery, 2021. [Online]. Available: https://doi.org/10.1145/3448734.3450926

[26] Y. Lu, W. Chen, Z. Yu, J. Wang, and C. Yang, "Vehicle abnormal behavior detection based on dense block and soft thresholding," *Computers, Materials & Continua*, vol. 79, pp. 1–10, 2024.

A. Protocolo de Revisión Sistemática

Este anexo resume el protocolo aplicado en Parsifal. La búsqueda se ejecutó en seis fuentes académicas: ACM Digital Library, ISI Web of Science, ScienceDirect, Scopus, Taylor & Francis Online y MDPI. El periodo de cobertura fue 2020–2026, con estudios publicados en inglés o español, disponibles a texto completo y relacionados con detección de anomalías en tráfico vehicular mediante *Deep Learning*. El registro inicial fue de 758 estudios importados, 37 citas duplicadas eliminadas, 721 registros depurados, 77 registros candidatos y 25 estudios finales incluidos.

Cadenas de búsqueda por base de datos

Scopus:

```
("traffic anomaly detection.0R .anomaly detection.0R ïncident detection") AND ("deep learning.0R "LSTM.0R .autoencoder.0R "transformer.0R ÇonvLSTM.0R "graph neural network") AND ("time series.0R "spatio-temporal") AND (ürban traffic.0R "vehicular traffic.0R road traffic.0R ïntelligent transportation")
```

ScienceDirect:

```
(.anomaly detection.0R "traffic anomaly") AND ("deep learning.0R "neural network") AND ("time series.0R "spatio-temporal") AND (ürban traffic.0R "vehicular traffic")
```

ACM Digital Library:

```
("traffic flow.ºR ürban traffic.ºR "vehicular traffic") AND (.ªnomaly detection.ºR "traffic
anomaly.ºR ïncident detection") AND ("deep learning.ºR "LSTM.ºR .ªutoencoder.ºR "transformer")
AND ("time series.ºR "spatio-temporal")
```

ISI Web of Science:

```
(.ªnomaly detection.ºR .ºutlier detection") AND (road traffic.ºR ürban traffic.ºR "vehicular
traffic.ºR "highway traffic.ºR "traffic congestion.ºR "traffic incident") AND ("deep learning.ºR
"LSTM.ºR .ªutoencoder.ºR "transformer.ºR "graph neural network.ºR ÇonvLSTM.ºR "GRU") AND ("time
series.ºR "spatio-temporal.ºR "traffic flow.ºR "traffic speed.ºR "traffic volume")
```

MDPI:

```
((.ªnomaly detection.ºR "traffic anomaly.ºR ïncident detection.ºR çongestion detection") AND
("deep learning.ºR "neural network.ºR LSTM OR GRU OR transformer OR autoencoder) AND ("traffic
flow.ºR ürban traffic.ºR "vehicular traffic.ºR road traffic.ºR transportation))
```

Taylor & Francis Online:

```
("traffic anomaly detection.ºR .ªnomaly detection.ºR ïncident detection") AND ("deep learning.ºR
"LSTM.ºR .ªutoencoder.ºR "transformer.ºR ÇonvLSTM.ºR "graph neural network") AND ("time series.ºR
"spatio-temporal") AND (ürban traffic.ºR "vehicular traffic.ºR road traffic.ºR ïntelligent
transportation")
```

Registro de cambios del protocolo

Cuadro 13: Historial de versiones del protocolo.

Versión	Fecha	Cambio realizado
V1.0	DD/MM/AAAA	Definición inicial del tema, preguntas de investigación y PICOC.
V1.1	DD/MM/AAAA	Ajuste de cadenas de búsqueda por base de datos y normalización de términos.
V1.2	DD/MM/AAAA	Aplicación de criterios de inclusión/exclusión y depuración de duplicados en Parsifal.
V1.3	DD/MM/AAAA	Evaluación de calidad, extracción de datos y selección final de 25 estudios primarios.

B. Lista Completa de Estudios Primarios

Cuadro 14: Estudios primarios incluidos en la RSL.

ID	Autores	Título abreviado	Año	Fuente
E01	Taheri et al.	Applicability of time series anomaly detection methods	2026	ScienceDirect
E02	Abdallah & Alghamdi	AIP-Urban: Edge DL for predictive maintenance	2025	MDPI
E03	Mao et al.	Detecting urban traffic anomalies	2024	MDPI
E04	Zhang et al.	Automatic traffic anomaly detection with ST-GNN	2022	WoS
E05	Hu et al.	Detecting extreme traffic events via context graph autoencoder	2022	ACM
E06	Pawar & Attar	Deep learning based detection and localization of road accidents	2022	ScienceDirect
E07	Fang et al.	Deep cycle limit learning machine for urban expressway incident detection	2020	WoS
E08	Mehrannia et al.	Deep representation of imbalanced spatio-temporal traffic flow	2023	WoS
E09	Jadhav et al.	Multi-stage classification of abnormal traffic events	2025	Scopus
E10	Huang et al.	Intelligent intersection: two-stream CNN for near-accident detection	2020	ACM
E11	Park et al.	Graph multi-resolution transformer for road traffic anomaly detection	2025	IEEE

ID	Autores	Título abreviado	Año	Fuente
E12	Duan et al.	Multimodal deep fusion framework for highway traffic anomaly detection	2025	Scopus
E13	Cai et al.	Road closure detection based upon multi-feature fusion	2021	ACM
E14	Ren et al.	Graph autoencoder with mirror temporal convolutional networks	2024	Scopus
E15	Nouri & Ilbeigi	Self-imputing deep multitask sequence model for traffic disruption	2025	IEEE
E16	Jia et al.	Prediction-based anomaly detection with multi-domain feature extraction	2025	MDPI
E17	Chakraborty et al.	Structural attention-based recurrent VAE for highway anomaly detection	2023	arXiv
E18	Khan et al.	Anomaly detection in traffic surveillance videos using deep learning	2022	MDPI
E19	Chai & Silamu	Road traffic anomaly detection by human-attention text-vision learning	2026	MDPI
E20	Riaz et al.	Traffic anomaly prediction system using predictive network	2022	MDPI
E21	Zhao et al.	Multi-adjacent camera-based dangerous driving trajectory recognition	2024	MDPI

ID	Autores	Título abreviado	Año	Fuente
E22	Wang et al.	Multi-scale detection of anomalous spatio-temporal trajectories	2024	ACM
E23	Giasemis & Sopasakis	Learning traffic anomalies from generative models on real-time observations	2025	arXiv
E24	Feng et al.	Traffic anomaly detection and identification based on multi-instance learning	2021	ACM
E25	Lu et al.	Vehicle abnormal behavior detection based on dense block and soft thresholding	2024	Taylor & Francis

C. Formulario de Extracción de Datos

El formulario de extracción fue gestionado en Parsifal y complementado con una matriz de síntesis. Para cada estudio primario se registraron los siguientes campos: identificador, autor y año, título, fuente, país o región del dataset, objetivo del estudio, modelo de *Deep Learning*, tipo de datos, conjunto de datos utilizado, tipo de dataset, tipo de anomalía, métricas, comparación de modelos, resultado principal y limitaciones.

Cuadro 15: Estructura resumida del formulario de extracción individual.

Campo	**Contenido esperado**
Identificador	Código del estudio primario, por ejemplo E01, E02, E03.
Referencia	Autores, año, título y fuente de publicación.
Objetivo	Propósito principal del estudio y problema abordado.
Modelo de *Deep Learning*	Arquitectura utilizada: CNN, LSTM, GRU, autoencoder, Transformer, GNN, híbrido u otro.
Tipo de datos	Sensores, cámaras, GPS, series temporales, datos espacio-temporales o multimodales.
Dataset	Nombre del conjunto de datos o descripción de la fuente.
Tipo de dataset	Real, simulado o mixto.
Tipo de anomalía	Accidentes, congestión, eventos inusuales, trayectorias peligrosas, cierres de vías o patrones anómalos.
Métricas	Accuracy, Precision, Recall, F1-score, AUC-ROC, PR-AUC, FPR, latencia u otras.
Comparación	Indicación de si el estudio compara contra baselines o modelos alternativos.
Resultado principal	Hallazgo cuantitativo o cualitativo más relevante.
Limitaciones	Debilidades metodológicas, restricciones del dataset o desafíos reportados.